




Föreläsning 10

Reglerteknik AK

©Bo Wahlberg
Avdelningen för Reglerteknik, KTH

27 september, 2023






Introduktion

Förra gången:

- Observatör
- Tillståndsåterkoppling
 - ▶ Systematisk metod att konstruera en regulator så att det återkopplade systemet får "önskade" poler (polplacering)
 - ▶ Lab 2


Dagens program:

- Alternativa regulatorstrukturer




Liknar tillståndsåterkoppling

Example



$$\begin{cases} \theta & : \text{tippvinkel} \\ \dot{\theta} = q & : \text{tipphastighet} \end{cases}$$

Rategyroåterkoppling:



Example (DC-motor)


$$G_A = \frac{1}{s+1}, \quad G_B = \frac{1}{s}$$

P-reglering: $F_A = K_A, \quad F_B = K_B$

Inre loopen: $Y_A = \frac{K_A}{s+1+K_A} R_A$

Välj stort K_A (t.ex. mer än 5 gånger snabbare än yttre loopen)

$$\Rightarrow Y_A \approx 1 \cdot R_A$$




Example (DC-motor, fort.)

$$\Rightarrow Y = \frac{K_B}{s + K_B} R, \text{ välj } K_B < \frac{1 + K_A}{5}$$

Analys:

$$Y = \frac{K_A K_B}{s^2 + (K_A + 1)s + K_A K_B} R$$

$L \sim [K_A \ K_B]$, så polerna kan placeras var som helst.



$$Y = G_2 [HV + G_1(R + F_f V)] =$$

$$= G_2 \left[\underbrace{(H + G_1 F_f)}_{\text{sätt} = 0} V + G_1 R \right]$$

Eliminera inverkan av v genom att välja $H + G_1 F_f = 0$:

$$\Rightarrow F_f = -\frac{H}{G_1}$$



Example

Antag att vi har

$$\begin{cases} G_1 &= \frac{1}{s+1} \\ H &= 1 \end{cases}$$

I så fall gess framkopplingen av

$$F_f = -(s + 1)$$



Framkoppling

Man kan dock stöta på problem med att derivera signaler.



En lösning är att approximera F_f , t.ex. genom att ta

$$F_f(0) = -\frac{H(0)}{G_1(0)}$$

för att eliminera inverkan av v i stationärt tillstånd.


Kombinera med återkoppling!

Example (Klimatreglering från Föreläsning 1)



Vänta ej på att det blir kallt inne!

Otto Smith regulatorn



Detta sker exempelvis i en pappersmaskin där man kan mäta tjockleken först efter torkpartiet (= 800 m papper).

$$G_T(s) = e^{-sT}$$

Vi ser att

$$|G_T(e^{i\omega})| = 1, \quad \arg [G_T(e^{i\omega})] = -\omega T$$

Negativ fasförskjutning $\Rightarrow$ Försämrar fasmarginalen (svårt att reglera)



Specialregulator

Steg 1:

Antag $T = 0$ och bestäm $\bar{F}$ så att

$$G_c^d(s) = \frac{\bar{F}(s)G_2(s)}{1 + \bar{F}(s)G_2(s)}$$

får bra egenskaper.

Steg 2:

Använd regulatorn

$$F(s) = \frac{\bar{F}(s)}{1 + (1 - e^{-sT})\bar{F}(s)G_2(s)}$$

$$\Rightarrow G_c(s) = \frac{G(s)F(s)}{1 + G(s)F(s)} = \frac{\bar{F}(s)G_2(s)}{1 + \bar{F}(s)G_2(s)}e^{-sT}$$

Identisk med $G_c^d(s)$ så när som tidsfördröjningen. Observera dock att man använder sig av en känd modell (T och G_2) i regulatorn.

Fasavancering: Nära ω_c


$$\Rightarrow \bar{F}(i\omega)G_2(i\omega) \approx -1$$

$$\Rightarrow F(i\omega) \approx e^{+i\omega T}\bar{F}(i\omega)$$

Prediktion av signaler med frekvens nära ω_c .

Internal Model Control

Finns ej i boken, men i kompendie på kurshemsidan.



$$U = \bar{Q} \left[\underbrace{R - Y}_E + G_m U \right] \Rightarrow$$

$$U = \frac{\bar{Q}}{1 - \underbrace{\bar{Q} G_m}_{F, \text{ vanlig regulator}}} E$$

$y_m = y$ om man ej har modellfel eller störningar $\Rightarrow$
Öppen styrning $G_c = G\bar{Q}$!

Otto Smith:

$$\bar{Q} = \frac{\bar{F}}{1 + \bar{F}G_2} \quad (\approx \frac{1}{G_2})$$

$$\Rightarrow G_c = \frac{\bar{F}G_2}{1 + \bar{F}G_2} e^{-sT} \quad (\approx e^{-sT})$$

$$\Rightarrow F = \frac{\bar{Q}}{1 - \bar{Q}G_m} \quad (= \text{"Otto Smith"})$$

$$\text{Allmänt är } \bar{Q} \approx \underbrace{1/\tilde{G}} \times G_c^d \Rightarrow G_c = G_c^d \frac{G}{\tilde{G}}$$

Det som går att invertera av G

där G_c^d är önskat slutet system (som man inte alltid kan uppnå)
Tidsfördröjningar och instabila nollställen kan inte förkortas bort!

Example

Otto-Smith

$$G = G_2 e^{-sT} \Rightarrow \bar{Q} = \frac{\bar{F}}{1 + \bar{F}G_2} = \frac{G_c^d}{G_2}$$

Example

$$G_m = \frac{\bar{k}_m}{\bar{\tau}_m s + 1}, \quad G_c^d = \frac{1}{\lambda s + 1}$$

$$\bar{Q} = \frac{G_c^d}{G_m} \Rightarrow F = \frac{\bar{\tau}_m s + 1}{\bar{k}_m \lambda s}$$

Enkel inställning av PI- regulator med

$$K = \frac{\tau_m}{\bar{k}_m \lambda}, \quad T_I = \tau_m$$

Med

$$G_m = \frac{\bar{k}_m}{(\bar{\tau}_1 s + 1)(\bar{\tau}_2 s + 1)}, \quad G_c^d = \frac{1}{\lambda s + 1}$$

Enkel inställning av PID- regulator, se kompendie.



Internal Model Control

Nackdelar:

- Klarar ej instabila system, "öppen styrning"
- Känslig för störningar

Perfekt reglering $G_c = 1 \cdot e^{-sT}$.

Känslighetsfunktion $S(i\omega) = 1 - e^{-i\omega T}$.

Observera att $S(i\omega) = 1 - (-1) = 2$ då $\omega = \frac{\pi}{T}$

Förstärker störningar $\omega \approx \frac{\pi}{T}$.

Fundamentalt svårt problem!

Minska ω_c relativt T !

EL2520 Reglerteknik, fortsättningskurs i Period 4!



Andra svårare reglerproblem

Svårare reglerproblem:

- Nollställena i H.H.P. (icke-minimumfassystem)

Example


$$\underbrace{\frac{1}{s+1}}_{\text{långsamt}} - \underbrace{\frac{2}{s+10}}_{\text{snabb}} = \frac{(-s+8)}{(s+1)(s+10)} = \frac{(s+8)}{(s+1)(s+10)} \left[\underbrace{\frac{(-s+8)}{(s+8)}}_{\text{negativ fasvridning}} \right]$$

Jämför med

$$e^{-\frac{s}{4}} = \frac{e^{-s/8}}{e^{s/8}} \approx \frac{1 - \frac{s}{8}}{1 + \frac{s}{8}}$$

Andra Reglerproblem


- Multivariabla system
 - ▶ Flera in- och utsignaler $\Rightarrow$ Regler FK och Optimering (optimal reglering)
- Tidsvariabla system med gain-scheduling



F ändras mha yttre variabler $p(t)$

Exempelvis på flygbanor.

- Adaptiv reglering



F ändras mha skattad modell

- Autotuning ("adaptiv reglering under uppstart")
- Förstärkande inlärning (Reinforcement Learning)



Super Human AI, Deep Learning,...

AlphaGo, Pluribus (poker), **Iuffarschack**, ...



- Möjligt att analysera alla möjliga spel
- Perfekt information
- Fungerar Reinforcement Learning (EL2805)?
- Lär dig vinna genom att spela (utan att tänka)
- Det blir alltid oavgjort om båda spelar optimalt



Reinforcement Learning

Trade-off between exploration and exploitation

- **A policy** is a mapping from perceived states of the environment to actions to be taken when in those states
- **A reward signal** defines the goal in a reinforcement learning problem. On each time step, the environment sends to the reinforcement learning agent a single number, a reward. The reward signal indicates what is good in an immediate sense (win, lose or tie one game)
- **The value function** specifies what is good in the long run (over many games)

Reinforcement Learning: An Introduction by Richard S. Sutton and Andrew G. Barto

Kurs EL2805 Reinforcement Learning



Gör som vanligt eller testa nya idéer (ibland)

- Belöning: +100 för en godkänd tenta
- -1000 för en missad tenta
- **Policy:** Till exempel, lär dig varje sida i boken utantill, lös alla övningsuppgifter, memorera alla gamla tentor,..
- Det är för mycket arbete, det måste finnas ett enklare sätt!
- Läs kursinformationen, man får ha boken på tentan, gå på övningar, räknestugor, ..



Optimal Reglering

Example

$$\dot{y}(t) = -ay(t) + bu(t)$$

Minimera kostnadsfunktionen (ändlig horisont) med avseende på insignal

$$J = \int_0^t [y^2(\tau) + q_1 u^2(\tau)] d\tau + q_2 y^2(t)$$

Kostnadsfunktion (oändlig horisont)

$$J = \int_0^\infty [y^2(\tau) + qu^2(\tau)] d\tau$$

Linjärkvadratisk (LQ) optimeringsproblem med analytisk lösning (se boken)

$$u(t) = -K(t)y(t)$$

$$u(t) = -Ky(t), \quad \text{oändlig horisont}$$



Model Predictive Control

Minimera

$$J = \int_t^{t+\Delta} [y^2(\tau) + q_1 u^2(\tau)] d\tau + q_2 y^2(t + \Delta)$$

med bivillkor

$$|y(t)| \leq \epsilon_y \quad |u(t)| \leq \epsilon_u, \quad \forall t$$

Konvext optimeringsproblem med unik lösning.

MPC: Använd bara den optimala lösningen $u(t)$ $t \leq t + \delta$ och räkna sedan fram en ny lösning vid nästa tidpunkt $t \mapsto t + \delta$

Lättare för samplade system (Föreläsning 11)

Kurs EL2700 Model Predictive Control