



Avd. Matematisk statistik

KTH Matematik

TENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS FREDAG 21 OKTOBER 2022, 08:00–13:00.

Examinator: Liam Solus, 072-566 04 80.

Tillåtna hjälpmedel: miniräknare, formelsamling (utan anteckningar)

Tentamen består av två delar: del I och del II. Del I består av uppgift 1–12 där varje uppgift är värd en poäng var. I denna del behöver du bara ge ett svar på den bifogade svarsblanketten och använd minst tre värdesiffror för numeriska svar. Studenter som fått godkänt på kontrollskrivningen behöver inte svara uppgifter 1–3 och kan tillgodoräkna sig dessa uppgifter. (Denna gäller bara för denna tentamen och omtentamen för denna kursomgång.) För att få godkänt på tentamen krävs minst 9 poäng på del I. Möjlighet till komplettering ges för 8 poäng på del I.

Del II av tentamen består av uppgift 13–16 där varje uppgift är värd 10 poäng. Denna del rättas bara för studenter som är godkända eller får komplettera på del I. Poängen på del II krävs för att få högre betyg än E. På denna del ska resonemang och uträkningar skall vara så utförliga och väl motiverade att de är lätta att följa. Införda beteckningar skall förklaras och definieras och numeriska svar skall anges med minst två värdesiffrors noggrannhet. För studenter som fick bonuspoäng på inlämningsuppgiften läggs dessa poäng till poängsumman för del II. (Detta gäller bara för denna tentamen och omtentamen för denna kursomgång.)

Tentamen kommer att vara rättad inom tre arbetsveckor från skrivningstillfället och kommer att finnas tillgänglig på studentexpeditionen minst sju veckor efter skrivningstillfället.

Del I

Uppgift 1

Låt $\mathbf{X} = (X_1, X_2, X_3, X_4) \sim N(\mathbf{0}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 1 & 2 & 1 & 9 \\ 2 & 5 & 2 & 21 \\ 1 & 2 & 2 & 12 \\ 9 & 21 & 12 & 100 \end{bmatrix}.$$

Vilken av följande stämmer?

- (a) $X_2 \perp\!\!\!\perp X_4$,
- (b) $X_2 \perp\!\!\!\perp X_3 \mid X_1$,
- (c) $X_3 \perp\!\!\!\perp X_4 \mid X_1$,
- (d) inget av ovanstående alternativ.

Uppgift 2

Antag att $x_1, x_2, \dots, x_n$ är ett slumpmässigt stickprov från en Laplacefördelning med täthetsfunktion

$$f_X(x) = \frac{1}{2\sigma} e^{-|x|/\sigma},$$

där $\sigma > 0$ är känd. Vilken av följande är en tillräcklig statistika för σ ?

- (a) $\sum_{i=1}^n x_i$,
- (b) $\sum_{i=1}^n |x_i|$,
- (c) $\sum_{i=1}^n x_i^2$,
- (d) $\sum_{i=1}^n \log x_i$.

Uppgift 3

Låt X_1, X_2 vara oberoende och $\text{Po}(\lambda - 3)$ -fördelade. Bestäm ML-skattningen för $\tau(\lambda) = \frac{\lambda}{1+\lambda}$ givet datan $x_1 = 7, x_2 = 6$.

Uppgift 4

Låt $X \mid \Theta = \theta \sim N(\theta, 1)$ och $\Theta \sim N(2, 2)$. Bestäm ett 0.95 symmetriskt kredibilitetsintervall för θ givet datan $X = 0.14$.

Uppgift 5

Antag att följande data observeras från en $U(a, b)$ -population:

4.46 5.83 5.59 3.56

Skatta a med hjälp av momentmetoden.

- (a) 3.28,
- (b) 3.56,
- (c) -3.70,
- (d) 1.98,
- (e) inget av de ovanstående.

Uppgift 6

Låt $X_1, X_2, \dots$ vara oberoende och $\text{Beta}(\alpha, 4)$ -fördelade. Vi skattar α med punktskattningen $W_n(\mathbf{X}) = (4\bar{X}_n)/(1 - \bar{X}_n)$ där vi vet att

$$\sqrt{n} \left(\bar{X}_n - \frac{\alpha}{\alpha + 4} \right) \longrightarrow N \left(0, \frac{4\alpha}{(\alpha + 4)^2(\alpha + 5)} \right).$$

Vilke av följande är den approximativa fördelningen för $W_n(\mathbf{X})$ när n är stort (som en funktion av n och α)?

- (a) $N \left(\alpha, \frac{\alpha^2}{4n(\alpha+4)(\alpha+5)} \right)$
- (b) $N \left(\alpha, \frac{\alpha(\alpha+4)}{n(\alpha+5)} \right)$
- (c) $N \left(\alpha, \frac{4\alpha(\alpha+4)}{n(\alpha+5)} \right)$
- (d) $N \left(\alpha, \frac{\alpha(\alpha+4)^2}{4n(\alpha+5)} \right)$
- (e) inget av ovanstående

Uppgift 7

Låt X_1, X_2, X_3, X_4, X_5 vara oberoende och likafördelade med täthetsfunktionen $f_{X_i}(x_i | \theta)$. Anta att vi har ett test med nivå $\alpha = 0.05$

$$\text{Förkasta } H_0 \text{ om } \bar{x} \leq \theta_0 - 0.78s^2/\sqrt{5}$$

för

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta < \theta_0$$

där $\bar{x}$ och s^2 är stickprovsväntevärdet respektive stickprovsvariansen. Beräkna ett 0.95 ensidigt konfidensintervall för θ givet datan:

$$-0.12 \quad -1.09 \quad 0.18 \quad 0.35 \quad 0.34.$$

Uppgift 8

Låt $X|\Theta = \theta \sim \text{Exp}(\theta)$ och $\Theta \sim \text{Gamma}(1, 1)$. Vilken av följande är den aposterioriprediktiva fördelningen $f_{Y|X}(y|x)$ given datan $X = 2$?

- (a) $f_{Y|X}(y|x) = \frac{18}{(y+3)^3},$
- (b) $f_{Y|X}(y|x) = \frac{18}{(y+3)^4},$
- (c) $f_{Y|X}(y|x) = \frac{24}{(y+2)^4},$
- (d) $f_{Y|X}(y|x) = \frac{24}{(y+2)^3},$
- (e) inget av ovanstående alternativ.

Uppgift 9

Vi observerar följande data

$$-0.86 \quad 1.62 \quad -1.68 \quad -1.22.$$

Anta att observationerna är betingat oberoende givet parametrarna Θ_M, Θ_V och har samma betingade fördelning $X \mid \Theta_M = \theta_M, \Theta_V = \theta_V \sim N(\theta_M, \theta_V)$. Beräkna aposteriorivariansen för Θ_M givet den icke-informativa apriorifördelningen $f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) = 1/\theta_V$.

Uppgift 10

Antag att vi vill simulera ett utfall från Wigners halvcirkelfördelning med täthetsfunktion

$$f_X(x) = \frac{2}{\pi r^2} \sqrt{r^2 - x^2},$$

för $x \in [-r, r]$ och $r > 0$. (Denna fördelning uppkommer bland annat som fördelningen av egenvärden hos vissa slumpmatriser då deras dimension går mot oändligheten.) Om vi använder förkastelsemetoden med $U(-r, r)$ som kandidatfördelning, bestäm antalet förväntade iterationer när $r = 2$.

Uppgift 11

En lektor rättar tentamenskrivningar varje år och noterar tiden detta tar:

År	Antal skrivningar	Tid (minuter)
2019	34	1136
2020	10	181
2021	29	1575

Han börjar rätta årets skrivningar och det tar 162 minuter att rätta de tre första. Antag att tiden att rätta en skrivning kan modelleras med en exponentialfördelning med en okänd parameter. Använd den empiriska bayesmetoden med en konjugerad apriorifördelning för att ta fram aposterioriväntevärdet för parametern.

Uppgift 12

Antag att följande data observeras från en $N(\theta, 3^2)$ -population med apriorifördelning $\Theta \sim N(0, 4^2)$:

$$1.13 \quad -0.93 \quad 3.09 \quad 1.65 \quad -0.39$$

Beräkna aposteriorioddset för $H_0 : \theta < 0$ med avseende på $H_1 : \theta > 0$.

Del II

Uppgift 13

Låt $W \sim \text{Gamma}(\alpha, \beta)$ och låt $Z = W - 0.5$.

- (a) Visa att familjen $\{f_Z(z \mid \alpha, \beta) : \alpha, \beta > 0\}$ bildar en exponentialfamilj. (3 p)
- (b) Låt $\alpha = 2$ och $Z_1, \dots, Z_n$ vara oberoende och likafördelade med täthetsfunktion från familjen i del (a). Visa att statistikan $T(\mathbf{Z}) = \frac{2\bar{Z}+1}{4}$ är en väntevärdesriktig skattning av $\tau(\beta) = \frac{1}{\beta}$. (3 p)
- (c) Låt $\alpha = 2$. Visa att statistikan $T(\mathbf{Z})$ från del (c) uppnår Cramér–Raos undre gräns. (4 p)

Uppgift 14





Låt $X \sim \chi^2(n)$ och $Y \sim \chi^2(m)$ där $X \perp\!\!\!\perp Y$. Ta fram täthetsfunktionen för

$$\frac{X/n}{Y/m}.$$

Ditt svar ska vara så förenklat som möjligt. (10 p)

Uppgift 15

Låt $(X_1, X_2, X_3, X_4) \sim N(\mathbf{0}, \Sigma)$ där vi vet att de enda oberoenderelationerna som uppfylls är $X_1 \perp\!\!\!\perp X_4 \mid \mathbf{X}_{\{2,3\}}$ och $X_2 \perp\!\!\!\perp X_3 \mid \mathbf{X}_{\{1,4\}}$. Betrakta följande acykliska riktade grafer:



- (a) Vilka grafer $\mathcal{G}_1, \mathcal{G}_2, \mathcal{G}_3, \mathcal{G}_4$ är (X_1, X_2, X_3, X_4) markovsk med avseende på? (Det kan finnas fler än en.) (4 p)
- (b) För graferna $\mathcal{G}_2$ och $\mathcal{G}_4$, bestäm antalet grafer i dess markovekvivalensklass. (4 p)
- (c) Låt $\hat{\Sigma}_{\mathcal{G}_i}$ beteckna ML-skattningen för Σ begränsat till alla Σ för vilken $(X_1, X_2, X_3, X_4) \sim N(\mathbf{0}, \Sigma)$ är markovsk till $\mathcal{G}_i$. Givet 1000 oberoende utfall från (X_1, X_2, X_3, X_4) ficks dessa till

$$\log L(\hat{\Sigma}_{\mathcal{G}_1} | \mathbf{x}) = -0.28,$$

$$\log L(\hat{\Sigma}_{\mathcal{G}_2} | \mathbf{x}) = -1.22,$$

$$\log L(\hat{\Sigma}_{\mathcal{G}_3} | \mathbf{x}) = -0.30,$$

$$\log L(\hat{\Sigma}_{\mathcal{G}_4} | \mathbf{x}) = -1.67.$$

Vilken graf föredras enligt AIC? Enligt BIC? (*Ledning:* För dessa modeller är antalet parametrar lika med antalet kanter i grafen.) (2 p)

Uppgift 16

Maria ser över uppvärmningen av sitt hus innan den kommande vintern. En ny luft/luftvärmepump kostar 21 700 kr och drar 21.6 kWh per grad Celsius och månad. Hennes nuvarande elradiatorer drar 65.9 kWh per grad Celsius och månad.

För att bestämma om det är värt kostnaden att installera en värmepump slår hon upp medeltemperaturen för hennes område under de fyra vintermånaderna november–februari de senaste fem åren. Hon får följande temperaturer:

År	2017–2018	2018–2019	2019–2020	2020–2021	2021–2022
Temperatur (°C)	1.2	4.3	1.3	−6.4	−2.7

Vi antar att dessa mätningar är normalfördelade med avseende på den underliggande okända temperaturparametern och att årsvariationen har en standardavvikelse på 5 °C.

- (a) Sätt upp en bayesiansk modell för datan med apriorifördelning för temperaturparametern som har väntevärde noll och standardavvikelse 10 °C. Ta fram aposteriorifördelningen. (2 p)
- (b) Maria vill minimera uppvärmningskostnaderna under vintermånaderna över en treårsperiod. Hon har tre alternativ:
 - (a₁) Behåll elradiatorerna och värm huset till 20 °C.
 - (a₂) Behåll elradiatorerna och värm huset till 18 °C.
 - (a₃) Installera en värmepump och värm huset till 20 °C.

Anta att hon har bundit elpriset på 3 kr/kWh. Anta vidare att medeltemperaturerna för var och en av de kommande tre vintrarna utgör nya oberoende utfall av din modell. För varje alternativ, ta fram ett intervall så att den totala kostnaden för uppvärmning under dessa tre vintrar ligger i intervallet med 95% sannolikhet. (6 p)

- (c) Beräkna bayesbeslutet med avseende på kostnaden över de närmaste tre åren. (2 p)

Lycka till!



Avd. Matematisk statistik

KTH Matematik

LÖSNINGAR TILL TENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS

Uppgift 1

$\mathbf{X}_A \perp \mathbf{X}_B | \mathbf{X}_C$ om och endast om $\text{Cov}[\mathbf{X}_A, \mathbf{X}_B | \mathbf{X}_C] = \mathbf{0}$. Så kan vi se att $X_2 \not\perp X_4$ eftersom $\sigma_{2,4} = 21 \neq 0$. Det följer att svaret är inte (a).

För (b), vi beräkna kovariansmatrisen för $\mathbf{X}_{2,3} | X_1 = x_1 \sim N(\mathbf{0}, \Sigma')$ där

$$\begin{aligned}\Sigma' &= \Sigma_{\{2,3\},\{2,3\}} - \Sigma_{\{2,3\},\{1\}} \Sigma_{\{1\},\{1\}}^{-1} \Sigma_{\{1\},\{2,3\}}, \\ &= \begin{bmatrix} 5 & 2 \\ 2 & 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 1 \end{bmatrix} \begin{bmatrix} 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \end{bmatrix}, \\ &= \begin{bmatrix} 5 & 2 \\ 2 & 2 \end{bmatrix} - \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}, \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.\end{aligned}$$

Eftersom $\sigma'_{1,2} = 0$ följer det att $X_2 \perp X_3 | X_1$. Därför är svaret (b).

Uppgift 2

Tillräcklig statistika är $\sum_{i=1}^n |x_i|$, så rätt svar är (b).

Uppgift 3

Log-likelihoodfunktionen är

$$\begin{aligned}\log L(\theta | \mathbf{x}) &= \log \prod_{i=1}^2 \frac{e^{-(\lambda-3)} (\lambda-3)^{x_i}}{x_i!}, \\ &= -2(\lambda-3) + (x_1 + x_2) \log(\lambda-3) - \sum_{i=1}^2 \log(x_i!).\end{aligned}$$

Det följer att

$$\begin{aligned}\frac{d}{d\lambda} \log L(\theta | \mathbf{x}) &= -2 + \frac{x_1 + x_2}{\lambda - 3}, \\ 0 &:= -2 + \frac{x_1 + x_2}{\lambda - 3}, \\ \lambda - 3 &= \bar{x}, \\ \hat{\lambda} &= \bar{x} + 3.\end{aligned}$$

Vi har att $\bar{x} = \frac{1}{2}(7 + 6) = \frac{13}{2}$. Med hjälp av invariansen för ML-skattningar har vi att

$$\tau(\hat{\lambda}) = \tau(\hat{\lambda}) = \frac{\bar{x} + 3}{1 + \bar{x} + 3} = \frac{\bar{x} + 3}{\bar{x} + 4} = \frac{(13/2) + 3}{(13/2) + 4} = \frac{19}{21} \approx 0.90476.$$

Uppgift 4

Vi har från formelsamlingen att

$$\Theta|X = x \sim N\left(\frac{\frac{\mu}{\tau^2} + \frac{x}{\sigma^2}}{\frac{1}{\tau^2} + \frac{1}{\sigma^2}}, \frac{1}{\frac{1}{\tau^2} + \frac{1}{\sigma^2}}\right) = N(0.76, 2/3)$$

där $\sigma^2 = 1$, $\mu = 2$ och $\tau^2 = 2$. När $Y \sim N(0.76, 2/3)$ följer det att

$$Z = \frac{Y - 0.76}{\sqrt{2/3}} \sim N(0, 1)$$

och vi har att

$$P(-\lambda_{0.025} < Z < \lambda_{0.025}) = 0.95.$$

Det följer att

$$\begin{aligned} 0.90 &= P(-1.96 < Z < 1.96), \\ &= P\left(-1.96 < \frac{Y - 0.76}{\sqrt{2/3}} < 1.96\right), \\ &= P\left(-1.96\sqrt{2/3} + 0.76 < Y < 1.96\sqrt{2/3} + 0.76\right). \end{aligned}$$

Därför ett 0.95 symmetriskt kredibilitetsintervall för θ är

$$[-1.96\sqrt{2/3} + 0.76, 1.96\sqrt{2/3} + 0.76] = [-0.84033, 2.36033].$$

Uppgift 5

Från datan har vi

$$\frac{1}{4} \sum_{i=1}^4 x_i = 4.86 \quad \text{och} \quad \frac{1}{4} \sum_{i=1}^4 x_i^2 \approx 24.451,$$

vilket i sin tur ger

$$\frac{1}{4} \sum_{i=1}^4 (x_i - \bar{x})^2 = 24.451 - 4.86^2 = 0.8314.$$

Formelsamlingen ger

$$E[X] = \frac{a+b}{2} \quad \text{och} \quad \text{Var}[X] = \frac{(b-a)^2}{12}.$$

Sätter vi $E[X] = 4.86$ och $\text{Var}[X] = 0.8314$ får vi

$$a + b = 9.72 \quad \text{och} \quad b - a = \sqrt{12 \cdot 0.8314} \approx 3.1586.$$

Med andra ord har vi

$$a = \frac{9.72 - 3.1586}{2} \approx 3.281.$$

Uppgift 6

Deltametoden där $g(z) = \frac{4z}{1-z}$ och $g'(z) = \frac{4}{(1-z)^2}$ ger oss

$$\sqrt{n} \left(g(\bar{X}_n) - g\left(\frac{\alpha}{\alpha+4}\right) \right) \longrightarrow N \left(0, g' \left(\frac{\alpha}{\alpha+4} \right)^2 \frac{4\alpha}{(\alpha+4)^2(\alpha+5)} \right),$$

eller motsvarande

$$\sqrt{n}(W_n - \alpha) \longrightarrow N \left(0, \frac{(\alpha+4)^4}{16} \frac{4\alpha}{(\alpha+4)^2(\alpha+5)} \right),$$

eller

$$\sqrt{n}(W_n - \alpha) \longrightarrow N \left(0, \frac{\alpha(\alpha+4)^2}{4(\alpha+5)} \right).$$

Därför

$$W_n \approx N \left(\alpha, \frac{\alpha(\alpha+4)^2}{4n(\alpha+5)} \right).$$

Uppgift 7

Testet accepterar H_0 om $\bar{x} \geq \theta - 0.78s^2/\sqrt{5}$. Eftersom testet har nivå $\alpha = 0.05$ har testet acceptanssannolikheten

$$P(\bar{X} \geq \theta_0 - 0.78s^2/\sqrt{5} | \theta_0) \geq 0.95.$$

När vi ordna om denna får vi

$$P(\bar{X} + 0.78s^2/\sqrt{5} \geq \theta_0 | \theta_0) \geq 0.95.$$

Därför är ett 0.95 ensidigt konfidensintervall för θ

$$(-\infty, \bar{x} + 0.78s^2/\sqrt{5}] \approx (-\infty, 0.033151],$$

eftersom $\bar{x} = -0.068$ och $s^2 = 0.289976$ för givet datan.

Uppgift 8

Vi ser från formelsamlingen att aposteriorifördelningen är

$$\Theta | X = 2 \sim \text{Gamma}(1+1, 1+2) = \text{Gamma}(2, 3).$$

Det följer att den aposteriori prediktiva fördelningen är

$$\begin{aligned}
 f_{Y|X}(y|x) &= \int f_{Y|\Theta}(y|\theta) f_{\Theta|X}(\theta|x) d\theta, \\
 &= \int_0^\infty \theta e^{-\theta y} \frac{3^2}{\Gamma(2)} \theta^{2-1} e^{-3\theta} d\theta, \\
 &= 9 \int_0^\infty \theta^2 e^{-\theta(3+y)} d\theta \\
 &= 9 \int_0^\infty \left(\frac{t}{(3+y)} \right)^2 e^t \frac{dt}{(3+y)}, \quad (t = \theta(3+y)) \\
 &= \frac{9}{(3+y)^3} \int_0^\infty t^2 e^{-t} dt, \\
 &= \frac{9\Gamma(3)}{(3+y)^3}, \\
 &= \frac{18}{(3+y)^3}.
 \end{aligned}$$

Uppgift 9

Datan ger $\bar{x} = -0.535$ och $s^2 = 2.1766$. Formelsamlingen ger då att

$$\Theta_M, \Theta_V \mid \mathbf{X} = \mathbf{x} \sim \text{NInvGamma}(-0.535, 4, 1.5, 1.5 \cdot 2.1766).$$

Vi är intresserade av Θ_M , vars marginella aposteriorifördelning fås från formelsamlingen till

$$\Theta_M \mid \mathbf{X} = \mathbf{x} \sim t(2 \cdot 1.5, -0.535, 1.5 \cdot 2.1766 / (4 \cdot 1.5)) = t(3, -0.535, 0.5442).$$

Vi har då

$$\text{Var}[\Theta_M \mid \mathbf{x} = \mathbf{x}] = \frac{3}{3-2} \cdot 0.5442 \approx 1.6326.$$

Uppgift 10

$$m = \sup_{x \in [-2, 2]} \frac{\frac{2}{4\pi} \sqrt{4-x^2}}{\frac{1}{4}} = 4 \frac{1}{2\pi} \sqrt{4} = \frac{4}{\pi} \approx 1.273.$$

Uppgift 11

För de tre åren får vi skattningarna $\hat{\theta}_1 = 0.02993$, $\hat{\theta}_2 = 0.05525$ och $\hat{\theta}_3 = 0.01841$ enligt momentmetoden. Om vi ansätter en gammafördelning som apriorifördelning får vi att dess parametrar är $\alpha = 5.037$ och $\lambda = 145.9$, detta också enligt momentmetoden. Med tre observationer på totalt 162 minuter har vi då aposteriorifördelningen $\text{Gamma}(5.037 + 3, 145.9 + 162) = \text{Gamma}(8.037, 307.9)$, vilket ger ett aposterioriväntevärde på $8.037/307.9 \approx 0.0261$.

Uppgift 12

Eftersom $\bar{x} = 0.91$ och $n = 5$ har vi enligt formelsamlingen

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{N}(0.8170, 1.6180),$$

vilket ger

$$P(\Theta < 0 \mid \mathbf{X} = \mathbf{x}) = P(0.8180 + Z\sqrt{1.6180} < 0) = P(Z < -0.643) = 1 - P(Z < 0.643)$$

för $Z \sim N(0, 1)$. Slår vi upp detta i tabellen får vi sannolikheten $1 - 0.7389 = 0.2611$. Aposterioroddset är därför

$$\frac{0.2611}{1 - 0.2611} \approx 0.353.$$

Uppgift 13

(a) Vi har att $W = Z + 0.5$ och därför $\frac{dW}{dz} = 1$. Det följer att

$$\begin{aligned} f_Z(z|\alpha, \beta) &= 1 \cdot f_W(z + 0.5), \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} (z + 0.5)^{\alpha-1} e^{-\beta(z+0.5)}, \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} \exp(\log((z + 0.5)^{\alpha-1} e^{-\beta(z+0.5)})), \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} \exp((\alpha - 1) \log(z + 0.5) - \beta(z + 0.5)). \end{aligned}$$

Det följer att $f_Z(z|\alpha, \beta)$ är i en exponentialfamilj där

$$h(z) = 1, \quad c(\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)},$$

$$w_1(\alpha, \beta) = \alpha - 1, \quad t_1(z) = \log(z + 0.5), \quad w_2(\alpha, \beta) = \beta, \quad t_2(z) = -(z + 0.5).$$

(b) För att se att $T(\mathbf{Z})$ är väntevärdesriktig måste vi visa att $E[T(\mathbf{Z})] = \frac{1}{\beta}$. Det följer eftersom

$$\begin{aligned} E[T(\mathbf{Z})] &= E\left[\frac{2\bar{Z} + 1}{4}\right], \\ &= \frac{2E[\bar{Z}] + 1}{4}, \\ &= \frac{2E[Z] + 1}{4}, \\ &= \frac{2E[W - 0.5] + 1}{4}, \\ &= \frac{1}{2}E[W] - \frac{1}{4} + \frac{1}{4}, \\ &= \frac{1}{2\beta}, \\ &= \frac{1}{\beta}. \end{aligned}$$

(c) Cramér-Rao nedra gränsen är $\frac{\tau'(\beta)^2}{J(\beta)}$ där $\tau(\beta) = 1/\beta$, $\tau'(\beta) = -1/\beta^2$ och

$$J(\beta) = -n E\left[\frac{d^2}{d\beta^2} \log f_Z(z|\beta)\right].$$

Vi har att

$$\begin{aligned}\frac{d^2}{d\beta^2} \log f_Z(z|\beta) &= \frac{d^2}{d\beta^2} (2 \log(\beta) - \log(\Gamma(2)) + \log(z + 0.5) - \beta(z + 0.5)), \\ &= -\frac{2}{\beta^2}.\end{aligned}$$

Det följer att $J(\beta) = \frac{2n}{\beta^2}$. Därför är Cramér-Rao nedre gränsen $\frac{1}{2n\beta^2}$.

För att se att $T(\mathbf{Z})$ uppnår nedre gränsen beräknar vi

$$\begin{aligned}\text{Var}[T(\mathbf{Z})] &= \text{Var}\left[\frac{2\bar{Z} + 1}{4}\right], \\ &= \frac{1}{4} \text{Var}[\bar{Z}], \\ &= \frac{1}{4} \frac{\text{Var}[Z]}{n}, \\ &= \frac{1}{4} \frac{\text{Var}[W - 0.5]}{n}, \\ &= \frac{1}{4} \frac{\text{Var}[W]}{n}, \\ &= \frac{1}{4n} \frac{2}{\beta^2}, \\ &= \frac{1}{2n\beta^2}.\end{aligned}$$

Uppgift 14

Först skalar vi om variablerna och får $U = X/n$ och $V = Y/m$ med täthetsfunktioner

$$f_U(u) = \frac{n^{n/2} \Gamma(n/2) 2^{n/2-1}}{u} e^{-nu/2}$$

och

$$f_V(v) = \frac{m^{m/2} \Gamma(m/2) 2^{m/2-1}}{v} e^{-mv/2}.$$

Variabelbytet $Z = U/V, W = V$ har invers $U = ZW, V = W$, vilket ger jakobideterminanten

$$\left| \begin{bmatrix} w & z \\ 0 & 1 \end{bmatrix} \right| = w.$$

Vi har alltså den simultana täthetsfunktionen (eftersom $X \perp Y \Rightarrow U \perp V$)

$$\begin{aligned}f_{Z,W}(z, w) &= \frac{n^{n/2}}{\Gamma(n/2) 2^{n/2}} (zw)^{n/2-1} e^{-nzw/2} \cdot \frac{m^{m/2}}{\Gamma(m/2) 2^{m/2}} w^{m/2-1} e^{-mw/2} \cdot w \\ f_{Z,W}(z, w) &= \frac{n^{n/2} m^{m/2}}{\Gamma(n/2) \Gamma(m/2) 2^{(n+m)/2}} z^{\frac{n}{2}-1} w^{\frac{n+m}{2}-1} e^{-\frac{nz+m}{2}w}.\end{aligned}$$

Marginaliserar vi ut W får vi nu

$$\begin{aligned} f_Z(z) &= \frac{n^{n/2}m^{m/2}}{\Gamma(n/2)\Gamma(m/2)2^{(n+m)/2}} z^{\frac{n}{2}-1} \int_0^{+\infty} e^{\frac{n+m}{2}-1} e^{-\frac{nz+m}{2}w} dw \\ &= \frac{n^{n/2}m^{m/2}}{\Gamma(n/2)\Gamma(m/2)2^{(n+m)/2}} z^{\frac{n}{2}-1} \frac{\Gamma((n+m)/2)}{\left(\frac{nz+m}{2}\right)^{\frac{n+m}{2}}} \\ &= \frac{\Gamma((m+n)/2)}{\Gamma(n/2)\Gamma(m/2)} \frac{1}{z} \sqrt{\frac{(nz)^n m^m}{(nz+m)^{n+m}}}. \end{aligned}$$

Uppgift 15

- (a) Enligt d-separation kodar $\mathcal{G}_1$ bara relationen $X_1 \perp\!\!\!\perp X_4 | \mathbf{X}_{2,3}$ som stämmer för (X_1, X_2, X_3, X_4) . Därför (X_1, X_2, X_3, X_4) är Markovsk till $\mathcal{G}_1$.

$\mathcal{G}_2$ kodar båda $X_1 \perp\!\!\!\perp X_4 | \mathbf{X}_{2,3}$ och $X_2 \perp\!\!\!\perp X_3 | X_1$. Den andra relationen stämmer inte i (X_1, X_2, X_3, X_4) och därför fördelningen är inte Markovsk till $\mathcal{G}_2$.

$\mathcal{G}_3$ kodar bara $X_2 \perp\!\!\!\perp X_3 | \mathbf{X}_{1,4}$ vilken stämmer i fördelningen. Därför fördelningen är Markov till $\mathcal{G}_3$.

Enligt d-separation kodar $\mathcal{G}_4$ $X_1 \perp\!\!\!\perp X_2$ vilken inte stämmer i fördelningen. Därför (X_1, X_2, X_3, X_4) är inte Markovsk till $\mathcal{G}_4$.

Så svaret är $\mathcal{G}_1$ och $\mathcal{G}_3$.

- (b) $\mathcal{G}_2$ har en v-struktur: $2 \rightarrow 4 \leftarrow 3$. Därför antalet element i Markovekvivalensklassen är antalet sätt att orientera $2 - 1 - 3$ så att det finns ingen v-struktur. Det finns 3 sätt att göra det.

$\mathcal{G}_4$ har en v-struktur $2 \rightarrow 3 \leftarrow 4$. Därför antalet element i Markovekvivalensklassen är antalet sätt att orientera kanten $1 - 4$. Det finns två.

- (c) För AIC har vi att

$$\begin{aligned} AIC(\mathcal{G}_1) &= 2(5) + 2(0.28) = 10.56, \\ AIC(\mathcal{G}_2) &= 2(4) + 2(1.67) = 11.34, \\ AIC(\mathcal{G}_3) &= 2(5) + 2(0.30) = 10.60, \\ AIC(\mathcal{G}_4) &= 2(3) + 2(2.93) = 11.86. \end{aligned}$$

För BIC har vi att $\log(1000) \approx 6.9078$. Det följer att

$$\begin{aligned} BIC(\mathcal{G}_1) &= (6.9078)(5) + 2(0.28) = 35.099, \\ BIC(\mathcal{G}_2) &= (6.9078)(4) + 2(1.67) = 30.9712, \\ BIC(\mathcal{G}_3) &= (6.9078)(5) + 2(0.30) = 35.139, \\ BIC(\mathcal{G}_4) &= (6.9078)(3) + 2(2.93) = 25.5834. \end{aligned}$$

Därför AIC föredrar $\mathcal{G}_1$ medan BIC föredrar $\mathcal{G}_4$.

Uppgift 16

- (a) En rimlig modell är $X \mid \Theta = \theta \sim N(\theta, 5^2)$ och $\Theta \sim N(0, 10^2)$ då de konjugerade apriorifördelningarna för normalfördelningen är normalfördelningarna själva. Eftersom $\bar{x} = -0.46$ får vi

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim N(-0.438, 4.762).$$

- (b) Uppvärmingskostnaden W_i för varje år kan skrivas på formen $(k - Y_i)b \cdot 4 \cdot 3$ där k är inomhustemperaturen och b är antalet kWh per månad (65.9 för direktverkande el och 21.6 för värmepump) medan Y_i är medeltemperaturen för vintermånaderna det året. Givet de redan observerade datan $\mathbf{X} = \mathbf{x}$ har Y_i den aposterioriprediktiva fördelningen, vilket kan läsas ut från hierarkin $Y_i \mid \Theta = \theta \sim N(\theta, 5^2)$ och $\Theta \mid \mathbf{X} = \mathbf{x} \sim N(-0.438, 4.762)$ som $Y_i \mid \mathbf{X} = \mathbf{x} \sim N(-0.438, 25 + 4.762) = N(-0.438, 29.762)$.

Med detta får vi att kostnaden uppfyller

$$W_i = (k - Y_i)b \cdot 4 \cdot 3 \sim N(kb \cdot 4 \cdot 3 + 0.438 \cdot b \cdot 4 \cdot 3, 29.762 \cdot b^2 \cdot 4^2 \cdot 3^2) = N(12b(k + 0.438), 4285.7b^2).$$

Men vi har ju kostnaden under tre år, vilket i sin tur ger

$$W_1 + W_2 + W_3 \sim N(3 \cdot 12b(k + 0.438), 3 \cdot 4285.7b^2) = N(36b(k + 0.438), 12860.1b^2).$$

Ett 95% symmetriskt intervall blir för totalkostnaden blir då

$$36b(k + 0.438) \pm \lambda_{0.025} b \sqrt{12860.1} = 36b(k + 0.438) \pm 222.3b.$$

För a_1 och a_2 har vi $k = 20$ respektive $k = 18$ med $b = 65.9$. Detta ger

$$[50000, 79299]$$

för a_1 och

$$[43674, 72973]$$

för a_2 . För a_3 har vi $k = 20$ och $b = 21.6$ men har också en fix kostnad på 21 700, vilket ger intervallet

$$[38088, 47692].$$

- (c) Eftersom förlustfunktionen utgörs av $W_1 + W_2 + W_3$ för a_1 och a_2 samt $21700 + W_1 + W_2 + W_3$ för a_3 får vi följande aposteriorrisker

$$a_1 : 48487 \quad a_2 : 43742 \quad a_3 : 37592.$$