



Avd. Matematisk statistik

KTH Matematik

OMTENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS ONSDAG 21 DECEMBER 2022, 08:00–13:00.

Examinator: Liam Solus, 072-148 63 16.

Tillåtna hjälpmedel: miniräknare, formelsamling (utan anteckningar)

Tentamen består av två delar: del I och del II. Del I består av uppgift 1–12 där varje uppgift är värd en poäng var. I denna del behöver du bara ge ett svar på den bifogade svarsblanketten och använd minst tre värdesiffror för numeriska svar. Studenter som fått godkänt på kontrollskrivningen behöver inte svara uppgifter 1–3 och kan tillgodoräkna sig dessa uppgifter. (Denna gäller bara för denna tentamen och omtentamen för denna kursomgång.) För att få godkänt på tentamen krävs minst 8 poäng på del I. Möjlighet till komplettering ges för 7 poäng på del I.

Del II av tentamen består av uppgift 13–16 där varje uppgift är värd 10 poäng. Denna del rättas bara för studenter som är godkända eller får komplettera på del I. Poängen på del II krävs för att få högre betyg än E. På denna del ska resonemang och uträkningar skall vara så utförliga och väl motiverade att de är lätta att följa. Införda beteckningar skall förklaras och definieras och numeriska svar skall anges med minst två värdesiffrors noggrannhet. För studenter som fick bonuspoäng på inlämningsuppgiften läggs dessa poäng till poängsumman för del II. (Detta gäller bara för denna tentamen och omtentamen för denna kursomgång.)

Tentamen kommer att vara rättad inom tre arbetsveckor från skrivningstillfället och kommer att finnas tillgänglig på studentexpeditionen minst sju veckor efter skrivningstillfället.

Del I

Uppgift 1

Låt $\mathbf{X} = (X_1, X_2, X_3, X_4) \sim N(\mathbf{0}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 1 & -1 & -1 & 1 \\ -1 & 2 & 1 & -1 \\ -1 & 1 & 2 & -2 \\ 1 & -1 & -2 & 3 \end{bmatrix}.$$

Vad är $\text{Cov}[X_2, X_4 \mid X_3 = 0]$?

Uppgift 2

Antag att $x_1, x_2, \dots, x_n$ är ett slumpmässigt stickprov från en fördelning med täthetsfunktion

$$f_X(x) = \frac{x}{\sigma^2} e^{-\frac{x^2}{\sigma^2}}$$

Vilken av följande är en tillräcklig statistika för σ^2 ?

- (a) $\prod_{i=1}^n x_i$,
- (b) $\sum_{i=1}^n x_i^2$,
- (c) $\sum_{i=1}^n \log(x_i)$,
- (d) inget av ovanstående.

Uppgift 3

Låt X_1, X_2, X_3, X_4 vara oberoende och Gamma($3, \lambda$)-fördelade. Bestäm ML-skattningen för $\tau(\lambda) = \frac{3(\lambda+1)}{\lambda^2}$ givet datan

$$x_1 = 0.29, \quad x_2 = 0.80, \quad x_3 = 0.60, \quad x_4 = 0.14.$$

Uppgift 4

Låt $X \mid \Theta = \theta \sim \text{Po}(\theta)$ och $\Theta \sim \text{Gamma}(3, 2)$. Bestäm ett 0.95 kredibilitetsintervall $[0, u]$ för θ givet datan $X = 6$; dvs. vad är u för givet data?

Uppgift 5

Antag att följande data observeras från en InvGamma(α, λ)-population med $\alpha > 2$:


$$\bar{x} = 4.86 \quad \frac{1}{n} \sum_{i=1}^n x_i^2 = 24.45.$$

Skatta α med hjälp av momentmetoden.





- (a) 1.02,
- (b) 2.04,
- (c) 2.45,
- (d) 0.97,
- (e) inget av de ovanstående.

Uppgift 6

Anta att vi har en fördelning med täthetsfunktion $f_{\mathbf{X}}(x_1, x_2, x_3, x_4)$ som är markovsk med avseende på följande grafer:



Med avseende på vilka av följande grafer kan vi säga att fördelningen också markovsk? Markera alla alternativ som stämmer.



Uppgift 7

Låt X_1, X_2, X_3, X_4, X_5 vara oberoende och likafördelade med täthetsfunktionen $f_{X_i}(x_i | \theta)$. Anta att vi har ett test med nivå $\alpha = 0.05$

$$\text{Förkasta } H_0 \text{ om } \bar{x} \leq \frac{\theta_0}{2} - 0.34s^2$$

för

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta < \theta_0$$

där $\bar{x}$ och s^2 är stickprovsväntevärdet respektive stickprovsvariansen. Beräkna ett 0.95 ensidigt konfidsintervall för θ givet datan:

$$1.64 \quad 1.10 \quad 2.03 \quad 0.23.$$

Uppgift 8

Anta vi singlar ett slant 13 (oberoende) gånger och får datan

$$0 \quad 1 \quad 1 \quad 0 \quad 0 \quad 0 \quad 1 \quad 0 \quad 0 \quad 1 \quad 0 \quad 1 \quad 1$$

där $X = 1$ representerar krona och $X = 0$ representerar klave. Givet modellen $X | \Theta = \theta \sim \text{Ber}(\theta)$ och $\Theta \sim \text{Beta}(2, 2)$ bestäm den aposterioriprediktiva sannolikheten $P(\text{klave} | \mathbf{X} = \mathbf{x})$ för det nästa kastet.

Uppgift 9

Vi observerar följande data

$$3.27 \quad 2.39 \quad -2.48 \quad -0.33 \quad 1.96 \quad 2.05$$

Anta att observationerna är betingat oberoende givet parametern Θ och har samma betingade fördelning $X \mid \Theta = \theta \sim N(1, \theta)$. Beräkna aposteriorivariansen för Θ

$$\text{Var}[\Theta \mid \mathbf{X} = \mathbf{x}]$$

givet den icke-informativa apriorifördelningen $f_{\Theta}(\theta) \propto \frac{1}{\theta}$.

Uppgift 10

Anta att vi approximerar fördelningen som har täthetsfunktion $f(x) = 3e^{-3x}$ med fördelningen som har täthetsfunktionen $g(x) = e^{-x}$ där $x > 0$ i båda fallen. Vad är Kullback–Leibler-divergensen $D(f, g)$ för denna approximation?

Uppgift 11

Antalet personer som kom in på en viss bank under den första timmen banken är öppen registrerades varje vardag under två veckor:

	Veckodag				
Vecka	M	Ti	O	To	F
1	14	8	18	21	3
2	12	17	16	24	2

Vi har även antalet personer som kommer in banken under den första timmen på måndag och tisdag under den tredje veckan:

$$X_M = 16 \quad X_{Ti} = 15.$$

Anta att antalet personer som kom in till banken under den första timmen kan modelleras med en poissonfördelning med okänd parameter. Använd den empiriska bayesmetoden med en konjugerad apriorifördelning för att ta fram aposteriorväntevärdet för parametern för den tredje veckan.

Uppgift 12

Anta att vi observerar följande data från en $\text{Exp}(\theta)$ -population:

$$1.20 \quad 1.31 \quad 1.59 \quad 2.55 \quad 3.90$$

Bestäm aposteriorioddset för

$$H_0 : \theta < 1 \text{ med avseende på } H_1 : \theta > 1$$

givet den konjugerade apriorifördelningen $\Theta \sim \text{Gamma}(2, 4)$.

Del II

Uppgift 13

Låt $X_1, \dots, X_n$ och $Y_1, \dots, Y_n$ vara slumpmässiga stickprov med fördelningarna $N(0, \sigma^2)$ respektive $N(0, \tau^2)$. Anta även att $X_1, \dots, X_n$ och $Y_1, \dots, Y_n$ är oberoende. Låt S_X^2 respektive S_Y^2 beteckna stickprovsvariansen för $X_1, \dots, X_n$ och $Y_1, \dots, Y_n$. Betrakta nu punktskattningen

$$W(X_1, \dots, X_n, Y_1, \dots, Y_n) = S_X^2 + S_Y^2 + \frac{2}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

för summan av varianserna $\sigma^2 + \tau^2$.

- (a) Visa att W är väntevärdesriktig.
- (b) Vad är $\text{Var}[W]$?
- (c) Uppnår W Cramér–Raos nedre gräns?

Uppgift 14

Låt Θ vara den stokastiska variabel som motsvarar antalet personer som klickade på en viss annons på nätet delat med antalet personer som såg annonsen, dvs. andelen av personer som klickade. Värdet θ kallas för annonsens *click-through rate* (CTR). Anta att vi observerar 500 000 oberoende CTR:er $\theta_1, \dots, \theta_{500000}$.

- (a) Givet statistikorna $\bar{\theta} = 0.75$ och $\frac{1}{500000} \sum_{i=1}^{500000} \theta_i^2 = 0.59$, bestäm en modell för den stokastiska variabeln Θ och bestäm parametrarna i denna modell. Förklara varför din modell är rimlig. (4 p)
- (b) Oddset för att en person ska klicka på annonsen kan skattas med

$$W(\theta_1, \dots, \theta_n) = \frac{\bar{\theta}}{1 - \bar{\theta}},$$

för ett nytt stickprov $\theta_1, \dots, \theta_{500000}$. Med hjälp av din modell från del (a), approximera fördelningen för denna skattning och förklara varför din approximation är rimlig. (6 p)

Uppgift 15

Inför det franska presidentvalet 2022 genomfördes ett antal opinionsundersökningar för att utröna väljarnas intentioner. Av de $n = 1264$ som indikerade att de tänkte gå och rösta var fördelningen över kandidater följande:

Kandidat	Antal
Emmanuel Macron (EM)	308
Marine Le Pen (MLP)	268
Jean-Luc Mélenchon (JLM)	192
Eric Zemmour (EZ)	99
Valérie Pécresse (VP)	99
Annan	298

- (a) Antag att svaren ovan kan modelleras med en multinomialfördelning $\text{Multi}(\boldsymbol{\theta})$ givet sannolikheterna $\boldsymbol{\Theta} = \boldsymbol{\theta}$ där $\boldsymbol{\Theta} = [\Theta_{\text{EM}}, \Theta_{\text{MLP}}, \Theta_{\text{JLM}}, \Theta_{\text{EZ}}, \Theta_{\text{VP}}, \Theta_{\text{annan}}]^T$ är andelen röster för var och en av kandidaterna. Om vi nu har en likformig apriorifördelning över $\boldsymbol{\Theta}$, bestäm aposteriorifördelningen för $\boldsymbol{\Theta}$ och ta fram aposterioriväntevärdet samt aposterioristandardavvikelsen för andelen röster Marine Le Pen får, Θ_{MLP} . (4 p)
- (b) Det franska presidentvalet hålls vanligtvis i två omgångar. Om ingen kandidat får mer än 50% av rösterna i första omgången går de två ledande kandidaterna vidare till en andra omgång. I detta fall gick Emmanuel Macron (EM) och Marine Le Pen (MLP) vidare. I vår modell motsvarar detta att $\Theta_{\text{JLM}} = \Theta_{\text{EZ}} = \dots = \Theta_{\text{annan}} = 0$. Vad är aposterioriväntevärdet och aposterioristandardavvikelsen för Θ_{MLP} i detta fall? (4 p)
- (c) Beskriv en metod för att beräkna den approximativa sannolikheten att Marine Le Pen har större röstandel än Emmanuel Macron i andra omgången (dvs. vinner valet). (2 p)

Uppgift 16

I samband med reaktorstoppet på Oskarshamn 3 i december 2022 måste Svenska Kraftnät förbereda sig på att koppla bort vissa elkunder för att förhindra sammanbrott i elnätet. I samband med detta görs bland annat följande mätningar hos två elkunder i ett visst industriområde under ett par dagar:

Företag	Maxeffekt (kW)
A	968, 705, 905, 1221
B	1018, 575, 886, 1036

I samma område mättes också effekten (i kW) som fanns tillgänglig från elnätet under dessa dagar:

3326, 3406, 3550, 2849.

- (a) Antag att effekten för de två elkunderna kan modelleras som X_A respektive X_B där $X_A \mid \Theta_A = \theta_A \sim N(\theta_A, 200^2)$ och $X_B \mid \Theta_B = \theta_B \sim N(\theta_B, 200^2)$. Antag vidare att den tillgängliga effekten kan modelleras som $Y \mid \Psi = \psi \sim N(\psi, 300^2)$ samt att $X_A, \Theta_A \perp\!\!\!\perp X_B, \Theta_B \perp\!\!\!\perp Y, \Psi$. Om Θ_A , Θ_B och Ψ har icke-informativa apriorifördelningar (dvs. $f_{\Theta}(\theta) \propto 1$), beräkna deras aposteriorifördelningar. (2 p)
- (b) Effektbrist uppstår när den efterfrågade effekten överstiger den tillgängliga. Beräkna sannolikheten för effektbrist i systemet ovan givet observationerna. (3 p)
- (c) Vid reaktorstoppet förväntas den tillgängliga effekten minska med 2000 kW. Vi har alltså $Y - 2000$ kW tillgänglig effekt. För att förhindra effektbrist överväger som sagt Svenska Kraftnät att koppla bort en av kunderna under en dag, men detta resulterar i en viss kostnad för samhället (dvs. utebliven produktion). Å andra sidan, om effektbrist uppstår och elnätet havererar så blir så klart båda kunderna utan el. Kostnaderna för företag A uppgår i 120 000 kr medan kostnaderna för företag B är 90 000 kr. Vilket av följande är bayesbeslutet: koppla bort företag A, koppla bort företag B eller koppla inte bort något företag? (5 p)

Lycka till!



Avd. Matematisk statistik

KTH Matematik

LÖSNINGAR TILL OMTENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS

Uppgift 1

Eftersom modellen är en flerdimensionell normalfördelning kan vi beräkna den betingade fördelningen $X_{2,4} \mid X_3 = 0 \sim N(\theta, \Sigma')$ där

$$\begin{aligned}\Sigma' &= \Sigma_{\{2,4\},\{2,4\}} - \Sigma_{\{2,4\},\{3\}} \Sigma_{\{3\},\{3\}}^{-1} \Sigma_{\{3\},\{2,4\}} \\ &= \begin{bmatrix} 2 & -1 \\ -1 & 3 \end{bmatrix} - \begin{bmatrix} 1 \\ -2 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & -2 \end{bmatrix}, \\ &= \begin{bmatrix} 2 & -1 \\ -1 & 3 \end{bmatrix} - \frac{1}{2} \begin{bmatrix} 1 & -2 \\ -2 & 4 \end{bmatrix}, \\ &= \begin{bmatrix} \frac{3}{2} & 0 \\ 0 & 1 \end{bmatrix}.\end{aligned}$$

Eftersom $\text{Cov}[X_2, X_4 \mid X_3 = 0] = \Sigma'_{\{2\},\{4\}}$ vilken är lika med noll har vi att $\text{Cov}[X_2, X_4 \mid X_3 = 0] = 0$.

Uppgift 2

Enligt faktoriseringssatsen har vi att $\sum_{i=1}^n x_i^2$ är en tillräcklig statistika eftersom vi kan skriva den simultana täthetsfunktionen

$$\begin{aligned}f(\mathbf{x} \mid \sigma^2) &= \prod_{i=1}^n \frac{x_i}{\sigma^2} e^{-\frac{x_i^2}{\sigma^2}}, \\ &= \left(\prod_{i=1}^n x_i \right) \left(\sigma^{-2n} e^{-\frac{1}{\sigma^2} \sum_{i=1}^n x_i^2} \right), \\ &= h(\mathbf{x}) g(T(\mathbf{x}) \mid \sigma^2),\end{aligned}$$

där $h(\mathbf{x}) = \prod_{i=1}^n x_i$, $g(t \mid \sigma^2) = \sigma^{-2n} e^{-\frac{1}{\sigma^2} t}$ och $T(\mathbf{x}) = \sum_{i=1}^n x_i^2$.

Uppgift 3

Vi har att $\bar{x} \approx 0.46$. Eftersom $X \sim \text{Gamma}(3, \lambda)$ vet vi att $\hat{\lambda} = \frac{3}{\bar{x}} \approx \frac{3}{0.46} \approx 6.52$. Enligt ML-skattningens invariansegenskap har vi då att

$$\widehat{\tau(\lambda)} = \tau(\hat{\lambda}) = \frac{3(\hat{\lambda} + 1)}{\hat{\lambda}^2} \approx 0.53.$$

Uppgift 4

Vi har att aposteriorifördelningen är

$$\Theta \mid X = 6 \sim \text{Gamma}(3 + 6, 2 + 1) = \text{Gamma}(9, 3).$$

Låt $Y = 2(3)\Theta$. Det följer att $Y \mid X = 6 \sim \text{Gamma}(9, 1/2) = \chi^2(2(9)) = \chi^2(18)$. Vi skulle vilja hitta kvantilen $\chi^2_{0.05}(18)$ så att

$$P(Y > \chi^2_{0.05}(18)) = 0.05.$$

Med hjälp av tabellen ser vi att $\chi^2_{0.05}(18) = 28.9$. Det följer att

$$0.95 = P(Y < 28.9) = P(6\Theta < 28.9 \mid X = 6) = P(\Theta < 4.82 \mid X = 6).$$

Därför är intervallet $[0, 4.82]$ och vi har $u = 4.82$.

Uppgift 5

Eftersom $\alpha > 2$ har vi att

$$E[X] = \frac{\lambda}{\alpha - 1}$$

och

$$\begin{aligned} E[X^2] &= \text{Var}[X] + E[X]^2, \\ &= \frac{\lambda^2}{(\alpha - 1)^2(\alpha - 2)} + \frac{\lambda^2}{(\alpha - 1)^2}, \\ &= \frac{\lambda^2(\alpha - 1)}{(\alpha - 1)^2(\alpha - 2)}, \\ &= \frac{\lambda^2}{(\alpha - 1)(\alpha - 2)}. \end{aligned}$$

Vi har från datan att

$$\frac{1}{n} \sum_{i=1}^n x_i \approx 4.86 \quad \frac{1}{n} \sum_{i=1}^n x_i^2 \approx 24.45.$$

Därför skulle vi lösa systemet

$$\begin{aligned} 4.86 &= \frac{\lambda}{\alpha - 1}, \\ 24.45 &= \frac{\lambda^2}{(\alpha - 1)(\alpha - 2)}. \end{aligned}$$

Från den första ekvationen får vi att

$$\alpha - 1 = \frac{\lambda}{4.86}.$$

Så följer det från den andra ekvationen att

$$\begin{aligned} (24.45)(4.86) &= \frac{\lambda^2}{(\alpha - 1)(\alpha - 2)}, \\ &= \frac{\lambda^2}{\left(\frac{\lambda}{4.86}\right)\left(\frac{\lambda}{4.86} - 1\right)}, \\ &= \frac{4.86^2 \lambda}{\lambda - 4.86}, \\ \lambda &= \frac{(4.86)(24.45)}{24.45 - 4.86^2} \approx 143.096. \end{aligned}$$

Det följer att

$$\alpha = \frac{143.096}{4.86} + 1 \approx 30.44.$$

Svaret är (e).

Uppgift 6

Fördelningen är markovsk till den givna grafen och vi har ingen mer information om fördelningen. Därför kan vi bara dra slutsatsen att fördelningen är också markovsk till graferna i markovekvivalensklassen av den givna grafen. Dessa grafer måste ha samma skelett och v-strukturer som den givna grafen. Därför är svaret (b) och (d).

Uppgift 7

Det kritiska området för testet är

$$\mathcal{R}(\theta_0) = \{\mathbf{x} : \bar{x} \leq \frac{\theta_0}{2} - 0.34s^2\}.$$

Därför är acceptansområdet

$$A(\theta_0) = \{\mathbf{x} : \bar{x} \geq \frac{\theta_0}{2} - 0.34s^2\}.$$

Vi har att $\bar{x} = 1.25$ och $s^2 \approx 0.608$ för givet data. Det följer att en 0.95 konfidensmängd för testet är

$$C(\theta_0) = \{\theta_0 : \bar{x} \geq \frac{\theta_0}{2} - 0.34s^2\} = \{\theta_0 : 2(\bar{x} + 0.34s^2) \geq \theta_0\} = (-\infty, 2.91].$$

Därför har vi $u = 2.09$.

Uppgift 8

Vi har att $X \mid \Theta = \theta \sim \text{Ber}(\theta)$ och $\Theta \sim \text{Beta}(2, 2)$. Det följer att aposteriorifördelningen är

$$\Theta \mid \mathbf{x} \sim \text{Beta}(2 + 6, 2 + 13 - 6) = \text{Beta}(8, 9).$$

Vi har även att aposterioriprediktiva fördelningen är

$$\begin{aligned} f_{Y|X}(y \mid x) &= \int_0^1 f_Y(y \mid \theta) f_{\Theta|X=\mathbf{x}}(\theta \mid \mathbf{x}) d\theta, \\ &= \int_0^1 \theta^y (1 - \theta)^{1-y} \frac{\Gamma(17)}{\Gamma(8)\Gamma(9)} \theta^7 (1 - \theta)^8 d\theta, \\ &= \frac{\Gamma(17)}{\Gamma(8)\Gamma(9)} \int_0^1 \theta^{y+7} (1 - \theta)^{9-y} d\theta, \\ &= \frac{\Gamma(17)}{\Gamma(8)\Gamma(9)} \frac{\Gamma(y+8)\Gamma(10-y)}{\Gamma(18)}, \\ &= \frac{16!(y+7)!(9-y)!}{7!8!17!}. \end{aligned}$$

(Vi kan också använda beta-binomialhierarkin i formelsamlingen eftersom bernoullifördelningen sammanfaller med binomialfördelningen för $n = 1$.) Det följer att aposteriorisannolikheten för klave ($Y = 0$) är

$$f_{Y|X}(0 \mid \mathbf{x}) = \frac{16!(y+7)!(9-y)!}{7!8!17!} = \frac{9!}{8!17} = \frac{9}{17} \approx 0.53.$$

Uppgift 9

Vi har att aposteriorifördelningen är

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{InvGamma}\left(\frac{6}{2}, \frac{1}{2} \sum_{i=1}^6 (x_i - 1)^2\right) = \text{InvGamma}(3, 11.49),$$

vilket är den en inversa gammafördelningen med $\alpha > 2$. Det följer att

$$\text{Var}[\Theta \mid \mathbf{X} = \mathbf{x}] = \frac{11.49^2}{(3-1)^2(3-2)} = \frac{11.49^2}{2^2} \approx 33.01.$$

Uppgift 10

Vi noterar att $f(x)$ och $g(x)$ är täthetsfunktionerna för $\text{Exp}(3)$ - respektive $\text{Exp}(1)$ -fördelade variabler. Med hjälp av formeln i formelsamlingen ser vi att

$$\begin{aligned} D(f, g) &= \int_0^\infty \log\left(\frac{3e^{-3x}}{e^{-x}}\right) 3e^{-3x} dx, \\ &= \int_0^\infty \log(3e^{-2x}) 3e^{-3x} dx, \\ &= \log(3) \int_0^\infty 3e^{-3x} dx - 2 \int_0^\infty x (3e^{-3x}) dx, \\ &= \log(3)(1) - 2 \mathbb{E}[X], \quad \text{där } X \sim \text{Exp}(3) \\ &= \log(3) - \frac{2}{3}, \\ &\approx 0.432. \end{aligned}$$

Uppgift 11

Låt θ_1, θ_2 och θ_3 beteckna väntevärdena för veckorna 1, 2 respektive 3. Vi har att $X \mid \Theta = \theta_i \sim \text{Po}(\theta_i)$ och $\Theta \sim \text{Gamma}(\alpha, \lambda)$. Med hjälp av data har vi skattningarna $\hat{\theta}_1 = 12.8$ och $\hat{\theta}_2 = 14.2$. Enligt momentmetoden betraktar vi systemet av ekvationerna

$$\begin{aligned} \frac{\alpha}{\lambda} &= \frac{12.8 + 14.2}{2} = 13.5, \\ \mathbb{E}[\Theta^2] &= \text{Var}[\Theta] + \mathbb{E}[\Theta]^2 = \frac{\alpha(\alpha+1)}{\lambda^2} = \frac{12.8^2 + 14.2^2}{2} = 182.74. \end{aligned}$$

Den första ekvationen ger oss

$$\alpha = 13.5\lambda,$$

och därför har vi att

$$\begin{aligned} 182.74 &= \frac{\alpha(\alpha + 1)}{\lambda^2}, \\ 182.74 &= \frac{13.5\lambda(13.5\lambda + 1)}{\lambda^2}, \\ 182.74 &= \frac{13.5^2\lambda + 13.5}{\lambda}, \\ (182.74 - 13.5^2)\lambda &= 13.5, \\ \lambda &= \frac{13.5}{182.74 - 13.5^2}, \\ \lambda &= 27.55. \end{aligned}$$

Med hjälp av den första ekvationen igen ser vi att

$$\alpha = 13.5(27.55) \approx 371.925.$$

Det följer att vi har apriorifördelningen $\Theta \sim \text{Gamma}(371.93, 27.55)$ för $X \mid \Theta = \theta_3 \sim \text{Po}(\theta_3)$. Därför har vi aposteriorifördelningen för den tredje veckan:

$$\Theta \mid X_M = 16, X_T = 15 \sim \text{Gamma}(371.93 + 16 + 15, 27.55 + 2) = \text{Gamma}(402.93, 29.55).$$

Det följer att för den tredje veckan $E[\Theta \mid \mathbf{x}] = 402.93/29.55 \approx 13.64$.

Uppgift 12

Vi har aposteriorifördelningen

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Gamma}(2 + 5, 4 + 5\bar{x}) = \text{Gamma}(7, 13.95).$$

Om vi låter $Y \sim \text{Gamma}(7, 13.95)$ vet vi att $2(13.95)Y = 29.1Y \sim \chi^2(2(7)) = \chi^2(14)$. Det följer att

$$\begin{aligned} P(\theta > 1 \mid \mathbf{X} = \mathbf{x}) &= P(Y > 1) = P(29.1Y > 29.1), \\ &= 0.01013, \end{aligned}$$

med hjälp av fördelningsfunktionen för χ^2 -fördelningen. Å andra sidan har vi att

$$P(\theta \leq 1 \mid \mathbf{x}) = P(Y \leq 29.1) = 1 - P(Y > 29.1) = 0.98987.$$

Därför är aposteriorioddset

$$\frac{0.98987}{0.01013} \approx 97.7.$$

Om man använder tabellsamlingen och ser på kvantilerna för χ^2 -fördelningen istället får man att

$$P(\theta > 1 \mid \mathbf{X} = \mathbf{x})P(29.1Y > 29.1) \approx 0.01.$$

Då blir svaret

$$\frac{P(\theta < 1 \mid \mathbf{x})}{1 - P(\theta < 1 \mid \mathbf{x})} \approx \frac{0.99}{0.01} = 99.$$

Uppgift 13

Låt $Z = X + Y$ där $X \perp Y$, $X \sim N(0, \sigma^2)$ och $Y \sim N(0, \tau^2)$. Det följer att $Z \sim N(0, \kappa^2)$ där

$$\kappa^2 = \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} \sigma^2 & 0 \\ 0 & \tau^2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \sigma^2 + \tau^2.$$

Låt S_Z^2 beteckna stickprovsvariansen för ett stickprov $Z_1, \dots, Z_n$ från $N(0, \kappa^2)$. Det följer att

$$\begin{aligned} S_Z^2 &= \frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2, \\ &= \frac{1}{n-1} \sum_{i=1}^n ((X_i + Y_i) - (\bar{X} + \bar{Y}))^2, \\ &= \frac{1}{n-1} \sum_{i=1}^n ((X_i - \bar{X}) + (Y_i - \bar{Y}))^2, \\ &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 + \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 + \frac{2}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}), \\ &= W(X_1, \dots, X_n, Y_1, \dots, Y_n). \end{aligned}$$

(a) Eftersom $E[S_Z^2] = \kappa^2$ följer det att

$$E[W] = E[S_Z^2] = \kappa^2 = \sigma^2 + \tau^2.$$

Därför har vi $\text{Bias}[W] = 0$.

(b) I formelsamlingen har vi formeln

$$\frac{(n-1)S_Z^2}{\kappa^2} \sim \chi^2(n-1)$$

och därför vet vi att

$$\text{Var}[W] = \text{Var}[S_Z^2] = \frac{2(\kappa^2)^2}{n-1} = \frac{2(\sigma^2 + \tau^2)^2}{n-1}.$$

(c) Vi såg i kursen att stickprovsvariansen för en normalfördelad variabel uppnår inte Cramér–Raos nedre gräns. Eftersom $W = S_Z^2$ där Z är normalfördelad vet vi att W inte uppnår gränsen.

Uppgift 14

(a) Eftersom CTR är sannolikheten att man klickar på annonsen kan vi modellera $\Theta \sim \text{Beta}(\alpha, \beta)$. Med hjälp av givna statistikor kan vi tillämpa momentmetoden för att hitta en modell:

$$\begin{aligned} \frac{\alpha}{\alpha + \beta} &= 0.75, \\ \left(\frac{\alpha}{\alpha + \beta} \right)^2 + \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)} &= 0.59. \end{aligned}$$

Från den första ekvationen får vi $\alpha = 3\beta$. Om vi tillämpar detta på den andra ekvationen får vi

$$\begin{aligned} 0.75^2 + \frac{3}{4^2(4\beta + 1)} &= 0.59, \\ \frac{1}{4} \left(\frac{3}{4^2(0.59 - 0.75^2)} - 1 \right) &= \beta, \\ \beta &\approx 1.45. \end{aligned}$$

Det följer att $\alpha = 3(1.45) = 4.35$. Därför är en rimlig modell $\Theta \sim \text{Beta}(4.35, 1.45)$.

- (b) Eftersom stickprovet är ganska stort kan vi använda en normalapproximation som hittas med hjälp av deltametoden. Med hjälp av centrala gränsvärdessatsen har vi att

$$\sqrt{n}(\bar{\theta} - E[\Theta]) \longrightarrow N(0, \text{Var}[\Theta]).$$

Enligt deltametoden med $g(y) = \frac{y}{1-y}$ har vi

$$\begin{aligned} \sqrt{n}(g(\bar{\theta}) - g(E[\Theta])) &\longrightarrow N(0, g'(E[\Theta])^2 \text{Var}[\Theta]), \\ \sqrt{n} \left(\frac{\bar{\theta}}{1-\bar{\theta}} - \frac{\alpha}{\beta} \right) &\longrightarrow N \left(0, \frac{\alpha}{\beta(\alpha + \beta + 1)} \right), \end{aligned}$$

Eftersom $\alpha = 4.35$ och $\beta = 1.45$ är en approximation för fördelningen

$$\frac{\bar{\theta}}{1-\bar{\theta}} \sim N \left(3, \frac{0.44}{n} \right)$$

där $n = 500000$. Det följer att variansen är nästan noll vilket säger att det chansen är 3 till 1 att personen klickar på annonsen för ett stort stickprov.

Uppgift 15

- (a) Likformig apriorifördelning för proportioner är en dirichletfördelning med alla parametrar satta till ett, dvs. $\Theta \sim \text{Dirichlet}(\mathbf{1})$. Aposteriorifördelningen blir då

$$\begin{aligned} \Theta \mid \mathbf{X} = \mathbf{x} &\sim \text{Dirichlet}(1 + 308, 1 + 268, 1 + 192, 1 + 99, 1 + 99, 1 + 298) \\ &= \text{Dirichlet}(309, 269, 193, 100, 100, 299). \end{aligned}$$

Enligt formelsamlingen har vi då

$$E[\Theta_{\text{MLP}} \mid \mathbf{X} = \mathbf{x}] = \frac{269}{309 + 269 + 193 + 100 + 100 + 299} = \frac{269}{1270} \approx 0.2118$$

samt

$$\text{Std}[\Theta_{\text{MLP}} \mid \mathbf{X} = \mathbf{x}] = \sqrt{\frac{269(1270 - 269)}{1270^2(1270 + 1)}} \approx 0.01146.$$

- (b) Vi betingar alltså aposteriorifördelningen med avseende på $\Theta_{\text{JLM}} = \Theta_{\text{EZ}} = \dots = \Theta_{\text{annan}} = 0$ och får då att

$$[\Theta_{\text{EM}}, \Theta_{\text{MLP}}]^T \mid \mathbf{X} = \mathbf{x}, \Theta_{\text{JLM}} = \Theta_{\text{EZ}} = \dots = \Theta_{\text{annan}} = 0 \sim \text{Dirichlet}(309, 269).$$

Enligt samma formler som ovan får vi då det betingade aposterioriväntevärdet 0.4654 samt aposterioristandardavvikelsen 0.02073.

- (c) Vi är intresserade av att beräkna sannolikheten att $\Theta_{\text{MLP}} > 1/2$ givet $\mathbf{X} = \mathbf{x}$ samt $\Theta_{\text{JLM}} = \Theta_{\text{EZ}} = \dots = \Theta_{\text{annan}} = 0$. Marginalfördelningen för Θ_{MLP} är en betafördelning, så vi kan försöka beräkna sannolikheten genom att approximera täthetsfunktionens integral över $[1/2, 1]$. Detta kan göras med hjälp av kvadraturegler från numeriska metoder. Alternativt kan vi dra utfall från en betafördelad stokastisk variabel med hjälp av simulering och räkna antalet utfall som överstiger $1/2$. Vi kan också använda en normalapproximering (eftersom båda parametrarna är stora) och beräkna sannolikheten med hjälp av denna. Detta ger då

$$1 - \Phi\left(\frac{0.50 - 0.4654}{0.02073}\right) \approx 1 - \Phi(1.68) \approx 1 - 0.9535 = 0.0465.$$

Uppgift 16

- (a) Eftersom vi har icke-informativa apriorifördelningar får vi enligt formelsamlingen

$$\Theta_A \mid \mathbf{X}_A = \mathbf{x}_A \sim N(\bar{x}_A, 200^2/4) = N(949.75, 10000),$$

$$\Theta_B \mid \mathbf{X}_B = \mathbf{x}_B \sim N(\bar{x}_B, 200^2/4) = N(878.75, 10000)$$

samt

$$\Psi \mid \mathbf{Y} = \mathbf{y} \sim N(\bar{y}, 300^2/4) = N(3282.75, 22500).$$

- (b) Vi är intresserade av fördelningarna för X'_A , X'_B samt Y' här, så vi tar fram de aposterioriprediktiva fördelningarna

$$X'_A \mid \mathbf{X}_A = \mathbf{x}_A \sim N(949.75, 200^2 + 10000) = N(949.75, 50000),$$

$$X'_B \mid \mathbf{X}_B = \mathbf{x}_B \sim N(878.75, 200^2 + 10000) = N(878.75, 50000)$$

samt

$$Y' \mid \mathbf{Y} = \mathbf{y} \sim N(3282.75, 300^2 + 22500) = N(3282.75, 112500).$$

För att beräkna risken för effektbrist tar vi fram den betingade fördelningen för $Y' - X'_A - X'_B$ som fås till

$$N(3282.75 - 949.75 - 878.75, 112500 + 50000 + 50000) = N(1454.25, 212500).$$

Sannolikheten att denna ska bli mindre än noll är då

$$\Phi\left(\frac{0 - 1454.25}{\sqrt{212500}}\right) \approx \Phi(-3.15) = 1 - \Phi(3.15) \approx 0.00097.$$

(c) Om vi ersätter Y' med $Y' - 2000$ får vi att $Y' - X'_A - X'_B$ har den betingade fördelningen

$$N(1282.75 - 949.75 - 878.75, 112500 + 50000 + 50000) = N(-545.75, 212500)$$

Alternativet att inte koppla bort något av företagen ger en förlust av $120000 + 90000 = 210000$ kr om effektmarginalen blir negativ, vilket händer med sannolikhet

$$\Phi\left(\frac{545.75}{\sqrt{212500}}\right) \approx \Phi(1.18) \approx 0.8106.$$

Aposterioririsken för detta beslut är alltså $210000 \cdot 0.8106 \approx 170226$ kr.

Om vi stänger ner företag A har vi en baskostnad på 120000 kr, men effektmarginalen får fördelningen

$$N(1282.75 - 878.75, 112500 + 50000) = N(404, 162500).$$

Sannolikheten för negativ effektmarginal blir nu

$$\Phi\left(-\frac{404}{\sqrt{162500}}\right) \approx \Phi(-1.00) \approx 0.1587$$

och vi har alltså en aposterioririsk på

$$120000 + 90000 \cdot 0.1587 \approx 134283.$$

Till slut kan vi välja att stänga ner företag B till en baskostnad av 90000 kr med effektmarginal som har den betingade fördelningen

$$N(1282.75 - 949.75, 112500 + 50000) = N(333, 162500).$$

Sannolikheten att denna blir negativ är alltså

$$\Phi\left(-\frac{333}{\sqrt{162500}}\right) \approx \Phi(-0.83) \approx 0.2033$$

och vi får aposterioririsken

$$90000 + 120000 \cdot 0.2033 \approx 114396.$$

Bayesbeslutet är då att stänga ner företag B.