



Avd. Matematisk statistik

KTH Matematik

OMTENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS TISDAG 19 DECEMBER 2023, 08:00–13:00.

Examinator: Liam Solus, 072-566 04 80.

Tillåtna hjälpmedel: miniräknare, formelsamling (utan anteckningar)

Tentamen består av två delar: del I och del II. Del I består av uppgift 1–12 där varje uppgift är värd en poäng var. I denna del behöver du bara ge ett svar på den bifogade svarsblanketten. Använd minst tre värdesiffror för numeriska svar. Studenter som fått godkänt på kontrollskrivningen behöver inte svara uppgifter 1–3 och kan tillgodoräkna sig dessa uppgifter. (Detta gäller bara för denna tentamen och omtentamen för denna kursomgång.) För att få godkänt på tentamen krävs minst 9 poäng på del I. Möjlighet till komplettering ges för 8 poäng på del I.

Del II av tentamen består av uppgift 13–16 där varje uppgift är värd 10 poäng. Denna del rättas bara för studenter som är godkända eller får komplettera på del I. Poängen på del II krävs för att få högre betyg än E. På denna del ska resonemang och uträkningar skall vara så utförliga och väl motiverade att de är lätta att följa. Införda beteckningar skall förklaras och definieras och numeriska svar skall anges med minst två värdesiffrors noggrannhet. För studenter som fick bonuspoäng på inlämningsuppgiften läggs dessa poäng till poängsumman för del II. (Detta gäller bara för denna tentamen och omtentamen för denna kursomgång.)

Tentamen kommer att vara rättad inom tre arbetsveckor från skrivningstillfället och kommer att finnas tillgänglig på studentexpeditionen minst sju veckor efter skrivningstillfället.

Del I

Uppgift 1

Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim N(\mathbf{0}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 3 & 2 & 1 & -1 \\ 2 & 3 & -1 & 1 \\ 1 & -1 & 8 & 3 \\ -1 & 1 & 3 & 8 \end{bmatrix}.$$

Vad är $E[(X_1 + X_2)^2(X_3 + X_4)^2]$?

Uppgift 2


Vi betraktar en fördelning $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5]^T$. Vi har observerat att fördelningen uppfyller följande oberoenderelationer:

$$X_3 \perp\!\!\!\perp X_1 | X_2,$$

$$X_4 \perp\!\!\!\perp X_1, X_2 | X_3,$$

$$X_5 \perp\!\!\!\perp X_2, X_3 | X_1, X_4.$$

Med avseende på vilken av följande grafer är $\mathbf{X}$ markovsk?



Uppgift 3

Låt $x_1 = 0.77, x_2 = 0.5, x_3 = 0.47$ vara ett stickprov från en $\text{Beta}(\theta, \theta)$ -population. Vilken av följande är en tillräcklig statistika för θ enligt stickprovet?

- (a) 0.770
- (b) 0.300
- (c) -4.507
- (d) 0.515
- (e) ingen av ovanstående.

Uppgift 4

Betrakta hierarkin

$$X|\Lambda = \lambda \sim \text{Po}(\lambda), \quad \Lambda \sim \text{Gamma}(5, 3).$$

Vad är $\text{Var}[X]$?

Uppgift 5

Låt $x_1, \dots, x_{30}$ vara ett stickprov från en $\text{Gamma}(\alpha, \lambda)$ -fördelning där både α och λ är okända. Vi har att

$$\frac{1}{30} \sum_{i=1}^{30} x_i = 0.344 \quad \text{och} \quad \frac{1}{30} \sum_{i=1}^{30} x_i^2 = 0.482.$$

Bestäm momentmetodens punktskattning för $[\alpha, \lambda]^T$ enligt datan.

Uppgift 6

Låt $X_1, X_2, X_3, Y_1, Y_2, Y_3$ vara oberoende och anta att $X_i \sim \text{Po}(\lambda_i)$ och $Y_i \sim \text{Po}(\beta\lambda_i)$ för alla $i = 1, \dots, n$. Vad är ML-skattningen av $[\beta, \lambda_1, \lambda_2, \lambda_3]^T$ enligt följande data?

$$[x_1, y_1]^T = [2, 6]^T, \quad [x_2, y_2]^T = [3, 10]^T, \quad [x_3, y_3]^T = [3, 9]^T.$$

Uppgift 7

Låt

$$x_1 = 6.31, x_2 = 7.15, x_3 = 5.37, x_4 = 3.65$$

vara ett stickprov från en $N(\theta, 4)$ -fördelning. Invertera ett likelihood-kvottest av

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta \neq \theta_0$$

för att bestämma ett tvåsidigt 0.95 konfidensintervall enligt stickprovet.

Uppgift 8

Blodtrycket av 150 personer mättes. Stickprovsmedelvärdet är $\bar{x} = 12.7$ mmHG och stickprovsstandardavvikelsen är $s = 3$ mmHG. Vi modellerar blodtrycket som normalfördelat med okända väntevärde θ_M och varians θ_V . Vad är aposterioriväntevärdet av θ_V om vi använder en bayesiansk modell med den icke-informativa apriorifördelningen?

Uppgift 9

Antalet minuter 100 personer lyssnade på poddar på Apple Music förra veckan modelleras som ett stickprov från en normalfördelning med standardavvikelsen av 5 minuter och okänt väntevärde θ . Stickprovet har medelvärde $\bar{x} = 14.537$. Vi använder en bayesiansk modell för θ med en konjugerad apriorifördelning med väntevärde $\mu = 10$ och standardavvikelse $\tau = 2$. Vad är aposteriorisannolikheten att Y är större än 20 där Y är ett nytt (oberoende) observation?

Uppgift 10

Vi har utfall

$$x_1 = 1.22, x_2 = 2.52, x_3 = 1.18, x_4 = 2.77$$

där vi antar att $X_i|A = \alpha \sim \text{Exp}(\alpha)$ för alla $i = 1, 2, 3, 4$ och X_1, X_2, X_3, X_4 är oberoende givet $A \sim \text{Gamma}(2, 3)$. Bestäm ett 0.90 symmetriskt kredibilitetsintervall för α enligt datan.

Uppgift 11

Du bor i en lagenhet med två personer, en matematiker och en datavetare. Igår kväll lämnade du 24 sushibitar i kylskåpet och imorse såg du att någon har ätit 8 bitar. Du vet att matematikern är 3 gånger mer benägen att stjäla sushi än datavetaren (och du antar att det inte är möjligt att båda åt dina sushibitar). Du vet att matematikern i regel äter mindre sushi, med en fördelning på $\text{Po}(6)$ sushibitar, jämfört med datavetaren som har en fördelning på $\text{Po}(10)$ sushibitar. Beräkna aposteriorioddsen för att det var matematikern som åt dina sushibitar.

Uppgift 12

Låt $X_1, \dots, X_{10}$ vara oberoende och $\text{Exp}(\lambda)$ -fördelade. Vi skattar λ med ML-skattningen $\hat{\lambda}$. Vad är denna punktskattnings systematiskt fel som en funktion av λ ? (dvs. vad är $\text{Bias}[\hat{\lambda}]$?)

Del II

Uppgift 13

Låt $X_1, \dots, X_n$ vara oberoende och $f_X(x|\theta)$ -fördelade där

$$f_X(x|\theta) = c(\theta)(1-x)^{\theta-1}, \quad 0 \leq x \leq 1, \quad \theta > 0.$$

- (a) Bestäm värdet $c(\theta)$ så att $f_X(x|\theta)$ är en täthetsfunktion. (1 p)
- (b) Bestäm momentmetodens punktskattning $\tilde{\theta}$ av θ . Använd deltametoden för att skatta punktskattningens asymptotisk varians. (3 p)
- (c) Bestäm ML-skattningen $\hat{\theta}$ av θ . Använd deltametoden för att skatta punktskattningens asymptotisk varians. (6 p)

Uppgift 14

En tentamen togs fram för att mäta den matematiska kunskaper hos studenter på olika skolor i Sverige. Studenternas genomsnittliga betyg på varje skola i tre olika regioner rapporteras:

Region	Genomsnittliga betyg på (tre) skolor i region
A	75.23, 63.46, 62.32
B	91.19, 74.59, 81.62
C	86.57, 72.02, 85.41

Vi antar att de genomsnittliga betygen är $N(\theta, 15^2)$ -fördelade där θ är okänt och alla betyg är oberoende givet θ . Vi betraktar en bayesiansk modell för θ med en konjugerad apriorifördelningen i följande.

- (a) Använd datan ovan för att skatta aprioriparametervärdena med hjälp av empiriska bayesmetoden. Vad är den resulterande apriorifördelningen? (3 p)
- (b) Vi observerar nya data från en fjärde region (region D):

Region	Genomsnittliga betyg på (två) skolor i region
D	88.45, 95.71

Använd apriorifördelningen i del (a) för att skatta ett tvåsidigt HPD 0.90 kredibilitetsintervall för θ givet datan för område D. (4 p)

- (c) Vi väntar på att en skola i region D ska rapportera sitt genomsnittligt betyg. Vad är aposteriorisannolikheten att betyget är större än 90? (3 p)

Uppgift 15

Maria har utvecklat ett test för att kvantifiera hur intelligent en AI (som ChatGPT) verkligen är. Hennes test liknar ett IQ-test för AI. Enligt Marias test är AI:en ovanligt intelligent om den förväntas få mer än eller lika med 100 på tentamen. När testet tillämpas på generativa AI-modeller (som ChatGPT) är det möjligt att ge testet till samma AI flera gånger eftersom sådana AI:er inte använder tidigare ställda frågor för att förbättra svaren. Maria gav testet till en generativ AI som kallas för **Heavy Annie** fem gånger och fick följande (oberoende) resultat:

101, 93, 96, 95, 103.

Maria modellerar resultaten som utfall från en normalfördelning med standardavvikelse 10 och väntevärde θ där θ representerar **Heavy Annies** ”verkliga” intelligensnivå enligt testet. Maria använder också en konjugerad apriorifördelning på θ med väntevärde 100 och standardavvikelse 15.

- (a) Vad är aposteriorifördelningen av θ givet datan ovan? (2 p)
- (b) Vad är aposteriorioddsen att **Heavy Annie** är ovanligt intelligent? (3 p)
- (c) Det anses faran för att felaktigt skatta **Heavy Annies** intelligens växer linjärt i avståndet mellan vår skattning och hennes verkliga intelligens. Det anses också dubbelt så farligt att underskatta **Heavy Annies** intelligens än att överskatta den. Enligt dessa antagande bestäm bayesskattningen av **Heavy Annies** verkliga intelligens med hjälp av ett lämpligt val av förlustfunktion. (5 p)

Uppgift 16

Låt $X_1, \dots, X_n$ vara oberoende och $\text{Exp}(\lambda)$ -fördelade. Vi ska beräkna ett tvåsidigt konfidensintervall för μ genom att invertera ett hypotestest.

- (a) Bestäm ett likelihoodkvottest med nivå $\alpha = 0.05$ för

$$H_0 : \lambda = \lambda_0 \quad \text{mot} \quad H_1 : \lambda \neq \lambda_0.$$

(7 p)

- (b) Invertera testet i del (a) för att ge ett tvåsidigt 0.95 konfidensintervall för λ enligt följande stickprov

16, 29, 49, 15, 56, 41, 3, 7, 4, 6, 4.

(3 p)

Lycka till!



Avd. Matematisk statistik

KTH Matematik

LÖSNINGAR TILL TENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS

Uppgift 1

Låt

$$A = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix}.$$

Det följer att $\mathbf{Y} = A\mathbf{X} = [Y_1, Y_2]^T = [X_1 + X_2, X_3 + X_4]^T \sim N(\mathbf{0}, \Sigma')$ där

$$\begin{aligned} \Sigma' &= A\Sigma A^T, \\ &= \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 3 & 2 & 1 & -1 \\ 2 & 3 & -1 & 1 \\ 1 & -1 & 8 & 3 \\ -1 & 1 & 3 & 8 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \\ 0 & 1 \end{bmatrix}, \\ &= \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 5 & 0 \\ 5 & 0 \\ 0 & 11 \\ 0 & 11 \end{bmatrix}, \\ &= \begin{bmatrix} 10 & 0 \\ 0 & 22 \end{bmatrix}. \end{aligned}$$

Det följer att $X_1 + X_2 \perp\!\!\!\perp X_3 + X_4$; dvs. $Y_1 \perp\!\!\!\perp Y_2$. Vi har då att

$$\begin{aligned} E[(X_1 + X_2)^2(X_3 + X_4)^2] &= E[(X_1 + X_2)^2] E[(X_3 + X_4)^2], \\ &= \text{Var}[X_1 + X_2] \text{Var}[X_3 + X_4], & (\text{Var}[Z] = E[Z^2] - E[Z]^2) \\ &= (10)(22), \\ &= 220. \end{aligned}$$

Uppgift 2

Enligt kedjeregeln och givna oberoenderelationerna har vi att

$$f_{\mathbf{X}}(x_1, x_2, x_3, x_4, x_5) = f_{X_1}(x_1)f_{X_2|X_1}(x_2|x_1)f_{X_3|X_2}(x_3|x_2)f_{X_4|X_3}(x_4|x_3)f_{X_5|X_1, X_4}(x_5|x_1, x_4).$$

Enligt definitionen av "Markovsk" har vi då att $\mathbf{X}$ är markovsk med avseende på $\mathcal{G}_3$ enligt definitionen.

Uppgift 3

Vi har att $X \sim \text{Beta}(\theta, \theta)$. Givet ett stickprov $x_1, \dots, x_n$ har vi då att

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}|\theta) &= \prod_{i=1}^n \frac{\Gamma(2\theta)}{\Gamma(\theta)^2} x_i^{\theta-1} (1-x_i)^{\theta-1}, \\ &= \frac{\Gamma(2\theta)^n}{\Gamma(\theta)^{2n}} (x_i(1-x_i))^{\theta-1}, \\ &= \frac{\Gamma(2\theta)^n}{\Gamma(\theta)^{2n}} e^{(\theta-1) \sum_{i=1}^n \log(x_i(1-x_i))} \end{aligned}$$

Det följer att $\sum_{i=1}^n \log(x_i(1-x_i))$ är en tillräcklig statistik för θ . För givet datan är statistikan -4.507 . Svaret är då (c).

Uppgift 4

Vi använder lagen om total varians:

$$\begin{aligned} \text{Var}[X] &= \text{E}[\text{Var}[X|\Lambda]] + \text{Var}[\text{E}[X|\Lambda]], \\ &= \text{E}[\Lambda] + \text{Var}[\Lambda], \\ &= \frac{5}{3} \cdot \frac{5}{3^2}, \\ &= \frac{20}{9}. \end{aligned}$$

Uppgift 5

Stickprovsmomenten är

$$m_1 = 0.344 \quad \text{och} \quad m_2 = 0.482$$

och det andra populationsmomentet ges av

$$\text{E}[X^2] = \text{Var}[X] + \text{E}[X]^2 = \frac{\alpha}{\lambda^2} + \left(\frac{\alpha}{\lambda}\right)^2 = \frac{\alpha(\alpha+1)}{\lambda^2}.$$

Enligt momentmetoden löser vi systemet

$$\begin{aligned} 0.344 &= \frac{\alpha}{\lambda}, \\ 0.482 &= \frac{\alpha(\alpha+1)}{\lambda^2}. \end{aligned}$$

Enligt det första ekvationen har vi att

$$\alpha = 0.344\lambda.$$

När vi stoppa in detta i det andra ekvationen får vi

$$\begin{aligned} 0.482 &= \frac{0.344\lambda(0.344\lambda+1)}{\lambda^2}, \\ 0.482\lambda &= 0.344^2\lambda + 0.344, \\ (0.482 - 0.344^2)\lambda &= 0.344, \\ \lambda &= \frac{0.344}{0.482 - 0.344^2}, \\ \lambda &\approx 0.946. \end{aligned}$$

Det följer att

$$\tilde{\alpha} = (0.344)(0.946) \approx 0.325.$$

Momentmetodens punktskattningen är då $[\tilde{\alpha}, \tilde{\lambda}]^T = [0.325, 0.946]^T$.

Uppgift 6

Log-likelihoodfunktionen ges av

$$\begin{aligned} \ell(\beta, \lambda_1, \lambda_2, \lambda_3 | \mathbf{x}) &= \log \prod_{i=1}^3 f_{X_i, Y_i}(x_i, y_i | \beta, \lambda_i), \\ &= \log \prod_{i=1}^3 f_{X_i}(x_i | \lambda_i) f_{Y_i}(y_i | \beta, \lambda_i), \\ &= \log \prod_{i=1}^3 \frac{e^{-\lambda_i} \lambda_i^{x_i}}{x_i!} \cdot \frac{e^{-\beta \lambda_i} (\beta \lambda_i)^{y_i}}{y_i!}, \\ &= \log \frac{e^{-(\lambda_1 + \lambda_2 + \lambda_3)} e^{-\beta(\lambda_1 + \lambda_2 + \lambda_3)} \left(\prod_{i=1}^3 \lambda_i^{x_i + y_i} \right) \beta^{y_1 + y_2 + y_3}}{\prod_{i=1}^3 x_i! y_i!}, \\ &= -(\lambda_1 + \lambda_2 + \lambda_3) - \beta(\lambda_1 + \lambda_2 + \lambda_3) + \sum_{i=1}^3 (x_i + y_i) \log(\lambda_i) \\ &\quad + (y_1 + y_2 + y_3) \log(\beta) - \log \left(\prod_{i=1}^3 x_i! y_i! \right). \end{aligned}$$

Derivatorna med avseende på var och en parameter ges av

$$\begin{aligned} \frac{d\ell}{d\lambda_i} &= -1 - \beta + \frac{x_i + y_i}{\lambda_i}, \quad (i = 1, 2, 3) \\ \frac{d\ell}{d\beta} &= -(\lambda_1 + \lambda_2 + \lambda_3) + \frac{y_1 + y_2 + y_3}{\beta}. \end{aligned}$$

När vi sätter derivatorna lika med 0 får vi

$$\lambda_i = \frac{x_i + y_i}{\beta + 1} \quad \text{och} \quad \beta = \frac{y_1 + y_2 + y_3}{\lambda_1 + \lambda_2 + \lambda_3}.$$

När vi löser detta system ekvationer får vi

$$\hat{\beta} = \frac{\sum_{i=1}^3 y_i}{\sum_{i=1}^3 x_i} \quad \hat{\lambda}_i = \frac{x_i + y_i}{\hat{\beta} + 1}.$$

Det följer att ML-skattningen för stickprovet är

$$[\beta, \lambda_1, \lambda_2, \lambda_3]^T = [3.125, 1.939, 3.154, 2.909]^T.$$

Uppgift 7

Från föreläsningarna vet vi att ett likelihoodkvottest ges av

Förkasta H_0 om $|\bar{x} - \theta_0| \geq c$.

För att bestämma ett test av nivå $\alpha = 0.05$ betrakta vi styrkefunktion på θ_0 :

$$\begin{aligned}\beta(\theta_0) &= P(|\bar{X} - \theta_0| \geq c | \theta_0), \\ &= P(\bar{X} \geq \theta_0 + c | \theta_0) + P(\bar{X} \leq \theta_0 - c | \theta_0), \\ &= P\left(\frac{\bar{X} - \theta_0}{2/\sqrt{n}} \geq \frac{c}{2/\sqrt{n}} | \theta_0\right) + P\left(\frac{\bar{X} - \theta_0}{2/\sqrt{n}} \leq \frac{-c}{2/\sqrt{n}} | \theta_0\right), \\ &= P(Z \geq c\sqrt{n}/2) + P(Z \leq -c\sqrt{n}/2), \quad (\text{där } Z \sim N(0, 1) \text{ eftersom } \bar{X} \sim N(\theta_0, 4/n)) \\ &= P(Z \geq c) + P(Z \leq -c), \quad (n = 4 \text{ i detta fall}) \\ &= 1 - F_Z(c) + 1 - F_Z(c), \\ &= 2(1 - F_Z(c))\end{aligned}$$

För att ha ett test med nivå $\alpha = 0.05$ vill vi ha c så att $\beta(\theta_0) = 0.05$; dvs. c så att

$$1 - 0.025 = F_Z(c).$$

Det följer att c är 0.025-kvantilen $z_{0.025} = 1.96$. Ett test med nivå $\alpha = 0.05$ ges då av

Förkasta H_0 om $|\bar{x} - \theta_0| \geq 1.96$.

När vi invertera testet får vi intervallet

$$[\bar{x} - 1.96, \bar{x} + 1.96] \approx [3.66, 7.58].$$

Uppgift 8

$X | \Theta_M = \theta_M, \Theta_V = \theta_V \sim N(\theta_M, \theta_V)$ där vi har apriorifördelningen $f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) \sim 1/\theta_V$. Enligt formelsamlingen har vi aposteriorifördelningen

$$\begin{aligned}[\Theta_M, \Theta_V]^T | \mathbf{X} = \mathbf{x} &\sim \text{NInvGamma}(\bar{x}, n, (n-1)/2, (n-1)s^2/2) \\ &\sim \text{NInvGamma}(12.7, 150, 149/2, (149)(9)/2).\end{aligned}$$

Enligt formelsamlingen har vi

$$\Theta_V | \mathbf{X} = \mathbf{x} \sim \text{InvGamma}(149/2, (149)(9)/2).$$

Det följer att

$$E[\Theta_V | \mathbf{X} = \mathbf{x}] = \frac{(149)(9)/2}{149/2 - 1} \approx 9.122.$$

Uppgift 9

Vi låter X betecknar antalet minuter ett slumpmässigt personer lyssnar på poddar. Vi har då att $X | \Theta = \theta \sim N(\theta, 25)$ och stickprovsmedelvärdet är $\bar{x} = 14.537$. Apriorifördelningen är $\Theta \sim N(10, 4)$. Enligt formelsamlingen har vi aposteriorifördelningen $\Theta | \mathbf{X} = \mathbf{x} \sim N(14.270, 0.2353)$. Den prediktiva aposteriorifördelningen ges då av $Y | \mathbf{X} = \mathbf{x} \sim N(14.270, 25 + 0.2353)$. Det följer att $Z = (Y - 14.270)/\sqrt{25.2353} \sim N(0, 1)$. Enligt statstabellen har vi att

$$P(Y > 20 | \mathbf{X} = \mathbf{x}) = P(Z > (20 - 14.270)/\sqrt{25.2353}) = P(Z > 1.14) \approx 1 - 0.8729 = 0.127.$$

Uppgift 10

Aposteriorifördelningen ges av

$$A|\mathbf{X} = \mathbf{x} \sim \text{Gamma}(6, 10.69)$$

enligt formelsamlingen. När $Z \sim \text{Gamma}(6, 10.69)$ har vi att

$$Y = (2)(10.69)Z \sim \text{Gamma}(6, 1/2) = \chi^2(12).$$

Det följer att

$$P(c \leq Y) = 0.05 = P(Y \geq d)$$

när $c = \chi_{12,0.95}^2 = 5.23$ och $d = \chi_{12,0.05}^2 = 21.0$ (enligt statstabellen). Det följer att

$$\begin{aligned} 0.90 &= P(c \leq Y \leq d), \\ &= P(5.23 \leq (2)(10.69)Z \leq 21), \\ &= P\left(\frac{5.23}{(2)(10.69)} \leq Z \leq \frac{21}{(2)(10.69)}\right), \\ &= P\left(\frac{5.23}{(2)(10.69)} \leq A \leq \frac{21}{(2)(10.69)} | \mathbf{X} = \mathbf{x}\right). \end{aligned}$$

Ett symmetriskt 0.90 kredibilitetsintervall är därför

$$\left[\frac{5.93}{(2)(10.69)}, \frac{21}{(2)(10.69)} \right] = [0.245, 0.982].$$

Uppgift 11

Aposteriorioddsen ges av

$$\begin{aligned} \frac{P(\Theta = 6|X = 8)}{P(\Theta = 10|X = 8)} &= \frac{P(X = 8|\Theta = 6)P(\Theta = 6)}{P(X = 8|\Theta = 10)P(\Theta = 10)} \\ &= \frac{P(X = 8|\Theta = 10)(3/4)}{P(X = 8|\Theta = 10)(1/4)} \\ &= \frac{3e^{-6}6^8/8!}{e^{-10}10^8/8!}, \\ &= \frac{3e^{-6}6^8}{e^{-10}10^8}, \\ &\approx 2.751 \end{aligned}$$

Uppgift 12

För $X_1, \dots, X_n$ oberoende och $\text{Exp}(\lambda)$ -fördelade har vi ML-skattningen $\hat{\lambda} = 1/\bar{X}$ för λ . Vi har sett i föreläsningarna att $\bar{X} \sim \text{Gamma}(n, n\lambda)$ för ett sådant stickprov (samplingfördelningen för ett $\text{Exp}(\lambda)$ -fördelade stickprov). Det följer att $1/\bar{X} \sim \text{InvGamma}(n, n\lambda)$. Det systematiska felet

ges då av

$$\begin{aligned}\text{Bias}[\hat{\lambda}] &= \text{E}[\hat{\lambda}] - \lambda, \\ &= \text{E}[1/\bar{X}] - \lambda, \\ &= \frac{n\lambda}{n-1} - \lambda, \quad (\text{enligt formelsamlingen}) \\ &= \left(\frac{n}{n-1} - 1 \right) \lambda, \\ &= \frac{\lambda}{9}\end{aligned}$$

eftersom $n = 10$ i detta fall.

Uppgift 13

(a) Vi löser

$$1 = \int_0^1 c(\theta)(1-x)^{\theta-1} dx$$

för $c(\theta)$. Resultatet är $c(\theta) = \theta$; dvs. $X \sim \text{Beta}(1, \theta)$.

(b) För att hitta momentmetodens punktskattning löser vi ut θ från

$$\bar{x} = \frac{1}{\theta + 1}$$

eftersom $E[X] = 1/(\theta + 1)$ för $X \sim \text{Beta}(1, \theta)$. Resultatet är

$$\tilde{\theta} = \frac{1}{\bar{x}} - 1.$$

Enligt den centrala gränsvärdessatsen har vi att

$$\sqrt{n}(\bar{X} - E[X]) \longrightarrow N(0, \text{Var}[X])$$

Om vi tar $g(u) = (1/u) - 1$ har vi att $g'(u) = -u^{-2}$. Enligt deltametoden har vi då att

$$\sqrt{n}(\tilde{\theta} - g(E[X])) \longrightarrow N(0, \text{Var}[X]/E[X]^4).$$

Eftersom $g(E[X]) = \theta$, $1/E[X]^4 = (\theta + 1)^4$ och $\text{Var}[X] = \theta/((\theta + 1)^2(\theta + 2))$ har vi att

$$\sqrt{n}(\tilde{\theta} - \theta) \longrightarrow N(0, \frac{\theta(\theta + 1)^2}{\theta + 2}).$$

Den asymptotiska variansen är då $\frac{\theta(\theta+1)^2}{\theta+2}$.

(c) Log-likelihoodfunktionen ges av

$$\begin{aligned} \ell(\theta|\mathbf{x}) &= \log \prod_{i=1}^n \theta(1-x)^{\theta-1}, \\ &= n \log(\theta) + (\theta - 1) \sum_{i=1}^n \log(1-x_i). \end{aligned}$$

Det följer att ML-skattningen av θ är

$$\hat{\theta} = \frac{-n}{\sum_{i=1}^n \log(1-x_i)} = \frac{1}{\bar{y}}$$

där $Y_i = -\log(1 - X_i)$. (Man behöver att verifiera med andra derivatan att denna punkt är egentligen det globala maximat.) Vi kan bestämma Y 's fördelning med hjälp av en transformation av stokastiska variabler: $g(x) = -\log(1 - x) = y$. Vi har att $x = g^{-1}(y) = 1 - e^{-y}$ och $\frac{dx}{dy} = e^{-y}$. Det följer att Y har täthetsfunktionen

$$\begin{aligned} f_Y(y) &= f_X(g^{-1}(y))e^{-y}, \\ &= \theta(1 - (1 - e^{-y}))^{\theta-1}e^{-y}, \\ &= \theta(e^{-y})^{\theta-1}e^{-y}, \\ &= \theta e^{-\theta y}. \end{aligned}$$

Det vill säga att $Y_i \sim \text{Exp}(\theta)$. Det följer då att $E[Y] = 1/\theta$ och $\text{Var}[Y] = 1/\theta^2$. Enligt centrala gränsvärdessatsen har vi att

$$\sqrt{n}(\bar{y} - 1/\theta) \longrightarrow N(0, 1/\theta^2).$$

Vi tillämpar deltametoden med funktionen $g(u) = 1/u$ och får ut

$$\sqrt{n}(\hat{\theta} - \theta) \longrightarrow N(0, (-1/(1/\theta)^2)^2(1/\theta^2));$$

dvs.

$$\sqrt{n}(\hat{\theta} - \theta) \longrightarrow N(0, \theta^2).$$

ML-skattningen har då den asymptotiska variansen θ^2 .

Uppgift 14

(a) Enligt empiriska bayesmetoden beräknar vi

$$\begin{aligned}\hat{\theta}_A &= \frac{1}{3}(75.23 + 63.46 + 62.32) \approx 67.003, \\ \hat{\theta}_B &= \frac{1}{3}(91.19 + 74.59 + 81.62) \approx 82.467, \\ \hat{\theta}_C &= \frac{1}{3}(86.57 + 72.02 + 85.41) \approx 81.333.\end{aligned}$$

Vi tar $\hat{\theta}_A, \hat{\theta}_B, \hat{\theta}_C$ som ett stickprov från en $N(\mu, \tau^2)$ -fördelningen och kör momentmetoden för att skatta μ och τ^2 ; dvs. vi löser ut μ och τ^2 från systemet

$$\begin{aligned}76.934 &= \frac{1}{3}(67.003 + 82.467 + 81.333) = \mu, \\ 5968.4363 &= \frac{1}{3}(67.003^2 + 82.467^2 + 81.333^2) = \mu^2 + \tau^2.\end{aligned}$$

Vi får ut punktskattningen

$$\begin{aligned}\mu &= 76.934, \\ \tau^2 &= 5968.4363 - 76.934^2 = 49.596.\end{aligned}$$

Vi tar då apriorifördelningen $\Theta \sim N(76.934, 49.596)$.

(b) Vi har stickprovet 88.45, 95.71. Enligt uppdateringsreglen i formelsamlingen har vi aposteriorifördelningen

$$\Theta | \mathbf{X} = \mathbf{x} \sim N(81.568, 34.421)$$

där vi använder apriorifördelningen från del (a). Vi vill ha ett 0.90 HPD kredibilitetsintervall för θ . Eftersom aposteriorifördelningen $\Theta | \mathbf{X} = \mathbf{x}$ är en $N(81.568, 34.421)$ -fördelningen har vi att aposteriorifördelningen är symmetriskt runt 81.568. Detta betyder att ett 0.90 HPD intervall är detsamma som ett 0.90 symmetriskt kredibilitetsintervall. Vi löser ut då värdet c så att $P(\theta \geq c | \mathbf{X} = \mathbf{x}) = 0.05$. Med hjälp av en standard normalfördelning och statstabellen får vi $c = 1.64\sqrt{34.421} + 81.568$. Det följer att intervallet ges av

$$[-1.64\sqrt{34.421} + 81.568, 1.64\sqrt{34.421} + 81.568] \approx [71.946, 91.190].$$

- (c) Det nytt slumpmässigt utfall Y är $N(\theta, 15^2)$ -fördelad givet $\Theta = \theta$ där $\Theta \sim N(76.934, 49.596)$. Eftersom aposteriorifördelningen $\Theta|\mathbf{X} = \mathbf{x} \sim N(81.568, 34.421)$ har vi att $Y|\mathbf{X} = \mathbf{x} \sim N(81.568, 15^2 + 34.421)$. Sannolikheten att Y är större än 90 är då

$$\begin{aligned} P(Y > 90|\mathbf{X} = \mathbf{x}) &= P\left(\frac{Y - 81.568}{\sqrt{15^2 + 34.421}} > \frac{90 - 81.568}{\sqrt{15^2 + 34.421}}|\mathbf{X} = \mathbf{x}\right), \\ &= P(Z > 0.524), \quad \text{där } Z \sim N(0, 1) \\ &= 1 - P(Z \leq 0.524), \\ &= 1 - 0.6984, \quad (\text{statstabellen}) \\ &\approx 0.302. \end{aligned}$$

Dvs. det finns ungefär en 30% chans att betyget är större än 90.

Uppgift 15

- (a) Vi har $X|\Theta = \theta \sim N(\theta, 100)$ och $\Theta \sim N(100, 15^2)$. När vi använder uppdateringsregeln från formelsamlingen kommer vi att få aposteriorifördelningen $\Theta|\mathbf{X} = \mathbf{x} \sim N(97.8, 18.37)$.
- (b) Vi tar nollhypotesen $H_0 : \theta \geq 100$ och mothypotesen $H_1 : \theta < 100$. Aposteriorisannolikheten av nollhypotesen beräknas som

$$\begin{aligned} P(\Theta \geq 100|\mathbf{X} = \mathbf{x}) &= P\left(\frac{\Theta - 97.8}{\sqrt{18.37}} \geq \frac{100 - 97.8}{\sqrt{18.37}}|\mathbf{X} = \mathbf{x}\right), \\ &= P(Z \geq 0.513), \quad (Z \sim N(0, 1)) \\ &= 1 - P(Z \leq 0.513), \\ &= 1 - 0.695 \quad (\text{statstabellen}) \\ &= 0.305. \end{aligned}$$

Aposteriorioddsen ges då av

$$\begin{aligned} \frac{P(\Theta \geq 100|\mathbf{X} = \mathbf{x})}{P(\Theta < 100|\mathbf{X} = \mathbf{x})} &= \frac{P(\Theta \geq 100|\mathbf{X} = \mathbf{x})}{1 - P(\Theta \geq 100|\mathbf{X} = \mathbf{x})}, \\ &= \frac{0.305}{1 - 0.305}, \\ &= 0.439. \end{aligned}$$

- (c) Enligt antagande använder vi förlustfunktionen

$$L(a, \theta) = \begin{cases} 2(\theta - a) & a \leq \theta \\ 1(a - \theta) & a > \theta. \end{cases}$$

Bayesskattning är beslutet $a \in (-\infty, \infty)$ som minimerar aposterioririsken $E[L(a, \theta)|\mathbf{X} = \mathbf{x}]$. När vi minimerar denna funktion (av a) ser vi att bayesskattningen är aposteriorifördelningens (1/3)-kvantil; dvs. vi vill hitta värdet a så att

$$F_{\Theta|\mathbf{X}}(a|\mathbf{x}) = 1 - (1/3) = 2/3.$$

Med hjälp av statstabellen ser vi att bayesskattningen är

$$a = 0.43\sqrt{18.37} + 97.8 \approx 99.64.$$

Uppgift 16

(a) Log-likelihoodfunktionen ges av

$$\begin{aligned}\ell(\lambda|\mathbf{x}) &= \log \prod_{i=1}^n \lambda e^{-\lambda x_i}, \\ &= n \log(\lambda) - \lambda n \bar{x}.\end{aligned}$$

Det följer att

$$\begin{aligned}\frac{d\ell}{d\lambda} &= \frac{n}{\lambda} - n\bar{x}, \\ \frac{d^2\ell}{d\lambda^2} &= -\frac{n}{\lambda^2}.\end{aligned}$$

När vi sätter den första derivatan lika med 0 och löser ut λ får vi den kritiska punkten $\hat{\lambda} = 1/\bar{x}$. Enligt den andra derivatan ovan ser vi att denna punkt är egentligen en den globala maximat och därför är ML-skattningen av λ . Vi beräknar då likelihoodkvoten:

$$\begin{aligned}\lambda(\mathbf{x}) &= \frac{L(\lambda_0|\mathbf{x})}{L(\hat{\lambda}|\mathbf{x})}, \\ &= \frac{\prod_{i=1}^n \lambda_0 e^{-\lambda_0 x_i}}{\prod_{i=1}^n \hat{\lambda} e^{-\hat{\lambda} x_i}}, \\ &= \frac{\lambda_0^n e^{-\lambda_0 n \bar{x}}}{(1/\bar{x})^n e^{-n}}, \quad (\text{eftersom } \hat{\lambda} = 1/\bar{x}) \\ &= (\lambda_0 \bar{x})^n e^{-n(\lambda_0 \bar{x})} e^n.\end{aligned}$$

Ett likelihoodkvottest ges då av

$$\text{Förkasta } H_0 : \lambda = \lambda_0 \text{ om } (\lambda_0 \bar{x})^n e^{-n(\lambda_0 \bar{x})} \leq c'$$

där $c' = ce^{-n}$ för något $c \in (0, 1)$.

I testet har vi en funktion på formen $f(u) = u^d e^{-du}$ där d är en positiv konstant och $u \in (0, \infty)$. Vi hävdar att $f(u)$ är en unimodal funktion med maximum i 1. För att se detta notera att den första derivatan av $f(u)$ ges av

$$f'(u) = dx^{d-1}e^{-du} + u^d(-d)x^{-du} = du^{d-1}e^{-du}(1-u).$$

I intervallet $(0, \infty)$ har vi bara en kristisk punkt: $u = 1$. Det andra derivatan ges av

$$\begin{aligned}f''(u) &= d(d-1)u^{d-2}e^{-du} + (-d)du^{d-1}e^{-du} + du^{d-1}(-d)e^{-du} + (-d)^2u^d e^{-du}, \\ &= e^{-du}u^{d-2}(d^2 - d - 2d^2u + d^2u^2), \\ &= e^{-du}u^{d-2}(2d^2(u-1)^2 - d).\end{aligned}$$

Det följer att $f''(1) < 0$ och vi har då att $u = 1$ är det globala maximat på intervallet $(0, \infty)$.

När $x < 1$ har vi att $f'(u) > 0$ och $f(u)$ är då växande. Å andra sidan har vi att $f'(u) < 0$ då $u > 1$. I detta fall är $f(u)$ avtagande. Det följer att $f(u)$ är unimodal med maximat i $u = 1$ på intervallet $(0, \infty)$.

I vårt fall har vi att $u = \lambda_0 \bar{x}$ och $d = n$. Det följer att likelihoodkvottestet ges av

Förkasta H_0 om $\lambda_0 \bar{x} \leq a$ eller $\lambda_0 \bar{x} \geq b$

för några konstanter a och b .

Under nollhypotesen har vi att $\lambda = \lambda_0$ och $X_1, \dots, X_n$ är $\text{Exp}(\lambda_0)$ -fördelade. Det följer med hjälp av en transformation av stokastiska variabler att $\bar{X} \sim \text{Gamma}(n, n\lambda_0)$. Enligt formelsamlingen har vi då att $2n\lambda_0 \bar{X} \sim \chi^2(2n)$. I detta fall har vi $n = 11$. Med hjälp av statstabellen har vi att sannolikheten att vi förkasta nollhypotesen trots att den stämmer är lika med 0.05 om och endast om $a = 1$ och $b = 36.8/22 \approx 1.673$. Ett test med nivå $\alpha = 0.05$ ges då av

Förkasta H_0 om $\lambda_0 \bar{x} \leq 1$ eller $\lambda_0 \bar{x} \geq 1.673$.

(b) Acceptansområdet för testet i del (a) ges av

$$A(\lambda_0) = \{\mathbf{x} : 1/\lambda_0 \leq \bar{x} \leq 1.673/\lambda_0\}.$$

Motsvarande konfidensintervallet ges då av

$$C(\mathbf{x}) = \{\lambda : 1/\bar{x} \leq \lambda \leq 1.673/\bar{x}\}.$$

Stickprovsmedelvärdet för givet datan är $\bar{x} = 20.909$. Det följer att intervallet är

$$[0.0478, 0.0800].$$