



Avd. Matematisk statistik

KTH Matematik

TENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS

Examiner: Joakim Andén, 08-790 80 52.

Tillåtna hjälpmedel: miniräknare, formel- och tabellsamling (utan anteckningar)

Tentamen består av sex uppgifter där varje uppgift är värd fem poäng. För att få godkänt krävs minst femton poäng. Möjlighet till komplettering ges vid fjorton poäng. I varje lösning ska resonemang och uträkningar vara så utförliga och väl motiverade att de är lätta att följa. Införda beteckningar ska förklaras och definieras och numeriska svar ska anges med minst två värdesiffrors noggrannhet. För studenter har fått bonuspoäng på inlämningsuppgiften läggs dessa poäng till poängsumman. Detta gäller bara för denna tentamen och omtentamen för denna kursomgång.

Tentamen kommer att vara rättad inom tre arbetsveckor från skrivningstillfället.

Uppgift 1

Låt $X \sim N(0, 1)$ och $Z \sim \text{InvGamma}(1/2, 1/2)$ där $X \perp Z$. Bestäm täthetsfunktionen för $X\sqrt{Z}$. (5 p)

Uppgift 2

Antag att vi har ett slumpmässigt stickprov $x_1, \dots, x_n$ från $U(a, b)$ som består av

8.77, 7.03, 4.70, 6.77, 2.70.

(a) Skatta a och b med hjälp av momentmetoden. (2 p)

(b) Skatta a och b med hjälp av ML-metoden. (3 p)

Uppgift 3

Låt $X_1, \dots, X_n$ vara betingat oberoende givet Θ så att $X_i \mid \Theta = \theta \sim \text{Po}(\theta)$ för $i = 1, \dots, n$. Antag vidare att Θ har apriorifördelningen $\text{Gamma}(\alpha_0, \lambda_0)$. Bestäm Bayesskattningen av Θ givet förlustfunktionen $L(\theta, a) = \theta(\theta - a)^2$ och tillämpa denna på datan

2, 2, 7, 2, 1, 7

med $\alpha_0 = 8$ och $\lambda_0 = 7$. (5 p)

Uppgift 4

Antag att vi observerar följande datapunkter från en normalfördelning $N(\mu, \sigma^2)$:

$$-0.42, \quad 2.06, \quad 2.76, \quad 2.26, \quad 5.54, \quad 20.76$$

där μ och σ^2 båda är okända. Sätt en icke-informativ apriorifördelning på μ och σ^2 och antag att vi kommer observera 10 nya datapunkter från samma fördelning och beräkna deras stickprovsmedelvärde $\bar{Y}$. Beräkna ett intervall som innehåller $\bar{Y}$ med 95% sannolikhet givet datan ovan (dvs. ett så kallat bayesianskt prediktionsintervall). (5 p)

Uppgift 5

Låt X vara fördelad enligt täthetsfunktionen

$$f_X(x) = \frac{1}{2}e^{-|x-\mu|}$$

för något $\mu \in \mathbb{R}$.

- (a) Ta fram ett likelihoodkvottest som prövar $H_0 : \mu \leq \mu_0$ mot $H_1 : \mu > \mu_0$ givet ett observerat värde på X med storlek α . (3 p)
- (b) Antag att vi observerar $X = 3.8$. Beräkna ett nedåt begränsat ensidigt konfidensintervall för μ med konfidensgrad 95%. (2 p)

Uppgift 6

I SCB:s partisynpatiuundersökning som genomfördes i maj 2025 fick ett antal respondenter svara på frågan ”Om det var val idag, vilket parti skulle du rösta på?”. Resultaten var följande för de åtta riksdagspartierna:

Parti	C	L	M	KD	S	V	MP	SD
Antal	253	129	841	156	1663	326	299	827

Antag att vi har en icke-informativ apriorifördelning för de sanna andelarna (proportionerna) av den röstberättigade populationen som tänker rösta på var och ett av partierna.

- (a) Vad är sannolikheten att KD hamnar över riksdagssparren (4% av rösterna)? (2 p)
- (b) Om vi bortser från att partier kan hamna under riksdagssparren (och de motsvarande rösterna inte räknas), vad är sannolikheten att S+V+MP erhåller en egen majoritet (mer än 50% av rösterna)? (2 p)
- (c) Gör samma beräkning för en annan möjlig regeringskoalition. (1 p)

Ledning: Beta(α, β) kan approximeras av en normalfördelning då $\alpha, \beta \rightarrow +\infty$.

Lycka till!



Avd. Matematisk statistik

KTH Matematik

LÖSNINGSFÖRSLAG TILL TENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS

Uppgift 1

Vi har alltså

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \quad \text{och} \quad f_Z(z) = \frac{(1/2)^{1/2}}{\Gamma(1/2)} z^{-1/2-1} e^{-1/2z} = \frac{1}{\sqrt{2}\Gamma(1/2)} z^{-3/2} e^{-1/2z}$$

och sätter $U = X\sqrt{Z}$ samt $V = 1/\sqrt{Z}$, vilket ger inversen $X = UV$ och $Z = 1/V^2$.

Vi tar fram jakobimatrisen och får jakobideterminanten:

$$\frac{\partial(x, y)}{\partial(u, v)} = \begin{vmatrix} v & u \\ 0 & -\frac{2}{v^3} \end{vmatrix} = -\frac{2}{v^2}.$$

För att ta fram domänen för U och V betraktar vi domänen för X och Z där vi har $X \in \mathbb{R}$ och $Z \in \mathbb{R}_{\geq 0}$. Alltså måste vi ha $U \in \mathbb{R}$ och $V \in \mathbb{R}_{\geq 0}$. Vi får alltså den simultana täthetsfunktionen

$$f_{U,V}(u, v) = \frac{1}{\sqrt{2\pi}} e^{-u^2 v^2/2} \cdot \frac{1}{\sqrt{2}\Gamma(1/2)} \left(\frac{1}{v^2}\right)^{-3/2} e^{-1/2(1/v^2)} \cdot \frac{2}{v^2} = \frac{v}{\sqrt{\pi}\Gamma(1/2)} e^{-(u^2+1)v^2/2}.$$

Vi integrerar nu längsmed v för att få marginalfördelningen för U , vilket görs enklast med variabelbytet $t = (u^2 + 1)v^2/2$ och ger

$$\begin{aligned} f_U(u) &= \int_0^{+\infty} \frac{v}{\sqrt{\pi}\Gamma(1/2)} e^{-(u^2+1)v^2/2} dv \\ &= \frac{1}{\sqrt{\pi}\Gamma(1/2)} \int_0^{+\infty} \frac{1}{u^2+1} e^{-t} dt \\ &= \frac{1}{\sqrt{\pi}\Gamma(1/2)(u^2+1)}, \end{aligned}$$

där vi har använt att $v dv = dt/(u^2 + 1)$. Vi kan förenkla ytterligare om vi kommer ihåg att $\Gamma(1/2) = \sqrt{\pi}$, vilket i så fall ger

$$f_U(u) = \frac{1}{\pi(u^2+1)}.$$

Uppgift 2

(a) Första och andra momentet för $U(a, b)$ ges av

$$\mu_1 = \frac{a+b}{2}$$

respektive

$$\mu_2 = \frac{(b-a)^2}{12} + \mu_1^2.$$

Vi kan alltså lösa ut a och b ifrån dessa med hjälp av

$$\frac{(b-a)^2}{12} = \mu_2 - \mu_1^2,$$

dvs.

$$|b-a| = \sqrt{12(\mu_2 - \mu_1^2)}.$$

Detta ger i sin tur

$$\begin{aligned} a &= \mu_1 - \frac{1}{2}\sqrt{12(\mu_2 - \mu_1^2)} = \mu_1 - \sqrt{3(\mu_2 - \mu_1^2)} \\ b &= \mu_1 + \frac{1}{2}\sqrt{12(\mu_2 - \mu_1^2)} = \mu_1 + \sqrt{3(\mu_2 - \mu_1^2)} \end{aligned}$$

Från datapunkterna har vi

$$\hat{\mu}_1 = 5.994 \quad \text{sam} \quad \hat{\mu}_2 \approx 40.309,$$

vilket ger skattningarna

$$\hat{a} \approx 2.369 \quad \text{sam} \quad \hat{b} \approx 9.619.$$

(b) Vi har alltså täthetsfunktionen

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{annars,} \end{cases}$$

vilket ger upphov till likelihoodfunktionen

$$\begin{aligned} L(a, b; \mathbf{x}) &= \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_1, x_2, \dots, x_n \leq b, \\ 0, & \text{annars,} \end{cases} \\ &= \begin{cases} \frac{1}{(b-a)^n}, & a \leq \min_i x_i, b \geq \max_i x_i, \\ 0, & \text{annars.} \end{cases} \end{aligned}$$

Likelihoodfunktionen är alltså endast nollskildd då $a \leq \min_i x_i$ samt $b \geq \max_i x_i$ men minskar i värde då avståndet $b - a$ blir större. Maximalvärdet på likelihoodfunktionen uppnås då både $a \leq \min_i x_i$ och $b \geq \max_i x_i$ men avståndet mellan a och b är som minst. De värden som maximerar likelihoodfunktionen måste alltså vara $a = \min_i x_i$ och $b = \max_i x_i$ och dessa utgör alltså ML-skattningen.

För datan har vi alltså

$$\hat{a} = \min_i x_i = 2.7 \quad \text{och} \quad \hat{b} = \max_i x_i = 8.77.$$

Uppgift 3

Vi vill minimera aposterioririsken med avseende på $L(\theta, a) = \theta(\theta - a)^2$, vilken ges av

$$\begin{aligned} E[L(\Theta, a) \mid \mathbf{X} = \mathbf{x}] &= \int_{\mathbb{R}} \theta(\theta - a)^2 f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) d\theta \\ &= \int_{\mathbb{R}} \theta^3 f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) d\theta - 2a \int_{\mathbb{R}} \theta^2 f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) d\theta + a^2 \int_{\mathbb{R}} \theta f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) d\theta. \end{aligned}$$

Detta är en kvadratisk form i a som minimeras genom att derivera och sätta derivatan till noll. Vi får då

$$a = \frac{\int_{\mathbb{R}} \theta^2 f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) d\theta}{\int_{\mathbb{R}} \theta f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) d\theta},$$

vilket alltså är Bayesskattningen givet $L(\theta, a)$.

Med datan får vi aposteriorifördelningen till $\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Gamma}(29, 13)$, vilket då ger

$$\frac{\int_{\mathbb{R}} \theta^2 f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) d\theta}{\int_{\mathbb{R}} \theta f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) d\theta} = \frac{\frac{29(29+1)}{13^2}}{\frac{29}{13}} = \frac{29+1}{13} \approx 2.308.$$

Uppgift 4

Vi observerar alltså n datapunkter från en $N(\theta_M, \theta_V)$ -fördelning och vill ta fram ett prediktionsintervall för en $N(\theta_M, \theta_V/m)$ -fördelning. En icke-informativ apriorifördelning kommer att ge oss en aposteriorifördelning på formen $\text{NInvGamma}(\mu, \lambda, \alpha, \beta)$, så låt oss anta att $\Theta_M, \Theta_V \mid \mathbf{X} = \mathbf{x}$ har denna fördelning.

Vi söker alltså marginalfördelningen för $Y \mid \mathbf{X} = \mathbf{x}$ där $Y \mid \Theta_M = \theta_M, \Theta_V = \theta_V \sim N(\theta_M, \theta_V/m)$. Denna får genom lagen om total sannolikhet, dvs.

$$\begin{aligned} f_{Y|\mathbf{X}}(y \mid \mathbf{x}) &= \int_{\mathbb{R}} f_{Y|\Theta_M, \Theta_V}(y \mid \theta_M, \theta_V) f_{\Theta_M, \Theta_V|\mathbf{X}}(\theta_M, \theta_V \mid \mathbf{x}) d\theta_M d\theta_V \\ &\propto \int_{\theta_M=-\infty}^{+\infty} \int_{\theta_V=0}^{+\infty} \frac{1}{\sqrt{\theta_V}} e^{-m(y-\theta_M)^2/\theta_V} \cdot \frac{\theta_V^{-\alpha-1}}{\sqrt{\theta_V}} e^{-\frac{1}{\theta_V}(2\beta+\lambda(\theta_M-\mu)^2)} d\theta_V d\theta_M \\ &\propto \int_{\theta_M=-\infty}^{+\infty} \int_{\theta'_V=0}^{+\infty} \frac{1}{\sqrt{\theta'_V}} e^{-(y-\theta_M)^2/\theta'_V} \cdot \frac{\theta'_V{}^{-\alpha-1}}{\sqrt{\theta'_V}} e^{-\frac{1}{m\theta'_V}(2\beta+\lambda(\theta_M-\mu)^2)} d\theta'_V d\theta_M \\ &\propto \int_{\theta_M=-\infty}^{+\infty} \int_{\theta'_V=0}^{+\infty} \frac{1}{\sqrt{\theta'_V}} e^{-(y-\theta_M)^2/\theta'_V} \cdot \frac{\theta'_V{}^{-\alpha-1}}{\sqrt{\theta'_V}} e^{-\frac{1}{\theta'_V}(2\frac{\beta}{m}+\frac{\lambda}{m}(\theta_M-\mu)^2)} d\theta'_V d\theta_M, \end{aligned}$$

där vi har gjort variabelbytet $\theta'_V = \theta_V/m$. Den sista integralen motsvarar hierarkin $Z \mid \Theta_M = \theta_M, \Theta_V = \theta'_V \sim N(\theta_M, \theta'_V)$ samt $\Theta_M, \Theta'_V \sim \text{NInvGamma}(\mu, \lambda/m, \alpha, \beta/m)$ och vi vet att marginalfördelningen här ges av

$$t\left(2\alpha, \mu, \frac{(\beta/m)(\lambda/m+1)}{\alpha\lambda/m}\right) = t\left(2\alpha, \mu, \frac{\beta}{\alpha} \left(\frac{1}{\lambda} + \frac{1}{m}\right)\right).$$

Stoppar vi in värdena för aposteriorifördelningen (med en icke-informativ apriorifördelning) får vi $\mu = \bar{x}$, $\lambda = n$, $\alpha = (n-1)/2$ och $\beta = s^2(n-1)/2$, vilket ger fördelningen $t(n-1, \bar{x}, s^2(1/n+1/m))$. Ett symmetriskt, 95%-igt prediktionsintervall ges alltså av

$$\bar{x} \pm t_{0.025}(n-1)s\sqrt{\frac{1}{n} + \frac{1}{m}}.$$

Från datan har vi $n = 6$, $\bar{x} \approx 5.493$, $s^2 \approx 59.551$ samt $m = 10$, vilket ger

$$5.493 \pm 10.241 \approx [-4.748, 15.735].$$

Uppgift 5

(a) Vi tar först fram ML-skattningen för μ . Likelihoodfunktionen ges av

$$L(\mu; x) = \frac{1}{2} e^{-|\mu-x|}$$

och denna maximeras i punkten $\hat{\mu} = x$ som då är vår ML-skattning (maxvärdet är $1/2$ och uppnås endast då $\mu = x$).

För likelihoodkvoten krävs också det maximala likelihoodvärdet över parametermängden för nollhypotesen $H_0 : \mu \leq \mu_0$, dvs.

$$\max_{\mu \leq \mu_0} L(\mu; x).$$

Låt oss benämna $\hat{\mu}_0$ som det värde på μ som maximerar $L(\mu; x)$ över $(-\infty, \mu_0)$. Vi har då två möjliga situationer. Om $\mu_0 \geq x$ så innehåller intervallet $x = \hat{\mu}$, och samma värde som maximerar $L(\mu; x)$ globalt maximerar funktionen också över intervallet. Vi har alltså $\hat{\mu}_0 = \hat{\mu} = x$. Om $\mu \leq x$ så är $L(\mu; x)$ strikt växande på intervallet och antar alltså sitt maxvärde i punkten $\hat{\mu}_0 = \mu_0$.

Likelihoodkvoten blir alltså på följande form

$$\begin{aligned} \lambda(x) &= \frac{\max_{\mu \leq \mu_0} L(\mu; x)}{\max_{\mu \in \mathbb{R}} L(\mu; x)} = \frac{L(\hat{\mu}_0; x)}{L(\hat{\mu}; x)} \\ &= \begin{cases} \frac{L(x; x)}{L(x; x)}, & x \leq \mu_0, \\ \frac{L(\mu_0; x)}{L(x; x)}, & x > \mu_0 \end{cases} \\ &= \begin{cases} 1, & x \leq \mu_0, \\ e^{-|x-\mu_0|}, & x > \mu_0. \end{cases} \end{aligned}$$

Vi förkastar alltså om $x > \mu_0$ och $e^{-|x-\mu_0|} < c$ för något $c \in (0, 1)$ (vi behöver inte betrakta fallet $x \leq \mu_0$ då vi aldrig kommer ha att $\lambda(x) = 1 < c$). Detta är ekvivalent med att $x > \mu_0 + c'$ för något c' .

Vi bestämmer c' med hjälp av storleken α då vi vill ha

$$P(X \leq \mu_0 + c'; \mu_0) = \alpha$$

vilket kan skrivas om till

$$\int_{\mu_0+c'}^{+\infty} \frac{1}{2} e^{-|x-\mu_0|} dx = \frac{1}{2} e^{-c'} = \alpha.$$

Med andra ord tar vi $c' = -\log 2\alpha$ och får följande hypotestest.

$$\text{Förkasta } H_0 : \mu \leq \mu_0 \text{ till förmån för } H_1 : \mu > \mu_0 \text{ om } x > \mu_0 - \log 2\alpha.$$

- (b) Inverterar vi hypotestestet ovan får vi ett $(1 - \alpha)$ konfidensintervall på formen

$$[x + \log 2\alpha, +\infty)$$

Med observationen $x = 3.8$ och $\alpha = 0.05$ ger detta

$$[1.497, +\infty).$$

Uppgift 6

Vi ansätter en likformig fördelning över andelarna, vilket ger Dirichlet(1) som apriorifördelning och vi får därför följande aposterorifördelning

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Dirichlet}([254, 130, 842, 157, 1664, 327, 300, 828]^T)$$

där $\Theta = [\Theta_C, \Theta_L, \Theta_M, \Theta_{KD}, \Theta_S, \Theta_V, \Theta_{MP}, \Theta_{SD}]^T$.

- (a) Vi är alltså intresserade av $P(\Theta_{KD} > 0.04 \mid \mathbf{X} = \mathbf{x})$. Från formelsamlingen har vi att marginalfördelningen för ett element av en Dirichletfördelning är betafördelningen där första parametern tas från den motsvarande parametern i Dirichletfördelningen och den andra tas som summan av resterande parametrar. Vi får alltså $\Theta_{KD} \mid \mathbf{X} = \mathbf{x} \sim \text{Beta}(157, 4345)$. Med hjälp normalapproximationen (vi arbetar med stora parametrar här för betafördelningen) får vi att Θ_{KD} är approximativt normalfördelad med väntevärde 0.03487 och standardavvikelse 0.0027339. Alltså är sannolikheten

$$1 - \Phi\left(\frac{0.04 - 0.03487}{0.0027339}\right) \approx 1 - \Phi(1.88) \approx 1 - 0.9699 \approx 0.0301.$$

- (b) På samma sätt kan vi ta marginalfördelningen för summan $\Theta_S + \Theta_V + \Theta_{MP}$ vilken ges av $\text{Beta}(1664 + 327 + 300, 254 + 130 + 842 + 157 + 828) = \text{Beta}(2291, 2211)$. Här har vi väntevärde 0.5089 och standardavvikelse 0.007450, vilket ger sannolikheten

$$\begin{aligned} P(\Theta_S + \Theta_V + \Theta_{MP} > 0.50 \mid \mathbf{X} = \mathbf{x}) &\approx 1 - \Phi\left(\frac{0.50 - 0.5089}{0.007450}\right) \approx 1 - \Phi(-1.19) \\ &= \Phi(1.19) \approx 0.8830. \end{aligned}$$

- (c) "Januariavtalet II: Återkomsten" skulle ge följande fördelning för $\Theta_C + \Theta_L + \Theta_S + \Theta_{MP} \mid \mathbf{X} = \mathbf{x}$:

$$\text{Beta}(254 + 130 + 1664 + 300, 842 + 327 + 828) = \text{Beta}(2348, 1997),$$

vilket approximeras med en normalfördelning med väntevärde 0.5404 och standardavvikelse 0.007560, vilket ger en sannolikhet på

$$\begin{aligned} P(\Theta_C + \Theta_L + \Theta_S + \Theta_{MP} > 0.50 \mid \mathbf{X} = \mathbf{x}) &\approx 1 - \Phi\left(\frac{0.50 - 0.5404}{0.007560}\right) \approx 1 - \Phi(-5.344) \\ &= \Phi(5.344) \approx 1. \end{aligned}$$