



Avd. Matematisk statistik

KTH Matematik

TENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS

Examiner: Joakim Andén, 08-790 80 52.

Tillåtna hjälpmedel: miniräknare, formel- och tabellsamling (utan anteckningar)

Tentamen består av sex uppgifter där varje uppgift är värd fem poäng. För att få godkänt krävs minst femton poäng. Möjlighet till komplettering ges vid fjorton poäng. I varje lösning ska resonemang och uträkningar vara så utförliga och väl motiverade att de är lätta att följa. Införda beteckningar ska förklaras och definieras och numeriska svar ska anges med minst två värdesiffrors noggrannhet. För studenter som har fått bonuspoäng på inlämningsuppgiften läggs dessa poäng till poängsumman. Detta gäller bara för denna tentamen och omtentamen för denna kursomgång. Tentamen kommer att vara rättad inom tre arbetsveckor från skrivningstillfället.

Uppgift 1

Varje måndagsmorgon tar Cecilia, lektor vid matematikinstitutionen, bilen till KTH. Parkeringsplatserna går snabbt åt och hon är därför intresserad av att modellera antalet lediga parkeringsplatser vid en viss tidpunkt (kl. 09:00) som kan antas följa en Poissonfördelning med parameter θ . Från tidigare erfarenhet gissar hon på att θ borde ligga runt 2 med standardavvikelse 1. Varje vecka noterar Cecilia antalet lediga parkeringsplatser utanför institutionen och observerar följande data:

0, 2, 0, 3, 1, 0, 1.

Vad är sannolikheten att det finns minst en parkeringsplats ledig nästa måndag? (5 p)

Uppgift 2

Antag att du observerar ett stickprov $x_1, x_2, \dots, x_n$ från en $\text{Exp}(\theta)$ -fördelning.

(a) Vad är den minsta möjliga variansen hos en väntevärdesriktig punktskattning för θ ? (3 p)

(b) Finns det någon väntevärdesriktig punktskattning som har denna varians? Om så är fallet, hur ser denna punktskattning ut? (2 p)

Uppgift 3

Anders, en hönsfarmare utanför Linköping, överväger att byta till ett ekologiskt foder för sina höns men är orolig för att äggproduktionen ska minska. Fodret kostar lite mer men ger också ett högre pris på äggen då han kan ansöka om KRAV-märkning för dem. Han provar då därför att ge hönsen båda fodertyperna under en period av nio veckor vardera och mäter antalet ägg som hönsen producerar. Följande data samlas in:

Icke-ekologiskt foder

Foderkostnad 10 000 kr per vecka

Äggpris: 3 kr per ägg

Antal producerade ägg per vecka:

 $\bar{x} = 4051, s = 115$ **Ekologiskt foder**

Foderkostnad 12 000 kr per vecka

Äggpris: 4 kr per ägg

Antal producerade ägg per vecka:

 $\bar{x} = 3508, s = 52.1$

För att gardera sig mot variation i produktionen är Anders intresserad av ett rimligt golv på den veckovisa vinsten. Ta fram en 95%-ig kvantil för den veckovinsten i båda fallen, dvs. det värde som vinsten överstiger med 95% sannolikhet. Vilket foder borde Anders välja? (5 p)

Uppgift 4

Hans arbetar för Naturvårdsverket och har i uppdrag att undersöka halterna av kvicksilver i ett visst vattendrag. Det finns två fabriker som släpper ut restprodukter i en å som rinner ned i vattendraget och han vet sedan tidigare att deras utsläpp kan modelleras enligt en normalfördelning med väntevärde 10 och standardavvikelse 2 (mätt i nanogram per liter). Utöver detta finns det en naturlig tillkomst i ån (genom erosion) som modelleras enligt en normalfördelning med väntevärde noll och varians ett. Antag att den totala halten vattendraget ges av summan av dessa tre källor.

Vid sina mätningar får Hans värdet 24 nanogram per liter i vattendraget och lyckas mäta den ena fabriken utsläpp till 8 nanogram per liter. Han kommer dock inte åt att mäta utsläppet hos den andra fabriken. Vad är sannolikheten att utsläppen hos den andra fabriken överstiger det tillåtna gränsvärdet på 15 nanogram per liter? (5 p)

Uppgift 5

Låt X vara standardnormalfördelad och betrakta $Y = |X|$. Du vill simulera utfall från Y med hjälp av förkastelsemetoden och använda en exponentialfördelning $\text{Exp}(\lambda)$ som kandidat.

- (a) Vad är det optimala värdet för λ om du vill minimera antalet förkastelseiterationer? (3 p)
- (b) Använd detta resultat för att formulera en metod för simulering av standardnormalfördelningen. Är denna att föredra jämfört med Box–Mullers algoritm? (2 p)

Uppgift 6

Antag att du har ett stickprov $x_1, x_2, \dots, x_n$ från en $\text{Beta}(\theta, 1)$ -fördelning. Ta fram ett likelihood-kvottest för $H_0 : \theta = 1$ mot $H_1 : \theta > 1$ med storlek α . (5 p)

Lycka till!



Avd. Matematisk statistik

KTH Matematik

LÖSNINGSFÖRSLAG TILL TENTAMEN I SF1930 STATISTISK INLÄRNING OCH DATAANALYS

Uppgift 1

Antag $X \mid \Theta = \theta \sim \text{Po}(\theta)$. Vi modellerar Cecilia's förkunskap med en gammafördelning som apriorifördelning

$$\Theta \sim \text{Gamma}(\alpha, \lambda).$$

Vi har alltså $E(\Theta) = \alpha/\lambda$ och $\text{Std}(\Theta) = \sqrt{\alpha}/\lambda$. Uppgiften anger $E(\Theta) = 2$ och $\text{Std}(\Theta) = 1$, vilket ger

$$\frac{\alpha}{\lambda} = 2, \quad \frac{\sqrt{\alpha}}{\lambda} = 1 \implies \alpha = 4, \lambda = 2.$$

Alltså $\Theta \sim \text{Gamma}(4, 2)$.

Vår data är $n = 7$ och $\sum_{i=1}^n x_i = 0 + 2 + 0 + 3 + 1 + 0 + 1 = 7$. Datafördelningen ges av

$$f_{\mathbf{X}|\Theta}(\mathbf{x} \mid \theta) \propto \theta^{\sum x_i} e^{-n\theta}.$$

Konjugering ger aposteriorifördelningen

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Gamma}(\alpha + \sum x_i, \lambda + n) = \text{Gamma}(11, 9).$$

Vi söker den aposterioriprediktiva sannolikheten

$$P(X_{\text{ny}} \geq 1 \mid \mathbf{X} = \mathbf{x}) = 1 - P(X_{\text{ny}} = 0 \mid \mathbf{x}).$$

Eftersom $X_{\text{ny}} \mid \Theta = \theta \sim \text{Po}(\theta)$ och $\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Gamma}(11, 9)$ så ser vi att $X_{\text{ny}} \mid \mathbf{X} = \mathbf{x} \sim \text{NegBin}(11, 9/(9+1))$ enligt hierarkitabellen i formelsamlingen. Vi får då alltså att

$$P(X_{\text{ny}} = 0 \mid \mathbf{x} = \mathbf{X}) = \left(\frac{9}{10}\right)^{11}.$$

Alltså är svaret

$$P(X_{\text{ny}} \geq 1 \mid \mathbf{X} = \mathbf{x}) = 1 - \left(\frac{9}{10}\right)^{11} \approx 0.686.$$

Uppgift 2

Antag att $X_1, \dots, X_n$ är ett stickprov från exponentialfördelningen med parameter θ , dvs.

$$f_{X_i|\Theta}(x_i \mid \theta) = \theta e^{-\theta x_i}, \quad x_i \in \mathbb{R}_{>0}.$$

(a) Log-likelihoodfunktionen för utfallet $X = x$ är

$$\log L(\theta \mid x) = \log f_{X|\Theta}(x \mid \theta) = \log \theta - \theta x.$$

Derivatorna ges av

$$\frac{\partial}{\partial \theta} \log L(\theta \mid x) = \frac{1}{\theta} - x, \quad \frac{\partial^2}{\partial \theta^2} \log L(\theta \mid x) = -\frac{1}{\theta^2}.$$

Fisherinformationen blir

$$I(\theta) = -n \mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \log L(\theta \mid X) \right) = \frac{n}{\theta^2}.$$

För en väntevärdesriktig skattning $W(\mathbf{X})$ av $g(\theta) = \theta$ ger Cramér–Rao:

$$\text{Var}(W(\mathbf{X})) \geq \frac{1}{I(\theta)} = \frac{\theta^2}{n}.$$

(b) Log-likelihoodfunktionen för hela stickprovet $\mathbf{X}$ ges av

$$\log f_{\mathbf{X}}(\mathbf{x} \mid \theta) = n \log \theta - \theta \sum_{i=1}^n x_i$$

med derivata

$$\frac{d}{d\theta} \log f_{\mathbf{X}}(\mathbf{x} \mid \theta) = \frac{n}{\theta} - \sum_{i=1}^n x_i.$$

Skriver vi om detta på formen $a(\theta)(W(\mathbf{x}) - g(\theta))$ får vi

$$a(\theta) = -n, \quad W(\mathbf{x}) = \bar{x}, \quad g(\theta) = \frac{1}{\theta}.$$

Med andra ord är det endast möjligt att uppnå minimal varians bland väntevärdesriktiga skattningar av $1/\theta$ (dvs. skalan, inte intensiteten) och denna skattning ges av $\bar{x}$.

Uppgift 3

Vi modellerar antalet ägg per vecka som normalfördelat givet okända parametrar. Samma modell gäller för fallet med ekologiskt som med icke-ekologiskt foder och vi antar att de båda fallen är oberoende av varandra. Låt $\Theta = (\Theta_M, \Theta_V)$ vara stokastiska parametrar och $\theta = (\theta_M, \theta_V)$ ett parameterutfall. Givet $\Theta = \theta$ antar vi

$$f_{X_i|\Theta_M, \Theta_V}(x_i \mid \theta_M, \theta_V) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \theta_M)^2}{2\theta_V}\right), \quad i \in [n],$$

där n är antalet mätpunkter. Vi antar vidare att alla mätpunkter är betingat oberoende givet Θ . Som apriorifördelning använder vi den icke-informativa apriorifördelningen $f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) \propto 1/\theta_V$. För båda fodertyperna har vi $n = 9$, stickprovsmedelvärde $\bar{x}$ och stickprovsstandardavvikelse s . Detta ger aposteriorifördelningen

$$\Theta_M, \Theta_V \mid \mathbf{X} = \mathbf{x} \sim \text{NInvGamma}(\bar{x}, 9, 4, 4s^2),$$

vilket i sin tur ger aposterioriprediktiva fördelningen för ett nytt veckoutfall X_{ny} som

$$X_{\text{ny}} \mid \mathbf{X} = \mathbf{x} \sim t \left(n - 1, \bar{x}, s^2 \left(1 + \frac{1}{n} \right) \right),$$

dvs. en t -fördelning med $\nu = n - 1 = 8$ frihetsgrader, läge $\bar{x}$ och variansparameter $s^2(1 + 1/n)$. Vinsten per vecka definieras som $V = pX - C$ (pris p kr/ägg, kostnad C kr/vecka). Därmed får vi

$$V_{\text{ny}} \mid \mathbf{X} = \mathbf{x} \sim t \left(8, p\bar{x} - C, p^2 s^2 \left(1 + \frac{1}{n} \right) \right).$$

Uppgiften ber om den nivå q som vinsten överstiger med 95% sannolikhet, dvs.

$$P(V_{\text{ny}} \geq q \mid \mathbf{X} = \mathbf{x}) = 0.95$$

Alltså är

$$q = p\bar{x} - C + t_{0.95}(8) \left(ps\sqrt{1 + 1/n} \right) = p\bar{x} - C - t_{0.05}(8) \left(ps\sqrt{1 + 1/n} \right)$$

där $t_{0.05}(5) \approx 1.86$.

Vi får alltså följande resultat:

Icke-ekologiskt. $p = 3$, $C = 10000$, $\bar{x} = 4051$, $s = 115$, $n = 9$.

$$\mu_V = p\bar{x} - C = 3 \cdot 4051 - 10000 = 2153, \quad \sigma_V = ps\sqrt{1 + 1/n} = 3 \cdot 115\sqrt{1 + 1/9} \approx 363.66.$$

$$q_{\text{icke}} = 2153 - 1.86 \cdot 363.66 \approx 1477 \text{ kr.}$$

Ekologiskt. $p = 4$, $C = 12000$, $\bar{x} = 3508$, $s = 52.1$, $n = 9$.

$$\mu_V = 4 \cdot 3508 - 12000 = 2032, \quad \sigma_V = 4 \cdot 52.1\sqrt{1 + 1/9} \approx 219.67.$$

$$q_{\text{eko}} = 2032 - 1.86 \cdot 219.67 \approx 1623 \text{ kr.}$$

Eftersom $q_{\text{eko}} > q_{\text{icke}}$ bör Anders välja **ekologiskt foder** om målet är ett högre "golv".

Uppgift 4

Låt $X_1, X_2 \sim N(10, 4)$ vara fabrikernas utsläpp och $Z \sim N(0, 1)$ den naturliga tillkomsten, och anta oberoende, dvs. $X_1 \perp\!\!\!\perp X_2 \perp\!\!\!\perp Z$. Totalhalten är

$$T = X_1 + X_2 + Z.$$

Vi observerar händelsen $\{T = 24, X_1 = 8\}$, vilket ger

$$X_2 + Z = 24 - 8 = 16.$$

Sätt $B = X_2$ och $S = B + Z$. Då gäller

$$B \sim N(10, 4), \quad S \sim N(10, 5), \quad \text{Cov}(B, S) = \text{Var}(B) = 4,$$

eftersom $B \perp\!\!\!\perp Z$. Med formeln för betingad normalfördelning fås

$$B \mid S = 16 \sim N \left(10 + \frac{4}{5}(16 - 10), 4 - \frac{4^2}{5} \right) = N(14.8, 0.8).$$

Alltså får vi

$$P(X_2 > 15 \mid T = 24, X_1 = 8) = P(B > 15 \mid S = 16) = 1 - \Phi\left(\frac{15 - 14.8}{\sqrt{0.8}}\right) \approx 0.41.$$

Sannolikheten att fabriakens utsläpp överstiger 15 nanogram per liter är därmed 41%.

Uppgift 5

Låt $X \sim N(0, 1)$ och $Y = |X|$. Då har Y täthet

$$f_Y(y) = \sqrt{\frac{2}{\pi}} e^{-y^2/2}, \quad y \in \mathbb{R}_{\geq 0}.$$

Som kandidat i förkastelsemetoden används $Z \sim \text{Exp}(\lambda)$ med intensitet λ , dvs.

$$f_Z(z) = \lambda e^{-\lambda z}, \quad z \in \mathbb{R}_{\geq 0}.$$

(a) Förkastelsekonstanten är $M(\lambda) = \sup_{y \geq 0} \frac{f_Y(y)}{f_Z(y)}$. Kvoten kan skrivas

$$\frac{f_Y(y)}{f_Z(y)} = \frac{\sqrt{2/\pi}}{\lambda} \exp\left(-\frac{y^2}{2} + \lambda y\right) = \frac{\sqrt{2/\pi}}{\lambda} \exp\left(\frac{\lambda^2}{2} - \frac{(y - \lambda)^2}{2}\right).$$

Maximum inträffar vid $y = \lambda$, så

$$M(\lambda) = \frac{\sqrt{2/\pi}}{\lambda} e^{\lambda^2/2}.$$

Väntevärdet för antalet förkastelseiterationer ges av $M(\lambda)$, så vi vill minimera detta. Detta är ekvivalent med att minimera logaritmen $\log M(\lambda) = -\log \lambda + \lambda^2/2 + \text{konstant}$. Om vi sätter derivatan till noll får vi en kritisk punkt

$$\frac{d}{d\lambda} \log M(\lambda) = -\frac{1}{\lambda} + \lambda = 0 \implies \lambda = 1.$$

Andraderivatan ges av

$$\frac{d^2}{d\lambda^2} \log M(\lambda) = \frac{1}{\lambda^2} > 0,$$

så den kritiska punkten är ett minimum. Det optimala värdet på λ är således $\lambda = 1$.

(b) Med $\lambda = 1$ blir acceptanssannolikheten (givet kandidatutfall $Z = y$)

$$P(\text{acceptera} \mid Y = y) = \frac{f_Y(y)}{M(1) f_Z(y)} = \exp\left(-\frac{(y - 1)^2}{2}\right).$$

Vi får alltså följande algoritm för att simulera $X \sim N(0, 1)$:

- Simulera $Y \sim \text{Exp}(1)$ och $U \sim U(0, 1)$ oberoende.
- Om $U \leq \exp(-(Y - 1)^2/2)$, acceptera Y ; annars gå tillbaka till (a).
- Simulera $S \sim \text{Ber}(1/2)$ och sätt $X = (2S - 1)Y$.

Då blir $|X| = Y$ halvnormals och sista steget gör X symmetrisk, alltså $X \sim N(0, 1)$.

Jämfört med Box–Muller undviker metoden trigonometriska funktioner men kan kräva fler utfall från en $U(0, 1)$ -fördelning beroende på hur många steg som krävs innan en kandidat accepteras (Box–Muller kräver alltid två $U(0, 1)$ -utfall för att generera två $N(0, 1)$ -utfall). Vilken som är bäst beror på hur dyra trigonometriska funktioner är att exekvera jämfört med simulering från $U(0, 1)$.

Uppgift 6

Antag $X_1, \dots, X_n$ iid från $\text{Beta}(\theta, 1)$, dvs.

$$f_{X_i}(x_i | \theta) = \theta x_i^{\theta-1}, \quad x_i \in [0, 1], \quad \theta \in \mathbb{R}_{>0}.$$

Vi testar $H_0 : \theta = 1$ mot $H_1 : \theta > 1$.

Likelihoodfunktionen blir (för observerat $\mathbf{x}$)

$$L(\theta | \mathbf{x}) = f_{\mathbf{X}}(\mathbf{x} | \theta) = \theta^n \prod_{i=1}^n x_i^{\theta-1}.$$

Sätt

$$t = \sum_{i=1}^n (-\ln x_i) \geq 0.$$

Vår log-likelihoodfunktion blir då

$$\log L(\theta | \mathbf{x}) = n \ln \theta - (\theta - 1)t.$$

För att ta fram ML-skattningen beräknar vi derivatan och sätter till noll

$$\frac{n}{\theta} - t = 0 \implies \theta = \frac{n}{t}.$$

Då andraderivatan är lika med $-n/\theta^2 < 0$ vet vi att den kritiska punkten är ett maximum, så ML-skattningen ges av $\theta^* = n/t$. Under nollhypotesen $H_0 : \theta = 1$ blir den begränsade ML-skattningen $\theta_0^* = 1$. Om vi inte har någon begränsning, utan låter θ ta vilket värde som helst i intervallet $[1, +\infty)$ (värden på θ mindre än ett är inte tillåtna då inte ingår i varken H_0 eller H_1) får vi ML-skattningen $\theta^* = \max(n/t, 1)$. Eftersom θ^* tar värdet n/t om $t < n$ och värdet 1 annars får vi likelihoodkvoten

$$\lambda(\mathbf{x}) = \begin{cases} (t/n)^n \exp(n - t), & \text{om } t < n, \\ 1, & \text{annars.} \end{cases}$$

Vi kommer bara förkasta nollhypotesen om $\lambda(\mathbf{x})$ är liten, så vi kan bortse från fallet $t \geq n$ och koncentrera oss på $t < n$. I detta fall kan vi ta logaritmen och derivera, vilket ger

$$\frac{d}{dt} \log \lambda(\mathbf{x}) = \frac{d}{dt} (n \log t - t + \text{konstant}) = \frac{n}{t} - 1.$$

Med andra ord är likelihoodkvoten växande i t över hela intervallet $[0, n]$ som vi betraktar. För att förkasta H_0 krävs alltså att t är litet och vi söker en konstant c_α så att $P(T < c_\alpha) = \alpha$ givet $H_0 : \theta = 1$ där

$$T = - \sum_{i=1}^n \log X_i.$$

Vad är nu T 's fördelning? Först ser vi att om $X_i \sim \text{Beta}(\theta, 1)$ har vi att $Y_i = -\log X_i = g(X_i)$ för $g(x) = \log(x)$ ger täthetsfunktionen

$$f_{Y_i}(y_i) = f_{X_i}(g^{-1}(y_i)) \left| \frac{dg^{-1}}{dy}(y) \right| = f_{X_i}(e^{-y_i}) |-e^{-y_i}| = \theta e^{-y_i(\theta-1)} \cdot e^{-y_i} = \theta e^{-\theta y_i}.$$

Med andra ord så har vi $Y_i \sim \text{Exp}(\theta)$. Vår teststatistiska T är alltså summan av n stycken oberoende $\text{Exp}(\theta)$ -fördelade stokastiska variabler och är därför $\text{Gamma}(n, \theta)$ -fördelad.

Under nollhypotesen $H_0 : \theta = 1$ har vi alltså $T \sim \text{Gamma}(n, 1)$. Detta ger i sin tur att $2T \sim \text{Gamma}(n, 1/2) = \chi^2(2n)$, så vi kan använda $\chi^2(2n)$ -kvantilerna som ger

$$P(2T > \chi^2_{\alpha}(2n)) = \alpha.$$

Vi får alltså

$$P(2T < \chi^2_{1-\alpha}(2n)) = \alpha$$

$$P(T < \frac{1}{2} \chi^2_{1-\alpha}(2n)) = \alpha.$$

Med andra ord så ges c_{α} av $(1/2) \chi^2_{1-\alpha}(2n)$ och hypotestestet lyder:

Förkasta $H_0 : \theta = 1$ till förmån för $H_1 : \theta > 1$ om

$$t = - \sum_{i=1}^n \log x_i < \frac{1}{2} \chi^2_{1-\alpha}(2n).$$