
FÖRELÄSNINGAR
I
STATISTISK INLÄRNING OCH DATAANALYS

JOAKIM ANDÉN
LIAM SOLUS

KTH
Stockholm

Innehåll

1	Kapitel 1	7
1.1	Simulering	8
1.1.1	Inversionsmetoden	8
1.1.2	Box–Muller-metoden	11
1.1.3	Inversionsmetoden för diskreta fördelningar	12
1.1.4	Simulering i Python	13
1.2	Familjer	14
1.2.1	Exponentialfamiljer	15
1.2.2	Läges-skalfamiljer	19
1.3	Uppgifter	20
2	Kapitel 2	25
2.1	Flerdimensionella fördelningar	25
2.1.1	Multinomialfördelningen	26
2.1.2	Flerdimensionella normalfördelningen	27
2.1.3	Flerdimensionella exponentialfamiljer	29
2.2	Transformation av stokastiska variabler	30
2.3	Betingning och oberoende	34
2.3.1	Betingade fördelningar	35
2.3.2	Oberoende stokastiska variabler	37
2.4	Väntevärde, varians och kovarians	38
2.4.1	Väntevärde i flera dimensioner	38
2.4.2	Kovariansmatris	39
2.5	Uppgifter	40
3	Kapitel 3	47
3.1	Betingat oberoende	47
3.2	Hierarkiska modeller	54
3.3	Uppgifter	58
4	Kapitel 4	63
4.1	Grafer	63
4.2	Grafiska modeller	66
4.2.1	d-sammanhängande och d-separation	71
4.3	Uppgifter	76
5	Kapitel 5	85
5.1	Statistikor	85
5.1.1	Samplingfördelningar för normalfördelade stickprov	88
5.2	Tillräckliga statistikor	94
5.3	Uppgifter	98

6	Kapitel 6	101
6.1	Momentmetoden	101
6.2	Maximum-likelihoodmetoden	103
6.2.1	Gradientmetoden	106
6.2.2	ML-skattningens invariansegenskap	110
6.2.3	Momentmetoden och ML-metoden	111
6.3	Utvärdering av skattningar	111
6.4	Cramér-Raos olikhet	115
6.5	Uppgifter	117
7	Kapitel 7	121
7.1	A priori och a posteriori	121
7.1.1	Apriorifördelning och aposteriorifördelning	121
7.1.2	Flera observationer	124
7.1.3	Bayesianska punktskattningar	127
7.2	Aposterioriprediktiva fördelningen	128
7.3	Konjugerade apriorifördelningar	131
7.4	Icke-informativa apriorifördelningar	132
7.5	Uppgifter	134
8	Kapitel 8	139
8.1	Flerdimensionella parametrar	139
8.1.1	Multinomialfördelad data	139
8.1.2	Normalfördelad data	140
8.1.3	Grafiska modeller för bayesiansk inferens	142
8.1.4	Exponentialfamiljer	144
8.2	Uppgifter	145
9	Kapitel 9	149
9.1	Bayesiansk beslutsteori	149
9.1.1	Bayesrisk och bayesskattning	150
9.2	Bayesiansk hypotesprövning	152
9.2.1	Bayesbeslut	153
9.2.2	Hypoteser	154
9.2.3	Bayesfaktor	155
9.2.4	Punkthypoteser för kontinuerliga parametrar	155
9.3	Uppgifter	155
10	Kapitel 10	159
10.1	Monte Carlo-metoden	159
10.2	Förkastelsemetoden	161
10.3	Markovkedje-Monte Carlo	166
10.3.1	Markovkedjor	166
10.3.2	Metropolisalgoritmen	167
10.3.3	Praktiska tips och exempel	168
10.4	Uppgifter	176
11	Kapitel 11	181
11.1	Empiriska bayesmetoden	182
11.2	Bayesiansk inferens i en binomialhierarki	184
11.3	Uppgifter	189

12 Kapitel 12	193
12.1 Frekventistiska hypotestest	193
12.2 Likelihood-kvottest	195
12.3 Val av tröskelvärde	201
12.4 Styrkefunktionen	203
12.4.1 Storlek och nivå	205
12.4.2 Styrka	208
12.4.3 Styrkefunktionen och risk	209
12.5 Uppgifter	210
13 Kapitel 13	215
13.1 Frekventistisk intervallskattning	215
13.1.1 Invertera en testvariabel	216
13.1.2 Pivotvariabler	219
13.2 Bayesiansk intervallskattning	222
13.3 Beslutsteori för intervallskattning	225
13.4 Uppgifter	226
14 Kapitel 14	229
14.1 Konvergens	229
14.2 Deltametoden	231
14.3 Konsistens	234
14.3.1 Asymptotiskt normalfördelade punktskattningar	235
14.4 Asymptotiska egenskaper hos aposteriorifördelningen	237
14.5 Uppgifter	239

Kapitel 1

Denna bok fokuserar på problemet *statistisk inferens*. Det allmänna målet av statistisk inferens är att dra användbara slutsatser om en *population* med hjälp av observationer (data). Här menar vi med ordet "population" totaliteten av observationer som är av intresse. Till exempel, populationen kunde vara alla studenterna i programmet teknisk matematik på KTH. För att skatta vilket betyg en slumpmässig student kommer att få på en viss tentamen kan man använda data från studenterna som skrivit tentamen tidigare. I denna situation är studenternas betyg som vi har antecknat, $x_1, \dots, x_n$, våra observationer (data) från populationen. Observationen x_i kallas också ett *utfall* (eftersom det är utfallet (resultatet) av att student i har skrivit tentamen). Varje utfall x_i är värdet av en stokastisk variabel X med sannolikhetsfunktion eller täthetsfunktion, $f_X(x)$. (Vi kommer att använda $f_X(x)$ för att beteckna en täthetsfunktion eller en sannolikhetsfunktion.) Därför säger vi *populationen* $f_X(x)$ när vi menar en population bestående av värdena som är de möjliga utfallen av en stokastisk variabel X med sannolikhetsfunktion eller täthetsfunktion $f_X(x)$. Med andra ord, vi kallar $f_X(x)$ en population eftersom den har en domän som består av alla möjliga utfall vi kan observera i populationen vi vill modellera med $f_X(x)$. I vårt exempel är vi intresserade av de möjliga betygen studenterna kan få på tentamen. Så populationen $f_X(x)$ blir av intresse när vi bestämma oss att modellera sannolikheten för de möjliga betygen med en fördelning som har täthetsfunktion $f_X(x)$.

En täthetsfunktion (eller sannolikhetsfunktion) ges ofta på parametriserad form. Till exempel, om X är normalfördelad med väntevärde μ och varians σ^2 är täthetsfunktionen för X

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2},$$

vilken är *parametriserad* av μ och σ^2 . Det vill säga att täthetsfunktionen för X beror på värdena μ och σ^2 . Vi skriver täthetsfunktionen $f_X(x)$ som en funktion av x eftersom vi tänker på parametrarna som fixa. Det blir klart att täthetsfunktionen är bara en funktion av x när vi låter $\mu = 2$ och $\sigma^2 = 1$:

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x-2)^2}.$$

Om vi vill specificera att täthetsfunktionen beror på vissa parametrar, exempelvis μ och σ^2 , skriver vi $f_X(x|\mu, \sigma^2)$ istället för $f_X(x)$.

Givet observationer som vi tolkar som utfall av en stokastisk variabel X med täthetsfunktion $f_X(x)$ som har en viss parametriserad form säger vi att observationerna är från en population med den specificerade fördelningen. Till exempel, vi kan betrakta utfall $x_1, \dots, x_n$ från en $N(\mu, \sigma^2)$ -population.

I praktiken vet vi aldrig vilken population våra observationer kommer ifrån. Således är en stor del av statistisk inferens fokuserade på metoder för att välja en bra *modell*; det vill säga ett bra val av täthetsfunktion. I den här boken kommer vi undersöka olika typer av användbara modeller. Vi kommer också betrakta metoder för att kvantifiera hur "bra" en viss modell är och hur vi kan jämföra olika val modeller.

När vi har bestämt oss att modellera data som utfall från en $f_X(x)$ -population kan vi sedan använda modellen för att göra prediktioner. Till exempel, efter vi bestämt oss för att modellera studenters betyg på tentamen som utfall från en $N(\mu, \sigma^2)$ -population skulle vi sedan vilja förutsäga hur en godtycklig student kommer att prestera på tentamen. Vanligtvis kommer $f_X(x)$ att ha en eller flera parametrar som är okända. För att göra prediktioner med modellen måste vi bestämma oss på rimliga värden parametrarna. Naturligtvis är det en bra idé att bestämma parametrarnas värden så att $f_X(x)$ passar bra med data. Därför är en stor del av statistik inferens fokuserad på vad man kan säga om parametrarnas värden baserat på data och särskilt utvecklingen av bra sätt för att *skatta* parametrarnas värden. Med tanke på vårt exempel kommer vi undersöka flera sätt för att skatta parametrarna μ och σ^2 med hjälp av studenternas betyg som vi har som data. Sedan kan vi exempelvis använda väntevärdet och variansen för X (som beräknas med hjälp av $f_X(x)$) för att bilda prediktioner om andra studenters betyg. Generellt sett är detta spelet som vi spelar när vi gör statistik inferens.

Det finns för nävarande två populära och kraftfulla metoder för statistisk inferens: Den *frekventistiska metoden* varigenom slutsatser endast görs med hjälp av informationen som finns i en sekvens slumpmässiga utfall från populationen, och den *bayesianska metoden* varigenom tidigare kunskaper om parametrarnas fördelning också kan användas. Vi kommer att utforska båda metoder, sida vid sida, för att bygga upp många olika och kraftfulla tekniker för dataanalys.

I en första kurs om sannolikhetssteori och statistik lärde vi oss förmodligen om flera olika möjliga statistiska modeller som vi kan välja mellan i olika situationer. Till exempel kunde X vara normalfördelad, Poissonfördelad, gammafördelad, osv. En lista av dessa fördelningar och deras viktiga egenskaper finns i formelsamlingen. När man försöker att välja en bra modell för en given situation kan det vara användbart att ha möjligheten att generera ett stickprov från dessa olika fördelningar. Kom ihåg att ett *stickprov* är en sekvens av utfall $x_1, \dots, x_n$ där $X_1, \dots, X_n$ är en sekvens av oberoende och likafördelade stokastiska variabler. Det vill säga att ett stickprov $x_1, \dots, x_n$ är oberoende utfall från en och samma X som har sannolikhetsfunktion (eller täthetsfunktion) $f_X(x)$. I denna bok kommer vi se att det kan vara hjälpsam att ha förmågan att generera ett stickprov från en given fördelning. Vi kallar denna process *simulering* eftersom det ger oss data från en vald fördelning istället från verkliga livet. Simuleringar kommer att hjälpa oss med modellval, prediktion och även med skattning av olika värden av intresse för komplexa modeller som kan inte beräknas numeriskt eller analytiskt. I praktiken är simuleringsmetoder också användbara när man testa prestandan av nyutvecklade statistiska metoder. Men vi börjar med det nu bara så att vi alltid har data att leka med!

1.1 Simulering

Nu presenterar vi några grundläggande metoder för att generera ett stickprov från en given fördelning. Den första metoden använder faktumet att vi kan redan generera ett stickprov från en $U(0, 1)$ -fördelning. Detta är processen för generering av slumpstal vilken är ett studieområde i och med sig själv. Tack vare arbetet på detta studieområde har vi redan bra metoder för att generera ett stickprov från $U(0, 1)$ – till exempel, *den permuterade kongruensgeneratorn* som används i NumPy och SciPy. För att generera sådant stickprov av storlek 1000 kan vi skriva i Python:

```
from scipy import stats
stats.uniform.rvs(size=1000)
```



Med hjälp av sådana tekniker för generering av ett stickprov från $U(0, 1)$ kan vi konstruera *simuleringsalgoritmer*; det vill säga algoritmer för generering av ett stickprov från många fördelningar som vi ofta använder.

1.1.1 Inversionsmetoden

Låt X vara en stokastisk variabel med en kontinuerlig och strikt växande fördelningsfunktion $F_X(x)$. Det följer att $F_X(x)$ har målmängd $[0, 1]$. Eftersom $F_X(x)$ är kontinuerlig och strikt växande gäller det även att $F_X(x)$ är inverterbar med invers $F_X^{-1}(y)$ för vilken

$$F_X(x) = y \quad \text{om och endast om} \quad F_X^{-1}(y) = x.$$

Naturligtvis har $F_X^{-1}(y)$ domän $[0, 1]$. Till exempel kan vi låta $X \sim \text{Exp}(1)$. Då har vi $F_X(x) = 1 - e^{-x}$ och $F_X^{-1}(y) = -\log(1 - y)$. Vi vet att $F_X^{-1}(y)$ har som domän $[0, 1]$ eftersom $F_X(x)$ är en fördelningsfunktion och vi kan verifiera analytiskt att $F_X(x)$ är kontinuerlig och strikt växande. Vi ser också det i följande plottar:

(a) $F_X(x)$ där $X \sim \text{Exp}(1)$ (b) $F_X^{-1}(y)$ där $X \sim \text{Exp}(1)$

Låt Z och X vara oberoende och likafördelade. Eftersom $F_X(x)$ är bara en funktion kan vi betrakta den stokastiska variabeln $Y = F_X(Z)$ med utfall i $[0, 1]$ definieras som en transformation av den stokastiska variabeln Z . Följande satsen säger att denna stokastisk variabel är egentligen $U(0, 1)$ -fördelad.

Sats 1.1. Låt X vara en stokastisk variabel med kontinuerlig och strikt växande fördelningsfunktion $F_X(x)$ och låt $Y = F_X(Z)$ där Z och X är oberoende och likafördelade. Då är $Y \sim U(0, 1)$.

Bevis. Notera först att $F_X^{-1}(y)$ är också en strikt växande funktion. För att visa det anta att $y < y'$. Eftersom $F_X(x)$ är inverterbar finns det (unika) x och x' så att

$$F_X(x) = y < y' = F_X(x').$$

Eftersom $F_X(x)$ är strikt växande följer det att $x < x'$ och därför

$$F_X^{-1}(y) = F_X^{-1}(F_X(x)) = x < x' = F_X^{-1}(F_X(x')) = F_X^{-1}(y').$$

För $0 < y < 1$ följer det att

$$\begin{aligned} P(Y \leq y) &= P(F_X(Z) \leq y), \\ &= P(F_X^{-1}(F_X(Z)) \leq F_X^{-1}(y)) \quad (F_X^{-1} \text{ strikt växande}), \\ &= P(Z \leq F_X^{-1}(y)), \\ &= F_Z(F_X^{-1}(y)) \quad (\text{definitionen av } F_Z), \\ &= F_X(F_X^{-1}(y)) \quad (X \text{ och } Z \text{ likafördelade}), \\ &= y. \end{aligned}$$

Det stämmer även att $P(Y \leq y) = P(F_X(Z) \leq y) = 1$ för $y \geq 1$ och $P(Y \leq y) = P(F_X(Z) \leq y) = 0$ för $y \leq 0$. Därför är $Y \sim U(0, 1)$. $\square$

Det finns många metoder för att generera utfall från en $U(0, 1)$ -fördelning. För att generera ett utfall från X kan vi därför generera ett utfall u från $U = F_X(Z) \sim U(0, 1)$. När vi därefter applicerar funktionen F_X^{-1} på u får vi ett utfall från Z eftersom $F_X^{-1}(U) = F_X^{-1}(F_X(Z)) = Z$. Eftersom Z och X är likafördelade är utfallet z liksom ett utfall från X ; det vill säga att vi får ett utfall $x = z = F_X^{-1}(u)$ från X . Således för att generera ett stickprov $x_1, \dots, x_n$ från en $f_X(x)$ -population kan vi generera ett stickprov $u_1, \dots, u_n$ från $U(0, 1)$ och ta $x_i = F_X^{-1}(u_i)$ för $i = 1, \dots, n$. Den här metoden kallas *inversionsmetoden*.

Exempel 1.1. Vi vill generera ett stickprov $x_1, \dots, x_n$ från $X \sim \text{Exp}(\theta)$. Eftersom $X \sim \text{Exp}(\theta)$ har X täthetsfunktion

$$f_X(x) = \theta e^{-\theta x}$$

och fördelningsfunktion

$$\begin{aligned} F_X(x) &= \int_0^x \theta e^{-\theta t} dt, \quad (0 \leq x < \infty, \theta > 0), \\ &= 1 - e^{-\theta x}, \end{aligned}$$

följer det att $F_X^{-1}(u) = -\frac{1}{\theta} \log(1-u)$. Notera att vi använder en specifik parametrisering för exponentialfördelningen. Den här parametriseringen kallas *intensitetsparametriseringen* för exponentialfördelningen. Den kommer att vara användbar senare när vi betraktar bayesianska metoder. Därför, när $U \sim U(0,1)$ följer det att

$$-\frac{1}{\theta} \log(1-U) \sim \text{Exp}(\theta).$$

Eftersom $1-U \sim U(0,1)$ för $U \sim U(0,1)$ kan vi förenkla detta till

$$-\frac{1}{\theta} \log(U) \sim \text{Exp}(\theta).$$

Således är $x_1, \dots, x_n$ där $x_i = -\frac{1}{\theta} \log(u_i)$ för $i = 1, \dots, n$ ett stickprov från $\text{Exp}(\theta)$ när $u_1, \dots, u_n$ är ett stickprov från $U(0,1)$.

För att generera ett stickprov av storlek 3 från $X \sim \text{Exp}(2)$ tar man först ett stickprov av storlek 3 från $U \sim U(0,1)$:

$$u_1 = 0.604, u_2 = 0.263, u_3 = 0.763.$$

Därefter får man ett stickprov från $X \sim \text{Exp}(2)$ genom att applicera den inversa fördelningsfunktionen på varje utfall u_1, u_2, u_3 :

$$x_1 = -\frac{1}{2} \log(u_1) = 0.252, \quad x_2 = -\frac{1}{2} \log(u_2) = 0.668, \quad x_3 = -\frac{1}{2} \log(u_3) = 0.135.$$

Nu när vi kan ta stickprov från $\text{Exp}(\theta)$ kan vi även ta stickprov från andra användbara fördelningar.

Exempel 1.2. Låt $n > 0$ vara ett heltal och låt $Y \sim \text{Gamma}(n, \theta)$. Täthetsfunktionen för Y är då

$$f_Y(y) = \frac{\theta^n}{\Gamma(n)} y^{n-1} e^{-\theta y}.$$

(Här använder vi *intensitetsparametriseringen* för gammafördelningen. I likhet med exponentialfördelningen använder vi den här parametriseringen eftersom det kommer att bli användbar när vi betrakta bayesianska metoder.) För att ta ett stickprov $y_1, \dots, y_m$ där $Y \sim \text{Gamma}(n, \theta)$ noterar vi att

$$Y = \sum_{i=1}^n X_i \sim \text{Gamma}(n, \theta)$$

när $X_1, \dots, X_n$ är oberoende och $\text{Exp}(\theta)$ -fördelade. (Ett bevis på detta kan göras med hjälp av metoden för transformation av stokastiska variabler som vi ska se i kapitel 2.) Nu följer det från Exempel 1.1 att

$$y = -\frac{1}{\theta} \sum_{i=1}^n \log(u_i)$$

är ett slumpmässigt utfall från en $\text{Gamma}(n, \theta)$ -population när $u_1, \dots, u_n$ är ett stickprov från $U(0,1)$.

Vi noterar att metoden i Exempel 1.2 fungerar bara för $\text{Gamma}(\alpha, \theta)$ -populationer där α är ett heltal. För andra α behöver vi mer avancerade metoder som vi ska se senare.

Exempel 1.3. Låt α, β vara heltal, $X \sim \text{Gamma}(\alpha, 1)$, $Y \sim \text{Gamma}(\beta, 1)$ och låt X och Y vara oberoende. Med hjälp av en transformation av stokastiska variabler kan man visa att

$$\frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta).$$

Därmed kan vi också ta stickprov från $\text{Beta}(\alpha, \beta)$ med hjälp av Exempel 1.2.

Man kan också visa att $\text{Gamma}(\alpha, 1/2) = \chi^2(2\alpha)$ för α ett positivt heltal; det vill säga att en $\text{Gamma}(\alpha, 1/2)$ -fördelning är en χ^2 -fördelningen med 2α frihetsgrader. Det följer från Exempel 1.2 att vi kan ta ett stickprov från $\chi^2(p)$ för jämnt p med inversionsmetoden. Tyvärr kan vi inte använda denna teknik när p är udda. Om det var möjligt kunde vi få (nästan) ett stickprov från $N(0,1)$ via ett stickprov från $\chi^2(1)$ och en kvadratrots. Så hur genererar vi stickprov från $N(0,1)$?

1.1.2 Box–Muller-metoden

För att generera utfall från en $N(0, 1)$ -fördelning kan vi ta hjälp av ”cirklar med slumpmässig radie”. Definiera den stokastiska variabeln $R^2 = X^2 + Y^2$ där X och Y är oberoende och $N(0, 1)$ -fördelade. Det följer att

$$R^2 \sim \chi^2(2) = \text{Gamma}(1, 1/2) = \text{Exp}(1/2).$$

Givet ett utfall r^2 av R^2 kan vi ta en slumpmässig punkt (x, y) på cirkeln $r^2 = x^2 + y^2$ som ges av vinklen $\Theta \sim U(0, 2\pi)$ mellan vektorn $(x, y) - (0, 0)$ och den positiva x-axeln. För att hitta en slumpmässig punkt (x, y) på den slumpmässiga cirkeln med radie R behöver vi därför ta ett utfall r^2 av $R^2 \sim \text{Exp}(1/2)$ och ett utfall av $\Theta \sim U(0, 2\pi)$. Så vi börjar med ett stickprov u_1, u_2 från $U(0, 1)$ och vi då får ett stickprov

$$\begin{aligned} r &= \sqrt{-2 \log(u_1)} & (R^2 \sim \text{Exp}(1/2)), \\ \theta &= 2\pi u_2 \end{aligned}$$

med hjälp av Exempel 1.1. För att bestämma den slumpmässiga punkten (x, y) beräknar vi

$$\begin{aligned} x &= r \cos(\theta) = \sqrt{-2 \log(u_1)} \cos(2\pi u_2), \text{ och} \\ y &= r \sin(\theta) = \sqrt{-2 \log(u_1)} \sin(2\pi u_2). \end{aligned}$$

Detta kallas *Box–Muller-metoden*. I en uppgift på övning 2 ska vi bevisa att X och Y är oberoende. Därmed får vi egentligen två utfall (som vi kan använda!). Tyvärr är Box-Muller-metoden ganska speciell eftersom den bara fungerar för normalfördelningen.

Exempel 1.4. Betrakta den simultana fördelningen för $[X_1, X_2]^T$ där

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= \lambda X_1 + N_2, \end{aligned}$$

för N_1 och N_2 oberoende och $N(0, 1)$ -fördelade. Vi skulle vilja generera ett stickprov från den simultana fördelningen $[X_1, X_2]^T$. För att göra det minns vi att den betingade fördelningen för X_2 givet $X_1 = x_1$ definieras som

$$f_{X_2|X_1}(x_2|x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

Det följer att

$$f_{X_1, X_2}(x_1, x_2) = f_{X_2|X_1}(x_2|x_1) f_{X_1}(x_1).$$


För att generera ett utfall (x_1, x_2) kan vi därför generera först ett utfall x_1 från $f_{X_1}(x_1)$ -populationen. Eftersom $X_1 = N_1 \sim N(0, 1)$ görs detta direkt med Box–Muller-metoden. Därefter kan vi generera ett utfall x_2 givet $X_1 = x_1$ från $f_{X_2|X_1}(x_2|x_1)$ där x_1 är utfallet som vi fick från Box–Muller-metoden. Det önskade utfallet x_2 ges då som ett slumpmässigt utfall av

$$X_2 = \lambda x_1 + N_2$$


eftersom $X_1 = x_1$ är givet. Därför är det tillräckligt att använda Box-Muller metoden en gång till för att generera ett utfall n_2 från $N_2 \sim N(0, 1)$. Utfallet från den simultana fördelningen är då

$$[x_1, x_2]^T = [x_1, \lambda x_1 + n_2]^T.$$


Följande plottar visar ett stickprov av storlek 500 genererade genom denna process för tre olika val för λ ; nämligen $\lambda = 2, -3$, och 0 .



(a) $\lambda = 2$



(b) $\lambda = -3$



(c) $\lambda = 0$

Plottarna visar att λ kontrollerar *korrelationen* mellan X_1 och X_2 vilken är ett beroende mått. Vi ser från formeln $X_2 = \lambda X_1 + N_1$ att X_2 är en linjär funktion av X_1 med lutningskoefficient λ . När data följer en linje med en positiv lutningskoefficient säger vi att X_1 och X_2 är *positivt korrelerade* och när den är negativ säger vi att de är *negativt korrelerade*. När lutningskoefficienten är lika med 0 säger vi att de är *okorrelerade*. Notera att X_1 och X_2 är även oberoende när $\lambda = 0$.

1.1.3 Inversionsmetoden för diskreta fördelningar

Inversionsmetoden är också bra för att ta stickprov från godtyckliga diskreta fördelningar. Låt Y vara en diskret stokastisk variabel med möjliga utfall $y_1 < \dots < y_k$. Låt $y_0 = -\infty$ och $F(y_0) = 0$. Då har vi

$$\begin{aligned} P(F_Y(y_{i-1}) < u \leq F_Y(y_i)) &= F_Y(y_i) - F_Y(y_{i-1}), \\ &= P(Y = y_i). \end{aligned}$$

För att generera ett utfall från Y tar vi därför ett utfall u där $U \sim U(0, 1)$ och bestämmer $i \in \{1, \dots, k\}$ så att

$$F(y_{i-1}) < u \leq F(y_i).$$

Då är y_i ett slumpmässigt utfall från Y .

Vi kan göra detsamma när Y har uppräknligt oändligt många möjliga utfall $y_1 < y_2 < \dots$. I denna situation låter vi y_i vara det minsta möjliga utfallet av Y för vilken $u_i \leq F_Y(y_i)$ för varje u_i i ett stickprov $u_1, \dots, u_n$ från $U \sim U(0, 1)$. Med hjälp av detta kan vi, exempelvis, ta ett stickprov från en $Po(\lambda)$ -fördelning (se uppgift 1.10).

Vi kan använda samma metod för att generera stickprov från vilka diskreta fördelningar som helst. I följande exempel genererar vi ett stickprov från en negativ binomialfördelning vilken är en användbar fördelning när man vill modellera antalet misslyckade försök innan ett givet antal av lyckade försök inträffar. Liksom poissonfördelningen använder vi den negativa binomialfördelningen när vi vill modellera väntetider. Poissonfördelningen används när vi modellerar antalet händelser i ett visst tidsintervall. Negativ binomialfördelningen modellerar väntetiden innan ett fixt antal händelserna inträffar.

Exempel 1.5. I en sekvens av oberoende $Ber(p)$ försök låt den stokastiska variabeln X beteckna antalet misslyckade försök innan det r :te lyckade försöket där $r \geq 0$ är ett fixt heltal. Det följer att

$$P(X = x) = \binom{r+x-1}{x} p^r (1-p)^x, \quad x = 0, 1, \dots$$

Vi säger att X är *negativt binomialfördelad* och skriver $X \sim \text{NegBin}(r, p)$. För att ta ett slumpmässigt utfall x från $\text{NegBin}(r, p)$ tar vi ett utfall u från $U(0, 1)$ och låter x vara det minsta heltal så att

$$u \leq \sum_{j=0}^x \binom{r+j-1}{j} p^r (1-p)^j.$$

Tabellen nedanför visar vilket x vi får som utfallet givet $u \in (0, 1)$ om $X \sim \text{NegBin}(3, 1/2)$.

x	intervall
0	$0 < u \leq 0.125$
1	$0.125 < u \leq 0.3125$
2	$0.3125 < u \leq 0.5$
$\vdots$	$\vdots$

Om vi tar stickprovet

$$u_1 = 0.272, \quad u_2 = 0.359$$

från en $U(0, 1)$ -population får vi då stickprovet

$$x_1 = 1, \quad x_2 = 2$$

från en $\text{NegBin}(3, 1/2)$ -population eftersom

$$0.125 < u_1 \leq 0.3125, \quad \text{och} \quad 0.3125 < u_2 \leq 0.5.$$

Eftersom vi kan använda inversionsmetoden för att generera ett stickprov från en godtycklig diskret fördelning kan vi också generera ett approximativt stickprov från en kontinuerlig fördelning med godtycklig täthetsfunktion $f_X(x)$. Anta att X är en kontinuerlig stokastisk variabel med täthetsfunktion $f_X(x)$, välj $x_1 < x_2 < \dots < x_k$ från utfallsrummet av X och låt

$$p_i = f_X(x_i).$$

Definiera en diskret stokastisk variabel Y med utfallsrum $\{x_1, \dots, x_k\}$ och sannolikhetsfunktion

$$f_Y(x_i) = P(Y = x_i) = \frac{p_i}{\sum_{j=1}^k p_j}.$$

För väl valda x_i kan vi använda ett stickprov från Y som en approximation av ett stickprov från X .


Exempel 1.6. Låt X ha täthetsfunktion

$$f_X(x) = \begin{cases} \frac{1}{11 - \cos(10)}(\sin(x) + 1) & 0 \leq x \leq 10, \\ 0 & \text{otherwise.} \end{cases}$$

Ta utfallen $\{0, 0.5, 1, 1.5, \dots, 9.5, 10\}$ som utfallsrummet av en diskret stokastisk variabel Y där

$$f_Y(y) = \frac{f_X(y)}{\sum_{j=1}^k f_X(y_j)}.$$

I följande bild ser vi täthetsfunktionen av X tillsammans med histogrammet av 1000 slumpmässigt utfall från Y .



Nu har vi metoder för att generera stickprov från våra favoritfördelningar men även metoder för att approximativt generera stickprov från godtyckliga fördelningar. I följande kommer sådana simuleringalgoritmer hjälpa oss på många olika sätt inklusive när vi skattar vissa viktiga fördelningar eller gör prediktioner. I praktiken är det också väldigt användbart att ha metoder för att simulera data när man vill utvärdera en ny statistisk metods prestanda.

1.1.4 Simulering i Python

Nuförtiden är det typiskt att använda programmeringsspråk, exempelvis Python, när vi behöver göra beräkningar med data. Medan det är bra att veta hur att generera ett stickprov själv har paketet SciPy flera användbara funktioner för att generera stickprov från några av våra favoritfördelningar. Exempelvis, kan vi generera ett stickprov av storlek 10 från många olika fördelningar med hjälp av följande:

```
from scipy import stats
```

Kod att skriva

```
stats.randint.rvs(size=10, low=4, high=20)
stats.bernoulli.rvs(size=10, p=0.6)
stats.binom.rvs(size=10, n=20, p=0.7)
```

Fördelningen från vilken vi får ett stickprov

```
U({4, 5, ..., 19, 20})
Ber(0.6)
Bin(20, 0.7)
```

<code>stats.poisson.rvs(size=10, mu=15)</code>	Po(15)
<code>stats.geom.rvs(size=10, p=0.4)</code>	Geom(0.4)
<code>stats.uniform.rvs(size=10, loc=-1, scale=2)</code>	U(-1, 1)
<code>stats.norm.rvs(size=10, loc=2, scale=5)</code>	N(2, 25)
<code>stats.chi2.rvs(size=10, df=3)</code>	$\chi^2(3)$
<code>stats.gamma.rvs(size=10, a=5, scale = 3)</code>	Gamma(5, 1/3)
<code>stats.beta.rvs(size=10, a=5, b=3)</code>	Beta(5, 3)
<code>stats.expon.rvs(size=10, scale=5)</code>	Exp(1/5)

Givet ett stickprov kan vi beräkna stickprovsmedelvärdet och stickprovsvariansen med hjälp av paketet NumPy:

```
import numpy as np


data = stats.norm.rvs(size=100, loc=2, scale=5)
väntevärdet = np.mean(data)
variansen = np.var(data)
```

Vi kan också plotta täthetsfunktionen och jämföra den med datas histogram:

```
fig, ax = plt.subplots(1, 1)
x = np.linspace(-20, 20, 100)

ax.plot(x, stats.norm.pdf(x, loc=2, scale=5))
ax.hist(stats.norm.rvs(size = 1000, loc=2, scale=5), density=True)

plt.show()
```



Medan vi kan använda Python funktioner för att generera stickprov från dessa speciella fördelningarna behöver vi fortfarande ha simuleringsmetoder för att generera stickprov från mer komplexa fördelningar. Vi såg ett sådant exempel i Exempel 1.4 och ett annat exempel i Exempel 1.6. Med dessa grundläggande simuleringsmetoder kan vi redan göra en hel del. Vi kommer också att betrakta mer avancerade metoder senare.

1.2 Familjer

Det första steget i statistisk inferens är ofta att bestämma en modell som vi tror passar bra för populationen från vilken datan kommer ifrån. Detta kan vara en omfattande process där vi noggrant undersöker tillgängliga data, åberopar olika, förhoppningsvis rimliga, antaganden och ofta specificerar en fördelning som vi tror representerar populationen. Om det är rimligt försöker vi ofta att använda en fördelning med parametrar som vi kan lätt skatta med hjälp av data. Det menar att vi ofta specificera en form för fördelningens täthetsfunktion och kräver att parametrarnas värden ligger i ett visst rum. På detta sätt använder vi vad som kallas för *familjer* av täthetsfunktioner.

En *familj* av täthetsfunktioner (eller sannolikhetsfunktioner) är en mängd $\{f_X(x | \theta) : \theta \in \Omega\}$; det vill säga en mängd av täthetsfunktioner (eller sannolikhetsfunktioner) *parametriserad* med någon parameter θ där θ kan vara vad som helst i mängden Ω . Mängden Ω kallas *parameterrummet*. När vi väljer $\theta \in \Omega$ väljer vi en viss täthetsfunktion $f_X(x | \theta)$ och specificerar därmed en medlem av familjen. Eftersom vi har bestämt parameterns värde till θ kan vi tänka att θ är givet. Därför skriver vi $f_X(x|\theta)$ för att beteckna detta, istället för bara $f_X(x)$. Även i de fall där θ 's värde är okänt skriver vi ofta $f_X(x|\theta)$ för att beteckna att täthetsfunktionen beror på parametern θ . Om $f_X(x | \theta_1, \dots, \theta_d)$ beror på flera parametrar $\theta_1, \dots, \theta_d \in \mathbb{R}$ kan vi definiera vektorn

$$\boldsymbol{\theta} = [\theta_1, \dots, \theta_d]^T \in \Omega,$$

för $\Omega \subset \mathbb{R}^d$ och skriva $f_X(x | \boldsymbol{\theta})$ för att vara mer kortfattad.

1.2.1 Exponentialfamiljer

En användbar egenskap hos en familj av täthetsfunktioner är när den bildar en exponentialfamilj. Anta att $f_X(x | \boldsymbol{\theta})$ kan skrivas som

$$f_X(x | \boldsymbol{\theta}) = h(x)c(\boldsymbol{\theta}) \exp \left(\sum_{j=1}^k w_j(\boldsymbol{\theta}) t_j(x) \right),$$

för några funktioner $h : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$, $c : \mathbb{R}^d \rightarrow \mathbb{R}_{\geq 0}$ och $w_j : \mathbb{R}^d \rightarrow \mathbb{R}$, $t_j : \mathbb{R} \rightarrow \mathbb{R}$ för $j = 1, \dots, k$. Därför kallas familjen av täthetsfunktioner $f_X(x | \boldsymbol{\theta})$ för alla val av $\boldsymbol{\theta}$ för en *exponentialfamilj*.

Exempel 1.7. Låt $n > 0$ vara ett fixt heltal och betrakta familjen

$$\mathcal{F}_n = \{f_X(x | p) : X \sim \text{Bin}(n, p), 0 < p < 1\}.$$

Då följer det att

$$\begin{aligned} f_X(x | p) &= \binom{n}{x} p^x (1-p)^{n-x}, \\ &= \binom{n}{x} (1-p)^n p^x (1-p)^{-x}, \\ &= \binom{n}{x} (1-p)^n \left(\frac{p}{1-p} \right)^x, \\ &= \binom{n}{x} (1-p)^n \exp \left(\log \left(\frac{p}{1-p} \right) x \right), \\ &= h(x)c(p) \exp(w_1(p)t_1(x)), \end{aligned}$$

där $h(x) = \binom{n}{x}$, $c(p) = (1-p)^n$, $w_1(p) = \log \left(\frac{p}{1-p} \right)$ och $t_1(x) = x$. Det följer att $\mathcal{F}_n$ är en exponentialfamilj. Notera att $w_1(p)$ inte alltid ändlig om vi inkluderar $p = 0$ eller $p = 1$ i parameterrummet. Därför måste vi begränsa parameterrummet för att få en exponentialfamilj.

Exempel 1.8. Låt $\boldsymbol{\theta} = [\mu, \sigma^2]^T$ där $\mu \in \mathbb{R}$ och $\sigma^2 > 0$. Familjen

$$\mathcal{F}_n = \{f_X(x | \mu, \sigma^2) : X \sim N(\mu, \sigma^2), [\mu, \sigma^2]^T \in \mathbb{R} \times \mathbb{R}_{>0}\}$$

är en exponentialfamilj eftersom $f_X(x|\mu, \sigma^2)$ kan skrivas som

$$\begin{aligned} f_X(x | \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x-\mu)^2}{2\sigma^2} \right), \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{x^2}{2\sigma^2} + \frac{\mu x}{\sigma^2} - \frac{\mu^2}{2\sigma^2} \right), \\ &= (1) \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{\mu^2}{2\sigma^2} \right) \exp \left(\left(\frac{1}{\sigma^2} \right) \left(-\frac{x^2}{2} \right) + \left(\frac{\mu}{\sigma^2} \right) (x) \right). \end{aligned}$$

Här är $h(x) \equiv 1$, $c(\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{\mu^2}{2\sigma^2} \right)$, $w_1(\mu, \sigma^2) = \frac{1}{\sigma^2}$, $w_2(\mu, \sigma^2) = \frac{\mu}{\sigma^2}$, $t_1(x) = -\frac{x^2}{2}$ och $t_2(x) = x$. Notera att funktionerna w_1 och w_2 använder värdet $\frac{1}{\sigma^2}$. Detta värde blir litet när modellens varians är stor och stor när

modellens varians är liten. Eftersom variansen mäter fördelningens spridning kring dess väntevärde kan vi tolka värdet $\frac{1}{\sigma^2}$ som ett mått på hur nära väntevärdet ett slumpmässigt utfall från fördelningen förväntas vara. Därför värdet $\frac{1}{\sigma^2}$ kallas modellens *precision*. När modellens varians är stor har modellen liten precision och när variansen är liten blir precisionen stor. Precisionen kommer att bli användbar när vi betraktar metoder för att bestämma vissa apriorifördelningar.

Vi föredrar familjer som gör att vi enkelt kan extrahera användbar information om deras parametrar. Exponentialfamiljer har exakt denna egenskap. Till exempel kan vi lätt beräkna väntevärden och varianser för exponentialfamiljer:

Sats 1.2. Om X är en stokastisk variabel med sannolikhets- eller täthetsfunktion från en exponentialfamilj har vi

1. $E \left[\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(X) \right] = -\frac{\partial}{\partial \theta_j} \log c(\boldsymbol{\theta}).$
2. $\text{Var} \left[\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(X) \right] = -\frac{\partial^2}{\partial \theta_j^2} \log c(\boldsymbol{\theta}) - E \left[\sum_{i=1}^k \frac{\partial^2 w_i(\boldsymbol{\theta})}{\partial \theta_j^2} t_i(X) \right].$

Bevis. För att förenkla beviset antar vi att $f_X(x | \boldsymbol{\theta})$ är kontinuerlig och ges på formen

$$f_X(x | \boldsymbol{\theta}) = h(x)c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right).$$

Eftersom $f_X(x | \boldsymbol{\theta})$ är en täthetsfunktion integreras den till ett. Så det följer att

$$\begin{aligned} \int_{\mathbb{R}} f_X(x | \boldsymbol{\theta}) dx &= \int_{\mathbb{R}} h(x)c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) dx, \\ 1 &= \int_{\mathbb{R}} h(x)c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) dx, \\ \frac{\partial}{\partial \theta_j} 1 &= \frac{\partial}{\partial \theta_j} \int_{\mathbb{R}} h(x)c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) dx, \\ 0 &= \frac{\partial}{\partial \theta_j} \int_{\mathbb{R}} h(x)c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) dx. \end{aligned}$$

Här är det tillåtet att flytta derivatan in i integralen och med hjälp av produktregeln får vi

$$0 = \int_{\mathbb{R}} \left(h(x) \left(\frac{\partial}{\partial \theta_j} c(\boldsymbol{\theta}) \right) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) + h(x)c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) \left(\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(x) \right) \right) dx.$$

Om vi betraktar var och en summans integraler separat ser vi att den högra summans integral är ett väntevärde. När vi multiplicerar och delar med $c(\boldsymbol{\theta})$ i den vänstra summan får vi

$$\begin{aligned} 0 &= \int_{\mathbb{R}} h(x) \left(\frac{\partial}{\partial \theta_j} c(\boldsymbol{\theta}) \right) \frac{c(\boldsymbol{\theta})}{c(\boldsymbol{\theta})} \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) dx + E \left[\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(x) \right], \\ &= \int_{\mathbb{R}} h(x) \left(\frac{\partial}{\partial \theta_j} c(\boldsymbol{\theta}) \frac{1}{c(\boldsymbol{\theta})} \right) c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) dx + E \left[\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(x) \right], \\ &= \int_{\mathbb{R}} h(x) \left(\frac{\partial}{\partial \theta_j} \log(c(\boldsymbol{\theta})) \right) c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) dx + E \left[\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(x) \right], \quad \left(\frac{d}{dt} \log g(t) = \frac{\frac{d}{dt} g(t)}{g(t)} \right) \\ &= \left(\frac{\partial}{\partial \theta_j} \log(c(\boldsymbol{\theta})) \right) \int_{\mathbb{R}} h(x)c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x) \right) dx + E \left[\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(x) \right], \quad \left(\frac{\partial}{\partial \theta_j} \log(c(\boldsymbol{\theta})) \text{ konstant m.a.p. } x \right) \\ &= \frac{\partial}{\partial \theta_j} \log(c(\boldsymbol{\theta})) + E \left[\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(x) \right]. \quad (\text{integralen är lika med } 1) \end{aligned}$$

Därför är

$$\mathbb{E} \left[\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(X) \right] = -\frac{\partial}{\partial \theta_j} \log c(\boldsymbol{\theta}).$$

Det bevisar del (1). Del (2) följer om vi integrerar en gång till. $\square$

Medan formelerna i Sats 1.2 kan se skrämmande ut är de inte så hemska att arbeta med.

Exempel 1.9. Låt $X \sim N(\mu, \sigma^2)$. Eftersom X är en medlem av en exponentialfamilj kan vi beräkna $\mathbb{E}[X]$ via Sats 1.2. Notera att

$$\begin{aligned} -\frac{\partial}{\partial \mu} \log c(\mu, \sigma^2) &= -\frac{\partial}{\partial \mu} \log \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{\mu^2}{2\sigma^2} \right) \right), \\ &= -\frac{\partial}{\partial \mu} \left(-\frac{\mu^2}{2\sigma^2} \right), \\ &= \frac{\mu}{\sigma^2}, \end{aligned}$$

och att

$$\begin{aligned} \mathbb{E} \left[\sum_{i=1}^k \frac{\partial w_i(\boldsymbol{\theta})}{\partial \theta_j} t_i(X) \right] &= \mathbb{E} \left[\frac{\partial}{\partial \mu} \left(\frac{1}{\sigma^2} \right) \left(-\frac{X^2}{2} \right) + \frac{\partial}{\partial \mu} \left(\frac{\mu}{\sigma^2} \right) X \right], \\ &= \mathbb{E} \left[0 + \frac{X}{\sigma^2} \right], \\ &= \frac{1}{\sigma^2} \mathbb{E}[X]. \end{aligned}$$

Därför, med hjälp av Sats 1.2, har vi

$$\frac{1}{\sigma^2} \mathbb{E}[X] = \frac{\mu}{\sigma^2},$$

och $\mathbb{E}[X] = \mu$.

Ett sätt att tänka på exponentialfamiljer är att funktionerna $w_i(\boldsymbol{\theta}) = \eta_i$ bildar en *omparametrisering* (det vill säga en förändring av parametreringen) av modellen. Eftersom $\eta_1, \dots, \eta_k$ är parametrarna som visar hur modellen bildar en exponentialfamilj är parametrarna $\eta_1, \dots, \eta_k$ de mer "naturliga" parametrarna. I allmänhet kan vi omparametriskera en exponentialfamilj parametriserad av $\boldsymbol{\theta} = [\theta_1, \dots, \theta_d]^T$ med $\boldsymbol{\eta} = [\eta_1, \dots, \eta_k]^T$ genom

$$f_X(x | \boldsymbol{\eta}) = h(x) c^*(\boldsymbol{\eta}) \exp \left(\sum_{i=1}^k \eta_i t_i(x) \right),$$

där

$$\boldsymbol{\eta} \in \left\{ (\eta_1, \dots, \eta_k) : \int_{\mathbb{R}} h(x) \exp \left(\sum_{i=1}^k \eta_i t_i(x) \right) dx < \infty \right\},$$

och

$$c^*(\boldsymbol{\eta}) = \left(\int_{\mathbb{R}} h(x) \exp \left(\sum_{i=1}^k \eta_i t_i(x) \right) dx \right)^{-1}.$$

Formeln för $c^*(\boldsymbol{\eta})$ kan verka komplicerad men det är bara funktionen som garanterar att $f_X(x|\boldsymbol{\eta})$ integrerar till 1. I denna situation $\eta_1, \dots, \eta_k$ kallas *de naturliga parametrarna* av familjen. När man arbetar med naturliga parametrarna kan det ofta förenkla vissa beräkningar. Till exempel reduceras Sats 1.2 till

$$\mathbb{E}[t_j(X)] = -\frac{\partial}{\partial \eta_j} \log c(\boldsymbol{\eta}) \quad \text{Var}[t_j(X)] = -\frac{\partial^2}{\partial \eta_j^2} \log c(\boldsymbol{\eta}).$$

Exempel 1.10. Den normala exponentialfamiljen från Exempel 1.8 har naturliga parametrar

$$\eta_1 = \frac{1}{\sigma^2} \text{ och } \eta_2 = \frac{\mu}{\sigma^2}.$$

Man kan visa att naturliga parameterrummet är $\{(\eta_1, \eta_2) \in \mathbb{R}^2 : \eta_1 > 0\}$. Från Exempel 1.8 hade vi att för $X \sim N(\mu, \sigma^2)$

$$f_X(x | \mu, \sigma^2) = h(x)c(\mu, \sigma^2) \exp(w_1(\mu, \sigma^2)t_1(x) + w_2(\mu, \sigma^2)t_2(x)),$$

där $h(x) = 1$, $c(\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\mu^2}{2\sigma^2}\right)$, $w_1(\mu, \sigma^2) = \frac{1}{\sigma^2}$, $w_2(\mu, \sigma^2) = \frac{\mu}{\sigma^2}$, $t_1(x) = -\frac{x^2}{2}$ och $t_2(x) = x$. Det följer att integralen

$$\int_{\mathbb{R}} h(x) \exp\left(\sum_{i=1}^k \eta_i t_i(x)\right) dx = \int_{\mathbb{R}} \exp\left(\eta_1 \left(-\frac{x^2}{2}\right) + \eta_2 x\right) dx$$

är ändlig om och endast om $\eta_1 > 0$. Så vi kan bara ha $\eta_1 > 0$ och $\eta_2 \in \mathbb{R}$. Om vi utvärderar integralen får vi

$$c^*(\eta_1, \eta_2) = \sqrt{\frac{\eta_1}{2\pi}} \exp\left(-\frac{\eta_2^2}{2\eta_1}\right).$$

Det följer att

$$f_X(x | \boldsymbol{\eta}) = \sqrt{\frac{\eta_1}{2\pi}} \exp\left(-\frac{\eta_2^2}{2\eta_1}\right) \exp\left(\eta_1 \left(-\frac{x^2}{2}\right) + \eta_2 x\right).$$

Notera att $f_X(x | \boldsymbol{\theta})$ kan ha d parametrar $\boldsymbol{\theta} = (\theta_1, \dots, \theta_d)$ men k naturliga parametrar $\boldsymbol{\eta} = (\eta_1, \dots, \eta_k)$ där $k \neq d$. När $d = k$ kallas familjen en *fullständig exponentialfamilj*. När $d < k$ kallas den en *krökt exponentialfamilj* eftersom parameteriseringen av de naturliga parametrar bäddar in det d -dimensionella parameterrummet Ω i ett rum av högre dimension. I Exempel 1.10 hade vi $d = k$. Så normalfamiljen är en fullständig exponentialfamilj. Men det är också lätt att hitta krökta exponentialfamiljer:

Exempel 1.11. Låt $X_1, X_2, \dots$ vara en sekvens av oberoende och $\text{Ber}(\theta)$ -fördelade stokastiska variabler. Det följer att $E[X_i] = \theta$ och $\text{Var}[X_i] = \theta(1 - \theta)$ för alla $i = 1, 2, \dots$. Låt $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ för $n = 1, 2, \dots$. Med hjälp av den centrala gränsvärdesatsen har vi att sekvensen av stokastiska variabler


$$\frac{\bar{X}_n - \theta}{\sqrt{\theta(1 - \theta)/n}}$$

konvergerar till en $N(0, 1)$ -fördelning. För stora n följer det att $\bar{X}_n$ är approximativt $N(\theta, \theta(1 - \theta)/n)$ -fördelad.

Denna fördelning är ett exempel av en krökt exponentialfamilj. Fördelningen $N(\theta, \theta(1 - \theta)/n)$ beror på bara en parameter; nämligen θ . Därför är $d = 1$. Å andra sidan, när vi skriver täthetsfunktionen för $Z \sim N(\theta, \theta(1 - \theta)/n)$ på exponentialfamiljens form får vi

$$\begin{aligned} f_Z(z|\theta) &= \frac{1}{\sqrt{2\pi\theta(1-\theta)/n}} \exp\left(-\frac{1}{2\theta(1-\theta)/n}(z-\theta)^2\right), \\ &= \frac{\sqrt{n}}{\sqrt{2\pi\theta(1-\theta)}} \exp\left(-\frac{n}{2\theta(1-\theta)}(z^2 - 2z\theta + \theta^2)\right), \\ &= \frac{\sqrt{n}}{\sqrt{2\pi\theta(1-\theta)}} \exp\left(\left(\frac{1}{\theta(1-\theta)}\right)\left(-\frac{nz^2}{2}\right) + \left(\frac{1}{1-\theta}\right)(nz) - \frac{n\theta}{2(1-\theta)}\right), \\ &= \left(\frac{\sqrt{n}}{\sqrt{2\pi\theta(1-\theta)}} \exp \frac{-n\theta}{2(1-\theta)}\right) \exp\left(\left(\frac{1}{\theta(1-\theta)}\right)\left(-\frac{nz^2}{2}\right) + \left(\frac{1}{1-\theta}\right)(nz)\right), \\ &= h(z)c(\theta) \exp(w_1(\theta)t_1(z) + w_2(\theta)t_2(z)), \end{aligned}$$

där $h(z) \equiv 1$, $c(\theta) = \left(\frac{\sqrt{n}}{\sqrt{2\pi\theta(1-\theta)}} \exp \frac{-n\theta}{2(1-\theta)}\right)$, $w_1(\theta) = \frac{1}{\theta(1-\theta)}$, $w_2(\theta) = \frac{1}{1-\theta}$, $t_1(z) = -\frac{nz^2}{2}$ och $t_2(z) = nz$. Därför är $d = 1 < 2 = k$ och familjen är krökt. Det följer att parameteriseringen av de naturliga parameter bäddar in det endimensionella parameterrummet $\Omega = \{\theta : \theta \in [0, 1]\}$ i ett tvådimensionellt rum.



1.2.2 Läges-skalfamiljer

Istället för att specificera en familj igenom en mängd av möjliga parametrar kan vi välja en enkel täthetsfunktion och konstruera en familj kring den genom att ändra funktionen. I synnerhet kan vi skala eller skifta funktionen.

Givet en stokastisk variabel Z med täthetsfunktion $f_Z(z)$ skiftar vi fördelningen med μ när vi betraktar den stokastiska variabeln $X = Z + \mu$. Notera att detta är en transformation av en stokastisk variabel; det vill säga $X = g(Z)$ där $g(z) = z + \mu$. Funktionen $g(z)$ är inverterbar för alla $\mu \in \mathbb{R}$ med invers $g^{-1}(x) = x - \mu$. Med hjälp av formeln för täthetsfunktionen för en transformerad stokastisk variabel har vi

$$f_X(x) = f_Z(g^{-1}(x)) \left| \frac{d}{dx} g^{-1}(x) \right| = f_Z(x - \mu).$$

Givet en täthetsfunktion $f_Z(z)$ kan vi definiera familjen av täthetsfunktioner

$$\{f_X(x) : f_X(x) = f_Z(x - \mu) : \mu \in \mathbb{R}\}$$

parametriserad av *lägesparametern* μ . Denna familj kallas *lägesfamiljen* med *standardtäthetsfunktion* $f_Z(z)$.

Vi kan göra detsamma om vi skulle vilja skala fördelningen istället. När vi tar den stokastiska variabeln $X = \sigma Z$ för $\sigma > 0$ betraktar vi en skalning av fördelningen för Z . Här tar vi funktionen $g(z) = \sigma z$ vilken har invers $g^{-1}(z) = \frac{1}{\sigma}z$. Det följer att

$$f_X(x) = \frac{1}{\sigma} f_Z\left(\frac{x}{\sigma}\right).$$

Då kan vi också definiera familjen av täthetsfunktioner

$$\left\{f_X(x) : f_X(x) = \frac{1}{\sigma} f_Z\left(\frac{x}{\sigma}\right) : \sigma > 0\right\}$$

för en *skalparameter* $\sigma > 0$. Denna familjen kallas *skalfamiljen* med *standardtäthetsfunktion* $f_Z(z)$.

Exempel 1.12. Familjen

$$\mathcal{F} = \{f_X(x) : X \sim \text{Exp}(\theta), \theta > 0\}$$

bildar en skalfamilj. För att visa det kom ihåg att vi parametriserar $X \sim \text{Exp}(\theta)$ med intensitetsparameteriseringen

$$f_X(x) = \theta e^{-\theta x}.$$

Vi kan skriva om täthetsfunktionen som

$$f_X(x) = \theta e^{-\theta x} = \frac{1}{\lambda} e^{-\frac{1}{\lambda} x}$$

där vi låter $\lambda = \frac{1}{\theta}$. Om vi tar $Z \sim \text{Exp}(1)$ har vi att $f_Z(z) = e^{-z}$ och

$$f_X(x) = \frac{1}{\lambda} e^{-\frac{x}{\lambda}} = \frac{1}{\lambda} f_Z\left(\frac{x}{\lambda}\right).$$

Därför är familjen

$$\begin{aligned}\mathcal{F} &= \{f_X(x) : X \sim \text{Exp}(\theta), \theta > 0\} \\ &= \{f_X(x) : f_X(x) = \frac{1}{\lambda} e^{-\lambda x}, \lambda > 0\} \\ &= \{f_X(x) : f_X(x) = f_Z\left(\frac{x}{\lambda}\right), \lambda > 0\}\end{aligned}$$

en skalfamilj med standardtätthetsfunktion $f_Z(z) = e^{-z}$ och skalparameter $\lambda = 1/\theta$. Av den här anledningen kallas vi parametreringen

$$f_X(x) = \frac{1}{\lambda} e^{-\frac{1}{\lambda}x}$$

skalparametriseringen för en exponentialfördelad stokastisk variabel.

Det går även att kombinera båda skalning och skiftning eftersom funktionen $g(z) = \sigma z + \mu$ är också inverterbar. Då kallar vi familjen

$$\left\{f_X(x) : f_X(x) = \frac{1}{\sigma} f_Z\left(\frac{x - \mu}{\sigma}\right) : (\mu, \sigma) \in \mathbb{R} \times \mathbb{R}_{>0}\right\}$$

läges-skalfamiljen med *standardtätthetsfunktion* $f_Z(z)$.

Exempel 1.13. Normalfamiljen

$$\{f_X(x | \mu, \sigma) : X \sim N(\mu, \sigma^2), (\mu, \sigma) \in \mathbb{R} \times \mathbb{R}_{>0}\}$$

bildar en läges-skalfamilj med standardtätthetsfunktion

$$f_Z(z | \mu = 0, \sigma = 1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2\sigma^2}\right).$$

Så namnet *standardnormalfördelningen* för $N(0, 1)$ passar bra. Notera att läges-skalfamiljer vanligtvis parametreras av skalan σ medan vår definition av normalfamiljen parametreras av variansen (dvs. skalan i kvadrat) σ^2 . Eftersom $\sigma > 0$ kan den ena så klart omparametreras till den andra, men det kan vara bra att ha detta i åtanke.

Läges-skalfamiljer kan vara bra modeller när vi tror att populationens fördelning har en viss funktionell form men vi är osäkra på fördelningens väntevärde och varians. Dessa värden kan beräknas direkt från de motsvarande värdena för standardtätthetsfunktionen. Det vill säga, om X har täthetsfunktion $f_X(x | \mu, \sigma)$ i en läges-skalfamilj med standardtätthetsfunktion $f_Z(z)$ är

$$E[X] = \sigma E[Z] + \mu, \text{ och } \text{Var}[X] = \sigma^2 \text{Var}[Z],$$

och vi har även

$$P(X \leq x) = P\left(Z \leq \frac{x - \mu}{\sigma}\right).$$

1.3 Uppgifter

1.1. [1] Visa att $\chi^2(p)$ och $\text{Exp}(\lambda)$ är gammafördelningar $\text{Gamma}(\alpha, \lambda)$ där α och λ väljs på lämpligt sätt.

1.2. [1] Generera ett stickprov av storlek 10 från en $\text{Beta}(3, 5)$ -population. Vad är stickprovsmedelvärde och stickprovsvariansen? Jämför dem med $E[X]$ och $\text{Var}[X]$ där $X \sim \text{Beta}(3, 5)$.

1.3. [1] En stokastisk variabel X är $\text{Pareto}(c, \alpha)$ -fördelad för givna $c, \alpha > 0$ om X har täthetsfunktionen

$$f(x|c, \alpha) = \alpha c^\alpha x^{-(\alpha+1)}, \quad c \leq x < \infty.$$

(a) Hur kan vi generera ett slumpmässigt utfall från en paretofördelning?

(b) Generera ett stickprov av storlek 100 från en $\text{Pareto}(2.5, 4)$ -population. Vad är stickprovsmedelvärde?

- (c) Generera ett stickprov av storlek 1000 från en Pareto(2.5, 4)-population. Vad är stickprovsmedelvärdet?
- (d) Vad är $E[X]$ för $X \sim \text{Pareto}(2.5, 4)$?

1.4. [1] Generera ett stickprov av storlek 100 från en $\chi^2(6)$ -fördelning. Plotta stickprovets histogram tillsammans med täthetsfunktionen.

1.5. [1] Generera ett stickprov av storlek 100 från en Gamma(7, 0.9)-population. Plotta stickprovets histogram tillsammans med täthetsfunktionen.

1.6. [2] Låt $U \sim U(0, 1)$. Vi säger X är *logistiskt fördelad* med parameter $\mu \in \mathbb{R}, \beta > 0$ om X har täthetsfunktion

$$f(x | \mu, \beta) = \frac{1}{\beta} \frac{e^{-(x-\mu)/\beta}}{(1 + e^{-(x-\mu)/\beta})^2}, \quad x \in \mathbb{R}.$$

Vi skriver då $X \sim \text{Logistic}(\mu, \beta)$.

- (a) Visa att $-\log(U)$ och $-\log(1 - U)$ är exponentialfördelade.
 - (b) Visa att $X = \log(U/(1 - U)) \sim \text{Logistic}(0, 1)$.
 - (c) Beskriva en metod för att generera ett slumpmässigt utfall från en $\text{Logistic}(\mu, \beta)$ -fördelning.
- 1.7. [1] Vi skulle vilja simulera hur lång tid vi väntar mellan ankomster av en viss buss vid en viss hållplats. I genomsnitt kommer bussen var 10:e minut. Simulera tre utfall från populationen av väntetider.
- 1.8. [1] En viss fabrik tillverkar mynt. I genomsnitt förväntas mynt vara oviktade, men vissa mynt kan vara något viktade på grund av ojämnheter i materialet. Vi mäter ett mynts bias (systematiska fel) som sannolikheten att vi singlar myntet och får krona. Anta att myntens bias följer en Beta(2, 2)-fördelning, simulera 10 mynt och rapportera deras bias. Vad är den observerade variansen biasen?
- 1.9. [1] Under 10 slumpmässigt utvalda dagar på sommaren mäts antalet gånger T en viss buss kommer till en viss hållplats i tid från början av dagen till bussen är sen för den andra gången. Datan som samlas är 2, 3, 7, 8, 2, 4, 7, 5, 5, 7. Låt $\bar{t}$ beteckna datans stickprovsmedelvärde.
- (a) Vi gissar att datan kommer ifrån en NegBin(2, 1/7)-fördelning. Skatta numeriskt sannolikheten $P(\bar{T} \leq \bar{t})$ med hjälp av stickprov $T_1, \dots, T_{10}$ från en NegBin(2, 1/7)-fördelning.
 - (b) Är det rimligt att anta att $T \sim \text{NegBin}(2, 1/7)$? Varför eller varför inte? Om det inte verkar rimligt kan du föreslå ett val för p (med $r = 2$) som ger en bättre modell för T ?
- 1.10. [1] Vi skulle vilja simulera antalet ankomster på en timme för en viss buss på en viss hållplats där bussen kommer tre gånger varje 20 minuter i genomsnitt. Generera ett rimligt exempel för hur många gånger bussen kunna ankomma i en timme.
- 1.11. [1] För varje av följande fördelningar: (i) skriv en algoritm för att generera slumpmässiga utfall från fördelningen (ii) använd algoritmen för att generera ett stickprov av storlek 1000 från fördelningen, och (iii) jämför stickprovsmedelvärdet, stickprovsvariansen och histogrammet av stickprovet med sitt väntevärde.
- (a) $Y \sim \text{Bin}(8, 2/3)$
 - (b) $Y \sim \text{Hypergeom}(10, 8, 4)$
 - (c) $Y \sim \text{NegBin}(5, 1/3)$
- 1.12. [1] Simulering för en icke-standardnormalfördelning:
- (a) Beskriva en metod för att generera slumpmässiga utfall från en $N(\theta, \sigma^2)$ -population där $\theta \neq 0$ och $\sigma^2 \neq 1$.
 - (b) Generera 10000 slumpmässiga utfall från en $N(3, 25)$ -population med hjälp av din metod.
 - (c) Gör ett histogram av ditt stickprov tillsammans med en ritning av täthetsfunktionen $f_X(x)$ för $X \sim N(3, 25)$. Passar histogrammet bra med täthetsfunktionen?

- (d) Jämför stickprovsmedelvärdet och stickprovsvariansen med väntevärdet respektive variansen för $N(3, 25)$ -fördelningen.

- 1.13. [2] Generera ett stickprov av storlek 500 från $(X_1, X_2)^T$ där

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= \frac{1}{2}X_1 + N_2 \end{aligned}$$

för $N_1 \sim N(0, 1)$, $N_2 \sim N(5, 4)$ och N_1 och N_2 är oberoende. Plotta stickprovet. Finns det någon observerbar korrelation mellan X_1 och X_2 ? Vad är stickprovsmedelvärdet?

- 1.14. [2] Vi har två obereonde maskiner som var och en genererar ett tal, antingen 0 eller 1, när vi trycker på en viss knapp. Den första maskinen ger 1 med sannolikhet $3/5$ och den andra maskinen ger 1 med sannolikhet $3/8$. Simulera 100 utfall för den stokastiska variabeln X som betecknar summan av dem två talen produceras när vi trycker på knappen. Vad är stickprovsmedelvärdet och stickprovsvariansen?

- 1.15. [2] Anta att du kastar en välgjord sexsidig tärning fyra gånger och skriver ner antalet gånger du se varje av de sex möjliga värdena. Upprepa detta experiment 1000 gånger och, för varje $i \in \{1, \dots, 6\}$, beräkna X_i 's stickprovsmedelvärde där X_i är antalet gånger du får värdet i i ett enda experiment. Jämför dessa stickprovsmedelvärden med de motsvarande väntevärdena.

- 1.16. [1] Generera ett stickprov av storlek 15 från en $\text{Bin}(10, 1/4)$ -population. Plotta stickprovets histogram. Jämför stickprovsmedelvärdet och stickprovsvariansen med $E[X]$ respektive $\text{Var}[X]$.

- 1.17. [2] Låt $X \sim \text{NegBin}(r, p)$. Visa att

$$E[X] = \frac{r(1-p)}{p} \quad \text{och} \quad \text{Var}[X] = \frac{r(1-p)}{p^2}.$$

- 1.18. [1] Visa att följande familjer fördelningar är exponentialfamiljer:

- (a) $\text{Gamma}(\alpha, \lambda)$ -familjen med antingen parametern α eller λ känd eller båda två okända.
- (b) $\text{Beta}(\alpha, \beta)$ -familjen med antingen parametern α eller β känd eller båda två okända.
- (c) $\text{NegBin}(r, p)$ -familjen med r känd.
- (d) $\text{Multi}(m, p_1, \dots, p_n)$ -familjen med m känd.

- 1.19. [1] Generera ett stickprov av storlek 10 från en $\text{NegBin}(5, 2/3)$ -population. Vad är stickprovsmedelvärdet och stickprovsvariansen?

- 1.20. [1] Vi säger X är $\text{Peak}(p, d)$ -fördelad om X har täthetsfunktion

$$f_X(x) = \begin{cases} 0 & \text{om } x < p - d, \\ \frac{1}{d^2}(x + d - p) & \text{om } p - d \leq x \leq p, \\ -\frac{1}{d^2}(x - d - p) & \text{om } p \leq x \leq p + d, \\ 0 & \text{om } x > p + d. \end{cases}$$

Visa att familjen $\mathcal{F} = \{f_X(x) : X \sim \text{Peak}(p, d), d > 0, p \in \mathbb{R}\}$ är en läge- och skalfamilj med standardtäthetsfunktion $f_Z(z)$ där $Z \sim \text{Peak}(0, 1)$. Vad är $E[X]$ och $\text{Var}[X]$ för $X \sim \text{Peak}(p, d)$?

- 1.21. [1] Generera ett approximativt stickprov från en $\text{Peak}(1, 7)$ -population (se Uppgift 1.20). Vad är stickprovsmedelvärdet och stickprovsvariansen? Plotta stickprovshistogrammet tillsammans med fördelningens täthetsfunktion.

- 1.22. [3] En konståkare tävlar i tävlingar där varje uppträdande ges fyra betyg mellan 0 och 12 och varje betyg ges av oberoende domare. Konståkarens totalbetyg X är genomsnittet av de fyra poängen. Vi kan *normalisera* ett givet betyg S från en individuell domare till ett *normaliserat betyg* $S/12 \in [0, 1]$.

- (a) Vi tror att konståkarens normaliserade betyg från varje domare modelleras av en $\text{Beta}(35, 40)$ -fördelning. Generera ett stickprov av storlek 500 från X . Vad är stickprovsmedelvärdet och stickprovsvariansen?
- (b) Antag istället att konståkarens normaliserade betyg modelleras av följande fördelningar: $\text{Beta}(35, 6)$, $\text{Beta}(37, 7)$, $\text{Beta}(29, 3)$ och $\text{Beta}(25, 5)$. Generera ett stickprov av storlek 500 från X . Vad är stickprovsmedelvärdet och stickprovsvariansen? Hur skiljer de sig från stickprovsmedelvärdet respektive stickprovsvariansen från (a)?

1.23. [3] Visa att Paretofamiljen $\text{Pareto}(c, \alpha)$ för $c, \alpha > 0$ inte är en exponentialfamilj.

1.24. [1] För var och en av följande familjer:

- verifiera att den är en exponentialfamilj,
- beskriv kurvan på vilken parametervektorn θ ligger och
- rita upp grafen av det böjda parameterrummet.

- (a) $N(\theta, \theta)$ där $\theta > 0$,
 (b) $N(\theta, a\theta^2)$, för a känd,
 (c) $\text{Gamma}(\alpha, 1/\alpha)$ och
 (d) $f(x | \theta) = C \exp(-(x - \theta)^4)$, för normaliseringskonstanten C .

1.25. [1] Visa att $\mathcal{F} = \{f_X(x|\alpha, \beta) : X \sim \text{Beta}(\alpha, \beta), \alpha > 0, \beta > 0\}$ är en exponentialfamilj.

1.26. [2] Låt $X \sim \text{Beta}(\alpha, 2)$ och låt $Y = -\log(X)$.

- (a) Beräkna $E[Y]$ med hjälp av en transformation av stokastiska variabler.
 (b) Visa att $f_X(x | \alpha)$ tillhör en exponentialfamilj, och använd Sats 1.2 för att beräkna $E[Y]$.

1.27. [1] Använd Sats 1.2 för att beräkna $\text{Var}[X]$ för $X \sim N(\mu, \sigma^2)$.

1.28. [2] Använd Sats 1.2 för att ta fram en formel för $E[X^2]$ för $X \sim N(\mu, \sigma^2)$.

1.29. [2] Visa att $\mathcal{F}_n = \{f_X(x | p) : X \sim \text{Bin}(n, p)\}$ för n fix är en exponentialfamilj. Använd Sats 1.2 för att ta fram en formel för $E[X]$ och $\text{Var}[X]$ för $X \sim \text{Bin}(n, p)$.

1.30. [1] Visa att familjen $\mathcal{F}_n = \{f_X(x|n, p) : X \sim \text{NegBin}(n, p), p > 0\}$ är en exponentialfamilj när n är fix.

1.31. [2] Låt $G = ([m], E)$ vara en oriktad graf med m noder och kantmängd $E(G) \subseteq [m] \times [m]$ och låt $\beta_1, \dots, \beta_m$ vara parametrar. β -modellen är modellen med utfallsrum $\mathbb{G}_m$ som består av alla grafer G med nodmängd $[m]$ där graf $G \in \mathbb{G}$ har sannolikhet

$$P(G) = \frac{1}{Z} \prod_{\{i,j\} \in E(G)} \beta_i \beta_j,$$

där $Z = \sum_G \prod_{\{i,j\} \in E(G)} \beta_i \beta_j$. Visa att β -modellen bildar en exponentialfamilj.

1.32. [2] Låt $G = ([m], E)$ vara en oriktad graf med m noder och kantmängd $E \subseteq [m] \times [m]$. Vi definierar *grannmatrisen* av G som $A = [a_{i,j}]$ där $a_{i,j} = 1$ om $(i, j) \in E$ samt $a_{i,j} = 0$ om $(i, j) \notin E$. *Erdős–Renyi-modellen* är en enkelparametermodell med utfallsrum $\mathbb{G}_m$ som består av alla grafer G med nodmängd $[m]$, där grafen $G \in \mathbb{G}$ har sannolikhet

$$P_\theta(G) = \prod_{i \in [m]} \prod_{j \in [m]} \theta^{a_{i,j}} (1 - \theta)^{1 - a_{i,j}} \quad \text{där } \theta \in (0, 1).$$

Visa att Erdős–Renyi-modellen bildar en exponentialfamilj.

1.33. [2] Använd Sats 1.2 för att ta fram en formel för $E[X]$ och $\text{Var}[X]$ där $X \sim \text{NegBin}(3, p)$.

Kapitel 2

2.1 Flerdimensionella fördelningar

I många verkliga dataanalytiska situationer är vi intresserade av flera beroende stokastiska variabler $X_1, \dots, X_m$, istället för bara en variabel X . Det kan därmed vara användbart att ha modeller som kan uttrycka sannolikheten av att se *simultan utfall* liksom $\mathbf{x} = [x_1, \dots, x_m]^T$. Ett sådant utfall är en observation av den m -dimensionella *stokastiska vektorn* $\mathbf{X} = [X_1, \dots, X_m]^T$.

Exempel 2.1. Låt X_1 beteckna den stokastiska variabeln med utfall $\{0, 1\}$, där 1 betecknar att det har varit inbrott i ett visst hus och 0 betecknar att inget inbrott har inträffat där. Låt X_2 beteckna den stokastiska variabeln med utfall $\{0, 1\}$, där 1 betecknar att polisen kommer till huset och 0 betecknar att de inte kommer. Vi skulle ha nytta av en förståelse av de simultana sannolikheter:

$$P(0, 0), P(0, 1), P(1, 0), \text{ och } P(1, 1),$$

där $P(x_1, x_2)$ betecknar sannolikheten av det simultana utfallet $[x_1, x_2]^T$ av $\mathbf{X} = [X_1, X_2]^T$.

I Exempel 2.1, utfallsrummet är ändligt och därför är $\mathbf{X} = [X_1, X_2]^T$ ett exempel av en *diskret stokastisk vektor*; det vill säga, en stokastisk vektor som tar värden i en uppräknelig mängd. En sådan stokastisk vektor har *simultan sannolikhetsfunktion*

$$f_{\mathbf{X}}(\mathbf{x}) = f_{\mathbf{X}}(x_1, \dots, x_m) = P(X_1 = x_1, X_2 = x_2, \dots, X_m = x_m).$$

Om $\mathbf{X}$ tar istället värden i en ouppräknelig mängd kallas det en *kontinuerlig stokastisk vektor*. En kontinuerlig stokastisk vektor $\mathbf{X} = [X_1, \dots, X_m]^T$ har *simultan täthetsfunktion*

$$f_{\mathbf{X}}(\mathbf{x}) = f_{\mathbf{X}}(x_1, \dots, x_m),$$

där

$$\int_{-\infty}^{a_1} \cdots \int_{-\infty}^{a_m} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = P(X_1 \leq a_1, \dots, X_m \leq a_m),$$

för alla $a_1, \dots, a_m \in \mathbb{R}$.

I denna bok betecknar vi vektorer med fetstilta eller understrukna bokstäver: $\mathbf{X} = [X_1, \dots, X_m]^T$. För ett stickprov $\mathbf{X}_1, \dots, \mathbf{X}_n$ från fördelningen av $\mathbf{X}$ skriver vi $\mathbf{X}_i = [X_{i,1}, \dots, X_{i,m}]^T$ för alla $i = 1, \dots, n$. Så är $X_{i,j}$ utfallet av X_j för det i :te elementet $\mathbf{X}_i$ i stickprovet.

Om $S = \{i_1, \dots, i_k\}$ är en delmängd av $\{1, \dots, m\}$ kan vi betrakta också den stokastiska *delvektorn* $\mathbf{X}_S = [X_{i_1}, \dots, X_{i_k}]^T$ av $\mathbf{X} = [X_1, \dots, X_m]^T$. Dessa har utfall $\mathbf{x}_S = [x_{i_1}, \dots, x_{i_k}]^T \in \mathbb{R}^k$. Vi är nu intresserade av fördelningen för $\mathbf{X}_S$; det vill säga hur sannolika olika värden på $\mathbf{X}_S$ är oavsett vad som händer med de resterande komponenterna i $\mathbf{X}$.

Denna fördelning kallas för *marginalfördelningen* av $\mathbf{X}_S$. I det diskreta fallet har vi den *marginella sannolikhetsfunktionen*

$$f_{\mathbf{X}_S}(\mathbf{x}_S) = \sum_{\mathbf{x}_{\{1, \dots, m\} \setminus S}} f_{\mathbf{X}}(\mathbf{x}),$$

det vill säga vi summerar den simultana täthetsfunktionen $f_{\mathbf{X}}(\mathbf{x})$ över alla möjliga värden på $\mathbf{x}$ där $\mathbf{x}_S$ hålls fixt. (För enkelhets skull kommer vi inte att skriva ner gränserna i summor för sannolikhetsfunktioner när dessa kan härledas från sannolikhetsfunktionens stöd.) För kontinuerliga stokastiska vektorer har vi på samma sätt den *marginella täthetsfunktionen*

$$f_{\mathbf{X}_S}(\mathbf{x}_S) = \int_{\mathbb{R}} \cdots \int_{\mathbb{R}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}_{\{1, \dots, m\} \setminus S}.$$

När vi beräknar dessa fördelningar säger vi att vi *marginaliserar* ut de variabler som inte är i S .

Det enklaste fallet är då $m = 2$. Om vi tar $S = \{1\}$ får vi

$$f_{X_1}(x_1) = \sum_{x_2} f_{X_1, X_2}(x_1, x_2),$$

i det diskreta fallet och

$$f_{X_1}(x_1) = \int_{\mathbb{R}} f_{X_1, X_2}(x_1, x_2) dx_2$$

i det kontinuerliga fallet. Dessa formler är detsamma som vi förmodligen såg i en första kurs om sannolikhets teori och statistik och de motsvarar marginalfördelningarna i det tvådimensionella fallet.

Exempel 2.2. Vi fortsätter med Exempel 2.1. Om vi skulle vilja veta den marginella sannolikheten av $X_2 = 0$ räknar vi

$$P(X_2 = 0) = f_{X_2}(0) = f_{\mathbf{X}}(0, 0) + f_{\mathbf{X}}(1, 0) = P(0, 0) + P(1, 0);$$

dvs, vi summerar sannolikheterna av $(0, 0)$ och $(1, 0)$. Resultatet är sannolikheten att polisen kommer till huset oavsett om något inbrott har skett.

Precis som endimensionella fördelningar parametrerar vi ofta flerdimensionella fördelningar. Naturligtvis finns det flera flerdimensionella familjer vilka generalisera motsvarande endimensionella familjer. I följande presenterar vi några viktiga exempel.

2.1.1 Multinomialfördelningen

Låt $\mathbf{X} = [X_1, \dots, X_m]^T$ vara en stokastisk vektor där X_i har möjliga utfall $\{0, 1, \dots, n\}$ för alla $i = 1, \dots, m$. För ett positivt heltal n och $0 \leq p_1, \dots, p_m \leq 1$ antar vi att $x_1 + \dots + x_m = n$ och $p_1 + \dots + p_m = 1$. Vi säger $\mathbf{X}$ är *multinomialfördelad* om

$$f_{\mathbf{X}}(x_1, \dots, x_m) = \frac{n!}{x_1! \dots x_m!} p_1^{x_1} \dots p_m^{x_m}.$$

Vi skriver detta som $\mathbf{X} \sim \text{Multi}(n, p_1, \dots, p_m)$.

Multinomialfördelningen modellerar en situation där ett experiment med möjliga utfall $1, \dots, m$ vilka inträffar med sannolikheter $p_1, \dots, p_m$. Detta experiment genomförs n gånger och X_i betecknar antalet gånger utfallet i inträffar. Man kan visa att marginalfördelningen $f_{X_i}(x_i)$ för alla $i = 1, \dots, m$ är en binomialfördelning (se övning 2); dvs, $X_i \sim \text{Bin}(n, p_i)$ om $\mathbf{X} \sim \text{Multi}(n, p_1, \dots, p_m)$.

Exempel 2.3. Multinomialfördelningen är användbar när vi vill modellera en situation där vi har två eller fler möjliga utfall, exempelvis ett val med tre kandidater. Anta att ett visst val har tre kandidater: kandidat 1, kandidat 2 och kandidat 3. Baserat på preliminära enkätdata skattar vi att sannolikheterna att kandidat 1, 2 och 3 vinner en viss persons röst är $p_1 = 1/10$, $p_2 = 1/2$ respektive $p_3 = 2/5$. Om 1 000 000 personer kommer att rösta i valet kan vi modellera antalet röster kandidaterna får med multinomialfördelningen

$$f_{\mathbf{X}}(x_1, x_2, x_3) = \frac{1000000!}{x_1! x_2! x_3!} \left(\frac{1}{10}\right)^{x_1} \left(\frac{1}{2}\right)^{x_2} \left(\frac{2}{5}\right)^{x_3},$$

där X_i betecknar antalet röster för kandidaten i för $i = 1, 2, 3$. I denna situation är ett givet "experiment" händelsen att en enda person lägger sin röst. Vi upprepar experimentet $n = 1\,000\,000$ gånger och X_i räknar antalet gånger experimentet resulterar i en röst för kandidat i .

Eftersom summan av $x_1, \dots, x_m$ alltid är lika med n räcker det att sätta $x_1, \dots, x_{m-1}$ och ta $x_m = n - x_1 - \dots - x_{m-1}$ för att specificera ett visst utfall av $\mathbf{X}$. På samma sätt har vi att $p_m = 1 - p_1 - \dots - p_{m-1}$. En alternativ definition av multinomialfördelningen är då som en $(m-1)$ -dimensionell fördelning med sannolikhetsfunktion

$$f_{X_1, \dots, X_{m-1}}(x_1, \dots, x_{m-1}) = \frac{n!}{x_1! \dots x_{m-1}! \left(n - \sum_{i=1}^{m-1} x_i\right)!} p_1^{x_1} \dots p_{m-1}^{x_{m-1}} \left(1 - \sum_{i=1}^{m-1} p_i\right)^{n - \sum_{i=1}^{m-1} x_i}.$$

Denna mindre elegantare variant har fördelen att fallet $m = 2$ ger (den endimensionella) binomialfördelningen. I denna bok kommer vi hålla oss till den första definitionen om inget annat anges.

2.1.2 Flerdimensionella normalfördelningen

Fixa parametrarna $\boldsymbol{\mu} \in \mathbb{R}^m$ och $\Sigma = [\Sigma_{i,j}]_{i,j=1}^m \in \mathbb{R}^m \times \mathbb{R}^m$ en positivt definit matris (dvs, en symmetrisk matris med bara positiva egenvärden). Vi säger $\mathbf{X} = [X_1, \dots, X_m]^T$ har en *flerdimensionell normalfördelning* (eller helt enkelt att $\mathbf{X}$ är normalfördelad) med parametrar $\boldsymbol{\mu}$ och Σ om $\mathbf{X}$ har täthetsfunktion

$$f_{\mathbf{X}}(\mathbf{x} \mid \boldsymbol{\mu}, \Sigma) = \frac{1}{(2\pi)^{m/2} \sqrt{\det(\Sigma)}} \exp\left(-\frac{1}{2}(\boldsymbol{\mu} - \mathbf{x})^T \Sigma^{-1}(\boldsymbol{\mu} - \mathbf{x})\right),$$

där $\det(\Sigma)$ är determinanten av Σ (positiv eftersom Σ är positivt definit). Den flerdimensionella normalfördelningen generaliserar den endimensionella normalfördelningen och de sammanfaller för $m = 1$. Vi skriver $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ om $\mathbf{X}$ är normalfördelad med parametrar $\boldsymbol{\mu}$ och Σ . (Man kan också definiera normalfördelningar för Σ som inte är positivt definita utan positivt *semidefinita* – med egenvärden som tillåts vara noll – men i dessa har ingen väldefinierad täthetsfunktion då Σ inte längre är inverterbar.)

Precis som dess endimensionella kusin har den flerdimensionella normalfördelningen ett antal användbara egenskaper. Till exempel, om $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ är väntevärdet $E[\mathbf{X}]$ av $\mathbf{X}$ lika med $\boldsymbol{\mu}$ (se avsnitt 2.4.1 nedan). Dessutom har marginalfördelningarna för en flerdimensionell normalfördelning en enkel form.

Sats 2.1. Låt $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ för någon $\boldsymbol{\mu} \in \mathbb{R}^m$ och $\Sigma \in \mathbb{R}^{m \times m}$ (positivt definit). Om $S \subset \{1, \dots, m\}$ har vi att delvektorn $\mathbf{X}_S$ uppfyller

$$\mathbf{X}_S \sim N(\boldsymbol{\mu}_S, \Sigma_{S,S})$$

där $\Sigma_{S,S} = [\Sigma_{i,j}]_{i,j \in S}$ (delmatrisen av Σ med rader och kolumner givna av S).

Bevis. Antag utan inskränkning att $S = \{1, \dots, k\}$ så att vi har $\mathbf{X}_S = [X_1, \dots, X_k]^T$ samt $\mathbf{x}_S = [x_1, \dots, x_k]^T$. Vidare sätter vi $T = \{1, \dots, m\} \setminus S = \{k+1, k+2, \dots, m\}$ så att vi kan skriva $\mathbf{X} = [\mathbf{X}_S^T \mathbf{X}_T^T]^T$ samt $\mathbf{x} = [\mathbf{x}_S^T \mathbf{x}_T^T]^T$.

För att beräkna den marginella täthetsfunktionen $f_{\mathbf{X}_S}(\mathbf{x}_S)$ för $\mathbf{X}_S$ måste vi ta den simultana täthetsfunktionen $f_{\mathbf{X}}(\mathbf{x})$ och integrera denna med avseende på $\mathbf{x}_T$ (dvs. marginalisera bort $\mathbf{X}_T$). Svårigheten med detta är att täthetsfunktionen $f_{\mathbf{X}}(\mathbf{x})$ involverar $\mathbf{x}_S$ och $\mathbf{x}_T$ på ett sätt som gör det svårt att integrera med avseende på den ena men inte den andra. Mer specifikt så har vi följande uttryck i exponenten

$$(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}).$$

Om vi delar upp $\boldsymbol{\mu}$ på samma sätt som $\mathbf{x}$, dvs. vi tar $\boldsymbol{\mu} = [\boldsymbol{\mu}_S^T \boldsymbol{\mu}_T^T]^T$, så kan vi skriva

$$\begin{bmatrix} \mathbf{x}_S - \boldsymbol{\mu}_S \\ \mathbf{x}_T - \boldsymbol{\mu}_T \end{bmatrix}^T \Sigma^{-1} \begin{bmatrix} \mathbf{x}_S - \boldsymbol{\mu}_S \\ \mathbf{x}_T - \boldsymbol{\mu}_T \end{bmatrix}$$

men matrismultiplikationen med Σ^{-1} ställer till det eftersom den blandar termer som beror på $\mathbf{x}_S$ med termer som beror på $\mathbf{x}_T$. Vi skulle behöva ett sätt att skriva om Σ^{-1} som separerar dessa termer.

För Σ själv är inte detta ett större problem. Vi kan göra en blockuppdelning med avseende på S och T vilket ger

$$\Sigma = \begin{bmatrix} \Sigma_{S,S} & \Sigma_{S,T} \\ \Sigma_{T,S} & \Sigma_{T,T} \end{bmatrix}$$

där $\Sigma_{S,S} = [\Sigma_{i,j}]_{i,j \in S}$, $\Sigma_{S,T} = [\Sigma_{i,j}]_{i \in S, j \in T}$, $\Sigma_{T,S} = \Sigma_{S,T}^T$ och $\Sigma_{T,T} = [\Sigma_{i,j}]_{i,j \in T}$. Om vi multiplicerar Σ med $\mathbf{x}$ kan vi med denna blockuppdelning separera termerna som beror på $\mathbf{x}_S$ från de som beror på $\mathbf{x}_T$. Frågan är nu hur vi kan hitta en liknande blockuppdelning för Σ^{-1} .

För att invertera en 2×2 -blockmatris på formen

$$M = \begin{bmatrix} A & B \\ C & D \end{bmatrix}$$

använder man *Schurkomplementet* av A i M , vilket ges av

$$M/A = D - CA^{-1}B.$$

Inversen av M ges då av

$$M^{-1} = \begin{bmatrix} \mathbf{I} & -A^{-1}B \\ 0 & \mathbf{I} \end{bmatrix} \begin{bmatrix} A^{-1} & 0 \\ 0 & (M/A)^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{I} & 0 \\ -CA^{-1} & \mathbf{I} \end{bmatrix}.$$

I vårt fall har vi $A = \Sigma_{SS}$, $B = \Sigma_{ST}$, $C = \Sigma_{TS}$ och $D = \Sigma_{TT}$, vilket ger

$$\Sigma^{-1} = \begin{bmatrix} \mathbf{I} & -\Sigma_{SS}^{-1}\Sigma_{ST} \\ 0 & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Sigma_{SS}^{-1} & 0 \\ 0 & (\Sigma/\Sigma_{SS})^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{I} & 0 \\ -\Sigma_{TS}\Sigma_{SS}^{-1} & \mathbf{I} \end{bmatrix}$$

där $\Sigma/\Sigma_{SS} = \Sigma_{TT} - \Sigma_{TS}\Sigma_{SS}^{-1}\Sigma_{ST}$. Eftersom Σ_{SS} är symmetrisk och $\Sigma_{ST}^T = \Sigma_{TS}$ kan vi skriva om detta som

$$\Sigma^{-1} = \begin{bmatrix} \mathbf{I} & 0 \\ -\Sigma_{TS}\Sigma_{SS}^{-1} & \mathbf{I} \end{bmatrix}^T \begin{bmatrix} \Sigma_{SS}^{-1} & 0 \\ 0 & (\Sigma/\Sigma_{SS})^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{I} & 0 \\ -\Sigma_{TS}\Sigma_{SS}^{-1} & \mathbf{I} \end{bmatrix}.$$

Vi får då

$$\begin{aligned} & (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \\ &= \begin{bmatrix} \mathbf{x}_S - \boldsymbol{\mu}_S \\ \mathbf{x}_T - \boldsymbol{\mu}_T \end{bmatrix}^T \begin{bmatrix} \mathbf{I} & 0 \\ -\Sigma_{TS}\Sigma_{SS}^{-1} & \mathbf{I} \end{bmatrix}^T \begin{bmatrix} \Sigma_{SS}^{-1} & 0 \\ 0 & (\Sigma/\Sigma_{SS})^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{I} & 0 \\ -\Sigma_{TS}\Sigma_{SS}^{-1} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{x}_S - \boldsymbol{\mu}_S \\ \mathbf{x}_T - \boldsymbol{\mu}_T \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{x}_S - \boldsymbol{\mu}_S \\ \mathbf{x}_T - \boldsymbol{\mu}_T - \Sigma_{TS}\Sigma_{SS}^{-1}(\mathbf{x}_S - \boldsymbol{\mu}_S) \end{bmatrix}^T \begin{bmatrix} \Sigma_{SS}^{-1} & 0 \\ 0 & (\Sigma/\Sigma_{SS})^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{x}_S - \boldsymbol{\mu}_S \\ \mathbf{x}_T - \boldsymbol{\mu}_T - \Sigma_{TS}\Sigma_{SS}^{-1}(\mathbf{x}_S - \boldsymbol{\mu}_S) \end{bmatrix} \\ &= (\mathbf{x}_S - \boldsymbol{\mu}_S)^T \Sigma_{SS}^{-1} (\mathbf{x}_S - \boldsymbol{\mu}_S) \\ &\quad + (\mathbf{x}_T - \boldsymbol{\mu}_T - \Sigma_{TS}\Sigma_{SS}^{-1}(\mathbf{x}_S - \boldsymbol{\mu}_S))^T (\Sigma/\Sigma_{SS})^{-1} (\mathbf{x}_T - \boldsymbol{\mu}_T - \Sigma_{TS}\Sigma_{SS}^{-1}(\mathbf{x}_S - \boldsymbol{\mu}_S)). \end{aligned}$$

Utöver detta har vi att

$$\det \Sigma = \det \Sigma_{SS} \cdot \det(\Sigma/\Sigma_{SS}).$$

Tillsammans ger detta

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}) &= \frac{1}{(2\pi)^{k/2} \sqrt{\det \Sigma_{SS}}} e^{-\frac{1}{2}(\mathbf{x}_S - \boldsymbol{\mu}_S)^T \Sigma_{SS}^{-1} (\mathbf{x}_S - \boldsymbol{\mu}_S)} \\ &\quad \frac{1}{(2\pi)^{(d-k)/2} \sqrt{\det(\Sigma/\Sigma_{SS})}} e^{-\frac{1}{2}(\mathbf{x}_T - \boldsymbol{\mu}_T - \Sigma_{TS}\Sigma_{SS}^{-1}(\mathbf{x}_S - \boldsymbol{\mu}_S))^T (\Sigma/\Sigma_{SS})^{-1} (\mathbf{x}_T - \boldsymbol{\mu}_T - \Sigma_{TS}\Sigma_{SS}^{-1}(\mathbf{x}_S - \boldsymbol{\mu}_S))}. \end{aligned}$$

Om vi nu integrerar med avseende på $\mathbf{x}_T$ så försvinner den andra faktorn eftersom den är täthetsfunktionen för $N(\boldsymbol{\mu}_T - \Sigma_{TS}\Sigma_{SS}^{-1}(\mathbf{x}_S - \boldsymbol{\mu}_S), \Sigma/\Sigma_{SS})$ och därför integrerar till ett. Vi får då

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{k/2} \sqrt{\det \Sigma_{SS}}} e^{-\frac{1}{2}(\mathbf{x}_S - \boldsymbol{\mu}_S)^T \Sigma_{SS}^{-1} (\mathbf{x}_S - \boldsymbol{\mu}_S)},$$

det vill säga att $\mathbf{X}_S \sim N(\boldsymbol{\mu}_S, \Sigma_{SS})$, vilket skulle visas. □

En konsekvens av denna sats är att $X_i \sim N(\mu_i, \Sigma_{i,i})$ så $E[X_i] = \mu_i$ och $\text{Var}[X_i] = \Sigma_{i,i}$.

Exempel 2.4. Låt $\mathbf{X} = [X_1, X_2, X_3]^T \sim N(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = \begin{bmatrix} 6 \\ 23 \\ -4.5 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 14 & 32 & 50 \\ 32 & 77 & 122 \\ 50 & 122 & 194 \end{bmatrix}.$$

Det följer att $X_1 \sim N(6, 14)$ och $\mathbf{X}_{\{1,3\}} = [X_1, X_3]^T \sim N(\boldsymbol{\mu}_{\{1,3\}}, \Sigma_{\{1,3\},\{1,3\}})$, där

$$\boldsymbol{\mu}_{\{1,3\}} = \begin{bmatrix} 6 \\ -4.5 \end{bmatrix}, \quad \Sigma_{\{1,3\},\{1,3\}} = \begin{bmatrix} 14 & 50 \\ 50 & 194 \end{bmatrix}.$$

2.1.3 Flerdimensionella exponentialfamiljer

Precis som i det endimensionella fallet kan familjer av flerdimensionella distributioner bilda en exponentialfamilj. För en m -dimensionell fördelning med parameter $\boldsymbol{\theta} \in \mathbb{R}^d$ kräver vi då att $f_{\mathbf{X}}(\mathbf{x} \mid \boldsymbol{\theta})$ kan skrivas som

$$f_{\mathbf{X}}(\mathbf{x} \mid \boldsymbol{\theta}) = h(\mathbf{x})c(\boldsymbol{\theta}) \exp \left(\sum_{j=1}^k w_j(\boldsymbol{\theta})^T t_j(\mathbf{x}) \right)$$

där $h : \mathbb{R}^m \rightarrow \mathbb{R}_{\geq 0}$, $c : \mathbb{R}^d \rightarrow \mathbb{R}_{\geq 0}$ och $w_i : \mathbb{R}^d \rightarrow \mathbb{R}^{k_i}$ samt $t_i : \mathbb{R}^m \rightarrow \mathbb{R}^{k_i}$ för något positivt heltal k_i för alla $i = 1, \dots, k$. Skillnaden är alltså att vi har $\mathbf{x} \in \mathbb{R}^m$ istället för $x \in \mathbb{R}$ samt att vi tillåter w_i och t_i att ta värden i $\mathbb{R}^{k_i}$ och bildar skalärprodukten $w_i(\boldsymbol{\theta})^T t_i(\mathbf{x})$ (det senare är bara till för att förenkla notation och spelar ingen större roll). Annars beter sig dessa exponentialfamiljer likadant som i det endimensionella fallet.

Exempel 2.5. Likt binomialfördelningen bildar multinomialfördelningen $\text{Multi}(n, p_1, \dots, p_m)$ också en exponentialfamilj för fixt antal försök n med parameter $\boldsymbol{\theta} = [p_1, \dots, p_m]^T$. Vi ser detta genom att skriva om sannolikhetsfunktionen

$$f(\mathbf{x} \mid \boldsymbol{\theta}) = \frac{n!}{x_1!x_2!\dots x_m!} p_1^{x_1} p_2^{x_2} \dots p_m^{x_m} = \frac{n!}{x_1!x_2!\dots x_m!} \exp \left(\sum_{i=1}^m x_i \log p_i \right) = h(\mathbf{x})c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^m w_i(\boldsymbol{\theta}) t_i(\mathbf{x}) \right)$$

där $h(\mathbf{x}) = n!/x_1!x_2!\dots x_m!$, $c(\boldsymbol{\theta}) = 1$ och $w_i(\boldsymbol{\theta}) = \log p_i$ samt $t_i(\mathbf{x}) = x_i$ för alla $i = 1, \dots, m$. Familjen av multinomialfördelningar för fixt n är också en fullständig exponentialfamilj (då antalet naturliga parametrar är lika med dimensionen på parameterrummet).

Exempel 2.6. För den flerdimensionella normalfördelningen med parametrar $\boldsymbol{\mu} \in \mathbb{R}^m$ och $\Sigma \in \mathbb{R}^{m \times m}$ (positivt definit) har vi täthetsfunktionen

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{m/2} \sqrt{\det \Sigma}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right).$$

Vi kan nu skriva

$$\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) = \frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x} - \boldsymbol{\mu}^T \Sigma^{-1} \mathbf{x} + \frac{1}{2} \boldsymbol{\mu}^T \Sigma^{-1} \boldsymbol{\mu}.$$

Eftersom $\mathbf{x}^T \Sigma^{-1} \mathbf{x}$ är en skalär är den lika med spåret

$$\text{tr}(\mathbf{x}^T \Sigma^{-1} \mathbf{x}) = \text{tr}(\Sigma^{-1} \mathbf{x} \mathbf{x}^T)$$

där vi har utnyttjat att spåret är invariant med avseende på cykliska permutationer (dvs. att $\text{tr}(ABC) = \text{tr}(CAB) = \text{tr}(BCA)$). Vidare har vi att $\text{tr}(A^T B) = \text{vec}(A)^T \text{vec}(B)$ där $\text{vec}(A)$ avser *vektoriseringen* av A , dvs. om $A = [a_{ij}]_{i,j=1}^{n,k}$ så sätter vi $\text{vec}(A)$ vektorn i $\mathbb{R}^{nm}$ vars element i index $(i-1)n + j$ är lika med a_{ij} för $i = 1, \dots, n$, $j = 1, \dots, k$. Med hjälp av dessa transformationer har vi

$$\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) = \frac{1}{2} \text{vec}(\Sigma^{-1})^T \text{vec} \mathbf{x} \mathbf{x}^T - (\Sigma^{-1} \boldsymbol{\mu})^T \mathbf{x} + \frac{1}{2} \boldsymbol{\mu}^T \Sigma^{-1} \boldsymbol{\mu}.$$

Alltså kan vi skriva

$$f_{\mathbf{X}}(\mathbf{x}) = h(\mathbf{x})c(\boldsymbol{\theta}) \exp((w_1(\boldsymbol{\theta})^T t_1(\mathbf{x}) + w_2(\boldsymbol{\theta})^T t_2(\mathbf{x})),$$

där

$$\begin{aligned} h(\mathbf{x}) &= \frac{1}{(2\pi)^{m/2}} \\ c(\boldsymbol{\theta}) &= \exp \left(-\frac{1}{2} \log \det \Sigma - \frac{1}{2} \boldsymbol{\mu}^T \Sigma^{-1} \boldsymbol{\mu} \right) \\ w_1(\boldsymbol{\theta}) &= \Sigma^{-1} \boldsymbol{\mu} \\ t_1(\mathbf{x}) &= \mathbf{x} \\ w_2(\boldsymbol{\theta}) &= -\frac{1}{2} \text{vec}(\Sigma^{-1}) \\ t_2(\mathbf{x}) &= \text{vec}(\mathbf{x} \mathbf{x}^T) \end{aligned}$$

Familjen av flerdimensionella normalfördelningar bildar således en exponentialfamilj.

2.2 Transformation av stokastiska variabler

Ett vanligt problem inom sannolikhetsteori är hur fördelningen av olika stokastiska variabler förändras när det avbildas genom olika funktioner. Vi har kanske en stokastisk variabel X och bildar $U = g(X)$ där $g : \mathbb{R} \rightarrow \mathbb{R}$. Om vi vet fördelningen för X kan vi använda denna, tillsammans med funktionen g , för att bestämma fördelningen för U .

Det första vi måste tänka på är stödet för fördelningen. Om vi har

$$\mathcal{A} = \{x \in \mathbb{R} : f_X(x) > 0\}$$

så innehåller $\mathcal{A}$ alla värden som X kan anta (med sannolikhet ett). På samma sätt får vi då mängden av möjliga värden på U som

$$\mathcal{B} = \{u \in \mathbb{R} : u = g(x) \text{ för något } x \in \mathcal{A}\}.$$

Vi söker då för en täthetsfunktion eller sannolikhetsfunktion $f_U(u)$ med stöd $\mathcal{B}$.

I det diskreta fallet är situationen relativt enkel. Det handlar om att bestämma sannolikheten att X befinner sig i

$$g^{-1}(u) = \{x : g(x) = u\},$$

den så kallade *urbilden* av u via g ("preimage" på engelska). Vi har då

$$f_U(u) = P(U = u) = P(g(X) = u) = P(X \in g^{-1}(u)) = \sum_{x \in g^{-1}(u)} f_X(x)$$

för $u \in \mathcal{B}$. Situationen är densamma för flerdimensionella stokastiska variabler $\mathbf{X} \in \mathbb{R}^n$ och $\mathbf{U} \in \mathbb{R}^n$ där $\mathbf{U} = g(\mathbf{X})$ för någon $g : \mathbb{R}^n \rightarrow \mathbb{R}^n$. Där har vi

$$\mathcal{A} = \{\mathbf{x} \in \mathbb{R}^n : f_{\mathbf{X}}(\mathbf{x}) > 0\}, \quad \mathcal{B} = \{\mathbf{u} \in \mathbb{R}^n : \mathbf{u} = g(\mathbf{x}) \text{ för något } \mathbf{x} \in \mathcal{A}\}$$

och sannolikhetsfunktionen

$$f_{\mathbf{U}}(\mathbf{u}) = \sum_{\mathbf{x} \in g^{-1}(\mathbf{u})} f_{\mathbf{X}}(\mathbf{x})$$

för $\mathbf{u} \in \mathcal{B}$.

I det kontinuerliga fallet blir situationen mer komplex. Vi såg förmodligen i en första kurs i sannolikhetsteori och statistik att för en funktion $g : \mathbb{R} \rightarrow \mathbb{R}$ så har vi

$$f_U(u) = f_X(g^{-1}(u)) \left| \frac{d}{du} g^{-1}(u) \right|, \quad (2.1)$$

för $u \in \mathcal{B}$ givet att g är injektiv på $\mathcal{A}$. (Notera att här så syftar g^{-1} på inversen av g eftersom denna är inverterbar på $\mathcal{B}$.)

Detta kan generaliseras till flera dimensioner. Låt oss börja med det tvådimensionella fallet. Då har vi de stokastiska variablerna X och Y samt en funktion $g : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ (injektiv på $\mathcal{A}$) och söker fördelningen för $[U, V]^T = g(X, Y)$. Man kan då visa att den simultana täthetsfunktionen för $[U, V]^T$ ges av

$$f_{U,V}(u, v) = f_{X,Y}(g^{-1}(u, v)) |J|$$

för $[u, v]^T \in \mathcal{B}$ där vi har använt absolutvärdet av jacobideterminanten

$$J = \frac{\partial(x, y)}{\partial(u, v)} = \det \left(\begin{bmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{bmatrix} \right) = \frac{\partial x}{\partial u} \frac{\partial y}{\partial v} - \frac{\partial x}{\partial v} \frac{\partial y}{\partial u}.$$

Detta värde kvantifierar hur pass mycket vår transformation $g(x, y)$ trycker ihop eller expanderar sannolikstätheten i en given punkt. Notera att detta är determinanten av jacobimatrisen för $g^{-1}(u, v)$, och generaliserar alltså på ett naturligt sätt skalfaktorn i (2.1).

Exempel 2.7. Man kan använda denna formel för att bestämma olika täthetsfunktioner, som till exempel täthetsfunktionen för summan eller differensen mellan två stokastiska variabler. Låt $X \sim N(0, 1)$ och $Y \sim N(0, 1)$ vara två oberoende stokastiska variabler. I detta fall har vi $\mathcal{A} = \mathbb{R}^2$ och $\mathcal{B} = \mathbb{R}^2$. Vi tar då $U = X + Y, V = X - Y$ och får

$$\begin{cases} u = x + y \\ v = x - y \end{cases} \Rightarrow \begin{cases} x = \frac{u+v}{2} \\ y = \frac{u-v}{2} \end{cases}.$$

Jacobideterminanten fås då som

$$J = \begin{vmatrix} 1/2 & 1/2 \\ 1/2 & -1/2 \end{vmatrix} = -\frac{1}{2}$$

och vi har då

$$\begin{aligned} f_{U,V}(u, v) &= f_{X,Y}\left(\frac{u+v}{2}, \frac{u-v}{2}\right) |J| \\ &= \frac{1}{\sqrt{2\pi}} e^{-(\frac{u+v}{2})^2/2} e^{-(\frac{u-v}{2})^2/2} \frac{1}{2} \\ &= \left(\frac{1}{\sqrt{2\pi} \cdot 2} e^{-u^2/4}\right) \left(\frac{1}{\sqrt{2\pi} \cdot 2} e^{-v^2/4}\right). \end{aligned}$$

Med andra ord är U och V två oberoende $N(0, 2)$ -fördelade stokastiska variabler.

Det finns också den välbekanta *faltningsformeln* för täthetsfunktionen hos summan $U = X + Y$ av två oberoende stokastiska variabler X och Y :

$$f_U(u) = \int f_X(x) f_Y(u - x) dx.$$

Vi kunde så klart också använt denna i exemplet ovan för att hitta täthetsfunktionen för $U = X + Y$, men detta skulle inte gett oss täthetsfunktionen för $V = X - Y$ (och inte heller att U och V är oberoende). Faltningsformeln kan faktiskt ses som ett specialfall av transformationsformeln ovan (ta $U = X + Y$ och $V = Y$ och marginalisera med avseende på V för att få marginalfördelningen för U), men är mycket mer generell.

För fler än två dimensioner har formlerna samma form. Vi antar att vi har en stokastisk vektor $\mathbf{X} = [X_1, \dots, X_m]^T$ och en funktion $g: \mathbb{R}^m \rightarrow \mathbb{R}^m$ (injektiv på $\mathcal{A}$). Om vi tar

$$\mathcal{A} = \{\mathbf{x} \in \mathbb{R}^m : f_{\mathbf{X}}(\mathbf{x}) > 0\} \quad \mathcal{B} = \{\mathbf{y} \in \mathbb{R}^m : \mathbf{y} = g(\mathbf{x}) \text{ för något } \mathbf{x} \in \mathcal{A}\}$$

så är $\mathbf{U} = g(\mathbf{X})$ en stokastisk vektor med värden i $\mathcal{B}$ och vars täthetsfunktion ges av

$$f_{\mathbf{U}}(\mathbf{u}) = f_{\mathbf{X}}(g^{-1}(\mathbf{u})) |J|$$

där vi har jacobideterminanten

$$J = \frac{\partial(x_1, \dots, x_m)}{\partial(u_1, \dots, u_m)} = \begin{vmatrix} \frac{\partial x_1}{\partial u_1} & \frac{\partial x_1}{\partial u_2} & \dots & \frac{\partial x_1}{\partial u_m} \\ \frac{\partial x_2}{\partial u_1} & \frac{\partial x_2}{\partial u_2} & \dots & \frac{\partial x_2}{\partial u_m} \\ \vdots & \vdots & & \vdots \\ \frac{\partial x_m}{\partial u_1} & \frac{\partial x_m}{\partial u_2} & \dots & \frac{\partial x_m}{\partial u_m} \end{vmatrix}.$$

Exempel 2.8. Låt oss anta att X_1, X_2, X_3, X_4 är oberoende och $\text{Exp}(1)$ -fördelade stokastiska variabler. Vi låter nu Y_1 vara det minsta av dessa fyra värden, Y_2 vara det näst minsta, Y_3 vara det näst största och Y_4 vara det största värdet. Dessa Y_1, Y_2, Y_3, Y_4 bildar då en stokastisk vektor och man kan visa (med hjälp av *ordningsstatistikor*, se övning 2) att de har den simultana täthetsfunktionen

$$f_{\mathbf{Y}}(\mathbf{y}) = 24e^{-y_1 - y_2 - y_3 - y_4}$$

för $0 \leq y_1 \leq y_2 \leq y_3 \leq y_4$. Antag att vi tar $U_1 = Y_1, U_2 = Y_2 - Y_1, U_3 = Y_3 - Y_2$ och $U_4 = Y_4 - Y_3$, dvs. vi mäter avståndet mellan de intilliggande värdena på X_1, X_2, X_3, X_4 . Om vi inverterar transformationen får vi

$$\begin{aligned} Y_1 &= U_1 \\ Y_2 &= U_1 + U_2 \\ Y_3 &= U_1 + U_2 + U_3 \\ Y_4 &= U_1 + U_2 + U_3 + U_4, \end{aligned}$$

och jacobideterminanten fås till

$$J = \begin{vmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 \end{vmatrix} = 1,$$

vilket ger

$$f_{\mathbf{U}}(\mathbf{u}) = 24e^{-4u_1-3u_2-2u_3-u_4}.$$

Med andra ord har vi att U_1, U_2, U_3, U_4 är oberoende exponentialfördelade stokastiska variabler med parametrar $1/4, 1/3, 1/2$ och 1 .

Vi kan också använda detta verktyg för att bevisa en av de viktigaste egenskaperna hos den flerdimensionella normalfördelningen: alla linjärkombinationer av en normalfördelad stokastisk vektor också är normalfördelade.

Sats 2.2. Låt $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ för någon $\boldsymbol{\mu} \in \mathbb{R}^m$ och $\Sigma \in \mathbb{R}^{m \times m}$ (positivt definit). Vidare låt $A \in \mathbb{R}^{k \times m}$ vara en matris av full rang så att $k \leq m$ och låt $\mathbf{b} \in \mathbb{R}^k$. Då har vi att

$$A\mathbf{X} + \mathbf{b} \sim N(A\boldsymbol{\mu} + \mathbf{b}, A\Sigma A^T)$$

Bevis. Vi antar först att $k = m$, dvs. att A är en kvadratisk matris. Om vi sätter $\mathbf{Y} = A\mathbf{X} + \mathbf{b}$ har vi då att

$$\mathbf{X} = A^{-1}(\mathbf{Y} - \mathbf{b}) \quad \text{och} \quad \mathbf{x} = A^{-1}(\mathbf{y} - \mathbf{b})$$

eftersom A är av full rang. Avbildningen $\mathbf{y} \mapsto A^{-1}(\mathbf{y} - \mathbf{b})$ är linjär, så dess jacobimatrix är A^{-1} , vilket ger

$$J = \frac{\partial(x_1, \dots, x_m)}{\partial(y_1, \dots, y_m)} = \det A^{-1} = \frac{1}{\det A}.$$

Givet täthetsfunktionen för $\mathbf{X}$,

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{m/2} \sqrt{\det \Sigma}} e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})},$$

får vi då

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{(2\pi)^{m/2} \sqrt{\det \Sigma}} e^{-\frac{1}{2}(A^{-1}(\mathbf{y} - \mathbf{b}) - \boldsymbol{\mu})^T \Sigma^{-1}(A^{-1}(\mathbf{y} - \mathbf{b}) - \boldsymbol{\mu})} \cdot \frac{1}{\det A}.$$

Eftersom

$$\begin{aligned} & (A^{-1}(\mathbf{y} - \mathbf{b}) - \boldsymbol{\mu})^T \Sigma^{-1} (A^{-1}(\mathbf{y} - \mathbf{b}) - \boldsymbol{\mu}) \\ &= (A^{-1}(\mathbf{y} - A\boldsymbol{\mu} - \mathbf{b}))^T \Sigma^{-1} (A^{-1}(\mathbf{y} - A\boldsymbol{\mu} - \mathbf{b})) \\ &= (\mathbf{y} - A\boldsymbol{\mu} - \mathbf{b})^T A^{-T} \Sigma^{-1} A^{-1} (\mathbf{y} - A\boldsymbol{\mu} - \mathbf{b}) \\ &= (\mathbf{y} - A\boldsymbol{\mu} - \mathbf{b})^T (A\Sigma A^T)^{-1} (\mathbf{y} - A\boldsymbol{\mu} - \mathbf{b}) \end{aligned}$$

och

$$\begin{aligned} \sqrt{\det \Sigma} \cdot \det A &= \sqrt{\det \Sigma (\det A)^2} \\ &= \sqrt{\det A \det \Sigma \det A} \\ &= \sqrt{\det A \det \Sigma \det A^T} \\ &= \sqrt{\det A \Sigma A^T} \end{aligned}$$

så får vi att

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{(2\pi)^{m/2} \sqrt{\det A \Sigma A^T}} e^{-\frac{1}{2}(\mathbf{y} - A\boldsymbol{\mu} - \mathbf{b})^T (A\Sigma A^T)^{-1}(\mathbf{y} - A\boldsymbol{\mu} - \mathbf{b})},$$

dvs. att $\mathbf{Y} \sim N(A\boldsymbol{\mu} + \mathbf{b}, A\Sigma A^T)$.

Om $k < m$ kan vi komplettera A med en matris $\tilde{A} \in \mathbb{R}^{m-k \times m}$ så att

$$\begin{bmatrix} A \\ \tilde{A} \end{bmatrix}$$

är en kvadratisk matris av full rang. Om vi sätter

$$\mathbf{Z} = \begin{bmatrix} A \\ \tilde{A} \end{bmatrix} \mathbf{X} + \begin{bmatrix} \mathbf{b} \\ 0 \end{bmatrix}$$

får vi då att

$$\mathbf{Z} \sim \mathcal{N} \left(\begin{bmatrix} A\boldsymbol{\mu} + \mathbf{b} \\ \tilde{A}\boldsymbol{\mu} \end{bmatrix}, \begin{bmatrix} A\Sigma A^T & A\Sigma\tilde{A}^T \\ \tilde{A}\Sigma A^T & \tilde{A}^T\Sigma\tilde{A} \end{bmatrix} \right).$$

Sats 2.1 ger då

$$\mathbf{Y} = A\mathbf{X} + \mathbf{b} = \mathbf{Z}_{\{1,2,\dots,k\}} \sim \mathcal{N}(A\boldsymbol{\mu} + \mathbf{b}, A\Sigma A^T),$$

vilket skulle visas. □

Exempel 2.9. Betrakta den stokastiska vektorn $\mathbf{X} = [X_1, X_2]^T \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{X}}, \Sigma_{\mathbf{X}})$ där

$$\boldsymbol{\mu}_{\mathbf{X}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{och} \quad \Sigma_{\mathbf{X}} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

dvs. $\Sigma_{\mathbf{X}} = \mathbf{I}_2$, den tvådimensionella identitetsmatrisen. Vi kan transformera den stokastiska vektorn för att få vektorn

$$\mathbf{Y} = A\mathbf{X} + \mathbf{b}$$


där vi tar

$$A = \begin{bmatrix} 1 & 0.25 \\ -0.5 & 4 \end{bmatrix} \quad \text{och} \quad \mathbf{b} = \begin{bmatrix} -2 \\ -0.5 \end{bmatrix}.$$

Enligt Sats 2.2 får vi $\mathbf{Y} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{Y}}, \Sigma_{\mathbf{Y}})$ där

$$\boldsymbol{\mu}_{\mathbf{Y}} = \begin{bmatrix} -1.25 \\ 3 \end{bmatrix} \quad \text{och} \quad \Sigma_{\mathbf{Y}} = \begin{bmatrix} 1.125 & 0.5 \\ 0.5 & 16.4 \end{bmatrix}.$$

Plottarna för fördelningarna av $\mathbf{X}$ respektive $\mathbf{Y}$ ser ut som:



När g inte är injektiv på $\mathcal{A}$ kan man fortfarande bestämma fördelningen för $\mathbf{U} = g(\mathbf{X})$ i många fall, men det kräver en del arbete. Först måste vi dela upp $\mathcal{A}$ i en partition

$$\mathcal{A} = A_0 \cup A_1 \cup \dots \cup A_k$$

så att $P(\mathbf{X} \in A_0) = 0$ och g bildar en bijektion mellan A_i och $\mathcal{B}$ för varje $i = 1, 2, \dots, k$ (notera att A_0 kan vara tom). Om vi betecknar restriktionen av g till A_i som g_i för $i = 1, 2, \dots, k$ har vi då att g_i^{-1} inverterar g på A_i , dvs. att $g_i^{-1}(\mathbf{u}) \in A_i$ och $g(g_i^{-1}(\mathbf{u})) = \mathbf{u}$ för alla $\mathbf{u} \in \mathcal{B}$. Låt J_i vara jacobideterminanten för g_i^{-1} . Då har vi att

$$f_U(\mathbf{u}) = \sum_{i=1}^k f_{\mathbf{X}}(g_i^{-1}(\mathbf{u})) |J_i|$$

för all $\mathbf{u} \in \mathcal{B}$. Vi kan se detta som att för varje $\mathbf{u}$ så lägger vi ihop täthetsvärdena för alla möjliga $\mathbf{x}$ som kan ha gett upphov till $\mathbf{u}$ och skalar dessa med hjälp av faktorn $|J_i|$.

Exempel 2.10. Låt X och Y vara oberoende $N(0, 1)$ -fördelade stokastiska variabler och sätt $U = X/Y$ samt $V = |Y|$ (värdet på U då $Y = 0$ kan sättas godtyckligt eftersom $P(Y = 0) = 0$). Eftersom punkterna (x, y) och $(-x, -y)$ avbildas på samma punkt $(x/y, y)$ är funktionen inte injektiv och vi måste använda formeln ovan. Vi tar $A_0 = \{(x, y) : y = 0\}$, $A_1 = \{(x, y) : y > 0\}$ och $A_2 = \{(x, y) : y < 0\}$. Eftersom $A_0 \cup A_1 \cup A_2 = \mathcal{A} = \mathbb{R}^2$ är detta en giltig partition och vi har att avbildningen är injektiv på A_1 och A_2 . Vidare har vi att restriktionerna $g_i : A_i \rightarrow \mathbb{R}^2$ är bijektiva på $\mathcal{B} = \{(u, v) : v > 0\}$ eftersom $v = |y|$ alltid är positiv och $u = x/y$ kan anta alla värden i $\mathbb{R}$.

Inversen g_1^{-1} ges av

$$\begin{cases} x = uv \\ y = v \end{cases}$$

medan för g_2^{-1} har vi

$$\begin{cases} x = -uv \\ y = -v \end{cases}.$$

I båda fall får vi jacobideterminanten $J_1 = J_2 = v$, vilket ger

$$\begin{aligned} f_{U,V}(u, v) &= \frac{1}{2\pi} e^{-(uv)^2/2} e^{-v^2/2} |v| + \frac{1}{2\pi} e^{-(-uv)^2/2} e^{-(-v)^2/2} |v| \\ &= \frac{v}{\pi} e^{-(u^2+1)v^2/2} \end{aligned}$$

för $(u, v) \in \mathcal{B}$ (vi kunde ersätta $|v|$ med v eftersom $v > 0$ för $(u, v) \in \mathcal{B}$).

Vi kan nu bestämma täthetsfunktionen för U genom att marginalisera bort V :

$$\begin{aligned} f_U(u) &= \int_0^{+\infty} \frac{v}{\pi} e^{-(u^2+1)v^2/2} dv \\ &= \frac{1}{2\pi} \int_0^{+\infty} e^{-(u^2+1)t/2} dt \\ &= \frac{1}{2\pi} \left[-\frac{e^{-(u^2+1)t/2}}{\frac{u^2+1}{2}} \right]_{t=0}^{+\infty} \\ &= \frac{1}{\pi} \frac{1}{u^2 + 1} \end{aligned}$$

där vi har använt oss av variabelbytet $t = v^2$ för att beräkna integralen. Marginalfördelningen för $U = X/Y$ som vi beräknade ovan kallas för *Cauchyfördelningen* och kommer upp i olika sammanhang. Bland annat är det en av de enklare fördelningarna som helt saknar väntevärde (den har däremot en median).

2.3 Betingning och oberoende

Vi såg redan att vi kan beräkna marginalfördelningen för någon delvektor $\mathbf{X}_S$ av $\mathbf{X}$ där $S \subset \{1, \dots, m\}$. Detta säger oss hur en eller flera av de stokastiska variablerna som utgör $\mathbf{X}$ beter sig i isolation. En annan viktig aspekt av stokastiska vektorer är hur de olika delvektorerna relaterar till varandra. Ett naturligt sätt att beskriva dessa relationer är genom betingning (hur en viss del av den stokastiska vektorn beror på en annan del). I vissa fall beror komponenterna inte alls på varandra och vi säger i detta fall att de är oberoende.

2.3.1 Betingade fördelningar

En liknande situation kan uppstå när vi har fixerat värdena på $X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_m$ och sedan betraktar X_i . I båda fall får vi en fördelning för X_i , den *betingade fördelningen* för X_i givet $X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_m$ – det som skiljer sig är hur vi behandlar de resterande komponenterna i den stokastiska vektorn. För marginalfördelningen har vi att de resterande komponenterna kan ta vilka värden som helst men för den betingade fördelningen tillåts de endast ta en viss uppsättning värden.

Som för marginalfördelningen kan vi definiera den betingade fördelningen för en godtycklig delvektor $\mathbf{X}_S$ för $S = \{i_1, \dots, i_k\} \subset \{1, \dots, m\}$. I så fall har vi den *betingade sannolikhetsfunktionen* (i det diskreta fallet) eller den *betingade täthetsfunktionen* (i det kontinuerliga fallet)

$$f_{\mathbf{X}_S|\mathbf{X}_T}(\mathbf{x}_S | \mathbf{x}_T) = \frac{f_{\mathbf{X}}(\mathbf{x})}{f_{\mathbf{X}_T}(\mathbf{x}_T)}$$

där $T = \{1, \dots, m\} \setminus S$. Vi använder notationen $f_{\mathbf{X}_S|\mathbf{X}_T}(\mathbf{x}_S | \mathbf{x}_T)$ för att beteckna (den betingade) sannolikhetsfunktionen eller täthetsfunktionen för $\mathbf{X}_S$ givet $\mathbf{X}_T = \mathbf{x}_T$, dvs. då de resterande komponenterna av $\mathbf{X}$ tar värdena $\mathbf{x}_T$. I synnerhet ser vi att $f_{\mathbf{X}_S|\mathbf{X}_T}(\mathbf{x}_S|\mathbf{x}_T)$ faktiskt bara är en funktion av $\mathbf{x}_S$ eftersom $\mathbf{x}_T$ är fix. När vi diskuterar själva fördelningen (dvs. om den är normalfördelad eller något liknande) så skriver vi detta som $\mathbf{X}_S | \mathbf{X}_T = \mathbf{x}_T$. I det tvådimensionella fallet kan vi förenkla formeln ovan till

$$f_{X_1|X_2}(x_1 | x_2) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_2}(x_2)},$$

vilken borde vara bekant. I princip kan man se $f_{\mathbf{X}_S|\mathbf{X}_T}(\mathbf{x}_S|\mathbf{x}_T)$ som en funktion av både $\mathbf{x}_S$ och $\mathbf{x}_T$ men det är bara en täthetsfunktion (eller sannolikhetsfunktion) när $\mathbf{x}_T$ är fixt. Det är också vanligtvis att skriver $f_{\mathbf{X}_S|\mathbf{X}_T=\mathbf{x}_T}(\mathbf{x}_S)$ för $f_{\mathbf{X}_S|\mathbf{X}_T}(\mathbf{x}_S|\mathbf{x}_T)$ när vi vill understryka att $f_{\mathbf{X}_S|\mathbf{X}_T}(\mathbf{x}_S|\mathbf{x}_T)$ är täthetsfunktionen för $\mathbf{X}_S|\mathbf{X}_T = \mathbf{x}_T$ (och därför bara en funktion av $\mathbf{x}_S$). Det är dock typiskt i statistik att använda $f_{\mathbf{X}_S|\mathbf{X}_T}(\mathbf{x}_S|\mathbf{x}_T)$ istället.

Exempel 2.11. Låt oss anta att vi har tre glödlampor och låt X_i vara tiden då den i :te glödlampan brinner ut. Dessa bildar då en stokastisk vektor $\mathbf{X} = [X_1, X_2, X_3]^T$. Vi antar vidare att den simultana täthetsfunktionen ges av

$$f_{X_1, X_2, X_3}(x_1, x_2, x_3) = \frac{1}{4}e^{-(x_2+x_3)/2} \quad \text{för } 0 < x_1 < x_2 < +\infty \text{ och } 0 < x_1 < x_3 < +\infty.$$

Vi kan använda denna för att beräkna marginalfördelningen för $[X_1, X_2]^T$. Om $x_1 \leq 0$ har vi att $f_{X_1, X_2, X_3}(x_1, x_2, x_3) = 0$, så $f_{X_1, X_2}(x_1, x_2) = 0$ i detta fall. Om $x_1 > 0$ har vi att $f_{X_1, X_2, X_3}(x_1, x_2, x_3) > 0$ om och endast om $x_2 > x_1$ och $x_3 > x_1$. Detta ger då

$$f_{X_1, X_2}(x_1, x_2) = \int_{\mathbb{R}} f_{X_1, X_2, X_3}(x_1, x_2, x_3) dx_3 = \int_{x_1}^{+\infty} \frac{1}{4}e^{-(x_2+x_3)/2} dx_3 = \frac{1}{4}e^{-x_2/2} \left[-2e^{-x_3/2} \right]_{x_1}^{+\infty} = \frac{1}{2}e^{-(x_1+x_2)/2}.$$

Vi har alltså den marginella täthetsfunktionen

$$f_{X_1, X_2}(x_1, x_2) = \frac{1}{2}e^{-(x_1+x_2)/2} \quad \text{för } 0 < x_1 < x_2.$$

Vi kan också beräkna marginalfördelningen för X_1 antingen genom att marginalisera bort X_2 och X_3 i den stokastiska vektorn $[X_1, X_2, X_3]^T$ eller genom att marginalisera bort X_2 i $[X_1, X_2]^T$ – resultatet är detsamma. För enkelhets skull väljer vi det senare alternativet och får

$$f_{X_1}(x_1) = \int_{\mathbb{R}} f_{X_1, X_2}(x_1, x_2) dx_2 = \int_{x_1}^{+\infty} \frac{1}{2}e^{-(x_1+x_2)/2} dx_2 = \frac{1}{2}e^{-x_1/2} \left[-2e^{-x_2/2} \right]_{x_1}^{+\infty} = e^{-x_1}$$

för $x_1 > 0$. Med andra ord är X_1 exponentialfördelad med parameter ett.

Med hjälp av dessa marginalfördelningar kan vi nu beräkna fördelningen för X_2 givet $X_1 = x_1$

$$f_{X_2|X_1}(x_2 | x_1) = \frac{\frac{1}{2}e^{-(x_1+x_2)/2}}{e^{-x_1}} = \frac{1}{2}e^{-(x_2-x_1)/2}$$

för $x_2 > x_1$. Med andra ord har vi att $X_2 - x_1 | X_1 = x_1 \sim \text{Exp}(1/2)$, dvs. att för ett fixt X_1 så är tiden mellan X_1 och X_2 exponentialfördelad.

På samma sätt (genom att beräkna marginalfördelningen för $[X_1, X_3]^T$ och sedan betinga med avseende på $X_1 = x_1$) får vi att $X_3 - x_1 \mid X_1 = x_1 \sim \text{Exp}(1/2)$. Vi kan också betinga både X_2 och X_3 med avseende på X_1 och får då

$$f_{X_2, X_3 \mid X_1}(x_2, x_3 \mid x_1) = \frac{f_{X_1, X_2, X_3}(x_1, x_2, x_3)}{f_{X_1}(x_1)} = \frac{\frac{1}{4}e^{-(x_2+x_3)/2}}{e^{-x_1}} = \frac{1}{4}e^{-(x_2+x_3-2x_1)/2}$$

för $x_2, x_3 > x_1$. Om vi nu i sin tur marginaliserar denna med avseende på X_3 återfår vi den betingade fördelningen för X_2 med avseende på X_1 :

$$f_{X_2 \mid X_1}(x_2 \mid x_1) = \int_{x_1}^{+\infty} \frac{1}{4}e^{-(x_2+x_3-2x_1)/2} dx_3 = \frac{1}{4}e^{-(x_2-2x_1)/2} \left[-2e^{-x_3/2} \right]_{x_1}^{+\infty} = \frac{1}{2}e^{-(x_2-x_1)/2}$$

Precis som för marginalfördelningarna kan betingade fördelningar enkelt räknas ut när det gäller delvektorer hos den flerdimensionella normalfördelningen.

Sats 2.3. Låt $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ för någon $\boldsymbol{\mu} \in \mathbb{R}^m$ och $\Sigma \in \mathbb{R}^{m \times m}$ (positivt definit). Om $S \subset \{1, \dots, m\}$ har vi

$$\mathbf{X}_S \mid \mathbf{X}_T = \mathbf{x}_T \sim N(\boldsymbol{\mu}_S + \Sigma_{ST}\Sigma_{TT}^{-1}(\mathbf{x}_T - \boldsymbol{\mu}_T), \Sigma_{SS} - \Sigma_{ST}\Sigma_{TT}^{-1}\Sigma_{TS})$$

där $T = \{1, \dots, m\} \setminus S$, $\Sigma_{SS} = [\Sigma_{ij}]_{i,j \in S}$, $\Sigma_{ST} = [\Sigma_{ij}]_{i \in S, j \in T}$, $\Sigma_{TS} = \Sigma_{ST}^T$ och $\Sigma_{TT} = [\Sigma_{ij}]_{i,j \in T}$.

Bevis. På samma sätt som i beviset för Sats 2.1 kan vi skriva om täthetsfunktionen $f_{\mathbf{X}}(\mathbf{x})$ med hjälp av Schurkomplementet Σ/Σ_{TT} och får då

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{(d-k)/2} \sqrt{\det \Sigma_{TT}}} e^{-\frac{1}{2}(\mathbf{x}_T - \boldsymbol{\mu}_T)^T \Sigma_{TT}^{-1}(\mathbf{x}_T - \boldsymbol{\mu}_T)} \\ \frac{1}{(2\pi)^{k/2} \sqrt{\det(\Sigma/\Sigma_{TT})}} e^{-\frac{1}{2}(\mathbf{x}_S - \boldsymbol{\mu}_S - \Sigma_{ST}\Sigma_{TT}^{-1}(\mathbf{x}_T - \boldsymbol{\mu}_T))^T (\Sigma/\Sigma_{TT})^{-1}(\mathbf{x}_S - \boldsymbol{\mu}_S - \Sigma_{ST}\Sigma_{TT}^{-1}(\mathbf{x}_T - \boldsymbol{\mu}_T))}.$$

(Notera att vi har bytt plats på S och T .) Sats 2.1 säger nu att

$$f_{\mathbf{X}_T}(\mathbf{x}_T) = \frac{1}{(2\pi)^{(d-k)/2} \sqrt{\det \Sigma_{TT}}} e^{-\frac{1}{2}(\mathbf{x}_T - \boldsymbol{\mu}_T)^T \Sigma_{TT}^{-1}(\mathbf{x}_T - \boldsymbol{\mu}_T)},$$

vilket ger

$$f_{\mathbf{X}_S \mid \mathbf{X}_T}(\mathbf{x}_S \mid \mathbf{x}_T) = \frac{f_{\mathbf{X}}(\mathbf{x})}{f_{\mathbf{X}_T}(\mathbf{x}_T)} \\ = \frac{1}{(2\pi)^{k/2} \sqrt{\det(\Sigma/\Sigma_{TT})}} e^{-\frac{1}{2}(\mathbf{x}_S - \boldsymbol{\mu}_S - \Sigma_{ST}\Sigma_{TT}^{-1}(\mathbf{x}_T - \boldsymbol{\mu}_T))^T (\Sigma/\Sigma_{TT})^{-1}(\mathbf{x}_S - \boldsymbol{\mu}_S - \Sigma_{ST}\Sigma_{TT}^{-1}(\mathbf{x}_T - \boldsymbol{\mu}_T))}.$$

Vi har alltså att

$$\mathbf{X}_S \mid \mathbf{X}_T = \mathbf{x}_T \sim N(\boldsymbol{\mu}_S + \Sigma_{ST}\Sigma_{TT}^{-1}(\mathbf{x}_T - \boldsymbol{\mu}_T), \Sigma_{SS} - \Sigma_{ST}\Sigma_{TT}^{-1}\Sigma_{TS}),$$

vilket skulle visas. □

Exempel 2.12. Låt $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ där $\boldsymbol{\mu} = [1, 0, 2]^T$ och

$$\Sigma = \begin{bmatrix} 3 & 1 & 4 \\ 1 & 2 & 3 \\ 4 & 3 & 9 \end{bmatrix}.$$

Marginalfördelningen för X_1 läses ut direkt från $\boldsymbol{\mu}$ och Σ och är alltså

$$X_1 \sim N(1, 3).$$

För den betingade fördelningen för X_1 givet $X_2 = -1, X_3 = 0$ har vi

$$\boldsymbol{\mu}_{\{1\}} + \Sigma_{\{1\}, \{2,3\}} \Sigma_{\{2,3\}, \{2,3\}}^{-1}([-1, 0]^T - \boldsymbol{\mu}_{\{2,3\}}) = 1 + \begin{bmatrix} 1 & 4 \end{bmatrix} \begin{bmatrix} 2 & 3 \\ 3 & 9 \end{bmatrix}^{-1} \begin{bmatrix} -1 \\ -2 \end{bmatrix} \\ = 1 - \frac{7}{9} = \frac{2}{9}$$

och

$$\begin{aligned}\Sigma_{\{1\},\{1\}} - \Sigma_{\{1\},\{2,3\}}\Sigma_{\{2,3\},\{2,3\}}^{-1}\Sigma_{\{2,3\},\{1\}} &= 3 - \frac{1}{9} \begin{bmatrix} 1 & 4 \end{bmatrix} \begin{bmatrix} 9 & -3 \\ -3 & 2 \end{bmatrix} \begin{bmatrix} 1 & 4 \end{bmatrix}^T \\ &= 3 - \frac{17}{9} = \frac{10}{9}.\end{aligned}$$

Vi får alltså

$$X_1 \mid X_2 = -1, X_3 = 0 \sim N(2/9, 10/9).$$

Vi kan notera två saker här. Den första är att väntevärdet för den betingade fördelningen är mindre än för marginalfördelningen. Detta kan förklaras med att både X_2 och X_3 är starkt korrelerade med X_1 och eftersom både X_2 och X_3 har värden under deras respektive väntevärden så drar de ner väntevärdet på X_1 . Vi kan också notera att variansen är mindre ($10/9$ jämfört med 3). Detta beror också på att vi har fixerat X_2 och X_3 , vilket reducerar den totala mängden varians i den stokastiska vektorn.

Om vi vänder på definitionen av den betingade fördelningen får vi ett användbart redskap

$$f_{\mathbf{X}}(\mathbf{x}) = f_{\mathbf{X}_S|\mathbf{X}_T}(\mathbf{x}_S \mid \mathbf{x}_T)f_{\mathbf{X}_T}(\mathbf{x}_T).$$

Denna relation kallas för *kedjeregeln* (ej att förväxla med kedjeregeln inom differentialkalkylen) och låter oss förenkla vissa uttryck och bygga modeller.

Exempel 2.13. Låt oss återta exemplet med glödlamporna. Vi ansätter att brinntiden för lampa ett har fördelningen $\text{Exp}(1)$, dvs.

$$f_{X_1}(x_1) = e^{-x_1}$$

för $x_1 > 0$. Lampa två antar vi har brinntid med fördelning $\text{Exp}(1/2)$. Om vi betecknar denna med Y_2 får vi

$$f_{Y_2}(y_2) = \frac{1}{2}e^{-y_2/2}$$

för $y_2 > 0$.

Men vi sätter ju inte på lampa två förrän lampa ett släcks. Om detta händer vi tidpunkt x_1 så har vi att lampa två släcks vid tiden $Y_2 + x_1$, vilket har fördelningen

$$f_{Y_2+x_1}(x_2) = \frac{1}{2}e^{-(x_2-x_1)/2}$$

för $x_2 > x_1$. (Detta fås genom enkel transformation av en endimensionell variabel.) Men detta är ju precis den betingade fördelningen för X_2 (tiden tills lampa två släcks) givet $X_1 = x_1$, dvs.

$$f_{X_2|X_1}(x_2 \mid x_1) = \frac{1}{2}e^{-(x_2-x_1)/2}$$

för $x_2 > x_1$.

Kedjeregeln ger nu att

$$f_{X_1,X_2}(x_1, x_2) = f_{X_2|X_1}(x_2 \mid x_1)f_{X_1}(x_1) = \frac{1}{2}e^{-(x_2-x_1)/2} \cdot e^{-x_1} = \frac{1}{2}e^{-(x_1+x_2)/2}$$

för $x_2 > x_1$, vilket stämmer överens med marginalfördelningen vi fick för (X_1, X_2) tidigare.

2.3.2 Oberoende stokastiska variabler

Ett viktigt specialfall av betingade fördelningar uppstår då den betingade fördelningen sammanfaller med marginalfördelningen. Vi har alltså, för $S \subset \{1, \dots, m\}$ och $T = \{1, \dots, m\} \setminus S$, att

$$f_{\mathbf{X}_S|\mathbf{X}_T}(\mathbf{x}_S \mid \mathbf{x}_T) = f_{\mathbf{X}_S}(\mathbf{x}_S).$$

Med andra ord så ändras inte fördelningen av $\mathbf{X}_S$ om vi låter $\mathbf{X}_T$ vara fixt eller variera. Genom definitionen av den betingade fördelningen har vi

$$\frac{f_{\mathbf{X}}(\mathbf{x})}{f_{\mathbf{X}_T}(\mathbf{x}_T)} = f_{\mathbf{X}_S}(\mathbf{x}_S) \quad \Leftrightarrow \quad f_{\mathbf{X}}(\mathbf{x}) = f_{\mathbf{X}_S}(\mathbf{x}_S)f_{\mathbf{X}_T}(\mathbf{x}_T).$$

När detta gäller säger vi att $\mathbf{X}_S$ och $\mathbf{X}_T$ är *oberoende* stokastiska vektorer och betecknar detta med $\mathbf{X}_S \perp \mathbf{X}_T$.

Notera att definitionen ovan kan också tillämpas då $S \cup T \neq \{1, \dots, m\}$. I detta fall betraktas oberoendet mellan $\mathbf{X}_S$ och $\mathbf{X}_T$ med avseende på $\mathbf{X}_{S \cup T}$ och vi har

$$f_{\mathbf{X}_{S \cup T}}(\mathbf{x}_{S \cup T}) = f_{\mathbf{X}_S}(\mathbf{x}_S) f_{\mathbf{X}_T}(\mathbf{x}_T).$$

Ett viktigt specialfall är då $S = \{i\}$ och $T = \{j\}$ och vi får

$$f_{X_i, X_j}(x_i, x_j) = f_{X_i}(x_i) f_{X_j}(x_j),$$

vilket är den välbekanta definitionen av oberoende för endimensionella stokastiska variabler.

Om vi har fler än två delvektorer $\mathbf{X}_{S_1}, \mathbf{X}_{S_2}, \dots, \mathbf{X}_{S_k}$ säger vi att dessa är oberoende om alla par av disjunkta unioner är oberoende, dvs. att vi har

$$\mathbf{X}_{\cup_{i \in P} S_i} \perp \mathbf{X}_{\cup_{j \in Q} S_j}$$

för alla $P, Q \subset \{1, \dots, k\}$ så att $P \cap Q = \emptyset$. (Notera att engelskan skiljer på denna definition, "mutual independence", och fallet då endast par av delvektorer är oberoende, "pairwise independent". På svenska syftar oberoende alltid på den tidigare definitionen.)

2.4 Väntevärde, varians och kovarians

Precis som i det endimensionella fallet är det användbart att försöka sammanfatta flerdimensionella stokastiska variabler. Detta görs enklast med väntevärden som beskriver vilka värden den stokastiska vektorn tar "i genomsnitt". För att beskriva spridningen blir saken mer komplicerad än för endimensionella stokastiska variabler då vi har flera möjliga riktningar som vektorn kan sprida sig i. Vi behöver därför en matris för att beskriva denna.

2.4.1 Väntevärde i flera dimensioner

Precis som i det endimensionella fallet kan vi definiera väntevärden för flerdimensionella stokastiska variabler. Om $\mathbf{X}$ är en diskret m -dimensionell stokastisk variabel och vi har $g : \mathbb{R}^m \rightarrow \mathbb{R}^p$ definierar vi väntevärdet

$$\mathbb{E}[g(\mathbf{X})] = \sum_{x_1, \dots, x_m} g(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}).$$

I det kontinuerliga fallet har vi

$$\mathbb{E}[g(\mathbf{X})] = \int_{\mathbb{R}^m} g(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Om vi bara har $g(\mathbf{x}) = \mathbf{x}$ talar vi om väntevärdet $\mathbb{E}[\mathbf{X}]$ av $\mathbf{X}$. Väntevärdet är linjär i $g(\mathbf{X})$, dvs.

$$\mathbb{E}[A g(\mathbf{X}) + \mathbf{b}] = A \mathbb{E}[g(\mathbf{X})] + \mathbf{b},$$

för $A \in \mathbb{R}^{k \times p}$ och $\mathbf{b} \in \mathbb{R}^k$.

Definitionen ovan kan också generaliseras till en matrisvärd funktion $g : \mathbb{R}^m \rightarrow \mathbb{R}^{p \times q}$ genom samma summa- och integralformler ovan. Vi har då den ytterligare linjäritetsegenskapen

$$\mathbb{E}[A g(\mathbf{X}) B + C] = A \mathbb{E}[g(\mathbf{X})] B + C$$

för matriser $A \in \mathbb{R}^{k \times p}$, $B \in \mathbb{R}^{q \times s}$ och $C \in \mathbb{R}^{k \times s}$.

För multinomialfördelningen har vi att om $\mathbf{X} \sim \text{Multi}(n, p_1, \dots, p_m)$ så gäller

$$\mathbb{E}[\mathbf{X}] = \begin{bmatrix} np_1 \\ np_2 \\ \vdots \\ np_m \end{bmatrix}$$

(se övning 2).

Exempel 2.14. Låt $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I})$ vara den m -dimensionella standardnormalfördelningen. I detta fall har vi

$$\begin{aligned} E[\mathbf{Z}] &= \int_{\mathbb{R}^m} \mathbf{z} \cdot \frac{1}{(2\pi)^{m/2}} e^{-\|\mathbf{z}\|^2/2} d\mathbf{z} \\ &= \frac{1}{(2\pi)^{m/2}} \int_{\mathbb{R}^m} \mathbf{z} e^{-\sum_{i=1}^m z_i^2/2} d\mathbf{z}. \end{aligned}$$

Det j :te elementet av $E[\mathbf{Z}]$ ges då av

$$\begin{aligned} &\frac{1}{(2\pi)^{m/2}} \int_{\mathbb{R}^m} z_j \prod_{i=1}^m e^{-z_i^2/2} d\mathbf{z} \\ &= \frac{1}{(2\pi)^{1/2}} \int_{\mathbb{R}} z_j e^{-z_j^2/2} dz_j \cdot \frac{1}{(2\pi)^{(m-1)/2}} \int_{\mathbb{R}^{m-1}} \prod_{i=1, i \neq j}^m e^{-z_i^2/2} dz_1 dz_2 \cdots dz_{j-1} dz_{j+1} \cdots dz_m \\ &= 0 \cdot 1 = 0. \end{aligned}$$

Med andra ord har vi $E[\mathbf{Z}] = \mathbf{0}$.

Man kan använda detta resultat tillsammans med Sats 2.2 för att visa att normalfördelningens $N(\boldsymbol{\mu}, \Sigma)$ väntevärde är $\boldsymbol{\mu}$ (föga oförväntat, se övning 2).

2.4.2 Kovariansmatris

Som vi nämnde ovan så kan spridningen hos en stokastisk vektor inte sammanfattas med ett värde eller ens en vektor – vad som krävs är en matris som beskriver hur fördelningen är utspridd i olika riktningar. Vi kallar denna matris *kovariansmatrisen* och definierar den som

$$\text{Cov}[\mathbf{X}] = E[(\mathbf{X} - E[\mathbf{X}])(\mathbf{X} - E[\mathbf{X}])^T].$$

Andra namn på matrisen är *autokovariansmatris*, *variansmatris* och *varians-kovariansmatris* och den betecknas ibland $\text{Var}[\mathbf{X}]$.

Det första vi ser är att $\text{Cov}[\mathbf{X}]$ är en $m \times m$ -matris. Vidare ser vi att $\text{Cov}[\mathbf{X}]^T = \text{Cov}[\mathbf{X}]$ är symmetrisk. Vi ser också att det (i, j) :te elementet av $\text{Cov}[\mathbf{X}]$ ges av

$$E[(X_i - E[X_i])(X_j - E[X_j])] = \text{Cov}[X_i, X_j],$$

därför namnet kovariansmatris. På diagonalen har vi varianserna $\text{Cov}[X_i, X_i] = \text{Var}[X_i]$.

En annan viktig egenskap är att $\text{Cov}[\mathbf{X}]$ är positivt semidefinit. Vi ser detta genom att ta

$$\begin{aligned} \mathbf{u}^T \text{Cov}[\mathbf{X}] \mathbf{u} &= E[\mathbf{u}^T (\mathbf{X} - E[\mathbf{X}])(\mathbf{X} - E[\mathbf{X}])^T \mathbf{u}] \\ &= E[|\mathbf{u}^T (\mathbf{X} - E[\mathbf{X}])|^2] \geq 0 \end{aligned}$$

för godtycklig $\mathbf{u} \in \mathbb{R}^m$. Med andra ord är alla egenvärden icke-negativa (men inte nödvändigtvis positiva).

Kovariansmatriser är inte linjära (som väntevärdet), men uppfyller en liknande egenskap. Vi har nämligen att för $A \in \mathbb{R}^{k \times m}$ och $\mathbf{b} \in \mathbb{R}^k$ så gäller

$$\text{Cov}[A\mathbf{X} + \mathbf{b}] = E[(A\mathbf{X} - A E[\mathbf{X}])(A\mathbf{X} - A E[\mathbf{X}])^T]$$

eftersom $E[A\mathbf{X} + \mathbf{b}] = A E[\mathbf{X}] + \mathbf{b}$. Om vi vidareutvecklar får vi

$$\text{Cov}[A\mathbf{X} + \mathbf{b}] = E[A(\mathbf{X} - E[\mathbf{X}])(\mathbf{X} - E[\mathbf{X}])^T A^T] = A \text{Cov}[\mathbf{X}] A^T.$$

Detta generaliserar den endimensionella relationen $\text{Var}[aX + b] = a^2 \text{Var}[X]$.

Ibland kan vi förenkla beräkningen av en kovariansmatris genom följande omskrivning

$$\begin{aligned} \text{Cov}[\mathbf{X}] &= E[(\mathbf{X} - E[\mathbf{X}])(\mathbf{X} - E[\mathbf{X}])^T] \\ &= E[\mathbf{X}\mathbf{X}^T] - E[\mathbf{X}] E[\mathbf{X}]^T - E[\mathbf{X}] E[\mathbf{X}^T] + E[\mathbf{X}] E[\mathbf{X}]^T \\ &= E[\mathbf{X}\mathbf{X}^T] - E[\mathbf{X}] E[\mathbf{X}]^T. \end{aligned}$$

För multinomialfördelningen har vi att om $\mathbf{X} \sim \text{Multi}(n, p_1, \dots, p_m)$ får vi (se övning 2)

$$\text{Cov}[\mathbf{X}] = \begin{bmatrix} np_1(1-p_1) & -np_1p_2 & \cdots & -np_1p_m \\ -np_2p_1 & np_2(1-p_2) & \cdots & -np_2p_m \\ \vdots & \vdots & & \vdots \\ -np_mp_1 & -np_mp_2 & \cdots & np_m(1-p_m) \end{bmatrix}.$$

Exempel 2.15. Låt $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I})$ vara den m -dimensionella standardnormalfördelningen (igen). Vi vet att det (i, j) :te elementet av $\text{Cov}[\mathbf{Z}]$ ges av $\text{Cov}[Z_i, Z_j]$. Eftersom $(Z_i, Z_j) \sim N(\mathbf{0}, \mathbf{I})$ enligt Sats 2.1 har vi för $i \neq j$

$$\text{Cov}[Z_i, Z_j] = \int_{\mathbb{R}^2} z_i z_j \cdot \frac{1}{2\pi} e^{-(z_i^2 + z_j^2)/2} dz_i dz_j = \left(\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} z_i e^{-z_i^2/2} dz_i \right) \left(\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} z_j e^{-z_j^2/2} dz_j \right) = 0 \cdot 0 = 0.$$

På samma sätt har vi att $\text{Cov}[Z_i, Z_i] = \text{Var}[Z_i] = 1$. Detta ger kovariansmatrisen

$$\text{Cov}[\mathbf{Z}] = \mathbf{I}.$$

Återigen kan vi använda detta resultat tillsammans med Sats 2.2 för att visa att kovariansmatrisen för $N(\boldsymbol{\mu}, \Sigma)$ är lika med Σ .

För två delvektorer $\mathbf{X}_S$ och $\mathbf{X}_T$ kan vi också definiera kovariansmatrisen

$$\text{Cov}[\mathbf{X}_S, \mathbf{X}_T] = E[(\mathbf{X}_S - E[\mathbf{X}_S])(\mathbf{X}_T - E[\mathbf{X}_T])^T]$$

mellan dessa vektorer. Detta motsvarar så klart blocket av $\text{Cov}[\mathbf{X}]$ där raderna tas från S och kolonnerna tas från T .

Om dessa två delvektorer är obereonde (dvs. $\mathbf{X}_S \perp \mathbf{X}_T$) har vi att

$$\text{Cov}[\mathbf{X}_S, \mathbf{X}_T] = E[(\mathbf{X}_S - E[\mathbf{X}_S])(\mathbf{X}_T - E[\mathbf{X}_T])^T] = E[\mathbf{X}_S - E[\mathbf{X}_S]] E[\mathbf{X}_T - E[\mathbf{X}_T]]^T = \mathbf{0} \cdot \mathbf{0}^T = \mathbf{0}$$

eftersom alla element av $\mathbf{X}_S$ är oberoende av alla element i $\mathbf{X}_T$ och vi då kan faktorisera väntevärdet.

Konversen till detta resultat håller inte i allmänhet, men det finns ett viktigt specialfall.

Sats 2.4. Låt $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ för något $\boldsymbol{\mu} \in \mathbb{R}^m$ och $\Sigma \in \mathbb{R}^{m \times m}$ (positivt definit). Om $S, T \subset \{1, \dots, m\}$ så att $S \cap T = \emptyset$ så har vi att

$$\mathbf{X}_T \perp \mathbf{X}_S \Leftrightarrow \text{Cov}[\mathbf{X}_S, \mathbf{X}_T] = \mathbf{0}.$$

Bevis. Den ena riktningen har vi redan visat. Den andra fås genom att faktorisera den simultana täthetsfunktionen och visa att den kan fås som produkten av täthetsfunktionerna för $\mathbf{X}_S$ och $\mathbf{X}_T$. $\square$

2.5 Uppgifter

- 2.1.** [1] Betrakta den stokastiska vektorn $\mathbf{X} = [X_1, X_2, X_3]^T$ där var och en av X_i har de möjliga utfallen 0 eller 1. Antag vidare att sannolikheten för utfallet $\mathbf{x} = [x_1, x_2, x_3]^T$ ges av följande tabell:

$\mathbf{x}$	$[0, 0, 0]^T$	$[0, 0, 1]^T$	$[0, 1, 0]^T$	$[0, 1, 1]^T$	$[1, 0, 0]^T$	$[1, 0, 1]^T$	$[1, 1, 0]^T$	$[1, 1, 1]^T$
$P(\mathbf{X} = \mathbf{x})$	1/24	1/8	2/15	1/5	1/36	5/36	1/7	4/21

- Vad är marginalsannolikheten för $P(X_2 = x_2, X_3 = x_3)$?
- Vad är marginalsannolikheten för $P(X_3 = x_3)$?
- Är $X_1 \perp X_2$?

- 2.2.** [1] En rättvis sexsidig tärning kastas tio gånger. Antalet gånger utfall i inträffa, betecknas x_i och registreras i vektorn $(x_1, x_2, x_3, x_4, x_5, x_6)$.

- Vad är marginalsannolikheten $P(X_i = x_i)$ för varje $i = 1, 2, 3, 4, 5, 6$?

(b) Vad är marginalsannolikheten för $P(X_i = x_i, X_j = x_j)$ för $i \neq j$?

2.3. [1] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5, X_6, X_7]^T \sim N(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = \begin{bmatrix} 0.517 \\ 0.839 \\ 0.817 \\ 0.660 \\ 0.674 \\ 0.385 \\ 0.259 \end{bmatrix} \quad \text{och} \quad \Sigma = \begin{bmatrix} 1 & 0.22 & 0.29 & 0.07 & 0.03 & 0.29 & 0.07 \\ 0.22 & 1 & 0.16 & 0.15 & 0.13 & 0.16 & 0.13 \\ 0.29 & 0.16 & 1 & 0.16 & 0.07 & 0.09 & 0.16 \\ 0.07 & 0.15 & 0.16 & 1 & 0.25 & 0.17 & 0.17 \\ 0.03 & 0.13 & 0.07 & 0.25 & 1 & 0.12 & 0.37 \\ 0.29 & 0.16 & 0.09 & 0.17 & 0.12 & 1 & 0.15 \\ 0.07 & 0.13 & 0.16 & 0.17 & 0.37 & 0.15 & 1 \end{bmatrix}.$$

Vad är marginalfördelningen för $\mathbf{Y} = [X_1, X_3, X_5, X_7]^T$?

2.4. [2] Låt N_1, N_2, N_3, N_4 vara oberoende och $N_1 \sim N(0, 3)$, $N_2 \sim N(0, 1)$, $N_3 \sim N(0, 1)$, $N_4 \sim N(0, 3)$. Låt vidare

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= 0.25X_1 + N_2, \\ X_3 &= -0.33X_2 + N_3, \\ X_4 &= 0.5X_2 + 0.75X_3 + N_4. \end{aligned}$$

Vad är marginalfördelningen för $[X_1, X_4]^T$?

2.5. [2] Box-Muller-metoden används för att generera utfall från den standardiserade normalfördelningen och bygger på transformationen

$$X_1 = \cos(2\pi U_1)\sqrt{-2\log U_2}, \quad X_2 = \sin(2\pi U_1)\sqrt{-2\log U_2},$$

där U_1 och U_2 är oberoende med fördelning $U(0, 1)$.

- (a) Visa att X_1 och X_2 är oberoende $N(0, 1)$ -fördelade stokastiska variabler.
 - (b) Implementera Box-Muller-metoden genom att generera utfall från likformigt fördelade stokastiska variabler (med hjälp av `scipy.stats.uniform`) och tillämpa transformationen ovan. Bekräfta att histogrammet, det stickprovsmedelvärde och stickprovsvariansen överensstämmer med dina förväntningar. Beräkna stickprovskovariansen mellan X_1 och X_2 för att se om denna är tillräckligt liten.
- 2.6. [1] Beräkna täthetsfunktionen för $Y = 1/X$ där $X \sim \text{Gamma}(\alpha, \beta)$. Den stokastiska variabeln Y sägs vara *inversgammafördelad* vilket skrivs som $Y \sim \text{InvGamma}(\alpha, \beta)$.
- 2.7. [1] Beräkna täthetsfunktionen för $Y = 1/X$ där $X \sim \chi^2(\theta)$. Den stokastiska variabeln Y sägs vara *invers- χ^2 -fördelad* vilket skrivs som $Y \sim \text{inv-}\chi^2(\theta)$.
- 2.8. [1] (a) Givet $X \sim \text{Gamma}(\alpha, \lambda)$, beräkna täthetsfunktionen för $Y = 1/X$. Vi säger då att Y är fördelad enligt den inversa gamma-fördelningen, skrivet $Y \sim \text{InvGamma}(\alpha, \lambda)$.
- (b) Anta nu att $X \sim \chi^2(\nu)$. Beräkna täthetsfunktionen för $Y = 1/X$. Denna fördelning kallas den inversa χ^2 -fördelningen och skrivs $\text{Inv-}\chi^2(\nu)$. Hur förhåller denna fördelning sig till den inversa gamma-fördelningen?
 - (c) Låt $\tau > 0$, sätt $Y = \nu\tau^2/X$ och beräkna dess täthetsfunktion. Detta är den skalade inversa χ^2 -fördelningen och skrivs $\text{ScaledInv-}\chi^2(\nu, \tau^2)$. Hur förhåller sig denna till den (ordinarie) inversa χ^2 -fördelningen?
 - (d) Visa att den skalade inversa χ^2 -fördelningen också kan skrivas som den inversa gamma-fördelningen.

- 2.9.** [2] Beräkna täthetsfunktionen för $Y = 1/X$ där $X \sim \text{Beta}(\alpha, \beta)$. Den stokastiska variabeln Y sägs vara *betaprimfördelad* vilket skrivs som $Y \sim \text{Beta}'(\alpha, \beta)$.
- 2.10.** [1] Beräkna täthetsfunktionen för $Y = \log(X)$ där $X \sim N(\mu, \sigma^2)$. Den stokastiska fördelningen Y sägs vara *lognormalfördelad* vilket skrivs som $Y \sim \text{lognormal}(\mu, \sigma^2)$.
- 2.11.** [3] Låt $X_1, \dots, X_n$ vara oberoende och $\text{Exp}(\theta)$ -fördelade. Visa att $Y = X_1 + \dots + X_n \sim \text{Gamma}(n, \theta)$.
- 2.12.** [1] Implementera algoritmer för att generera utfall från följande fördelningar:
- (a) $\text{Exp}(\lambda)$,
 - (b) $\text{Gamma}(\alpha, \lambda)$ för α heltal,
 - (c) $\text{InvGamma}(\alpha, \lambda)$ för α heltal och
 - (d) $\text{Inv-}\chi^2(\nu)$ för ν jämnt heltal.
- Du kan använda utfall från den likformiga fördelningen (`scipy.stats.uniform`). Verifiera din implementering genom att beräkna stickprovsmedelvärden, stickprovsvarianser och histogram.
- 2.13.** [2] Låt $X \sim \text{Po}(\lambda_1)$ och $Y \sim \text{Po}(\lambda_2)$ vara två oberoende stokastiska variabler. Visa att $Z = X + Y \sim \text{Po}(\lambda_1 + \lambda_2)$.
- 2.14.** [2] Visa att $Z = \frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta)$ där X och Y är oberoende stokastiska variabler så att $X \sim \text{Gamma}(\alpha, 1)$ samt $Y \sim \text{Gamma}(\beta, 1)$.
- 2.15.** [3] Låt $X_1, \dots, X_n$ vara oberoende och likafördelade stokastiska variabler med fördelning $U(0, 1)$. Låt $X_{(1)}$ beteckna det minsta värdet, $X_{(2)}$ det näst minsta värdet, och så vidare, där $X_{(n)}$ då betecknar det största värdet. Med andra ord låter vi $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ värdena $X_1, \dots, X_n$ efter sortering från minst till störst. Dessa kallas för *ordningsstatistikorna* av $X_1, \dots, X_n$.

- (a) Låt $g : [0, 1]^n \rightarrow [0, 1]^n$ vara *sorteringsavbildningen* som tar en sekvens $x_1, x_2, \dots, x_n$ till den sorterade sekvensen $x_{(1)}, x_{(2)}, \dots, x_{(n)}$. Visa att g 's värdemängd består av delmängden

$$B = \{(x_{(1)}, x_{(2)}, \dots, x_{(n)}) : 0 \leq x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)} \leq 1\}$$

och att definitionsområdet $[0, 1]^n$ kan delas upp i $n!$ undermängder så att g är bijektiv på varje undermängd (nästan överallt, dvs. överallt utom på en nollmängd).

- (b) Visa att absolutvärdet hos g 's jacobideterminant är lika med ett på var och en av dessa undermängder (nästan överallt).
- (c) Visa att den simultana täthetsfunktionen för $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ är konstant och lika med $n!$.
- (d) Beräkna marginalfördelningen för $X_{(i)}$ där $i = 1, 2, \dots, n$.
- (e) Låt $X_1, \dots, X_n$ istället vara oberoende och likafördelade stokastiska variabler, men med en godtycklig täthetsfunktion $f(x)$. Bestäm den simultana täthetsfunktionen för $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ och marginalfördelningen för $X_{(i)}$ där $i = 1, \dots, n$.
- 2.16.** [2] Vad är den betingade fördelningen för $\mathbf{Y} \mid X_3 = 0$ där $\mathbf{Y} = [X_1, X_2]^T$ och

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= N_2, \\ X_3 &= 0.3X_1 + 0.4X_2 + N_3 \end{aligned}$$

om N_1, N_2, N_3 är oberoende och $N(0, 1)$ -fördelade?

- 2.17.** [2] Vi har tidigare sett att om $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ där $\boldsymbol{\mu} = [\mu_1, \mu_2, \dots, \mu_n]^T \in \mathbb{R}^n$ och $\Sigma = [\Sigma_{ij}]_{i,j=1}^n \in \mathbb{R}^{n \times n}$ är positivt definit, så har vi att $\mathbf{Y} = A\mathbf{X} + b$ för $A \in \mathbb{R}^{m \times n}$ och $b \in \mathbb{R}^m$ så gäller $\mathbf{Y} \sim N(A\boldsymbol{\mu} + b, A\Sigma A^T)$. Använd detta för att bevisa följande egenskaper
- (a) [1] $X_i \sim N(\mu_i, \Sigma_{ii})$ för alla $i = 1, 2, \dots, n$.

- (b) $[2+] \text{ Cov}[X_i, X_j] = \Sigma_{ij}$ för alla $i, j = 1, 2, \dots, n$.
- (c) $[1] Y \sim N(\mu_Y, \Sigma_Y)$ där Y består av de m första elementen av X , $\mu_Y = [\mu_1, \mu_2, \dots, \mu_m]^T$ och $\Sigma_Y = [\Sigma_{ij}]_{i,j=1}^m$.

2.18. [1] Låt $\mathbf{X} = [X_1, X_2, X_3]^T \sim N(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = [0, 0, 0]^T \quad \text{and} \quad \Sigma = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 3 & 2 \\ 0 & 2 & 4 \end{bmatrix}.$$

- (a) Bekräfta att Σ är positivt definit.
- (b) Låt $Y = X_1 - X_2$ and $Z = X_2 - X_3$. Beräkna väntevärdena och varianserna för Y and Z samt deras kovarians.
- (c) Beräkna den betingade fördelningen för (X_1, X_3) givet $X_2 = 0$. Vad är de betingade väntevärdena och varianserna? Vad är kovariansen?
- (d) Tolka resultatet från del (c) och beskriv relationen mellan X_1 , X_2 och X_3 . Hur kan de ha uppkommit?
- (e) Generera utfall av $\mathbf{X}$ med hjälp av `scipy.stats.multivariate_normal` och använd medelvärden för att approximera värdena ovan. För att simulera den betingade fördelningen, välj utfall som har x_2 inom ett snävt intervall $[-\epsilon, \epsilon]$ kring noll för något litet värde ϵ .

2.19. [2] Låt $\mathbf{X} \sim \text{Multi}(n, p_1, p_2, \dots, p_k)$.

- (a) Bestäm X_i :s marginalfördelning med hjälp av *multinomialsatsen* som ger att

$$(p_1 + p_2 + \dots + p_k)^n = \sum_{x_1 + x_2 + \dots + x_k = n} \frac{n!}{x_1! x_2! \dots x_k!} p_1^{x_1} p_2^{x_2} \dots p_k^{x_k}.$$

- (b) Bestäm den betingade fördelningen för $X_1, X_2, \dots, X_{k-1}$ givet $X_k = x_k$.
- (c) Visa att kovariansen mellan X_i och X_j för $i \neq j$ ges av $-np_i p_j$. Varför är kovariansen alltid negativ?

2.20. [2] Låt $[X_1, \dots, X_m]^T \sim \text{Multi}(n; p_1, \dots, p_m)$ och låt $1 = b_0 < b_1 < \dots < b_{k-1} < b_k = m$ vara heltal. Vi definierar variablerna $Y_i = \sum_{j=b_{i-1}}^{b_i-1} X_j$ för alla $i = 1, \dots, k$ och betraktar deras simultana fördelning $\mathbf{Y} = [Y_1, \dots, Y_k]^T$. Visa att $\mathbf{Y} \sim \text{Multi}(n; q_1, \dots, q_k)$ där $q_i = p_{b_{i-1}} + \dots + p_{b_i}$ för alla $i = 1, \dots, k$.

2.21. [1] Låt X och Y vara oberoende och exponentialfördelade stokastiska variabler med parametrar λ respektive μ . Vi observerar inte X och Y direkt utan Z och W definierade enligt

$$Z = \min(X, Y) \quad \text{och} \quad W = \begin{cases} 1 & \text{om } Z = X, \\ 0 & \text{om } Z = Y. \end{cases}$$

Visa att Z och W är oberoende.

2.22. [1] Betrakta modellen $[X_1, X_2]^T$ i Exempel 1.4. Visa att $X_1 \perp X_2$ om och endast om $\lambda = 0$.

2.23. [2] Låt $X_1 \sim \text{Po}(\lambda_1)$ och $X_2 \sim \text{Po}(\lambda_2)$ vara två oberoende stokastiska variabler. Sätt $Y = X_1 + X_2$

- (a) Visa att $X_1 | Y = y \sim \text{Bin}(\theta)$ där $\theta = \frac{\lambda_1}{\lambda_1 + \lambda_2}$.
- (b) Hur är $X_2 | Y = y$ fördelad?

2.24. [1] En punkt (X, Y) väljs slumpmässigt ut enligt en likformig fördelning på kvadraten med hörn $(1, 1)$, $(-1, 1)$, $(-1, -1)$ och $(1, -1)$.

- (a) Beräkna täthetsfunktionen $f_{X,Y}(x, y)$.
- (b) Bestäm de marginella täthetsfunktionerna för X och Y .

- (c) Beräkna $P(\sqrt{X^2 + Y^2} < 1)$.
- (d) Beräkna $P(Y - 2X < 0)$.

2.25. [2] Låt $X \sim \text{Exp}(\lambda)$ och $Y \sim \text{Exp}(\mu)$ vara oberoende stokastiska variabler för $\lambda, \mu > 0$.

- (a) Beräkna täthetsfunktionen för $Z = X/(X + Y)$. Vad händer då $\lambda = \mu$?
- (b) Beräkna täthetsfunktionen för $Z = \lambda X - \mu Y$.
- (c) Beräkna täthetsfunktionen för $Z = \lambda X/\mu Y$.

2.26. [2] Antag att $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_n)$.

- (a) Givet $A \in \mathbb{R}^{m \times n}$ och $\mathbf{b} \in \mathbb{R}^m$ för $m \leq n$, vad har $A\mathbf{Z} + \mathbf{b}$ för fördelning?
- (b) Använd svaret från del (a) för att utveckla två metoder för simulering av $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ för $\boldsymbol{\mu} \in \mathbb{R}^n$ and positivt definita $\Sigma \in \mathbb{R}^{n \times n}$ med hjälp av utfall från den standardiserade normalfördelningen.
- (c) Visa att $E[\mathbf{X}] = \boldsymbol{\mu}$ och $\text{Cov}[\mathbf{X}] = \Sigma$.
- (d) Implementera algoritmerna från del (b) (med hjälp av `scipy.stats.norm`). Vilken av de två metoderna föredrar du?

2.27. [3] Betrakta den simultana fördelningen för $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ där

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= 3X_1 + N_2, \\ X_3 &= -4X_2 + N_3, \\ X_4 &= 2X_1 + X_2 + N_4. \end{aligned}$$

och N_1, N_2, N_3, N_4 är oberoende och standardnormalfördelade.

- (a) Bestäm $\boldsymbol{\mu}$ och Σ så att $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$.
- (b) Vad är den betingade fördelningen för $[X_2, X_3]^T | X_4 = 0$? Generera ett stickprov av storlek 500 från denna fördelning och plotta resultatet. Finns det någon korrelation mellan X_2 och X_3 i denna fördelning?
- (c) Vad är marginalfördelningen för $[X_2, X_3]^T$? Generera ett stickprov från denna fördelning och plotta resultatet. Ser du någon korrelation här?

2.28. [1] Låt X och Y vara oberoende stokastiska variabler.

- (a) Visa att $E[X^2] = \text{Var}[X] + E[X]^2$.
- (b) Visa att $\text{Var}[XY] = E[X^2]E[Y^2] - E[X]^2E[Y]^2$.
- (c) Visa att $\text{Var}[XY] = \text{Var}[X]\text{Var}[Y] + \text{Var}[X]E[Y]^2 + \text{Var}[Y]E[X]^2$.

2.29. [1] Vad är $E[\mathbf{X}]$ och $\text{Cov}[\mathbf{X}]$ där $\mathbf{X} = [X_1, X_2, X_3]^T$ är fördelad som i Uppgift 2.1?

2.30. [1] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim N(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \quad \text{och} \quad \Sigma = \begin{bmatrix} 5 & 1 & -0.5 & -0.3 \\ 1 & 4 & 0.25 & 0 \\ -0.5 & 0.25 & 5 & 2.4 \\ -0.3 & 0 & 2.4 & 4 \end{bmatrix}$$

- (a) Är $X_2 \perp\!\!\!\perp X_4$?
- (b) Är $X_2 \perp\!\!\!\perp X_3$?
- (c) Vad är $\text{Cov}[X_1, X_3]$?
- (d) Vad är $\text{Var}[X_2]$?

(e) Vad är $E[X_2, X_3]$?

(f) Vad är $\text{Cov}[\mathbf{Y}]$ där $\mathbf{Y} = [X_1, X_3, X_4]^T$?

2.31. [1] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim N(\mathbf{0}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 1 & 0 & 2 & 2 \\ 0 & 1 & 0 & 0 \\ 2 & 0 & 5 & 4 \\ 2 & 0 & 4 & 5 \end{bmatrix}.$$

(a) Vad är $E[(X_3 + X_4)X_2^2]$?

(b) Vad är $E[(X_3 + X_4)^2 X_2^2]$?

(c) Vad är $E[(X_3 + X_4)^2 + X_2^2]$?

2.32. [1] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ vara fördelad som i Uppgift 2.31.

(a) Vad är $\text{Var}[X_2 + X_3 + X_4]$?

(b) Vad är $\text{Var}[(X_3 + X_4)X_2]$?

(c) Vad är $\text{Var}[(X_3 + X_4)X_2^2]$?

2.33. [2] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5]^T$ vara $N(\mathbf{0}, \Sigma)$ -fördelad där

$$\Sigma = \begin{bmatrix} 10 & 1 & -1 & -2 & 0 \\ 1 & 7 & 4 & -1 & 0 \\ -1 & 4 & 9 & 0 & 0 \\ -2 & -1 & 0 & 8 & 0 \\ 0 & 0 & 0 & 0 & 17 \end{bmatrix}.$$

Beräkna $E[(X_1 + X_2)^2((X_3 + X_4)^2 + X_5^2)^2]$.

2.34. [3] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5, X_6, X_7, X_8]^T \sim N(\mathbf{0}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 1 & 3 & 0 & 2 & 0 & 0 & 0 & 0 \\ 3 & 10 & 0 & 6 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 2 & 3 & 0 & 0 \\ 2 & 6 & 0 & 5 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 5 & 6 & 0 & 0 \\ 0 & 0 & 3 & 0 & 6 & 10 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 27 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 27 \end{bmatrix}.$$

Låt

$$Y = \frac{1}{(X_2 + X_4)^2 + (X_5 + X_6)^2 + X_7^2 + X_8^2}.$$

Vad är $E[Y]$?

Kapitel 3

3.1 Betingat oberoende

I föregående kapitel introducerade vi flerdimensionellafördelningar för stokastiska vektorer $\mathbf{X} = [X_1, \dots, X_m]^T$ där $X_1, \dots, X_m$ inte nödvändigtvis är oberoende. Istället kan de vara beroende på komplexa sätt (exempelvis, glödlamporna i Exempel 2.11). En av de främsta anledningarna för att använda multivariatfördelningar är för att modellera sådana beroende. I statistiken föredrar vi ofta att identifiera när det definitivt inte finns något beroende. Därför bildar vi vanligtvis modeller baserade på *de observerbara oberoenderelationerna* inom systemet; dvs. oberoenderelationerna som vi kan anta med hjälp av apriori kunskap om variablerna eller som vi lära oss från data (med hjälp av tekniker vi ska se senare i boken). Dessa oberoenderelationer kan ha väldigt mycket komplexare former än bara $X_i \perp\!\!\!\perp X_j$. Till exempel kan man betrakta oberoende som inte existerar i den simultana fördelningen men bara existerar i en betingad fördelning.

I det följande betecknar vi en mängd $\{1, \dots, m\}$ för ett positivt heltal m med $[m]$. Om vi har en fördelning $f_{\mathbf{X}}(x_1, \dots, x_m)$ och $A, B \subseteq [m]$ skriver vi $f_{\mathbf{X}_{A \cup B}}(\mathbf{x}_A, \mathbf{x}_B)$ för marginalfördelningen av $\mathbf{X}_{A \cup B}$. Exempelvis, om $m = 8$ och $A = \{3, 5\}$ och $B = \{4, 6, 7\}$ är

$$\begin{aligned} f_{\mathbf{X}_{A \cup B}}(\mathbf{x}_A, \mathbf{x}_B) &= f_{\mathbf{X}_A, \mathbf{X}_B}(\mathbf{x}_A, \mathbf{x}_B), \\ &= f_{X_3, X_5, X_4, X_6, X_7}(x_3, x_5, x_4, x_6, x_7), \\ &= f_{X_3, X_4, X_5, X_6, X_7}(x_3, x_4, x_5, x_6, x_7) \end{aligned}$$

Det vill säga att man kan permutera variabler i funktionen som man vill och det är fortfarande samma funktion.

Låt $A, B, C \subseteq [m]$ vara disjunkta delmängder av $[m]$ där $A, B \neq \emptyset$. Vi säger $\mathbf{X}_A$ är oberoende av $\mathbf{X}_B$ given $\mathbf{X}_C$ (kortfattat, A är oberoende av B givet C) om

$$f_{\mathbf{X}_{A \cup B} | \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B | \mathbf{x}_C) = f_{\mathbf{X}_A | \mathbf{X}_C}(\mathbf{x}_A | \mathbf{x}_C) f_{\mathbf{X}_B | \mathbf{X}_C}(\mathbf{x}_B | \mathbf{x}_C)$$

för alla $\mathbf{x}_A, \mathbf{x}_B$ och alla $\mathbf{x}_C$ där $f_{\mathbf{X}_C}(\mathbf{x}_C) > 0$. I sådant fall skriver vi $X_A \perp\!\!\!\perp X_B | X_C$ (eller $A \perp\!\!\!\perp B | C$). Om A inte är oberoende av B given C säger vi att A är beroende av B given C och skriver $A \not\perp\!\!\!\perp B | C$.

Exempel 3.1. Låt $[X_1, X_2, X_3]^T \sim N(0, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 1 & 1 & -2 \\ 1 & 2 & -4 \\ -2 & -4 & 9 \end{bmatrix}.$$

Det följer från Sats 2.4 att $X_1 \not\perp\!\!\!\perp X_3$ eftersom

$$\text{Cov}[X_1, X_3] = \Sigma_{1,3} = -2 \neq 0.$$

Med hjälp av Sats 2.3 har vi dock att $\mathbf{X}_{\{1,3\}} | X_2 = x_2 \sim N(\mu', \Sigma')$ där

$$\mu' = 0 + \Sigma_{\{1,3\},2} \Sigma_{2,2}^{-1} [x_2] = \begin{pmatrix} x_2 \\ 2 \end{pmatrix} \begin{bmatrix} 1 \\ -4 \end{bmatrix} = \begin{bmatrix} x_2/2 \\ -2x_2 \end{bmatrix},$$

och

$$\begin{aligned}\Sigma' &= \Sigma_{\{1,3\},\{1,3\}} - \Sigma_{\{1,3\},2} \Sigma_{2,2}^{-1} \Sigma_{2,\{1,3\}}, \\ &= \begin{bmatrix} 1 & -2 \\ -2 & 9 \end{bmatrix} - \begin{bmatrix} 1 \\ -4 \end{bmatrix} \begin{bmatrix} \frac{1}{2} \\ 1 \end{bmatrix} \begin{bmatrix} 1 & -4 \end{bmatrix}, \\ &= \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \end{bmatrix}.\end{aligned}$$

Det följer att

$$\begin{aligned}f_{\mathbf{X}_{\{1,3\}}|X_2}(x_1, x_3|x_2) &= \frac{1}{(2\pi)\sqrt{1/2}} \exp \left(-\frac{1}{2} \left(\begin{bmatrix} x_2/2 & -2x_2 \end{bmatrix} - \begin{bmatrix} x_1 & x_3 \end{bmatrix} \right) \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \left(\begin{bmatrix} x_2/2 \\ -2x_2 \end{bmatrix} - \begin{bmatrix} x_1 \\ x_3 \end{bmatrix} \right) \right), \\ &= \frac{1}{(2\pi)\sqrt{1/2}} \exp \left(-\frac{1}{2} (2(x_2/2 - x_1)^2 + (-2x_2 - x_3)^2) \right), \\ &= \frac{1}{\sqrt{2\pi(1/2)}} \exp \left(-\frac{1}{2(1/2)} (x_2/2 - x_1)^2 \right) \frac{1}{\sqrt{2\pi(1)}} \exp \left(-\frac{1}{2(1)} (-2x_2 - x_3)^2 \right), \\ &= f_{X_1|X_2}(x_1|x_2) f_{X_3|X_2}(x_3|x_2),\end{aligned}$$

eftersom

$$\begin{aligned}X_1|X_2 = x_2 &\sim N(0 + \Sigma_{1,2}\Sigma_{2,2}^{-1}x_2, \Sigma_{1,1} - \Sigma_{1,2}\Sigma_{2,2}^{-1}\Sigma_{2,1}) = N(x_2/2, 1/2), \text{ och} \\ X_3|X_2 = x_2 &\sim N(-2x_2, 1).\end{aligned}$$

Eftersom detta gäller för godtyckliga värden x_2 får vi att $X_1 \perp\!\!\!\perp X_3|X_2$.

Exempel 3.1 visar att betingat oberoende är verkligen oberoende som händer in betingade fördelningar. Detta innebär att vi kan generalisera Sats 2.4 för oberoende i flerdimensionella normalfördelningar till en karaktärisering av betingat oberoende i sådana fördelningar; nämligen, om $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ gäller $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B|\mathbf{X}_C$ om och endast om $\text{Cov}[\mathbf{X}_A, \mathbf{X}_B|\mathbf{X}_C] = \mathbf{0}$.

Den betingade kovariansmatrisen $\text{Cov}[\mathbf{X}_A, \mathbf{X}_B|\mathbf{X}_C]$ definieras på samma sätt som betingat väntevärde och betingad varians. Vi definierar *det betingade väntevärdet* för X givet $Y = y$ som

$$\begin{aligned}\mathbb{E}[X|Y = y] &= \sum_x x f_{X|Y}(x|y), \quad (\text{diskret}) \\ \mathbb{E}[X|Y = y] &= \int x f_{X|Y}(x|y) dx. \quad (\text{kontinuerlig})\end{aligned}$$

När vi låter y variera får vi en funktion $g(y) = \mathbb{E}[X|Y = y]$ och kan därmed definiera

$$\mathbb{E}[X|Y] = g(Y)$$

som en transformation av stokastiska variabler. På samma sätt definierar vi *den betingade kovariansmatrisen*. För $\mathbf{X}_A, \mathbf{X}_B$ och $\mathbf{X}_C = \mathbf{x}_C$ definierar vi *den betingade kovariansen*

$$\text{Cov}[\mathbf{X}_A, \mathbf{X}_B|\mathbf{X}_C = \mathbf{x}_C] = \mathbb{E}[(\mathbf{X}_A - \mathbb{E}[\mathbf{X}_A|\mathbf{X}_C = \mathbf{x}_C])(\mathbf{X}_B - \mathbb{E}[\mathbf{X}_B|\mathbf{X}_C = \mathbf{x}_C])^T | \mathbf{X}_C = \mathbf{x}_C].$$

Notera att detta är verkligen bara kovariansen av $\mathbf{X}_A$ och $\mathbf{X}_B$ i den betingade fördelningen $\mathbf{X}_{A \cup B}|\mathbf{X}_C = \mathbf{x}_C$. När vi låter $\mathbf{x}_C$ variera får vi funktionen $g(\mathbf{x}_C) = \text{Cov}[\mathbf{X}_A, \mathbf{X}_B|\mathbf{X}_C = \mathbf{x}_C]$ med vilken kan vi definiera den stokastiska variabeln

$$\text{Cov}[\mathbf{X}_A, \mathbf{X}_B|\mathbf{X}_C] = g(\mathbf{X}_C).$$

Notera att formeln blir den välbekanta formeln för den betingade variansen när vi tar $A = B = \{i\}$ och $C = \{k\}$:

$$\text{Cov}[\mathbf{X}_{\{i\}}, \mathbf{X}_{\{i\}}|\mathbf{X}_{\{k\}}] = \text{Cov}[X_i, X_i|X_k] = \text{Var}[X_i|X_k].$$

Exempel 3.2. Betraka en flerdimensionell normalfördelning $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$, exempelvis fördelningen i Exempel 3.1. Enligt Sats 2.3 har vi att $\mathbf{X}_{A \cup B} | \mathbf{X}_C = \mathbf{x}_C \sim N(\boldsymbol{\mu}', \Sigma')$ där

$$\Sigma' = \Sigma_{A \cup B, A \cup B} - \Sigma_{A \cup B, C} \Sigma_{C, C}^{-1} \Sigma_{C, A \cup B}$$

för varje $\mathbf{x}_C$. Eftersom formeln för Σ' inte beror på valet av $\mathbf{x}_C$ har vi att funktionen $g(\mathbf{x}_C)$ är en konstant funktion, nämligen

$$\text{Cov}[\mathbf{X}_A, \mathbf{X}_B | \mathbf{X}_C] = \text{Cov}[\mathbf{X}_A, \mathbf{X}_B | \mathbf{X}_C = \mathbf{0}].$$

I detta fall är $\text{Cov}[\mathbf{X}_A, \mathbf{X}_B | \mathbf{X}_C]$ inte stokastisk. Istället är det bara lika med den betingade kovariansen för $\mathbf{X}_A$ och $\mathbf{X}_B$ givet $\mathbf{X}_C = \mathbf{x}_C$ (för vilken $\mathbf{x}_C$ som helst). Eftersom $\text{Cov}[\mathbf{X}_A, \mathbf{X}_B | \mathbf{X}_C = \mathbf{x}_C]$ bara är kovariansen för $\mathbf{X}_A$ och $\mathbf{X}_B$ i den betingade fördelningen $\mathbf{X}_{A \cup B} | \mathbf{X}_C = \mathbf{x}_C$, vilken är normalfördelad, följer det enligt Sats 2.4 att $\mathbf{X}_A \perp \mathbf{X}_B | \mathbf{X}_C$ om och endast om $\text{Cov}[\mathbf{X}_A, \mathbf{X}_B | \mathbf{X}_C] = \mathbf{0}$.

För att kontrollera $\text{Cov}[\mathbf{X}_A, \mathbf{X}_B | \mathbf{X}_C] = \mathbf{0}$ skulle vi naturligtvis beräkna först kovariansmatrisen av $\mathbf{X}_{A \cup B} | \mathbf{X}_C = \mathbf{x}_C$:

$$\Sigma_{A \cup B} - \Sigma_{A \cup B, C} \Sigma_{C, C}^{-1} \Sigma_{C, A \cup B}.$$

Enligt nästa sats kan vi bara beräkna rangen av en viss submatris av Σ istället.

Sats 3.1. Låt $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$ och $A, B, C \subseteq [m]$ disjunkta. Matrisen $\Sigma_{A \cup C, B \cup C}$ har rang $|C|$ om och endast om $\mathbf{X}_A \perp \mathbf{X}_B | \mathbf{X}_C$.

Bevis. Med hjälp av Sats 2.3 har vi att den betingade fördelningen för $\mathbf{X}_{A \cup B}$ givet $\mathbf{X}_C = \mathbf{x}_C$ är

$$N\left(\boldsymbol{\mu}_{A \cup B} + \Sigma_{A \cup B, C} \Sigma_{C, C}^{-1}(\mathbf{x}_C - \boldsymbol{\mu}_C), \Sigma_{A \cup B, A \cup B} - \Sigma_{A \cup B, C} \Sigma_{C, C}^{-1} \Sigma_{C, A \cup B}\right).$$

Enligt definitionen av betingat oberoende skulle vi vilja se att $\mathbf{X}_A \perp \mathbf{X}_B$ i denna fördelning för alla $\mathbf{X}_C = \mathbf{x}_C$. Vi kommer se i Sats 3.2 att $\mathbf{X}_A \perp \mathbf{X}_B$ om och endast om $f_{\mathbf{X}_A | \mathbf{X}_B}(\mathbf{x}_A | \mathbf{x}_B) = f_{\mathbf{X}_A}(\mathbf{x}_A)$. Vi har dock att denna ekvivalens av fördelningar stämmer om och endast om dessa två normalfördelningar har samma kovariansmatris; det vill säga,

$$\Sigma_{A, A} - \Sigma_{A, B} \Sigma_{B, B}^{-1} \Sigma_{B, A} = \Sigma_{A, A}.$$

Eftersom $\Sigma_{B, B}^{-1}$ är positivt definit har den full rang. Så denna likhet stämmer om och endast om $\Sigma_{A, B} = 0$. (Vi har nu formellt bevisat att $\mathbf{X}_A \perp \mathbf{X}_B | \mathbf{X}_C$ om och endast om $\text{Cov}[\mathbf{X}_A, \mathbf{X}_B | \mathbf{X}_C] = \mathbf{0}$ vilket vi noterade i diskussionen ovan.)

Det följer att $\mathbf{X}_A \perp \mathbf{X}_B | \mathbf{X}_C$ om och endast om

$$\mathbf{0} = \left(\Sigma_{A \cup B, A \cup B} - \Sigma_{A \cup B, C} \Sigma_{C, C}^{-1} \Sigma_{C, A \cup B} \right)_{A, B} = \Sigma_{A, B} - \Sigma_{A, C} \Sigma_{C, C}^{-1} \Sigma_{C, B}.$$

Formeln till höger är schurkomplementet $\Sigma_{A \cup C, B \cup C} / \Sigma_{C, C}$ av matrisen

$$\Sigma_{A \cup C, B \cup C} = \begin{bmatrix} \Sigma_{A, B} & \Sigma_{A, C} \\ \Sigma_{C, B} & \Sigma_{C, C} \end{bmatrix}.$$

Har använder vi schurkomplementet $M/D = A - BD^{-1}C$ för matrisen

$$M = \begin{bmatrix} A & B \\ C & D \end{bmatrix}$$

istället för schurkomplementet $M/A = D - CA^{-1}B$ som användes i Kapitel 2. För schurkomplementet M/D har vi *Guttman's rangsummeformel* som säger att

$$\text{rang}(M) = \text{rang}(D) + \text{rang}(A - BD^{-1}C).$$

(Denna formel följer från t.ex. en singularvärdesuppdelning av M .) I vårt fall blir formeln

$$\text{rang}(\Sigma_{A \cup C, B \cup C}) = \text{rang}(\Sigma_{C, C}) + \text{rang}(\Sigma_{A, B} - \Sigma_{A, C} \Sigma_{C, C}^{-1} \Sigma_{C, B}).$$

Eftersom $\Sigma_{C, C}$ är positivt definit har den rang $|C|$. Därför följer det att schurkomplementet $\Sigma_{A \cup B, A \cup B} / \Sigma_{C, C} = \mathbf{0}$ om och endast om $\text{rang}(\Sigma_{A \cup C, B \cup C}) = |C|$, vilket skulle bevisas. $\square$

Exempel 3.3. Vi återgår till vårt glödlampsexempel, där $\mathbf{X} = [X_1, X_2, X_3]^T$ har fördelningen

$$f_{\mathbf{X}}(x_1, x_2, x_3) = \frac{1}{4}e^{-(x_2+x_3)/2} \quad \text{för } 0 < x_1 < x_2 < +\infty \text{ och } 0 < x_1 < x_3 < +\infty,$$

så vi i Exempel 2.11 att

$$f_{X_2, X_3 | X_1}(x_2, x_3 | x_1) = \frac{1}{4}e^{-(x_2+x_3-2x_1)/2}$$

och

$$f_{X_2 | X_1}(x_2 | x_1) = \frac{1}{2}e^{-(x_2-x_1)/2}.$$

På samma sätt har vi att

$$f_{X_3 | X_1}(x_3 | x_1) = \frac{1}{2}e^{-(x_3-x_1)/2}.$$

Det följer att

$$f_{\mathbf{X}_{\{2,3\}} | X_1}(x_2, x_3 | x_1) = f_{X_2 | X_1}(x_2 | x_1)f_{X_3 | X_1}(x_3 | x_1);$$

det vill säga att $X_2 \perp\!\!\!\perp X_3 | X_1$. Det är också en bra övning att kontrollera att $X_2 \not\perp\!\!\!\perp X_3$.

Som vi såg i beviset för Sats 3.1 kan det vara användbart att ha olika sätt att verifiera betingat oberoende:

Sats 3.2. Låt $\mathbf{X} = [X_1, \dots, X_m]^T$ ha täthetsfunktion (eller sannolikhetsfunktion) $f_{\mathbf{X}}(x_1, \dots, x_m) > 0$ för alla simultana utfall $[x_1, \dots, x_m]^T$. Låt $A, B, C \subseteq [m]$ vara disjunkta. Följande är ekvivalent:

- (a) $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_C$,
- (b) $f_{\mathbf{X}_A | \mathbf{X}_{B \cup C}}(\mathbf{x}_A | \mathbf{x}_B, \mathbf{x}_C) = f_{\mathbf{X}_A | \mathbf{X}_C}(\mathbf{x}_A | \mathbf{x}_C)$ för alla $\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C$, och
- (c) $f_{\mathbf{X}_A | \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A | \mathbf{x}_B, \mathbf{x}_C) = f_{\mathbf{X}_A | \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A | \mathbf{x}'_B, \mathbf{x}_C)$ för alla $\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C$ och alla $\mathbf{x}'_B \neq \mathbf{x}_B$.

Bevis. Vi ska bevisa att (a) och (b) är ekvivalent i övning 3, uppgift 8(b). Så visar vi bara att (b) och (c) är ekvivalena. Anta att (b) stämmer. Då har vi att

$$f_{\mathbf{X}_A | \mathbf{X}_{B \cup C}}(\mathbf{x}_A | \mathbf{x}_B, \mathbf{x}_C) = f_{\mathbf{X}_A | \mathbf{X}_C}(\mathbf{x}_A | \mathbf{x}_C)$$

för alla $\mathbf{x}_A$ och $\mathbf{x}_C$ och en given $\mathbf{x}_B$. På samma sätt har vi också

$$f_{\mathbf{X}_A | \mathbf{X}_{B \cup C}}(\mathbf{x}_A | \mathbf{x}'_B, \mathbf{x}_C) = f_{\mathbf{X}_A | \mathbf{X}_C}(\mathbf{x}_A | \mathbf{x}_C)$$

för alla $\mathbf{x}_A$ och $\mathbf{x}_C$ och en given $\mathbf{x}'_B \neq \mathbf{x}_B$. Det följer att (c) stämmer.

Nu anta att (c) stämmer. Per definition av betingade fördelningar har vi

$$\frac{f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C)}{f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_B, \mathbf{x}_C)} = \frac{f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}'_B, \mathbf{x}_C)}{f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}'_B, \mathbf{x}_C)},$$

eller

$$f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C)f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}'_B, \mathbf{x}_C) = f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}'_B, \mathbf{x}_C)f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_B, \mathbf{x}_C).$$

Om vi integrerar med avseende på variablen $\mathbf{x}'_B$ får vi

$$\begin{aligned} \int f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C)f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}'_B, \mathbf{x}_C)d\mathbf{x}'_B &= \int f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}'_B, \mathbf{x}_C)f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_B, \mathbf{x}_C)d\mathbf{x}'_B, \\ f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C) \left(\int f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}'_B, \mathbf{x}_C)d\mathbf{x}'_B \right) &= \left(\int f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}'_B, \mathbf{x}_C)d\mathbf{x}'_B \right) f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_B, \mathbf{x}_C), \\ f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C)f_{\mathbf{X}_C}(\mathbf{x}_C) &= f_{\mathbf{X}_A, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_C)f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_B, \mathbf{x}_C), \\ \frac{f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C)}{f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_B, \mathbf{x}_C)} &= \frac{f_{\mathbf{X}_A, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_C)}{f_{\mathbf{X}_C}(\mathbf{x}_C)}, \\ f_{\mathbf{X}_A | \mathbf{X}_{B \cup C}}(\mathbf{x}_A | \mathbf{x}_B, \mathbf{x}_C) &= f_{\mathbf{X}_A | \mathbf{X}_C}(\mathbf{x}_A | \mathbf{x}_C) \end{aligned}$$

vilket skulle visas. □

Villkor (2) i Sats 3.2 passar bra ihop med kedjereglen från det föregående kapitlet. I sin mer allmänna form blir kedjereglen följande:

Sats 3.3 (Kedjereglen). *För en stokastisk vektor $\mathbf{X} = [X_1, \dots, X_m]^T$ gäller det att*

$$f_{\mathbf{X}}(x_1, \dots, x_m) = \prod_{i=1}^m f_{X_i|\mathbf{X}_{[i-1]}}(x_i|\mathbf{x}_{[i-1]}).$$

Bevis. Per definition av en betingad fördelning har vi att

$$\prod_{i=1}^m f_{X_i|\mathbf{X}_{[i-1]}}(x_i|\mathbf{x}_{[i-1]}) = \frac{f_{\mathbf{X}}(\mathbf{x})}{f_{\mathbf{X}_{[m-1]}}(\mathbf{x}_{[m-1]})} \cdot \frac{f_{\mathbf{X}_{[m-1]}}(\mathbf{x}_{[m-1]})}{f_{\mathbf{X}_{[m-2]}}(\mathbf{x}_{[m-2]})} \dots \frac{f_{\mathbf{X}_{[2]}}(\mathbf{x}_{[2]})}{f_{X_1}(x_1)} f_{X_1}(x_1) = f_{\mathbf{X}}(\mathbf{x}).$$

□

Exempel 3.4. För glödlamporna i Exempel 2.11 har vi

$$f_{X_1, X_2, X_3}(x_1, x_2, x_3) = f_{X_2, X_3, X_1}(x_2, x_3, x_1) = f_{X_2|\mathbf{X}_{\{1,3\}}}(x_2|x_1, x_3) f_{X_3|X_1}(x_3|x_1) f_{X_1}(x_1).$$

Vi såg i Exempel 3.3 att $X_3 \perp\!\!\!\perp X_2|X_1$. Med hjälp av Sats 3.2 (2) kan vi förenkla faktoriseringen av fördelningen som

$$f_{X_1, X_2, X_3}(x_1, x_2, x_3) = f_{X_2|X_1}(x_2|x_1) f_{X_3|X_1}(x_3|x_1) f_{X_1}(x_1).$$

I Exempel 1.4 såg vi att det är möjligt att specificera en simultan fördelning med hjälp av en sekvens av ekvationer som definierar varje stokastisk variabel som en funktion av de andra. Vi observerade även (med hjälp av korrelationen när $\lambda = 0$) att för sådana fördelningar kan vi få oberoende när en variabel definieras av en funktion som inte beror på de andra variablerna. Närmare bestämt, får vi i Exempel 1.4 att X_2 definieras som $X_2 = f(N_2) = N_2$ när $\lambda = 0$. Vi såg i denna situation att $X_2 \perp\!\!\!\perp X_1$. Nu kan vi formulera denna observation som en sats om betingat oberoende. Först bevisar vi följande resultat som gäller för diskreta såväl som kontinuerliga fördelningar.

Sats 3.4. *Låt $\mathbf{X} = [X_1, \dots, X_d]^T$ och $A, B, C \subseteq [d]$ med $A, B \neq \emptyset$ för vilken $A \cap B = A \cap C = B \cap C = \emptyset$ och $A \cup B \cup C = [d]$. Då har vi $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B|\mathbf{X}_C$ om och endast om det existerar funktioner $h(\mathbf{x}_A, \mathbf{x}_C)$ och $k(\mathbf{x}_B, \mathbf{x}_C)$ så att*

$$f_{\mathbf{X}}(x_1, \dots, x_d) = h(\mathbf{x}_A, \mathbf{x}_C) k(\mathbf{x}_B, \mathbf{x}_C).$$

Bevis. Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B|\mathbf{X}_C$ har vi enligt definitionen för betingat oberoende att

$$f_{\mathbf{X}}(x_1, \dots, x_d) = f_{\mathbf{X}_A|\mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_C) f_{\mathbf{X}_B|\mathbf{X}_C}(\mathbf{x}_B|\mathbf{x}_C).$$

Eftersom $f_{\mathbf{X}_A|\mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_C)$ och $f_{\mathbf{X}_B|\mathbf{X}_C}(\mathbf{x}_B|\mathbf{x}_C)$ bara är funktioner som beror på $\mathbf{x}_A, \mathbf{x}_C$ respektive $\mathbf{x}_B, \mathbf{x}_C$ kan vi ta

$$h(\mathbf{x}_A, \mathbf{x}_C) = f_{\mathbf{X}_A|\mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_C) \quad \text{och} \quad k(\mathbf{x}_B, \mathbf{x}_C) = f_{\mathbf{X}_B|\mathbf{X}_C}(\mathbf{x}_B|\mathbf{x}_C).$$

Detta visar "endast om" delen. Å andra sidan antar vi att det existerar funktioner $h(\mathbf{x}_A, \mathbf{x}_C)$ och $k(\mathbf{x}_B, \mathbf{x}_C)$ så att

$$f_{\mathbf{X}}(x_1, \dots, x_d) = h(\mathbf{x}_A, \mathbf{x}_C) k(\mathbf{x}_B, \mathbf{x}_C).$$

Det följer att

$$f_{\mathbf{X}_A|\mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_C) = \frac{\int_{\mathbb{R}^{|B|}} f_{\mathbf{X}}(x_1, \dots, x_d) d\mathbf{x}_B}{f_{\mathbf{X}_C}(\mathbf{x}_C)} = \frac{\int_{\mathbb{R}^{|B|}} h(\mathbf{x}_A, \mathbf{x}_C) k(\mathbf{x}_B, \mathbf{x}_C) d\mathbf{x}_B}{f_{\mathbf{X}_C}(\mathbf{x}_C)} = \frac{h(\mathbf{x}_A, \mathbf{x}_C) \int_{\mathbb{R}^{|B|}} k(\mathbf{x}_B, \mathbf{x}_C) d\mathbf{x}_B}{f_{\mathbf{X}_C}(\mathbf{x}_C)}.$$

På samma sätt har vi

$$f_{\mathbf{X}_B|\mathbf{X}_C}(\mathbf{x}_B|\mathbf{x}_C) = \frac{k(\mathbf{x}_B, \mathbf{x}_C) \int_{\mathbb{R}^{|A|}} h(\mathbf{x}_A, \mathbf{x}_C) d\mathbf{x}_A}{f_{\mathbf{X}_C}(\mathbf{x}_C)}.$$

Det följer därefter att

$$\begin{aligned}
 f_{\mathbf{X}_A|\mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_C)f_{\mathbf{X}_B|\mathbf{X}_C}(\mathbf{x}_B|\mathbf{x}_C) &= \left(\frac{h(\mathbf{x}_A, \mathbf{x}_C) \int_{\mathbb{R}^{|B|}} k(\mathbf{x}_B, \mathbf{x}_C) d\mathbf{x}_B}{f_{\mathbf{X}_C}(\mathbf{x}_C)} \right) \left(\frac{k(\mathbf{x}_B, \mathbf{x}_C) \int_{\mathbb{R}^{|A|}} h(\mathbf{x}_A, \mathbf{x}_C) d\mathbf{x}_A}{f_{\mathbf{X}_C}(\mathbf{x}_C)} \right), \\
 &= \frac{h(\mathbf{x}_A, \mathbf{x}_C)k(\mathbf{x}_B, \mathbf{x}_C) \int_{\mathbb{R}^{|A|}} h(\mathbf{x}_A, \mathbf{x}_C) d\mathbf{x}_A \int_{\mathbb{R}^{|B|}} k(\mathbf{x}_B, \mathbf{x}_C) d\mathbf{x}_B}{f_{\mathbf{X}_C}(\mathbf{x}_C)^2}, \\
 &= \frac{f_{\mathbf{X}}(x_1, \dots, x_d) \int_{\mathbb{R}^{|A \cup B|}} h(\mathbf{x}_A, \mathbf{x}_C)k(\mathbf{x}_B, \mathbf{x}_C) d\mathbf{x}_{A \cup B}}{f_{\mathbf{X}_C}(\mathbf{x}_C)^2}, \\
 &= \frac{f_{\mathbf{X}}(x_1, \dots, x_d) \int_{\mathbb{R}^{|A \cup B|}} f_{\mathbf{X}}(x_1, \dots, x_d) \mathbf{x}_{A \cup B}}{f_{\mathbf{X}_C}(\mathbf{x}_C)^2}, \\
 &= \frac{f_{\mathbf{X}}(x_1, \dots, x_d) f_{\mathbf{X}_C}(\mathbf{x}_C)}{f_{\mathbf{X}_C}(\mathbf{x}_C)^2}, \\
 &= \frac{f_{\mathbf{X}}(x_1, \dots, x_d)}{f_{\mathbf{X}_C}(\mathbf{x}_C)}, \\
 &= f_{\mathbf{X}_{A \cup B}|\mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B|\mathbf{x}_C).
 \end{aligned}$$

Det vill säga att $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B|\mathbf{X}_C$, vilket skulle visas. $\square$

Sats 3.4 betyder att vi kan läsa av betingat oberoende direkt från formen av den simultana täthetsfunktionen (eller sannolikhetsfunktionen). På samma sätt är det möjligt att se betingat oberoende från formen av täthetsfunktionen (eller sannolikhetsfunktionen) för en viss stokastisk variabel.

Följdsats 3.1. Låt $\mathbf{X}_A, \mathbf{X}_B$ och $\mathbf{X}_C$ vara stokastiska vektorer där $A \cap B = A \cap C = B \cap C = \emptyset$. Vi har att $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B|\mathbf{X}_C$ om och endast om det existerar en funktion $h(\mathbf{x}_A, \mathbf{x}_C)$ så att $f_{\mathbf{X}_A|\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_B, \mathbf{x}_C) = h(\mathbf{x}_A, \mathbf{x}_C)$.

Bevis. Anta först att $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B|\mathbf{X}_C$. Med hjälp av Sats 3.2 har vi att

$$f_{\mathbf{X}_A|\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_B, \mathbf{x}_C) = f_{\mathbf{X}_A|\mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_C).$$

Så vi kan låta $h(\mathbf{x}_A, \mathbf{x}_C) = f_{\mathbf{X}_A|\mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_C)$. Detta visar "endast om" delen.

Å andra sidan, om vi antar att det finns en funktion $h(\mathbf{x}_A, \mathbf{x}_C)$ så att

$$f_{\mathbf{X}_A|\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_B, \mathbf{x}_C) = h(\mathbf{x}_A, \mathbf{x}_C),$$

har vi även

$$\begin{aligned}
 f_{\mathbf{X}_A|\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A|\mathbf{x}_B, \mathbf{x}_C) &= h(\mathbf{x}_A, \mathbf{x}_C), \\
 \frac{f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C)}{f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_B, \mathbf{x}_C)} &= h(\mathbf{x}_A, \mathbf{x}_C), \\
 f_{\mathbf{X}_A, \mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_A, \mathbf{x}_B, \mathbf{x}_C) &= h(\mathbf{x}_A, \mathbf{x}_C) f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_B, \mathbf{x}_C).
 \end{aligned}$$

När vi låter $k(\mathbf{x}_B, \mathbf{x}_C) = f_{\mathbf{X}_B, \mathbf{X}_C}(\mathbf{x}_B, \mathbf{x}_C)$ har vi $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B|\mathbf{X}_C$ med hjälp av Sats 3.4. $\square$

Exempel 3.5. Vi såg i Exempel 1.4 att ett sätt att definiera en simultan fördelning är att specificera en sekvens av ekvationer som definierar varje stokastisk variabel som en funktion av andra variabler. Till exempel kan vi definiera den simultana fördelningen för $\mathbf{X} = [X_1, X_2, X_3]^T$ med

$$\begin{aligned}
 X_1 &= N_1, \\
 X_2 &= 3X_1 + N_2, \\
 X_3 &= 2X_1 + N_2.
 \end{aligned}$$

där N_1, N_2, N_3 är oberoende och $N(0, 1)$ -fördelade. Vi kan se direkt från detta att X_2 definieras som en funktion av stokastiska variabler som inte beror på X_3 . Givet $X_1 = x_1$ har vi egentligen att $X_2 = 3x_1 + N_2$ och därför är fördelningen bara en funktion av x_1 och N_2 och kan därför inte bero på X_3 (alla bidrag från X_3 till X_2 måste komma igenom X_1 men inget sådant bidrag inträffar när $X_1 = x_1$ är fixt). Det vill säga att $X_2 \perp\!\!\!\perp X_3|X_1$! Vi kan se detta på ett formellt sätt med hjälp av Följdsats 3.1.

Låt $\mathbf{N} = [N_1, N_2, N_3]^T$. Vi noterar att

$$\mathbf{X} = \Lambda \mathbf{X} + \mathbf{N}$$

där

$$\Lambda = \begin{bmatrix} 0 & 0 & 0 \\ 3 & 0 & 0 \\ 2 & 0 & 0 \end{bmatrix}.$$

Det följer att $\mathbf{X} = (\mathbf{I} - \Lambda)^{-1} \mathbf{N}$; det vill säga att $\mathbf{X}$ definieras som en linjär transformation av den stokastiska vektorn $\mathbf{N}$. Med hjälp av Sats 2.2 har vi $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = \mathbf{0} \quad \text{och} \quad \Sigma = \begin{bmatrix} 1 & 0 & 0 \\ 3 & 1 & 0 \\ 2 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 3 & 2 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 3 & 2 \\ 3 & 10 & 6 \\ 2 & 6 & 5 \end{bmatrix}.$$

Sats 2.3 ger oss $X_2|X_1 = x_1, X_3 = x_3 \sim \mathcal{N}(\mu', \eta^2)$ där

$$\mu' = 0 + \Sigma_{2,\{1,3\}} \Sigma_{\{1,3\},\{1,3\}}^{-1} (\mathbf{0} - [x_1, x_3]^T) = 0 + \begin{bmatrix} 3 & 6 \end{bmatrix} \begin{bmatrix} 5 & -2 \\ -2 & 1 \end{bmatrix} \begin{bmatrix} -x_1 \\ -x_3 \end{bmatrix} = -15x_1 + 6x_3 + 12x_1 - 6x_3 = -3x_1.$$

och

$$\eta^2 = \Sigma_{2,2} - \Sigma_{2,\{1,3\}} \Sigma_{\{1,3\},\{1,3\}}^{-1} \Sigma_{\{1,3\},2} = 10 - \begin{bmatrix} 3 & 6 \end{bmatrix} \begin{bmatrix} 5 & -2 \\ -2 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 6 \end{bmatrix} = 1.$$

Därför har $X_2|X_1 = x_1, X_3 = x_3$ täthetsfunktionen


$$f_{X_2|X_1, X_3}(x_2|x_1, x_3) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x_2 + 3x_1)^2}.$$

Eftersom detta är inte en funktion som beror på x_3 har vi $X_2 \perp\!\!\!\perp X_3|X_1$ med hjälp av Följdsats 3.1.


Å andra sidan, om vi försöker att skriva marginalfördelningen för $[X_2, X_3]^T$ som

$$f_{X_2, X_3}(x_2, x_3) = h(x_2)k(x_3)$$

kommer vi att misslyckas. Det vill säga att $X_2 \not\perp\!\!\!\perp X_3$. Vi kan se detta med hjälp av simulering och korrelationer:



(a) 500 slumpmässiga utfall från $[X_2, X_3]^T|X_1 = 0.5$.



(b) 500 slumpmässiga utfall från $[X_2, X_3]^T$.

Betingat oberoende är kanske bland ett av de viktigaste begreppen inom statistik. Vi kommer att utveckla metoder senare i boken för att bestämma om vi kan anta relationer för betingat oberoende mellan variabler i komplexa system. När vi kan göra detta får vi en djupare förståelse för komplexa system av interaktioner samt möjligheten att minska komplexiteten i att modellera sådana system. Samtidigt är betingat oberoende ett kraftfullt sätt att lägga in expertkunskap eller antaganden till en statistik modell som vi bildar för att studera sådana komplexa system. Som ett första exempel på hur vi kan använda betingat oberoende när vi bildar och analyserar statistiska modeller kan vi betrakta klassen av modeller som kallas för *hierarkiska modeller*.

3.2 Hierarkiska modeller

Hittills har vi bara betraktat modeller $[X_1, \dots, X_m]^T$ med parameterar $\theta_1, \dots, \theta_d$ som är fixa. Det kan också vara användbart att betrakta modeller för vilka parameterarna kan variera enligt någon fördelning. För sådana modeller kan kedjereglen hjälpa oss att beräkna intressanta värden – exempelvis, väntevärdet.

Exempel 3.6. Anta att en insekt lägger ett stort antal ägg och varje ägg överlever med sannolikheten p . (Vi antar att äggens överlevnad är oberoende.) Vi vill beräkna väntevärdet av antalet ägg som överlever. Detta väntevärde beror naturligtvis på antal ägg produceras.

Låt N vara antalet ägg som produceras och X antalet ägg som överlever. Vi kan modellera N med en Poissonfördelning med parameter λ ; dvs. $N \sim \text{Po}(\lambda)$. Den betingade fördelningen $X|N = n$ modelleras som $\text{Bin}(n, p)$. Så den *hierarkiska modellen* är

$$\begin{aligned} X|N = n &\sim \text{Bin}(n, p), \\ N &\sim \text{Po}(\lambda). \end{aligned}$$

Notera att $X|N = n$ har sannolikhetsfunktion $f_{X|N}(x|n)$.

För att beräkna väntevärdet $E[X]$ kan vi börja med den simultana fördelningen $f_{X,N}(x, n)$ och hitta marginalfördelningen $f_X(x)$. Kedjereglen säger att

$$f_{X,N}(x, n) = f_{X|N}(x|n)f_N(n) = \binom{n}{x} p^x (1-p)^{n-x} \frac{\lambda^n e^{-\lambda}}{n!}.$$

Därför kan vi beräkna

$$\begin{aligned} f_X(x) &= \sum_{n=0}^{\infty} \binom{n}{x} p^x (1-p)^{n-x} \frac{\lambda^n e^{-\lambda}}{n!}, \\ &= \sum_{n=x}^{\infty} \binom{n}{x} p^x (1-p)^{n-x} \frac{\lambda^n e^{-\lambda}}{n!}, \quad \left(\binom{n}{x} = 0 \text{ om } n < x \right) \\ &= \frac{\lambda^x}{\lambda^x} \sum_{n=x}^{\infty} \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} \frac{\lambda^n e^{-\lambda}}{n!}, \\ &= \frac{(\lambda p)^x e^{-\lambda}}{x!} \sum_{n=x}^{\infty} \frac{(1-p)^{n-x} \lambda^{n-x}}{(n-x)!}, \\ &= \frac{(\lambda p)^x e^{-\lambda}}{x!} \sum_{k=0}^{\infty} \frac{(\lambda(1-p))^k}{k!}, \quad (\text{låt } k = n - x) \\ &= \frac{(\lambda p)^x e^{-\lambda}}{x!} e^{(1-p)\lambda}, \\ &= \frac{(\lambda p)^x e^{-\lambda p}}{x!}. \end{aligned}$$

Därför är $X \sim \text{Po}(\lambda p)$ och vi har att $E[X] = \lambda p$.

Låt X och Y vara stokastiska variabler. Den betingade fördelningen $f_{X|Y}(x|y)$ har väntevärdet

$$E[X|Y = y] = \int x f_{X|Y}(x|y) dx.$$

Som vi såg redan kan vi betrakta $E[X|Y = y]$ som en funktion av y , dvs. $g(y) = E[X|Y = y]$ och därmed kan vi definiera den betingade väntevärdet som den stokastiska variabeln $E[X|Y] = g(Y)$. I Exempel 3.6 ville vi att beräkna $E[X]$. Följande låter oss att göra det utan att beräkna marginalfördelningen.

Sats 3.5 (Lagen om total förväntan). *Om X och Y är stokastiska variabler har vi att*

$$E[X] = E[E[X|Y]].$$

Bevis. Om $f_{X,Y}(x,y)$ är den simultana fördelningen av X och Y har vi

$$\begin{aligned} E[X] &= \int \int x f_{X,Y}(x,y) dx dy, \\ &= \int \int x f_{X|Y}(x|y) f_Y(y) dx dy, \\ &= \int \left(\int x f_{X|Y}(x|y) dx \right) f_Y(y) dy, \\ &= \int E[X|Y=y] f_Y(y) dy, \\ &= E[g(Y)], \end{aligned}$$

där $g(y) = E[X|Y=y]$. □

Lagen om total förväntan gör det lättare att beräkna väntevärden inom hierarkiska modeller. Som ett första exempel betraktar vi följande:

Exempel 3.7. För den hierarkiska modellen i Exempel 3.6 har vi

$$\begin{aligned} E[X] &= E[E[X|N]], \\ &= E[Np], & (X|N=n \sim \text{Bin}(n,p)) \\ &= p E[N], \\ &= \lambda p. & (N \sim \text{Po}(\lambda)) \end{aligned}$$

Vi kan bestämma formler för varianser på samma sätt. Med hjälp av formeln som vi såg redan för den betingade kovariansen ser vi att variansen av $X|Y=y$ är

$$\text{Var}[X|Y=y] = E[X^2|Y=y] - E[X|Y=y]^2.$$

På samma sätt som $E[X|Y]$ kan vi definiera funktionen $g(y) = \text{Var}[X|Y=y]$. Då har vi den stokastiska variabeln $\text{Var}[X|Y] = g(Y)$.

Sats 3.6 (Lagen om total varians). *Låt X och Y vara stokastiska variabler. Då har vi att*

$$\text{Var}[X] = E[\text{Var}[X|Y]] + \text{Var}[E[X|Y]].$$

Bevis. Per definitionen av $\text{Var}[X]$ har vi

$$\text{Var}[X] = E[(X - E[X])^2] = E[(X - E[X|Y] + E[X|Y] - E[X])^2],$$

där vi subtraherade och adderade $E[X|Y]$. Om vi expanderar kvadraten får vi

$$\text{Var}[X] = E[(X - E[X|Y])^2] + E[(E[X|Y] - E[X])^2] + 2E[(X - E[X|Y])(E[X|Y] - E[X])].$$

Vi ska visa att den sista termen är lika med 0. Med hjälp av Sats 3.5 har vi att

$$E[(X - E[X|Y])(E[X|Y] - E[X])] = E[E[(X - E[X|Y])(E[X|Y] - E[X])|Y]].$$

I den betingade fördelningen $X|Y=y$ är X stokastisk. Det följer att $E[X|Y]$ och $E[X]$ är konstanter i

$$E[(X - E[X|Y])(E[X|Y] - E[X])|Y],$$

och $E[X|Y] - E[X]$ också är en konstant. Därför har vi

$$\begin{aligned} E[(X - E[X|Y])(E[X|Y] - E[X])|Y] &= (E[X|Y] - E[X]) E[(X - E[X|Y])|Y], \\ &= (E[X|Y] - E[X])(E[X|Y] - E[X|Y]), \\ &= (E[X|Y] - E[X])(0), \\ &= 0. \end{aligned}$$

Så följer det att

$$\begin{aligned}\text{Var}[X] &= \text{E}[(X - \text{E}[X|Y])^2] + \text{E}[(\text{E}[X|Y] - \text{E}[X])^2] + 2\text{E}[(X - \text{E}[X|Y])(\text{E}[X|Y] - \text{E}[X])], \\ &= \text{E}[(X - \text{E}[X|Y])^2] + \text{E}[(\text{E}[X|Y] - \text{E}[X])^2].\end{aligned}$$

På samma sätt (med hjälp av Sats 3.5) ser vi också att

$$\begin{aligned}\text{E}[(X - \text{E}[X|Y])^2] &= \text{E}[\text{E}[(X - \text{E}[X|Y])^2|Y]], \\ &= \text{E}[\text{Var}[X|Y]],\end{aligned}$$

och

$$\text{E}[(\text{E}[X|Y] - \text{E}[X])^2] = \text{Var}[\text{E}[X|Y]].$$

□

På samma sätt som lagen om total förväntan gör lagen om total varians det lättare att beräkna varianser inom hierarkiska modeller.

Exempel 3.8. För den hierarkiska modellen

$$\begin{aligned}X|N = n &\sim \text{Bin}(n, p), \\ N &\sim \text{Po}(\lambda)\end{aligned}$$

från Exempel 3.6 ger Satsen 3.6

$$\begin{aligned}\text{Var}[X] &= \text{E}[\text{Var}[X|N]] + \text{Var}[\text{E}[X|N]], \\ &= \text{E}[Np(1-p)] + \text{Var}[Np], \\ &= p(1-p)\text{E}[N] + p^2\text{Var}[N], \\ &= \lambda p(1-p) + \lambda p^2, \\ &= \lambda p.\end{aligned}$$

Resultatet stämmer eftersom vi har redan sett att $X \sim \text{Po}(\lambda p)$.

Vi kan bilda en annan hierarkisk modell genom att specificera en fördelning på parametern p i en binomialmodell.

Exempel 3.9. Låt n vara ett fixt positivt heltal och

$$\begin{aligned}X|\Theta = \theta &\sim \text{Bin}(n, \theta), \\ \Theta &\sim \text{Beta}(3, 2).\end{aligned}$$

Detta borde kännas bekant om vi tänker tillbaka på hur vi specificerar en apriorifördelning i ett av de första exemplen på en bayesiansk modell. Med hjälp av Sats 3.5 kan vi beräkna väntevärdet $\text{E}[X]$ som

$$\text{E}[X] = \text{E}[\text{E}[X|\Theta]] = \text{E}[n\Theta] = n\text{E}[\Theta] = n\frac{3}{2+3} = \frac{3n}{5}.$$

Med hjälp av Sats 3.6 kan vi även beräkna variansen $\text{Var}[X]$:

$$\begin{aligned}\text{Var}[X] &= \text{E}[\text{Var}[X|\Theta]] + \text{Var}[\text{E}[X|\Theta]], \\ &= \text{E}[n\Theta(1-\Theta)] + \text{Var}[n\Theta], \\ &= n\text{E}[\Theta] - n\text{E}[\Theta^2] + n^2\text{Var}[\Theta], \\ &= n\frac{3}{2+3} - n(\text{Var}[\Theta] + \text{E}[\Theta]^2) + n^2\text{Var}[\Theta], \\ &= \frac{3n}{5} - n\left(\frac{3}{5}\right)^2 + (n^2 - n)\text{Var}[\Theta], \\ &= \frac{6n}{25} + n(n-1)\frac{(3)(2)}{(3+2)^2(3+2+1)}, \\ &= \frac{6n}{25} + \frac{6n(n-1)}{(25)(7)}, \\ &= \frac{42n + 6n(n-1)}{175}, \\ &= \frac{6n(n+6)}{175}.\end{aligned}$$

Vi kan också bilda hierarkiska modeller där två eller fler parametrar kan variera. Nu blir det användbart att använda betingat oberoende.

Exempel 3.10. Låt

$$\begin{aligned} U|X = x &\sim U(0, x + 1), \\ X|\Theta = \theta &\sim \text{Bin}(n, \theta), \\ \Theta &\sim \text{Beta}(3, 2), \end{aligned}$$

där n är ett positivt heltal och $U \perp\!\!\!\perp \Theta|X$. Det följer med hjälp av kedjeregeln (Sats 3.3) och Sats 3.2(a) att

$$\begin{aligned} f_{U,X,\Theta}(u, x, \theta) &= f_{U|X,\Theta}(u|x, \theta) f_{X|\Theta}(x|\theta) f_{\Theta}(\theta), & (\text{kedjeregeln}) \\ &= f_{U|X}(u|x) f_{X|\Theta}(x|\theta) f_{\Theta}(\theta) & (U \perp\!\!\!\perp \Theta|X). \end{aligned}$$

Vi kan göra detsamma som i beviset för Sats 3.5 för att se varför lagen om total förväntan kallas också för *tornregeln* (*tower rule* på engelska):

$$\begin{aligned} E[U] &= \int \int \int u f_{U,X,\Theta}(u, x, \theta) du dx d\theta, \\ &= \int \int \int u f_{U|X}(u|x) f_{X|\Theta}(x|\theta) f_{\Theta}(\theta) du dx d\theta, \\ &= \int \int \left(\int u f_{U|X}(u|x) du \right) f_{X|\Theta}(x|\theta) f_{\Theta}(\theta) dx d\theta, \\ &= \int \int E[U|X = x] f_{X|\Theta}(x|\theta) f_{\Theta}(\theta) dx d\theta, \\ &= \int \left(\int E[U|X = x] f_{X|\Theta}(x|\theta) dx \right) f_{\Theta}(\theta) d\theta, \\ &= \int E[E[U|X]|\Theta = \theta] f_{\Theta}(\theta) d\theta, \\ &= E[E[E[U|X]|\Theta]], \end{aligned}$$

det vill säga

$$E[U] = E[E[E[U|X]|\Theta]].$$

Vi kan nu beräkna $E[U]$ som

$$\begin{aligned} E[U] &= E[E[(X + 1)/2|\Theta]], \\ &= E[(n\Theta + 1)/2], \\ &= \frac{(3/5)n + 1}{2}, \\ &= \frac{3n + 5}{10}. \end{aligned}$$

Till exempel har vi $E[U] = 0.8$ när $n = 1$. Eftersom $E[\Theta] = 3/5$ är det lite mer sannolikt att $X = 1$ i vilket fall $U \sim U(0, 2)$ och har väntevärdet 1. Men det är fortfarande möjligt att $X = 0$. I detta fall $U \sim U(0, 1)$, vilket har väntevärdet 0.5. Eftersom vi förväntar $X = 1$ oftare än $X = 0$ stämmer det att $E[U]$ är lite mindre än 1 men närmare 1 än 0.5.

Vi kan bilda mer komplex hierarki med hjälp av antaganden för betingat oberoende. I sin tur kan dessa antaganden hjälpa när vi beräknar väntevärden.

Exempel 3.11. Betrakta den hierarkiska modellen

$$\begin{aligned} Y|X_1 = x_1, X_2 = x_2 &\sim N(x_1 x_2, 1), \\ X_1|\Theta = \theta &\sim N(\theta, 3), \\ X_2|\Theta = \theta &\sim N(\theta/2, 10), \\ \Theta &\sim \text{Gamma}(5, 4), \end{aligned}$$

där vi antar att $X_1 \perp\!\!\!\perp X_2 | \Theta$ och $Y \perp\!\!\!\perp \Theta | X_1, X_2$. Med hjälp av lagen om total förväntan har vi

$$\begin{aligned}
 E[Y] &= E[E[Y|X_1, X_2]|\Theta], \\
 &= E[E[X_1 X_2 | \Theta]], \\
 &= E[E[X_1 | \Theta] E[X_2 | \Theta]], \quad (X_1 \perp\!\!\!\perp X_2 | \Theta) \\
 &= E[\Theta(\Theta/2)], \\
 &= \frac{E[\Theta^2]}{2}, \\
 &= \frac{\text{Var}[\Theta] + E[\Theta]^2}{2}, \quad (\text{Var}[\Theta] = E[\Theta^2] - E[\Theta]^2) \\
 &= \frac{1}{2} \left(\frac{5}{4^2} + \frac{5^2}{4^2} \right), \\
 &= \frac{30}{32}.
 \end{aligned}$$

I Exempel 3.10 och 3.11 bildar vi hierarkiska modeller med hjälp av antaganden för betingat oberoende vilka var också användbara när vi beräknade väntevärdena. Naturligtvis är det möjligt att bilda hierarkiska modeller med flera stokastiska variabler som uppfyller flera relationer för betingat oberoende. Sådana modeller kan bli ganska komplicerade att skriva ner trots att de är ofta ganska användbara. I nästa kapitel ska vi betrakta en metod för att representera sådana komplexa modeller med hjälp av grafer. Vi kommer att se att denna metod kan även vara användbar när vi inte vet något a priori om de stokastiska variablerna i systemet och skulle vilja förenkla deras simultana fördelning.

3.3 Uppgifter

3.1. [1] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim N(\mathbf{0}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 1 & 2 & -2 & -12 \\ 2 & 5 & -4 & -27 \\ -2 & -4 & 5 & 27 \\ -12 & -27 & 27 & 163 \end{bmatrix}.$$

Stämmer det att $X_1 \perp\!\!\!\perp X_4 | \mathbf{X}_{\{2,3\}}$?

3.2. [1] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim N(\mathbf{0}, \Sigma)$ där Σ är matrisen i Uppgift 3.1. Stämmer det att $X_1 \perp\!\!\!\perp X_4 | X_3$?

3.3. [1] Låt $\mathbf{X} = [X_1, X_2, X_3] \sim N(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \quad \text{och} \quad \Sigma = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 3 & 3 \\ 2 & 3 & 6 \end{bmatrix}.$$

- (a) Vad är $\text{Cov}[X_1, X_2]$?
- (b) Vad är $\text{Cov}[X_1, X_2 | X_3]$?
- (c) Stämmer det att $X_1 \perp\!\!\!\perp X_2$?
- (d) Stämmer det att $X_1 \perp\!\!\!\perp X_2 | X_3$?

3.4. [2] Låt $\mathbf{X} = [X_1, X_2, X_3]^T$ vara den stokastiska vektorn från Uppgift 3.3. Vad är $\text{Var}[X_3 | X_2]$? Vad är $E[X_3 | X_2]$?

3.5. [1] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5, X_6]^T \sim N(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 3 \\ -2 \\ 0 \\ 1 \\ 3 \end{bmatrix} \quad \text{och} \quad \Sigma = \begin{bmatrix} 1 & 0 & -2 & 4 & 4 & 12 \\ 0 & 1 & 1 & -2 & -2 & -6 \\ -2 & 1 & 6 & -12 & -12 & -36 \\ 4 & -2 & -12 & 25 & 25 & 75 \\ 4 & -2 & -12 & 25 & 26 & 75 \\ 12 & -6 & -36 & 75 & 75 & 226 \end{bmatrix}.$$

- (a) Stämmer det att $X_1 \perp\!\!\!\perp X_2$?
- (b) Vad är $\text{Cov}[X_1, X_3|X_2]$?
- (c) Vad är $\text{Cov}[X_3, X_5|X_2, X_6]$? Stämmer det att $X_3 \perp\!\!\!\perp X_5|X_2, X_6$?
- (d) Stämmer det att $(X_1 + X_2)/2 \perp\!\!\!\perp (X_5 - X_6)/2$?
- (e) Stämmer det att $(X_1 + X_2)/2 \perp\!\!\!\perp (X_5 - X_6)/2|X_3$?
- 3.6.** [1] Ett löpande band med oändligt många urnor på börjar köra. Den i :te urnan innehåller 1 röd boll och $m^i - 1$ svarta bollar där $m \geq 1$. En urna $U = i$ väljs slumpmässigt enligt en geometrisk fördelning, dvs. $U \sim \text{Geom}(p)$ där $0 < p < 1$, och en boll dras slumpmässigt från urnan. Låt X vara den stokastiska variabeln som betecknar färgen av bollen där $X = 1$ motsvarar röd och $X = 0$ motsvarar svart. Vad är $E[X]$?
- 3.7.** [1] Låt X, Y, Z vara oberoende och $N(0, \sigma^2)$ -fördelade. Låt också $V = (X + Y)/(\sqrt{2}Z)$ och $W = (X - Y)/(\sqrt{2}Z)$. Vad är $f_{V,W}(v, w)$? Stämmer det att $W \perp\!\!\!\perp V|Z$?
- 3.8.** [1] Låt $X \sim \text{Gamma}(\theta, 1)$ och $Y \sim \text{Gamma}(\alpha, 1)$. Hur är $Z = X + Y$ och $W = X/(X + Y)$ fördelade? Visa att Z och W är oberoende.
- 3.9.** [1] Låt X och Y vara diskreta stokastiska variabler och anta att

$$f_X(x) = f_{Y|X}(y | x)$$

för alla möjliga utfall $[x, y]^T$ av $[X, Y]^T$. Visa att X och Y är oberoende och likefördelade.

- 3.10.** [1] Låt X, Y, Z vara oberoende stokastiska variabler, och låt $W = X + Z$ och $V = Y + Z$. Visa att $W \perp\!\!\!\perp V|Z$.
- 3.11.** [1] Låt X, Y vara binära stokastiska variabler med simultan sannolikhetsfunktion $f_{X,Y}(x, y)$. Visa att $X \perp\!\!\!\perp Y$ om

$$f_{X,Y}(0, 0) = f_X(0)f_Y(0).$$

- 3.12.** [3] Låt X, Y, Z vara binära stokastiska variabler med simultan sannolikhetsfunktion $f_{X,Y,Z}(x, y, z)$. Stämmer det att

$$f_{X,Y|Z=0}(x, y|0) = f_{X|Z=0}(x|0)f_{Y|Z=0}(y|0)$$

innebär $X \perp\!\!\!\perp Y | Z$?

- 3.13.** [1] Betrakta den simultana fördelningen för $\mathbf{X} = [X_1, X_2, X_3]^T$ där

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= N_2, \\ X_3 &= (0.5)X_1 + (-0.23)X_2 + N_3. \end{aligned}$$

och N_1, N_2, N_3 är oberoende och $N(0, 1)$ -fördelade.

- (a) Stämmer det att $X_1 \perp\!\!\!\perp X_2$?

(b) Stämmer det att $X_1 \perp\!\!\!\perp X_3 \mid X_1$?

3.14. [1] Betrakta den simultana fördelningen för $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ där

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= \lambda_{21}X_1 + N_2, \\ X_3 &= \lambda_{31}X_1 + N_3, \\ X_4 &= \lambda_{42}X_2 + \lambda_{43}X_3 + N_4, \end{aligned}$$

för N_1, N_2, N_3 oberoende och $N(0, 1)$ -fördelade och $\lambda_{21}, \lambda_{31}, \lambda_{42}, \lambda_{43} \neq 0$.

(a) Stämmer det att $X_2 \perp\!\!\!\perp X_3 \mid X_1$?

(b) Stämmer det att $X_2 \perp\!\!\!\perp X_3 \mid X_1, X_4$?

3.15. [1] Olika arter av träd som växer i samma skog kan utvecklas till att växa till olika höjder (i förväntan) i förhållande till de andra träderna de delar skogen med. Vi modellerar höjderna (mätt i meter) på fyra olika trädarter som delar samma skog som $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim N(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = \begin{bmatrix} 35 \\ 10 \\ 20 \\ 5 \end{bmatrix} \quad \text{och} \quad \Sigma = \begin{bmatrix} 1.07813 & -0.275 & -0.31875 & 0.1875 \\ -0.275 & 1 & 1.25 & -0.5 \\ -0.31875 & 1.25 & 2.8125 & -0.125 \\ 0.1875 & -0.5 & -0.125 & 1.25 \end{bmatrix}$$

(a) Vad är covariansen mellan höjderna av trädarter 2 och 3?

(b) Är höjderna av trädarter 2 och 3 oberoende i denna modell?

(c) Vad är covariansen mellan höjderna av trädarter 1 och 4 givet höjderna av trädarter 2 och 3?

(d) Är höjderna av trädarter 1 och 4 oberoende givet 2 och 3 i denna modell?

(e) Vad är $E[X_3|X_2 = 7.5]$ och $\text{Var}[X_3|X_2]$?

3.16. [3] Låt $\mathbf{X} = [X_1, \dots, X_d]^T$ ha täthetsfunktion (eller sannolikhetsfunktion) $f_{\mathbf{X}}(x_1, \dots, x_n) > 0$ för alla $(x_1, \dots, x_m)$. Visa att följande stämmer. Dessa resultat kallas gemensamt för *axiomen för betingat oberoende*.

(a) (Symmetri) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B \mid \mathbf{X}_C$ gäller $\mathbf{X}_B \perp\!\!\!\perp \mathbf{X}_A \mid \mathbf{X}_C$.

(b) (Sönderfall) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_{B \cup D} \mid \mathbf{X}_C$ gäller $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B \mid \mathbf{X}_C$.

(c) (Svag union) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_{B \cup D} \mid \mathbf{X}_C$ gäller $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B \mid \mathbf{X}_{C \cup D}$.

(d) (Kontraktion) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B \mid \mathbf{X}_{C \cup D}$ och $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_D \mid \mathbf{X}_C$ gäller $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_{B \cup D} \mid \mathbf{X}_C$.

(e) (Snitt) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B \mid \mathbf{X}_{C \cup D}$ och $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_C \mid \mathbf{X}_{B \cup D}$ gäller $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_{B \cup C} \mid \mathbf{X}_D$.

3.17. [1] Med hjälp av *axiomen för betingat oberoende* från Uppgift 3.16 visa att om $X_1 \perp\!\!\!\perp X_2 \mid \mathbf{X}_{3,4,5}$ och $X_1 \perp\!\!\!\perp \mathbf{X}_{4,5} \mid X_3$ så har vi $X_1 \perp\!\!\!\perp \mathbf{X}_{2,4,5} \mid X_3$.

3.18. [2] Med hjälp av *axiomen för betingat oberoende* från Uppgift 3.16 visa att om följande stämmer

- $X_2 \perp\!\!\!\perp X_1$,
- $X_3 \perp\!\!\!\perp X_2 \mid X_1$,
- $X_4 \perp\!\!\!\perp \mathbf{X}_{\{1,3\}} \mid X_2$
- $X_5 \perp\!\!\!\perp \mathbf{X}_{\{1,2\}} \mid \mathbf{X}_{\{3,4\}}$

stämmer det även att $X_1 \perp\!\!\!\perp X_2 \mid \mathbf{X}_{\{3,4,5\}}$.

3.19. [1] Anta att

$$\begin{aligned} X|Y=y, Z=z &\sim \text{Bin}(y, z), \\ Y &\sim \text{Po}(\lambda), \\ Z &\sim \text{Beta}(\lambda, 1), \end{aligned}$$

och $Y \perp\!\!\!\perp Z$. Vad är $E[X]$? Vad är $\text{Var}[X]$? Kan du beskriva en situation som kan modelleras med denna hierarki?

3.20. [2] Betrakta $X|P = p \sim \text{Bin}(n, p)$ där $P \sim \text{Beta}(\alpha, \beta)$. Man säger i en sådan situation att X är fördelad enligt en *beta-binomialfördelning*.

(a) Bestäm sannolikheten $P(X = k)$ för $1 \leq k \leq n$.

(b) Vad är $E[X]$?

(c) Visa att variansen av X kan skrivas som

$$\text{Var}[X] = n E[P](1 - E[P]) + n(n - 1) \text{Var}[P].$$

(Den första termen speglar binomialvariation med sannolikhet $E[P]$, medan den andra termen ofta kallas "extra-binomialvariation" och visa hur denna hierarki har högre varians än den vanliga binomialfördelningen.)

(d) (*Pólya-Urna*) Anta att vi har en urna som innehåller α röda bollar och β svarta bollar. När vi drar en röd boll från urnan lägger vi tillbaks två röda bollar. På samma sätt lägger vi tillbaks två svarta bollar när vi drar en svart boll. Låt X beteckna antalet röda bollar efter n dragningar från urnan. Visa att X är beta-binomialfördelad.

3.21. [3] (a) För den hierarkiska modellen

$$Y | \Lambda = \lambda \sim \text{Po}(\lambda) \quad \text{och} \quad \Lambda \sim \text{Gamma}(\alpha, \beta),$$

bestäm marginalfördelningen, väntevärdet, och variansen för Y . Visa att marginalfördelningen för Y är negativt binomialfördelad om α är ett heltal.

(b) För hierarkin i del (a), visa att variansen av Y kan skrivas som

$$\text{Var}[Y] = E[\Lambda] + \text{Var}[\Lambda] = \mu + \frac{1}{\alpha} \mu^2,$$

där $\mu = E[\Lambda]$. Identifiera "extra-Poisson"-variationen som induceras av hierarkin (se Uppgift 3.20(c) för definitionen av "extra".)

(c) Visa att marginalfördelning för Y i trestegsmodellen

$$Y | N = n \sim \text{Bin}(n, p), \quad N | \Lambda = \lambda \sim \text{Po}(\lambda), \quad \text{och} \quad \Lambda \sim \text{Gamma}(\alpha, \beta)$$

är också en negativt binomialfördelning om α är ett heltal.

3.22. [1] Låt

$$\begin{aligned} X | \Lambda = \lambda &\sim \text{Exp}(\lambda), \\ \Lambda | B = \beta &\sim \text{Gamma}(6, \beta), \\ B &\sim \chi^2(30) \end{aligned}$$

där $X \perp\!\!\!\perp B | \Lambda$. Vad är $E[X]$?

3.23. [1] Låt

$$\begin{aligned} U | X_1 = x_1, X_2 = x_2 &\sim \text{U}(x_2 - 1, x_1 + 1), \\ X_1 | \Theta = \theta_1 &\sim \text{Bin}(5, \theta), \\ X_2 | \Theta = \theta_2 &\sim \text{Bin}(15, \theta), \\ \Theta &\sim \text{Beta}(3, 2) \end{aligned}$$

där n är ett positivt heltal, $U \perp\!\!\!\perp \Theta | \mathbf{X}_{\{1,2\}}$ och $X_1 \perp\!\!\!\perp X_2 | \Theta$. Vad är $E[U]$?

3.24. [2] Låt

$$\begin{aligned} X \mid A = \alpha, B = \beta &\sim \text{Gamma}(\alpha, \beta), \\ A &\sim \text{Exp}(3), \\ B &\sim \text{U}(3, 5) \end{aligned}$$

och $A \perp\!\!\!\perp B$. Vad är $E[X]$?

3.25. [1] Låt

$$\begin{aligned} X \mid R = r &\sim \text{NegBin}(r, 3/5), \\ R &\sim \text{Geom}(7/9). \end{aligned}$$

Vad är $\text{Var}[X]$?

3.26. [2] Låt

$$\begin{aligned} X \mid \Lambda = \lambda &\sim \text{Exp}(\lambda), \\ \Lambda &\sim \text{Gamma}(7, 5). \end{aligned}$$

Vad är $\text{Var}[X]$?


3.27. [2] Låt $[X_1, \dots, X_m]^T$ har täthetsfunktion $f_{\mathbf{X}}(x_1, \dots, x_m)$, och låt A, B, C, D vara disjunkta delmängder av $\{1, \dots, m\}$ för icke-tomma A, B, C . Bevisa följande:

- (a) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_{B \cup D} \mid \mathbf{X}_C$ så har vi $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B \mid \mathbf{X}_C$.
- (b) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B \mid \mathbf{X}_C$ så har vi $\mathbf{X}_B \perp\!\!\!\perp \mathbf{X}_A \mid \mathbf{X}_C$.

Kapitel 4

4.1 Grafer

Grafer är grundläggande objekt i *diskret matematik* som är området inom matematik som behandlar icke-kontinuerliga fenomen. Grafer används inom många tillämpade och teoretiska matematiska områden eftersom de modellerar hur objekt relaterar till varandra. En graf kan liknas vid man prickar förbundna med streck. Ur ett statistiskt perspektiv kan prickar representera stokastiska variabler och ett streck mellan två prickar kan representera en relation (exempelvis, en beroenderelation) mellan två stokastiska variabler. Det vill säga att vi kan representera relationen $X_1 \not\perp X_2$ med grafen:



medan vi skulle representera relationen $X_1 \perp X_2$ med grafen:



När vi ritat graferna som ovan ritat vi cirklar som innehåller tal istället för prickar så att vi kan särskilja prickarna (eftersom vi kommer att tolka de olika prickarna som olika stokastiska variabler). Vi såg i föregående kapitel att det är möjligt att ha flera relationer för betingat oberoende mellan flera stokastiska variabler. I följande utvecklar vi en metod för att representera flera relationer för betingat oberoende som håller i en given simultan fördelning med hjälp av en graf. För att göra det presenterar vi först flera grundläggande definitioner och resultat inom grafteori.

En prick kallas för en *nod* (eng. node) eller *hörn* (eng. vertex) och en förbindelse (ett streck mellan prickar) kallas för en *kant* (eng. edge). Graferna ovan har två noder och den första grafen har en kant medan den andra har inga kanter. Två noder som har en kant mellan sig är *grannar* (eng. adjacent, or neighbors) i grafen. En *graf* är bara en mängd noder varav några är parvis förbundna av kanter; det vill säga att en graf är ett ordnat par $\mathcal{G} = (V, E)$ av mängder V och E där V är grafens noder och E är grafens kanter. Vi kallar V grafens *nodmängd* och E grafens *kantmängd*. Generellt sett är det möjligt för en graf att ha kanter som bildar en *multimängd*; dvs. en samling där samma element kan förekomma flera gånger. Till exempel har följande grafen nodmängden $V = \{1, 2\}$ och kantmängden $E = \{1 - 2, 1 - 2\}$:




Det är också möjligt att ha kanter i grafer som bildar *öglor* (eng. loops); dvs. kanter som förbinder en nod med sig själv:



Grafen ovan har kantmängd $E = \{1 - 2, 1 - 2, 2 - 2\}$ och den sista kanten kallas för en *ögla* (eng. loop). Två eller flera kanter mellan samma par av noder betraktas tillsammans sägs vara en *flerkant* (eng. multiedge). Till exempel är $1 - 2$ en flerkant i grafen ovan eftersom kanten $1 - 2$ dyker upp flera gånger i kantmängden. En graf med inga flerkanter och inga öglor kallas för en *enkel graf*. **I följande (resten av denna bok) ska vi använda bara enkla grafer.**

Grafer kan ha olika typer av kanter. Graferna som vi har ritat hittills har bara haft *oriktade kanter*; det vill säga, kanter utan någon specifik riktning. En graf med endast oriktade kanter kallas för en *oriktad graf*. En kant som går från en nod till en annan kallas för en *riktad kant* och betecknas med en pilspets:




En graf som ovan med bara riktade kanter kallas för en *riktad graf*. Följande visar en oriktad graf och en riktad graf:



Figur 4.1: Exempel på grafer

När en graf har flera kanter är det användbart att skriva kantmängden som en samling mängder med två element eller ordnade par där $\{i, j\}$ representerar en oriktad kant $i - j$ och (i, j) representerar en riktad kant $i \rightarrow j$. Med hjälp av denna beteckning kan vi formellt definiera oriktade och riktade grafer: En *oriktad graf* är en graf vars kantmängd bara innehåller mängder på formen $\{i, j\}$ och en *riktad graf* är en graf vars kantmängd bara innehåller ordnade par (i, j) .

Det är givetvis möjligt att ha grafer med både riktade och oriktade kanter. Till exempel kan vi ha följande graf:



Sådana grafer kallas för *blandade grafer*.

Det är användbart att ha ett formellt sätt att prata om hur man går längs kanterna på en given graf. En *vandring* (*walk* på engelska) i en graf är en sekvens av noder och kanter som uppfyller följande:

- sekvensen alternerar mellan nod och kant,
- sekvensen börjar och slutar med noder, och
- den unika kanten mellan varje par på varandra följande noder i, j i sekvensen förbinder i och j i grafen (dvs, $e = (i, j), (j, i)$ eller $\{i, j\}$).

Till exempel, en vandring i grafen i Figur 4.1a är

$$w = (5, \{2, 5\}, 2, \{2, 3\}, 3, \{3, 4\}, 4, \{3, 4\}, 3, \{1, 3\}, 1, \{1, 2\}, 2).$$

En vandring i den riktade grafen i Figur 4.1b är


$$w' = (4, (4, 3), 3, (3, 1), 1, (1, 5), 5, (5, 3), 3, (3, 1), 1, (1, 2), 2).$$

I enkla grafer kan vi förenkla beteckningen för en vandring eftersom det bara finns ett val av kant mellan två angränsande noder i sekvensen. Det vill säga att vi kan skriva våra exempel som $w = (5, 2, 3, 4, 3, 1, 2)$ respektive $w' = (4, 3, 1, 5, 3, 1, 2)$.

Det är givetvis möjligt att besöka samma nod flera gånger i en given vandring. En *stig* (*path* på engelska) är en vandring som inte passerar samma nod flera gånger. Exempelvis, en stig i den oriktade grafen i Figur 4.1a är $s = (5, 2, 3, 1)$ och en stig i den riktade grafen i Figur 4.1b är $s' = (1, 5, 4, 2)$.


I riktade grafer tillåter vi att stigar går baklänges längs riktade kanter; det vill säga, vi kan gå från j till i längs kanten $i \rightarrow j$. Till exempel är $s'' = (1, 2, 4, 3, 5)$ i grafen i Figur 4.1b också en stig. Om kanterna i en stig $s = (v_1, v_2, \dots, v_m)$ är så att $v_i \rightarrow v_{i+1}$ för alla $i = 1, \dots, m - 1$ kallar vi stigen för en *riktad stig* (från v_1 till v_m). Det vill säga att stigen $s'' = (1, 2, 4, 3, 5)$ inte är en riktad stig men stigen $s' = (1, 5, 4, 2)$ är en riktad stig (från 1 till 2) i grafen i Figur 4.1b.

En graf är *sammanhängande* (eng. connected) om det finns en stig mellan varje par av noder i grafen. En graf som inte är sammanhängande delar i ett antal *sammanhängande komponenter*. Till exempel är graferna i Figur 4.1 sammanhängande men inte följande graf:



Den här grafen har tre sammanhängande komponenter.


En *delgraf* av en graf $\mathcal{G} = (V, E)$ är en graf $\mathcal{H} = (V', E')$ där $V' \subseteq V$, $E' \subseteq E$ och varje nod i kanterna i E' tillhör V' . En delgraf kallas för *inducerad* (av V') om E' består av alla kanter i E som ligger mellan noderna i V' . Följande grafer är delgrafer av grafen i Figur 4.1b.



Figur 4.2: Exempel på delgrafer

Delgrafen till vänster är inte inducerad medan delgrafen till höger är inducerad.

En *cykel* i en graf är en delgraf med nodmängd $\{v_1, \dots, v_m\}$ och kantmängd som består av precis en kant mellan v_i och v_{i+1} för alla $i = 1, \dots, m-1$ samt en kant mellan v_1 och v_m . När kanterna i en cykel i en riktad graf pekar åt samma håll säger vi att cykeln är *riktad*. Graferna i figur 4.2 är cykler men endast grafen i Figur 4.2a är riktad cykel. En riktad graf utan riktade cykler kallas för en *acyklisk riktad graf* (eng. directed acyclic graph eller DAG). Den riktade grafen i Figur 4.1b är inte acyklisk men följande graf är:



Figur 4.3: Exempel på en DAG

Vi vill nu använda acykliska riktade grafer för att definiera en flexibel typ av flerdimensionell statistisk modell med hjälp av betingat oberoende. För att göra detta kommer det att bli användbart att ha följande ytterliggande definitioner: Om $i \rightarrow j$ är en kant i en riktad graph $\mathcal{G}$ säger vi att i är en av j 's *föräldrar* (eng. *parents*) och j är ett av i 's *barn* (eng. *children*). Vi låter $\text{pa}_{\mathcal{G}}(i)$ och $\text{ch}_{\mathcal{G}}(i)$ betecknar mängden föräldrar respektive barn till i i $\mathcal{G}$; det vill säga

$$\text{pa}_{\mathcal{G}}(i) = \{j : j \rightarrow i \text{ en kant i } \mathcal{G}\} \quad \text{och} \quad \text{ch}_{\mathcal{G}}(i) = \{j : i \rightarrow j \text{ en kant i } \mathcal{G}\}.$$

Om det finns en riktad stig från i till j i $\mathcal{G}$ säger vi att j är en av i 's *ättlingar* (eng. *descendents*) och i är en av j 's *förfäder* (eng. *ancestors*). Vi definierar i som både en ättling och en förfader till sig själv. Vi betecknar mängden ättlingar och förfäder till i i $\mathcal{G}$ som $\text{des}_{\mathcal{G}}(i)$ respektive $\text{ang}_{\mathcal{G}}(i)$; det vill säga

$$\text{des}_{\mathcal{G}}(i) = \{i\} \cup \{j : \text{det finns en riktad stig från } i \text{ till } j \text{ i } \mathcal{G}\}$$

och

$$\text{an}_{\mathcal{G}}(i) = \{i\} \cup \{j : \text{det finns en riktad stig från } j \text{ till } i \text{ i } \mathcal{G}\}.$$

Till exempel, för noden 5 i grafen $\mathcal{G}$ i Figur 4.3 har vi

$$\text{pa}_{\mathcal{G}}(5) = \{1\}, \quad \text{ch}_{\mathcal{G}}(5) = \{3, 4\}, \quad \text{des}_{\mathcal{G}}(5) = \{2, 3, 4, 5\}, \quad \text{och} \quad \text{an}_{\mathcal{G}}(5) = \{1, 5\}.$$

Det är också möjligt att betrakta en mängds förfäder: En mängd $C \subseteq [m]$ har förfäder

$$\text{an}_{\mathcal{G}}(C) = \bigcup_{i \in C} \text{an}_{\mathcal{G}}(i).$$

4.2 Grafiska modeller

Låt oss nu återkomma till hierarkiska modeller. Till exempel kan vi betrakta hierarkin

$$\begin{aligned} U|X = x &\sim \text{U}(0, x + 1), \\ X|\Theta = \theta &\sim \text{Bin}(n, \theta), \\ \Theta &\sim \text{Beta}(3, 2), \end{aligned}$$

från Exempel 3.10. Här antog vi att $U \perp\!\!\!\perp \Theta|X$. Det följer från Sats 3.2 att $f_{U|X,\Theta}(u|x,\theta) = f_{U|X}(u|x)$ och, med hjälp av kedjeregeln, får vi

$$\begin{aligned} f_{U,X,\Theta}(u, x, \theta) &= f_{U|X,\Theta}(u|x, \theta) f_{X|\Theta}(x|\theta) f_{\Theta}(\theta), \\ &= f_{U|X}(u|x) f_{X|\Theta}(x|\theta) f_{\Theta}(\theta). \end{aligned}$$

Vi ser från faktoriseringen att vi kan bestämma 'sannolikheten' för utfallet $X = x$ givet $\Theta = \theta$. Givet $X = x$ kan vi sedan bestämma 'sannolikheten' för $U = u$. Tänker grafiskt betyder det att från Θ kan vi gå till X och från X kan vi sedan gå till U . Detta resonemang antyder att vi kan representera relationerna för beroende i den hierarkiska modellen med riktade kanter mellan tre noder – en nod för varje variabel i modellen:

$$\Theta \longrightarrow X \longrightarrow U.$$

Vi bildade grafen ovan baserat på faktoriseringen för den simultana täthetsfunktionen:

$$f_{U,X,\Theta}(u, x, \theta) = f_{U|X}(u|x) f_{X|\Theta}(x|\theta) f_{\Theta}(\theta)$$


där varje variabel motsvarar en faktor $f_{Z_i|\mathbf{Z}_C}(z_i|\mathbf{z}_C)$. För att åstadkomma detta ritade vi en nod för varje variabel i den simultana fördelningen. Sedan ritade vi en riktad kant till en given nod i (variabel Z_i) från varje nod $j \in C$. På detta sätt fick vi en acyklisk riktad graf som representerar beroenderelationerna mellan variablerna i den simultana fördelningen. Vi ser även att grafen representerar de relevanta relationerna för betingat oberoende i modellen: att det finns en riktad stig från Θ till U kan vi tolka som att " U beror på Θ ." Men när $X = x$ är givet har vi fixerat något mitt i den enda riktade stigen från Θ till U . Man kan tänka sig att detta blockerar den enda stigen från Θ till U vilken gör Θ och U oberoende. Det vill säga att $U \perp\!\!\!\perp \Theta|X$. På detta sätt representerar grafen både relationer för beroende som bildar modellen och relationerna för betingat oberoende som modellen uppfyller. Grafen ger oss en enkel bild att betrakta för att se många relationer som existerar i modellen. Denna metod för att representera en modell fungerar för så många variabler som önskas. Utöver detta byggde vi grafen bara enligt en faktorisering för den simultana fördelningens täthetsfunktion. Det betyder att vi kan bygga en graf för en simultan fördelning $\mathbf{X} = [X_1, \dots, X_n]^T$ endast baserat på en faktorisering utan en parameterisering för $\mathbf{X}$! Denna egenskap är väldigt användbar in *oövervakad inlärning* och *icke-parametrisk statistik* (vilka är populär i maskininlärning). Detta är den grundläggande idén och kraften hos grafiska modeller.

För ett annat enkelt exempel kan vi betrakta den simultana fördelningen för glödlamporna i Exempel 2.11.

Exempel 4.1. Vi såg i Exempel 3.4 att den simultana fördelningen av $[X_1, X_2, X_3]^T$ för glödlamporna kan faktoriseras enligt

$$f_{(X_1, X_2, X_3)}(x_1, x_2, x_3) = f_{X_2|X_1}(x_2|x_1) f_{X_3|X_1}(x_3|x_1) f_{X_1}(x_1),$$

så vi kan representera fördelningen med grafen




Eftersom variablerna är X_1, X_2, X_3 förenklar vi grafrepresentationen ovan genom att bara använda indexen till variablerna istället för själva variablerna. Vi ser direkt från grafen att $X_2 \perp\!\!\!\perp X_3 | X_1$ vilken vi redan bevisade i Exempel 3.3.

I både exempel ovan använder vi faktoriseringen för den simultana fördelningen för att bilda grafen som representerar den givna fördelningen. Enligt kedjeregeln (Sats 3.3) kan vi alltid skriva en täthetsfunktion $f_{X_1, X_2, X_3}(x_1, x_2, x_3)$ som

$$f_{X_1, X_2, X_3}(x_1, x_2, x_3) = f_{X_1}(x_1)f_{X_2|X_1}(x_2|x_1)f_{X_3|X_2, X_1}(x_3|x_2, x_1)$$

och därmed bildar följande graf för att representera fördelningen




Problemet är att denna graf inte är särskilt informativ. I allmänhet är målet med grafiska modeller att hitta en faktorisering för fördelningen som representerar så många som möjligt av oberoenderelationerna som modellen uppfyller och bildar sedan grafen. På detta sätt får vi en graf som representerar fördelningen på det mest informativa sättet. Från detta perspektiv passar det att definiera en grafisk modell som ett par bestående av en graf och en fördelning där grafen är anpassad efter fördelningen.

Definition 4.1. En fördelningen $\mathbf{X} = [X_1, \dots, X_m]^T$ sägs vara *markovsk* med avseende på en acyklisk riktad graf $\mathcal{G} = ([m], E)$ om täthetsfunktionen (eller sannolikhetsfunktionen) $f_{\mathbf{X}}(x_1, \dots, x_m)$ kan faktoriseras enligt

$$f_{\mathbf{X}}(x_1, \dots, x_m) = \prod_{i=1}^m f_{X_i | \mathbf{X}_{\text{pa}_{\mathcal{G}}(i)}}(x_i | \mathbf{x}_{\text{pa}_{\mathcal{G}}(i)}).$$

Paret $(\mathcal{G}, \mathbf{X})$ kallas för en *grafisk modell*.

Exempel 4.2. Vi ser från Exempel 3.4 att glödlampornas fördelning $\mathbf{X} = [X_1, X_2, X_3]^T$ är markovsk med avseende på följande graf $\mathcal{G}$:



eftersom

$$f_{X_1, X_2, X_3}(x_1, x_2, x_3) = f_{X_2|X_1}(x_2|x_1)f_{X_3|X_1}(x_3|x_1)f_{X_1}(x_1).$$

Därför är paret $(\mathcal{G}, \mathbf{X})$ en grafisk modell.

Vi såg också den simultana fördelningen $\mathbf{Y} = [U, X, \Theta]^T$ som definierades enligt hierarkin

$$\begin{aligned} U | X = x &\sim \text{U}(0, x + 1), \\ X | \Theta = \theta &\sim \text{Bin}(n, \theta), \\ \Theta &\sim \text{Beta}(3, 2) \end{aligned}$$

har täthetsfunktion

$$f_{U, X, \Theta}(u, x, \theta) = f_{U|X}(u|x)f_{X|\Theta}(x|\theta)f_{\Theta}(\theta)$$

eftersom vi antog att $U \perp\!\!\!\perp \Theta | X$. Därmed är fördelningen $\mathbf{Y} = [U, X, \Theta]^T$ markovsk med avseende på följande graf $\mathcal{H}$:

$$\Theta \longrightarrow X \longrightarrow U$$

Den resultande grafiska modellen är då $(\mathcal{H}, \mathbf{Y})$.

Exempel 4.3. Som ett exempel till kan vi betrakta fördelningen $\mathbf{Z} = [Y, X_1, X_2, \Theta]^T$ definierad enligt hierarkin

$$\begin{aligned} Y|X_1 = x_1, X_2 = x_2 &\sim N(x_1x_2, 1), \\ X_1|\Theta = \theta &\sim N(\theta, 3), \\ X_2|\Theta = \theta &\sim N(\theta/2, 10), \\ \Theta &\sim \text{Gamma}(5, 4) \end{aligned}$$

presenteras i Exempel 3.11. Vi antog också att $X_1 \perp\!\!\!\perp X_2|\Theta$ och $Y \perp\!\!\!\perp \Theta|X_1, X_2$. För att hitta en graf med avseende på vilken $\mathbf{Z}$ är markovsk kan vi börja med att skriva täthetsfunktionen som

$$f_{\mathbf{Z}}(y, x_1, x_2, \theta) = f_{Y|X_1, X_2, \Theta}(y|x_1, x_2, \theta) f_{X_2|X_1, \Theta}(x_2|x_1, \theta) f_{X_1|\Theta}(x_1|\theta) f_{\Theta}(\theta)$$


med hjälp av kedjeregeln. Med hjälp av oberoenderelationerna ser vi då att

$$f_{Y|X_1, X_2, \Theta}(y|x_1, x_2, \theta) = f_{Y|X_1, X_2}(y|x_1, x_2) \quad \text{och} \quad f_{X_2|X_1, \Theta}(x_2|x_1, \theta) = f_{X_2|\Theta}(x_2|\theta).$$

Därför har vi att

$$f_{\mathbf{Z}}(y, x_1, x_2, \theta) = f_{Y|X_1, X_2}(y|x_1, x_2) f_{X_2|\Theta}(x_2|\theta) f_{X_1|\Theta}(x_1|\theta) f_{\Theta}(\theta).$$

Det följer att $\mathbf{Z}$ är markovsk med avseende på följande graf $\mathcal{D}$:



Det vill säga att vi har den grafiska modellen $(\mathcal{D}, \mathbf{Z})$.

Exempel 4.2 och 4.3 visar att hierarkiska modeller på ett naturligt sätt bildar grafiska modeller där grafen specificeras genom beroenderelationerna som ges i hierarkin. Ett annat naturligt sätt att bilda grafiska modeller är med fördelningar som specificeras med system av ekvationer som i Exempel 3.5. I det exemplet definierar vi den flerdimensionella normalfördelningen $\mathbf{X} = [X_1, X_2, X_3]^T$ med hjälp av ekvationerna:

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= 3X_1 + N_2, \\ X_3 &= 2X_1 + N_2. \end{aligned}$$

Vi observerade att $X_3 \perp\!\!\!\perp X_2|X_1$ och kunde därför skriva täthetsfunktionen som

$$f_{\mathbf{X}}(x_1, x_2, x_3) = f_{X_3|X_1}(x_3|x_1) f_{X_2|X_1}(x_2|x_1) f_{X_1}(x_1).$$

Det följer att fördelningen är markovsk med avseende på grafen $\mathcal{G}$ i Exempel 4.2. Generellt sett kan vi använda samma logik för att dra slutsatsen att en fördelning $\mathbf{X} = [X_1, \dots, X_m]^T$ som definieras genom ett sådant system ekvationer är markovsk med avseende på en graf $\mathcal{G}$ där varje nod i har föräldrar som ges av variablerna X_j i ekvationen som definierar X_i . Vi ger ett exempel.

Exempel 4.4. Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ där

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= \lambda_1 X_1 + N_2, \\ X_3 &= \lambda_2 X_2 + N_3, \\ X_4 &= \lambda_3 X_3 + N_4 \end{aligned}$$

för $\lambda_1, \lambda_2, \lambda_3 \neq 0$ och N_1, N_2, N_3, N_4 oberoende och $N(0, 1)$ -fördelade. Med hjälp av kedjeregeln kan vi skriva täthetsfunktionen som

$$f_{\mathbf{X}}(x_1, x_2, x_3, x_4) = f_{X_4|X_1, X_2, X_3}(x_4|x_1, x_2, x_3) f_{X_3|X_1, X_2}(x_3|x_1, x_2) f_{X_2|X_1}(x_2|x_1) f_{X_1}(x_1).$$

Eftersom ekvationen som definieras X_3 bara beror på X_2 har vi att

$$f_{X_3|X_1,X_2}(x_3|x_1,x_2) = f_{X_3|X_2}(x_3|x_2). \quad (4.1)$$


På samma sätt har vi att

$$f_{X_4|X_1,X_2,X_3}(x_4|x_1,x_2,x_3) = f_{X_4|X_3}(x_4|x_3). \quad (4.2)$$

Därför förenklas täthetsfunktionen till

$$f_{\mathbf{X}}(x_1, x_2, x_3, x_4) = f_{X_4|X_3}(x_4|x_3)f_{X_3|X_2}(x_3|x_2)f_{X_2|X_1}(x_2|x_1)f_{X_1}(x_1),$$

och vi ser att $\mathbf{X}$ är markovsk med avseende på grafen $\mathcal{G}$ som ges av



Det vill säga att $(\mathcal{G}, \mathbf{X})$ är en grafisk modell.

Notera att analysen från Exempel 3.5 kan också tillämpas på denna fördelning. Det betyder att fördelningen $\mathbf{X}$ är en flerdimensionell normalfördelning. Notera också att, med hjälp av Sats 3.2, ger ekvationerna (4.1) och (4.2) att $X_3 \perp\!\!\!\perp X_1|X_2$ och $X_4 \perp\!\!\!\perp \mathbf{X}_{\{1,2\}}|X_3$. Vi kan se dessa relationer för betingat oberoende i grafen $\mathcal{G}$ eftersom 2 ”blockerar” den enda riktade stigen från 1 till 3 och 3 ”blockerar” den enda riktade stigen i $\mathcal{G}$ från 1 och/eller 2 till 4. (Vi kommer snart att formalisera idén av ”att blockera” stiger och dess koppling till betingat oberoende men för nu kommer vi bara att tänka på det på ett intuitivt sätt.)

Även om det är fint att vi kan se relationerna för betingat oberoende som definierar modellen inom grafen är det mer användbart att grafen avslöjar nya relationer. Till exempel ser vi även med hjälp av grafen att $X_4 \perp\!\!\!\perp X_1|\mathbf{X}_{2,3}$ eftersom den enda riktade stigen från 1 till 4 ”blockeras” av 2 och 3. På samma sätt ser vi att $X_4 \perp\!\!\!\perp X_1|X_2$.

Exempel 4.4 illustrerar två viktiga saker: För det första belyser det att grafiska modeller egentligen definieras genom en samling relationer för betingat oberoende. Vi kan nämligen alltid skriva täthetsfunktionen för $\mathbf{X} = [X_1, \dots, X_m]^T$ som

$$f_{\mathbf{X}}(x_1, \dots, x_m) = \prod_{i=1}^m f_{X_i|\mathbf{X}_{[i-1]}}(x_i|x_1, \dots, x_{i-1})$$

enligt kedjeregeln. För varje i kan vi ta en delmängd $C_i \subseteq [i-1]$ så att

$$X_i \perp\!\!\!\perp \mathbf{X}_{[i-1] \setminus C_i} | \mathbf{X}_{C_i}. \quad (4.3)$$

Det följer då från Sats 3.2 att

$$f_{X_i|\mathbf{X}_{[i-1]}}(x_i|x_1, \dots, x_{i-1}) = f_{X_i|\mathbf{X}_{C_i}}(x_i|\mathbf{x}_{C_i})$$

och

$$f_{\mathbf{X}}(x_1, \dots, x_m) = \prod_{i=1}^m f_{X_i|\mathbf{X}_{C_i}}(x_i|\mathbf{x}_{C_i}).$$

Därför har vi att $\mathbf{X}$ är markovsk med avseende på grafen $\mathcal{G} = ([m], E)$ där

$$E = \{j \rightarrow i : j \in C_i, i \in [m]\}.$$

Med andra ord kan vi specificera en grafisk modell $(\mathcal{G}, \mathbf{X})$ genom den samling oberoenderelationer – en relation för varje i i ekvation (4.3) – som modellen uppfyller. Den motsvarande grafen $\mathcal{G}$ ges ovan.


Exempel 4.5. Låt $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5]^T$ vara en fördelning som uppfyller följande relationer:

$$\begin{aligned} X_2 &\perp\!\!\!\perp X_1, \\ X_3 &\perp\!\!\!\perp X_2|X_1 \\ X_4 &\perp\!\!\!\perp X_2|\mathbf{X}_{1,3}, \\ X_5 &\perp\!\!\!\perp X_1|\mathbf{X}_{2,3,4}. \end{aligned}$$

Det följer att täthetsfunktionen för $\mathbf{X}$ kan skrivas som

$$\begin{aligned} f_{\mathbf{X}}(x_1, x_2, x_3, x_4, x_5) &= f_{X_5|\mathbf{X}_{\{1,2,3,4\}}}(x_5|\mathbf{x}_{\{1,2,3,4\}})f_{X_4|\mathbf{X}_{\{1,2,3\}}}(x_4|\mathbf{x}_{\{1,2,3\}})f_{X_3|\mathbf{X}_{\{1,2\}}}(x_3|\mathbf{x}_{\{1,2\}})f_{X_2|X_1}(x_2|x_1)f_{X_1}(x_1), \\ &= f_{X_5|\mathbf{X}_{\{2,3,4\}}}(x_5|\mathbf{x}_{\{2,3,4\}})f_{X_4|\mathbf{X}_{\{1,3\}}}(x_4|\mathbf{x}_{\{1,3\}})f_{X_3|X_1}(x_3|x_1)f_{X_2}(x_2)f_{X_1}(x_1). \end{aligned}$$

Därför är $\mathbf{X}$ markovsk med avseende på följande graf $\mathcal{G}$:



och $(\mathcal{G}, \mathbf{X})$ bildar en grafisk modell. Observera att vi inte angav några parametrar i denna modell! Detta är en användbar egenskap hos grafiska modeller. Man kan bilda grafiska modeller utan konkreta antaganden om fördelningens parametrisering utan det räcker med antaganden om betingat oberoende.

Vi såg redan att grafer och hierarkier är nära kopplade i meningen att om man har en hierarkisk modell kan man bilda en graf som representerar hierarkin. I praktiken kan vi bilda en modell baserad endast på en samling relationer för betingat oberoende som vi tror fördelningen uppfyller. Denna mängd kan innehålla mer än bara relationerna som ger oss en grafisk modell. Det är naturligt att betrakta alla relationer som vi tror fördelningen uppfyller och extrahera de som låter oss bilda en grafiska modell med en graf som har så få kanter som möjligt. Grafen kan sedan ge oss en rimlig hierarki att använda för modellen. I Exempel 4.5 visar grafen $\mathcal{G}$ att en rimlig hierarki för $\mathbf{X}$ kan ha X_3 och X_4 definierade som funktioner av endast X_1 och X_5 definieras som en funktion av bara $[X_2, X_3, X_4]^T$. (Även om detta är kanske uppenbart från oberoenderelationerna i detta fall kommer vi att se grafen kan antyda olika hierarkier som vi inte förväntar!)

Den andra viktiga saken vilken Exempel 4.4 visar är att om vi vet att en fördelning $\mathbf{X}$ är markovsk med avseende på en viss graf $\mathcal{G}$ kan vi läsa av grafen relationer för betingat oberoende utöver de som visade oss att $\mathbf{X}$ var markovsk med avseende på $\mathcal{G}$ i första hand (dvs., utöver de som ges av ekvation (4.3)). Dessa relationer *implieras* av relationerna som bestämmer att $\mathbf{X}$ är markovsk med avseende på $\mathcal{G}$. Kom i håg att en fördelning $\mathbf{X} = [X_1, \dots, X_m]^T$ är markovsk med avseende på $\mathcal{G} = ([m], E)$ om

$$f_{\mathbf{X}}(x_1, \dots, x_m) = \prod_{i=1}^m f_{X_i | \mathbf{X}_{\text{pa}_{\mathcal{G}}(i)}}(x_i | \mathbf{x}_{\text{pa}_{\mathcal{G}}(i)}).$$

Om vi antar att $\mathcal{G}$ har egenskapen att j aldrig är en ättling till i när $i > j$ har vi att denna faktorisering är ekvivalent till villkoret att

$$X_i \perp\!\!\!\perp \mathbf{X}_{[i-1] \setminus \text{pa}_{\mathcal{G}}(i)} | \mathbf{X}_{\text{pa}_{\mathcal{G}}(i)} \quad \text{för alla } i. \quad (4.4)$$

Dessa relationer definierar därför den grafiska modellen $(\mathcal{G}, \mathbf{X})$. Till exempel ger grafen $\mathcal{G}$ i Exempel 4.4 oss relationerna för betingat oberoende

$$\begin{aligned} X_3 &\perp\!\!\!\perp X_1 | X_2, \\ X_4 &\perp\!\!\!\perp \mathbf{X}_{\{1,2\}} | X_3. \end{aligned} \quad (4.5)$$

Enligt definitionen måste en fördelning $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ som är markovsk med avseende på $\mathcal{G}$ uppfylla

$$f_{\mathbf{X}}(x_1, x_2, x_3, x_4) = f_{X_4 | X_3}(x_4 | x_3) f_{X_3 | X_2}(x_3 | x_2) f_{X_2 | X_1}(x_2 | x_1) f_{X_1}(x_1).$$

Men eftersom *alla* fördelningar med fyra variabler uppfyller

$$f_{\mathbf{X}}(x_1, x_2, x_3, x_4) = f_{X_4 | \mathbf{X}_{\{1,2,3\}}}(x_4 | \mathbf{x}_{\{1,2,3\}}) f_{X_3 | \mathbf{X}_{\{1,2\}}}(x_3 | \mathbf{x}_{\{1,2\}}) f_{X_2 | X_1}(x_2 | x_1) f_{X_1}(x_1)$$

motsvarar detta

$$f_{X_4 | \mathbf{X}_{\{1,2,3\}}}(x_4 | \mathbf{x}_{\{1,2,3\}}) = f_{X_4 | X_3}(x_4 | x_3) \quad \text{och} \quad f_{X_3 | \mathbf{X}_{\{1,2\}}}(x_3 | \mathbf{x}_{\{1,2\}}) = f_{X_3 | X_2}(x_3 | x_2).$$

I sin tur motsvarar detta till att fördelningen uppfyller relationerna i (4.4). På detta sätt definierar relationerna i (4.4) vilka fördelningar är markovsk med avseende på $\mathcal{G}$.

Vi såg dock i Exempel 4.4 att vi kan läsa ytterligare relationer för betingat oberoende direkt från grafen $\mathcal{G}$, inklusive $X_4 \perp\!\!\!\perp X_1 | \mathbf{X}_{\{2,3\}}$ och $X_4 \perp\!\!\!\perp X_1 | X_2$. Dessa relationer impliceras av relationerna som definierar den grafiska modellen genom regler som säger vilka relationer för betingat oberoende följer från andra. Vi såg redan dessa regler i Uppgift 3.16. Reglerna kallas för *axiomen för betingat oberoende*:

Sats 4.1 (Axiomen för betingat oberoende). *Låt $\mathbf{X} = [X_1, \dots, X_d]^T$ ha täthetsfunktion (eller sannolikhetsfunktion) där $f_{\mathbf{X}}(x_1, \dots, x_n) > 0$ för alla $(x_1, \dots, x_n)$. Då har vi att*

1. (Symmetri) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_C$ gäller $\mathbf{X}_B \perp\!\!\!\perp \mathbf{X}_A | \mathbf{X}_C$.
2. (Sönderfall) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_{B \cup D} | \mathbf{X}_C$ gäller $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_C$.
3. (Svag union) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_{B \cup D} | \mathbf{X}_C$ gäller $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_{C \cup D}$.
4. (Kontraktion) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_{C \cup D}$ och $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_D | \mathbf{X}_C$ gäller $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_{B \cup D} | \mathbf{X}_C$.
5. (Snitt) Om $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_{C \cup D}$ och $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_C | \mathbf{X}_{B \cup D}$ gäller $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_{B \cup C} | \mathbf{X}_D$.

Med hjälp av axiomen för betingat oberoende kan vi visa, exempelvis, att relationerna $X_4 \perp\!\!\!\perp X_1 | \mathbf{X}_{\{2,3\}}$ och $X_4 \perp\!\!\!\perp X_1 | X_2$ uppfylls av fördelningen i Exempel 4.4 utan att betrakta (betingade) kovarianser.

Exempel 4.6. Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ vara fördelningen som definieras i Exempel 4.4. Från detta exempel vet vi att

$$\begin{aligned} X_3 &\perp\!\!\!\perp X_1 | X_2, \\ X_4 &\perp\!\!\!\perp \mathbf{X}_{\{1,2\}} | X_3. \end{aligned}$$

Eftersom $X_4 \perp\!\!\!\perp \mathbf{X}_{\{1,2\}} | X_3$ vet vi att $X_4 \perp\!\!\!\perp X_1 | \mathbf{X}_{\{2,3\}}$ med hjälp av svag union där

$$A = \{4\}, \quad B = \{1\}, \quad D = \{2\} \quad \text{och} \quad C = \{3\}.$$

När vi tillämpar symmetri på $X_3 \perp\!\!\!\perp X_1 | X_2$ får vi att $X_1 \perp\!\!\!\perp X_3 | X_2$. På samma sätt har vi att $X_1 \perp\!\!\!\perp X_4 | \mathbf{X}_{\{2,3\}}$. Om vi nu tar

$$A = \{1\}, \quad B = \{4\}, \quad C = \{2\} \quad \text{och} \quad D = \{3\}$$

kan vi tillämpa kontraktion på

$$X_1 \perp\!\!\!\perp X_4 | \mathbf{X}_{\{2,3\}} \quad \text{och} \quad X_1 \perp\!\!\!\perp X_3 | X_2$$

för att få $X_1 \perp\!\!\!\perp X_{\{3,4\}} | X_2$. Sedan tillämpar vi sönderfall på $X_1 \perp\!\!\!\perp X_{\{3,4\}} | X_2$ med

$$A = \{1\}, \quad B = \{4\}, \quad C = \{2\} \quad \text{och} \quad D = \{3\}$$


för att få $X_1 \perp\!\!\!\perp X_4 | X_2$. Till sist tillämpar vi symmetri en gång till för att få $X_4 \perp\!\!\!\perp X_1 | X_2$.

På detta sätt verifierade vi att relationerna $X_4 \perp\!\!\!\perp X_1 | \mathbf{X}_{\{2,3\}}$ och $X_4 \perp\!\!\!\perp X_1 | X_2$ uppfylls av fördelningen (vilket vi redan hade gissat baserat på grafen $\mathcal{G}$ i Exempel 4.4).

4.2.1 d-sammanhängande och d-separation

Exempel 4.6 visar hur komplicerat det kan vara att hitta alla relationer för betingat oberoende som impliceras när vi antar att en fördelning uppfyller en viss samling relationer. Å andra sidan såg vi redan att grafen ger oss ett intuitivt sätt för att läsa av ytterliggande sådana relationer. Frågan blir då följande: "Finns det ett sätt att läsa av alla relationer för betingat oberoende i grafen som en fördelning måste uppfylla om det är markovsk med avseende på $\mathcal{G}$?"

Det är möjligt att göra detta och regeln som behövs kallas för *d-separation*. Intuitivt är d-separation en regel som beskriver hur information färdas genom grafen när värdena för vissa variabler i systemet ges. För att få en känsla av detta betraktar vi följande exempel. Låt $\mathcal{G}$ vara grafen



och anta att $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ är markovsk med avseende på $\mathcal{G}$. Som i de tidigare exemplen ser vi att det bara finns en riktad stig från 1 till 4 och en från 2 till 4. Dessa stigar är $s = (1, 3, 4)$ respektive $s' = (2, 3, 4)$. När vi ingenting vet (dvs. när ingenting är givet) kan information färdas från 1 till 4 och 2 till 4. Därför borde vi intuitivt ha att $X_4 \not\perp\!\!\!\perp X_1$ och $X_4 \not\perp\!\!\!\perp X_2$. Å andra sidan, när $X_3 = x_3$ är givet kan vi inte lära oss någonting nytt om X_4 baserat på vad vi vet om X_1 eftersom alla information som vi får om X_4 från X_1 färdas genom X_3 , vilken redan är fix. Därför är kopplingen mellan X_1 och X_4 bruten när $X_3 = x_3$ är given; det vill säga att $X_4 \perp\!\!\!\perp X_1 | X_3$. På samma sätt har vi $X_4 \perp\!\!\!\perp X_2 | X_3$.

Samtidigt kan given information om värdet på en stokastisk variabel öppna nya stigar för information att färdas genom. Till exempel, när ingenting är givet ser det ut som $X_2 \perp\!\!\!\perp X_1$ baserat på grafen. Det är eftersom stigen $s = (1, 3, 2)$ består av kanterna $1 \rightarrow 3 \leftarrow 2$. Vi kan tolka detta som att vi bara kan lära oss något om 3 (inte 2) när vi vet något om 1. Vi kan inte gå baklänges längs kanten $2 \rightarrow 3$ för att lära ny information om 2 baserat på vad 1 berättade för oss om 3. Som ett exempel, föreställ dig att X_1 och X_2 representerar genetisk information för två föräldrar och X_3 representerar genetisk information för deras barn. Vi kan naturligtvis lära oss genetisk information för barnet när vi har informationen för en förälder. Men vi kan inte lära oss för den ena förälder bara med information för den andra föräldern (förhoppningsvis). Därför borde vi ha $X_2 \perp\!\!\!\perp X_1$. Å andra sidan, när vi är givet $X_3 = x_3$ (dvs., när barnets genetiska information är given) kan vi jämföra informationen som vi har om X_1 med informationen för X_3 och lära oss nya saker om X_2 . Det vill säga att $X_2 \not\perp\!\!\!\perp X_1 | X_3$.

Detta exempel ger oss grundidén för hur d-separation fungerar i grafiska modeller. d-separation kommer att berätta för oss när vi inte kan lära oss om variabler i en mängd B baserat på information för variabler i mängden A när variabler i mängden C är givna. Relationer för d-separation mellan nodmängder A, B, C kommer då att motsvara relationer för betingat oberoende på formen $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_C$. För att formellt definiera d-separation måste vi först definiera d-sammanhängande, vilken beskriver när vi *kan* lära oss om B med hjälp av A när C är givet; det vill säga att d-sammanhängande relationer mellan nodmängder A, B, C motsvarar relationer på formen $\mathbf{X}_A \not\perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_C$:


Definition 4.2. Låt $\mathcal{G} = ([m], E)$ vara en acyklisk riktad graf och låt $A, B, C \subseteq [m]$ vara disjunkta delmängder till $[m]$ med $A, B \neq \emptyset$. Vi säger att A och B är *d-sammanhängande* givet C om det finns en stig $(v_1, \dots, v_t)$ i $\mathcal{G}$ så att

1. $v_1 \in A$ och $v_t \in B$,
2. om $v_{i-1} \rightarrow v_i \rightarrow v_{i+1}$, $v_{i-1} \leftarrow v_i \rightarrow v_{i+1}$ eller $v_{i-1} \leftarrow v_i \leftarrow v_{i+1}$ för $1 < i < t$ är delgrafer av $\mathcal{G}$ har vi att $v_i \notin C$, och
3. om $v_{i-1} \rightarrow v_i \leftarrow v_{i+1}$ är en delgraf i $\mathcal{G}$ har vi att $v_i \in \text{an}_G(C)$.

Om A och B inte är d-sammanhängande givet C i $\mathcal{G}$ säger vi att A och B är *d-separerade* givet C i $\mathcal{G}$. Om A och B är d-separerade givet C i $\mathcal{G}$ skriver vi $A \perp_G B | C$. Om A och B är d-sammanhängande givet C av $\mathcal{G}$ skriver vi $A \not\perp_G B | C$.

Definitionen är lite mer generell än vårt lilla exempel på två anmärkningsvärda sätt: För det första betraktar definitionen för d-sammanhängande hur information färdas mellan *mängder* av variabler istället för bara mellan variabler. Villkoret 1 i Definition 4.2 säger att så länge som information kan färdas från någon variabel i mängden A till någon variabel i mängden B givet C (dvs. så länge som det finns ett val $v_1 \in A$ och $v_t \in B$ för vilka vi kan hitta en stig mellan v_1 och v_t som uppfyller 2 och 3) är hela mängderna av variabler d-sammanhängande. Därför för att bevisa d-separation måste vi verifiera att alla stiger mellan alla noder i A och B inte uppfyller både 2 och 3 givet C . Detta låter svårt men det kan göras snabbt i praktiken. Vi ger ett exempel:

Exempel 4.7. Betrakta den acykliska riktade grafen $\mathcal{G} = ([8], E)$:



Då har vi, exempelvis, att $1 \perp_G 5 | \emptyset$. Här tar vi $A = \{1\}$, $B = \{5\}$ och $C = \emptyset$. Det finns bara en stig i grafen mellan 1 och 5 som är $s = (1, 2, 3, 4, 5)$. Stigen innehåller delgrafen $1 \rightarrow 2 \leftarrow 3$ och $2 \notin C$. Vi ser också att det finns en riktad stig från 2 till en annan nod, nämligen 6. Om 6 tillhör C skulle vi ha möjligheten att gå längs stigen s förbi 2. Tyvärr är $6 \notin C$ och därför kan vi inte göra detta. Det följer att $1 \perp_G 5 | \emptyset$.


Vi har också att $\{1, 2, 6\} \perp_G \{5, 7\} | \{3, 4, 8\}$. I denna situation har vi $A = \{1, 2, 6\}$, $B = \{5, 7\}$ och $C = \{3, 4, 8\}$. För att se det måste vi verifiera att det inte finns någon stig från 1, 2 eller 6 till 5 eller 7 som uppfyller alla villkor för d-sammanhängande. Men alla sådana stigar måste gå förbi 3 vilken ligger i C . Det följer från villkor 2 i definitionen för d-sammanhängande att sådana stigar inte uppfyller villkor 2 för d-sammanhängande. Därför har vi att $\{1, 2, 6\} \perp_G \{5, 7\} | \{3, 4, 8\}$.

På samma sätt kan vi också observera att $\{2, 3\} \perp_G 5 | \{1, 6\}$ och

$$1 \not\perp_G 5 | \{6, 8\}, \quad 1 \not\perp_G 5 | \{2, 7\}, \quad \{2, 6\} \not\perp_G \{5, 7\} | \{1, 8\}.$$

Villkoret 2 i definitionen för d-sammanhängande generaliserar vår intuition att vi blockerar information när vi fixerar värdena för variabler på en riktad stig. Enligt villkoret blockerar vi också information när vi fixerar värdet för en variabel v på en stig av formen $w \leftarrow v \rightarrow k$. Följande ger ett exempel som hjälpa att göra detta litet mer intuitivt:


Exempel 4.8. Låt $\mathbf{X} = [X_1, X_2, X_3]^T$ vara glödlampornas fördelning från Exempel 2.11. Vi såg i Exempel 4.1 att $\mathbf{X}$ är Markovsk till följande graf $\mathcal{G}$:



Det finns bara en stig mellan 2 och 3 i $\mathcal{G}$, nämligen $s = (2, 1, 3)$. Därför har vi att $2 \perp_{\mathcal{G}} 3 | 1$ enligt villkor 2 i definitionen för d-sammanhängande. Detta är rimligt från det statistiska perspektivet eftersom vi såg i Exempel 3.4 att $X_2 \perp\!\!\!\perp X_3 | X_1$. När vi tänker på informationsflödet i detta exempel är idén att om vi vet att glödlampa 2 är på måste det vara så att glödlampa 1 redan har dött. Det följer att vi vet att glödlampa 3 också är på. Det vill säga att $X_2 \not\perp\!\!\!\perp X_3$ (eller $2 \not\perp_{\mathcal{G}} 3$ med grafen). Å andra sidan när $X_1 = x_1$ är givet har vi att X_2 och X_3 är oberoende eftersom de är båda på och de har livslängder som är oberoende. I grafen vi ser att $2 \perp_{\mathcal{G}} 3 | 1$.

Villkoret 3 generaliserar vår intuition att information kan färdas genom en stig $w \rightarrow v \leftarrow k$ när v är given. Istället för att bara gå från w till k när v är given kan information från en ättling till v också låta oss att gå från w till k . Om vi tänka tillbaks till exemplet med genetisk information kan man tolka detta som att vi kan lära oss nya saker om den ena föräldern från den andra föräldern med hjälp av genetisk information från deras barnbarn:

Exempel 4.9. Betrakta följande graf $\mathcal{G}$:



Enligt Definition 4.2 har vi att $1 \not\perp_{\mathcal{G}} 2 | 4$. I denna relation för d-sammanhängande har vi $A = \{1\}$, $B = \{2\}$ och $C = \{4\}$. Resultatet följer eftersom det finns en stig $s = (1, 3, 2)$ mellan 1 och 2 där vi även har en riktad stig $w = (3, 4)$ från 3 till 4. Eftersom $4 \in C$ har vi att 1 och 2 är d-sammanhängande.

För att förstå varför det är vettigt att $1 \not\perp_{\mathcal{G}} 2 | 4$ betraktar genetisk informations exempel. Här är 1 och 2 föräldrar med barnbarn 4. Om vi vet genetisk information om deras barnbarn kan vi jämföra detta med information från 1 för att lära oss nya saker om genetisk information om 2. Information färdas genom grafen längs vandringen

$$1 \rightarrow 3 \rightarrow 4 \leftarrow 3 \leftarrow 2.$$

Definition 4.2 säger att när det inte finns någon stig i grafen $\mathcal{G}$ som uppfyller alla tre villkoren 1, 2, 3 är mängderna A och B d-separerade i $\mathcal{G}$ givet C . Det vill säga att A och B är d-separerade givet C när det är omöjligt för information från A att färdas till B givet C . Eftersom detta bara är en regel på grafen $\mathcal{G}$ kan man läsa av grafen hela mängden relationer för d-separation som grafen uppfyller:

Exempel 4.10. Hela mängden d-separationer i grafen $\mathcal{G}$ från Exempel 4.7 är

$$1 \perp_{\mathcal{G}} 2, \quad 1 \perp_{\mathcal{G}} 4 | 3, \quad 2 \perp_{\mathcal{G}} 4 | 3, \quad \{1, 2\} \perp_{\mathcal{G}} 4 | 3, \quad 1 \perp_{\mathcal{G}} 4 | \{2, 3\}, \quad 2 \perp_{\mathcal{G}} 4 | \{1, 3\}.$$

Följande sats säger att mängden d-separation i en given graf motsvarar mängden relationer för betingat oberoende som impliceras av de relationer som definieras den grafiska modellen:

Sats 4.2. Om $\mathbf{X} = [X_1, \dots, X_m]^T$ är markovsk med avseende på en acyklisk riktad graf $\mathcal{G} = ([m], E)$ gäller att $X_A \perp\!\!\!\perp X_B | X_C$ när A och B är d-separerade givet C i $\mathcal{G}$. Sådana oberoenderelationer är alla som följer från villkoret att $\mathbf{X}$ är markovsk med avseende på $\mathcal{G}$.

Sats 4.2 har många konsekvenser inklusive en alternativ karakterisering för en fördelning att vara markovsk med avseende på en acyklisk riktad graf:

Sats 4.3. Låt $\mathbf{X} = [X_1, \dots, X_m]^T$ vara en fördelning och låt $\mathcal{G} = ([m], E)$ vara en acyklisk riktad graf. Följande påståenden är ekvivalenta:

1. $\mathbf{X}$ är markovsk med avseende på $\mathcal{G}$.
2. $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_C$ när $A \perp_{\mathcal{G}} B | C$ i $\mathcal{G}$.


Vi bevisar inte dessa satser utan sparar istället de till en kurs på mastersnivå.

Vi såg i Exempel 4.5 att det är möjligt att definiera en grafiska modell $(\mathcal{G}, \mathbf{X})$ genom att anta $\mathbf{X}$ uppfyller relationer för betingat oberoende som gör den markovsk med avseende på $\mathcal{G}$. Sats 4.3 säger att detta motsvarar att uppfylla en relation för betingat oberoende för varje d-separation som håller i grafen. I princip är det möjligt att två olika grafer har exakt samma relationer för d-separation. I detta fall har vi att *alla* fördelningar som är markovsk med avseende på en graf också måste vara markovsk med avseende på den andra.

Exempel 4.11. Låt $\mathbf{X} = [X_1, X_2, X_3]^T$ vara markovsk med avseende på grafen $\mathcal{G}$:



Det finns bara en d-separation i grafen $\mathcal{G}$, nämligen $1 \perp_{\mathcal{G}} 3 | 2$. Enligt Sats 4.3 är antagandet att $\mathbf{X}$ är markovsk med avseende på $\mathcal{G}$ ekvivalent till villkoret att $X_1 \perp\!\!\!\perp X_3 | X_2$. Betrakta nu följande två grafer:



som vi betecknar med $\mathcal{H}$ respektive $\mathcal{D}$. Båda $\mathcal{H}$ och $\mathcal{D}$ har också bara en d-separation vilken är $1 \perp_{\mathcal{G}} 3 | 2$. Eftersom $\mathbf{X}$ är markovsk med avseende på $\mathcal{G}$ vet vi att $X_1 \perp\!\!\!\perp X_3 | X_2$. Enligt Sats 4.3 vet vi därför att $\mathbf{X}$ också är markovsk med avseende på $\mathcal{H}$ och $\mathcal{D}$.

Observationen i Exempel 4.11 kan vara besvärlig om vi, exempelvis, hade hoppats använda grafen för att påtvinga modellen en hierarki, som i Exempel 4.5. I sådana fall kommer vi ha flera hierarkier att välja mellan. Dessa möjligheter ges av alla grafer som har exakt samma relationer för d-separation. Därför har vi följande definition.

Definition 4.3. Vi säger att två acykliska riktade grafer $\mathcal{G} = ([m], E)$ och $\mathcal{H} = ([m], E')$ är *markovekvivalenta* om de har samma relationer för d-separation; det vill säga att

$$A \perp_{\mathcal{G}} B | C \quad \text{om och endast om} \quad A \perp_{\mathcal{H}} B | C$$

för alla $A, B, C \subseteq [m]$.

Det kan vara svårt att bestämma alla d-separationer i två grafer $\mathcal{G}$ och $\mathcal{H}$ och verifiera att de är lika. Lyckligtvis finns det ett enklare sätt att verifiera om två grafer är markovekvivalent. För att beskriva denna metod behöver vi två definitioner:

Definition 4.4. Låt $\mathcal{G} = ([m], E)$ vara en acyklisk riktad graf. *Skelettet* för $\mathcal{G}$ är den oriktade grafen $G = ([m], E')$ där

$$E' = \{i - j : i \rightarrow j \in E\};$$


det vill säga att $\mathcal{G}$'s skelett är den oriktade grafen där varje kant i $\mathcal{G}$ ersätts med en oriktad kant.

Det andra definitionen som behövs belyser en speciell typ av inducerade delgrafer inom acykliska riktade grafer:


Definition 4.5. Låt $\mathcal{G} = ([m], E)$ vara en acyklisk riktad graf. En *v-struktur* inom $\mathcal{G}$ är en inducerad delgraf av $\mathcal{G}$ på tre noder $i, j, k \in [m]$ på formen



Det är viktigt att notera att v-strukturer måste vara inducerade delgrafer. Exempelvis, om grafen är




delgrafen $2 \rightarrow 3 \leftarrow 4$ är en v-struktur eftersom det är en inducerad delgraf. Det vill säga att det är en delgraf där vi tog delnodmängden $\{2, 3, 4\}$ och *alla* kanter mellan dessa noder som ligger i grafen. Å andra sidan är delgrafen $1 \rightarrow 3 \leftarrow 2$ inte en v-struktur eftersom det inte är en inducerad delgraf. Om vi tar delnodmängden $\{1, 2, 3\}$ och alla kanter mellan dessa bildar vi delgraf




vilken inte har formen som vi specificerade i Definition 4.5. Vi ger nu ett komplett exempel för skelettet och alla v-strukturer i en viss acyklisk riktad graf.

Exempel 4.12. Betrakta grafen $\mathcal{G}$ från Exempel 4.5:



Grafen har skelettet



Det har också precis två v-strukturer:




Notera att delnodmängderna $\{1, 3, 4\}$ och $\{3, 4, 5\}$ inte bildar v-strukturer eftersom deras inducerade delgrafer inte har formen i Definition 4.5.

Dessa konstiga definitioner kan hjälpa oss identifiera när två grafer är markovekvivalent. Det visar sig nämligen att skelettet och v-strukturerna räcker för att bestämma markovekvivalens.


Sats 4.4. *Två acykliska riktade grafer är markovekvivalent om och endast om de har samma skelett och samma v-strukturer.*

Enligt Sats 4.4 kan vi identifiera alla grafer som är markovekvivalenta till en given graf.

Exempel 4.13. Låt $\mathcal{G}$ vara grafen från Exempel 4.12. I det exemplet hittade vi skelettet och alla v-strukturer i $\mathcal{G}$ vilken vi kan representera tillsammans med följande blandad graf:




En godtycklig acyklisk riktad graf som har samma skelett och v-strukturer som ovan är markovekvivalent till $\mathcal{G}$. För att hitta alla sådana grafer kan vi därför orientera de oriktade kanterna i den här blandade grafen för att bilda en acyklisk riktad graf i alla möjliga sätt. Det finns precis sex möjligheter:



Som vi såg i Exempel 4.13 kan vi använda Sats 4.4 för att bestämma alla grafer som är markovekvivalent till en viss graf. Dessa grafer är ekvivalent i meningen att alla representerar samma d-separationer. Vi kallar hela mängden grafer som är markovekvivalent till en viss graf $\mathcal{G}$ för *markovekvivalensklassen* för $\mathcal{G}$. De sex graferna i Exempel 4.13 bildar markovekvivalensklassen för grafen $\mathcal{G}$ från Exempel 4.12. Om vi hade bildat grafiska modellen $(\mathcal{G}, \mathbf{X})$ baserat på att $\mathbf{X}$ uppfyller vissa relationer för betingat oberoende skulle vi behöva då att bestämma oss för vilken graf som vi vill använda till hierarkin. Ibland är valet enkelt:

Exempel 4.14. Vi såg i Exempel 4.1 att den simultana fördelningen $[X_1, X_2, X_3]^T$ för våra tre glödlampor från Exempel 3.4 och 2.11 är markovsk med avseende på grafen



Det följer från Sats 4.4 att modellen kan också representeras med två andra hierarkier:









eftersom alla tre har samma skelett och inga v-strukturer. Notera att i Exempel 4.11 såg vi att dessa tre grafer har samma d-separationer och är därför markovekvivalent. Den första grafen är intuitivt det bästa valet för att representera systemet eftersom vi vet att det finns en effekt av det första glödlampan på de andra två; nämligen, vi slår på glödlampa två och tre endast efter glödlampa ett har brunnit ut. Därför är det klart vilken graf vi borde använda.







I andra situationer där vi inte vet så mycket om systemet kan det vara svårare att bestämma vilken graf som är bäst. För att svara på denna fråga behöver man mer information och mer avancerade tekniker. Detta är ett stort fokus inom området *kausal inferens*. Vi kommer inte att hinna gå djupare in på detta ämne i den här boken. Istället sparar vi det till kurser på mastersnivån.

4.3 Uppgifter

4.1. [1] Vilka av följande grafer är enkla?



4.2. [1] Vilka av följande grafer är riktade? Oriktade? Blandade?




4.3. [1] Vilka av följande riktade grafer är acykliska?


- (a) $\mathcal{G}_1 = ([4], \{(1, 2), (1, 4), (2, 3), (4, 3)\})$
- (b) $\mathcal{G}_2 = ([5], \{(1, 2), (1, 5), (2, 3), (4, 2), (4, 3), (5, 1)\})$
- (c) $\mathcal{G}_3 = ([6], \{((1, 3), (2, 1), (2, 3), (3, 5), (4, 3), (4, 5), (5, 6), (6, 1), (6, 2))\})$
- (d) $\mathcal{G}_4 = ([4], \{(1, 2), (1, 4), (3, 2), (3, 4), (2, 4)\})$

(e) $\mathcal{G}_5 = ([6], \{(1, 2), (3, 1), (3, 2), (4, 3), (5, 1), (5, 4), (6, 3)\})$

4.4. [1] Skriv ned nodmängden och kantmängden till följande grafer:




4.5. [1] Hitta en stig mellan nod 1 och 4 i följande grafer. Hitta en vandring mellan 1 och 4 som inte är en stig i varje graf. Vilka av dessa vandringar (och stigar) är riktade? I vilka grafer kan du hitta en riktad vandring som inte är en stig?



4.6. [1] Vilka av följande grafer är sammanhängande? För graferna som inte är sammanhängande, identifiera deras sammanhängande komponenter.

- (a) $\mathcal{G}_1 = ([5], \{(1, 3), \{1, 4\}, (1, 5), (2, 3), \{2, 4\}\})$
 (b) $\mathcal{G}_2 = ([6], \{(2, 1), (2, 4), (4, 1), (5, 1), (6, 3)\})$
 (c) $\mathcal{G}_3 = ([8], \{\{1, 2\}, \{1, 5\}, \{1, 8\}, \{2, 6\}, \{3, 7\}, \{5, 6\}\})$
 (d) $\mathcal{G}_4 = ([10], \{(1, 2), (1, 7), (1, 8), (1, 10), (2, 7), (2, 10), (3, 5), (4, 6), (4, 9), (6, 9), (8, 10)\})$



4.7. [1] Låt $\mathcal{G}$ vara följande graf:



Vilka av följande är delgrafer till $\mathcal{G}$? Vilka av följande är inducerade delgrafer till $\mathcal{G}$?

- (a) $\mathcal{G}_1 = (\{2, 4, 5, 6\}, \{(2, 5), \{2, 6\}, (6, 5), (4, 5)\})$
 (b) $\mathcal{G}_2 = (\{1, 2, 4, 5, 6\}, \{(1, 5), \{1, 4\}, (2, 5), \{2, 6\}, (5, 6)\})$
 (c) $\mathcal{G}_3 = (\{2, 4, 5\}, \{(2, 5), (4, 5)\})$
 (d) $\mathcal{G}_4 = (\{1, 3, 4\}, \{(1, 3), (4, 3)\})$
 (e) $\mathcal{G}_5 = ([6], \{(2, 5), \{2, 6\}, (6, 5), (1, 3), \{1, 4\}, (4, 3)\})$

4.8. [1] Identifiera mängderna $\text{pa}_{\mathcal{G}}(i)$, $\text{ch}_{\mathcal{G}}(i)$, $\text{des}_{\mathcal{G}}(i)$, och $\text{an}_{\mathcal{G}}(i)$ för nod $i = 3$ i var och en av följande grafer:



4.9. [2] Betrakta den hierarkiska modellen som ges av

$$X_4 \mid vX_{1,2,3} = [0, 0, 0]^T \sim \text{Ber}(\theta_1)$$

$$X_4 \mid vX_{1,2,3} = [1, 0, 0]^T \sim \text{Ber}(\theta_1)$$

$$X_4 \mid vX_{1,2,3} = [0, 0, 1]^T \sim \text{Ber}(\theta_2)$$

$$X_4 \mid vX_{1,2,3} = [1, 0, 1]^T \sim \text{Ber}(\theta_2)$$

$$X_4 \mid vX_{1,2,3} = [0, 1, 0]^T \sim \text{Ber}(\theta_3)$$

$$X_4 \mid vX_{1,2,3} = [0, 1, 0]^T \sim \text{Ber}(\theta_3)$$

$$X_4 \mid vX_{1,2,3} = [0, 1, 1]^T \sim \text{Ber}(\theta_4)$$

$$X_4 \mid vX_{1,2,3} = [1, 1, 1]^T \sim \text{Ber}(\theta_4)$$

$$X_3 \mid vX_{\{1,2\}} = [0, 0]^T \sim \text{Ber}(\theta_5)$$

$$X_3 \mid vX_{\{1,2\}} = [0, 1]^T \sim \text{Ber}(\theta_5)$$

$$X_3 \mid vX_{\{1,2\}} = [1, 0]^T \sim \text{Ber}(\theta_6)$$

$$X_3 \mid vX_{\{1,2\}} = [1, 1]^T \sim \text{Ber}(\theta_6)$$

$$X_2 \mid = 0 \sim \text{Ber}(\theta_7)$$

$$X_2 \mid = 1 \sim \text{Ber}(\theta_8)$$

$$X_1 \sim \text{Ber}(\theta_9)$$

där $0 < \theta_1, \theta_2, \theta_3, \theta_4, \theta_5, \theta_6, \theta_7, \theta_8, \theta_9 < 1$. Följer det att

(a) $X_2 \perp\!\!\!\perp X_3 \mid ?$

(b) $X_2 \perp\!\!\!\perp X_3 \mid ?$

(c) $X_4 \perp\!\!\!\perp X_1 \mid vX_{\{2,3\}}?$

4.10. [2] Betrakta fördelningen $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5, X_6]^T$ där

$$X_1 = 0.25X_5 + N_1,$$

$$X_2 = -0.3X_3 + N_2,$$

$$X_3 = 0.75X_4 + N_3,$$

$$X_4 = N_4,$$

$$X_5 = -0.65X_2 + N_5,$$

$$X_6 = 0.1X_3 + 0.2X_4 + N_6,$$

med $N_1, N_2, N_3, N_4, N_5, N_6$ oberoende och $N(0, 1)$ -fördelade.

(a) Bestäm en acyklisk riktad graf med avseende på vilken $\mathbf{X}$ är markovsk.

(b) Följer det att $\mathbf{X}_{\{1,5\}} \perp\!\!\!\perp \mathbf{X}_{\{4,6\}} \mid vX_{\{2,3\}}?$ Svara med hjälp av en graf.

(c) Verifiera ditt svar till del (b) med hjälp av kovarianser.

4.11. [2] Anta att fördelningen $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5, X_6]^T$ uppfyller

$$X_3 \perp\!\!\!\perp X_2 \mid X_1,$$

$$X_4 \perp\!\!\!\perp \mathbf{X}_{\{1,2\}} \mid X_3,$$

$$X_5 \perp\!\!\!\perp \mathbf{X}_{\{1,3\}} \mid \mathbf{X}_{\{2,4\}},$$


$$X_6 \perp\!\!\!\perp \mathbf{X}_{\{1,3,4\}} \mid \mathbf{X}_{\{2,5\}}$$

(a) Visa att $\mathbf{X}_{\{1,3\}} \perp\!\!\!\perp \mathbf{X}_{\{5,6\}} \mid \mathbf{X}_{\{2,4\}}$ med hjälp av axiomen för betingat oberoende.

(b) Visa att $\mathbf{X}_{\{1,3\}} \perp\!\!\!\perp \mathbf{X}_{\{5,6\}} \mid \mathbf{X}_{\{2,4\}}$ med hjälp av en acyklisk riktad graf.

4.12. [2] Tre oberoende och jämna mynt singlar. Resultaten registreras med hjälp av tre binära stokastiska variabler X_1, X_2, X_3 där $X_i = 1$ och $X_i = 0$ motsvarar krona respektive klave. Låt $X_4 = X_1 + X_2 + X_3$. Hitta en acyklisk riktad graf med så få kanter som möjligt med avseende på vilken fördelningen $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ är markovsk. Kan du dra slutsatsen att $X_1 \perp\!\!\!\perp \mathbf{X}_{\{2,3\}} \mid X_4$ med hjälp av grafen? Verkar slutsatsen rimlig? Hur många grafer är i din grafs markovekvivalensklass?

4.13. [1] Betrakta en grafisk modell $(\mathcal{G}, \mathbf{X})$ där $\mathcal{G}$ är den acykliska riktade grafen




Vilka av följande relationer uppfylls av $\mathbf{X}$ enligt grafen $\mathcal{G}$?

- (a) $\mathbf{X}_{\{2,5\}} \perp\!\!\!\perp X_4 \mid \mathbf{X}_{\{1,3,6\}}$
- (b) $X_1 \perp\!\!\!\perp X_2 \mid \mathbf{X}_{\{3,5\}}$
- (c) $X_6 \perp\!\!\!\perp \mathbf{X}_{1,3} \mid X_4$
- (d) $X_6 \perp\!\!\!\perp X_1$
- (e) $X_5 \perp\!\!\!\perp \mathbf{X}_{\{3,4\}} \mid \mathbf{X}_{\{1,2,6\}}$.


4.14. [2] Anta att den simultana fördelningen $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ endast uppfyller följande relationer:

$$X_2 \perp\!\!\!\perp X_3 \mid X_1, \quad X_3 \perp\!\!\!\perp X_2 \mid X_1, \quad X_1 \perp\!\!\!\perp X_4 \mid \mathbf{X}_{\{2,3\}}, \quad X_4 \perp\!\!\!\perp X_1 \mid \mathbf{X}_{\{2,3\}}.$$


Betrakta följande grafer:




(A)




(B)




(C)



(D)



(E)



(F)

- (a) Med avseende på vilka av dessa grafer är $\mathbf{X}$ markovsk?
- (b) Vilka grafer representerar exakt samma relationer som uppfylls av fördelningen $\mathbf{X}$?
- (c) Vad kan du säga om graferna som identifierades i del (b) jämfört med graferna som identifierades i del (a)?

4.15. [1] Vi betraktar en fördelning $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ och observerar att fördelningen uppfyller

$$X_4 \perp\!\!\!\perp X_1 \mid X_2, X_3 \quad \text{och} \quad X_3 \perp\!\!\!\perp X_2 \mid X_1.$$

- (a) Är $\mathbf{X}$ markovsk med avseende på grafen $\mathcal{G} = ([4], E)$ där

$$E = \{(1, 3), (2, 1), (2, 3), (2, 4), (3, 4)\}?$$

- (b) Är $\mathbf{X}$ markovsk med avseende på grafen $\mathcal{G} = ([4], E)$ där

$$E = \{(2, 1), (2, 4), (3, 1), (3, 4)\}?$$

- (c) Är $\mathbf{X}$ markovsk med avseende på grafen $\mathcal{G} = ([4], E)$ där

$$E = \{(1, 3), (1, 4), (2, 1), (2, 4), (3, 4)\}?$$

- (d) Är $\mathbf{X}$ markovsk med avseende på grafen $\mathcal{G} = ([4], E)$ där

$$E = \{(1, 2), (1, 3), (2, 4), (3, 4)\}?$$

(e) Betrakta graferna ovan med avseende på vilka $\mathbf{X}$ är markovsk. Vilken graf föredrar du? Varför?

4.16. [1] En *komplett* acyklisk riktad graf $\mathcal{G}$ på nodmängd $[n]$ är en acyklisk riktad graf med kantmängd som innehåller en kant mellan i och j för alla $i, j \in [n]$ med $i \neq j$. Visa att en godtycklig fördelning $\mathbf{X} = [X_1, \dots, X_n]^T$ är markovsk med avseende på $\mathcal{G}$. Varför är detta värdelöst?

4.17. [2] Anta att $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim N(\mathbf{0}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 7 & -2 & 1 & -2 \\ -2 & 7 & -2 & 1 \\ 1 & -2 & 7 & -2 \\ -2 & 1 & -2 & 7 \end{bmatrix}.$$


Hitta två icke-kompleta acykliska riktade grafer $\mathcal{G}$ och $\mathcal{H}$ så att $\mathbf{X}$ är markovsk med avseende på både $\mathcal{G}$ och $\mathcal{H}$ men $\mathcal{G}$ och $\mathcal{H}$ inte är markovekvivalenta.

4.18. [2] Betrakta fördelningen $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ som endast uppfyller relationerna $X_4 \perp\!\!\!\perp X_1 \mid X_2, X_3$, $X_3 \perp\!\!\!\perp X_2 \mid X_1, X_4$, $X_1 \perp\!\!\!\perp X_4 \mid X_2, X_3$ och $X_2 \perp\!\!\!\perp X_3 \mid X_1, X_4$.

(a) Visa att det inte finns någon acyklisk riktad graf med nodmängd $[4]$ som har endast d-separationerna $1 \perp_{\mathcal{G}} 4 \mid \{2, 3\}$, $2 \perp_{\mathcal{G}} 3 \mid \{1, 4\}$, $4 \perp_{\mathcal{G}} 1 \mid \{2, 3\}$ och $3 \perp_{\mathcal{G}} 2 \mid \{1, 4\}$.

(b) Vad säger del (a) om fördelningen $\mathbf{X}$?


4.19. [1] Betrakta följande acykliska riktade graf $\mathcal{G}$:




(a) Vad är $\mathcal{G}$'s skelett?

(b) Vilka är $\mathcal{G}$'s v-strukturer?


(c) Vilka av följande grafer är markovekvivalent till $\mathcal{G}$?




(A)



(B)



(C)



(D)

(d) Består $\mathcal{G}$'s markovekvivalensklass endast av $\mathcal{G}$ samt de grafer som identifierades i del (c)? Om svaret är nej bestäm markovekvivalensklassen till $\mathcal{G}$.

4.20. [2] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5]^T$ vara $N(\boldsymbol{\mu}, \Sigma)$ -fördelad där

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \\ \mu_5 \end{bmatrix} \quad \text{och} \quad \Sigma = \begin{bmatrix} \sigma_{1,1} & \sigma_{1,2} & \sigma_{1,3} & \sigma_{1,4} & \sigma_{1,5} \\ \sigma_{1,2} & \sigma_{2,2} & \sigma_{2,3} & \sigma_{2,4} & \sigma_{2,5} \\ \sigma_{1,3} & \sigma_{2,3} & \sigma_{3,3} & \sigma_{3,4} & \sigma_{3,5} \\ \sigma_{1,4} & \sigma_{2,4} & \sigma_{3,4} & \sigma_{4,4} & \sigma_{5,5} \\ \sigma_{1,5} & \sigma_{2,5} & \sigma_{3,5} & \sigma_{4,5} & \sigma_{5,5} \end{bmatrix}$$

Anta att $\mathbf{X}$ uppfyller

$$\begin{aligned} X_5 &\perp\!\!\!\perp \mathbf{X}_{\{1,2\}} \mid \mathbf{X}_{\{3,4\}}, \\ X_4 &\perp\!\!\!\perp X_1 \mid \mathbf{X}_{\{2,3\}}, \\ X_3 &\perp\!\!\!\perp X_2 \mid X_1. \end{aligned}$$

Föreslå en rimlig hierarki för modellen och skriv modellen som en hierarkisk modell av typen som introducerades i kapitel 3.

4.21. [3] Betrakta följande hierarki:

$$\begin{aligned} X_4 \mid X_2 = x_2, X_3 = x_3 &\sim \text{U}(0, x_2 + x_3 + 1), \\ X_3 &\sim \text{Bin}(10, \theta), \\ X_2 \mid X_1 = x_1 &\sim \text{Ber}(x_1), \\ X_1 &\sim \text{Beta}(\alpha, \beta) \end{aligned}$$

där $\alpha, \beta > 0$, $0 < \theta < 1$, $X_4 \perp\!\!\!\perp X_1 \mid X_2, X_3$ och $X_3 \perp\!\!\!\perp X_1, X_2$. Identifiera en alternativ hierarki för samma fördelning $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$.

4.22. [2] Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim \text{N}(\mathbf{1}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 1 & 1 & 0 & 1 \\ 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 1 & 1 & 3 \end{bmatrix}.$$

(a) Visa att $\mathbf{X}$ är markovsk med avseende på $\mathcal{G} = ([4], E)$ där

$$E = \{(1, 2), (3, 4), (1, 4)\}.$$

(b) Använd grafen i del (a) för att ge en hierarkisk representation av modellen som i föreläsning 3.

(c) Ge en annan hierarkisk representation för modellen än den som du gav i del (b).


4.23. [1] Vi har den simultana fördelningen $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$. Vi tror att X_1, X_3 och X_2, X_4 beror på variablerna Θ_1 respektive Θ_2 . Vi antar också att

$$\begin{aligned} \Theta_1 &\perp\!\!\!\perp \Theta_2, \\ X_1 &\perp\!\!\!\perp \Theta_2 \mid \Theta_1, \\ X_3 &\perp\!\!\!\perp \Theta_2, X_1 \mid \Theta_1, \\ X_2 &\perp\!\!\!\perp \Theta_1 \mid \Theta_2, X_1, X_3, \\ X_4 &\perp\!\!\!\perp \Theta_1, X_2 \mid \Theta_2, X_1, X_3. \end{aligned}$$

Visa att den betingade fördelningen $f_{\Theta_1, \Theta_2 \mid \mathbf{X}}(\theta_1, \theta_2 \mid \mathbf{x})$ uppfyller

$$f_{\Theta_1, \Theta_2 \mid \mathbf{X}}(\theta_1, \theta_2 \mid \mathbf{x}) = f_{\Theta_1 \mid \mathbf{X}}(\theta_1 \mid \mathbf{x}) f_{\Theta_2 \mid \mathbf{X}}(\theta_2 \mid \mathbf{x}).$$

4.24. [1] Låt $\mathcal{G}$ beteckna följande graf



Anta att $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5, X_6, X_7, X_8]^T$ är markovsk med avseende på $\mathcal{G}$. Vet vi om $\mathbf{X}$ uppfyller följande oberoenderelationer?

- (a) $\mathbf{X}_{\{1,2\}} \perp\!\!\!\perp X_7 \mid \mathbf{X}_{\{4,5\}}?$
- (b) $\mathbf{X}_{\{2,6\}} \perp\!\!\!\perp \mathbf{X}_{\{3,4,7\}} \mid X_1?$
- (c) $X_4 \perp\!\!\!\perp X_7 \mid \mathbf{X}_{\{3,5\}}?$
- (d) $X_8 \perp\!\!\!\perp X_1 \mid \mathbf{X}_{\{4,5\}}?$
- (e) $\mathbf{X}_{\{3,8\}} \perp\!\!\!\perp \mathbf{X}_{\{1,6\}} \mid \mathbf{X}_{\{2,5\}}?$

4.25. [1] Vad är skelettet och v-strukturerna för grafen $\mathcal{G}$ i Uppgift 4.24? Hur många grafer finns i markovekvivalensklassen för $\mathcal{G}$?

4.26. [1] Anta att fördelningen $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5, X_6, X_7]^T$ uppfyller

$$\begin{aligned} X_2 &\perp\!\!\!\perp X_1, \\ X_3 &\perp\!\!\!\perp X_2 \mid X_1, \\ X_4 &\perp\!\!\!\perp \mathbf{X}_{\{1,3\}} \mid X_2, \\ X_5 &\perp\!\!\!\perp \mathbf{X}_{\{1,2\}} \mid \mathbf{X}_{\{3,4\}}. \end{aligned}$$

- (a) Visa att $X_1 \perp\!\!\!\perp X_2 \mid \mathbf{X}_{\{3,4,5\}}$ med hjälp av axiomen för oberoende.
- (b) Visa att $X_1 \perp\!\!\!\perp X_2 \mid \mathbf{X}_{\{3,4,5\}}$ med hjälp av en graf.
- (c) Hur kan du visa att $X_1 \perp\!\!\!\perp X_2 \mid \mathbf{X}_{\{3,4,5\}}$ om du antar att $\mathbf{X}$ är normalfördelad?
- (d) Vilken metod tycker du är bäst? Varför?

4.27. [3] En riktad kant (i, j) i en acyklisk riktad graf $\mathcal{G} = ([n], E)$ kallas för en *täckt kant* om

$$\text{pa}_{\mathcal{G}}(j) = \text{pa}_{\mathcal{G}}(i) \cup \{i\}.$$

Anta att $\mathcal{G} = ([n], E)$ och $\mathcal{H} = ([n], E')$ där

$$E' = \{(j, i)\} \cup E \setminus \{(i, j)\}$$

där (i, j) är en täckt kant i $\mathcal{G}$. Visa att $\mathcal{G}$ och $\mathcal{H}$ är markovekvivalenta.

4.28. [3] Låt $\mathcal{G} = ([n], E)$ vara en acyklisk riktad graf och beteckna $\mathcal{G}$'s skelett med $G = ([n], E')$. Visa att $\{i, j\} \notin E'$ om och endast om det finns en mängd $C \subseteq [n] \setminus \{i, j\}$ så att i och j är d-separerade i $\mathcal{G}$ givet C .

4.29. [3] Låt $\mathcal{G} = ([n], E)$ vara en acyklisk riktad graf. Visa att $i, j \in [n]$ är grannar i $\mathcal{G}$ om och endast om det inte finns någon $C \subseteq [n] \setminus \{i, j\}$ så att i och j är d-separerade givet C i $\mathcal{G}$.

4.30. [2] Betrakta den hierarkiska modellen ges av

$$\begin{aligned} Z &= X + Y, \\ X \mid \Theta_1 = \theta_1 &\sim \text{Bin}(5, \theta_1), \\ Y \mid \Theta_1 = \theta_1 &\sim \text{Bin}(5, \theta_1), \\ \Theta_1 \mid A_1 = \alpha_1, B_1 = \beta_1 &\sim \text{Beta}(\alpha_1, \beta_1), \\ \Theta_2 \mid A_2 = \alpha_2, B_2 = \beta_2 &\sim \text{Beta}(\alpha_2, \beta_2), \\ A_1 \mid \Gamma = \gamma &\sim \text{Exp}(\gamma), \\ B_1 \mid \Gamma = \gamma &\sim \text{Exp}(\gamma), \\ A_2 \mid \Gamma = \gamma &\sim \text{Exp}(\gamma), \\ B_2 \mid \Gamma = \gamma &\sim \text{Exp}(\gamma), \\ \Gamma &\sim \text{Gamma}(2, 4). \end{aligned}$$

där vi antar att

$$\begin{aligned}
Z &\perp\!\!\!\perp \Theta_1, \Theta_2, A_1, B_1, A_2, B_2, \Gamma \mid X, Y, \\
X &\perp\!\!\!\perp Y, \Theta_2, A_1, B_1, A_2, B_2, \Gamma \mid \Theta_1, \\
Y &\perp\!\!\!\perp X, \Theta_1, A_1, B_1, A_2, B_2, \Gamma \mid \Theta_2, \\
\Theta_1 &\perp\!\!\!\perp \Theta_2, A_2, B_2, \Gamma \mid A_1, B_1, \\
\Theta_2 &\perp\!\!\!\perp \Theta_1, A_1, B_1, \Gamma \mid A_2, B_2, \\
A_1 &\perp\!\!\!\perp B_1, A_2, B_2 \mid \Gamma, \\
B_1 &\perp\!\!\!\perp A_1, A_2, B_2 \mid \Gamma, \\
A_2 &\perp\!\!\!\perp B_2, A_1, B_1 \mid \Gamma, \quad \text{och} \\
B_2 &\perp\!\!\!\perp A_1, B_1, A_2 \mid \Gamma.
\end{aligned}$$

- (a) Bestäm en graf med avseende på vilken den simultana fördelningen

$$\mathbf{X} = [\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2, X, Y, Z]^T$$

är markovsk. Modellen kan då definieras genom att ansätta de betingade fördelningarna ovan samt kräva att $(\mathbf{X}, \mathcal{G})$ är en grafisk modell istället för att ange listan över obereonderelationer ovan. Vilken definition föredrar du?

- (b) Låt $\mathcal{G} = (V, E)$ där

$$V = \{\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2, X, Y, Z\}$$

vara din graf från del (a). Visa följande:

- (a) $[\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2, X, Y]^T$ är markovsk med avseende på den inducerade delgrafen på

$$\{\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2, X, Y\}$$

av $\mathcal{G}$.

- (b) $[\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2, X]^T$ är markovsk med avseende på den inducerade delgrafen på

$$\{\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2, X\}$$

av $\mathcal{G}$.

- (c) $[\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2, Y]^T$ är markovsk med avseende på den inducerade delgrafen på

$$\{\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2, Y\}$$

av $\mathcal{G}$.

- (d) $[\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2]^T$ är markovsk med avseende på den inducerade delgrafen på

$$\{\Gamma, A_1, B_1, A_2, B_2, \Theta_1, \Theta_2\}$$

av $\mathcal{G}$.

- 4.31.** [3] Låt $\mathcal{G} = ([n], E)$ vara en acyklisk riktad graf. Låt $i, j, k \in [n]$ vara så att deras inducerade delgraf i $\mathcal{G}$:s skelett endast har kanter $\{j, i\}$ och $\{j, k\}$. Visa att följande är ekvivalenta:

- (a) $i \rightarrow j \leftarrow k$ är en v-struktur i $\mathcal{G}$.
(b) Det finns en delmängd $C \subset [n] \setminus \{i, k\}$ som inte innehåller j så att i och k är d-separerade givet C i $\mathcal{G}$.
(c) Alla delmängder $C \subset [n] \setminus \{i, k\}$ som innehåller j d-separerar inte i och j i $\mathcal{G}$.


- 4.32.** [3] För ett givet positivt heltal n , visa att det finns en acyklisk riktad graf med nodmängd $[n]$ så att *alla* fördelningar $[X_1, \dots, X_n]^T$ är markovska till denna graf. Hur många sådana grafer finns det?

- 4.33.** [3] Det i:te *fibonacci*talet F_i definieras enligt $F_0 = 1, F_1 = 1$ och $F_i = F_{i-1} + F_{i-2}$ för alla $i > 1$. För ett positivt heltal n , låt $\mathcal{I}_n = ([n], E_n)$ vara den oriktade grafen med kantmängden

$$E_n = \{\{i, i+1\} : i \in [n-1]\}.$$

Visa att antalet markovekvivalensklasser av grafer med nodmängd $[n]$ och skelett $\mathcal{I}_n$ är F_n .

4.34. [1] Hur många acykliska riktade grafer ligger i markovekvivalensklassen för följande graf?



Kapitel 5

Nu har vi byggt upp en stor samling av statistiska modeller (båda endimensionella och flerdimensionella) som kan bero på en eller flera parametrar $\theta_1, \dots, \theta_d$. I praktiken får vi inte dessa parametrar men istället bara data vilka vi vill använda för att skatta parametrarna. Ett vanligt antagande är att datan är ett stickprov $x_1, \dots, x_n$; det vill säga, en sekvens av utfall där $X_1 = x_1, \dots, X_n = x_n$ och $X_1, \dots, X_n$ är oberoende och likafördelade.

Det följer från oberoende av $X_1, \dots, X_n$ att den simultana fördelningen av $\mathbf{X} = [X_1, \dots, X_n]^T$ är relativt enkel:

$$f_{\mathbf{X}}(x_1, \dots, x_n) = f_{X_1}(x_1) \cdots f_{X_n}(x_n) = \prod_{i=1}^n f_{X_i}(x_i).$$

Denna fördelning beror ofta på några parametrar $\boldsymbol{\theta} = (\theta_1, \dots, \theta_d)$; dvs.

$$f_{\mathbf{X}}(x_1, \dots, x_n | \boldsymbol{\theta}) = \prod_{i=1}^n f_{X_i}(x_i | \boldsymbol{\theta}).$$

Exempel 5.1. Låt $X_1, \dots, X_n$ vara brinntiderna i år för n oberoende glödlampor. Vi antar att $X_1, \dots, X_n$ är oberoende och likafördelade med sannolikhetsfunktion

$$f_X(x) = \lambda e^{-\lambda x}, \quad 0 \leq x < \infty, \quad \lambda > 0;$$

dvs. $X_1, \dots, X_n$ är $\text{Exp}(\lambda)$ -fördelade. Eftersom $X_1, \dots, X_n$ är oberoende har vi

$$f_{\mathbf{X}}(x_1, \dots, x_n | \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda e^{-\lambda \sum_{i=1}^n x_i} = \lambda^n e^{-n\lambda \bar{x}},$$

där $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ är stickprovsmedelvärdet av $x_1, \dots, x_n$. Vi kan använda denna simultana fördelning för att beräkna vissa sannolikheter; exempelvis, sannolikheten att alla glödlamporna håller längre än 2 år:

$$\begin{aligned} P(X_1 > 2, \dots, X_n > 2) &= P(X_1 > 2) \cdots P(X_n > 2) && \text{(oberoende),} \\ &= P(X > 2)^n && \text{(likafördelade),} \\ &= \left(\int_2^\infty \lambda e^{-\lambda x} dx \right)^n, \\ &= (e^{-2\lambda})^n, \\ &= e^{-2n\lambda}. \end{aligned}$$

5.1 Statistikor

I Exempel 5.1 skrev vi den simultana fördelningen av $X_1, \dots, X_n$ som en funktion av $\bar{x}$ – ett värde som sammanfattar datan $x_1, \dots, x_n$:

$$f_{\mathbf{X}}(x_1, \dots, x_n | \lambda) = \lambda^n e^{-n\lambda \bar{x}}.$$

Det är ofta användbart att sammanfatta ett stickprov. Detta görs med hjälp av en funktion

$$T: \mathbb{R}^n \longrightarrow \mathbb{R}^m$$

där $T(X_1, \dots, X_n) = T(\mathbf{X}) = \mathbf{Y}$ kallas för en *statistika*.

Exempel 5.2. Några vanliga statistikor är

- *stickprovsmedelvärde*: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$,
- *stickprovsvarians*: $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, och
- *stickprovsstandardavvikelsen*: $S = \sqrt{S^2}$.

Om vi har ett stickprov $x_1, \dots, x_n$ skriver vi

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{respektive} \quad s = \sqrt{s^2}.$$

Eftersom T är en funktion av stokastiska variabler är $\mathbf{Y} = T(\mathbf{X})$ bara en transformation av stokastiska variabler. Det följer att en statistika har en fördelning. Denna fördelning kallas *samplingfördelningen*. Samplingfördelningen för statistikor som stickprovsmedelvärde och stickprovsvarians har bra egenskaper:

Sats 5.1. För $X_1, \dots, X_n$ oberoende och likafördelade med väntevärde och varians μ respektive $\sigma^2 < \infty$ har vi att

1. $E[\bar{X}] = \mu$,
2. $\text{Var}[\bar{X}] = \frac{\sigma^2}{n}$, och
3. $E[S^2] = \sigma^2$.

Bevis. För (a) har vi, med hjälp av väntevärdets linjäritet, att

$$E[\bar{X}] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} n E[X_1] = \mu,$$

där vi använder att $E[X_1] = E[X_i]$ för alla $i = 1, \dots, n$ eftersom $X_1, \dots, X_n$ är likafördelade.

För (b) har vi att

$$\text{Var}[\bar{X}] = \text{Var}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n^2} \sum_{i=1}^n \text{Var}[X_i] = \frac{1}{n^2} n \text{Var}[X_1] = \frac{\sigma^2}{n},$$

där vi först använder att $X_1, \dots, X_n$ är oberoende och sedan att de är likafördelade.

För (c) observerar vi först att

$$\begin{aligned} \sum_{i=1}^n X_i^2 &= \sum_{i=1}^n (X_i - \bar{X} + \bar{X})^2, \\ &= \sum_{i=1}^n ((X_i - \bar{X})^2 + 2\bar{X}(X_i - \bar{X}) + \bar{X}^2), \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 + 2\bar{X} \sum_{i=1}^n X_i - \sum_{i=1}^n 2\bar{X}^2 + \sum_{i=1}^n \bar{X}^2, \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 + 2n\bar{X}^2 - 2n\bar{X}^2 + n\bar{X}^2, \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 + n\bar{X}^2. \end{aligned}$$

Därför har vi att

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right).$$

Det följer att

$$\begin{aligned} \mathbb{E}[S^2] &= \mathbb{E}\left[\frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)\right], \\ &= \frac{1}{n-1} \left(\sum_{i=1}^n \mathbb{E}[X_i^2] - n\mathbb{E}[\bar{X}^2]\right), \\ &= \frac{1}{n-1} (n\mathbb{E}[X_1^2] - n\mathbb{E}[\bar{X}^2]), \\ &= \frac{1}{n-1} \left(n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right)\right), \end{aligned}$$

som visar att $\mathbb{E}[S^2] = \sigma^2$. □

Sats 5.1 säger att $\bar{X}$ och S^2 är bra skattningar för μ respektive σ^2 i meningen att det är bra att väntevärdet är vad vi vill skatta. Medan det kan verka konstigt att dela med $n-1$ i den tredje formeln i Sats 5.1 ska vi se att det är användbart när vi diskuterar *väntevärdesriktiga skattningar*.

Antag att $X_1, \dots, X_n$ är oberoende och likafördelade med täthetsfunktion (eller sannolikhetsfunktion) $f_X(x)$ i en läge-skalfamilj med standardtäthetsfunktion $f_Z(z)$. I så fall kan vi använda samplingfördelningen för $\bar{Z}$ för att få direkt en formel för samplingfördelningen för $\bar{X}$. Eftersom $f_X(x)$ är i läge-skalfamiljen med standardtäthetsfunktion $f_Z(z)$ har vi att $X_i = \sigma Z_i + \mu$ för några μ och $\sigma > 0$ där Z_i är $f_Z(z)$ -fördelade. Eftersom $X_1, \dots, X_n$ är oberoende följer det även att $Z_1, \dots, Z_n$ är oberoende. Vi har också att

$$\bar{X} = \sigma \bar{Z} + \mu.$$

Om vi har täthetsfunktion $f_{\bar{Z}}(\bar{z})$ för $\bar{Z}$ får vi att

$$f_{\bar{X}}(\bar{x}) = \frac{1}{\sigma} f_{\bar{Z}}\left(\frac{\bar{x} - \mu}{\sigma}\right).$$

Det följer att samplingfördelningarna för $\bar{X}$ också bildar en läge-skalfamilj. Det vill säga om vi har läge-skalfamiljen

$$\mathcal{F} = \left\{ f_X(x) : f_X(x) = \frac{1}{\sigma} f_Z\left(\frac{x - \mu}{\sigma}\right) : (\mu, \sigma) \in \mathbb{R} \times \mathbb{R}_{>0} \right\}$$

med standardtäthetsfunktion $f_Z(z)$ och vi tar $X_1, \dots, X_n$ oberoende och $f_X(x)$ -fördelade (för ett fixt positivt heltal n) är

$$\bar{\mathcal{F}} = \{ f_{\bar{X}}(\bar{x}) : X_1, \dots, X_n \text{ oberoende och } f_X(x)\text{-fördelade för } f_X(x) \in \mathcal{F} \}$$

också en läges-skalfamilj.

Exempel 5.3. Låt $X_1, \dots, X_n$ vara oberoende och $\text{Exp}(\lambda)$ -fördelade; dvs. $X_1, \dots, X_n$ har täthetsfunktion

$$f_X(x|\lambda) = \lambda e^{-\lambda x}.$$

Detta är en läge-skalfamilj med standardtäthetsfunktion

$$f_Z(z) = e^{-z}.$$

För $Z_1, \dots, Z_n$ oberoende och $\text{Exp}(1)$ -fördelade såg vi i kapitel 1 att

$$Y = \sum_{i=1}^n Z_i \sim \text{Gamma}(n, 1).$$

Därmed har vi

$$f_Y(y) = \frac{1}{\Gamma(n)} y^{n-1} e^{-y}.$$

Det följer att $\bar{Z} = \frac{1}{n} Y$ har sannolikhetsfunktion

$$f_{\bar{Z}}(\bar{z}) = n f_Y(n\bar{z}) = \frac{n}{\Gamma(n)} (n\bar{z})^{n-1} e^{-n\bar{z}} = \frac{n^n}{\Gamma(n)} \bar{z}^{n-1} e^{-n\bar{z}}.$$

Det följer från den föregående diskussionen att

$$f_{\bar{X}}(\bar{x}) = \lambda f_{\bar{Z}}(\lambda \bar{x}) = \frac{n^n \lambda}{\Gamma(n)} (\lambda \bar{x})^{n-1} e^{-n\lambda \bar{x}} = \frac{(n\lambda)^n}{\Gamma(n)} \bar{x}^{n-1} e^{-(n\lambda)\bar{x}}.$$

Så vi får att $\bar{X} \sim \text{Gamma}(n, n\lambda)$.

5.1.1 Samplingfördelningar för normalfördelade stickprov

Med hjälp av satserna från de tidigare kapitlen kan vi hitta samplingfördelningarna för $\bar{X}$ och S^2 när $X_1, \dots, X_n$ är oberoende och $N(\mu, \sigma^2)$ -fördelade. Till exempel har vi att

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} X_1 + \dots + \frac{1}{n} X_n,$$

bara är en linjär transformation av $\mathbf{X} = (X_1, \dots, X_n) \sim N(\mu \mathbf{1}_n, \sigma^2 \mathbf{I}_n)$ där $\mathbf{1}_n = [1, 1, \dots, 1]^T \in \mathbb{R}^n$ och $\mathbf{I}_n$ betecknar identitetsmatrisen av storlek $n \times n$. Sats 2.2 säger att för $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$, $A \in \mathbb{R}^{k \times n}$ en matris av full rang med $k \leq n$ och $\mathbf{b} \in \mathbb{R}^k$ har vi att $A\mathbf{X} + \mathbf{b} \sim N(A\boldsymbol{\mu} + \mathbf{b}, A\Sigma A^T)$. Vi har även att

$$E[A\mathbf{X} + \mathbf{b}] = A E[\mathbf{X}] + \mathbf{b}$$

och

$$\text{Cov}[A\mathbf{x} + \mathbf{b}] = A \text{Cov}[\mathbf{X}] A^T.$$

I vår situation där $X_1, \dots, X_n$ är likafördelade med väntevärde μ har vi att $E[\mathbf{X}] = \mu \mathbf{1}_n$ samt $\text{Cov}[\mathbf{X}] = \sigma^2 \mathbf{I}_n$ eftersom $X_1, \dots, X_n$ är oberoende. Om vi låter

$$A = \begin{bmatrix} \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{bmatrix} \in \mathbb{R}^{1 \times n}$$

har vi $\bar{X} \sim N(\mu, \sigma^2/n)$ eftersom

$$A\mu \mathbf{1}_n = \begin{bmatrix} \frac{1}{n} & \dots & \frac{1}{n} \end{bmatrix} \begin{bmatrix} \mu \\ \vdots \\ \mu \end{bmatrix} = \sum_{i=1}^n \frac{1}{n} \mu = \mu,$$

och

$$A\sigma^2 \mathbf{I}_n A^T = \begin{bmatrix} \frac{1}{n} & \dots & \frac{1}{n} \end{bmatrix} \begin{bmatrix} \sigma^2 & 0 & \dots & 0 \\ 0 & \sigma^2 & & \vdots \\ \vdots & & \ddots & 0 \\ 0 & \dots & 0 & \sigma^2 \end{bmatrix} \begin{bmatrix} \frac{1}{n} \\ \vdots \\ \frac{1}{n} \end{bmatrix} = \frac{\sigma^2}{n}.$$

Så givet $X_1, \dots, X_n$ oberoende och $N(\mu, \sigma^2)$ -fördelade har vi att $\bar{X} \sim N(\mu, \sigma^2/n)$. Vi kan också bestämma samplingfördelningen för S^2 med lite mer arbete. Först ska vi bevisa ett annat användbart faktum.

Sats 5.2. Låt $X_1, \dots, X_n$ vara oberoende och $N(\mu, \sigma^2)$ -fördelade. Då är $\bar{X} \perp S^2$.

Bevis. Vi kan skriva S^2 som

$$\begin{aligned} S^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \\ &= \frac{1}{n-1} \left((X_1 - \bar{X})^2 + \sum_{i=2}^n (X_i - \bar{X})^2 \right), \\ &= \frac{1}{n-1} \left(\left(-\sum_{i=2}^n (X_i - \bar{X}) \right)^2 + \sum_{i=2}^n (X_i - \bar{X})^2 \right). \quad (\text{eftersom } \sum_{i=1}^n (X_i - \bar{X}) = 0) \end{aligned}$$

Så S^2 är en funktion av $X_2 - \bar{X}, \dots, X_n - \bar{X}$. Med hjälp av Sats 2.2 vet vi att $[\bar{X}, X_2 - \bar{X}, \dots, X_n - \bar{X}]^T$ är normalfördelad. Vi har också att

$$\begin{aligned} \text{Cov}[\bar{X}, X_i - \bar{X}] &= \text{Cov}[\bar{X}, X_i] - \text{Cov}[\bar{X}, \bar{X}], \\ &= \frac{1}{n} \sum_{j=1}^n \text{Cov}[X_j, X_i] - \frac{1}{n^2} \sum_{j=1}^n \sum_{k=1}^n \text{Cov}[X_j, X_i], \\ &= \frac{1}{n} \sigma^2 - \frac{1}{n^2} n \sigma^2, \\ &= 0. \end{aligned}$$

Med hjälp av Sats 2.4 följer det att $\bar{X} \perp [X_2 - \bar{X}, \dots, X_n - \bar{X}]^T$ och därför är $\bar{X} \perp S^2$ eftersom S^2 är en funktion av $[X_2 - \bar{X}, \dots, X_n - \bar{X}]^T$. $\square$

För att bestämma samplingfördelningen av S^2 behöver vi några användbara fakta om χ^2 -fördelningen som vi kommer att använda utan bevis. Notera dock att (b) kan visas med hjälp av formeln för summan av oberoende gammafördelade stokastiska variabler som vi använde i Exempel 1.2 och (a) kan visas igenom att betrakta variabeltransformationen $Y = X^2$.

Lemma 5.1. *Följande fakta gäller för χ^2 -fördelade stokastiska variabler:*

(a) Om $Z \sim N(0, 1)$ så gäller det att $Z^2 \sim \chi^2(1)$.

(b) Om $X_1, \dots, X_n$ är oberoende och $X_i \sim \chi^2(p_i)$ så gäller det att $X_1 + \dots + X_n \sim \chi^2(p_1 + \dots + p_n)$.

Nu kan vi bestämma samplingfördelningen för S^2 när $X_1, \dots, X_n$ är oberoende och $N(\mu, \sigma^2)$ -fördelade.

Sats 5.3. *Låt $X_1, \dots, X_n$ vara oberoende och $N(\mu, \sigma^2)$ -fördelade. Då är*

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1);$$

dvs. den stokastiska variabeln $Y = \frac{(n-1)S^2}{\sigma^2}$ har täthetsfunktion

$$f_Y(y) = \frac{1}{\Gamma\left(\frac{n-1}{2}\right) 2^{\frac{n-1}{2}}} y^{\frac{n-1}{2}-1} e^{-\frac{y}{2}}.$$

Bevis. Anta att $X_1, \dots, X_n$ är oberoende och $N(0, 1)$ -fördelade. I det som följer låt $\bar{X}_k$ och S_k^2 beteckna stickprovsmedelvärde respektive stickprovsvariansen för de första k variablerna i $X_1, \dots, X_n$. I Uppgift 5.6 kommer ni bevisa att

$$(n-1)S_n^2 = (n-2)S_{n-1}^2 + \left(\frac{n-1}{n}\right)(X_n - \bar{X}_{n-1})^2.$$

Vi bevisar nu satsen igenom induktion på n . Definiera $0 \times S_1^2 = 0$ och betrakta fallet $n = 2$. Vi har från vår rekursionsformel för $(n-1)S_n^2$ att

$$S_2^2 = \frac{1}{2}(X_2 - X_1)^2.$$

Med hjälp av Sats 2.2 ser vi att $X_2 - X_1 \sim N(0, 2)$ och därmed är $\frac{X_2 - X_1}{\sqrt{2}} \sim N(0, 1)$. Från del (a) i Lemma 5.1 följer det att $S_2^2 \sim \chi^2(1)$.

Nu antar vi att $(n-1)S_n^2 \sim \chi^2(n-1)$ för $n = k$ och betraktar $n = k+1$. För $n = k+1$ får vi

$$kS_{k+1}^2 = (k-1)S_k^2 + \left(\frac{k}{k+1}\right)(X_{k+1} - \bar{X}_k)^2$$

från vår rekursionsformel. Det följer på samma sätt som i beviset av Sats 5.2 att $(k/(k+1))(X_{k+1} - \bar{X}_k)^2 \perp (k-1)S_k^2$. Vi har också att $(k/(k+1))(X_{k+1} - \bar{X}_k)^2 \sim \chi^2(1)$ eftersom $X_{k+1} - \bar{X}_k$ är normalfördelad med väntevärde 0 och varians

$$\text{Var}[X_{k+1} - \bar{X}_k] = \frac{k+1}{k}.$$

(Man kan bevisa detta faktum med hjälp av Sats 2.2.) Det följer att $(k/(k+1))(X_{k+1} - \bar{X}_k)^2 \sim \chi^2(1)$. Eftersom $(k-1)S_k^2 \sim \chi^2(k-1)$ enligt induktionshypotes får vi att $kS_{k+1}^2 \sim \chi^2(k)$ från Lemma 5.1 (b). Det följer att $(n-1)S_n^2 \sim \chi^2(n-1)$ när $X_1, \dots, X_n$ är oberoende och $N(0, 1)$ -fördelade.

Det återstår att bevisa påståendet när $X_1, \dots, X_n$ är oberoende och $N(\mu, \sigma^2)$ -fördelade. Kom ihåg från Exempel 1.13 att normalfamiljen är en läge-skalfamilj med standardtäthetsfunktion given av $Z \sim N(0, 1)$. Vi har därför att $X \sim N(\mu, \sigma)$ har täthetsfunktion

$$f_X(x) = \frac{1}{\sigma} f_Z\left(\frac{x - \mu}{\sigma}\right),$$

och $X_i = \sigma Z_i + \mu$ där $Z_1, \dots, Z_n$ är oberoende och $N(0, 1)$ -fördelade. Låt $T(X_1, \dots, X_n) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = S^2$. Då har vi

$$\begin{aligned} S^2 &= T(X_1, \dots, X_n), \\ &= T(\sigma Z_1 + \mu, \dots, \sigma Z_n + \mu), \\ &= \frac{1}{n-1} \sum_{i=1}^n \left(\sigma Z_i + \mu - \frac{1}{n} \sum_{j=1}^n (\sigma Z_j + \mu) \right)^2, \\ &= \frac{\sigma^2}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2. \end{aligned}$$

Låt $S_Z^2 = \frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2$. Det följer att $\frac{(n-1)S^2}{\sigma^2} = (n-1)S_Z^2$. Därför är

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

□

Exempel 5.4. Vi har stickprovet

$$\begin{aligned} x_1 &= 3.12, & x_2 &= 2.51, & x_3 &= 2.06, & x_4 &= 3.47, & x_5 &= 4.97, \\ x_6 &= 5.28, & x_7 &= -0.17, & x_8 &= 4.94, & x_9 &= 7.37, & x_{10} &= 1.91 \end{aligned}$$

från en $N(3, 4)$ -population och får då stickprovsvariansen

$$s^2 = \frac{1}{10-1} \sum_{i=1}^{10} (x_i - \bar{x})^2 \approx 4.62$$

där $\bar{x} \approx 3.55$ är stickprovsmedelvärdet. Sats 5.3 säger $s^2 = 4.62$ är ett slumpmässigt utfall av S^2 där

$$\frac{9}{4} S^2 \sim \chi^2(9).$$

Låt $U = \frac{4}{9} Y$ där $Y \sim \chi^2(9)$. Då har vi att $g(y) = \frac{4}{9} y = u$ och $g^{-1}(u) = \frac{9}{4} u$. Med hjälp av formeln för en transformation av stokastiska variabler har vi då att

$$f_U(u) = \frac{9 f_Y\left(\frac{9u}{4}\right)}{4}.$$


Eftersom $Y \sim \chi^2(9)$ förenklar vi detta till

$$f_U(u) = \left(\frac{9}{4}\right)^{\frac{9}{2}} \frac{1}{\Gamma(9/2) 2^{9/2}} u^{9/2-1} e^{-(9/8)u}.$$

Det vill säga att

$$f_{S^2}(s^2) = \left(\frac{9}{4}\right)^{\frac{9}{2}} \frac{1}{\Gamma(9/2) 2^{9/2}} (s^2)^{9/2-1} e^{-(9/8)(s^2)}.$$

Vi kan ta flera (exempelvis 500) stickprov av storlek 10 från en $N(3, 4)$ -fördelning, beräkna S^2 för vart och ett stickprov och se att det resulterande histogrammet passar in i täthetsfunktionen:



Vi ser från histogrammet att $s^2 = 4.62$ är ett ganska rimligt utfall från samplingfördelningen.

För att kvantifiera osäkerheten i $\bar{X}$ när vi använder det som en skattning för μ kan vi använda samplingfördelningen

$$\bar{X} \sim N(\mu, \sigma^2/n),$$

eller motsvarande

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

Detta fungerar bara när vi vet σ^2 . Om vi inte vet σ^2 kan vi skatta det som S^2 och approximera fördelningen $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ med kvoten

$$Y = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}}{\sqrt{S^2/\sigma^2}},$$

där $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ och S^2/σ^2 är en skalad $\chi^2(n-1)$ -fördelad variabel. Eftersom $\bar{X} \perp S^2$ kan vi använda en transformation av stokastiska variabler för att beräkna täthetsfunktionen för Y . Det är

$$f_Y(y) = \frac{\Gamma((p+1)/2)}{\Gamma(p/2)\sqrt{p\pi}} \frac{1}{\left(1 + \frac{y^2}{p}\right)^{(p+1)/2}}, \quad -\infty < y < \infty,$$

som kallas *t-fördelningen* p frihetsgrader där $p = n - 1$. Generellt sett kan $p = 1, 2, \dots$ och vi säger att en stokastisk variabel Y med sådan täthetsfunktion $f_Y(y|p)$ är *t-fördelad med p frihetsgrader* och skriver $Y \sim t(p)$. Man kan visa att $E[Y] = 0$ om $p > 1$ och $\text{Var}[Y] = \frac{p}{p-2}$ om $p > 2$ för $Y \sim t(p)$ (se Uppgift 5.9).

En användbar observation är att vi kan konstruera en *t-fördelad* stokastiska variabler som en kvot av en standardnormalfördelad variabel och en chitvåfördelad variabel som är skalad enligt antalet frihetsgrader.

Sats 5.4. Låt $Z \sim N(0, 1)$ och $W \sim \chi^2(p)$ vara oberoende. Då är $Y = \frac{Z}{\sqrt{W/p}}$ en $t(p)$ -fördelad stokastisk variabel.

Vi lämnar beviset för Sats 5.4 som en uppgift (se Uppgift 5.7). Vi såg redan ett exempel ovan där

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

och

$$W = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

Ett annat exempel på en tillämpning av Sats 5.4 är följande:

Exempel 5.5. Betrakta den enkla linjära regressionsmodellen

$$Y_i = b + mx_i + E_i, \quad \text{för } i = 1, \dots, n$$

där m och b är okända konstanter, $x_1, \dots, x_n$ är fixa och kända, och $E_1, \dots, E_n$ är oberoende och $N(0, \sigma^2)$ -fördelade med σ^2 okänd. Det följer att $Y_1, \dots, Y_n$ är också oberoende och normalfördelade. Vi vet (från en första kurs i sannolikhets teori och statistik) att vi kan skatta m som

$$\hat{m} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Vi har alltså stickprovsvariabeln

$$\hat{M} = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Vi kommer att bevisa i Uppgift 5.8 att vi kan förenkla detta som

$$\hat{M} = \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Vi vill förstå samplingfördelningen för $\hat{M}$; dvs. vi vill ha en formel för täthetsfunktionen för $\hat{M}$. Det följer från ovan att $\hat{M}$ är en linjärkombination av normalfördelade stokastiska variabler $Y_1, \dots, Y_n$ och därför också är normalfördelad. Vi kan även bestämma väntevärdet och variansen för denna samplingfördelning. Vi beräknar väntevärdet som

$$\begin{aligned} E[\hat{M}] &= \frac{\sum_{i=1}^n (x_i - \bar{x}) E[Y_i]}{\sum_{i=1}^n (x_i - \bar{x})^2}, \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})(b + mx_i)}{\sum_{i=1}^n (x_i - \bar{x})^2}, \\ &= \frac{b \sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} + \frac{\sum_{i=1}^n (x_i - \bar{x})mx_i}{\sum_{i=1}^n (x_i - \bar{x})^2}, \\ &= 0 + \frac{\sum_{i=1}^n (x_i - \bar{x})mx_i}{\sum_{i=1}^n (x_i - \bar{x})^2}, \\ &= m \frac{\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i}{\sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2)}, \\ &= m \frac{(\sum_{i=1}^n x_i^2) - n\bar{x}^2}{(\sum_{i=1}^n x_i^2) - 2n\bar{x}^2 + n\bar{x}^2}, \\ &= m \frac{(\sum_{i=1}^n x_i^2) - n\bar{x}^2}{(\sum_{i=1}^n x_i^2) - n\bar{x}^2}, \\ &= m \end{aligned}$$

och variansen som

$$\begin{aligned} \text{Var}[\hat{M}] &= \text{Var} \left[\frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \right], \\ &= \frac{1}{(\sum_{i=1}^n (x_i - \bar{x})^2)^2} \sum_{i=1}^n \text{Var}[(x_i - \bar{x})Y_i], \\ &= \frac{1}{(\sum_{i=1}^n (x_i - \bar{x})^2)^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}[Y_i], \\ &= \frac{1}{(\sum_{i=1}^n (x_i - \bar{x})^2)^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2, \quad (\text{Var}[Y_i] = \text{Var}[b + mx_i + E_i] = \text{Var}[E_i] = \sigma^2) \\ &= \frac{\sigma^2 \sum_{i=1}^n (x_i - \bar{x})^2}{(\sum_{i=1}^n (x_i - \bar{x})^2)^2}, \\ &= \frac{\sigma^2}{(\sum_{i=1}^n (x_i - \bar{x})^2)}. \end{aligned}$$

Därför har vi att $\hat{M} \sim N(m, \sigma^2 / \sum_{i=1}^n (x_i - \bar{x})^2)$; dvs.

$$\frac{\hat{M} - m}{\sigma / \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}} \sim N(0, 1).$$

Vi såg också i en första kurs i sannolikhetssteori och statistik att vi kan skatta σ^2 som

$$\text{rss} = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{b} - \hat{m}x_i)^2$$

där $\hat{b} = \bar{y} - \hat{m}\bar{x}$. I likhet till Sats 5.3 kan man visa att samplingfördelningen för statistiken

$$\text{RSS} = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{B} - \hat{M}x_i)^2 \quad (\text{där } \hat{B} = \bar{Y} - \hat{M}\bar{x})$$

uppfyller

$$\frac{(n-2)\text{RSS}}{\sigma^2} \sim \chi^2(n-2).$$

(Vi tappar intuitivt två frihetsgrader eftersom vi redan har gjort två skattningar med datan, $\hat{b}$ och $\hat{m}$ i RSS. Det är därför att variabeln har $n-2$ frihetsgrader. Jämför detta med observationen att $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ har $n-1$ frihetsgrader eftersom vi använt $\bar{X}$.)

Om vi låter då $V = \frac{(n-2)\text{RSS}}{\sigma^2}$ har vi

$$\frac{\frac{\hat{M}-m}{\sigma/\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}}{\sqrt{V/(n-2)}} \sim t(n-2)$$

enligt Sats 5.4. Vi kan förenkla detta uttryck till

$$\frac{\frac{\hat{M}-m}{\sigma/\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}}{\sqrt{V/(n-2)}} = \frac{\frac{\hat{M}-m}{\sigma/\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}}{\sqrt{\text{RSS}/\sigma^2}} = \frac{\hat{M} - m}{\sqrt{\text{RSS}/\sum_{i=1}^n (x_i - \bar{x})^2}}.$$

Det följer att statistika $t = \frac{\hat{m}-m}{\sqrt{\text{RSS}/\sum_{i=1}^n (x_i - \bar{x})^2}}$ är ett utfall från en $t(n-2)$ -fördelning när datan verkligen dras från en regressionsmodell med regressionskoefficient m .

Om till exempel vi har stickprovet

x_i	-0.51	0.79	-1.97	0.45	3.34	-0.05	1.18	0.82	1.78	-1.55
y_i	-0.23	2.24	-2.2	0.25	1.34	-0.64	2.24	2.22	2.05	-2.5

har vi

$$\hat{m} = 0.945, \quad \hat{b} = 0.071, \quad \text{rss} = 1.177, \quad \sum_{i=1}^{10} (x_i - \bar{x})^2 = 21.930, \quad \text{och} \quad t = \frac{0.945 - m}{\sqrt{1.177/21.930}}$$

Vi kan testa vad händer om vi tar $m = 0$. I detta fall har vi att $t = 4.765$. Om vi tror att stickprovet dras från en population med $m = 0$ borde den observerade statistiken $t = 4.765$ vara ett rimligt utfall från en $t(8)$ -fördelningen. För att testa detta kan vi beräkna sannolikheten $P(|T| > 4.765)$ där $T \sim t(8)$. Med hjälp av täthetsfunktionen för T får vi $P(|T| > 4.765) \approx 0.001$ vilken är ganska liten. Det är osannolikt att utfall från T ska vara mer extremt än vårt stickprov $t = 4.765$. Detta föreslår att $m = 0$ är troligtvis inte modellens regressionskoefficient. Här använde vi samplingfördelningen för att dra denna slutsats. Vi kommer att formellt beskriva denna användning av samplingfördelningar när vi diskuterar hypotestest.

Vi såg i det första exemplet i detta kapitel (Exempel 5.1) att statistikor som stickprovsmedelvärde $\bar{X}$ är användbara eftersom de dyker upp naturligt när vi skulle vilja skriva den simultana fördelningen för ett stickprov från en viss population på en enkel form. Sådana statistikor är även användbara eftersom de kan ge upphov till skattningar för populationens parametrar. Till exempel, om $x_1, \dots, x_n$ är ett stickprov från en $N(\mu, 1)$ -population där μ är okänt kan vi skatta μ med $\bar{x}$ eftersom $E[\bar{X}] = \mu$ (enligt Sats 5.1). Sådana skattningar har dock naturligtvis en del osäkerhet eftersom likheten $E[\bar{X}] = \mu$ bara gäller i förväntan. Å andra sidan noterade vi också att statistikor kan ses som transformationer av stickprovet och därmed har egna fördelningar vilka kallas för samplingfördelningar. Dessa samplingfördelningar kvantifierar vår osäkerhet i skattningen; dvs. i vårt exempel berättar samplingfördelningen

för oss hur sannolikt det är att observera stickprovsmedelvärde $\bar{x}$ när stickprovet $x_1, \dots, x_n$ egentligen dras från en $N(\mu, 1)$ -population.

På så sätt är samplingfördelningar användbara när vi vill skatta okända parametrar, såsom μ ovan. Vi såg redan ett exempel på detta i Exempel 5.5. Vi kan göra detsamma med vårt lilla exempel här också. Anta att vi tror att $\mu = 0$. Samplingfördelningen för $\bar{X}$ är då $N(0, 1/n)$. Anta nu att vi har stickprovet $x_1, \dots, x_{10}$ med $\bar{x} = 0.9$. Om vi tror att detta stickprov verkligen dras från en $N(0, 1)$ -population vet vi att $\bar{X} \sim N(0, 1/10)$. Därför kan vi beräkna sannolikheten

$$P(\bar{X} > 0.9) = 1 - \int_{-0.9}^{0.9} f_{\bar{X}}(\bar{x}) d\bar{x} \approx 0.004$$

vilken är ganska liten. Detta föreslår att vårt antagande att stickprovet dras från en $N(0, 1)$ -population är orimligt. Så vi skulle vara benägna att förkasta vår förmodan att $\mu = 0$ baserat på data.

Detta är grundtanken om hur samplingfördelningar kan vara användbara i hypotestest, vilka kommer vi att diskutera i mer detalj senare. Om vi tillämpar samma logik till situationer som i Exempel 5.5 ser vi att kunskap om samplingfördelningar kan hjälpa oss att testa många hypoteser om givna data och hur vi borde modellera detta.

Givet en statistika kan det därmed vara värdefullt att veta dess täthetsfunktion. Som vi redan såg ovan kan det dock vara svårt att få en formel för samplingfördelningen. Å andra sidan, när stickprovets storlek är tillräckligt stort kan vi använda approximationer till samplingfördelningen tack vare satser som centrala gränsvärdessatsen.

Exempel 5.6. Låt $X_1, X_2, \dots$ vara en sekvens av oberoende och $\text{Bin}(10, p)$ -fördelade stokastiska variabler och låt $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Vi har då att X_i har väntevärde $\mu = np$ och varians $\sigma^2 = 10p(1-p)$. Enligt Sats 5.1 vet vi att $E[\bar{X}_n] = E[X_1] = 10p$ och $\text{Var}[\bar{X}_n] = \text{Var}[X_1]/n = 10p(1-p)/n$. Enligt den centrala gränsvärdessatsen har vi också att sekvensen $Z_1, Z_2, \dots$ där

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

uppfyller

$$\lim_{n \rightarrow \infty} F_{Z_n}(z_n) \rightarrow F_Z(z)$$

där $Z \sim N(0, 1)$. Med andra ord har vi att $\bar{X}_n$ är approximativt $N(10p, 10p(1-p)/n)$ -fördelad när n är tillräckligt stort. Om vi har ett stickprov $x_1, \dots, x_{100}$ av storlek $n = 100$ kan vi då approximera samplingfördelningen för $\bar{X}$ som $N(10p, 10p(1-p)/100)$; dvs., $\bar{Z} = \frac{\bar{X} - 10p}{\sqrt{10p(1-p)/100}}$ är approximativt $N(0, 1)$ -fördelad. Anta nu att vi tror att $p = 0.5$.

Då har vi att $E[\bar{X}] = 2$ och $\text{Var}[\bar{X}] = 0.025$. Om vi observerar $\bar{x} = 2.45$ har vi observationen $\bar{z} = \frac{2.45-2}{\sqrt{0.025}} \approx 2.846$. Vi har att $\bar{Z}$ är approximativt $N(0, 1)$ -fördelad och därför betrakta $\bar{z} = 2.846$ som ett utfall från en $N(0, 1)$ -population. Vi ser att sannolikheten att ett slumpmässigt utfall från denna population är mer extremt än $z = 2.846$ är

$$P(|\bar{Z}| > 2.846) \approx 0.004.$$

Denna sannolikhet är ganska liten. Vi kan säga då att det är osannolikt att stickprovet dras från en $\text{Bin}(10, p)$ -population där $p = 0.5$.

5.2 Tillräckliga statistikor

Vi såg i föregående avsnitt att $\bar{X}$ och S^2 är bra skattningar för μ och σ^2 givet ett stickprov från en $N(\mu, \sigma^2)$ -fördelning. Vi ska nu se att resten av stickprovet $\mathbf{X} = [X_1, \dots, X_n]^T$ inte kan berätta mer än $\bar{X}$ och S^2 om parametrarna μ och σ^2 . Med andra ord är $\bar{X}$ och S^2 tillräckliga för att skatta parametrarna för fördelningen; dvs. vi behöver bara $\bar{X}$ och S^2 och inte hela stickprovet $\mathbf{X}$. På oberoendes språk säger detta att givet $T(\mathbf{X})$ berättar $\mathbf{X}$ för oss ingenting nytt om θ . Hur kan vi formulera detta för en godtycklig familj av fördelningar? Idén är att vi studerar fördelningen av $\mathbf{X} = [X_1, \dots, X_n]^T$ betingad på $T(\mathbf{X})$ (dvs. för $T(\mathbf{X})$ fixt). En statistika $T(\mathbf{X})$ kallas en *tillräcklig statistika för parametern θ* om fördelningen av $\mathbf{X}$ givet $T(\mathbf{X})$ inte beror på θ .

Betrakta idén först för diskreta stokastiska variabler. Anta att $T(\mathbf{X})$ kan anta värdet t ; dvs. $P(T(\mathbf{X}) = t) > 0$. Vi är intresserade av fördelningen för $\mathbf{X}$ givet $T(\mathbf{X}) = t$; dvs.

$$P(\mathbf{X} = \mathbf{x} | T(\mathbf{X}) = t).$$

Om $t \neq T(\mathbf{x})$ har vi att

$$\begin{aligned} P(\mathbf{X} = \mathbf{x} | T(\mathbf{X}) = t) &= \frac{P(\mathbf{X} = \mathbf{x}, T(\mathbf{X}) = t)}{P(T(\mathbf{X}) = t)}, \\ &= \frac{P(\mathbf{X} = \mathbf{x}, T(\mathbf{x}) = t)}{P(T(\mathbf{X}) = t)}, \\ &= 0. \end{aligned}$$

Eftersom $\mathbf{X} = \mathbf{x}$ innebär att $T(\mathbf{X}) = T(\mathbf{x}) \neq t$. Alltså beror $P(\mathbf{X} = \mathbf{x} | T(\mathbf{X}) = t)$ inte på θ i detta fall. Om $t = T(\mathbf{x})$ har vi

$$\begin{aligned} P(\mathbf{X} = \mathbf{x} | T(\mathbf{X}) = t) &= P(\mathbf{X} = \mathbf{x} | T(\mathbf{X}) = T(\mathbf{x})), \\ &= \frac{P(\mathbf{X} = \mathbf{x}, T(\mathbf{X}) = T(\mathbf{x}))}{P(T(\mathbf{X}) = T(\mathbf{x}))}, \\ &= \frac{P(\mathbf{X} = \mathbf{x})}{P(T(\mathbf{X}) = T(\mathbf{x}))}, \end{aligned}$$

eftersom $\mathbf{X} = \mathbf{x}$ innebär att $T(\mathbf{X}) = T(\mathbf{x})$. Men detta kvot är lika med

$$\frac{f_{\mathbf{X}}(\mathbf{x}|\theta)}{q(T(\mathbf{x})|\theta)},$$

där $q(T(\mathbf{x})|\theta)$ är sannolikhetsfunktionen av $T(\mathbf{X})$. Så har vi visat att $T(\mathbf{X})$ är en tillräcklig statistika för θ om och endast om denna kvot inte beror på θ . Samma resultat stämmer för kontinuerliga fördelningar om vi ersätter sannolikhetsfunktioner för täthetsfunktioner.

Exempel 5.7. Låt $X_1, \dots, X_n$ vara oberoende och $\text{Ber}(\theta)$ -fördelade. Vi skulle vilja visa att

$$T(\mathbf{X}) = X_1 + \dots + X_n$$

är en tillräcklig statistika för θ . Det vill säga att all nödvändig information i $X_1, \dots, X_n$ för att skatta θ ges av antalet ettor i stickprovet (ordningen spelar ingen roll). Vi vet att

$$f_{\mathbf{X}}(\mathbf{x}|\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i}.$$

Eftersom $T = T(\mathbf{X}) \sim \text{Bin}(n, \theta)$ vet vi också att

$$q(t|\theta) = \binom{n}{t} \theta^t (1 - \theta)^{n-t}.$$

Eftersom $T(\mathbf{x}) = \sum_{i=1}^n x_i$ har vi då att

$$\begin{aligned} \frac{f_{\mathbf{X}}(\mathbf{x}|\theta)}{q(T(\mathbf{x})|\theta)} &= \frac{\prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i}}{\binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}}, \\ &= \frac{\theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}}{\binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}}, \\ &= \frac{1}{\binom{n}{\sum_{i=1}^n x_i}}, \end{aligned}$$

vilket inte beror på θ . Så $T(\mathbf{X})$ är en tillräcklig statistika för θ .

Medan föregående metod fungerar har den nackdelen att man först måste gissa $T(\mathbf{X})$ och därefter beräkna kvoten för att verifiera att den inte beror på θ . Följande sats ger oss en lösning till detta problem:

Sats 5.5 (Faktoriseringsatsen). Låt $f_{\mathbf{X}}(\mathbf{x}|\theta)$ vara täthetsfunktionen (eller sannolikhetsfunktionen) för den stokastiska vektorn $\mathbf{X} = [X_1, \dots, X_n]^T$ där $X_1, \dots, X_n$ är oberoende och likafördelade, och låt $T(\mathbf{X})$ vara en statistika. Då är $T(\mathbf{X})$ en tillräcklig statistika med avseende på θ om och endast om det finns funktioner $g(t|\theta)$ och $h(\mathbf{x})$ så att

$$f_{\mathbf{X}}(\mathbf{x}|\theta) = g(T(\mathbf{x})|\theta)h(\mathbf{x})$$

för alla $\mathbf{x}$ och θ .

Bevis. Vi visar resultatet i det diskreta fallet. Anta först att $T(\mathbf{X})$ är en tillräcklig statistika. Vi har redan sett att kvoten

$$\frac{f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta})}{q(T(\mathbf{x})|\boldsymbol{\theta})},$$

inte beror på $\boldsymbol{\theta}$ där $f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta})$ är sannolikhetsfunktionen för $\mathbf{X}$ och $q(T(\mathbf{x})|\boldsymbol{\theta})$ är sannolikhetsfunktionen för $T(\mathbf{X})$. Därför låter vi

$$h(\mathbf{x}) = \frac{f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta})}{q(T(\mathbf{x})|\boldsymbol{\theta})} \quad \text{och} \quad g(T(\mathbf{x})|\boldsymbol{\theta}) = q(T(\mathbf{x})|\boldsymbol{\theta}).$$

Vilket visar att det finns funktioner $g(T(\mathbf{x})|\boldsymbol{\theta})$ och $h(\mathbf{x})$ så att

$$f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta}) = g(T(\mathbf{X})|\boldsymbol{\theta})h(\mathbf{x}).$$

Anta nu att det finns funktioner $g(t|\boldsymbol{\theta})$ och $h(\mathbf{x})$ så att

$$f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta}) = g(T(\mathbf{x})|\boldsymbol{\theta})h(\mathbf{x})$$

för alla $\mathbf{x}$ och $\boldsymbol{\theta}$. Vi vill nu visa att kvoten

$$\frac{f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta})}{q(T(\mathbf{x})|\boldsymbol{\theta})}$$

inte beror på $\boldsymbol{\theta}$ om det existerar funktioner $g(t|\boldsymbol{\theta})$ och $h(\mathbf{x})$ så att $f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta}) = g(T(\mathbf{x})|\boldsymbol{\theta})h(\mathbf{x})$. Så vi måste beräkna $q(T(\mathbf{x})|\boldsymbol{\theta})$. Kom ihåg att $q(T(\mathbf{x})|\boldsymbol{\theta})$ är sannolikhetsfunktionen för $T(\mathbf{X})$. Eftersom $T(\mathbf{X})$ är en transformation av den diskreta stokastiska vektorn $\mathbf{X}$ kan vi beräkna dess sannolikhetsfunktion som

$$\begin{aligned} q(T(\mathbf{x})|\boldsymbol{\theta}) &= \sum_{\mathbf{y}:T(\mathbf{y})=T(\mathbf{x})} f_{\mathbf{Y}}(\mathbf{y}|\boldsymbol{\theta}), \\ &= \sum_{\mathbf{y}:T(\mathbf{y})=T(\mathbf{x})} g(T(\mathbf{y})|\boldsymbol{\theta})h(\mathbf{y}), \\ &= \sum_{\mathbf{y}:T(\mathbf{y})=T(\mathbf{x})} g(T(\mathbf{x})|\boldsymbol{\theta})h(\mathbf{y}), \\ &= g(T(\mathbf{x})|\boldsymbol{\theta}) \sum_{\mathbf{y}:T(\mathbf{y})=T(\mathbf{x})} h(\mathbf{y}). \end{aligned}$$

Det följer att

$$\frac{f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta})}{q(T(\mathbf{x})|\boldsymbol{\theta})} = \frac{g(T(\mathbf{x})|\boldsymbol{\theta})h(\mathbf{x})}{g(T(\mathbf{x})|\boldsymbol{\theta}) \sum_{\mathbf{y}:T(\mathbf{y})=T(\mathbf{x})} h(\mathbf{y})} = \frac{h(\mathbf{x})}{\sum_{\mathbf{y}:T(\mathbf{y})=T(\mathbf{x})} h(\mathbf{y})},$$

som inte beror på $\boldsymbol{\theta}$. □

Sats 5.5 säger att om vi kan skriva om täthetsfunktion som en produkt av en funktion $g(T(\mathbf{x})|\boldsymbol{\theta})$ som beror på datan $\mathbf{x}$ transformerade på ett sätt (motsvarar funktionen $T(\mathbf{x})$) och $\boldsymbol{\theta}$ och en funktion $h(\mathbf{x})$ som bara beror på datan har vi att $T(\mathbf{X})$ är en tillräcklig statistika. Detta betyder att vi kan hitta en tillräcklig statistika bara genom att andra hur vi skriver täthetsfunktionens formel. Vi ger ett exempel.

Exempel 5.8. Låt $\mathbf{X} = [X_1, \dots, X_n]^T$ där $X_1, \dots, X_n$ är oberoende och $N(\mu, \sigma^2)$ -fördelade. Då är

$$f_{\mathbf{X}}(\mathbf{x}|\mu, \sigma^2) = \frac{1}{(\sqrt{2\pi\sigma^2})^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right).$$

Summan i exponenten kan skrivas som

$$\begin{aligned} \sum_{i=1}^n (x_i - \mu)^2 &= \sum_{i=1}^n (x_i - \bar{x} + \bar{x} - \mu)^2, \\ &= \sum_{i=1}^n (x_i - \bar{x})^2 + 2 \sum_{i=1}^n (x_i - \bar{x})(\bar{x} - \mu) + \sum_{i=1}^n (\bar{x} - \mu)^2, \\ &= \sum_{i=1}^n (x_i - \bar{x})^2 + 2(0) + \sum_{i=1}^n (\bar{x} - \mu)^2, \\ &= \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2. \end{aligned}$$

Om σ^2 är känt får vi att

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}|\mu, \sigma^2) &= \frac{1}{(\sqrt{2\pi\sigma^2})^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2\right) \exp\left(-\frac{n}{2\sigma^2} (\bar{x} - \mu)^2\right), \\ &= h(\mathbf{x})g(\bar{x}|\mu), \end{aligned}$$

där

$$h(\mathbf{x}) = \frac{1}{(\sqrt{2\pi\sigma^2})^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2\right) \quad \text{och} \quad g(\bar{x}|\mu) = \exp\left(-\frac{n}{2\sigma^2} (\bar{x} - \mu)^2\right).$$

Det följer att $\bar{X}$ är en tillräcklig statistika för μ .

Om σ och μ är båda okända observerar vi att $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$. Så vi kan skriva

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}|\mu, \sigma^2) &= \frac{1}{(\sqrt{2\pi\sigma^2})^n} \exp\left(-\frac{1}{2\sigma^2} ((n-1)s^2 + n(\bar{x} - \mu)^2)\right), \\ &= h(\mathbf{x})g(\bar{x}, s^2|\mu, \sigma^2), \end{aligned}$$

där

$$h(\mathbf{x}) = 1 \quad \text{och} \quad g(\bar{x}, s^2|\mu, \sigma^2) = \frac{1}{(\sqrt{2\pi\sigma^2})^n} \exp\left(-\frac{1}{2\sigma^2} ((n-1)s^2 + n(\bar{x} - \mu)^2)\right).$$

Så är $[\bar{X}, S^2]^T$ en två-dimensionell tillräcklig statistika för $[\mu, \sigma^2]^T$.

Exempel 5.9. Låt $\mathbf{X} = [X_1, \dots, X_n]^T$ där $X_1, \dots, X_n$ är oberoende och $U(0, \theta)$ -fördelade för något $\theta > 0$. Då är täthetsfunktionen

$$f_X(x|\theta) = \begin{cases} \frac{1}{\theta} & 0 \leq x \leq \theta, \\ 0 & \text{annars.} \end{cases}$$

Med hjälp av indikatorfunktionen för en mängd A

$$\mathbf{1}_A(x) = \begin{cases} 1 & x \in A, \\ 0 & x \notin A, \end{cases}$$

kan vi skriva täthetsfunktionen som

$$f_X(x|\theta) = \mathbf{1}_{[0, \theta]}(x).$$

Den simultana täthetsfunktionen för hela stickprovet $\mathbf{X}$ är då

$$f_{\mathbf{X}}(\mathbf{x}|\theta) = \frac{1}{\theta^n} \mathbf{1}_{[0, \theta]}(x_1) \cdots \mathbf{1}_{[0, \theta]}(x_n).$$

Eftersom $f_{\mathbf{X}}(\mathbf{x}|\theta) \neq 0$ om och endast om $0 \leq x_1, \dots, x_n \leq \theta$ och $0 \leq x_1, \dots, x_n \leq \theta$ om och endast om $\min_{i \in [n]}(x_i) \geq 0$ och $\max_{i \in [n]}(x_i) \leq \theta$ kan vi skriva täthetsfunktionen som

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}|\theta) &= \frac{1}{\theta^n} \mathbf{1}_{[0, \infty)}(\min_{i \in [n]}(x_i)) \mathbf{1}_{(-\infty, \theta]}(\max_{i \in [n]}(x_i)), \\ &= h(\mathbf{x})g(T(\mathbf{x})|\theta), \end{aligned}$$

där

$$\begin{aligned} h(\mathbf{x}) &= \mathbf{1}_{[0, \infty)}(\min_{i \in [n]}(x_i)), \\ g(T(\mathbf{x})|\theta) &= \frac{1}{\theta^n} \mathbf{1}_{(-\infty, \theta]}(T(\mathbf{x})), \quad \text{och} \\ T(\mathbf{x}) &= \max_{i \in [n]}(x_i). \end{aligned}$$

Så det följer från Sats 5.5 att $T(\mathbf{X}) = \max_{i \in [n]}(X_i)$ är en tillräcklig statistika för θ . Resultatet stämmer eftersom resten av datan hjälper inte med skattning av θ när man har beräknat det största värdet i stickprovet.

Vi kan också få en formel för tillräckliga statistikor för en godtycklig exponentialfamilj.

Sats 5.6. Låt $\mathbf{X} = [X_1, \dots, X_n]^T$ där $X_1, \dots, X_n$ är oberoende och likafördelade med täthetsfunktion (eller sannolikhetsfunktion) på formen

$$f_X(x|\boldsymbol{\theta}) = h(x)c(\boldsymbol{\theta}) \exp\left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x)\right),$$

där $\boldsymbol{\theta} = [\theta_1, \dots, \theta_d]^T$ för $d \leq k$. Då är

$$\left(\sum_{j=1}^n t_1(X_j), \dots, \sum_{j=1}^n t_k(X_j)\right)$$

en k -dimensionell tillräcklig statistika för $\boldsymbol{\theta}$.

Bevis. Vi kan skriva den simultana täthetsfunktionen som

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta}) &= \prod_{j=1}^n h(x_j)c(\boldsymbol{\theta}) \exp\left(\sum_{i=1}^k w_i(\boldsymbol{\theta})t_i(x_j)\right), \\ &= \left(\prod_{j=1}^n h(x_j)\right) c(\boldsymbol{\theta})^n \exp\left(\sum_{i=1}^k w_i(\boldsymbol{\theta}) \sum_{j=1}^n t_i(x_j)\right), \\ &= h(\mathbf{x})g(T(\mathbf{x})|\boldsymbol{\theta}), \end{aligned}$$

där

$$\begin{aligned} h(\mathbf{x}) &= \prod_{j=1}^n h(x_j), \quad \text{och,} \\ g(T(\mathbf{x})|\boldsymbol{\theta}) &= c(\boldsymbol{\theta})^n \exp\left(\sum_{i=1}^k w_i(\boldsymbol{\theta}) \sum_{j=1}^n t_i(x_j)\right). \end{aligned}$$

Påståendet följer från Sats 5.5. □

Tillräckliga statistikor är bra eftersom de berättar allt vi kan veta om parametrarna baserat på stickprovet. De låter oss förenkla formler för att skatta parametrarna och de har samplingfördelningar som kan hjälpa oss med skattning och kvantifiering av osäkerhet i skattningarna. Nu när vi har bra statistikor och förstår flera av deras användbara egenskaper är vi redo att beskriva hur vi kan använda statistikor för att skatta parametrar på ett formellt sätt. Vi börjar först med den enklaste typen av skattning som vi får med hjälp av statistikor. De kallas för *punktskattningar*.

5.3 Uppgifter

- 5.1. [1] Anta att 14% av alla människor är färgblinda. Hur stort måste ett stickprov vara för att sannolikheten att få minst en färgblind person är minst 0.95?
- 5.2. [1] Vad är samplingfördelningen för $\bar{X}$ där $X_1, \dots, X_n$ är oberoende och $\text{Exp}(\lambda)$ -fördelade?
- 5.3. [1] Vad är samplingfördelningen för $\bar{X}$ där $X_1, \dots, X_n$ är oberoende och $\text{Gamma}(m, \theta)$ -fördelade och m är ett positivt heltal?
- 5.4. [1] Vad är samplingfördelningarna för $\bar{X}$ och S^2 där $X_1, \dots, X_n$ är oberoende och $\text{Po}(\lambda)$ -fördelade?
- 5.5. [3] Bevisa Lemma 5.1.
- 5.6. [2] Låt $X_1, X_2, \dots$ vara oberoende och likafördelade. Låt $\bar{X}_n$ och S_n^2 beteckna stickprovsmedelvärdet respektive stickprovsvariansen för $X_1, \dots, X_n$, $n \geq 2$. Bevisa följande rekursiva formler.

- (a) $\bar{X}_{n+1} = \frac{X_{n+1} + n\bar{X}_n}{n+1}$ och
 (b) $nS_{n+1}^2 = (n-1)S_n^2 + \frac{n}{n+1}(X_{n+1} - \bar{X}_n)^2$.

5.7. [3] Bevisa Sats 5.4.

5.8. [1] För $x_1, \dots, x_n$ och $y_1, \dots, y_n$ definiera $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ och $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$. Visa att

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})y_i = \sum_{i=1}^n (y_i - \bar{y})x_i.$$

5.9. [2] Låt $X \sim t(p)$. Visa att $E[X] = 0$ och $\text{Var}[X] = \frac{p}{p-2}$ när $p > 2$.

5.10. [2] Låt

$$\begin{aligned} X_1 &= E_1, \\ X_2 &= \lambda_1 X_1 + E_2, \\ X_3 &= \lambda_2 X_2 + E_3, \end{aligned}$$

där λ_1, λ_2 är okända konstanter och E_1, E_2, E_3 är oberoende och $E_i \sim N(0, \sigma_i^2)$ för alla $i = 1, 2, 3$. Vad är samplingfördelningarna för λ_1 respektive λ_2 ?

5.11. [1] Låt $X_i \sim N(i, i^2)$ för $i = 1, 2, 3$ och anta att X_1, X_2, X_3 är oberoende. Använd X_1, X_2, X_3 för att konstruera statistikor med följande fördelning:

- (a) χ^2 -fördelning med 3 frihetsgrader och
 (b) t -fördelning med 2 frihetsgrader.

5.12. [1] Bestäm samplingfördelningen för statistikan $W(\mathbf{X}) = \max(X_1, \dots, X_n) - \log(n)$ där $X \sim \text{Exp}(\lambda)$.

5.13. [1] Anta att antalet dagar tills att ett visst frö gror är 22 med en standardavvikelse på 6.3. Givet ett stickprov av 250 frön, skatta sannolikheten att stickprovsmedelvärdet ligger högst 0.5 från populationens väntevärde.

5.14. [1] I en viss stad är det förväntade beloppet för kreditkortsskulder per hushåll 152 500 kr, med en standardavvikelse på 71 250 kr. Givet ett stickprov av storlek 1 600, skatta sannolikheten att stickprovsmedelvärdet ligger inom 3 000 kr av populationens väntevärde.

5.15. [1] Givet ett stickprov $x_1, \dots, x_n$ från en $\text{InvGamma}(\alpha, \lambda)$ -population, bestäm en tvådimensionell tillräcklig statistika för $[\alpha, \lambda]^T$.

5.16. [1] Givet ett stickprov $x_1, \dots, x_n$ från en $\text{Beta}(\alpha, \alpha)$ -population, bestäm en endimensionell tillräcklig statistika för α .

5.17. [1] Givet ett stickprov $x_1, \dots, x_n$ från en $U(a, 0)$ -population, bestäm en endimensionell tillräcklig statistika för a .

5.18. [1] Givet ett stickprov $x_1, \dots, x_n$ från en $U(a, b)$ -population, bestäm en tvådimensionell tillräcklig statistika för $[a, b]^T$.

5.19. [2] Låt $X_1, \dots, X_n$ vara oberoende och anta att $X_i \sim N(i\theta, \sigma^2)$ för $i = 1, \dots, n$. Visa att

$$t = \frac{6}{n(n+1)(2n+1)} \sum_{i=1}^n ix_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - it)^2$$

är en tvådimensionell tillräcklig statistika för $[\theta, \sigma^2]^T$.

5.20. [1] Låt $X \sim N(0, \sigma^2)$. Givet ett enda utfall x , är $|x|$ en tillräcklig statistika för σ^2 ?

- 5.21.** [1] (a) Låt $x_1, \dots, x_n$ vara ett stickprov från en population med täthetsfunktion

$$f_X(x \mid \mu, \sigma) = \frac{1}{\sigma} e^{-(x-\mu)/\sigma}, \quad \mu < x < \infty, 0 < \sigma < \infty.$$

Bestäm en tvådimensionell tillräcklig statistika för $[\mu, \sigma]^T$.

- (b) Låt $x_1, \dots, x_n$ vara ett stickprov från en $\text{Gamma}(\alpha, \beta)$ -population. Bestäm en tvådimensionell tillräcklig statistika för $[\alpha, \beta]^T$.

Kapitel 6

Nu när vi vet några metoder för att hitta bra statistikor är frågan, ”Hur kan man använda sådana statistikor för att skatta parametrar?” Anta, exempelvis, att $x_1, \dots, x_n$ är ett stickprov där $X_1, \dots, X_n$ är oberoende och $N(\mu, 4)$ -fördelade. Vi skulle vilja använda våra statistikor för att skatta μ . Vi såg i Exempel 5.8 att $\bar{X}$ är en tillräcklig statistika för μ ; dvs. all information som man kan använda för att skatta μ ingår i $\bar{X}$. Vi såg också att $E[\bar{X}] = \mu$. Dessa fakta föreslår att en bra skattning för μ är $\mu^* = \bar{x}$. Detta val är ganska enkelt men är helt baserat på vad vi vet om μ från datan $x_1, \dots, x_n$.

Generellt sett kallas denna process för att skatta parametrarna $\theta_1, \dots, \theta_d$ i en fördelning $f_X(x|\theta_1, \dots, \theta_d)$ från data för en *punktskattning* och det görs med en funktion

$$W : \mathbb{R}^n \longrightarrow \mathbb{R}^d$$

där $W(\mathbf{X}) = W(X_1, \dots, X_n)$; dvs. som tar ett stickprov och ger en skattning av parametrarna. Funktionen W eller $W(\mathbf{X})$ kallas en *stickprovsvariabel* (eller *punktskattning*) och det observerade värdet $W(\mathbf{x}) = W(x_1, \dots, x_n)$ kallas en *punktskattning*. Vår första metod för att hitta en punktskattning generaliserar vårt lilla exempel med normalfördelningen.

6.1 Momentmetoden

En av de enklaste metoderna för att bestämma en punktskattning är följande: Anta att vi har $\mathbf{X} = [X_1, \dots, X_n]^T$ där $X_1, \dots, X_n$ är oberoende och likafördelade med sannolikhetsfunktion (eller täthetsfunktion) $f_X(x|\boldsymbol{\theta})$ där $\boldsymbol{\theta} = [\theta_1, \dots, \theta_d]^T$. Vi kan beräkna de första d *stickprovsmomenten*:

$$\begin{aligned} m_1(\mathbf{X}) &= \frac{1}{n} \sum_{i=1}^n X_i, \\ m_2(\mathbf{X}) &= \frac{1}{n} \sum_{i=1}^n X_i^2, \\ &\vdots \\ m_d(\mathbf{X}) &= \frac{1}{n} \sum_{i=1}^n X_i^d. \end{aligned}$$

Vi kan också beräkna formler för de första d *populationsmomenten*:

$$E[X|\boldsymbol{\theta}], E[X^2|\boldsymbol{\theta}], \dots, E[X^d|\boldsymbol{\theta}].$$

Här skriver vi $E[X^k|\boldsymbol{\theta}]$ för $E[X^k]$ för att betona att X (och därmed X^k) har fördelningar som beror på $\boldsymbol{\theta}$. Då får vi ett ekvationssystem

$$\begin{aligned} m_1(\mathbf{X}) &= E[X|\boldsymbol{\theta}], \\ m_2(\mathbf{X}) &= E[X^2|\boldsymbol{\theta}], \\ &\vdots \\ m_d(\mathbf{X}) &= E[X^d|\boldsymbol{\theta}]. \end{aligned}$$

som vi kan lösa ut för att få *momentmetodens punktskattning*:

$$\tilde{\boldsymbol{\theta}} = (\tilde{\theta}_1, \dots, \tilde{\theta}_d).$$

Exempel 6.1. Låt $x_1, \dots, x_n$ vara ett stickprov där $X_1, \dots, X_n$ är oberoende och $N(\mu, \sigma^2)$ -fördelade. Vi vill bestämma en punktskattning enligt momentmetoden för (μ, σ^2) . Det första momentet av $X \sim N(\mu, \sigma^2)$ är $E[X] = \mu$. För att bestämma det andra momentet använder vi att $\text{Var}[X] = \sigma^2$ och

$$\text{Var}[X] = E[X^2] - E[X]^2.$$

Det följer att

$$\begin{aligned} E[X^2] &= \text{Var}[X] + E[X]^2, \\ &= \sigma^2 + \mu^2. \end{aligned}$$

De första två stickprovsmomenten är då

$$\begin{aligned} m_1(\mathbf{X}) &= \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}, \quad \text{och,} \\ m_2(\mathbf{X}) &= \frac{1}{n} \sum_{i=1}^n X_i^2. \end{aligned}$$

Så vi löser nu systemet

$$\begin{aligned} \bar{X} &= \mu, \\ \frac{1}{n} \sum_{i=1}^n X_i^2 &= \sigma^2 + \mu^2. \end{aligned}$$

Den första ekvationen ger oss att $\tilde{\mu} = \bar{x}$ och den andra ekvationen ger

$$\begin{aligned} \tilde{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2, \\ &= \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - 2\bar{x}^2 + \bar{x}^2, \\ &= \frac{1}{n} \sum_{i=1}^n x_i^2 - \frac{2\bar{x}}{n} \sum_{i=1}^n x_i + \frac{1}{n} \sum_{i=1}^n \bar{x}^2, \\ &= \frac{1}{n} \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2), \\ &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2, \\ &= \frac{n-1}{n} s^2. \end{aligned}$$

Så vi får punktskattningen $[\tilde{\mu}, \tilde{\sigma}^2]^T = [\bar{x}, (n-1)s^2/n]^T$ för $[\mu, \sigma^2]^T$. Punktskattningen för μ är bra eftersom $E[\tilde{\mu}] = \mu$. Å andra sidan har vi att

$$E[\tilde{\sigma}^2] = \frac{n-1}{n} \sigma^2.$$

Så skattningen för σ^2 kommer att underskatta det rätta värdet för små n . Vi kommer att diskutera detta problem i nästa kapitel.

Exempel 6.2. Låt $x_1, \dots, x_n$ vara ett stickprov där $X_1, \dots, X_n$ är oberoende och $\text{Bin}(\theta, p)$ -fördelade där både θ och p är okända. Vi vill bestämma en punktskattning enligt momentmetoden för $[\theta, p]^T$. Det första momentet av $X \sim \text{Bin}(\theta, p)$ är $E[X] = \theta p$. För att bestämma det andra momentet använder vi att $\text{Var}[X] = \theta p(1-p)$ och $\text{Var}[X] = E[X^2] - E[X]^2$. Då får vi att

$$\begin{aligned} E[X^2] &= \text{Var}[X] + E[X]^2, \\ &= \theta p(1-p) + \theta^2 p^2. \end{aligned}$$

De första två stickprovsmomenten är

$$m_1(\mathbf{X}) = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \quad \text{och}$$

$$m_2(\mathbf{X}) = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

Vi löser nu systemet av ekvationer:

$$\bar{x} = \theta p,$$

$$m_2(\mathbf{x}) = \theta p(1-p) + \theta^2 p^2.$$

Den första ekvationen ger

$$p = \frac{\bar{x}}{\theta}.$$

Med hjälp av denna formel och den andra ekvationen får vi att

$$\tilde{\theta} = \frac{\bar{x}^2}{\bar{x} - \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Formeln för $\tilde{\theta}$ ger oss att

$$\tilde{p} = \frac{\bar{x}}{\tilde{\theta}} = \frac{\bar{x} - \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}{\bar{x}}.$$

Denna punktskattning kan vara opålitlig när n är litet eftersom vi kan ha

$$\bar{x} < \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

vilket ger $\tilde{\theta} < 0$. Men det är en bra start eftersom punktskattningen är lätt att beräkna. I nästa kapitel ska vi se andra metoder för punktskattning.

Det är också möjligt att använda momentmetoden för att hitta skattningar för parametrar i en flerdimensionell modell men detta kräver mer avancerade tekniker från algebra. I nästa kapitel ska vi se en annan punktskattning som är lite lättare att hitta för sådana modeller.

6.2 Maximum-likelihoodmetoden

Medan momentmetoden är snabb och enkel ger den inte alltid de bästa skattningarna. En annan metod är baserad på ett stickprovs likelihoodfunktion. *Likelihoodfunktionen* för ett stickprov $x_1, \dots, x_n$ från en $f_X(x|\boldsymbol{\theta})$ -population definieras som

$$L(\boldsymbol{\theta}|\mathbf{x}) = L(\boldsymbol{\theta}|x_1, \dots, x_n),$$

$$= f_{\mathbf{X}}(x_1, \dots, x_n|\boldsymbol{\theta}),$$

Likelihoodfunktionen är bara den simultana täthetsfunktionen (eller sannolikhetsfunktionen) men där värdena $x_1, \dots, x_n$ är fixa och $\boldsymbol{\theta}$ varierar. Eftersom $x_1, \dots, x_n$ är ett stickprov är $x_1, \dots, x_n$ slumpmässiga utfall från $X_1, \dots, X_n$ där $X_1, \dots, X_n$ är oberoende och $f_X(x|\boldsymbol{\theta})$ -fördelade. Det följer att den simultana täthetsfunktionen (eller sannolikhetsfunktionen) $f_{\mathbf{X}}(x_1, \dots, x_n|\boldsymbol{\theta})$ uppfyller

$$f_{\mathbf{X}}(x_1, \dots, x_n|\boldsymbol{\theta}) = \prod_{i=1}^n f_{X_i}(x_i|\boldsymbol{\theta}).$$

Med andra ord har vi att stickprovets likelihoodfunktion är

$$L(\boldsymbol{\theta}|\mathbf{x}) = \prod_{i=1}^n f_{X_i}(x_i|\boldsymbol{\theta}).$$

I det diskreta fallet ger likelihoodfunktionen stickprovets sannolikhet för godtyckliga värden på parametrarna. På detta sätt svarar likelihoodfunktionen på frågan om hur troligt datan är för varje givet val av θ .

Låt $\hat{\theta}$ vara valet för θ som maximerar likelihoodfunktionen för datan $\mathbf{x}$; det vill säga

$$\hat{\theta}(\mathbf{x}) = \operatorname{argmax}_{\theta \in \Omega} L(\theta|\mathbf{x})$$

där Ω betecknar parameterrummet. Funktionen $\hat{\theta}$ är en funktion $\hat{\theta} : \mathbb{R}^n \rightarrow \mathbb{R}^d$ som skickar möjliga observationer till parametervärden. När vi tillämpar funktionen $\hat{\theta}(\mathbf{x})$ på stickprovet $\mathbf{x}$ får vi *maximum-likelihoodskattningen* (ML-skattningen) $\hat{\theta}(\mathbf{x})$ för θ . När data förstås utifrån sammanhanget skriver vi ofta helt enkelt $\hat{\theta}$; det vill säga ML-skattningen för θ är $\hat{\theta}$.

ML-skattningen är ofta unik; det vill säga, det finns bara ett val för θ som maximerar $L(\theta|\mathbf{x})$. Detta behöver dock inte vara fallet (ML-skattningen behöver egentligen inte existera!). Det vore mer korrekt att kalla $\hat{\theta}$ för *en* ML-skattning men det är brukligt att bara säga ML-skattningen. ML-skattningar är ganska lätta att definiera men de kan vara svåra att beräkna i praktiken. Eftersom ML-skattningen maximerar en funktion har vi ett generellt recept för att beräkna den:

1. Beräkna de partiella derivatorna $\frac{\partial}{\partial \theta_j} L(\theta|\mathbf{x})$ där $\theta = [\theta_1, \dots, \theta_d]^T$. Det är vanligt att beräkna dessa för *log-likelihoodfunktionen* $\log L(\theta|\mathbf{x})$ istället (Båda metoderna ger samma svar eftersom $\log(\cdot)$ är en strikt växande funktion.).
2. Beräkna kritiska punkter av $L(\theta|\mathbf{x})$ (eller $\log L(\theta|\mathbf{x})$); dvs. lösningarna för systemet av ekvationer som fås när vi sätter de partiella derivatorna lika med 0.
3. Bestäm de kritiska punkterna som är (lokala) maxima genom att beräkna matrisen

$$\left[\frac{\partial^2}{\partial \theta_i \partial \theta_j} L(\theta|\mathbf{x}) \right]_{i,j=1}^d$$

och bestäm för vilka kritiska punkter matrisen är negativt definit (alla egenvärden är negativa). (Detta går också att göra med $\log L(\theta|\mathbf{x})$.) Ibland kan vi använda algebraiska metoder för att verifiera att en kritisk punkt är ett lokalt maximum istället.

4. Jämför värdet $L(\theta|\mathbf{x})$ på θ för alla lokala maxima θ och randpunkter (inklusive oändligheten) och ta punkten med det största värdet.

Exempel 6.3. Låt $x_1, \dots, x_n$ vara ett stickprov från en $\text{Ber}(p)$ -population. Då har vi likelihoodfunktionen

$$\begin{aligned} L(p|\mathbf{x}) &= L(p|x_1, \dots, x_n), \\ &= f_{\mathbf{X}}(x_1, \dots, x_n|p), \\ &= \prod_{i=1}^n f_{X_i}(x_i|p), & (X_1, \dots, X_n \text{ är oberoende}) \\ &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}, & (X_i \sim \text{Ber}(p) \text{ för alla } i = 1, \dots, n) \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i}. \end{aligned}$$

För att förenkla beräkningen använder vi log-likelihoodfunktionen som ges av

$$\begin{aligned} \log L(p|\mathbf{x}) &= \log(p) \left(\sum_{i=1}^n x_i \right) + \log(1-p) \left(n - \sum_{i=1}^n x_i \right), \\ &= \log(p)n\bar{x} + \log(1-p)n(1-\bar{x}). \end{aligned}$$

Vi betrakta först fallet där $0 < \bar{x} < 1$. Vi har att

$$\frac{d}{dp} \log L(p|\mathbf{x}) = \frac{n\bar{x}}{p} - \frac{n(1-\bar{x})}{1-p}.$$

För att bestämma de kritiska punkterna sätter vi derivatan ovan lika med 0 och löser ut p :

$$\begin{aligned} 0 &= \frac{n\bar{x}}{p} - \frac{n(1-\bar{x})}{1-p}, \\ pn(1-\bar{x}) &= n\bar{x}(1-p), \\ p &= \bar{x}. \end{aligned}$$

Det finns bara en kritisk punkt, $p = \bar{x}$. Vi ser att $p = \bar{x}$ är ett lokalt maximum eftersom

$$\frac{d^2}{dp^2} \log L(p|\mathbf{x}) = -\frac{n\bar{x}}{p^2} - \frac{n(1-\bar{x})}{(1-p)^2} < 0$$

där vi använder att $\bar{x} > 0$ och $1 - \bar{x} > 0$. Här har vi randpunkter 0 och 1. För $0 < \bar{x} < 1$ ser vi att

$$L(0|\mathbf{x}) = L(1|\mathbf{x}) = 0 < L(\bar{x}|\mathbf{x}) = \bar{x}^{\sum_{i=1}^n x_i} (1-\bar{x})^{n-\sum_{i=1}^n x_i}.$$

Därför är $\hat{p} = \bar{x}$ det globala maximum. Det är också möjligt att $\bar{x} = 0$ eller $\bar{x} = 1$. I dessa fall har vi att

$$\log L(p|\mathbf{x}) = \begin{cases} n \log(1-p) & \text{om } \bar{x} = 0, \\ n \log(p) & \text{om } \bar{x} = 1. \end{cases}$$

I båda fall har vi att $\log L(p|\mathbf{x})$ är en monoton funktion av p på $[0, 1]$ med maximum i $\bar{x}$. Det följer att $\hat{p} = \bar{x}$ är ML-skattningen för p .

Vi kan också använda samma metod för modeller som beror på fler än en parameter.

Exempel 6.4. Låt $X_1, \dots, X_n$ vara oberoende och $N(\mu, \sigma^2)$ -fördelade med både μ och σ^2 okända. Likelihoodfunktionen är

$$L(\mu, \sigma^2|\mathbf{x}) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right).$$

Vi har då log-likelihoodfunktionen

$$\log L(\mu, \sigma^2|\mathbf{x}) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Det följer att de partiella derivatorna är

$$\begin{aligned} \frac{\partial}{\partial \mu} \log L(\mu, \sigma^2|\mathbf{x}) &= \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu), \\ \frac{\partial}{\partial \sigma^2} \log L(\mu, \sigma^2|\mathbf{x}) &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2. \end{aligned}$$

(Observera att den andra derivatan är med avseende på σ^2 (inte σ). Detta är eftersom vi parametriserar modellen med variansen utan standardavvikelsen.) Vi sätter nu partialderivatorna lika med 0 och löser ut $[\mu, \sigma^2]^T$. Vi får då

$$\begin{aligned} \mu &= \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \\ \sigma^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n-1}{n} s^2. \end{aligned}$$

För att se om den kritiska punkten $[\mu, \sigma^2]^T = [\bar{x}, (n-1)s^2/n]^T$ är ML-skattningen verifierar vi först att den är ett lokalt maximum. Istället för att beräkna andraderivatorna noterar vi att för alla μ har vi

$$\sum_{i=1}^n (x_i - \mu)^2 > \sum_{i=1}^n (x_i - \bar{x})^2.$$

Så vi har att

$$L(\mu, \sigma^2 | \mathbf{x}) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right) \leq \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2\right) = L(\bar{x}, \sigma^2 | \mathbf{x})$$

för alla $\sigma^2 > 0$. Så det är tillräckligt att visa likelihoodfunktionen maximeras i $\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ när $\mu = \bar{x}$. Andraderivatan med avseende på σ^2 ges av

$$\begin{aligned} \frac{d^2}{d(\sigma^2)^2} \log L(\bar{x}, \sigma^2 | \mathbf{x}) &= \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum_{i=1}^n (x_i - \bar{x})^2, \\ &= -\frac{1}{\sigma^6} \left(\sum_{i=1}^n (x_i - \bar{x})^2 - \frac{n\sigma^2}{2} \right). \end{aligned}$$

Eftersom faktorn

$$\left(\sum_{i=1}^n (x_i - \bar{x})^2 - \frac{n\sigma^2}{2} \right)$$

är positiv när $\sigma^2 = (n-1)s^2/n = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ vet vi att andraderivatan är negativ. Därför är punkten $[\mu, \sigma^2]^T = [\bar{x}, (n-1)s^2/n]^T$ ett lokalt maximum.

Det återstår att visa att punkten är ett globalt maximum. Vi har redan sett att $L(\mu, \sigma^2 | \mathbf{x}) < L(\bar{x}, \sigma^2 | \mathbf{x})$ för $\mu \neq \bar{x}$. Därför måste ett annat maximum $[\mu^*, (\sigma^2)^*]^T$ ha $\mu^* = \bar{x}$. Det följer att problemet är ett endimensionellt problem där vi måste visa att $\sigma^2 = (n-1)s^2/n$ ger det globala maximum för funktionen $L(\bar{x}, \sigma^2 | \mathbf{x})$. Vi kan visa detta på följande sätt: Vi vet att $\sigma^2 = (n-1)s^2/n$ är ett lokalt maximum och det är det enda inre kritiska punkten för funktionen $L(\bar{x}, \sigma^2 | \mathbf{x})$ på $\sigma^2 > 0$. Om det fanns ett annat maximum $(\sigma^2)^*$ måste vi då ha ett minimum mellan $(n-1)s^2/n$ och $(\sigma^2)^*$. Det minimum skulle ha givits av en annan kritisk punkt. Detta motsäger att vi bara ha en inre kritisk punkt. Därför måste $\sigma^2 = (n-1)s^2/n$ vara det globala maximum. Det följer att ML-skattningen för $[\mu, \sigma^2]^T$ är $[\hat{\mu}, \hat{\sigma}^2]^T = [\bar{x}, (n-1)s^2/n]^T$.

Resultatet i Exempel 6.4 kan generaliseras även till flerdimensionella normalfördelningar. Matrisen $\hat{\Sigma}$ i följande sats kallas *stickprovskovariansmatrisen* och den är garanterat positivt semidefinit och positivt definit när ML-skattningen existerar. Att beskriva när ML-skattningen existerar ligger utanför denna bok. Om stickprovskovariansmatrisen dock är positivt definit existerar ML-skattningen.

Sats 6.1. Låt $\mathbf{X}_1, \dots, \mathbf{X}_n$ vara oberoende och $N(\boldsymbol{\mu}, \Sigma)$ -fördelade. ML-skattningen för $[\boldsymbol{\mu}, \Sigma]^T$ är

$$\hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i = \bar{\mathbf{X}}, \quad \hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^T.$$

6.2.1 Gradientmetoden

I våra exempel hittills var det möjligt att hitta en formel för ML-skattningen *analytiskt*; dvs., det var möjligt att lösa ett system av ekvationer som ges av de partiella derivatorna för att hitta en formel för ML-skattningen. Det finns dock modeller för vilka det är omöjligt att göra detta. En styrka med ML-skattningen är att det finns bra *numeriska* metoder för att approximera ML-skattningen trots att vi inte kan hitta en analytisk formel.

Ett populärt sätt att göra detta är naturligt baserat på derivator. Anta att vi vill maximera log-likelihoodfunktionen $L(\theta | \mathbf{x})$. Att maximera $\log L(\theta | \mathbf{x})$ är detsamma som att minimera funktionen $f(\theta) = -\log L(\theta | \mathbf{x})$. Anta också att vi börjar i en viss punkt θ_0 i parameterutrymmet. Derivatan av $f(\theta)$ på θ_0 är tangentens lutning för $f(\theta)$ på θ_0 . Om lutningen $f'(\theta_0)$ är negativ kommer vi närmare ett minimum om vi tar ett steg ”framåt” (om vi ökar värdet för θ_0). Om lutningen är positiv borde vi ta ett steg bakåt för att närma oss ett minimum. I både fall tar vi ett steg mot θ_1 där

$$\theta_1 = \theta_0 - n_0 f'(\theta_0).$$

Här använder vi konstanten n_0 som bestämmer hur långt steg vi tar. Konstanten n_0 kallas för *steglängden*. Vi kan upprepa denna process flera gånger och bilda en sekvens $\theta_0, \theta_1, \theta_2, \dots$ där

$$\theta_{k+1} = \theta_k - n_k f'(\theta_k) \quad \text{för } k = 0, 1, 2, \dots$$

och n_k är steglängden på den k :te iterationen. Om vi tar n_k tillräckligt liten kommer vi att konvergera till ett (lokalt) minimum. Men om vi tar n_k för liten kan det ta lång tid att konvergera. Å andra sidan, om vi tar n_k för stor är det möjligt att vi inte konvergerar alls (vi kan hoppa över minimat igen och igen för alltid). Med andra ord är valet av n_k viktigt!

Exempel 6.5. Låt $x_1, \dots, x_{1000}$ vara ett stickprov från en $\text{Gamma}(\alpha, 5)$ -population. Log-likelihoodfunktionen ges av

$$\begin{aligned}\ell(\alpha|\mathbf{x}) &= \log \prod_{i=1}^{1000} \frac{5^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-5x_i}, \\ &= 1000\alpha \log(5) - 1000 \log(\Gamma(\alpha)) + (\alpha - 1) \sum_{i=1}^{1000} \log(x_i) - 5(1000)\bar{x}.\end{aligned}$$


När vi tar derivatan med avseende på α får vi

$$f'(\alpha) = 1000 \log(5) - (1000) \frac{\Gamma'(\alpha)}{\Gamma(\alpha)} + \sum_{i=1}^{1000} \log(x_i).$$

Om vi sätter $f'(\alpha) = 0$ kan vi inte lösa ut α eftersom vi inte har någon analytisk formel för inversen av *digamma-funktionen*

$$\Psi(\alpha) = \frac{\Gamma'(\alpha)}{\Gamma(\alpha)}.$$

Python har dock en implementering av digammafunktionen vilken låter oss beräkna värdet $f'(\alpha_k)$ för givet α_k . I vårt exempel använder vi ett stickprov genererat från en $\text{Gamma}(10, 5)$ -population och vi vill approximera ML-skattningen för α . Om metoden fungerar kommer vi att få ut ett värde nära 10. Om vi börjar med $\alpha_0 = 20$ och tar $n_k = 0.01$ för varje $k = 0, 1, \dots, 20$ får vi resultatet i följande figur.



Vi ser att metoden konvergerar till ett (lokalt) minimum nära $\alpha = 10$. Sedan kan vi använda $\hat{\alpha} = 10$ som en (approximativ) ML-skattning för α . Vi måste dock vara försiktiga. Detta är bara en approximation till ett lokalt maximum för likelihoodfunktionen. Det är möjligt att det finns en annan kritisk punkt som är det verkliga globala maximum men vi inte hittade det på grund av våra val av initialisering eller steglängd. Å andra sidan, om vi vet att likelihoodfunktionen bara har en kritisk punkt kan vi vara mer säkra på att skattningen är bra. Det vill säga ju mer vi vet om likelihoodfunktionen, desto mer säkra kan vi vara att vi har hittat det globala maximum med denna metod.

Metoden fungerar lika bra för att approximera ML-skattningen för modeller med fler än en parameter. När vi har flera parametrar $\boldsymbol{\theta} = [\theta_1, \dots, \theta_d]^T$ definierar vi den k :te iterationen $\boldsymbol{\theta}_k$ genom

$$\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - n_k \nabla f(\boldsymbol{\theta}_k)$$

där

$$\nabla f(\boldsymbol{\theta}_k) = \begin{bmatrix} \left. \frac{\partial f(\boldsymbol{\theta})}{\partial \theta_1} \right|_{\boldsymbol{\theta}=\boldsymbol{\theta}_k} \\ \vdots \\ \left. \frac{\partial f(\boldsymbol{\theta})}{\partial \theta_d} \right|_{\boldsymbol{\theta}=\boldsymbol{\theta}_k} \end{bmatrix}$$

är *gradienten* (*gradient* på engelska) för $f(\boldsymbol{\theta})$ i $\boldsymbol{\theta}_k$. Detta är riktningen (och hastigheten) för den snabbaste ökningen av $f(\boldsymbol{\theta})$ på $\boldsymbol{\theta}_k$. Det följer att

$$\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - n_k \nabla f(\boldsymbol{\theta}_k)$$

har ett mindre värde på $f(\boldsymbol{\theta})$ relativt till $\boldsymbol{\theta}_k$ med steglängden n_k (om n_k är tillräckligt liten). Eftersom vi alltid ”går ner” i den negativa gradientens riktning vid varje iteration kallar vi denna metod för *gradientmetoden*.

Exempel 6.6. Låt $x_1, \dots, x_{1000}$ vara ett stickprov från en $\text{Gamma}(\alpha, \lambda)$ -population. Vi använder samma stickprov som i Exempel 6.5; dvs. vi använder ett stickprov genererat från en $\text{Gamma}(10, 5)$ -population. Vi vill hitta skattningar $\hat{\alpha}$ och $\hat{\lambda}$ nära 10 respektive 5. Log-likelihoodfunktionen ges av

$$\begin{aligned} \ell(\alpha, \lambda | \mathbf{x}) &= \log \prod_{i=1}^{1000} \frac{\lambda^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\lambda x_i}, \\ &= 1000\alpha \log(\lambda) - 1000 \log(\Gamma(\alpha)) + (\alpha - 1) \sum_{i=1}^{1000} \log(x_i) - 1000\lambda \bar{x}. \end{aligned}$$

Vi låter $\boldsymbol{\theta} = [\alpha, \lambda]^T$ och $f(\boldsymbol{\theta}) = -\ell(\alpha, \lambda | \mathbf{x})$. Vi har då två partiella derivator

$$\begin{aligned} \frac{\partial f(\boldsymbol{\theta})}{\partial \alpha} &= -1000 \log(\lambda) + n\Psi(\alpha) - \sum_{i=1}^{1000} \log(x_i), \quad \text{och} \\ \frac{\partial f(\boldsymbol{\theta})}{\partial \lambda} &= -\frac{n\alpha}{\lambda} + n\bar{x}. \end{aligned}$$


Det följer att gradienten för $f(\boldsymbol{\theta})$ är

$$\nabla f(\boldsymbol{\theta}) = \begin{bmatrix} -1000 \log(\lambda) + n\Psi(\alpha) - \sum_{i=1}^{1000} \log(x_i) \\ -\frac{n\alpha}{\lambda} + n\bar{x} \end{bmatrix}.$$

Vi låter $\boldsymbol{\theta}_0 = [20, 3]^T$, $n_k = 0.001$ för alla k och vi genererar $\boldsymbol{\theta}_k$ för $k = 1, \dots, 1000$ enligt


$$\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - 0.001 \nabla f(\boldsymbol{\theta}_k).$$

Resultatet visas i följande figur



Vi ser från figuren att metoden konvergerar till ungefär $\theta = [10.4, 5.25]^T$ vilken är ganska rimligt eftersom data genererats från en $\text{Gamma}(10, 5)$ -population.

Det är användbart att notera att konvergens tog lite fler iterationer än i Exempel 6.5. Detta är eftersom det är svårare att optimera för flera variabler istället för bara en. Det är också bra att notera att vi konvergerar eftersom steglängden och initieringen var väl valda. Följande plot visar vad som kan hända för andra val av steglängd och initialisering:



Vi ser att valet $\theta_0 = [8, 3]^T$ och $n_k = 0.0045$ (i rött) konvergerade nästan lika bra som ovan men steglängden var lite för stor för att nå konvergens. I synnerhet ser vi att i de sista iterationerna hoppar vi över en viss punkt många gånger och vi missar den optimala punkten varje gång. Denna bild kan dyka upp ofta när log-likelihoodfunktionen är ganska platt nära det globala maximumet och steglängden är för stor. I blått ser vi att valet $\theta_0 = [11, 7]^T$ och $n_k = 0.01$ hade en bra initialisering men steglängden var för stor. Ett sätt att fixa detta problem är att minska steglängden n_k för större k ; dvs. när vi tror att vi kommer fram till ett maximum. (Det finns flera metoder för att göra detta men vi kommer inte att diskutera dem här.) Den stora steglängden förde iterationerna bort från de riktiga parametrarna $\theta = [10, 5]^T$ och hindrade dem från att konvergera. I grönt tog vi $\theta_0 = [1, 6]^T$ och $n_k = 0.0003$ där vi hade en rimlig initialisering men en för liten steglängd. Det ser ut som vi behöver fler iterationer i detta fall innan vi kan vara säkra på att vi har konvergerat.

Vi ser från detta exempel att man måste vara försiktig med numeriska metoder och alltid prova olika val av initialisering och steglängd. Generellt sett är det bra att prova flera val och ta ML-skattningen till att vara resultatet som ser rimligast ut.

Gradientmetoden används nu ofta inom *maskininlärning*. Därför finns det mycket teori om bra sätt att bestämma initialisering och steglängd. Här visade vi bara grundidén. Om du vill lära dig mer om gradientmetoden kan du ta kurser inom maskininlärning på masternivå. På den mer teoretiska sidan såg vi också att det är viktigt att veta om log-likelihoodfunktionen har fler än en kritisk punkt. (Till exempel är det möjligt i Exempel 6.6 att den blåa linjen i den sista figuren hittade en annan kritisk punkt än de andra! Man måste undersöka log-likelihoodfunktionen närmare för att förkasta denna möjlighet.) Inom *algebraisk geometri* bildar mängden av kritiska punkter för en log-likelihoodfunktion en *algebraisk varietet*. När denna mängd är ändlig är denna varietet 0-dimensionell och dess *grad* (degree på engelska) är antalet kritiska punkter för log-likelihoodfunktionen. Denna varietets grad kallas för modellens *likelihoodgrad* (eng. *likelihood degree*) och det finns mycket forskning om detta i fältet *algebraisk statistik* (inklusive forskning gjord av någon som tog Fieldsmedaljen!). Du kan lära dig mer om detta i kurser i algebraisk geometri och algebraisk statistik.

Nu återkommer vi till våra exempel där det är möjligt att hitta en analytisk formel för ML-skattningen. När vi betraktar sådana exempel (dvs. Exempel 6.3 och 6.4) kan vi märka att det verkar finnas en koppling mellan ML-skattningar och tillräckliga statistikor. Till exempel såg vi att $\bar{X}$ och S^2 är tillräckliga statistikor för μ respektive σ^2 när $X_1, \dots, X_n$ är oberoende och $N(\mu, \sigma^2)$ -fördelade. Vi såg också att ML-skattningarna för μ och σ^2 är $\bar{x}$ respektive $\frac{n-1}{n} s^2$. Denna koppling är inte en slump. Med hjälp av Sats 5.5 vet vi att

$$f_{\mathbf{X}}(\mathbf{x}|\theta) = h(\mathbf{x})g(T(\mathbf{x})|\theta)$$

för några funktioner h och g när $T(\mathbf{x})$ är en tillräcklig statistika för θ där $\mathbf{x}$ är ett stickprov från en $f_{\mathbf{X}}(\mathbf{x}|\theta)$ -population. Det följer att $L(\theta|\mathbf{x})$ maximeras på $\hat{\theta}$ om och endast om $g(T(\mathbf{x})|\theta)$ maximeras på $\hat{\theta}$. Det vill säga att ML-skattningen kan alltid vara skrivas som en funktion av tillräckliga statistikor.

6.2.2 ML-skattningens invariansegenskap

En användbar egenskap hos ML-skattningar är att de är invarianta under transformationer. Mer specifikt är ML-skattningen för $\tau(\boldsymbol{\theta})$ lika med $\tau(\hat{\boldsymbol{\theta}})$ när $\tau : \mathbb{R}^d \rightarrow \mathbb{R}^d$ är injektiv och $\hat{\boldsymbol{\theta}}$ är ML-skattningen för $\boldsymbol{\theta}$. För att se detta, notera först att $\boldsymbol{\theta} = \tau^{-1}(\boldsymbol{\eta})$ är väldefinierad när τ är injektiv. Därför har vi att

$$\begin{aligned} L(\boldsymbol{\eta}|\mathbf{x}) &= \prod_{i=1}^n f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\eta}), \\ &= \prod_{i=1}^n f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta}), \quad (\text{där } \tau(\boldsymbol{\theta}) = \boldsymbol{\eta}) \\ &= L(\boldsymbol{\theta}|\mathbf{x}). \end{aligned}$$

Att maximera $L(\boldsymbol{\eta}|\mathbf{x})$ är därför detsamma som att maximera $L(\boldsymbol{\theta}|\mathbf{x})$. Det följer att $\hat{\boldsymbol{\eta}} = \tau(\hat{\boldsymbol{\theta}})$. Till exempel, vad borde vi göra när vi har ML-skattningen till variansen σ^2 och vi vill ta fram ML-skattningen för standardavvikelsen σ ? Eftersom $\sqrt{\cdot}$ är injektiv på parameterrummet för σ^2 , $\Omega = \{\sigma^2 : \sigma^2 > 0\}$, har vi att $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$.

Det händer dock ofta att vi vill använda ML-skattningen för vissa parametrar $\boldsymbol{\theta}$ för att hitta en ML-skattning för parametrarna $\boldsymbol{\eta}$ som inte är relaterade till $\boldsymbol{\theta}$ genom en injektiv transformation. Till exempel anta att vi vill hitta ML-skattningen för det andra momentet av $X \sim N(\mu, \sigma^2)$. Vi har att $E[X^2] = \mu^2 + \sigma^2$ men funktionen $\tau(\mu, \sigma^2) = \mu^2 + \sigma^2$ är inte injektiv. Det är alltså möjligt att det finns $[\mu_0, \sigma_0^2]^T \neq [\hat{\mu}, \hat{\sigma}^2]^T$ så att $\tau(\mu_0, \sigma_0^2) = \tau(\hat{\mu}, \hat{\sigma}^2)$ och $L(\mu_0, \sigma_0^2|\mathbf{x}) \neq L(\hat{\mu}, \hat{\sigma}^2|\mathbf{x})$. Vilket val för $\boldsymbol{\theta} = [\mu, \sigma^2]^T$ pekar ut det bästa valet för $\eta = \mu^2 + \sigma^2$? Intuitivt borde det vara ML-skattningen $\hat{\boldsymbol{\theta}}$. Vilket går att bevisa!

I situationerna där τ inte är injektiv går korrespondensen ovan mellan optimering över $\boldsymbol{\eta}$ och optimering över $\boldsymbol{\theta}$ sönder. Eftersom vi letar efter ML-skattningen för $\boldsymbol{\eta} = \tau(\boldsymbol{\theta})$ är det dock endast viktigt att vi hittar det optimala värdet för $\boldsymbol{\eta}$ oavsett vilken $\boldsymbol{\theta}$ som $\boldsymbol{\eta}$ kommer ifrån. Därför definierar vi *den inducerade likelihoodfunktionen*

$$L^*(\boldsymbol{\eta}|\mathbf{x}) = \sup_{\boldsymbol{\theta} : \tau(\boldsymbol{\theta}) = \boldsymbol{\eta}} L(\boldsymbol{\theta}|\mathbf{x}).$$

För parametrarna $\boldsymbol{\theta} = [\theta_1, \dots, \theta_d]^T$, $\boldsymbol{\eta} = [\eta_1, \dots, \eta_k]^T$ och en funktion $\tau(\boldsymbol{\theta}) = \boldsymbol{\eta}$ definierar vi *ML-skattningen* för $\boldsymbol{\eta} = \tau(\boldsymbol{\theta})$ som

$$\hat{\boldsymbol{\eta}}(\mathbf{x}) = \operatorname{argmax}_{\boldsymbol{\eta}} L^*(\boldsymbol{\eta}|\mathbf{x}).$$

Idéen att definiera $\hat{\boldsymbol{\eta}}$ med hjälp av den inducerade likelihoodfunktionen är att det bygger en bro för oss att beräkna ML-skattningen för $\boldsymbol{\eta}$ med hjälp av ML-skattningen för $\boldsymbol{\theta}$. Detta kan vara användbart när det är lättare att beräkna $\hat{\boldsymbol{\theta}}$ istället för $\hat{\boldsymbol{\eta}}$. Medan det kan låta svårt att bestämma ML-skattningen $\hat{\boldsymbol{\eta}}$ på detta sätt går det lättare med följande:

Sats 6.2. Om $\hat{\boldsymbol{\theta}}$ är ML-skattningen för $\boldsymbol{\theta}$ så har vi att $\tau(\hat{\boldsymbol{\theta}})$ är ML-skattningen för $\tau(\boldsymbol{\theta})$ för vilken funktion $\tau : \mathbb{R}^d \rightarrow \mathbb{R}^k$ som helst.

Bevis. Låt $\hat{\boldsymbol{\eta}}$ maximera $L^*(\boldsymbol{\eta}|\mathbf{x})$. Vi vill visa att

$$L^*(\hat{\boldsymbol{\eta}}|\mathbf{x}) = L^*(\tau(\hat{\boldsymbol{\theta}})|\mathbf{x}).$$

Då gäller det att $\tau(\hat{\boldsymbol{\theta}})$ också maximerar $L^*(\boldsymbol{\eta}|\mathbf{x})$ och därför är en ML-skattning.

Eftersom $\hat{\boldsymbol{\eta}}$ maximerar $L^*(\boldsymbol{\eta}|\mathbf{x})$ har vi

$$L^*(\hat{\boldsymbol{\eta}}|\mathbf{x}) = \sup_{\boldsymbol{\eta}} L^*(\boldsymbol{\eta}|\mathbf{x}) = \sup_{\boldsymbol{\eta}} \sup_{\boldsymbol{\theta} : \tau(\boldsymbol{\theta}) = \boldsymbol{\eta}} L(\boldsymbol{\theta}|\mathbf{x})$$

som följer direkt från definitionen av $L^*(\boldsymbol{\eta}|\mathbf{x})$. Att maximera $L(\boldsymbol{\theta}|\mathbf{x})$ först över en delmängd $\{\boldsymbol{\theta} : \tau(\boldsymbol{\theta}) = \boldsymbol{\eta}\}$ och sedan över alla $\boldsymbol{\eta}$ är ekvivalent med att maximera över alla $\boldsymbol{\theta}$. Därför har vi

$$L^*(\hat{\boldsymbol{\eta}}|\mathbf{x}) = \sup_{\boldsymbol{\theta}} L(\boldsymbol{\theta}|\mathbf{x}) = L(\hat{\boldsymbol{\theta}}|\mathbf{x})$$

där $\hat{\boldsymbol{\theta}}$ är ML-skattningen för $\boldsymbol{\theta}$. Vi har även att

$$L(\hat{\boldsymbol{\theta}}|\mathbf{x}) = \sup_{\boldsymbol{\theta} : \tau(\boldsymbol{\theta}) = \tau(\hat{\boldsymbol{\theta}})} L(\boldsymbol{\theta}|\mathbf{x}) = L^*(\tau(\hat{\boldsymbol{\theta}})|\mathbf{x}).$$

Genom att kombinera dessa observationer får vi att

$$L^*(\hat{\eta}|\mathbf{x}) = L(\hat{\theta}|\mathbf{x}) = L^*(\tau(\theta)|\mathbf{x}),$$

vilket skulle visas. □

Sats 6.2 säger att vi kan beräkna ML-skattningen för vissa parametrar för vilka det är lätt att beräkna ML-skattningen och transformera denna ML-skattning för att erhålla ML-skattningen för andra parametrar. Vi ger två exempel:

Exempel 6.7. Vi såg i Exempel 6.4 att

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

är ML-skattningen för variansen när $x_1, \dots, x_n$ är ett stickprov från en $N(\mu, \sigma^2)$ -population. Eftersom $\sigma = \tau(\sigma^2)$ där $\tau(\theta) = \sqrt{\theta}$ har vi att $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$ är ML-skattningen för standardavvikelsen σ .

Exempel 6.8. Låt $\tau(\theta) = \theta(1 - \theta)$ och låt $x_1, \dots, x_n$ vara ett stickprov från en $\text{Ber}(p)$ -fördelning. Variansen av $X \sim \text{Ber}(\theta)$ är $\theta(1 - \theta)$ och vi såg i Exempel 6.3 att $\hat{\theta} = \bar{x}$ är ML-skattningen för θ . Så det följer från Sats 6.2 att $\tau(\bar{x}) = \bar{x}(1 - \bar{x})$ är ML-skattningen för modellens varians.

6.2.3 Momentmetoden och ML-metoden

Vi avslutar diskussionen om ML-skattningar med en observation om deras relation till punktskattningar enligt momentmetoden. För ett $N(\mu, \sigma^2)$ -fördelat stickprov såg vi att

$$[\hat{\mu}, \hat{\sigma}^2]^T = \left[\bar{x}, \frac{n-1}{n} s^2 \right]^T = [\tilde{\mu}, \tilde{\sigma}^2]^T.$$

Det vill säga att punktskattningarna sammanfaller. Det går också snabbt att verifiera att ML-skattningen för p är densamma som momentmetodens punktskattning när $x_1, \dots, x_n$ är ett stickprov från en $\text{Ber}(p)$ -population. Medan detta ofta kan hända behöver inte dessa två punktskattningar alltid sammanfalla.

Exempel 6.9. Låt $x_1, \dots, x_n$ vara ett stickprov från en $U(0, \theta)$ -fördelning. Momentmetodens punktskattning för θ beräknas som

$$\frac{\theta}{2} = E[X|\theta] = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

där $X \sim U(0, \theta)$. Därför har vi $\tilde{\theta} = 2\bar{x}$. Å andra sidan har vi att likelihoodfunktionen för θ är

$$L(\theta|\mathbf{x}) = \frac{1}{\theta^n} \mathbf{1}_{[0, \theta]}(x_1) \cdots \mathbf{1}_{[0, \theta]}(x_n)$$

vilken är en strikt avtagande funktion av θ på $\theta \geq \max_{i \in [n]}(x_i)$. Det följer att ML-skattningen för θ är $\hat{\theta} = \max_{i \in [n]}(x_i)$. Generellt sett är $\tilde{\theta} \neq \hat{\theta}$. Om vi till exempel har stickprovet

$$x_1 = 0.28, x_2 = 0.43, x_3 = 0.88, x_4 = 0.48, x_5 = 0.2$$

får vi att $\tilde{\theta} = 0.908$ och $\hat{\theta} = 0.88$.

Nu har vi olika metoder för att bestämma en punktskattning för parametrarna som kan ge oss olika skattningar. Frågan är nu "vilken punktskattning borde vi använda?"

6.3 Utvärdering av skattningar

För att bestämma vilken skattning som är bäst behöver vi metoder för att utvärdera skattningar. Skattningars utvärdering använder vanligtvis funktioner som kallas förlustfunktioner och den resulterande teorin och utvärderingstekniker bildar området inom statistisk inferens som kallas för beslutsteori. Givet ett stickprov $x_1, \dots, x_n$ från en $f_X(x|\theta)$ -population (där θ är okänt) kan vi göra ett val (eller *beslut* eller *handling*) om θ . Till exempel gör

vi beslutet att $\theta = \hat{\theta}$. *Handlingsrummet* $\mathcal{A}$ är mängden tillåtna beslut. Handlingsrummet är vanligtvis lika med parameterrummet; dvs. $\mathcal{A} = \Omega$ men det behöver inte vara så (eg. i hypotestester).

I detta avsnitt arbetar vi i det frekventistiska ramverket där vi antar att det finns ett riktigt val för de okända parametrarnas värden. Vi kan beteckna dessa värden som θ_0 (i vektorform). En *förlustfunktion* är en funktion som kvantifierar korrektheten i vårt beslut $a \in \mathcal{A}$ relativt till θ_0 . Om a är långt borta från θ_0 ska *förlusten* (dvs. värdet av förlustfunktionen) vara stor. Det representerar idén att vårt beslut att använda a (som är en ganska dåligt skattning för det riktiga parametervärdet θ_0) är en dålig idé. Samtidigt om a är nära till θ_0 ska förlusten vara liten. På detta sätt ger förlustfunktioner oss ett mått på hur mycket vi förlorar när vi skattar θ_0 med a .

Några vanliga förlustfunktioner är

- *absolutfel*: $L(\theta, a) = |a - \theta|$,
- *kvadratfel*: $L(\theta, a) = (a - \theta)^2$.

Det går att generalisera dessa till flera parametrar $\theta = [\theta_1, \dots, \theta_d]^T$ och beslut $a = [a_1, \dots, a_d]^T$ som

$$L(\theta, a) = \sum_{i=1}^n |a_i - \theta_i| \quad \text{respektive} \quad L(\theta, a) = \sum_{i=1}^n (a_i - \theta_i)^2.$$

Eftersom $L(\theta_0, a) = 0$ om och endast om $a = \theta_0$ är förlusten 0 om och endast om vårt beslut är korrekt. Olika val av förlustfunktioner kan naturligtvis ge oss olika förluster för samma beslut. Till exempel ger absolutfel en större förlust för små fel jämfört med kvadratfel. Å andra sidan ger kvadratfel en större förlust för större fel jämfört med absolutfel. Vi kan också definiera förlustfunktioner som ger mindre fel när vi överskattar θ_0 än när vi underskattar θ_0 :

$$L(\theta, a) = \begin{cases} (a - \theta)^2 & a < \theta, \\ 10(a - \theta)^2 & a \geq \theta. \end{cases}$$

Anta att vi beräknar en punktskattning $W(\mathbf{x})$ för parametrarna θ från ett stickprov $\mathbf{x}_1, \dots, \mathbf{x}_n$ från en $f_{\mathbf{X}}(\mathbf{x}|\theta)$ -population. Här betraktar vi $\mathbf{x}_i$ som ett slumpmässigt utfall från $\mathbf{X}_i$ där $\mathbf{X}_1, \dots, \mathbf{X}_n$ är oberoende och $f_{\mathbf{X}}(\mathbf{x}|\theta)$ -fördelade. Därför är punktskattningen $W(\mathbf{x})$ ett utfall från stickprovsvariabeln $W(\mathbf{X})$. I föregående kapitel gav vi två metoder för att hitta en punktskattning; nämligen momentmetoden och ML-metoden. Eftersom vi kan tillämpa dessa metoder till godtyckliga stickprov har metoderna motsvarande stickprovsvariabler. Vi vill jämföra dessa metoders prestanda för olika modeller utan hänsyn till givet stickprov. Därför jämför vi deras stickprovsvariabler. Vi har också ingen aning om det riktiga parametervärdet och därför vill vi jämföra dessa stickprovsvariabler med hjälp av funktioner av θ . Givet en förlustfunktion $L(\theta, a)$ och en stickprovsvariabel $W(\mathbf{X})$ kan vi kvantifiera stickprovsvariabelns kvalitet som skattningsmetod med hjälp av *riskfunktionen* för $L(\theta, a)$ och $W(\mathbf{X})$:

$$R(\theta, W) = E[L(\theta, W(\mathbf{X}))].$$

Notera att väntevärdet tas med avseende på $\mathbf{X}$; dvs,

$$R(\theta, W) = \int_{\mathbb{R}^n} L(\theta, W(\mathbf{x})) f_{\mathbf{X}}(\mathbf{x}|\theta) d\mathbf{x}.$$

Det följer att $R(\theta, W)$ är en funktion av θ (som vi sa att vi vill ha!). Värdet $R(\theta, W)$ för ett givet θ är den förväntade förlusten som vi får när vi använder $W(\mathbf{x})$ som en punktskattning för θ . Ett sätt för att jämföra olika skattningar är att jämföra deras riskfunktioner. Till exempel, om $W_1(\mathbf{x})$ och $W_2(\mathbf{x})$ är olika punktskattningar för θ där

$$R(\theta, W_1) < R(\theta, W_2) \quad \text{för alla } \theta \in \Omega$$

är $W_1(\mathbf{X})$ den föredragna punktskattningen enligt valet av förlustfunktionen $L(\theta, a)$.

Generellt sett kan det vara svårt att beräkna risken och förlustfunktionen för en given punktskattning men för kvadratfelet har vi en formel som gör det lättare:

Sats 6.3. Låt $X_1, \dots, X_n$ vara oberoende och $f_X(x|\theta)$ -fördelade och låt $W(\mathbf{X})$ vara en stickprovsvariabel som ger punktskattningar $W(\mathbf{x})$ för θ . För kvadratfelet $L(\theta, a) = (a - \theta)^2$ gäller det att

$$R(\theta, W) = E[(W(\mathbf{X}) - \theta)^2] = \text{Var}[W(\mathbf{X})] + (E[W(\mathbf{X})] - \theta)^2.$$

Bevis. Formeln följer enligt

$$\begin{aligned}
 E[(W(\mathbf{X}) - \theta)^2] &= E[(W(\mathbf{X}) - E[W(\mathbf{X})] + E[W(\mathbf{X})] - \theta)^2], \\
 &= E[(W(\mathbf{X}) - E[W(\mathbf{X})])^2] + E[(W(\mathbf{X}) - E[W(\mathbf{X})])(E[W(\mathbf{X})] - \theta)] + E[(E[W(\mathbf{X})] - \theta)^2], \\
 &= \text{Var}[(W(\mathbf{X}))] + (E[W(\mathbf{X})] - E[W(\mathbf{X})])(E[W(\mathbf{X})] - \theta) + (E[W(\mathbf{X})] - \theta)^2, \\
 &= \text{Var}[(W(\mathbf{X}))] + (0)(E[W(\mathbf{X})] - \theta) + (E[W(\mathbf{X})] - \theta)^2, \\
 &= \text{Var}[W(\mathbf{X})] + (E[W(\mathbf{X})] - \theta)^2.
 \end{aligned}$$

□

Risken $E[(W(\mathbf{X}) - \theta)^2]$ kallas vanligtvis för *medelkvadratfelet*. Med hjälp av ovanstående formel kan vi jämföra våra två punktskattningar för parametern θ i Exempel 6.9:

Exempel 6.10. Låt $X_1, \dots, X_n$ vara oberoende och $U(0, \theta)$ -fördelade. Vi såg tidigare att $\tilde{\Theta} = 2\bar{X}$ och $\hat{\Theta} = \max_{i \in [n]}(X_i)$ var stickprovsvariabelerna för momentmetoden respektive ML-metoden i Exempel 6.9. Medelkvadratfelet för $\tilde{\Theta}$ beräknas som

$$\begin{aligned}
 E[(2\bar{X} - \theta)^2] &= \text{Var}[2\bar{X}] + (E[2\bar{X}] - \theta)^2, \\
 &= \frac{4}{n^2} \sum_{i=1}^n \text{Var}[X_i] + \left(\frac{2}{n} \sum_{i=1}^n E[X_i] - \theta \right)^2, \quad (X_1, \dots, X_n \text{ oberoende}) \\
 &= \frac{4}{n^2} \frac{n\theta^2}{12} + \left(\frac{2}{n} \frac{n\theta}{2} - \theta \right)^2, \\
 &= \frac{\theta^2}{3n}.
 \end{aligned}$$


För att beräkna medelkvadratfelet för $\hat{\Theta}$ behöver vi $\text{Var}[\hat{\Theta}]$ och $E[\hat{\Theta}]$. Med hjälp av en variabelstransformation kan det visas att samplingfördelningen för $\hat{\Theta}$ är

$$f_{\hat{\Theta}}(\hat{\theta}) = \frac{1}{\theta^n} n\hat{\theta}^{n-1} \quad \text{för } \hat{\theta} > 0.$$

Med hjälp av denna formel kan vi beräkna $E[\hat{\Theta}] = \frac{n}{n+1}\theta$ och $E[\hat{\Theta}^2] = \frac{n}{n+2}\theta^2$. Det följer att

$$\begin{aligned}
 E[(\hat{\Theta} - \theta)^2] &= \text{Var}[\hat{\Theta}] + (E[\hat{\Theta}] - \theta)^2, \\
 &= \left(\frac{n\theta^2}{n+2} - \left(\frac{n\theta}{n+1} \right)^2 \right) + \left(\frac{\theta}{n+1} \right)^2, \quad (\text{Var}[\hat{\Theta}] = E[\hat{\Theta}^2] - E[\hat{\Theta}]^2) \\
 &= \frac{2}{(n+2)(n+1)}\theta^2.
 \end{aligned}$$

Eftersom både $\frac{1}{3n}$ och $\frac{2}{(n+2)(n+1)}$ går mot 0 då $n \rightarrow \infty$ blir risken för båda punktskattningarna mindre för större stickprov. Risken för ML-skattningen minskar dock snabbare än momentmetodens punktskattning. Vi ser detta i följande figur:



Så ML-skattningen ser ut som en bättre punktskattning för θ .

Å andra sidan såg vi i Exempel 6.10 att $E[\tilde{\Theta}] = \theta$ medan $E[\hat{\Theta}] < \theta$ för alla n . Så momentmetodens punktskattning är mer exakt än ML-skattningen i förväntan. För att formalisera denna idé definierar vi *det systematiska felet* (eng. *bias*) för en stickprovsvariabel $W(\mathbf{X})$ som ger punktskattningar för θ . Det systematiska felet för $W(\mathbf{X})$ definieras som

$$\text{Bias}[W(\mathbf{X})] = E[W(\mathbf{X})] - \theta.$$

Så vi har att

$$E[(W(\mathbf{X}) - \theta)^2] = \text{Var}[W(\mathbf{X})] + \text{Bias}[W(\mathbf{X})]^2.$$

Generellt sätt mäter systematiskt fel *riktighet* (hur långt borta punktskattningen är från målet) medan variansen mäter *precision* (hur konsekvent punktskattningen är). Vi vill vanligtvis ha både bra riktighet och precision eftersom det betyder att risken är låg. Ibland accepterar vi ett litet systematiskt fel om det låter oss reducera variansen (eller vice versa). Detta gjorde vi, exempelvis, i Exempel 6.10.

Vi har också sett i Exempel 6.10 att det kan kräva mycket arbete för att beräkna både variansen och det systematiska felet även för enkla modeller. Ett sätt för att bestämma bra punktskattningar i allmänhet är att kräva att det systematiska felet är 0; dvs. $E[W(\mathbf{X})] = \theta$. I sådana fall kallas $W(\mathbf{X})$ för en *väntevärdesriktig skattning*.

Exempel 6.11. Låt $X_1, \dots, X_n$ vara oberoende och $N(\mu, \sigma^2)$ -fördelade. Vi såg i Sats 5.1 att $\bar{X}$ och S^2 är väntevärdesriktiga skattningar för μ respektive σ^2 eftersom

$$E[\bar{X}] = \mu \quad \text{och} \quad E[S^2] = \sigma^2.$$

(Detta är varför vi delar med $n - 1$ istället för n i definitionen för S^2 !) Vi kan också beräkna deras varianser som

$$\text{Var}[\bar{X}] = \frac{\sigma^2}{n} \quad \text{och} \quad \text{Var}[S^2] = \frac{2\sigma^4}{n-1}.$$

Eftersom dessa skattningar är väntevärdesriktiga följer det att deras varianser är lika med deras medelkvadratfel.

Om vi istället tar ML-skattningen $\frac{n-1}{n}S^2$ för σ^2 har vi det systematiska felet

$$\text{Bias}\left[\frac{n-1}{n}S^2\right] = \frac{n-1}{n}\sigma^2 - \sigma^2 = -\frac{\sigma^2}{n}$$

och variansen

$$\text{Var}\left[\frac{n-1}{n}S^2\right] = \left(\frac{n-1}{n}\right)^2 \text{Var}[S^2] = \left(\frac{n-1}{n}\right)^2 \frac{2\sigma^4}{n-1} = \frac{2(n-1)}{n^2}\sigma^4.$$

Så medelkvadratfelet är

$$E\left[\left(\frac{n-1}{n}S^2 - \sigma^2\right)^2\right] = \frac{2(n-1)}{n^2}\sigma^4 + \frac{\sigma^4}{n^2} = \frac{2n-1}{n^2}\sigma^4 < \frac{2}{n-1}\sigma^4 = E[(S^2 - \sigma^2)^2].$$

Så ML-skattningen har ett mindre medelkvadratfel än S^2 trots att ML-skattningen är inte väntevärdesriktig och S^2 är väntevärdesriktig.

I våra exempel hittills har ML-skattningen varit en bättre skattning än alternativen i den meningen att den har haft mindre medelkvadratfel. Det betyder inte nödvändigtvis att man alltid ska använda ML-skattningen. Till exempel finns det inte så stor skillnad mellan skattningarna för stora stickprov. Så det kan vara lättare att använda, exempelvis, momentmetoden om den är lättare att beräkna. Vi har också sett att det kan vara svårt att hitta ML-skattningen analytiskt. I sådana fall skattar vi den numeriskt vilken kan öka felet i skattningen. I dessa situationer kan det vara en bra idé att betrakta momentmetoden.

Vi vet också att ML-skattningen (i dessa exempel) inte är väntevärdesriktig och underskattar parametern. Detta kan vara ett problem i vissa tillämpningar. Samtidigt har vi bara jämfört skattningarna med hjälp av medelkvadratfelet som straffar både underskattning och överskattning lika mycket. Detta stämmer nödvändigtvis inte för en skalparameter som σ^2 som alltid är positiv och kan potentiellt vara mer känslig för underskattning. Sist kan vi se att medelkvadratfelet är en funktion av θ som kan variera över Ω . Det är möjligt att det finns en skattning som fungerar bättre än ML-skattningen för vissa värden av θ men inte för andra.

6.4 Cramér-Raos olikhet

Nu fokuserar vi på väntevärdesriktiga skattningar $W(\mathbf{X})$. För sådana skattningar minimerar vi medelkvadratfelet precis när vi minimerar variansen $\text{Var}[W(\mathbf{X})]$. Det finns en kraftfull sats som hjälper oss att hitta väntevärdesriktiga skattningar med den minsta möjliga variansen. Satsen ger oss en undre gräns för variansen för sådana skattningar. Om vi når denna gräns vet vi att vi har en skattning med det minsta möjliga medelkvadratfelet.

Sats 6.4. Låt $X_1, \dots, X_n$ vara oberoende och likafördelade med sannolikhetsfunktion (eller täthetsfunktion) $f_X(x|\boldsymbol{\theta})$ där $\boldsymbol{\theta} = [\theta_1, \dots, \theta_d]^T$. Låt $W(\mathbf{X}) = W(X_1, \dots, X_n)$ vara en väntevärdesriktig skattning för $g(\boldsymbol{\theta})$ där $\boldsymbol{\theta} \in \{\theta_1, \dots, \theta_d\}$ och anta att $f_X(x|\boldsymbol{\theta})$ tillhör en exponentialfamilj. Då gäller det att

$$\text{Var}[W(\mathbf{X})] \geq \frac{g'(\boldsymbol{\theta})^2}{I(\boldsymbol{\theta})},$$

där

$$I(\boldsymbol{\theta}) = n \mathbb{E} \left[\left(\frac{\partial}{\partial \boldsymbol{\theta}} \log f_X(X|\boldsymbol{\theta}) \right)^2 \right] = -n \mathbb{E} \left[\frac{\partial^2}{\partial \boldsymbol{\theta}^2} \log f_X(X|\boldsymbol{\theta}) \right].$$

Värdet $I(\boldsymbol{\theta})$ kallas *informationstalet* eller *fisherinformationen* och värdet $\frac{g'(\boldsymbol{\theta})^2}{I(\boldsymbol{\theta})}$ kallas *Cramér-Raos undre gräns*.

Exempel 6.12. För $X_1, \dots, X_n$ oberoende och $\text{Po}(\lambda)$ -fördelade vet vi att

$$\mathbb{E}[\bar{X}] = \lambda$$

eftersom en $\text{Po}(\lambda)$ -fördelad stokastisk variabel har väntevärde lika med λ . (Här använder vi Sats 5.1.) Sannolikhetsfunktionen för en $\text{Po}(\lambda)$ -fördelad stokastisk variabel X är

$$f_X(x|\lambda) = \frac{\lambda^x e^{-\lambda}}{x!}.$$

Så vi har att fisherinformationen för λ är

$$\begin{aligned} I(\lambda) &= -n \mathbb{E} \left[\frac{d}{d\lambda^2} \log f_X(X|\lambda) \right], \\ &= -n \mathbb{E} \left[\frac{d}{d\lambda^2} (X \log(\lambda) - \lambda - \log(X!)) \right], \\ &= -n \mathbb{E} \left[-\frac{X}{\lambda^2} \right], \\ &= \frac{n \mathbb{E}[X]}{\lambda^2}, \\ &= \frac{n}{\lambda}. \end{aligned}$$

Med hjälp av Sats 5.1 har vi att

$$\text{Var}[\bar{X}] = \frac{\text{Var}[X]}{n} = \frac{\lambda}{n} = \frac{1}{I(\lambda)}.$$

Det följer att $\bar{X}$ har den minsta möjliga variansen (och därmed det minsta medelkvadratfelet) bland alla väntevärdesriktiga skattningar för λ .

Exempel 6.13. Låt $X_1, \dots, X_n$ vara oberoende och $N(\mu, \sigma^2)$ -fördelade. Fisherinformationen för σ^2 är

$$\begin{aligned} I(\sigma^2) &= -n \mathbb{E} \left[\frac{\partial^2}{\partial (\sigma^2)^2} \log f_X(X|\mu, \sigma^2) \right], \\ &= -n \mathbb{E} \left[\frac{1}{2\sigma^4} - \frac{(X - \mu)^2}{\sigma^6} \right], \\ &= -n \left(\frac{1}{2\sigma^4} - \frac{\mathbb{E}[(X - \mu)^2]}{\sigma^6} \right), \\ &= -n \left(\frac{1}{2\sigma^4} - \frac{\text{Var}[X]}{\sigma^6} \right), \\ &= -n \left(\frac{1}{2\sigma^4} - \frac{1}{\sigma^4} \right), \\ &= \frac{n}{2\sigma^4}. \end{aligned}$$

Enligt Sats 6.4 gäller det för en väntevärdesriktig skattning $W(\mathbf{X})$ för σ^2 att

$$\text{Var}[W(\mathbf{X})] \geq \frac{2\sigma^4}{n}.$$

Sats 5.1 visar att S^2 är en väntevärdesriktig skattning för σ^2 men vi såg i Exempel 6.11 att

$$\text{Var}[S^2] = \frac{2\sigma^4}{n-1} > \frac{2\sigma^4}{n}.$$

Därför uppnås inte S^2 Cramér-Raos undre gräns.

I situationer när vi inte hittar en skattning som uppnår Cramér-Raos undre gräns är det oklart om det finns en skattning som gör det. Följande sats ger oss ett sätt för att svara på denna fråga.

Sats 6.5. Låt $X_1, \dots, X_n$ vara oberoende och likafördelade med sannolikhetsfunktion (eller täthetsfunktion) $f_X(x|\boldsymbol{\theta})$ som tillhör en exponentialfamilj där $\boldsymbol{\theta} = [\theta_1, \dots, \theta_d]^T$. En väntevärdesriktig skattning $W(\mathbf{X})$ för $g(\boldsymbol{\theta})$ där $\boldsymbol{\theta} \in \{\theta_1, \dots, \theta_d\}$ uppnår Cramér-Raos undre gräns om och endast om

$$\frac{\partial}{\partial \boldsymbol{\theta}} \log f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta}) = a(\boldsymbol{\theta})(W(\mathbf{X}) - g(\boldsymbol{\theta}))$$

för någon funktion $a(\boldsymbol{\theta})$ där $f_{\mathbf{X}}(\mathbf{x}|\boldsymbol{\theta})$ är den simultana sannolikhetsfunktionen (eller täthetsfunktionen) för $X_1, \dots, X_n$.

Exempel 6.14. För normalfamiljen har vi den simultana täthetsfunktionen

$$f_{\mathbf{X}}(\mathbf{x}|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right).$$

Det följer att

$$\begin{aligned} \frac{\partial}{\partial \sigma^2} \log f_{\mathbf{X}}(\mathbf{x}|\mu, \sigma^2) &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2, \\ &= \frac{n}{2\sigma^4} \left(\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 - \sigma^2 \right). \end{aligned}$$

När vi tar $a(\sigma^2) = \frac{n}{2\sigma^4}$ får vi

$$W(\mathbf{X}) = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2.$$

Det följer att en skattning som uppnår Cramér-Raos undre gräns kräver att vi vet μ . Utan denna information kan vi inte uppnå gränsen.

I sådana fall som Exempel 6.14 säger vi att gränsen är *ouppnåelig*.

6.5 Uppgifter

- 6.1. [1] Paretofördelningen användes först för att modellera fördelningen av välstånd i ett samhälle, med grundantagandet att en stor del av förmögenheten innehas av en liten del av befolkningen. Vi har ett stickprov av årslönen hos 10 slumpmässiga invånare i New York City (räknat i tiotusentals dollar):

3.62, 4.84, 5.35, 2.51, 2.73, 3.75, 3.56, 2.51, 4.39, 7.08

Vi modellera datan som utfall från $X \sim \text{Pareto}(c, \alpha)$ där vi antar att $\alpha > 2$. Bestäm momentmetodens punktskattning för parametrarna $[c, \alpha]^T$.

- 6.2. [1] En *myon* är en elementarpartikel med en elektrisk laddning av $+1$ och ett spinn (en inneboende rörelsemängd) på $1/2$. Det är en instabil subatomär partikel med en livstid på $2.2 \mu\text{s}$. Eftersom myonens laddning och spin är samma som en elektrons men har en större massa kan myonen ses som en mycket tyngre version av elektronen. Kollisionen mellan en accelererad protonstråle med kärnorna i ett visst material producerar positiva pioner. Pionerna sönderfaller snabbt till myoner som sedan sönderfaller till en positron, en elektronuutrino och en myonantinuutrino. Vinkeln T mellan positronbanan och myonens spinn har täthetsfunktion

$$f_T(t | \alpha) = \frac{1}{2\pi}(1 + \alpha \cos(t)), \quad -\pi < t \leq \pi$$

för en parameter $\alpha \in [-1/3, 1/3]$. Givet ett stickprov $t_1, \dots, t_n$, beräkna momentmetodens punktskattning för parametern α .

- 6.3. [2] Låt

$$\begin{aligned} X | \Lambda = \lambda &\sim \text{Po}(\lambda), \\ \Lambda &\sim \text{Gamma}(\alpha, \beta). \end{aligned}$$

Beräkna momentmetodens punktskattning för $[\alpha, \beta]^T$ med hjälp av följande stickprov från X .

3 4 3 5 5 3 4 1 2 2
4 6 10 6 3 10 11 15 3 3
3 6 7 11 1 6 4 4 2 6.

Rita datans histogram tillsammans med den skattade täthetsfunktionen och diskutera punktskattningens kvalitet.

- 6.4. [2] Låt X vara en stokastisk variabel med täthetsfunktion

$$f_X(x | \lambda, \nu) = \frac{\lambda^2}{2\Gamma(2)}xe^{-\lambda x} + \frac{\nu^4}{2\Gamma(4)}x^3e^{-\nu x}, \quad 0 \leq x < \infty.$$

Beräkna momentmetodens punktskattning för $[\lambda, \nu]^T$ med hjälp av följande stickprov från X .

4.708 5.454 4.564 6.406 4.053 3.577 2.493 4.368 0.532 9.518
1.985 2.395 1.614 0.573 1.624 4.004 2.107 2.044 2.032 1.716.

Rita datans histogram tillsammans med den skattade täthetsfunktionen och diskutera punktskattningens kvalitet.

- 6.5. [1] Poissonfördelningen används ofta för att modellera antalet förekomster av en händelse inom ett givet tidsintervall. Vi antar att händelserna förekommer med ett konstant väntevärde och beror inte på tiden sedan den sista händelsen. Till exempel, antalet kunder på en restaurang under en dag kan modelleras med en $\text{Po}(\lambda)$ -fördelning där λ är den okända men konstanta takten för kundernas ankomst. Anta att

en viss restaurang i Gamla stan har uppmätt följande kundantal på 10 slumpmässigt utvalda dagar på sommaren:

110, 117, 93, 123, 102, 129, 107, 126, 119, 118

Förutsatt att antalet kunder per dag är $Po(\lambda)$ -fördelat bestäm ML-skattningen för λ med hjälp av datan. Med hjälp av din ML-skattning skatta sannolikheten att restaurangen har mer än 125 kunder på en given dag på sommaren.

6.6. [1] Betrakta stickprovet

3.62, 4.84, 5.35, 2.51, 2.73, 3.75, 3.56, 2.51, 4.39, 7.08

från Uppgift 6.1. Eftersom datan är årslöner för personer från ett visst samhälle (NYC) modellerar vi den med en $Pareto(c, \alpha)$ -fördelningen. Skatta ML-skattningen för $[c, \alpha]^T$ med hjälp av stickprovet. Jämför din ML-skattning med din momentmetods punktskattning från Uppgift 6.1.

6.7. [2] De oberoende stokastiska variablerna $X_1, \dots, X_n$ har den simultana fördelningen

$$P(X_i \leq x \mid \alpha, \beta) = \begin{cases} 0, & x < 0, \\ (x/\beta)^\alpha, & 0 \leq x \leq \beta \\ 1, & x > \beta, \end{cases}$$

där parametrarna α och β är positiva.

- (a) Bestäm en tvådimensionell tillräcklig statistika för $[\alpha, \beta]^T$.
- (b) Bestäm ML-skattningen för $[\alpha, \beta]^T$.
- (c) Längden (i millimeter) på ett gökäggs i häcksparvans bon kan modelleras med denna fördelning. Bestäm ML-skattningen för $[\alpha, \beta]^T$ med hjälp av datan

22.0, 23.9, 20.9, 23.8, 25.0, 24.0, 21.7, 23.8, 22.8, 23.1, 23.1, 23.5, 23.0, 23.0.

6.8. [2] Ikea tror att det genomsnittliga antalet köp i en av deras butik i Jönköping under en given dag ska vara proportionell mot det genomsnittliga antalet köp i deras butik i Stockholm (i Kungens kurva) under samma dag. Eftersom avståndet mellan de två städerna är stor antar Ikea att antalet köp i de två butikerna är oberoende. Ikea vill skatta det genomsnittliga antalet köp under en dag för båda butiker och väntevärdenas proportionalitetskonstant. Låt $X \sim Po(\lambda)$ beteckna antalet köp i Jönköpingsbutiken och $Y \sim Po(\beta\lambda)$ beteckna antalet köp i Stockholmsbutiken. Beräkna ML-skattningen för (β, λ) med hjälp av det bivariata stickprovet från $[X, Y]^T$:

$[2519, 7466]^T, [2511, 7377]^T, [2510, 7402]^T, [2474, 7556]^T, [2498, 7429]^T$.

6.9. [1] På en viss flygplats delar SAS och Norwegian en gate. Låt $S = X - (1/4)N$ beteckna tiden (i timmar) mellan ankomsterna för SAS-flygplan och $N = Y - (2/9)S$ beteckna tiden mellan ankomsterna för Norwegians flygplan där $X \sim \text{Exp}(\lambda)$, $Y \sim \text{Exp}(\nu)$ och $X \perp Y$. Vi modeller tiden mellan ankomster som sådan eftersom, exempelvis, om ett SAS-flygplan är på gaten kan det försena en ankomsten för Norwegians flygplan. Gaten betjänar 6 SAS- och 6 Norwegian-flyg per dag. Givet följande stickprov i formen $[S_i, N_i]^T$ för en slumpmässig dag

$[0.92, 0.68]^T, [0.86, 1.69]^T, [0.07, 5.92]^T, [0.44, 0.82]^T, [0.75, 1.26]^T$

bestäm ML-skattningen för $[\lambda, \nu]^T$.

6.10. [2] Låt $X_1, \dots, X_n$ vara ett stickprov från en fördelning med täthetsfunktion

$$f_X(x \mid \theta) = \frac{1}{\theta}, \quad 0 \leq x \leq \theta, \theta > 0.$$

Bestäm momentmetodens punktskattning och ML-skattningen för θ . Beräkna punktskattningarnas väntevärden och varianser. Vilken borde föredras och varför?

- 6.11.** [3] Låt $\mathbf{X} = [X_1, X_2, X_3]^T$ där X_i är en binär stokastisk variabel med möjliga utfall $\{0, 1\}$ för $i = 1, 2, 3$. Anta att den simultana sannolikhetsfunktionen $f_{\mathbf{X}}(x_1, x_2, x_3)$ är strikt positiv och uppfyller

$$f_{\mathbf{X}}(x_1, x_2, x_3) = f_{X_1}(x_1)f_{X_2|X_1}(x_2|x_1)f_{X_3|X_2}(x_3|x_2).$$

Anta vidare att vi ha stickprovet $\mathbf{X}_1 = [0, 0, 0]^T$, $\mathbf{X}_2 = [0, 1, 0]^T$, $\mathbf{X}_3 = [1, 1, 0]^T$, $\mathbf{X}_4 = [1, 1, 1]^T$.

- (a) Eftersom X_i bara har utfall i $\{0, 1\}$ för alla $i = 1, 2, 3$, och $f_{\mathbf{X}}(x_1, x_2, x_3)$ har den givna faktoriseringen kan vi parametrisera modellen med fem parametrar:

$$\begin{aligned} p_1 &= f_{X_1}(X_1 = 0) \\ p_{2, X_1=0} &= f_{X_2|X_1}(X_2 = 0|X_1 = 0) \\ p_{2, X_1=1} &= f_{X_2|X_1}(X_2 = 0|X_1 = 1) \\ p_{3, X_2=0} &= f_{X_3|X_2}(X_3 = 0|X_2 = 0) \\ p_{3, X_2=1} &= f_{X_3|X_2}(X_3 = 0|X_2 = 1). \end{aligned}$$

Visa att ML-skattningen för $\mathbf{p} = [p_1, p_{2, X_1=0}, p_{2, X_1=1}, p_{3, X_2=0}, p_{3, X_2=1}]^T$ inte existerar för givna datan.

- (b) Anta nu att vi observera ett femte (oberoende) utfall $\mathbf{X}_5 = [1, 0, 1]^T$. Existerar parametrarnas ML-skattning för datan $\mathbf{X}_1, \dots, \mathbf{X}_5$? Om svaret är ja, bestäm ML-skattningen.

- 6.12.** [2] Givet ett stickprov $X_1, \dots, X_n$ från en $\text{Exp}(\lambda)$ -population, visa att ML-skattningen $\hat{\lambda}$ är en punktskattning med systematiskt fel λ . Med avseende på detta systematiska fel, när är $\hat{\lambda}$ en bra punktskattning för λ ?

- 6.13.** [1] Anta att de stokastiska variablerna $Y_1, \dots, Y_n$ uppfyller

$$Y_i = \beta x_i + \epsilon_i, \quad i = 1, \dots, n,$$

där $x_1, \dots, x_n$ är konstanter och $\epsilon_1, \dots, \epsilon_n$ är oberoende och $N(0, \sigma^2)$ -fördelade för okänd σ^2 .

- (a) Visa att $\sum_{i=1}^n Y_i / \sum_{i=1}^n x_i$ är en väntevärdesriktig punktskattning för β .
 (b) Beräkna punktskattningens varians och jämför det mot ML-skattningens varians där ML-skattningen är

$$\frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2}.$$

- 6.14.** [1] Låt $X_1, \dots, X_n$ vara oberoende och $\text{Ber}(p)$ -fördelade. Visa att variansen för $\bar{X}$ uppnår den Cramér–Rao undre gränsen. Dra slutsatsen att $\bar{X}$ är den bästa väntevärdesriktiga punktskattningen för p .

- 6.15.** [1] Betrakta ett stickprov $X_1, \dots, X_n$ från var och en av följande fördelningar. Finns det en funktion $g(\theta)$ av θ för vilken det finns en väntevärdesriktig punktskattning vars varians uppnår den Cramér–Rao undre gränsen? Ge $g(\theta)$ och punktskattningen om svaret är ja. Motivera annars varför svaret är nej.

- (a) $f_X(x | \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \theta > 0$

Kapitel 7

7.1 A priori och a posteriori

Som vi diskuterade i början av Kapitel 1 finns det två huvudsakliga ramverk för att skatta parametrar inom statistiken: det frekventistiska (eller klassiska) och det bayesianska. Hittills har vi diskuterat den frekventistiska metoden, vilken låter oss skatta parametrar med hjälp av exempelvis momentmetoden och ML-metoden. Dessa punktskattningar kan sedan utvärderas genom att jämföra deras riskfunktioner för olika parametervärden.

Det som sammanbinder de frekventistiska metoderna är att parametern θ anses vara fixt, men okänd (inom en viss mängd). Med andra ord så antar vi att det finns en underliggande parameter som använts för att generera den data som observeras. Målet är då att försöka bestämma denna okända parameter så väl som möjligt.

Även om de frekventistiska metoderna fungerar bra i många sammanhang är de mindre användbara när vi anser att θ är ett utfall av en stokastisk variabel Θ med en viss fördelning. Detta kan ske i olika situationer, men det vanligaste är att vi vill kvantifiera information om vilka värden på parametern som är mer sannolika än andra. Denna information är relevant vid två tillfällen: innan vi observerar vår data (a priori) och efter vi observerar data (a posteriori).

Informationen a priori kan bestå av subjektiva uppfattningar om vilka värden vi tror parametern borde ta. Det kan också grunda sig i tidigare experiment som visat att parametern tar vissa värden oftare än andra. Med andra ord så behöver denna information nödvändigtvis vara subjektiv.

Informationen om parametern a posteriori kombinerar informationen som vi har innan observation (a priori) samt observationerna i sig. Detta sker med hjälp av Bayes sats.

7.1.1 Apriorifördelning och aposteriorifördelning

I detta kapitel antar vi att vi endast har en parameter att skatta, dvs. θ är en skalär. Senare kommer vi att generalisera detta till vektorvärda parametrar θ . Vi har som regel en parameter Θ med täthetsfunktion (eller sannolikhetsfunktion) givet av $f_{\Theta}(\theta)$. Denna fördelning kallas för *apriorifördelningen*. Givet att Θ tar ett visst värde θ , dvs. att $\Theta = \theta$, så har vi en *datafördelning* som ges av täthetsfunktionen (eller sannolikhetsfunktionen) $f_{\mathbf{X}|\Theta}(\mathbf{x} | \theta)$. Dessa är de enda ingredienserna i en bayesiansk modell. Utifrån apriorifördelningen och datafördelningen kan vi använda observationer $\mathbf{x}$ för att dra olika slutsatser om parametern Θ . Här utmärker sig det bayesianska synsättet i och med att det egentligen bara finns *en* metod för att göra inferens, till skillnad från i det frekventistiska ramverket där olika val (momentmetoden, ML-metoden, osv.) ger olika resultat och vi inte alltid vet vilket som bäst speglar verkligheten. Denna entydighet kan vara en fördel, men i vissa fall också en nackdel då denna enda metod kan leda till svåra beräkningar.

Vi kommer att se att svårigheterna med beräkningarna ofta är kopplade till vårt val av modell; dvs. valet av apriorifördelning och datafördelning. I likhet med det frekventistiska ramverket där man kan välja att använda en viss modell eller skattning för att underlätta beräkningen, visar det sig att vissa val för apriorifördelningen och datafördelningen har fördelen att göra beräkningar relativt hanterbara. När vi väljer en apriorifördelning för en modell försöker vi därför ofta hitta en balans mellan något som är relativt lätt att arbeta med och något som gör att vi kan bygga in våra subjektiva uppfattningar om parametrarna på ett lämpligt sätt. Vi kommer att undersöka flera metoder för att göra detta. I de situationer som vi betraktar i denna bok kommer beräkningarna därmed att visa sig vara hanterbara.

Metoden för inferens som vi syftar på här är att ta fram *aposteriorifördelningen*, dvs. den betingade fördelningen för Θ givet observationen $\mathbf{X} = \mathbf{x}$. Bayes regel säger att aposteriorifördelningens täthetsfunktion (eller sannolikhetsfunktion) ges av

$$f_{\Theta|\mathbf{X}}(\theta | \mathbf{x}) = \frac{f_{\mathbf{X}|\Theta}(\mathbf{x} | \theta)f_{\Theta}(\theta)}{f_{\mathbf{X}}(\mathbf{x})}.$$

Marginalfördelningen av $\mathbf{X}$ (som ges av $f_{\mathbf{X}}(\mathbf{x})$) kallas ibland för *aprioriprediktiva fördelningen* då den motsvarar hur vi förväntar oss att datan är fördelad innan vi observerar den. Den beräknas oftast genom lagen om total sannolikhet, vilket ger

$$f_{\mathbf{X}}(\mathbf{x}) = \int_{\Omega} f_{\mathbf{X}|\Theta}(\mathbf{x} | \theta) f_{\Theta}(\theta) d\theta$$

i det kontinuerliga fallet.

Vi upprepar först ett exempel som vi förmodligen redan har sett.

Exempel 7.1. Låt $X | \Theta = \theta \sim \text{Bin}(n, \theta)$ och $\Theta \sim \text{Beta}(\alpha_0, \beta_0)$. Då har vi

$$\begin{aligned} f_{X|\Theta}(x | \theta) f_{\Theta}(\theta) &= \binom{n}{x} \theta^x (1 - \theta)^{n-x} \left(\frac{\Gamma(\alpha_0 + \beta_0)}{\Gamma(\alpha_0) \Gamma(\beta_0)} \theta^{\alpha_0-1} (1 - \theta)^{\beta_0-1} \right) \\ &= \binom{n}{x} \frac{\Gamma(\alpha_0 + \beta_0)}{\Gamma(\alpha_0) \Gamma(\beta_0)} \theta^{\alpha_0+x-1} (1 - \theta)^{\beta_0+n-x-1}. \end{aligned}$$

Detta ger aprioriprediktiva fördelningen

$$\begin{aligned} f_X(x) &= \int_0^1 f_{X|\Theta}(x | \theta) f_{\Theta}(\theta) d\theta \\ &= \binom{n}{x} \frac{\Gamma(\alpha_0 + \beta_0)}{\Gamma(\alpha_0) \Gamma(\beta_0)} \int_0^1 \theta^{\alpha_0+x-1} (1 - \theta)^{\beta_0+n-x-1} d\theta \\ &= \binom{n}{x} \frac{\Gamma(\alpha_0 + \beta_0)}{\Gamma(\alpha_0) \Gamma(\beta_0)} \frac{\Gamma(\alpha_0 + x) \Gamma(\beta_0 + n - x)}{\Gamma(\alpha_0 + \beta_0 + n)} \int_0^1 \frac{\Gamma(\alpha_0 + \beta_0 + n)}{\Gamma(\alpha_0 + x) \Gamma(\beta_0 + n - x)} \theta^{\alpha_0+x-1} (1 - \theta)^{\beta_0+n-x-1} d\theta \\ &= \binom{n}{x} \frac{\Gamma(\alpha_0 + \beta_0)}{\Gamma(\alpha_0) \Gamma(\beta_0)} \frac{\Gamma(\alpha_0 + x) \Gamma(\beta_0 + n - x)}{\Gamma(\alpha_0 + \beta_0 + n)} \cdot 1 \\ &= \binom{n}{x} \frac{\Gamma(\alpha_0 + \beta_0) \Gamma(\alpha_0 + x) \Gamma(\beta_0 + n - x)}{\Gamma(\alpha_0) \Gamma(\beta_0) \Gamma(\alpha_0 + \beta_0 + n)}, \end{aligned}$$

där vi har använt faktumet att täthetsfunktionen hos en $\text{Beta}(\alpha_0 + x, \beta_0 + n - x)$ integrerar till ett. Denna fördelning kallas för *beta-binomialfördelningen* med parametrar n, α_0, β_0 .

Vi bildar nu aposteriorifördelningen

$$\begin{aligned} f_{\Theta|X}(\theta | x) &= \frac{f_{X|\Theta}(x | \theta) f_{\Theta}(\theta)}{f_X(x)} \\ &= \frac{\Gamma(\alpha_0 + \beta_0 + n)}{\Gamma(\alpha_0 + x) \Gamma(\beta_0 + n - x)} \theta^{\alpha_0+x-1} (1 - \theta)^{\beta_0+n-x-1}. \end{aligned}$$

Med andra ord har vi $\Theta | X = x \sim \text{Beta}(\alpha_1, \beta_1)$ där $\alpha_1 = \alpha_0 + x$ och $\beta_1 = \beta_0 + n - x$.

Låt oss nu relatera exemplet ovan till idén om en grafisk modell som utvecklades i Kapitel 4. Observera först att den bayesianska modellen i exemplet också kan tolkas som en hierarkisk modell:

$$\begin{aligned} X | \Theta = \theta &\sim \text{Bin}(n, \theta), \\ \Theta &\sim \text{Beta}(\alpha, \beta). \end{aligned}$$

Vi såg i Kapitel 4 att den simultana fördelningen $[X, \Theta]^T$ därför är markovsk med avseende på den acykliska riktade grafen $\mathcal{G}$:

$$\Theta \longrightarrow X$$

eftersom vi kan skriva täthetsfunktionen som $f_{X,\Theta}(x, \theta) = f_{X|\Theta}(x | \theta) f_{\Theta}(\theta)$.

Grafen $\mathcal{G}$ och motsvarande faktorisering av $f_{X,\Theta}(x, \theta)$ kan tolkas som "Givet information om Θ kan vi säga något om X ." I statistisk inferens börjar vi dock med data $X = x$ och skulle vilja säga något om Θ . För att svara på denna fråga i det bayesianska ramverket, beräknar vi aposteriorifördelningen $f_{\Theta|X}(\theta | x)$ som kan tolkas som en beräkning baklänges längs kanten i grafen. En viktig tillämpning för grafiska modeller är att representera bayesianska modeller med variabler $X_1, \dots, X_n$ som vi kan observera samt flera ytterligare variabler $\Theta_1, \dots, \Theta_k$ som representerar modellens parametrar. Grafen ger då insikter om aposteriorifördelningen $\Theta | \mathbf{X} = \mathbf{x}$ där $\Theta = [\Theta_1, \dots, \Theta_k]^T$ och

$\mathbf{X} = [X_1, \dots, X_n]^T$. Till exempel kan d-separationsreglen hjälpa oss att bestämma vilka parametrar som ska vara oberoende i aposteriorifördelningen. Denna kunskap kan vara användbar eftersom detta innebär att vi kan beräkna aposteriorifördelningen för Θ som en produkt av enklare aposteriorifördelningar. På grund av detta kallas ibland en grafiska modell för ett *bayesianskt nätverk*. I detta lilla exempel behöver vi inte grafen på detta sätt eftersom vi enkelt kan beräkna aposteriorifördelningen. Vi kommer dock att se i Kapitel 8 att det finns bayesianska modeller med flera parametrar där grafen kan vara till hjälp.

Typen av beräkning i Exempel 7.1 kan tillämpas på andra fördelningar.

Exempel 7.2. Låt $X \mid \Theta = \theta \sim \text{Po}(\theta)$ och $\Theta \sim \text{Gamma}(\alpha_0, \lambda_0)$. Då har vi

$$\begin{aligned} f_{X|\Theta}(x \mid \theta) f_{\Theta}(\theta) &= \frac{\lambda_0^{\alpha_0}}{\Gamma(\alpha_0)} \theta^{\alpha_0-1} e^{-\lambda_0 \theta} \frac{\theta^x}{x!} e^{-\theta} \\ &= \frac{\lambda_0^{\alpha_0}}{x! \Gamma(\alpha_0)} \theta^{\alpha_0+x-1} e^{-(\lambda_0+1)\theta}, \end{aligned}$$

samt

$$\begin{aligned} f_X(x) &= \int_0^{+\infty} f_{X|\Theta}(x \mid \theta) f_{\Theta}(\theta) d\theta \\ &= \frac{\lambda_0^{\alpha_0}}{x! \Gamma(\alpha_0)} \int_0^{+\infty} \theta^{\alpha_0+x-1} e^{-(\lambda_0+1)\theta} d\theta \\ &= \frac{\lambda_0^{\alpha_0}}{x! \Gamma(\alpha_0)} \frac{\Gamma(\alpha_0+x)}{(\lambda_0+1)^{\alpha_0+x}} \int_0^{+\infty} \frac{(\lambda_0+1)^{\alpha_0+x}}{\Gamma(\alpha_0+x)} \theta^{\alpha_0+x-1} e^{-(\lambda_0+1)\theta} d\theta \\ &= \frac{\lambda_0^{\alpha_0}}{x! \Gamma(\alpha_0)} \frac{\Gamma(\alpha_0+x)}{(\lambda_0+1)^{\alpha_0+x}} \cdot 1 \\ &= \frac{\Gamma(\alpha_0+x)}{x! \Gamma(\alpha_0)} \lambda_0^{\alpha_0} (\lambda_0+1)^{-\alpha_0-x}, \end{aligned}$$

där vi har använt att täthetsfunktionen hos en $\text{Gamma}(\alpha_0+x, \lambda_0+1)$ -fördelning integrerar till ett.

Vi får då aposteriorifördelningen

$$\begin{aligned} f_{\Theta|X}(\theta \mid x) &= \frac{f_{X|\Theta}(x \mid \theta) f_{\Theta}(\theta)}{f_X(x)} \\ &= \frac{\frac{\lambda_0^{\alpha_0}}{x! \Gamma(\alpha_0)} \theta^{\alpha_0+x-1} e^{-(\lambda_0+1)\theta}}{\frac{\Gamma(\alpha_0+x)}{x! \Gamma(\alpha_0)} \lambda_0^{\alpha_0} (\lambda_0+1)^{-\alpha_0-x}} \\ &= \frac{(\lambda_0+1)^{\alpha_0+x}}{\Gamma(\alpha_0+x)} \theta^{\alpha_0+x-1} e^{-(\lambda_0+1)\theta}, \end{aligned}$$

dvs. att $\Theta \mid X = x \sim \text{Gamma}(\alpha_1, \lambda_1)$ där $\alpha_1 = \alpha_0 + x$ och $\lambda_1 = \lambda_0 + 1$.

Det finns ett mycket användbart trick för att ta fram aposteriorifördelningar som baserar sig på att alla täthetsfunktioner integrerar till ett (och att alla sannolikhetsfunktioner summerar till ett). Detta betyder att alla täthetsfunktioner och sannolikhetsfunktioner endast behöver bestämmas upp till en konstant faktor (dvs. faktorer som inte beror på utfallsvariabeln). Denna konstant kan sedan bestämmas med hjälp av integration (eller summering). I princip kan vi nästan alltid hoppa över detta steg genom att identifiera vilken fördelning det gäller och sätta in rätt konstant. Vi arbetar alltså i praktiken med *onormaliserade täthetsfunktioner* och *onormaliserade sannolikhetsfunktioner*.

Detta trick kan användas i olika sammanhang men är extra användbart när man beräknar aposteriorifördelningar på grund av följande observation: i aposteriorifördelningen kan den aprioriprediktiva fördelningen $f_{\mathbf{X}}(\mathbf{x})$ betraktas som konstant (då denna inte beror på θ). Vi har alltså

$$f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) \propto f_{\mathbf{X}|\Theta}(\mathbf{x} \mid \theta) f_{\Theta}(\theta).$$

För att hitta aposteriorifördelningen behöver vi därför bara multiplicera apriorifördelningen med datafördelningen och sedan hitta den fördelning som överensstämmer med denna form upp till en konstant. (Vi kommer se senare i boken att denna formulering också är användbar även då vi inte kan identifiera en känd fördelning då den onormaliserade formen kan användas för att simulera från aposteriorifördelningen.) Vi slipper därmed beräkna den aprioriprediktiva fördelningen för att ta fram aposteriorifördelningen, vilket förenklar processen avsevärt. Utöver detta kan vi också ta bort och lägga till konstanta faktorer (konstanter med avseende på θ) vid behov.

Exempel 7.3. I binomialfallet ovan (Exempel 7.1) har vi då

$$\begin{aligned} f_{\Theta|X}(\theta | x) &\propto \binom{n}{x} \theta^x (1-\theta)^{n-x} \cdot \frac{\Gamma(\alpha_0 + \beta_0)}{\Gamma(\alpha_0)\Gamma(\beta_0)} \theta^{\alpha_0-1} (1-\theta)^{\beta_0-1} \\ &\propto \theta^{\alpha_0+x-1} (1-\theta)^{\beta_0+n-x-1}, \end{aligned}$$

där vi har tagit bort alla faktorer som inte beror på θ . Från denna onormaliserade täthetsfunktion ser vi att $\Theta | X = x$ måste vara fördelad enligt $\text{Beta}(\alpha_0 + x, \beta_0 + n - x)$.

För poissonfördelningen (Exempel 7.2) har vi, på samma sätt,

$$\begin{aligned} f_{\Theta|X}(\theta | x) &\propto \frac{\theta^x}{x!} e^{-\theta} \cdot \frac{\lambda_0^{\alpha_0}}{\Gamma(\alpha_0)} \theta^{\alpha_0-1} e^{-\lambda_0 \theta} \\ &\propto \theta^{\alpha_0+x} e^{-(\lambda_0+1)\theta}, \end{aligned}$$

dvs. att $\Theta | X = x \sim \text{Gamma}(\alpha_1, \lambda_1)$ med $\alpha_1 = \alpha_0 + x$, $\lambda_1 = \lambda_0 + 1$ som vi såg tidigare.

Detta trick kan avsevärt förenkla beräkningarna när integralerna för den aprioriprediktiva fördelningen blir komplicerade, som i fallet med normalfördelad data (se övning 7).

7.1.2 Flera observationer

När man går från en apriorifördelning till en aposteriorifördelning brukar man säga att man *uppdaterar* fördelningen för parametern med avseende på vissa data. Ibland kallas man detta för en *bayesiansk uppdatering*. Idén här är att vi har någon uppfattning om hur en viss parameter beter sig (dess apriorifördelning) och att vi uppdaterar denna uppfattning (för att få dess aposteriorifördelning) när vi observerar vissa data.

En konsekvens av detta är att aposteriorifördelningarna ovan enkelt generaliseras till flera datapunkter i ett stickprov. Om vi har $X_1, \dots, X_n$ stokastiska variabler, betingat oberoende givet $\Theta = \theta$, har vi enligt kedjeregeln

$$\begin{aligned} f_{X_1, \dots, X_n | \Theta}(x_1, \dots, x_n | \theta) &= f_{X_n | X_1, \dots, X_{n-1}, \Theta}(x_n | x_1, \dots, x_{n-1}, \theta) f_{X_1, \dots, X_{n-1} | \Theta}(x_1, \dots, x_{n-1} | \theta) \\ &= f_{X_n | \Theta}(x_n | \theta) f_{X_1, \dots, X_{n-1} | \Theta}(x_1, \dots, x_{n-1} | \theta), \end{aligned}$$

där vi i andra raden utnyttjat att $X_n \perp\!\!\!\perp X_1, \dots, X_{n-1} | \Theta$ och tillämpat Sats 3.2. Med tanke på att

$$f_{\Theta | X_1, \dots, X_n}(\theta | x_1, \dots, x_n) \propto f_{X_1, \dots, X_n | \Theta}(x_1, \dots, x_n | \theta) f_{\Theta}(\theta)$$

har vi då

$$\begin{aligned} f_{\Theta | X_1, \dots, X_n}(\theta | x_1, \dots, x_n) &\propto f_{X_n | \Theta}(x_n | \theta) f_{X_1, \dots, X_{n-1} | \Theta}(x_1, \dots, x_{n-1} | \theta) f_{\Theta}(\theta) \\ &\propto f_{X_n | \Theta}(x_n | \theta) f_{\Theta | X_1, \dots, X_{n-1}}(\theta | x_1, \dots, x_{n-1}). \end{aligned}$$

Med andra ord kan vi uppdatera fördelningen för Θ först med avseende på $X_1 = x_1, \dots, X_{n-1} = x_{n-1}$ och sedan ta detta som apriorifördelning och uppdatera med avseende på $X_n = x_n$. Induktion ger att detta kan delas upp i n stycken separata uppdateringar, en för varje $X_i = x_i$. Notera att ordningen inte spelar någon roll här – det viktiga är att vi uppdaterar med avseende på olika stokastiska variabler som alla är betingat oberoende givet parametern.


Exempel 7.4. Vi vill bygga en modell som hjälper oss att förutse om en ny film regisserad av Quentin Tarantino kommer att nomineras till en Oscar. Vi definierar en binär stokastisk variabel X där $X = 0$ om filmen inte nomineras och $X = 1$ om den nomineras. Hittills har Quentin Tarantino regisserat elva filmer (som vi antar är oberoende) och därför har vi elva slumpmässiga och oberoende utfall

$$x_1 = 0, \quad x_2 = 0, \quad x_3 = 1, \quad x_4 = 0, \quad x_5 = 0, \quad x_6 = 0, \quad x_7 = 0, \quad x_8 = 1, \quad x_9 = 1, \quad x_{10} = 0, \quad x_{11} = 1.$$

Eftersom X är en naturlig kandidat för att vara bernoullifördelad kan vi modellera detta som

$$\begin{aligned} X | \Theta = \theta &\sim \text{Ber}(\theta), \\ \Theta &\sim \text{Beta}(\alpha, \beta). \end{aligned}$$

Vi har inte riktigt en bra uppfattning om egenskaperna hos en regissör som tenderar att leda till Oscarnomineringar, så vi börjar med en apriorifördelning som ger Quentin en 50:50 chans i förväntan. Vi tar därför $\alpha = \beta = 2$. Om vi uppdaterar apriorifördelningen elva gånger (en gång för varje ytterligande datapunkt där vi använder den föregående aposteriorifördelningen som en ny apriorifördelning) ser vi hur aposteriorifördelningen uppdateras enligt den ytterligare datan:



I figuren ovan ritar vi apriorifördelningen i svart. Färgerna skiftar sedan från mörkrött till blått när vi ökar antalet observationer. I början (röd) har vi datan $x_1 = 0, x_2 = 0, x_3 = 1$ och vi ser att de två första apriorifördelningarna skiftar mot 0. Men när vi uppdaterar fördelningen med $x_3 = 1$ studsar fördelningen tillbaka lite mot 1. Sedan finns det en rad filmer som inte är nominerade (i gult och orange), vilket flyttar tillbaka fördelningen mot 0 samtidigt som variansen minskar. I de senaste fyra resultaten (i grönt och blått) fick filmerna flera nomineringar, vilket flyttar tillbaka fördelningen mot 1. Slutresultatet är

$$\Theta | \mathbf{X} = \mathbf{x} \sim \text{Beta}(6, 9)$$

vilket har väntevärde $E[\Theta | \mathbf{X} = \mathbf{x}] = 0.4$ och varians $\text{Var}[\Theta | \mathbf{X} = \mathbf{x}] = 0.015$. Vi lämnar det som en uppgift att beräkna aposteriorifördelningen $\Theta | \mathbf{X} = \mathbf{x}$ där $\mathbf{x} = [x_1, \dots, x_{11}]^T$ på en gång. Man kommer att se att uppdatering bara en gång med avseende på den hela datamängden ger samma slutresultat (fördelningen ritad i blått ovan).

Ett konkret exempel på hur en aposteriorifördelning ser ut när vi uppdaterar för flera utfall samtidigt ges i följande:

Exempel 7.5. Givet $X_1, \dots, X_n$ betingat oberoende givet Θ med $X_i | \Theta = \theta \sim \text{Po}(\theta)$ och $\Theta \sim \text{Gamma}(\alpha_0, \lambda_0)$ gör vi ansatsen

$$f_{\Theta | X_1, \dots, X_n}(\theta | x_1, \dots, x_n) \propto \theta^{\alpha_0 + \sum_{i=1}^n x_i - 1} e^{-(\lambda_0 + n)\theta}$$

utifrån det tidigare resultatet om poissonfördelade data. Med andra ord vill vi visa att

$$\Theta | X_1 = x_1, \dots, X_n = x_n \sim \text{Gamma}(\alpha_n, \lambda_n)$$

där $\alpha_n = \alpha_0 + \sum_{i=1}^n x_i$ och $\lambda_n = \lambda_0 + n$. Vi ser att för $n = 1$ återfår vi detta resultat och om det håller för $n - 1$ har vi

$$\begin{aligned} f_{\Theta | X_1, \dots, X_n}(\theta | x_1, \dots, x_n) &\propto f_{X_n | \Theta}(x_n | \theta) f_{\Theta | X_1, \dots, X_{n-1}}(\theta | x_1, \dots, x_{n-1}) \\ &\propto \theta^{x_n} e^{-\theta} \cdot \theta^{\alpha_0 + \sum_{i=1}^{n-1} x_i - 1} e^{-(\lambda_0 + (n-1))\theta} \\ &= \theta^{\alpha_0 + \sum_{i=1}^n x_i - 1} e^{-(\lambda_0 + n)\theta}, \end{aligned}$$

vilket visar att ansatsen håller genom induktion.

På liknande sätt kan vi ta fram aposteriorifördelningar för andra populära datafördelningar, som exponentielfördelad och normalfördelad data (se övning 7). Bland annat har vi att för $\mathbf{X} = [X_1, \dots, X_n]^T$ där alla element är betingat oberoende givet Θ och $X_i | \Theta = \theta \sim N(\theta, \sigma^2)$ för $i = 1, \dots, n$ med $\Theta \sim N(\mu_0, \tau_0^2)$ så har vi

$$\Theta | \mathbf{X} = \mathbf{x} \sim N(\mu_n, \tau_n^2)$$

där

$$\begin{aligned} \mu_n &= \left(\frac{\mu_0}{\tau_0^2} + \frac{\sum_{i=1}^n x_i}{\sigma^2} \right) / \left(\frac{1}{\tau_0^2} + \frac{n}{\sigma^2} \right) \\ \tau_n^2 &= \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}. \end{aligned}$$

Ett annat resultat är att för $\mathbf{X} = [X_1, \dots, X_n]^T$ med alla element betingat oberoende givet Θ och $X_i \mid \Theta = \theta \sim \text{Exp}(\theta)$ för $i = 1, \dots, n$ och $\Theta \sim \text{Gamma}(\alpha_0, \lambda_0)$ så har vi

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Gamma}(\alpha_n, \lambda_n)$$

där

$$\begin{aligned}\alpha_n &= \alpha_0 + n \\ \lambda_n &= \lambda_0 + \sum_{i=1}^n x_i.\end{aligned}$$

Nu när vi har ett par formler kan vi börja genomföra några beräkningar.

Exempel 7.6. På väg till jobbet behöver du korsa en hårt trafikerad cykelyg. Det finns ett övergångsställe, men cyklisterna verkar inte speciellt intresserade av att stanna, så du väntar på ett mellanrum så att du kan komma över. Under tiden räknar du antalet cyklister som passerar under varje 10-sekundersintervall:

Intervall (sek.)	0–10	10–20	20–30	30–40	40–50	50–60
Antal cyklister	4	4	1	3	2	6

Antag att antalet cyklister X_i under varje intervall har den betingade fördelningen

$$X_i \mid \Theta = \theta \sim \text{Po}(\theta)$$

där $X_1, X_2, \dots, X_6$ är betingat oberoende givet Θ . För att använda vår uppdateringsregel ovan antar vi att

$$\Theta \sim \text{Gamma}(\alpha, \lambda)$$

för några α, λ . Det vill säga att vi bestämmer oss för att använda den bayesianska modellen med datafördelningen $X \mid \Theta = \theta \sim \text{Po}(\theta)$ och apriorifördelningen $\Theta \sim \text{Gamma}(\alpha, \lambda)$. Observera att vi inte har valt apriorifördelningen med hjälp av subjektiva uppfattningar utan istället baserat på observationen att det är lätt att beräkna aposteriorifördelningen för denna modell (enligt vår uppdateringsregel ovan). Vi har dock inte specificerat den fullständiga apriorifördelningen ännu eftersom vi inte har valt värdena α och λ . I detta val har vi möjlighet att bygga in några av våra subjektiva uppfattningar.

Från formelsamlingen har vi att $E[\Theta] = \alpha/\lambda$ samt $\text{Var}[\Theta] = \alpha/\lambda^2$. Ett vettigt antagande kan vara att vi förväntar oss cirka en cykel per tio sekunder (dvs. sex stycken per minut) med en osäkerhet (standardavvikelse) på ± 1 cyklist. Vi har då $E[\Theta] = 1$ och $\text{Var}[\Theta] = 1^2 = 1$, vilket ger $\alpha = 1$, $\lambda = 1$.

Datan ovan ger $n = 6$ och $\sum_{i=1}^n x_i = 20$. Enligt vår uppdateringsformel har vi då att

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Gamma}(1 + 20, 1 + 6) = \text{Gamma}(21, 7).$$

Denna aposteriorifördelning har väntevärde

$$E[\Theta \mid \mathbf{X} = \mathbf{x}] = 21/7 = 3$$

och standardavvikelse

$$\text{Std}[\Theta \mid \mathbf{X} = \mathbf{x}] = \sqrt{21/7^2} = \sqrt{21}/7 \approx 0.655.$$

Vår parameter Θ är därför sannolikt mycket större än vi tidigare hade trott, närmare tre än ett.

Notera att ett annat val av apriorifördelning skulle ge ett annat svar här. Låt oss säga att vi fortfarande förväntar oss att Θ befinner sig runt ett, men att vi har mycket mindre osäkerhet, dvs. vi tror starkt på detta påstående (vi kanske går här varje dag och observerar sällan eller aldrig fler än en eller två cyklister per tio sekunder). Vi kanske har $\text{Std}[\Theta] = 1/4$, vilket ger $\text{Var}[\Theta] = 1/16$. Tillsammans med $E[\Theta] = 1$ får vi då $\alpha = 16$, $\lambda = 16$. I detta fall får vi aposteriorifördelningen

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Gamma}(16 + 20, 16 + 6) = \text{Gamma}(36, 22),$$

vilken är koncentrerad närmare ett än den tidigare aposteriorifördelningen. Vi har, till exempel

$$E[\Theta \mid \mathbf{X} = \mathbf{x}] = 36/22 = 18/11 \approx 1.636$$

och

$$\text{Std}[\Theta \mid \mathbf{X} = \mathbf{x}] = \sqrt{36/22^2} = 3/11 \approx 0.273.$$

I detta fall så är aposteriorifördelningen ganska starkt beroende på vilken apriorifördelning som väljs. Detta beror på att vi har relativt få datapunkter ($n = 6$), vilket gör att apriorifördelningen får större betydelse än vi annars skulle se.

7.1.3 Bayesianska punktskattningar

Även om det centrala objektet inom bayesiansk inferens är aposteriorifördelningen (eftersom denna innehåller *all* information om parametern som vi får från datan) är det ofta användbart att sammanfatta denna aposteriorifördelning på olika sätt. Till exempel kan vi, som ovan, använda väntevärdet och variansen (eller standardavvikelsen) hos aposteriorifördelningen för att bilda en uppfattning om hur parametern beter sig. Detta är så pass vanligt att vi benämner dessa som *aposterioriväntevärdet*, *aposteriorivariansen* och *aposterioristandardavvikelsen*. (Ibland kallas de också helt enkelt för det *betingade väntevärdet*, den *betingade variansen* och den *betingade standardavvikelsen*.) För apriorifördelningen har vi på samma sätt *aprioriväntevärdet*, *apriorivariansen* samt *aprioristandardavvikelsen*.

För binomialfördelad data $X \mid \Theta = \theta \sim \text{Bin}(n, \theta)$ där $\Theta \sim \text{Beta}(\alpha, \beta)$ har vi då

$$E[\Theta \mid X = x] = \frac{\alpha + x}{\alpha + \beta + n}$$

vilket kan jämföras med väntevärdet hos apriorifördelningen

$$E[\Theta] = \frac{\alpha}{\alpha + \beta}.$$

En annan skattning är ML-skattningen för θ (dvs. inom den frekventistiska ramverket), vilken ges av x/n . Intressant nog kan vi se aposterioriväntevärdet som en interpolation mellan aprioriväntevärdet $\alpha/(\alpha + \beta)$ och ML-skattningen x/n :

$$E[\Theta \mid X = x] = \frac{\alpha + \beta}{\alpha + \beta + n} \frac{\alpha}{\alpha + \beta} + \frac{n}{\alpha + \beta + n} \frac{x}{n}.$$

Ju mindre n är, desto närmare ett ligger $(\alpha + \beta)/(\alpha + \beta + n)$ och desto mer vikt lägger vi på aprioriväntevärdet $\alpha/(\alpha + \beta)$. Å andra sidan, för stora n så närmar vi oss istället ML-skattningen x/n . Den bayesianska metoden ger oss alltså ett sätt att (automatiskt) väga av inflytandet av tidigare information (dvs. a priori) och den observerade datan.

En användbar olikhet för aposteriorivariansen fås genom att betrakta lagen om total varians (Sats 3.6), som säger att

$$\text{Var}[\Theta] = E[\text{Var}[\Theta \mid \mathbf{X}]] + \text{Var}[E[\Theta \mid \mathbf{X}]].$$

Eftersom den andra termen är större än eller lika med noll får vi

$$E[\text{Var}[\Theta \mid \mathbf{X}]] \leq \text{Var}[\Theta].$$

Med andra ord så är aposteriorivariansen i genomsnitt mindre än apriorivariansen (där medelvärdet tagits över alla möjliga observationer $\mathbf{X}$). Ofta så håller också denna olikhet för enskilda observationer $\mathbf{X} = \mathbf{x}$. Detta är ganska naturligt, då tillförandet av information (dvs. observationen $\mathbf{X} = \mathbf{x}$) rimligtvis borde minska osäkerheten hos parametern Θ och därför ge oss en mindre varians. Notera att undantag finns till denna tumregel (se övning 7). Vi kan dock se denna minskning i varians i följande exempel.

Exempel 7.7. Betrakta längden (i cm) på 10 slumpmässiga svenska kvinnor:

167.3, 164.9, 168.4, 164.9, 168.6, 166.4, 167.4, 167.6, 167.9, 167.7.

Vi antar att längd är normalfördelad och har en standardavvikelse av 2 centimeter. För att uppdatera vår skattning för den förväntade längden kan vi bilda följande bayesianska modell:

$$\begin{aligned} X \mid \Theta = \theta &\sim N(\theta, 4), \\ \Theta &\sim N(\mu, \tau^2). \end{aligned}$$


Med hjälp av lagen om total förväntan har vi att

$$E[X] = E[E[X \mid \Theta]] = E[\Theta] = \mu.$$

Baserat på våra subjektiva uppfattningar tror vi att den genomsnittliga längden av en svensk kvinna är ungefär 167 centimeter. Därför är $\mu = 167$ ett vettigt antagande för aprioriväntevärdet. Vi tar också helt enkelt $\tau^2 = 1$. Enligt uppdateringsreglen för denna modell (se ovan) har vi då att

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim N(167.08, 0.53).$$

Vi ser då att variansen har minskat i aposteriorifördelning samt att vår gissning för den genomsnittliga längden stöds av datan:



Andra vanliga sätt att sammanfatta aposteriorifördelningen är att använda kvantiler, eller mer specifikt medianen av aposteriorifördelningen. Denna kallas helt enkelt för *aposteriorimedianen*. Ett annat alternativ är att beräkna typvärdet, dvs. det värde på θ som maximerar $f_{\Theta|\mathbf{X}}(\theta | \mathbf{x})$. Detta kallas för *maximum a posteriori* (MAP) för Θ givet $\mathbf{X} = \mathbf{x}$.

Vilken av dessa sammanfattningar som används beror på tillämpningen. Vi kommer att se i senare kapitel hur man kan använda beslutsteori för att bestämma vilken sammanfattning som passar bäst i en viss situation.

7.2 Aposterioriprediktiva fördelningen

En viktig aspekt av bayesiansk inferens är att den erbjuder ett naturligt ramverk för förutsägelse av nya datapunkter utifrån de observerade data, så kallad *prediktion*. Detta är också möjligt inom frekventistisk inferens, men där krävs att vi binder oss vid en specifik skattning av parametern θ för att generera nya datapunkter. Osäkerheten i själva skattningen av θ kan inte enkelt tas i beaktning.

Aposteriorifördelningen gör det däremot enkelt att beräkna fördelningen för nya (icke observerade) data genom att tillämpa kedjeregeln och marginalisera bort parametern Θ . Om våra nya datapunkter har datafördelning $f_{\mathbf{Y}|\Theta}(\mathbf{y} | \theta)$ där $\mathbf{Y} \perp \mathbf{X} | \Theta$ så får vi att $\mathbf{Y}$ givet $\mathbf{X}$ har fördelningen

$$\begin{aligned} f_{\mathbf{Y}|\mathbf{X}}(\mathbf{y} | \mathbf{x}) &= \int_{\Omega} f_{\mathbf{Y},\Theta|\mathbf{X}}(\mathbf{y}, \theta | \mathbf{x}) d\theta \\ &= \int_{\Omega} f_{\mathbf{Y}|\Theta,\mathbf{X}}(\mathbf{y} | \theta, \mathbf{x}) f_{\Theta|\mathbf{X}}(\theta | \mathbf{x}) d\theta \\ &= \int_{\Omega} f_{\mathbf{Y}|\Theta}(\mathbf{y} | \theta) f_{\Theta|\mathbf{X}}(\theta | \mathbf{x}) d\theta, \end{aligned}$$

där den sista likheten fås genom att tillämpa det betingade oberoendet mellan $\mathbf{X}$ och $\mathbf{Y}$ givet Θ (med hjälp av Sats 3.2).

Fördelningen för $\mathbf{Y}$ givet $\mathbf{X}$ kallas för den *aposterioriprediktiva fördelningen* av $\mathbf{Y}$ givet $\mathbf{X}$. Det är alltså den (prediktiva) fördelning som vi anser nya datapunkter borde ha givet en viss observation (dvs. a posteriori).

Exempel 7.8. Låt oss återgå till poissonfördelad data med gammafördelad parameter. Vi har alltså att $X_1, \dots, X_n$ är betingat oberoende givet $\Theta = \theta$ där $X_i | \Theta = \theta \sim \text{Po}(\theta)$ för $i = 1, \dots, n$ samt $\Theta \sim \text{Gamma}(\alpha_0, \lambda_0)$. Detta gav $\Theta | \mathbf{X} = \mathbf{x} \sim \text{Gamma}(\alpha_n, \lambda_n)$ där $\alpha_n = \alpha_0 + \sum_{i=1}^n x_i$ och $\lambda_n = \lambda_0 + n$.

Om vi nu har $Y \perp\!\!\!\perp \mathbf{X} \mid \Theta$ så att $Y \mid \Theta = \theta \sim \text{Po}(\theta)$ så får vi

$$\begin{aligned} f_{Y|\mathbf{X}}(y \mid \mathbf{x}) &= \int_0^{+\infty} f_{Y|\Theta}(y \mid \theta) f_{\Theta|\mathbf{X}}(\theta \mid \mathbf{x}) d\theta \\ &= \int_0^{+\infty} \frac{\theta^y}{y!} e^{-\theta} \cdot \frac{\lambda_n^{\alpha_n}}{\Gamma(\alpha_n)} \theta^{\alpha_n-1} e^{-\lambda_n \theta} d\theta \\ &= \frac{\lambda_n^{\alpha_n}}{\Gamma(\alpha_n)} \frac{1}{y!} \int_0^{+\infty} \theta^{\alpha_n+y-1} e^{-(\lambda_n+1)\theta} d\theta \\ &\propto \frac{1}{y!} \int_0^{+\infty} \theta^{\alpha_n+y-1} e^{-(\lambda_n+1)\theta} d\theta \\ &= \frac{1}{y!} \frac{\Gamma(\alpha_n + y)}{(\lambda_n + 1)^{\alpha_n+y}} \\ &\propto \frac{\Gamma(\alpha_n + y)}{y!} (\lambda_n + 1)^y \end{aligned}$$

där vi i sista likheten har använt att täthetsfunktionen för en gammalfördelning integrerar till ett. För att identifiera fördelningen antar vi att $\alpha_0 \in \mathbb{Z}_{>0}$, vilket ger att $\alpha_n + y \in \mathbb{Z}_{>0}$ och $\Gamma(\alpha_n + y) = (\alpha_n + y - 1)!$. Vi kan då introducera ett par konstanter (med avseende på y) och skriva

$$\begin{aligned} f_{Y|\mathbf{X}}(y \mid \mathbf{x}) &\propto \frac{(\alpha_n + y - 1)!}{y!} \left(\frac{1}{\lambda_n + 1} \right)^{\alpha_n+y} \\ &\propto \frac{(\alpha_n + y - 1)!}{(\alpha_n - 1)! y!} \left(\frac{\lambda_n}{\lambda_n + 1} \right)^{\alpha_n} \left(\frac{1}{\lambda_n + 1} \right)^y. \end{aligned}$$

Alltså har vi att Y givet $\mathbf{X}$ är negativt binomialfördelad, dvs. att $Y \mid \mathbf{X} = \mathbf{x} \sim \text{NegBin}\left(\alpha_n, \frac{\lambda_n}{\lambda_n + 1}\right)$.

En direkt tillämpning av den aposterioriprediktiva fördelningen är helt enkelt att göra en prediktion, dvs. att förutsäga att någonting kommer att hända med en viss sannolikhet som beror på den datan vi har observerat.

Exempel 7.9. Låt oss återgå till cykelvägsexemplet. Där hade vi $\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Gamma}(\alpha_n, \lambda_n)$ med $\alpha_n = 21$ och $\lambda_n = 7$ (för den första apriorifördelningen). Vad är nu sannolikheten att antalet cyklister under nästa 10-sekundersintervall är noll (och vi kan korsa cykelvägen säkert)? Enligt formeln ovan har vi att om $Y \mid \Theta = \theta \sim \text{Po}(\theta)$ och $Y \perp\!\!\!\perp \mathbf{X} \mid \Theta$ så har vi att

$$Y \mid \mathbf{X} = \mathbf{x} \sim \text{NegBin}\left(\alpha_n, \frac{\lambda_n}{\lambda_n + 1}\right) = \text{NegBin}(21, 7/8).$$

Den sökta sannolikheten är alltså

$$P(Y = 0 \mid \mathbf{X} = \mathbf{x}) = \binom{21-1}{0} (7/8)^{21} (1/8)^0 \approx 0.0606,$$

dvs. relativt liten (kanske är värt att ta en omväg).

En annan tillämpning är för att göra en rimlighetsbedömning av modellen. Vi kommer att gå in mer i detalj i detta under senare kapitel, men grundidén är att generera nya datapunkter $\mathbf{Y}$ enligt samma datafördelning som originaldatat. Om den denna aposteriorifördelning överensstämmer bra med de observerade datat kan vi konstatera att modellen är någorlunda korrekt.

Exempel 7.10. Vi repeterar dragning av sex stycken utfall från $\text{NegBin}(21, 7/8)$ och får

8	5	3	3	1	1
3	1	2	3	1	6
4	3	1	2	0	4
1	2	5	4	5	3
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Om vi jämför dessa med våra observerade data

4 4 1 3 2 6

så förefaller de inte vara särskilt avvikande (noll är relativt sällsynt, medan vi har få värden över fem). För att kvantifiera denna avvikelse behöver vi mer avancerade verktyg som kommer att introduceras i en senare kapitel.

Notera att den aposterioriprediktiva fördelningen inte nödvändigtvis behöver baseras på den ursprungliga datafördelningen. Ibland vill vi prediktera relaterade storheter som beror på samma parameter.

Exempel 7.11. I cykelvägsexemplet var vi intresserade av när antalet cyklister i ett 10-sekundersintervall är noll. Som vi såg är sannolikheten att detta inträffar för ett givet intervall ganska låg. En relaterad fråga är under hur många intervall vi måste vänta innan vi får noll cyklister per intervall. Om vi har $Y \mid \Theta = \theta \sim \text{Po}(\theta)$ är sannolikheten att ha noll cyklister lika med

$$P(Y = 0 \mid \Theta = \theta) = \frac{\theta^0}{0!} e^{-\theta} = e^{-\theta}.$$

Antalet intervall K vi måste vänta innan detta inträffar har då en geometrisk fördelning med parameter $e^{-\theta}$, dvs. vi har $K \mid \Theta = \theta \sim \text{Geom}(e^{-\theta})$. Detta ger i sin tur den aposterioriprediktiva fördelningen

$$\begin{aligned} f_{K \mid \mathbf{X}}(k \mid \mathbf{x}) &= \int_0^{+\infty} f_{K \mid \Theta}(k \mid \theta) f_{\Theta \mid \mathbf{X}}(\theta \mid \mathbf{x}) d\theta \\ &= \int_0^{+\infty} e^{-\theta} (1 - e^{-\theta})^k \cdot \frac{\theta^{\alpha_n}}{\Gamma(\alpha_n)} e^{-\lambda_n \theta} d\theta \\ &= \frac{1}{\Gamma(\alpha_n)} \int_0^{+\infty} (1 - e^{-\theta})^k \theta^{\alpha_n} e^{-(\lambda_n + 1)\theta} d\theta. \end{aligned}$$

Integralen ovan går att beräkna (binomialutveckling av $(1 - e^{-\theta})^k$, vilket ger en summa av gammaintegraler), men det kräver ganska mycket arbete.

Istället kan vi ta ett par genvägar. Den första är att använda lagen om total förväntan, vilket ger oss

$$\begin{aligned} E[K \mid \mathbf{X} = \mathbf{x}] &= E[E[K \mid \Theta, \mathbf{X} = \mathbf{x}] \mid \mathbf{X} = \mathbf{x}] \\ &= E[E[K \mid \Theta] \mid \mathbf{X} = \mathbf{x}] \\ &= E\left[\frac{1 - e^{-\Theta}}{e^{-\Theta}} \mid \mathbf{X} = \mathbf{x}\right] \\ &= E[e^{\Theta} - 1 \mid \mathbf{X} = \mathbf{x}] = E[e^{\Theta} \mid \mathbf{X} = \mathbf{x}] - 1, \end{aligned}$$

där vi bland annat har utnyttjat att $K \perp \mathbf{X} \mid \Theta$. Detta väntevärde kan beräknas genom en enkel gammaintegral


$$\begin{aligned} E[e^{\Theta} \mid \mathbf{X} = \mathbf{x}] &= \int_0^{+\infty} e^{\theta} f_{\Theta \mid \mathbf{X}}(\theta \mid \mathbf{x}) d\theta \\ &= \int_0^{+\infty} e^{\theta} \frac{\lambda_n^{\alpha_n}}{\Gamma(\alpha_n)} \theta^{\alpha_n - 1} e^{-\lambda_n \theta} d\theta \\ &= \int_0^{+\infty} \frac{\lambda_n^{\alpha_n}}{\Gamma(\alpha_n)} \theta^{\alpha_n - 1} e^{-(\lambda_n - 1)\theta} d\theta \\ &= \frac{\lambda_n^{\alpha_n}}{\Gamma(\alpha_n)} \frac{\Gamma(\alpha_n)}{(\lambda_n - 1)^{\alpha_n}} \\ &= \left(\frac{\lambda_n}{\lambda_n - 1}\right)^{\alpha_n} \end{aligned}$$

I vårt fall har vi alltså

$$E[K \mid \mathbf{X} = \mathbf{x}] = \left(\frac{7}{7-1}\right)^{21} - 1 = \left(\frac{7}{6}\right)^{21} - 1 \approx 24.5.$$

Vi måste alltså vänta i genomsnitt 24.5 intervall, dvs. runt 245 sekunder. Alltså är det definitivt värt att ta en annan väg (eller gå ut i cykelvägen och ta sina chanser).

Ett annat alternativ är att använda simulering för att numeriskt approximera den aposterioriprediktiva fördelningen och beräkna de sökta väntevärdena eller sannolikheterna empiriskt. Vi gör detta genom att generera ett stort antal utfall n_{samp} av $\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Gamma}(21, 7)$, vilket ger $\theta_1, \dots, \theta_{n_{\text{samp}}}$. Dessa kan sedan användas för att generera utfall av $K \mid \mathbf{X} = \mathbf{x}$ genom att för varje $i = 1, \dots, n_{\text{samp}}$ generera k_i utifrån fördelningen $\text{Geom}(\theta_i)$. Vi får då n_{samp} utfall av $K \mid \mathbf{X} = \mathbf{x}$ och kan plotta deras histogram (här har vi tagit $n_{\text{samp}} = 10000$):



Om vi beräknar det aritmetiska medelvärdet får vi 25.2, vilket ligger ganska nära väntevärdet vi fick ovan.

Histogrammet ovan vittnar dock om att det är ett fåtal större utfall av K som drar upp medelvärdet. Merparten av utfallen ser ut att ligga under 25. En viktig fördel med simuleringar är att vi kan enkelt skatta andra viktiga storheter, som till exempel aposteriorimedianen, genom att göra motsvarande beräkningar på de numeriska värden vi erhållit. Till exempel får vi att aposteriorimedianen är approximativt 13, vilket betyder att i hälften av fallen behöver vi bara vänta $13 \cdot 10 = 130$ sekunder, dvs. strax över två minuter.

Vi kan också approximera sannolikheter som $P(K \leq 6 \mid \mathbf{X} = \mathbf{x})$, dvs. sannolikheten att vi måste vänta högst en minut. Detta fås genom att räkna andelen av våra genererade utfall k som är mindre än eller lika med 6. För datat ovan får vi att denna sannolikhet är ungefär 0.29.

7.3 Konjugerade apriorifördelningar

Vi har nu sett flera exempel på bayesianska modeller. Vi byggde dessa modeller genom att ange en form på datafördelningen, en form på apriorifördelningen och parametrarnas värden i apriorifördelningen. Hur man väljer formen på datafördelningen känns kanske inte så mystiskt, då detta val i konstruktionen av modeller är bekant från våra erfarenheter i det frekventistiska ramverket. Å andra sidan är användningen av apriorifördelningen ny! Hur väljer man på ett smart sätt den här nya och obekanta delen av modellen? Som vi diskuterade i början av Kapitel 7 kan man specificera en apriorifördelningen utifrån två naturliga mål:

1. Formen på apriorifördelningen bör göra det någorlunda enkelt att beräkna aposteriorifördelningen.
2. Apriorifördelningen bör tillåta dig att representera subjektiva uppfattningar som du vill använda.

Observera att dessa mål inte är krav som måste uppfyllas utan fungerar mer som riktlinjer för att hjälpa oss att bygga rimliga modeller. (Vi kommer särskilt att diskutera senare vad du ska göra om du inte vill några subjektiva uppfattningar alls!) Vi har faktiskt använt dessa riktlinjer i våra exempel hittills.

I föregående kapitel repeterades ett mönster för de olika datafördelningarna vi studerade. För varje datafördelning valde vi en apriorifördelning för parametern Θ från en viss familj (betafördelningar, gammafördelningar, osv.) och det visade sig sedan att aposteriorifördelningen kom från samma familj. När detta händer säger vi att denna familj av apriorifördelningar är *konjugerad* med avseende på datafördelningens familj.

Vi har då sett följande exempel

- $\text{Bin}(n, \theta)$ har som konjugerade apriorifördelningar $\text{Beta}(\alpha, \beta)$,
- $\text{Po}(\theta)$ har som konjugerade apriorifördelningar $\text{Gamma}(\alpha, \lambda)$,
- $\text{Exp}(\theta)$ har som konjugerade apriorifördelningar $\text{Gamma}(\alpha, \lambda)$, och

- $N(\theta, \sigma^2)$ har som konjugerade apriorifördelningar $N(\mu, \tau^2)$.

Att använda konjugerade apriorifördelningar är ett sätt att uppnå vårt första mål ovan! Notera dock att enligt denna definition finns det en familj som är konjugerad med avseende på alla datafördelningar: familjen av alla fördelningar över parameterområdet Ω (eftersom aposteriorifördelningen nödvändigtvis ingår i denna familj). För att undvika detta används ofta begreppet *naturlig konjugerad apriorifördelning*. Med detta menas att täthetsfunktionen (eller sannolikhetsfunktionen) hos apriorifördelningen har samma funktionella form (dvs. samma uttryck i θ upp till en normaliseringskonstant) som täthetsfunktionen (eller sannolikhetsfunktionen) hos datafördelningen. Alla exempel vi gav ovan är naturliga konjugerade apriorifördelningar.

Exempel 7.12. Låt oss undersöka en annan datafördelning: $X \mid \Theta = \theta \sim N(\mu, \theta)$, dvs. normalfördelad data med känt väntevärde μ och där variansen θ är vår parameter. I detta fall har vi

$$f_{X|\Theta}(x \mid \theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-\frac{1}{2\theta}(x-\mu)^2}.$$

Om vi bortser från alla konstanter (dvs. faktorer som inte beror på θ) får vi

$$f_{X|\Theta}(x \mid \theta) = a\theta^{-b}e^{-c/\theta}.$$

När vi ser över de olika fördelningar vi har i formelsamlingen ser vi att detta överensstämmer med den inversa gammafördelningen som har täthetsfunktion

$$f_{\Theta}(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{-\alpha-1} e^{-\beta/\theta}.$$

Om vi nu sätter $\Theta \sim \text{InvGamma}(\alpha_0, \beta_0)$ så får vi aposteriorifördelningen

$$\begin{aligned} f_{\Theta|X}(\theta \mid x) &\propto \theta^{-1/2} e^{-\frac{1}{2\theta}(x-\mu)^2} \cdot \theta^{-\alpha_0-1} e^{-\beta_0/\theta} \\ &= \theta^{-(\alpha_0+\frac{1}{2})-1} e^{-(\beta_0+\frac{1}{2}(x-\mu)^2)/\theta}. \end{aligned}$$

Med andra ord har vi att $\Theta \mid X = x \sim \text{InvGamma}(\alpha_1, \beta_1)$ där $\alpha_1 = \alpha_0 + 1/2$ och $\beta_1 = \beta_0 + (x - \mu)^2/2$.

Detta resultat generaliseras till godtyckligt antal data $\mathbf{X} = [X_1, \dots, X_n]^T$ för betingat oberoende $X_1, \dots, X_n$ givet Θ där $X_i \mid \Theta = \theta \sim N(\mu, \theta)$ för $i = 1, \dots, n$ där $\Theta \sim \text{InvGamma}(\alpha_0, \beta_0)$. Vi får då att

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{InvGamma}(\alpha_n, \beta_n)$$

där

$$\begin{aligned} \alpha_n &= \alpha_0 + \frac{n}{2} \\ \beta_n &= \beta_0 + \frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2. \end{aligned}$$

Notera att naturliga konjugerade apriorifördelningar inte alltid finns. För de flesta datafördelningar som vi studerar i denna bok kommer de dock finnas.

Ett större problem med konjugerade apriorifördelningar är att de är relativt oflexibla. Låt oss säga att vi har binomialfördelad data, dvs. att $X \mid \Theta = \theta \sim \text{Bin}(n, \theta)$ och vi vet att θ antingen är runt 1/4 eller runt 3/4, men inte däremellan. Den konjugerade apriorifördelningen för binomialfördelad data är betafördelningen, men inget val av parametrar ger oss en fördelning som är stor runt 1/4 och 3/4, men liten för andra värden på θ . En sådan bimodal fördelning är nödvändigtvis okonjugerad. I detta fall kan vi beräkna aposteriorifördelningen, men den har inte samma enkla form som för en konjugerad apriorifördelning.

7.4 Icke-informativa apriorifördelningar

Valet av apriorifördelning kan vara svårt för vissa tillämpningar. Ofta har vi ingen bra idé av hur parametern borde vara fördelad. Till exempel kanske vi inte är säkra på att parametern inte är fördelad enligt en bimodal fördelning som diskuterats ovan. I sådana fall skulle vi föredra att inte arbeta med en konjugerad apriorifördelning (särskilt om det är en unimodal fördelning) även om vi inte har några bättre idéer. En lösning är då att använda

en apriorifördelning som innehåller så lite information som möjligt. Denna typ av apriorifördelningar kallas för *icke-informativa apriorifördelningar*.

Notera att även om målet med dessa apriorifördelningar är att påverka skattningen så lite som möjligt utgör valet av en icke-informativ apriorifördelning en viss påverkan i sig. Andra val, som hur datafördelningen är parametriserad, påverkar också aposteriorifördelningen. Exempelvis kan binomialfördelningen $\text{Bin}(n, p)$ parametriseras genom standardparametern p eller genom log-oddsen $\log(p/(1-p))$ (den naturliga parametern i exponentialfamiljen). En icke-informativ fördelning över en parametrisering kan ge olika resultat i en annan parametrisering.

Standardförfarandet för att ta fram icke-informativa apriorifördelningar är att studera aposteriorifördelningen för en konjugerad apriorifördelning och låta antalet observationer gå mot oändligheten för att se för vilka parametrar som datan dominerar aposteriorifördelningen. För binomialfördelad data har vi, till exempel att $X \mid \Theta = \theta \sim \text{Bin}(n, \theta)$ och $\Theta \sim \text{Beta}(\alpha, \beta)$ ger

$$\Theta \mid X = x \sim \text{Beta}(\alpha + x, \beta + n - x).$$

Om vi låter $x, n \rightarrow +\infty$ så får vi, approximativt, aposteriorifördelningen $\text{Beta}(x, n - x)$. Med andra ord motsvarar detta $\alpha = 0$ och $\beta = 0$ i apriorifördelningen. En rimlig icke-informativ apriorifördelning är då $\text{Beta}(0, 0)$.

Ett problem med denna fördelning är att den faktiskt inte är en fördelning. När vi tar $\alpha, \beta \rightarrow 0$ så divergerar täthetsfunktionen och approximerar en bernoullifördelning med parameter $1/2$, dvs. med sannolikhet $1/2$ på 0 och 1. Med andra ord har vi att

$$f_{\Theta}(\theta) \propto \theta^{-1}(1 - \theta)^{-1}$$

inte går att integrera och därför inte kan bilda en täthetsfunktion. En sådan "fördelning" kallas för en *oegentlig fördelning* och när den används som apriorifördelning kallas den för en *oegentlig apriorifördelning*.

Även om en apriorifördelning är oegentlig betyder det inte att den är oanvändbar. I fallet ovan med $\text{Beta}(0, 0)$ kan vi ta fram aposteriorifördelningen givet $X = x$ där $X \mid \Theta = \theta \sim \text{Bin}(n, \theta)$, vilken ges av

$$f_{\Theta \mid X}(\theta \mid x) \propto \theta^x (1 - \theta)^{n-x} \cdot \theta^{-1} (1 - \theta)^{-1} = \theta^{x-1} (1 - \theta)^{n-x-1},$$

dvs. $\Theta \mid X = x \sim \text{Beta}(x, n - x)$. Såvida vi inte har $x = 0$ eller $x = n$ så är aposteriorifördelningen alltså en egentlig fördelning. Många andra oegentliga apriorifördelningar har samma egenskap, dvs. att aposteriorifördelningen är en egentlig fördelning för de flesta datapunkter.

Apriorifördelningen $\text{Beta}(0, 0)$ kallas för *Haldanes apriorifördelning*. Andra alternativ är $\text{Beta}(1, 1)$, som ger samma sannolikhet åt alla värden på θ . Denna apriorifördelning är en egentlig fördelning och kallas för *Bayes* eller *Laplaces apriorifördelning*. Ett annat alternativ är *Jeffreys apriorifördelning* som ges av $\text{Beta}(1/2, 1/2)$ (också kallad för *arcus-sinusfördelningen*).

För normalfördelningen har vi att om $X_1, \dots, X_n$ är betingat oberoende givet $\Theta = \theta$ med $X_i \mid \Theta = \theta \sim N(\theta, \sigma^2)$ för $\Theta \sim N(\mu_0, \tau_0^2)$ så har vi sedan tidigare att

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim N(\mu_n, \tau_n^2)$$

där

$$\mu_n = \left(\frac{\mu_0}{\tau_0^2} + \frac{\sum_{i=1}^n x_i}{\sigma^2} \right) / \left(\frac{1}{\tau_0^2} + \frac{n}{\sigma^2} \right)$$

$$\tau_n^2 = \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}.$$

För n stort har vi att

$$\mu_n \approx \frac{\sum_{i=1}^n x_i}{n}$$

$$\tau_n^2 \approx \frac{\sigma^2}{n}.$$

Detta motsvarar att vi låter $\mu_0 \rightarrow 0$ och $\tau_0^2 \rightarrow +\infty$ i vår apriorifördelning. En rimlig icke-informativ "apriorifördelning" är då $N(0, +\infty)$, dvs. en konstant sannolikhet över hela $\mathbb{R}$:

$$f_{\Theta}(\theta) \propto 1.$$

Återigen är detta en oegentlig apriorifördelning, men den ger alltid en egentlig aposteriorifördelning när vi uppdaterar med data eftersom vi då får

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim N\left(\frac{1}{n} \sum_{i=1}^n x_i, \frac{1}{n} \sigma^2\right).$$

På samma sätt kan vi ta fram en icke-informativ apriorifördelning för normalfördelad data med känt väntevärde och okänd varians. Här har vi $X_1, \dots, X_n$ betingat oberoende givet $\Theta = \theta$ och $X_i | \Theta = \theta \sim N(\mu, \theta)$ för $i = 1, \dots, n$ och $\Theta \sim \text{InvGamma}(\alpha, \beta)$, vilket ger

$$\Theta | \mathbf{X} = \mathbf{x} \sim \text{InvGamma}\left(\alpha + \frac{n}{2}, \beta + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2}\right).$$

När n blir stort approximerar denna fördelning

$$\text{InvGamma}\left(\frac{n}{2}, \frac{\sum_{i=1}^n (x_i - \mu)^2}{2}\right),$$

vilket gör att en icke-informativ apriorifördelning skulle kunna vara $\text{InvGamma}(0, 0)$. Här har vi då

$$f_{\Theta}(\theta) \propto \frac{1}{\theta}$$

vilket ger en oegentlig fördelning, men denna ger också upphov till en egentlig aposteriorifördelning

$$\Theta | \mathbf{X} = \mathbf{x} \sim \text{InvGamma}\left(\frac{n}{2}, \frac{\sum_{i=1}^n (x_i - \mu)^2}{2}\right).$$

7.5 Uppgifter

7.1. [2] Låt $\Theta \sim \text{Gamma}(\alpha, \lambda)$ och $X | \Theta = \theta \sim \text{Exp}(\theta)$.

- Beräkna aposteriorifördelningen $\Theta | X = x$. Verifiera ditt resultat med hjälp av formelsamlingen.
- Låt $Y | \Theta = \theta \sim \text{Exp}(\theta)$ var betingat oberoende med avseende på X given Θ . Härled den aposterioriprediktiva fördelningen $Y | X = x$.
- Antag nu att du har en mängd observationer $\mathbf{X} = [X_1, \dots, X_n]^T$ som är betingat oberoende givet Θ och likafördelade enligt $X_i | \Theta = \theta \sim \text{Exp}(\theta)$ för $i = 1, \dots, n$. Generalisera resultaten ovan för observationen $\mathbf{X} = \mathbf{x} = [x_1, \dots, x_n]^T$.
- Givet observationerna

2.04 2.08 2.85 2.28 2.07 3.17 3.01

av X och apriorifördelningen $\Theta \sim \text{Gamma}(3, 4)$, vad är sannolikheten att nästa observation är större än 3?

7.2. [1] Antag att $X | \theta = \theta \sim \text{Exp}(2\theta)$ och $Y | \theta = \theta \sim \text{Exp}(3\theta)$ där $\Theta \sim \text{Gamma}(2, 2)$ samt $X \perp\!\!\!\perp Y | \Theta$. Vi observerar $X = 2.01$ och $Y = 3.82$.

- Beräkna aposterioriväntevärdet av Θ .
- Använd en datorsimulering av aposteriorifördelningen för att skatta aposterioriväntevärdet med aritmetiska medelvärden. Överensstämmer denna med svaret i del (a)?
- Använd simuleringen för att skatta sannolikheten att $\Theta > 0.3$.

7.3. [2] Antag att $X | \Theta = \theta \sim \text{Exp}(\theta)$ med $\Theta \sim \text{Gamma}(\alpha, \lambda)$.

- Beräkna aposteriorifördelningen för Θ givet $X \geq 20$ (med andra ord observerar vi inte X direkt, bara att X överstiger 20). Vad är aposterioriväntevärdet och variansen?
- Jämför detta med aposteriorifördelningen för Θ givet $X = 20$ (med andra ord att vi observerar X exakt). Hur påverkar detta aposterioriväntevärdet och variansen?
- Varför är aposteriorivariansen mindre för den mindre informativa observationen $X \geq 20$ jämfört med $X = 20$? Varför motsäger inte detta tumregeln att $\text{Var}[\Theta | X = x]$ bör vara mindre än $\text{Var}[\Theta]$?

7.4. [3] Låt $X | \Theta = \theta \sim N(\theta, \sigma^2)$ och $\Theta \sim N(\mu, \tau^2)$ för känd σ^2 .

- Beräkna aposteriorifördelningen för $\Theta | X = x$.

- (b) Generalisera resultatet till flera betingat oberoende utfall.
- (c) Beräkna den aposterioriprediktiva fördelningen. Med andra ord, låt $Y \mid \Theta = \theta \sim N(\theta, \sigma^2)$, $X \mid \Theta = \theta \sim N(\theta, \sigma^2)$ och $\Theta \sim N(\mu, \tau^2)$ för känd σ^2 , och härled fördelningen för $Y \mid X = x$.
- (d) Generalisera resultatet till ett godtyckligt antal utfall $\mathbf{X} = [X_1, \dots, X_n]^T$.

7.5. [1] Antag att du har gjort följande observationer för $X \mid \Theta = \theta \sim N(\theta, 1.6)$:

1.05 3.07 2.57 -1.79 -0.30.

Mätningarna är betingat oberoende givet Θ och $\Theta \sim N(0, 4^2)$.

- (a) Beräkna sannolikheten att nästa mätning överstiger noll.
- (b) Istället för att beräkna den aposterioriprediktiva fördelningen analytiskt kan vi simulera denna enligt följande recept. Vi börjar med $i = 1$ och genererar ett utfall θ_i från aposteriorifördelningen $\Theta \mid \mathbf{X} = \mathbf{x}$. Efter detta simulerar vi ett utfall y_i från $Y \mid \Theta = \theta_i \sim N(\theta_i, 1.6)$. Vi repeterar detta för ett tillräckligt stort antal i för att simulera utfall från den aposterioriprediktiva fördelningen. Verifiera att det erhållna histogrammet överensstämmer med den aposterioriprediktiva täthetsfunktionen och använd metoden för att skatta sannolikheten att Y överstiger noll.

7.6. [2] Låt $X \sim \text{Beta}(\alpha, \beta)$ och antag att $E[X] = \mu$ samt $\text{Std}[X] = \sigma$. Visa att följande formler gäller

$$\alpha = \left(\frac{\mu(1-\mu)}{\sigma^2} - 1 \right) \mu, \quad \beta = \left(\frac{\mu(1-\mu)}{\sigma^2} - 1 \right) (1-\mu).$$

7.7. [1] Denna vår bestämmer du dig för att plantera blommor i din rabatt. Dina fingrar är inte speciellt gröna, men du förväntar dig åtminstone att lyckas med sannolikhet 0.7 för varje sått frö. Du är inte helt säker på detta, däremot, och har en standardavvikelse på 0.1 för denna sannolikhet. Du bestämmer dig för att plantera tio frön med ordentligt avstånd mellan men till sommaren får du bara fyra blommor. Givet denna information, vad är din justerade sannolikhet?

- 7.8. [1] (a) Låt $X \mid \Theta = \theta \sim \text{Po}(\rho\theta)$ och $\Theta \sim \text{Gamma}(\alpha, \lambda)$ för något $\rho > 0$. Beräkna aposteriorifördelningen för Θ givet $X = x$.
- (b) Generalisera resultatet till en stokastisk vektor $\mathbf{X} = [X_1, \dots, X_n]^T$ av betingat oberoende $X_i \mid \Theta = \theta \sim \text{Po}(\rho_i\theta)$ för $i = 1, \dots, n$ och $\rho_1, \dots, \rho_n > 0$ där $\Theta \sim \text{Gamma}(\alpha, \lambda)$. Beräkna aposteriorifördelningen för $\Theta \mid \mathbf{X} = \mathbf{x}$.
- (c) Antag att $n = 8$, $\alpha = 2$ och $\lambda = 3$. Vi har observationerna

ρ_i	1	1	3	3	4	2	8	1
X_i	7	8	21	15	40	28	50	10

Beräkna aposterioriväntevärdet för Θ .

- (d) Beräkna sannolikheten att $Y = 0$ givet $Y \mid \Theta = \theta \sim \text{Po}(\theta)$ där $Y \perp\!\!\!\perp X_1, \dots, X_n \mid \Theta$.

7.9. [1] Låt $X \mid \Theta = \theta \sim \text{Po}(\theta)$ där $\Theta \sim \text{Gamma}(2, 3)$. Antag att följande observationer gjorts

4 3 6 6 1 1 5 1.

- (a) Beräkna aposterioriväntevärdet för Θ .
- (b) Beräkna sannolikheten att nästa observation är noll.

- 7.10. [2] (a) Låt $\mathbf{X} = [X_1, \dots, X_n]^T$ vara en stokastisk vektor av oberoende och likafördelade stokastiska variabler med fördelning $\text{Exp}(\theta)$. Visa att $Y = \sum_{i=1}^n X_i \sim \text{Gamma}(n, \theta)$.
- (b) Låt $Y \mid \Theta = \theta \sim \text{Gamma}(\beta, \theta)$ och $\Theta \sim \text{Gamma}(\alpha, \lambda)$. Härled aposteriorifördelningen för $\Theta \mid Y = y$.
- (c) Antag nu att $X_1, \dots, X_n$ är betingat oberoende givet Θ och att $X_i \mid \Theta = \theta \sim \text{Exp}(\theta)$ för $i = 1, \dots, n$ där $\Theta \sim \text{Gamma}(\alpha, \lambda)$. Jämför aposteriorifördelningen för $\Theta \mid \mathbf{X} = \mathbf{x}$ med den för $\Theta \mid Y = y$ där $\mathbf{x} = [x_1, \dots, x_n]^T$ och $y = \sum_{i=1}^n x_i$.

7.11. [3] Fördelningsfunktionen för betafördelningen ges av

$$I_x(\alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \int_0^x u^{\alpha-1}(1-u)^{\beta-1} du.$$

Denna funktion kallas för den *regulariserade ofullständiga betafunktionen* och har en rad användbara egenskaper.

(a) Visa att $I_x(\alpha, 1) = x^\alpha$ för $\alpha \geq 1$.

(b) Visa att

$$I_x(\alpha, \beta) = I_x(\alpha + 1, \beta - 1) + \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{x^\alpha(1-x)^{\beta-1}}{\alpha}$$

för $\alpha, \beta \geq 1$.

(c) Visa att följande formel gäller

$$I_x(m, n) = \sum_{k=m}^{m+n-1} \binom{m+n-1}{k} x^k (1-x)^{n+m-1-k}.$$

för alla positiva heltal m och n .

(d) Visa den alternativa formeln

$$I_x(m, n) = 1 - \sum_{k=0}^{m-1} \binom{m+n-1}{k} x^k (1-x)^{n+m-1-k}.$$

(e) Verifiera formlerna ovan numeriskt genom att generera utfall från en betafördelning (med hjälp av `scipy.stats.beta`) och beräkna proportionen av utfall som är mindre än ett visst värde x .

7.12. [1] Låt $\mathbf{X} = [X_1, \dots, X_n]^T$ vara en vektor av betingat oberoende stokastiska variabler så att $X_i \mid \Theta = \theta \sim \text{Ber}(\theta)$ där $\Theta \sim \text{Beta}(1, 1)$. Antag att följande observationer har gjorts

$$0 \quad 1 \quad 0 \quad 0.$$

(a) Beräkna aposterioriväntevärdet $E[\Theta \mid \mathbf{X} = \mathbf{x}]$.

(b) Beräkna aposteriorisannolikheten $P(\Theta < 0.25 \mid \mathbf{X} = \mathbf{x})$.

7.13. [2] Ute på promenad ser du en spårvagn med numret "56". Du vill använda denna information för att skatta det totala antalet spårvagnar N i staden.

(a) Givet apriorifördelningen $N \sim \text{Geom}(0.01)$, beräkna aposteriorifördelningen givet din observation och beräkna aposterioriväntevärdet.

(b) Beräkna aposterioristandardavvikelsen.

(c) Vad är några utmaningar med att använda en icke-informativ apriorifördelning för N ?

7.14. [1] Låt $X \mid \Theta = \theta \sim N(\theta, 2.1)$. Använd en icke-informativ apriorifördelning för Θ och beräkna aposterioriväntevärdet för följande data:

$$0.46 \quad 2.76 \quad -1.16 \quad -3.10 \quad 6.78 \quad 3.04 \quad -0.97 \quad 1.70.$$

7.15. [1] Antag att följande data erhålls från data som är oberoende och $N(0, \theta)$ -fördelade givet $\Theta = \theta$ där $\Theta \sim \text{InvGamma}(2, 1)$:

$$-0.45 \quad -3.92 \quad -5.85 \quad 2.83 \quad 0.38.$$

Bestäm aposterioriväntevärdet och aposterioristandardavvikelsen för Θ .

7.16. [2] Identifiera den naturligt konjugerade apriorifördelningen och aposteriorifördelningen för följande datafördelningar

(a) $X \mid \Theta = \theta \sim \text{Geom}(\theta)$,

- (b) $X \mid \Theta = \theta \sim \text{NegBin}(r, \theta)$ (r känd), och
- (c) $X \mid \Theta = \theta \sim \text{U}(0, \theta)$.

7.17. [2] För var och en av datafördelningarna i föregående uppgift, beräkna aposterioriprediktiva fördelningen givet en konjugat apriorifördelning.

Kapitel 8

8.1 Flerdimensionella parametrar

Hittills har vi arbetat med en enda parameter för vilken vi har tagit fram en aposteriorifördelning. Som vi har sett tidigare är det dock ofta relevant att modellera data med hjälp av flera parametrar. Inom bayesiansk inferens innebär detta helt enkelt att vi har en flerdimensionell apriorifördelning $f_{\Theta}(\theta)$ över $\Omega \subset \mathbb{R}^d$ och en datafördelning $f_{X|\Theta}(x | \theta)$ som ger oss en aposteriorifördelning $f_{\Theta|X}(\theta | x)$ från vilken vi kan dra olika slutsatser om våra data. Alla resultat som vi tidigare visat för endimensionella parametrar Θ kan enkelt generaliseras för flerdimensionella parametrar Θ .

En styrka med det bayesianska synsättet är när vi väl har aposteriorifördelningen kan vi manipulera denna för att extrahera den information som är relevant för oss. Till exempel, vi kanske har två parametrar Θ_1 och Θ_2 i vår modell, men endast Θ_1 är av intresse för vår tillämpning. Parametern Θ_2 kallas då för en *störparameter*. I detta fall marginaliserar vi helt enkelt med avseende på Θ_2 för att erhålla den marginella aposteriorifördelningen för Θ_1 givet datat. På samma sätt kan vi också bilda betingade fördelningar för att studera hur vissa parametrar beror på andra.

8.1.1 Multinomialfördelad data

Som vi har sett innan är en multinomialfördelningen en användbar diskret flerdimensionell fördelning som används för att beskriva antalet gånger en viss händelse inträffar. Parametrarna är det totala antalet försök m samt sannolikheterna för de olika händelserna. Låt oss anta att vi har

$$X | \Theta = \theta \sim \text{Multi}(m, \theta)$$

där $\theta \in \mathbb{R}^d$ så att $\theta_1 + \dots + \theta_d = 1$. Vi har då

$$f_{X|\Theta}(x | \theta) = \frac{m!}{x_1! \dots x_d!} \theta_1^{x_1} \dots \theta_d^{x_d}.$$

Om vi söker en naturligt konjugerad apriorifördelning borde den vara på formen

$$f_{\Theta}(\theta) \propto \theta_1^{\alpha_1} \dots \theta_d^{\alpha_d}$$

för $\theta_1 + \dots + \theta_d = 1$ och $0 \leq \theta_1, \dots, \theta_d \leq 1$. En naturlig kandidat är då dirichletfördelningen, vars täthetsfunktion ges av

$$f_{\Theta}(\theta) = \frac{\Gamma(\alpha_1 + \dots + \alpha_d)}{\Gamma(\alpha_1) \dots \Gamma(\alpha_d)} \theta_1^{\alpha_1-1} \dots \theta_d^{\alpha_d-1}$$

för $\theta_1 + \dots + \theta_d = 1$ och $0 \leq \theta_1, \dots, \theta_d \leq 1$. Detta skrivs som $\Theta \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_d) = \text{Dirichlet}(\alpha)$. Aposteriorifördelningen ges då av

$$\Theta | X = x \sim \text{Dirichlet}(\alpha + x).$$

Två rimliga icke-informativa apriorifördelningar är $\text{Dirichlet}(0, \dots, 0)$ (en oegentlig apriorifördelning) och $\text{Dirichlet}(1, \dots, 1)$ (den likformiga fördelningen). I båda fall kan vi använda uppdateringsregeln ovan. Observera dock att aposteriorifördelningen för $\text{Dirichlet}(0, \dots, 0)$ endast är en egentlig fördelning om $x_1, \dots, x_d > 0$.

Exempel 8.1. En opinionsundersökning gjordes under oktober 1988 av den amerikanska TV-kanalen CBS. Svars-personerna tillfrågades om vilken presidentkandidat de tänkte rösta på i höstens val: George H.W. Bush, Michael Dukakis eller någon annan (detta inkluderade också ingen preferens). Totalt 1447 personer deltog och resultaten var följande:

Bush	Dukakis	Annan/ingen
727	583	137


Om vi antar att svarspersonerna valdes slumpmässigt ur populationen av röstberättigade får vi att antalet svar borde vara multinomialfördelat med parameter motsvarande de andelar av population som har den underliggande preferensen. Med andra ord har vi $\mathbf{X} \mid \Theta = \theta \sim \text{Multi}(1447, \theta)$.

Om vi inte har någon tidigare information om de olika kandidaternas stöd kan vi använda en icke-informativ apriorifördelning. Här tar vi $\Theta \sim \text{Dirichlet}(1, 1, 1)$, vilket ger aposteriorifördelningen

$$\Theta \mid \mathbf{X} = \mathbf{x} \sim \text{Dirichlet}(728, 584, 138).$$

Här kan det vara intressant att beräkna fördelningen för $\Theta_1 - \Theta_2$, dvs. skillnaden i andel för Bush jämfört med Dukakis. Vi kan försöka beräkna denna fördelning analytiskt, men det är enklare att simulera utfall från Θ_1 och Θ_2 , bilda differensen, och plotta dess histogram.

Om vi drar $n_{\text{samp}} = 10000$ utfall får vi följande histogram:



Alla utfall har att $\theta_1 > \theta_2$, så vi kan med säkerhet säga att Bush har en klar fördel över Dukakis här.

Notera att om vi hade en annan apriorifördelning (t.ex. som gav Dukakis ett större stöd till och börja med) hade aposteriorifördelningen sett annorlunda ut.

8.1.2 Normalfördelad data

En annan viktig modell är normalfördelad data. Vi har redan studerat denna, men där vi har tagit fixt väntevärde μ eller varians σ^2 . Låt oss nu undersöka fallet då både väntevärdet och variansen är okända.

Låt oss anta att $\mathbf{X} = [X_1, \dots, X_n]^T$ för betingat oberoende $X_1, \dots, X_n$ där

$$X_i \mid \Theta_M = \theta_M, \Theta_V = \theta_V \sim N(\theta_M, \theta_V)$$

för $i = 1, \dots, n$. Om vi studerar den betingade täthetsfunktionen för $\mathbf{X}$ har vi

$$\begin{aligned} f_{\mathbf{X} \mid \Theta_M, \Theta_V}(\mathbf{x} \mid \theta_M, \theta_V) &= \prod_{i=1}^n \frac{1}{(2\pi\theta_V)^{1/2}} e^{-(x_i - \theta_M)^2 / 2\theta_V} \\ &\propto \theta_V^{-n/2} e^{-\frac{1}{2\theta_V} \sum_{i=1}^n (x_i - \theta_M)^2} \\ &= \theta_V^{-n/2} e^{-\frac{1}{2\theta_V} ((n-1)s^2 + n(\bar{x} - \theta_M)^2)}, \end{aligned}$$

där vi i sista raden har använt identiteten

$$\sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - a)^2 = (n-1)s^2 + n(\bar{x} - a)^2$$

för $a \in \mathbb{R}$. För att hitta en konjugerad apriorifördelning söker vi alltså en täthetsfunktion på formen

$$f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) \propto \theta_V^{-a} e^{-\frac{1}{\theta_V} (b + c(\theta_M - d)^2)}.$$

Denna ganska komplicerade form ger inte någon självklar fördelning, men en faktor ser bekant ut:

$$\theta_V^{-a} e^{-\frac{b}{\theta_V}}.$$

Denna form delas av täthetsfunktionen hos den inversa gammafördelningen, som vi såg innan som den konjugerade apriorifördelningen för normalfördelat data med känt väntevärde. Om vi då tar $\Theta_V \sim \text{InvGamma}(\alpha_0, \beta_0)$ så ser vi kan bygga upp den sökta täthetsfunktionen genom att ta $\Theta_M | \Theta_V = \theta_V \sim N(\mu_0, \theta_V/\lambda_0)$, och använda kedjeregeln för att få

$$\begin{aligned} f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) &= \frac{\sqrt{\lambda_0}}{(2\pi\theta_V)^{1/2}} e^{-\frac{\lambda_0}{2\theta_V}(\theta_M - \mu_0)^2} \cdot \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \theta_V^{-\alpha_0-1} e^{-\beta_0/\theta_V} \\ &= \frac{\sqrt{\lambda_0}\beta_0^{\alpha_0}}{(2\pi\theta_V)^{1/2}\Gamma(\alpha_0)} \theta_V^{-\alpha_0-1} e^{-\frac{1}{2\theta_V}(2\beta_0 + \lambda_0(\theta_M - \mu_0)^2)}. \end{aligned}$$

Denna fördelning kallas den normal- och inversa gammafördelningen och betecknas $\text{NInvGamma}(\mu_0, \lambda_0, \alpha_0, \beta_0)$.

Genom att multiplicera $f_{\mathbf{X}|\Theta_M, \Theta_V}(\mathbf{x} | \theta_M, \theta_V)$ och $f_{\Theta_M, \Theta_V}(\theta_M, \theta_V)$ får vi

$$\begin{aligned} f_{\Theta_M, \Theta_V|\mathbf{X}}(\theta_M, \theta_V | \mathbf{x}) &\propto f_{\mathbf{X}|\Theta_M, \Theta_V}(\mathbf{x} | \theta_M, \theta_V) f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) \\ &\propto \theta_V^{-n/2} e^{-\frac{1}{2\theta_V}((n-1)s^2 + n(\bar{x} - \theta_M)^2)} \cdot \theta_V^{-1/2} \theta_V^{-\alpha_0-1} e^{-\frac{1}{2\theta_V}(2\beta_0 + \lambda_0(\theta_M - \mu_0)^2)} \\ &= \theta_V^{-1/2} \theta_V^{-\alpha_0-n/2-1} e^{-\frac{1}{2\theta_V}((n-1)s^2 + n(\bar{x} - \theta_M)^2 + 2\beta_0 + \lambda_0(\theta_M - \mu_0)^2)}. \end{aligned}$$

Om vi utvecklar kvadrattermerna i exponenten kan vi skriva om dem som

$$\begin{aligned} n(\bar{x} - \theta_M)^2 + \lambda_0(\theta_M - \mu_0)^2 &= n\bar{x}^2 - 2n\bar{x}\theta_M + n\theta_M^2 + \lambda_0\theta_M^2 - 2\lambda_0\mu_0\theta_M + \lambda_0\mu_0^2 \\ &= (\lambda_0 + n)\theta_M^2 + 2(\lambda_0\mu_0 + n\bar{x})\theta_M + n\bar{x}^2 + \lambda_0\mu_0^2 \\ &= (\lambda_0 + n) \left(\theta_M^2 + 2 \left(\frac{\lambda_0\mu_0 + n\bar{x}}{\lambda_0 + n} \right) \theta_M + \left(\frac{\lambda_0\mu_0 + n\bar{x}}{\lambda_0 + n} \right)^2 \right) - (\lambda_0 + n) \left(\frac{\lambda_0\mu_0 + n\bar{x}}{\lambda_0 + n} \right)^2 + n\bar{x}^2 + \lambda_0\mu_0^2 \\ &= (\lambda_0 + n) \left(\theta_M - \frac{\lambda_0\mu_0 + n\bar{x}}{\lambda_0 + n} \right)^2 + \frac{-(\lambda_0\mu_0 + n\bar{x})^2 + (\lambda_0 + n)n\bar{x}^2 + (\lambda_0 + n)\lambda_0\mu_0^2}{\lambda_0 + n} \\ &= (\lambda_0 + n) \left(\theta_M - \frac{\lambda_0\mu_0 + n\bar{x}}{\lambda_0 + n} \right)^2 + \frac{-\lambda_0^2\mu_0^2 - 2n\bar{x}\lambda_0\mu_0 - n^2\bar{x}^2 + (\lambda_0 + n)n\bar{x}^2 + (\lambda_0 + n)\lambda_0\mu_0^2}{\lambda_0 + n} \\ &= (\lambda_0 + n) \left(\theta_M - \frac{\lambda_0\mu_0 + n\bar{x}}{\lambda_0 + n} \right)^2 + \frac{\lambda_0 n}{\lambda_0 + n} (\bar{x}^2 - 2\bar{x}\mu_0 + \mu_0^2) \\ &= (\lambda_0 + n) \left(\theta_M - \frac{\lambda_0\mu_0 + n\bar{x}}{\lambda_0 + n} \right)^2 + \frac{\lambda_0 n}{\lambda_0 + n} (\bar{x} - \mu_0)^2. \end{aligned}$$

(Notera att vi inte kan dra ifrån och lägga till konstanter på samma sätt som i andra fall då alla dessa termer multipliceras med $1/2\theta_V$ i täthetsfunktionen och därför inte kan anses konstanta med avseende på θ_M, θ_V .) Om vi stoppar in detta i uttrycket ovan för täthetsfunktionen får vi

$$f_{\Theta_M, \Theta_V|\mathbf{X}}(\theta_M, \theta_V | \mathbf{x}) = \theta_V^{-1/2} \theta_V^{-\alpha_0-n/2-1} e^{-\frac{1}{2\theta_V} \left(2 \left(\beta_0 + \frac{(n-1)s^2}{2} + \frac{\lambda_0 n}{\lambda_0 + n} \frac{(\bar{x} - \mu_0)^2}{2} \right) + (\lambda_0 + n) \left(\theta_M - \frac{\lambda_0\mu_0 + n\bar{x}}{\lambda_0 + n} \right)^2 \right)}.$$

Vi har alltså

$$\Theta_M, \Theta_V | \mathbf{X} = \mathbf{x} \sim \text{NInvGamma}(\mu_n, \lambda_n, \alpha_n, \beta_n)$$

där

$$\begin{aligned} \mu_n &= \frac{\lambda_0\mu_0 + n\bar{x}}{\lambda_0 + n}, \\ \lambda_n &= \lambda_0 + n, \\ \alpha_n &= \alpha_0 + \frac{n}{2}, \\ \beta_n &= \beta_0 + \frac{n-1}{2}s^2 + \frac{n\lambda_0}{\lambda_0 + n} \frac{(\bar{x} - \mu_0)^2}{2}. \end{aligned}$$

Som vi noterat tidigare är det ofta så att vissa parametrar är mer intressanta än andra. För normalfördelningen kanske vi har både okänt väntevärde Θ_M och varians Θ_V , men det är endast Θ_M som intresserar oss; dvs. Θ_V är en störparameter. I detta fall kan vi beräkna marginalfördelningen för Θ_M . Denna fås genom

$$f_{\Theta_M|\mathbf{X}}(\theta_M | \mathbf{x}) \propto \int_0^{+\infty} \theta_V^{-1/2} \theta_V^{-\alpha_n-1} e^{-\frac{1}{2\theta_V}(2\beta_n + \lambda_n(\theta_M - \mu_n)^2)} d\theta_V.$$

Om vi sätter $Q = 2\beta_n + \lambda_n(\theta_M - \mu_n)^2$ och gör variabelbytet $u = \frac{1}{2\theta_V}Q$ får vi $d\theta_V = \frac{-1}{2u^2}Qdu$, vilket ger

$$\begin{aligned} f_{\Theta_M|\mathbf{X}}(\theta_M | \mathbf{x}) &\propto \int_0^{+\infty} \left(\frac{1}{2u}Q\right)^{-1/2} \left(\frac{1}{2u}Q\right)^{-\alpha_n-1} e^{-u} \frac{-1}{2u^2}Qdu \\ &\propto Q^{-\alpha_n-1/2} \int_0^{+\infty} u^{\alpha_n-1/2} e^{-u} du. \end{aligned}$$

Integralen är konstant med avseende på θ_M , så vi får

$$\begin{aligned} f_{\Theta_M|\mathbf{X}}(\theta_M | \mathbf{x}) &\propto Q^{-\alpha_n-1/2} = (2\beta_n + \lambda_n(\theta_M - \mu_n)^2)^{-\alpha_n-1/2} \\ &\propto \left(1 + \frac{1}{2\alpha_n} \frac{(\theta_M - \mu_n)^2}{\beta_n/\alpha_n\lambda_n}\right)^{-\frac{2\alpha_n+1}{2}}. \end{aligned}$$

Formen på täthetsfunktionen sammanfaller med den generaliserade t-fördelningen med $2\alpha_n$ frihetsgrader skiftad med μ_n och skalad med $\sqrt{\beta_n/\alpha_n\lambda_n}$, dvs.

$$\Theta_M | \mathbf{X} = \mathbf{x} \sim t\left(2\alpha_n, \mu_n, \frac{\beta_n}{\alpha_n\lambda_n}\right)$$

För Θ_V har vi

$$\Theta_V | \mathbf{X} = \mathbf{x} \sim \text{InvGamma}(\alpha_n, \beta_n)$$

från definitionen av normal- och inversa gammafördelningen.

Från innan har vi sett att en icke-informativ apriorifördelning för Θ_M är $f_{\Theta_M}(\theta_M) \propto 1$ medan för Θ_V har vi $f_{\Theta_V}(\theta_V) \propto 1/\theta_V$. Om vi antar att $\Theta_M \perp \Theta_V$ får vi den icke-informativa apriorifördelningen

$$f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) \propto \frac{1}{\theta_V}.$$

Aposteriorifördelningen blir då

$$\Theta | \mathbf{X} = \mathbf{x} \sim \text{NInvGamma}(\bar{x}, n, (n-1)/2, (n-1)s^2/2).$$

Detta ger i sin tur de marginella posteriorifördelningarna

$$\Theta_M | \mathbf{X} = \mathbf{x} \sim t(n-1, \bar{x}, s^2/n)$$

och

$$\Theta_V | \mathbf{X} = \mathbf{x} \sim \text{InvGamma}((n-1)/2, (n-1)s^2/2).$$

Dessa resultat kan också generaliseras till vektorvärd data (dvs. där datafördelningen är en flerdimensionell normalfördelning). Vi ersätter då den inversa gammafördelningen med en annan fördelning över positivt definita matriser som kallas den inversa wishartfördelningen (se övning 8).

8.1.3 Grafiska modeller för bayesiansk inferens

Medan det är användbart att ha formler för bayesiansk inferens när modellerna är normal- eller multinomialfördelad finns det naturligtvis situationer där vi kanske vill använda andra typer av flerdimensionella fördelningar. I sådana fall kan vi exempelvis välja att bygga en hierarkisk modell som i Kapitel 3. Vi har sett i kapitel 4 att modellen då kan representeras som en grafisk modell. I dessa situationer kan grafstrukturen hjälpa oss att förenkla beräkningen av posteriorifördelningen.

Exempel 8.2. Du är fortfarande på väg till jobbet och gav upp på att korsa cykelvägen vi diskuterade i Kapitel 7. Istället bestämde du att ta en omväg men nu har du hamnat i en mycket mer komplicerad situation: du väntar nu på att korsa en tvåfilig cykelväg och precis efter måste du korsa en enkelriktad gata. Medan du väntar räknar du antalet cyklar som passerar under varje 10-sekundersintervall. Du räknar cyklarna som passerar åt båda hållen tillsammans eftersom det är för svårt att räkna dem separat. Detta ger dig datan:

Intervall (sek.)	0–10	10–20	20–30	30–40	40–50	50–60
Antal cyklister	1	3	2	2	2	2

Du räknar också bilar som passerar på gatan och får datan:

Intervall (sek.)	0–10	10–20	20–30	30–40	40–50	50–60
Antal bilar	0	2	3	1	0	0

Det bästa vore om du kunde hitta en stund där du kan korsa både cykelvägen och gatan samtidigt. För att skatta hur lång tid du kommer att vänta bildar du följande bayesianska modell: Du antar att antalet cyklar som passerar från höger under varje 10-sekundersintervall X_i har den betingade fördelningen

$$X_i | \Upsilon = v \sim \text{Po}(v)$$


och antalet cyklar som passerar från vänster Y_i har fördelningen

$$Y_i | \Theta = \theta \sim \text{Po}(\theta).$$

Du modellerar också antalet bilar som passerar under varje 10-sekundersintervall W_i som

$$W_i | \Gamma = \gamma \sim \text{Po}(\gamma).$$

Här antar du att $X_1, \dots, X_6, Y_1, \dots, Y_6$ och $W_1, \dots, W_6$ är oberoende givet Υ, Θ respektive Γ . Notera att du bara observerade datan $[\mathbf{z}, \mathbf{w}]^T = [z_1, \dots, z_6, w_1, \dots, w_6]^T$ där $Z_i = X_i + Y_i$. Du kommer plötsligt ihåg resultatet från Uppgift 2.13 som säger att $Z_i \sim \text{Po}(v + \theta)$. Eftersom du vill korsa cykelvägen och gatan samtidigt är du intresserad av fördelningen $T = W + Z \sim \text{Po}(v + \theta + \gamma)$. Du är relativt säker på att du kan anta Υ, Θ och Γ är oberoende. Detta ger dig den grafiska modellen $(\mathcal{G}, [T, W, Z, Y, X, \Upsilon, \Theta, \Gamma]^T)$ med $\mathcal{G}$ som ges av



Du bestämmer att använda naturliga konjugerade apriorifördelningar för de poissonfördelade variablerna X, Y och W . Om du använder samma antagande som i Exempel 7.6 så tror du att en cykel ska passera från varje håll var tionde sekund med en standardavvikelse på 1. Du gör också samma antagande för bilar på gatan. Detta ger dig

$$\begin{aligned} \Upsilon &\sim \text{Gamma}(1, 1), \\ \Theta &\sim \text{Gamma}(1, 1), \text{ och} \\ \Gamma &\sim \text{Gamma}(1, 1). \end{aligned}$$

Du ser från grafen $\mathcal{G}$ att $Z \perp\!\!\!\perp W, \Gamma$ och $W \perp\!\!\!\perp \Theta, \Upsilon$. Detta hjälper dig att förenkla datafördelningen och får då

$$\begin{aligned} f_{\mathbf{Z}, \mathbf{W} | \Upsilon, \Theta, \Gamma}(\mathbf{z}, \mathbf{w} | v, \theta, \gamma) &= f_{\mathbf{Z} | \mathbf{W}, \Theta, \Upsilon}(\mathbf{z} | \mathbf{w}, v, \theta) f_{\mathbf{W} | \Theta, \Upsilon, \Gamma}(\mathbf{w} | v, \theta, \gamma), \\ &= f_{\mathbf{Z} | \Theta, \Upsilon}(\mathbf{z} | v, \theta) f_{\mathbf{W} | \Gamma}(\mathbf{w} | \gamma). \end{aligned}$$

Eftersom du har antagit att Υ, Θ och Γ är oberoende så har du den simultana apriorifördelningen

$$f_{\Upsilon, \Theta, \Gamma}(v, \theta, \gamma) = f_{\Upsilon}(v) f_{\Theta}(\theta) f_{\Gamma}(\gamma).$$

Därför beräknar du aposteriorifördelningen som

$$\begin{aligned} f_{\Upsilon, \Theta, \Gamma | \mathbf{Z}, \mathbf{W}}(v, \theta, \gamma | \mathbf{z}, \mathbf{w}) &\propto f_{\mathbf{Z} | \Upsilon}(\mathbf{z} | v, \theta) f_{\mathbf{W} | \Gamma}(\mathbf{w} | \gamma) f_{\Upsilon}(v) f_{\Theta}(\theta) f_{\Gamma}(\gamma), \\ &\propto (f_{\mathbf{Z} | \Upsilon}(\mathbf{z} | v, \theta) f_{\Upsilon}(v) f_{\Theta}(\theta)) (f_{\mathbf{W} | \Gamma}(\mathbf{w} | \gamma) f_{\Gamma}(\gamma)), \\ &\propto \left(\frac{e^{-n(v+\theta)} (v+\theta)^{\sum_{i=1}^6 z_i} e^{-v} e^{-\theta}}{\prod_{i=1}^6 z_i!} \right) \left(\frac{e^{-n\gamma} \gamma^{\sum_{i=1}^6 w_i} e^{-\gamma}}{\prod_{i=1}^6 w_i} \right), \\ &\propto \left((v+\theta)^{(1+\sum_{i=1}^6 z_i)-1} e^{-(6+1)(v+\theta)} \right) \left(e^{-(6+1)\gamma} \gamma^{(1+\sum_{i=1}^6 w_i)-1} \right). \end{aligned}$$

Det vill säga att den simultana aposteriorifördelningen ges av en produkt av två gammafördelningar; nämligen,

$$\begin{aligned} \Upsilon + \Theta | [\mathbf{Z}, \mathbf{W}]^T = [\mathbf{z}, \mathbf{w}]^T &\sim \text{Gamma}(1 + \sum_{i=1}^6 z_i, 7), \text{ och} \\ \Gamma | [\mathbf{Z}, \mathbf{W}]^T = [\mathbf{z}, \mathbf{w}]^T &\sim \text{Gamma}(1 + \sum_{i=1}^6 w_i, 7). \end{aligned}$$

Du ser av detta att $\Gamma \perp\!\!\!\perp \Upsilon, \Theta | [\mathbf{Z}, \mathbf{W}]$ som kunde du ha sett direkt från $\mathcal{G}$ med hjälp av d-separationsreglen; dvs. Γ är d-separerade från $\{\Upsilon, \Theta\}$ givet $\{\mathbf{Z}, \mathbf{W}\}$. Notera att $\Upsilon \not\perp\!\!\!\perp \Theta | \mathbf{Z}, \mathbf{W}$ och man ser denna relation för beroende i aposteriorifördelningen. Observera också att $\Gamma \not\perp\!\!\!\perp \Upsilon, \Theta | T$ enligt $\mathcal{G}$ vilket betyder att aposteriorifördelningen skulle ha varit mer komplicerad om du hade använt datan $\mathbf{t} = [t_1, \dots, t_6]^T$ istället för $[\mathbf{z}, \mathbf{w}]^T$.

Du kan dock använda denna aposteriorifördelningen för att förutsäga hur länge du kommer att vänta på ett 10-sekundersintervall utan cyklar och bilar. Du har att $T | \Upsilon = v, \Theta = \theta, \Gamma = \gamma \sim \text{Po}(v + \theta + \gamma)$ och eftersom summan av gammafördelningarna ovan är gammafördelad har du

$$\Upsilon + \Theta + \Gamma | [\mathbf{Z}, \mathbf{W}]^T = [\mathbf{z}, \mathbf{w}]^T \sim \text{Gamma}(2 + \sum_{i=1}^6 z_i + \sum_{i=1}^6 w_i, 7) = \text{Gamma}(20, 7).$$

Låt nu K vara antalet intervaller som inträffar innan du har ett intervall utan cyklar och bilar. Du såg i Exempel 7.11 att $K | \Upsilon + \Theta + \Gamma = v + \theta + \gamma \sim \text{Geom}(e^{-(v+\theta+\gamma)})$. På samma sätt som i det där exemplet räknar du ut

$$\mathbb{E}[K | [\mathbf{Z}, \mathbf{W}]^T = [\mathbf{z}, \mathbf{w}]^T] = \left(\frac{7}{7-1} \right)^{20} \approx 21.8.$$

Så du kan förvänta dig att vänta omkring $21.8 * 10/60 \approx 3.6$ minuter innan du kan korsa säkert. Medan du kommer vänta (i förväntan) mindre vid denna korsning än vid korsningen från Exempel 7.6 och 7.11 kommer det fortfarande att ta lite tid (mycket trafik idag).

8.1.4 Exponentialfamiljer

Vi avslutar med ett resultat som sammanbinder exponentialfamiljer, tillräckliga statistikor, och naturligt konjugerade apriorifördelningar. Som vi sett innan så har vi en exponentialfamilj med avseende på $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^d$ om täthetsfunktionen för en stokastisk vektor $\mathbf{X} \in \mathbb{R}^m$ uppfyller

$$f_{\mathbf{X}}(\mathbf{x} | \boldsymbol{\theta}) = h(\mathbf{x}) c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta})^T t_i(\mathbf{x}) \right)$$

där $h : \mathbb{R}^m \rightarrow \mathbb{R}_{\geq 0}$, $c : \mathbb{R}^d \rightarrow \mathbb{R}_{\geq 0}$ och $w_i : \mathbb{R}^d \rightarrow \mathbb{R}^{k_i}$ samt $t_i : \mathbb{R}^m \rightarrow \mathbb{R}^{k_i}$ för något positivt heltal k_i för alla $i = 1, \dots, k$. (Här är $\mathbf{X}$ en kontinuerlig stokastisk vektor, men följande resonemang håller även i det diskreta fallet.) Vi kan generalisera Sats 5.6 och visa att givet ett oberoende och likafördelat stickprov $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ så utgör

$$\left[\sum_{j=1}^n t_1(\mathbf{X}_j), \sum_{j=1}^n t_2(\mathbf{X}_j), \dots, \sum_{j=1}^n t_k(\mathbf{X}_j) \right]^T$$

en tillräcklig statistika för $\boldsymbol{\theta}$ (av dimension $(\sum_{i=1}^k k_i)$).

Vi kan också definiera naturliga parametrar i det flerdimensionella fallet. Detta ger parametreringen $\boldsymbol{\eta} = [\boldsymbol{\eta}_1, \dots, \boldsymbol{\eta}_k]^T$ där $\boldsymbol{\eta}_i \in \mathbb{R}^{k_i}$ och $\boldsymbol{\eta}$ uppfyller

$$\int_{\mathbb{R}^m} h(\mathbf{x}) \exp \left(\sum_{i=1}^k \boldsymbol{\eta}_i^T t_i(\mathbf{x}) \right) d\mathbf{x} < +\infty.$$

Vi har då faktoriseringen

$$f_{\mathbf{X}}(\mathbf{x} | \boldsymbol{\eta}) = h(\mathbf{x})c(\boldsymbol{\eta}) \exp \left(\sum_{i=1}^k \boldsymbol{\eta}_i^T t_i(\mathbf{x}) \right)$$

där $c(\boldsymbol{\eta})$ väljs så att täthetsfunktionen integrerar till ett.

Om vi nu antar att vi har ett stickprov $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ som är betingat oberoende givet $\mathbf{H} = \boldsymbol{\eta}$ och varje observation $\mathbf{X}_i$ har den betingade täthetsfunktionen ovan givet $\mathbf{H} = \boldsymbol{\eta}$, så söker vi den naturligt konjugerade familjen av apriorifördelningar (versalformen av η är $\mathbf{H}$). Vi definierar då en exponentialfamilj i $\mathbf{H}$ genom

$$f_{\mathbf{H}}(\boldsymbol{\eta}) \propto c(\boldsymbol{\eta})^{\nu_0} \exp \left(\sum_{i=1}^k \boldsymbol{\eta}_i^T \boldsymbol{\alpha}_{0,i} \right)$$

där $\nu_0 \in \mathbb{R}_{>0}$ och $\boldsymbol{\alpha}_{0,i} \in \mathbb{R}^{k_i}$ för $i = 1, \dots, k$ och tar denna som apriorifördelning. Detta ger då aposteriorifördelningen

$$\begin{aligned} f_{\mathbf{H}|\mathbf{X}_1, \dots, \mathbf{X}_n}(\boldsymbol{\eta} | \mathbf{x}_1, \dots, \mathbf{x}_n) &\propto c(\boldsymbol{\eta})^{\nu_0+n} \exp \left(\sum_{i=1}^k \boldsymbol{\eta}_i^T \left(\boldsymbol{\alpha}_{0,i} + \sum_{j=1}^n t_i(\mathbf{x}_j) \right) \right) \\ &= c(\boldsymbol{\eta})^{\nu_n} \exp \left(\sum_{i=1}^k \boldsymbol{\eta}_i^T \boldsymbol{\alpha}_{n,i} \right), \end{aligned}$$

där $\nu_n = \nu_0 + n$ och $\boldsymbol{\alpha}_{n,i} = \boldsymbol{\alpha}_{0,i} + \sum_{j=1}^n t_i(\mathbf{x}_j)$. Med andra ord bildar denna exponentialfamilj en naturligt konjugerad familj av apriorifördelningar för den naturliga parametern. Uppdateringsregeln för ν lägger till antalet observationer medan för de andra parametrarna $\boldsymbol{\alpha}_i$ lägger vi till de tillräckliga statistikorna $\sum_{j=1}^n t_i(\mathbf{x}_j)$.

En intressant observation är att aposteriorifördelningen här endast beror på stickprovsstorleken n samt de tillräckliga statistikorna för våra parametrar. Man kan visa att detta håller mer generellt (dvs. inte bara för exponentialfamiljer med den naturliga parametreringen). När man söker aposteriorifördelningen för en ny datafördelning kan det därför vara användbart att beräkna aposteriorifördelningen med avseende på de tillräckliga statistikorna då detta kan avsevärt förenkla kalkylen.

8.2 Uppgifter

- 8.1. [2] Generaliseringen av betafördelningen till k dimensioner kallas *Dirichletfördelningen*. För $k = 3$ har vi täthetsfunktionen

$$f_{X_1, X_2, X_3}(x_1, x_2, x_3) = \frac{\Gamma(\alpha_1 + \alpha_2 + \alpha_3)}{\Gamma(\alpha_1)\Gamma(\alpha_2)\Gamma(\alpha_3)} x_1^{\alpha_1-1} x_2^{\alpha_2-1} x_3^{\alpha_3-1},$$

för $0 < x_1, x_2, x_3 < 1, x_1 + x_2 + x_3 = 1$ och där $\alpha_1, \alpha_2, \alpha_3 > 0$ är konstanter.

- Visa att X_1, X_2 och X_3 är marginellt betafördelade samt bestäm deras parametrar α, β .
- Bestäm den betingade fördelningen $X_2 | X_1 = x_1$ och visa att för $W = X_2/(1 - X_1)$ har vi $W | X_1 = x_1 \sim \text{Beta}(\alpha_2, \alpha_3)$.
- Om $U = X_1/(X_1 + X_2)$, visa att $U \sim \text{Beta}(\alpha_1, \alpha_2)$.
- Visa att $E[X_1 X_2] = \frac{\alpha_1 \alpha_2}{(\alpha_1 + \alpha_2 + \alpha_3 + 1)(\alpha_1 + \alpha_2 + \alpha_3)}$ och beräkna $\text{Cov}[X, Y]$.

- 8.2. [2] På kvällen den 25 september 1988 genomfördes den första TV-sända debatten mellan de två amerikanska presidentkandidaterna, George H. W. Bush och Michael Dukakis. I samband med denna debatt gjorde den amerikanska TV-kanalen ABC två opinionsundersökningar via telefon: en före debatten och en efter. Samma antal svarspersoner, 639, tillfrågades i varje undersökning, men urvalet av personer skilde sig mellan undersökningarna. Deras svar ges i följande tabell:

Undersökning	Bush	Dukakis	Ingen åsikt/annan	Totalt
Innan	294	307	38	639
Efter	288	332	19	639

Modellera dessa data med hjälp av två multinomialfördelningar. Antag en icke-informativ apriorifördelning där svarsandelarna är likformigt fördelade. Låt Q_1 vara andelen väljare som föredrar Bush utav de väljare som föredrog antingen Bush eller Dukakis (dvs. som inte valde det tredje alternativet) i den första undersökningen och låt Q_2 vara motsvarande andel i den andra undersökningen. Bestäm aposteriorisannolikheten att stödet för Bush ökade, dvs. att $Q_2 - Q_1$ är positiv.

- 8.3.** [1] Ett experiment utfördes för att undersöka effekten av magnetfält på kalciumflöden ur tamhönans hjärna. Fåglarna delades upp i oberoende två grupper: en kontrollgrupp om 32 fåglar och en försöksgrupp med 36 fåglar. Kalciumflödet mättes för varje fågel, och målet var att mäta medelflödena $\Theta_{M,K}$ och $\Theta_{M,F}$ inom kontrollgruppen respektive försöksgruppen. Inom kontrollgruppen erhöles ett stickprovsmedelvärde på 1.013 samt en stickprovsstandardavvikelse 0.24. Motsvarande värden för försöksgruppen var 1.173 samt 0.20.

- (a) Anta att mätvärdena från kontrollgruppen genererades från en normalfördelning med väntevärde $\Theta_{M,K}$ och varians $\Theta_{S,K}^2$ medan värdena från försöksgruppen togs från en normalfördelning med väntevärde $\Theta_{M,F}$ samt varians $\Theta_{S,F}^2$. Bestäm aposteriorifördelningarna för $\Theta_{M,K}$ samt $\Theta_{M,F}$ givet en icke-informativ apriorifördelning.
- (b) Beskriv aposteriorifördelningen för $\Theta_{M,F} - \Theta_{M,K}$. Vad är sannolikheten att $\Theta_{M,F} > \Theta_{M,K}$?

- 8.4.** [1] Låt $\mathbf{X} \mid \boldsymbol{\Theta} = \boldsymbol{\theta} \sim \text{Multi}(m, \boldsymbol{\theta})$ där $\boldsymbol{\Theta} \sim \text{Dirichlet}(1, 1, 1, 1)$ och anta att vi observerar $\mathbf{X} = [2, 9, 11, 13]^T$.

- (a) Beräkna $E[\Theta_2 \mid \mathbf{X} = \mathbf{x}]$ och $\text{Cov}[\Theta_2, \Theta_2 \mid \mathbf{X} = \mathbf{x}]$.
- (b) Antag att $\mathbf{Y} \mid \boldsymbol{\Theta} = \boldsymbol{\theta} \sim \text{Multi}(10, \boldsymbol{\theta})$. Beräkna $E[\mathbf{Y} \mid \mathbf{X} = \mathbf{x}]$ samt $\text{Var}[\mathbf{Y} \mid \mathbf{X} = \mathbf{x}]$.

- 8.5.** [2] En trafikundersökning genomfördes i Berkeley, Kalifornien under våren 1993. I undersökningen räknades (bland annat) antalet cyklar jämfört med andra fordon längs olika vägar i ett bostadsområde. För varje väg som undersöktes noterades också om en cykelväg fanns där eller inte. Resultaten blev följande:

Cykelväg?	Antal cyklar/antal andra fordon
Ja	16/58, 9/90, 10/48, 13/57, 19/103, 20/57, 18/86, 17/112, 35/273, 55/64
Nej	12/113, 1/18, 2/14, 4/44, 9/208, 7/67, 9/29, 8/154

- (a) Låt $Y_1, Y_2, \dots, Y_{10}$ och $Z_1, Z_2, \dots, Z_8$ vara andelen av fordonen som utgjordes av cyklar längs vägarna med respektive utan cykelvägar (dvs. vi har $y_1 = 16/(16 + 58)$, $z_1 = 12/(12 + 113)$, osv.). Sätt upp en modell så att $Y_1, Y_2, \dots, Y_{10}$ är oberoende och likafördelade givet parametervektorn $\boldsymbol{\Theta}_Y$ samt $Z_1, Z_2, \dots, Z_8$ är oberoende givet parametervektorn $\boldsymbol{\Theta}_Z$.
- (b) Sätt upp oberoende apriorifördelningar för $\boldsymbol{\Theta}_Y$ och $\boldsymbol{\Theta}_Z$.
- (c) Bestäm aposteriorifördelningarna för dina parametrar och simulera 1000 utfall från dessa.
- (d) Låt $M_Y = E[Y_i \mid \boldsymbol{\Theta}_Y]$ samt $M_Z = E[Z_i \mid \boldsymbol{\Theta}_Z]$. Använd dina simulerade utfall från del (c) för att plotta ett histogram för $M_Y - M_Z$, den förväntade skillnaden i proportionen för cykeltrafik mellan vägar med och utan cykelvägar. Approximera sannolikheten att $M_Y > 2M_Z$ givet observationerna.
- 8.6.** [1] Antag att $X_1, \dots, X_n$ är oberoende och likafördelade givet Θ_M, Θ_V så att $X_i \mid \Theta_M = \theta_M, \Theta_V = \theta_V \sim N(\theta_M, \theta_V)$ samt att $\Theta_M, \Theta_V \sim \text{NInvGamma}(0, 1, 2, 2)$. Observationerna är följande:

1.18 2.26 0.36 0.95 -2.93 -1.02 -2.77 -0.46

- (a) Bestäm aposteriorifördelningen för Θ_M, Θ_V .
- (b) Beräkna sannolikheten att $\Theta_M < 0$ samt $\Theta_V > 1$ givet observationerna.

8.7. [3] Aposteriorifördelningar för den flerdimensionella normalfördelningen kan fås på samma sätt som för den endimensionella. Den huvudsakliga skillnaden är att vi nu behöver bestämma fördelningen över kovariansmatrisen Σ istället för endast variansen σ^2 .

- (a) Låt $\mathbf{X} \mid \boldsymbol{\Theta} = \boldsymbol{\theta} \sim N(\boldsymbol{\theta}, \Sigma)$ och $\boldsymbol{\Theta} \sim N(\boldsymbol{\mu}_0, \Lambda_0)$ (dvs. med känd kovariansmatris). Visa att $\boldsymbol{\Theta} \sim \mathbf{X} = \mathbf{x} \sim N(\boldsymbol{\mu}_1, \Lambda_1)$ där

$$\boldsymbol{\mu}_1 = (\Lambda_0^{-1} + \Sigma^{-1})^{-1}(\Lambda_0^{-1}\boldsymbol{\mu}_0 + \Sigma^{-1}\mathbf{x}) \quad \text{och} \quad \Lambda_1 = (\Lambda_0^{-1} + \Sigma^{-1})^{-1}.$$

- (b) Låt nu $\mathbf{X} \mid \boldsymbol{\Theta} = \boldsymbol{\theta} \sim N(\boldsymbol{\mu}, \boldsymbol{\theta})$ (dvs. med känt väntevärde) och $\boldsymbol{\Theta}$ ha täthetsfunktionen

$$f_{\boldsymbol{\Theta}}(\boldsymbol{\theta}) = \frac{(\det \boldsymbol{\psi}_0)^{\nu/2}}{2^{m\nu_0/2} \Gamma_m(\nu_0/2)} (\det \boldsymbol{\theta})^{-(\nu_0+m+1)/2} e^{-\frac{1}{2} \text{tr}(\boldsymbol{\psi}_0 \boldsymbol{\theta}^{-1})},$$

för positivt definita $m \times m$ -matriser $\boldsymbol{\theta}$ där $\Gamma_m(x)$ är den m -dimensionella gammafunktionen

$$\Gamma_m(x) = \pi^{m(m-1)/4} \prod_{j=1}^m \Gamma(x + (1-j)/2),$$

$\nu_0 > m - 1$ och $\boldsymbol{\psi}_0$ är en positivt definit $m \times m$ -matris. Detta kallas för den *inversa Wishart-fördelningen* och betecknas $\boldsymbol{\Theta} \sim \text{InvWishart}(\nu_0, \boldsymbol{\psi}_0)$. Visa att $\boldsymbol{\Theta} \mid \mathbf{X} = \mathbf{x} \sim \text{InvWishart}(\nu_1, \boldsymbol{\psi}_1)$ där

$$\nu_1 = \nu_0 + 1$$

$$\boldsymbol{\psi}_1 = \boldsymbol{\psi}_0 + (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T.$$

- (c) Vi låter nu både väntevärdet och kovariansmatrisen vara okända. I detta fall har vi $\mathbf{X} \mid \boldsymbol{\Theta}_M = \boldsymbol{\theta}_M, \boldsymbol{\Theta}_V = \boldsymbol{\theta}_V \sim N(\boldsymbol{\theta}_M, \boldsymbol{\theta}_V)$ där $\boldsymbol{\Theta}_M \mid \boldsymbol{\Theta}_V = \boldsymbol{\theta}_V \sim N(\boldsymbol{\mu}_0, \boldsymbol{\theta}_V/\lambda_0)$ och $\boldsymbol{\Theta}_V \sim \text{InvWishart}(\nu_0, \boldsymbol{\psi}_0)$. Den simultana fördelningen för $\boldsymbol{\Theta}_M, \boldsymbol{\Theta}_V$ kallas för den *normala och inversa Wishart-fördelningen* betecknas $\text{NInvWishart}(\boldsymbol{\mu}_0, \lambda_0, \nu_0, \boldsymbol{\psi}_0)$ och har täthetsfunktion

$$f_{\boldsymbol{\Theta}_M, \boldsymbol{\Theta}_V}(\boldsymbol{\theta}_M, \boldsymbol{\theta}_V) = \frac{\lambda_0^{m/2} (\det \boldsymbol{\psi}_0)^{\nu/2} (\det \boldsymbol{\theta}_V)^{-(\nu_0+m+2)/2}}{(2\pi)^{m/2} 2^{m\nu_0/2} \Gamma_m(\nu_0/2)} e^{-\frac{1}{2} \text{tr}(\boldsymbol{\psi}_0 \boldsymbol{\theta}_V^{-1}) - \frac{\lambda_0}{2} (\boldsymbol{\theta}_M - \boldsymbol{\mu}_0)^T \boldsymbol{\theta}_V^{-1} (\boldsymbol{\theta}_M - \boldsymbol{\mu}_0)},$$

där $\boldsymbol{\mu}_0 \in \mathbb{R}^m$, $\lambda_0 > 0$, $\nu_0 > m - 1$ och $\boldsymbol{\psi}_0$ är en positivt definit $m \times m$ -matris. Visa att aposteriorifördelningen ges av $\boldsymbol{\Theta}_M, \boldsymbol{\Theta}_V \mid \mathbf{X} = \mathbf{x} \sim \text{NInvGamma}(\boldsymbol{\mu}_1, \lambda_1, \nu_1, \boldsymbol{\psi}_1)$ där

$$\boldsymbol{\mu}_1 = \frac{\lambda_0 \boldsymbol{\mu}_0 + \mathbf{x}}{\lambda_0 + 1}$$

$$\lambda_1 = \lambda_0 + 1$$

$$\nu_1 = \nu_0 + 1$$

$$\boldsymbol{\psi}_1 = \boldsymbol{\psi}_0 + \frac{\lambda_0}{\lambda_0 + 1} (\mathbf{x} - \boldsymbol{\mu}_0)(\mathbf{x} - \boldsymbol{\mu}_0)^T$$

Kapitel 9

9.1 Bayesiansk beslutsteori

Vi har tidigare sett hur beslutsteori kan tillämpas inom det frekventistiska ramverket för att utvärdera olika punktskattningar. Där hade vi en förlustfunktion $L(\boldsymbol{\theta}, \mathbf{a})$ som anger hur önskvärd en viss handling $\mathbf{a} \in \mathcal{A}$ är för ett visst värde $\boldsymbol{\theta} \in \Omega$ på parametern. I det fallet hade vi $\mathcal{A} = \Omega$ och $\mathbf{a} = \hat{\boldsymbol{\theta}} = W(\mathbf{x})$ avsåg en skattning av $\boldsymbol{\theta}$.

Vi kan göra detsamma i det bayesianska ramverket. Givet observationen $X = x$ kan vi ta fram aposteriorifördelningen $\boldsymbol{\Theta} \mid X = x$ och använda denna för att beräkna en punktskattning, som till exempel aposterioriväntevärdet $W(X) = E[\boldsymbol{\Theta} \mid X]$. Som innan kan vi då beräkna riskfunktionen, dvs. väntevärdet av förlustfunktionen över alla möjliga observationer, men för samma värde på parametern $\boldsymbol{\Theta}$. Vi har alltså ett betingat väntevärde:

$$R(\boldsymbol{\theta}, W) = E[L(\boldsymbol{\Theta}, W(\mathbf{X})) \mid \boldsymbol{\Theta} = \boldsymbol{\theta}].$$

Man kan då variera $\boldsymbol{\theta}$ för att se hur skattningen beter sig och jämföra med andra skattningar.

Exempel 9.1. Antag att $X \mid \Theta = \theta \sim \text{Bin}(n, \theta)$. Då har vi ML-skattningen

$$\hat{\Theta}_{\text{ML}} = W_{\text{ML}}(X) = \frac{X}{n}.$$

Givet en apriorifördelning $\text{Beta}(\alpha, \beta)$ för Θ har vi också ett aposterioriväntevärde

$$\hat{\Theta}_{\text{Bayes}} = W_{\text{Bayes}}(X) = \frac{\alpha + X}{\alpha + \beta + n}.$$

Vi kan visa (prova!) att för kvadratfelet $L(\theta, a) = (\theta - a)^2$ har dessa skattningar riskfunktionerna


$$R(\theta, W_{\text{ML}}) = \frac{\theta(1 - \theta)}{n}$$

respektive

$$R(\theta, W_{\text{Bayes}}) = \frac{n\theta(1 - \theta)}{(\alpha + \beta + n)^2} + \left(\frac{n\theta + \alpha}{\alpha + \beta + n} - \theta \right)^2.$$


Riskfunktionen för ML-skattningen är stor för θ runt 1/2 och avtar för θ nära noll eller ett (för dessa värden har X mindre varians, vilket leder till ett mindre medelkvadratfel).

För aposterioriväntevärdet beror riskfunktionen såklart på valet av α och β . Om $\alpha = \beta = 0$ (dvs. en icke-informativ apriorifördelning) återfår vi ML-skattningen och dess riskfunktion. Låter vi α vara stort och β litet får vi ett stort medelkvadratfel för θ nära noll och ett litet för θ nära ett (apriorifördelningen är då koncentrerad runt ett, vilket ger bättre skattningar där).




Ett speciellt val av aprioriparametrar α och β är $\alpha = \beta = \sqrt{n/4}$, vilket ger en konstant riskfunktion (verifiera detta!). Vi har då

$$R(\theta, W_{\text{Bayes}}) = \frac{n}{4(n + \sqrt{n})^2}.$$



När n är litet ger detta ett bättre medelkvadratfel för aposterioriväntevärdet när θ är runt $1/2$ jämfört med ML-skattningen. Vi ser dock att när $n \rightarrow +\infty$ så går medelkvadratfelet mot noll som $1/\sqrt{n}$ medan felet för ML-skattningen går mot noll som $1/n$, dvs. snabbare. För stora värden på n är då ML-skattningen att föredra, oavsett värdet på θ .



9.1.1 Bayesrisk och bayesskattning

Hittills har vi endast tillämpat verktygen från frekventistisk beslutsteori på våra bayesianska punktskattningar. Dessa ger riskfunktionen som beror på parametervärdet θ och vi kan jämföra dessa. En viktig skillnad i det

bayesianska ramverket är att vi antar att θ är ett utfall av en stokastisk vektor Θ som har en viss fördelning – apriorifördelningen. Vi kan då sammanfatta risken hos en viss skattning genom att ta väntevärdet med avseende på denna fördelning. Vi får då

$$\mathbb{E}[R(\Theta, W)] = \int_{\Omega} R(\theta, W) f_{\Theta}(\theta) d\theta.$$

Detta värde kallas *bayesrisken* och motsvarar den genomsnittliga risken som vi får om vi repeterar skattningen för olika värden på θ enligt apriorifördelningen av Θ .

Eftersom vi nu har sammanfattat utvärderingen av punktskattningen i ett enda värde kan detta användas för att rangordna olika punktskattningar (detta går inte med riskfunktionen då denna kan vara både större eller mindre för olika värden av θ). Om vi tror på vår apriorifördelning och vår förlustfunktion ger bayesrisken en bra fingervisning om vilken punktskattning som är strikt bättre än annan. Bland annat kan vi söka efter den punktskattning som ger *lägst* bayesrisk. Denna skattning kallas för *bayesskattningen* med avseende på förlustfunktionen $L(\theta, a)$ och apriorifördelningen $f_{\Theta}(\theta)$.

Att beräkna bayesskattningen kan verka komplicerat. Först måste vi beräkna väntevärdet för förlustfunktionen över olika utfall $\mathbf{x}$ av $\mathbf{X}$ givet en fix parameter $\Theta = \theta$ med hjälp av datafördelningen. Sedan tar vi denna och bildar väntevärdet över olika utfall θ av Θ med hjälp av apriorifördelningen. Till slut ska vi optimera detta värde med avseende på själva skattningen, dvs. en funktion $W(\mathbf{x})$ från $\mathbb{R}^m$ till $\mathbb{R}^d$.

Det finns en (mycket) enklare väg att gå. Vi kan utnyttja faktumet att de två väntevärdena går att beräkna i en annan ordning. Mer specifikt har vi

$$\begin{aligned} \mathbb{E}[R(\Theta, W)] &= \int_{\Omega} R(\theta, W) f_{\Theta}(\theta) d\theta \\ &= \int_{\Omega} \left(\int_{\mathbb{R}^m} L(\theta, W(\mathbf{x})) f_{\mathbf{X}|\Theta}(\mathbf{x} | \theta) d\mathbf{x} \right) f_{\Theta}(\theta) d\theta \\ &= \int_{\mathbb{R}^m} \left(\int_{\Omega} L(\theta, W(\mathbf{x})) f_{\Theta|\mathbf{X}}(\theta | \mathbf{x}) d\theta \right) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}, \end{aligned}$$

där vi har bytt integrationsordning och använt att $f_{\mathbf{X}|\Theta}(\mathbf{x} | \theta) f_{\Theta}(\theta) = f_{\Theta|\mathbf{X}}(\theta | \mathbf{x}) f_{\mathbf{X}}(\mathbf{x})$. Eftersom $f_{\mathbf{X}}(\mathbf{x}) \geq 0$ för alla $\mathbf{x}$ minimeras hela uttrycket om vi lyckas minimera den inre integralen för varje $\mathbf{x} \in \mathbb{R}^m$.

Denna inre integral kallas för *aposterioririsen* och är lika med

$$\mathbb{E}[L(\Theta, W(\mathbf{X})) | \mathbf{X} = \mathbf{x}].$$

Detta värde motsvarar felet som begås i genomsnitt för skattningen av Θ givet en viss observation $\mathbf{X} = \mathbf{x}$. Vi har alltså reducerat problemet med att hitta bayesskattningen till att minimera aposterioririsen för varje $\mathbf{x} \in \mathbb{R}^m$. Eftersom $W(\mathbf{x})$ kan anta ett godtyckligt värde för varje $\mathbf{x}$ betyder detta att vi helt enkelt tar

$$W(\mathbf{x}) = \operatorname{argmin}_{\mathbf{a} \in \mathbb{R}^d} \mathbb{E}[L(\Theta, \mathbf{a}) | \mathbf{X} = \mathbf{x}].$$

Detta minimeringsproblem är oftast betydligt enklare än originalproblemet och löses vanligast genom standardverktyg från differentialkalkylen.

Exempel 9.2. Antag att vi har kvadratfelet $L(\theta, a) = (\theta - a)^2$. Aposterioririsen är då

$$\begin{aligned} \mathbb{E}[L(\theta, a) | \mathbf{X} = \mathbf{x}] &= \int_{\Omega} L(\theta, a) f_{\Theta|\mathbf{X}}(\theta | \mathbf{x}) d\theta \\ &= \int_{\Omega} (\theta - a)^2 f_{\Theta|\mathbf{X}}(\theta | \mathbf{x}) d\theta \\ &= \int_{\Omega} (\theta^2 - 2a\theta + a^2) f_{\Theta|\mathbf{X}}(\theta | \mathbf{x}) d\theta \\ &= \mathbb{E}[\Theta^2 | \mathbf{X} = \mathbf{x}] - 2a \mathbb{E}[\Theta | \mathbf{X} = \mathbf{x}] + a^2. \end{aligned}$$

Denna funktion är minimierad i $a = \mathbb{E}[\Theta | \mathbf{X} = \mathbf{x}]$, så vår bayesskattning är

$$\mathbb{E}[\Theta | \mathbf{X}],$$

dvs. aposterioriväntevärdet.

Det visar sig alltså att om vi endast är intresserade av att minimera kvadratfelet till det sanna värdet θ så ges den optimala skattningen av aposterioriväntevärdet.

Exempel 9.3. Om vi istället tar absolutfelet $L(\theta, a) = |\theta - a|$ och antar att $\Omega = \mathbb{R}$ får vi aposterioririsen

$$\begin{aligned} E[L(\theta, a) | X = x] &= \int_{\Omega} L(\theta, a) f_{\Theta|X}(\theta | x) d\theta \\ &= \int_{\Omega} |\theta - a| f_{\Theta|X}(\theta | x) d\theta \\ &= \int_{-\infty}^a |\theta - a| f_{\Theta|X}(\theta | x) d\theta + \int_a^{+\infty} |\theta - a| f_{\Theta|X}(\theta | x) d\theta \\ &= \int_{-\infty}^a (a - \theta) f_{\Theta|X}(\theta | x) d\theta + \int_a^{+\infty} (\theta - a) f_{\Theta|X}(\theta | x) d\theta \\ &= a \int_{-\infty}^a f_{\Theta|X}(\theta | x) d\theta - \int_{-\infty}^a \theta f_{\Theta|X}(\theta | x) d\theta + \int_a^{+\infty} \theta f_{\Theta|X}(\theta | x) d\theta - a \int_a^{+\infty} f_{\Theta|X}(\theta | x) d\theta. \end{aligned}$$

Vi vill nu minimera med avseende på a och differentierar därför uttrycket med hjälp av integralkalkylens fundamentalsats ($\frac{d}{da} \int_a^b f(x) dx = f(b)$ och $\frac{d}{da} \int_a^b f(x) dx = -f(a)$). Detta ger

$$\begin{aligned} \frac{d}{da} E[L(\theta, a) | X = x] &= \int_{-\infty}^a f_{\Theta|X}(a | x) d\theta + a f_{\Theta|X}(a | x) - a f_{\Theta|X}(a | x) - a f_{\Theta|X}(a | x) - \int_a^{+\infty} f_{\Theta|X}(\theta | x) d\theta + a f_{\Theta|X}(a | x) \\ &= \int_{-\infty}^a f_{\Theta|X}(\theta | x) d\theta - \int_a^{+\infty} f_{\Theta|X}(\theta | x) d\theta \\ &= \int_{-\infty}^a f_{\Theta|X}(\theta | x) d\theta - \left(1 - \int_{-\infty}^a f_{\Theta|X}(\theta | x) d\theta\right) \\ &= 2 \int_{-\infty}^a f_{\Theta|X}(\theta | x) d\theta - 1. \end{aligned}$$

Om vi sätter detta till noll får vi

$$\int_{-\infty}^a f_{\Theta|X}(\theta | x) d\theta = \frac{1}{2}.$$

Vi söker alltså a så att aposteriorifördelningens fördelningsfunktion uppfyller $F_{\Theta|X}(a | x) = 1/2$, dvs. aposteriorimedianen givet $X = x$.

Om vi differentierar en gång till får vi

$$\frac{d^2}{da^2} E[L(\theta, a) | X = x] = 2f_{\Theta|X}(a | x).$$

Denna andraderivata är positiv om vi har en unik median. Annars har vi ett intervall av parametervärden som alla är medianer till aposteriorifördelningen. Oavsett har vi hittat ett värde på a som minimerar aposterioririsen.

Exempel 9.4. Absolutfelet är ett specialfall av förlustfunktionen

$$L(\theta, a) = \begin{cases} c_0(\theta - a), & a \leq \theta, \\ c_1(a - \theta), & a > \theta, \end{cases}$$

för $c_0, c_1 \in \mathbb{R}_{>0}$ (absolutfelet återfås om vi tar $c_0 = c_1 = 1$). Denna förlustfunktion kallas för kvantilfel eller pingpongfel. Man kan visa att bayesskattningen med avseende på denna förlustfunktion ges av $c_1/(c_0 + c_1)$ -kvantilen av aposteriorifördelningen, dvs. $W(x) = a$ för det a som uppfyller $F_{\Theta|X}(a | x) = 1 - c_1/(c_0 + c_1) = c_0/(c_0 + c_1)$.

Observera att i fallen ovan kan vi ta fram en sluten form för bayesskattningen, men detta är inte alltid möjligt för godtyckliga förlustfunktioner. I detta fall kan aposterioririsen behöva minimeras numeriskt. Om det finns en sluten form för aposterioririsen kan standardmetoder inom optimering användas. Annars måste aposterioririsen approximeras genom simulering från aposteriorifördelningen och sedan minimeras.

9.2 Bayesiansk hypotesprövning

Som vi har använt den hittills ger beslutsteorin ett verktyg för att utvärdera skattningar och identifiera ”optimala” skattningar. Vi antydde dock tidigare att handlingsrummet $\mathcal{A}$ inte nödvändigtvis behöver sammanfalla med parameterrummet. Det kan bestå av en godtycklig mängd handlingar a_1, a_2, a_3 osv. som vi kan ta beroende på vår

observation $X = x$. Vi har då vad som kallas en beslutsregel $W(x) \in \mathcal{A}$ som anger hur en viss observation leder till ett visst beslut eller handling. Det enda som krävs är att vi har någon förlustfunktion $L(\theta, a)$ som kvantifierar handlingens ”korrekthet” givet ett visst parametervärde $\theta \in \Omega$.

9.2.1 Bayesbeslut

Givet en förlustfunktion och en apriorifördelning kan vi på samma sätt som innan definiera riskfunktionen $R(\theta, W)$ och bayesrisken $E[R(\Theta, W)]$ för någon beslutsregel $W : \mathbb{R}^m \rightarrow \mathcal{A}$. När vi talar om allmänna beslutsregler $W(\mathbf{x})$ kallas den regel som minimerar bayesrisken för den *bayesianska beslutsregeln* eller *bayesbeslutet* (den kallas också för den *formella bayesregeln*, men då detta mest skapar förvirring undviker vi denna benämning). För att ta fram bayesbeslutet kan vi på samma sätt som innan minimera aposterioririsen

$$E[L(\Theta, a) \mid \mathbf{X} = \mathbf{x}]$$

med avseende på $a = W(\mathbf{x})$ för varje $\mathbf{x} \in \mathbb{R}^m$. Genom att välja den handling a som minimerar denna risk kan vi då fatta det optimala beslutet (med avseende på förlustfunktionen och apriorifördelningen, så klart).

Exempel 9.5. En bonde funderar på att investera i ett litet vindkraftverk för att få ner sina elkostnader. Hon har två modeller att välja på: den mindre modellen a_1 som kostar 11 400 kr med radie 0.8 m och en större modell a_2 som kostar 67 900 kr med radie 1.5 m. Den teoretiska maxeffekten hos ett vindkraftverk ges av formeln

$$P = \frac{1}{2} \rho A v^3,$$

där P är effekten i watt, $\rho = 1.29 \text{ kg/m}^3$ är luftdensiteten, A är arean (i m^2) som rotorbladen sveper över och v är vindhastigheten (i m/s). Hon räknar på ett genomsnittligt elpris på 3 kr/kWh (dvs. 0.003 kr/Wh) och vill maximera sin vinst under de kommande fem åren.

Den okända variabeln här (som måste skattas) är vindhastigheten v . Förlustfunktionen (förlust är negativ vinst) blir då för a_1 lika med

$$L(v, a_1) = 11400 - \frac{1}{2} \cdot 1.29 \cdot \pi \cdot 0.8^2 v^3 \cdot 24 \cdot 365 \cdot 5 \cdot 0.003 = 11400 - 170.5 v^3$$

eftersom vi har $24 \cdot 365 \cdot 5$ timmar under fem år. På samma sätt har vi

$$L(v, a_2) = 67900 - \frac{1}{2} \cdot 1.29 \cdot \pi \cdot 1.5^2 v^3 \cdot 24 \cdot 365 \cdot 0.003 = 67900 - 600 v^3.$$

Under ett par veckor antecknar hon vindhastigheten (i m/s) på platsen hon tänker placera vindkraftverket och får värdena

5.80 7.88 2.97 4.33 3.25 6.83 1.73

Om vi antar att vindhastigheterna är betingat oberoende och normalfördelade givet väntevärdet och variansen får vi att den marginella aposteriorifördelningen för väntevärdet ges av

$$V \mid \mathbf{X} = \mathbf{x} \sim t(6, 4.68, 4.98/7) = t(6, 4.68, 0.71)$$

eftersom $\bar{x} = 4.68$ och $s^2 = 4.98$.

För att beräkna aposterioririsen exakt behöver vi beräkna det tredje momentet hos den generaliserade t -fördelningen, vilket är ganska krävande. Istället kan vi approximera aposterioririsen genom att generera ett stort antal (10000) utfall från $t(6, 4.68, 0.71)$ och ta medelvärdena av $L(v, a_1)$ och $L(v, a_2)$. Vi får då

$$\begin{aligned} E[L(V, a_1) \mid \mathbf{X} = \mathbf{x}] &\approx -8480 \\ E[L(V, a_2) \mid \mathbf{X} = \mathbf{x}] &\approx -2060. \end{aligned}$$

Med tanke på vindförhållandena är det alltså bättre att köpa den mindre modellen. (Observera dock att med en längre tidshorisont skulle den större modellen vara bättre placerad.)

9.2.2 Hypoteser

En speciell (men vanligt förekommande) typ av handling är en hypotes. Med detta avser vi en undermängd Ω_0 av parameterrummet Ω som jämförs med en annan mängd Ω_1 . Oftast har vi att $\Omega_1 = \Omega \setminus \Omega_0$ så att $\Omega_0 \cap \Omega_1 = \emptyset$ och $\Omega_0 \cup \Omega_1 = \Omega$. Vi har då två handlingar: a_0 "acceptera $H_0 : \theta \in \Omega_0$ " och a_1 "acceptera $H_1 : \theta \in \Omega_1$ ".

En naturlig förlustfunktion i detta fall är det så kallade 0–1-felet:

$$L(\theta, a_0) = \begin{cases} 0, & \theta \in \Omega_0, \\ 1, & \theta \in \Omega_1, \end{cases} \quad L(\theta, a_1) = \begin{cases} 1, & \theta \in \Omega_0, \\ 0, & \theta \in \Omega_1. \end{cases}$$

Med andra ord har vi en förlust på noll om vi gör "rätt" val och ett annars. Vi vill alltså undvika fel av första slaget (att vi accepterar H_1 när $\theta \in \Omega_0$) lika mycket som fel av andra slaget (att vi accepterar H_0 när $\theta \in \Omega_1$). I detta fall får vi aposterioririsken till

$$\begin{aligned} E[L(\Theta, a_0) \mid X = x] &= P(\Theta \in \Omega_1 \mid X = x) \\ E[L(\Theta, a_1) \mid X = x] &= P(\Theta \in \Omega_0 \mid X = x). \end{aligned}$$

Bayesbeslutet blir då a_0 om $P(\Theta \in \Omega_0 \mid X = x) > P(\Theta \in \Omega_1 \mid X = x)$ och a_1 annars. Vi väljer alltså den hypotes som har högst aposteriorisannolikhet.

Mer allmänt har vi det generaliserade 0–1-felet:

$$L(\theta, a_0) = \begin{cases} 0, & \theta \in \Omega_0, \\ c_{II}, & \theta \in \Omega_1, \end{cases} \quad L(\theta, a_1) = \begin{cases} c_I, & \theta \in \Omega_0, \\ 0, & \theta \in \Omega_1, \end{cases}$$

där c_I motsvarar kostnaden för ett fel av första slaget (accepterar H_1 när vi borde acceptera H_0) och c_{II} motsvarar kostnaden för ett fel av andra slaget. I detta fall har vi

$$\begin{aligned} E[L(\Theta, a_0) \mid X = x] &= c_{II} P(\Theta \in \Omega_1 \mid X = x) \\ E[L(\Theta, a_1) \mid X = x] &= c_I P(\Theta \in \Omega_0 \mid X = x). \end{aligned}$$

Bayesbeslutet är då a_0 om

$$c_{II} P(\Theta \in \Omega_1 \mid X = x) < c_I P(\Theta \in \Omega_0 \mid X = x),$$

dvs. om

$$\frac{P(\Theta \in \Omega_0 \mid X = x)}{P(\Theta \in \Omega_1 \mid X = x)} > \frac{c_{II}}{c_I},$$

annars väljer vi a_1 . Vänsterledet kallas här för aposteriorioddset för H_0 mot H_1 . Om detta värde är tillräckligt stort (där "tillräckligt" avgörs av de relativa kostnaderna c_I och c_{II}) så accepterar vi alltså H_0 – annars accepterar vi H_1 .

Eftersom $\Omega_1 = \Omega \setminus \Omega_0$ kan vi förenkla bayesbeslutet ytterligare. Vi har $P(\Theta \in \Omega_1 \mid X = x) = 1 - P(\Theta \in \Omega_0 \mid X = x)$, vilket ger

$$\frac{P(\Theta \in \Omega_0 \mid X = x)}{P(\Theta \in \Omega_1 \mid X = x)} > \frac{c_{II}}{c_I}$$

om och endast om

$$\frac{P(\Theta \in \Omega_0 \mid X = x)}{1 - P(\Theta \in \Omega_0 \mid X = x)} > \frac{c_{II}}{c_I},$$

vilket i sin tur kan skrivas om som

$$P(\Theta \in \Omega_0 \mid X = x) > \frac{c_{II}}{c_I + c_{II}},$$

Observera att till skillnad från i frekventistisk hypotesprövning så behöver vi inte ange någon signifikansnivå α . Att acceptera H_0 eller H_1 beror helt och hållet på förlustfunktionens utseende, vilket i sin tur beror på tillämpningen.

9.2.3 Bayesfaktor

Ett annat sätt att göra hypotesprövning inom bayesiansk inferens är att jämföra hur oddsen ändras efter att datat observeras. Ovan hade vi aposterioroddset. Vi kan också definiera apriorioddset

$$\frac{P(\Theta \in \Omega_0)}{P(\Theta \in \Omega_1)},$$

dvs. oddset enligt apriorifördelningen. Om vi tar kvoten mellan aposterioroddset och apriorioddset får vi *bayesfaktorn*

$$\frac{P(\Theta \in \Omega_0 | X = x) / P(\Theta \in \Omega_1 | X = x)}{P(\Theta \in \Omega_0) / P(\Theta \in \Omega_1)} = \frac{P(\Theta \in \Omega_0 | X = x) P(\Theta \in \Omega_1)}{P(\Theta \in \Omega_1 | X = x) P(\Theta \in \Omega_0)}.$$

Tanken är att reducera inflytandet av apriorifördelningen och fokusera på hur observationerna påverkar förhållandet mellan hypoteserna. Apriorifördelningen har så klart en påverkan (förutom fallet med "enkla hypoteser" $\Omega_0 = \{\theta_0\}$ och $\Omega_1 = \{\theta_1\}$), men *bayesfaktorn* gör denna påverkan mindre kännbar.

Exempel 9.6. Antag att vi mäter kvaliteten hos komjölk på en indexerad skala där 100 är medelvärdet över hela populationen. Vi har en apriorifördelning $\Theta \sim N(100, 15^2)$ och en datafördelning $X | \Theta = \theta \sim N(\theta, 10^2)$.

Nu vill vi testa om ett visst prov ligger under eller över medelvärdet. Vi har då $H_0 : \theta > 100$ och $H_1 : \theta \leq 100$. Eftersom apriorifördelningen är symmetrisk runt 100 har vi att apriorioddset är ett. Vi observerar $X = 115$ och aposteriorifördelningen är då $N(110.39, 69.23)$. Detta ger aposterioroddset:

$$\frac{P(\Theta > 100 | X = 115)}{P(\Theta \leq 100 | X = 115)} \approx \frac{0.894}{0.106} \approx 8.44.$$

Eftersom apriorioddset är lika med ett får vi också att bayesfaktorn är lika med 8.44. Detta är en ganska stor bayesfaktor och indikerar att hypotesen H_0 sannolikt stämmer.

9.2.4 Punkthypoteser för kontinuerliga parametrar

En sak som skiljer sig mellan bayesiansk och frekventistiskt hypotesprövning är hur man behandlar punkthypoteser, dvs. hypoteser på formen $H_0 : \theta = \theta_0$, för kontinuerliga parametrar. Inom det frekventistiska ramverket är det vanligt att specificera nollhypotesen $H_0 : \theta = \theta_0$ och jämföra denna med $H_1 : \theta \neq \theta_0$. För kontinuerliga variabler i bayesiansk inferens så fungerar inte detta eftersom vi alltid har $P(\theta = \theta_0) = 0$ och $P(\theta \neq \theta_0) = 1$, både i apriorifördelningen och aposteriorifördelningen.

Ett kontraargument är att punkthypoteser för kontinuerliga parametrar egentligen inte är rimliga för de flesta tillämpningar. Oftast så spelar det inte någon roll om ett parametervärde θ är exakt lika med θ_0 . Det som är viktigt är om θ ligger inom ett visst intervall runt θ_0 . Man kan då bilda hypotesen $H_0 : |\theta - \theta_0| \leq \epsilon$ för något $\epsilon > 0$. En sådan hypotes kan då ha positiv sannolikhet.

En annan möjlighet är att specificera en blandad apriorifördelning (blandad i och med att den är både diskret och kontinuerlig). I det fallet så antar vi att vi har två oberoende stokastiska variabler H och $Z \sim \text{Ber}(p)$ för någon $p > 0$ samt ett värde θ_0 så att

$$P(\Theta = \theta | Z = 1) = \begin{cases} 1, & \theta = \theta_0, \\ 0, & \text{annars.} \end{cases}$$

och

$$P(\Theta \leq \theta | Z = 0) = F_H(z),$$

dvs. att $\Theta = \theta_0$ om $Z = 1$ och $\Theta = H$ om $Z = 0$. I detta fall har vi en positiv sannolikhet p att $\Theta = \theta_0$ och med sannolikhet $1 - p$ har den en annan (kontinuerlig) fördelning.

9.3 Uppgifter

- 9.1.** [1] Låt $X | \Theta = \theta \sim N(\theta, 1)$ och låt $\hat{\Theta}$ vara bayesskattningen av Θ med avseende på medelkvadratfelet (under en viss apriorifördelning för Θ). Beräkna och plotta riskfunktionerna $R(\theta, \hat{\theta})$ för $\Theta \sim N(0, 1)$ och $\Theta \sim N(0, 10)$. Hur påverkar apriorifördelningen denna riskfunktion?

- 9.2. [2] En så kallad LINEX-förlustfunktion (linjär-exponentiell) är en asymmetrisk förlustfunktion som hanterar asymmetrier på ett kontinuerligt sätt. Den ges av

$$L(\theta, a) = e^{c(a-\theta)} - c(a - \theta) - 1$$

för något $c > 0$. Om man varierar c kan man gå från en mycket asymmetrisk förlustfunktion till en som nästan är symmetrisk.

- (a) Plotta $L(\theta, a)$ som en funktion av $a - \theta$ för $c = 0.1, 0.5$, och 1 .
 (b) Om X är en kontinuerlig stokastisk variabel med betingad täthetsfunktion $f_{X|\Theta}(x | \theta)$, visa att bayesskattningen ges av

$$-\frac{1}{c} \log E[e^{-c\Theta} | X].$$

- (c) Låt $X_1, \dots, X_n$ vara betingat oberoende givet Θ med $X_i | \Theta = \theta \sim N(\theta, \sigma^2)$ för $i = 1, \dots, n$ och σ^2 känt. Antag vidare att Θ har den icke-informativa apriorifördelningen $f_{\Theta}(\theta) \propto 1$. Visa att bayesskattningen i detta fall är lika med

$$\bar{X} - \frac{c\sigma^2}{2n}.$$

Tolka resultatet.

- 9.3. [1] Antag att Θ procent av den röstberättigade befolkningen som tänker rösta på ett visst parti har varierat under året före valet enligt fördelningen $\Theta \sim N(2.8, 0.68)$. En månad innan valet görs en ny opinionsundersökning där partiet får 5.1 procent stöd. Om vi antar att denna sista mätning har fördelningen $X | \Theta = \theta \sim N(\theta, 0.26)$, ange bayesfaktorn för H_0 : partiet ligger över 4%-spärren gentemot H_1 : partiet ligger under 4%-spärren.

- 9.4. [2] En oljeborrare försöker bestämma hur han ska finansiera nästa oljeborrhål. Det kostar 1 000 000 kronor att borra och han har tre val: a_1 , finansiera borrhålet själv och behålla all vinst, a_2 , ta 700 000 kr från investerare och ge dem 50% av vinsten och a_3 , ta 1 200 000 kr från investerare och ge dem 90% av vinsten. Givet θ fat olja från borrhålet beräknas vinsten vara 30θ kr. Från tidigare borrhål vet vi att $\theta = 0$ med sannolikhet 0.9 och för $\theta > 0$ har vi täthetsfunktionen

$$f_{\Theta}(\theta) = \frac{0.1}{300000} e^{-\theta/300000}.$$

Ett seismiskt test har gjorts för att ge en uppfattning om eventuella oljefyndigheter. Detta test identifierar den geologiska struktur X som återfinns i marken och kan ta värdet x_1, x_2 eller x_3 . Sannolikheten att en av dessa strukturer återfinns beror i sin tur på θ , med den betingade sannolikhetsfunktionen

$$f_{X|\Theta}(x | \theta) = \begin{cases} 0.8e^{-\theta/100000}, & X = x_1, \\ 0.2, & X = x_2, \\ 0.8(1 - e^{-\theta/100000}), & X = x_3. \end{cases}$$

- (a) Vilken finansiering ska borrharen välja om x_1 observeras (och han vill maximera sin egen vinst)?
 (b) Vilken finansiering ska han välja om x_2 och x_3 observeras?
- 9.5. [1] En student ska på fest men är osäker på om det är overall eller vanlig klädsel som gäller. Han antar därför att andelen overallbärande festdeltagare Θ är likformigt fördelad över $[0, 1]$. På väg hem för att byta om ser han en annan student som ska på festen iklädd overall. Han måste nu göra ett val, att sätta på sig sin overall (a_1) eller inte (a_2). Han vill inte sticka ut, så om han tillhör majoriteten av studenterna på festen (med avseende på klädsel) är hans förlustfunktion noll. Däremot tycker han att det är fyra gånger så pinsamt att ha overall om majoriteten av studenterna inte har det jämfört med tvärtom. Beräkna kvoten mellan aposterioririsken för a_1 och a_2 och bestäm det optimala valet. Antag nu att han ser en till overallklädd student som ska på festen. Hur påverkar detta beslutet? (Antag att detta är en stor fest.)

- 9.6. [1] Ett av dina två småsyskon har ätit av ditt lördagsgodis. Du hade köpt 31 godisbitar och när du räknade de senare under dagen fick du det till 20 bitar. Från tidigare vet du att det yngre lillasyskonet är fyra gånger mer benäget att stjäla godis än den äldre (vi antar att det inte är möjligt att båda stal ditt godis). Du vet också att det yngre syskonet i regel äter mindre godis, med en fördelning på $Po(8)$ godisbitar, jämfört med det äldre syskonet, som har en fördelning på $Po(12)$ bitar. Beräkna aposterioroddsen för att det var det yngre syskonet som åt ditt godis.
- 9.7. [1] Från perturbationer i omloppsbanan hos en närliggande sol ska massan Θ_M av en neutronstjärna skattas. Fem observationer 1.2, 1.6, 1.3, 1.4 och 1.4 erhålls. Antag att dessa data är betingat oberoende givet $\Theta_M = \theta_M, \Theta_V = \theta_V$ med den betingade fördelningen $N(\theta_M, \theta_V)$ och att (Θ_M, Θ_V) har den icke informativa fördelningen som ges av $f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) \propto 1/\theta_V$. Vi skulle vilja testa hypotesen $H_0 : \theta \leq 1$ mot $H_1 : \theta > 1$. Beräkna aposteriorisannolikheten för de två hypoteserna, aposterioroddsen och bayesfaktorn.
- 9.8. [2] Du har hittat ett objekt (handblåst dricksglas från Reijmyre glasbruk) på en onlineauktion som du gärna skulle vilja ha. På sidan lägger man in ett maxbud som sedan jämförs med andra maxbud. Från tidigare erfarenhet vet du att de flesta köpare lägger in sina maxbud strax innan auktionen stänger (så kallad "bid sniping") för att undvika budgivningskrig. Du planerar därför att göra detsamma men måste välja ett bra maxbud för att se till att du vinner auktionen. Liknande objekt har sålts på samma auktionssida med slutpriser vars medelvärde är 700 kr och standardavvikelse 300 kr. Du observerar också att utropspriserna ligger i genomsnitt 20% under slutpriserna, med en standardavvikelse på 100 kr. Objektet du är intresserad av har ett utropspris på 600 kr. Då du är speciellt intresserad av detta objekt (det skulle fullända din samling av Reijmyre-glas) är du villig att betala en viss premium för att vinna. Av denna anledning värderar du varje krona under det förväntade slutpriset tio gånger så mycket som en krona över slutpriset. Vilket pris borde du ange som maxbud?
- 9.9. [1] Antag att en stor order reservdelar har mottagits hos en bilreparatör. Fem delar väljs ut för att testa för defekter. Antalet defektiva reservdelar X , antas ha fördelningen $\text{Bin}(5, \theta)$ givet $\Theta = \theta$. Från tidigare ordrar vet vi att $\Theta \sim \text{Beta}(1, 9)$. Låt a_0 beteckna handlingen "bestäm $0 \leq \theta \leq 0.15$ " medan a_1 betecknar "bestäm $\theta > 0.15$ ". Utför ett bayestest givet datat $x = 0$ under följande förlustfunktioner
- (a) 0-1-förlust
- (b) $L(\theta, a_0) = \begin{cases} 1, & \text{if } \theta > 0.15, \\ 0, & \text{if } \theta \leq 0.15. \end{cases} \quad L(\theta, a_1) = \begin{cases} 0, & \text{if } \theta > 0.15, \\ 2, & \text{if } \theta \leq 0.15. \end{cases}$
- (c) $L(\theta, a_0) = \begin{cases} 1, & \text{if } \theta > 0.15, \\ 0, & \text{if } \theta \leq 0.15. \end{cases} \quad L(\theta, a_1) = \begin{cases} 0, & \text{if } \theta > 0.15, \\ 0.15 - \theta, & \text{if } \theta \leq 0.15. \end{cases}$
- 9.10. [2] En maskin har utvecklats som ska klassificera blodprover enligt blodtyp A, B, AB eller O. Maskinen mäter kvantiteten X som har den betingade täthetsfunktionen

$$f_{X|\Theta}(x | \theta) = e^{-(x-\theta)} 1_{(\theta, +\infty)}(x).$$

Om $0 < \theta < 1$ så är blodtypen AB; om $1 < \theta < 2$ så är den A; om $2 < \theta < 3$ är den B; och om $\theta > 3$ så är den O. Inom hela populationen har Θ fördelningen som ges av

$$f_{\Theta}(\theta) = e^{-\theta} 1_{(0, +\infty)}(\theta).$$

Förlustfunktionen för ges av följande tabell, där varje rad motsvarar den sanna blodtypen och varje kolonn motsvarar dess klassificering.

	AB	A	B	O
AB	0	1	1	2
A	1	0	2	2
B	1	2	0	2
O	3	3	3	0

Om vi observerar $x = 4$, vad är bayesbeslutet?

- 9.11. [2] Antag att vi skattar $\Theta = [\Theta_1, \Theta_2, \dots, \Theta_d]^T$ och har en kvadratisk förlustfunktion

$$L(\theta, a) = (\theta - a)^T Q (\theta - a)$$

för någon positivt definit $Q \in \mathbb{R}^{d \times d}$. Visa att bayesskattningen av Θ då ges av det betingade

$$E[\Theta \mid X = x].$$

(Antag att alla relevanta integraler existerar.)

- 9.12. [3] Antag att du har en ren signal $\mathbf{X} = [X_1, \dots, X_n]^T$ som är kontaminerad av oberoende brus $\mathbf{Z} = [Z_1, \dots, Z_n]^T$ för att ge den observerade signalen

$$\mathbf{Y} = \mathbf{X} + \mathbf{Z}.$$


Du vet sedan tidigare att $\mathbf{X}$ har väntevärde $\mathbf{0}$ och kovarians $\Sigma \in \mathbb{R}^{n \times n}$ medan $Z_1, \dots, Z_n$ är oberoende och likafördelade med $Z_i \sim N(0, \sigma^2)$ för $i = 1, \dots, n$ där $\sigma^2 > 0$. Problem att skatta $\mathbf{X}$ givet $\mathbf{Y}$ kallas för *avbrusning*.

- (a) Beräkna väntevärdet och kovariansen för $\mathbf{Y}$.
 (b) Givet kvadratfelet $L(\mathbf{x}, \hat{\mathbf{x}}) = \|\hat{\mathbf{x}} - \mathbf{x}\|^2$ som förlustfunktion, antag att vi begränsar oss till linjära skattningar $\hat{\mathbf{x}} = A\mathbf{y}$, dvs. vi söker A så att

$$E[L(\mathbf{X}, A\mathbf{Y})]$$

minimeras. Visa att $A = \Sigma(\Sigma + \sigma^2 \mathbf{I})^{-1}$. Detta kallas för den *linjära MMSE-skattningen* (MMSE står för “minimum mean square error” dvs. minimala medelkvadratfelet).

- (c) Antag nu att $\mathbf{X}$ också är normalfördelad (simultant med $\mathbf{Z}$). Givet samma förlustfunktion, visa att bayesskattningen för $\mathbf{X}$ givet $\mathbf{Y} = \mathbf{y}$ är densamma som du tog fram i del (b).
 (d) Vi antar att Σ diagonaliseras som $\Sigma = \sum_{i=1}^n \lambda_i^2 \mathbf{v}_i \mathbf{v}_i^T$ för $\lambda_i^2 > 0$ och $\mathbf{v}_i \in \mathbb{R}^n$ där $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ bildar en ortonormal bas för $\mathbb{R}^n$. Skriv om bayesskattningen ovan i basen $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ och beskriv hur dess beteende beror på egenvärdena $\lambda_1^2, \lambda_2^2, \dots, \lambda_n^2$. Denna form kallas ofta för *Wienerfilter*.
 (e) Antag nu att vi observerar signalen nedan:



Ladda ner den observerade signalen och beräkna Wienerfilter-skattningen ovan givet $\Sigma = [e^{-(i-j)^2/2 \cdot 2^2}]_{i,j=1}^n$. Jämför med den sanna signalen och beräkna brusreduktionen jämfört med den observerade signalen.

Kapitel 10

10.1 Monte Carlo-metoden

På flera ställen hittills har vi stött på uttryck på formen

$$E[h(X)]$$

för någon funktion $h : \mathbb{R} \rightarrow \mathbb{R}$ och stokastisk variabel X , dvs. väntevärden (betingade eller inte) som måste beräknas. Inom bayesiansk inferens har vi till exempel aposterioriväntevärden och aposteriorivarianser, men också svanssannolikheter som kan skrivas om som väntevärden

$$P(\Theta > \theta_0 \mid X = x) = E[\mathbf{1}_{(-\infty, \theta_0]}(\Theta) \mid X = x],$$

där $\mathbf{1}_A(x)$ avser indikatorfunktionen på A (dvs. funktionen som är ett för $x \in A$ och noll annars). Vi kan också leta efter intervall som definieras enligt sådana väntevärden. Till exempel kallas den bayesianska analogin till ett konfidensintervall för ett *kredibilitetsintervall* vilket beräknas utifrån aposteriorifördelningen $\Theta \mid \mathbf{X} = \mathbf{x}$. Ett exempel på ett kredibilitetsintervall är det $(1 - \alpha)$ *symmetriska kredibilitetsintervallet* (eller *aposterioriintervallet*) som är intervallet $[a, b]$ där

$$P(\Theta \leq a \mid X = x) = \alpha/2 \quad \text{och} \quad P(\Theta \geq b \mid X = x) = \alpha/2,$$

vilket är ekvivalent med att invertera funktionerna

$$a \mapsto P(\Theta \leq a \mid X = x) = E[\mathbf{1}_{(-\infty, a]}(\Theta) \mid X = x]$$

och

$$b \mapsto P(\Theta \geq b \mid X = x) = E[\mathbf{1}_{[b, +\infty)}(\Theta) \mid X = x].$$

Liknande frågeställningar uppstår också inom frekventistisk inferens när vi söker kritiska värden för hypotestest eller gränser för konfidensintervall. (Ni har förmodligen redan sett hypotestest och konfidensintervaller i en föregående kurs men vi kommer också att diskutera dessa koncept senare.)

Ibland kan dessa väntevärden beräknas genom direkt integration eller summering (även om det kan vara svårt ibland). I vissa fall kan vi använda trick som lagen om total förväntan eller lagen om total varians. Men ibland är det inte möjligt att beräkna dessa väntevärden för hand.

Då krävs det numeriska approximationer av väntevärdet. För diskreta stokastiska variabler innebär detta att utvärdera summan

$$E[h(X)] = \sum_{x=0}^{+\infty} h(x)f_X(x),$$

vilket ofta är ganska smärtfritt. För kontinuerliga stokastiska variabler har vi däremot integralen

$$E[h(X)] = \int_{\mathbb{R}} h(x)f_X(x)dx,$$

som kan vara svårare att approximera. Ett tillvägagångssätt är att tillämpa numeriska metoder som kvadraturregler där värdet hos integralen kan beräknas upp till en godtycklig felmarginal. Detta kan dock vara tidskrävande både med avseende på implementering och exekvering, speciellt när antalet dimensioner är stort.

Ett problem med kvadraturregler (och andra numeriska integrationsmetoder) är att integralen påverkas mer av de värden där $f_X(x)$ är stor, dvs. de värden på X som har större sannolikhet. Kvadraturregler approximerar alla delar av integranden med samma precision och kan på det sättet vara ineffektiv från en beräkningssynpunkt. Bättre vore att lägga mer fokus på de värden där $f_X(x)$ är stor än på de värden där $f_X(x)$ är liten.

Ett sätt att göra detta är att sampla flera stokastiska variabler $X_1, \dots, X_k$ med samma fördelning som X och beräkna summan

$$H_k = \frac{1}{k} \sum_{i=1}^k h(X_i).$$

Enligt stora talens lag har vi att H_k konvergerar till $E[h(X)]$ när $k \rightarrow +\infty$, mer specifikt att $P(|H_k - E[h(X)]| < \epsilon) \rightarrow 1$ för varje $\epsilon > 0$. Med centrala gränsvärdessatsen har vi ett starkare resultat där vi får att H_k har den approximativa fördelningen

$$N(E[h(X)], \text{Var}[h(X)]/k)$$

när k är tillräckligt stort. Eftersom $\text{Var}[h(X)]$ inte är känd här (att beräkna denna analytiskt är minst lika svårt som att beräkna $E[h(X)]$) approximerar vi den med

$$\frac{1}{k} \sum_{i=1}^k (h(X_i) - H_k)^2.$$

Vi delar med k för att approximera variansen av H_k och tar kvadratroten för att få medelfelet

$$\sqrt{\frac{1}{k} \cdot \frac{1}{k} \sum_{i=1}^k (h(X_i) - H_k)^2} = \frac{1}{k} \sqrt{\sum_{i=1}^k (h(X_i) - H_k)^2}.$$

Detta kan användas för att utvärdera noggrannheten i skattningen av $E[h(X)]$.

Metoden ovan brukar kallas för *Monte Carlo-metoden*. Namnet kommer från forskningsprojektet där metoden utvecklades under andra världskriget. Den ursprungliga tillämpningen var nämligen simulering av neutrondiffusion i en atombomb, forskning som var strikt sekretessbelagd och därför krävde ett kodnamn. En av forskarna hade en släkting som brukade spela bort sina (och släktens) pengar på kasinot i Monte Carlo och detta i kombination med metodens användning av slumpmässighet gav upphov till namnet.

Exempel 10.1. Låt oss återgå till Exempel 9.5 (skattning av vindhastighet för småskalig vindkraft) där vi tog fram aposteriorifördelningen

$$V \mid \mathbf{X} = \mathbf{x} \sim t(6, 4.68, 0.31).$$

Aposterioriväntevärdet $E[V \mid \mathbf{X} = \mathbf{x}]$ är här enkelt att få ut och är lika med 4.68, men det som intresserade oss var $E[V^3 \mid \mathbf{X} = \mathbf{x}]$ (eftersom detta var en term i vår aposterioririsk).

Om vi approximerar $E[V^3 \mid \mathbf{X} = \mathbf{x}]$ med Monte Carlo-metoden och varierar antalet utfall k får vi följande tabell:

k	approximation	approximationsfel
1000	109.05	1.55
10000	109.42	0.478
100000	109.07	0.158
1000000	108.97	0.0490

Beroende på användningsområdet kan det alltså räcka med 10000 eller 100000 utfall för att få en bra approximation.

På samma sätt kan vi approximera sannolikheten $P[V^3 > 100 \mid \mathbf{X} = \mathbf{x}]$ genom att räkna antalet utfall som uppfyller $v^3 > 100$. Vi får då

k	approximation	approximationsfel
1000	0.506	0.0158
10000	0.523	0.00499
100000	0.528	0.00158
1000000	0.527	0.000499

Sannolikheten verkar alltså ligga runt 0.53 och det räcker återigen med 10000 eller 100000 utfall.

Till slut kan vi skapa symmetriska kredibilitetsintervall genom att sortera utfallen och välja värdena på plats $(\alpha/2)k$ och $(1-\alpha/2)k$ för $\alpha = 0.05$. Här är det svårare att approximerar felet, men vi kan ändå se en viss konvergens när vi ökar antalet utfall:

k	approximation
1000	[31.4, 224]
10000	[35.6, 223]
100000	[36.4, 221]
1000000	[36.5, 221]

(I detta fall kan vi beräkna kredibilitetsintervallen explicit eftersom $v \mapsto v^3$ är en monoton funktion och det därför räcker att transformera kredibilitetsintervallet för V .)

10.2 Förkastelsemetoden

Hjärtat i alla Monte Carlo-approximationer är en metod för att generera utfall från en viss fördelning. I Kapitel 1 såg vi en grundläggande samplingalgorithm, inversionsmetoden, som gav oss ett sätt att generera utfall från fördelningar vars fördelningsfunktioner kunde inverteras enkelt. Vi såg också Box–Muller-metoden som används för att generera utfall från den standardiserade normalfördelningen. Dessa metoder går ibland under benämningen *direkta samplingmetoder* eftersom de genererar utfall för en fördelning utifrån utfall från en enklare fördelning (som den likformiga fördelningen $U(0,1)$) genom variabeltransformation. Samplingmetoder som inte är på denna form kallas för *indirekta samplingmetoder* och kan användas för mer allmänna fördelningar.

En av de mer kraftfulla metoderna av detta slag är *förkastelsemetoden* (alternativt acceptans–förkastelsemetoden eller acceptans–förkastelsesampling). Vi illustrerar denna algoritm med ett exempel.

Låt oss först anta att vi har en fördelning med ändligt stöd $[a, b]$ och täthetsfunktion $f(x)$. Detta kan, till exempel, vara en Beta(α, β)-fördelning när α och β inte är heltal (till exempel $\alpha = 2.7$, $\beta = 6.3$). I samband med inversionsmetoden såg vi att betafördelningen för heltalsparametrar kan simuleras med utfall från gammafördelningen, vilka i sin tur kan simuleras med exponentialfördelade utfall och exponentialfördelningen kan simuleras med hjälp av inversionsmetoden. Med godtyckliga positiva parametrar fungerar tyvärr inte denna metod (samma problem uppstår om vi vill simulera en gammafördelning med en formparameter som inte är ett heltal).

Istället betraktar vi mängden

$$B = \{[x, u]^T : x \in [a, b], 0 \leq u \leq f(x)\}.$$

Vi påstår nu att om vi tar en punkt $[x, u]^T$ på måfå inom B , dvs. vi genererar ett utfall från den likformiga fördelningen över B , så har X täthetsfunktionen $f(x)$ (dvs. när vi marginaliserar bort U).

Vi har alltså den simultana täthetsfunktionen

$$f_{X,U}(x, u) = \mathbf{1}_B(x, u) = \mathbf{1}_{[a,b]}(x)\mathbf{1}_{[0,f(x)]}(u).$$

Detta ger då för $x \in [a, b]$ att

$$f_X(x) = \int_{\mathbb{R}} f_{X,U}(x, u) du = \int_{\mathbb{R}} \mathbf{1}_B(x, u) du = \int_{\mathbb{R}} \mathbf{1}_{[0,f(x)]}(u) du = \int_0^{f(x)} 1 du = f(x).$$

Vi kan då säga att sampling från täthetsfunktionen $f(x)$ är detsamma som sampling av $[X, U]^T$ likformigt från $B = \{[x, u]^T : x \in [a, b], 0 \leq u \leq f(x)\}$. Detta faktum kallas ibland för *simuleringens fundamentalsats*.

Men hur hjälper detta oss? Jo, att sampla från en likformig fördelning över B är (relativt) enkelt. Nyckeln är att välja en större mängd R som innehåller B men där sampling från den likformiga fördelningen över R kan göras med standardmetoder. Sedan behåller vi endast de utfall som ligger i B (och *förkastar* de värden som hamnar i $R \setminus B$, därav namnet).

Till exempel kan vi välja

$$R = [a, b] \times [0, m],$$

där $m \geq f(x)$ för alla $x \in [a, b]$. Om vi då tar $V \sim U(a, b)$ och $U \sim U(0, 1)$ så har vi att (V, mU) är likformigt fördelat över R .

Låt oss nu anta att vi har en punkt (V, mU) från den likformiga fördelningen över R . Om $(V, mU) \in B$ behåller vi alltså utfallet, annars genererar vi ett nytt utfall och börjar om. Vi fortsätter tills vi erhåller ett utfall inom B . När vi väl har detta så sparar vi V som ett utfall av X .

Algoritmen är alltså följande:


- (1) Generera $V \sim U(a, b)$ och $U \sim U(0, 1)$.
- (2) Om $U < f_X(V)/m$, sätt $X = V$ och terminera, annars gå tillbaka till (1).

Vi terminerar alltså bara om $U < f_X(V)/m$, vilket betyder att sannolikheten att X antar ett visst värde är betingat på händelsen $U < f(V)/m$. Detta ger

$$\begin{aligned} P(X \leq x) &= P(V \leq x \mid U < f(V)/m) \\ &= \frac{P(V \leq x, U < f(V)/m)}{P(U < f(V)/m)} \\ &= \frac{\int_a^x \int_0^{f(v)/m} du dv}{\int_a^b \int_0^{f(v)/m} du dv} = \frac{\int_a^x \frac{f(v)}{m} dv}{\int_a^b \frac{f(v)}{m} dv} \\ &= \frac{\int_a^x \frac{f(v)}{m} dv}{\frac{1}{m}} = \int_a^x f(v) dv. \end{aligned}$$

Med andra ord har den genererade X den sökta fördelningsfunktionen.



Exempel 10.2. Vi illustrerar algoritmen ovan med ett enkelt exempel. Anta att vi vill ta fram ett slumpmässigt utfall från en $\text{Beta}(2.7, 3.6)$ -population. En stokastisk variabel X med denna fördelning har täthetsfunktion



Vi ser från figuren att $f(x) \leq 2$ för alla $0 \leq x \leq 1$ och därför låter vi $m = 2$. Eftersom $f_X(x)$ har stöd $[a, b]$ där $a = 0$, och $b = 1$ genererar vi två oberoende utfall $u = 0.1896, v = 0.9870$ från $U(0, 1)$ och avgör om $u < f_X(v)/m$. I vårt exempel är olikheten inte uppfylld eftersom $u = 0.1896 > 0.0002 = f_X(0.9870)/2$. Vi upprepar processen tre gånger och hittar ett par u, v som uppfyller olikheten vid den tredje iterationen. Resultatet är $x = 0.34$ vilket är ett slumpmässigt utfall från $\text{Beta}(2.7, 3.6)$ -populationen enligt ovan. Vi kan sammanfatta algoritmens steg med följande tabell:

steg	1	2	3
u	0.1896	0.0174	0.8886
v	0.9870	0.9788	0.3389
$f_X(v)/m$	0.0002	0.0008	0.9522
beslut	förkasta	förkasta	acceptera

Vi kan också ta ett större värdet för m , exempelvis $m = 5$. I detta fall får vi utfallet från $\text{Beta}(2.7, 3.6)$ efter 7 iterationer. Det är intuitivt att det tar lite längre eftersom vi genererar utfall från $U([0, 1] \times [0, 5])$ och det finns mer yta under $g(x) = 5$ som inte är under $f_X(x)$ än jämfört med $g(x) = 2$:



Som visade i Exempel 10.2 är risken med denna metod att den kan kräva ett stort antal försök (generering av punkter från den likformiga fördelningen på R) innan ett värde accepteras. Notera att sannolikheten att acceptera paret (V, U) ges av

$$P(U \leq f(V)/m) = \int_a^b \int_0^{f(v)/m} du dv = \int_a^b \frac{f(v)}{m} dv = \frac{1}{m}.$$

Antalet försök N innan vi accepterar ett par har alltså en $\text{Geom}(1/m)$ -fördelning. Dess väntevärde är

$$E[N] = (1/m)^{-1} = m.$$

Exempel 10.3. Vi återgår till Exempel 10.2. Vi upprepar algoritmen 2000 gånger för $m = 2$ och $m = 5$ och observerar antalet iterationer R_2 och R_5 som behövs innan vi respektive accepterar. Detta ger stickprovmedelvärdena

$$\bar{r}_2 = 2.0015 \approx 2 \quad \text{och} \quad \bar{r}_5 = 5.019 \approx 5.$$

Vi måste i genomsnitt alltså generera m utfall av (V, U) för att generera ett enda utfall av X enligt förkastelsemetoden. Därför är det viktigt att vi väljer m så litet som möjligt. Eftersom vi måste ha $m \geq f(x)$ för alla $x \in [a, b]$ får vi då

$$m = \max_{x \in [a, b]} f(x).$$

Ofta kan detta värde beräknas analytiskt. Till exempel har vi i Exempel 10.2 $\max_{x \in [0, 1]} f(x) = 1.9620$ vilket är lite mindre än $m = 2$. Om det kan inte beräknas analytiskt kan det approximeras genom att beräkna $f(x)$ på ett finmaskigt rutnät och ta det största värdet.

För en given täthetsfunktion $f(x)$ kan vi dock inte komma ifrån faktumet att fördelningar som är mer koncentrerade i en viss punkt (och därför har ett stort maxvärde) leder till mindre effektiva implementeringar av förkastelsemetoden. Detta är ganska naturligt då komplementet $R \setminus B$ är större och vi oftare hamnar utanför B när vi genererar punkter på R .

Ett sätt att effektivisera metoden att välja R så att följande kriterier uppfylls:

- (i) Vi kan (enkelt) sampla från den likformiga fördelningen på R ,
- (ii) $B \subset R$ och
- (iii) $R \setminus B$ är liten.

Antag att vi har en annan fördelning med täthetsfunktion $g(x)$ så att

$$f(x) \leq mg(x)$$

för alla $x \in \mathbb{R}$ och något $m \geq 1$. Vi kan då definiera

$$R = \{(x, u) : 0 \leq u \leq mg(x)\}.$$

Eftersom $f(x) \leq mg(x)$ har vi att $B \subset R$ och om m är litet så är komplementet $R \setminus B$ litet. Vi uppfyller alltså (ii) och (iii).

Om vi enkelt kan sampla från $g(x)$ uppfyller vi även (i). Vi tar då v från $g(x)$ och u där $U \sim U(0, 1)$ och bildar

$$[v, mg(v)u]^T.$$

Enligt samma argument som för simuleringens fundamentalsats är detta par likformigt fördelat över R .

Om vi sätter ihop detta får vi följande algoritm:

- (1) Generera V från $g(x)$ och $U \sim U(0, 1)$ oberoende.
- (2) Om $mg(V)U \leq f(V)$, dvs. om $U \leq f(V)/mg(V)$, sätt $X = V$ och terminera, annars gå tillbaka till steg (1).

Detta kallas alltså *förkastelsemetoden* med *kandidatfördelning* $g(x)$ och *målfördelning* $f(x)$.

Återigen får vi att fördelningsfunktionen för X ges av fördelningsfunktionen för V betingad på händelsen $U \leq f(V)/mg(V)$, så vi har

$$\begin{aligned} P(X \leq x) &= P(V \leq x \mid U \leq f(V)/mg(V)) \\ &= \frac{P(V \leq x \mid U \leq f(V)/mg(V))}{P(U \leq f(V)/mg(V))} \\ &= \frac{\int_{-\infty}^x \int_0^{f(v)/mg(v)} du g(v) dv}{\int_{-\infty}^{+\infty} \int_0^{f(v)/mg(v)} du g(v) dv} \\ &= \frac{\int_{-\infty}^x \frac{f(v)}{m} dv}{\int_{-\infty}^{+\infty} \frac{f(v)}{m} dv} = \frac{\int_{-\infty}^x \frac{f(v)}{m} dv}{\frac{1}{m}} = \int_{-\infty}^x f(v) dv \end{aligned}$$

Vi får alltså den sökta fördelningsfunktionen.

Ett par aspekter av denna metod är värda att diskutera. Först så har vi inte längre någon begränsning av fördelningens stöd. Så länge $g(x)$:s stöd har $f(x)$:s stöd som delmängd fungerar algoritmen. (Det tidigare kravet att $f(x)$ måste ha ändligt stöd berodde på valet av kandidatfördelning $U(a, b)$.)

Sedan har vi att sannolikheten att acceptera paret $[V, U]^T$ nu ges av

$$P(U \leq f(V)/mg(V)) = \int_{-\infty}^{+\infty} \int_0^{f(v)/mg(v)} du g(v) dv = \int_{-\infty}^{+\infty} \frac{f(v)}{m} dv = \frac{1}{m}.$$

Så antalet förväntade försök är $(1/m)^{-1} = m$. Vi vill alltså återigen välja m så litet som möjligt men så att $f(x) \leq mg(x)$ för alla $x \in \mathbb{R}$. Det naturliga valet är då


$$m = \sup_{x \in \mathbb{R}} \frac{f(x)}{g(x)}.$$

Som tidigare kan detta ofta beräknas analytiskt men vi kan också approximera m genom att utvärdera kvoten $f(x)/g(x)$ på ett finmaskigt rutnät och välja det största värdet.

Exempel 10.4. Vi återgår till Exempel 10.2 där vi vill generera ett utfall av $X \sim \text{Beta}(2.7, 3.6)$. I det där exemplet tog vi $g(x) = f_Z(x)$ där $Z \sim U(0, 1)$ och $m = 2$ (resp. $m = 5$). Istället kan vi ta kandidatfördelning $g(x) = f_Z(x)$ där $Z \sim \text{Beta}(2, 3)$. Vi beräknar

$$m = \sup_{x \in \mathbb{R}} \frac{f_X(x)}{g(x)} \approx 1.2.$$

Följande figur visar att $f_X(x) \leq 1.2g(x)$ uppfylls för alla $0 \leq x \leq 1$:



Notera att ytan mellan $f_X(x)$ och $g(x)$ är nu mycket mindre än ytan mellan $f_X(x)$ och $g(x)$ i Exempel 10.2! Nu förväntar vi oss omkring $m = 1.2$ iterationer innan vi accepterar. När vi implementerar förkastelsemetoden accepterar vi utfallet $x = 0.228$ efter bara en enda iteration!

En av de viktigaste egenskaperna hos förkastelsemetoden är att täthetsfunktionen $f(x)$ *behöver inte vara normaliserad* (men den måste vara integrerbar). Låt

$$f(x) = cq(x)$$

för någon $c > 0$ där $q(x)$ är en (normaliserad) täthetsfunktion. Då har vi

$$f(x) \leq mg(x) \Leftrightarrow q(x) \leq \frac{m}{c}g(x),$$

och acceptanskriteriet blir

$$U \leq \frac{f(V)}{mg(V)} \Leftrightarrow U \leq \frac{q(V)}{\frac{m}{c}g(V)}.$$

Med andra ord är det enda som spelar roll för algoritmen kvoten

$$\frac{f(V)}{m} = \frac{q(V)}{m/c},$$

vilken är densamma i båda fall. Med andra ord kan vi multiplicera $f(x)$ med en godtycklig konstant, men detta betyder bara att vi multiplicerar m med samma konstant. (Notera dock att resultatet ovan angående det genomsnittliga antalet försök m innan acceptans bara håller när $f(x)$ är en normaliserad täthetsfunktion.)

Denna sista punkt blir speciellt viktig när vi genererar utfall från aposteriorifördelningar. I dessa fall så vill vi inte alltid beräkna normaliseringsfaktorn för täthetsfunktionen utan uttrycker ofta denna genom

$$f_{\Theta|X}(\theta | x) \propto f_{X|\Theta}(x | \theta)f_{\Theta}(\theta).$$

Med förkastelsemetoden kan vi helt enkelt använda oss av högerledet som det är utan att behöva ta fram normaliseringsfaktorn.


Exempel 10.5. Antag att vi har normalfördelad data där vi har t-fördelningen som apriorifördelning:

$$\begin{aligned} X|\Theta = \theta &\sim N(\theta, 0.8^2), \\ \Theta &\sim t(4, 2, 0.3) \end{aligned}$$


Då är apriorifördelningen inte konjugerad och vi kan inte enkelt generera utfall från aposteriorifördelningen. Vi använder istället numeriska metoder för att generera utfall. I detta exempel använder vi syntetiska data $\mathbf{x} = [x_1, \dots, x_{50}]^T$ genererade från en $N(0.4, 0.8^2)$ -fördelning. Den onormaliserade aposteriorifördelningen är

$$f_{\mathbf{X}}(\mathbf{x}|\theta)f_{\Theta}(\theta)$$

vilket ser ut som



Vi använder förkastelsemetoden med en cauchyfördelning som kandidatfördelning för att generera 1000 utfall från aposteriorifördelningen. Histogrammet och den skattade täthetsfunktion ser ut som:



Aposterioristickprovet $\theta_1, \dots, \theta_{1000}$ kan användas för att skatta aposterioriväntevärdet och aposterioristandardavvikelsen:

$$E[\Theta|\mathbf{x}] \approx \frac{1}{1000} \sum_{i=1}^{1000} \theta_i \approx 0.547 \quad \text{och} \quad \text{Std}[\Theta|\mathbf{x}] \approx \frac{1}{999} \sum_{i=1}^{1000} (\theta_i - E[\Theta|\mathbf{x}])^2 \approx 0.114.$$

Vi kan jämföra dessa med aposterioriväntevärdet och aposterioristandardavvikelsen för en normal apriorifördelning vilka kan beräknas analytiskt eftersom denna är konjugerad med avseende på datafördelningen:

$$E[\Theta|\mathbf{x}] = 0.695 \quad \text{och} \quad \text{Std}[\Theta|\mathbf{x}] = 0.105.$$

Vi kan också skatta ett $(1 - \alpha)$ symmetriskt kredibilitetsintervall för $\alpha = 0.05$ för aposteriorifördelningen med avseende på den t-fördelade apriorifördelningen. För att göra detta ordnar vi stickprovet $\theta_1, \dots, \theta_{1000}$ och tar det 25:de utfallet som undre gräns och det 975:de utfallet som övre gräns:

$$[0.318, 0.767].$$

Vi kan också skatta aposteriorisannolikheter, exempelvis

$$P(\Theta \leq 0.6 | \mathbf{X} = \mathbf{x}) \approx \frac{|\{\theta_i : \theta_i \leq 0.6\}|}{1000} = 0.679.$$

10.3 Markovkedje-Monte Carlo

Även om förkastelsemetoden som presenterades ovan är mycket kraftfull har den ett par potentiella nackdelar. Den första är att valet av kandidatfördelning inte alltid är enkelt och utöver behöver vi dessutom beräkna $m = \sup_{x \in \mathbb{R}} f(x)/g(x)$. För vissa fördelningar med hög sannolikhet att ta stora värden är det inte heller alltid möjligt att hitta möjliga kandidatfördelningar så att $m < +\infty$. Det kan också vara så att m är ändlig men så pass stor att algoritmen inte är effektiv. Detta är vanligt när vi arbetar med fler dimensioner.

Ett alternativ till förkastelsemetoden är en familj av algoritmer som kallas *markovkedje-Monte Carlo* (på engelska *Markov chain Monte Carlo* eller MCMC). Dessa är mer flexibla och ställer inte samma typ av krav som förkastelsemetoden utan kan köras utan större förberedelser. Priset är att vi inte längre kan garantera att vi exakt genererar utfall från den sökta täthetsfunktionen. MCMC skiljer sig alltså från inversions- och förkastelsemetoden som är *exakta* simuleringsmetoder utan ger en *approximativ* simulering. Oftast innebär inte detta några större problem, utan löses oftast genom mindre kalibreringssteg.

10.3.1 Markovkedjor

För att beskriva MCMC-metoder behöver vi introducera ett par begrepp. Först har vi en sekvens $X_0, X_1, \dots$ av stokastiska variabler så att

$$X_i \perp\!\!\!\perp X_0, X_1, \dots, X_{i-2} \mid X_{i-1}$$

för $i = 1, 2, \dots$. Med andra ord är den simultana fördelningen $\mathbf{X} = [X_1, X_2, \dots]^T$ markovska med avseende på grafen

$$X_0 \longrightarrow X_1 \longrightarrow \dots \longrightarrow X_{i-1} \longrightarrow X_i \longrightarrow \dots$$

och uppfyller

$$\begin{aligned} P(X_i \leq x_i \mid X_0 = x_0, X_1 = x_1, \dots, X_{i-1} = x_{i-1}) \\ = P(X_i \leq x_i \mid X_{i-1} = x_{i-1}) = K(x_i, x_{i-1}) \end{aligned}$$

för $i = 1, 2, \dots$ där $K : \mathbb{R}^2 \rightarrow \mathbb{R}$. Med andra ord så beror X_i på tidigare tillstånd endast genom X_{i-1} och detta beroende är detsamma för alla i . Denna sekvens är alltså entydigt definierad av X_0 's fördelning samt $K(x, y)$ och kallas för en *markovkedja*.

Ett exempel på en markovkedja är

$$X_{i+1} = X_i + Z_i$$

där $Z_i \perp\!\!\!\perp X_0, X_1, \dots, X_i$ och har samma fördelning för alla i . Detta kallas för en *slumpvandring*. Om Z_i har en symmetrisk fördelning kallas kedjan för en *symmetrisk slumpvandring*.

En vanlig egenskap hos markovkedjor är att de ofta har en *stationär fördelning* $p(x)$ så att

$$X_i \sim p(x) \Rightarrow X_{i+1} \sim p(x).$$

Om vi alltså börjar med $X_0 \sim p(x)$ så kommer alla element i kedjan ha samma fördelning $p(x)$.

Även om X_0 inte har den stationära fördelningen så gäller det ofta att X_i konvergerar till den stationära fördelningen när $i \rightarrow +\infty$. Många markovkedjor är också *ergodiska*, vilket betyder att

$$P\left(\left|\frac{1}{k} \sum_{i=0}^k h(X_i) - E[h(X)]\right| < \epsilon\right) \rightarrow 1$$

när $k \rightarrow +\infty$ för varje $\epsilon > 0$ där $X \sim p(x)$.

Denna sista egenskap är lik de stora talens lag, men skiljer sig väsentligt från denna. För det första så kräver stora talens lag att de stokastiska variablerna $X_1, X_2, \dots$ är oberoende och likafördelade, men detta gäller inte här. Resultatet är alltså mer generellt än stora talens lag. Anledningen till att detta fungerar beror på att X_i konvergerar till den stationära fördelningen $p(x)$ när $i \rightarrow +\infty$.

Idén med MCMC är nu att konstruera en markovkedja så att den stationära fördelningen har den täthetsfunktion vi vill simulera. Om vi lyckas med detta kan vi approximera olika väntevärden med hjälp av ergodicitetsresultatet ovan.

Innan vi går in på detta ska vi bara notera att markovkedjor också studeras för sin egen skull och har tillämpningar inom flera andra områden, som taligenkänning, sökmotorer, beräkningslingvistik, kompression, och optimering. Mer information kan fås i kursen SF1904.

10.3.2 Metropolisalgoritmen

Som innan, låt nu $f(x)$ vara täthetsfunktionen för någon målfördelning och låt $q(y \mid x)$ vara en betingad täthetsfunktion så att

$$q(y \mid x) = q(x \mid y)$$

(dvs. $q(y \mid x)$ är symmetrisk). Vi kallar $q(y \mid x)$ för en *hoppfördelning* (eller *förslagsfördelning*).

Vi skulle nu kunna definiera en markovkedja genom

$$X_i \mid X_{i-1} = x_{i-1} \sim q(x_i \mid x_{i-1}).$$

Denna kommer då konvergera till någon stationär fördelning som bara beror på $q(y \mid x)$. Eftersom vi vill att denna stationära fördelning ska ha en viss täthetsfunktion måste vi modifiera denna hoppfördelning på något sätt innan vi använder den i vår markovkedja.

Detta uppnås av *metropolisalgoritmen* som ges av

(1) Generera ett initialvärde X_0 (enligt någon fördelning)

(2) För $i = 1, 2, \dots$:

(2.1) Generera y där $Y \sim q(y \mid x_{i-1})$ (ett *förslag*)

(2.2) Sätt $R = f(y)/f(x_{i-1})$

(2.3) Generera u där $U \sim U(0, 1)$

(2.4) Om $u \leq \min(1, R)$, sätt $x_i = y$

(2.5) Annars sätt $x_i = x_{i-1}$

Det finns ett par ytliga likheter med förkastelsemetoden här, men algoritmen skiljer sig på ett flertal viktiga sätt.

Först så beror förslaget y på tidigare genererade värden. I förkastelsemetoden så var varje förslag oberoende av de andra. Denna länk med tidigare värden låter metropolisalgoritmen ”utforska” olika delar av utfallsrummet en bit i taget. Eftersom förslaget beror på tidigare värden har vi också ett beroende mellan successiva utfall.

Sedan så resulterar varje iteration i ett genererat utfall. Med andra ord så har vi ett nytt värde x_i även om förslaget förkastas. Här är detta värde lika med det föregående, men det räknas fortfarande som ett ”nytt” element i kedjan.

Vi kräver inte att hoppfördelningen $q(y | x)$ har någon speciell form med avseende på målfördelningen $f(x)$. På grund av detta behöver vi inte heller räkna ut någon konstant m för att algoritmen ska fungera. Med detta sagt så spelar formen på $q(y | x)$ roll för hur snabbt kedjan konvergerar till den stationära fördelningen.

En viktig likhet med förkastelsemetoden är däremot att $f(x)$ inte behöver vara normaliserad (men måste såklart vara integrerbar). Anledningen är att $f(x)$ endast återfinns på formen $f(y)/f(x_{i-1})$, så någon möjlig normaliseringsfaktor tar ut sig själv. Som sagt är detta mycket användbart när vi vill generera utfall från en aposteriorifördelning utan att normalisera denna.

Så vad gör denna algoritm? I varje iteration genererar den ett förslag y enligt $Y \sim q(y | x_{i-1})$. Vi kan se detta som att den ”hoppa” från ett tidigare värde x_{i-1} till något intelligande värde y i utfallsrummet. Sedan bildar den *acceptanskvoten*

$$R = \frac{f(y)}{f(x_{i-1})}$$

för att bestämma om förslaget ändrar sannolikheten jämfört med tidigare värde. Om $R \geq 1$ så har y högre sannolikhet och vi accepterar alltid förslaget (eftersom $U \leq 1 = \min(1, R)$).

Å andra sidan om $R < 1$ så accepterar vi bara förslaget med sannolikhet R . Om sannolikheten går ner mycket med avseende på x_{i-1} är det alltså osannolikt att vi accepterar. En mindre minskning har däremot större chans att accepteras.

Om det inte var för denna andra möjlighet (dvs. att vi förflyttar oss till ett område med lägre sannolikhet) så skulle markovkedjan konvergera till ett lokalt maximum av $f(x)$ och stanna där. Möjligheten att ”gå ner” i sannolikhet låter markovkedjan utforska en större del av utfallsrummet.

Nu påstår vi att den stationära fördelningen för markovkedjan som metropolisalgoritmen producerar har täthetsfunktion $f(x)$. Är detta sant?

För att visa detta krävs två egenskaper: existens och entydighet. Existens bevisas genom att visa att $f(x)$ är en stationär fördelning för kedjan. Med andra ord, givet $X_i \sim f(x)$ måste vi visa att $X_{i+1} \sim f(x)$. Detta reducerar till faktumet att $q(y | x) = q(x | y)$ och att sannolikheten att ”gå ner” exakt kompenserar hoppfördelningens bidrag.

Entydighet kräver ett mer tekniskt argument och beror på olika egenskaper hos hoppfördelningen $q(y | x)$ som att denna ska vara tillräckligt ”bred” för att täcka stora delar av utfallsrummet.

I vårt fall kommer egenskaperna ovan att gälla för de fördelningar som vi betraktar i denna bok. Vi har då

$$\frac{1}{k} \sum_{i=0}^k h(X_i) \rightarrow E[h(X)]$$

och att X_k är approximativt fördelad enligt $f(x)$ när $k \rightarrow +\infty$.

10.3.3 Praktiska tips och exempel

Den goda nyheten om metropolisalgoritmen är att den konvergerar till målfördelningen för en bred uppsättning initialvärden och hoppfördelningar. Den dåliga nyheten är att denna konvergens kan ta mycket lång tid om man har otur. Som konsekvens av detta är det viktigt att se över konvergensen av algoritmen och se till att den ger vettiga värden innan vi börjar använda utfallen för inferens.

Det enklaste sättet är att plotta utfallen som funktion av iterationen. Om värdena rör sig mycket långsamt är det ett tecken på att hoppfördelningen är för begränsad, dvs. att dess skala är för liten. Om värdena är konstanta under en lång tid kan detta bero på att hoppfördelningen har för stor skala, eftersom alla förslag då hamnar i områden med låg sannolikhet och ett stort antal av dem därför förkastas.

En annan metod är att beräkna löpande medelvärden. Dessa kommer att variera mycket i början av algoritmen och sedan stabilisera runt något värde när den börjar konvergera.

Generellt sett kommer de första värdena i kedjan bero starkt på initialvärdet X_0 som använts. Därför approximerar dessa värden ganska dåligt målfördelningen och denna fas kallas ofta för ”uppvärmningsfasen”. En bra tumregel är att så fort kedjan verkar ha konvergerat så delar man den i två delar, kastar bort den första delen, och behåller den andra delen för att göra sina beräkningar.


Som vi poängterade ovan så är metropoliskedjan också starkt beroende av elementen sinsemellan så om (approximativt) oberoende värden söks krävs en del efterbehandling. Det vanligaste sättet att åstadkomma detta är att behålla vart m :te värde för något tillräckligt stort m (detta kan väljas genom att skatta korrelationen mellan element i kedjan). Observera att för många tillämpningar (som för att beräkna väntevärden) är detta inte nödvändigt eftersom summan $\frac{1}{k} \sum_{i=0}^k h(X_i)$ konvergerar ändå. Samma gäller för kredibilitetsintervall, histogram, osv. där vi kan använda värdena som de är.

En viktig metod för att studera konvergens hos metropolisalgoritmen är att köra flera kedjor parallellt. Varje kedja börjar då i olika startpunkter och vi kan då se hur mycket kedjorna ”blandas” (dvs. om de täcker samma område av utfallsrummet). När vi ser detta är det ett tecken på att kedjorna konvergerat.

Exempel 10.6. Vi börjar med ett exempel där vi genererar utfall från en $N(1.2, 0.3^2)$ -fördelningen; dvs. målfördelningen har täthetsfunktion

$$f_X(x) = \frac{1}{\sqrt{2\pi(0.3)^2}} e^{-\frac{1}{2}(x-1.2)^2}.$$


Vi vill generera ett stickprov från denna fördelning med hjälp av metropolisalgoritmen. Därmed behöver vi en hoppfördelning vilken vi tar till att vara $q(x_i|x_{i-1}) \sim U(-\delta, \delta)$. Värdet δ är en skalparameter och därför gäller det att ju större steg vi vill ta desto större värdet tar vi för δ . Här tar vi $\delta = 1$. Vi behöver också ett initialvärde vilket vi tar till att vara ett slumpmässigt utfall från den standardiserade cauchyfördelningen. Vi kör sedan metropolisalgoritmen 10000 iterationer. Vi plottar utfallen $x_1, \dots, x_{10000}$ för att se kvaliteten på konvergens:




Figuren visar att utfallen x_i håller sig kring 1.2 eller 1.3 efter de första flera värdena (vilka är lite låga). Det ser ut som att vi konvergerar till 1.2 (det sanna väntevärdet). Det är lite lättare att se detta om vi plottar det löpande medelvärde vilket beräknas för varje $k = 1, \dots, 10000$ som:

$$r(k) = \frac{1}{k} \sum_{i=1}^k x_i.$$


Plotten ser ut så här:



Det verkar som om vi har konvergens till den stationära fördelningen efter x_{4000} . Eftersom flera av de första utfallen kan ha ett starkt beroende på valet av initialisering tar vi den andra hälften som ett stickprov från målfördelningen. Vi verifierar att konvergensen fortfarande ser bra ut för dessa utfall:




Det ser bra ut. Histogrammet ser också bra ut:




Vi verifierar att stickprovsmedelvärdet och stickprovsvariansen för $x_{5001}, \dots, x_{10000}$ är rimliga skattningar för de riktiga värdena $\mu = 1.2$ och $\sigma = 0.3$:

$$\bar{x} = \frac{1}{5000} \sum_{i=5000}^{10000} x_i \approx 1.196 \quad s = \left(\frac{1}{4999} \sum_{i=5000}^{10000} (x_i - \bar{x})^2 \right)^{1/2} \approx 0.301.$$


Eftersom vi vet de sanna värdena för μ och σ i detta exempel kan vi vara säkra att vi har konvergens med denna markovkedja. I många situationer vet vi inte de sanna parametervärdena och måste ha metoder för att känna oss säkra på att kedjan har konvergerat. Ett sätt att göra detta är att ta fram flera kedjor. När vi ser att de börjar "blandas" kan vi vara säkra på att vi har konvergens. Naturligtvis borde vi ta olika värden för initialisering för de olika kedjorna. I detta exempel kan vi specificera fyra olika kedjor med fyra olika utfall från cauchyfördelningen som gav oss initialiseringen för kedjan ovan. Vi plottar utfallen och de löpande medelvärdena tillsammans i följande plottar:



Vi ser från plottarna att alla fyra kedjor konvergerar till ungefär samma värde (kring 1.2)! Detta är bra bevis på att vi har konvergens. Vi tar igen den andra hälften av utfallen och verifierar att konvergensen fortfarande ser bra ut:



Vi ser också alla kedjor ger liknande histogram:



Stickprovsmedelvärdena och stickprovsvarianserna ser också lika ut:



$\bar{x}$	1.20	1.19	1.197	1.194
s	0.298	0.299	0.306	0.299

Vi behövde egentligen inte metropolisalgoritmen för att simulera fördelningen i Exempel 10.6. Metoden är ju mer användbar om vi vill simulera en fördelning där vi inte har en analytisk form för täthetsfunktionen. Till exempel, låt oss anta att vi har en aposteriorifördelning för en icke-konjugat apriorifördelning.



Exempel 10.7. Betrakta modellen

$$\begin{aligned} X|\Theta = \theta &\sim N(\theta, 0.8^2), \\ \Theta &\sim t(4, 2, 0.3) \end{aligned}$$


från Exempel 10.5 där vi vill simulera aposteriorifördelningen. Vi använder samma hoppfördelning från Exempel 10.6 men med $\delta = 0.1$ och tar fram fyra markovkedjor av längd 10000. Kedjornas utfall och löpande medelvärden ser ut så här:



Konvergensen ser bra ut, så vi tar den andra hälften av markovkedjorna och verifierar att vi fortfarande är nöjda med konvergensen:



Vi tittar också på histogrammen. Om vi har konvergens borde histogrammen passa bra med vår skattning av aposteriorfördelningen där vi har normaliserade med hjälp av den skattade normaliseringskonstanten som i Exempel 10.5:



Det ser bra ut. Denna simuleringsmetod ger oss ett alternativ till förkastelsemetoden som vi använde i Exempel 10.5. Vi kan använda resultaten här på samma sätt som i det exemplet och skatta aposteriorivärdet, aposterioristandardavvikelsen, 95% kredibilitetsintervallet och aposteriorisannolikheten att $\theta \leq 0.6$:

$$\begin{aligned} E[\Theta|\mathbf{x}] &\approx 0.550, \\ \text{Std}[\Theta|\mathbf{x}] &\approx 0.113, \\ 95\text{-intervall} &\approx [0.324, 0.762], \\ P(\Theta \leq 0.6|\mathbf{X} = \mathbf{x}) &\approx 0.678. \end{aligned}$$

Resultaten är nästan desamma.

Metropolisalgoritmen fungerar också för att simulera flerdimensionella fördelningar, till exempel en aposteriorifördelning med flera parametrar.

Exempel 10.8. Företag gillar ofta att skatta andelen av kunder som ser deras annons på en slumpmässig webbsida som också klickar på annonsen. För att öka denna andel kunder testar företagen om en annan annons för samma produkt fungerar bättre än den nuvarande annonsen; t.ex. byter de bilderna eller typsnitten som används i annonsen. Innan ett visst företag ersätter alla annonser på alla webbsidor vill de se några kvantifierbara bevis som stödjer att den nya annonsen ökar antalet klick. För att göra detta använder företaget en *randomiserad kontrollerad studie* där de delar in kunder slumpmässigt i två grupper: en grupp (*kontrollgruppen*) som ser den aktuella annonsen och en grupp (*experimentgruppen*) som ser den nya annonsen. Företaget skapar dessa två grupper för kunder som besöker 10 slumpmässiga valda webbsidor som presenterar annonsen. Webbsidorna är valda för att garantera att de kunder som besöker dem inte överlappar med varandra och att webbsidorna i sig är förmodligen ”oberoende” i meningen, exempelvis, att de inte är anslutna via länkar eller tjänster de erbjuder. Vi kan därför låta K_i beteckna andelen kunder som besöker webbsidan i med den aktuella annonsen som klickar på annonsen, E_i beteckna delen kunder som besöker webbsidan i med den nya annonsen som klickar på den och anta att $k_1, \dots, k_{10}$ och $e_1, \dots, e_{10}$ är stickprov från en kontrollpopulation respektive en experimentpopulation. Vi observerar följande data från en sådan studie:

$K(\text{kontroll})$	0.16	0.32	0.15	0.27	0.3	0.16	0.36	0.41	0.48	0.28
$E(\text{experiment})$	0.8	0.89	0.78	0.68	0.86	0.8	0.85	0.64	0.78	0.81

Eftersom utfallen k_i och e_i är proportioner modellerar vi dem som $K_i|[A_K, B_K]^T = [\alpha_K, \beta_K]^T \sim \text{Beta}(\alpha_K, \beta_K)$ respektive $E_i|[A_E, B_E]^T = [\alpha_E, \beta_E]^T \sim \text{Beta}(\alpha_E, \beta_E)$ där vi antar att $K_1, \dots, K_{10}$ och $E_1, \dots, E_{10}$ är oberoende givet $[A_K, B_K]^T$ respektive $[A_E, B_E]^T$. Eftersom kunderna är slumpmässigt indelade i grupper kan vi också anta att $[A_K, B_K]^T \perp [A_E, B_E]^T$.

Vi vill skatta aposteriorifördelningarna $[A_K, B_K]^T | \mathbf{K} = \mathbf{k}$ och $[A_E, B_E]^T | \mathbf{E} = \mathbf{e}$ där $\mathbf{K} = [K_1, \dots, K_{10}]^T$ och $\mathbf{E} = [E_1, \dots, E_{10}]^T$. För att göra detta behöver vi en apriorifördelning för parametrarna i en betafördelning. Vi har ingen bra kandidat för en konjugerad apriorifördelning och beslutar därför att använda en betingad apriorifördelning. Eftersom det är oklart hur vi kan specificera en sådan apriorifördelning betraktar vi en omparametrisering av fördelningen: Istället för standardparametriseringen kan vi parametrisera $\text{Beta}(\alpha, \beta)$ enligt dess väntevärde och ett precisionsmått:

$$\mu = \frac{\alpha}{\alpha + \beta} \quad \text{och} \quad \kappa = \alpha + \beta + 1.$$

För att se att κ är ett precisionsmått, notera att för $X \sim \text{Beta}(\alpha, \beta)$ har vi

$$\text{Var}[X] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)} = \frac{\mu(1 - \mu)}{\kappa};$$

dvs. κ är inverst proportionell mot $\text{Var}[X]$.

Vi kan då specificera en apriorifördelning för $[\mu, \kappa]^T$ och tillämpa en transformation av stokastiska variabler för att få en apriorifördelning för $[\alpha, \beta]^T$. Vi bildar en betingad apriorifördelning för $[\mu, \kappa]^T$ enligt faktoriseringen

$$f(\mu, \kappa) = f(\kappa|\mu)f(\mu)$$

där vi tar



$$\begin{aligned} \kappa|\mu &\sim \text{Gamma}(\theta, \lambda), \\ \mu &\sim \text{U}(0, 1). \end{aligned}$$

Detta ger oss fördelningen


$$f_{A,B}(\alpha, \beta) = \frac{\lambda^\theta}{\Gamma(\theta)} (\alpha + \beta + 1)^{\theta-1} e^{-\lambda(\alpha+\beta+1)} (\alpha + \beta)^{-1}.$$

En viktig observation är att valet av parametrarna μ och κ i hög grad kan påverka aposteriorifördelningen när vi bara har en liten mängd data. Till exempel ser vi från formeln för $f_{A,B}(\alpha, \beta)$ att för vissa val av θ och λ kan apriorifördelningens täthetsfunktion öka avsevärt när $\alpha, \beta \rightarrow 0$. Om vi har tillräckligt med data kommer datafördelningen att dominera apriorifördelningen och vi kan undvika detta. Men om vi inte har tillräckligt med data kan aposteriorifördelningens täthetsfunktion ha ett globalt maximum i $[0, 0]^T$. Detta kan leda till konstiga skattningar och vi vill därför undvika detta genom ett bra val av parametrarna θ och λ . I det här exemplet har vi tillräckligt med data men det är generellt sett bra att undersöka detta.


Vi väljer ett rimligt värde för precisionen till att börja med. Vi kan till exempel ta $\kappa = 3$, vilket motsvarar värdet för κ för en $\text{Beta}(1, 1)$ -fördelning. För att hitta ett val för parametrarna θ, λ fixerar vi exempelvis $\lambda = 1$ och tar $\theta = \kappa\lambda = (3)(1) = 3$. (Om vi hade mindre data kunde vi ha ökat värdet på κ och gjort detsamma för att bestämma valet av θ och λ .) Vi använder samma val för θ och λ för apriorifördelningen för både K och E . Följande figur visar konturlinjerna för aposteriorifördelningarna.




För att simulera aposteriorifördelningarna bildar vi fyra markovkedjor. Som i föregående exempel börjar vi med en intialisering som ges av en punktskattning för $[\alpha, \beta]^T$. Här använder vi momentmetoden. Vi börjar med att simulera aposteriorifördelningen $[A_K, B_K]^T | \mathbf{K} = \mathbf{k}$. För att få fyra olika initieringar lägger vi till punkten $[\tilde{\alpha}, \tilde{\beta}]^T$ värdet e^v där v är ett slumpmässigt utfall från en cauchyfördelning med skalparameter 0.05. (Vi exponentierar värdet v för att garantera att initialiseringen är positiv.) Vi tar hoppfördelningen till att vara en standardiserad normalfördelning med skalparameter (standardavvikelse) $\delta = 0.5$. Här börjar vi med en skalparameter som är lite större än i föregående exempel eftersom vi inte är säkra på hur lång tid konvergensen kommer att ta. Om det ser för stort ut kan vi alltid minska värdet på δ . Vi kan se om vi har konvergens genom att titta på markovkedjans värden för α och β separat:




Vi kan också titta på ett spridningsdiagram där vi kopplar konsekutiva värden i kedjan med en kant:




Det ser ut som vi har konvergens. Alla kedjorna börjar kring momentmetodens punktskattning och snabbt konvergerar till området som markeras av konturerna i figuren ovan. Så vi delar markovkedjorna i två delar och verifierar att konvergens fortfarande ser bra ut för de andra hälfterna:




De löpande medelvärdena ser också bra ut:



Vi göra detsamma för aposteriorifördelningen $[A_E, B_E]^T | \mathbf{E} = \mathbf{e}$. Resultaten efter vi delar markovkedjorna ser ut som så här:



De löpande medelvärdena ser också bra ut:



Vi kan använda de simulerade utfallen för att skatta aposteriorimedelvärdena:

$$E[A_K, B_K | \mathbf{K} = \mathbf{k}] \approx [0.577, 0.958]^T \quad \text{och} \quad E[A_E, B_E | \mathbf{E} = \mathbf{e}] \approx [1.022, 0.501]^T$$

Med hjälp av detta kan vi skatta den (*aposteriori*) *genomsnittliga behandlingseffekten*:

$$E[E | \mathbf{E} = \mathbf{e}] - E[K | \mathbf{K} = \mathbf{k}] = E[E[E | A_E, B_E, \mathbf{E} = \mathbf{e}]] - E[E[K | A_K, B_K, \mathbf{K} = \mathbf{k}]], \\ \approx 0.295$$

Det ser ut som den nya annonsen kommer att öka delen kunder som klickar på annonsen! Resultaten tycks stödja en förändring av policyn enligt de experimentella förutsättningarna.

10.4 Uppgifter

- 10.1. [2] Istället för Box–Muller-metoden kan vi simulera $Z \sim N(0, 1)$ med hjälp av förkastelsemetoden där vi använder som kandidatfördelning X där

$$X = YW$$

för $Y \sim \text{Exp}(\lambda)$ för någon $\lambda > 0$ och W har sannolikhetsfunktionen

$$f_W(w) = \begin{cases} 0.5, & \text{om } w = -1, \\ 0.5, & \text{om } w = +1 \end{cases}.$$

Vilket värde på λ ger den effektivaste samplingen?

- 10.2. [2] Antag att vi har en normal datafördelning $X \mid \Theta = \theta \sim N(\theta, 1)$ med $t(1)$ som apriorifördelning (även kallad *Cauchyfördelningen*), dvs. $f_\Theta(\theta) \propto 1/(1 + \theta^2)$. Vi får då aposteriorifördelningen som ges av täthetsfunktionen

$$f_{\Theta|X}(\theta \mid x) \propto \frac{1}{1 + \theta^2} e^{-(x-\theta)^2/2}.$$

Aposterioriväntevärdet ges då av

$$W(x) = E[\Theta \mid X = x] = \int_{\mathbb{R}} \theta f_{\Theta|X}(\theta \mid x) d\theta = \frac{\int_{\mathbb{R}} \frac{\theta}{1+\theta^2} e^{-(x-\theta)^2/2} d\theta}{\int_{\mathbb{R}} \frac{1}{1+\theta^2} e^{-(x-\theta)^2/2} d\theta},$$

där vi har normaliserat uttrycket ovan för täthetsfunktionen genom att beräkna dess integral.

- (a) Antag att vi observerar $x = 1$. Plotta integranderna ovan.
 - (b) Använd Monte Carlo-metoden för att approximera integralerna och således approximera $W(x)$ för $x = 1$.
 - (c) Använd förkastelsemetoden med $t(1)$ som kandidatfördelning för att simulera utfall av $\Theta \mid X = x$ och använd dessa utfall för att approximera $W(x)$ för $x = 1$.
- 10.3. [1] Låt oss approximera ett par svanssannolikheter.
- (a) Låt Z ha den standardiserade normalfördelningen och approximera $P(Z > 2)$ med hjälp av Monte Carlo-metoden.
 - (b) Verifiera att för $X \sim \text{Gamma}(1, 1)$ så har vi $P(X > 3.7) \approx 0.025$ med hjälp av Monte Carlo-metoden. Ta fram det korrekta värdet på a upp till tre värdesiffror så att $P(X > a) = 0.025$.
 - (c) Använd relationen mellan gammafördelningen och χ^2 -fördelningen för att bestämma a utifrån tabellsamlingen.
- 10.4. [1] Vi har tidigare sett den icke-informativa fördelningen för lägesparametern Θ som ges av $f_\Theta(\theta) \propto 1$. Eftersom denna fördelning är oegentlig kan den skapa problem i vissa sammanhang och vi kan då välja att approximera denna med den egentliga fördelningen $U(-A, A)$ för något $A > 0$. Låt nu $X \mid \Theta = \theta \sim N(\theta, 1)$ och $\Theta \sim U(-10, 10)$. Använd förkastelsemetoden för att beräkna aposterioriväntevärdet för observationerna $x = 1$, $x = 3$, $x = 9$, $x = 11$ och $x = 13$. Tolk resultatet. Vad händer när $x \rightarrow +\infty$?
- 10.5. [2] Antag att vi vill simulera $X \sim \text{Gamma}(\alpha, \lambda)$ för $\alpha > 1$. Om $\alpha \in \mathbb{Z}_{>0}$ kan vi använda inversionsmetoden för att simulera α stycken oberoende och $\text{Exp}(\lambda)$ -fördelade stokastiska variabler (med hjälp av inversionsmetoden) och ta summan för att simulera X . När $\alpha \notin \mathbb{Z}_{>0}$ måste vi istället använda förkastelsemetoden för att sampla från fördelningen.
- (a) Visa att det räcker att simulera $X \sim \text{Gamma}(\alpha, 1)$.
 - (b) Använd $V \sim \text{Exp}(\beta)$ som kandidatfördelning för något $\beta > 0$. Välj β så att det förväntade antalet försök är så litet som möjligt.

- (c) Ta nu $V \sim \text{Gamma}(\lfloor \alpha \rfloor, \beta)$ (där $\lfloor \alpha \rfloor$ betecknar α avrundat nedåt) istället och bestäm det optimala $\beta > 0$. Hur skiljer sig antalet förväntade försök från metoden i del (a)?
- (d) Implementera båda varianterna och jämför deras prestanda. Hur överensstämmer antalet iterationer med dina beräkningar?

- 10.6.** [1] En kaffemaskinsfabrik ska testa sina produkter och väljer ut åtta stycken maskiner som de låter sin testningsrobot utvärdera. Denna robot fyller på med bönor och vatten automatiskt och kör maskinen tills den slutar producera kaffe. Antalet koppar X (i tusen koppar) fram tills maskinen går sönder sparas för varje maskin och följande data erhålls.

1.8 1.3 2.6 1.8 4.6 1.9 1.0 1.5.

Låt $X \mid \Theta = \theta \sim \text{Exp}(\theta)$. Maskinerna ska teoretiskt sett klara 1000 koppar innan reparation, så för att ge en viss marginal tar de apriorifördelningen som ges av

$$f_{\Theta}(\theta) = \begin{cases} \frac{2}{3}, & 0 \leq \theta < 1, \\ \frac{2}{3}(2 - \theta), & 1 \leq \theta < 2, \\ 0, & \text{annars,} \end{cases}$$

för Θ . Antag nu att vi har en ny kaffemaskin. Bestäm ett 0.95 symmetriskt kredibilitetsintervall för dess livslängd och beräkna sannolikheten att den håller för mer än tusen koppar.

- 10.7.** [2] Den *trunkerade och standardiserade normalfördelningen* på $[a, +\infty)$ har täthetsfunktionen

$$f_X(x) \propto \begin{cases} e^{-x^2/2}, & x \geq a, \\ 0, & \text{annars.} \end{cases}$$

- (a) Det enklaste sättet att simulera utfall från X är att simulera utfall från $N(0, 1)$ och endast behålla de utfall som överskrider a . Hur många försök krävs i genomsnitt för att erhålla ett utfall av X ?
- (b) Man kan istället använda förkastelsemetoden med en skiftad exponentialfördelning $a + \text{Exp}(\lambda)$ som kandidatfördelning. Denna har då täthetsfunktionen

$$f_V(v) = \begin{cases} \lambda e^{-\lambda(v-a)}, & v \geq a, \\ 0, & \text{annars.} \end{cases}$$

Vad är det förväntade antalet försök som krävs för att generera ett utfall av X ? Bestäm λ så att detta antal minimeras.

- (c) Implementera algoritmerna ovan och jämför deras prestanda för $a = 1$, $a = 2$ och $a = 3$.

- 10.8.** [1] Antag att vi har $X \mid \Theta = \theta \sim \text{Po}(\theta)$ med $\Theta \sim N(10, 1)$. Vi observerar följande data

13 5 8 5 8.

Bestäm aposteriorioddset för $H_0 : \Theta \leq 9$ mot $H_1 : \Theta > 9$ med hjälp av förkastelsemetoden.

- 10.9.** [2] Låt $X \mid \Theta = \theta \sim \text{Bin}(n, \theta)$ där Θ har täthetsfunktionen

$$f_{\Theta}(\theta) = \frac{1}{2} \frac{\Gamma(20)}{\Gamma(16)\Gamma(4)} (\theta^{15}(1 - \theta)^3 + (1 - \theta)^{15}\theta^3)$$

Antag att vi har $n = 5$ och observerar $x = 3$.

- (a) Plotta den onormaliserade täthetsfunktionen hos aposteriorifördelningen.
- (b) Använd metropolisalgoritmen för att simulera från aposteriorifördelningen med normalfördelningen som hoppfördelning och plotta histogrammet. Hur påverkar valet av startpunkt och hoppfördelningens skala resultatet?

- (c) Approximera aposterioriväntevärdet och aposteriorimedianen med hjälp av de simulerade utfallen. Är några av dessa att föredra?

10.10. [2] Vi återgår till vindkraftverksexemplet från föreläsning 8. Här hade vi observationerna

5.80 7.88 2.97 4.33 3.25 6.83 1.73

som modellerades som betingat oberoende utfall av $X \mid \Theta_M = \theta_M, \Theta_V = \theta_V \sim N(\theta_M, \theta_V)$. Utöver detta hade vi förlustfunktionen

$$L(\theta_M, a_1) = 11400 - 170.5\theta_M^3$$

$$L(\theta_M, a_2) = 67900 - 600\theta_M^3.$$

Istället för en icke-informativ apriorifördelning väljer vi nu apriorifördelningen där $\Theta_M \sim N(10, 2^2)$ och $\Theta_V \sim U(1, 3^2)$. Bestäm bayesbeslutet genom att generera ett stort antal utfall av aposteriorifördelningen med hjälp av metropolisalgoritmen och använd sedan dessa för att approximera aposterioririskerna för a_1 och a_2 . (*Tips:* Prova först med den icke-informativa apriorifördelningen och se till att du får samma resultat med den analytiska aposteriorifördelningen.)

10.11. [2] Vi vill simulera dirichletfördelningen $\text{Dirichlet}(\alpha_1, \dots, \alpha_n)$ där vi antar att $\alpha_i > 1$ för alla $i = 1, 2, \dots, n$.

- (a) Visa att om $X_1, X_2, \dots, X_n$ är oberoende och $\text{Exp}(1)$ -fördelade så är

$$\mathbf{Y} = \frac{[X_1, X_2, \dots, X_n]^T}{\sum_{i=1}^n X_i}$$

likformigt fördelad över $\{\mathbf{x} \in [0, 1]^n : \sum_{i=1}^n x_i = 1\}$.

- (b) Implementera förkastelsemetoden för $\text{Dirichlet}(\alpha_1, \dots, \alpha_n)$ med denna likformiga fördelning som kandidatfördelning. Verifiera att medelvärdet och variansen approximerar de sanna värdena för olika värden på $\alpha_1, \dots, \alpha_n$.

10.12. [3] Ägaren av glassaffär är intresserad av att förutsäga antalet sålda glassar under en viss dag. Hon gissar att antalet sålda glassar beror på lufttemperaturen över en viss gräns (arton grader) och sätter därför upp följande modell

$$Y \mid A = a, B = b \sim \text{Po}(a \max(t - 18, 0) + b),$$

där Y är antalet sålda glassar, t är lufttemperaturen (i grader Celsius) medan A och B är parametrarna som ska skattas. Hon samlar därför in temperatur- och försäljningsdata under sommaren använder dessa för att skatta A och B .

Hon vet att under vintern (då temperatur inte är någon större faktor) brukar försäljningssiffrorna ligga på ungefär 20 glassar om dagen, så hon tar $N(20, 10^2)$ som apriorifördelning för B . När det gäller parametern A vill hon testa om temperaturberoendet faktiskt existerar, så hon vill ha en symmetrisk, men någorlunda vag apriorifördelning för A och väljer därför $t(1)$. Parametrarna antas vara oberoende a priori.

- (a) Ladda ner de observerade datapunkterna och generera utfall från aposteriorifördelningen för A och B givet datat. Plotta ett tvådimensionellt histogram för båda parametrarna (använd `hist2d` i Matplotlib). Vad är den approximativa sannolikheten att $A > 0$?
- (b) Beräkna aposterioriväntevärdet för (A, B) genom att ta medelvärdet av de genererade utfallen.
- (c) Ägaren vet att det finns vissa dagar som sticker ut i datat och inte är representativa (till exempel var det få kunder midsommar och en dag anordnades en gratis utomhuskonsert i området). För att vara mindre känslig med avseende på dessa avvikande värden (även kallade *outliers*) vill ägaren beräkna bayesskattningen med avseende på absolutfelet $L((a, b), (\hat{a}, \hat{b})) = \sqrt{|a - \hat{a}|^2 + |b - \hat{b}|^2}$ som är mer robust än kvadratfelet. I det endimensionella fallet ger detta aposteriorimedianen, men i det flerdimensionella fallet kräver bayesskattningen ett annat tillvägagångssätt.

Approximera aposterioririskerna $E[L((A, B), (\hat{a}, \hat{b})) \mid \mathbf{X} = \mathbf{x}]$ för absolutfelet på ett rutnät i $\hat{a}$ - $\hat{b}$ -planet och välj det värde som minimerar denna risk.

- (d) Rutnätsmetoden ovan kan kräva mycket beräkningar om vi vill ha en noggrann approximation (då detta kräver ett mer finmaskigt rutnät).

En annan metod är att optimera aposterioririsen. Detta görs enklast genom att approximera gradienten av aposterioririsen

$$\nabla_{\hat{a}, \hat{b}} = \begin{bmatrix} \frac{\partial}{\partial \hat{a}} \\ \frac{\partial}{\partial \hat{b}} \end{bmatrix} E[L((A, B), (\hat{a}, \hat{b})) \mid \mathbf{X} = \mathbf{x}]$$

och stega längs $-\nabla_{\hat{a}, \hat{b}}$ med någon steglängd λ . Detta ger sekvensen


$$\begin{bmatrix} \hat{a}_{n+1} \\ \hat{b}_{n+1} \end{bmatrix} = \begin{bmatrix} \hat{a}_n \\ \hat{b}_n \end{bmatrix} - \lambda \nabla_{\hat{a}_n, \hat{b}_n}$$

där vi har initialiserat $\hat{a}_0$ och $\hat{b}_0$ till någon slumpmässig punkt.

Implementera denna metod och jämför resultatet med svaret från rutnätsmetoden ovan.


Kapitel 11

Tidigare har vi skattat en eller ett par parametrar utifrån data med hjälp av metoder från bayesiansk inferens. Den vanligaste situationen är att vi har något stickprov $X_1, \dots, X_n$ där varje observation är betingat oberoende med avseende på någon parametervektor Θ . Vidare har vi att de betingade datafördelningarna är identiska med avseende på denna underliggande parameter. I grafform får vi följande modell.




En viktig egenskap hos denna modell är att parametervektorn Θ är densamma för *alla* observationer. Med andra ord antar vi att observationerna är starkt kopplade till varandra (de kanske är repetitioner av samma experiment eller identiska produkter som undersöks på samma sätt). Vi kan variera modellen ovan genom att variera datafördelningarna mellan de olika observationerna, men den underliggande parametern Θ är alltid densamma.


I många fall har vi dock inte alltid en lika stark koppling mellan observationerna. Vi har kanske en grupp experiment som utförs på olika sätt och beror på olika underliggande parametrar eller så har vi liknande produkter från olika fabriker som ska undersökas. En variant är då att ansätta en parameter Θ_j som hör till varje observation X_j , vilket ger följande modell.



Mer allmänt kanske vi har grupper av observationer $X_{j,1}, X_{j,2}, \dots, X_{j,n_j}$ för något $n_j \in \mathbb{Z}_{>0}$ som alla delar samma parametervektor Θ_j för $j = 1, \dots, m$. Detta ger följande modell.



Till exempel hade vi $K_1, \dots, K_{10}$ och $E_1, \dots, E_{10}$ som alla delar samma parametervektor $[A_K, B_K]^T$ respektive $[A_E, B_E]^T$ i Exempel 10.8. Som i Exempel 10.8 kan vi nu skatta de olika parametrarna $\Theta_1, \Theta_2, \dots, \Theta_m$ var för sig (givet någon apriorifördelning för parametrarna). Nackdelen här är att vi saknar någon relation mellan de olika parametervektorerna. I Exempel 10.8 var det försvarbart eftersom vi arbetade i en randomiserad kontrollerad studie. Det finns dock situationer där vi inte kan vara säkra att parametrarna för de olika grupper verkligen är oberoende. Till exempel, om vi inte är försiktiga är det möjligt att alla kunder i Exempel 10.8 kommer ifrån samma land eller även samma stad! I sådana situationer ökar risken att medlemmar i grupperna inte är oberoende. Även om parametrarna inte är identiska kanske det finns någon länk mellan dem. Ett vanligt antagande är att parametervektorerna i sig kan anses vara betingat oberoende givet en annan parametervektor Φ . Den gemensamma parametervektorn Φ kallas ofta för *hyperparameter* då de är parametrar för de ordinarie parametrarna $\Theta_1, \Theta_2, \dots, \Theta_m$. Vi får då följande modell.



Detta kallas för en *bayesiansk hierarkisk modell* (i två nivåer). Resten av kapitlet kommer vi att ägna oss åt att skatta parametrar och hyperparametrar i denna typ av modeller.

11.1 Empiriska bayesmetoden

Ett sätt att angripa en bayesiansk hierarkisk modell är att konstruera punktskattningar för hyperparametrarna och sedan använda den resulterande apriorifördelningen för att genomföra traditionell bayesiansk inferens för varje

parameter var för sig. Det finns en mängd olika sätt att göra detta med hjälp av ML-skattningar av hyperparametrarna eller momentmetoden. Dessa kallas för *empiriska bayesmetoder* då de använder observationerna (dvs. den empiriska datan) för att konstruera en apriorifördelning.

I denna bok kommer vi att betrakta en specifik variant av den empiriska bayesmetoden. Metoden har följande steg.

1. Skatta var parameter Θ_j för sig med momentmetoden från datat $x_{j,1}, x_{j,2}, \dots, x_{j,n_j}$ för $j = 1, \dots, m$. Beteckna skattningen med $\hat{\theta}_j$.
2. Dessa $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ betraktas nu som utfall av $\Theta_1, \Theta_2, \dots, \Theta_m$ och används för att skatta hyperparametrarna Φ med momentmetoden. Denna skattning betecknar vi med $\hat{\phi}$.
3. Fixera $\Phi = \hat{\phi}$ i modellen och använd den resulterande fördelningen för Θ som apriorifördelning.
4. Givet nya datapunkter $x_1, x_2, \dots, x_n$, bestäm aposteriorifördelningen för Θ med denna apriorifördelning.

Eftersom metoden bygger på punktskattningar av hyperparametrarna och inte tar deras variation i beaktning (dvs. eftersom vi inte beräknar någon aposteriorifördelning med avseende på hyperparametrarna) så är inte denna modell bayesiansk i dess sanna bemärkelse. Den empiriska bayesmetoden är dock ett enkelt sätt att inkorporera tidigare observationer för att förbättra inferens i en situation med få mätdata. Vi illustrerar den med ett exempel.

Exempel 11.1. Ett antal råttor undersöks för utveckling av tumörer. Råttorna är av standardtypen "F344" och kommer från en kontrollgrupp som inte har utsatts för någon intervention (t.ex. injektion av ett läkemedel). I vårt experiment observerar vi 14 råttor, varav 4 utvecklar tumörer. Vi skulle nu vilja bestämma den underliggande sannolikheten att utveckla tumörer för dessa råttor.

Denna observation X är binomialfördelad givet sannolikheten $\Theta = \theta$ att råttan utvecklar en tumör. Med andra ord har vi $X | \Theta = \theta \sim \text{Bin}(14, \theta)$. En naturlig apriorifördelning är betafördelningen, då denna familj är konjugerad med binomialfördelningen. Vi har då $\Theta \sim \text{Beta}(\alpha, \beta)$, men behöver parametrarna α och β för att göra inferens.

Ett tillvägagångssätt är att anta en icke-informativ apriorifördelning $\Theta \sim \text{Beta}(0, 0)$ (Haldanes apriorifördelning). Detta ger aposteriorifördelningen $\Theta | X = 4 \sim \text{Beta}(4, 10)$ och aposterioriväntevärdet $E[\Theta | X = 4] = 4/14 \approx 0.286$ med aposterioristandardavvikelsen $\text{Std}[\Theta | X = 4] \approx 0.117$. Med andra ord har vi ganska stor osäkerhet i vår skattning.

Låt oss nu anta att andra experiment har gjorts på samma typ av råttor (dvs. av typen F344) och följande resultat har uppnåtts

(0,20)	(0,20)	(0,20)	(0,20)	(0,20)	(0,20)	(0,20)	(0,19)	(0,19)	(0,19)
(0,19)	(0,18)	(0,18)	(0,17)	(1,20)	(1,20)	(1,20)	(1,20)	(1,19)	(1,19)
(1,18)	(1,18)	(2,25)	(2,24)	(2,23)	(2,20)	(2,20)	(2,20)	(2,20)	(2,20)
(2,20)	(1,10)	(5,49)	(2,19)	(5,46)	(3,27)	(2,17)	(7,49)	(7,47)	(3,20)
(3,20)	(2,13)	(9,48)	(10,50)	(4,20)	(4,20)	(4,20)	(4,20)	(4,20)	(4,20)
(4,20)	(10,48)	(4,19)	(4,19)	(4,19)	(5,22)	(11,46)	(12,49)	(5,20)	(5,20)
(6,23)	(5,19)	(6,22)	(6,20)	(6,20)	(6,20)	(16,52)	(15,47)	(15,46)	(9,24)

där beteckningen (x, n) motsvarar x råttor med tumörer av n totalt. Vi kan använda den empiriska bayesmetoden för att skatta hyperparametrarna α och β .

För varje experiment (x_j, n_j) har vi skattningen av $\theta_j = x_j/n_j$. Med andra ord har vi $\hat{\theta}_1 = 0/20 = 0$, $\hat{\theta}_2 = 0/20$, $\dots$, $\hat{\theta}_{70} = 9/24 = 0.375$. Om vi skattar medelvärdet och variansen får vi

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^m \hat{\theta}_i \approx 0.136$$

respektive

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^m (\hat{\theta}_i - \hat{\mu})^2 \approx 0.0106.$$

Om vi sätter formelerna för $E[\Theta_j]$ och $\text{Var}[\Theta_j]$ från betafördelningen lika med dessa får vi skattningen $(\hat{\alpha}, \hat{\beta}) = (1.4, 8.6)$.

Vi kan nu använda apriorifördelningen $\Theta \sim \text{Beta}(1.4, 8.6)$ för att ta fram aposteriorifördelningen för vår data $X = 4$ där $X \mid \Theta = \theta \sim \text{Bin}(14, \theta)$. Detta ger då $\Theta \mid X = 4 \sim \text{Beta}(1.4 + 4, 8.6 + 10) = \text{Beta}(5.4, 18.6)$ som ger aposterioriväntevärdet $5.4/(5.4 + 18.6) \approx 0.223$. Vi får alltså ett lägre aposterioriväntevärde än för den icke-informativa apriorifördelningen $\text{Beta}(0, 0)$. Detta följer från faktumet att antalet tumörer i vårt experiment är ovanligt högt jämfört med de andra experimenten, så sannolikheten justeras ned. Aposterioristandardavvikelsen $\text{Std}[\Theta \mid X = 4] \approx 0.083$ är också mindre, vilket representerar en större tillförlitlighet i skattningen.

Ett tredje alternativ är att anta att alla experiment har samma Θ , dvs. $X_j \mid \Theta = \theta \sim \text{Bin}(n_j, \theta)$ för alla $j = 1, 2, \dots, 71$. I detta fall kan vi anta att Θ har en icke-informativ apriorifördelning $\Theta \sim \text{Beta}(0, 0)$. Detta skulle ge ett aposterioriväntevärde $E[\Theta \mid X_1 = x_1, \dots, X_{71} = x_{71}] \approx 0.150$ och aposterioristandardavvikelse $\text{Std}[\Theta \mid X_1 = x_1, \dots, X_{71} = x_{71}] \approx 0.00865$. Väntevärdet är alltså mycket mindre och likaså standardavvikelsen. Här tillåter vi alltså ingen variation mellan de olika kontrollgrupperna och får då en mindre skattning som i sin tur också är ganska säker (dvs. har låg standardavvikelse). Olika antaganden ger alltså olika resultat i detta fall. Vilken skattning som är bäst beror på hur väl modellen representerar verkligheten. (Detta kan, till exempel, utvärderas med hjälp av den prediktiva aposteriorifördelningen.)

11.2 Bayesiansk inferens i en binomialhierarki

Den empiriska bayesmetoden är som sagt ett sätt att genomföra inferens i en hierarkisk modell. Problemet är att vi ansätter fixa värden för hyperparametrarna, vilket gör att metoden inte ger hela bilden från ett bayesianskt perspektiv. Punktskattningarna $\hat{\phi}$ för Φ måste då ersättas med aposteriorifördelningar som vi sedan kan generera utfall från och beräkna olika värden.

Om alla apriorifördelningar är kända kan vi göra detta med de verktyg vi har tagit fram hittills. Det viktiga är att kunna skilja på de betingade aposteriorifördelningarna (där vi håller en parameter eller hyperparameter fix) och de marginaliserade aposteriorifördelningarna (där vi integrerar bort en parameter eller hyperparameter). Om vi sätter ihop dessa på rätt sätt kan vi sedan få ut de skattningar vi är intresserade av. Till skillnad från den empiriska bayesmetoden innefattar denna mer kompletta metod en hel del mer beräkning, men resultatet är en mer flexibel metod som har större chans att ge oss en bättre insikt i datat.

Låt oss anta att vi, som innan, har observationer $X_{j,1}, X_{j,2}, \dots, X_{j,n_j}$ betingat oberoende givet Θ_j där $n_j \in \mathbb{Z}_{>0}$ med samma betingade fördelningar för $j = 1, 2, \dots, m$. Vidare har vi att $\Theta_1, \Theta_2, \dots, \Theta_m$ är betingat oberoende givet någon hyperparameter Φ med samma betingade fördelningar. Vi har också att $X_{j,i} \perp\!\!\!\perp X_{j',i'} \mid \Phi$. (Se grafen ovan!)

Anta nu att vi har, för varje $j = 1, \dots, m$, observationen $[X_{j,1}, \dots, X_{j,n_j}]^T = [x_{j,1}, \dots, x_{j,n_j}]^T$, vilket vi betecknar med $\mathbf{X}_j = \mathbf{x}_j$. Om vi samlar alla observationer i en enda stor vektor kan vi skriva detta som $\mathbf{X} = \mathbf{x}$. Som vanligt kan vi bilda täthetsfunktionen för aposteriorifördelningen

$$f_{\Theta, \Phi | \mathbf{X}}(\boldsymbol{\theta}, \boldsymbol{\phi} \mid \mathbf{x}) \propto f_{\mathbf{X} | \Theta, \Phi}(\mathbf{x} \mid \boldsymbol{\theta}, \boldsymbol{\phi}) f_{\Theta, \Phi}(\boldsymbol{\theta}, \boldsymbol{\phi}),$$

där vi har använt Θ för att beteckna vektorn $[\Theta_1, \dots, \Theta_m]^T$. Eftersom vi har den betingade fördelningen för Θ givet Φ skriver vi om detta som

$$f_{\Theta, \Phi | \mathbf{X}}(\boldsymbol{\theta}, \boldsymbol{\phi} \mid \mathbf{x}) \propto f_{\mathbf{X} | \Theta, \Phi}(\mathbf{x} \mid \boldsymbol{\theta}, \boldsymbol{\phi}) f_{\Theta | \Phi}(\boldsymbol{\theta} \mid \boldsymbol{\phi}) f_{\Phi}(\boldsymbol{\phi}).$$

Formellt sett räcker det med resultatet ovan. Om vi sätter in de observerade datapunkterna $\mathbf{x}$ och en passande apriorifördelning $f_{\Phi}(\boldsymbol{\phi})$ för hyperparametrarna kan vi sedan använda metropolialgoritmen för att generera utfall från $[\Theta, \Phi]^T$ och beräkna olika väntevärden. Problemet är att aposteriorifördelningen ovan, som kallas *den simultana aposteriorifördelningen* eftersom den bestämmer fördelningen för Θ och Φ simultant, kan vara svår att simulera ifrån då antalet parametrar ofta är stort. Ett annat problem är att det kan vara svårt att få insikt i hur de olika parametrarna påverkar varandra utifrån detta uttryck.

Nästa steg är därför att ta fram den betingade aposteriorifördelningen för Θ givet $\mathbf{X}$ och Φ , dvs. aposteriorifördelningen för Θ om vi antar att hyperparametern Φ är fix. Detta motsvarar sista steget i den empiriska bayesmetoden och är oftast ganska enkel om vi väljer Θ s fördelning från en familj av konjugerade apriorifördelningar med avseende på datafördelningarna. Vi kan då använda standardreglerna för bayesiansk uppdatering. Utifrån detta får vi ett uttryck för $f_{\Theta | \Phi, \mathbf{X}}(\boldsymbol{\theta} \mid \boldsymbol{\phi}, \mathbf{x})$.

Det sista steget är att ta fram den marginaliserade aposteriorifördelningen för Φ givet $\mathbf{X}$. Ett sätt att ta fram detta är att integrera den simultana aposteriorifördelningen $f_{\Theta, \Phi | \mathbf{X}}(\boldsymbol{\theta}, \boldsymbol{\phi} \mid \mathbf{x})$ med avseende på $\boldsymbol{\theta}$. Detta kräver ofta

ganska mycket jobb, så vi använder oss istället av ett litet trick. Enligt kedjeregeln har vi

$$f_{\Theta, \Phi | \mathbf{X}}(\theta, \phi | \mathbf{x}) = f_{\Theta | \Phi, \mathbf{X}}(\theta | \phi, \mathbf{x}) f_{\Phi | \mathbf{X}}(\phi | \mathbf{x}),$$

vilket vi kan skriva om som

$$f_{\Phi | \mathbf{X}}(\phi | \mathbf{x}) = \frac{f_{\Theta, \Phi | \mathbf{X}}(\theta, \phi | \mathbf{x})}{f_{\Theta | \Phi, \mathbf{X}}(\theta | \phi, \mathbf{x})}.$$

Med andra ord kan vi helt enkelt stoppa in den simultana aposteriorifördelningen för Θ, Φ givet $\mathbf{X}$ och den betingade aposteriorifördelningen för Θ givet $\Phi, \mathbf{X}$ i formeln ovan och få ut den marginaliserade aposteriorifördelningen för Φ givet $\mathbf{X}$. Observera att man måste vara försiktig med täthetsfunktionen i täljaren. I vanliga fall kan vi komma undan genom att ta bort olika konstanter i täthetsfunktionen som inte beror på Θ , men i detta fall kan dessa vara viktiga (om de beror på Φ) när vi använder dem i formeln ovan. Därför är det säkrast att arbeta med normaliserade täthetsfunktioner för den betingade aposteriorifördelningen (vilket ofta inte är något problem när vi arbetar med konjugerade apriorifördelningar då dessa ger oss de nödvändiga konstanterna).

Med denna marginaliserade aposteriorifördelning för hyperparametrarna kan vi sedan utföra inferens genom sampling från de olika fördelningarna. Först genererar vi utfall från aposteriorifördelningen för hyperparametrarna Φ , sedan använder vi dessa för att generera utfall för parametrarna $\Theta_1, \Theta_2, \dots, \Theta_m$ och beräknar de väntevärden som är av intresse.

Vi illustrerar detta med tillämpning på en binomialhierarki där

$$\begin{aligned} X_j | \Theta_j = \theta_j &\sim \text{Bin}(n_j, \theta_j), \\ \Theta_j | A = \alpha, B = \beta &\sim \text{Beta}(\alpha, \beta) \quad \text{för } j = 1, 2, \dots, m. \end{aligned}$$

Här har vi att $X_j \perp\!\!\!\perp X_{j'} | A, B$, $\Theta_j \perp\!\!\!\perp \Theta_{j'} | A, B$ samt $X_j \perp\!\!\!\perp \Theta_{j'} | A, B$ för $j \neq j'$. Vi väljer inte någon apriorifördelning för A, B än utan låter denna vara obestämd tills vidare.

Detta ger nu den simultana aposteriorifördelningen

$$\begin{aligned} f_{\Theta, A, B | \mathbf{X}}(\theta, \alpha, \beta | \mathbf{x}) &\propto f_{A, B}(\alpha, \beta) f_{\Theta | A, B}(\theta | \alpha, \beta) f_{\mathbf{X} | \Theta, A, B}(\mathbf{x} | \theta, \alpha, \beta) \\ &\propto f_{A, B}(\alpha, \beta) \prod_{j=1}^m \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta_j^{\alpha-1} (1 - \theta_j)^{\beta-1} \prod_{j=1}^m \binom{n_j}{x_j} \theta_j^{x_j} (1 - \theta_j)^{n_j - x_j}. \end{aligned}$$

Eftersom de j olika beta-binomialhierarkierna $X_j | \Theta_j$ är betingat oberoende givet A, B har vi att $\Theta_j | X_j = x_j, A = \alpha, B = \beta \sim \text{Beta}(\alpha + x_j, \beta + n_j - x_j)$, dvs.

$$f_{\Theta_j | A, B, X_j}(\theta_j | \alpha, \beta, x_j) = \frac{\Gamma(\alpha + \beta + n_j)}{\Gamma(\alpha + x_j)\Gamma(\beta + n_j - x_j)} \theta_j^{\alpha + x_j - 1} (1 - \theta_j)^{\beta + n_j - x_j - 1}.$$

Med alla $j = 1, \dots, m$ tillsammans får vi då den betingade aposteriorifördelningen

$$f_{\Theta | A, B, \mathbf{X}}(\theta | \alpha, \beta, \mathbf{x}) = \prod_{j=1}^m \frac{\Gamma(\alpha + \beta + n_j)}{\Gamma(\alpha + x_j)\Gamma(\beta + n_j - x_j)} \theta_j^{\alpha + x_j - 1} (1 - \theta_j)^{\beta + n_j - x_j - 1}.$$

Här använde vi observationen $\Theta_i \perp\!\!\!\perp \Theta_j | A, B, \mathbf{X}$ för alla $i \neq j$ vilket stämmer enligt d-separationen i grafen ovan. Genom att använda vårt trick ovan får vi nu ut

$$f_{A, B | \mathbf{X}}(\alpha, \beta | \mathbf{x}) \propto f_{A, B}(\alpha, \beta) \prod_{j=1}^m \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha + x_j)\Gamma(\beta + n_j - x_j)}{\Gamma(\alpha + \beta + n_j)}.$$

Denna formel kan vi inte förenkla ytterligare men går att beräkna numeriskt för godtyckliga α, β .

Valet av apriorifördelning för A, B återstår. Ett alternativ är att använda en egentlig apriorifördelning, vilket garanterar att aposteriorifördelningen också är egentlig. Till exempel kan vi använda apriorifördelningen som definieras i Exempel 10.8. Att välja en bra icke-informativ apriorifördelning är svårt, men det går att visa att

$$f_{A, B}(\alpha, \beta) \propto (\alpha + \beta)^{-5/2}$$

ger en egentlig aposteriorifördelning om det håller att $0 < x_j < n_j$ för något j .

Anmärkning 11.1. Det kan kännas mystiskt hur man väljer apriorifördelningar som $f_{A,B}(\alpha, \beta)$ ovan. Faktum är att mycket forskning inom matematisk statistik har arbetat med att utveckla metoder för att specificera rimliga apriorifördelningar. Den oegentliga apriorifördelningen ovan och apriorifördelningen som används i Exempel 10.8 är byggda med samma teknik som även kan tillämpas på andra situationer. Idén är att börja med en omparismetrisering. Då kan vi specificera en apriorifördelning för de nya parametrarna och transformerar den resulterande fördelningen tillbaka till de ursprungliga parametrarna. I Exempel 10.8 började vi med transformationen

$$\mu = \frac{\alpha}{\alpha + \beta} \quad \text{och} \quad \kappa = \alpha + \beta + 1.$$

Sedan specificerade vi en betingad apriorifördelning för parametrarna $[\mu, \kappa]^T$ enligt hierarkin

$$\begin{aligned} \kappa | \mu &\sim \text{Gamma}(\theta, \lambda), \\ \mu &\sim \text{U}(0, 1). \end{aligned}$$

För att använda denna apriorifördelning behövde vi specificera värdena θ och λ . Från detta perspektiv är denna apriorifördelning lite ”informativ” eftersom valet av θ och λ påverkar aposteriorifördelningen. Om vi vill ha en ”helt icke-informativ” apriorifördelning som endast påverkar aposteriorifördelningen genom sin funktionella form (och inte genom ytterliggande val) skulle det ha varit bättre att ta fördelningen $f_{\mu, \kappa}(\mu, \kappa) \propto 1$. Med ett sådant val påverkas modellen bara genom valet av variabeltransformation. Apriorifördelningen $f_{A,B}(\alpha, \beta) \propto (\alpha + \beta)^{-5/2}$ är ett sådant exempel. Vi såg redan att för $X \sim \text{Beta}(\alpha, \beta)$ har vi

$$\text{Var}[X] = \frac{\mu(1 - \mu)}{\alpha + \beta + 1}$$

där $\mu = \frac{\alpha}{\alpha + \beta}$. Det följer att

$$\text{Var}[X] \propto \frac{1}{\alpha + \beta + 1} \approx \frac{1}{\alpha + \beta}.$$

Därför är $\text{Std}[X]$ approximativt proportionell till $(\alpha + \beta)^{-1/2}$. Istället för att ta en transformation baserat på väntevärdet och ett mått på precision som i Exempel 10.8 kan vi istället ta en transformation baserat på väntevärdet och ett spridningsmått:

$$\mu = \frac{\alpha}{\alpha + \beta} \quad \text{och} \quad \eta = (\alpha + \beta)^{-1/2}.$$

För att vara ”icke-informativ” tar vi $f_{\mu, \eta}(\mu, \eta) \propto 1$. Det följer enligt en transformation av stokastiska variabler att

$$\begin{aligned} f_{A,B}(\alpha, \beta) &\propto f_{\mu, \eta}(g^{-1}(\alpha, \beta)) |J|, \\ &\propto 1 \left(\frac{1}{2}(\alpha + \beta)^{-5/2} \right), \\ &\propto (\alpha + \beta)^{-5/2}, \end{aligned}$$

där

$$J = \begin{vmatrix} \frac{\beta}{(\alpha + \beta)^2} & -\frac{\alpha}{(\alpha + \beta)^2} \\ -\frac{1}{2}(\alpha + \beta)^{-3/2} & -\frac{1}{2}(\alpha + \beta)^{-3/2} \end{vmatrix} = -\frac{1}{2}(\alpha + \beta)^{-5/2}.$$


På så sätt är dessa två apriorifördelningar konstruerade på ett liknande sätt. Man kan göra detsamma för andra fördelningar och transformationer men vi måste alltid vara försiktiga och verifiera att den resulterande aposteriorifördelningen är egentlig.

När vi använder en icke-informativ apriorifördelning måste vi fortfarande vara försiktiga för att undvika konstiga resultat. Icke-informativa apriorifördelningar som ovan har ofta enorma (även oändliga) varianser och därför måste vi ha tillräckligt med data så att datafördelningen kan dominera apriorifördelningen och därmed ge oss en rimlig aposteriorifördelning. Till exempel, om vi har för lite data kan det hända att datafördelningen i modellen ovan inte dominerar singulariteten i $[\alpha, \beta]^T = [0, 0]^T$ och aposteriorifördelningen kan därmed ha ett globalt maximum i denna punkt. Detta kan vara ett problem om vi vill använda aposterioripunktskattningar eller till och med när vi vill använda den aposterioriprediktiva fördelningen. I situationer när vi bara har lite data är det därför bra att verifiera att aposteriorifördelningens globala maximum är någorlunda långt borta från $[0, 0]^T$. Observera att samma problem kan hända med apriorifördelningen från Exempel 10.8 om vi har för lite data och dåligt val för θ och λ .

Generellt sett är det alltid bra att testa olika val för dessa parametrar när man bara har en liten mängd data. Du kan testa detta genom att plotta konturlinjerna eller simulera aposteriorfördelningen.


I vårt exempel med råttorna har vi tillräckligt med data för att säkert använda den icke-informativa apriorifördelningen ovan. Med denna kan vi simulera utfall från A, B och sedan använda dessa för att simulera utfall av $\Theta_1, \Theta_2, \dots, \Theta_m$.

Exempel 11.2. Vi återgår till exemplet med råttorna. Om vi plottar aposteriorfördelningen för hyperparametrarna A och B får vi följande figur:



Fördelningen verkar alltså koncentrera sig kring $\alpha = 2$ och $\beta = 10$, vilket stämmer bra med punktskattningarna från den empiriska bayesmetoden (där vi fick $\hat{\alpha} = 1.4$ och $\hat{\beta} = 8.6$).

Vi kan simulera denna fördelning med hjälp av metropolisalgoritmen som vi har sett i tidigare. De 2000 utfall vi får från detta ser ut att följa fördelningen ganska bra:




Om vi tar medelvärdet över alla dessa utfall kan vi approximera aposterioriväntevärdena för hyperparametrarna A och B , vilket ger

$$E[A \mid \mathbf{X} = \mathbf{x}] \approx 2.00 \quad \text{och} \quad E[B \mid \mathbf{X} = \mathbf{x}] \approx 11.9.$$

Detta är återigen nära punktskattningen vi fick från den empiriska bayesmetoden.

Vi kan också simulera fördelningen för Θ där $\Theta \mid A = \alpha, B = \beta \sim \text{Beta}(\alpha, \beta)$ där A och B följer fördelningen ovan. Detta görs enklast genom att simulera utfall från A, B och sedan använda dessa för att simulera utfall från Θ enligt betafördelningen. Vi får då histogrammet



Vi kan också använda dessa för att beräkna aposterioriväntevärdet och aposteriorivariansen för Θ . Ett bättre resultat kan vi få genom att utnyttja lagen om total förväntan och lagen om total sannolikhet. Detta ger

$$E[\Theta \mid \mathbf{X}] = E[E[\Theta \mid A, B, \mathbf{X}] \mid \mathbf{X}] = E\left[\frac{A}{A+B} \mid \mathbf{X}\right] \approx 0.145$$

och

$$\begin{aligned} \text{Var}[\Theta \mid \mathbf{X}] &= E[\text{Var}[\Theta \mid A, B, \mathbf{X}] \mid \mathbf{X}] + \text{Var}[E[\Theta \mid A, B, \mathbf{X}] \mid \mathbf{X}] \\ &= E\left[\frac{AB}{(A+B)^2(A+B+1)} \mid \mathbf{X}\right] + \text{Var}\left[\frac{A}{A+B} \mid \mathbf{X}\right] \approx 0.00909 \end{aligned}$$

Båda är återigen ganska nära värdena som vi fick i den empiriska bayesmetoden, med en aningen mindre varians.

Med de simulerade utfallen från A, B kan vi använda den betingade aposteriorifördelningen för Θ_{71} för att ge en skattning av denna parameter som var aktuell i vårt experiment. Vi har då $\Theta_{71} \mid A = \alpha, B = \beta, \mathbf{X} = \mathbf{x} \sim \text{Beta}(\alpha + x_{71}, \beta + n_{71} - x_{71})$. Återigen använder vi lagarna om total förväntan och varians för att ta fram väntevärdet

$$E[\Theta_{71} \mid \mathbf{X}] = E[E[\Theta \mid A + X_{71}, B + n_{71} - X_{71}, \mathbf{X}] \mid \mathbf{X}] = E\left[\frac{A + X_{71}}{A + B + n_{71}} \mid \mathbf{X}\right] \approx 0.217$$

och variansen


$$\begin{aligned} \text{Var}[\Theta_{71} \mid \mathbf{X}] &= E[\text{Var}[\Theta_{71} \mid A, B, \mathbf{X}] \mid \mathbf{X}] + \text{Var}[E[\Theta_{71} \mid A, B, \mathbf{X}] \mid \mathbf{X}] \\ &= E\left[\frac{(A + X_{71})(B + n_{71} - X_{71})}{(A + B + n_{71})^2(A + B + n_{71} + 1)} \mid \mathbf{X}\right] + \text{Var}\left[\frac{A + X_{71}}{A + B + n_{71}} \mid \mathbf{X}\right] \approx 0.00616, \end{aligned}$$

vilket ger en aposterioristandardavvikelse på ungefär $\sqrt{0.00616} \approx 0.0785$. Väntevärdet ligger strax under skattningen från den empiriska bayesmetoden och standardavvikelsen är aningen mindre. Den mer kompletta bayesianska analysen har alltså reducerat väntevärdet mer mot de andra värdena (som hade mycket färre tumörer jämfört med vårt experiment) och har gjort detta med lite större säkerhet. Detta kan bero på att aposteriorifördelningen för Θ (obetingat med avseende på datat) generellt är mer koncentrerad, vilket leder till större koncentration för Θ_{71} .

Återigen visar det sig att den empiriska bayesmetoden ger hyfsat bra resultat, då denna ligger ganska nära skattningarna som vi får med den kompletta modellen. Detta beror på att vi i denna situation har ganska ordentligt

med data, så punktskattningen är av hög kvalitet och utgör en bra approximering av aposteriorifördelningen hos hyperparametern. Utan att göra denna närmare analys kan det dock vara svårt att komma fram till denna slutsats, så om man söker hög tillförlitlighet är det alltid en bra idé att försöka modellera hela hierarkin från ett bayesianskt perspektiv.

Avslutningsvis jämför vi skattningarna med skattningarna vi fick från de separata skattningarna x_j/n_j . Vi kan repetera simuleringarna ovan för alla parametrar $\Theta_1, \Theta_2, \dots, \Theta_{71}$ och ta fram deras aposterioriväntevärden. Om vi plottar dessa tillsammans med de separata skattningarna får vi



För experiment som hade högt antal tumörer ger den hierarkiska modellen en mindre skattning, medan för experiment med mycket få tumörer ger modellen en aningen större skattning. Vi krymper alltså variationen mot mitten av fördelningen för Θ , vilket är effekten av att modellen "binder ihop" parametrarna med hjälp av hyperparametrarna A och B .

11.3 Uppgifter

- 11.1. [1] Som skogsbrukskonsult inspekterar du granskogar i Bergslagen för att upptäcka angrepp av granbarkborrar. Du för anteckningar över dina inspektioner under det gångna året och har följande resultat

Antal inspekterade	12	21	26	13	13	14
Antal angripna	8	4	13	5	5	7

Du undersöker nu en ny skog och finner där 12 angripna träd av 20 inspekterade. Använd den empiriska bayesmetoden för att bestämma aposterioriväntevärdet för proportionen av angripna träd i den aktuella skogen.

- 11.2. [2] Anta att du har en stokastisk vektor $\Theta = [\Theta_1, \Theta_2, \dots, \Theta_d]^T$ där elementen är betingat oberoende givet någon parameter Φ med samma betingade fördelningar givet Φ . Visa att $\text{Cov}[\Theta_i, \Theta_j] \geq 0$ för alla $i, j = 1, 2, \dots, d$. (*Tips:* Ta fram lagen om total kovarians.)
- 11.3. [1] En mjölkbonde vill undersöka fetthalten i mjölken som hans kor producerar. Utrustningen han använder kan antas ha ett normalfördelat mätfel med standardavvikelse 0.2 procent. Eftersom korna äter olika typer av foder (ekologiska foder eller annat) delar han upp dem i grupper och mäter mjölkens fetthalter separat. I första gruppen mäter han procentsatserna 3.83, 4.06, 4.11 och 4.04, i andra gruppen mäter han 3.40, 3.37 och 3.92 medan i tredje gruppen mäter han 3.99, 3.45, 3.51 och 4.10. Anta att han nu

mäter en ny grupp och får värdena 3.94, 4.00 och 3.63. Använd den empiriska bayesmetoden för att bestämma aposteriorisannolikheten att fetthalten i denna sista grupp överstiger fyra procent. Hur skiljer sig denna sannolikhet från aposteriorisannolikheten givet en icke-informativ apriorifördelning?

- 11.4. [2] Vi återgår till undersökningen av cykeltrafik i Berkeley, Kalifornien. För vägarna i bostadsområdet med cykelbana noterades följande data:

Antal cyklar/antal andra fordon			
16/58,	9/90,	10/48,	13/57,
19/103,	20/57,	18/86,	17/112,
35/273,	55/64		

- Antag att antalet cyklar X_j för varje gata j är binomialfördelat och låt Θ_j vara den underliggande proportionen cyklar på gatan för $j = 1, 2, \dots, 10$. Låt $\Theta_1, \Theta_2, \dots, \Theta_{10}$ vara betingat oberoende givet $A = \alpha, B = \beta$ med betingad fördelning $\text{Beta}(\alpha, \beta)$. Skriv ner aposteriorifördelningen för $\Theta_1, \Theta_2, \dots, \Theta_{10}, A, B$ givet datan och den icke-informativa apriorifördelningen $f_{A,B}(\alpha, \beta) \propto (\alpha + \beta)^{-5/2}$.
- Beräkna den marginella aposteriorifördelningen för A, B , plotta denna och simulera utfall med hjälp av metropolisalgoritmen. Använd dessa för att approximera aposterioriväntevärdet.
- Simulera utfall från $\Theta_1, \Theta_2, \dots, \Theta_{10}$ givet datat och ta fram deras aposterioriväntevärden. Jämför dessa med proportionerna i datat.
- Bestäm ett 95% symmetriskt kredibilitetsintervall för medelproportionen av cyklar i trafiken.
- En ny väg observeras och 100 fordon passerar. Bestäm ett intervall så att antalet cyklar som passerar ligger i det intervallet med 95% sannolikhet.

- 11.5. [1] En restaurangkedja försöker modellera antalet sålda luncher under en dag. Kedjan gör följande mätningar på tre av deras restauranger

Restaurang	Stockholm	Uppsala	Södertälje
Sålda luncher	79	110	102

Antag att antalet luncher på en ny restaurang (i Enköping) mäts och fås till 106. Mätningarna antas följa en poissonfördelning givet var sin intensitetsparameter (antalet luncher per dag). Dessa är i sin tur betingat oberoende med samma betingade fördelning givet ett antal hyperparametrar. Använd den empiriska bayesmetoden för att bestämma aposterioriväntevärdet för antalet luncher per dag för den nya restaurangen.

- 11.6. [2] Vi använder nu datat från uppgift 11.4 för att uppskatta det totala antalet fordon för de olika gatorna.

- Låt X_j vara antalet fordon som passerar och anta att detta har fördelningen $X_j | \Theta_j = \theta_j \sim \text{Po}(\theta_j)$, där θ_j är medelantalet fordon för den j :te gatan för $j = 1, 2, \dots, 10$. Antag vidare att dessa $\Theta_1, \Theta_2, \dots, \Theta_{10}$ är betingat oberoende och har samma betingade gammafördelning givet dess hyperparametrar $A = \alpha$ och $B = \beta$ som i sin tur har apriorifördelningen $B | A = \alpha \sim \text{Gamma}(0.05, 3/\alpha)$ och $A \sim \text{Gamma}(3, 1)$. Skriv ner den simultana aposteriorifördelningen.
- Ta fram den marginella aposteriorifördelningen för A och B givet datan och plotta den. Simulera utfall från denna med metropolisalgoritmen och ta fram aposterioriväntevärdena för A och B .
- Simulera utfall från $\Theta_1, \Theta_2, \dots, \Theta_{10}$ givet datan. Beräkna ett 95% kredibilitetsintervall för Θ_9 . Vad är sannolikheten att gata 4 i genomsnitt har fler fordon som passerar jämfört med gata 3 givet datan?

- 11.7. [1] Under sommarsemestern mäter du tiden till första myggsticket från uppvaknandet varje morgon. Då du befinner dig på olika orter under semestern noterar du också dessa och får ihop följande data

Ort	Tid till första myggstick (minuter)
Flen	20.9, 0.2, 15.0
Arild	59.8, 114.2, 136.6, 17.8
Fagerhult	3.5, 103.8, 34.7.

Du antar att tiderna är exponentialfördelade enligt en okänd parameter som varierar med orten. Tillbaka i Stockholm efter semestern blir du biten av en mygga 93 minuter efter du vaknat. Använd den empiriska bayesmetoden för att beräkna aposterioriväntevärdet för tiden till nästa myggbett i Stockholm.

11.8. [2] Vi tar nu fram en full bayesiansk hierarkisk modell för uppgift 11.7.

- Antag som tidigare att varje mätning X_{ji} är exponentialfördelad givet $\Theta_j = \theta_j$ med betingad fördelning $\text{Exp}(\theta_j)$ för $j = 1$ (Flen), $j = 2$ (Arild), $j = 3$ (Fagerhult) och $j = 4$ (Stockholm). Vidare antar vi att $\Theta_1, \Theta_2, \Theta_3, \Theta_4$ är betingat oberoende givet $A = \alpha, B = \beta$ med samma betingade fördelning $\text{Gamma}(\alpha, \beta)$ där $B | A = \alpha \sim \text{Gamma}(50, 1/\alpha)$ och $A \sim \text{Gamma}(5, 1)$. Ta fram den simultana aposteriorifördelningen.
- Beräkna den marginella aposteriorifördelningen för hyperparametrarna A och B och plotta den. Simulera utfall från denna med metropolialgoritmen och ta fram aposterioriväntevärdena. Jämför dessa med skattningarna av A och B från uppgift 11.7.
- Ta fram ett 90% kredibilitetsintervall för genomsnittstiden mellan myggstick i Stockholm.
- Vad är aposteriorisannolikheten att tiden mellan myggstick är större i Stockholm än i Arild?

11.9. [3] Antag att vi har en hierarkisk modell för normalfördelad data. Med andra ord har vi $X_{j,1}, X_{j,2}, \dots, X_{j,n_j}$ betingat oberoende givet Θ_j med betingade fördelningar $X_{j,i} | \Theta_j = \theta_j \sim N(\theta_j, \sigma^2)$ för $i = 1, 2, \dots, n_j$ och $j = 1, 2, \dots, m$ där σ^2 antas vara känd. Vi har i sin tur att $\Theta_1, \Theta_2, \dots, \Theta_m$ är betingat oberoende givet Φ_M, Φ_V där $\Theta_j | \Phi_M = \phi_M, \Phi_V = \phi_V \sim N(\phi_M, \phi_V)$ för $j = 1, 2, \dots, m$. Apriorifördelningen för Φ_M, Φ_V låter vi vara obestämd tills vidare.

- För att underlätta beräkningarna ersätter vi $X_{j,1}, X_{j,2}, \dots, X_{j,n_j}$ med deras medelvärden $Y_j = n_j^{-1} \sum_{i=1}^{n_j} X_{j,i}$ för $j = 1, \dots, m$. Visa att den simultana aposteriorifördelningen för $\Theta_1, \Theta_2, \dots, \Theta_m, \Phi_M, \Phi_V$ med avseende på $Y_1, Y_2, \dots, Y_m$ ges av

$$f_{\Theta, \Phi_M, \Phi_V | \mathbf{Y}}(\boldsymbol{\theta}, \phi_M, \phi_V | \mathbf{y}) \propto f_{\Phi_M, \Phi_V}(\phi_M, \phi_V) \prod_{j=1}^m \frac{1}{\sqrt{2\pi\phi_V}} e^{-(\theta_j - \phi_M)^2 / 2\phi_V} \cdot \frac{1}{\sqrt{2\pi\sigma_j^2}} e^{-(y_j - \theta_j)^2 / 2\sigma_j^2}$$

där $\sigma_j^2 = \sigma^2 / n_j$ för $j = 1, \dots, m$.

- Visa att den betingade aposteriorifördelningen för Θ_j givet Φ_M, Φ_V ges av

$$\Theta_j | \Phi_M = \phi_M, \Phi_V = \phi_V, \mathbf{Y} = \mathbf{y} \sim N(\hat{\theta}_j, \hat{v}_j)$$

där

$$\hat{\theta}_j = \frac{\phi_M / \phi_V + y_j / \sigma_j^2}{1 / \phi_V + 1 / \sigma_j^2} \quad \text{och} \quad \hat{v}_j = \frac{1}{1 / \phi_V + 1 / \sigma_j^2}.$$

- Visa att vi kan marginalisera bort parametern Θ_j och i den betingade fördelningen för Y_j , vilket ger

$$Y_j | \Phi_M = \phi_M, \Phi_V = \phi_V \sim N(\phi_M, \phi_V + \sigma_j^2).$$

- Visa att den marginella aposteriorifördelningen för Φ_M, Φ_V ges av

$$f_{\Phi_M, \Phi_V | \mathbf{Y}}(\boldsymbol{\phi}, \phi_M, \phi_V | \mathbf{y}) \propto f_{\Phi_M, \Phi_V}(\phi_M, \phi_V) \prod_{j=1}^m \frac{1}{\sqrt{2\pi(\phi_V + \sigma_j^2)}} e^{-(y_j - \phi_M)^2 / 2(\phi_V + \sigma_j^2)}.$$

- (e) Åtta olika skolor har implementerat ett specialprogram med syfte att förbättra elevernas resultat på vissa standardiserade tester. Följande data observeras

Skola	A	B	C	D	E	F	G	H
Effekt	28	8	-3	7	-1	1	18	12
Mätfel	15	10	16	11	9	11	10	18

Anta att datan är normalfördelad med standardavvikelse som ges av mätfelet. Implementera en hierarkisk modell med den icke-informativa apriorifördelningen $f_{\Phi_M, \Phi_V}(\phi_M, \phi_V) \propto 1$. Ta fram aposteriorimedianerna för $\Theta_1, \Theta_2, \dots, \Theta_8$ och beräkna aposteriorisannolikheten att effekten är högre i skola A jämfört med skola C.

Kapitel 12

Nu när vi har sett en del bayesiansk inferens återvänder vi till det frekventistiska ramverket. I frekventistisk inferens är målet att hitta en bra punktskattning för ett visst okänt parametervärde. Punktskattningar ger oss värden för en eller flera parametrar med hjälp av data i form av ett stickprov. Vi vill dock inte alltid endast ha ett förslag på parametervärdet som ges när vi använder en viss punktskattningsmetod. Istället vill vi ofta svara en viss fråga om parametervärdet. Till exempel skulle vi kunna ställa frågan, ”Givet ett stickprov $x_1, \dots, x_n$ från en $f_X(x|\theta)$ -population stämmer det att $\theta > 10$?” eller ”Stämmer det att $\theta = 10$?” Eftersom vi inte vet θ :s värde och vi istället bara har data föredrar vi att svara frågan med ett svar tillsammans med en sannolikhet att svaret stämmer. Med andra ord vill vi utveckla hypotestest för frekventistiska modeller (som vi redan har gjort för bayesianska modeller).

Generellt sett är en *hypotes* ett visst påstående om en populationsparameter såsom $\mu = 0$, $\lambda > 3$ eller $\sigma^2 > 1$. I det bayesianska ramverket hade vi hypoteser på formen $\theta \in \Omega_0$ där Ω_0 var en viss delmängd av parameterrummet Ω . Hypoteser i det frekventistiska ramverket är på samma form. Målet i hypotesprövning är att bestämma om hypotesen stöds av datan där datan är ett stickprov. Låt $x_1, \dots, x_n$ vara ett stickprov från en $f_X(x|\theta)$ -population där θ är en parameter som tillhör parameterrummet Ω . Vi har en viss *nollhypotes* (man kan också säga *grundhypotes*) H_0 som påstår att θ tillhör en delmängd Ω_0 av Ω . Vi skriver nollhypotesen som

$$H_0 : \theta \in \Omega_0.$$

Som alternativ till nollhypotesen H_0 har vi en *mothypotes* (eller *alternativhypotes*) H_1 som består av alla möjliga värden av θ som inte tillhör nollhypotesen. Det vill säga att

$$H_1 : \theta \in \Omega_1,$$

där $\Omega_1 := \Omega \setminus \Omega_0$ är komplementet av Ω_0 i parameterrummet.

Vi säger att H_0 *accepteras* om H_0 stöds av datan $x_1, \dots, x_n$ och H_0 *förkastas* om den inte stöds av datan. Detta är detsamma som att förkasta H_1 respektive acceptera H_1 eftersom H_0 och H_1 är komplementära mängder. Det är vanligt i statistik för att man antingen förkastar H_0 eller inte förkastar H_0 eftersom vårt beslut är baserat på ett stickprov och det kan därför vara fel att säga ”Ja, $\theta \in \Omega_0$.” Med detta i åtanke föredrar många statistiker att bara säga ”Nej, vi kan inte förkasta nollhypotesen när H_0 stöds av datan.” Skillnaden mellan att acceptera och inte förkasta H_0 är inte oviktig men vi ska inte säga mer om det i denna bok.

12.1 Frekventistiska hypotestest

Vi har sett redan i föregående kapitel att man kan använda beslutsteori och bayesianska metoder för att ge ett svar på frågor om en parameter som ”Givet ett stickprov $x_1, \dots, x_n$ från en $f_X(x|\theta)$ -population stämmer det att $\theta > 10$?” eller ”Stämmer det att $\theta = 10$?” Den andra frågan är kanske svårt att arbeta med i det bayesianska ramverket när θ är kontinuerlig men i det frekventistiska ramverket där θ inte är slumpmässig behöver vi inte oroa oss om detta. Ett exempel som motiverar hur vi kan svara på sådana frågor i det frekventistiska ramverket är följande.

Exempel 12.1. Vi betraktar leveranshastigheten av produkter från en viss fabrik. Fabriken har en bas-leveranshastighet som de måste upprätthålla för att fortsätta vara i drift. Denna baslinje är 3 leveranser med ett tusen artiklar var per arbetsdag. Under COVID-19-pandemin levererade fabriken enligt bashastigheten. Efter nedstängningarna var över registrerade fabriken sin leveranshastighet under fem slumpmässiga dagar:

$$x_1 = 9, x_2 = 2, x_3 = 4, x_4 = 3, x_5 = 6.$$

Fabriken tror att deras genomsnittliga leveranshastighet har ökat efter pandemin. Under det frekventistiska perspektivet tror vi att detta väntevärde är ett visst (okänt) värde. Vi kan verifiera om påståendet stöds av datan. För

att göra det modellerar vi leveranshastigheten med en $\text{Po}(\lambda)$ -fördelning och tar nollhypotesen

$$H_0 : \lambda = 3.$$

Parameterrummet är bara $\Omega = \{\lambda \in \mathbb{R} : \lambda \geq 3\}$ eftersom 3 är fabriken minsta möjliga leveranshastighet. Därför kan vi ta mothypotesen som ges av

$$H_1 : \lambda > 3.$$

Som ett första steg kan vi betrakta sannolikheten av datan om nollhypotesen stämmer. Det kan ge oss en idé om hur rimlig nollhypotesen är baserad på den observerade datan. Eftersom vi vill betrakta sannolikheten av den genomsnittliga leveranshastigheten använder vi statistiken $\bar{x}$ och betraktar sannolikheten $P(\bar{x}|\lambda = 3)$. För att beräkna denna sannolikhet använder vi samplingfördelningen $f_{\bar{X}}(\bar{x}|\lambda)$ vilken ges av

$$f_{\bar{X}}(\bar{x}|\lambda) = \frac{(5\lambda)^{5\bar{x}} e^{-5\lambda}}{(5\bar{x})!} \quad \text{för } \bar{x} \in \{0, \frac{1}{5}, \frac{2}{5}, \dots\}.$$

För den givna datan har vi att

$$f_{\bar{X}}(\bar{x}|\lambda = 3) = f_{\bar{X}}(4.8|\lambda = 3) = \frac{(15)^{5(4.8)} e^{-15}}{(5(4.8))!} \approx 0.0083.$$

Eftersom denna sannolikhet är liten är det mycket osannolikt att vi skulle ha sett datan om nollhypotesen stämmer. Detta indikerar att vi kanske vill förkasta nollhypotesen $\lambda = 3$. Med tanke på att fabriken kanske vill köra experimentet igen i framtiden skulle det vara mycket lättare för dem om vi kan ge en regel för att förkasta nollhypotesen så att det inte behöver beräkna dessa sannolikheter varje gång. Anta till exempel att vi istället har datan $\bar{x} = 3.8$. Då kommer vi att få $f_{\bar{X}}(\bar{x}|\lambda = 3) \approx 0.0557$. Detta är också en ganska låg sannolikhet men är den tillräckligt låg för att förkasta H_0 ? Det skulle även vara lättare om vi hade en mängd R och en regel som säger att när $\bar{x} \in R$ borde vi förkasta H_0 . Det skulle vara även bättre om vi kan definiera området R enligt en sannolikhet som beskriver hur troligt det är att se datan när H_0 stämmer.

Till exempel vet vi att under nollhypotesen har vi $E[\bar{X}|\lambda = 3] = 3$. Så sannolikheten att observera $\bar{x}$ som är mycket större än 3 är ganska liten. För att minska risken att vi förkasta nollhypotesen när den egentligen stämmer kan vi förkasta nollhypotesen när $\bar{x} \geq t$ och $P(\bar{x} \geq t|\lambda = 3)$ är liten. Vi får själva bestämma vad vi anser vara en liten sannolikhet (dvs. värdet $P(\bar{x} \geq t|\lambda = 3)$ som vi vill ha) och när vi har detta kan vi lösa ut värdet t . Detta ger oss området $R = \{\bar{x} : \bar{x} \geq t\}$. Då kan vi utföra hypotestestet för godtycklig data så många gånger vi vill!

Till exempel, om fabriken vill att sannolikheten att vi förkastar nollhypotesen när den stämmer är lika med 0.05 behöver vi t så att $P(\bar{X} \geq t|\lambda = 3) = 0.05$. Vi beräknar värdet t med hjälp av formeln

$$\begin{aligned} 0.05 &= P(\bar{X} \geq t|\lambda = 3), \\ &= 1 - P(\bar{X} < t|\lambda = 3), \\ &= 1 - P(5\bar{X} < k|\lambda = 3), \quad (\text{där } k \in \{0, 1, 2, \dots\}) \\ &= 1 - \sum_{i=0}^{k-1} \frac{(15)^{5k} e^{-15}}{k!}. \end{aligned}$$

Det följer att för $t = 21/5 = 4.2$ är $P(\bar{X} \geq t|\lambda = 3) \approx 0.05$ så vi har regeln

$$\text{Förkasta } H_0 : \lambda = 3 \text{ om } \bar{X} \geq 4.2.$$

På följande sidor utvecklar vi ett allmänt sätt att hitta sådana regler för att förkasta en hypotes. På ett formellt sett är ett *hypotestest* (eller ett *test*) en regel som vi använda för att förkasta H_0 (och därmed acceptera H_1). Mängden stickprov $\mathbf{x}$ för vilka hypotestestet förkastar H_0 kallas för *det kritiska området*. Det kritiska området brukar betecknas R . Till exempel har vi det kritiska området $R = \{\mathbf{x} \in \mathbb{R}^5 : \bar{x} \geq 4.2\}$ i Exempel 12.1. Hypotestest formuleras ofta med en statistiska

$$W(\mathbf{X}) = W(X_1, \dots, X_n)$$

som kallas för en *testvariabel*. I exemplet ovan har vi $W(\mathbf{X}) = \bar{X}$.

Eftersom det finns många olika situationer där vi vill ha ett hypotestest skulle det vara bra att ha en allmän metod för att konstruera ett hypotestest som kan användas för den givna modellen. Nu betraktar vi en sådan metod.

12.2 Likelihood-kvottest

Ett sett att utvärdera en hypotes $H_0 : \theta \in \Omega_0$ är att jämföra likelihoodfunktionen begränsad till nollhypotesen med likelihoodfunktionen över hela parameterrummet Ω . Om likelihoodfunktionens värden på Ω_0 är tillräckligt små relativt värdena över hela parameterrummet har vi en bra anledning att förkasta H_0 . Därför vill vi betrakta testvariabeln

$$\lambda(\mathbf{x}) = \frac{\max_{\theta \in \Omega_0} L(\theta|\mathbf{x})}{\max_{\theta \in \Omega} L(\theta|\mathbf{x})}$$

som kallas för *likelihood-kvotstestvariabeln* eller bara *likelihoodkvoten*.

Notera att ML-skattningen $\hat{\theta}$ för datan $\mathbf{x}$ uppfyller

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Omega} L(\theta|\mathbf{x})$$

och därför är $\hat{\theta}$ ML-skattningen för θ om och endast om

$$\max_{\theta \in \Omega} L(\theta|\mathbf{x}) = L(\hat{\theta}|\mathbf{x}).$$

Så likelihoodkvotens nämnare är helt enkelt likelihoodfunktionens värde för ML-skattningen. På samma sätt kan vi beräkna täljaren som $L(\hat{\theta}_0|\mathbf{x})$ där $\hat{\theta}_0$ är ML-skattningen under nollhypotesen; dvs.

$$\hat{\theta}_0 = \operatorname{argmax}_{\theta \in \Omega_0} L(\theta|\mathbf{x}).$$

Eftersom vi redan vet hur man beräknar ML-skattningar för många olika modeller kan vi också beräkna likelihood-kvoter!

Medan det ofta händer att mängden Ω_0 är sluten (till exempel, $H_0 : \mu = 3$ eller $H_0 : \lambda \geq 5.7$) kan det också hända att Ω_0 är öppen (exempelvis, $H_0 : \lambda > 5.7$). För att konstruera ett likelihood-kvottest i sådana fall ersätter vi max med sup i likelihoodkvoten:

$$\lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Omega_0} L(\theta|\mathbf{x})}{\sup_{\theta \in \Omega} L(\theta|\mathbf{x})}.$$

Notera att täljaren av $\lambda(\mathbf{x})$ är alltid mindre än eller lika med nämnaren; dvs. $0 \leq \lambda(\mathbf{x}) \leq 1$ när $L(\hat{\theta}|\mathbf{x}) > 0$. När $\lambda(\mathbf{x})$ är liten följer det att vi kan hitta parametrar i $\Omega \setminus \Omega_0$ som ger en ganska mycket bättre likelihood än alla parametrarna i Ω_0 . Så vi kan formulera *likelihood-kvottestet*

Förkasta $H_0 : \theta \in \Omega_0$ när $\lambda(\mathbf{x}) \leq c$ för något $c \in (0, 1)$.

I detta test tar vi alltså $H_1 : \theta \in \Omega_1 = \Omega \setminus \Omega_0$ som mothypotesen. Precis som vi själva fick bestämma gränsen 0.05 i Exempel 12.1 får vi även bestämma valet för $c \in (0, 1)$ som vi använder i likelihood-kvottestet. (I det exemplet bestämde vi värdet för $P(\bar{x} \geq t | \lambda = 3) = P(\mathbf{x} \in R | \lambda = 3)$ och använde detta val för att hitta värdet t som definierar det kritiska området. Vi kommer att se hur vi kan göra detsamma här men vi utforskar först likelihood-kvotstestets form för givet c .) I punkthypotesens fallet reduceras beräkningen av likelihood-kvotstestvariabel till en ML-skattningsberäkning:

Exempel 12.2. Låt $x_1, \dots, x_n$ vara ett stickprov från en $N(\mu, 1)$ -population. Vi vill testa

$$H_0 : \mu = \mu_0 \quad \text{mot} \quad H_1 : \mu \neq \mu_0.$$

För detta test är $\Omega_0 = \{\mu_0\}$ och $\Omega_1 = \Omega \setminus \Omega_0 = \mathbb{R} \setminus \{\mu_0\}$ och likelihoodkvoten ges av

$$\begin{aligned} \lambda(\mathbf{x}) &= \frac{\sup_{\mu \in \Omega_0} L(\mu|\mathbf{x})}{\sup_{\mu \in \Omega} L(\mu|\mathbf{x})}, \\ &= \frac{L(\mu_0|\mathbf{x})}{\sup_{\mu \in \mathbb{R}} L(\mu|\mathbf{x})}, \\ &= \frac{L(\mu_0|\mathbf{x})}{L(\hat{\mu}|\mathbf{x})}, \\ &= \frac{f_{\mathbf{X}}(\mathbf{x}|\mu_0)}{f_{\mathbf{X}}(\mathbf{x}|\hat{\mu})}, \end{aligned}$$

där $\hat{\mu}$ är ML-skattningen för μ givet datan. Vi såg i Exempel 6.4 att $\hat{\mu} = \bar{x}$. Så vi har att

$$\begin{aligned}\lambda(\mathbf{x}) &= \frac{f_{\mathbf{X}}(\mathbf{x}|\mu_0)}{f_{\mathbf{X}}(\mathbf{x}|\hat{\mu})}, \\ &= \frac{\frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} \sum_{i=1}^n (x_i - \mu_0)^2\right)}{\frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2\right)}, \\ &= \exp\left(-\frac{1}{2} \left(\sum_{i=1}^n (x_i - \mu_0)^2 - \sum_{i=1}^n (x_i - \bar{x})^2\right)\right), \\ &= \exp\left(-\frac{1}{2} n(\bar{x} - \mu_0)^2\right),\end{aligned}$$

där vi har använt

$$\sum_{i=1}^n (x_i - \mu_0)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu_0)^2.$$

Ett likelihood-kvottest kan då formuleras som

$$\text{Förkasta } H_0 : \mu = \mu_0 \text{ om } e^{-\frac{n}{2}(\bar{x} - \mu_0)^2} \leq c$$

där $c \in (0, 1)$ fortfarande måste specificeras. Med lite algebra ser vi att testet är ekvivalent med

$$\text{Förkasta } H_0 : \mu = \mu_0 \text{ om } |\bar{x} - \mu_0| \geq c',$$

där $c' = \sqrt{-\frac{2}{n} \log(c)}$. Eftersom $c \in (0, 1)$ är godtycklig kan vi ta vilken c' som helst i $(0, \infty)$. Med detta test förkastar vi alltså H_0 när stickprovsmedelvärdet är tillräckligt långt borta från μ_0 . Testvariabeln är då

$$W(\mathbf{x}) = |\bar{x} - \mu_0|,$$

där vi förkastar H_0 när $W(\mathbf{x})$ är stor. Det kritiska området är

$$R = \{\mathbf{x} : |\bar{x} - \mu_0| \geq c'\},$$

där $c' \in (0, \infty)$ är fixt.

Ett exempel där nollhypotesen inte är en punkthypotes är följande.

Exempel 12.3. Låt $X_1, \dots, X_n$ vara oberoende och $f_X(x)$ -fördelade där $f_X(x)$ tillhör en lägesfamilj med standardtätthetsfunktion $f_Z(z)$ där $Z \sim \text{Exp}(1)$ och lägesparameter θ ; dvs.

$$f_X(x|\theta) = f_Z(x - \theta) \quad \text{där } Z \sim \text{Exp}(1).$$

Så vi har då att

$$\begin{aligned}f_X(x|\theta) &= \begin{cases} e^{-(x-\theta)} & x \geq \theta, \\ 0 & x < \theta, \end{cases} \\ &= e^{-(x-\theta)} \mathbf{1}_{[\theta, \infty)}(x).\end{aligned}$$

Vi vill testa

$$H_0 : \theta \leq \theta_0 \quad \text{mot} \quad H_1 : \theta > \theta_0,$$

för något θ_0 . Parameterrummet är $\Omega = \mathbb{R}$ och parametervärdena som uppfyller H_0 är

$$\Omega_0 = \{\theta \in \mathbb{R} : \theta \leq \theta_0\} = (-\infty, \theta_0].$$

Likelihoodfunktionen för θ är

$$\begin{aligned}L(\theta|\mathbf{x}) &= \prod_{i=1}^n f_{X_i}(x_i|\theta), \\ &= \prod_{i=1}^n e^{-(x_i-\theta)} \mathbf{1}_{[\theta, \infty)}(x_i), \\ &= e^{-\sum_{i=1}^n (x_i-\theta)} \mathbf{1}_{[\theta, \infty)}(\min_i(x_i)), \\ &= e^{n(\theta-\bar{x})} \mathbf{1}_{(-\infty, \min_i(x_i)]}(\theta),\end{aligned}$$

eftersom $\mathbf{1}_{[\theta, \infty)}(\min_i(x_i)) = 1$ om och endast om $\mathbf{1}_{(-\infty, \min_i(x_i)]}(\theta) = 1$. Det följer att $L(\theta|\mathbf{x})$ är lika med 0 för $\theta > \min_i(x_i)$ och strikt växande på $(-\infty, \min_i(x_i)]$. Så ML-skattningen $\hat{\theta}$ för θ (över Ω) är lika med $\min_i(x_i)$. Det följer då att

$$\sup_{\theta \in \Omega} L(\theta|\mathbf{x}) = L(\min_i(x_i)|\mathbf{x}) = e^{n(\min_i(x_i) - \bar{x})}.$$

Detta ger oss nämnaren i likelihoodkvoten.

För att beräkna täljaren behöver vi lösa det begränsade likelihoodproblemet:

$$\hat{\theta}_0 = \operatorname{argmax}_{\theta \in \Omega_0} L(\theta|\mathbf{x})$$

där $\Omega_0 = \{\theta \in \mathbb{R} : \theta_0 \geq \theta\}$. ML-skattningen $\hat{\theta}_0$ beror på om $\min_i(x_i)$ är mindre eller större än θ_0 . (Observera att både $\min_i(x_i)$ och θ_0 är kända då $\min_i(x_i)$ ges av datan $x_1, \dots, x_n$ och θ_0 är givet.) Om $\min_i(x_i) \geq \theta_0$ har vi att

$$\sup_{\theta \in \Omega_0} L(\theta|\mathbf{x}) = e^{n(\theta_0 - \bar{x})}.$$

Detta är eftersom likelihoodfunktionen är $L(\theta|\mathbf{x}) = e^{n(\theta - \bar{x})}$ för $\theta \in \Omega_0$ när $\min_i(x_i) \geq \theta_0$ och denna funktion är strikt växande på $(-\infty, \theta_0]$. Om $\min_i(x_i) < \theta_0$ har vi att $\hat{\theta} = \min_i(x_i) \in \Omega_0$ och därför

$$\sup_{\theta \in \Omega_0} L(\theta|\mathbf{x}) = \sup_{\theta \in \Omega} L(\theta|\mathbf{x}).$$

Det följer att

$$\begin{aligned} \lambda(\mathbf{x}) &= \begin{cases} 1 & \min_i(x_i) < \theta_0, \\ \frac{e^{n(\theta_0 - \bar{x})}}{e^{n(\min_i(x_i) - \bar{x})}} & \min_i(x_i) \geq \theta_0, \end{cases} \\ &= \begin{cases} 1 & \min_i(x_i) < \theta_0, \\ e^{n(\theta_0 - \min_i(x_i))} & \min_i(x_i) \geq \theta_0, \end{cases} \end{aligned}$$

Så vi har likelihood-kvottestet

$$\text{Förkasta } H_0 : \theta \leq \theta_0 \text{ om } e^{n(\theta_0 - \min_i(x_i))} \leq c$$

där $c \in (0, 1)$ är givet. Notera att vi kan ignorera fallet $\min_i(x_i) < \theta_0$ eftersom $c < 1$. På samma sätt som i det föregående exemplet kan vi omformulera hypotestestet som

$$\text{Förkasta } H_0 : \theta \leq \theta_0 \text{ om } \min_i(x_i) - \theta_0 \geq c'$$

där $c' > 0$ är givet. Här har vi $c' = -\frac{1}{n} \log(c)$. Det kritiska området för testet är då $R = \{\mathbf{x} : \min_i(x_i) - \theta_0 \geq c'\}$.

Vi kan tillämpa testet till en situation som man kan modellera med en exponentialfördelning. Exponentialfördelningar används ofta för att modellera tiden mellan händelser som i en poissonmodell – till exempel, vulkanutbrott. Eftersom det kan ta lite tid för en vulkan att bli kritiskt aktiv igen efter varje vulkanutbrott stämmer det att modellera tiden mellan vulkanutbrotten med en skiftat exponentiell modell; dvs. att vi modellerar tiden mellan vulkanutbrotten som $X = Z + \theta$ där $Z \sim \text{Exp}(1)$ och θ är en lägesparameter som representerar tiden efter ett utbrott innan vulkanen är kritiskt aktiv igen. Åren mellan vulkanutbrotten av vulkanen Mt. Sankt Helens i Washington, USA ges som

$$15, 9, 59, 18, 5, 41, 3, 7, 5, 7, 4.$$

Vi vill testa om $\theta \leq \theta_0 = 2.5$ år. Enligt datan har vi att $\min_i(x_i) = 3$. Om vi tar ett ganska litet värde för c , exempelvis, $c = 0.05$, har vi att $c' \approx 0.27$. Så testet ska förkasta $H_0 : \theta \leq \theta_0$ när $\theta_0 = 2.5$ men acceptera $H_0 : \theta \leq \theta_0$ när $\theta = 2.75$. Detta säger att tiden innan Mt. Sankt Helens blir kritiskt aktiv igen efter ett utbrott är troligtvis mer än 2.5 år men mindre än 2.75 år.

I båda exempel ovan berodde testvariabeln bara på en tillräcklig statistika för parametern θ ($\bar{x}$ för μ och $\min_i(x_i)$ för θ). Detta fenomen gäller mer generellt.

Sats 12.1. Om $T(\mathbf{X})$ är en tillräcklig statistika för θ och $\lambda^*(t)$ och $\lambda(\mathbf{x})$ är likelihood-kvotstestvariabler baserade på $T(\mathbf{X})$ respektive $\mathbf{X}$ gäller det att

$$\lambda^*(T(\mathbf{X})) = \lambda(\mathbf{X})$$

för alla $\mathbf{x}$.

Bevis. Låt $X_1, \dots, X_n$ vara oberoende och likafördelade med täthetsfunktion (eller sannolikhetsfunktion) $f_X(x|\theta)$. Eftersom $T(\mathbf{X})$ är en tillräcklig statistika för θ säger Sats 4.2 (Faktoriseringsatsen) att det finns funktioner $h(\mathbf{x})$ och $g(t|\theta)$ så att

$$f_{\mathbf{X}}(\mathbf{x}|\theta) = h(\mathbf{x})g(T(\mathbf{x})|\theta).$$

Det följer att

$$\begin{aligned} \lambda(\mathbf{x}) &= \frac{\sup_{\theta \in \Omega_0} L(\theta|\mathbf{x})}{\sup_{\theta \in \Omega} L(\theta|\mathbf{x})}, \\ &= \frac{\sup_{\theta \in \Omega_0} f_{\mathbf{X}}(\mathbf{x}|\theta)}{\sup_{\theta \in \Omega} f_{\mathbf{X}}(\mathbf{x}|\theta)}, \\ &= \frac{\sup_{\theta \in \Omega_0} h(\mathbf{x})g(T(\mathbf{x})|\theta)}{\sup_{\theta \in \Omega} h(\mathbf{x})g(T(\mathbf{x})|\theta)}, \\ &= \frac{\sup_{\theta \in \Omega_0} g(T(\mathbf{x})|\theta)}{\sup_{\theta \in \Omega} g(T(\mathbf{x})|\theta)}, \quad (h(\mathbf{x}) \text{ är konstant och den står i både täljaren och nämnaren}) \\ &= \frac{\sup_{\theta \in \Omega_0} L^*(\theta|T(\mathbf{x}))}{\sup_{\theta \in \Omega} L^*(\theta|T(\mathbf{x}))}, \quad (g(T(\mathbf{x})|\theta) = f_{T(\mathbf{X})}(T(\mathbf{x})|\theta) \text{ enligt faktoriseringsatsen}) \\ &= \lambda^*(T(\mathbf{x})). \end{aligned}$$

□

Med hjälp av Sats 12.1 kan beräkningarna i våra exempel förenklas.

Exempel 12.4. Vi återgår till Exempel 12.2 där vi hade ett stickprov $x_1, \dots, x_n$ från en $N(\mu, 1)$ -population och ville testa

$$H_0 : \mu = \mu_0 \quad \text{mot} \quad H_1 : \mu \neq \mu_0.$$

Vi vet från Exempel 5.8 att $\bar{x}$ är en tillräcklig statistika. Vi vet också från Sektion 5.1.1 att $\bar{X} \sim N(\mu, 1/n)$. Det följer att

$$L(\mu|\bar{x}) = \frac{1}{(2\pi/n)^{1/2}} e^{-\frac{n}{2}(\mu - \bar{x})^2},$$

och därför har vi att

$$\sup_{\mu \in \Omega} L(\mu|\bar{x}) = L(\bar{x}|\bar{x}) = \frac{1}{(2\pi/n)^{1/2}} e^{-\frac{n}{2}(\bar{x} - \bar{x})^2} = \frac{1}{(2\pi/n)^{1/2}}.$$

Vi har också att

$$\sup_{\mu \in \Omega_0} L(\mu|\bar{x}) = \sup_{\mu \in \{\mu_0\}} L(\mu|\bar{x}) = L(\mu_0|\bar{x}) = \frac{1}{(2\pi/n)^{1/2}} e^{-\frac{n}{2}(\mu_0 - \bar{x})^2}.$$

Det följer då att

$$\lambda(\bar{x}) = \frac{\frac{1}{(2\pi/n)^{1/2}} e^{-\frac{n}{2}(\mu_0 - \bar{x})^2}}{\frac{1}{(2\pi/n)^{1/2}}} = e^{-\frac{n}{2}(\mu_0 - \bar{x})^2} = \lambda(\mathbf{x}).$$

Detta är samma testvariabel som vi hade i Exempel 12.2.

Exempel 12.5. I Exempel 12.3 hade vi ett stickprov $x_1, \dots, x_n$ från en $f_X(x|\theta)$ -population där $f_X(x|\theta)$ tillhör lägesfamiljen med standardtäthetsfunktion $f_Z(z) = e^{-z}$ och lägesparameter θ . Vi såg att vi kan skriva den simultana täthetsfunktionen $f_{\mathbf{X}}(\mathbf{x}|\theta)$ som

$$f_{\mathbf{X}}(\mathbf{x}|\theta) = e^{n(\theta - \bar{x})} \mathbf{1}_{[\theta, \infty)}(\min_i(x_i)) = e^{n\theta} e^{-n\bar{x}} \mathbf{1}_{[\theta, \infty)}(\min_i(x_i)).$$

Det följer då från faktoriseringsatsen (Sats 4.2) att $\min_i(x_i)$ är en tillräcklig statistika för θ . Eftersom $X_i = Z_i + \theta$ där $Z_1, \dots, Z_n$ är oberoende och $\text{Exp}(1)$ -fördelade och

$$\min_i(X_i) = \min_i(Z_i + \theta) = \min_i(Z_i) + \theta$$

har vi att $f_{\min_i(X_i)}(\min_i(x_i)) = f_{\min_i(Z_i)}(\min_i(x_i) - \theta)$. Man kan visa att samplingfördelningen $f_{\min_i(Z_i)}(\min_i(z_i))$ är

$$f_{\min_i(Z_i)}(\min_i(z_i)) = \begin{cases} ne^{-n \min_i(z_i)} & 0 \leq \min_i(z_i), \\ 0 & 0 > \min_i(z_i). \end{cases}$$

Det följer att

$$f_{\min_i(X_i)}(\min_i(x_i)) = \begin{cases} ne^{-n(\min_i(x_i)-\theta)} & \theta \leq \min_i(x_i), \\ 0 & \theta > \min_i(x_i). \end{cases}$$

Eftersom $ne^{-n(\min_i(x_i)-\theta)}$ är strikt växande för $\theta \leq \min_i(x_i)$ följer det att ML-skattningen för θ på Ω är $\hat{\theta} = \min_i(x_i)$ och ML-skattningen för θ på Ω_0 är $\hat{\theta}_0 = \min_i(x_i)$ om $\min_i(x_i) < \theta_0$ och $\hat{\theta}_0 = \theta_0$ om $\min_i(x_i) \geq \theta_0$. Så vi får att

$$\begin{aligned} \lambda(\min_i(x_i)) &= \begin{cases} 1 & \min_i(x_i) < \theta_0, \\ \frac{ne^{-n(\min_i(x_i)-\theta_0)}}{ne^{-n(\min_i(x_i)-\min_i(x_i))}} & \min_i(x_i) \geq \theta_0, \end{cases} \\ &= \begin{cases} 1 & \min_i(x_i) < \theta_0, \\ e^{-n(\min_i(x_i)-\theta_0)} & \min_i(x_i) \geq \theta_0, \end{cases} \\ &= \lambda(\mathbf{x}) \end{aligned}$$

där $\lambda(\mathbf{x})$ är likelihoodkvoten som beräknas i Exempel 12.3.

Likelihood-kvottest är användbara i situationer där det finns störparametrar; dvs. parametrar som används i modellen men inte är av intresse. Störparametrar påverkar inte hur vi konstruerar testet men de kan påverka resultatet. Ett exempel är följande.

Exempel 12.6. Låt $x_1, \dots, x_n$ vara ett stickprov från en $N(\mu, \sigma^2)$ -population där både $\mu \in \mathbb{R}$ och $\sigma^2 > 0$ är okända. Vi vill testa

$$H_0 : \mu \leq \mu_0 \quad \text{mot} \quad H_1 : \mu > \mu_0.$$

Notera att vi bara är intresserade av μ (inte σ^2). Det vill säga att σ^2 är en störparameter. Eftersom testet inte sätter några begränsningar på σ^2 kan testet skrivas om som

$$H_0 : \mu \leq \mu_0 \text{ och } \sigma^2 > 0 \quad \text{mot} \quad H_1 : \mu > \mu_0 \text{ och } \sigma^2 > 0.$$

Sedan har vi

$$\Omega_0 = \{[\mu, \sigma^2]^T : \mu \leq \mu_0, \sigma^2 > 0\} = (-\infty, \mu_0] \times (0, \infty)$$

för H_0 . Vi såg i Exempel 6.4 att ML-skattningen över hela parameterrummet Ω är

$$\hat{\mu} = \bar{x} \quad \text{och} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n-1}{n} s^2.$$

Det följer att

$$\begin{aligned} \sup_{\mu \in \mathbb{R}, \sigma^2 > 0} L(\mu, \sigma^2 | \bar{x}) &= L(\hat{\mu}, \hat{\sigma}^2 | \mathbf{x}), \\ &= \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} e^{-\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (x_i - \hat{\mu})^2}, \\ &= \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} e^{-\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (x_i - \bar{x})^2}, \\ &= \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} e^{-\frac{1}{2\hat{\sigma}^2} n\hat{\sigma}^2}, \\ &= \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} e^{-\frac{n}{2}}. \end{aligned}$$

Detta ger oss likelihoodkvotens täljare.

Vi behöver nu beräkna nämnaren. När $\bar{x} \leq \mu_0$ har vi att ML-skattningen på Ω_0 är densamma som på hela parameterrummet Ω eftersom $[\bar{x}, ((n-1)/n)s^2]^T = [\hat{\mu}, \hat{\sigma}^2]^T$ tillhör Ω_0 . I detta fall har vi att

$$\sup_{[\mu, \sigma^2]^T \in \Omega_0} L(\mu, \sigma^2 | \mathbf{x}) = \sup_{\mu \in \mathbb{R}, \sigma^2 > 0} L(\mu, \sigma^2 | \mathbf{x}) = \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} e^{-\frac{n}{2}}.$$

Å andra sidan, om $\bar{x} > \mu_0$ har vi att $L(\mu, \sigma^2 | \mathbf{x})$ maximeras på $[\mu_0, \hat{\sigma}^2]^T$ där

$$\hat{\sigma}_0^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2.$$

(Det är en bra övning att visa detta!) Det följer att

$$\begin{aligned} \sup_{\mu \leq \mu_0, \sigma^2 > 0} L(\mu, \sigma^2 | \mathbf{x}) &= L(\mu_0, \hat{\sigma}_0^2 | \mathbf{x}), \\ &= \frac{1}{(2\pi\hat{\sigma}_0^2)^{n/2}} e^{-\frac{1}{2\hat{\sigma}_0^2} \sum_{i=1}^n (x_i - \mu_0)^2}, \\ &= \frac{1}{(2\pi\hat{\sigma}_0^2)^{n/2}} e^{-\frac{1}{2\hat{\sigma}_0^2} n\hat{\sigma}_0^2}, \\ &= \frac{1}{(2\pi\hat{\sigma}_0^2)^{n/2}} e^{-\frac{n}{2}}. \end{aligned}$$

Vi har då likelihood-kvotstestvariabeln

$$\begin{aligned} \lambda(\mathbf{x}) &= \begin{cases} 1 & \bar{x} \leq \mu_0, \\ \frac{L(\mu_0, \hat{\sigma}_0^2 | \mathbf{x})}{L(\bar{x}, \hat{\sigma}^2 | \mathbf{x})} & \bar{x} > \mu_0, \end{cases} \\ &= \begin{cases} 1 & \bar{x} \leq \mu_0, \\ \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2}\right)^{n/2} & \bar{x} > \mu_0. \end{cases} \end{aligned}$$

Eftersom $c < 1$ har vi likelihoodkvottestet

$$\text{Förkasta } H_0 : \mu \leq \mu_0 \text{ om } \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2}\right)^{n/2} \leq c.$$

Med hjälp av lite algebra kan vi förenkla testet. Notera att

$$\begin{aligned} \hat{\sigma}^2 &= \frac{n-1}{n} s^2, \quad \text{och} \\ \hat{\sigma}_0^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 + (\bar{x} - \mu_0)^2 = \frac{n-1}{n} s^2 + (\bar{x} - \mu_0)^2. \end{aligned}$$

Det följer att $\left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2}\right)^{n/2} \leq c$ om och endast om

$$\begin{aligned} \frac{\frac{n-1}{n} s^2}{\frac{n-1}{n} s^2 + (\bar{x} - \mu_0)^2} &\leq c^{2/n}, \quad \text{om och endast om} \\ \frac{n-1}{n-1 + \frac{(\bar{x} - \mu_0)^2}{s^2/n}} &\leq c^{2/n}, \quad \text{om och endast om} \\ \frac{(\bar{x} - \mu_0)^2}{s^2/n} &\geq (n-1) \left(\frac{1}{c^{2/n}} - 1 \right), \quad \text{om och endast om} \\ \left| \frac{(\bar{x} - \mu_0)}{s/\sqrt{n}} \right| &\geq c' \end{aligned}$$

där

$$c' = \sqrt{(n-1) \left(\frac{1}{c^{2/n}} - 1 \right)}.$$

Vi har då testet

$$\text{Förkasta } H_0 : \mu \leq \mu_0 \text{ om } \left| \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \right| \geq c'.$$

Men detta är ekvivalent med

$$\text{Förkasta } H_0 : \mu \leq \mu_0 \text{ om } \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \geq c' \text{ och } \bar{x} > \mu_0$$

(eftersom testet accepterar H_0 när $\lambda(\mathbf{x}) > c$ för givet $0 < c < 1$ och $\lambda(\mathbf{x}) = 1$ när $\bar{x} \leq \mu_0$). När det riktiga parametervärdet μ är lika med μ_0 följer det att testvariabeln är t-fördelad med $n-1$ frihetsgrader; dvs. $W(\mathbf{X}) \sim t(n-1)$. Detta test är ett *t-test*!

12.3 Val av tröskelvärde

I föregående kapitel utvecklade vi en familj av hypotestest på formen

$$\text{Förkasta } H_0 \text{ om } \lambda(\mathbf{x}) \leq c$$

där $\lambda(\mathbf{x})$ är likelihoodkvoten och $c \in (0, 1)$. Sådana test definieras enligt likelihoodfunktionen och de kan därför tillämpas på många olika modeller. Ett viktigt steg när vi använder ett likelihood-kvottest är att bestämma värdet $c \in (0, 1)$ som vi vill använda. Vi kan såklart ta vilket värde som helst men det är ju mycket bättre om vi kan motivera valet för c . Hur kan vi göra det?

I Exempel 12.6 hade vi ett stickprov $x_1, \dots, x_n$ från en $N(\mu, \sigma^2)$ -fördelning med både μ och σ^2 okända. Målet var att bestämma ett test för

$$H_0 : \mu \leq \mu_0 \quad \text{mot} \quad H_1 : \mu > \mu_0$$

för ett givet $\mu_0 \in \mathbb{R}$. Vi beräknade likelihood-kvottestet

$$\text{Förkasta } H_0 \text{ om } \frac{\bar{x} - \mu_0}{s/\sqrt{n}} > c' \text{ och } \bar{x} \geq \mu_0$$

där

$$c' = \sqrt{(n-1) \left(\frac{1}{c^{2/n}} - 1 \right)} \in (0, \infty).$$

För att hitta ett välmotiverat val till c' kan vi göra något liknande det vi gjorde i det första exemplet i föregående kapitel. För $\mu' \in \Omega_0 = \{\mu : \mu \leq \mu_0\}$ betraktar vi sannolikheten att testet förkastar H_0 givet $\mu = \mu'$:

$$P \left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}} > c' \mid \mu = \mu' \right) = P(\bar{X} - c'(S/\sqrt{n}) > \mu_0 \mid \mu = \mu').$$

Man kan visa att

$$P \left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}} > c' \mid \mu = \mu' \right) \leq P \left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}} > c' \mid \mu = \mu_0 \right)$$

för alla $\mu' \in \Omega_0$ eftersom $\mu' \leq \mu_0$. Med andra ord kommer testet att förkasta H_0 för ett givet c' trots att H_0 stämmer med den största sannolikheten när $\mu = \mu_0$. Om vi begränsar denna sannolikhet att vara liten kan vi lösa ut ett välmotiverat val till c' . Till exempel vi kan specificera att

$$P \left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}} > c' \mid \mu = \mu_0 \right) = 0.05.$$

Eftersom $\mu = \mu_0$ följer det att testvariabeln $\frac{\bar{X} - \mu_0}{S/\sqrt{n}}$ är $t(n-1)$ -fördelad. Därför har vi att c' är α -kvantilen för en $t(n-1)$ -fördelningen; dvs. c' är lika med värdet $t_{n-1, \alpha}$ som uppfyller

$$F_T(t_{n-1, \alpha}) = 1 - \alpha \quad \text{där } T \sim t(n-1).$$

Vi kan beräkna $t_{n-1, \alpha}$ med hjälp av T 's täthetsfunktion, en statstabel eller vi kan skatta kvantilen med hjälp av simulerade utfall från en $t(n-1)$ -fördelning. Testet ovan blir då

$$\text{Förkasta } H_0 \text{ om } \frac{\bar{x} - \mu_0}{s/\sqrt{n}} > t_{n-1, \alpha} \text{ och } \bar{x} \geq \mu_0.$$

På detta sätt har vi ett välmotiverat val för värdet c' för detta test. Valet ger oss en sannolikhetstolkning för värdet som bestämmer när vi ska förkasta nollhypotesen. Sådana tester (där testvariabeln är t -fördelad under nollhypotesen) kallas för *t-test* och har flera användbara tillämpningar. Ett exempel är följande.

Exempel 12.7. Låt $\mathbf{X} = [X_1, \dots, X_m]^T \sim N(\boldsymbol{\mu}, \Sigma)$ och ta $i, j \in [m]$ och $C \subseteq [m] \setminus \{i, j\}$. Vi vill testa

$$H_0 : X_i \perp\!\!\!\perp X_j \mid \mathbf{X}_C \quad \text{mot} \quad H_1 : X_i \not\perp\!\!\!\perp X_j \mid \mathbf{X}_C.$$

För att göra det vi ska konstruera ett *t-test* vars testvariabel ges av *den partiella korrelationen*. Inversen av kovariansmatrisen Σ betecknas $K = [k_{ij}]_{i,j=1}^m$ och kallas för *precisionsmatrisen*. *Den partiella korrelationen* av X_i och X_j givet $\mathbf{X}_{[m] \setminus \{i,j\}}$ definieras som

$$\rho_{i,j|[m] \setminus \{i,j\}} = -\frac{k_{ij}}{\sqrt{k_{ii}k_{jj}}}.$$

När vi vill betrakta $C \subsetneq [m] \setminus \{i, j\}$ (dvs. när $\mathbf{X}_{[m] \setminus (C \cup \{i, j\})}$ är störparametrar) kan vi arbeta med marginalfördelningen $\mathbf{X}_{\{i, j\} \cup C} \sim N(\boldsymbol{\mu}_{\{i, j\} \cup C}, \Sigma_{\{i, j\} \cup C, \{i, j\} \cup C})$ (se Kapitel 2). I detta fall låter vi $\boldsymbol{\mu} = \boldsymbol{\mu}_{\{i, j\} \cup C}$ och $\Sigma = \Sigma_{\{i, j\} \cup C, \{i, j\} \cup C}$ för att förenkla notationen.

Eftersom Σ är positivt definit följer det att K också är positivt definit och därför $k_{ii} \neq 0$ för alla $i \in [m]$. Vi har också att $\rho_{i, j|C} = 0$ om och endast om $k_{ij} = 0$. Med hjälp av *Cramers regel* kan vi beräkna k_{ij} enligt

$$k_{ij} = \frac{(-1)^{i+j} \det(\Sigma_{C \cup \{j\}, C \cup \{i\}})}{\det(\Sigma)}.$$

Eftersom Σ är positivt definit har vi att $\det(\Sigma) \neq 0$. Vi har alltså att $k_{ij} = 0$ om och endast om $\det(\Sigma_{C \cup \{j\}, C \cup \{i\}}) = 0$. Enligt Sats 3.1 har vi att $X_i \perp\!\!\!\perp X_j | \mathbf{X}_C$ om och endast om $\Sigma_{C \cup \{j\}, C \cup \{i\}}$ har rang $|C|$. Eftersom $\Sigma_{C \cup \{j\}, C \cup \{i\}}$ har delmatrisen $\Sigma_{C, C}$ som är av rang $|C|$ (eftersom det är positivt definit) följer det att $\Sigma_{C \cup \{i\}, C \cup \{j\}}$ har rang $|C|$ om och endast om $\det(\Sigma_{C \cup \{i\}, C \cup \{j\}}) = 0$. Det följer därför att $\rho_{i, j|C} = 0$ om och endast om $X_i \perp\!\!\!\perp X_j | \mathbf{X}_C$.

Givet ett stickprov $\mathbf{x}_1, \dots, \mathbf{x}_n$ från $N(\boldsymbol{\mu}, \Sigma)$ definierat vi *den partiella stickprovskorrelationen*

$$r_{i, j|C} = \frac{\hat{k}_{ij}}{\sqrt{\hat{k}_{ii} \hat{k}_{jj}}}$$

där $\hat{K} = [\hat{k}_{ij}]_{i, j=1}^m = \hat{\Sigma}^{-1}$ är *stickprovsprecisionmatrisen*; dvs. inversen av stickprovskovariansmatrisen från Sats 6.1. Om $\hat{\Sigma}$ är positivt definit har vi att det är ML-skattningen för Σ (enligt Sats 6.1). Med hjälp av Sats 6.2 har vi då att $r_{i, j|C}$ är ML-skattningen för $\rho_{i, j|C}$. Så ett bra test för $H_0 : X_i \perp\!\!\!\perp X_j | \mathbf{X}_C$ är att förkasta H_0 om $r_{i, j|C}$ är långt borta från 0. Med hjälp av beräkningarna i Exempel 5.5 och en regressionskurs på mastersnivå kan det visas att testvariabeln

$$T(\mathbf{X}) = \sqrt{n - |C| - 2} \frac{r_{i, j|C}}{\sqrt{1 - r_{i, j|C}^2}}$$

är $t(n - |C| - 2)$ -fördelad. (Idén är att statistikan t i Exempel 5.5 är lika med statistikan $t(\mathbf{x})$ för denna testvariabel. Till exempel är det bra övning att visa att detta i fallet $C = \emptyset$.) Det kan också visas att $-1 \leq r_{i, j|C} \leq 1$. Därför kommer $T(\mathbf{x})$ att vara liten eller stor när $r_{i, j|C}$ är liten respektive stor.

Det följer att vi kan använda $T(\mathbf{X})$ för att formulera ett t -test enligt

$$\text{Förkasta } H_0 : X_i \perp\!\!\!\perp X_j | \mathbf{X}_C \text{ om } |T(\mathbf{x})| \geq c.$$

där värdet c anses vara lika med en α -kvantil för en $t(n - |C| - 2)$ -fördelning.


Som ett exempel kan vi tillämpa testet för att lära oss en acyklisk riktad graf med avseende på vilken datafördelning är markovsk. Vi har ett stickprov av storlek $n = 5000$ från $\mathbf{X} = [X_1, X_2, X_3]^T \sim N(\mathbf{0}, \Sigma)$ och stickprovskovariansmatrisen är

$$\hat{\Sigma} = \begin{bmatrix} 0.990 & 0.018 & 0.987 \\ 0.018 & 0.968 & 0.972 \\ 0.987 & 0.972 & 2.920 \end{bmatrix}$$

Det finns sex möjliga oberoenderelationer $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B | \mathbf{X}_C$ som fördelningen kan uppfylla. Vi använda testet ovan för att acceptera eller förkasta olika oberoenderelationer. Vi får resultatet

A	B	C	Beslut
1	2	$\emptyset$	acceptera
1	3	$\emptyset$	förkasta
2	3	$\emptyset$	förkasta
1	2	3	förkasta
1	3	2	förkasta
2	3	1	förkasta

Det följer att fördelningen (enligt datan och testet) bara uppfyller en enda oberoenderelation; nämligen $X_1 \perp\!\!\!\perp X_2$. Enligt Sats 4.2 har vi att $\mathbf{X}$ är markovsk med avseende på grafen



Detta är ett första exempel på *icke-vägled inlärning*. Icke-vägled inlärning fokuserar på att lära sig information om hur simultant fördelade variabler är relaterade. I en kurs om maskininlärning kommer du lära dig att icke-vägled inlärningsalgoritmer försöker lära sig relationer mellan data i form av kluster eller grafer – t.ex. acykliska riktade grafer!

12.4 Styrkefunktionen

I exemplet ovan använde vi att testvariabelns samplingfördelning var t -fördelad under nollhypotesen för att bestämma ett rimligt val av c i vårt likelihood-kvottest. Vi vill ha en metod för att göra detta generellt. Idén är att använda en funktion som kallas för styrkefunktionen.

Givet ett test för

$$H_0 : \theta \in \Omega_0 \text{ mot } H_1 : \theta \in \Omega_1$$

kan vi betrakta testets kritiska område

$$R = \{\mathbf{x} \in \mathbb{R}^n : \text{testet förkastar } H_0 \text{ givet datan } \mathbf{x}\}.$$

Man kallar ofta komplementet av R för *acceptansområdet*; dvs. *acceptansområdet* är mängden

$$A = \{\mathbf{x} \in \mathbb{R}^n : \text{testet accepterar } H_0 \text{ givet datan } \mathbf{x}\}.$$

Styrkefunktionen av ett test med det kritiska området R definieras som

$$\beta(\theta) = P(\mathbf{X} \in R | \theta).$$

Styrkefunktionen är en funktion av θ där θ varierar över parameterrummet Ω . $\beta(\theta)$ mäter sannolikheten att vi förkastar nollhypotesen H_0 för $\theta \in \Omega$. Vi vill i synnerhet ha att vi förkastar H_0 när $\theta \in \Omega_1$ och accepterar H_0 när $\theta \in \Omega_0$ och vi vill därför att $\beta(\theta)$ är liten när $\theta \in \Omega_0$ och stor när $\theta \in \Omega_1$.

När nollhypotesen är en *punkthypotes* (dvs. Ω_0 innehåller endast ett element) är ett likelihood-kvottest på formen

$$\text{Förkasta } H_0 : \theta = \theta_0 \text{ om } \lambda(\mathbf{x}) \leq c.$$

Det följer att det kritiska området är på en ganska enkel form; nämligen, $R = \{\mathbf{x} : \lambda(\mathbf{x}) < c\}$. Utöver har vi att

$$\beta(\theta_0) = P(\lambda(\mathbf{x}) < c | \theta_0).$$

Vi såg ett exempel i Kapitel 12 där vi hade ett test för leveranshastigheten av en viss fabrik. I detta exempel hade vi $\Omega_0 = \{3\}$ och det kritiska området $R = \{\mathbf{x} : \mathbf{x} \geq t\}$. För detta test specificerade vi

$$\beta(3) = P(\mathbf{X} \geq t | 3) = 0.05;$$

det vill säga att vi bestämde oss för att använda *signifikansnivån* 0.05. Vi kommer utveckla en strategi att använda styrkefunktionen för att specificera bra val av värdet c i ett likelihood-kvottest som motiveras utifrån ett val av signifikansnivå. Innan vi gör detta ska vi undersöka styrkefunktionen på ett generellt sett.

När vi felaktigt förkastar nollhypotesen (dvs. vi förkastar H_0 trots att den stämmer) kallas det för ett *ett fel av första slaget* (eng. *type I error*). Å andra sidan, när vi felaktigt förkastar alternativhypotesen (dvs. felaktigt acceptera H_0) kallas det för ett *ett fel av andra slaget* (eng. *type II error*). Dessa är de enda två typer av fel som vi kan göra i vårt test:

		Beslut	
		acceptera H_0	acceptera H_1
Sanning	H_0	korrekt	fel av första slaget
	H_1	fel av andra slaget	korrekt

Styrkefunktionen ger oss ett sätt att kvantifiera sannolikheten att vi gör ett fel. Eftersom testet förkastar H_0 om och endast om $\mathbf{x} \in R$ följer det att $P(\mathbf{X} \in R|\theta)$ när $\theta \in \Omega_0$ är sannolikheten att vi har gjort ett fel av det första slaget. När $\theta \in \Omega_1$ har vi att $P(\mathbf{X} \in A|\theta)$ är då sannolikheten att vi har gjort ett fel av det andra slaget. Kom ihåg att A betecknar acceptansområdet som definieras som komplementet av det kritiska området. Det följer att $P(\mathbf{X} \in A|\theta) = 1 - P(\mathbf{X} \in R|\theta)$ för ett givet $\theta \in \Omega$. Därför har vi att

$$\beta(\theta) = P(\mathbf{X} \in R|\theta) = \begin{cases} \text{sannolikheten av ett fel av första slaget} & \theta \in \Omega_0, \\ \text{ett minus sannolikheten av ett fel av andra slaget} & \theta \in \Omega_1. \end{cases}$$

Det följer att vi vill ha $\beta(\theta)$ liten när $\theta \in \Omega_0$ och stor när $\theta \in \Omega_1$.

I vissa fall är det lätt att beräkna styrkefunktionen för ett likelihood-kvottest. Ett exempel är följande.

Exempel 12.8. Låt $x_1, \dots, x_n$ vara ett stickprov från en $N(\theta, 1)$ -population. I Exempel 12.2 såg vi att likelihood-kvottestet för

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta \neq \theta_0$$

ges av

$$\text{Förkasta } H_0 \text{ om } |\bar{x} - \theta_0| \geq c$$

där $c > 0$. Det kritiska området för ett visst c är då

$$R = \{\mathbf{x} : |\bar{x} - \theta_0| \geq c\}.$$

Det följer att styrkefunktionen ges av


$$\begin{aligned} \beta(\theta) &= P(|\bar{X} - \theta_0| \geq c | \theta), \\ &= P(\bar{X} - \theta_0 \geq c | \theta) + P(\bar{X} - \theta_0 \leq -c | \theta), \\ &= P(\bar{X} \geq \theta_0 + c | \theta) + P(\bar{X} \leq \theta_0 - c | \theta). \end{aligned}$$

Vi vet från Sats 5.1 att $\bar{X} \sim N(\theta, 1/n)$ och därför har vi att


$$\begin{aligned} \beta(\theta) &= P(\bar{x} \geq \theta_0 + c | \theta) + P(\bar{x} \leq \theta_0 - c | \theta), \\ &= P\left(\frac{\bar{X} - \theta}{1/\sqrt{n}} \geq \frac{(\theta_0 - \theta) + c}{1/\sqrt{n}} | \theta\right) + P\left(\frac{\bar{X} - \theta}{1/\sqrt{n}} \leq \frac{(\theta_0 - \theta) - c}{1/\sqrt{n}} | \theta\right), \\ &= P(Z \geq \sqrt{n}((\theta_0 - \theta) + c)) + P(Z \leq \sqrt{n}((\theta_0 - \theta) - c)), \\ &= 1 - F_Z(\sqrt{n}((\theta_0 - \theta) + c)) + F_Z(\sqrt{n}((\theta_0 - \theta) - c)), \end{aligned}$$

där $Z \sim N(0, 1)$.

Om vi tar $\theta_0 = 0$ kan vi plotta styrkefunktionen $\beta(\theta)$ för flera val av c :



Givet ett stickprov av storlek $n = 10$ ser vi hur styrkefunktionen ser ut för olika val av c . Här plottar vi styrkefunktionen för $c = 0.25, 0.5$ och 1.5 . Vi vill att $\beta(\theta_0)$ är lite och $\beta(\theta)$ är stor när $\theta \neq \theta_0 = 0$. När $\beta(\theta)$ uppfyller båda dessa krav vet vi att vi undviker båda typer av fel och har ett bra test. I området runt $\theta_0 = 0$ ser vi att $\beta(\theta)$ är ganska liten för $\theta \neq \theta_0$. Detta betyder att vi har en större risk att göra ett fel av det andra slaget för dessa θ . Vi ser också att den här risken är större för större c . Å andra sidan vill vi ha att $\beta(\theta_0)$ är liten (helst lika med noll!). Ju högre c är desto lägre är $\beta(\theta_0)$. Dessa observationer föreslår att vi vill ha ett tillräckligt stort värdet på c så att $\beta(\theta_0)$ är nära noll men inte så stort att vi har ett stort område kring θ_0 där $\beta(\theta)$ är liten för $\theta \neq \theta_0$. För $n = 10$ verkar det svårt att hitta en balans. Om vi ökar stickprovets storlek blir dock valet för c enklare:



När vi plottar samma funktioner för $n = 100$ ser vi att $c = 0.25$ kanske är ett bra val av c eftersom $\beta(\theta_0)$ är jättenära noll och området kring θ_0 där $\beta(\theta)$ är liten för $\theta \neq \theta_0$ är ganska litet. De andra valen, dvs. $c = 0.5$ och $c = 1.5$ är troligtvis dåliga val eftersom det finns flera $\theta \neq \theta_0$ där $\beta(\theta) = 0$. För dessa värden är sannolikheten att vi gör ett fel av andra slaget lika med ett!

I exemplet ovan var det möjligt att beräkna styrkefunktionen analytiskt och plotta funktionen för att hitta ett bra val av c . Generellt sett kan det vara svårt (eller omöjligt) att beräkna styrkefunktionen analytiskt. Ibland kommer det att vara möjligt att simulera utfall som låter oss skatta styrkefunktionen och göra ett approximativ version av denna analys. Detta kan dock vara tidskrävande. Istället kan vi fokusera på att begränsa sannolikheten att vi har ett fel av det första slaget. När vi gör det specificerar vi en *nivå* för testet.

12.4.1 Storlek och nivå

Det är vanligt att bestämma värdet av c som används i ett likelihood-kvottest så att av c begränsar sannolikheten att göra ett fel av första slaget oavsett sannolikheten att vi har ett fel av andra slaget. Vi säger att ett test har *storlek* α om

$$\max_{\theta \in \Omega_0} \beta(\theta) = \alpha.$$

Vanliga val av storlekar är $\alpha = 0.05, 0.01, 0.001$. Ett exempel är följande.

Exempel 12.9. Betrakta testet i Exempel 12.8. Där hade vi ett stickprov $x_1, \dots, x_n$ från en $N(\theta, 1)$ -population och ville testa

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta \neq \theta_0.$$

Vi beräknade likelihood-kvottestet

$$\text{Förkasta } H_0 \text{ om } |\bar{x} - \theta_0| \geq c$$

där $c > 0$. Vi beräknade också styrkefunktionen som

$$\beta(\theta) = 1 - F_Z(\sqrt{n}((\theta_0 - \theta) + c)) + F_Z(\sqrt{n}((\theta_0 - \theta) - c)).$$

Om vi vill begränsa sannolikheten att vi har ett fel av första slaget kan vi beräkna helt enkelt $\beta(\theta_0)$ eftersom $\Omega_0 = \{\theta_0\}$. Vi får ut

$$\begin{aligned}\beta(\theta_0) &= 1 - F_Z(\sqrt{n}((\theta_0 - \theta_0) + c)) + F_Z(\sqrt{n}((\theta_0 - \theta_0) - c)), \\ &= 1 - F_Z(\sqrt{n}(c)) + F_Z(-\sqrt{n}(c)), \\ &= 1 - F_Z(\sqrt{n}(c)) + (1 - F_Z(\sqrt{n}(c))), \\ &= 2(1 - F_Z(\sqrt{n}c))\end{aligned}$$

Här använde vi att $F_Z(z) = 1 - F_Z(-z)$ eftersom täthetsfunktionen för $Z \sim N(0, 1)$ är symmetrisk runt 0. Eftersom $\beta(\theta_0)$ är lika med sannolikheten att vi har ett fel av första slaget kan vi begränsa denna sannolikhet genom att specificera att

$$\max_{\theta \in \Omega_0} \beta(\theta)$$

är en konstant α ; dvs. vi kan fixera värdet α och lösa ut värdet c som ger ett test av storlek α . Till exempel vi kan ta $\alpha = 0.05$. I detta fall får vi då att

$$\begin{aligned}0.05 &= \max_{\theta \in \Omega_0} \beta(\theta), \\ 0.05 &= \beta(\theta_0), \\ 0.05 &= 2(1 - F_Z(\sqrt{n}c)), \\ \frac{0.05}{2} &= 1 - F_Z(\sqrt{n}c), \\ F_Z(\sqrt{n}c) &= 1 - \frac{0.05}{2}.\end{aligned}$$

Det följer att $(\alpha/2)$ -kvantilen $z_{\alpha/2}$ borde vara lika med $\sqrt{n}c$; dvs. valet av storlek $\alpha = 0.05$ motsvarar valet av $c = z_{\alpha/2}/\sqrt{n}$. Vi har då att testet

$$\text{Förkasta } H_0 \text{ om } |\bar{x} - \theta_0| \geq z_{\alpha/2}/\sqrt{n}$$

är ett test av storlek $\alpha = 0.05$. När $n = 100$ har vi att $z_{\alpha/2}/\sqrt{n} = 1.96/\sqrt{100} = 0.196$. Om vi plottar $\beta(\theta)$ för $c = 0.196$ ser det ganska likt ut styrkefunktionen för $c = 0.25$ i Exempel 12.8.

I exemplet ovan var det lätt att lösa ut värdet c så att

$$\alpha = \max_{\theta \in \Omega_0} \beta(\theta)$$

eftersom Ω_0 endast innehöll ett element. Ibland kan det vara svårt eller omöjligt att hitta värdet c som garanterar att $\beta(\theta)$:s maximum på Ω_0 är lika med α .

I sådana fall kan vi specificera en övre gräns α av styrkefunktionens värden på Ω_0 istället. Vi säger att ett test har *nivå* α om

$$\max_{\theta \in \Omega_0} \beta(\theta) \leq \alpha.$$

Det följer att ett test av storlek α är ett test av nivå α . (Konversen behöver inte dock stämma.)

Den vanliga definitionen av *signifikansnivå* är värdet α som är sannolikheten att vi förkastar nollhypotesen när nollhypotesen stämmer. Det vill säga att signifikansnivån är sannolikheten att vi har ett fel av första slaget. När nollhypotesen är en punkthypotes (dvs., $\Omega_0 = \{\theta_0\}$ innehåller bara ett element) har testet nivå α när det har storlek α som är i sin tur detsamma som att α är sannolikheten att vi har ett fel av första slaget. När man väljer att använda en viss signifikansnivå måste man lösa ut värdet c att använda i testet så att testets storlek (och nivå) är lika med den specificerade signifikansnivån. Detta är precis vad vi gjorde i föregående exempel. Vi valde signifikansnivån $\alpha = 0.05$ och hittade då värdet c som ger oss det önskade testet. För att hitta c löste vi ekvationen $\alpha = \max_{\theta \in \Omega_0} \beta(\theta)$. I detta fall behövde vi inte att maximera styrkefunktionen eftersom $\Omega_0 = \{\theta_0\}$ och $\max_{\theta \in \Omega_0} \beta(\theta) = \beta(\theta_0)$. Om vi dock har Ω_0 som innehåller flera element måste vi lösa ett maximeringsproblem för att visa att ett visst test har storlek eller nivå α . Ett exempel är följande.

Exempel 12.10. Låt $x_1, \dots, x_n$ vara ett stickprov från en $N(\theta, \sigma^2)$ -population där σ^2 är känt. Man kan visa att likelihood-kvottestet för

$$H_0 : \theta \leq \theta_0 \quad \text{mot} \quad H_1 : \theta > \theta_0$$

ges av

Förkasta H_0 om $\bar{x} - \theta_0 > c$

för någon $c > 0$. På samma sätt som det föregående exemplet har vi styrkefunktionen

$$\begin{aligned}\beta(\theta) &= P(\bar{x} - \theta_0 > c | \theta), \\ &= P\left(\frac{\bar{X} - \theta}{\sigma/\sqrt{n}} > \frac{c + \theta_0 - \theta}{\sigma/\sqrt{n}} | \theta\right), \\ &= P\left(Z > \frac{c + \theta_0 - \theta}{\sigma/\sqrt{n}} | \theta\right), \\ &= 1 - F_Z\left(\frac{c + \theta_0 - \theta}{\sigma/\sqrt{n}}\right),\end{aligned}$$

där $Z \sim N(0, 1)$.

I detta exempel är $\Omega_0 = \{\theta : \theta \leq \theta_0\}$ (inte bara $\{\theta_0\}$). För att hitta värdet c som ger ett test av storlek α löser vi

$$\begin{aligned}\alpha &= \max_{\theta \leq \theta_0} \beta(\theta), \\ &= \max_{\theta \leq \theta_0} \left(1 - F_Z\left(\frac{c + \theta_0 - \theta}{\sigma/\sqrt{n}}\right)\right).\end{aligned}$$

Eftersom $F_Z(z)$ är strikt växande är $\beta(\theta)$:s maximum uppnådd i $\theta = \theta_0$. Så vi har att

$$\begin{aligned}\alpha &= \max_{\theta \leq \theta_0} \beta(\theta), \\ &= 1 - F_Z\left(\frac{c + \theta_0 - \theta_0}{\sigma/\sqrt{n}}\right), \\ &= 1 - F_Z\left(\frac{c}{\sigma/\sqrt{n}}\right),\end{aligned}$$

vilken sker om och endast om $z_\alpha = \frac{c}{\sigma/\sqrt{n}}$. Vi vill därför ta

$$c = \frac{z_\alpha \sigma}{\sqrt{n}}$$

för att få ett test av storlek (och nivå) α . Det vill säga att testet

$$\text{Förkasta } H_0 : \theta \leq \theta_0 \text{ om } \bar{x} > \theta_0 + \frac{z_\alpha \sigma}{\sqrt{n}}$$

har storlek (och nivå) α .

Ett exempel som inte har en normalfördelning är följande.

Exempel 12.11. Vi återgår till testet i Exempel 12.3 där vi hade $X_1, \dots, X_n$ oberoende och $f_X(x|\theta)$ -fördelade där $f_X(x|\theta)$ tillhör lägesfamiljen med standardtätthetsfunktion $f_Z(z)$ där $Z \sim \text{Exp}(1)$ och lägesparameter θ . Likelihood-kvottestet för

$$H_0 : \theta \leq \theta_0 \quad \text{mot} \quad H_1 : \theta > \theta_0$$

var

$$\text{Förkasta } H_0 : \theta \leq \theta_0 \text{ om } \min_i(x_i) - \theta_0 \geq c$$

för $c > 0$. Testets styrkefunktion är

$$\beta(\theta) = P(\mathbf{X} \in R | \theta) = P(\min_i(X_i) - \theta_0 \geq c | \theta) = P(\min_i(X_i) \geq c + \theta_0 | \theta).$$

Det följer att $\beta(\theta)$ är en strikt växande funktion eftersom det blir mer sannolikt att $\min_i(X_i)$ är större än $c + \theta_0$ när vi ökar θ . Så vi har att

$$\begin{aligned}\max_{\theta \in \Omega_0} \beta(\theta) &= \max_{\theta \leq \theta_0} P(\min_i(X_i) \geq c + \theta_0 | \theta), \\ &= P(\min_i(X_i) \geq c + \theta_0 | \theta_0).\end{aligned}$$

Eftersom $Y = \min_i(X_i)$ har täthetsfunktion

$$f_Y(y|\theta) = \begin{cases} ne^{-n(y-\theta)} & y \geq \theta, \\ 0 & y < \theta, \end{cases}$$

har vi att

$$\begin{aligned} P(\min_i(X_i) \geq c + \theta_0 | \theta_0) &= \int_{c+\theta_0}^{\infty} ne^{-n(y-\theta_0)} dy, \\ &= e^{-n(c+\theta_0-\theta_0)}, \\ &= e^{-nc}. \end{aligned}$$

När vi löser ut c från

$$e^{-nc} = \max_{\theta \in \Omega_0} \beta(\theta) = \alpha$$

får vi $c = -\frac{\log(\alpha)}{n}$. Det följer att testet

$$\text{Förkasta } H_0 : \theta \leq \theta_0 \text{ om } \min_i(x_i) - \theta_0 \geq -\frac{\log(\alpha)}{n}$$

har storlek (och nivå) α . I vårt exempel med vulkanutbrottsdata tog vi $c = 0.27$. Det följer att testet hade storlek $\alpha = e^{-(11)(0.27)} \approx 0.05$. Detta förklarar varför vi använde värdet $c = 0.27$!

I exemplen ovan var varje test med storlek α också ett test med nivå α . Varje gång löste vi ut c som gav oss ett test av storlek α och det resulterande testet hade nivå α som en konsekvens. Det är dock möjligt att det är lättare att hitta ett test med nivå α trots att testet inte har storlek α . Detta kan exempelvis hända när Ω_0 är öppen.

12.4.2 Styrka

När vi har fixat en storlek för testet har vi begränsat sannolikheten att vi har ett fel av första slaget. Sannolikheten att vi har ett fel av andra slaget är dock fortfarande obegränsad. Vi såg att sannolikheten att vi har ett fel av andra slaget är

$$P(\mathbf{x} \in A|\theta) = 1 - P(\mathbf{x} \in R|\theta) = 1 - \beta(\theta) \quad (\text{där } \theta \in \Omega_1).$$

Ett test sägs ha *styrka*

$$\beta(\theta) = P(\mathbf{x} \in R|\theta)$$

mot $\theta \in \Omega_1$. En typisk nedre gräns för $\beta(\theta)$ är 0.80. När $\beta(\theta) \geq 0.80$ man säger ofta helt enkelt att testet har *styrka* mot θ . Till exempel har testet för $n = 10$ och $c = 0.5$ i Exempel 12.8 styrka mot $\theta < 0.25$ medan testet med $c = 1.5$ inte har styrka mot $\theta < 0.25$. I praktiken kan vi ha vissa $\theta \in \Omega_1$ som vi vill ha styrka mot. Detta beror självklart på tillämpningen.

Som ett exempel kan vi betrakta en randomiserad kontrollerad studie (som i Exempel 10.8) där man vill testa om väntevärdet av experimentgruppen θ_E är större än väntevärdet av kontrollgruppen θ_K ; dvs.

$$H_0 : \mu \leq 0 \quad \text{mot} \quad H_1 : \mu > 0$$

där $\mu = \theta_E - \theta_K$ (och målet med experimentet var att öka väntevärdet). Om vi accepterar H_0 i detta fall kommer vi inte att ändra vår praxis enligt experimentet; dvs. vi kommer inte att använda läkemedlet eller annonsen som vi testade i experimentet. Vi behåller istället praxis som vi hade i kontrollgruppen. I detta fall spelar det inte så mycket roll om vi accepterar H_0 trots att $\mu > 0$ när μ är ganska nära noll. Vi vill dock inte acceptera H_0 när μ är ganska stor. Vi får bestämma hur långt bort är för långt bort. Vi vill då ha styrka mot dessa värde för μ .

Exempel 12.12. Låt $X_1, \dots, X_n$ oberoende och $N(\theta, 1)$ -fördelade. Vi vill testa

$$H_0 : \theta \leq 0 \quad \text{mot} \quad H_1 : \theta > 0.$$

Vi såg i Exempel 12.10 att ett test med nivå $\alpha = 0.05$ är

$$\text{Förkasta } H_0 : \theta \leq 0 \text{ om } \bar{x} \geq 1.64/\sqrt{n}.$$

Om vi tar $\theta \in \Omega_1$ har testet stryka $\beta(\theta)$ mot θ där

$$\begin{aligned}\beta(\theta) &= P(\bar{X} \geq 1.64/\sqrt{n}|\theta), \\ &= P\left(\frac{\bar{X} - \theta}{\sqrt{n}} \geq 1.64 - \theta\sqrt{n}\right), \\ &= \int_{1.64 - \theta\sqrt{n}}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy,\end{aligned}$$

Eftersom $\theta \in \Omega_1$ är θ positiv. Det följer att testets styrka ökar när vi ökar stickprovets storlek, n . Vi ser också att $P(\bar{x} \geq 1.64/\sqrt{n}|\theta) \leq P(\bar{x} \geq 1.64/\sqrt{n}|\theta')$ för $\theta, \theta' \in \Omega_1$ där $\theta \leq \theta'$. Vi kan därför bestämma en nedre gräns för $\theta \in \Omega_1$ och beräkna n så att testet har stryka mot alla $\theta' \geq \theta$. Om vi fixar $\theta = 0.5$ har vi att

$$P(\bar{x} \geq 1.64/\sqrt{n}|\theta) \approx 0.791$$

för $n = 24$ men

$$P(\bar{x} \geq 1.64/\sqrt{n}|\theta) \approx 0.805$$

för $n = 25$. Det följer att testet har stryka mot $\theta \geq 0.5$ när vi har minst 25 utfall i stickprovet.

12.4.3 Styrkefunktionen och risk

Hittills har vi utvärderat test med hjälp av styrkefunktionen men det är också naturligt att utvärdera test med hjälp av beslutsteori. På samma sätt som vi gjorde med punktskattningar kan vi definiera förlustfunktioner som kan användas för att utvärdera hypotestest. Vi kommer se att det finns starka kopplingar mellan beslutsteori och styrkefunktionen. Beslutsteoriens perspektiv kommer dock låta oss kvantifiera fel på ett annat sätt.

I ett hypotestest med det kritiska området R har vi vanligtvis två handlingar i handlingsrummet

$$\begin{aligned}a_0 &: \text{acceptera } H_0 \text{ (} \mathbf{x} \notin R \text{)}, \\ a_1 &: \text{förkasta } H_1 \text{ (} \mathbf{x} \in R \text{)},\end{aligned}$$

Notera att vi kan tolka testet

$$\text{Förkasta } H_0 \text{ om } \mathbf{X} \in R$$

som en funktion

$$W(\mathbf{X}) \begin{cases} a_0 & \text{testet accepterar } H_0 \\ a_1 & \text{testet förkastar } H_0. \end{cases}$$

Det vill säga att vi kan tolka testet som en beslutsregel. Givet en beslutsregel kan vi sedan specificera en förlustfunktion. Till exempel kan vi ta den generaliserade 0-1-felet

$$L(\theta, a_0) = \begin{cases} 0, & \theta \in \Omega_0, \\ c_{II}, & \theta \in \Omega_1, \end{cases} \quad L(\theta, a_1) = \begin{cases} c_I, & \theta \in \Omega_0, \\ 0, & \theta \in \Omega_1, \end{cases}$$

där c_I motsvarar kostnaden av ett fel av första slaget och c_{II} motsvarar kostnaden av ett fel av andra slaget. Vi kan då beräkna riskenfunktionen med avseende på förlustfunktionen och ett visst hypotestest $W(\mathbf{X}) = W(X_1, \dots, X_n)$:

$$\begin{aligned}R(\theta, W(\mathbf{X})) &= E[L(\theta, W(\mathbf{X}))], \\ &= \int_{\mathbb{R}^n} L(\theta, a) f_{\mathbf{X}}(\mathbf{x}|\theta) d\mathbf{x}, \\ &= L(\theta, a_0) \int_{\mathbf{X}: W(\mathbf{X})=a_0} f_{\mathbf{X}}(\mathbf{x}|\theta) d\mathbf{x} + L(\theta, a_1) \int_{\mathbf{X}: W(\mathbf{X})=a_1} f_{\mathbf{X}}(\mathbf{x}|\theta) d\mathbf{x}, \\ &= L(\theta, a_0) P(W(\mathbf{X}) = a_0|\theta) + L(\theta, a_1) P(W(\mathbf{X}) = a_1|\theta), \\ &= L(\theta, a_0) P(\mathbf{X} \notin R|\theta) + L(\theta, a_1) P(\mathbf{X} \in R|\theta), \\ &= L(\theta, a_0)(1 - \beta(\theta)) + L(\theta, a_1)\beta(\theta).\end{aligned}$$

Vi har då att

$$R(\theta, W(\mathbf{X})) = \begin{cases} c_I \beta(\theta) & \theta \in \Omega_0, \\ c_{II}(1 - \beta(\theta)) & \theta \in \Omega_1. \end{cases}$$

Notera att $\beta(\theta)$ för $\theta \in \Omega_0$ är sannolikheten att vi har ett fel av första slaget och $1 - \beta(\theta)$ för $\theta \in \Omega_1$ är sannolikheten att vi har ett fel av andra slaget. Så vi ser att riskfunktionen och styrkefunktionen är nära sammanlänkade men riskfunktionen inkluderar kostnaderna av fel som specificeras enligt förlustfunktionen.

Vi kan också använda mer sofistikerade förlustfunktioner i sådana analyser. Till exempel kan vi använda förlustfunktioner som ger ett större fel när θ är längre bort från parametrarna i Ω_0 .

12.5 Uppgifter

- 12.1.** [1] Vi antar antalet bilolyckor i en viss stad under ett givet år är $\text{Po}(\theta)$ -fördelad. De senaste åren var väntevärdet av antalet bilolyckor per år 15. I år var väntevärdet lika med 10. Är det motiverat att säga att frekvensen hos bilolyckorna per år har sjunkit?

- 12.2.** [1] Anta att X har täthetsfunktion

$$f_X(x | \beta) = \frac{\Gamma(1 + \beta)}{\Gamma(1)\Gamma(\beta)} (1 - x)^{\beta-1},$$

där $0 < x < 1$ och $\beta > 0$. Vi vill testa $H_0 : \beta = \beta_0$ mot $H_1 : \beta \neq \beta_0$. Vilken av följande utgör ett likelihood-kvottest för H_0 mot H_1 ?

- (a) Förkasta H_0 om $\beta_0^n \left(\overline{\log(1/(1-x))} \right)^n \prod_{i=1}^n (1 - x_i)^{\beta_0 - \overline{\log(1-x)}}^{-1} \leq c$.
- (b) Förkasta H_0 om $\beta_0^n \left(\overline{\log(1-x)} \right)^{-n} \prod_{i=1}^n (1 - x_i)^{\beta_0 - \overline{\log(1-x)}}^{-1} \leq c$.
- (c) Förkasta H_0 om $\beta_0^n \left(\overline{\log(1/(1-x))} \right)^n \prod_{i=1}^n (1 - x_i)^{\beta_0 + \overline{\log(1-x)}}^{-1} \leq c$.
- (d) Förkasta H_0 om $\beta_0^n \left(\overline{\log(1-x)} \right)^{-n} \prod_{i=1}^n (1 - x_i)^{\beta_0 + \overline{\log(1-x)}}^{-1} \leq c$.

- 12.3.** [1] Anta att X har täthetsfunktion

$$f_X(x | \alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x},$$

där $0 \leq x < \infty$, α är fixt och $\lambda > 0$. Vi vill testa $H_0 : \lambda = \lambda_0$ mot $H_1 : \lambda \neq \lambda_0$. Vilken av följande utgör ett likelihood-kvottest för H_0 mot H_1 ?

- (a) Förkasta H_0 om $\lambda_0 \bar{x} e^{-\lambda_0 n \bar{x}} \leq c$.
- (b) Förkasta H_0 om $(\lambda_0 \bar{x})^\alpha e^{-\lambda_0 \bar{x}} \leq c$.
- (c) Förkasta H_0 om $e^{-\lambda_0 n \bar{x}} \leq c$.
- (d) Förkasta H_0 om $\lambda_0^\alpha e^{-\lambda_0 \bar{x}} \leq c$.

- 12.4.** [1] Vi har ett stickprov $y_1, \dots, y_n$ från en $\text{Ber}(\theta)$ -population och vi vill testa

$$H_0 : \theta \leq \theta_0 \quad \text{mot} \quad H_1 : \theta > \theta_0.$$

Visa att ett likelihood-kvottest förkastar H_0 när $\sum_{i=1}^n y_i > c$ för något c .

- 12.5.** [3] Låt X_1, X_2 vara diskreta stokastiska variabler med möjliga utfall $\{0, \dots, d_1 - 1\}$ respektive $\{0, \dots, d_2 - 1\}$ för heltal $d_1, d_2 > 1$.

- (a) Den simultana fördelningen för $[X_1, X_2]^T$ där $d_1 = d_2 = 2$ parametreras av $p_{00}, p_{01}, p_{10}, p_{11}$ där

$$p_{ij} = P(X_1 = i, X_2 = j), \quad p_{00} + p_{01} + p_{10} + p_{11} = 1 \quad \text{och} \quad p_{ij} > 0.$$

Fördelningarna som uppfyller $X_1 \perp\!\!\!\perp X_2$ kan också parametreras av $p_0^{(1)}, p_1^{(1)}, p_0^{(2)}, p_1^{(2)}$ där

$$p_j^{(i)} = P(X_i = j), \quad p_0^{(i)} + p_1^{(i)} = 1 \quad \text{och} \quad p_0^{(i)}, p_1^{(i)} > 0 \quad \text{för } i = 1, 2.$$

Vi observerar ett stickprov $[x_{1,1}, x_{2,1}]^T, \dots, [x_{1,n}, x_{2,n}]^T$ från $[X_1, X_2]^T$ och vi vill testa

$$H_0 : X_1 \perp X_2 \quad \text{mot} \quad H_1 : X_1 \not\perp X_2.$$

Låt

$$G^2 = 2 \sum_{a=1}^{d_1} \sum_{b=1}^{d_2} u_{1,2}^{(a,b)} \log \left(\frac{u_{1,2}^{(a,b)} n}{u_1^{(a)} u_2^{(b)}} \right),$$

där $u_{1,2}^{(a,b)}$ betecknar antalet gånger $[X_1, X_2]^T = [a, b]^T$ dyker upp i stickprovet och $u_i^{(a)}$ betecknar antalet gånger $X_i = a$ dyker upp. Visa att likelihood-kvottestet förkastar H_0 när $G^2 \geq c$ för givet $c \in [0, \infty)$.

- (b) Statistiken G^2 i del (a) kallas för G^2 -statistiken och den är asymptotiskt fördelad som $\chi^2(f)$ med $f = (d_1 - 1)(d_2 - 1)$ frihetsgrader. Likelihood-kvottestet ovan kallas för G -testet. G^2 -statistiken och G -testet fungerar egentligen för godtyckliga val av $d_1, d_2 > 1$. Låt $d_1 = 3$, $d_2 = 2$ och $c = 5.99 = \chi_{0.05}^2(2)$. Använd G -testet för att acceptera eller förkasta $H_0 : X_1 \perp X_2$ enligt följande data (ges på formen (x_1, x_2)):

$$(2, 1), (0, 1), (2, 0), (2, 0), (2, 1), (1, 0), (1, 0), (1, 1), (0, 0), (0, 0), \\ (0, 1), (2, 0), (1, 0), (2, 1), (0, 0), (2, 0), (0, 1), (2, 0), (2, 0), (2, 0)$$

- 12.6. [1] Låt $x_1, \dots, x_n$ vara ett stickprov från en Pareto(ν, θ)-population.

- (a) Bestäm ML-skattningen för $[\nu, \theta]^T$.
 (b) Vi vill testa $H_0 : \theta = 1$ mot $H_1 : \theta \neq 1$ där ν är okänt. Visa att likelihood-kvottestet har kritiskområdet $\{\mathbf{x} : T(\mathbf{x}) \leq c_1 \text{ eller } T(\mathbf{x}) \geq c_2\}$, där $0 < c_1 < c_2$ och

$$T(\mathbf{x}) = \log \left(\frac{\prod_{i=1}^n x_i}{(\min_i(x_i))^n} \right).$$

- 12.7. [2] Anta att vi har två oberoende stickprov $x_1, \dots, x_n$ och $y_1, \dots, y_m$ som är Exp(θ)-fördelad respektive Exp(μ)-fördelad.

- (a) Bestäm ett likelihood-kvottest för $H_0 : \theta = \mu$ mot $H_1 : \theta \neq \mu$.
 (b) Visa att testet i del (a) kan använda testvariabeln

$$T(\mathbf{x}, \mathbf{y}) = \frac{\sum_i x_i}{\sum_i x_i + \sum_j y_j}.$$

- (c) Hur är $T(\mathbf{X}, \mathbf{Y})$ fördelad när H_0 uppfylls?

- 12.8. [3] Låt $x_1, \dots, x_n$ vara ett stickprov från en $N(\mu_X, \sigma_X^2)$ -population och låt $y_1, \dots, y_m$ vara ett stickprov från en $N(\mu_Y, \sigma_Y^2)$ -population där $X_1, \dots, X_n, Y_1, \dots, Y_m$ är oberoende. Vi vill testa

$$H_0 : \mu_X = \mu_Y \quad \text{mot} \quad H_1 : \mu_X \neq \mu_Y,$$

under antagandet att $\sigma_X^2 = \sigma_Y^2 = \sigma^2$.

- (a) Beräkna ett likelihood-kvottest för detta. Visa att testet kan använda testvariabeln

$$T(\mathbf{x}, \mathbf{y}) = \frac{\bar{x} - \bar{y}}{\sqrt{S_p^2(1/n + 1/m)}},$$

där

$$S_p^2 = \frac{1}{n + m - 2} \left(\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^m (y_i - \bar{y})^2 \right).$$

- (b) Visa att $T \sim t_{n+m-2}$ när H_0 uppfylls. Detta hypotestest kallas för t -testet för två stickprov.
 (c) Ett stickprov av trä erhöles från kärnan och periferin av en viss Bysantinsk kyrka. Datumen av stickproven bestämdes och vi fick följande data:

Kärna		Periferi	
1294	1251	1284	1274
1279	1248	1272	1264
1274	1240	1256	1256
1264	1232	1254	1250
1263	1220	1242	
1254	1218		
1251	1210		

Använd t-testet för två stickprov för att bestämma om kärnans medelålder är lika med periferins medelålder.

12.9. [3] Vi har sett ovan att det är möjligt att testa $X_1 \perp\!\!\!\perp X_2$ för två diskreta stokastiska variabler X_1 och X_2 med hjälp av hypotestest.

(a) Visa att man kan generalisera G -testet till ett test för betingat obereonde.

(b) Lös Uppgift 4.29.

(c) Lös Uppgift 4.30.

(d) Anta att vi har ett stickprov från $\mathbf{X} = [X_1, \dots, X_m]^T$ där X_i har möjliga utfall $\{0, \dots, d_i - 1\}$ för alla $i = 1, \dots, m$ och heltal $d_1, \dots, d_m > 1$. Anta att $\mathbf{X}$ har möjliga utfall $\prod_{i=1}^m \{0, \dots, d_i - 1\}$. Beskriva en metod för att skatta en acykliska riktad graf $\mathcal{G}$ så att $\mathbf{X}$ är markovsk med avseende på $\mathcal{G}$.

12.10. [1] Bestäm ett likelihood-kvottest för $H_0 : \lambda = 3$ mot $H_1 : \lambda \neq 3$ där $X_1, \dots, X_n$ är oberoende och $\text{Po}(\lambda)$ -fördelade. Förkastar testet H_0 enligt stickprovet

$$4, 2, 1, 0, 2, 4, 5, 0, 7, 3$$

när vi tar $c = 0.5$?

12.11. [1] Anta att vi har ett stickprov $x_1, \dots, x_n$ från en $f_X(x|\theta)$ -population och vi betrakta bara två möjligheter för θ ; dvs. vi anta att modellen har parameterutrymme $\Omega = \{\theta_0, \theta_1\}$. Vi vill testa

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta = \theta_1.$$

(a) Visa att likelihoodkvoten $\lambda(\mathbf{x})$ uppfyller

$$\lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Omega_0} L(\theta|\mathbf{x})}{\sup_{\theta \in \Omega} L(\theta|\mathbf{x})} \leq c$$

för någon $c \in (0, 1)$ om och endast om

$$\lambda_r(\mathbf{x}) = \frac{L(\theta_0|\mathbf{x})}{L(\theta_1|\mathbf{x})} \leq d$$

för någon $d \in (0, 1)$.

(b) Dra slutsatsen att likelihood-kvottestet

$$\text{Förkasta } H_0 \text{ om } \lambda(\mathbf{x}) \leq c$$

är detsamma som testet

$$\text{Förkasta } H_0 \text{ om } \lambda_r(\mathbf{x}) \leq d.$$

12.12. [1] Låt $x_1, \dots, x_{10}$ vara ett stickprov av storlek 10 från en $\text{Ber}(\theta)$ -population där vi betrakta bara två möjliga utfall för θ ; nämligen vi ta $\Omega = \{1/2, 3/4\}$. Bestäm ett likelihood-kvottest med storlek $\alpha = 0.05$ för

$$H_0 : \theta = \frac{1}{2} \quad \text{mot} \quad H_1 : \theta = \frac{3}{4}.$$

- 12.13.** [1] Låt $x_1, \dots, x_n$ vara ett stickprov från en $\text{Po}(\lambda)$ -population där vi berakta bara två möjliga utfall för θ ; nämligen vi ta $\Omega = \{\lambda_0, \lambda_1\}$. Bestäm ett likelihood-kvottest med storlek α för

$$H_0 : \lambda = \lambda_0 \quad \text{mot} \quad H_1 : \lambda = \lambda_1.$$

- 12.14.** [2] Anta att X har täthetsfunktion

$$f_X(x | \alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x},$$

där $0 \leq x < \infty$, α är känt och $\lambda > 0$. Ta fram ett test med nivå 0.05 för $H_0 : \lambda = \lambda_0$ mot $H_1 : \lambda \neq \lambda_0$.

- 12.15.** [1] Betrakta ett stickprov $x_1, \dots, x_n$ från en $N(\mu, \sigma^2)$ -population där σ^2 är känt. Plotta styrkefunktionen för följande likelihood-kvottest med storlek $\alpha = 0.05$ för varje n där $n = 1, 4, 16, 64, 100$. Hur ser styrkefunktionen ut för olika val av σ^2 och n ?

$$H_0 : \mu \leq 0 \quad \text{mot} \quad H_1 : \mu > 0.$$

- 12.16.** [2] Låt X_1 och X_2 vara oberoende och $U(\theta, \theta + 1)$ -fördelade. Vi vill testa $H_0 : \theta = 0$ mot $H_1 : \theta > 0$ och vi har två möjliga test:

$$T_1: \text{Förkasta } H_0 \text{ om } X_1 > 0.95,$$

$$T_2: \text{Förkasta } H_0 \text{ om } X_1 + X_2 > C \text{ där } 1 \leq C \leq 2.$$

- (a) Bestäm värdet på C för vilket T_2 har samma storlek som T_1 .
- (b) Beräkna styrkefunktionen för båda test. Rita upp styrkefunktionerna.
- (c) Stämmer det att T_2 är starkare än T_1 för alla θ ?

- 12.17.** [1] Låt $X_1, \dots, X_n$ vara oberoende och $N(\theta, \sigma^2)$ -fördelade med σ^2 känt. Ett likelihood-kvottest för $H_0 : \theta = \theta_0$ mot $H_1 : \theta \neq \theta_0$ ges av

$$\text{Förkasta } H_0 \text{ om } |\bar{X} - \theta_0|/(\sigma/\sqrt{n}) > c.$$

- (a) Bestäm en formel för styrkefunktionen $\beta(\theta)$ med hjälp av sannolikheter för standard-normalfördelningen.
- (b) En forskare kräver ett test där sannolikheten att vi ha ett fel av det första slaget är 0.05 och sannolikheten att vi ha ett fel av det andra slaget är högst 0.25 på $\theta = \theta_0 + \sigma$. Bestäm värden för n och c som uppfyller detta.

- 12.18.** [2] Låt S^2 vara stickprovsvariansen för $X_1, \dots, X_n$ som är oberoende och $N(\mu, \sigma^2)$ -fördelade. Ta apriorifördelningen $\sigma^2 \sim \text{InvGamma}(\alpha, \beta)$. Vi betraktar testet

$$H_0 : \sigma \leq 1 \quad \text{mot} \quad H_1 : \sigma > 1.$$

- (a) Bestäm området där $P(\sigma \leq 1 | s^2) > P(\sigma > 1 | s^2)$; dvs. området där bayestestet med 0 – 1-felet kommer att acceptera H_0 .
- (b) Jämför området i del (a) med acceptansområdet för ett likelihood-kvottest. Finns det ett val parametrar α och β så att dessa områden sammanfaller?

- 12.19.** [1] Låt $x_1, \dots, x_n$ vara ett stickprov från en $N(\mu, \sigma^2)$ -population där σ^2 är känt. Betrakta likelihood-kvottestet med nivå α

$$\text{Förkasta } H_0 : \mu \leq \mu_0 \text{ om } \bar{x} - \mu_0 \geq z_\alpha \sigma / \sqrt{n}$$

för

$$H_0 : \mu \leq \mu_0 \quad \text{mot} \quad H_1 : \mu > \mu_0.$$

- (a) Visa att när vi ökar n så minskar vi sannolikheten att vi ha ett fel av det första slaget.
- (b) Visa att när vi ökar n så minskar vi sannolikheten att vi ha ett fel av det andra slaget.
- (c) Visa att om vi minskar testets nivå minskar vi också testets styrka mot μ för varje $\mu \in \Omega_1$. Vad betyder detta i relation till sannolikheterna att vi ha ett fel av det första (respektive andra) slaget?

- 12.20.** [1] Låt $x_1, \dots, x_n$ vara ett stickprov från en $N(\mu, \sigma^2)$ -population med σ^2 känt. Bestäm ett likelihood-kvottest med nivå $\alpha = 0.10$ för

$$H_0 : \theta \geq \theta_0 \quad \text{mot} \quad H_1 : \theta < \theta_0.$$

Plotta riskfunktionen för $n = 10$ och det generaliserade 0-1-felet med $c_I = 8$ och $c_{II} = 3$. Ge en förklaring av eventuella diskontinuiteter som du ser i grafen.

- 12.21.** [3] Låt $X_1, \dots, X_n$ vara oberoende och $\text{Beta}(\mu, 1)$ -fördelade och $Y_1, \dots, Y_m$ oberoende och $\text{Beta}(\theta, 1)$ -fördelade. Anta också att $X_1, \dots, X_n, Y_1, \dots, Y_m$ är oberoende.

- (a) Bestäm ett likelihood-kvottest för $H_0 : \mu = \theta$ mot $H_1 : \mu \neq \theta$.
(b) Visa att testet i del (a) kan använda testvariabeln

$$T = \frac{\sum_{i=1}^n \log(X_i)}{\sum_{i=1}^n \log(X_i) + \sum_{j=1}^m \log(Y_j)}.$$

- (c) Bestäm T 's fördelning när H_0 uppfylls och visa hur man kan konstruera ett test med storlek $\alpha = 0.10$.

Kapitel 13

13.1 Frekventistisk intervallskattning

Istället för att skatta värdet av en viss parameter θ med en punktskattning $W(\mathbf{x})$ eller att testa om parametern har ett visst värde θ_0 enligt ett hypotestest kan vi bestämma en delmängd $C(\mathbf{x})$ till parameterområdet Ω som vi förväntar oss innehålla θ med en viss sannolikhet. Delmängden $C(\mathbf{x})$ skattas enligt ett stickprov $\mathbf{x} = [x_1, \dots, x_n]^T$ och den kallas för en *mängdskattning*.

När $\Omega = \mathbb{R}$ kan det hända att $C(\mathbf{x})$ är ett intervall. När $C(\mathbf{x})$ är ett intervall kallas $C(\mathbf{x})$ för en *intervallskattning*. En intervallskattning $C(\mathbf{x})$ kan skrivas som

$$C(\mathbf{x}) = [L(\mathbf{x}), U(\mathbf{x})]$$

där $L(\mathbf{x})$ och $U(\mathbf{x})$ är funktioner som uppfyller $L(\mathbf{x}) \leq U(\mathbf{x})$ för alla $\mathbf{x}$. Här skriver vi $C(\mathbf{x})$ som ett slutet intervall men det kan också vara öppet. Det kan också hända att $L(\mathbf{x}) = -\infty$ eller $U(\mathbf{x}) = \infty$. När vi har antingen $L(\mathbf{x}) = -\infty$ och $U(\mathbf{x}) \neq \infty$ eller $L(\mathbf{x}) \neq -\infty$ och $U(\mathbf{x}) = \infty$ kallar vi $C(\mathbf{x})$ för en *ensidig intervallskattning*. När $L(\mathbf{x}) > -\infty$ och $U(\mathbf{x}) < \infty$ kallas $C(\mathbf{x})$ för en *tvåsidig intervallskattning*.

Givet ett stickprov $\mathbf{x} = [x_1, \dots, x_n]^T$ från en $f_X(x|\theta)$ -population med det riktiga parametervärdet θ vill vi hitta en intervallskattning $C(\mathbf{x})$ så att θ tillhör $C(\mathbf{x})$ med en viss sannolikhet. För att göra detta betraktar vi intervallets *täckningssannolikhet*

$$P(\theta \in C(\mathbf{X})|\theta);$$

dvs. sannolikheten att θ tillhör $C(\mathbf{x})$ när stickprovet $\mathbf{x} = [x_1, \dots, x_n]^T$ genereras från en population med parametervärdet θ . Eftersom vi inte vet det riktiga värdet θ kan vi kräva att täckningssannolikheten är högre än en viss nivå för alla $\theta \in \Omega$. Vi säger att $C(\mathbf{x})$ är en $1 - \alpha$ *konfidensmängd* när

$$P(\theta \in C(\mathbf{X})|\theta) \geq 1 - \alpha \quad \text{för alla } \theta \in \Omega.$$

Detta betyder att sannolikheten att θ tillhör mängden $C(\mathbf{x})$ när datan genereras från en fördelning med parametervärde θ är minst $1 - \alpha$. Eftersom detta stämmer för alla $\theta \in \Omega$ vet vi att det stämmer för värdet θ som gav oss vårt stickprov $x_1, \dots, x_n$! Vanliga val för α är 0.05, 0.01 och 0.001. För $\alpha = 0.05$ har vi att sannolikheten att parametervärdet θ som används för att generera datan $\mathbf{x}$ tillhör $C(\mathbf{x})$ med sannolikhet 0.95 – vilken är ganska stor. Värdet $1 - \alpha$ kallas för *konfidensgraden* av $C(\mathbf{x})$. När $C(\mathbf{x})$ är ett intervall med konfidensgrad $1 - \alpha$ kallar vi $C(\mathbf{x})$ för ett $1 - \alpha$ *konfidensintervall*.

Exempel 13.1. Låt $X_1, \dots, X_n$ vara oberoende och $U(0, \theta)$ -fördelade och låt $Y = \max(X_1, \dots, X_n)$. Vi betraktar två intervallskattningar:

$$C_1(\mathbf{X}) = [aY, bY] \quad \text{och} \quad C_2(\mathbf{X}) = [Y + c, Y + d]$$

där $1 \leq a < b$ och $0 \leq c < d$. Observera att vi specificerar intervallskattningarna enligt funktionerna $L(\mathbf{X})$ och $U(\mathbf{X})$. Detta är helt okej! Till exempel har vi definierat en intervallskattning enligt $C(\mathbf{X}) = [L(\mathbf{X}), U(\mathbf{X})]$ där $L(\mathbf{X}) = aY$ och $U(\mathbf{X}) = bY$. Observera också att $Y \leq \theta$ eftersom $P(Y > \theta) = 0$. Täckningssannolikheten av $C_1(\mathbf{X})$ ges av

$$P(\theta \in [aY, bY]|\theta) = P(aY \leq \theta \leq bY|\theta) = P\left(\frac{1}{b} \leq \frac{Y}{\theta} \leq \frac{1}{a}|\theta\right).$$

Vi har sett redan i Exempel 6.10 att $Y = \max(X_1, \dots, X_n)$ har täthetsfunktion

$$f_Y(y|\theta) = n \frac{y^{n-1}}{\theta^n}.$$

Det följer då att $T = Y/\theta$ har täthetsfunktion

$$f_T(t|\theta) = nt^{n-1}.$$

Täckningssannolikheten av $C_1(\mathbf{x})$ är då

$$P\left(\frac{1}{b} \leq \frac{Y}{\theta} \leq \frac{1}{a}|\theta\right) = P\left(\frac{1}{b} \leq T \leq \frac{1}{a}|\theta\right) \int_{1/b}^{1/a} nt^{n-1}dt = \left(\frac{1}{a}\right)^n - \left(\frac{1}{b}\right)^n.$$

Denna sannolikhet beror inte på θ och vi har därför samma täckningssannolikhet för alla $\theta \in \Omega$. Det följer att intervallet $C_1(\mathbf{X}) = [aY, bY]$ har konfidsensgrad $a^{-n} - b^{-n}$.

Å andra sidan har intervallet $C_2(\mathbf{X}) = [Y + c, Y + d]$ täckningssannolikhet

$$\begin{aligned} P(\theta \in [Y + c, Y + d]|\theta) &= P(Y + c \leq \theta \leq Y + d|\theta), \\ &= P\left(1 - \frac{d}{\theta} \leq \frac{Y}{\theta} \leq 1 - \frac{c}{\theta}|\theta\right), \\ &= \left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n. \end{aligned}$$

Denna täckningssannolikhet beror på θ och vi har att

$$\lim_{\theta \rightarrow \infty} \left(\left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n \right) = 0.$$

Det följer att konfidsensgraden av $[Y + c, Y + d]$ är 0. Det verkar som att vissa konfidensmängder är bättre än andra.

I exemplet ovan var konfidensintervallen ganska intuitiva att konstruera. Vi vill naturligtvis ha metoder för att bestämma konfidensmängder i allmänhet. Då kommer vi att ha möjligheten att konstruera konfidensintervall i mer komplexa situationer.

13.1.1 Invertera en testvariabel

Ett sätt att konstruera en konfidensmängd (eller konfidensintervall) är att använda ett hypotestest.

Exempel 13.2. Låt $X_1, \dots, X_n$ vara oberoende och $N(\theta, \sigma^2)$ -fördelade där σ^2 är känt. Vi såg i Exempel 12.8 (för $\sigma^2 = 1$) att ett test för

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta \neq \theta_0$$

med nivå α ges av

$$\text{Förkasta } H_0 : \theta = \theta_0 \text{ om } |\bar{x} - \theta_0| > z_{\alpha/2}\sigma/\sqrt{n}.$$

Eftersom testet har nivå α har vi att

$$P(\text{acceptera } H_0|\theta_0) = 1 - P(\text{förkasta } H_0|\theta_0) \geq 1 - \alpha;$$

dvs.

$$P(\mathbf{X} \in A|\theta_0) = 1 - P(\mathbf{X} \in R|\theta_0) \geq 1 - \alpha$$

där A och R betecknar testets acceptansområde respektive kritiskt område. Vi kan skriva $P(\mathbf{X} \in A|\theta_0)$ som

$$\begin{aligned} P(\mathbf{X} \in A|\theta_0) &= P(|\bar{X} - \theta_0| < z_{\alpha/2}\sigma/\sqrt{n}|\theta_0), \\ &= P(-z_{\alpha/2}\sigma/\sqrt{n} < \bar{X} - \theta_0 < z_{\alpha/2}\sigma/\sqrt{n}|\theta_0), \\ &= P(\bar{X} - z_{\alpha/2}\sigma/\sqrt{n} < \theta_0 < \bar{X} + z_{\alpha/2}\sigma/\sqrt{n}|\theta_0). \end{aligned}$$

Eftersom testet har nivå α följer det att

$$P(\bar{X} - z_{\alpha/2}\sigma/\sqrt{n} < \theta_0 < \bar{X} + z_{\alpha/2}\sigma/\sqrt{n}|\theta_0) \geq 1 - \alpha.$$

Detta stämmer för alla val $\theta_0 \in \Omega$. Därför har vi att

$$[\bar{X} - z_{\alpha/2}\sigma/\sqrt{n}, \bar{X} + z_{\alpha/2}\sigma/\sqrt{n}]$$

ett $1 - \alpha$ konfidensintervall.

På generellt sett har vi en korrespondens mellan acceptansområdet

$$A(\theta_0) = \{\mathbf{x} : \text{testet accepterar } H_0 : \theta = \theta_0\}$$

av ett test av $H_0 : \theta = \theta_0$ med nivå α och en $1 - \alpha$ konfidensmängd

$$C(\mathbf{x}) = \{\theta : \bar{X} - z_{\alpha/2}\sigma/\sqrt{n} < \theta < \bar{X} + z_{\alpha/2}\sigma/\sqrt{n}\}$$

som ges av

$$\mathbf{x} \in A(\theta_0) \quad \text{om och endast om} \quad \theta_0 \in C(\mathbf{x}).$$

Båda mängderna $A(\theta_0)$ och $C(\mathbf{x})$ försöker svara på samma fråga: "Vilka parametervärden θ överensstämmer med datan $\mathbf{x}$?" Vi skriver konkret denna korrespondens i följande sats:

Sats 13.1. *Betrakta ett test med nollhypotes $H_0 : \theta = \theta_0$, nivå α och acceptansområde*

$$A(\theta_0) = \{\mathbf{x} \in \mathbb{R}^n : \text{testet accepterar } H_0\}.$$

Givet $\mathbf{x} \in \mathbb{R}^n$ definierar vi mängden

$$C(\mathbf{x}) = \{\theta \in \Omega : \mathbf{x} \in A(\theta_0)\}.$$

Vi har då att $C(\mathbf{x})$ är en $1 - \alpha$ konfidensmängd.

Bevis. Eftersom $A(\theta_0)$ är acceptansområdet för ett test med nivå α har vi att

$$P(\mathbf{X} \in A(\theta_0) | \theta_0) = 1 - P(\mathbf{X} \notin A(\theta_0) | \theta_0) \geq 1 - \alpha.$$

Det följer att

$$P(\theta_0 \in C(\mathbf{X}) | \theta_0) = P(\mathbf{X} \in A(\theta_0) | \theta_0) \geq 1 - \alpha$$

för alla $\theta_0 \in \Omega$. Därför har vi att $C(\mathbf{X})$ är en $1 - \alpha$ konfidensmängd. $\square$

Vi har sett redan ett exempel på denna metod för att hitta en konfidensmängd (Exempel 13.2). Ett annat exempel är följande.

Exempel 13.3. Låt $X_1, \dots, X_n$ vara oberoende och $f_X(x|\lambda)$ -fördelade där

$$f_X(x|\lambda) = \frac{1}{\lambda} e^{-x/\lambda}.$$

Vi kan testa

$$H_0 : \lambda = \lambda_0 \quad \text{mot} \quad H_1 : \lambda \neq \lambda_0$$

med ett likelihood-kvottest som ges av

$$\text{Förkasta } H_0 \text{ om } \frac{L(\lambda_0|\mathbf{x})}{L(\hat{\lambda}|\mathbf{x})} < c$$

för någon $c \in (0, 1)$ där $\hat{\lambda}$ betecknar ML-skattningen av λ . Man kan verifiera att $\hat{\lambda} = \bar{x}$. Därför kan vi förenkla testet som

$$\text{Förkasta } H_0 \text{ om } \left(\frac{\sum_{i=1}^n x_i}{\lambda_0} \right)^n e^{-(\sum_{i=1}^n x_i)/\lambda_0} < k$$

för någon k som ger oss ett test med nivå α . Acceptansområdet av testet är då

$$A(\lambda_0) = \left\{ \mathbf{x} : \left(\frac{\sum_{i=1}^n x_i}{\lambda_0} \right)^n e^{-(\sum_{i=1}^n x_i)/\lambda_0} \geq k \right\}.$$


Det följer från Sats 13.1 att

$$C(\mathbf{x}) = \left\{ \lambda > 0 : \left(\frac{\sum_{i=1}^n x_i}{\lambda} \right)^n e^{-(\sum_{i=1}^n x_i)/\lambda} \geq k \right\}.$$

Men hur ser mängden $C(\mathbf{x})$ ut? Notera först att mängden beror på stickprovet $x_1, \dots, x_n$ genom $y = \sum_{i=1}^n x_i$ där $y \in [0, \infty)$ (eftersom y är en tillräcklig statistika för λ). När vi plottar funktionen

$$f(\lambda) = \left(\frac{y}{\lambda} \right)^n e^{-y/\lambda}$$

där $n = 10$, $y = 4.29$ och $k = 0.25$ ser vi



Det följer att $C(\mathbf{x})$ är mängden av alla λ så att värdet $f(\lambda)$ är större än $k = 0.25$ (linjen i plotten ovan). Vi ser att området har ett enda lokalt maximum (dvs., $f(\lambda)$ är *unimodal*) och därför måste $C(\mathbf{x})$ vara ett intervall på formen

$$C(\mathbf{x}) = [L(y), U(y)]$$

där

$$\left(\frac{y}{L(y)}\right)^n e^{-y/L(y)} = k = \left(\frac{y}{U(y)}\right)^n e^{-y/U(y)}.$$

Om vi låter $L(y) = y/a$ och $U(y) = y/b$ får vi begränsningen

$$a^n e^{-a} = b^n e^{-b}.$$

Täckningssannolikheten ger oss en begränsning till:

$$\begin{aligned} P(\lambda_0 \in C(\mathbf{x}) | \lambda_0) &= P(L(y) \leq \lambda_0 \leq U(y) | \lambda_0), \\ &= P\left(\frac{y}{a} \leq \lambda_0 \leq \frac{y}{b} | \lambda_0\right), \\ &= P(b \leq \frac{y}{\lambda_0} \leq a | \lambda_0) \geq 1 - \alpha. \end{aligned}$$

Man kan vi visa att $Y/\lambda \sim \text{Gamma}(n, 1)$ (prova!). Det följer att $Z = Y/\lambda$ har täthetsfunktion

$$f_Z(z|\lambda) = \frac{1}{\Gamma(n)} z^{n-1} e^{-z}.$$

Vi kan därför lösa ut a och b från följande ekvationssystem

$$\begin{aligned} a^n e^{-a} &= b^n e^{-b}, \\ \int_b^a \frac{1}{\Gamma(n)} z^{n-1} e^{-z} dz &= 1 - \alpha. \end{aligned}$$

Lösningen har ingen sluten form men vi kan beräkna den numeriskt. Med hjälp av partiell integration kan man visa att

$$\int_b^a \frac{1}{\Gamma(n)} z^{n-1} e^{-z} dz = e^{-b} \sum_{k=0}^{n-1} \frac{b^k}{k!} - e^{-a} \sum_{k=0}^{n-1} \frac{a^k}{k!}.$$

För $n = 2$ får vi då

$$e^{-b}(b+1) - e^{-a}(a+1).$$

I detta fall vill vi lösa systemet

$$\begin{aligned} a^2 e^{-a} &= b^2 e^{-b}, \\ e^{-b}(b+1) - e^{-a}(a+1) &= 1 - \alpha. \end{aligned}$$

Om vi vill ha ett 0.90 konfidensintervall tar vi $\alpha = 0.1$ och vi får

$$a \approx 5.480 \quad \text{och} \quad b \approx 0.441.$$

Det följer att ett 0.90 konfidensintervall ges av

$$\left[\frac{x_1 + x_2}{5.480}, \frac{x_1 + x_2}{0.441} \right].$$

Här använde vi ett likelihood-kvottest för att hitta konfidensintervallet. Likelihood-kvottest har acceptansområde på formen

$$A(\theta_0) = \left\{ \mathbf{x} : \frac{L(\theta_0|\mathbf{x})}{L(\hat{\theta}|\mathbf{x})} \geq k(\theta_0) \right\}$$

för någon funktion $k(\theta_0)$ av θ_0 . Om vi tar $g(\theta_0, \mathbf{x}) = k(\theta_0)L(\hat{\theta}|\mathbf{x})$ får vi

$$A(\theta_0) = \{ \mathbf{x} : L(\theta_0|\mathbf{x}) \geq g(\theta_0, \mathbf{x}) \}.$$

När funktionen $g(\theta_0, \mathbf{x})$ är konstant på θ_0 har vi att $A(\theta_0)$ består av alla θ som har likelihood större än något värde bestämt av datan $\mathbf{x}$. I detta fall har vi ett område med högsta likelihood som en konfidensmängd. Detta händer ibland men inte alltid. När det händer har vi en användbar tolkning av konfidensmängden.

Notera att Sats 13.1 inte specificerar mothypotesen. Till exempel kan vi ta

$$H_1 : \theta = \theta_1, \quad H_1 : \theta \neq \theta_0, \quad H_1 : \theta > \theta_0 \quad \text{eller} \quad H_1 : \theta < \theta_0.$$

Valet för mothypotesen kommer att påverka $C(\mathbf{X})$. Mer specifikt kan vi få ett ensidigt konfidensintervall eller ett tvåsidigt konfidensintervall för olika val av mothypotesen. Ett exempel där vi får ett ensidigt konfidensintervall är följande.

Exempel 13.4. Låt $X_1, \dots, X_n$ vara oberoende och $N(\theta, \sigma^2)$ -fördelade med både θ och σ^2 okända. Vi vill ha en övre gräns för θ ; dvs. ett konfidensintervall på formen $(-\infty, U(\mathbf{x})]$.

För att få ett sådant konfidensintervall kan vi inverta ett test för

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta < \theta_0.$$

Ett sådant test kommer att förkasta H_0 när datan $\mathbf{x}$ föreslår att θ är litet. Acceptansområdet kommer därför att bestå av $\mathbf{x}$ som föreslår att θ är stort. Detta betyder att acceptansområdet $A(\theta_0)$ kommer att ha en nedre gräns. Det följer att konfidensintervallet $C(\mathbf{x})$ i Sats 13.1 kommer att ha en övre gräns.

Ett likelihood-kvottest för $H_0 : \theta = \theta_0$ mot $H_1 : \theta < \theta_0$ är

$$\text{Förkasta } H_0 \text{ om } \frac{\bar{x} - \theta_0}{s/\sqrt{n}} < -t_{n-1, \alpha}.$$

Testet har då acceptansområdet

$$A(\theta_0) = \{ \mathbf{x} : \bar{x} \geq \theta_0 - t_{n-1, \alpha} s / \sqrt{n} \}.$$

Det följer att ett $1 - \alpha$ konfidensintervall är

$$C(\mathbf{x}) = (-\infty, \bar{x} + t_{n-1, \alpha} s / \sqrt{n}].$$

13.1.2 Pivotvariabler

Pivotvariabler ger ett annat sätt att konstruera en intervallskattning. En *pivotvariabel* är en stokastisk variabel $Q(\mathbf{X}, \theta)$ vars fördelning inte beror på θ . Det följer att sannolikheten

$$P(Q(\mathbf{X}, \theta) \in A | \theta)$$

inte beror på θ . Vi kan därför ta en mängd A oavsett θ och skaffa mängdskattningen

$$C(\mathbf{x}) = \{ \theta : Q(\mathbf{x}, \theta) \in A \}.$$

Exempel 13.5. Betrakta modellen i Exempel 12.3 där vi hade vulkanutbrotsdata för Mt. Sankt Helens i USA. Vi modellerade datan $x_1, \dots, x_{11}$ som oberoende och $f_X(x|\theta)$ -fördelade där

$$f_X(x|\theta) = e^{-(x-\theta)} \quad \theta \leq x < \infty.$$

Vi såg att $Y = \min(X_1, \dots, X_n)$ har täthetsfunktion

$$f_Y(y|\theta) = \begin{cases} ne^{-n(y-\theta)} & \theta \leq y \\ 0 & \theta > y. \end{cases}$$

Det följer att $W = Y - \theta$ är en pivotvariabel eftersom täthetsfunktionen

$$f_W(w) = ne^{-nw} \quad 0 \leq w < \infty$$

inte beror på θ . Vi har också att $W \sim \text{Exp}(n)$. Om vi vill ha ett tvåsidigt $1 - \alpha$ konfidensintervall kan vi betrakta en mängd $A = \{w \in \mathbb{R} : a \leq w \leq b\}$ så att

$$P(W \in A|\theta) = P(a \leq W \leq b|\theta) = \int_a^b f_W(w)dw \geq 1 - \alpha.$$

För att hitta ett sådant intervall kan vi delar upp nedre gränsen $1 - \alpha$ jämnt mellan a och b ; dvs. att vi kan ta a och b så att

$$\alpha/2 = \int_0^a f_W(w)dw \quad \text{respektive} \quad \alpha/2 = \int_b^\infty f_W(w)dw.$$

Det följer att $a = w_{1-\alpha/2}$ och $b = w_{\alpha/2}$ där w_α betecknar värdet som uppfyller

$$F_W(w_\alpha) = 1 - \alpha;$$

dvs. α -kvantilen av W . För detta val har vi att

$$\begin{aligned} 1 - \alpha &\leq P(a \leq W \leq b|\theta) = P(w_{1-\alpha/2} \leq W \leq w_{\alpha/2}|\theta), \\ &= P(w_{1-\alpha/2} \leq \min(X_1, \dots, X_n) - \theta \leq w_{\alpha/2}|\theta), \\ &= P(w_{1-\alpha/2} - \min(X_1, \dots, X_n) \leq -\theta \leq w_{\alpha/2} - \min(X_1, \dots, X_n)|\theta), \\ &= P(\min(X_1, \dots, X_n) - w_{1-\alpha/2} \geq \theta \geq \min(X_1, \dots, X_n) - w_{\alpha/2}|\theta), \end{aligned}$$

Utbrottens data har $y = \min(x_1, \dots, x_{11}) = 3$. För $\alpha = 0.05$ har vi då det tvåsidiga 0.95 konfidensintervallet

$$C(\mathbf{x}) = \{\theta \in \mathbb{R} : w \in [w_{0.975}, w_{0.025}]\} = [\min(x_1, \dots, x_{11}) - w_{0.975}, \min(x_1, \dots, x_{11}) - w_{0.025}] = [2.665, 2.998].$$

I exemplet ovan hittade vi ett konfidensintervall för lägesparametern θ . I allmänhet har lägesparametrar och skalparametrar enkla pivotvariabler. Om vi till exempel låter $\mathcal{F}_\mu, \mathcal{F}_\sigma$ och $\mathcal{F}_{\mu,\sigma}$ betecknar lägesfamiljen med lägesparametern μ , skalfamiljen med skalparametern σ respektive läges-skalfamiljen med lägesparametern μ och skalparametern σ har vi följande pivotvariabler:

- Familjen $\mathcal{F}_\mu$ har pivotvariabeln $Q(X, \mu) = X - \mu$.
- Familjen $\mathcal{F}_\sigma$ har pivotvariabeln $Q(X, \sigma) = X/\sigma$.
- Familjen $\mathcal{F}_{\mu,\sigma}$ har pivotvariabeln $Q(X, (\mu, \sigma)) = (X - \mu)/\sigma$.

I exemplet ovan hade vi att statistikan $\min(X_1, \dots, X_n)$ tillhör en lägesfamilj eftersom X tillhör en lägesfamilj. Vi använde därför pivotvariabeln för lägesfamiljen som innehöll statistikan $\min(X_1, \dots, X_n)$. Vi kan göra detsamma för andra vanliga statistikor som i följande exempel.

Exempel 13.6. I Exempel 13.3 hade vi $X_1, \dots, X_n$ oberoende och $f_X(x|\lambda)$ -fördelade där

$$f_X(x|\lambda) = \frac{1}{\lambda} e^{-x/\lambda}.$$

Det följer att $f_X(x)$ tillhör skalfamiljen med skalparametern λ och standardtäthetsfunktion $f_Z(z)$ där $Z \sim \text{Exp}(1)$. Vi har att

$$Y = \sum_{i=1}^n X_i = \sum_{i=1}^n \lambda Z_i = \lambda \left(\sum_{i=1}^n Z_i \right)$$

där $Z_1, \dots, Z_n$ är oberoende och $\text{Exp}(1)$ -fördelade. Det följer att

$$V = \sum_{i=1}^n Z_i \sim \text{Gamma}(n, 1)$$

och $Y = \lambda V$. Med hjälp av en variabeltransformation har vi också att $2V \sim \text{Gamma}(n, 1/2)$; dvs. $2V \sim \chi^2(2n)$. Vi har då att

$$\frac{2Y}{\lambda} \sim \chi^2(2n)$$

är en pivotvariabel eftersom dess täthetsfunktion inte beror på λ .

För att använda en pivotvariabel för att skatta ett $1 - \alpha$ konfidensintervall $[c, d]$ kan vi bestämma $a, b \in \mathbb{R}$ så att

$$P(a \leq Q(\mathbf{X}, \theta) \leq b) \geq 1 - \alpha.$$

Vi har då en $1 - \alpha$ konfidensmängd som ges av

$$C(\mathbf{x}) = \{\theta : a \leq Q(\mathbf{X}, \theta) \leq b\}.$$

Notera att pivotvariabeln $Q(\mathbf{X}, \theta)$ ges av en transformation av $\mathbf{X}$ och θ . I exemplet ovan hade vi exempelvis $Q(\mathbf{X}, \lambda) = 2Y/\lambda$. När denna funktion är monoton kan vi invertera intervallet

$$\{\mathbf{x} : a \leq Q(\mathbf{X}, \theta) \leq b\}$$

för att få $1 - \alpha$ konfidensintervallet

$$C(\mathbf{x}) = \{\theta : a \leq Q(\mathbf{X}, \theta) \leq b\}.$$

(När transformationen inte är monoton är det möjligt att konfidensmängden $C(\mathbf{x})$ inte är ett intervall.)

I Exempel 13.6 använde vi uttrycket av pivotvariabeln $2Y/\lambda$ som en χ^2 -variabel eftersom det låter oss använda en statstabel för att beräkna intervallet. Ett exempel är följande.

Exempel 13.7. I Exempel 13.6 hade vi pivotvariabeln $T = 2Y/\lambda$ och vi bevisade att $T \sim \chi^2(2n)$. För att bestämma ett $1 - \alpha$ konfidensintervall kan vi hitta a och b så att

$$P(a \leq T \leq b) \geq 1 - \alpha.$$

Vi kan därför ta $a = \chi_{2n, 1-\alpha/2}^2$ och $b = \chi_{2n, \alpha/2}^2$ där $\chi_{\eta, \alpha}^2$ betecknar α -kvantilen av en $\chi^2(\eta)$ -fördelningen. Det följer att vi har

$$\begin{aligned} 1 - \alpha &\leq P(a \leq T \leq b) = P(\chi_{2n, 1-\alpha/2}^2 \leq T \leq \chi_{2n, \alpha/2}^2), \\ &= P\left(\chi_{2n, 1-\alpha/2}^2 \leq \frac{2Y}{\lambda} \leq \chi_{2n, \alpha/2}^2\right), \\ &= P\left(\frac{\chi_{2n, 1-\alpha/2}^2}{2Y} \leq \frac{1}{\lambda} \leq \frac{\chi_{2n, \alpha/2}^2}{2Y}\right), \\ &= P\left(\frac{2Y}{\chi_{2n, 1-\alpha/2}^2} \geq \lambda \geq \frac{2Y}{\chi_{2n, \alpha/2}^2}\right). \end{aligned}$$

Vi har då $1 - \alpha$ konfidensintervallet

$$C(\mathbf{x}) = \left[\frac{2y}{\chi_{2n, \alpha/2}^2}, \frac{2y}{\chi_{2n, 1-\alpha/2}^2} \right].$$

Om vi tar $n = 2$ och $1 - \alpha = 0.9$ som i Exempel 13.3 har vi intervallet

$$C(\mathbf{x}) = \left[\frac{x_1 + x_2}{4.744}, \frac{x_1 + x_2}{0.355} \right]$$

Notera att detta intervall inte är detsamma som intervallet från Exempel 13.3 som ges av att invertera ett test. I vissa fall kommer båda metoder ge oss samma intervall men det behöver inte hända.

Ett exempel där båda metoder ger samma intervall är följande.

Exempel 13.8. Låt $X_1, \dots, X_n$ vara oberoende och $N(\theta, \sigma^2)$ -fördelade där σ^2 är känt. Det följer att

$$Z = \frac{\bar{X} - \theta}{\sigma/\sqrt{n}} \sim N(0, 1)$$

och därför kan vi ta Z som en pivotvariabel. Vi har då att

$$P\left(-z_{\alpha/2} \leq \frac{\bar{X} - \theta}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha$$

och därför

$$P(\bar{X} - z_{\alpha/2}\sigma/\sqrt{n} \leq \theta \leq \bar{X} + z_{\alpha/2}\sigma/\sqrt{n}) = 1 - \alpha.$$

Det följer att

$$C(\mathbf{x}) = [\bar{x} - z_{\alpha/2}\sigma/\sqrt{n}, \bar{x} + z_{\alpha/2}\sigma/\sqrt{n}]$$

är ett $1 - \alpha$ konfidensintervall. Detta intervall är detsamma som intervallet i Exempel 13.2 som ges av att invertera ett test.

När vi har fler än en parameter kan vi använda olika pivotvariabler för att skatta ett intervall till var och en parameter. Ett exempel är följande.

Exempel 13.9. Låt $X_1, \dots, X_n$ vara oberoende och $N(\theta, \sigma^2)$ -fördelade där båda θ och σ^2 är okända. I detta fall har vi att

$$\frac{\bar{X} - \theta}{S/\sqrt{n}} \sim t(n-1)$$

är en pivotvariabel. Denna pivotvariabel ger $1 - \alpha$ konfidensintervallet

$$C(\mathbf{x}) = [\bar{x} - t_{n-1, \alpha/2}s/\sqrt{n}, \bar{x} + t_{n-1, \alpha/2}s/\sqrt{n}]$$

för θ . En annan pivotvariabel ges av

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

För denna pivotvariabel har vi

$$P\left(\chi_{n-1, 1-\alpha/2}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{n-1, \alpha/2}^2\right) = 1 - \alpha.$$

När vi inverterar intervallet har vi

$$P\left(\frac{(n-1)S^2}{\chi_{n-1, 1-\alpha/2}^2} \geq \sigma^2 \geq \frac{(n-1)S^2}{\chi_{n-1, \alpha/2}^2}\right) = 1 - \alpha.$$

Därför är

$$C(\mathbf{x}) = \left[\frac{(n-1)s^2}{\chi_{n-1, \alpha/2}^2}, \frac{(n-1)s^2}{\chi_{n-1, 1-\alpha/2}^2}\right]$$

ett $1 - \alpha$ konfidensintervall för σ^2 .

13.2 Bayesiansk intervallskattning

Intervallskattningar är ännu mer användbara i bayesiansk inferens eftersom de ger oss bättre sammanfattningar av aposteriorifördelningen än punktskattningar såsom aposterioriväntevärdet och aposteriorivariansen. I bayesiansk intervallskattning använder vi aposteriorisannolikheter istället för täckningssannolikheter. Detta gör egentligen intervallskattning lättare jämfört med frekventistisk intervallskattning där intervallet är stokastiskt ($L(\mathbf{X})$ och $U(\mathbf{X})$ är stokastiska variabler).

Betrakta en bayesiansk modell där $X_1, \dots, X_n$ är betingat oberoende givet Θ och $X_i|\Theta = \theta$ är $f_X(x|\theta)$ -fördelade för alla $i = 1, \dots, n$. Givet data $\mathbf{x} = [x_1, \dots, x_n]^T$ där $X_1, \dots, X_n$ är oberoende givet Θ kallar vi en mängd A där

$$P(\Theta \in A | \mathbf{X} = \mathbf{x}) = \int_A f_{\Theta|\mathbf{X}}(\theta|\mathbf{x})d\theta = 1 - \alpha$$

för en $1 - \alpha$ kredibilitetsmängd för θ givet datan $\mathbf{X} = \mathbf{x}$. Sannolikheten $P(\Theta \in A | \mathbf{X} = \mathbf{x})$ kallas för kredibilitets-sannolikheten av A . Notera att kredibilitetssannolikheten är helt enkelt aposteriorisannolikheten att θ tillhör A .

När A är ett intervall säger vi att kredibilitetsmängden A är ett *kredibilitetsintervall*. För att bestämma ett $1 - \alpha$ kredibilitetsintervall behöver vi hitta c och d så att

$$\int_{-\infty}^c f_{\Theta|\mathbf{X}}(\theta|\mathbf{x})d\theta + \int_d^{\infty} f_{\Theta|\mathbf{X}}(\theta|\mathbf{x})d\theta = \alpha.$$

Ett naturligt val för intervallet är $[c, d]$ där

$$\int_{-\infty}^c f_{\Theta|\mathbf{X}}(\theta|\mathbf{x})d\theta = \frac{\alpha}{2} \quad \text{och} \quad \int_d^{\infty} f_{\Theta|\mathbf{X}}(\theta|\mathbf{x})d\theta = \frac{\alpha}{2}.$$

Ett sådant intervall kallas för ett *symmetriskt* $1 - \alpha$ kredibilitetsintervall. Vi har redan sett ett exempel på ett symmetriskt kredibilitetsintervall i Kapitel 10. Ett annat exempel är följande.

Exempel 13.10. Låt $X_1, \dots, X_n$ vara oberoende givet Λ där $\Lambda \sim \text{Gamma}(a, b)$ och anta att $X_i|\Lambda = \lambda \sim \text{Po}(\lambda)$ för all $i = 1, \dots, n$. Anta också att a är ett positivt heltal. Det följer att

$$\Lambda|\mathbf{X} = \mathbf{x} \sim \text{Gamma}\left(a + \sum_{i=1}^n x_i, b + n\right).$$

För att bestämma ett $1 - \alpha$ kredibilitetsintervall behöver vi c och d så att

$$\int_{-\infty}^c f_{\Lambda}(\lambda|\mathbf{x})d\lambda + \int_d^{\infty} f_{\Lambda}(\lambda|\mathbf{x})d\lambda = \alpha.$$

Vi kan beräkna c och d så att intervallet är symmetriskt. Vi vill därför ha c och d som uppfyller

$$\int_{-\infty}^c f_{\Lambda}(\lambda|\mathbf{x})d\lambda = \frac{\alpha}{2} \quad \text{och} \quad \int_d^{\infty} f_{\Lambda}(\lambda|\mathbf{x})d\lambda = \frac{\alpha}{2}.$$

Låt $m = a + \sum_{i=1}^n x_i$ och notera att m är ett positivt heltal. Givet $Z \sim \text{Gamma}(m, b + n)$ har vi då att

$$(b + n)Z \sim \text{Gamma}(m, 1)$$

och

$$2(b + n)Z \sim \text{Gamma}(m, 1/2) = \chi^2(2m).$$

Det vill säga att

$$2(b + n)\Lambda|\mathbf{X} = \mathbf{x} \sim \text{Gamma}\left(a + \sum_{i=1}^n x_i, 1/2\right) = \chi^2\left(2a + 2\sum_{i=1}^n x_i\right).$$

Med hjälp av α -kvantilerna av en χ^2 -fördelning (som ges av en statstabell) kan vi beräkna det symmetriska $1 - \alpha$ kredibilitetsintervallet enligt

$$P\left(\chi_{2a+2\sum_{i=1}^n x_i, 1-\alpha/2}^2 \leq 2(b + n)\Lambda \leq \chi_{2a+2\sum_{i=1}^n x_i, \alpha/2}^2 | \mathbf{X} = \mathbf{x}\right) = 1 - \alpha.$$

Mer specifikt tar vi

$$c = \frac{1}{2(b + n)} \chi_{2a+2\sum_{i=1}^n x_i, 1-\alpha/2}^2 \quad \text{och} \quad d = \frac{1}{2(b + n)} \chi_{2a+2\sum_{i=1}^n x_i, \alpha/2}^2.$$

Det följer att det $1 - \alpha$ kredibilitetsintervallet är

$$\left[\frac{\chi_{2a+2\sum_{i=1}^n x_i, 1-\alpha/2}^2}{2(b + n)}, \frac{\chi_{2a+2\sum_{i=1}^n x_i, \alpha/2}^2}{2(b + n)} \right].$$

Som ett konkret exempel kan vi låta $\alpha = 0.1$, $a = b = 1$, $n = 10$ och $\sum_{i=1}^n x_i = 6$. Vi har då det symmetriska 0.90 kredibilitetsintervallet

$$[0.299, 1.077].$$

Istället för symmetriska $1 - \alpha$ kredibilitetsintervall kan vi betrakta $1 - \alpha$ kredibilitetsmängden ges av mängden A som innehåller värdena θ som ger de största värdena på $f_{\Theta|\mathbf{X}}(\theta|\mathbf{x})$; dvs. mängden

$$A = \{\theta \in \Omega : f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) \geq k\}$$

för $k \geq 0$ som uppfyller $P(\Theta \in A | \mathbf{X} = \mathbf{x}) = 1 - \alpha$. Denna mängd kallas för $1 - \alpha$ *HPD-kredibilitetsmängden* (eng. $1 - \alpha$ *highest posterior density (HPD) credible set*).

När aposteriorifördelningen är unimodal har vi att $1 - \alpha$ HPD-kredibilitetsmängden är ett intervall som innehåller aposterioritypvärdet θ^* . I detta fall kallar vi mängden ett $1 - \alpha$ *HPD-kredibilitetsintervall*. För att hitta detta intervall $[c, d]$ söker vi efter värdena c och d så att

- $c \leq \theta^* \leq d$,
- $f_{\Theta|\mathbf{X}}(c|\mathbf{x}) = f_{\Theta|\mathbf{X}}(d|\mathbf{x}) = k \geq 0$, och
- $\int_c^d f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) d\theta = 1 - \alpha$.

Observera att $1 - \alpha$ HPD-kredibilitetsintervallet är detsamma som det symmetriska $1 - \alpha$ kredibilitetsintervallet när $f_{\Theta|\mathbf{X}}(\theta|\mathbf{x})$ är unimodal och symmetrisk. Till exempel är dessa intervall desamma när $X|\Theta = \theta \sim N(\theta, \sigma^2)$ med σ^2 känt och vi tar den konjugerade apriorifördelningen för Θ .

I exemplet ovan hade vi en aposteriorifördelning som var gammafördelad. I detta fall är aposteriorifördelningen unimodal men inte symmetrisk. Detta betyder att $1 - \alpha$ HPD-kredibilitetsintervallet inte kommer att vara lika med intervallet som vi beräknade ovan.

Exempel 13.11. I Exempel 13.10 hade vi aposteriorifördelningen

$$\Lambda | \mathbf{X} = \mathbf{x} \sim \text{Gamma} \left(a + \sum_{i=1}^n, n + b \right).$$

Vi tog $a = b = 1$, $n = 10$ och $\sum_{i=1}^n x_i = 6$ och därför hade vi

$$\Lambda | \mathbf{X} = \mathbf{x} \sim \text{Gamma}(7, 11).$$

Aposteriorifördelningen är unimodal och därför kommer $1 - \alpha$ HPD-kredibilitetsmängden att vara ett intervall. För att hitta detta intervall behöver vi hitta $c < d$ så att

$$f_{\Lambda|\mathbf{X}}(c|\mathbf{x}) = f_{\Lambda|\mathbf{X}}(d|\mathbf{x})$$

och

$$\int_c^d f_{\Lambda|\mathbf{X}}(\lambda|\mathbf{x}) d\lambda = 1 - \alpha.$$

Det vill säga att vi vill lösa systemet

$$\begin{aligned} c^6 e^{-11c} &= d^6 e^{-11d}, \\ \int_c^d \frac{11^7}{\Gamma(7)} \lambda^6 e^{-11\lambda} d\lambda &= 1 - \alpha. \end{aligned}$$

Systemet kan lösas numeriskt och vi får ut intervallet

$$[c, d] = [0.253, 1.001]$$

när vi tar $\alpha = 0.1$.

Detta intervall har längd 0.75 medan det 0.90 symmetriska kredibilitetsintervallet som beräknas i Exempel 13.10 har längd 0.78. HPD-kredibilitetsintervallet är då kortare än det 0.90 symmetriska kredibilitetsintervallet trots att de har samma kredibilitetssannolikhet. Vi har då två olika intervall med samma kredibilitetssannolikhet. Det skulle därför vara bra om vi hade metoder för att jämföra olika val av intervall.

13.3 Beslutsteori för intervallskattning

Precis som punktskattningar och hypotestest kan tolkas som beslut i ett visst handlingsrum kan vi göra detsamma för intervallskattningar. Det vill säga att vi kan betrakta ett beslutsregel $W : \mathbb{R}^n \rightarrow \mathcal{A}$ som specificerar ett intervall $W(\mathbf{x}) \in \mathcal{A}$ enligt datan $\mathbf{x}$ där $\mathcal{A}$ är en mängd intervallskattningar. Vi kan då definiera en förlustfunktion på detta handlingsrum och betrakta riskfunktionen.

Till exempel kan vi betrakta handlingsrummet $\mathcal{A} = \{(-\infty, a] : a \in \mathbb{R}\}$ som består av alla ensidiga intervall med en övre gräns. Vi kan då definiera förlustfunktionen

$$L(\theta, a) = \begin{cases} c(a - \theta) & a \geq \theta \quad (\text{intervallet täcker } \theta) \\ (1 - c)(\theta - a) & a < \theta \quad (\text{intervallet täcker inte } \theta) \end{cases}$$

för något c som uppfyller $c < 1 - c$. Vi straffar därför intervall som täcker θ med c gånger så mycket de "övertäcker" θ och vi straffar intervall som inte täcker θ med $1 - c$ gånger så mycket de "undertäcker" θ . Notera att vi straffar intervall som inte täcker θ mer eftersom $c < 1 - c$.

Riskfunktionen och aposterioririsen kan beräknas som vanligt. Mer specifikt ges aposterioririsen av

$$\begin{aligned} E[L(\theta, a) | \mathbf{X} = \mathbf{x}] &= \int_{-\infty}^{\infty} L(\theta, a) f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta, \\ &= \int_{-\infty}^a c(a - \theta) f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta + \int_a^{\infty} (1 - c)(\theta - a) f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta, \\ &= ca \int_{-\infty}^a f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta - c \int_{-\infty}^a \theta f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta + (1 - c) \int_a^{\infty} \theta f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta \\ &\quad - (1 - c)a \int_a^{\infty} f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta, \\ &= ca \int_{-\infty}^a f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta - (1 - c)a \int_a^{\infty} f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta - c \int_{-\infty}^a \theta f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta + \int_a^{\infty} \theta f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta. \end{aligned}$$

För att hitta bayesbeslutet (dvs. intervallet som minimerar aposterioririsen) beräknar vi derivatan av $E[L(\theta, a) | \mathbf{X} = \mathbf{x}]$ med avseende på a med hjälp av integralkalkylens fundamentalsats (som vi gjorde i Exempel 9.3).

$$\begin{aligned} \frac{d}{da} E[L(\theta, a) | \mathbf{X} = \mathbf{x}] &= c \int_{-\infty}^a f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta + ca f_{\Theta | \mathbf{X}}(a | \mathbf{x}) - (1 - c) \int_a^{\infty} f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta \\ &\quad + (1 - c)a f_{\Theta | \mathbf{X}}(a | \mathbf{x}) - 0 - a f_{\Theta | \mathbf{X}}(a | \mathbf{x}), \\ &= c \int_{-\infty}^a f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta - (1 - c) \int_a^{\infty} f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta, \\ &= c \int_{-\infty}^{\infty} f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta - \int_a^{\infty} f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta, \\ &= c - \int_a^{\infty} f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta. \end{aligned}$$

När vi sätter $\frac{d}{da} E[L(\theta, a) | \mathbf{X} = \mathbf{x}]$ lika med noll får vi

$$\int_a^{\infty} f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta = c,$$

vilket är detsamma som

$$1 - c = \int_{-\infty}^a f_{\Theta | \mathbf{X}}(\theta | \mathbf{x}) d\theta.$$

Man kan verifiera att andraderivatan $\frac{d^2}{da^2} E[L(\theta, a) | \mathbf{X} = \mathbf{x}]$ är positiv i punkten a som löser ekvationen ovan. Det vill säga att bayesbeslutet är c -kvantilen av aposteriorifördelningen.

Om vi vill ha ett tvåsidigt intervall $[a_1, a_2]$ kan vi betrakta förlustfunktionen

$$L(\theta, [a_1, a_2]) = a_2 - a_1 + \begin{cases} c_1(a_1 - \theta) & \theta < a_1, \\ 0 & a_1 \leq \theta \leq a_2, \\ c_2(\theta - a_2) & \theta > a_2 \end{cases}$$

där $c_1, c_2 > 1$. Bayesbeslutet med avseende på denna förlustfunktion ges av $[a_1, a_2]$ där a_1 är $1/c_1$ -aposteriorikvantilen och a_2 är $(1 - 1/c_2)$ -aposteriorikvantilen när $c_1, c_2 > 1$. Mer specifikt är bayesbeslutet det symmetriska $1 - \alpha$ kredibilitetsintervallet när $c_1 = c_2 = 2/\alpha > 1$.

Till sist kan vi betrakta en förlustfunktion som ger ett konstant straff när vi inte täcker θ :

$$L(\theta, [a_1, a_2]) = a_2 - a_1 + c(1 - \mathbf{1}_{[a_1, a_2]}(\theta)).$$

Bayesbeslutet med avseende på denna förlustfunktion är

$$\{\theta : f_{\Theta}(\theta | \mathbf{X} = \mathbf{x}) \geq 1/c\}$$

när aposteriorifördelningen är unimodal och kontinuerlig; dvs. bayesbeslutet är $1 - \alpha$ HPD-kredibilitetsintervallet med undre gräns $1/c$. Värdet c representerar kostnaden för att inte täcka θ . Ju högre c är desto längre är intervallet (bayesbeslutet).

I exemplet ovan fokuserade vi på beslutsteori som används i bayesiansk intervallskattning. Man kan självklart också använda besluteori för att utvärdera intervallskattningar i frekventistisk inferens. Till exempel kan detta hjälpa oss bestämma mellan två olika val av intervallskattning. I detta fall kan man ta mängden av alla intervall vi kan välja på som handlingsrum. Vi specificerar då en förlustfunktion och tar intervallet som minimerar risken. Det är exempelvis vanligt att betrakta mängden av alla $1 - \alpha$ konfidensintervall för ett fixt α och definiera en förlustfunktion som minimerar en informativ egenskap hos intervallet; t.ex. intervallets längd. Ett kortare intervall kan föredras eftersom man kan tolka intervallet som mer exakt än längre intervall med samma konfidensgrad. Till exempel beräknade vi två 0.90 konfidensintervall

$$C_1(\mathbf{x}) = \left[\frac{x_1 + x_2}{5.480}, \frac{x_1 + x_2}{0.441} \right] \quad \text{och} \quad C_2(\mathbf{x}) = \left[\frac{x_1 + x_2}{4.744}, \frac{x_1 + x_2}{0.355} \right]$$

för samma parameter i Exempel 13.3 respektive Exempel 13.7. Om vi tar handlingsrummet $\mathcal{A} = \{C_1(\mathbf{x}), C_2(\mathbf{x})\}$ och en förlustfunktion som föredrar kortare intervall kommer vi att välja intervallet $C_1(\mathbf{x})$.

13.4 Uppgifter

13.1. [1] Låt

$$x_1 = -1.379, x_2 = -4.004, x_3 = 3.8, x_4 = -1.797, x_5 = 0.341.$$

vara ett stickprov från en $N(\theta, 4)$ -population. Intervertera ett test med nollhypotes $H_0 : \theta = \theta_0$ för att bestämma följande:

- (a) ett tvåsidigt 0.95 konfidensintervall $[a, b]$ för θ .
- (b) ett ensidigt 0.95 konfidensintervall $[a, \infty)$ för θ .
- (c) ett ensidigt 0.95 konfidensintervall $(-\infty, b]$ för θ .

13.2. [1] Vi har ett stickprov

$$\begin{aligned} x_1 &= -0.34, x_2 = 0.62, x_3 = -0.37, x_4 = -0.07, x_5 = -0.70, \\ x_6 &= 0.07, x_7 = -2.49, x_8 = 0.70, x_9 = -1.52, x_{10} = -0.27 \end{aligned}$$

från en $N(\theta, \sigma^2)$ -population där båda θ och σ^2 är okända.

- (a) Invertera ett test med nollhypotes $H_0 : \theta = \theta_0$ för att bestämma ett tvåsidigt 0.90-konfidensintervall för θ .
- (b) Använda en pivotvariabel för att bestämma ett tvåsidigt 0.90-konfidensintervall för θ .
- (c) Är dessa intervall desamma? Om de inte är desamma bestämma vilket intervall du föredrar och förklara varför.

13.3. [1] Vi har ett stickprov

$$\begin{aligned} x_1 &= 4.12, x_2 = 1.98, x_3 = -1.86, x_4 = 12.31, x_5 = 0.33, \\ x_6 &= 5.96, x_7 = 5.75, x_8 = 6.67, x_9 = -4.71, x_{10} = 2.47 \end{aligned}$$

från en $N(0, \sigma^2)$ -population. Använd en pivotvariabel för att bestämma ett tvåsidigt 0.90-konfidensintervall för σ^2 .

- 13.4. [1] Låt $X_1, \dots, X_n$ vara oberoende och likafördelade med fördelningsfunktion ges av

$$P(X_i \leq x \mid \alpha, \beta) = \begin{cases} 0, & x < 0, \\ (x/\beta)^\alpha, & 0 \leq x \leq \beta \\ 1, & x > \beta, \end{cases}$$

där parametrarna α och β är positiva.

- (a) ML-skattningen $[\hat{\alpha}, \hat{\beta}]^T$ för $[\alpha, \beta]^T$ ges av

$$\hat{\alpha} = \frac{n}{\sum_{i=1}^n (\log(\max_i(X_i)) - \log(X_i))} \quad \hat{\beta} = \max_i(X_i).$$

(Se uppgift 3 på övning 6.) Bestäm ett ensidigt 0.95 konfidensintervall $(0, U(\mathbf{X}))$ för β när α är fixt (och därmed känt).

- (b) Längden (i millimeter) på ett gökäg i häcksparvars bon kan modelleras med denna fördelning. Konstruera ett konfidensintervall för β med hjälp av data

$$22.0, 23.9, 20.9, 23.8, 25.0, 24.0, 21.7, 23.8, 22.8, 23.1, 23.1, 23.5, 23.0, 23.0$$

där du får anta att α är fixt och lika med sin ML-skattning.

- 13.5. [1] (a) Plotta täthetsfunktionerna för $\text{Beta}(\alpha, \beta)$ och $N\left(\frac{\alpha}{\alpha+\beta}, \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}\right)$ tillsammans för flera olika val för $\alpha, \beta > 0$. Vad observerar du när $\alpha, \beta \geq 10$?
- (b) Låt $X|\Theta = \theta \sim \text{Bin}(20, \theta)$ och $\Theta \sim \text{Beta}(5, 3)$. Bestäm ett *approximativt* 0.95 symmetriskt kredibilitetsintervall för θ med hjälp av del (a) och följande data

$$10, 10, 15, 16, 12, 11, 3, 4, 8, 5.$$

- 13.6. [2] Anta att $X_1, \dots, X_n$ är betingat oberoende givet Θ_M och Θ_V där

$$\begin{aligned} X_i|\Theta_M = \theta_m, \Theta_V = \theta_V &\sim N(\theta_m, \theta_V), \\ \Theta_M|\Theta_V = \theta_V &\sim N(0, \theta_V) \\ \Theta_V &\sim \text{InvGamma}(5, 3) \end{aligned}$$

Bestäm ett 0.95 symmetriskt kredibilitetsintervall för $\Theta_M|\mathbf{X} = \mathbf{x}$ med hjälp av stickprovet

$$-0.013, -1.793, 0.204, -1.786, -2.617, -1.095, -0.903, 1.044.$$

- 13.7. [1] Anta att $X_1, \dots, X_n$ är betingat oberoende givet Θ och $\text{Exp}(\theta)$ -fördelade där vi har apriorifördelningen $\Theta \sim \text{Gamma}(7, 3)$. Bestäm ett 0.95 symmetriskt kredibilitetsintervall för θ med hjälp av stickprovet

$$0.238, 0.014, 0.465, 0.384, 0.032, 0.140, 0.200, 0.134, 0.772, 0.744.$$

- 13.8. [1] Anta att

$$3.998, 4.087, 6.403, 3.598, 4.786, 3.619, 2.850, 4.980, 4.100, 3.384$$

är ett stickprov från en $N(\theta, 4)$ -fördelning. Bestäm ett 0.90 konfidensintervall för θ genom att invertera testet

$$\text{Förkasta } H_0 \text{ om } |\bar{x} - \theta_0| \geq c \text{ för någon } c > 0$$

för

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta \neq \theta_0.$$

- 13.9. [1] Låt $X_1, \dots, X_n$ vara oberoende och likafördelade med täthetsfunktion $f_X(x|\theta)$ som tillhör lägefamiljen med standardtäthetsfunktion $f_Z(z) = e^{-z}$. Vi såg i föreläsning 12 att ett test för

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_1 : \theta > \theta_0$$

med nivå $\alpha = 0.05$ ges av

Förkasta H_0 om $\min_i(X_i) - \theta_0 \geq 0.27$.

Invertera detta test för att bestämma ett 0.95 konfidensintervall för θ med hjälp av utbrottens data 15, 9, 59, 18, 5, 41, 3, 7, 5, 7, 4.

- 13.10.** [2] (a) Låt $x_1, \dots, x_n$ vara ett stickprov från en $N(\theta, a\theta)$ -population där θ är okänt. Invertera ett likelihood-kvottest för $H_0 : a = a_0$ mot $H_1 : a \neq a_0$ för att bestämma en $1 - \alpha$ konfidensmängd för a .
- (b) Anta istället att $x_1, \dots, x_n$ är ett stickprov från en $N(\theta, a\theta^2)$ -population. Invertera ett likelihood-kvottest för $H_0 : a = a_0$ mot $H_1 : a \neq a_0$ för att bestämma en $1 - \alpha$ konfidensmängd för a .
- 13.11.** [2] Låt x vara ett utfall från en $\text{Beta}(\theta, 1)$ -population.
- (a) Låt $Y = -\frac{1}{\log(X)}$. Vad är konfidensgraden av intervallet $[y/2, y]$?
- (b) Bestäm en pivotvariabel och använd den för att bestämma ett konfidensintervall med samma konfidensgrad som intervallet i del (a).
- (c) Jämför intervallena i del (a) och (b).
- 13.12.** [2] Vi modellerar antalet bränder per vecka i en viss by som $X|\Theta = \theta \sim \text{Po}(\theta)$ med den icke-informativa apriorifördelningen $f_\Theta(\theta) \propto \theta^{-1} \mathbf{1}_{(0, \infty)}$. Vi vill bestämma ett 0.95 kredibilitetsintervall för θ med hjälp av antalet bränder varje vecka över fem veckor:

0, 1, 1, 0, 0.

- (a) Bestäm det önskade kredibilitetsintervallet.
- (b) Bestäm ett approximativt 0.90 kredibilitetsintervall med hjälp av en normalapproximering $N(E[\Theta|\mathbf{x}], \text{Var}[\Theta|\mathbf{x}])$ som i Uppgift 13.5.

Kapitel 14

14.1 Konvergens

Vi såg flera gånger att det ofta blir lättare att skatta parametrar när vi har ett stort stickprov. Till exempel betraktade vi monte-carlo metoden där approximationsfel för $E[h(X)]$ minskade mot noll då stickprovets storlek ökade mot oändlighet. Från detta perspektiv kan det vara användbart att betrakta vad händer till skattningarna som vi har när stickprovets storlek är oändligt stor. När skattningarna konvergerar till vissa värden som vi kan beräkna kan vi då använda dessa värden för att approximera skattningarna när stickprovet är ändligt men tillräckligt stort.

Vi kommer att betrakta två typer av konvergens. Den första typen kallas för konvergens i sannolikhet. Vi säger att en följd av stokastiska variabler $X_1, X_2, \dots$ konvergerar i sannolikhet mot en stokastisk variabel X när

$$P(|X_n - X| \geq \varepsilon) \rightarrow 0$$

då $n \rightarrow \infty$ för varje $\varepsilon > 0$. När $X_1, X_2, \dots, X_n, \dots$ konvergerar i sannolikhet mot X skriver vi

$$X_n \xrightarrow{P} X \quad \text{då} \quad n \rightarrow \infty.$$

I statistik är vi ofta intresserade av situationer där X är en konstant och $X_1, \dots, X_n$ är en följd av väntevärden. Till exempel bevisade vi *Tjebysjovs olikhet* i SF1918 som kan användas för att bevisa stora talens lag:

Sats 14.1 (Tjebysjovs olikhet). *Låt X vara en stokastisk variabel med väntevärdet μ och standardavvikelse $\sigma > 0$. För varje $k > 0$ har vi att*

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

Sats 14.2 (Stora talens lag). *Låt $X_1, X_2, \dots$ vara oberoende och likafördelade stokastiska variabler med samma väntevärde μ och standardavvikelsen $\sigma > 0$. Låt*

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Då har vi för varje $\varepsilon > 0$ att

$$P(|\bar{X}_n - \mu| < \varepsilon) \rightarrow 1 \quad \text{då} \quad n \rightarrow \infty.$$

Med andra ord,

$$\bar{X}_n \xrightarrow{P} \mu \quad \text{då} \quad n \rightarrow \infty.$$

Bevis. Låt $\varepsilon > 0$ och låt $k = \varepsilon\sqrt{n}/\sigma$. Enligt Tjebysjovs olikhet har vi att

$$P(|\bar{X}_n - \mu| \geq \varepsilon) = P(|\bar{X}_n - \mu| \geq k\sigma/\sqrt{n}) \leq \frac{1}{k^2} = \frac{\sigma^2}{\varepsilon^2 n}.$$

Här använder vi att $\text{Var}[\bar{X}_n] = \sigma^2/n$ (se Sats 5.1). Det följer då att

$$P(|\bar{X}_n - \mu| < \varepsilon) = 1 - P(|\bar{X}_n - \mu| \geq \varepsilon) \geq 1 - \frac{\sigma^2}{n\varepsilon^2} \rightarrow 1$$

då $n \rightarrow \infty$. □

I följande kommer vi ofta betrakta en följd av stokastiska variabler $X_1, X_2, \dots$ och statistikan $W_n(\mathbf{X}) = W_n(X_1, \dots, X_n)$ för $n = 1, 2, \dots$. Till exempel betecknar vi stickprovsmedelvärdena och stickprovsvarianserna

$$\frac{1}{n} \sum_{i=1}^n X_i \quad \text{och} \quad \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

som $\bar{X}_n$ respektive S_n^2 när $X_1, X_2, \dots$ är oberoende och likafördelade.

Den andra typen av konvergens vi kommer att betrakta kallas för konvergens i fördelning. Vi säger att en följd av stokastiska variabler $X_1, X_2, \dots$ *konvergerar i fördelning* mot X när

$$F_{X_n}(x) \longrightarrow F_X(x) \quad \text{då} \quad n \longrightarrow \infty$$

för varje x i vilket $F_X(x)$ är kontinuerlig. När $X_1, X_2, \dots$ konvergerar i fördelning mot $F_X(x)$ skriver vi

$$X_n \xrightarrow{D} X \quad \text{då} \quad n \longrightarrow \infty.$$

Exempel 14.1. Låt $X_1, X_2, \dots$ vara oberoende och $U(0, 1)$ -fördelade och låt $Y_n = \max(X_1, \dots, X_n)$. Eftersom $Y_n \leq 1$ för alla n har vi

$$P(|Y_n - 1| \geq \varepsilon) = P(Y_n \geq 1 + \varepsilon) + P(Y_n \leq 1 - \varepsilon) = 0 + P(Y_n \leq 1 - \varepsilon) = P(Y_n \leq 1 - \varepsilon)$$

för alla $\varepsilon > 0$. Eftersom $X_1, \dots, X_n$ är oberoende och $U(0, 1)$ -fördelade har vi att

$$P(Y_n \leq 1 - \varepsilon) = \prod_{i=1}^n P(X_i \leq 1 - \varepsilon) = (1 - \varepsilon)^n.$$

Det följer att

$$P(Y_n \leq 1 - \varepsilon) = (1 - \varepsilon)^n \longrightarrow 0 \quad \text{då} \quad n \longrightarrow \infty.$$

Detta betyder att Y_n konvergerar mot 1 i sannolikhet. Om vi istället låter $\varepsilon = t/n$ har vi att

$$P(Y_n \leq 1 - t/n) = (1 - t/n)^n \longrightarrow e^{-t} \quad \text{då} \quad n \longrightarrow \infty.$$

Det vill säga att

$$P(n(1 - Y_n) \leq t) \longrightarrow 1 - e^{-t} \quad \text{då} \quad n \longrightarrow \infty.$$

Vi har då bevisat att $n(1 - Y_n)$ konvergerar i fördelning mot $Z \sim \text{Exp}(1)$.

Vi har också sett (i SF1918) konvergens i fördelning när vi diskuterade *centrala gränsvärdessatsen*:

Sats 14.3 (Centrala gränsvärdessatsen). *Låt $X_1, X_2, \dots$ vara oberoende och likafördelade med samma väntevärde μ och varians $0 < \sigma^2 < \infty$. Vi har då att*

$$\sqrt{n} \left(\frac{\bar{X}_n - \mu}{\sigma} \right) \xrightarrow{D} Z \quad \text{då} \quad n \longrightarrow \infty$$

där $Z \sim N(0, 1)$.

Eftersom vi inte vill definiera en ny variabel X och specificera X 's fördelning varje gång vi har konvergens i fördelning skriver vi ofta ovan som

$$\sqrt{n} \left(\frac{\bar{X}_n - \mu}{\sigma} \right) \xrightarrow{D} N(0, 1) \quad \text{då} \quad n \longrightarrow \infty$$

eller

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N(0, \sigma^2) \quad \text{då} \quad n \longrightarrow \infty.$$

Generellt sett har vi att $X_1, X_2, \dots$ konvergerar i fördelning när $X_1, X_2, \dots$ konvergerar i sannolikhet; dvs.

$$X_n \xrightarrow{P} X \quad \implies \quad X_n \xrightarrow{D} X.$$

Konversen behöver inte stämma. Ett fall där konversen stämmer är när $X_n \xrightarrow{D} c$ för en konstant c . I detta fall har vi att $X_n \xrightarrow{P} c$.

Vi har också följande sats:

Sats 14.4. Låt $g(x)$ vara en kontinuerlig funktion. Vi har då att

$$\begin{aligned} g(X_n) &\xrightarrow{P} g(X) & \text{när} & \quad X_n \xrightarrow{P} X, & \text{och} \\ g(X_n) &\xrightarrow{D} g(X) & \text{när} & \quad X_n \xrightarrow{D} X. \end{aligned}$$

Ett annat användbart resultat kallas för Slutskys sats. Denna sats tillämpas ofta tillsammans med centrala gränsvärdessatsen.

Sats 14.5 (Slutskys sats). Låt $X_1, X_2, \dots$ konvergera mot X i fördelning och $Y_1, Y_2, \dots$ konvergera i sannolikhet mot en konstant k . Då har vi att

1. $X_n Y_n \xrightarrow{D} kX$, och
2. $X_n + Y_n \xrightarrow{D} X + k$.

Exempel 14.2. Anta att $X_1, X_2, \dots$ är oberoende och likafördelade med samma väntevärde μ och varians $0 < \sigma^2 < \infty$. Enligt centrala gränsvärdessatsen har vi att

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1)$$

men σ är okänd. Vi kommer också att bevisa $S_n^2 \xrightarrow{P} \sigma^2$. Eftersom funktionen $g(x) = \sigma/\sqrt{x}$ är kontinuerlig på $(0, \infty)$ har vi att $\sigma/S_n \xrightarrow{P} 1$ enligt Sats 14.4. Enligt Slutskys sats har då vi att

$$\frac{\bar{X}_n - \mu}{S_n/\sqrt{n}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \frac{\sigma}{S_n} \xrightarrow{D} (1) N(0, 1) = N(0, 1).$$

14.2 Deltametoden

Centrala gränsvärdessatsen är ett kraftfullt resultat som säger att när en följd av standardiserade stokastiska variabler konvergerar till en standardnormalfördelning. Vi är dock inte alltid intresserade av de stokastiska variablerna $X_1, X_2, \dots$ själva utan en funktion av variablerna $g(X_1), g(X_2), \dots$.

Vi kan ofta använda formeln för en variabeltransformation

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|$$

men detta kan ibland vara svårt att beräkna. I detta fall vill vi ha en approximation istället. Ett sätt att göra detta är att använda Taylorpolynom.

Låt $g(x)$ vara en funktion så att

$$g^{(r)}(x) = \frac{d^r}{dx^r} g(x)$$

existerar; dvs. $g(x)$ är r gånger differentierbar där r ett positivt heltal. Låt c vara en konstant. Det r :te Taylorpolynomet av $g(x)$ i c är

$$T_r(x) = \sum_{i=0}^r \frac{g^{(i)}(c)}{i!} (x - c)^i.$$

Taylorpolynom ger oss ett sätt att approximera funktionen $g(x)$ runt c . I denna bok använder vi ofta första Taylorpolynomet för att approximera $g(x)$:

$$g(x) \approx T_1(x) = g(c) + g'(c)(x - c).$$

Vi kan också göra detsamma när $g(\mathbf{x}) : \mathbb{R}^k \rightarrow \mathbb{R}$ är en funktion av flera variabler. Till exempel har vi approximationen

$$g(\mathbf{x}) \approx g(\mathbf{c}) + \sum_{i=0}^k \left(\frac{\partial g}{\partial x_i}(\mathbf{c}) \right) (x_i - c_i)$$

när $g(\mathbf{x})$ är två gånger differentierbar och $\mathbf{c} \in \mathbb{R}^k$ är en konstant (vektor).

När vi låter $\mathbf{c} = \boldsymbol{\mu}$ och betraktar den k -dimensionella stokastiska vektorn $\mathbf{X} = [X_1, \dots, X_k]^T$ har vi att

$$\begin{aligned} g(\mathbf{x}) &\approx g(\boldsymbol{\mu}) + \sum_{i=1}^k \left(\frac{\partial g}{\partial x_i}(\boldsymbol{\mu}) \right) (x_i - \mu_i), \quad \text{och} \\ \mathbb{E}[g(\mathbf{X})] &\approx \mathbb{E}[g(\boldsymbol{\mu})] + \sum_{i=1}^k \left(\frac{\partial g}{\partial x_i}(\boldsymbol{\mu}) \right) \mathbb{E}[X_i - \mu_i], \\ \mathbb{E}[g(\mathbf{X})] &\approx \mathbb{E}[g(\boldsymbol{\mu})] + \sum_{i=1}^k \left(\frac{\partial g}{\partial x_i}(\boldsymbol{\mu}) \right) 0, \\ \mathbb{E}[g(\mathbf{X})] &\approx g(\boldsymbol{\mu}). \end{aligned}$$

På samma sätt kan vi approximera variansen av $g(\mathbf{X})$ enligt

$$\begin{aligned} \text{Var}[g(\mathbf{X})] &\approx \mathbb{E}[(g(\mathbf{X}) - g(\boldsymbol{\mu}))^2], \\ &\approx \mathbb{E} \left[\left(\sum_{i=1}^k \left(\frac{\partial g}{\partial x_i}(\boldsymbol{\mu}) \right) (X_i - \mu_i) \right)^2 \right], \\ &\approx \sum_{i=1}^n \left(\frac{\partial g}{\partial x_i}(\boldsymbol{\mu}) \right)^2 \text{Var}[X_i] + 2 \sum_{i>j} \left(\left(\frac{\partial g}{\partial x_i}(\boldsymbol{\mu}) \right) \left(\frac{\partial g}{\partial x_j}(\boldsymbol{\mu}) \right) \right) \text{Cov}[X_i, X_j]. \end{aligned}$$

Detta ger oss inte en approximation till hela fördelningen. Det är dock ofta tillräckligt att ha en bra approximation för väntevärdet och variansen. I ovan använde vi den första taylorpolynomet för att beräkna approximationen. Detta kommer bara att fungera bra när $X_1, \dots, X_n$ inte varierar så mycket runt $\boldsymbol{\mu}$. Detta är exempelvis fallet när vi tillämpar centrala gränsvärdessatsen:

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{D} N(0, \sigma^2).$$

I detta fall har vi att $\bar{X}$ varierar mindre och mindre runt μ då n ökar. Det följer att approximationen ovan blir bättre och bättre då n ökar.

Här använder vi taylorapproximationen

$$g(x) \approx g(c) + g'(d)(x - c),$$

där d ligger mellan x och c . Denna approximation fungerar när $g(x)$ är kontinuerlig. Anta nu att vi har en följd av stokastiska variabler $W_1, W_2, \dots$ så att

$$\sqrt{n}(W_n - \theta) \xrightarrow{D} N(0, \sigma^2)$$

för något $\theta \in \mathbb{R}$ och $\sigma^2 > 0$. Vi har då att

$$g(W_n) \approx g(\theta) + g'(\tilde{\theta}_n)(W_n - \theta)$$

för något $\tilde{\theta}_n$ mellan θ och W_n . Notera att $W_n \xrightarrow{P} \theta$. Detta följer enligt Slutskys sats eftersom

$$\sqrt{n}(W_n - \theta) \xrightarrow{D} N(0, \sigma^2) \quad \text{och} \quad \frac{1}{\sqrt{n}} \xrightarrow{P} 0.$$

Eftersom $\tilde{\theta}_n$ ligger mellan θ och W_n följer det också att $\tilde{\theta}_n \xrightarrow{P} \theta$ då $n \rightarrow \infty$. Det följer då att

$$g'(\tilde{\theta}_n) \xrightarrow{P} g'(\theta) \quad \text{då} \quad n \rightarrow \infty$$

eftersom $g'(x)$ är kontinuerlig.

Vi kan då skriva om

$$g(W_n) \approx g(\theta) + g'(\tilde{\theta}_n)(W_n - \theta)$$

som

$$\sqrt{n}(g(W_n) - g(\theta)) \approx g'(\tilde{\theta}_n)\sqrt{n}(W_n - \theta)$$

där vi har att

$$\sqrt{n}(W_n - \theta) \xrightarrow{D} N(0, \sigma^2) \quad \text{och} \quad g'(\tilde{\theta}_n) \xrightarrow{P} g'(\theta).$$

Enligt Slutskys sats har vi då att

$$\sqrt{n}(g(W_n) - g(\theta)) \xrightarrow{D} g'(\theta) N(0, \sigma^2) = N(0, g'(\theta)^2 \sigma^2)$$

när $g'(\theta) \neq 0$. Det följer att vi kan approximera fördelningen av $g(W_n)$ som

$$N\left(g(\theta), \frac{g'(\theta)^2 \sigma^2}{n}\right)$$

när n är stort. Detta resultat kallas för *deltametoden*. Vi sammanfattar resultatet i följande sats.

Sats 14.6 (Deltametoden). *Låt $W_1, W_2, \dots$ vara en följd av stokastiska variabler som uppfyller*

$$\sqrt{n}(W_n - \theta) \xrightarrow{D} N(0, \sigma^2)$$

för något $\theta \in \mathbb{R}$ och $\sigma^2 > 0$. Låt $g(x)$ vara kontinuerlig och anta att $g'(x)$ existerar och $g'(\theta) \neq 0$. Det följer att

$$\sqrt{n}(g(W_n) - g(\theta)) \xrightarrow{D} N(0, g'(\theta)^2 \sigma^2).$$

Ett exempel är följande.

Exempel 14.3. Låt $X_1, X_2, \dots$ vara oberoende och $\text{Ber}(p)$ -fördelade. Vi är ofta intresserade av p men biologer föredrar ibland att skatta *oddset* $p/(1-p)$ istället. Till exempel betraktar biologer kvoten

$$\frac{p}{1-p} \bigg/ \frac{p'}{1-p'}.$$

när de kör ett experiment med en kontrollgrupp och en experimentgrupp. Här betecknar p sannolikheten att en person som inte tar ett visst läkemedel blir frisk och p' betecknar sannolikheten att en person som tar läkemedlet blir frisk.

Vi har i detta fall att $E[X_i] = p$ och $\text{Var}[X_i] = p(1-p)$. Det följer då att

$$\sqrt{n}(\bar{X}_n - E[X_i]) \xrightarrow{D} N(0, \text{Var}[X_i])$$

enligt centrala gränsvärdessatsen; dvs.

$$\sqrt{n}(\bar{X}_n - p) \xrightarrow{D} N(0, p(1-p)),$$

Om vi vill skatta oddset $\frac{p}{1-p}$ kan vi ta $g(x) = \frac{x}{1-x}$ och använda deltametoden. Vi har då att

$$\sqrt{n}(g(\bar{X}_n) - g(p)) \xrightarrow{D} N(0, g'(p)^2 p(1-p)),$$

eller

$$\sqrt{n}(g(\bar{X}_n) - p/(1-p)) \xrightarrow{D} N\left(0, \frac{1}{(1-p)^4} (p(1-p))\right) = N\left(0, \frac{p}{(1-p)^3}\right),$$

För stor n kan vi approximera fördelningen av $g(\bar{X}_n)$ med

$$N\left(\frac{p}{1-p}, \frac{p}{n(1-p)^3}\right).$$

Skattningen blir mer exakt när $n \rightarrow \infty$ men konvergenshastigheten ges av $p/(1-p)^3$. För litet p konvergerar det snabbt men för stort p konvergerar det långsamt eftersom nämnaren är stor.

Deltametoden är ganska användbar eftersom det kan tillämpas så länge som vi har ett resultat på formen

$$\sqrt{n}(W_n - c) \xrightarrow{D} N(0, v),$$

Till exempel kan vi alltid tillämpa deltametoden till ett resultat som ges av centrala gränsvärdessatsen.

14.3 Konsistens

Vi kan tillämpa de asymptotiska resultaten ovan på många olika följder av stokastiska variabler $W_1, W_2, \dots$. I statistisk inferens är vi ofta intresserade av en viss statistika $W = W(X_1, \dots, X_n)$ som beräknas enligt ett stickprov $X_1, \dots, X_n$; t.ex. en punktskattning. Vi kan då utforska vad händer med punktskattningen då stickprovets storlek n går mot oändlighet. I detta fall vill vi betrakta en följd av punktskattningar $W_1, W_2, \dots$ där

$$W_n = W(X_1, \dots, X_n)$$

och följden $X_1, X_2, \dots$ består av oberoende och likafördelade variabler. Till exempel har vi redan betraktat följden $W_1, W_2, \dots$ där $W_n = \bar{X}_n$ flera gånger.

I detta fall hoppas vi att följden konvergerar i sannolikhet till parametern som vi vill skatta. När detta händer vet vi att punktskattningen W_n blir bättre och bättre när stickprovets storlek ökar. Vi säger då att en följd av punktskattningar $W_1, W_2, \dots$ med avseende på en parameter θ är *konsistent* när

$$W_n \xrightarrow{P} \theta \quad \text{då} \quad n \rightarrow \infty \quad \text{för alla } \theta \in \Omega.$$

Punktskattningarna $W_1, W_2, \dots$ är ofta desamma i den meningen att de är på samma form; t.ex. $W_n = \bar{X}_n$ för alla $n = 1, 2, 3, \dots$ eller W_n är ML-skattningen av θ enligt stickprovet $X_1, \dots, X_n$ för alla $n = 1, 2, 3, \dots$. Vi säger då att punktskattningen W_n är *konsistent* när följden $W_1, W_2, \dots$ är konsistent. Till exempel har vi att $\bar{X}_1, \bar{X}_2, \dots$ är konsistent med avseende på väntevärdet $\mu = E[X_i]$ enligt stora talens lag. Därför säger man att stickprovsmedelvärdet $\bar{X}$ är en konsistent punktskattning av μ .

Men hur kan vi visa att en viss punktskattning är konsistent? En bra plats att börja är när vi vet att $E[W_n] \rightarrow \theta$ då $n \rightarrow \infty$. Vi säger då att en punktskattning W_n är *asymptotiskt väntevärdesriktig* när

$$E[W_n] \rightarrow \theta \quad \text{då} \quad n \rightarrow \infty.$$

I detta fall kan vi hitta ett positivt heltal N för varje ε så att

$$|E[W_n] - \theta| < \frac{\varepsilon}{2} \quad \text{för alla } n > N.$$

Vi har då att

$$\begin{aligned} |W_n - \theta| &= |W_n - E[W_n] + E[W_n] - \theta|, \\ &\leq |W_n - E[W_n]| + |E[W_n] - \theta|, \quad (\text{triangelolikhet}) \\ &\leq |W_n - E[W_n]| + \frac{\varepsilon}{2}. \end{aligned}$$

Om $\text{Var}[W_n] \rightarrow 0$ då $n \rightarrow \infty$ följer det att $W_n \xrightarrow{P} E[W_n]$ med hjälp av Tjebysjovs olikhet. Därför kan vi hitta N så att $|W_n - E[W_n]| < \varepsilon/2$ för alla $n > N$. Det följer då att $|W_n - \theta| < \varepsilon$ och

$$P(|W_n - \theta| > \varepsilon) \leq P(|W_n - E[W_n]| > \varepsilon/2).$$

Enligt Tjebysjovs olikhet har vi att

$$P(|W_n - E[W_n]| > \varepsilon/2) \leq \frac{\text{Var}[W_n]}{(\varepsilon/2)^2},$$

och därför

$$P(|W_n - \theta| > \varepsilon) \rightarrow 0 \quad \text{då} \quad n \rightarrow \infty$$

när $\text{Var}[W_n] \rightarrow 0$ då $n \rightarrow \infty$. Vi har då bevisat att $W_n \xrightarrow{P} \theta$ när W_n är asymptotiskt väntevärdesriktig och $\text{Var}[W_n] \xrightarrow{P} 0$ för alla $\theta \in \Omega$. Konversen stämmer också! Vi sammanfattar detta resultat i följande.

Sats 14.7. *Låt $W_1, W_2, \dots$ vara en följd av punktskattningar (på samma form) för θ . Vi har att W_n är asymptotiskt väntevärdesriktig och $\text{Var}[W_n] \rightarrow 0$ då $n \rightarrow \infty$ för alla $\theta \in \Omega$ om och endast om W_n är konsistent.*

Det är såklart användbart om vi kan visa att en punktskattning är konsistent. Detta kan vara svårt att göra för specifika punktskattningar men vi har att vissa vanliga punktskattningar är konsistenta.

Sats 14.8. Låt $X_1, X_2, \dots$ vara oberoende och likafördelade med täthetsfunktion (eller sannolikhetsfunktion) $f_{X_i}(x_i|\theta)$. Låt $\hat{\theta}_n$ vara ML-skattningen för θ given $X_1, \dots, X_n$. Anta att

1. $f_{X_i}(x_i|\theta) \neq f_{X_i}(x_i|\theta')$ när $\theta \neq \theta'$ (dvs. θ är identifierbar),
2. stödet av $f_{X_i}(x_i|\theta)$ inte beror på θ ,
3. $f_{X_i}(x_i|\theta)$ är differentierbar, och
4. parameterrummet Ω är öppet.

Vi har då vi att

$$\hat{\theta}_n \xrightarrow{P} \theta \quad \text{då} \quad n \rightarrow \infty$$

för alla $\theta \in \Omega$; dvs. $\hat{\theta}_n$ är konsistent.

Vi kommer inte att bevisa denna sats men idén är att

$$\frac{1}{n} \log L(\hat{\theta}_n | \mathbf{x}_n)$$

konvergerar mot $E[\log f_{X_i}(x_i|\theta)]$ för alla $\theta \in \Omega$ då $n \rightarrow \infty$. Med hjälp av detta kan man bevisa att $\hat{\theta}_n \xrightarrow{P} \theta$ då $n \rightarrow \infty$.

14.3.1 Asymptotiskt normalfördelade punktskattningar

Vi är ibland inte intresserade av θ utan vill istället skatta en funktion $\tau(\theta)$ av θ (se Exempel 14.3). Enligt Sats 6.2 har vi att $\tau(\hat{\theta})$ är ML-skattningen för $\tau(\theta)$ om $\hat{\theta}$ är ML-skattningen för θ . Eftersom $\hat{\theta}_n \xrightarrow{P} \theta$ i Sats 14.8 har vi också att

$$\tau(\hat{\theta}_n) \xrightarrow{P} \tau(\theta) \quad \text{då} \quad n \rightarrow \infty$$

för alla $\tau(\theta)$.

Medan konsistens är en bra egenskap säger det inte så mycket. Om vi exempelvis har två olika konsistenta punktskattningar kommer vi att föredra punktskattningen som konvergerar snabbare. Det skulle därför vara bra att ha en metod för att jämföra två olika konsistenta punktskattningar. Ett sätt att göra det är att betrakta konvergens i fördelning.

Eftersom $\tau(\hat{\theta}_n)$ konvergerar till $\tau(\theta)$ (en konstant) i sannolikhet har vi att $\tau(\hat{\theta}_n)$ konvergerar till $\tau(\theta)$ i fördelning. Vi har dock att $\text{Var}[\tau(\hat{\theta}_n)] \rightarrow 0$ då $n \rightarrow \infty$. Därför är gränsfördelningen för $\tau(\hat{\theta}_n)$ bara en punkt. Vi kan dock betrakta

$$\sqrt{n}(W_n - \tau(\theta)) \quad \text{då} \quad n \rightarrow \infty.$$

Det händer ofta att $\sqrt{n}(W_n - \tau(\theta))$ konvergerar till en normalfördelning. I detta fall säger vi att W_n är *asymptotiskt normal*; dvs.

$$\sqrt{n}(W_n - \tau(\theta)) \xrightarrow{D} N(0, \sigma^2(\theta)).$$

Värdet $\sigma^2(\theta)$ kallas för *den asymptotiska variansen*. Observera att $\sigma^2(\theta)$ kan betraktas som en funktion av θ när vi låter θ variera. När θ är förstås skriver vi ofta bara σ^2 . För att jämföra olika konsistenta skattningar kan vi jämföra sina asymptotiska varianser. Medan σ^2 kallas för en "varians" är det inte variansen för någon W_n . Istället är det konvergensthastigheten för följderna $W_1, W_2, \dots$. Man kan se detta när eftersom W_n är approximativt fördelad som

$$N\left(\tau(\theta), \frac{\sigma^2(\theta)}{n}\right)$$

för stora n ; dvs. när $\sigma^2(\theta)$ är stor har vi att W_n konvergerar långsammare. Givet två konsistenta punktskattningar kommer vi då att föredra punktskattningen med den minsta asymptotiska variansen.

Betrakta då en väntevärdesriktig punktskattning W för $\tau(\theta)$. Vi såg i Sats 6.4 att $\text{Var}[W]$ är minst Cramér-Raos nedre gräns:

$$\text{Var}[W] \geq \frac{\tau'(\theta)^2}{I(\theta)}$$

där

$$I(\theta) = -n E \left[\frac{\partial^2}{\partial \theta^2} \log f_X(X|\theta) \right].$$

Betrakta nu en konsistent punktskattning W_n för $\tau(\theta)$. Eftersom W_n är konsistent är W_n asymptotiskt väntevärdesriktig (enligt Sats 14.7). Vi förväntar oss därför att en asymptotisk version av Cramér-Rao nedre gräns kommer att stämma. Anta också att W_n är asymptotiskt normalfördelad. I detta fall har vi att

$$\sqrt{n}(W_n - \tau(\theta)) \xrightarrow{D} N(0, \sigma^2(\theta))$$

Vi säger då att W_n är *asymptotiskt effektiv* för $\tau(\theta)$ om

$$\sqrt{n}(W_n - \tau(\theta)) \xrightarrow{D} N\left(0, \frac{\tau'(\theta)^2}{J(\theta)}\right)$$

där

$$J(\theta) = -E\left[\frac{\partial^2}{\partial\theta^2} \log f_X(X|\theta)\right]$$

är den *normaliserade fisherinformationen*. Det vill säga att den asymptotiska variansen har undre gräns

$$\frac{\tau'(\theta)^2}{J(\theta)}.$$

Det händer ofta att ML-skattningar är asymptotiskt effektiva:

Sats 14.9. Låt $X_1, X_2, \dots$ vara oberoende och likafördelade med täthetsfunktion (eller sannolikhetsfunktion) $f_{X_i}(x_i|\theta)$ och låt $\hat{\theta}_n$ vara ML-skattningen för θ given $X_1, \dots, X_n$. När villkoren i Sats 14.8 och ytterligare två villkorar (som alltid uppfylls för exemplen i denna bok) uppfylls har vi att $\tau(\hat{\theta}_n)$ är asymptotiskt effektiv för $\tau(\theta)$.

Vi kan använda denna sats för att skatta variansen för $\tau(\hat{\theta}_n)$ när n är stort. Vi har att

$$\text{Var}[\tau(\hat{\theta}_n)] \approx \frac{\tau'(\theta)^2}{nJ(\theta)}.$$

Vi kan inte använda denna för att approximera $\text{Var}[\tau(\hat{\theta}_n)]$ direkt eftersom täljaren och nämnaren i kvoten beror på θ (som är okänt). Vi kan dock approximera dessa värden. Först kan vi anta att $\hat{\theta}_n$ är tillräckligt nära θ så att vi kan approximera $\tau(\theta) \approx \tau(\hat{\theta}_n)$ och $J(\theta) \approx J(\hat{\theta}_n)$.

Men $J(\theta)$ är ett väntevärde med avseende på X . Detta betyder att vi behöver approximera funktionen J också! Vi kan göra detta enligt

$$J(\theta) = -E\left[\frac{d^2}{d\theta^2} \log f_X(x|\theta)\right] \approx -\frac{1}{n} \sum_{i=1}^n \frac{d^2}{d\theta^2} \log f_X(x_i|\theta) = -\frac{1}{n} \frac{d^2}{d\theta^2} \log L(\theta|\mathbf{x}).$$

Nämnaren approximeras därför med

$$nJ(\theta) \approx n\hat{J}(\hat{\theta}) = -\frac{d^2}{d\theta^2} \log L(\hat{\theta}|\mathbf{x})$$

som kallas för den *observerade fisherinformationen*. I följande låter vi

$$\hat{I}_n(\hat{\theta}_n) = -\frac{d^2}{d\theta^2} \log L(\hat{\theta}_n|\mathbf{x}).$$

Vi kan då approximera $\text{Var}[\tau(\hat{\theta}_n)]$ med

$$\widehat{\text{Var}}[\tau(\hat{\theta}_n)] \approx \frac{\tau'(\hat{\theta}_n)^2}{\hat{I}_n(\hat{\theta}_n)} = \frac{\tau'(\hat{\theta}_n)^2}{-\frac{d^2}{d\theta^2} \log L(\hat{\theta}_n|\mathbf{x})}.$$

Exempel 14.4. Låt $X_1, X_2, \dots$ vara oberoende och $\text{Ber}(\theta)$ -fördelade. Då har vi att $\hat{\theta}_n = \bar{X}_n$. Med hjälp av invariansegenskapen hos ML-skattningar har vi att ML-skattningen för oddset $\theta/(1-\theta)$ ges av

$$\frac{\hat{\theta}_n}{1 - \hat{\theta}_n}$$

där

$$\tau(x) = \frac{x}{1-x}$$

och

$$\tau'(x) = \frac{1}{(1-x)^2}.$$

Vi har också att

$$f_{X_i}(x_i|\theta) = \theta^{x_i}(1-\theta)^{1-x_i}$$

och därför

$$\begin{aligned} \frac{d^2}{d\theta^2} \log L(\theta|\mathbf{x}) &= \frac{d^2}{d\theta^2} \log \prod_{i=1}^n f_{X_i}(x_i|\theta), \\ &= \frac{d^2}{d\theta^2} \log(\theta^{n\bar{x}_n}(1-\theta)^{n-n\bar{x}_n}), \\ &= \frac{d^2}{d\theta^2} (n\bar{x}_n \log(\theta) + (n-n\bar{x}_n) \log(1-\theta)), \\ &= -\frac{n\bar{x}_n}{\theta^2} - \frac{n(1-\bar{x}_n)}{(1-\theta)^2}, \\ &= -\frac{n\hat{\theta}_n}{\theta^2} - \frac{n(1-\hat{\theta}_n)}{(1-\theta)^2}. \end{aligned}$$

Det följer att

$$\hat{I}_n(\hat{\theta}_n) = - \left(-\frac{n\hat{\theta}_n}{\hat{\theta}_n^2} - \frac{n(1-\hat{\theta}_n)}{(1-\hat{\theta}_n)^2} \right) = \frac{n}{\hat{\theta}_n(1-\hat{\theta}_n)}.$$

Därför har vi att

$$\widehat{\text{Var}} \left[\frac{\hat{\theta}_n}{1-\hat{\theta}_n} \middle| \theta \right] = \frac{\frac{1}{(1-\hat{\theta}_n)^4}}{\frac{n}{\hat{\theta}_n(1-\hat{\theta}_n)}} = \frac{\hat{\theta}_n}{n(1-\hat{\theta}_n)^3}.$$

Notera att denna varians är densamma som den som vi fick med hjälp av deltametoden.

14.4 Asymptotiska egenskaper hos aposteriorifördelningen

Vi kan också betrakta asymptotiska egenskaper hos bayesianska modeller. Det kan visas att våra två vanliga bayesianska punktskattningar

$$\mathbb{E}[\Theta|\mathbf{X}=\mathbf{x}] \quad \text{och} \quad \hat{\theta} = \operatorname{argmax}_{\theta \in \Omega} f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}),$$

(aposterioriväntevärdet respektive aposterioritypvärdet) är konsistenta med avseende på θ_0 givet att datan genereras från $f_{X|\Theta}(x|\theta_0)$. Medan detta ger oss sammanfattningar av den asymptotiska aposteriorifördelningen kommer vi självklart att föredra en beskrivning av den hela asymptotiska aposteriorifördelningen.

För att göra detta betraktar vi taylorpolynomet $T_2(x)$ av aposteriorfördelningens logaritm runt aposterioritypvärdet $\hat{\theta}$:

$$\begin{aligned} \log f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) &\approx \log f_{\Theta|\mathbf{X}}(\hat{\theta}|\mathbf{x}) + \frac{d}{d\theta} \log f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) \Big|_{\theta=\hat{\theta}} (\theta - \hat{\theta}) + \frac{1}{2} \frac{d^2}{d\theta^2} \log f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) \Big|_{\theta=\hat{\theta}} (\theta - \hat{\theta})^2, \\ &\approx \log f_{\Theta|\mathbf{X}}(\hat{\theta}|\mathbf{x}) + \frac{1}{2} \frac{d^2}{d\theta^2} \log f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) \Big|_{\theta=\hat{\theta}} (\theta - \hat{\theta})^2, \end{aligned}$$

där vi använde

$$\frac{d}{d\theta} \log f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) \Big|_{\theta=\hat{\theta}} = 0$$

eftersom $\hat{\theta}$ är aposterioritypvärdet. Vi har också att $\log f_{\Theta|\mathbf{X}}(\hat{\theta}|\mathbf{x})$ är en konstant. Detta betyder att $f_{\Theta|\mathbf{X}}(\theta|\mathbf{x})$ är approximativt proportionellt till

$$e^{-\frac{\hat{I}(\hat{\theta})}{2}(\theta-\hat{\theta})^2}$$

där

$$\hat{I}(\hat{\theta}) = - \left. \frac{d^2}{d\theta^2} \log f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) \right|_{\theta=\hat{\theta}}.$$

Vi kallar $\hat{I}(\hat{\theta})$ för den *bayesianska observerade informationen*. Det följer direkt att

$$\Theta|\mathbf{X} = \mathbf{x} \approx \mathcal{N}(\hat{\theta}, (\hat{I}(\hat{\theta}))^{-1}).$$

Exempel 14.5. Låt $X_1, X_2, \dots$ vara oberoende och $\text{Ber}(\theta)$ -fördelade där $\Theta \sim \text{Beta}(\alpha_0, \beta_0)$. Vi har att

$$\Theta|\mathbf{X} = \mathbf{x} \sim \text{Beta}\left(\alpha_0 + \sum_{i=1}^n x_i, \beta_0 + n - \sum_{i=1}^n x_i\right) = \text{Beta}(\alpha_1, \beta_1).$$

Det följer att

$$\hat{I}(\hat{\theta}) = - \left. \frac{d^2}{d\theta^2} \log f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) \right|_{\theta=\hat{\theta}} = (\alpha_1 - 1) \frac{1}{\hat{\theta}^2} + (\beta_1 - 1) \frac{1}{(1 - \hat{\theta})^2}.$$

Vi har också att aposterioritypvärdet av en $\text{Beta}(\alpha_1, \beta_1)$ -fördelning ges av

$$\hat{\theta} = \frac{\alpha_1 - 1}{\alpha_1 + \beta_1 - 2}.$$

Därför har vi att

$$\hat{I}(\hat{\theta}) = \frac{(\alpha_0 + \beta_0 + n - 2)^3}{(\alpha_0 + \sum_{i=1}^n x_i - 1)(\beta_0 + n - \sum_{i=1}^n x_i - 1)}.$$

Vi har då att

$$\Theta|\mathbf{X} = \mathbf{x} \approx \mathcal{N}\left(\frac{\alpha_0 + \sum_{i=1}^n x_i - 1}{\alpha_0 + \beta_0 + n - 2}, \frac{(\alpha_0 + \sum_{i=1}^n x_i - 1)(\beta_0 + n - \sum_{i=1}^n x_i - 1)}{(\alpha_0 + \beta_0 + n - 2)^3}\right).$$

Notera att för den icke-informativa apriorifördelningen $\Theta \sim \text{Beta}(1, 1)$ förenklas detta till

$$\Theta|\mathbf{X} = \mathbf{x} \approx \mathcal{N}\left(\bar{x}_n, \frac{1}{n} \bar{x}_n (1 - \bar{x}_n)\right).$$

Generellt sett ser vi att $f_{\Theta|\mathbf{X}}(\theta|\mathbf{x})$ går mot

$$\mathcal{N}\left(\theta_0, \frac{1}{nJ(\theta_0)}\right)$$

då $n \rightarrow \infty$ givet att $\mathbf{x}$ genereras från en $f_{X|\Theta}(x|\theta_0)$ -fördelning. Detta är eftersom $\hat{\theta}$ är konsistent med avseende på θ_0 och därför $\hat{\theta}_n \xrightarrow{P} \theta_0$ då $n \rightarrow \infty$. Vi har också att

$$\begin{aligned} \hat{I}(\theta) &= - \left. \frac{d^2}{d\theta^2} \log f_{\Theta|\mathbf{X}}(\theta|\mathbf{x}) \right|_{\theta=\hat{\theta}}, \\ &= - \left. \frac{d^2}{d\theta^2} \log f_{\Theta}(\theta) \right|_{\theta=\hat{\theta}} - \sum_{i=1}^n \left. \frac{d^2}{d\theta^2} \log f_{X_i|\Theta}(x_i|\theta) \right|_{\theta=\hat{\theta}} \end{aligned}$$

Den första termen är konstant med avseende på n . Den andra termen ökar dock då $n \rightarrow \infty$. Eftersom varje term i summan har väntevärdet $J(\theta_0)$ går summan mot $nJ(\theta_0)$ enligt stora talens lag. Det vill säga att aposterioritermen domineras. Notera att denna asymptotiska varians $1/J(\theta_0)$ är densamma som ML-skattningens asymptotisk varians. Med andra ord är aposteriorifördelningen asymptotiskt normal och asymptotiskt effektiv (i den frekventistiska meningen).

14.5 Uppgifter

14.1. [1] Låt $X_1, X_2, \dots$ vara oberoende och Beta(α, β)-fördelade. Låt $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ för alla $n = 1, 2, \dots$

- (a) Visa att $\bar{X}_n \rightarrow \frac{\alpha}{\alpha+\beta}$ då $n \rightarrow \infty$.
- (b) Bestäm den asymptotiska variansen av $\bar{X}_n$.

14.2. [1] Låt $X_1, X_2, \dots$ vara oberoende och låt X_i ha täthetsfunktionen

$$f_{X_i}(x_i|\theta) = \begin{cases} \frac{1}{2}(1 + \theta x_i^3) & -1 < x < 1 \\ 0 & \text{annat,} \end{cases}$$

där $\theta > 0$ för alla $i = 1, 2, \dots$. Visa att momentmetodens punktskattning $\tilde{\theta}_n$ för θ givet $X_1, \dots, X_n$ är väntevärdesriktig och bestäm dess asymptotiska varians.

14.3. [1] Låt $X_1, X_2, \dots$ vara oberoende och Geom(p)-fördelade, $Y_n = \frac{1}{n} \sum_{i=1}^n$ och $g(y) = y(y+1)$. Approximera $g(Y_n)$ med en normalfördelning med hjälp av deltametoden.

14.4. [1] Låt $X | \Theta = \theta \sim \text{Po}(\theta)$ och $\Theta \sim \text{Gamma}(2, 3)$. Anta att vi ha ett stort stickprov $x_1, \dots, x_n$ där $n = 1000$ och $\sum_{i=1}^n x_i = 966$. Bestäm en normalapproximation för aposteriorifördelningen och använd den för att ge ett approximativt 0.90 symmetriskt kredibilitetsintervall för Θ .

14.5. [2] Låt $\alpha = P(X \leq 3)$ för $X \sim \text{Po}(\lambda)$ och låt $\hat{\alpha}$ vara ML-skattningen för α enligt datan $x_1, \dots, x_n$. Ge en approximation av fördelningen av $\hat{\alpha}$ för stort n som en funktion av λ och n .

14.6. [1] Låt $X_1, \dots, X_n$ vara oberoende och låt X_i ha täthetsfunktionen

$$f_{X_i}(x_i|\theta) = \begin{cases} \frac{1}{2}(1 + \theta x_i) & -1 < x_i < 1, \\ 0 & \text{annat} \end{cases}$$

där $-1 < \theta < 1$. Bestäm en konsistent punktskattning för θ och visa att punktskattningen är konsistent.

14.7. [2] Låt $Y_1, \dots, Y_n$ vara stokastiska variabler där

$$Y_i = \beta X_i + Z_i,$$

$X_1, \dots, X_n$ är oberoende och $N(\mu, \tau^2)$ -fördelade och $Z_1, \dots, Z_n$ är oberoende och $N(0, \sigma^2)$ -fördelade. Vi antar också att $X_1, \dots, X_n, Z_1, \dots, Z_n$ är oberoende. Approximera väntevärdena och varianserna av följande som funktioner av μ, τ och σ^2 :

- (a) $\frac{\sum_{i=1}^n X_i Y_i}{\sum_{i=1}^n X_i^2},$
- (b) $\frac{\sum_{i=1}^n Y_i}{\sum_{i=1}^n X_i},$ och
- (c) $\frac{1}{n} \sum_{i=1}^n \frac{Y_i}{X_i}.$

14.8. [2] Låt $W_n, n \geq 1$, vara en konsistent följd av punktskattningar för parametern θ och låt $a_1, a_2, \dots$ och $b_1, b_2, \dots$ vara följder av konstanter som uppfyller

$$\lim_{n \rightarrow \infty} a_n = 1 \quad \text{och} \quad \lim_{n \rightarrow \infty} b_n = 0.$$

Visa att $U_n = a_n W_n + b_n$ är en konsistent följd av punktskattningar för θ .

14.9. [2] Låt $X_1, \dots, X_n$ vara oberoende och $N(\theta, \theta)$ -fördelade där $\theta > 0$.

- (a) Visa att ML-skattningen, $\hat{\theta}$, för θ är en rot till den kvadratiske ekvationen $\theta^2 + \theta - W = 0$ där $W = \frac{1}{n} \sum_{i=1}^n X_i^2$. Bestäm vilken rot som är ML-skattningen.
- (b) Bestäm den approximativa variansen av $\hat{\theta}$.