


Guide: Åtkomst till ESS-data

Detta dokument beskriver hur du skaffar, öppnar och kvalitetskontrollerar din data från European Social Survey (ESS). Det beskriver *inte* vilka variabler, länder eller händelser du ska välja för din analys – det finns i uppgiftstexten. Om något här inte stämmer med det du ser på skärmen, fråga på en labbhandledning.

1. Skaffa åtkomst

ESS-data finns endast tillgänglig via ESS Data Portal (<https://ess.sikt.no/en/>), och nedladdning kräver ett konto. Enklast är att registrera dig via ditt KTH-konto (man kan också registrera med hjälp av ett Google-konto eller genom att skapa ett konto via e-postadress).


För att logga in väljer du först Feide (Norges identitetsfederation – detta är förvalt eftersom portalen drivs av Sikt, en norsk organisation). Eftersom KTH inte ingår i Feide måste du därifrån hitta ett alternativ för att växla till eduGAIN. I eduGAIN-listan väljer du Sverige som land och KTH som lärosäte. Sedan loggar in med ditt vanliga KTH-konto.



Efter du har loggat in kommer du behöva fylla i lite personliga uppgifter men detta behöver du bara göra en gång.

2. Hitta och ladda ner din data

När du är registrerad kommer du tillbaka till startskärmen för ESS. Här går du in i menyn och väljer “Datafile Builder” – datafilsbyggaren – som är verktyget för att extrahera information från databasen:



Väl inne i datafilsbyggaren kommer du först välja vilken eller vilka länder samt vilken eller vilka *omgångar* (eng. “rounds”) som du är intresserad av. En omgång är enskild datainsamlingsomgång i ESS. Varje omgång bygger på ett helt nytt slumpmässigt urval av respondenter i varje deltagande land – det är alltså *inte* samma personer som svarar från omgång till omgång. Frågeformuläret består av en kärndel (eng. “core”), som hålls i stort sett oförändrad mellan omgångarna för att möjliggöra jämförelser över tid, samt två eller tre roterande moduler med nya teman som byts ut från omgång till omgång. Själva intervjuprocessen i ett land pågår under minst sex veckor inom ett fönster på fem månader. Notera att alla länder inte är med i varje omgång. Man kan tekniskt sett välja alla omgångar samt alla länder här, men det rekommenderas inte då filerna kan bli mycket stora.

Efter att vi valt en omgång (säg omgång 10) och ett land (säg Schweiz) är det dags att välja variabler. ESS har mer än tusen variabler som registreras, men alla variabler är inte med i varje omgång. Dels finns några variabler som roteras in och ut (dvs. de variablerna som inte är med i kärndelen). Dels så tas några variabler bort efter ett antal omgångar, medan andra läggs till. Variablerna är organiserade under olika kategorier, som t.ex. “Media use and trust” eller “Socio-demographic profile”.

För varje variabel kan man ta fram den exakta frågeställningen, vilka omgångar som frågan ställdes i, samt de olika svaren som finns för den frågan:

netusoft - Internet use, how often



Question: People can use the internet on different devices such as computers, tablets and smartphones. How often do you use the internet on these or any other devices, whether for work or personal use?

ESS rounds: ESS8, ESS9, ESS10, ESS10SC, ESS11

Code list Code comparison

Value	Category
1	Never
2	Only occasionally
3	A few times a week
4	Most days
5	Every day
7	Refusal*
8	Don't know*
9	No answer*

*) Missing Value

Notera att vissa svar är inte riktiga svar, utan är svars-koder som indikerar att data saknas. I detta exempel har vi koderna 7, 8 och 9 som motsvarar att respondenten vägrat svara, inte vet respektive att inget svar finns av någon annan anledning. Det är viktigt att komma ihåg att dessa koder varierar från fråga till fråga och inte är desamma över hela databasen. Oftast är de dock på formen 99, 999, 9999, osv. Det kan vara svårt att bestämma vilka variabler du vill ha i din fil, så enklast är att välja alla variabler (hoppa över steg två i datafilsbyggaren).

När du har valt dina variabler presenteras du med tre alternativ för att ladda ned filerna. Vi rekommenderar att du använder CSV-formatet (kommaseparerade värden, en rad per respondent). Utöver detta finns två mer specialiserade format, SPSS och Stata, som innehåller mer metadata, men kan vara mer komplicerade att använda.

När du laddar ned din datafil följer det också med en HTML-fil som innehåller *kodboken*. Denna beskriver vilka variabler som finns med i datafilen, men också vad de olika koderna betyder och vilka som motsvarar saknade svar (se nedan).

3. Öppna datan i Python

Du har använt SciPy tidigare men förmodligen inte Pandas. Om du laddade ner i CSV-formatet är inläsningen enkel:

```
import pandas as pd

df = pd.read_csv("ESS11_dittland.csv")
```

En översikt över datafilen kan fås genom metoden `df.info()`, som visar antal rader, kolumnnamn och hur många värden som saknas per kolumn (som `NaN` – inte att förväxla med ESS:s egna koder för saknade svar, se nedan). Utöver detta kan du extrahera individuella kolumner ifrån dataramen genom att indexera den. En annan användbar metod är `df.head()` som visar de första fem raderna från datafilen.

Om vi inkluderat variablerna `pplfair` ("Most people try to take advantage of you, or try to be fair") och `eisced` ("Highest level of education") kan vi skriva `df["pplfair"]` och `df["eisced"]` för att extrahera värdena på denna variabel. Värdena här är råa numeriska koder. Du behöver slå upp dem i kodboken för att tolka dem.

Innan du gör något annat med en variabel, titta på värdena som den antar:

```
df["pplfair"].value_counts()
```

Detta är ofta det snabbaste sättet att upptäcka en kod för saknat värde som gömmer sig bland i övrigt rimliga värden (se nedan).

För att extrahera en viss rad, använd `df.loc[index]`. Man kan också skapa masker och extrahera endast dessa rader:

```
low_trust = (df["pplfair"] <= 5)
df_masked = df.loc[low_trust]
```

Masker kombineras genom `&`-operatoren, dvs. "och"-operatoren:

```
low_trust_grads = ((df["pplfair"] <= 5)
                  & (df["eisced"] >= 6) & (df["eisced"] <= 7))
df_masked = df.loc[low_trust_grads]
```

Parenteserna är viktiga här då `&` har företräde framför `==` i Python. Utöver `&` finns också `|`-operatoren, dvs. ”eller”-operatoren:

```
low_trust_or_grads = ((df["pplfair"] <= 5)
                      | ((df["eisced"] >= 6) & (df["eisced"] < 7)))
df_masked = df.loc[low_trust_or_grads]
```

Man kan också extrahera både rader och kolumner via `df.loc`:

```
df_subset = df.loc[low_trust, ["pplfair", "eisced"]]
```

Kolumner kan transformeras för att ge upphov till nya kolumner

```
df["no_grad"] = (df["eisced"] < 6)
```

Värdena kan behandlas med hjälp av NumPy-funktioner. För att t.ex. beräkna medelvärdet kan vi skriva

```
import numpy as np

avg_trust = np.mean(df["pplfair"])
```

Eller korrelationskoefficienten mellan två variabler

```
trust_edu_corr = np.corrcoef(df["pplfair"], df["eisced"])
```

Notera att båda dessa beräkningar är inkorrekta eftersom vi inte filtrerat ut koder för saknade värden här.

4. Saknade värden

ESS-variabler använder specifika numeriska koder för att beteckna ”vet ej”, ”vill ej svara” eller ”ej tillämpligt” och vilka koder som betyder vad varierar mellan variabler (det beror bland annat på hur många siffror variabeln har). Det finns ingen enskild siffra du kan hårdkoda som den saknade koden för hela datafilen.

Regel: innan du använder en variabel, slå upp den i omgångens kodbok och kontrollera vilka värden som är reserverade för att beteckna saknade svar. Filtrera bort dessa explicit (genom en mask), och redovisa i din rapport hur många observationer du uteslöt och varför – detta är ett normalt och förväntat steg när man arbetar med enkätdata.

5. Intervjudatumvariabler

En del uppgifter i projektets andra del kräver att du delar in respondenterna i ”före” och ”efter” en händelse. På grund av detta behöver du varje respondents intervjudatum. I datafilsbyggaren finns de under “Administrative variables; interview time, administration of split ballot”.

Vilken eller vilka variabler som gäller beror på vilken omgång du använder – detta har ändrats två gånger i ESS historia, och att använda fel variabel för en omgång ger en kolumn med enbart saknade värden:

- **ESS1–ESS2:** ett enda datum, uppdelat i separata variabler – `inwdd` (dag), `inwmm` (månad) och `inwyr` (år).

- **ESS3–ESS9:** här började man istället registrera *start* och *slut* av intervjun separat (eftersom vissa intervjuer sträckte sig över flera sessioner eller passerade midnatt) – `inwdds/inwdde` (dag), `inwmms/inwmme` (månad), `inwyys/inwyye` (år).
- **ESS10–ESS11:** nu slogs allting samman till två fält, `inwds` (“Start of interview”) och `inwde` (“End of interview”). Varje fält är en ren tidsstämpel, t.ex. "2023-07-31 09:51:17" (ÅÅÅÅ-MM-DD TT:MM:SS). Konvertera dessa med `pd.to_datetime(df["inwds"])` innan du gör några datumjämförelser – försök inte plocka ut dag/månad/år för hand eller återanvända logik skriven för ESS3–9:s numeriska komponentvariabler, eftersom formatet är helt annorlunda.

Anta aldrig att ett variabelnamn gäller över omgångar. Klicka på varje kandidatvariabel i byggaren – den visar exakt vilka ESS-omgångar den täcker – innan du bestämmer er för att den är rätt. En variabel som ser rätt ut utifrån namnet (t.ex. `inwdd`) kanske helt enkelt inte finns för er omgång.