

Föreläsning ett

Joakim Andén

Översikt

Denna kurs innefattar två huvudämnen. Det första är *sannolikhetsteori* och handlar om att beskriva slumpen, eller mer specifikt *slumpmässiga förlopp*. Dessa präglas av en viss osäkerhet där vi inte kan säga exakt hur ett förlopp (eller matematiskt förhållande) ser ut. Sannolikhetsteorin fokuserar därför istället på *sannolikheten* att någonting inträffar på ett visst sätt och på detta vis kan en *sannolikhetskalkyl* utvecklats.

Till exempel kan vi ta *Ohms lag*:

$$U = R \cdot I,$$

dvs. spänningen (U) är lika med resistans (R) gånger ström (I). Detta är en *deterministisk* modell (dvs. ej slumpmässigt).

I verkligheten stämmer dock aldrig denna relation exakt utan vi har olika typer av *mätfel*. Till exempel så kan temperaturvariationer ge upphov till små skillnader i spänningen. Skillnader från formeln ovan kan också uppstå om vi har orenheter i resistorn eller ledningen. Dessa skillnader kan modelleras som en variabel Z . Vi får då

$$U = R \cdot I + Z.$$

Det viktiga här är att värdet på Z i regel är okänt men vi kan ändå ha en uppfattning om vilka värden den kan anta och med vilka sannolikheter. Detta är då en *stokastisk modell* eller *slumpmodell*.

Den andra delen av kursen använder sannolikhetsteorin för att extrahera information från data och använda detta för att dra olika slutsatser. Detta kallas för *statistisk inferens*. I modellen ovan kan det handla om att bestämma R givet olika mätvärden av U och I . Utöver detta kan det finnas olika parametrar i beskrivningen av Z som behöver skattas för att ge en komplett modell. Vi skulle alltså kunna använda datan för att svara på följande frågor: "hur stor är resistensen i systemet?", "är resistensen mindre än 100 ohm?", "hur stort mätfel har vi i genomsnitt?" eller "hur många mätningar måste vi ta för att bestämma resistensen med en osäkerhet på högst 1 ohm?".

Tillämpningar

Sannolikhetsteori och statistik kan användas i ett stort antal tillämpningar:

- Opinionsundersökningar: "31% av väljarna tänker rösta på Socialdemokraterna med 2% felmarginal."
- Kvalitetskontroll: "En dos läkemedel innehåller 5 ± 1.03 mg av den aktiva substansen."
- Pris på försäkringspremier eller optioner: "Vilket pris garanterar vinst med 95% sannolikhet (förutsett att vår modell stämmer)?"
- Vetenskapliga slutsatser: "Hur väl stämmer mätdata överens med hypotesen att metangasutsläppen i Sibirien har ökat med 5% mellan 2010 och 2019?"
- Modellering av priser: Bostadspriser som funktion av olika variabler plus en slumpmässig term

$$Y = a_1x_1 + a_2x_2 + \cdots a_nx_n + Z,$$

där Y är priset i kronor, x_1 är antalet rum, x_2 är boytan, osv. Här motsvarar feltermen Z den slumpmässiga variation som innehåller alla faktorer som *inte* ingår i modellen. Om vi anpassar a_1, a_2 , osv. till data, hur säkra kan vi vara på att de ger rätt pris när vi tillämpar på nya data?

- Maskininlärning: Bygg modeller från data som förutsäger (predikterar) egenskaper eller värden hos andra, ej än observerade, data. Exempel: "Vad är sannolikheten att en 32×32 -bild föreställer en katt?"

Utfall och händelser

Informellt sett är ett slumpmässigt försök ett "oförutsägbart förlopp" – även om det upprepas under exakt samma omständigheter kan vi inte (eller vill inte) förutsäga resultatet från gång till gång. (Det finns andra tolkningar av slump- och sannolikhetsbegreppen, se nedan.)

Grundläggande begrepp inom sannolikhetsteorin är utfall, utfallsrum och händelser. Ett *utfall* är resultatet av ett slumpmässigt försök. Mängden av alla möjliga utfall kallas *utfallsrummet*. En samling utfall (dvs. en delmängd av utfallsrummet) kallar för en *händelse*. (Notera att "utfall" och "händelse" inte är synonyma inom sannolikhetsteorin.) Konventionen är att beteckna utfall med variablerna $\omega_1, \omega_2, \dots$, utfallsrummet med Ω och händelser med $A, B, \dots$

Exempel 1. Vid ett tärningskast kan de olika utfallen bestå av antalet ögon på tärningen. Detta ger då

$$\omega_1 = \text{"tärningen har ett öga"}$$

$$\omega_2 = \text{"tärningen har två ögon"}$$

$$\vdots$$

$$\omega_6 = \text{"tärningen har sex ögon"}$$

med utfallsrummet

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_6\}.$$

Några händelser kan då vara

$$A = \text{"antalet ögon är udda"} = \{\omega_1, \omega_3, \omega_5\}$$

$$B = \text{"antalet ögon är minst fem"} = \{\omega_5, \omega_6\}$$

$$C = \text{"antalet ögon är exakt sex"} = \{\omega_6\}.$$

Notera att i det sista fallet har vi en händelse C som innehåller ett enda utfall ω_6 .

Utfallsrum kommer i väsentligen två former: diskreta och kontinuerliga. Om Ω är ändligt eller uppräknligt oändligt kallas det för ett *diskret utfallsrum*. Annars (dvs. om Ω är ouppräknligt oändligt) kallas Ω för ett *kontinuerligt utfallsrum*. (Kom ihåg att en uppräknligt oändlig mängd är en mängd där vi kan ge varje element ett positivt heltal som "etikett".)

Exempel 2. Vi kan betrakta följande utfallsrum:

Antalet ögon vid ett tärningskast	diskret (ändligt, 6 möjliga utfall)
Antalet kast tills vi får en etta	diskret (uppräknligt oändligt)
Antalet ögon vid n tärningskast	diskret (ändligt, 6^n utfall)
Tiden kvar i minuter till slutet av föreläsningen	kontinuerligt ($\Omega = [0, 120)$)
Vinkeln en tappad synål bildar med en fix linje på ett papper	kontinuerligt ($\Omega = [0, \pi)$)

Informellt är Ω ett kontinuerligt utfallsrum om utfallen kan ligga "oändligt nära varandra". Som innan är händelser fortfarande en delmängd av utfallsrummet. I det sista exemplet ovan skulle kunna ha händelsen "vinkeln är mellan $\pi/4$ och $3\pi/4$ " vilket skulle motsvara delmängden $[\pi/4, 3\pi/4]$.

Snitt, union och komplement

Vi har nu sett olika exempel på utfallsrum och händelser. Hur kombinerar vi dessa på olika sätt? Här kan vi använda begrepp från mängdläran eftersom A och B är delmängder av utfallsrummet Ω .

Till exempel kanske vi har två händelser A och B och vill beskriva vad som händer om *båda* inträffar. Detta kallar för *snittet* av A och B och skrivs

$$\begin{aligned} A \cap B &= \text{"både } A \text{ och } B \text{ inträffar"} \\ &= \{\text{alla utfall som ligger i både } A \text{ och } B\} \\ &= \{\omega \in \Omega : \omega \in A \text{ och } \omega \in B\}. \end{aligned}$$

Detta motsvarar ett logiskt "och" (dvs. "AND" i boolesk logik). Vi kan generalisera detta till $n > 2$ händelser

$$A_1 \cap A_2 \cap \dots \cap A_n = \{\omega \in \Omega : \omega \in A_1, \omega \in A_2, \dots, \omega \in A_n\},$$

vilket också kan skrivas

$$\bigcap_{i=1}^n A_i.$$

Om $A \cap B = \emptyset$ (dvs. snittet av A och B är den tomma mängden) så innehåller A och B inte några gemensamma utfall och vi säger att A och B är *oförenliga*. Med andra ord så kan A och B inte inträffa samtidigt. (Inom mängdläran kallas A och B för disjunkta mängder.)

Ett annat sätt att kombinera A och B är att ta *unionen*, vilket motsvarar händelsen att A *eller* B inträffar. Vi skriver detta som

$$\begin{aligned} A \cup B &= \text{"minst en av } A \text{ eller } B \text{ inträffar"} \\ &= \{\text{alla utfall som ligger i } A \text{ eller } B\} \\ &= \{\omega \in \Omega : \omega \in A \text{ eller } \omega \in B\}. \end{aligned}$$

Detta motsvarar ett logiskt "eller" (dvs. "OR" i boolesk logik). Notera att detta skiljer sig från "exklusivt eller", dvs. "antingen ... eller ...". Händelsen ovan tillåter att både A och B inträffar samtidigt. Med andra ord har vi $A \cap B \subset A \cup B$.

Som innan kan vi generalisera unionen till $n > 2$ händelser:

$$A_1 \cup A_2 \cup \dots \cup A_n = \{\omega \in \Omega : \omega \in A_1 \text{ eller } \omega \in A_2 \text{ eller } \dots \text{ eller } \omega \in A_n\}$$

vilket också kan skrivas

$$\bigcup_{i=1}^n A_i.$$

Om vi endast har en händelse A kan vi definiera dess *komplement* (inom Ω), dvs. att A *inte* händer, genom



$$\begin{aligned} A^* &= \text{"}A \text{ inträffar inte"} \\ &= \{\text{alla utfall som inte ligger i } A\} \\ &= \{\omega \in \Omega : \omega \notin A\}. \end{aligned}$$

Detta motsvarar logiskt "inte" (dvs. "NOT" i boolesk logik). Komplementet kan också skrivas som A^c , $\complement A$, $\Omega \setminus A$ eller $\Omega - A$. De senare två uttrycken är användbara när det inte framgår tydligt vilket rum som komplementet ska tas med avseende på (dvs. när det inte är klart vad som är utfallsrummet).


Med hjälp av definitionerna ovan kan vi nu definiera "exklusivt eller" som $(A \cup B) \setminus (A \cap B)$, dvs. unionen av A och B där vi har tagit bort snittet.

Euler- och venndiagram

För att visualisera olika händelser inom ett utfallsrum kan det vara bra att rita bilder som illustrerar relationerna mellan händelserna. Dessa kallas då *eulardiagram* (ett eulardiagram där alla händelser överlappar med varandra kallas för ett *venndiagram*). Notera att även om dessa kan vara bra för att bygga intuition om olika händelser så kan de också leda till fel slutsatser om man inte är försiktig. Därför är det alltid säkrast att använda mängdlärans räkneregler (se nedan).



Komplement



$$A^* = \Omega \setminus A$$

Ett annat sätt att illustrera relationen mellan händelser är genom sanningsvärdestabeller där vi markerar med "S" ("sant") om en händelse inträffar och "F" ("falskt") annars.

A	B	$A \cap B$	$A \cup B$
S	S	S	S
S	F	F	S
F	S	F	S
F	F	F	F


Mängdlärans räkneregler

Om vi har mer komplicerade relationer mellan händelser kan vi ofta skriva om dessa med hjälp av ett par räkneregler. Dessa kan bevisas genom att skriva upp sanningsvärdestabellerna och verifiera att de är ekvivalenta.

Först har vi att snitt distribuerar över union, dvs. att

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$


I vänsterledet har vi händelsen "A och minst en av B eller C inträffar" medan i högerledet har vi att minst en av "A och B inträffar" eller "A och C inträffar" inträffar.



Vi har också att union distribuerar över snitt, dvs. att

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C).$$

I vänsterledet har vi att minst en av "A inträffar" eller "B och C inträffar" inträffar. Högerledet ger att "minst en av A eller B inträffar" och "minst en av A eller C inträffar".




Till sist har vi De Morgans lagar som säger att

$$\begin{aligned}
 (A \cap B)^* &= \text{"A och B inträffar inte båda två"} \\
 &= \text{"minst en av } A^* \text{ eller } B^* \text{ inträffar"} \\
 &= A^* \cup B^*.
 \end{aligned}$$

samt

$$\begin{aligned}(A \cup B)^* &= \text{"varken } A \text{ eller } B \text{ inträffar"} \\ &= \text{"både } A^* \text{ och } B^* \text{ inträffar"} \\ &= A^* \cap B^*.\end{aligned}$$



Sannolikhet

Vi tilldelar nu varje händelse $A \subset \Omega$ ett värde mellan noll och ett som vi kallas A 's *sannolikhet*. Detta värde betecknas med $P(A)$.

Frågan är nu hur vi väljer A ? Vad är egentligen en sannolikhet? Det finns olika tolkningar av sannolikhetsbegreppet. En vanlig tolkning är *frekvenstolkningen*:

Om vid N slumpmässiga försök A inträffar N_A av gångerna sätter vi $P(A) = \lim_{N \rightarrow +\infty} N_A/N$, dvs. $P(A)$ är den relativa frekvensen av A när antalet försök går mot oändligheten.

Frekvenstolkningen är naturlig för vissa fenomen som tärningskast, kortspel eller olika fysikaliska förlopp. För andra påståenden som "chansen för regn på lördag är 80%" eller "Donald Trump vann valet 2020 med 10% sannolikhet" blir frekvenstolkningen problematisk. Då passar en *subjektiv tolkning* (också kallad *bayesiansk tolkning*) bättre:

Sannolikheten $P(A)$ motsvarar hur "troligt" vi anser det är att händelsen A inträffar.

Detta ger en bredare definition av sannolikhet men kan vara lite för "personlig" för att beskriva till exempel fysikaliska fenomen (en sönderfallande cesiumatom bryr sig inte så mycket om vad vi "tror".)

Valet av tolkning beror på tillämpningen och studeras flitigt inom sannolikhetsteorins epistemologi (en del av den matematiska filosofin). Oavsett tolkning ska vi se att man kan räkna på samma sätt med de resulterande sannolikheterna så länge de följer ett par grundläggande regler.

Föreläsning två

Joakim Andén

Repetition

Ett *utfallsrum* Ω består av *utfall* $\omega_1, \omega_2, \dots$. Kan vara *diskret* eller *kontinuerlig*. En samling händelser, dvs. delmängd av Ω kallas en *händelse* och betecknas A, B , osv.

Operationer på händelser.

- *Snitt* $A \cap B$, alla utfall som ligger i både A och B – motsvarar händelsen att både A och B inträffar. Om $A \cap B = \emptyset$ säger vi att A och B är oförenliga.
- *Union* $A \cup B$, alla utfall som ligger i minst en av A och B – motsvarar händelsen att minst en av A och B inträffar.
- *Komplement* $A^* = \Omega \setminus A$, alla utfall som inte ligger i A (men ligger i Ω) – motsvarar händelsen att A inte inträffar.

Räkneregler för händelser:

- Snitt distribuerar över union: $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$.
- Union distribuerar över snitt: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$.
- De Morgans lagar

$$(A \cap B)^* = A^* \cup B^* \quad (A \cup B)^* = A^* \cap B^*.$$

Sannolikhetsbegreppet kan tolkas olika beroende på användningsområde och filosofisk läggning. Vanligast är *frekvenstolkningen* (sannolikheten $P(A)$ är den relativa frekvensen av A , dvs. hur ofta A förekommer vid repeterade slumpmässiga försök) och *subjektiva tolkningen* (sannolikheten $P(A)$ motsvarar hur "troligt" vi anser att det är att A inträffar).

Notera att $P(A)$ inte är en vanlig funktion (dvs. en funktion som tar ett tal eller vektor som argument och ger ett annat tal ut) eftersom den tar en delmängd av Ω som argument. En sådan funktion kallar för en *mängdfunktion*.

Kolmogorovs axiomsystem

Oavsett tolkning vill vi att *sannolikhetsmättet* $P(A)$ är logiskt sammanhängande, så vi kräver att

- (i) $0 \leq P(A) \leq 1$,

- (ii) $P(\Omega) = 1$, och
- (iii) om $A_1, A_2, \dots$ är en samling parvis oförenliga händelser (dvs. $A_i \cap A_j = \emptyset$ för alla i, j) så har vi att
- $$P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$$

Det sista axiomet kallas *uppräknelig additivitet*. Ett specialfall av axiomet (iii) är att $P(A \cup B) = P(A) + P(B)$ förutsatt att $A \cap B = \emptyset$. Sammantaget bildar dessa *Kolmogorovs axiomsystem* och ligger till grunden för mycket av sannolikhets teorin.

Utöver tolkningarna vi såg i föregående föreläsning finns det en annan tolkning av sannolikhetsbegreppet som kan underlätta intuitionen: *masstolkningen*. I detta fall tolkar vi Ω som en delmängd i tre eller två dimensioner och vilket gör att $A \subset \Omega$ också är en delmängd i ett sådant rum. Vi tolkar nu $P(A)$ som *volymen* eller *arean* relativt Ω . Givet konstant densitet är denna då proportionerlig mot *massan* av A . Omvänt kan vi säga att om vi tar massan av A och delar med massan av Ω så får vi $P(A)$. Om vi nu väljer en godtycklig punkt på måfå i Ω så hamnar vi i delmängden A med sannolikhet $P(A)$. (Vi kan visualisera detta som att vi kastar en pil på mängden Ω och "träffar" delmängden med en viss sannolikhet.)

Vi kan nu visa ett par enkla satser.

Sats 1. (Komplementsatsen) $P(A^*) = 1 - P(A)$


Bevis. Eftersom A och A^* är oförenliga ($A \cap A^* = \emptyset$) har vi att

$$P(A \cup A^*) = P(A) + P(A^*),$$

men $A \cup A^* = \Omega$, så $P(A \cup A^*) = P(\Omega) = 1$, vilket ger $P(A^*) = 1 - P(A)$. □

Följdsats 2. $P(\emptyset) = 0$

Bevis. Sätt $A = \Omega$. Då är $A^* = \emptyset$ och vi får $P(\emptyset) = 1 - P(\Omega) = 0$. □



Sats 3. (Additionssatsen) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Bevis. Satsen gäller trivialt då A och B är oförenliga eftersom vi då har $P(A \cap B) = P(\emptyset) = 0$ och kan tillämpa axiomet (iii). Problemet är alltså när $A \cap B \neq \emptyset$. Om vi

ritar upp eulerdiagrammet ovan och ser att när vi tar summan $P(A) + P(B)$ så har vi räknat $P(A \cap B)$ "dubbelt". Det är detta som vi måste korrigera för när vi vill beräkna $P(A \cup B)$.

Ett sätt att utnyttja axiom (iii) är att skriva om $A \cup B$ som en annan union av två delmängder som är oförenliga. Om vi betraktar eulerdiagrammet ovan ser vi att ett alternativ skulle kunna vara $A \cup (A^* \cap B)$, eftersom $A \cap (A^* \cap B) = (A \cap A^*) \cap B = \emptyset \cap B = \emptyset$. Låt oss visa att $A \cup (A^* \cap B)$ ger samma händelse med hjälp av räkneregler.

Enligt unionens distributivitet har vi

$$A \cup (A^* \cap B) = (A \cup A^*) \cap (A \cup B) = \Omega \cap (A \cup B) = A \cup B,$$

där vi har använt att $A \cup A^* = \Omega$ och snittet mellan Ω och en godtycklig händelse är händelsen själv (Ω inträffar alltid). Unionen av A och B kan alltså ersättas med unionen av A och $A^* \cap B$, B med A borttaget (kan också skrivas $B \setminus A$). Enligt axiom (iii) har vi då

$$P(A \cup B) = P(A \cup (A^* \cap B)) = P(A) + P(A^* \cap B).$$

Det återstår alltså att beräkna $P(A^* \cap B)$.

Återigen betraktar vi eulerdiagrammet. Det ser ut som att B kan delas upp i två disjunkta delmängder (dvs. två oförenliga händelser): $A^* \cap B$ och $A \cap B$. Låt oss visa att detta stämmer.

Vi har alltså

$$(A \cap B) \cup (A^* \cap B) = (A \cup A^*) \cap B = \Omega \cap B = B$$

där vi återigen använt distributionsregeln för snitt samt att $A \cup A^* = \Omega$ och att snittet mellan Ω och godtycklig händelse ger samma händelse igen. Enligt axiom (iii) har vi då, eftersom $(A \cap B) \cap (A^* \cap B) = (A \cap A^*) \cap (B \cap B) = \emptyset \cap B = \emptyset$,

$$P(B) = P((A \cap B) \cup (A^* \cap B)) = P(A \cap B) + P(A^* \cap B),$$

dvs. att

$$P(A^* \cap B) = P(B) - P(A \cap B).$$

Om vi stoppar in detta i uttrycket för $P(A \cup B)$ får vi den sökta identiteten. □

Notera att i beviset ovan så använde vi eulerdiagrammet för att bygga upp intuitionen, men sedan tillämpade axiomen och mängdlärans räkneregler för att visa att intuitionen stämde.

Följdsats 4. (Booles olikhet) $P(A \cup B) \leq P(A) + P(B)$

Bevis. Tillämpa additionssatsen och axiom (i) som ger att $P(A \cap B) \geq 0$. □

Man kan generalisera både additionssatsen och Booles olikhet till tre eller flera händelser med hjälp av induktion.

Likformigt sannolikhetsmått

Antag att utfallsrummet Ω är ändligt med m möjliga utfall $\omega_1, \omega_2, \dots, \omega_m$. Ett naturligt sätt att definiera en sannolikhetsfunktion är då att anta att varje utfall har samma sannolikhet p :

$$P(\{\omega_1\}) = P(\{\omega_2\}) = \dots = P(\{\omega_m\}) = p.$$

Eftersom enskilda utfall är oförenliga, dvs. $\{\omega_i\} \cap \{\omega_j\} = \emptyset$ för $i \neq j$ så har vi att

$$\begin{aligned} P(\Omega) &= P(\{\omega_1\} \cup \{\omega_2\} \cup \dots \cup \{\omega_m\}) \\ &= P(\{\omega_1\}) + P(\{\omega_2\}) + \dots + P(\{\omega_m\}) \\ &= p + p + \dots + p \\ &= mp, \end{aligned}$$

där vi har använt additivitetsaxiomet samt att alla utfall har samma sannolikhet. Å andra sidan vet vi att $P(\Omega) = 1$, vilket ger att $1 = mP(\{\omega_1\})$ eller mer generellt

$$P(\{\omega_i\}) = p = \frac{1}{m}$$

för $i = 1, 2, \dots, m$. Sannolikhetsmättet P kallas då det *likformiga sannolikhetsmättet* över Ω . Denna situation uppstår ofta på grund av symmetrier (hos mynt, tärningar, dragning av kort, osv.) eller när det inte finns någon anledning att ett utfall är troligare än ett annat (den så kallade *likgiltighetsprincipen*).

Låt oss anta att vi har någon händelse $A \subset \Omega$ som innehåller $g = |A|$ utfall och låt $i_1, i_2, \dots, i_g \in \{1, 2, \dots, m\}$ indexera utfallen i händelsen så att vi har

$$A = \{\omega_{i_1}, \omega_{i_2}, \dots, \omega_{i_g}\}.$$

Sannolikheten $P(A)$ beror då endast på hur många utfall som A består av:

$$\begin{aligned} P(A) &= P(\{\omega_{i_1}\} \cup \{\omega_{i_2}\} \cup \dots \cup \{\omega_{i_g}\}) \\ &= P(\{\omega_{i_1}\}) + P(\{\omega_{i_2}\}) + \dots + P(\{\omega_{i_g}\}) \quad (\text{enskilda utfall är oförenliga}) \\ &= \frac{1}{m} + \frac{1}{m} + \dots + \frac{1}{m} = \frac{g}{m}. \end{aligned}$$

Formeln

$$P(A) = \frac{g}{m}$$

brukar kallas *den klassiska sannolikhetsdefinitionen*. Tekniskt sett är det inte en definition utan en konsekvens av det likformiga sannolikhetsmättet, men vi kallar det för den klassiska sannolikhetsdefinitionen av historiska skäl.

Exempel 5. Vi återgår till tärningsexemplet. I detta fall har vi sex möjliga utfall $\omega_1, \omega_2, \dots, \omega_6$ där ω_i betecknar utfallet att tärningen landar med sida i pekandes uppåt. Låt oss anta att händelsen vi är intresserad av är

$$A = \text{"antal ögon är udda"} = \{\omega_1, \omega_3, \omega_5\}.$$

Om vi antar att tärningen är välgjord är det naturligt att anta att vi har ett likformigt sannolikhetsmått. Detta ger då


$$P(A) = \frac{3}{6} = \frac{1}{2}.$$

Notera att det viktiga med detta sannolikhetsmått är hur många utfall som finns i händelsen – det spelar ingen roll vilka utfall de är egentligen. Detta är en konsekvens av att varje utfall har samma sannolikhet, så det enda som spelar roll är hur många de är.


Kombinatorik

För att få fram intressanta värden på m och g behöver vi ett par verktyg för att räkna utfall (eller val, som vi kommer att se strax). Dessa härstammar från *kombinatorik*, som omfattar ett helt forskningsfält inom matematiken. Vi kommer att nöja oss med ett par enkla formler för dragning av element ur en mängd, vilket kan göras på ett par olika sätt.

Antag först att vi måste göra ett antal val, ett efter varandra. I det första valet har vi n_1 alternativ och i det andra har vi n_2 alternativ. På en restaurang kanske vi har n_1 stycken förrätter att välja på och n_2 stycken efterrätter. Det totala antalet möjliga alternativ (beställningar i restaurangen) är då $n_1 n_2$. Med tre val har vi på samma sätt $n_1 n_2 n_3$ om det tredje valet innefattar n_3 alternativ. Denna formel kan generaliseras till godtyckligt antal val och kallas *multiplikationsprincipen*.




Låt oss nu anta att vi har en mängd med n element. Det finns n sätt att välja ett element ur mängden. Vi skriver ner vilket element vi valde och lägger tillbaka det. Om vi nu väljer ett andra element finns det återigen n sätt att välja det på. Vi skriver ner vilket element och lägger tillbaka det. Sedan fortsätter vi tills vi har en lista med k element.



Antalet sätt vi kan välja k element från en mängd med n element förutsatt att vi lägger tillbaka elementet varje gång är då

$$\underbrace{n \cdot n \cdot \dots \cdot n}_{k \text{ gånger}} = n^k,$$

enligt multiplikationsprincipen eftersom vi har n alternativ varje gång vi väljer. Notera att detta förutsätter att ordningen spelar roll i vår lista, dvs. att en lista med samma element i en annan ordning räknas som ett annat "val". Detta förfarande kallas därför för *dragning med återläggning av k element ur n med hänsyn till ordning*.



Om vi inte lägger tillbaka ett element efter att vi dragit det från mängden får vi ett annat totalt antal alternativ. I detta fall har vi först n val, sedan $n - 1$ val, sedan $n - 2$ val, osv. tills vi har endast $n - k + 1$ val (sista gången har vi samlat på oss $k - 1$ element, så det finns $n - k + 1$ kvar i mängden). Detta ger totalt

$$n \cdot (n - 1) \cdot \dots \cdot (n - k + 1)$$

antal sätt. Notera att ordningen vi väljer elementen fortfarande spelar roll. Detta förfarande kallas *dragning utan återläggning av k element ur n med hänsyn till ordning*.


Ovanstående formel kan skrivas om med hjälp av fakultetsnotationen

$$n! = n \cdot (n - 1) \cdot \dots \cdot 2 \cdot 1,$$

vilket ger totalt

$$\frac{n!}{(n - k)!}$$

sätt för dragning utan återläggning med hänsyn till ordning. Denna formel kan vara användbar för att förenkla vissa resultat men man ska akta sig för att använda den i numeriska sammanhang – $n!$ är ett väldigt stort tal även för små n och kan skapa precisionsproblem i beräkningar med ändlig precision.



En konsekvens av detta är att antalet sätt man kan ordna n element är $n!$ eftersom detta motsvarar dragning utan återläggning av n element ur n med hänsyn till ordning. Vi kan använda denna formel för att derivata antalet sätt att dra k element ur n med återläggning *utan* hänsyn till ordning (dvs. vi kan betrakta detta som dragning av en *mängd*, inte som en lista eller sekvens).

Antag att vi dragit k element ur n med återläggning. Vi vet nu att det finns $k!$ olika sätt att ordna dessa element. Med andra ord finns det $k!$ stycken "kopior" av vår lista som kan anses ekvivalenta. Det totala antalet sätt vi kan utföra *dragning av k element ur n utan återläggning och utan hänsyn till ordning* är då

$$\frac{n \cdot (n-1) \cdot \dots \cdot (n-k+1)}{k!} = \frac{n!}{k!(n-k)!} = \binom{n}{k}.$$

Detta tal brukar benämnas antalet *kombinationer av k element bland n* eller *binomialkoefficienten* $\binom{n}{k}$.

Ovanstående resonemang fungerar dock inte när det gäller dragning med återläggning utan hänsyn till ordning efter som vi kan få samma element flera gånger. Vi kommer inte att derivata denna formel i kursen.

Exempel 6. Vad är sannolikheten att vi drar fyra kort ur en kortlek och att alla är ess? Vad är sannolikheten att vi drar två kort och båda är ess?

En kortlek har 52 kort varav fyra ess. Vi drar alltså fyra kort från kortleken utan återläggning. Antag först att detta sker utan hänsyn till ordning, vilket är rimligt eftersom vi egentligen bara bryr oss om vilka korten är, inte i vilken ordning de valdes. Det finns då $m = \binom{52}{4}$ sätt att välja fyra kort. Eftersom leken bara har fyra ess finns det bara $g = 1$ gynnsamt utfall (eftersom $\binom{4}{4} = 1$), vilket ger

$$P(\text{av 4 dragna kort är 4 ess}) = \frac{g}{m} = \frac{1}{\binom{52}{4}} = \frac{4 \cdot 3 \cdot 2 \cdot 1}{52 \cdot 51 \cdot 50 \cdot 49} = \frac{1}{270725} \approx 3.96 \cdot 10^{-6}.$$

Alternativt kan vi dra korten med hänsyn till ordning. Vi har då $m = 52!/(52-4)! = 52 \cdot 51 \cdot 50 \cdot 49$. Antalet gynnsamma utfall blir då $4! = 4 \cdot 3 \cdot 2 \cdot 1$ eftersom det finns $4!$ olika sätt att ordna de fyra essen. Sannolikheten blir dock återigen

$$P(\text{av 4 dragna kort är 4 ess}) = \frac{g}{m} = \frac{4 \cdot 3 \cdot 2 \cdot 1}{52 \cdot 51 \cdot 50 \cdot 49} = \frac{1}{270725}.$$


Båda modellerna (dragning med eller utan hänsyn till ordning) fungerar och ger samma resultat eftersom de speglar samma verkliga förlopp.

Om vi nu drar två kort och gör detta utan hänsyn till ordning får vi $m = \binom{52}{2}$ medan $g = \binom{4}{2}$, vilket ger

$$P(\text{av 2 dragna kort är 2 ess}) = \frac{g}{m} = \frac{4 \cdot 3}{2 \cdot 1} \cdot \frac{2 \cdot 1}{52 \cdot 51} = \frac{1}{221}.$$

Vad händer om vi istället räknar med hänsyn till ordning?

Exempel 7. (Dragning utan återläggning ur en urna) En populär modell inom statistiken är dragning utan återläggning ur en urna. Vi antar att vi har b blåa kulor och r röda kulor i en urna och drar n kulor från denna utan återläggning. Vad är sannolikheten att vi erhåller k blåa kulor?



Antalet möjliga utfall är $m = \binom{b+r}{n}$ eftersom det totala antalet kulor är $b + r$. När det gäller antalet gynnsamma utfall så måste vi tänka på att det är antalet blåa kulor som räknas, inte vilka specifika kulor vi drar. Från det perspektivet finns det $\binom{b}{k}$ sätt att välja k blåa kulor ur urnan. De resterande $n - k$ kulorna måste dras från de r röda kulorna, vilket kan göras på $\binom{r}{n-k}$ sätt. Multiplikationsprincipen ger då totalt $g = \binom{b}{k} \binom{r}{n-k}$ gynnsamma fall och vi får

$$P(\text{av totalt } n \text{ dragna kulor är } k \text{ blåa}) = \frac{\binom{b}{k} \binom{r}{n-k}}{\binom{b+r}{n}}.$$

Exempel 8. Vi kan modellera dragning av kort ur en kortlek som dragning ur en urna. Låt oss återgå till sannolikheten att dra fyra ess ur kortleken. I urnmodellen ovan har vi då att blått motsvarar ess och rött motsvarar icke-ess, vilket ger $b = 4$, $r = 48$. Fallen som diskuterades i det föregående exemplet är då $n = k = 4$ respektive $n = k = 2$. Till exempel så får vi

$$P(\text{av 4 dragna kort är 4 ess}) = \frac{\binom{4}{4}\binom{48}{0}}{\binom{52}{4}} = \frac{4 \cdot 3 \cdot 2 \cdot 1}{52 \cdot 51 \cdot 50 \cdot 49} = \frac{1}{270725}$$

och

$$P(\text{av 2 dragna kort är 2 ess}) = \frac{\binom{4}{2}\binom{48}{2}}{\binom{52}{2}} = \frac{(4 \cdot 3)/2}{(52 \cdot 51)/2} = \frac{1}{221}.$$

Vi kan också betrakta fallet att vi drar fyra kort men att bara två är ess, vilket då ger $n = 4$, $k = 2$ och har sannolikhet

$$P(\text{av 4 dragna kort är 2 ess}) = \frac{\binom{4}{2}\binom{48}{2}}{\binom{52}{4}} = \frac{1}{40} = 0.025.$$

Exempel 9. (Dragning med återläggning ur en urna) En variant på den ovanstående modellen fås om vi lägger tillbaka varje kula innan vi drar en ny. Det finns då $m = (b + r)^n$ möjliga utfall (vid varje dragning finns $b + r$ olika kulor i urnan).

Nu finns det flera sätt vi kan erhålla k blåa kulor utav de n vi dragit. Vi skulle kunna först dra k blåa kulor, sedan $n - k$ röda. Eller skulle vi kunna dra en blå kula, sedan en röd, sedan $k - 1$ blåa kulor och sedan $n - k - 2$ röda kulor, osv. Totalt sett finns det då $\binom{n}{k}$ olika sekvenser av blåa och röda kulor. Vi kan också se detta som att av n möjliga "positioner" i dragningssekvensen så väljer vi k stycken för de blåa.




Varje sådan sekvens kan innehålla olika distinkta kulor från urnan. Mer konkret kan vi välja de blåa kulorna på b^k sätt och de röda på r^{n-k} sätt. Enligt multiplikationsprincipen får vi då $g = \binom{n}{k}b^k r^{n-k}$, vilket ger

$$P(\text{av } n \text{ med återläggning dragna kulor är } k \text{ blåa}) = \frac{\binom{n}{k}b^k r^{n-k}}{(b + r)^n}.$$

Betingade sannolikheter

Om vi vet att en händelse redan inträffat, vad kan vi då säga om en annan händelses sannolikhet? Med andra ord, vad är sannolikheten av A givet att B inträffat? Detta kallas en *betingad sannolikhet* och betecknas $P(A | B)$ (läses "sannolikheten av A givet B ").

Vi kan till exempel betrakta sannolikheten att det har regnat under det senaste dygnet givet att trottoaren är våt. Ett annat exempel är sannolikheten att ett diagnostiskt test ger ett positivt svar givet att patienten är sjuk.



Vad för egenskaper söker vi hos $P(A | B)$? Om $A \cap B = \emptyset$, dvs. om A och B är oförenliga, så borde vi ha $P(A | B) = 0$ eftersom att B inträffar gör det omöjligt för A att inträffa. Om $A \subset B$ borde $P(A | B)$ vara större än noll och rimligtvis större än $P(A)$ eftersom vi har vet att A utgör en större del av B jämfört med Ω (så länge $B \neq \Omega$). Åt andra hållet har vi att $P(B | A)$ borde vara ett eftersom B måste inträffa när A redan inträffat. Om ingetdera gäller, dvs. att $A \cap B \neq \emptyset$ och $A \cap B^* \neq \emptyset$, borde $P(A | B)$ bero på $P(A \cap B)$ eftersom delen av A utanför B , dvs. $A \cap B^*$ inte kan inträffa.

En naturlig definition som har dessa egenskaper är

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

vilket också är hur betingade sannolikheter definieras. Det är alltså kvoten mellan sannolikheten att både $A \cap B$ inträffar och sannolikheten att B inträffar – man kan se detta som en *relativ* sannolikhet.

Notera att $P(A | B)$ som sannolikhetsmått, med B fix, uppfyller alla tre av Kolmogorovs axiom. Med andra ord har vi $P(A | B) \geq 0$, $P(B | B) = 1$ (B ersätter Ω som utfallsrum när vi betingar med avseende på B) och $P(A \cup C | B) = P(A | B) + P(C | B)$ om $A \cap C = \emptyset$. En konsekvens av detta är att alla satser vi bevisat för vanliga (obetingade) sannolikhetsmått också gäller för betingade sannolikheter, så länge vi håller den betingade händelsen B fixt. Till exempel har vi att $P(A^* | B) = 1 - P(A | B)$ och $P(A \cup C | B) = P(A | B) + P(C | B) - P(A \cap C | B)$.

Två användbara omformuleringar är

$$P(A \cap B) = P(A | B)P(B) \text{ och } P(A \cap B) = P(B | A)P(A).$$

Dessa formler kallas ibland för *kedjeregeln* (ej att förväxlas med kedjeregeln inom differentialekalkylen). Sannolikheten att A och B båda inträffar är alltså lika med sannolikheten att B inträffar gånger sannolikheten att A inträffar givet B (och vice versa).

Exempel 10. Låt oss återigen beräkna sannolikheten att vi drar fyra ess från en kortlek, men den här gången med hjälp av betingade sannolikheter.

Låt A_i beteckna händelsen att det i :te kortet vi drar är ett ess. Vi har då för det första kortet att det finns 4 ess att välja från och 52 kort totalt i leken, vilket ger

$$P(A_1) = 4/52.$$

Efter att vi har dragit det första esset finns det 51 kort kvar i leken, varav 3 är ess. Detta ger

$$P(A_2 | A_1) = 3/51.$$

Vidare har vi

$$P(A_3 | A_1 \cap A_2) = 2/50 \text{ och } P(A_4 | A_1 \cap A_2 \cap A_3) = 1/49.$$

Den sökta sannolikheten är nu $P(A_1 \cap A_2 \cap A_3 \cap A_4)$, vilket kan beräknas med upprepade tillämpning av kedjeregeln som

$$\begin{aligned} P(A_1 \cap A_2 \cap A_3 \cap A_4) &= P(A_4 | A_1 \cap A_2 \cap A_3)P(A_1 \cap A_2 \cap A_3) \\ &= P(A_4 | A_1 \cap A_2 \cap A_3)P(A_3 | A_1 \cap A_2)P(A_1 \cap A_2) \\ &= P(A_4 | A_1 \cap A_2 \cap A_3)P(A_3 | A_1 \cap A_2)P(A_2 | A_1)P(A_1) \\ &= \frac{1}{49} \cdot \frac{2}{50} \cdot \frac{3}{51} \cdot \frac{4}{52} \\ &= \frac{1}{270725}, \end{aligned}$$


dvs. samma resultat som innan.

Betingade sannolikheter kan vara kniviga att ha att göra med. Se, till exempel, Monty Hall-problemet och trefångarsproblemet. Iaktta därför stor försiktighet vid hantering av betingade sannolikheter (skriv upp alla möjliga utfall, rita eulerdiagrammet, sätt upp sanningsvärdestabeller, osv.).

Ett sätt som betingade sannolikheter används i praktiken är inom generativa sekvensmodeller, som till exempel BERT, ChatGPT eller LLaMA. Grovt förenklat så försöker dessa modeller beräkna $P(A | B)$ där B motsvarar en tidigare genererad text (som konversationen hittills i en chatt) och A är nästa ord i texten. Modellerna beräknar då denna betingade sannolikhet för olika ord A och väljer sedan det som maximerar den betingade sannolikheten. Sedan läggs detta ord till i texten B och en ny betingad sannolikhet beräknas. Genom att träna modellen på stora mängder

data kan man approximera $P(A | B)$ ganska bra och använda denna för att generera olika textstycken.

Antag nu att vi kan dela upp utfallsrummet Ω i ett antal händelser $H_1, H_2, \dots, H_n$ som är parvis oförenliga (dvs. att $H_i \cap H_j = \emptyset$ för alla i, j) och $H_1 \cup H_2 \cup \dots \cup H_n = \Omega$. Detta kallas en *partition* av Ω . Vi kan se detta som en samling *hypoteser* i vår modell där bara en av hypoteserna kan stämma. I så fall kan $P(A)$ (den obetingade sannolikheten för A) att skrivas med hjälp av de betingade sannolikheterna $P(A | H_1), P(A | H_2), \dots, P(A | H_n)$.



Sats 11. (Lagen om total sannolikhet) Låt $H_1, H_2, \dots, H_n$ bilda en partition av Ω . Då gäller

$$P(A) = \sum_{i=1}^n P(A | H_i)P(H_i).$$

Bevis. Eftersom $A \cap \Omega = A$ har vi att $A = A \cap \bigcup_{i=1}^n H_i = \bigcup_{i=1}^n (A \cap H_i)$ genom distributivitet. Händelserna i denna union är oförenliga ($(A \cap H_i) \cap (A \cap H_j) = A \cap (H_i \cap H_j) = \emptyset$), så vi kan använda axiom (iii), vilket ger

$$P(A) = P\left(\bigcup_{i=1}^n (A \cap H_i)\right) = \sum_{i=1}^n P(A \cap H_i) = \sum_{i=1}^n P(A | H_i)P(H_i),$$

där vi i sista ledet använt kedjeregeln. □

Bayes sats

Ofta har vi tillgång till en viss betingad sannolikhet $P(A | B)$ men är intresserad av den omvända, dvs. $P(B | A)$. Vi kanske känner till sannolikheten att marken är våt givet att det har regnat under de senaste dygnet (avdunstningen sker enligt en viss känd process) men är intresserad av betingningen åt andra hållet: sannolikheten att det har regnat under det senaste dygnet givet att marken är våt. Genom att flytta om termerna i identiteten $P(A \cap B) = P(A | B)P(B) = P(B | A)P(A)$ får vi

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}.$$

Denna formel kallas för *Bayes sats* eller *Bayes regel*.

Det viktiga att notera här är hur $P(A)$ och $P(B)$ spelar in. Låt oss anta att det är mycket sannolikt att marken är våt (A) givet att det regnat under det senaste dygnet (B), dvs. att $P(A | B)$ är stor (nära ett). Detta behöver inte nödvändigtvis betyda att $P(B | A)$ också är stor. Vi kanske befinner oss i Atacamaöknen och har därför ett $P(B)$ nära noll. Alternativt kanske står mitt i ett konstbevattnat vetefält, vilket ger ett $P(A)$ nära ett. I båda fallen får vi att $P(B | A)$ är liten. Med andra ord kan vi inte med stor säkerhet konstatera att det har regnat bara för att marken är våt i dessa fall, vilket verkar rimligt.

Vi kan generalisera formeln ovan med hjälp av en partition av Ω .

Sats 12. (Bayes sats) Givet en partition $H_1, H_2, \dots, H_n$ av Ω har vi

$$P(H_i | A) = \frac{P(A | H_i)P(H_i)}{\sum_{j=1}^n P(A | H_j)P(H_j)}.$$

Exempel 13. (Sensitivitet och specificitet av diagnostiskt test) Diagnostiska test för olika sjukdomar brukar utvärderas med avseende på deras sensitivitet (känslighet), sannolikheten att testet ger ett positivt svar för en person som har sjukdomen, och specificitet (träffsäkerhet), sannolikheten att testet ger ett negativt svar för en person som inte har sjukdomen. Om vi betecknar händelsen att personen har sjukdomen med A och ett positivt testsvar med B ser vi att sensitiviteten motsvarar $P(B | A)$ och specificiteten motsvarar $P(B^* | A^*)$.

Antag att ett PCR-test för covid-19 har sensitivitet $P(B | A) = 0.9$ och specificitet $P(B^* | A^*) = 0.995$. Om en person tar testet och får ett positivt provsvar, vad är då sannolikheten att personen har sjukdomen?

Tyvärr kan vi inte svara på denna fråga utan en till variabel: sannolikheten $P(A)$ att personen har sjukdomen över huvudtaget. Om personen vid tidpunkten för testet befann sig i Sverige i slutet av maj 2020 beräknades prevalensen av covid-19 bland befolkningen vara 0.3%, dvs. $P(A) = 0.003$. Bayes sats ger då

$$P(A | B) = \frac{P(B | A)P(A)}{P(B | A)P(A) + P(B | A^*)P(A^*)} = \frac{0.9 \cdot 0.003}{0.9 \cdot 0.003 + (1 - 0.995)(1 - 0.003)} \approx 0.35,$$

eftersom $P(B | A^*) = 1 - P(B^* | A^*)$. Ett positivt testsvar ger då ungefär 35% sannolikhet att personen har sjukdomen.

I slutet av april 2020 beräknades prevalensen vara runt 0.9%, vilket ger $P(A) = 0.009$. Detta skulle då ge

$$P(A | B) = \frac{0.9 \cdot 0.009}{0.9 \cdot 0.009 + (1 - 0.995)(1 - 0.009)} \approx 0.62.$$

Här ger alltså ett positivt testsvar sannolikheten 62% att personen är sjuk.

Föreläsning tre


Joakim Andén

Oberoende händelser

I vissa situationer kan vi konstatera att den betingade sannolikheten för A givet B är densamma som den obetingade sannolikheten för A . Med andra ord, händelsen A inträffar oberoende av B (och vice versa) och vi har $P(A | B) = P(A)$. Om vi nu använder identiteten $P(A \cap B) = P(A | B)P(B)$ får vi

$$P(A \cap B) = P(A)P(B).$$

När detta gäller säger vi att A och B är *oberoende* händelser.



Notera att oberoende och oförenlighet är två vitt skilda relationer. Den enda situationen då två händelser kan vara oberoende och oförenliga är om en av dem har sannolikhet noll. I detta fall har vi att $P(A \cap B) = P(\emptyset) = 0$ (eftersom A och B är oförenliga) vilket kräver att $P(A)P(B) = 0$ (om A och B är oberoende). En annan viktig distinktion är att egenskapen oförenlig är något som beror på händelserna i sig och har inget att göra med sannolikhetsmåttet.

Oberoende händelser är väldigt användbara eftersom de förenklar många beräkningar. Lyckligtvis förekommer de också ofta i verkligheten (mer eller mindre). Olika tärningskast kan anses oberoende, till exempel, eller olika mätvärden av en fysisk parameter.

Om vi har fler än två händelser kräver vi att sannolikheten för alla möjliga snitt mellan händelserna kan skrivas som en produkt av händelsernas sannolikheter. Låt oss anta att vi har en samling händelser $A_1, A_2, \dots, A_n$. För varje $2 \leq k \leq n$ kräver vi

då att varje sekvens $1 \leq i_1 < i_2 < \dots < i_k \leq n$ uppfyller


$$P(A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_k}) = P(A_{i_1})P(A_{i_2}) \dots P(A_{i_k}).$$

Händelserna är då *oberoende*. Notera att det räcker inte med parvis oberoende, dvs. att kravet bara uppfylls för $k = 2$.

Ett kontraexempel är om vi har ett utfallsrum Ω med fyra utfall $\omega_1, \omega_2, \omega_3, \omega_4$ och ett likformigt sannolikhetsmått (dvs. $P(\omega_i) = 1/4$ för $i = 1, 2, 3, 4$). Om vi då tar $A = \{\omega_1, \omega_2\}$, $B = \{\omega_1, \omega_3\}$ och $C = \{\omega_1, \omega_4\}$ så har vi att $A \cap B = B \cap C = C \cap A = \{\omega_1\}$. Vidare har vi $P(A) = P(B) = P(C) = 1/2$ samt att $P(A \cap B) = P(B \cap C) = P(C \cap A) = 1/4$ vilket ger att A , B och C är parvis oberoende. Däremot har vi att $A \cap B \cap C = \{\omega_1\}$, men $P(A)P(B)P(C) = 1/8 \neq P(A \cap B \cap C) = 1/4$.

Sats 1. Om A och B är oberoende har vi att

- (i) A^* och B är oberoende,
- (ii) A och B^* är oberoende, och
- (iii) A^* och B^* är oberoende.



Bevis. Med mängdlärans räkneregler, additivitetsaxiomet och $P(A \cap B) = P(A)P(B)$ får vi

$$\begin{aligned}
 P(B) &= P(\Omega \cap B) & (B &= \Omega \cap B) \\
 &= P((A^* \cup A) \cap B) & (\Omega &= A^* \cup A) \\
 &= P((A^* \cap B) \cup (A \cap B)) & (\text{distributivitet}) \\
 &= P(A^* \cap B) + P(A \cap B) & (\text{additivitet}) \\
 &= P(A^* \cap B) + P(A)P(B) & (\text{oberoende})
 \end{aligned}$$

Om vi subtraherar $P(A)P(B)$ från båda led får vi

$$P(A^* \cap B) = (1 - P(A))P(B) = P(A^*)P(B),$$

vilket skulle visas för (i).

Del (ii) visas genom att byta plats på A och B i del (i). Del (iii) visas genom att tillämpa del (i) följt av del (ii). $\square$

Detta resultat kan generaliseras till en godtycklig sekvens av oberoende händelser och deras komplement.

Låt $A_1, A_2, \dots, A_n$ vara oberoende händelser. Eftersom de är oberoende kan vi enkelt beräkna sannolikheten att minst en av dem inträffar, dvs. att $A_1 \cup A_2 \cup \dots \cup A_n$ inträffar. Enligt De Morgans lag har vi att den komplementära händelsen är $A_1^* \cap A_2^* \cap \dots \cap A_n^*$. Komplementen $A_1^*, A_2^*, \dots, A_n^*$ är också oberoende som vi sett ovan. Vi har då

$$\begin{aligned} P(A_1 \cup A_2 \cup \dots \cup A_n) &= 1 - P(A_1^* \cap A_2^* \cap \dots \cap A_n^*) \\ &= 1 - P(A_1^*)P(A_2^*) \dots P(A_n^*) \\ &= 1 - (1 - P(A_1))(1 - P(A_2)) \dots (1 - P(A_n)). \end{aligned}$$

Om händelserna alla har samma sannolikhet $P(A_i) = p$ får vi sannolikheten

$$1 - (1 - p)^n$$

att minst en av dem inträffar. Intuitionen här är att även om något är väldigt osannolikt (t.ex. att bli påkörd av en bil när man korsar gatan) så blir det mer och mer sannolikt att det händer någon gång ju fler gånger man gör det.

Exempel 2. Antag att en tärning kastas tre gånger. Vad är sannolikheten att vi får en sexa exakt ett av kasten?

I stället för att beräkna detta med hjälp av kombinatoriken kan vi utnyttja faktumet att varje tärningskast är oberoende av varandra. Låt A vara händelsen att vi först får en sexa och sedan två icke-sexor, B att vi för en icke-sexa, sen en sexa och sen en icke-sexa igen och C vara händelsen att vi får två icke-sexor och sedan en sexa. Dessa tre händelser är oförenliga, så den sökta sannolikheten

$$P(A \cup B \cup C)$$

kan skrivas som

$$P(A) + P(B) + P(C).$$

Problemet är nu att beräkna dessa sannolikheter.

Händelsen A i sig kan skrivas som snittet av tre händelser: A_1 , att första tärningen är en sexa, A_2 att andra tärningen inte är en sexa och A_3 , att den tredje tärningen inte är en sexa. Vi antar att tärningskasterna är oberoende av varandra, så händelserna A_1 , A_2 och A_3 är då också oberoende. Detta ger då

$$P(A) = P(A_1 \cap A_2 \cap A_3) = P(A_1)P(A_2)P(A_3)$$

och eftersom $P(A_1) = 1/6$ och $P(A_2) = P(A_3) = 5/6$ får vi

$$P(A) = \frac{1}{6} \cdot \frac{5}{6} \cdot \frac{5}{6} = \frac{25}{216}.$$

På samma sätt har vi sannolikheten för B till

$$P(B) = \frac{5}{6} \cdot \frac{1}{6} \cdot \frac{5}{6} = \frac{25}{216}.$$

Och till slut, har vi sannolikheten för två icke-sexor följt av en sexa som

$$P(C) = \frac{5}{6} \cdot \frac{5}{6} \cdot \frac{1}{6} = \frac{25}{216}.$$

Vi får då den totala sannolikheten

$$\frac{25}{216} + \frac{25}{216} + \frac{25}{216} = \frac{25}{72}.$$


Vad är sannolikheten att vi får exakt två sexor?

Stokastiska variabler

Ofta är vi intresserade av att associera vissa värden, dvs. reella tal, med olika utfall i ett slumpmässigt försök. Detta kan vara ett mätvärde, en vinst, en tidpunkt, osv. som *beror på* resultatet av ett slumpmässigt förlopp. Vi kan säga att värdet i sig är slumpmässigt, eller stokastiskt. Därför kallas sådana värden för *stokastiska variabler* (s.v.) eller *slumpvariabler*.


Konkret så tilldelar vi ett visst värde x till varje utfall $\omega \in \Omega$. Man kan tänka på stokastiska variabler som ett sätt att "ordna" utfallsrummet så att vi kan göra beräkningar på det (man kan till exempel inte addera eller multiplicera utfall och händelser med varandra, men detta kommer vi kunna göra med stokastiska variabler senare).

En enkel stokastisk variabel är antalet ögon vid ett tärningskast. I detta fall motsvarar varje utfall ett heltal mellan ett och sex, vilket kan beskrivas som en stokastisk variabel. Vi kanske har slagit vad om tärningskastet och vinner sex kronor om vi slår en etta eller två och måste betala två kronor annars. I så fall kan vi tilldela ett vinstvärde till varje utfall: sex kronor om vi slår en etta eller två och minus två kronor annars.



Om vi har två tärningskast är *ögonsumman* en stokastisk variabel. Här tilldelar vi då kastet etta–etta värdet två, kasten etta–tvåa och tvåa–etta värdet tre, osv. En annan stokastisk variabel är antalet ettor i tre tärningskast. Kastet etta–etta–etta ger då värdet tre, etta–etta–tvåa värdet två, tvåa–trea–sexa värdet noll, osv. Vi kan också utföra ett oändligt antal kast och räkna antalet kast tills vi får en etta.

En stokastisk variabel behöver inte ta heltal som värde. Vi kan, till exempel, släppa två tandpetare på bordet och mäta vinkeln mellan de två linjerna som bildas. Vinkeln är en stokastisk variabel med värden i $[0, \pi]$. Om vi släpper tre tandpetare kan vi mäta den area som innesluts av de tre linjerna som bildas. Detta är också en stokastisk variabel med värden i de positiva reella talen. Annars är det vanligt att tider (t.ex. väntetiden på vårdcentralen) kan modelleras som kontinuerliga stokastiska variabler.



Formellt definierar vi en stokastisk variabel som en funktion X från utfallsrummet Ω till de reella talen $\mathbb{R}$, dvs. $X : \Omega \rightarrow \mathbb{R}$. För ett givet utfall ω tar då X värdet $X(\omega) \in \mathbb{R}$. Angående notation så använder vi alltid stora bokstäver (X , Y , osv.) för stokastiska variabler. Detta gör det enklare att skilja från vanliga (deterministiska) variabler eller konstanter (x , y , osv.).

I tärningskastexemplet ovan har vi

$$X(\omega) = \begin{cases} 6, & \omega = \omega_1 \text{ eller } \omega = \omega_2, \\ -2, & \text{annars} \end{cases}$$

där utfallsrummet är $\Omega = \{\omega_1, \omega_2, \dots, \omega_6\}$ och utfallet ω_i motsvarar att tärningen visar i ögon. Om vi har två tärningar som kastas med utfallsrummet

$$\Omega = \{\omega_{1,1}, \omega_{1,2}, \dots, \omega_{6,5}, \omega_{6,6}\}$$

där $\omega_{i,j}$ motsvarar att första tärningen visar i ögon och andra tärningen visar j ögon så har vi

$$X(\omega_{i,j}) = i + j$$

för den stokastiska variabeln som beskriver ögonsumman. Vi kan också definiera en stokastisk variabel $X(\omega_{i,j}) = ij$ för produkten av antalet ögon.

Låt nu M vara en delmängd av $\mathbb{R}$. Vi kan nu betrakta händelsen $X \in M$, vilket är en kortform för $\{\omega \in \Omega : X(\omega) \in M\}$, dvs. alla utfall vars värde $X(\omega)$ på X ligger i M . Denna händelse har en sannolikhet som skrivs

$$P(X \in M) = P(\{\omega \in \Omega : X(\omega) \in M\}),$$

dvs. sannolikheten för att utfallen ω som ger att $X(\omega) \in M$ inträffar. På ett sätt så "inducerar" X ett sannolikhetsmått på $\mathbb{R}$ genom att överföra sannolikhetsmåttet P från Ω till ett sannolikhetsmått på $\mathbb{R}$. Detta sannolikhetsmått (som tilldelar en sannolikhet till varje delmängd av $\mathbb{R}$) kallas *sannolikhetsfördelningen* eller helt enkelt

fördelningen av den stokastiska variabeln X . Notera att vi kan definiera stokastiska variabler på olika sätt men ändå erhålla samma fördelning.

Om värdemängden $X(\Omega) = \{X(\omega) \text{ för } \omega \in \Omega\}$ är ändlig eller uppräkneligt oändlig (dvs. om vi kan "räkna" elementen i $X(\Omega)$) kallas X för en *diskret stokastisk variabel*. (Notera att enligt denna definition har vi alltid att Ω diskret $\Rightarrow X$ diskret.) I exemplena ovan är vinsten och ögonsumman diskreta stokastiska variabler.

Diskreta stokastiska variabler

För diskreta stokastiska variabler kan vi betrakta ett specialfall av $P(X \in M)$, nämligen fallet då $M = \{x\}$ för någon $x \in \mathbb{R}$, vilket skrivs $P(X = x)$ och är lika med $P(\{\omega \in \Omega : X(\omega) = x\})$. Notera skillnaden mellan X (en stokastisk variabel, dvs. en funktion från Ω till $\mathbb{R}$) och x (ett konkret utfall av en stokastisk variabel, dvs. ett reellt tal – ett element av $\mathbb{R}$).

En användbar beskrivning av X ges alltså av dess *sannolikhetsfunktion*

$$p_X(x) = P(X = x).$$

Vanligtvis är $p_X(x)$ endast definierad för de x som ingår i värdemängden $X(\Omega)$, men den kan också definieras för alla $x \in \mathbb{R}$, i vilket fall de x som inte ingår i $X(\Omega)$ har sannolikhet noll.

Det är vanligt att X tar värden inom de icke-negativa heltalen $\mathbb{Z}_{\geq 0} = \{0, 1, 2, \dots\}$ (eller de positiva heltalen $\mathbb{Z}_{> 0} = \{1, 2, 3, \dots\}$). Ett par egenskaper hos sannolikhetsfunktionen kan då skrivas ned. Först kan vi skriva om sannolikheten att $X \in M$ med hjälp av sannolikhetsfunktionen

$$\begin{aligned} P(X \in M) &= P(\{\omega \in \Omega : X(\omega) \in M\}) \\ &= P\left(\bigcup_{x \in M} \{\omega \in \Omega : X(\omega) = x\}\right) \quad (\text{gruppera utfallen som ger samma värde på } x) \\ &= \sum_{x \in M} P(\{\omega \in \Omega : X(\omega) = x\}) \quad (\text{union av oförenliga händelser}) \\ &= \sum_{x \in M} P(X = x) = \sum_{x \in M} p_X(x) \end{aligned}$$

Ett specialfall av detta är om $M = [a, b]$ för $a, b \in \mathbb{Z}_{\geq 0}$, vilket ger

$$P(a \leq X \leq b) = \sum_{x=a}^b p_X(x).$$

Ett annat specialfall ges av $M = [0, +\infty)$,

$$\sum_{x=0}^{\infty} p_X(x) = P(X \in \mathbb{Z}_{\geq 0}) = P(\Omega) = 1.$$

Dessa håller även om X tar andra värden än $\mathbb{Z}_{\geq 0}$, men notationen blir lite otymplig.

Diskreta fördelningar

Låt oss nu betrakta ett par grundläggande diskreta fördelningar.

Först har vi att ett värde a antas med sannolikhet ett:

$$p_X(x) = \begin{cases} 1, & x = a, \\ 0, & \text{annars.} \end{cases}$$

Med andra ord är X *deterministisk*. Detta kallas en *enpunktsfördelning* eller helt enkelt en konstant (dvs. den varierar inte slumpmässigt).

Anta nu att X har värdet a med sannolikheten p och ett annat värde b sannolikheten $1 - p$:

$$p_X(x) = \begin{cases} p, & x = a, \\ 1 - p, & x = b, \\ 0, & \text{annars.} \end{cases}$$

Detta är en *tvåpunktsfördelning*. Ett viktigt specialfall är $a = 1, b = 0$, vilket kallas *bernoullifördelningen med sannolikhet p* . Om X har denna fördelning så skriver vi $X \sim \text{Ber}(p)$. I kursen kommer vi oftast beskriva att en stokastisk variabel har en viss fördelning med denna notation, dvs. med namnet X följt av $\sim$ och någon fördelningsbeteckning samt parameter. Boken använder $\in$ istället för $\sim$, men då detta skiljer sig från vad som är sedvanligt inom sannolikhetsteori så föredrar vi i anteckningarna $\sim$.

Givet en ändlig mängd M har vi en fördelning som ger samma sannolikhet åt varje värde i M :


$$p_X(x) = \begin{cases} 1/|M|, & x \in M, \\ 0, & \text{annars,} \end{cases}$$

där $|M|$ är antalet element i M . Detta är en *likformig fördelning över M* . Specialfallet $M = \{1, 2, \dots, m\}$ ger sannolikhetsfunktionen

$$p_X(x) = \begin{cases} 1/m, & x = 1, 2, \dots, m, \\ 0, & \text{annars.} \end{cases}$$

Denna fördelning förkortas ofta $U(M)$. Att X har fördelningen $U(M)$ skrivs då $X \sim U(M)$. Notera att med ett utfallsrum $\Omega = \{\omega_1, \omega_2, \dots, \omega_m\}$ och $X(\omega_i) = i$ så inducerar det likformiga sannolikhetsmåttet på Ω (som vi såg i den föregående föreläsningen) den likformiga fördelningen över $\{1, 2, \dots, m\}$.

Ett sätt att visualisera en diskret fördelning är att plotta dess värden i ett stapeldiagram:



Antag nu att en viss händelse inträffar med sannolikhet p . Vi utför nu flera oberoende försök och fortsätter tills händelsen inträffar. Låt X vara antalet misslyckade försök innan vi lyckas. Hur ser $p_X(k)$ ut?


Om A_i betecknar händelsen att vi lyckas i det i :te försöket har vi

$$\begin{aligned}
 p_X(x) &= P(A_1^* \cap A_2^* \cap \dots \cap A_x^* \cap A_{x+1}) \\
 &= P(A_1^*) \cdot P(A_2^*) \cdot \dots \cdot P(A_x^*) \cdot P(A_{x+1}) \\
 &= (1-p)^x p,
 \end{aligned}$$

eftersom händelserna är oberoende. Vi får då sannolikhetsfunktionen

$$p_X(x) = \begin{cases} (1-p)^x p, & x = 0, 1, 2, \dots, \\ 0, & \text{annars.} \end{cases}$$

Detta är en *geometrisk fördelning* och betecknas $\text{Ge}(p)$. Vi skriver $X \sim \text{Ge}(p)$. En variant av den geometriska fördelningen räknar det totala antalet försök inklusive det lyckade försöket och motsvarar då den geometriska fördelningen plus ett. Detta kalla *för-första-gången-fördelningen*.




Vi antar istället att vi fixerar antalet försök n och låter X beteckna antalet lyckade försök. För att beräkna $p_X(x)$ antar vi först att det är de x första försöken som lyckas och de resterande $n-x$ misslyckas. Sannolikheten för detta är $p^x(1-p)^{n-x}$. Det finns

så klart andra sätt vi kan erhålla x lyckade försök, mer exakt $\binom{n}{x}$ sätt. Detta ger då, enligt multiplikationsprincipen,

$$p_X(x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x}, & x = 0, 1, 2, \dots, n \\ 0, & \text{annars.} \end{cases}$$

Detta kallas för en *binomialfördelning* och betecknas $\text{Bin}(n, p)$. Vi skriver $X \sim \text{Bin}(n, p)$.



Exempel 3. Låt X vara antalet ettor i tre tärningskast. I så fall har vi $X \sim \text{Bin}(3, 1/6)$ och

$$p_X(0) = \binom{3}{0} \left(\frac{5}{6}\right)^3 = \frac{125}{216}$$

$$p_X(1) = \binom{3}{1} \left(\frac{1}{6}\right)^1 \left(\frac{5}{6}\right)^2 = 3 \cdot \frac{1}{6} \cdot \frac{25}{36} = \frac{25}{72}$$

$$p_X(2) = \binom{3}{2} \left(\frac{1}{6}\right)^2 \left(\frac{5}{6}\right)^1 = 3 \cdot \frac{1}{36} \cdot \frac{5}{6} = \frac{5}{72}$$

$$p_X(3) = \binom{3}{3} \left(\frac{1}{6}\right)^3 = \frac{1}{216}$$

Låt oss nu istället för ett ändligt antal försök anta att vi har *punkthändelser* som inträffar på ett kontinuum. Notera att detta inte riktigt är samma sak som de händelser, delmängder av utfallsrummet, som vi diskuterat tidigare, utan mer likt atomer som sönderfaller i tiden, samtal som kommer in till kundservice hos ett företag eller bussar som anländer till en hållplats.

Dessa punkthändelser inträffar med en viss intensitet μ per tidsenhet (t.ex. radioaktiva sönderfall per sekund, samtal per timme, osv.) och punkthändelserna inträffar oberoende av varandra. Eftersom frekvensen är μ antar vi att för ett litet tidsintervall $[a, a + h]$ med storlek h så har vi att sannolikheten för att exakt en punkthändelse inträffar i $[a, a + h]$ är μh men att sannolikheten att två eller fler punkthändelser inträffar i intervallet är praktiskt taget noll. (Detta förlopp kallas för en *poissonprocess* och är en bra modell för en mängd naturliga fenomen.)


Vi vill nu räkna antalet punkthändelser på intervallet $[0, 1]$. För att tillämpa modellen ovan delar vi upp intervallet i n lika stora intervall (dvs. med storlek $1/n$). Om n är tillräckligt stort får vi då att sannolikheten att exakt en punkthändelse inträffar i ett av interfallen är μ/n . Punkthändelserna inträffar oberoende av varandra, så det totala antalet händelser per tidsenhet har då fördelningen $\text{Bin}(n, \mu/n)$. Sannolikhetsfunktionen kan skrivas om enligt

$$\begin{aligned} p_X(x) &= \binom{n}{x} \left(\frac{\mu}{n}\right)^x \left(1 - \frac{\mu}{n}\right)^{n-x} \\ &= \frac{n \cdot (n-1) \cdots (n-x+1) \mu^x}{x! n^x} \left(1 - \frac{\mu}{n}\right)^n \left(1 - \frac{\mu}{n}\right)^{-x} \\ &= \frac{\mu^x}{x!} \underbrace{\left(1 - \frac{\mu}{n}\right)^n}_{\rightarrow e^{-\mu} \text{ då } n \rightarrow \infty} \underbrace{\frac{n \cdot (n-1) \cdots (n-x+1)}{n^x}}_{\rightarrow 1 \text{ då } n \rightarrow \infty} \underbrace{\left(1 - \frac{\mu}{n}\right)^{-x}}_{\rightarrow 1 \text{ då } n \rightarrow \infty}. \end{aligned}$$

Med andra ord, om vi låter $n \rightarrow \infty$, dvs. vi delar upp tidsenheten i mindre och mindre intervall, så får vi sannolikhetsfunktionen

$$p_X(x) = \begin{cases} \frac{\mu^x}{x!} e^{-\mu}, & x = 0, 1, 2, \dots, \\ 0, & \text{annars.} \end{cases}$$

Detta kallas för en *poissonfördelning* och betecknas $\text{Po}(\mu)$.




En generalisering av resonemanget ovan ger att antalet punkthändelser i ett godtyckligt intervall av längd t (till exempel intervallet $[0, t]$) har fördelningen $\text{Po}(\mu t)$. Vi kommer se i nästa föreläsning hur detta kan användas för att bestämma fördelningen för tiden mellan händelser i en poissonmodell.

Till slut återkommer vi till urnmodellen (utan återläggning). Om vi har N kulor totalt, varav Np är blåa (dvs. de blåas relativa frekvens är p) har antalet blåa kulor X vid dragning av n kulor från urnan sannolikhetsfunktionen

$$p_X(x) = \begin{cases} \frac{\binom{Np}{x} \binom{N(1-p)}{n-x}}{\binom{N}{n}}, & x = \max(0, n - N(1-p)), \dots, \min(Np, n) \\ 0, & \text{annars.} \end{cases}$$

Detta är den *hypergeometrisk fördelningen* som betecknas $\text{Hyp}(N, n, p)$.



Föreläsning fyra

Joakim Andén

Repetition

En stokastisk variabel är en funktion som avbildar utfallsrummet Ω på $\mathbb{R}$

$$X : \Omega \rightarrow \mathbb{R}.$$

Om värdemängden $X(\Omega) = \{x(\omega) : \omega \in \Omega\}$ är ändlig eller uppräknligt oändlig sägs X vara en diskret stokastisk variabel. I detta fall kan vi definiera en tillhörande sannolikhetsfunktion

$$p_X(x) = P(X = x) = P(\{\omega \in \Omega : X(\omega) = x\}),$$

vilket kan användas för att beräkna mer komplicerade sannolikheter som bland annat

$$P(X \in A) = \sum_{x \in A} p_X(x).$$

Kontinuerliga stokastiska variabler

Vad gör vi om värdemängden $X(\Omega)$ är ouppräknligt oändlig? Om så är fallet kan vi inte nödvändigtvis tilldela varje värde i $X(\Omega)$ en positiv sannolikhet, eftersom summan av dessa ouppräknligt oändligt många positiva sannolikheter skulle bli oändligt stort. Med andra ord har vi $P(X = x) = 0$.

Istället betraktar vi sannolikheten för ett intervall $P(X \in [a, b])$, dvs. sannolikheten att X ligger i intervallet $[a, b]$. Denna sannolikhet behöver inte nödvändigtvis vara noll, eftersom vi kan beskriva hela $\mathbb{R}$ som en uppräknlig union av små intervall (dvs. $\mathbb{R} = \dots \cup [-1, 0) \cup [0, 1) \cup [1, 2) \cup \dots$). Vad händer nu om vi tar $b = a + h$ och låter h gå mot noll? Då får vi också att $P(X \in [a, a + h])$ går mot noll, eftersom intervallets storlek h blir oändligt litet. Men om vi delar med h , får vi en sorts "sannolikhetstäthet"

$$\frac{P(X \in [a, a + h])}{h}$$

som mäter hur mycket sannolikhet vi har "runt" a per enhet. Om vi låter h gå mot noll i kvoten ovan så borde vi få någon slags infinitesimal täthet som inte är noll. Vi skulle då kunna använda funktionen


$$f(a) = \lim_{h \rightarrow 0} \frac{P(X \in [a, a + h])}{h}$$

för att studera fördelningen av X . Man kan se detta som en slags "derivata" av sannolikheten i för X punkten a .

En alternativ (och mer eller mindre ekvivalent) definition ges om vi istället för en derivata använder en integral för att beskriva sannolikheten. Mer formellt söker vi en funktion $f : \mathbb{R} \rightarrow \mathbb{R}$ så att

$$P(a \leq X \leq b) = \int_a^b f(x) dx,$$

för $a \leq b \in \mathbb{R}$. Om detta gäller kallar vi X för en *kontinuerlig stokastisk variabel*. Funktionen $f(x)$ kallas X 's *täthetsfunktion* och betecknas ofta $f_X(x)$ om den behöver särskiljas från täthetsfunktioner som tillhör andra stokastiska variabler. Sannolikheten att X ligger i ett visst intervall är alltså arean under kurvan för täthetsfunktionen över det intervallet.



Mer generellt kan vi ta en godtycklig delmängd $A \subset \mathbb{R}$ och få

$$P(X \in A) = \int_A f(x) dx.$$

Notera att det inte spelar roll för kontinuerliga stokastiska variabler om vi inkluderar ändpunkterna a och b eller inte. Med andra ord har vi

$$P(a < X < b) = P(a \leq X < b) = P(a \leq X \leq b) = P(a < X \leq b).$$

Detta beror på att sannolikheten att X tar exakt värdet a eller b är noll, så att inkludera dem eller inte ger samma sannolikhet. Detta gäller dock *inte* för diskreta stokastiska variabler eftersom varje värde på X kan ha en nollskild sannolikhet.

Om vi nu återgår till vårt lilla intervall $[a, a + h]$ ser vi att

$$\begin{aligned} \frac{P(X \in [a, a + h])}{h} &= \frac{1}{h} \int_a^{a+h} f(x) dx \\ &= \frac{1}{h} f(a + \theta h) h = f(a + \theta h) \end{aligned}$$

för något $\theta \in [0, 1]$ enligt medelvärdessatsen. Vi ser då att

$$\frac{P(X \in [a, a+h])}{h} = f(a + \theta h) \longrightarrow f(a)$$

då $h \rightarrow 0$, så $f(a)$ motsvarar mycket riktigt vår intuition om sannolikhetens "täthet". (Under vissa förhållanden kan man också visa att denna definition av $f(x)$ implicerar integraldefinitionen ovan.)

Täthetsfunktionen $f_X(x)$ har två viktiga egenskaper:

(i) $f_X(x) \geq 0$ för alla $x \in \mathbb{R}$, och

(ii) $\int_{\mathbb{R}} f_X(x) dx = 1$.


Del (i) kan anses hålla per definition eller visas genom att betrakta gränsvärdet ovan och notera att högerledet alltid är icke-negativt. Del (ii) fås genom

$$\int_{\mathbb{R}} f_X(x) dx = \int_{-\infty}^{+\infty} f_X(x) dx = P(-\infty < X < \infty) = P(\Omega) = 1.$$

Som exempel kan vi ta täthetsfunktionen

$$f_X(x) = \begin{cases} e^{-x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

Vi kan plotta denna som funktion av x .



Funktionen är också positiv ($e^{-x} > 0$ för alla $x \geq 0$) och integrerar till ett:

$$\int_{-\infty}^{+\infty} f_X(x) dx = \int_{-\infty}^0 0 dx + \int_0^{+\infty} e^{-x} dx = 0 + 1 = 1.$$

(Vi kommer att se senare att denna täthetsfunktion tillhör en exponentialfördelning.)

Fördelningsfunktion

Ett annat användbart sätt att beskriva en stokastisk variabel är att betrakta dess *fördelningsfunktion*

$$F_X(x) = P(X \leq x).$$

I det kontinuerliga fallet har vi då

$$F_X(x) = P(X \leq x) = P(X \in (-\infty, x]) = \int_{-\infty}^x f_X(u) du.$$

(Notera att vi måste använda variabeln u i integralen för att x används redan som övre integrationsgräns.) I exemplet ovan med täthetsfunktionen

$$f_X(x) = \begin{cases} e^{-x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

får vi för $x < 0$ att

$$F_X(x) = \int_{-\infty}^x f_X(u) du = \int_{-\infty}^x 0 du = 0$$


medan för $x \geq 0$ gäller

$$F_X(x) = \int_{-\infty}^x f_X(u) du = \int_{-\infty}^0 f_X(u) du + \int_0^x f_X(u) du = \int_{-\infty}^0 0 du + \int_0^x e^{-u} du = 1 - e^{-u},$$

så sammantaget har vi

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1 - e^{-u}, & x \geq 0. \end{cases}$$

Plottar vi den med avseende på x får vi följande figur.



Notera att lutningen i varje punkt är lika med täthetsfunktionen.

Definitionen av $F_X(x)$ ovan gäller också om X är en diskret stokastisk variabel. I detta fall har vi

$$F_X(x) = \sum_{u \in X(\Omega): u \leq x} p_X(u).$$

Eftersom mängden $\{u \in X(\Omega) : u \leq x\}$ är densamma för olika x som ligger mellan de värden som X antar så är fördelningsfunktionen styckvis konstant funktion, också

kallad stegfunktion eller trappfunktion. Varje hopp (eller språng) i $F_X(x)$ motsvarar ett diskret värde som antas av $X(\Omega)$.


Fördelningsfunktionen existerar alltså för både kontinuerliga och diskreta stokastiska variabler och är därför en mer generell beskrivning av X jämfört med sannolikhetsfunktioner och täthetsfunktioner. Man kan, till exempel, definiera blandade stokastiska variabler som har både diskreta och kontinuerliga komponenter (se Blom, m. fl., kap. 3.9). Utöver dessa går det också att definiera stokastiska variabler som inte kan beskrivas som en kombination av kontinuerliga och diskreta stokastiska variabler, men som har en fördelningsfunktion, så kallade singulära fördelningar. Ingen av dessa typer av stokastiska variabler kommer att studeras i kursen.

Som exempel på fördelningsfunktion för en diskret stokastisk variabel betraktar vi $X \sim U(\{1, 2\})$. Den har sannolikhetsfunktionen

$$p_X(x) = \begin{cases} 1/2, & x = 1, 2, \\ 0, & \text{annars} \end{cases}$$

medan fördelningsfunktionen är

$$F_X(x) = \begin{cases} 0, & x < 1 \\ 1/2, & 1 \leq x < 2 \\ 1, & 2 \leq x. \end{cases}$$



Notera att fördelningsfunktionen inte nödvändigtvis är kontinuerlig, men uppfyller

$$\lim_{x \rightarrow a^+} F_X(x) = F_X(a)$$

i alla punkter a , dvs. att gränsvärdet högerifrån överensstämmer med funktionsvärdet. En sådan funktion kallas *högerkontinuerlig* (eller *kontinuerlig till höger*). Fördelningsfunktionen för en kontinuerlig stokastisk variabel är också kontinuerlig i den vanliga bemärkelsen (dvs. kontinuerlig både från höger och från vänster).

Eftersom $F_X(x)$ för en kontinuerlig stokastisk variabel ges av integralen av $f_X(x)$ kan vi vända på relationen genom integralkalkylens fundamentalsats, vilket ger

$$f_X(x) = \frac{d}{dx} F_X(x).$$

Vi kan åstadkomma en liknande relation för diskreta stokastiska variabler, men formen på denna beror på värdemängden $X(\Omega)$ hos X . Om vi har $X(\Omega) = \mathbb{Z}_{\geq 0}$ får vi

$$p_X(x) = \begin{cases} F_X(0), & x = 0 \\ F_X(x) - F_X(x-1), & x = 1, 2, 3, \dots \end{cases}$$

Fördelningsfunktioner uppfyller ett par andra egenskaper:

- (i) $F_X(x) \rightarrow 0$ då $x \rightarrow -\infty$,
- (ii) $F_X(x) \rightarrow 1$ då $x \rightarrow +\infty$, och
- (iii) $F_X(x)$ är växande (icke-avtagande) med avseende på x , dvs. att för $a \geq b$ har vi $F_X(a) \leq F_X(b)$.

Del (i) och (ii) följer från faktumet att $P(\emptyset) = 0$ och $P(\Omega) = 1$. Del (iii) fås eftersom givet $a \leq b$ har vi $\{X \leq a\} \subset \{X \leq b\}$, vilket ger $P(X \leq a) \leq P(X \leq b)$, dvs. $F_X(a) \leq F_X(b)$.

En annan användbar egenskap som gäller för både diskreta och kontinuerliga variabler är följande sats.

Sats 1. Om $a < b$ har vi

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

Bevis. Intervallet $(-\infty, b]$ kan skrivas som unionen av de disjunkta intervallen $(-\infty, a]$ och $(a, b]$. Händelserna $X \in (-\infty, a]$ och $X \in (a, b]$ är alltså oförenliga och vi får

$$P(X \in (-\infty, b]) = P(X \in (-\infty, a]) + P(X \in (a, b])$$

vilket, genom insättning av definitionerna av $F_X(a)$ och $F_X(b)$, ger

$$F_X(b) = F_X(a) + P(X \in (a, b]).$$

Genom att subtrahera $F_X(a)$ från båda leden fås den önskade identiteten. □


Notera att faktumet att intervallet $(a, b]$ är halvöppet spelar roll för diskreta stokastiska variabler (där sannolikheten $P(X = a) \neq 0$), men inte för kontinuerliga stokastiska variabler. I det senare fallet kan vi ersätta med ett öppet $((a, b))$ eller stängt intervall $[a, b]$, dvs.

$$P(a \leq X \leq b) = P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = F_X(b) - F_X(a)$$

Vi kan också använda fördelningsfunktionen för att bestämma ett värde på x som ger en viss sannolikhet att X ligger under eller över x . Ofta är vi intresserade av α -kvantilen, vilket är det värde på x som ger att sannolikheten $P(X > x) = \alpha$, dvs. att $F_X(x) = P(X \leq x) = 1 - \alpha$. Vi betecknar α -kvantilen ofta x_α och anger α vanligtvis i procent. Vissa kvantiler har speciella namn:

- (i) $x_{0.25}$, eller 25%-kvantilen, kallas den *övre kvartilen*,

- (ii) $x_{0.50}$, eller 50%-kvantilen, kallas *medianen*, och
- (iii) $x_{0.75}$, eller 75%-kvantilen, kallas den *undre kvartilen*.



Notera att tekniskt sätt är definitionen ovan inte entydig eftersom det kan finnas flera x så att $F_X(x) = 1 - \alpha$ för något givet α om $F_X(x)$ är konstant vid dessa x . Man kan då tala om att x är en (av flera) α -kvantiler (eller medianer, övre kvartiler, osv.). Definitionen kommer dock vara entydig för fördelningarna som studeras i kursen.

Kontinuerliga fördelningar

Om X antar ett värde i intervallet $[a, b]$ med lika stor sannolikhet för varje värde får vi

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & \text{annars.} \end{cases}$$

Värdet $1/(b-a)$ för $x \in [a, b]$ får vi eftersom $f_X(x)$ ska integreras till ett. Mycket riktigt ser vi att


$$\begin{aligned} \int_{-\infty}^{\infty} f_X(x) dx &= \int_{-\infty}^a f_X(x) dx + \int_a^b f_X(x) dx + \int_b^{+\infty} f_X(x) dx \\ &= \int_{-\infty}^a 0 dx + \int_a^b \frac{1}{b-a} dx + \int_b^{+\infty} 0 dx \\ &= 0 + \frac{1}{b-a}(b-a) + 0 = 1, \end{aligned}$$

där vi är tvungna att dela upp integralen i tre delar eftersom $f_X(x)$ är styckvis kontinuerlig med diskontinuiteter i a och b .

På samma sätt kan vi beräkna fördelningsfunktionen

$$\begin{aligned}
 F_X(x) &= \int_{-\infty}^x f_X(u) du \\
 &= \begin{cases} \int_{-\infty}^x 0 du, & x < a \\ \int_{-\infty}^a 0 du + \int_a^x \frac{1}{b-a} du, & a \leq x \leq b \\ \int_{-\infty}^a 0 du + \int_a^b \frac{1}{b-a} du + \int_b^x 0 du, & x > b \end{cases} \\
 &= \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}
 \end{aligned}$$

Vi betecknar att X är likformigt fördelat på $[a, b]$ genom $X \sim U([a, b])$ eller $X \sim U(a, b)$.



Låt oss nu återgå till poissonmodellen som introducerades i föregående föreläsning. Vi har då en viss typ av händelser som inträffar oberoende av varandra och med en viss intensitet λ per tidsenhet. Vi är nu intresserade av tiden tills första händelsen inträffar, eller, ekvivalent formulerat, tiden mellan två händelser. (Dessa är ekvivalenta eftersom händelserna i en poissonmodell inträffar oberoende av varandra, därför spelar det ingen roll vad för startpunkt vi tar för mätningen.)

Vi noterar nu att medelantalet händelser i tidsintervallet $[0, t]$ är λt . Antalet händelser i det intervallet har då fördelningen $Po(\lambda t)$. Till varje tidpunkt t kan vi då fästa en stokastisk variabel X_t som har fördelningen $Po(\lambda t)$. (En sådan sekvens av stokastiska variabler kallas en stokastisk process, mer specifikt en poissonprocess, men vi kommer inte att diskutera detta djupare i kursen.) Om vi nu låter T vara en stokastisk variabel som svarar mot tidpunkten för den första händelsen kan vi beräkna dess fördelningsfunktion genom att notera identiteten $\{T \leq t\} = \{X_t \geq 1\}$. Detta följer eftersom $T \leq t$ motsvarar att tidpunkten för den första händelsen är mindre än t , vilket betyder att minst en händelse har inträffat på intervallet $[0, t]$, dvs. att $X_t \geq 1$. Vi får då för $t \geq 0$ att

$$F_T(t) = P(T \leq t) = P(X_t \geq 1) = 1 - P(X_t = 0) = 1 - p_{X_t}(0) = 1 - \frac{(\lambda t)^0}{0!} e^{-\lambda t} = 1 - e^{-\lambda t}.$$

Om vi deriverar med avseende på t får vi

$$f_T(t) = \frac{d}{dt}F_T(t) = \lambda e^{-\lambda t}.$$


För $t < 0$ är sannolikheten noll, vilket ger täthetsfunktionen

$$f_T(t) = \begin{cases} \lambda e^{-\lambda t}, & t \geq 0 \\ 0, & t < 0. \end{cases}$$

Fördelningsfunktionen såg vi en bit av ovan och är

$$F_T(t) = \begin{cases} 0, & t < 0 \\ 1 - e^{-\lambda t}, & t \geq 0. \end{cases}$$

Den stokastiska variabeln T sägs då vara *exponentialfördelad*, vilket skrivs $T \sim \text{Exp}(\lambda)$.



En viktig egenskap hos exponentialfördelningen är dess minneslöshet, vilken säger att sannolikheten att vänta en viss tid t utöver den tid vi redan har väntat a inte beror på a . Vi kan beskriva detta med hjälp av den betingade sannolikheten

$$P(T > a + t | T > a),$$

dvs. sannolikheten att vi väntar minst $a + t$ givet att vi redan väntat a . Vi har då

$$\begin{aligned} P(T > a + t | T > a) &= \frac{P(T > a + t, T > a)}{P(T > a)} && \text{(definition av betingad sannolikhet)} \\ &= \frac{P(T > a + t)}{P(T > a)} && (T > a + t \Rightarrow T > a) \\ &= \frac{1 - P(T \leq a + t)}{1 - P(T \leq a)} && \text{(komplement)} \\ &= \frac{1 - F_T(a + t)}{1 - F_T(a)} && \text{(definition av fördelningsfunktion)} \\ &= \frac{e^{-\lambda(a+t)}}{e^{-\lambda a}} && (F_T(t) = 1 - e^{-\lambda t}) \\ &= e^{-\lambda t} = 1 - F_T(t) = P(T > t), \end{aligned}$$

där vi har använt oss av den förkortade beteckningen $P(\{T > a + t\} \cap \{T > a\}) = P(T > a + t, T > a)$ och faktumet att $\{T > a + t\} \cap \{T > a\} = \{T > a + t\}$ (om $T > a + t$ har vi garanterat att $T > a$). Sannolikheten är därför densamma att vi väntar t utöver a som att vi väntar t överhuvudtaget. Detta kan verka kontraintuitivt, men stämmer väl överens med poissonmodellen vi antagit. Närmare bestämt så inträffar händelserna oberoende av varandra, därför kan nästa inte händelse "minnas" när den senaste inträffade.

Precis som poissonmodellen generaliserar den ändliga binomialmodellen till ett kontinuum så generaliserar exponentialfördelningen den geometriska fördelningen (eller omvänt, den geometriska fördelningen är en diskret variant av exponentialfördelningen). Den geometriska fördelningen har samma minneslöshetsegenskap: låt oss säga att vi räknar antalet tärningskast till vi observerar en etta. Denna stokastiska variabel har fördelning $\text{Ge}(1/6)$. Om vi slår ett antal kast och inte får en etta så påverkar det inte antalet kast utöver dessa som vi måste slår till vi får en etta. Tanken är densamma för exponentialfördelningen, men i ett kontinuum.


En generalisering av exponentialfördelningen fås om vi lägger till en faktor $t^{\alpha-1}$ i täthetsfunktionen, vilket ger

$$f_T(t) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} t^{\alpha-1} e^{-\lambda t}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

där $\Gamma(\alpha)$ syftar på gammafunktionen

$$\Gamma(\alpha) = \int_0^{+\infty} u^{\alpha-1} e^{-u} du$$


definierad för $\alpha > 0$. Denna funktion har för övrigt flera intressanta egenskaper, som att $\Gamma(1) = 1$, $\Gamma(n) = (n-1)!$ och att $\Gamma(1/2) = \sqrt{\pi}$. Om T har denna fördelningen kallas den *gammafördelad*, vilket betecknas $X \sim \text{Gamma}(c, \lambda)$. Med $c = 1$ återfår vi exponentialfördelningen. Gammafördelningen för ett heltal $\alpha = n$ motsvarar tiden vi behöver vänta för att n stycken händelser ska inträffa i poissonmodellen som vi diskuterade ovan.



Den sista kontinuerliga fördelningen vi diskuterar är *normalfördelningen*, som har täthetsfunktionen

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-\mu)^2/2\sigma^2},$$

där μ och σ är parametrarna till fördelningen. Att X har denna fördelning betecknas med $X \sim N(\mu, \sigma^2)$. Vi kommer inte att säga något mer utöver detta eftersom vi diskuterar normalfördelningen i mer i detalj under senare föreläsningar.



Föreläsning fyra bis

Joakim Andén

Differentialkalkyl i flera variabler


En vanlig (endimensionell funktion) $f(x)$ kan approximeras lokalt med en linjär funktion – en tangentlinje. Detta görs med hjälp av dess derivata

$$\frac{df}{dx}f(a) = \lim_{h \rightarrow 0} \frac{f(a+h) - f(a)}{h}.$$

Vi har då att

$$y = f(a) + \frac{df}{dx}(x - a)$$

bildar en tangentlinje för kurvan $y = f(x)$ vid punkten $x = a$.




På samma sätt kan vi betrakta en tvådimensionell funktion $f(x, y)$ som tar en punkt $(x, y) \in \mathbb{R}^2$ till ett värde $z = f(x, y) \in \mathbb{R}$. Istället för en kurva får vi en yta $z = f(x, y)$ i tre dimensioner och istället för en tangentlinje får vi ett *tangentplan* i $(x, y) = (a, b)$. Denna är given av

$$z = f(a, b) + \frac{\partial f}{\partial x}(a, b)(x - a) + \frac{\partial f}{\partial y}(a, b)(y - b),$$

där vi definierar *partialderivatorna*

$$\frac{\partial f}{\partial x}(a, b) = \lim_{h \rightarrow 0} \frac{f(a+h, y) - f(a, b)}{h} \quad \frac{\partial f}{\partial y}(a, b) = \lim_{h \rightarrow 0} \frac{f(a, b+h) - f(a, b)}{h}.$$



För att beräkna dessa använder vi samma räkneregler som för vanliga derivator och håller den andra variabeln konstant. Till exempel, om $f(x, y) = x^3 + xy + e^{-y}$ har vi

$$\frac{\partial f}{\partial x}(x, y) = 3x^2 + y \quad \frac{\partial f}{\partial y}(x, y) = x - e^{-y}.$$

Ibland kombineras partialderivatorna i en vektor

$$\nabla f(a, b) = \begin{bmatrix} \frac{\partial f}{\partial x}(a, b) \\ \frac{\partial f}{\partial y}(a, b) \end{bmatrix}$$

som kallas *gradienten* av $f(x, y)$ i punkten $(x, y) = (a, b)$. I exemplet ovan har vi då gradienten

$$\nabla f(a, b) = \begin{bmatrix} 3x^2 + y \\ x - e^{-y} \end{bmatrix}.$$


Om vi återkommer till envariabelfallet så ser vi att *kritiska punkter* kan identifieras då $df/dx = 0$, dvs. då tangentlinjen är parallell med x-axeln. På samma sätt identifieras kritiska punkter i två variabler då tangentplanet är parallellt med xy-planet. Detta inträffar endast då båda partialderivatorna är noll, dvs. att gradienten är noll. För funktionen $f(x, y) = 1 - x^2 - y^2 + xy$ har vi

$$\frac{\partial f}{\partial x}(x, y) = -2x + y \quad \frac{\partial f}{\partial y}(x, y) = -2y + x.$$

Om vi sätter dessa till noll och löser det resulterande ekvationssystemet får vi den kritiska punkten $(x, y) = (0, 0)$.

Hur bestämmer vi om den kritiska punkten är ett lokalt maximum, lokalt minimum eller någonting annat? Ett sätt är att använda andraderivator (i det flerdimensionella fallet bildar dessa den så kallade *hessianen*). Ett annat är att använda algebraiska relationer för att förenkla problemet och ersätta det med ett optimeringsproblem i en dimension.


Integralkalkyl i flera variabler




Om $f(x, y)$ är positiv motsvarar *dubbelintegralen*

$$\iint_D f(x, y) dx dy$$

volymen mellan grafen $z = f(x, y)$ och $D \subset \mathbb{R}^2$.



För fallet då D är en rektangel $D = R = \{(x, y) \in \mathbb{R}^2 : a \leq x \leq b, c \leq y \leq d\}$ kan vi definiera en rektangelpartition $a = x_0 < x_1 < \dots < x_n = b, c = y_0 < y_1 < \dots < y_n = d$. Om vi betraktar ett rektangelement $[x_i, x_{i+1}] \times [y_j, y_{j+1}]$ har vi att utrymmet mellan det elementet och ytan $z = f(x, y)$ kan approximeras av ett *prisma* med rektangeln som bas och höjd $f(x^*, y^*)$, där $x^* \in [x_i, x_{i+1}]$ och $y^* \in [y_j, y_{j+1}]$.



För enkelhets skull tar vi $x^* = x_i$ och $y^* = y_j$, vilket ger ett prisma med volym

$$f(x_i, y_j)(x_{i+1} - x_i)(y_{j+1} - y_j).$$

Vi kan förenkla ytterligare genom att anta att alla element i partitionen är lika stora. I så fall har vi $x_{i+1} - x_i = \Delta x = (b - a)/n$ för alla $i = 0, 1, \dots, n-1$ och $y_{j+1} - y_j = \Delta y = (d - c)/n$ för alla $j = 0, 1, \dots, n-1$. Detta ger då volymen

$$f(x_i, y_j)\Delta x\Delta y.$$

Om vi lägger ihop alla dessa volymapproximationer får vi summan

$$I_n = \sum_{i=0}^{n-1} \sum_{j=0}^{n-1} f(x_i, y_j)\Delta x\Delta y.$$

Detta är *riemannsumman* för den givna rektangelpartitionen.


Om gränsvärdet för I_n då $n \rightarrow +\infty$ existerar (vilket det gör för "snälla" funktioner) definierar vi dubbelintegralen som detta värde:

$$\iint_R f(x, y)dx dy = \lim_{n \rightarrow +\infty} I_n.$$

Vi kan visa att denna integral kan beräknas antingen genom att först integrera längs x , sedan längs y eller först längs y , sedan längs x :

$$\iint_R f(x, y)dx dy = \int_{y=c}^d \left(\int_{x=a}^b f(x, y)dx \right) dy = \int_{x=a}^b \left(\int_{y=c}^d f(x, y)dy \right) dx.$$


(Parenteserna är bara här för tydlighet och behövs egentligen inte.) Detta kallas *Fubinis sats*.



Om D inte är en rektangel definierar vi funktionen

$$\tilde{f}(x, y) = \begin{cases} f(x, y), & (x, y) \in D \\ 0, & \text{annars,} \end{cases}$$


för $(x, y) \in R$ där R är en rektangel som innesluter D . Vi utökar alltså $f(x, y)$ till en funktion $\tilde{f}(x, y)$ på R genom att lägga till nollor utanför D .



Vi kan nu definiera integralen av $f(x, y)$ över D :

$$\iint_D f(x, y) dx dy = \iint_R \tilde{f}(x, y) dx dy.$$

Vi noterar att funktionen $\tilde{f}(x, y)$ nu är diskontinuerlig på randen av D , men så länge randen är tillräckligt slät så är högerledet väldefinierat.



Svårighetsgraden för beräkning av dubbelintegraler beror delvis på integranden, men också på formen på integrationsområdet D . Vi kallar integrationsområdet D *y-enkelt* om det finns a, b och funktioner $g_1(x), g_2(x)$ så att


$$D = \{(x, y) : a \leq x \leq b, g_1(x) \leq y \leq g_2(x)\}.$$

I detta fall kan vi beräkna dubbelintegralen enligt definitionen ovan genom att först

integrera längs y och sedan längs x :

$$\begin{aligned}
 \iint_D f(x, y) dx dy &= \iint_R \tilde{f}(x, y) dx dy \\
 &= \int_{x=a}^b \int_{y=c}^d \tilde{f}(x, y) dy dx \\
 &= \int_{x=a}^b \left(\int_{y=c}^{g_1(x)} \tilde{f}(x, y) dy + \int_{y=g_1(x)}^{g_2(x)} \tilde{f}(x, y) dy + \int_{y=g_2(x)}^d \tilde{f}(x, y) dy \right) dx \\
 &= \int_{x=a}^b \left(0 + \int_{y=g_1(x)}^{g_2(x)} f(x, y) dy + 0 \right) dx \\
 &= \int_{x=a}^b \int_{y=g_1(x)}^{g_2(x)} f(x, y) dy,
 \end{aligned}$$

där vi har utnyttjat faktumet att för ett fixt x kan vi dela upp $[c, d]$ längs y i tre intervall: $[c, g_1(x)]$, $[g_1(x), g_2(x)]$ och $[g_2(x), d]$. På det första och sista intervallet är $\tilde{f}(x, y) = 0$ per definition (eftersom $(x, y) \notin D$) samt i det andra intervallet har vi $\tilde{f}(x, y) = f(x, y)$ (eftersom $(x, y) \in D$).



Vi kan också ha ett x -enkelt integrationsområde D om det finns c, d och funktioner $h_1(y), h_2(y)$ så att

$$D = \{(x, y) : h_1(y) \leq x \leq h_2(y), c \leq y \leq d\}.$$

Om detta håller kan vi integrera först längs x , sedan längs y , vilket ger

$$\iint_D f(x, y) dx dy = \int_{y=c}^d \int_{x=h_1(y)}^{h_2(y)} f(x, y) dx dy.$$


Dubbelintegralerna i denna kurs kommer vara över antingen x -enkla eller y -enkla integrationsområden eller över integrationsområden som kan delas upp i x -enkla eller y -enkla integrationsområden.

För att illustrera, låt $f(x, y) = e^{-x-y}$ och

$$D = \{(x, y) : x, y \geq 0, x + y \leq 1\}.$$

Det visar sig att D är både x -enkelt och y -enkelt:

$$D = \{(x, y) : 0 \leq x \leq 1, 0 \leq y \leq 1 - x\} = \{(x, y) : 0 \leq x \leq 1 - y, 0 \leq y \leq 1\}.$$



Vi väljer att först integrera längs y först, sedan längs x . Detta ger

$$\begin{aligned}
 \iint_D f(x, y) dx dy &= \int_{x=0}^1 \int_{y=0}^{1-x} e^{-x-y} dy dx \\
 &= \int_{x=0}^1 \left[\frac{e^{-x-y}}{-1} \right]_{y=0}^{1-x} dx \\
 &= \int_{x=0}^1 -e^{-1} + e^{-x} dx \\
 &= -e^{-1} + \left[\frac{e^{-x}}{-1} \right]_{x=0}^1 = -e^{-1} - e^{-1} + 1 = 1 - 2e^{-1} \approx 0.26.
 \end{aligned}$$

Definitionerna ovan gäller för begränsade integrationsområden D . Om D är obegränsad kan vi beräkna dubbelintegralen som ett gränsvärde

$$\iint_D f(x, y) dx dy = \lim_{N \rightarrow +\infty} \iint_{D \cap [-N, N]^2} f(x, y) dx dy.$$

Dessa integraler kan beräknas på samma sätt som ovan om D är x -enkel (då $a(y)$, $b(y)$, c , d tillåts vara oändligt stora) eller y -enkel (då a , b , $c(x)$, $d(x)$ tillåts vara oändligt stora).

Som exempel, låt oss integrera

$$f(x, y) = \begin{cases} e^{-|x+y|}, & 0 \leq x \leq 1 \\ 0, & \text{annars.} \end{cases}$$

över $\mathbb{R}^2$. Funktionen är nollskild över $[0, 1] \times \mathbb{R}$, så det räcker att integrera över denna domän. Den är både x -enkel och y -enkel så vi integrerar först med avseende

på y och sedan x . Vi får då

$$\begin{aligned}\iint_{\mathbb{R}^2} f(x, y) dx dy &= \int_{x=0}^1 \int_{y=-\infty}^{+\infty} e^{-|x+y|} dy dx \\&= \int_{x=0}^1 \left(\int_{y=-\infty}^{-x} e^{-|x+y|} dy + \int_{y=-x}^{+\infty} e^{-|x+y|} dy \right) dx \\&= \int_{x=0}^1 \left(\int_{y=-\infty}^{-x} e^{x+y} dy + \int_{y=-x}^{+\infty} e^{-x-y} dy \right) dx \\&= \int_{x=0}^1 \left([e^{x+y}]_{y=-\infty}^{-x} + [-e^{-x-y}]_{y=-x}^{+\infty} \right) dx \\&= \int_{x=0}^1 (1 + 1) dx = 2,\end{aligned}$$

där vi har utnyttjat att $|x + y| = -x - y$ för $y < -x$ och $|x + y| = x + y$ för $y > -x$.

Föreläsning fem

Joakim Andén

Repetition

En stokastisk variabel är en funktion som avbildar utfallsrummet Ω på $\mathbb{R}$

$$X : \Omega \rightarrow \mathbb{R}.$$

Om värdemängden $X(\Omega)$ är ändlig eller uppräkneligt oändlig sägs X vara en diskret stokastisk variabel. Vi har då en sannolikhetsfunktion

$$p_X(x) = P(X = x).$$

Om den stokastiska variabeln inte är diskret, men det finns en funktion $f_X(x)$ så att

$$P(X \in A) = \int_A f_X(x) dx$$

säger vi att X är en kontinuerlig stokastisk variabel med täthetsfunktion $f_X(x)$.

Funktioner av stokastiska variabler

Om vi har en stokastisk variabel X och vill beräkna en funktion av denna $Y = g(X)$. Det kan röra sig om att vi har mätt en längden på en kvadrat och vill beräkna arean. Eftersom vi har ett visst mätfel kan det då vara intressant att se hur mätfelet fortplantar sig i areavärdet.

I fallet då både X och Y är diskreta stokastiska variabler finns ett enkelt tillvägagångssätt: för varje värde y som Y antar, lägg ihop sannolikheterna för det värdet x på X vars avbildning $g(x)$ är lika med y . Med andra ord har vi en sannolikhetstabell för X som vi omvandlar till en sannolikhetstabell för Y . Formellt kan detta skrivas

$$p_Y(y) = \sum_{x:g(x)=y} p_X(x).$$

Om Y är diskret men X är kontinuerlig blir det lite mer arbete, men vi kan fortfarande konstruera en sannolikhetstabell för Y enligt samma princip. Vi har då

$$p_Y(y) = P(g(X) = y) = \int_{\{x:g(x)=y\}} f_X(x) dx.$$

När Y är kontinuerlig kan vi inte längre konstruera en sannolikhetsstabell utan måste använda en annan metod. Om vi försöker beräkna fördelningsfunktionen för Y får vi

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y).$$

Vi skulle nu vilja omvandla denna olikhet $g(X) \leq y$ på $g(X)$ till en olikhet på X . Om $g(x)$ har en invers $g^{-1}(y)$ kan vi göra detta. Så är fallet om $g(x)$ är strikt monoton, dvs. strikt växande eller strikt avtagande. Då har vi följande sats.

Sats 1. Låt $g(x)$ vara strikt monoton och låt X vara en kontinuerlig stokastisk variabel. Då gäller att

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|.$$

Bevis. Vi antar först att $g(x)$ är strikt växande. I så fall har vi att

$$g(x) \leq y \Leftrightarrow x \leq g^{-1}(y),$$

vilket ger

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = P(X \leq g^{-1}(y)) = F_X(g^{-1}(y)).$$

Om vi deriverar med avseende på y och använder kedjeregeln får vi

$$f_Y(y) = \frac{d}{dx} F_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y) = f_X(g^{-1}(y)) \cdot \frac{d}{dy} g^{-1}(y).$$

Eftersom $g(x)$ är växande har vi att dess derivata är positiv, vilket ger

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|.$$

Om $g(x)$ är strikt avtagande gäller

$$g(x) \leq y \Leftrightarrow x \geq g^{-1}(y).$$

Samma kalkyl ger då

$$F_Y(y) = 1 - F_X(g^{-1}(y))$$

och vi får tätheten

$$f_Y(y) = f_X(g^{-1}(y)) \cdot -\frac{d}{dy} g^{-1}(y).$$

En avtagande funktion har en negativ derivata, så dess negation är positiv. Eftersom $g(x)$ är avtagande är dess invers $g^{-1}(y)$ också avtagande så vi får

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|.$$

□

Det går också att beräkna täthetsfunktioner och fördelningsfunktioner för andra $g(x)$ som inte är strikt monotona. Då kan vi dela upp funktionen i mindre intervall på vilka den är monoton och arbeta med dem. Nyckeln är oavsett att arbeta med fördelningsfunktionen istället för att försöka sig på täthetsfunktionen direkt.

Tvådimensionella stokastiska variabler


Vid ett slumpmässigt försök kan vi erhålla mer än ett värde. Till exempel, om vi drar en slumpmässig bowlingboll kan vi associera flera värden:

- vikten i kg (värde i $\mathbb{R}_{>0}$),
- volymen i m^3 (värde i $\mathbb{R}_{>0}$),
- färgen som röd–grön–blå-trippel (RGB) (värde i $[0, 1] \times [0, 1] \times [0, 1]$),
- och så vidare.

Låt oss säga att vi tar vikten X och volymen Y . Dessa bildar då en avbildning (X, Y) från utfallsrummet Ω (av möjliga bowlingbollar) på $\mathbb{R} \times \mathbb{R} = \mathbb{R}^2$. Med andra ord, för varje utfall ω (bowlingboll) har vi $X(\omega)$ (vikten) och $Y(\omega)$ (volymen). Vi kan då betrakta sannolikheten att $(X, Y) \in A$ för någon delmängd $A \subset \mathbb{R}^2$,

$$P((X, Y) \in A) = P(\{\omega \in \Omega : (X(\omega), Y(\omega)) \in A\}),$$

och säger att (X, Y) bildar en *tvådimensionell stokastisk variabel*.



Av speciellt intresse är sannolikheten att (X, Y) ligger i delmängden $\{(u, v) : u \leq x, v \leq y\}$, dvs. funktionen

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$$

som kallas *fördelningsfunktionen* för X, Y (eller den *simultana fördelningsfunktionen*).

Vi noterar att detta kan också utvidgas till fler än två variabler. Detta ger då flerdimensionella stokastiska variabler. Till exempel kan vi ha avbildningen som tar ett utfall $\omega \in \Omega$ och tilldelar den en trippel $(X(\omega), Y(\omega), Z(\omega))$. Detta gäller också begreppen vi introducerar nedan i två dimensioner – de kan ofta generaliseras på ett naturligt sätt till tre eller högre dimensioner.

Diskreta tvådimensionella stokastiska variabler

Om värdemängderna $X(\Omega)$ och $Y(\Omega)$ båda är ändliga eller uppräknligt oändliga kallas (X, Y) en *diskret tvådimensionell stokastisk variabel*. Vi kan då definiera *sannolikhetsfunktionen* (den *simultana sannolikhetsfunktionen*)

$$p_{X,Y}(x, y) = P(X = x, Y = y) = P(\{\omega \in \Omega : X(\omega) = x, Y(\omega) = y\}).$$

Som innan kommer vi anta att $X(\Omega) = \mathbb{Z}_{\geq 0}$, $Y(\Omega) = \mathbb{Z}_{\geq 0}$, dvs. att X och Y antar icke-negativa heltal $0, 1, 2, \dots$ som värden. Alla resultat gäller naturligtvis också i det mer generella fallet.

Vi kan nu beräkna

$$P((X, Y) \in A) = \sum_{(x,y) \in A} p_{X,Y}(x, y)$$

$$F_{X,Y}(x, y) = \sum_{u \leq x} \sum_{v \leq y} p_{X,Y}(u, v).$$

Sannolikhetsfunktionen har egenskaperna

(i) $p_{X,Y}(x, y) \in [0, 1]$, och

(ii) $\sum_{x=0}^{+\infty} \sum_{y=0}^{+\infty} p_{X,Y}(x, y) = 1$.

Låt oss säga att vi har en tvådimensionell stokastisk variabel (X, Y) , men vi inte är intresserade av värdet på Y – det kan vara vad som helst. I det fallet vill vi ha fördelningen för enbart X . Eftersom vi arbetar med diskreta stokastiska variabler betraktar vi sannolikhetsfunktionen $p_X(x)$. Denna kan fås från den simultana sannolikhetsfunktionen $p_{X,Y}(x, y)$ genom följande identitet:

$$p_X(x) = P(X = x) = P(X = x, Y \in \mathbb{R}) = \sum_{y=0}^{+\infty} p_{X,Y}(x, y).$$

Detta är den *marginella sannolikhetsfunktionen* för X . Vi säger också att fördelningen för X är *marginalfördelningen* för X med avseende på den tvådimensionella stokastiska variabeln (X, Y) . På samma sätt ges den marginella sannolikhetsfunktionen för Y av

$$p_Y(y) = \sum_{x=0}^{+\infty} p_{X,Y}(x, y).$$

Kontinuerliga tvådimensionella stokastiska variabler

På samma sätt som vi inte kan definiera en sannolikhetsfunktion för endimensionella stokastiska variabler när värdemängden är ouppräkneligt stor kan vi inte heller göra detta i det tvådimensionella fallet. Vi måste därför betrakta "tätheten", sannolikheten per areaenhet, hos sannolikhetsmåttet i olika punkter. Om (X, Y) är en tvådimensionell stokastisk variabel och det finns en funktion $f_{X,Y}(x, y)$ så att

$$P((X, Y) \in A) = \iint_A f_{X,Y}(x, y) dx dy$$

säger vi att (X, Y) är en *kontinuerlig tvådimensionell stokastisk variabel* med *täthetsfunktionen* $f_{X,Y}(x, y)$ (kallas också den *simultana täthetsfunktionen*)

Om detta gäller har vi fördelningsfunktionen

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y) = \int_{u=-\infty}^x \int_{v=-\infty}^y f_{X,Y}(u, v) dv du.$$

Vi kan beräkna täthetsfunktionen utifrån fördelningsfunktionen genom att derivera med avseende på x och y och tillämpa integralkalkylens fundamentalsats två gånger (en gång på x och en gång på y):


$$\begin{aligned}\frac{\partial}{\partial y} \left(\frac{\partial}{\partial x} F_{X,Y}(x, y) \right) &= \frac{\partial}{\partial y} \left(\frac{\partial}{\partial x} \int_{u=-\infty}^x \int_{v=-\infty}^y f_{X,Y}(u, v) dv du \right) \\ &= \frac{\partial}{\partial y} \int_{v=-\infty}^y f_{X,Y}(x, v) dv \\ &= f_{X,Y}(x, y).\end{aligned}$$

Vi har alltså

$$f_{X,Y}(x, y) = \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x, y).$$

Täthetsfunktionen har egenskaperna

- $f_{X,Y}(x, y) \geq 0$, och
- $\iint_{\mathbb{R}^2} f_{X,Y}(x, y) dx dy = 1$.



Som för det diskreta fallet kan vi definiera de kontinuerliga marginalfördelningarna för X och Y som har täthetsfunktionerna


$$f_X(x) = \int_{y=-\infty}^{+\infty} f_{X,Y}(x, y) dy \quad \text{och} \quad f_Y(y) = \int_{x=-\infty}^{+\infty} f_{X,Y}(x, y) dx.$$

Ett exempel på en kontinuerlig tvådimensionell fördelning är den *likformiga fördelningen* över D som har täthetsfunktion

$$f_{X,Y}(x, y) = \begin{cases} \frac{1}{\iint_D dx dy}, & (x, y) \in D \\ 0, & \text{annars,} \end{cases}$$

där $\iint_D dx dy$ helt enkelt är arean av D .

Notera att det också finns tvådimensionella stokastiska variabler som varken är diskreta eller kontinuerliga (i alla fall enligt definitionen ovan). Det kan vara att vi kombinerar en kontinuerlig stokastisk variabel X (bowlingbollens vikt) med en diskret stokastisk variabel (antal hål i bowlingbollen).



Vi kan också stöta på singulära fördelningar som inte kan skrivas som en sådan kombination, till exempel den likformiga fördelningen över enhetscirkeln $\{(x, y) : x^2 + y^2 = 1\}$. För $A = \{(x, y) : a \leq x \leq b, c \leq y \leq d\}$ med $b, d > 1$ och $a, c \in [0, \sqrt{2}]$ har vi då

$$P((X, Y) \in A) = \frac{\cos^{-1}(a) - \sin^{-1}(c)}{2\pi},$$

vilket inte kan skrivas som en dubbelintegral av någon funktion $f_{X,Y}(x, y)$ över A .

Oberoende stokastiska variabler

Antag att vi har en tvådimensionell stokastisk variabel (X, Y) . Låt oss vidare anta att vi vet att om X antar ett visst värde så påverkar inte detta fördelningen för Y och vice versa. Med andra ord "beror inte" Y på X eller X på Y .

Beskriver vi detta med händelser får vi att för alla $A, B \subset \mathbb{R}$ är händelserna

$$\{X \in A\} = \{\omega \in \Omega : X(\omega) \in A\} \quad \text{och} \quad \{Y \in B\} = \{\omega \in \Omega : Y(\omega) \in B\}$$

oberoende – att den ena inträffar påverkar inte sannolikheten att den andra inträffar. Detta ger då

$$P(X \in A, Y \in B) = P(\{X \in A\} \cap \{Y \in B\}) = P(X \in A)P(Y \in B).$$


Om vi tar $A = (-\infty, x]$ och $B = (-\infty, y]$ får vi en relation mellan den simultana och de marginella fördelningsfunktionerna:

$$\begin{aligned} P(X \leq x, Y \leq y) &= P(X \leq x)P(Y \leq y) \\ F_{X,Y}(x, y) &= F_X(x)F_Y(y). \end{aligned}$$

Antag nu att vi har kontinuerliga stokastiska variabler. Deriverar vi denna relation med avseende på x och y får vi täthetsfunktionen

$$\begin{aligned} f_{X,Y}(x,y) &= \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x,y) \\ &= \frac{\partial}{\partial x} \left(\frac{\partial}{\partial y} F_X(x) F_Y(y) \right) \\ &= \frac{\partial}{\partial x} F_X(x) f_Y(y) \\ &= f_X(x) f_Y(y), \end{aligned}$$

dvs. den simultana täthetsfunktionen faktoriseras i de marginella täthetsfunktionerna.



En naturlig definition är då att två kontinuerliga stokastiska variabler X och Y anses vara *oberoende* om

$$f_{X,Y}(x,y) = f_X(x) f_Y(y).$$

Vi kan visa att detta är ekvivalent med att händelserna ovan är oberoende.

Sats 2. De kontinuerliga stokastiska variablerna X och Y är oberoende om och endast om, för varje $A, B \subset \mathbb{R}$

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B).$$

Bevis. Om X och Y är oberoende har vi

$$\begin{aligned}
 P(X \in A, Y \in B) &= P((X, Y) \in A \times B) \\
 &= \iint_{A \times B} f_{X,Y}(x, y) dx dy \\
 &= \int_{x \in A} \int_{y \in B} f_X(x) f_Y(y) dy dx \\
 &= \int_{x \in A} f_X(x) \int_{y \in B} f_Y(y) dy dx \\
 &= \int_{x \in A} f_X(x) P(Y \in B) dx \\
 &= P(X \in A) P(Y \in B).
 \end{aligned}$$

Den andra riktningen fås genom att följa resonemanget ovan för motiveringen av definitionen för oberoende kontinuerliga stokastiska variabler. $\square$

På liknande sätt säger vi att de två diskreta stokastiska variablerna X och Y är *oberoende* om

$$p_{X,Y}(x, y) = p_X(x)p_Y(y).$$

Även i detta fall kan vi visa att denna definition är ekvivalent med att de associerade händelserna är oberoende.

Ett vanligt förfarande inom sannolikheteeteorin och statistiken är att vi använder oberoenderelationen för att kombinera olika stokastiska variabler. Med andra ord så är det ofta lämpligt att två värden mäts eller på annat sätt produceras oberoende av varandra, till exempel genom repeterade experiment. Detta gör det enkelt att bilda den simultana stokastiska variabeln, man behöver då bara multiplicera täthetsfunktionerna eller sannolikhetsfunktionerna.

Exempel 3. Antag att vi kastar en tärning två gånger och låt X vara antalet ögon i första kastet och Y vara antalet ögon i andra kastet. Då har vi två oberoende diskreta stokastiska variabler med den simultana sannolikhetsfunktionen

$$p_{X,Y}(x, y) = p_X(x)p_Y(y) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36}.$$

för $x, y \in \{1, 2, \dots, 6\}$.

Exempel 4. Antag att vi har två glödlampor med livslängd i timmar fördelade enligt $\text{Exp}(1)$. Vi tänder den ena lampan och väntar tills den går ut, sedan tänder vi den andra. Vad är sannolikheten att den totala brinntiden (dvs. från att vi tänt den första tills den andra har gått ut) är mindre än en timme?


Vi har två oberoende stokastiska variabler $X \sim \text{Exp}(1)$ och $Y \sim \text{Exp}(1)$. Deras simultana täthetsfunktion är då

$$f_{X,Y}(x, y) = f_X(x)f_Y(y) = e^{-x}e^{-y} = e^{-x-y},$$

vilket ger den sökta sannolikheten

$$\begin{aligned} P(X + Y \leq 1) &= P(\{(X, Y) \in \{(x, y) : x, y \geq 0, x + y \leq 1\}\}) \\ &= \iint_D f_{X,Y}(x, y) dx dy, \end{aligned}$$

där $D = \{(x, y) : x, y \geq 0, x + y \leq 1\}$.



Vi konstaterar att denna domän är både y -enkel och kan skrivas

$$D = \{(x, y) : 0 \leq x \leq 1, 0 \leq y \leq 1 - x\},$$

så vi väljer att först integrera längs y först, sedan längs x . Detta ger

$$\begin{aligned} \iint_D f(x, y) dx dy &= \int_{x=0}^1 \int_{y=0}^{1-x} e^{-x-y} dy dx \\ &= \int_{x=0}^1 \left[\frac{e^{-x-y}}{-1} \right]_{y=0}^{1-x} dx \\ &= \int_{x=0}^1 -e^{-1} + e^{-x} dx \\ &= -e^{-1} + \left[\frac{e^{-x}}{-1} \right]_{x=0}^1 = -e^{-1} - e^{-1} + 1 = 1 - 2e^{-1} \approx 0.26. \end{aligned}$$

Vi kan utvidga båda dessa definitioner till fler än två stokastiska variabler. Om vi till exempel har tre stokastiska variabler X , Y och Z är de oberoende om

$$\begin{aligned} p_{X,Y,Z}(x, y, z) &= p_X(x)p_Y(y)p_Z(z) && \text{(diskreta fallet)} \\ f_{X,Y,Z}(x, y, z) &= f_X(x)f_Y(y)f_Z(z) && \text{(kontinuerliga fallet)} \end{aligned}$$

Minimum och maximum

Har vi flera oberoende stokastiska variabler kan vi kombinera dem på olika sätt. Till och börja med kan vi beräkna deras minsta och största värden.

Sats 5. Låt X och Y vara oberoende stokastiska variabler (diskreta eller kontinuerliga). Om $U = \min(X, Y)$ och $V = \max(X, Y)$ har vi

$$\begin{aligned} F_U(u) &= 1 - (1 - F_X(u))(1 - F_Y(u)) \\ F_V(v) &= F_X(v)F_Y(v). \end{aligned}$$

Bevis. Vi börjar med V eftersom det är lite enklare. Fördelningsfunktionen är då

$$\begin{aligned} F_V(v) &= P(V \leq v) \\ &= P(\max(X, Y) \leq v) \\ &= P(X \leq v, Y \leq v) = F_{X,Y}(v, v) = F_X(v)F_Y(v) \end{aligned}$$

eftersom X och Y är oberoende.

För U konstaterar vi att $\min(X, Y) \leq u$ är samma sak som att *inte* X och Y båda är större än u . Detta ger då, med hjälp av De Morgans lagar,

$$\begin{aligned} F_U(u) &= P(U \leq u) \\ &= P(\min(X, Y) \leq u) \\ &= P(X \leq u \text{ eller } Y \leq u) \\ &= 1 - P(X \geq u, Y \geq u) \\ &= 1 - P(X \geq u)P(Y \geq u) \\ &= 1 - (1 - F_X(u))(1 - F_Y(u)), \end{aligned}$$

där näst sista raden fås eftersom händelserna $\{X \geq u\}$ och $\{Y \geq u\}$ är oberoende. $\square$

Vi kan utvidga detta till fler än två oberoende stokastiska variabler. Om vi också antar att alla har samma fördelning får vi

$$F_{\min(X_1, X_2, \dots, X_n)}(x) = 1 - (1 - F_{X_1}(x))^n \quad \text{och} \quad F_{\max(X_1, X_2, \dots, X_n)}(x) = (F_{X_1}(x))^n.$$

Exempel 6. Låt $X \sim U([0, 1])$, vilket ger

$$F_X(x) = \begin{cases} x, & x \in [0, 1] \\ 0, & \text{annars.} \end{cases}$$

Om vi har n oberoende kopior $X_1, X_2, \dots, X_n$ och definierar $U = \min(X_1, X_2, \dots, X_n)$ samt $V = \max(X_1, X_2, \dots, X_n)$ får vi

$$F_U(x) = \begin{cases} 1 - (1 - x)^n, & x \in [0, 1] \\ 0, & \text{annars} \end{cases}$$

vilket ger

$$f_U(x) = \begin{cases} n(1 - x)^{n-1}, & x \in [0, 1] \\ 0, & \text{annars.} \end{cases}$$

och

$$F_V(x) = \begin{cases} x^n, & x \in [0, 1] \\ 0, & \text{annars} \end{cases}$$

vilket ger

$$f_V(x) = \begin{cases} nx^{n-1}, & x \in [0, 1] \\ 0, & \text{annars.} \end{cases}$$

Föreläsning sex


Joakim Andén

Summa av stokastiska variabler

Givet två oberoende stokastiska variabler X och Y kan vi betrakta fördelningen hos summan $Z = X + Y$. Låt oss först anta att X och Y är diskreta. I så fall har vi

$$\begin{aligned} p_Z(z) &= P(Z = z) = P(X + Y = z) \\ &= \sum_{x,y \geq 0: x+y=z} p_{X,Y}(x,y) \\ &= \sum_{x=0}^z p_{X,Y}(x, z-x) \\ &= \sum_{x=0}^z p_X(x)p_Y(z-x), \end{aligned}$$

eftersom händelsen $\{X + Y = z\}$ är den (disjunkta) unionen av alla händelser $\{X = x, Y = y\}$ så att $x + y = z$.



Detta kallas för den *diskreta faltningsformeln*. (En *faltning* är en operation som förekommer i många olika sammanhang, från polynommultiplikation till modellering

av hålrumsresonatorer inom akustiken eller diffraktionsmönster inom optiken.) Falt-ningsformeln är kommutativ och vi kan därför skriva den på två sätt:

$$p_{X+Y}(z) = \sum_{x=0}^z p_X(x)p_Y(z-x) = \sum_{y=0}^z p_X(z-y)p_Y(y).$$

Sats 1. Låt X, Y vara oberoende stokastiska variabler med fördelning $\text{Bin}(n, p)$ respektive $\text{Bin}(m, p)$. Då har $Z = X + Y$ fördelningen $\text{Bin}(n + m, p)$.

Bevis. Vi har

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x} \quad \text{och} \quad p_Y(y) = \binom{m}{y} p^y (1-p)^{m-y}.$$

Sannolikhetsfunktionen för Z är då

$$\begin{aligned} p_Z(z) &= \sum_{y=0}^z p_X(z-y)p_Y(y) \\ &= \sum_{y=0}^z \binom{n}{z-y} p^{z-y} (1-p)^{n-z+y} \cdot \binom{m}{y} p^y (1-p)^{m-y} \\ &= p^z (1-p)^{n+m-z} \sum_{i=0}^k \binom{n}{z-y} \binom{m}{y}. \end{aligned}$$

Summan kan förenklas genom *Vandermondes identitet*

$$\binom{n+m}{k} = \sum_{i=0}^k \binom{n}{k-i} \binom{m}{i}.$$

vilket ger

$$p_Z(z) = \binom{n+m}{z} p^z (1-p)^{n+m-z},$$

som skulle visas.

Vandermondes identitet visas genom att dra k kulor från en samling med n blåa och m röda kulor. Vi kan ta k blåa kulor och noll röda kulor, vilket kan göras på $\binom{n}{k} \binom{m}{0}$ olika sätt. Eller så kan vi ta $k-1$ blåa kulor och en röda kula, vilket görs på $\binom{n}{k-1} \binom{m}{1}$ sätt. Eller så tar vi $k-2$ blåa kulor och två röda kulor, vilket ger $\binom{n}{k-2} \binom{m}{2}$ sätt, och så vidare. Totalt sett har vi

$$\sum_{i=0}^k \binom{n}{k-i} \binom{m}{i}$$

sätt att välja k kulor på detta vis. Men om vi struntar i färgen och bara tar k kulor bland alla $n+m$ kulor kan detta göras på

$$\binom{n+m}{k}$$

sätt, varför identiteten följer. □

Sats 2. Låt X, Y vara oberoende stokastiska variabler med fördelningar $\text{Po}(\mu)$ respektive $\text{Po}(\nu)$. Då har $Z = X + Y$ fördelningen $\text{Po}(\mu + \nu)$.

Bevis. Återigen tillämpar vi faltningsformeln

$$\begin{aligned} p_Z(z) &= \sum_{y=0}^z \frac{\mu^{z-y}}{(z-y)!} e^{-\mu} \cdot \frac{\nu^y}{y!} e^{-\nu} = \frac{e^{-\mu-\nu}}{z!} \sum_{y=0}^z \frac{z!}{(z-y)!y!} \mu^{z-y} \nu^y \\ &= \frac{e^{-\mu-\nu}}{z!} \sum_{y=0}^z \binom{z}{y} \mu^{z-y} \nu^y = \frac{e^{-(\mu+\nu)}}{z!} (\mu + \nu)^z, \end{aligned}$$


där vi i sista raden tillämpat *binomialsatsen*

$$(x + y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k}.$$

□

För kontinuerliga stokastiska variabler X och Y har vi att summan Z har fördelningsfunktionen

$$\begin{aligned} F_Z(z) &= P(Z \leq z) = P(X + Y \leq z) \\ &= \iint_{\{(x,y): x+y \leq z\}} f_{X,Y}(x,y) dx dy = \iint_{\{(x,y): x+y \leq z\}} f_X(x) f_Y(y) dx dy. \end{aligned}$$



Integrationsområdet $\{(x,y) : x + y \leq z\}$ kan skrivas om som $\{(x,y) : y \leq z - x\}$,

vilket ger

$$\begin{aligned} F_Z(z) &= \int_{x=-\infty}^{+\infty} \int_{y=-\infty}^{z-x} f_X(x)f_Y(y)dydx \\ &= \int_{x=-\infty}^{+\infty} f_X(x) \int_{y=-\infty}^{z-x} f_Y(y)dydx \\ &= \int_{x=-\infty}^{+\infty} f_X(x)F_Y(z-x)dx. \end{aligned}$$

Om vi nu deriverar med avseende på z får vi täthetsfunktionen

$$\begin{aligned} f_Z(z) &= \frac{\partial}{\partial z} F_Z(z) = \frac{\partial}{\partial z} \int_{x=-\infty}^{+\infty} f_X(x)F_Y(z-x)dx \\ &= \int_{x=-\infty}^{+\infty} f_X(x) \frac{\partial}{\partial z} F_Y(z-x)dx \\ &= \int_{x=-\infty}^{+\infty} f_X(x)f_Y(z-x)dx, \end{aligned}$$

vilket kallas den *kontinuerliga faltningsformeln*. Som innan är denna relation kommutativ och vi har således

$$f_{X+Y}(z) = \int_{x=-\infty}^{+\infty} f_X(x)f_Y(z-x)dx = \int_{y=-\infty}^{+\infty} f_X(z-y)f_Y(y)dy.$$

Med hjälp av faltningsformlerna kan vi nu visa ett par användbara resultat gällande summor av vissa oberoende och identiskt fördelade stokastiska variabler.

Sats 3. Låt $X_1, X_2, \dots, X_n$ vara oberoende stokastiska variabler fördelade enligt $\text{Exp}(\lambda)$. Vi har då att $X_1 + X_2 + \dots + X_n \sim \text{Gamma}(n, \lambda)$.

Bevis. Vi visar detta med induktion på n . Eftersom $\text{Gamma}(1, \lambda)$ är detsamma som $\text{Exp}(\lambda)$ vet vi att satsen gäller för $n = 1$.

Antag nu att den gäller för $n-1$. Vi har då att $Y = X_1 + X_2 + \dots + X_{n-1} \sim \text{Gamma}(n-1, \lambda)$, dvs.

$$f_Y(y) = \frac{\lambda^{n-1}}{\Gamma(n-1)} y^{n-2} e^{-\lambda y} \quad \text{för } y \geq 0.$$

Om $Z = X_1 + X_2 + \dots + X_n = Y + X_n$ får vi då, enligt faltningsformeln,

$$f_Z(z) = \int_{y=-\infty}^{+\infty} f_Y(y)f_{X_n}(z-y)dy = \int_{y=0}^z f_Y(y)f_{X_n}(z-y)dy$$

där vi har kunnat ersätta integrationsgränserna med 0 och z eftersom $f_Y(y) = 0$ för $y < 0$ och $f_{X_n}(z-y) = 0$ för $y > z$. Vi sätter in formelerna för täthetsfunktionerna $f_Y(y)$

och $f_{X_n}(x)$, vilket ger

$$\begin{aligned} f_Z(z) &= \int_{y=0}^z f_Y(y) f_{X_n}(z-y) dy \\ &= \int_{y=0}^z \frac{\lambda^{n-1}}{\Gamma(n-1)} y^{n-2} e^{-\lambda y} \cdot \lambda e^{-\lambda(z-y)} dy \\ &= \frac{\lambda^n}{\Gamma(n-1)} e^{-\lambda z} \int_{y=0}^z y^{n-2} dy \\ &= \frac{\lambda^n}{\Gamma(n-1)} e^{-\lambda z} \frac{z^{n-1}}{n-1} = \frac{\lambda^n}{\Gamma(n)} z^{n-1} e^{-\lambda z}, \end{aligned}$$

eftersom $\Gamma(n) = (n-1)\Gamma(n-1)$. □

Betingade fördelningar

Om vi har två stokastiska variabler (dvs. en tvådimensionell stokastisk variabel) och vi vet att en av dem har ett visst utfall, hur påverkar det fördelningen hos den andra? Vi stötte på en liknande fråga tidigare när det gäller sannolikheten för olika händelser. Där definierade vi den betingade sannolikheten $P(A|B)$ att A inträffar givet att B redan har inträffat.

För att översätta denna definition till stokastiska variabler låter vi X och Y vara två diskreta stokastiska variabler och betraktar händelserna $\{X = x\}$ samt $\{Y = y\}$. Vi bildar då den betingade sannolikheten

$$P(X = x|Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)} = \frac{p_{X,Y}(x, y)}{p_Y(y)},$$

där vi har satt in definitionen på sannolikhetsfunktionerna $p_{X,Y}(j, k)$ samt $p_Y(y)$. Detta ger då en naturlig definition på den *betingade sannolikhetsfunktion* för X givet $Y = y$:

$$p_{X|Y=y}(x) = \frac{p_{X,Y}(x, y)}{p_Y(y)},$$

Precis som de betingade sannolikheter $P(A|B)$ vi såg innan har dessa betingade sannolikhetsfunktioner ett antal användbara egenskaper:

$$p_{X,Y}(x, y) = p_{X|Y=y}(x) p_Y(y)$$

$$p_X(x) = \sum_{y=0}^{+\infty} p_{X|Y=y}(x) p_Y(y) \quad (\text{lagen om total sannolikhet})$$

$$p_{X|Y=y}(x) = \frac{p_{Y|X=y}(x) p_X(x)}{p_Y(y)} \quad (\text{Bayes sats})$$

Utöver detta beter sig de betingade sannolikhetsfunktionerna precis som vanliga sannolikhetsfunktioner så länge man håller betingningen $Y = y$ fix. Med andra ord

har vi fördelningar för funktioner $g(X)$ av betingade stokastiska variabler X givet $Y = y$. Vi har den betingade diskreta faltningsformeln för summor av betingade stokastiska variabler, och så vidare.

Exempel 4. Låt (X, Y) vara två diskreta stokastiska variabler med simultan sannolikhetsfunktion vars värden ges av

$$\begin{aligned} p_{X,Y}(1, 1) &= 2/18 & p_{X,Y}(1, 2) &= 1/18 & p_{X,Y}(1, 3) &= 3/18 \\ p_{X,Y}(2, 1) &= 1/18 & p_{X,Y}(2, 2) &= 4/18 & p_{X,Y}(2, 3) &= 1/18 \\ p_{X,Y}(3, 1) &= 0 & p_{X,Y}(3, 2) &= 1/18 & p_{X,Y}(3, 3) &= 5/18 \end{aligned}$$

och som är noll för andra värden på (x, y) . Vi kan då beräkna marginalfördelningen för X :

$$\begin{aligned} p_X(1) &= p_{X,Y}(1, 1) + p_{X,Y}(1, 2) + p_{X,Y}(1, 3) = 6/18 = 1/3 \\ p_X(2) &= \dots = 1/3 \\ p_X(3) &= \dots = 1/3. \end{aligned}$$

Med andra ord är X likformigt fördelad över $\{1, 2, 3\}$. Om vi betingar med avseende på $Y = 1$ får vi en annan fördelning. Först har vi att

$$p_Y(1) = p_{X,Y}(1, 1) + p_{X,Y}(2, 1) + p_{X,Y}(3, 1) = 1/6,$$

vilket ger

$$\begin{aligned} p_{X|Y=1}(1) &= (2/18)/(1/6) = 2/3 \\ p_{X|Y=1}(2) &= (1/18)/(1/6) = 1/3 \\ p_{X|Y=1}(3) &= 0/(1/6) = 0. \end{aligned}$$

Så om vi bara observerar X (oavsett värde på Y) får vi en likformig fördelning, medan om vi redan observerat $Y = 1$ så har vi större sannolikhet att få $X = 1$ och mindre sannolikhet att få $X = 3$. Vad händer om vi istället hade observerat $Y = 3$?

För kontinuerliga stokastiska variabler blir det mer komplicerat eftersom den betingande händelsen $\{Y = y\}$ har sannolikhet noll (och därför också sannolikheten för händelsen $\{X \leq x, Y = y\}$). Sannolikheten $P(X \leq x | Y = y)$ är därför inte väldefinierad. En utväg är att konstatera att vi egentligen aldrig har $Y = y$ för en kontinuerlig variabel – detta skulle motsvara att vi känner till Y 's utfall till oändlig precision, vilket inte är möjligt. Om något så vet vi att $Y = y$ med en viss precision, till exempel att $Y \in [y, y + \Delta y]$ för något $\Delta y > 0$.

Vi kan då skriva

$$\begin{aligned} P(X \leq x | Y \in [y, y + \Delta y]) &= \frac{P(X \leq x, Y \in [y, y + \Delta y])}{P(Y \in [y, y + \Delta y])} \\ &= \frac{\int_{u=-\infty}^x \int_{v=y}^{y+\Delta y} f_{X,Y}(u, v) dv du}{\int_{v=y}^{y+\Delta y} f_Y(v) dv}. \end{aligned}$$

Om vi använder medelvärdessatsen får vi att det finns två $\theta_1, \theta_2 \in [0, 1]$ så att integralerna med avseende på v kan skrivas om

$$\int_{v=y}^{y+\Delta y} f_{X,Y}(u, v) dv = f_{X,Y}(u, y + \theta_1 \Delta y) \Delta y$$

$$\int_{v=y}^{y+\Delta y} f_Y(v) dv = f_Y(y + \theta_2 \Delta y) \Delta y.$$

Vi sätter nu in dessa i sannolikhetsuttrycket ovan och får

$$P(X \leq x | Y \in [y, y + \Delta y]) = \frac{\int_{u=-\infty}^x f_{X,Y}(u, y + \theta_1 \Delta y) \Delta y du}{f_Y(y + \theta_2 \Delta y) \Delta y}$$

$$= \frac{\int_{u=-\infty}^x f_{X,Y}(u, y + \theta_1 \Delta y) du}{f_Y(y + \theta_2 \Delta y)}.$$

Ett av problemen är nu löst: sannolikheterna i täljaren och nämnaren är både väldigt små när Δy är litet, men båda är proportionerliga med Δy så deras proportion är nollskild.

Vi kan nu låta $\Delta y \rightarrow 0$ och får då

$$\lim_{\Delta y \rightarrow 0} P(X \leq x | Y \in [y, y + \Delta y]) = \frac{\int_{u=-\infty}^x f_{X,Y}(u, y) du}{f_Y(y)},$$


vilket är en sorts fördelningsfunktion för X givet " $Y = y$ ". Vi kan derivera denna med avseende på x för att få en tillhörande täthetsfunktion

$$\frac{\partial}{\partial x} \frac{\int_{u=-\infty}^x f_{X,Y}(u, y) du}{f_Y(y)} = \frac{f_{X,Y}(x, y)}{f_Y(y)},$$

enligt integralkalkylens fundamentalsats. Detta ger då en naturlig definition för den *betingade täthetsfunktionen* för X givet $Y = y$,

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)},$$

som också överstämmer på formen med den betingade sannolikhetsfunktionen. (Tyvärr är inte denna definition helt oproblematisk. Gränsvärdet som togs ovan kan ibland göras på flera sätt, vilket leder till olika betingade täthetsfunktioner. Detta kallas Borel–Kolmogorovs paradox. I de flesta fall, och de fall som uppstår i kursen, kommer definitionen ovan dock inte ställa till några problem.)



Som i det diskreta fallet har vi ett antal användbara egenskaper hos denna betingade täthetsfunktion:

$$f_{X,Y}(x, y) = f_{X|Y=y}(x)f_Y(y)$$

$$f_X(x) = \int_{y=-\infty}^{+\infty} f_{X|Y=y}(x)f_Y(y)dy \quad (\text{lagen om total sannolikhet})$$

$$f_{X|Y=y}(x) = \frac{f_{Y|X=x}(y)f_X(x)}{f_Y(y)} \quad (\text{Bayes sats})$$

På samma sätt betar sig de betingade täthetsfunktionerna som vanliga (obetingade) täthetsfunktioner, givet att $Y = y$ hålls fixt. Vi har betingade fördelningsfunktioner $F_{X|Y=y}(x)$ som kan användas till att beskriva fördelningen hos betingade maximum $F_{\max(X_1, X_2)|Y=y}(x) = F_{X_1|Y=y}(x)F_{X_2|Y=y}(x)$. Vi kan också betrakta betingade summor av stokastiska variabler, och så vidare.

Exempel 5. Låt oss anta att (X, Y) är slumpmässiga punkter på enhetsskivan $\{(x, y) : x^2 + y^2 \leq 1\} \subset \mathbb{R}^2$. Med andra ord har vi täthetsfunktionen

$$f_{X,Y}(x, y) = \begin{cases} \frac{1}{\pi}, & x^2 + y^2 \leq 1 \\ 0, & \text{annars,} \end{cases}$$

eftersom enhetsskivan har area π . Notera att vi kan skriva definitionen på enhetsskivan som

$$\{(x, y) : -1 \leq y \leq 1, -\sqrt{1-y^2} \leq x \leq \sqrt{1-y^2}\}.$$

Marginalfördelningen $f_Y(y)$ med avseende på Y blir nu då

$$f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx = \int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}} \frac{1}{\pi} dx = \frac{2\sqrt{1-y^2}}{\pi},$$

för $-1 \leq y \leq 1$ och noll annars eftersom värden på y utanför intervallet $[-1, 1]$ ger att den simultana täthetsfunktionen $f_{X,Y}(x, y)$ blir noll. Alltså har y större sannolikhet att vara nära noll än nära ett eller minus ett. Detta är naturligt då enhetsskivan är "tjockare" (sett från y -axeln) nära noll. På samma sätt fås också


$$f_X(x) = \frac{2\sqrt{1-x^2}}{\pi}$$

för $-1 \leq x \leq 1$ och noll annars.

Den betingade täthetsfunktionen för X givet $Y = y$ är då

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{\frac{1}{\pi}}{\frac{2\sqrt{1-y^2}}{\pi}} = \frac{1}{2\sqrt{1-y^2}},$$

för $-\sqrt{1-y^2} \leq x \leq \sqrt{1-y^2}$ och noll annars (då täljaren är noll för x utanför detta intervall). Detta är den likformiga fördelningen över intervallet $[-\sqrt{1-y^2}, \sqrt{1-y^2}]$.



Eftersom vi började med en (tvådimensionell) likformig fördelning så är det naturligt att den betingade fördelningen också är likformig, eftersom vi endast håller den ena variabeln (y) fix medan vi betraktar den andra (x), som då fortsätter att vara likformigt fördelad.

Notera att den betingade täthetsfunktionen för X givet $Y = y$ skiljer sig markant från den marginella täthetsfunktionen för X . Den senare avser tätheten för X oavsett värdet på Y medan den tidigare avser tätheten för X givet ett visst värde på Y .

Vi har nu också en alternativ definition för oberoende stokastiska variabler. De stokastiska variablerna X och Y är oberoende om och endast om

$$\begin{aligned} p_{X|Y=y}(x) &= p_X(x) && \text{(diskret)} \\ f_{X|Y=y}(x) &= f_X(x). && \text{(kontinuerlig)} \end{aligned}$$

Väntevärde

Antag att vi har en stokastisk variabel X . Hur X beter sig beskrivs som bekant av dess fördelning, antingen genom en sannolikhetsfunktion eller en täthetsfunktion. Ibland kan det vara användbart att beskriva X med endast ett värde som sammanfattar dess beteende. Till exempel, kan det vara användbart att veta vad X tar för värde "i genomsnitt". Med andra ord, om vi repeterar samma slumpförsök, skriver ner de olika utfallen hos X , vad blir medelvärdet?

Exempel 6. Låt oss anta att vid ett tärningskast får vi följande vinster:

Tärning	1	2	3	4	5	6
Vinst	1 kr	2 kr	2 kr	4 kr	4 kr	4 kr

Vad är medelvinsten? Alternativt, vad är ett rimligt pris för att delta i spelet?

Låt X beteckna vinsten vid ett tärningskast. Detta är en diskret stokastisk variabel som tar värden i $\{1, 2, 4\}$ och har sannolikhetsfunktion

$$p_X(x) = \begin{cases} 1/6, & x = 1 \\ 1/3, & x = 2 \\ 1/2, & x = 4 \\ 0, & \text{annars.} \end{cases}$$

Enligt frekvenstolkningen av sannolikheten förväntar vi oss att om vi slår ett stort antal tärningskast så kommer vi att vinna en krona $1/6$ av gångerna, två kronor $1/3$ av gångerna och fyra kronor $1/2$ av gångerna. I medel vinner vi då

$$\frac{1}{6} \cdot 1 + \frac{1}{3} \cdot 2 + \frac{1}{2} \cdot 4 = \frac{17}{6}$$

kronor. Detta är då också ett rimligt pris för att delta i spelet eftersom man då (i genomsnitt) vinner tillbaka lika mycket som man betalat in vid ett stort antal försök. (Troligen vill nog spelarrangören också generera en liten vinst, så hen kanske sätter priset lite högre.)

För en diskret stokastisk variabel X definierar vi då dess väntevärde som

$$E[X] = \sum_{x=0}^{+\infty} x p_X(x).$$

Detta betecknas också μ eller μ_X . Vissa föredrar också att skriva E som $\mathbb{E}$ för att inte förväxla denna med en stokastisk variabel. (Bokstaven E kommer från engelskans "expected value" eller "expectation".)

Exempel 7. Antag att $X \sim \text{Bin}(n, p)$. I detta fall har vi

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x}$$

för $x = 0, 1, \dots, n$ och noll annars. Väntevärdet blir då

$$\begin{aligned}
 E[X] &= \sum_{x=0}^n x \cdot \binom{n}{x} p^x (1-p)^{n-x} \\
 &= \sum_{x=1}^n x \cdot \binom{n}{x} p^x (1-p)^{n-x} && (\text{termen } x=0 \text{ utgår}) \\
 &= \sum_{x=1}^n x \frac{n!}{(n-x)!x!} p^x (1-p)^{n-x} && \left(\text{utveckling av } \binom{n}{x} \right) \\
 &= \sum_{x=1}^n np \frac{(n-1)!}{(n-x)!(x-1)!} p^{x-1} (1-p)^{n-x} && (\text{förkorta } x, \text{ faktorera ut } n \text{ och } p) \\
 &= np \sum_{k=0}^{n-1} \frac{(n-1)!}{(n-1-k)!k!} p^k (1-p)^{n-1-k} && (\text{sätt } k = x-1) \\
 &= np(p + (1-p))^{n-1} = np. && (\text{binomialsatsen})
 \end{aligned}$$

Exempel 8. Låt $X \sim \text{Po}(\mu)$. Då har vi

$$p_X(x) = \frac{\mu^x}{x!} e^{-\mu}$$

för $x = 0, 1, 2, \dots$. Väntevärdet ges av

$$\begin{aligned}
 E[X] &= \sum_{x=0}^{+\infty} x \cdot \frac{\mu^x}{x!} e^{-\mu} = \sum_{x=1}^{+\infty} x \cdot \frac{\mu^x}{x!} e^{-\mu} && (\text{termen } x=0 \text{ utgår}) \\
 &= \sum_{x=1}^{+\infty} \mu \cdot \frac{\mu^{x-1}}{(x-1)!} e^{-\mu} && (\text{förkorta } x, \text{ faktorera ut } \mu) \\
 &= \mu \sum_{k=0}^{+\infty} \frac{\mu^k}{k!} e^{-\mu} && (\text{sätt } k = x-1) \\
 &= \mu. && (\text{sannolikhetsfunktionen summerar till ett})
 \end{aligned}$$

För kontinuerliga variabler ersätter vi summan med en integral och får

$$E[X] = \int_{-\infty}^{+\infty} x f_X(x) dx.$$

I båda fallen kan vi tolka $E[X]$ som "tyngdpunkten" hos massfördelningen som beskrivs av $p_X(x)$ eller $f_X(x)$. Väntevärdet brukar därför kallas för ett *lägesmått* för den stokastiska variabeln X – den beskriver *var* X befinner sig, i genomsnitt. Andra användbara lägesmått är *medianen* $x_{0.50}$ (dvs. 50%-kvantilen) som delar fördelningen i två lika stora (lika sannolika) delar samt *typvärdet*, vilket är det värde på x som maximerar täthetsfunktionen (eller sannolikhetsfunktionen). En nackdel med dessa alternativ är att de inte alltid är entydiga.

Exempel 9. Låt $X \sim \text{Exp}(\lambda)$. Då har vi

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{annars.} \end{cases}$$

Detta ger då väntevärdet

$$\begin{aligned} E[X] &= \int_{x=-\infty}^{+\infty} x f_X(x) dx = \int_{x=0}^{+\infty} x \lambda e^{-\lambda x} dx = \left[\frac{x \lambda e^{-\lambda x}}{-\lambda} \right]_{x=0}^{+\infty} - \frac{\lambda}{-\lambda} \int_{x=0}^{+\infty} e^{-\lambda x} dx \\ &= 0 + \int_{x=0}^{+\infty} e^{-\lambda x} dx = \frac{1}{\lambda}. \end{aligned}$$

Exempel 10. Antag att X har en cauchyfördelning med täthetsfunktion

$$f_X(x) = \frac{1}{\pi} \frac{1}{1+x^2}.$$

En sådan fördelning uppstår, till exempel, om vi delar två oberoende normalfördelade variabler med varandra. Vi ser att integralen av $f_X(x)$ är lika med ett genom substitutionen $x = \tan \theta$. Täthetsfunktionen är symmetrisk runt noll, så det skulle vara ett rimligt "genomsnitt".

Väntevärdet får vi till

$$E[X] = \int_{x=-\infty}^{+\infty} x \cdot \frac{1}{\pi} \frac{1}{1+x^2} dx = \frac{1}{\pi} \int_{x=-\infty}^0 \frac{x}{1+x^2} dx + \frac{1}{\pi} \int_{x=0}^{+\infty} \frac{x}{1+x^2} dx.$$

Båda integralerna divergerar här (den första mot $-\infty$ och den andra mot $+\infty$) så väntevärdet är inte väldefinierat. (Däremot är väntevärdena $E[|X|^p]$ för $p < 1$ väldefinierade.)

Vad betyder detta? Jo, om vi drar olika värden på X så kommer deras fördelning att vara centrerad runt noll, precis som täthetsfunktionen ovan beskriver, men deras medelvärde kommer inte konvergera mot noll. Chansen att vi drar ett mycket stort (positivt eller negativt) värde på X är helt enkelt för stor för att dessa ska ta ut varandra i längden.

Om vi istället använder andra mått för att sammanfatta "genomsnittet" hos X , som medianen eller typvärdet, får vi det "naturliga" svaret noll.

Vi kan också beräkna väntevärden hos funktioner $g(X)$ av en stokastisk variabel X . Eftersom $Y = g(X)$ också är en stokastisk variabel kan vi beräkna dess fördelning och sedan beräkna väntevärdet. Det visar sig att detta inte är nödvändigt. Rent

konkret har vi, för en diskret stokastisk variabel X ,

$$\begin{aligned}
 E[g(X)] &= E[Y] = \sum_{y=0}^{+\infty} y p_Y(y) = \sum_{y=0}^{+\infty} y P(Y = y) \\
 &= \sum_{y=0}^{+\infty} y P(g(X) = y) = \sum_{y=0}^{+\infty} y \sum_{x: g(x)=y} P(X = x) \\
 &= \sum_{y=0}^{+\infty} y \sum_{x: g(x)=y} p_X(x) = \sum_{y=0}^{+\infty} \sum_{x: g(x)=y} g(x) p_X(x) \\
 &= \sum_{x=0}^{+\infty} g(x) p_X(x),
 \end{aligned}$$

där den sista raden fås eftersom $\{x : g(x) = 0\}, \{x : g(x) = 1\}, \dots$ bildar en partition av $\mathbb{Z}_{\geq 0}$.

På liknande sätt har vi för kontinuerliga stokastiska variabler

$$E[g(X)] = \int_{x=-\infty}^{+\infty} g(x) f_X(x) dx.$$

Vi kan också utvidga definitionen så att den innefattar funktioner av två (eller flera) stokastiska variabler:

$$E[g(X, Y)] = \begin{cases} \sum_{x, y=0}^{+\infty} g(x, y) p_{X, Y}(x, y) & \text{(diskreta } X, Y) \\ \int_{x, y=-\infty}^{+\infty} g(x, y) f_{X, Y}(x, y) & \text{(kontinuerliga } X, Y) \end{cases}$$

En mycket användbar egenskap hos väntevärdet är dess linjäritet, dvs. att

$$E[aX + b] = aE[X] + b,$$

vilket följer från faktumet att summor och integraler är linjära samt att $\sum_{x=0}^{+\infty} p_X(x) = 1$ och $\int_{x=-\infty}^{+\infty} f_X(x) dx = 1$. Med två variabler X, Y har vi på liknande sätt att $E[aX + bY + c]$ är lika med

$$\begin{aligned}
 &\int \int_{x, y=-\infty}^{+\infty} (ax + by + c) f_{X, Y}(x, y) dx dy \\
 &= \int \int_{x, y=-\infty}^{+\infty} ax f_{X, Y}(x, y) dx dy + \int \int_{x, y=-\infty}^{+\infty} by f_{X, Y}(x, y) dx dy + \int \int_{x, y=-\infty}^{+\infty} cf_{X, Y}(x, y) dx dy \\
 &= a \int_{x=-\infty}^{+\infty} x \int_{y=-\infty}^{+\infty} f_{X, Y}(x, y) dy dx + b \int_{y=-\infty}^{+\infty} y \int_{x=-\infty}^{+\infty} f_{X, Y}(x, y) dx dy + c \\
 &= a \int_{x=-\infty}^{+\infty} x f_X(x) dx + b \int_{y=-\infty}^{+\infty} y f_Y(y) dy + c = aE[X] + bE[Y] + c.
 \end{aligned}$$

Denna identitet gäller också i det diskreta fallet.

Den kan till exempel användas för en alternativ härledning $E[X] = np$ för $X \sim \text{Bin}(n, p)$. Vi noterar först att X kan skrivas som en summa av n oberoende stokastiska variabler, var och en fördelad enligt $\text{Ber}(p)$. Dessa har var och en väntevärdet $1 \cdot p + 0 \cdot (1 - p) = p$, vilket ger att väntevärdet för X är summan av dessa n väntevärden p , dvs. np .

Om X och Y är oberoende har vi att (i det kontinuerliga fallet)


$$\begin{aligned} E[XY] &= \iint_{x,y=-\infty}^{+\infty} xy f_{X,Y}(x,y) dx dy \\ &= \int_{x=-\infty}^{+\infty} \int_{y=-\infty}^{+\infty} xy f_X(x) f_Y(y) dy dx \\ &= \int_{x=-\infty}^{+\infty} x f_X(x) \int_{y=-\infty}^{+\infty} y f_Y(y) dy dx \\ &= \int_{x=-\infty}^{+\infty} x f_X(x) E[Y] dx = E[X] E[Y]. \end{aligned}$$

Båda dessa identiteter gäller också för diskreta variabler och kan generaliseras till fler än två variabler. Till exempel, om $X_1, X_2, \dots, X_n$ är oberoende stokastiska variabler fås

$$E[X_1 X_2 \cdots X_n] = E[X_1] E[X_2] \cdots E[X_n].$$

Varians

Som vi såg ovan är väntevärdet ett lägesmått för den stokastiska variabeln X . Ett annat mått som sammanfattar X är ett spridningsmått. Om väntevärdet indikerar att X befinner sig runt $\mu = E[X]$ så bestämmer ett spridningsmått hur koncentrerad fördelningen är runt μ .



Ett tillvägagångssätt är att betrakta $|X - \mu|$, den stokastiska variabeln som mäter avståndet mellan X och μ . Dess väntevärde $E[|X - \mu|]$ kallas den *genomsnittliga avvikelser* och ger ett vettigt spridningsmått. Vi kan också betrakta medianen av $|X - \mu|$ eller byta ut μ mot $x_{0.50}$. En annan variant är *interkvartilavståndet* $x_{0.25} - x_{0.75}$, dvs. skillnaden mellan 25%-kvantilen och 75%-kvantilen. Alla dessa varianter ger olika spridningsmått. Tyvärr kan dessa vara svåra att beräkna och har inte alltid de egenskaper vi söker.

Istället betraktar vi väntevärdet hos kvadraten $|X - \mu|^2$ av avståndet mellan X och μ . Detta kallas *variansen* och skrivs

$$V[X] = E[|X - \mu|^2] = E[(X - \mu)^2].$$

Ett problem med variansen är att den inte behåller samma enheter som X och μ . Därför tar vi ofta kvadratroten av variansen vilket ger *standardavvikelsen*

$$D[X] = \sqrt{V[X]} = \sqrt{E[(X - \mu)^2]}.$$

Notera att detta *inte* är samma sak som den genomsnittliga avvikelsen $E[|X - \mu|]$. (Vi har faktiskt alltid att $E[|X - \mu|] \leq \sqrt{E[|X - \mu|^2]}$ för alla stokastiska variabler X med väldefinierad varians.) Utöver dessa definierar vi också, för positiva stokastiska variabler X , *variationskoefficienten*

$$R[X] = \frac{D[X]}{E[X]},$$

vilket beskriver den relativa spridningen runt väntevärdet $E[X]$.

För att beräkna variansen använder vi ofta identiteten

$$\begin{aligned} V[X] &= E[(X - \mu)^2] = E[X^2 - 2\mu X + \mu^2] \\ &= E[X^2] - 2\mu E[X] + \mu^2 = E[X^2] - 2\mu \cdot \mu + \mu^2 \\ &= E[X^2] - \mu^2 = E[X^2] - E[X]^2. \end{aligned}$$

Återigen är det viktigt att hålla i sär $E[X^2]$ (väntevärdet av kvadraten) samt $E[X]^2$ (kvadraten av väntevärdet).

Exempel 11. För $X \sim \text{Bin}(n, p)$ behöver vi beräkna $E[X^2]$. Vi använder samma trick som för beräkningen av $E[X]$, dvs. att termen $x = 0$ utgår och att

$$x \binom{n}{x} = x \frac{n!}{(n-x)!x!} = n \frac{(n-1)!}{(n-x)!(x-1)!} = n \binom{n-1}{x-1}.$$

Detta ger då

$$\begin{aligned} E[X^2] &= \sum_{x=0}^n x^2 \binom{n}{x} p^x (1-p)^{n-x} \\ &= \sum_{x=1}^n n p x \binom{n-1}{x-1} p^{x-1} (1-p)^{n-x} \\ &= n p \sum_{k=0}^{n-1} (k+1) \binom{n-1}{k} p^k (1-p)^{n-1-k} & (k = x-1) \\ &= n p \sum_{k=0}^{n-1} k \binom{n-1}{k} p^k (1-p)^{n-1-k} + n p \sum_{k=0}^{n-1} \binom{n-1}{k} p^k (1-p)^{n-1-k} \\ &= n p \cdot (n-1) p + n p \cdot 1 = n(n-1)p^2 + n p, \end{aligned}$$

där den sista raden fås från faktumet att den första summan är väntevärdet hos en $\text{Bin}(n-1, p)$ -fördelad variabel och den andra summan är summan av en sannolikhetsfunktion.

Om vi använder formeln ovan får vi

$$V[X] = E[X^2] - E[X]^2 = n(n-1)p^2 + np - n^2p^2 = -np^2 + np = np(1-p).$$

En liknande beräkning ger att för $X \sim \text{Po}(\mu)$ har vi $E[X^2] = \mu^2 + \mu$, vilket ger $V[X] = E[X^2] - E[X]^2 = \mu^2 + \mu - \mu^2 = \mu$. Variansen för en Poissonfördelad stokastisk variabel är alltså densamma som väntevärdet, μ .

Exempel 12. Vi återkommer till $X \sim \text{Exp}(\lambda)$. Från innan har vi $\mu = E[X] = 1/\lambda$ och får

$$\begin{aligned} E[X^2] &= \int_{x=-\infty}^{+\infty} x^2 f_X(x) dx = \int_{x=0}^{+\infty} x^2 \lambda e^{-\lambda x} dx \\ &= \left[x^2 \frac{\lambda e^{-\lambda x}}{-\lambda} \right]_{x=0}^{+\infty} - \int_{x=0}^{+\infty} 2x \frac{\lambda e^{-\lambda x}}{-\lambda} dx \\ &= 0 + 2 \int_{x=0}^{+\infty} x e^{-\lambda x} dx \\ &= 2 \left[x \frac{e^{-\lambda x}}{-\lambda} \right]_{x=0}^{+\infty} - 2 \int_{x=0}^{+\infty} \frac{e^{-\lambda x}}{-\lambda} dx \\ &= \frac{2}{\lambda} \int_{x=0}^{+\infty} e^{-\lambda x} dx = \frac{2}{\lambda^2}. \end{aligned}$$

Alltså blir variansen

$$V[X] = E[X^2] - E[X]^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

och standardavvikelsen $D[X] = 1/\lambda$. Variationskoefficienten $R[X]$ är då alltid 1.

Om vi tar en enkel linjärtransformation $Y = aX + b$ av X har vi sedan innan

$$\mu_Y = E[Y] = E[aX + b] = aE[X] + b = a\mu_X + b.$$

Variansen blir då

$$\begin{aligned} V[aX + b] &= V[Y] = E[(Y - \mu_Y)^2] = E[(aX + b - (a\mu_X + b))^2] \\ &= E[(aX - a\mu_X)^2] = E[a^2(X - \mu_X)^2] = a^2 E[(X - \mu_X)^2] \\ &= a^2 V[X]. \end{aligned}$$

Med andra ord är variansen *inte* linjär i X . Den ändras inte om vi skiftar X med en konstant b , vilket är en bra egenskap hos ett spridningsmått – det ska inte bero på

läget. Om vi skalar X med en faktor a skalar variansen med kvadraten a^2 . Standardavvikelsen $D(aX + b)$ är däremot $|a|D(X)$, dvs. skalas med $|a|$ (vi får inte en "negativ" spridning bara för att vi multiplicerar med -1 , till exempel).


Hur ser variansen $V(X + Y)$ ut för summan av två stokastiska variabler X och Y ? Har vi också där $V(X + Y) = V(X) + V(Y)$ som i fallet med väntevärdet? Inte nödvändigtvis. Om vi till exempel tar $Y = -X$ så skulle vi då få $V(0) = V(X - X) = V(X) + V(-X) = 2V(X)$, vilket inte verkar särskilt vettigt. Ett fullständigt svar på denna fråga måste därför beakta beroendet mellan X och Y – förstärks eller reduceras spridningen när vi summerar dem?

Föreläsning sju

Joakim Andén

Beroendemått

Vi har tidigare sett att två stokastiska variabler X och Y kan vara oberoende av varandra, dvs. att $f_{X,Y}(x,y) = f_X(x)f_Y(y)$ i det kontinuerliga fallet. Men om variablerna inte är oberoende, kan vi kvantifiera graden av beroende? Inte bara det, men är beroendet "positivt", dvs. att större X medför större Y , eller "negativt", dvs. att större X medför mindre Y ?



Ett sätt att mäta beroendet hos X och Y är att betrakta produkten $(X - \mu_X)(Y - \mu_Y)$. Om produkten oftast tar positiva värden betyder det att när X är stort (större än μ_X) är Y också stort (större än μ_Y) och när X är litet (mindre än μ_X) är Y också litet (mindre än μ_Y). Med andra ord kan vi då säga att X och Y är starkt positivt beroende. Om istället produkten oftast tar negativa värden betyder det att X är stort när Y är litet och vice versa, dvs. att vi har ett starkt negativt beroende. Om produkten tar både positiva och negativa värden, dvs. dess fördelning är centrerad runt noll, så är X och Y svagt beroende.

Vi definierar därför *kovariansen* mellan X och Y som

$$C[X, Y] = E[(X - \mu_X)(Y - \mu_Y)]$$

Detta värde mäter alltså hur X och Y varierar *tillsammans* ("kovarierar"?). Notera att $C[X, X] = V[X]$.

Som innan har vi en användbar identitet för att beräkna kovariansen

$$\begin{aligned} C[X, Y] &= E[(X - \mu_X)(Y - \mu_Y)] = E[XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y] \\ &= E[XY] - \mu_X \mu_Y - \mu_Y \mu_X + \mu_X \mu_Y = E[XY] - \mu_X \mu_Y \\ &= E[XY] - E[X]E[Y]. \end{aligned}$$

Som konsekvens av detta ser vi att om X och Y är oberoende så har vi $E[XY] = E[X]E[Y]$, vilket då ger att $C[X, Y] = 0$.

Om vi delar med standardavvikelserna $D[X]$ och $D[Y]$ får vi *korrelationskoefficienten*

$$\rho[X, Y] = \frac{C[X, Y]}{D[X]D[Y]}.$$

Man kan visa (genom tillämpning av Cauchy-Schwarz olikhet) att $|C[X, Y]| \leq D[X]D[Y]$, vilket ger att $-1 \leq \rho[X, Y] \leq 1$. Om $\rho[X, Y] = 1$ är variablerna maximalt positivt korrelerade medan om $\rho[X, Y] = -1$ är variablerna maximalt negativt korrelerade. Korrelationskoefficienten är ett sätt att beskriva beroendet mellan X och Y utan att ta hänsyn till skala. Om vi multiplicerar X eller Y med en konstant så multipliceras kovariansen $C[X, Y]$ med samma konstant – korrelationskoefficienten $\rho[X, Y]$ är däremot oförändrad. Man säger att korrelationskoefficienten är *skal invariant*.

Exempel 1. Antag att X och Y är diskreta stokastiska variabler så att sannolikhetsfunktionen har värdena

$$\begin{aligned} p_{X,Y}(0,0) &= 1/3 & p_{X,Y}(0,1) &= 1/6 & p_{X,Y}(0,2) &= 0 \\ p_{X,Y}(1,0) &= 0 & p_{X,Y}(1,1) &= 1/6 & p_{X,Y}(1,2) &= 1/3 \end{aligned}$$

och som är noll för andra värden på (x, y) . Då kan vi beräkna marginalfördelningarnas sannolikhetsfunktioner

$$p_X(x) = \begin{cases} 1/2, & x = 0, \\ 1/2, & x = 1, \end{cases}$$

och

$$p_Y(y) = \begin{cases} 1/3, & y = 0, \\ 1/3, & y = 1, \\ 1/3, & y = 2, \end{cases}$$

som alltså är likformiga. Om vi betingar med avseende på $X = 0$ däremot får vi sannolikhetsfunktionen

$$p_{Y|X=0}(y) = \begin{cases} 2/3, & y = 0, \\ 1/3, & y = 1, \\ 0, & y = 2, \end{cases}$$

vilket skiljer sig (markant) från marginalfördelningen $p_Y(y)$. Alltså är X och Y inte oberoende (om så var fallet skulle marginalfördelningen och den betingade fördelningen sammanfalla).

Låt oss nu beräkna kovariansen. Först har vi väntevärdena

$$E[X] = 0 \cdot p_X(0) + 1 \cdot p_X(1) = 0 \cdot \frac{1}{2} + 1 \cdot \frac{1}{2} = \frac{1}{2}$$

och

$$E[Y] = 0 \cdot p_Y(0) + 1 \cdot p_Y(1) + 2 \cdot p_Y(2) = 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} + 2 \cdot \frac{1}{3} = 1.$$

För att beräkna $E[XY]$ kan vi tänka på två sätt. Antingen tar vi varje värde på (x, y) , beräknar $xyp_{X,Y}(x, y)$ och summerar. Eller så identifierar vi de par (x, y) som ger samma produkt xy , lägger ihop deras sannolikheter, och summerar. Paren $(0, 0)$, $(0, 1)$, $(0, 2)$ och $(1, 0)$ ger produkten 0, $(1, 1)$ ger produkten 1 och $(1, 2)$ ger produkten 2, därför får vi

$$E[XY] = 0 \cdot \left(\frac{1}{3} + \frac{1}{6} + 0 + 0 \right) + 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{3} = \frac{5}{6}.$$

Vi har alltså

$$C[X, Y] = \frac{5}{6} - \frac{1}{2} \cdot 1 = \frac{1}{3}.$$

Vi kan också beräkna korrelationskoefficienten. Först har vi $V[X] = 1/4$ och $V[Y] = 1$, vilket ger $D[X] = 1/2$ och $D[Y] = 1$, så

$$\rho[X, Y] = \frac{1/3}{1/2 \cdot 1} = \frac{2}{3}.$$

Variablerna är alltså relativt starkt korrelerade.

Vi säger att X och Y är okorrelerade om $\rho[X, Y] = 0$, dvs. om $C[X, Y] = 0$. Icke-korrelation är en svagare egenskap än oberoende – två stokastiska variabler är okorrelerade om de är oberoende, men två okorrelerade variabler är inte nödvändigtvis oberoende.

Exempel 2. Låt X och Y vara oberoende tvåpunktsfördelade med sannolikhetsfunktioner

$$p_X(x) = \begin{cases} 1/2, & x = 0, 1 \\ 0, & \text{annars,} \end{cases} \quad \text{och} \quad p_Y(y) = \begin{cases} 1/2, & y = -1, 1 \\ 0, & \text{annars.} \end{cases}$$

Produkten $U = XY$ har då sannolikhetsfunktionen

$$p_U(u) = \begin{cases} 1/4, & u = -1, 1 \\ 1/2, & u = 0 \\ 0, & \text{annars.} \end{cases}$$

Vi har då att $E[X] = 1/2$, $E[Y] = 0$ och $E[U] = 0$ samt

$$E[UX] = E[X^2Y] = E[X^2]E[Y] = E[X^2] \cdot 0 = 0,$$

vilket ger $C[U, X] = E[UX] - E[X]E[U] = 0 - 0 = 0$.

Men U och X är inte oberoende. Vi har, till exempel

$$P(U = 1|X = 0) = P(XY = 1|X = 0) = 0 \neq 1/4 = P(U = 1).$$

Med kovariansbegreppet i hand låt oss nu återkomma till variansen av $X + Y$. Vi kan skriva om denna som

$$\begin{aligned} V[X + Y] &= E[(X + Y - (\mu_X + \mu_Y))^2] \\ &= E[((X - \mu_X) + (Y - \mu_Y))^2] \\ &= E[(X - \mu_X)^2 + 2(X - \mu_X)(Y - \mu_Y) + (Y - \mu_Y)^2] \\ &= E[(X - \mu_X)^2] + 2E[(X - \mu_X)(Y - \mu_Y)] + E[(Y - \mu_Y)^2] \\ &= V[X] + V[Y] + 2C[X, Y]. \end{aligned}$$

Kovariansen bestämmer alltså om summan av X och Y kommer att öka eller minska spridningen jämfört med den individuella spridningen hos X och Y . Vårt exempel innan med $Y = -X$ ger då $C[X, Y] = C[X, -X] = -V[X]$, så med identiteten ovan får vi $V[0] = V[X - X] = V[X] + V[-X] + 2C[X, -X] = 2V[X] - 2V[X] = 0$.

Vi kan nu generalisera ovanstående resultat till två identiteter gällande linjärkombinationer av n stokastiska variabler $X_1, X_2, \dots, X_n$. Först har vi

$$E\left[\sum_{i=1}^n a_i X_i + b\right] = \sum_{i=1}^n a_i E[X_i] + b,$$

dvs. väntevärdet av linjärkombinationen är linjärkombinationen av väntevärdena. För variansen har vi

$$V\left[\sum_{i=1}^n a_i X_i + b\right] = \sum_{i=1}^n a_i^2 V[X_i] + 2 \sum_{1 \leq j < k \leq n} a_j a_k C[X_j, X_k],$$

dvs. vi får summan av varianserna plus en korrektion som beror på de parvisa kovarianserna mellan termerna i summan. Notera att korrektionstermen försvinner när $X_1, X_2, \dots, X_n$ är okorrelerade. För okorrelerade stokastiska variabler $X_1, X_2, \dots, X_n$ har vi

$$V\left[\sum_{i=1}^n a_i X_i + b\right] = \sum_{i=1}^n a_i^2 V[X_i]$$

Som följd av detta har vi att om $X_1, X_2, \dots, X_n$ har samma väntevärde μ (om de representerar repeterade mätningar av samma storhet, till exempel) får vi

$$E\left[\sum_{i=1}^n X_i\right] = n\mu.$$

Vi ser därför att det *aritmetiska medelvärdet* $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ har väntevärde

$$E[\bar{X}] = \mu.$$

Om $X_1, X_2, \dots, X_n$ är okorrelerade och har samma varians σ^2 har vi varianserna

$$V\left[\sum_{i=1}^n X_i\right] = n\sigma^2 \quad \text{och} \quad V[\bar{X}] = \frac{1}{n^2} V\left[\sum_{i=1}^n X_i\right] = \frac{\sigma^2}{n}.$$

vilket ger standardavvikelser

$$D\left[\sum_{i=1}^n X_i\right] = \sigma\sqrt{n} \quad \text{och} \quad D[\bar{X}] = \frac{\sigma}{\sqrt{n}}.$$

Vi ser alltså att det aritmetiska medelvärdet $\bar{X}$ närmar sig väntevärdet μ när n går mot oändligheten. Detta sker som $1/\sqrt{n}$, vilket betyder att vi måste multiplicera antalet försök n med fyra för att halvera standardavvikelsen. Senare i denna föreläsning kommer vi stärka detta resultat genom att visa hur denna konvergens sker med avseende på fördelningen hos $\bar{X}$.

Identitet ovan för variansen av summan av okorrelerade och likafördelade stokastiska variabler ger oss ett enklare sätt att härleda variansen hos en $\text{Bin}(n, p)$ -fördelad stokastisk variabel. Kom ihåg att denna kan skrivas som summan av n oberoende $\text{Ber}(p)$ -fördelade stokastiska variabler. Eftersom dessa har väntevärde p blir variansen $\sigma^2 = (1-p)^2 \cdot p + (0-p)^2 \cdot (1-p) = p(1-p)$. Enligt formeln ovan måste då variansen för summan av dessa n stokastiska variabler vara $n\sigma^2 = np(1-p)$, vilket stämmer med variansen för $\text{Bin}(n, p)$ som vi beräknade innan.

Betingade väntevärden

Som vi diskuterade tidigare har betingade fördelningar i stort sett samma egenskaper som vanliga fördelningar. Bland annat kan vi definiera det *betingade väntevärdet*

$$E[X|Y=y] = \sum_{x=0}^{+\infty} x p_{X|Y=y}(x) \quad (\text{diskret})$$

$$E[X|Y=y] = \int_{x=-\infty}^{+\infty} x f_{X|Y=y}(x) dx \quad (\text{kontinuerlig})$$

som också betecknas $\mu_{X|Y=y}$.

För varje värde $y \in \mathbb{R}$ har vi ett betingat väntevärde $E[X|Y=y]$. Vi kan därför definiera funktionen $g(y) = E[X|Y=y]$ och betrakta den stokastiska variabeln $Z = g(Y)$ vilken vi betecknar $E[X|Y]$. Detta kan förstås som att vi tar väntevärdet av X med avseende på allt som *inte* beror på Y och låter Y fortfarande variera slumpmässigt. Den enda variationen som är kvar är då variationen i Y .

Som ett exempel, antag att X är en bowlingbolls vikt och Y är en bowlingbolls volym. Eftersom densiteten hos bowlingbollen inte kan vara vilket värde som helst har

vi ett beroende mellan X och Y . Vi kan betrakta väntevärdet $E[X]$ (medelvikten) och väntevärdet $E[Y]$ (medelvolymen). För en viss volym y kan vi också betrakta medelvikten $E[X|Y = y]$ för bowlingbollarna med volymen y . Men vi kan också betrakta medelvikten som en stokastisk variabel $E[X|Y]$ om vi låter volymen Y variera slumpmässigt enligt sin marginalfördelning. Detta betyder att om vi tar en godtycklig volym Y på måfå så har vi också medelvikten $E[X|Y]$ för den medelvolymen.

Med detta synsätt kan vi visa *lagen om total förväntan*:

$$E[X] = E[E[X|Y]],$$

dvs. väntevärdet av X kan beräknas genom att först beräkna det betingade väntevärdet av X givet Y och sedan det obetingade väntevärdet av denna – vi integrerar först bort variationen hos X som inte beror på Y , sedan variationen som beror på Y . I det kontinuerliga fallet har vi

$$\begin{aligned} E[E[X|Y]] &= \int_{y=-\infty}^{+\infty} E[X|Y=y] f_Y(y) dy \\ &= \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} x f_{X|Y=y}(x) dx f_Y(y) dy \\ &= \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} x f_{X|Y=y}(x) f_Y(y) dx dy \\ &= \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} x f_{X,Y}(x, y) dx dy = E[X]. \end{aligned}$$

(Detta är egentligen en tillämpning av lagen om total sannolikhet.)

Givet att vi håller betingningen med avseende på Y fixt har vi i övrigt samma egenskaper hos betingade väntevärden som för vanliga (obetingade) väntevärden. För kontinuerliga stokastiska variabler gäller till exempel att vi kan beräkna det betingade väntevärdet av en funktion $g(X)$ av X :

$$E[g(X)|Y=y] = \int_{x=-\infty}^{+\infty} g(x) f_{X|Y=y}(x) dx.$$

Vi har också samma linjäritetsrelationer:

$$E[a_1 X_1 + a_2 X_2 + b|Y=y] = a_1 E[X_1|Y=y] + a_2 E[X_2|Y=y] + b.$$

På samma sätt som i det obetingade fallet kan vi definiera den *betingade variansen*

$$V[X|Y=y] = E[(X - \mu_{X|Y=y})^2|Y=y].$$

Precis som $E[X|Y]$ kan vi definiera den stokastiska variabeln $V[X|Y]$ dvs. variansen av X givet Y men där vi låter Y fortfarande variera slumpmässigt.

Vi har då en nära släkting till lagen om total förväntan, *lagen om total varians*:

$$V[X] = E[V[X|Y]] + V[E[X|Y]].$$

Variansen för X har alltså två komponenter: väntevärdet hos den betingade variansen $V[X|Y]$ (medelvariansen av X givet Y) samt variansen hos det betingade väntevärdet $E[X|Y]$ (variansen av medelvärdet av X givet Y). Detta kan visas genom att tillämpa lagen om total förväntan på $E[X^2]$ och $E[X]$, vilket ger

$$\begin{aligned} V[X] &= E[X^2] - E[X]^2 = E[E[X^2|Y]] - E[E[X|Y]]^2 \\ &= E[E[X^2|Y]] - E[E[X|Y]^2] + E[E[X|Y]^2] - E[E[X|Y]]^2 \\ &= E[E[X^2|Y] - E[X|Y]^2] + E[E[X|Y]^2] - E[E[X|Y]]^2 \\ &= E[V[X|Y]] + V[E[X|Y]]. \end{aligned}$$

Exempel 3. Betingade fördelningar är kraftfulla verktyg för att bygga avancerade stokastiska modeller. Låt till exempel antalet bilar X som passerar en korsning under en timme vara Poissonfördelat med parameter $\mu = 560$, dvs. $X \sim \text{Po}(560)$. Korsningen är relativt olycksdrabbad, så risken att en bil hamnar i en singelolycka där är $p = 0.01$. Vi är nu intresserade av Y , antalet olyckor i korsningen.

Ett sätt att bestämma fördelningen för Y är att konstatera att om x bilar passerar korsningen så är antalet olyckor fördelat enligt $\text{Bin}(x, 0.01)$. Med andra ord har vi att den betingade fördelningen av Y givet $X = x$ är $\text{Bin}(x, 0.01)$. Vi kan då använda lagen om total sannolikhet $p_Y(y) = \sum_{x=0}^{+\infty} p_{Y|X=x}(y)p_X(x)$ där $p_{Y|X=x}(y)$ och $p_X(x)$ ges av sannolikhetsfunktionerna för binomialfördelningen respektive Poissonfördelningen. Om vi bara intresserar oss för väntevärdet och variansen kan vi använda identiteterna ovan (lagarna om total förväntan och varians). Den första ger

$$E[Y] = E[E[Y|X]] = E[X \cdot 0.01] = 0.01E[X] = 0.01 \cdot 560 = 5.6,$$

där vi har använt formeln för väntevärdet av binomialfördelningen i första likheten och väntevärdet för Poissonfördelningen i sista likheten. På samma sätt har vi

$$\begin{aligned} V[Y] &= E[V[Y|X]] + V[E[Y|X]] = E[X \cdot 0.01 \cdot (1 - 0.01)] + V[0.01X] \\ &= 0.0099 \cdot 560 + 0.0001 \cdot 560 = 0.01 \cdot 560 = 5.6, \end{aligned}$$

vilket ger en standardavvikelse på $D[Y] = \sqrt{V[Y]} \approx 2.37$.

Exempel 4. Låt N vara en diskret stokastisk variabel med värden $0, 1, 2, \dots$ och låt $X_1, X_2, \dots$ vara en följd oberoende likafördelade stokastiska variabler med samma väntevärde μ och varians σ^2 . Vi antar också att N och $X_1, X_2, \dots$ är oberoende och definierar

$$S_N = \sum_{i=1}^N X_i.$$

Notera att antalet termer i summan är slumpmässigt. Fördelningen för S_N är komplicerad, men vi kan komma åt dess väntevärde och varians genom att betinga med avseende på N och använda resultaten ovan.

Mer konkret har vi det betingade väntevärdet

$$E[S_N|N = n] = E\left[\sum_{i=1}^N X_i|N = n\right] = E\left[\sum_{i=1}^n X_i\right] = n\mu$$

dvs. $E[S_N|N] = N\mu$. Lagen om total förväntan ger då $E[S_N] = E[E[S_N|N]] = E[N\mu] = E[N]\mu$.

För variansen har vi

$$V[S_N|N=n] = V\left[\sum_{i=1}^n X_i\right] = n\sigma^2$$

dvs. $V[S_N|N] = N\sigma^2$. Den totala variansen är alltså

$$\begin{aligned} V[S_N] &= E[V[S_N|N]] + V[E[S_N|N]] \\ &= E[N\sigma^2] + V[N\mu] = E[N]\sigma^2 + V[N]\mu^2. \end{aligned}$$

Det är alltså inte bara medelvariationen hos $X_1, X_2, \dots$ (varav vi har i genomsnitt $E[N]$ stycken termer) som ger variansen hos S_N . Vi har också variationen hos N , givet av $V[N]$, som ger en extra dos variation givet att $\mu^2 \neq 0$.

Standardiserade normalfördelningen

Vi såg tidigare att en normalfördelad variabel $X \sim N(\mu, \sigma)$ har täthetsfunktion

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-\mu)^2/2\sigma^2}$$


och fördelningsfunktion

$$F_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^x e^{-(u-\mu)^2/2\sigma^2} du.$$

Tyvärr finns det ingen sluten form på fördelningsfunktionen utan dess värden måste beräknas numeriskt. Som vi ser har normalfördelning två parametrar: μ och σ . Vi kommer se senare att $\mu = E[X]$ och $\sigma = D[X]$.

Ett speciellt parameterväl är $\mu = 0$ och $\sigma = 1$. I detta fall har vi $Z \sim N(0, 1)$ och betecknar täthetsfunktionen $\phi(z) = f_Z(z)$ och fördelningsfunktionen $\Phi(z) = F_Z(z)$. Vi har då

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \quad \text{och} \quad \Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-u^2/2} du.$$



Denna fördelning har ett par mycket användbara egenskaper:

- (i) Täthetsfunktionen $\phi(z)$ är symmetrisk: $\phi(-z) = \phi(z)$.

(ii) Eftersom $\phi(z)$ är symmetrisk har vi att $\Phi(-z) = 1 - \Phi(z)$ eftersom

$$\Phi(-z) = \int_{u=-\infty}^{-z} \phi(u) du = \int_{u=z}^{+\infty} \phi(-u) du = \int_{u=z}^{+\infty} \phi(u) du = 1 - \Phi(z).$$

(iii) Sannolikheten att $Z \in [a, b]$ ges av

$$P(a < Z < b) = \Phi(b) - \Phi(a).$$

Notera att inklusion av ändpunkterna a och b inte har någon effekt eftersom Z är en kontinuerlig stokastisk variabel.

(iv) α -kvantilerna för $N(0, 1)$ ges specialbeteckningen λ_α . Vi har alltså


$$P(Z > \lambda_\alpha) = \alpha \Leftrightarrow P(Z \leq \lambda_\alpha) = 1 - \alpha \Leftrightarrow \Phi(\lambda_\alpha) = 1 - \alpha \Leftrightarrow \lambda_\alpha = \Phi^{-1}(1 - \alpha).$$

(v) Om vi tillämpar $\Phi(-z) = 1 - \Phi(z)$ på definitionen av λ_α har vi att $\lambda_{1-\alpha} = -\lambda_\alpha$ eftersom

$$\Phi(\lambda_\alpha) = 1 - \alpha \Leftrightarrow \Phi(-\lambda_\alpha) = 1 - \Phi(\lambda_\alpha) = 1 - (1 - \alpha).$$

(vi) Det symmetriska intervallet $[-\lambda_{\alpha/2}, \lambda_{\alpha/2}]$ innehåller Z med sannolikheten $1 - \alpha$ eftersom

$$P(-\lambda_{\alpha/2} < Z < \lambda_{\alpha/2}) = \Phi(\lambda_{\alpha/2}) - \Phi(-\lambda_{\alpha/2}) = (1 - \alpha/2) - \alpha/2 = 1 - \alpha.$$



(vii) Väntevärdet är $E[Z] = 0$ eftersom $\phi(z)$ är symmetrisk, vilket ger att $z\phi(z)$ är en ojämn funktion vars integral således är noll.

(viii) Standardavvikelsen är $D[Z] = 1$, eftersom $E[Z^2] = 1$, vilket fås genom partiell integration

$$\begin{aligned} E[Z^2] &= \frac{1}{\sqrt{2\pi}} \int_{z=-\infty}^{+\infty} z^2 e^{-z^2/2} dz = \frac{1}{\sqrt{2\pi}} \int_{z=-\infty}^{+\infty} z \cdot z e^{-z^2/2} dz \\ &= \frac{1}{\sqrt{2\pi}} \left[z \cdot -e^{-z^2/2} \right]_{z=-\infty}^{+\infty} - \frac{1}{\sqrt{2\pi}} \int_{z=-\infty}^{+\infty} -e^{-z^2/2} dz = 0 + 1 = 1. \end{aligned}$$

En stokastisk variabel sägs vara *standardiserad* om dess väntevärde är noll och dess varians ett. Därför kallas detta specialfall av normalfördelningen för den *standardiserade normalfördelningen*.

Allmänna normalfördelningen

Vi ska nu se hur egenskaperna ovan kan överföras till den allmänna normalfördelningen $N(\mu, \sigma)$. För detta krävs följande sats:

Sats 5. För $\mu \in \mathbb{R}, \sigma \in \mathbb{R}_{>0}$ har vi

$$X \sim N(\mu, \sigma) \Leftrightarrow Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

Bevis. Vi antar först att $X \sim N(\mu, \sigma)$. Detta ger fördelningsfunktionen

$$\begin{aligned} F_Z(z) &= P(Z \leq z) = P\left(\frac{X - \mu}{\sigma} \leq z\right) = P(X \leq \mu + \sigma z) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\mu + \sigma z} e^{-(u-\mu)^2/2\sigma^2} du \end{aligned}$$

Med variabelbytet $v = \frac{u-\mu}{\sigma}$ får vi

$$\begin{aligned} &\frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\mu + \sigma z} e^{-(u-\mu)^2/2\sigma^2} du \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^z e^{-v^2/2} |\sigma| dv \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-v^2/2} dv = \Phi(z). \end{aligned}$$

Så Z har fördelningsfunktion $\Phi(z)$ och måste då ha fördelningen $N(0, 1)$.

Andra riktningen visas på samma sätt. □

Som direkt konsekvens av denna ekvivalens har vi för $X \sim N(\mu, \sigma)$ att

$$f_X(x) = \frac{1}{\sigma} \phi\left(\frac{x-\mu}{\sigma}\right) \quad \text{och} \quad F_X(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$$

samt att

$$E[X] = E[\mu + \sigma Z] = \mu + \sigma E[Z] = \mu + 0 = \mu$$

och

$$V[X] = V[\mu + \sigma Z] = \sigma^2 V[Z] = \sigma^2 \cdot 1 = \sigma^2 \Rightarrow D[X] = \sigma,$$

där $Z = (X - \mu)/\sigma \sim N(0, 1)$. Parametrarna μ och σ för normalfördelningen $N(\mu, \sigma)$ svarar alltså mot fördelningens väntevärde och standardavvikelse. Vi kan också översätta sannolikhetsberäkningar rörande $N(\mu, \sigma)$ med beräkningar på $N(0, 1)$, dvs. med avseende på $\Phi(z)$:

$$P(a < X < b) = P\left(\frac{a-\mu}{\sigma} < \frac{X-\mu}{\sigma} < \frac{b-\mu}{\sigma}\right) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right).$$

Eftersom normalfördelningens fördelningsfunktion inte går att skriva på sluten form används relationen ovan för att beräkna sannolikheter genom att slå upp sökta värden på $\Phi(z)$ i tabellverk.

Kvantilerna för $N(\mu, \sigma)$ kan också beräknas utifrån kvantilerna λ_α för $N(0, 1)$. Med andra ord har vi, eftersom $P(Z > \lambda_\alpha) = \alpha$ för $Z \sim N(0, 1)$, att

$$P\left(\frac{X - \mu}{\sigma} > \lambda_\alpha\right) = \alpha \Leftrightarrow P(X > \mu + \lambda_\alpha \sigma) = \alpha,$$

dvs. α -kvantilen för $N(\mu, \sigma)$ ges av $\mu + \lambda_\alpha \sigma$. På samma sätt har vi det symmetriska intervallet $[\mu - \lambda_{\alpha/2} \sigma, \mu + \lambda_{\alpha/2} \sigma]$ runt μ som uppfyller

$$P(\mu - \lambda_{\alpha/2} \sigma < X < \mu + \lambda_{\alpha/2} \sigma) = 1 - \alpha.$$

Linjärtransformationer av normalfördelade variabler

En viktig egenskap hos normalfördelningen är att vi kan applicera godtyckliga linjärtransformationer på normalfördelade stokastiska variabler och återfå en normalfördelad stokastisk variabel. Vi betraktar först transformationen $X \mapsto aX + b$.

Sats 6. Låt $X \sim N(\mu, \sigma)$ och $b \in \mathbb{R}$, $a \in \mathbb{R}_{>0}$. Då har vi $Y = aX + b \sim N(a\mu + b, |a|\sigma)$.

Bevis. Enligt Sats 5 har vi

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

Om $Y = aX + b$ måste $X = (Y - b)/a$, vilket ger

$$Z = \frac{(Y - b)/a - \mu}{\sigma} = \frac{Y - (b + a\mu)}{a\sigma} \sim N(0, 1).$$

Antag nu att $a > 0$, vi har då $\mu' = b + a\mu$ och $\sigma' = a\sigma > 0$ så att

$$\frac{Y - \mu'}{\sigma'} \sim N(0, 1),$$

och enligt Sats 5 ger detta att $Y \sim N(\mu', \sigma') = N(a\mu + b, a\sigma) = N(a\mu + b, |a|\sigma)$ (eftersom $a > 0$ så $a = |a|$).

Om $a < 0$ så kan vi inte definiera standardavvikelsen som $a\sigma$ eftersom denna är negativ. Istället noterar vi att om $Z \sim N(0, 1)$ så är $-Z \sim N(0, 1)$ eftersom fördelningen är symmetrisk. Detta ger då

$$-Z = \frac{Y - (a\mu + b)}{-a\sigma} \sim N(0, 1),$$

så med $\mu' = a\mu + b$ och $\sigma' = -a\sigma > 0$ har vi att

$$\frac{Y - \mu'}{\sigma'} \sim N(0, 1),$$

vilket återigen ger att $Y \sim N(\mu', \sigma') = N(a\mu + b, -a\sigma) = N(a\mu + b, |a|\sigma)$ (eftersom $a < 0$ så $-a = |a|$). $\square$

Ett liknande förhållande gäller om vi adderar två normalfördelade stokastiska variabler.

Sats 7. Om $X_1 \sim N(\mu_1, \sigma_1)$ och $X_2 \sim N(\mu_2, \sigma_2)$ är oberoende har vi att

$$X_1 + X_2 \sim N\left(\mu_1 + \mu_2, \sqrt{\sigma_1^2 + \sigma_2^2}\right).$$

Med andra ord är summan av två normalfördelade variabler också normalfördelad.

Bevis. Enligt Sats 5 finns oberoende $Z_1 \sim N(0, 1)$ och $Z_2 \sim N(0, 1)$ så att

$$X_1 = \mu_1 + \sigma_1 Z_1 \quad \text{och} \quad X_2 = \mu_2 + \sigma_2 Z_2,$$

vilket ger

$$X_1 + X_2 = \mu_1 + \mu_2 + \sigma_1 Z_1 + \sigma_2 Z_2 = (\mu_1 + \mu_2) + \sigma_1(Z_1 + \sigma_1^{-1}\sigma_2 Z_2).$$

Det räcker alltså att visa att $Z_1 + \alpha Z_2 \sim N(0, \sqrt{1 + \alpha^2})$ för $\alpha > 0$ och sedan tillämpa Sats 6.

Om $Y = Z_1 + \alpha Z_2$ använder vi den kontinuerliga faltningsformeln och får

$$\begin{aligned} f_Y(y) &= \int_{z=-\infty}^{+\infty} f_{Z_1}(y-z) f_{\alpha Z_2}(z) dz \\ &= \int_{z=-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-(y-z)^2/2} \cdot \frac{1}{\sqrt{2\pi\alpha^2}} e^{-z^2/2\alpha^2} dz \\ &= \frac{1}{2\pi\alpha} \int_{z=-\infty}^{+\infty} e^{-\frac{(y-z)^2}{2} - \frac{z^2}{2\alpha^2}} dz \\ &= \frac{1}{2\pi\alpha} \int_{z=-\infty}^{+\infty} e^{-\frac{\alpha^2(y-z)^2 + z^2}{2\alpha^2}} dz. \end{aligned}$$

Kvoten i exponenten kan skrivas om med hjälp av kvadratkomplettering till

$$\begin{aligned} \frac{\alpha^2(y-z)^2 + z^2}{2\alpha^2} &= \frac{\alpha^2 y^2 - 2\alpha^2 yz + \alpha^2 z^2 + z^2}{2\alpha^2} \\ &= \frac{\alpha^2 y^2 + (1 + \alpha^2)z^2 - 2\alpha^2 yz + \alpha^4(1 + \alpha^2)^{-1}y^2 - \alpha^4(1 + \alpha^2)^{-1}y^2}{2\alpha^2} \\ &= \frac{\alpha^2 y^2 + ((1 + \alpha^2)^{1/2}z - \alpha^2(1 + \alpha^2)^{-1/2}y)^2 - \alpha^4(1 + \alpha^2)^{-1}y^2}{2\alpha^2} \\ &= \frac{\alpha^2(1 + \alpha^2)^{-1}y^2 + ((1 + \alpha^2)^{1/2}z - \alpha^2(1 + \alpha^2)^{-1/2}y)^2}{2\alpha^2} \\ &= \frac{y^2}{2(1 + \alpha^2)} + \frac{(z - \alpha^2(1 + \alpha^2)^{-1}y)^2}{2\alpha^2(1 + \alpha^2)^{-1}} \end{aligned}$$

Stoppar vi denna tillbaka in i exponenten får vi

$$\begin{aligned} f_Y(Y) &= \frac{1}{2\pi\alpha} \int_{z=-\infty}^{+\infty} e^{-\frac{\alpha^2(y-z)^2+z^2}{2\alpha^2}} dz = \frac{1}{2\pi\alpha} e^{-\frac{y^2}{2(1+\alpha^2)}} \int_{z=-\infty}^{+\infty} e^{-\frac{(z-\alpha^2(1+\alpha^2)^{-1}y)^2}{2\alpha^2(1+\alpha^2)^{-1}}} dz \\ &= \frac{1}{2\pi\alpha} e^{-\frac{y^2}{2(1+\alpha^2)}} \sqrt{2\pi\alpha^2(1+\alpha^2)^{-1}} \int_{z=-\infty}^{+\infty} \frac{1}{\sqrt{2\pi\alpha^2(1+\alpha^2)^{-1}}} e^{-\frac{(z-\alpha^2(1+\alpha^2)^{-1}y)^2}{2\alpha^2(1+\alpha^2)^{-1}}} dz \\ &= \frac{1}{\sqrt{2\pi(1+\alpha^2)}} e^{-\frac{y^2}{2(1+\alpha^2)}} \int_{z=-\infty}^{+\infty} \frac{1}{\sqrt{2\pi\alpha^2(1+\alpha^2)^{-1}}} e^{-\frac{(z-\alpha^2(1+\alpha^2)^{-1}y)^2}{2\alpha^2(1+\alpha^2)^{-1}}} dz. \end{aligned}$$

Integralen är lika med integralen av täthetsfunktionen för $N(\alpha^2(1+\alpha^2)^{-1}y, \alpha(1+\alpha^2)^{-1/2})$ över $\mathbb{R}$ och är således ett, vilket ger

$$f_Y(y) = \frac{1}{\sqrt{2\pi(1+\alpha^2)}} e^{-\frac{y^2}{2(1+\alpha^2)}},$$

dvs. $Y \sim N(0, \sqrt{1+\alpha^2})$, vilket skulle visas. □

Satsen ovan kan generaliseras till fler stokastiska variabler. Om vi har oberoende stokastiska variabler $X_1 \sim N(\mu_1, \sigma_1), X_2 \sim N(\mu_2, \sigma_2), \dots, X_n \sim N(\mu_n, \sigma_n)$ får vi

$$\sum_{i=1}^n a_i X_i + b \sim N\left(\sum_{i=1}^n a_i \mu_i + b, \sqrt{\sum_{i=1}^n a_i^2 \sigma_i^2}\right).$$

Ett intressant specialfall inträffar då alla $X_1, X_2, \dots, X_n$ är oberoende och likafördelade, (samma μ och σ) och vi beräknar det aritmetiska medelvärdet $\bar{X}$. Då har vi

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right).$$

Med andra ord så "krymper" normalfördelningen när vi tar medelvärdet $\bar{X}$ av flera normalfördelade stokastiska variabler med samma väntevärde och varians.

Stora talens lag

Resultatet ovan gällande $\bar{X}$ för normalfördelade stokastiska variabler stämmer väl med resultatet tidigare i föreläsningen angående standardavvikelsen hos $\bar{X}$ för likafördelade oberoende stokastiska variabler med samma väntevärde μ och standardavvikelse σ (men med godtycklig fördelning annars). Vi såg då att $D[\bar{X}] = \frac{\sigma}{\sqrt{n}}$.

Vi kan visa några starkare resultat för detta konvergensbeteende. Det första kallas stora talens lag och ligger till grund för mycket av den empiriska vetenskapen. Den säger att det inte bara är standardavvikelsen som går mot noll, men hela sannolikhetsmåttet koncentrerar sig runt väntevärdet μ då $n \rightarrow \infty$.

Sats 8. (Stora talens lag) Låt $X_1, X_2, \dots$ vara oberoende likafördelade stokastiska variabler med samma väntevärde μ och standardavvikelse σ . Sätt

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Då har vi för varje $\epsilon > 0$ att

$$P(\mu - \epsilon < \bar{X}_n < \mu + \epsilon) \rightarrow 1 \quad \text{då } n \rightarrow +\infty.$$

För att bevisa satsen behöver vi ett par enklare resultat.

Sats 9. (Markovs olikhet) Låt Y vara en icke-negativ stokastisk variabel (dvs. Y tar endast värden större än eller lika med noll) och $a > 0$. Då har vi

$$P(Y \geq a) \leq \frac{E[Y]}{a}.$$

Bevis. Enligt definitionen av $E[Y]$ har vi i det kontinuerliga fallet

$$\begin{aligned} E[Y] &= \int_{y=0}^{+\infty} y f_Y(y) dy = \int_{y=0}^a y f_Y(y) dy + \int_{y=a}^{+\infty} y f_Y(y) dy \\ &\geq \int_{y=a}^{+\infty} y f_Y(y) dy \geq a \int_{y=a}^{+\infty} f_Y(y) dy = a P(Y \geq a). \end{aligned}$$

Om vi stuvor om olikheten får vi $P(Y \geq a) \leq E[Y]/a$. Det diskreta fallet visas på samma sätt men integralerna ersätts med summor. $\square$

Sats 10. (Tjebysjovs olikhet) Låt X vara en stokastisk variabel med väntevärde μ och standardavvikelse $\sigma > 0$. För varje $k > 0$ har vi då

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

Bevis. Vi har alltså

$$P(|X - \mu| \geq k\sigma) = P\left(\frac{|X - \mu|^2}{\sigma^2} \geq k^2\right).$$

Om vi sätter $Y = |X - \mu|^2/\sigma^2$ och tillämpar Markovs olikhet får vi

$$P(|X - \mu| \geq k\sigma) = P\left(\frac{|X - \mu|^2}{\sigma^2} \geq k^2\right) = P(Y \geq k^2) \leq \frac{E[Y]}{k^2} = \frac{1}{k^2}$$

vilket visar den sökta olikheten. $\square$

Vi återgår nu till beviset för stora talens lag.

Bevis. (Bevis för Sats 8) Vi vet att

$$P(\mu - \epsilon < \bar{X}_n < \mu + \epsilon) = P(|\bar{X}_n - \mu| < \epsilon) = 1 - P(|\bar{X}_n - \mu| \geq \epsilon).$$

Om vi sätter $k = \epsilon\sqrt{n}/\sigma$ ger Tjebysjovs olikhet att

$$P(|\bar{X}_n - \mu| \geq \epsilon) = P(|\bar{X}_n - \mu| \geq k\sigma/\sqrt{n}) \leq \frac{1}{k^2} = \frac{\sigma^2}{\epsilon^2 n}.$$

Eftersom $n \rightarrow +\infty$ går högerledet mot noll, vilket i sin tur ger att

$$P(\mu - \epsilon < \bar{X}_n < \mu + \epsilon) \rightarrow 1 \quad \text{då } n \rightarrow +\infty.$$

□

Centrala gränsvärdessatsen

Stora talens lag visar att sannolikhetsfördelningen för $\bar{X}$ koncentreras runt μ när $n \rightarrow +\infty$, men i övrigt vet vi inte riktigt hur den fördelningen ser ut. Sådan information kan vara viktig för att bestämma sannolikheten att $\bar{X}$ ligger tillräckligt nära μ eller för att utesluta ett alltför stort fel.

Det visar sig att vi kan beskriva denna fördelning approximativt om n är tillräckligt stort. Mer konkret så konvergerar fördelningsfunktionen för summan av oberoende stokastiska variabler till fördelningsfunktionen för en normalfördelning. Detta resultat kallas *centrala gränsvärdessatsen* och spelar en nyckelroll inom statistiken.

Sats 11. (*Centrala gränsvärdessatsen*) Låt $X_1, X_2, \dots$ vara oberoende likafördelade stokastiska variabler med väntevärde μ och standardavvikelse σ . Om vi definierar

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}}$$

har vi att

$$\lim_{n \rightarrow +\infty} F_{Z_n}(z) = \Phi(z).$$

(Detta kallas att Z_n konvergerar till $N(0, 1)$ i distribution.) Med andra ord har vi

$$P(a \leq Z_n \leq b) = P\left(a \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq b\right) = P\left(a \leq \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \leq b\right) \rightarrow \Phi(b) - \Phi(a)$$

då $n \rightarrow +\infty$.

Det viktiga att notera här är att $X_1, X_2, \dots$ kan ha vilken fördelning som helst (diskret eller kontinuerlig) – deras summa konvergerar oavsett till en normalfördelad stokastisk variabel. Detta motiverar normalfördelningens centrala roll inom statistiken: den uppstår varje gång vi summerar ett stort antal slumpmässiga värden.

Intuitivt bygger beviset på upprepade tillämpningar av faltningsformeln. Varje faltning innebär en viss utjämning eller utslätning av tätheten. Resultatet av denna utslätning är då normalfördelningen – denna motsvarar på något sätt "den slätaste" fördelningen med avseende på faltningsoperationen.


Ett sätt att tolka centrala gränsvärdessatsen är att för ett tillräckligt stort n så har vi att Z_n har approximativt fördelningen $N(0, 1)$. Eftersom $Z_n = (\bar{X}_n - \mu)/(\sigma/\sqrt{n}) = (\sum_{i=1}^n X_i - n\mu)/(\sigma\sqrt{n})$ ger detta att $\bar{X}_n$ approximativt har fördelningen $N(\mu, \sigma/\sqrt{n})$ medan $\sum_{i=1}^n X_i$ approximativt har fördelningen $N(n\mu, \sigma\sqrt{n})$.

Ett problem med den centrala gränsvärdessatsen är att den inte säger hur stort n måste vara för att få en bra approximation. Ofta är det svårt att säga hur nära vi kommer för ett givet n utan att veta mer om fördelningen för $X_1, X_2, \dots$. I de problem vi studerar i kursen kommer det framgå när satsen kan tillämpas.

Vi kan illustrera satsen genom att ta $X_1, X_2, \dots$ med likformig fördelning över $[-1, 1]$. I detta fall har vi $\mu = 0$ och $\sigma = 1/\sqrt{3}$. Enligt centrala gränsvärdessatsen kommer då

$$\frac{\sqrt{3}}{\sqrt{n}} \sum_{i=1}^n X_i$$

att vara approximativt $N(0, 1)$ -fördelad när $n \rightarrow \infty$.



Notera att även om den likformiga fördelningen är långt ifrån normalfördelningen så krävs det inte många termer förrän vi börjar närma oss normalfördelningen.

Föreläsning åtta

Joakim Andén

Approximation av fördelningar

En tillämpning av centrala gränsvärdessatsen som vi presenterade i föregående föreläsning är för att approximera några av de föreläsningar vi sett tidigare. Låt först $X \sim \text{Bin}(n, p)$. Vi har sett att X kan skrivas som en summa av n stycken oberoende och likafördelade stokastiska variabler $Y_1, Y_2, \dots, Y_n$ med $Y_i \sim \text{Ber}(p)$. Utfallet $Y_i = 1$ motsvarar att det i :te försöket lyckades medan $Y_i = 0$ betyder att det misslyckades. Summan $X = Y_1 + Y_2 + \dots + Y_n$ är då det totala antalet lyckade försök, vilket har fördelning $\text{Bin}(n, p)$. Detta håller eftersom $\text{Bin}(1, p) = \text{Ber}(p)$ och summan $U + V$ av två binomialfördelade stokastiska variabler $U \sim \text{Bin}(n, p)$ och $V \sim \text{Bin}(m, p)$ har fördelningen $\text{Bin}(n + m, p)$ (tillämpning av den diskreta faltningsformeln).

Från detta fick vi att $E[X] = E[Y_1] + E[Y_2] + \dots + E[Y_n] = p + p + \dots + p = np$ samt att $V[X] = V[Y_1] + V[Y_2] + \dots + V[Y_n] = p(1 - p) + p(1 - p) + \dots + p(1 - p) = np(1 - p)$ eftersom $Y_1, Y_2, \dots, Y_n$ är oberoende. Från $V[X] = np(1 - p)$ får vi då att $D[X] = \sqrt{np(1 - p)}$.

En annan konsekvens av denna uppdelning är att vi kan tillämpa den centrala gränsvärdessatsen för n stort. Då har vi att X approximativt har fördelningen $N(E[X], D[X]) = N(np, \sqrt{np(1 - p)})$. Hur bra approximationen är beror så klart på vad man ska ha den till, men en tumregel är att den håller ganska bra då $np(1 - p) \geq 10$.

Denna approximation kan vara bra att ha för att beräkna sannolikheter som rör binomialfördelningar. Om $X \sim \text{Bin}(215, 0.6)$, till exempel, så kanske vi vill beräkna $P(X \leq 120)$. Då har vi

$$P(X \leq 120) = \sum_{x=0}^{120} p_X(x) = \sum_{x=0}^{120} \binom{215}{x} 0.6^x 0.4^{215-x}.$$

Detta går att beräkna, men det är inte lätt och kräver ofta tillgång till dator och en del tålamod. Om vi istället använder normalapproximationen ovan får vi att $E[X] = 215 \cdot 0.6 = 129$ samt $D[X] = \sqrt{215 \cdot 0.6 \cdot 0.4} \approx 7.18$. Vi har då att X är approximativt $N(129, 7.18)$ -fördelad, vilket då ger

$$\begin{aligned} P(X \leq 120) &= P\left(\frac{X - 129}{7.18} \leq \frac{120 - 129}{7.18}\right) \\ &\approx P(Z \leq -1.25) = \Phi(-1.25) = 1 - \Phi(1.25) \approx 0.1006, \end{aligned}$$

där $Z \sim N(0, 1)$.

En annan (och ännu mer användbar) tillämpning är för att beräkna kvantiler. Låt oss säga att i fallet ovan vi söker ett värde x så att $P(X > x) = 0.10$. Detta fås då genom

$$\begin{aligned} P(X > x) &= P\left(\frac{X - 129}{7.18} > \frac{x - 129}{7.18}\right) \\ &\approx P\left(Z > \frac{x - 129}{7.18}\right) = 0.10. \end{aligned}$$

Detta uppfylls då genom att sätta $(x - 129)/7.18 = \lambda_{0.10}$ eftersom $P(Z > \lambda_{0.10}) = 0.10$. Alltså har vi den approximativa 0.10-kvantilen $x = 129 + 7.18\lambda_{0.10} \approx 129 + 7.18 \cdot 1.28 \approx 138.2$.

Vi kan härleda liknande relationer för Poissonfördelningen. Låt $X \sim \text{Bin}(\mu)$. När vi härledde Poissonfördelningen såg vi att den kunde approximeras av $\text{Bin}(n, \mu/n)$ för stort n . Vi fick detta från Poissonmodellen där X är antalet händelser som inträffar i intervallet $[0, 1]$ givet att händelserna inträffar oberoende av varandra och att en händelse inträffar på intervallet $[t, t + h]$ med sannolikhet h för små h . Binomialapproximation fås då genom att dela upp intervallet $[0, 1]$ i n lika stora delar, där var och en har sannolikhet μ/n att innehålla en händelse.

Om vi kopplar ihop denna approximation med centrala gränsvärdessatsen ser vi att $\text{Bin}(n, \mu/n)$ kan approximeras med $N(n \cdot \mu/n, \sqrt{n \cdot \mu/n \cdot (1 - \mu/n)}) = N(\mu, \sqrt{\mu(1 - \mu/n)})$. För stora n är μ/n försumbar och vi får approximationen $N(\mu, \sqrt{\mu})$. Med samma tumregel som för normalapproximation av binomialfördelningen får vi att denna approximation stämmer ganska bra då $\mu \geq 10$.

Från sannolikhetssteori till statistik

Hittills har kursen behandlat sannolikhetssteori, dvs. vi har studerat olika modeller för slumpmässiga förlopp genom begrepp som händelser, sannolikhetsmått och stokastiska variabler. Med hjälp av dessa modeller kan vi bland annat beräkna sannolikheten att ett visst förlopp sker (till exempel att en händelse inträffar eller en stokastisk variabel antar ett visst värde) eller andra relevanta storheter (till exempel väntevärdet och variansen hos en viss stokastisk variabel). Vi utgår alltså från en viss modell och härleder egenskaper hos data som genereras av modellen.

Inom statistiken utgår vi istället från datamängden och försöker dra slutsatser om dessa. I vissa fall gäller det att sammanfatta datapunkterna på olika sätt, vilket kallas *beskrivande statistik*. I andra fall vill vi bygga en modell för hur datapunkterna har genererats (ofta i form av en fördelning hos en stokastisk variabel), vilket kallas *statistisk inferens*. Denna kurs kommer att fokusera till stor del på detta senare fall men vi börjar med ett par grundläggande begrepp inom beskrivande statistik då dessa kommer upp ofta också inom inferensen.

Beskrivande statistik

Inom den beskrivande statistiken söker vi olika sätt att sammanfatta en viss datamängd


$$\{x_1, x_2, \dots, x_n\}.$$

Vi behöver inte göra några antaganden gällande datamängdens härkomst (dvs. som utfallen hos en stokastisk variabel), utan är intresserad av datamängden i sig.

En användbar sammanfattning av datapunkterna fås genom *histogrammet* definierad på klassgränserna $g_1, g_2, \dots, g_{m+1}$ som ges av

$$f_i = |\{j : g_i \leq x_j < g_{i+1}\}| \quad \text{för } i = 1, 2, \dots, m,$$

där beteckningen $|A|$ avser kardinaliteten hos mängden A , dvs. antalet element i A . Variabeln f_i kallas den *absoluta frekvensen* för klassen $[g_i, g_{i+1}]$ och vi definierar också den *relativa frekvensen* $p_i = f_i/n$. Ofta ser vi till att *klassbredden* $h_i = g_{i+1} - g_i$ hålls konstant. Värdena för f_i eller p_i kan sedan plottas i ett stolpdiagram för att få en översikt.



Vi diskuterade tidigare lägesmått, spridningsmått och beroendemått för stokastiska variabler. Dessa har också motsvarigheter för datamängder. Vi kan, till exempel, definiera det *aritmetiska medelvärde* (eller *stickprovsmedelvärde*)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

stickprovsvariansen

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

och *stickprovets standardavvikelse*

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

(I både stickprovsvariansen och stickprovets standardavvikelse kan vi ersätta $n - 1$ med n , men det visar sig att $n - 1$ är mer gynnsamt från ett inferensperspektiv).

För att förenkla formlerna ovan inför vi beteckningen Q för *kvadratsumman kring det aritmetiska medelvärdet*

$$Q = \sum_{i=1}^n (x_i - \bar{x})^2,$$

vilket ger $s^2 = Q/(n - 1)$. En trevlig egenskap är att

$$\begin{aligned} Q &= \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2 \\ &= \sum_{i=1}^n x_i^2 - n\bar{x}^2 = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2. \end{aligned}$$

(Detta kan jämföras med formeln $V[X] = E[X^2] - E[X]^2$ för variansen av en stokastisk variabel.)

Vi kan också ha datapunkter som består av par (x_i, y_i) och hela datamängden blir då

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}.$$

I detta fall kan vi beräkna *stickprovskovariansen*

$$c_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

och *stickprovets korrelationskoefficient*

$$r = \frac{c_{xy}}{s_x s_y},$$

där s_x och s_y syftar på stickprovsstandardavvikelserna för x respektive y . Som innan kan vi förenkla summan i c_{xy} som

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}.$$

Avslutningsvis noterar vi att terminologin kan vara lite förvirrande. Vi har alltså definierat begreppen väntevärde, varians och så vidare för en stokastisk variabel X . Som vi sett i tidigare föreläsningar kan vi ha en modell med flera oberoende kopior av $X_1, X_2, \dots, X_n$ av X och beräkna dess aritmetiska medelvärde

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

vilket också är en stokastisk variabel. Vi kommer också att se alldeles strax att det går att beräkna en stickprovsvarians utifrån dessa $X_1, X_2, \dots, X_n$ som även denna är en stokastisk variabel.

Medelvärdena, varianserna och så vidare som vi definierat i denna del avser som sagt datamängder, och det finns en viktig länk här. Värdena som tillhör datamängden kan nämligen ses som *utfall* av deras stokastiska motparter. Till exempel kan $\bar{x}$ ses som ett utfall av $\bar{X}$. Strikt sett behöver inte detta vara fallet inom den beskrivande statistiken (eftersom den endast förhåller sig till datamängder), men det kan vara bra att veta hur kopplingen ser ut.

Vi kan också beräkna kvantiler på datamängden. Om vi sorterar värdena $x_1, x_2, \dots, x_n$ och benämner de sorterade värdena $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ så har vi att det minsta värdet är $\min(x_1, x_2, \dots, x_n) = x_{(1)}$ och det största värdet är $\max(x_1, x_2, \dots, x_n) = x_{(n)}$. Vi kan då definiera α -kvantilen $\tilde{x}_\alpha$ som $x_{(n - \lfloor \alpha n \rfloor)}$ där $\lfloor \alpha \rfloor$ är α rundat nedåt. Det finns alternativa definitioner för dessa kvantiler som interpolerar mellan olika värden i de fall αn inte är ett heltal. När n är tillräckligt stort ger alla dessa definitioner i stort sett samma resultat, så vi håller oss till definitionen ovan i kursen (notera att kursboken använder en lite annorlunda definition).

Låt oss anta att vi har en datamängd

$$x_1 = 0.63, x_2 = 0.14, x_3 = 0.98, x_4 = 0.82, x_5 = 0.61.$$

Vi sorterar denna och får

$$x_{(1)} = 0.14, x_{(2)} = 0.61, x_{(3)} = 0.63, x_{(4)} = 0.82, x_{(5)} = 0.98.$$

Enligt formeln ovan har vi $\tilde{x}_{0.50} = x_{(3)} = 0.63$ eftersom $5 - \lfloor 0.5 \cdot 5 \rfloor = 5 - 2 = 3$. På samma sätt får vi $\tilde{x}_{0.25} = x_{(4)} = 0.82$ och $\tilde{x}_{0.75} = x_{(2)} = 0.61$. Dessa kvantiler har speciella namn: $\tilde{x}_{0.50}$ kalla *medianen*, $\tilde{x}_{0.25}$ kallas den *övre kvartilen* och $\tilde{x}_{0.75}$ kallas den *undre kvartilen*. Genom att subtrahera den undre kvartilen från den övre får vi *interkvartilavståndet* $\tilde{x}_{0.25} - \tilde{x}_{0.75}$.

Medianer och kvartiler har den bra egenskapen att de i regel är mer robusta mot mycket små eller mycket stora värden. Detta kan jämföras med det aritmetiska medelvärdet som i regel är mer känsligt.

Introduktion till statistisk inferens

Den grundläggande frågan inom statistisk inferens är: hur kan vi dra olika slutsatser från data? Ofta handlar dessa slutsatser om olika modeller för datamängden eller om olika parametrar för dessa modeller. Generellt antar vi att en stokastisk variabel har en viss fördelning som beror på en viss parameter och använder sedan data för att passa denna parameter.

Låt oss ta som motiverande exempel, en opinionsundersökning. Utav alla röstberättigade individer i Sverige (cirka 7.5 miljoner människor) väljer vi 1000 stycken och ber dem svara ja eller nej på en viss fråga (till exempel: Borde Sverige begära utträde ur EU?). Antag att 450 av dessa 1000 svarar ja och 550 svarar nej. Vad säger detta om antalet röstberättigade i Sverige, populationen, som skulle svarat samma på den frågan? En viktig fråga att besvara är om proportionen av ja-svar inom populationen överstiger 0.50, vilket då skulle ge en uppfattning om resultatet vid en folkomröstning.

Låt oss beteckna andelen inom populationen som skulle svara ja som p . Målet är alltså att skatta p . Ett direkt sätt är att helt enkelt beräkna andelen inom vårt stickprov som svarat ja. Vi betecknar detta p_{obs}^* (notationen kommer att förklaras strax) och får då

$$p_{\text{obs}}^* = 450/1000 = 0.45.$$

För att denna skattning ska vara användbar måste vi veta mera. Hur bra är denna skattning, dvs. hur nära ligger den det "sanna" värdet? Vad skulle hända om vi repeterade undersökningen med ett annat urval av tillfrågade? Skulle svaret skilja sig markant? Hur ser fördelningen på skattningen ut mer allmänt? Om vi återgår till frågan om $p > 0.50$ så ligger skattningen 0.45 ganska nära 0.50. Ett fel större än 0.05 skulle då göra opinionsundersökningen relativt värdelös för att förutsäga utfallet av en folkomröstning.

Dessa frågor kan delvis besvaras genom att betrakta en statistisk modell över förloppet. Denna modell utgår från den sökta parametern p och definierar en stokastisk variabel p^* som motsvarar vår skattning. Vad utgör källan till slumpmässigheten i denna modell? Urvalet av utfrågade personer. Om vi har otur råkar vi välja 1000 personer som alla svarar ja på frågan (eller som alla svarar nej), men detta är ganska osannolikt.

I regel kan vi betrakta urvalet som dragning från en urna med röda (svar: ja) och blåa (svar: nej) kulor, eftersom identiteten hos personerna inte spelar någon roll utöver deras svar. Vi frågar inte varje person mer än en gång, så det är en dragning utan återläggning. I vårt fall är sannolikheten att dra samma person två gånger så pass liten (eftersom det totala antalet röstberättigade personer, mer än sju miljoner, är stort med avseende på urvalets storlek, ett tusen). Vi kan därför approximera urvalet som dragning med återläggning. Detta ger att antalet positiva svar X har fördelningen $\text{Bin}(1000, p)$. (Dragning utan återläggning skulle istället gett en hypergeometrisk fördelning.)

Vi skattar då p som $p^* = X/1000$. Notera att detta är en stokastisk variabel eftersom den beror på det slumpmässiga urvalet vi gjort. I det konkreta utfallet vi diskuterade ovan har vi $x = 450$, vilket ger $p_{\text{obs}}^* = 0.45$, alltså det *observerade utfallet* av den stokastiska variabeln p^* . (Man skulle kunna tro att den vanliga konventionen för stokastiska variabler med stora och små bokstäver skulle gälla här, vilket skulle ge P^* och p^* , men så är det tyvärr inte.) Vi kan nu betrakta väntevärdet för p^* , $E[p^*] = E[X]/1000 = 1000p/1000 = p$, eftersom väntevärdet för en $\text{Bin}(n, p)$ -fördelad stokastisk variabel är np . Med andra ord så ligger skattningen i genomsnitt runt det sanna värdet p .

Hur ser spridningen ut? En $\text{Bin}(n, p)$ -fördelad stokastisk variabel har varians $np(1 - p)$, vilket i detta fall ger

$$V[p^*] = V\left[\frac{X}{1000}\right] = \frac{V[X]}{1000^2} = \frac{1000p(1-p)}{1000^2} = \frac{p(1-p)}{1000}.$$

Standardavvikelsen är då $D[p^*] = \sqrt{p(1-p)/1000}$ och beror på den okända parametern p . Eftersom vi inte känner till p kan vi betrakta det maximala värdet på

standardavvikelsen. I detta fall maximeras standardavvikelsen av $p = 0.5$, vilket ger $D[p^*] = \sqrt{0.5^2/1000} \approx 0.016$, dvs. ett fel på 1.6%.

Om vi emellertid antar att vår skattning p_{obs}^* är nära det sanna värdet kan vi använda dess värde *istället* för p . Vi får då $\sqrt{0.45 \times 0.55/1000} \approx 0.016$. (Vårt antagande att p_{obs}^* kan då ses som rimligt då standardavvikelsen är relativt liten.) Vår skattning på 45% kan då anses som någorlunda korrekt, med en approximativ standardavvikelse på 1.6%. Vi ser att skattningen $p_{\text{obs}}^* = 0.45$ så pass nära det värde $p = 0.50$ som ger maximal standardavvikelse att denna approximation inte gör så stor skillnad, men så är inte alltid fallet (i vissa skattningar kan standardavvikelsen bli godtyckligt stor).

Punktskattning

Låt oss nu formalisera och generalisera metoden ovan så att vi kan tillämpa den på andra problem. Allmänt har vi en stokastisk variabel X med en okänd fördelning. Ofta vet vi att fördelningen tillhör en viss familj men har en okänd parameter (som ovan, där X var binomialfördelad med okänd parameter p). Oavsett beror på någon parameter θ i något parameterrum Σ_θ som vi är intresserade av att skatta.

För att lösa denna uppgift har vi ett *stickprov* av X bestående av n oberoende stokastiska variabler $X_1, X_2, \dots, X_n$ med samma fördelning som X (de behöver egentligen inte ha samma fördelning, men borde alla bero på samma parameter θ). Detta stickprov har ett utfall av formen $x_1, x_2, \dots, x_n$, dvs. n reella värden. Givet dessa stickprov har vi en funktion $g(x_1, x_2, \dots, x_n)$ så att


$$\theta_{\text{obs}}^* = g(x_1, x_2, \dots, x_n),$$

är en skattning av parametern θ . Detta värde kallas en *punktskattning* av θ . Om vi istället tillämpar g på de stokastiska variablerna $X_1, X_2, \dots, X_n$ får vi

$$\theta^* = g(X_1, X_2, \dots, X_n),$$

vilket är en *stickprovsvariabel* som motsvarar punktskattningen θ_{obs}^* . (Ibland skrivs detta lite slarvigt som $\theta^* = \theta^*(X_1, X_2, \dots, X_n)$, och $\theta_{\text{obs}}^* = \theta^*(x_1, x_2, \dots, x_n)$, dvs. funktionen g ersätts av "funktionen" θ^* .) Funktionen g är alltså ett "recept" på en skattning av parametern θ givet vissa värden. Om den tillämpas på stokastiska variabler får vi stickprovsvariabeln θ^* , en annan stokastisk variabel. Om den tillämpas på utfall får vi punktskattningen θ_{obs}^* .

Givet θ^* kan vi nu undersöka dess täthetsfunktion (se nedan), dess egenskaper och beräkna dess väntevärde $E[\theta^*]$, varians $V[\theta^*]$ och så vidare. Detta ger oss då en uppfattning om hur själva skattningen θ_{obs}^* skulle bete sig om vi repeterade försöket. Varje repetition skulle då ge en annan skattning och de skulle då vara fördelade enligt θ^* .



Exempel 1. I opinionsundersökningen ovan hade vi att den sökta parametern θ var p , och $X \sim \text{Bin}(1000, p)$. Stickprovet hade storlek $n = 1$, dvs. vi hade en variabel X_1 och beräknade stickprovsvariabeln $p^* = X_1/1000$, vilket gav utfallet $p_{\text{obs}}^* = 0.45$ eftersom $x_1 = 450$.

Alternativt skulle vi kunnat modellera problemet som $n = 1000$ stycken bernoulli-fördelade stokastiska variabler $X_1, X_2, \dots, X_{1000}$ med sannolikhet p att ge ett (svar: ja) och sannolikhet $1 - p$ att ge noll (svar: nej). Vi skulle då fått $p^* = \sum_{i=1}^n X_i/1000$, men svaret förblir detsamma som ovan.

Exempel 2. Låt X vara antalet telefonsamtal till kundservice hos ett visst företag mellan kl. 13:00 och kl. 14:00. Antag att X har fördelningen $\text{Po}(\mu)$. Under en vecka mäter vi antalet samtal 13:00–14:00 måndag–fredag, vilket ger vissa värden x_1, x_2, x_3, x_4, x_5 . En vettig punktskattning kan vara medelvärdet $\mu_{\text{obs}}^* = (x_1 + x_2 + x_3 + x_4 + x_5)/5$.

Stickprovet är då X_1, X_2, X_3, X_4, X_5 oberoende stokastiska variabler fördelade enligt $\text{Po}(\mu)$. Stickprovsvariabeln motsvarande skattningen är då $\mu^* = (X_1 + X_2 + X_3 + X_4 + X_5)/5$.

Exempel 3. Låt oss anta att vi gjort fyra mätningar x_1, x_2, x_3, x_4 av smältpunkten hos en viss legering. Eftersom de mätningarna är behäftade med ett visst fel så överensstämmer de inte helt. Vi kan då anta att mätningarna är utfall av oberoende likafördelade variabler X_1, X_2, X_3, X_4 . Vi söker då parametrarna μ och σ^2 motsvarande väntevärdet och variansen för denna fördelning.

Notera att vi kan anta att fördelningen har en viss form (t.ex. $N(\mu, \sigma)$) men detta är strikt sett inte nödvändigt (även om det kan komma visa sig vara användbart).

Skattning av väntevärde och varians

I det sista exemplet ovan noterade vi att det inte är nödvändigt att specificera en viss fördelning: den sökta parametern kan helt enkelt vara väntevärdet eller variansen hos en viss stokastisk variabel. I dessa fall kan vi definiera några standardskatt-

ningar. De kommer inte alltid att vara optimala (även om de ofta är det), men kan utgöra en användbar utgångspunkt för mer sofistikerade skattningar.

Till och börja med har vi det *aritmetiska medelvärdet*, som vi sett innan. Givet en samling utfall $x_1, x_2, \dots, x_n$ har vi

$$\mu_{\text{obs}}^* = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

vilket ses som ett utfall av stickprovsvariabeln

$$\mu^* = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

där vi betraktar stickprovet av oberoende likafördelade $X_1, X_2, \dots, X_n$. Vi kommer se i nästa del att denna skattning har en rad trevliga egenskaper, oavsett vilken fördelning stickprovet härstammar från.

Den andra viktiga punktskattningen är *stickprovsvariansen*

$$(\sigma^2)_{\text{obs}}^* = s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Notera att denna beror på det aritmetiska medelvärdet $\bar{x}$ eftersom väntevärdet måste skattas också. (Om väntevärdet redan är känt kan man använda en variant av stickprovsvariansen ovan, men detta fall är ganska sällsynt.) Den motsvarande stickprovsvariabeln är

$$(\sigma^2)^* = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$


Notera att vi ofta använder beteckningarna s^2 och S^2 istället för de klumpigare $(\sigma^2)_{\text{obs}}^*$ och $(\sigma^2)^*$.

Egenskaper hos punktskattningar

En viktig egenskap hos en punktskattning är att dess stickprovsvariabel har ett väntevärde som överensstämmer med den sanna parametern. Med andra ord, om vi repeterar skattningen ett stort antal gånger kommer medelvärdet att närma sig det korrekta värdet. Givet en punktskattning θ_{obs}^* av en parameter θ : säger vi att den är *väntevärdesriktig* om

$$E[\theta^*] = \theta$$

där θ^* är den motsvarande stickprovsvariabeln. (Vi kan också kräva att väntevärdet $E[\theta^*]$ närmar sig θ då antalet element i stickprovet går mot oändligheten, vilket betyder att skattningen är *asymptotiskt väntevärdesriktig*.) Skillnaden $E[\theta^*] - \theta$ kallas det *systematiska felet* hos skattningen.



Det aritmetiska väntevärdet är väntevärdesriktigt eftersom

$$E[\mu^*] = E[\bar{X}] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \times n \times E[X] = E[X] = \mu.$$

Stickprovsvariansen likaså då

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X})^2 &= \sum_{i=1}^n ((X_i - \mu) - (\bar{X} - \mu))^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - 2(\bar{X} - \mu) \sum_{i=1}^n (X_i - \mu) + n(\bar{X} - \mu)^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - 2n(\bar{X} - \mu)^2 + n(\bar{X} - \mu)^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2, \end{aligned}$$

vilket ger, eftersom $V[\bar{X}] = \sigma^2/n$ som vi såg tidigare,

$$\begin{aligned} E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] &= E\left[\sum_{i=1}^n (X_i - \mu)^2\right] - nE[(\bar{X} - \mu)^2] \\ &= nE[(X - \mu)^2] - nV[\bar{X}] = n\sigma^2 - n\frac{\sigma^2}{n} = (n-1)\sigma^2 \end{aligned}$$


så $E[S^2] = \frac{1}{n-1}(n-1)\sigma^2 = \sigma^2$. Detta förklarar varför vi behöver $n-1$ istället för n i nämnaren: annars skulle skattningen inte vara väntevärdesriktig.

Notera att även om stickprovsvariansen s^2 är väntevärdesriktig så är detta inte fallet för stickprovsstandardavvikelsen s eftersom vi inte kan "flytta in" kvadratroten innanför väntevärdet (dvs. $E[S] = E[\sqrt{S^2}] \neq \sqrt{E[S^2]} = \sqrt{\sigma^2} = \sigma$). Ofta har vi däremot att det systematiska felet $E[S] - \sigma$ är så litet att det inte spelar så stor roll.

En annan viktig egenskap beskriver hur skattningen beter sig med avseende på stickprovsstorleken. Antag att vi har ett oändligt stort stickprov $X_1, X_2, \dots$ samt en följd av punktskattningar $\theta_{1,obs}^*, \theta_{2,obs}^*, \dots$ där $\theta_{n,obs}^*$ bara beror på de n första värdena $X_1, X_2, \dots, X_n$. Med andra ord har $\theta_{n,obs}^*$ stickprovsstorleken n . Låt θ_n^* vara stickprovsvariabeln motsvarande $\theta_{n,obs}^*$. Om

$$\lim_{n \rightarrow \infty} P(|\theta_n^* - \theta| > \epsilon) = 0,$$

för varje $\epsilon > 0$ sägs denna följd av punktskattningar vara *konsistent*.



Detta är en naturlig och användbar egenskap hos skattningar – när antalet datapunkter går mot oändligheten förväntar vi oss att skattningen blir mer och mer exakt. Vi ser att det aritmetiska medelvärdet $\bar{x}$ bildar en konsistent följd av punktskattningar på grund av stora talens lag. För att erhålla ett liknande resultat för stickprovsvariansen krävs att $V[(X_i - \bar{X})^2]$ är ändlig, dvs. att $E[|X|^4]$ är ändlig, vilket inte alltid är fallet för alla fördelningar. När detta gäller, som till exempel för normalfördelningen, är stickprovsvariansen en konsistent skattning.

Att felet går till noll när n går mot oändligheten är bra att veta, men vi är också intresserade av *felet* i skattningen θ_{obs}^* av θ . Detta definieras oftast som *medelkvadratfelet* (MSE från engelskans "mean square error")

$$MSE = E[(\theta^* - \theta)^2]$$

där θ^* är den motsvarande stickprovsvariabeln. I regel vill vi ha ett lågt MSE, då detta betyder att den slumpmässiga inverkan på skattningen θ_{obs}^* är liten. Notera att MSE beror på den sökta parameterns θ värde. I vissa tillämpningar är det relevant att ta maximum över möjliga θ -värden och vi får då ett specifikt maxfel för en viss

skattning. Alternativt kan vi ha en fördelning över troliga θ -värden och beräkna väntevärdet av medelkvadratfelet med avseende på denna fördelning. Detta kallas punktskattningens Bayesrisk och kommer att introduceras senare i kursen.

Om vi utvecklar lite ser vi att medelkvadratfelet kan uttryckas som summan av två felkomponenter:

$$\begin{aligned} \text{MSE} &= E[(\theta^* - \theta)^2] \\ &= E[(\theta^* - E[\theta^*] + E[\theta^*] - \theta)^2] \\ &= E[(\theta^* - E[\theta^*])^2] + 2E[\theta^* - E[\theta^*]](E[\theta^*] - \theta) + (E[\theta^*] - \theta)^2 \\ &= E[(\theta^* - E[\theta^*])^2] + 0 + (E[\theta^*] - \theta)^2 \\ &= V[\theta^*] + (E[\theta^*] - \theta)^2 \end{aligned}$$

Med andra ord så beror felet dels på skattningens varians $V[\theta^*]$ samt kvadraten av det systematiska felet $E[\theta^*] - \theta$. Minimeringen av MSE sker då genom att minimera både variansen och det systematiska felet. Tyvärr är detta inte alltid möjligt, utan en mindre varians kan ge ett större systematiskt fel och vice versa. Den optimala avvägningen mellan systematiskt fel och varians beror ofta på tillämpningen. Man kan, till exempel, ofta tillåta ett litet systematiskt fel om variansen minskas.

Som vi sett ovan har vi dock ofta att det systematiska felet är noll, dvs. att skattningen är väntevärdesriktig. I så fall har vi att $\text{MSE} = V[\theta^*]$. Om det systematiska felet är litet utan att vara noll kan det fortfarande vara bra att istället fokusera på variansen. Detta förenklar bland annat beräkningar och låter oss jämföra olika skattningar. Låt θ_{obs}^* och $\hat{\theta}_{\text{obs}}$ vara två olika punktskattningar. Vi säger att θ_{obs}^* är *effektivare* än $\hat{\theta}_{\text{obs}}$ om

$$V[\theta^*] \leq V[\hat{\theta}]$$

för alla $\theta \in \Sigma_\theta$ samt att det finns ett $\theta_0 \in \Sigma_\theta$ så att

$$V[\theta^*] < V[\hat{\theta}].$$

För vissa punktskattningar kan vi visa att de är effektivare än alla andra möjliga skattningar.

Föreläsning nio

Joakim Andén

Maximum-likelihood-skattning

I föregående föreläsning diskuterade vi två konkreta punktskattningar: det aritmetiska medelvärdet och stickprovsvariansen. Dessa visade sig ha ett antal användbara egenskaper som väntevärdesriktighet och konsistens (för stickprovsvariansen gäller detta inte allmänt men för många fördelningar, som till exempel normalfördelningen). Frågan kvarstår dock om hur man går till väga för att konstruera punktskattningar mer allmänt för olika parametrar.

Ett sätt går ut på att betrakta hur sannolikheten för erhållna mätvärden varierar med valet av parameter. Låt oss först introducera notation som klargör detta beroende. Vi antar att θ är en parameter med värde i ett parameterrum Σ_θ . I vår modell skriver vi då $P(A; \theta)$ för sannolikheten att A inträffar när parametern är θ . På samma sätt skriver vi sannolikhetsfunktionen för diskreta stokastiska variabler som $p_X(x; \theta)$ och täthetsfunktionen för kontinuerliga stokastiska variabler som $f_X(x; \theta)$. Om θ_0 är den sanna parametern som genererat våra mätvärden följer dessa då sannolikhetsmåttet $P(A; \theta_0)$ och har sannolikhetsfunktionerna $p_X(x; \theta_0)$ (i det diskreta fallet) eller täthetsfunktionerna $f_X(x; \theta_0)$ (i det kontinuerliga fallet).

Antag nu att vi har n oberoende diskreta stokastiska variabler $X_1, X_2, \dots, X_n$, inte nödvändigtvis likafördelade, genererade enligt parametern $\theta = \theta_0$. Sannolikheten att dessa har utfallen $x_1, x_2, \dots, x_n$ för parametern θ (dvs. ett annat värde på θ jämfört med θ_0) är då

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta) = \prod_{i=1}^n p_{X_i}(x_i; \theta).$$


Antag att vi erhållit just dessa mätvärden $x_1, x_2, \dots, x_n$. Vi kan då vända på beroendet och bilda funktionen

$$L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n p_{X_i}(x_i; \theta)$$

som kallas *likelihoodfunktionen* och motsvarar en sorts "rimlighet" för parametern θ – dvs. sannolikheten att just dessa värden erhållits om parametern är lika med θ .

Antag till exempel att vi har två parametervärden θ_1 och θ_2 samt dess sannolikhetsfunktioner $p_X(x; \theta_1)$ och $p_X(x; \theta_2)$. Om vi plottar dessa funktioner tillsammans

med histogrammet av mätdata nedan så ser vi att en av parametervärdena verkar passa datan bättre än den andra.



För att skatta den sanna parametern θ_0 antar vi att det θ som maximerar likelihoodfunktionen (dvs. det θ som är "rimligast") ligger nära θ_0 . Detta kallas *likelihoodprincipen* och vi kallar detta maximerande värde på θ för *maximum-likelihood-skattningen*, eller ML-skattningen, av θ och betecknar den som vanligt med θ_{obs}^* . Vi har då att ML-skattningen θ_{obs}^* uppfyller

$$L(\theta_{\text{obs}}^*; x_1, x_2, \dots, x_n) \geq L(\theta; x_1, x_2, \dots, x_n)$$

för alla $\theta \in \Omega_\theta$. Detta kan verka lite kontraintuitivt, men är en mycket naturlig skattning. Vi säger helt enkelt att för andra värden på θ så är sannolikheten mindre att vi fick de observerade mätvärdena. Om vi inte har väldigt otur och får väldigt osannolika utfall så borde detta hålla. Det visar sig att för större stickprovsstorlekar n har vi mindre sannolikt otur och ML-skattningen blir mer exakt.


Exempel 1. Om vi återgår till opinionsundersökningen innan har vi utfallet $k = 450$ av den diskreta stokastiska variabeln $X \sim \text{Bin}(1000, p)$ och söker värdet på p . Vi har då likelihoodfunktionen

$$L(p; k) = p_X(x; p) = \binom{1000}{x} p^x (1-p)^{1000-x}.$$

I vårt fall ger $x = 450$ funktionen

$$L(p; 450) = \binom{1000}{450} p^{450} (1-p)^{550},$$

och vi söker värdet på p som maximerar denna funktion.



Som den ser ut är likelihoodfunktionen lite komplicerad att maximera rätt av, så vi använder oss av ett användbart trick: logaritmering. Eftersom logaritmen är en strikt växande funktion så har detta ingen effekt på det p som maximerar funktionen. Logaritmen av likelihoodfunktionen är då

$$\log L(p; 450) = \log \binom{1000}{450} + 450 \log p + 550 \log(1 - p).$$

Om vi deriverar med avseende på p fås

$$\frac{d}{dp} \log L(p; 450) = \frac{450}{p} - \frac{550}{1 - p},$$

vilket är noll då $p = 450/(550 + 450) = 0.45$. För att verifiera att detta utgör ett maximum beräknar vi andraderivatan

$$\frac{d^2}{dp^2} \log L(p; 450) = -\frac{450}{p^2} - \frac{550}{(1 - p)^2}.$$

Eftersom denna är negativ är alla kritiska punkter (inklusive $p = 0.45$) lokala maximum. Randvärdena $L(0; 450) = 0$ och $L(1; 450) = 0$ är mindre än $L(0.45; 450) > 0$ så $p = 0.45$ är ett globalt maximum för $L(p; 450)$ över $[0, 1]$. Med andra ord har vi ML-skattningen $p_{\text{obs}}^* = 0.45$, vilket överensstämmer med den intuitiva skattningen vi definierade i föregående föreläsning.

Logaritmtricket som tillämpades ovan är så vanligt att man brukar ge funktionen $\log L(\theta; x_1, x_2, \dots, x_n)$ ett speciellt namn: *log-likelihoodfunktionen*.

Fallet ovan med $n = 1$ är inte så typiskt för parameterskattningar. Låt oss betrakta ett mer naturligt exempel.

Exempel 2. Låt återigen X vara antalet telefonsamtal till kundservice hos ett visst mellan kl. 13:00 och kl. 14:00. Om X har fördelningen $\text{Po}(\mu)$ och vi observerar fem oberoende mätvärden $k_1, k_2, \dots, k_5$ (ett värde för varje vardag under en vecka) får vi likelihoodfunktionen

$$L(\mu; k_1, k_2, \dots, k_5) = \prod_{i=1}^5 p_X(k_i; \mu) = \prod_{i=1}^5 \frac{\mu^{k_i} e^{-\mu}}{k_i!} = \mu^{\sum_{i=1}^5 k_i} e^{-5\mu} \prod_{i=1}^5 \frac{1}{k_i!}.$$

Log-likelihoodfunktionen fås som

$$\log L(\mu; k_1, k_2, \dots, k_5) = (\log \mu) \sum_{i=1}^5 k_i - 5\mu + C$$

där C är en konstant som inte beror på μ . Derivatan är då

$$\frac{d}{d\mu} \log L(\mu; k_1, k_2, \dots, k_5) = \frac{1}{\mu} \sum_{i=1}^5 k_i - 5$$

vilket ger en kritisk punkt i $\mu = \frac{1}{5} \sum_{i=1}^5 k_i$. Derivatan är strikt avtagande, så andraderivatan är negativ, vilket ger att den kritiska punkten är ett lokalt maximum. Randvärdet $\mu = 0$ har $L(0; k_1, k_2, \dots, k_5) = 0$ så det lokala maximum i $\mu = \frac{1}{5} \sum_{i=1}^5 k_i$ är ett globalt maximum. ML-skattningen av μ är då $\mu_{\text{obs}}^* = \frac{1}{5} \sum_{i=1}^n k_i$.

Antag att vi observerade värdena 11, 13, 10, 14, 12, vi får då $\mu_{\text{obs}}^* = 60/5 = 12$.

För kontinuerliga stokastiska variabler återkommer problemet att sannolikheten att $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ är noll, oavsett vilket värde på θ vi använder. Som innan så antar vi istället att utfallen ligger i ett litet intervall av storlek Δx och får då, eftersom variablerna är oberoende,

$$\begin{aligned} P(X_1 \in [x_1, x_1 + \Delta x], X_2 \in [x_2, x_2 + \Delta x], \dots, X_n \in [x_n, x_n + \Delta x]; \theta) \\ = \int_{u_1=x_1}^{x_1+\Delta x} \int_{u_2=x_2}^{x_2+\Delta x} \dots \int_{u_n=x_n}^{x_n+\Delta x} \prod_{i=1}^n f_{X_i}(u_i; \theta) du_n \dots du_2 du_1 \\ = \Delta x^n \prod_{i=1}^n f_{X_i}(x_i + \alpha_i \Delta x; \theta), \end{aligned} \quad (\text{medelvärdessatsen})$$

för $(\alpha_1, \alpha_2, \dots, \alpha_n) \in [0, 1]^n$. Om vi nu tar kvoten av sannolikheterna för två parametrar θ_1 och θ_2 har vi

$$\begin{aligned} \frac{P(X_1 \in [x_1, x_1 + \Delta x], X_2 \in [x_2, x_2 + \Delta x], \dots, X_n \in [x_n, x_n + \Delta x]; \theta_1)}{P(X_1 \in [x_1, x_1 + \Delta x], X_2 \in [x_2, x_2 + \Delta x], \dots, X_n \in [x_n, x_n + \Delta x]; \theta_2)} \\ = \frac{\prod_{i=1}^n f_{X_i}(x_i + \alpha_i \Delta x; \theta_1)}{\prod_{i=1}^n f_{X_i}(x_i + \alpha_i \Delta x; \theta_2)}. \end{aligned}$$

Låter vi $\Delta x \rightarrow 0$ ger detta kvoten

$$\frac{\prod_{i=1}^n f_{X_i}(x_i; \theta_1)}{\prod_{i=1}^n f_{X_i}(x_i; \theta_2)}.$$

Denna kvot kan alltså ses som hur sannolika mätvärdena är för parametern θ_1 jämfört med parametern θ_2 . Om kvoten är större än ett antar vi att θ_1 är ett "rimligare" parametervärde än θ_2 .

Med bakgrund av detta definierar vi likelihoodfunktionen för oberoende kontinuerliga stokastiska variabler som

$$L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i; \theta),$$

och ML-skattningen θ_{obs}^* fås återigen som det θ som maximerar $L(\theta; x_1, x_2, \dots, x_n)$.

Exempel 3. Låt $X_1, X_2, \dots, X_n$ vara oberoende stokastiska variabler med fördelning $\text{Exp}(\lambda)$, dvs. med täthetsfunktioner

$$f_{X_i}(x_i) = \begin{cases} \lambda e^{-\lambda x_i}, & x \geq 0, \\ 0, & \text{annars.} \end{cases}$$

Detta ger likelihoodfunktionen

$$L(\lambda; x_1, x_2, \dots, x_n) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i},$$

och vi får då log-likelihoodfunktionen

$$\log L(\lambda; x_1, x_2, \dots, x_n) = n \log \lambda - \lambda \sum_{i=1}^n x_i.$$

Derivatan är

$$\frac{d}{d\lambda} \log L(\lambda; x_1, x_2, \dots, x_n) = \frac{n}{\lambda} - \sum_{i=1}^n x_i,$$

som har nollstället $\lambda = \left(\frac{1}{n} \sum_{i=1}^n x_i\right)^{-1} = 1/\bar{x}$. Derivatan är strikt avtagande i λ så detta är ett lokalt maximum. Likelihoodfunktionen är noll för $\lambda = 0$, så det lokala maximumet är globalt. Med andra ord har vi ML-skattningen $\lambda_{\text{obs}}^* = 1/\bar{x}$.

Om vi observerar värdena 2.1, 0.3 och 1.6 blir ML-skattningen här $\lambda_{\text{obs}}^* = 3/(2.1 + 0.3 + 1.6) = 3/3.6 = 5/6 \approx 0.833$.

Som vi ser följer metoden för att bestämma ML-skattningen ett par distinkta steg:

- (i) Bilda likelihoodfunktionen: $L(\theta; x_1, x_2, \dots, x_n)$.
- (ii) Logaritmera: $\log L(\theta; x_1, x_2, \dots, x_n)$.
- (iii) Maximera.

Notera att vi inte alltid behöver logaritmera: ibland räcker det att arbeta med likelihoodfunktionen. Det sista steget kan göras genom att derivera log-likelihoodfunktionen, hitta nollställena, och bestämma ett globalt maximum genom att betrakta andraderivatan samt randvärdena. Detta är inte alltid möjligt (om likelihoodfunktionen är diskontinuerlig) eller önskvärt (om beräkning av derivatan eller andraderivatan är mycket arbetskrävande).

Exempel 4. Som exempel på en annorlunda ML-skattning betraktar vi den likformiga fördelningen $U[0, \theta]$. Givet oberoende stokastiska variabler $X_1, X_2, \dots, X_n$ med denna fördelning har vi täthetsfunktionerna

$$f_{X_i}(x_i; \theta) = \begin{cases} \frac{1}{\theta}, & x_i \in [0, \theta], \\ 0, & \text{annars.} \end{cases}$$


Detta ger likelihoodfunktionen

$$L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i) = \begin{cases} \frac{1}{\theta^n}, & \theta \geq \max(x_1, x_2, \dots, x_n), \\ 0, & \text{annars,} \end{cases}$$

eftersom om någon $x_i > \theta$ så blir dess täthetsfunktion $f_{X_i}(x_i; \theta)$ noll. Att någon av alla x_i är större än θ är detsamma som att $\max(x_1, x_2, \dots, x_n) > \theta$. Vi har då att en av täthetsfunktionerna är noll, så hela likelihoodfunktionen är noll i detta fall. Om $\max(x_1, x_2, \dots, x_n) \leq \theta$ så är alla täthetsfunktioner lika med $1/\theta$, så likelihoodfunktionen är då lika med $1/\theta^n$.

För θ större än $\max(x_1, x_2, \dots, x_n)$ så avtar alltså likelihoodfunktionen och för $\theta < \max(x_1, x_2, \dots, x_n)$ är den noll, vilket ger att maximum uppnås i

$$\theta_{\text{obs}}^* = \max(x_1, x_2, \dots, x_n).$$



Vad har denna punktskattning för egenskaper? Vi vet sedan tidigare att fördelningsfunktionen för maximum $\theta^* = \max(X_1, X_2, \dots, X_n)$ ges av

$$F_{\theta^*}(\theta) = (F_X(\theta))^n.$$

Om θ_0 är den sanna parametern för fördelningen har vi

$$F_X(x) = \begin{cases} \frac{x}{\theta_0}, & x \in [0, \theta_0], \\ 0, & \text{annars,} \end{cases}$$

vilket ger

$$F_{\theta^*}(\theta) = \begin{cases} \frac{\theta^n}{\theta_0^n}, & \theta \in [0, \theta_0], \\ 0, & \text{annars.} \end{cases}$$

Täthetsfunktionen är då

$$f_{\theta^*}(\theta) = \begin{cases} \frac{n\theta^{n-1}}{\theta_0^n}, & \theta \in [0, \theta_0], \\ 0, & \text{annars,} \end{cases}$$

och väntevärdet blir

$$E[\theta^*] = \int_{-\infty}^{+\infty} \theta f_{\theta^*}(\theta) d\theta = \int_0^{\theta_0} \theta \cdot \frac{n\theta^{n-1}}{\theta_0^n} d\theta = \frac{n}{n+1} \theta_0.$$

ML-skattningen är alltså inte väntevärdesriktig.

Som tur är ger formeln ovan tillräckligt med information för att korrigera skattningen. Om vi tar

$$\hat{\theta}_{\text{obs}} = \frac{n+1}{n} \max(x_1, x_2, \dots, x_n)$$

är denna skattning väntevärdesriktig. Vi ser också att $E[\max(X_1, X_2, \dots, X_n)^2] = \frac{n}{n+2} \theta_0^2$, vilket ger att $E[\hat{\theta}^2] = \frac{(n+1)^2}{n(n+2)} \theta_0^2$ och $V[\hat{\theta}] = \frac{\theta_0^2}{n(n+2)}$.

Som vi såg i exemplet är ML-skattningen inte alltid väntevärdesriktig, men kan ofta omvandlas till en väntevärdesriktig skattning genom att multiplicera med en konstant. Denna skattning kallas ofta för den *korrigerade ML-skattningen*.

ML-skattningar kan också definieras för fler än en parameter. Om vi har parametrarna $\theta_1, \theta_2, \dots, \theta_k$ är likelihoodfunktionen för $X_1, X_2, \dots, X_n$ oberoende stokastiska variabler

$$L(\theta_1, \theta_2, \dots, \theta_k; x_1, x_2, \dots, x_n) = \prod_{i=1}^n p_{X_i}(x_i; \theta_1, \theta_2, \dots, \theta_k), \quad (\text{diskreta fallet})$$

$$L(\theta_1, \theta_2, \dots, \theta_k; x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i; \theta_1, \theta_2, \dots, \theta_k). \quad (\text{kontinuerliga fallet})$$

ML-skattningen fås då för de värden på $\theta_1, \theta_2, \dots, \theta_k$ som samtidigt maximerar likelihoodfunktionen.

Exempel 5. Antag att $X_1, X_2, \dots, X_n$ är oberoende med fördelning $N(\mu, \sigma)$. Låt oss skatta μ och σ^2 . Likelihoodfunktionen är

$$L(\mu, \sigma^2; x_1, x_2, \dots, x_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x_i - \mu)^2 / 2\sigma^2} = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2},$$

vilket ger log-likelihoodfunktionen

$$\log L(\mu, \sigma^2; x_1, x_2, \dots, x_n) = -\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 + C,$$

där C är en konstant som inte beror på μ eller σ^2 .

För att maximera en tvådimensionell funktion söker vi först dess kritiska punkter där partialderivatorna är noll. Ett globalt maximum är en kritisk punkt, men det kan finnas flera sådana, så för varje kritisk punkt måste vi verifiera om den är ett globalt maximum eller inte.

Partialderivatorna hos log-likelihoodfunktionen är

$$\begin{aligned}\frac{\partial}{\partial \mu} \log L(\mu, \sigma^2; x_1, x_2, \dots, x_n) &= \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu), \\ \frac{\partial}{\partial \sigma^2} \log L(\mu, \sigma^2; x_1, x_2, \dots, x_n) &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2.\end{aligned}$$

Derivatn med avseende på μ är noll när $\mu = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$ medan σ^2 är noll då $\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$. Punkten

$$(\mu, \sigma^2) = \left(\bar{x}, \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)$$

är alltså det enda simultana nollstället för båda partialderivatorna.

För att bekräfta att denna punkt är ett globalt maximum har vi ett par alternativ. Vi kan beräkna andraderivatorna för log-likelihoodfunktionen och visa att matrisen som bildas bara har negativa egenvärden, men detta kräver mycket arbete (även om det är fullt möjligt att utföra). Vi kan också visa att likelihoodfunktionen går mot noll då μ och σ^2 går mot oändligheten, men detta är komplicerat eftersom variablerna interagerar på ett icke-trivialt sätt.

Istället visar vi först att $\mu = \bar{x}$ maximerar log-likelihoodfunktionen med avseende på μ och fixerar sedan $\mu = \bar{x}$ och visar att detta maximeras av $\sigma^2 = Q/n$ där vi låtit $Q = \sum_{i=1}^n (x_i - \bar{x})^2$. Först noterar vi att $\sum_{i=1}^n (x_i - \mu)^2$ alltid minimeras i $\mu = \bar{x}$ eftersom

$$\begin{aligned}\sum_{i=1}^n (x_i - \mu)^2 &= \sum_{i=1}^n ((x_i - \bar{x}) + (\bar{x} - \mu))^2 \\ &= \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n 2(x_i - \bar{x})(\bar{x} - \mu) + n(\bar{x} - \mu)^2 \\ &= \sum_{i=1}^n (x_i - \bar{x})^2 + 0 + n(\bar{x} - \mu)^2 \geq \sum_{i=1}^n (x_i - \bar{x})^2\end{aligned}$$

där vi får likhet då $\mu = \bar{x}$. På grund av detta har vi

$$-\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \leq -\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2,$$

dvs.

$$\log L(\mu, \sigma^2; x_1, x_2, \dots, x_n) \leq \log L(\bar{x}, \sigma^2; x_1, x_2, \dots, x_n),$$

för alla $\mu \in \mathbb{R}$ och $\sigma^2 \in \mathbb{R}_{>0}$. Med andra ord så för varje $\sigma^2 \in \mathbb{R}_{>0}$ har vi att $\mu = \bar{x}$ maximerar funktionen $\mu \mapsto \log L(\mu, \sigma^2; x_1, x_2, \dots, x_n)$. Det räcker då att visa att $\sigma^2 = Q/n$ maximerar funktionen $\sigma^2 \mapsto \log L(\bar{x}, \sigma^2; x_1, x_2, \dots, x_n)$.

Vi vet redan att

$$\frac{d}{d\sigma^2} \log L(\bar{x}, \sigma^2; x_1, x_2, \dots, x_n) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \bar{x})^2,$$

och att denna är noll för $\sigma^2 = Q/n$ så vi behöver bara bekräfta att andraderivatan är negativ i den punkten. Andraderivatan med avseende på σ^2 är

$$\begin{aligned} \frac{d^2}{(d\sigma^2)^2} \log L(\bar{x}, \sigma^2; x_1, x_2, \dots, x_n) &= \frac{n}{\sigma^4} - \frac{2}{2\sigma^6} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} Q \\ &= \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} n\sigma^2 = -\frac{n}{2\sigma^4} < 0. \end{aligned}$$

Med andra ord är σ^2 ett globalt maximum för $\log L(\bar{x}, \sigma^2; x_1, x_2, \dots, x_n)$ och det följer då att ML-skattningen av (μ, σ^2) är

$$(\mu_{\text{obs}}^*, (\sigma^2)_{\text{obs}}^*) = \left(\bar{x}, \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right).$$

Notera att ML-skattningen av μ är väntevärdesriktig men så är inte fallet för σ^2 . För att denna ska vara väntevärdesriktig måste vi korrigera den och får då stickprovsvariansen

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Hittills har vi antagit att alla stokastisk variabler i stickprovet har samma fördelning, men det behöver inte vara fallet. Det viktiga är att deras fördelningar beror på samma parametrar – parametrarna vi vill skatta.

Exempel 6. Antag att vi har två stickprov, det ena fördelat som $N(\mu_1, \sigma)$ och det andra fördelat som $N(\mu_2, \sigma)$. Med andra ord har vi olika väntevärden, men samma varians. Detta uppstår, till exempel, om vi använder samma mätinstrument (med samma felfördelning, dvs. samma varians) och mäter olika storheter.

Mer konkret har vi $X_1, X_2, \dots, X_{n_1} \sim N(\mu_1, \sigma)$ och $Y_1, Y_2, \dots, Y_{n_2} \sim N(\mu_2, \sigma)$. Alla stokastiska variabler är oberoende. Likelihoodfunktionen är nu

$$\begin{aligned} L(\mu_1, \mu_2, \sigma^2; x_1, x_2, \dots, x_{n_1}, y_1, y_2, \dots, y_{n_2}) \\ &= \prod_{i=1}^{n_1} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x_i - \mu_1)^2 / 2\sigma^2} \prod_{j=1}^{n_2} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(y_j - \mu_2)^2 / 2\sigma^2} \\ &= \frac{1}{(2\pi\sigma^2)^{\frac{n_1+n_2}{2}}} e^{-\frac{1}{2\sigma^2} (\sum_{i=1}^{n_1} (x_i - \mu_1)^2 + \sum_{j=1}^{n_2} (y_j - \mu_2)^2)}. \end{aligned}$$

Log-likelihoodfunktionen är då

$$\begin{aligned} \log L(\mu_1, \mu_2, \sigma^2; x_1, x_2, \dots, x_{n_1}, y_1, y_2, \dots, y_{n_2}) \\ = -\frac{n_1 + n_2}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \left(\sum_{i=1}^{n_1} (x_i - \mu_1)^2 + \sum_{j=1}^{n_2} (y_j - \mu_2)^2 \right) + C, \end{aligned}$$

där C är en konstant som inte beror på μ_1 , μ_2 eller σ^2 .

Som innan kan vi beräkna partialderivatorna med avseende på μ_1 , μ_2 och σ^2 . Dessa är alla noll i den kritiska punkten

$$(\mu_1, \mu_2, \sigma^2) = \left(\bar{x}, \bar{y}, \frac{Q_1 + Q_2}{n_1 + n_2} \right),$$

där $Q_1 = \sum_{i=1}^{n_1} (x_i - \bar{x})^2$ och $Q_2 = \sum_{j=1}^{n_2} (y_j - \bar{y})^2$. På samma sätt som föregående exempel kan vi också visa att $\mu_1 = \bar{x}$ och $\mu_2 = \bar{y}$ maximerar log-likelihoodfunktionen med avseende på μ_1 och μ_2 :

$$\begin{aligned} \log L(\bar{x}, \bar{y}, \sigma^2; x_1, x_2, \dots, x_{n_1}, y_1, y_2, \dots, y_{n_2}) \\ \geq \log L(\mu_1, \mu_2, \sigma^2; x_1, x_2, \dots, x_{n_1}, y_1, y_2, \dots, y_{n_2}) \end{aligned}$$

för alla $\mu_1, \mu_2 \in \mathbb{R}$ och $\sigma^2 \in \mathbb{R}_{>0}$. Om vi deriverar vänsterledet med avseende på σ^2 två gånger ser vi återigen att andraderivatan är negativ, så vår kritiska punkt är ett globalt maximum. Vi har alltså ML-skattningen

$$((\mu_1)_{\text{obs}}^*, (\mu_2)_{\text{obs}}^*, (\sigma^2)_{\text{obs}}^*) = \left(\bar{x}, \bar{y}, \frac{Q_1 + Q_2}{n_1 + n_2} \right).$$

Som i fallet med ett stickprov är variansskattningen inte väntevärdesriktig utan måste korrigeras. Den korrigerade ML-skattningen för variansen är

$$\frac{Q_1 + Q_2}{(n_1 - 1) + (n_2 - 1)} = \frac{\sum_{i=1}^{n_1} (x_i - \bar{x})^2 + \sum_{j=1}^{n_2} (y_j - \bar{y})^2}{(n_1 - 1) + (n_2 - 1)}$$

och brukar betecknas s^2 .

ML-skattningar har ett antal viktiga egenskaper. Det första är att om vi har två parametrar θ och η så att η kan skrivas som en strikt monoton funktion $g(\theta)$ av θ så gäller att $\eta_{\text{obs}}^* = g(\theta_{\text{obs}}^*)$. Med andra ord så kan vi beräkna ML-skattningen av η från ML-skattningen av θ – den är invariant med avseende på parametreringen. Som konsekvens av detta kan vi se att ML-skattningen för σ i normalfördelningen ovan är helt enkelt

$$\sigma_{\text{obs}}^* = \sqrt{(\sigma^2)_{\text{obs}}^*} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

En annan egenskap är konsistens. Man kan visa att under vissa (relativt milda) krav på fördelningen, så är ML-skattningen konsistent, dvs. den konvergerar mot

det sanna värdet då $n \rightarrow +\infty$. Till slut så kan man visa (återigen under relativt milda krav) att ML-skattningen är effektivast (dvs. den har minst varians) bland alla punktskattningar då $n \rightarrow +\infty$.

Med alla dessa trevliga egenskaper kan man fråga sig om det ens är värt att betrakta andra skattningar. Den stora nackdelen med ML-skattningar är tyvärr att de kan vara svåra att beräkna för alla fördelningar. I fördelningarna som vi har betraktat ovan har vi haft tur att ML-skattningen kan skrivas på sluten form. Detta är inte så vanligt för mer komplicerade fördelningar (som, till exempel, blandningsmodeller). Om en sluten form saknas måste ML-skattningen beräknas numeriskt genom optimeringsalgoritmer. En vanlig komplikation är då att algoritmerna kan ta lång tid att konvergera, eller det inte ens kan garanteras att de konvergerar. Under dessa förhållanden kan andra skattningar spela en viktig roll, även om de inte har lika fördelaktiga egenskaper som ML-skattningen.

Minsta-kvadrat-skattning

En viktig förutsättning för ML-skattningen är att vi har tillgång till fördelningen hos de stokastiska variabler vars utfall utgör vår mätdata. Så är inte alltid fallet. Vi kanske vet att vår mätdata är behäftade med vissa fel, men inte hur dessa fel är fördelade. Antag att vi har $X_1, X_2, \dots, X_n$ oberoende stokastiska variabler vars fördelningar beror på en parameter θ . Om vi betecknar väntevärdet av X_i där fördelningen har parametern θ med $E[X_i; \theta]$ så har vi funktionerna

$$\mu_i(\theta) = E[X_i; \theta]$$

som beskriver väntevärdet som funktion av parametern. Ekvivalent kan vi skriva X_i som

$$X_i = \mu_i(\theta) + E_i$$

där $E_1, E_2, \dots, E_n$ är oberoende stokastiska variabler med $E[E_i] = 0$ för alla $i = 1, 2, \dots, n$.

Om vi vidare antar att felen har samma varians, dvs. att $V[E_i] = \sigma^2$ för alla $i = 1, 2, \dots, n$ är det naturligt att minimera följande kvadratsumma:

$$Q(\theta) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (x_i - \mu_i(\theta))^2,$$

där $e_1, e_2, \dots, e_n$ är utfall av $E_1, E_2, \dots, E_n$. Det θ_{obs}^* som minimerar $Q(\theta)$ kallas *minsta-kvadrat-skattningen* (MK-skattningen) av θ . Notera att denna endast är användbar då $\mu_i(\theta)$ inte är konstant, dvs. att θ har en effekt på väntevärdet. Den kan, till exempel, inte användas för att skatta variansen hos felet E_i .

Exempel 7. Antag att vi släpper n objekt från en höjd och mäter hur långt de faller x_i inom en viss tid t_i . Vi antar vidare att objekten befinner sig i fritt fall och därför har konstant acceleration θ , vilket ger relationen

$$x_i = \theta t_i^2 / 2 + e_i,$$

för $n = 1, 2, \dots, n$ där e_i är mätfelet för det i :te objektet.

För att skatta θ definierar vi de oberoende stokastiska variablerna

$$X_i = \theta t_i^2/2 + E_i$$

för $n = 1, 2, \dots, n$. Felet E_i har väntevärde $E[E_i] = 0$, så vi kan tillämpa MK-metoden med $\mu_i(\theta) = \theta t_i^2/2$. Kvadratsumman är då

$$Q(\theta) = \sum_{i=1}^n (x_i - \mu_i(\theta))^2 = \sum_{i=1}^n (x_i - \theta t_i^2/2)^2.$$

Om vi deriverar och sätter derivatan till noll fås

$$-\sum_{i=1}^n t_i^2 x_i + \theta \sum_{i=1}^n t_i^4/2 = 0 \implies \theta = \frac{2 \sum_{i=1}^n t_i^2 x_i}{\sum_{i=1}^n t_i^4}.$$

Andraderivatan är alltid positiv, så detta är ett globalt minimum och ger alltså MK-skattningen θ_{obs}^* .

Notera att om E_i är normalfördelade så överensstämmer MK-skattningen med ML-skattningen eftersom likelihoodfunktionen då är

$$L(\theta; x_1, x_2, \dots, x_n) = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_i(\theta))^2} = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} Q(\theta)}$$

och maximering av $L(\theta; x_1, x_2, \dots, x_n)$ är således detsamma som minimering av $Q(\theta)$. I andra fall kan ML- och MK-skattningarna skilja sig avsevärt.

Exempel 8. Vi antar återigen att vi har $X_1, X_2, \dots, X_n$ oberoende likafördelade stokastiska variabler med fördelning $U[0, \theta]$. Detta ger $\mu_i(\theta) = E_\theta[X_i] = \theta/2$ så vi får

$$Q(\theta) = \sum_{i=1}^n (x_i - \theta/2)^2,$$

vilket ger MK-skattningen $\theta_{\text{obs}}^* = 2\bar{x}$. Denna skattning kan verka rimlig – den är väntevärdesriktig och det aritmetiska medelvärde $\bar{x}$ borde ligga runt $\theta/2$ – men vi ska se att den korrigerade ML-skattningen är att föredra.

Den korrigerade ML-skattningen är

$$\hat{\theta}_{\text{obs}} = \frac{n+1}{n} \max(x_1, x_2, \dots, x_n)$$

och var varians $V[\hat{\theta}] = \frac{\theta_0^2}{n(n+2)}$ där θ_0 är den parameter som användas för att generera mätvärdena. För MK-skattningen har vi däremot

$$V[\theta^*] = V[2\bar{X}] = 4V[\bar{X}] = \frac{4}{n} V[X] = \frac{4}{n} \cdot \frac{\theta_0^2}{12} = \frac{\theta_0^2}{3n}.$$

Alltså är ML-skattningen $(n+2)/3$ gånger effektivare (dvs. den har $(n+2)/3$ gånger lägre varians) jämfört med MK-skattningen. Anledningen är att ML-skattningen bara beror på ett värde – det största mätvärdet bland $x_1, x_2, \dots, x_n$ – medan MK-skattningen beror på alla mätvärdena. MK-skattningen kommer alltså att "störas" av dessa mindre mätvärden som inte tillför någon viktig information om θ .

Medelfel

Som vi såg i början av föregående föreläsning är en viktig del av den statistiska modelleringen att skatta felet i vår punktskattning. Vi kommer att diskutera detta mer i detalj under nästa föreläsning då vi behandlar intervallskattning, men kan redan introducera ett närliggande begrepp inom punktskattningsramverket.

I regel har vi en standardavvikelse $D[\theta^*]$ för en punktskattning θ_{obs}^* . Problemet är oftast att uttrycket för $D[\theta^*]$ beror på den sökta parametern θ_0 själv och kan därför inte bestämmas exakt. Vi måste därför skatta $D[\theta^*]$. En sådan skattning kallas *medelfelet* och betecknas ofta $d(\theta^*)$.

Ett rimligt medelfel fås ofta om vi istället för det sanna värdet θ_0 använder skattningen θ_{obs}^* som värde på θ när vi beräknar $D[\theta^*]$. Motiveringen här är att om θ_{obs}^* är en tillräckligt bra skattning av θ_0 (vi kanske har en konsistent punktskattning och arbetar med stor stickprovsstorlek n) så kommer $d(\theta^*) = D[\theta^*]|_{\theta=\theta_{\text{obs}}^*}$ vara en bra skattning av $D[\theta^*]|_{\theta=\theta_0}$.

Om vi återvänder till opinionsundersökningen så skattade vi p med punktskattningen $p_{\text{obs}}^* = x/n$. Denna har standardavvikelsen

$$D[p^*] = \sqrt{\frac{p(1-p)}{n}},$$

så ett rimligt medelfel ges av

$$d(p^*) = \sqrt{\frac{p_{\text{obs}}^*(1-p_{\text{obs}}^*)}{n}}.$$

På samma sätt har vi kanske skattat μ och σ för normalfördelade variabler med $\mu_{\text{obs}}^* = \bar{x}$ och $\sigma_{\text{obs}}^* = s$. Standardavvikelsen för $\bar{X}$ är

$$D[\mu^*] = D[\bar{X}] = \frac{\sigma}{\sqrt{n}},$$

så vi får medelfelet

$$d(\mu^*) = \frac{s}{\sqrt{n}}.$$

Ett annat tillvägagångssätt är att "simulera" olika utfall av punktskattningen. Detta görs genom att dra n mätvärden ut stickprov $x_1, x_2, \dots, x_n$ med återläggning. Vi har då alltså återigen ett stickprov med n värden, men vissa av de ursprungliga mätvärdena saknas och andra förekommer mer än en gång. Utifrån detta stickprov beräknar vi punktskattningen $\theta_{1,\text{obs}}^*$. Vi repeterar detta B gånger och får då B stycken punktskattningar $\theta_{1,\text{obs}}^*, \theta_{2,\text{obs}}^*, \dots, \theta_{B,\text{obs}}^*$. Låt $\overline{\theta_{\text{obs}}^*}$ beteckna det aritmetiska medelvärdet av dessa B skattningar. Medelfelet kan då definieras som

$$d(\theta^*) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\theta_{b,\text{obs}}^* - \overline{\theta_{\text{obs}}^*})^2}.$$


Utöver denna standardavvikelse kan vi betrakta histogrammet för punktskattningarna och på så sätt få en bättre uppfattning om hur mycket variation vi kan förvänta oss i skattningen. Denna metod kallas *icke-parametrisk bootstrap* och är speciellt användbar i situationer då vi inte har tillgång till $D[\theta^*]$, vilket kan ske, till exempel, om θ_{obs}^* fås som resultatet av en numerisk optimeringsalgoritm.

Exempel 9. Anta att vi har $n = 300$ värden från en $\text{Exp}(\lambda)$ -fördelad variabel X . Vi har sett att ML-skattningen för λ är $1/\bar{x}$ så genom invariansegenskapen är ML-skattningen för väntevärdet $\mu = E[X] = 1/\lambda$ lika med $\bar{x}$. Standardavvikelsen för denna skattning $\mu^* = \bar{X}$ fås som $D[\bar{X}] = D[X]/\sqrt{n} = \mu/\sqrt{n}$. Stoppa vi in skattningen μ_{obs}^* får vi medelfelet $d(\mu^*) = \mu_{\text{obs}}^*/\sqrt{n}$, vilket kan jämföras med den sanna standardavvikelsen $\mu_0/\sqrt{n}$ där μ_0 är parametern som använts för att generera värdena.

För $\mu_0 = 17.89$ får vi $\mu_{\text{obs}}^* \approx 17.77$ vilket ger $d(\mu^*) \approx 1.03$. Eftersom vi känner till det sanna värdet μ_0 på parametern kan vi beräkna $D[\mu^*]$ och får detta också till 1.03. Skattningen av standardavvikelsen i form av medelfelet ovan är alltså ganska bra.

Med icke-parametrisk bootstrap utför vi $B = 10000$ slumpmässiga urval ur stickprovet. Detta ger B olika skattningar av μ vars standardavvikelse fås till 1.07. Denna skattning är alltså aningen sämre än den vi fick genom att sätta $\mu = \mu_{\text{obs}}^*$ i uttrycket för $D[\mu^*]$. Fördelen är att vi inte behövde känna till $D[\mu^*]$ eller egentligen något om fördelningen på μ^* – skattningen av felet fick vi "gratis" genom att repetera skattningen på olika urval av stickprovet.

Som nämnt ovan kan vi också plotta det normaliserade histogrammet för dessa bootstrappade skattningar. Vi jämför med täthetsfunktionen för μ^* (som vi kan visa har fördelningen $\text{Gamma}(n, \mu_0/n)$) och ser att de överensstämmer ganska bra.



Föreläsning tio

Joakim Andén

Intervallskattning

I föregående föreläsningar har vi diskuterat punktskattningar. Dessa skattningar ger ett visst värde θ_{obs}^* på en sökt parameter θ , men inget mer. Punktskattningen kan ha flera bra egenskaper som väntevärdesriktighet, konsistens och effektivitet. Detta betyder att skattningen är någorlunda exakt, speciellt om stickprovsstorleken n är stor, men detta säger inte så mycket om hur säker vår punktskattning är, rent konkret.

För att få en uppfattning om måttet av osäkerhet i skattningen såg vi i den senaste föreläsningen att vi kan skatta standardavvikelsen hos punktskattningen i form av medelfelet $d(\theta^*)$. Detta säger att den sanna parametern p borde ligga någonstans mellan $\theta_{\text{obs}}^* - d(\theta^*)$ och $\theta_{\text{obs}}^* + d(\theta^*)$. Vi ska nu vidareutveckla detta och skatta parametrar med hjälp av intervall som innehåller det sanna värdet på parametern med en viss sannolikhet. Med andra ord söker vi inte längre påståenden på formen

Andelen p som tänker rösta ja är ungefär 0.45,

utan

Andelen p som tänker rösta ja ligger mellan 0.43 och 0.47 med 95% sannolikhet


eller

Andelen p som tänker rösta ja är större än 0.44 med 95% sannolikhet.

Formellt söker vi funktioner $a_1(x_1, x_2, \dots, x_n)$ och $a_2(x_1, x_2, \dots, x_n)$ av mätvärdena $x_1, x_2, \dots, x_n$ så att för stickprovet $X_1, X_2, \dots, X_n$ gäller

$$P(a_1(X_1, X_2, \dots, X_n) < \theta < a_2(X_1, X_2, \dots, X_n)) = 1 - \alpha$$

för något $\alpha > 0$. Vi säger då att $I_\theta = [a_1(x_1, x_2, \dots, x_n), a_2(x_1, x_2, \dots, x_n)]$ är ett *konfidensintervall* för θ med *konfidensgrad* $1 - \alpha$.



Notera att slumpmässigheten i uttrycket ovan härstammar *inte* från parametern θ (som är konstant), utan från stickprovet $X_1, X_2, \dots, X_n$. Med andra ord så ska vi inte se detta som sannolikheten att ett slumpmässigt θ ligger i det fixa intervallet I_θ utan som sannolikheten att det slumpmässiga intervallet I_θ täcker det fixa θ .

Om både a_1 och a_2 är ändliga kallas konfidensintervallet I_θ för *tvåsidigt*. Om någon av dem är oändliga (dvs. om $a_1 = -\infty$ eller $a_2 = +\infty$) kallas intervallet *ensidigt* och motsvarar

$$P(\theta < a_2(X_1, X_2, \dots, X_n)) = 1 - \alpha \quad \text{eller} \quad P(a_1(X_1, X_2, \dots, X_n) < \theta) = 1 - \alpha.$$

Exempel 1. Vi vet att $X \sim N(\theta, \sigma)$, dvs. ett stickprov med endast ett mätvärde ($n = 1$). Standardavvikelsen σ är känd, men vi vill skatta väntevärdet θ utifrån ett utfall x av X .

I detta fall vet vi att

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1),$$

och kan då använda kvantilerna λ_α för den standardiserade normalfördelningen och få

$$P(-\lambda_{\alpha/2} < Z < \lambda_{\alpha/2}) = 1 - \alpha.$$

(Kom ihåg att $\lambda_{1-\alpha/2} = -\lambda_{\alpha/2}$ eftersom $N(0, 1)$ är symmetrisk.) Relationen $-\lambda_{\alpha/2} < Z < \lambda_{\alpha/2}$ består av olikheterna $-\lambda_{\alpha/2} < Z$ och $Z < \lambda_{\alpha/2}$, vilka kan omvandlas enligt

$$\begin{aligned} -\lambda_{\alpha/2} < Z &= \frac{X - \theta}{\sigma} \\ -\lambda_{\alpha/2}\sigma &< X - \theta \\ -X - \lambda_{\alpha/2}\sigma &> -\theta \\ \theta &< X + \lambda_{\alpha/2}\sigma \end{aligned}$$

och vi får på samma sätt

$$X - \lambda_{\alpha/2}\sigma < \theta,$$


vilket ger den sammansatta relationen

$$X - \lambda_{\alpha/2}\sigma < \theta < X + \lambda_{\alpha/2}\sigma.$$

Vi får då sannolikheten

$$P(X - \lambda_{\alpha/2}\sigma < \theta < X + \lambda_{\alpha/2}\sigma) = 1 - \alpha.$$

Med andra ord om vi tar $a_1(x) = x - \lambda_{\alpha/2}\sigma$ och $a_2(x) = x + \lambda_{\alpha/2}\sigma$ har vi konfidensintervallet $I_\theta = [a_1(x), a_2(x)]$ för θ med konfidensgraden $1 - \alpha$.



Låt oss anta att $x = -0.69$ och $\sigma = 0.66$. Med $\alpha = 0.05$ får vi $\lambda_{\alpha/2} = \lambda_{0.025} \approx 1.96$, vilket ger konfidensintervallet $I_\theta = [-1.98, 0.61]$. (Utfallet x var i detta fall genererat med parametern $\theta = 0.1$, så denna ingick i intervallet för skattningen.)

Vad händer med intervallet när vi ändrar parametrarna? Om σ ökar så får vi ett bredare intervall. Detta motsvarar att vårt mätvärde x ger mindre information om parametern θ som vi söker. På samma sätt kan vi minska α (dvs. öka konfidensgraden $1 - \alpha$). Detta ger då ett större värde på λ_α , vilket i sin tur ger ett bredare intervall. Tolkningen är här att om vi vill vara säkrare på att intervallet verkligen täcker θ så måste vi öka storleken.

Exemplet ovan anger en generell metod som kan användas för de flesta intervallskattningarna.

- (i) Hitta en punktskattning θ^* för parametern θ givet utfallet $x_1, x_2, \dots, x_n$ av stickprovet $X_1, X_2, \dots, X_n$. Detta kan, till exempel, vara en ML- eller MK-skattning, ett stickprovsmedelvärde eller en stickprovsvarians. (Ovan hade vi bara utfallet x självt.)
- (ii) Bestäm fördelningen för θ^* . Denna beror då oftast på det sanna värdet på parametern θ . (Ovan hade vi $X \sim N(\theta, \sigma)$.)
- (iii) Transformera θ^* så att dess fördelning *inte* beror på parametern θ . Detta kallas för en *pivotvariabel*. (Ovan var detta $Z = (X - \theta)/\sigma \sim N(0, 1)$.)
- (iv) Använd kvantiler hos pivotvariabelns fördelning för att bilda ett intervall för pivotvariabeln som håller med sannolikhet $1 - \alpha$. (Ovan hade vi $-\lambda_{\alpha/2} < Z < \lambda_{\alpha/2}$.)

- (v) Transformera detta till ett konfidensintervall för θ där ändpunkterna beror på stickprover $X_1, X_2, \dots, X_n$. (Ovan gav detta $I_\theta = [x - \lambda_{\alpha/2}\sigma, x + \lambda_{\alpha/2}\sigma]$.)

Vi kommer nu tillämpa denna metod i olika former på ett par typexempel.

Normalfördelat stickprov

Vi kommer nu betrakta fallet då stickprovet $X_1, X_2, \dots, X_n$ består av oberoende normalfördelade variabler och vi vill skatta väntevärdet μ , standardavvikelsen σ eller båda två.

Exempel 2. (Skatta μ , känt σ) Antag att vi har ett stickprov $X_1, X_2, \dots, X_n$ av oberoende stokastiska variabler fördelade enligt $N(\mu, \sigma)$. Vi antar att σ är känd och vill skatta μ utifrån $x_1, x_2, \dots, x_n$.

För detta använder vi förslagsvis ML-skattningen, dvs. stickprovsmedelvärdet,

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Den motsvarande stickprovsvariabeln $\bar{X}$ har fördelningen $N(\mu, \sigma/\sqrt{n})$. Utifrån denna bildar vi pivotvariabeln

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

vars fördelning är oberoende av μ (i det här fallet också oberoende av σ , vilket förenklar nästa steg ytterligare). Med denna använder vi kvantilerna $-\lambda_{\alpha/2}$ och $\lambda_{\alpha/2}$ för den standardiserade normalfördelningen och får

$$P\left(-\lambda_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < \lambda_{\alpha/2}\right) = 1 - \alpha.$$

Vi transformerar nu detta (se föregående exempel) till ett intervall runt μ , vilket ger

$$P\left(\bar{X} - \frac{\lambda_{\alpha/2}\sigma}{\sqrt{n}} < \mu < \bar{X} + \frac{\lambda_{\alpha/2}\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

Ett tvåsidigt konfidensintervall för μ med konfidensgrad $1 - \alpha$ är då

$$I_\mu = \left[\bar{x} - \frac{\lambda_{\alpha/2}\sigma}{\sqrt{n}}, \bar{x} + \frac{\lambda_{\alpha/2}\sigma}{\sqrt{n}}\right].$$

Intervallat blir snävt när σ är litet eller n är stort. I dessa fall har vi högt förtroende (dvs. konfidens) till vår punktskattning θ^* och denna ligger med stor sannolikhet nära det sanna värdet θ .

På samma sätt erhåller vi ensidiga konfidensintervall med konfidensgrad $1 - \alpha$ på formen

$$\left(-\infty, \bar{x} + \frac{\lambda_\alpha\sigma}{\sqrt{n}}\right) \quad \text{och} \quad \left(\bar{x} - \frac{\lambda_\alpha\sigma}{\sqrt{n}}, +\infty\right).$$

Fallet ovan med ett känt σ uppkommer till exempel när kalibrerad mätutrustning används för vilken standardavvikelsen är specificerad. Dock är det vanligt att standardavvikelsen inte är känd (eller given men inte helt tillförlitlig). I detta fall måste vi skatta både μ och σ . Låt oss börja med μ .

Exempel 3. (Skatta μ , okänt σ) Återigen antar vi att vi har ett stickprov $X_1, X_2, \dots, X_n$ av oberoende stokastiska variabler fördelade enligt $N(\mu, \sigma)$. Nu är både μ och σ okända och vi vill skatta μ utifrån $x_1, x_2, \dots, x_n$.

Om vi använder stickprovsmedelvärdet $\bar{X}$ och försöker bilda pivotvariabeln

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

ser vi genast ett problem: vi kan inte dela med σ eftersom denna inte är känd (mer exakt så måste σ ingå i ändpunkterna hos intervallet, vilket inte är möjligt eftersom den inte är känd). Istället har vi en skattning, stickprovsstandardavvikelsen

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

Om vi sätter in denna istället för σ för vi

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{(\bar{X} - \mu)\sqrt{n}}{S}.$$

Frågan är nu om T är en pivotvariabel, dvs. om fördelningen av T beror på de okända parametrarna μ och σ .

Eftersom X_i är normalfördelad med väntevärde μ och standardavvikelse σ kan vi skriva

$$X_i = \mu + \sigma Z_i$$

där $Z_i \sim N(0, 1)$. Om vi betecknar $\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i$ har vi då $\bar{X} = \mu + \sigma \bar{Z}$, vilket ger

$$\bar{X} - \mu = \sigma \bar{Z}$$

och i S kan vi då faktorisera ut σ och få

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} = \sigma \sqrt{\frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2}.$$

Vi kan då skriva om T som

$$T = \frac{\bar{Z}\sqrt{n}}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2}}.$$


Den stokastiska variabeln T beror alltså bara på de standardiserade variablerna Z_i och dess fördelning kan således inte bero på μ eller σ .

Vad är då T 's fördelning? Man kan visa dess täthetsfunktion är

$$f_T(t) = \frac{\Gamma(n/2)}{\sqrt{(n-1)\pi}\Gamma(\frac{n-1}{2})} \left(1 + \frac{t^2}{n-1}\right)^{-n/2}.$$

Fördelningen kallas t-fördelningen med $n-1$ frihetsgrader (detta motsvarar antalet oberoende termer i kvadratsumman $\sum_{i=1}^n (Z_i - \bar{Z})^2$) och betecknas $t(n-1)$. Vi betecknar dess kvantiler med $t_\alpha(n-1)$, dvs. att

$$P(T > t_\alpha(n-1)) = \alpha.$$



Likt normalfördelningen är t-fördelningen symmetrisk ($f_T(-t) = f_T(t)$), vilket ger att $t_{1-\alpha}(n-1) = -t_\alpha(n-1)$. Vi har då

$$P(-t_{\alpha/2}(n-1) < T < t_{\alpha/2}(n-1)) = 1 - \alpha,$$

dvs.

$$P\left(-t_{\alpha/2}(n-1) < \frac{(\bar{X} - \mu)\sqrt{n}}{S} < t_{\alpha/2}(n-1)\right) = 1 - \alpha,$$

vilket ger

$$P\left(\bar{X} - \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1) < \mu < \bar{X} + \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\right) = 1 - \alpha.$$

Ett konfidensintervall för μ med konfidensgrad $1 - \alpha$ är alltså

$$I_\mu = \left[\bar{X} - \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1), \bar{X} + \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\right].$$

Låt oss jämföra dessa två fall: känd och okänd standardavvikelse σ . Om $\sigma = 1.2$ och $n = 9$ får vi $\sigma/\sqrt{n} = 0.4$. Med $1 - \alpha = 0.95$ har vi $\alpha = 0.05$, vilket ger ett konfidensintervall

$$\begin{aligned} I_\mu &= [\bar{X} - 0.4\lambda_{0.025}, \bar{X} + 0.4\lambda_{0.025}] \\ &\approx [\bar{X} - 0.4 \cdot 1.96, \bar{X} + 0.4 \cdot 1.96] \approx [\bar{X} - 0.78, \bar{X} + 0.78]. \end{aligned}$$

Antag nu att σ är okänd och vi skattar den genom s . Vi antar vidare att vi har tur och s landar exakt på den sanna standardavvikelsen 1.2. Detta ger då $s/\sqrt{n} = 0.4$ som innan, men konfidensintervallet med $\alpha = 0.05$ blir då

$$I_\mu = [\bar{x} - 0.4t_{0.025}(8), \bar{x} + 0.4t_{0.025}(8)] \\ \approx [\bar{x} - 0.4 \cdot 2.31, \bar{x} + 0.4 \cdot 2.31] \approx [\bar{x} - 0.92, \bar{x} + 0.92].$$

Konfidensintervallet blir då längre (1.84 istället för 1.56) när vi skattar σ jämfört med om σ redan är känt. Anledningen är att vi "bakar in" osäkerheten hos vår skattning av σ i skattningen av felet hos skattningen av μ .

Detta motiverar delvis förfarandet i föregående föreläsning där vi ansatte att medelfelet $d(\theta^*)$ hos en punktskattning kan fås genom att ersätta θ i uttrycket för $D[\theta^*]$ med skattningen θ_{obs}^* . I fallet med normalfördelade stickprov kan vi göra detta argument rigoröst genom tillämpningen av t-fördelningen ovan.

Det är också värt att notera att $t(n-1)$ går mot $N(0, 1)$ när $n \rightarrow +\infty$. (Vi ser detta genom att låta $n \rightarrow +\infty$ i täthetsfunktionen och använda faktumet att $\Gamma(n+1/2)/(\sqrt{n}\Gamma(n)) \rightarrow 1$ då $n \rightarrow +\infty$.) För små n är $t(n-1)$ -fördelningen "bredare" än $N(0, 1)$ men närmar sig den senare för större n . Vi kan se detta som att för stora n är skattningen s av σ så pass exakt att ersättandet av σ med s har en mycket liten effekt och $T = (\bar{X} - \mu)\sqrt{n}/s \approx (\bar{X} - \mu)\sqrt{n}/\sigma \sim N(0, 1)$.

I fallet med okänt σ kan det också vara av intresse att bestämma ett konfidensintervall för denna parameter. Detta görs enkelt med hjälp av en annan fördelning.

Exempel 4. (Skatta σ , okänt μ) Vi antar igen att vi har oberoende $X_1, X_2, \dots, X_n$ med fördelning $N(\mu, \sigma)$ och både μ och σ är okända (fallet med okänd σ och känd μ behandlas på liknande sätt, men antal frihetsgrader blir n istället för $n-1$). Vi har då punktskattningen s med stickprovsvariabeln

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

Om vi återigen tar $X_i = \mu + \sigma Z_i$ för $Z_i \sim N(0, 1)$ får vi

$$S = \sigma \sqrt{\frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2}.$$

En rimlig pivotvariabel vore då

$$Y = \frac{S}{\sigma}$$

eftersom denna fås genom kombination av de standardiserade stokastiska variablerna $Z_1, Z_2, \dots, Z_n$. Vad har denna variabel för fördelning?

Man kan visa att kvadratsumman

$$\sum_{i=1}^n (Z_i - \bar{Z})^2$$


har en så kallad χ^2 -fördelning med $n - 1$ frihetsgrader, vilket betecknas $\chi^2(n - 1)$. (Kvadratsumman av n oberoende $N(0, 1)$ -fördelade stokastiska variabler är fördelad enligt $\chi^2(n)$. Att vi har $n - 1$ frihetsgrader har att göra med att vi subtraherar $\bar{Z}$ innan vi kvadrerar.) Denna fördelning har täthetsfunktionen

$$f(x) = \frac{1}{2^{\frac{n-1}{2}} \Gamma\left(\frac{n-1}{2}\right)} x^{\frac{n-3}{2}} e^{-x/2}$$

och vi betecknar dess kvantiler med $\chi^2_\alpha(n - 1)$, vilket ger

$$P\left(\sum_{i=1}^n (Z_i - \bar{Z})^2 > \chi^2_\alpha(n - 1)\right) = \alpha.$$

(Notera att eftersom $\chi^2(n - 1)$ inte är symmetrisk har inte att $\chi^2_{1-\alpha}(n - 1)$ är lika med $-\chi^2_\alpha(n - 1)$).



Eftersom

$$Y = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2}$$

och kvadratroten är en strikt monoton funktion ger detta

$$\begin{aligned} P\left(\sum_{i=1}^n (Z_i - \bar{Z})^2 > \chi^2_\alpha(n - 1)\right) &= \alpha \\ P\left(\sqrt{\frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2} > \sqrt{\frac{\chi^2_\alpha(n - 1)}{n - 1}}\right) &= \alpha \\ P\left(Y > \sqrt{\frac{\chi^2_\alpha(n - 1)}{n - 1}}\right) &= \alpha. \end{aligned}$$

På samma sätt får vi

$$P\left(Y < \sqrt{\frac{\chi^2_{1-\alpha}(n - 1)}{n - 1}}\right) = \alpha.$$

Om vi ersätter α med $\alpha/2$ har vi då

$$P\left(Y < \sqrt{\frac{\chi_{1-\alpha/2}^2(n-1)}{n-1}} \text{ eller } \sqrt{\frac{\chi_{\alpha/2}^2(n-1)}{n-1}} < Y\right) = \alpha/2 + \alpha/2 = \alpha.$$

Sedan tar vi komplementet, vilket ger

$$P\left(\sqrt{\frac{\chi_{1-\alpha/2}^2(n-1)}{n-1}} < Y < \sqrt{\frac{\chi_{\alpha/2}^2(n-1)}{n-1}}\right) = 1 - \alpha.$$

Eftersom $Y = S/\sigma$ kan vi nu stuva om (samma princip som innan) och får

$$P\left(S\sqrt{\frac{n-1}{\chi_{\alpha/2}^2(n-1)}} < \sigma < S\sqrt{\frac{n-1}{\chi_{1-\alpha/2}^2(n-1)}}\right) = \alpha.$$

(Notera att vi måste vända på ändpunkterna ovan för att gå från $1/\sigma$ till σ .)

Utifrån utfallen $x_1, x_2, \dots, x_n$ har vi alltså konfidensintervallet

$$I_\sigma = \left[s\sqrt{\frac{n-1}{\chi_{\alpha/2}^2(n-1)}}, s\sqrt{\frac{n-1}{\chi_{1-\alpha/2}^2(n-1)}} \right]$$

med konfidensgrad $1 - \alpha$.

Två normalfördelade stickprov

En annan vanlig situation är att vi har två oberoende stickprov som vi vill jämföra. Det kan röra sig om skillnaden för någon viss egenskap mellan två kemiska föreningar. Eller vi kanske vill mäta skillnaden i effektivitet mellan två medicinska behandlingar för att bestämma om den ena är bättre än den andra. Vi skulle kunna jämföra punktskattningarna, men om de ligger tillräckligt nära varandra kan det vara svårt att säga om den ena verkligen är större än den andra.

I härledningarna nedan antar vi som innan att det rör sig om normalfördelade stickprov.

Exempel 5. (Skatta $\mu_1 - \mu_2$, känd σ_1, σ_2) Vi har nu två oberoende stickprov: oberoende och $N(\mu_1, \sigma_1)$ -fördelade $X_1, X_2, \dots, X_{n_1}$ samt oberoende och $N(\mu_2, \sigma_2)$ -fördelade $Y_1, Y_2, \dots, Y_{n_2}$. Standardavvikelserna σ_1 och σ_2 antas kända och vi söker väntevärdesskillnaden $\mu_1 - \mu_2$.

Utifrån utfallen $x_1, x_2, \dots, x_{n_1}$ och $y_1, y_2, \dots, y_{n_2}$ bildar vi punktskattningen

$$\bar{x} - \bar{y}$$

för $\mu_1 - \mu_2$. Den motsvarande stickprovsvariabeln $\bar{X} - \bar{Y}$ har fördelningen $N(\mu_1 - \mu_2, \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2})$. Vi bildar då pivotvariabeln

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$$

och med samma resonemang som tidigare får vi alltså

$$P\left(\bar{X} - \bar{Y} - \lambda_{\alpha/2} \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2} < \mu_1 - \mu_2 < \bar{X} - \bar{Y} + \lambda_{\alpha/2} \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}\right) = 1 - \alpha,$$

vilket ger konfidensintervallet

$$I_{\mu_1 - \mu_2} = \left[\bar{x} - \bar{y} - \lambda_{\alpha/2} \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}, \bar{x} - \bar{y} + \lambda_{\alpha/2} \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2} \right]$$

för $\mu_1 - \mu_2$ med konfidensgrad $1 - \alpha$.

Som innan har vi också det intressanta fallet med okända standardavvikelser.

Exempel 6. (Skatta $\mu_1 - \mu_2$, okänd $\sigma_1 = \sigma_2 = \sigma$) För enkelhetens skull antar vi att de okända standardavvikelserna σ_1 och σ_2 är lika och betecknar de som σ . Detta uppstår, till exempel, om vi använder samma mätinstrument eller procedur för de båda stickproven, vilket leder till samma felstorlek i mätvärdena.

Vi har alltså två oberoende stickprov: $X_1, X_2, \dots, X_{n_1}$ oberoende och $N(\mu_1, \sigma)$ -fördelade stokastiska variabler samt $Y_1, Y_2, \dots, Y_{n_2}$ oberoende och $N(\mu_2, \sigma)$ -fördelade stokastiska variabler. Från dessa har vi utfallen $x_1, x_2, \dots, x_{n_1}$ respektive $y_1, y_2, \dots, y_{n_2}$. Vi skattar återigen $\mu_1 - \mu_2$ med $\bar{x} - \bar{y}$. Den motsvarande stickprovsvariabeln $\bar{X} - \bar{Y}$ har fördelningen $N(\mu_1 - \mu_2, \sigma \sqrt{1/n_1 + 1/n_2})$.

För att bilda en pivotvariabel behöver vi alltså skatta σ . Vi såg i föregående föreläsning att

$$s = \sqrt{\frac{\sum_{i=1}^{n_1} (x_i - \bar{x})^2 + \sum_{j=1}^{n_2} (y_j - \bar{y})^2}{(n_1 - 1) + (n_2 - 1)}}$$

är en lämplig punktskattning för σ . Med hjälp av den motsvarande stickprovsvariabeln S bildar vi alltså pivotvariabeln

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S \sqrt{1/n_1 + 1/n_2}}$$

Man kan visa att T beror varken på μ_1 , μ_2 eller σ och har fördelningen $t((n_1 - 1) + (n_2 - 1))$.

Om vi låter $f = (n_1 - 1) + (n_2 - 1)$ får vi enligt samma resonemang som för ett stickprov konfidensintervallet

$$I_{\mu_1 - \mu_2} = [\bar{x} - \bar{y} - t_{\alpha/2}(f)s\sqrt{1/n_1 + 1/n_2}, \bar{x} - \bar{y} + t_{\alpha/2}(f)s\sqrt{1/n_1 + 1/n_2}]$$

för $\mu_1 - \mu_2$ med konfidensgrad $1 - \alpha$.

Vi avslutar med ett subtilt fall som liknar fallet ovan med två stickprov. I stället för att jämföra väntevärdena mellan två olika stickprov är vi intresserade av den systematiska skillnaden mellan par av mätningar. (Vi har alltså ett stickprov bestående av par istället för ett par av stickprov.)

Detta uppstår om vi vill utvärdera effekten av ett visst läkemedel på ett mätvärde hos olika patienter. Vi kan ta två stickprov, en kontrollgrupp och en interventionsgrupp, och jämföra medelvärdena. Detta är så klart möjligt, men problemet är att stickproven också kommer att innehålla den naturliga variationen mellan patienter (oberoende av läkemedlet) och därför ge stor spridning i väntevärdesskattningen. För att få ett snävt konfidensintervall krävs alltså stora stickprovsstorlekar. Om vi istället mäter varje patient två gånger, före och efter läkemedlet administreras, kan vi bli av med denna extra variation genom att jämföra mätvärdena i par och skatta den genomsnittliga skillnaden.

Exempel 7. (Stickprov i par) Vi har alltså ett stickprov $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ bestående av oberoende par med fördelningar $X_i \sim N(\mu_i, \sigma_1)$ samt $Y_i \sim N(\mu_i + \Delta, \sigma_2)$ (dvs. stickprovet är inte likafördelat). Notera att väntevärdena μ_i tillåts variera genom stickprovet. Detta motsvarar (den icke intressanta) variationen som vi försöker eliminera.

Från detta stickprov har vi utfall $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ och vi vill skatta Δ . Standardavvikelseerna σ_1 och σ_2 kan vara kända eller okända.

Eftersom vi bara är intresserade av Δ bildar vi differenserna

$$Z_1 = y_1 - x_1, Z_2 = y_2 - x_2, \dots, Z_n = y_n - x_n,$$

med de motsvarande stokastiska variablerna

$$Z_1 = Y_1 - X_1, Z_2 = Y_2 - X_2, \dots, Z_n = Y_n - X_n.$$

Dessa har då alla fördelningen $N(\Delta, \sigma)$ där $\sigma = \sqrt{\sigma_1^2 + \sigma_2^2}$. Vi har nu återfått situationen med ett stickprov. Om σ_1 och σ_2 är kända har vi alltså konfidensintervallet

$$I_\Delta = \left[\bar{Z} - \lambda_{\alpha/2} \sqrt{\sigma_1^2 + \sigma_2^2} / \sqrt{n}, \bar{Z} + \lambda_{\alpha/2} \sqrt{\sigma_1^2 + \sigma_2^2} / \sqrt{n} \right]$$

för Δ med konfidensgrad $1 - \alpha$. Om σ_1 och σ_2 är okända skattar vi σ med

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (z_i - \bar{Z})^2}$$

och får konfidensintervallet

$$I_\Delta = [\bar{Z} - t_{\alpha/2}(n-1)s/\sqrt{n}, \bar{Z} + t_{\alpha/2}(n-1)s/\sqrt{n}]$$

för Δ med konfidensgrad $1 - \alpha$.

Approximativ intervallskattning

Hittills har vi betraktat normalfördelade stickprov, vilket ger punktskattningar vars stickprovsvariabler har bekanta fördelningar (normalfördelning, t-fördelning och χ^2 -fördelning). Normalfördelade stickprov är vanliga, men ofta förekommer stickprov med andra fördelningar. I dessa fall kan vi ibland tillämpa centrala gränsvärdessatsen om stickprovsstorleken n är tillräckligt stor.

Antag att vi har en punktskattning θ_{obs}^* med stickprovsvariabel θ^* . Vi antar vidare att den är väntevärdesriktig och har känd standardavvikelse D . Om denna är väntevärdesriktig och approximativt normalfördelad har vi att

$$Z = \frac{\theta^* - \theta}{D}$$

är approximativt $N(0, 1)$ -fördelad. Ett *approximativt konfidensintervall* för θ med konfidensgrad $1 - \alpha$ är då

$$I_\theta = [\theta_{\text{obs}}^* - \lambda_{\alpha/2} D, \theta_{\text{obs}}^* + \lambda_{\alpha/2} D].$$

Om standardavvikelsen inte är känd skattar vi den med d . Detta ger ett mindre exakt konfidensintervall, men om n är stort kan vi fortfarande bilda det approximativa konfidensintervallet

$$I_\theta = [\theta_{\text{obs}}^* - \lambda_{\alpha/2} d, \theta_{\text{obs}}^* + \lambda_{\alpha/2} d],$$

med konfidensgrad $1 - \alpha$. Notera att i detta fall använder vi inte t-fördelningen eftersom vid n stort så är det så liten skillnad mellan $t(n-1)$ och $N(0, 1)$ att det inte har så stor effekt. Felet som introduceras av normalapproximationen via centrala gränsvärdesatsen är troligen större.

Exempel 8. Vi återgår till opinionsundersökningen med $X \sim \text{Bin}(n, p)$ med $n = 1000$ och utfallet $x = 450$. Vår punktskattning $p_{\text{obs}}^* = x/n$ har motsvarande stickprovsvariabel $p^* = X/n$.

Vi har sett sedan innan att X kan skrivas som en summa av n oberoende Bernoullifördelade stokastiska variabler, vilket gör att vi kan tillämpa centrala gränsvärdesatsen för stora n , vilket ger att $p^* = X/n$ approximativt har fördelningen $N(p, \sqrt{p(1-p)/n})$. Enligt härledningen ovan har vi då det approximativa konfidensintervallet

$$I_p = [p_{\text{obs}}^* - \lambda_{\alpha/2} d, p_{\text{obs}}^* + \lambda_{\alpha/2} d],$$

med konfidensgrad $1 - \alpha$ där $d = \sqrt{p_{\text{obs}}^* (1 - p_{\text{obs}}^*) / n}$. Med värdena $n = 1000$, $x = 450$ får vi $p_{\text{obs}}^* = 0.45$ och $d = 0.016$, vilket ger, för $1 - \alpha = 0.99$,

$$I_p = [0.45 - 2.58 \cdot 0.016, 0.45 + 2.58 \cdot 0.016] \approx [0.41, 0.49].$$

Med andra ord så täcker intervallet $[0.41, 0.49]$ med sannolikhet 0.99 det sanna värdet på p . Vi kan därför dra slutsatsen att det är högst osannolikt att andelen ja-svar i en folkomröstning skulle räcka för att rösta igenom frågan.

Föreläsning elva

Joakim Andén

Hypotesprövning

Punktskattning och intervallskattning ger oss en uppfattning om värdet hos en eller flera parametrar givet en samling datapunkter. Ibland är vi inte intresserad av parametern i sig utan av *påståenden om parametern*, till exempel att den har ett visst värde eller överstiger en viss gräns. Sådana påståenden kallar vi *hypoteser* och vi är intresserade av att se om dessa överensstämmer med datapunkterna, dvs. om hypotesen borde förkastas eller inte. Vi vill också utföra detta på ett sätt som reducerar risken att vi felaktigt förkastar hypotesen. För att göra detta mer konkret börjar vi med ett exempel.

Exempel 1. *Margit påstår att hon kan singla slant på ett sätt så att hon får krona oftare än klave. Om detta stämmer är sannolikheten θ att hon får en krona vid en given singlar större än $1/2$. Vi tror inte riktigt på det här utan utgår från att slanten inte kan singlas på detta sätt, vilket ger $\theta = 1/2$, dvs. krona är lika sannolikt som klave.*

För att testa vår hypotes " $\theta = 1/2$ " mot Margits hypotes " $\theta > 1/2$ " ber vi henne singla slant tio gånger i rad och räknar antalet gånger x hon får krona. Hon lyckas få sju kronor, dvs. $x = 7$. Eftersom detta är större än väntevärdet 5 givet $\theta = 1/2$ hävdar Margit att detta utgör ett bevis för att hon verkligen kan påverka slantsinglingen, dvs. att $\theta > 1/2$.

Låt oss studera detta från en sannolikhetssynpunkt. Vi kan tänka oss att vi repeterar experimentet ovan (dvs. att vi ber Margit singla tio gånger och räknar antalet kronor). I denna situation vill vi utforma ett test så att vi i de flesta av fallen gör rätt val (vi kan inte garantera att vi alltid gör rätt val på grund av den inbyggda slumpmässigheten i experimentet).

Vi får då att x är då ett utfall av den stokastiska variabeln $X \sim \text{Bin}(10, 1/2)$ enligt vår hypotes. Tanken är nu att om Margit lyckas få ett tillräckligt stort antal kronor x borde vi förkasta vår hypotes (att $\theta = 1/2$) eftersom detta utfall är väldigt osannolikt under den hypotesen (dvs. det kommer inträffa mycket sällan om vi repeterar experimentet ett stort antal gånger). Ett sådant utfall skulle istället styrka Margits hypotes (att $\theta > 1/2$).

Men hur stort måste x vara för att vi ska anse utfallet tillräckligt osannolikt? Sanno-

likheten att alla tio singlar ger kronor är liten:

$$P(X = 10) = p_X(10) = \binom{10}{10} \left(\frac{1}{2}\right)^{10} = 1 \cdot \frac{1}{1024} \approx 0.00098.$$

Om vi får $x = 10$ borde vi alltså definitivt förkasta hypotesen att $\theta = 1/2$ och godta Margits hypotes att $\theta > 1/2$. Sannolikheten att få minst nio kronor är också liten

$$P(X \geq 9) = p_X(9) + p_X(10) = \binom{10}{9} \left(\frac{1}{2}\right)^9 \cdot \frac{1}{2} + \frac{1}{1024} = \frac{11}{1024} \approx 0.011,$$

medan sannolikheten att få minst åtta är större

$$P(X \geq 8) = p_X(8) + p_X(9) + p_X(10) = \binom{10}{8} \left(\frac{1}{2}\right)^8 \cdot \left(\frac{1}{2}\right)^2 + \frac{11}{1024} = \frac{56}{1024} \approx 0.055.$$

Låt oss anta att vi vill att risken att felaktigt förkasta hypotesen ska vara mindre än 0.05. Ett rimligt test är då:

Förkasta hypotesen att $\theta = 1/2$ om $x \geq 9$.

Som vi ser från beräkningen ovan kommer vi att felaktigt förkasta hypotesen (dvs. att $X \geq 9$ även om $\theta = 1/2$) med sannolikhet $0.011 < 0.05$. I fallet $x = 7$ ovan kan vi alltså inte förkasta hypotesen med detta test, dvs. vi godtar inte Margits påstående att hon kan påverka slantsinglingen.

Påståendet som vi prövar, dvs. som vi eventuellt vill förkasta, kallas *nollhypotesen* eller *grundhypotesen* och betecknas H_0 . Ofta avser hypotesen något värde på en parameter θ som bestämmer fördelningarna hos ett antal stokastiska variabler $X_1, X_2, \dots, X_n$. I de fall som vi betraktar här har nollhypotesen alltid formen $H_0 : \theta = \theta_0$, dvs. påståendet att parametern θ tar värdet θ_0 . Detta kallas för en *enkel hypotes* (till skillnad från *sammansatta hypoteser*).

Som alternativ till $H_0 : \theta = \theta_0$ har vi en *mothypotes* eller *alternativhypotes* H_1 . Mothypotesen kan vara enkel ($H_1 : \theta = \theta_1$) eller sammansatt ($H_1 : \theta < \theta_0$, $H_1 : \theta > \theta_0$ eller $H_1 : \theta \neq \theta_0$). Vi antar att antingen H_0 eller H_1 måste vara sann och vill bestämma vilken som gäller givet vår data.

För att pröva hypotesen H_0 utgår vi från utfallen $x_1, x_2, \dots, x_n$ av $X_1, X_2, \dots, X_n$. Med hjälp av dessa bildar vi en *testvariabel*

$$t_{\text{obs}} = t(x_1, x_2, \dots, x_n)$$

och söker ett en delmängd $C \subset \mathbb{R}$, det så kallade *kritiska området*. Tanken är då att vi har testet:

Om $t_{\text{obs}} \in C$, förkasta H_0 (till förmån för H_1).

Om $t_{\text{obs}} \notin C$ förkastar vi alltså inte H_0 .

Hur väljer vi $t(x_1, x_2, \dots, x_n)$ och C ? Ofta är $t(x_1, x_2, \dots, x_n)$ en punktskattning av θ och C bestäms då av fördelningen så att H_0 förkastas om punktskattningen blir för


osannolikt givet att H_0 är sann. Det viktiga är att vi kontrollerar risken att felaktigt förkasta H_0 , dvs. att vi förkastar H_0 även den är sann. Vi har då en *felrisk* eller *signifikansnivå* α som motsvarar hur stor felsannolikhet vi tolererar. Med andra ord vill vi ha

$$P(t(X_1, X_2, \dots, X_n) \in C) = \alpha \quad \text{givet att } H_0 \text{ är sann.}$$

Notera att med notationen $P(A; \theta)$ för sannolikheten för händelsen A givet att parametern har värdet θ så kan vi skriva relationen ovan som

$$P(t(X_1, X_2, \dots, X_n; \theta_0) \in C) = \alpha$$

eftersom $H_0 : \theta = \theta_0$.



Populära val för α är 0.05, 0.01 och 0.001. I diskreta fall, som i exemplet ovan, kan vi inte garantera att $P(t(X_1, X_2, \dots, X_n) \in C; \theta_0) = \alpha$ men söker då största C så att $P(t(X_1, X_2, \dots, X_n) \in C; \theta_0) \leq \alpha$. Vi hade då bara ett utfall x och satte $t_{\text{obs}} = x$ med $C = \{9, 10\}$, vilket gav en signifikansnivå på $\alpha = 0.011 < 0.05$.

Om vi förkastar H_0 , dvs. om $t_{\text{obs}}(x_1, x_2, \dots, x_n) \in C$, sägs ibland att vi har ett *signifikant* resultat (dvs. en signifikant avvikelse från nollhypotesen). Omvänt om vi inte förkastar H_0 sägs det att vi har ett *icke-signifikant* resultat. Denna terminologi säger något om hur vi borde välja nollhypotesen H_0 . Den ska på något sätt motsvara ett standardförlopp eller ett normal- eller referenstillstånd – att avvika från nollhypotesen ska betraktas som något exceptionellt. Detta ställs då i kontrast med H_1 , som representerar avvikelsen från normalstillståndet. I många vetenskapliga experiment motsvarar därför H_1 ofta en ny teori som ska prövas och som jämförs med nuvarande teori H_0 .

Notera att om $t_{\text{obs}}(x_1, x_2, \dots, x_n) \notin C$ så förkastar vi inte H_0 , men tekniskt sett betyder detta inte nödvändigtvis att H_0 är sann, dvs. att vi godtar H_0 . I exemplet ovan kan det ju vara så att personen i fråga hade handen i bandage och därför inte lyckades med sitt trick. Med detta sagt, om hypotesen är väl ställd (dvs. den avser ett slags normalstillstånd) så brukar man anta att ett icke-förkastande av H_0 medför ett godkännande av hypotesen.

Detta gäller för många empiriska vetenskapliga fakta. För hundra år sedan var en rimlig nollhypotes att ljus färdas längs en rak linje i rummet. Även om den då nyutvecklade relativitetsteorin förutsade att ljuset kunde böjas av ett gravitationsfält var det inte förrän Arthur Eddingtons expedition observerade just detta i maj 1919 som nollhypotesen kunde förkastas. Om expeditionen inte hade lyckats skulle nollhypotesen fortfarande antas gälla. Att en teori eller hypotes ska kunna förkastas, dvs. att den är *falsifierbar*, utgör ett viktigt element av vetenskapsteorin.

Ett alternativ till att bestämma det kritiska området C är den så kallade *direktmetoden* eller *p-värdesmetoden*. Denna utgår ifrån att beräkna sannolikheten att testvariabeln $t(X)$ antar ett värde minst lika "extremt" som $t_{\text{obs}}(x)$. Om den sannolikheten är tillräckligt liten förkastar vi H_0 . Här motsvarar "extrema" värden de värden som $t(X)$ antar givet att H_1 är sann. Ofta betyder "extremt" att $t_{\text{obs}}(x)$ är mycket stor (antingen negativt eller positivt) eller skiljer sig mycket från något referensvärde. I fallet ovan med slantsingling ses större värden på $t_{\text{obs}}(x) = x$ som mer extrema eftersom de är mindre sannolika under nollhypotesen $H_0 : \theta = 1/2$ men är mer sannolika under mothypotesen $H_0 : \theta > 1/2$. Vi beräknar därför

$$p = P(t(X) \geq t_{\text{obs}}; 1/2) = P(X \geq t_{\text{obs}}; 1/2)$$

Med fallet $t_{\text{obs}} = x = 7$ får vi $p = P(X \geq 7; 1/2) \approx 0.17$. Detta ligger långt över någon relevant signifikansnivå (vanligtvis 0.05, 0.01 eller 0.001) så vi förkastar inte H_0 . Direktmetoden kan vara användbar om vi på förhand inte har bestämt vilken signifikansnivå som är relevant för vårt experiment. Resultatet av hypotestestet noteras då med dess tillhörande p-värde.

Ett hypotestest kallas *ensidigt* om det kritiska området är begränsat ovanifrån ($C = (-\infty, b]$) eller underifrån ($C = [a, +\infty)$). (I direktmetoden motsvarar dessa att vi betraktar små respektive stora värden som extrema.) Om det kritiska området består av två obegränsade intervall $C = (-\infty, b] \cup [a, +\infty)$ kallas det *tvåsidigt*. (I direktmetoden motsvarar detta att vi betraktar stora skillnader till ett referensvärde som extrema.) Slantsinglingstestet ovan är ett ensidigt hypotestest då det kritiska området har formen $C = [9, +\infty)$.


Låt oss betrakta ett tvåsidigt hypotestest.

Exempel 2. Antag att vi mäter den akustiska absorptionskoefficienten θ vid en viss frekvens för ett material. Vi vet att vår mätning har ett fel som följer en normalfördelning med känd standardavvikelse σ . Modellen är alltså att mätningen x är ett utfall av den stokastiska variabeln X med fördelning $N(\theta, \sigma)$.

För ett visst material, säg ett omålat trägolv, vet vi att $\theta = 0.15$ och vi vill veta om vi kan förändra θ genom en viss behandling, säg att vi målar golvet med en färg som sägs absorbera ljudet. Vår nollhypotes H_0 är då att ingen förändring sker, dvs. att $\theta = 0.15$ medan mothypotesen H_1 är att det sker en förändring, dvs. att $\theta \neq 0.15$. Givet en mätning x är en lämplig testvariabel då avståndet mellan x och 0.15:

$$u = |x - 0.15|.$$

Om u är större än ett kritiskt värde Δ förkastar vi H_0 till förmån för H_1 .



Hur väljer vi Δ ? Antag att vi nöjer oss med signifikansnivån $\alpha = 0.05$. Vi söker då Δ så att

$$P(|X - 0.15| \geq \Delta; 0.15) = \alpha$$

förutsatt att nollhypotesen gäller, dvs. att $X \sim N(0.15, \sigma)$. Vi kan omvandla sannolikheten ovan till

$$P(0.15 - \Delta < X < 0.15 + \Delta; 0.15) = 1 - \alpha,$$

och ser att vi kan använda kvantilerna hos den standardiserade normalfördelningen för att få $\Delta = \sigma \lambda_{\alpha/2} \approx 1.96\sigma$. Vårt test blir då

Om $|x - 0.15| \geq 1.96\sigma$, förkasta $H_0 : \theta = 0.15$.

Om ett test är ensidigt eller tvåsidigt beror på mothypotesen H_1 . I exemplet ovan har vi mothypotesen $H_1 : \theta \neq 0.15$. Som konsekvens får vi ett tvåsidigt test eftersom vi kan förkasta H_0 på två sätt: antingen för att θ är för litet eller för att θ är för stort. I slantsinglingsexemplet innan har vi nollhypotesen $H_0 : \theta = 1/2$ och mothypotesen $H_1 : \theta > 1/2$ eftersom vår slantsinglare Margit påstår att hon kan öka, inte minska, chansen att få krona (om hon endast påstod att hon kunde förändra chansen, men inte i en specifik riktning, skulle vi ha mothypotesen $H_1 : \theta \neq 1/2$).

I exemplet ovan kan vi också ana en länk mellan hypotestest och konfidensintervall. Generellt sett, antag att vi har ett konfidensintervall I_θ med konfidensgrad $1 - \alpha$ och söker ett test för nollhypotesen $H_0 : \theta = \theta_0$. Testet

Om $\theta_0 \notin I_\theta$, förkasta H_0

är då ett hypotestest med felrisk α eftersom vi har

$$P(\theta_0 \notin I_\theta; \theta_0) = 1 - P(\theta_0 \in I_\theta; \theta_0) = 1 - (1 - \alpha) = \alpha.$$

Konfidensintervallet I_θ kan ofta skrivas som en funktion $I_\theta(t)$ av testvariabeln t (till exempel om $t = \bar{x}$ så har vi $I_\theta(t) = [\bar{x} - \lambda_{\alpha/2}\sigma/\sqrt{n}, \bar{x} + \lambda_{\alpha/2}\sigma/\sqrt{n}]$ för ett normalfördelat stickprov med känd standardavvikelse σ). Med denna notation kan vi skriva det kritiska området som

$$C = \{t : \theta_0 \notin I_\theta(t)\},$$

dvs. vi förkastar H_0 för de värden på t som gör att konfidensintervallet $I_\theta(t)$ inte täcker θ_0 .

Vilken typ av konfidensintervall som krävs beror på mothypotesen H_1 . Om $H_1 : \theta \neq \theta_0$, dvs. testet är tvåsidigt, krävs ett tvåsidigt konfidensintervall $I_\theta = [a_1, a_2]$. Däremot om $H_1 : \theta < \theta_0$ behövs ett uppåt begränsat ensidigt konfidensintervall $I_\theta = (-\infty, a_2]$ eftersom vi vill förkasta H_0 om vårt skattade värde på θ ligger tillräckligt långt under θ_0 . På samma sätt har vi att för $H_1 : \theta > \theta_0$ behövs ett nedåt begränsat ensidigt konfidensintervall $I_\theta = [a_1, +\infty)$.

Denna metod för konstruktion av hypotestest kallas *konfidensmetoden*. Notera att alla tre metoder (testvariabel, direktmetoden och konfidensmetoden) ger upphov till samma test i slutändan.

Styrkefunktion

Som vi har sett är signifikansnivån eller felrisken α ett viktigt mått hos ett hypotes-test. Ett bra test ska ha en låg signifikansnivå eftersom detta minskar sannolikheten att H_0 förkastas felaktigt. Det finns inget som hindrar oss från att göra signifikansnivån godtyckligt liten – i testvariabelmetoden räcker det att minska det kritiska området. Vi minskar då risken att felaktigt förkasta H_0 men får ett test som kan vara mindre användbart då det blir näst intill omöjligt att förkasta H_0 över huvud taget. Om vi betraktar nollhypotesen H_0 som ett normaltillstånd är ett test med låg signifikansnivå alltså ett mycket *konserverativt* test – det krävs mycket extrema utfall för att förkasta nollhypotesen. Detta kan vara lämpligt i vissa situationer, men ofta vill vi inte vara så pass restriktiva.

För att förstå detta är det bra att kategorisera de två typer av fel vi kan göra i samband med ett hypotestest:

- Att vi förkastar H_0 trots att H_0 är sann. Detta kallas ett *fel av första slaget* eller ett *typ I-fel*. Sannolikheten att vi drabbas av ett sådant fel är α , per definition.
- Att vi inte förkastar H_0 trots att H_1 är sann. Detta kallas ett *fel av andra slaget* eller ett *typ II-fel*.

Om vi reducerar α för mycket löper vi risken att få typ II-fel, dvs. att vi inte förkastar H_0 även om vi borde då H_1 är sann.

För att kvantifiera ett typ II-fel är det användbart att betrakta en mothypotes H_1 . Vi kan då betrakta sannolikheten att H_0 inte förkastas givet att H_1 är sann. Mer allmänt definierar vi *styrkefunktionen*

$$h(\theta) = P(H_0 \text{ förkastas}; \theta).$$

Vi mäter alltså sannolikheten att H_0 förkastas givet att parametern tar värdet θ . Per definition har vi att $h(\theta_0) = \alpha$ givet nollhypotesen $H_0 : \theta = \theta_0$. För en mothypotes $H_1 : \theta = \theta_1$ har vi att $h(\theta_1)$ är sannolikheten att H_0 förkastas givet att H_1 är sann. Vi vill att detta ska vara stort. Med andra ord vill vi att $1 - h(\theta_1)$, sannolikheten att vi inte förkastar H_0 givet att H_1 är sann (ett typ II-fel) ska vara liten. Vi kallar $h(\theta_1)$ testets *styrka* för mothypotesen $H_1 : \theta = \theta_1$. Generellt sett kan vi säga att ett starkt test (dvs. ett test med hög styrka) är bra på att särskilja mellan H_0 och H_1 (för en given signifikansnivå).


Exempel 3. Vi återgår till slantsinglingsproblemet. Anta att Margit gör sitt påstå-
ende mer konkret. Hon hävdar att hon kan få krona sju gånger av åtta (att alltid få
krona är tydligen för svårt). Vi har då en mothypotes $H_1 : \theta = 7/8$ att ställa emot
vår nollhypotes $H_0 : \theta = 1/2$. Vad är styrkan för H_1 ?

Vårt test bestod i att förkasta H_0 om antalet kronor x är större än eller lika med 9,
så vi har

$$h(\theta) = P(X \geq 9; \theta) = p_X(9; \theta) + p_X(10; \theta) = \binom{10}{9} \theta^9 (1 - \theta) + \binom{10}{10} \theta^{10}.$$

Detta ger alltså $h(7/8) \approx 0.64$, vilket är stort men innebär ändå en risk för typ II-fel

på 0.36, vilket är för högt. Med andra ord finns det en risk att vi missar att förkasta vår nollhypotes även om vi borde (för att H_1 är sann).



Hur kan vi öka styrkan hos testet? Med andra ord, hur gararderar vi oss mot denna mothypotes? Vi singlar flera slantar. Vi tar $n = 20$ slantar får vi $X \sim \text{Bin}(20, \theta)$ och ett rimligt test är då

Om $x \geq 15$, förkasta $H_0 : \theta = 1/2$.

Detta test har en signifikansnivå på $\alpha = 0.02$ och styrkefunktionen

$$h(\theta) = P(X \geq 15; \theta) = \sum_{k=15}^{20} \binom{20}{k} \theta^k (1-\theta)^{20-k}.$$

Vi får då $h(7/8) \approx 0.97$ vilket ger att sannolikheten för ett typ II-fel med avseende på denna mothypotes är 0.03. Med detta test vet vi att vi troligen inte kommer att förkasta H_0 om nollhypotesen stämmer (eftersom α är litet) samt att vi troligen kommer förkasta H_0 om mothypotesen H_1 stämmer (eftersom $h(7/8)$ är stort).

Normalfördelade stickprov

Som innan är vi ofta intresserade av tillämpningar på normalfördelade stickprov. Låt oss anta att vi har oberoende stokastiska variabler $X_1, X_2, \dots, X_n$ med fördelning $N(\mu, \sigma)$. Till att börja med antar vi också att σ är känd. Vi vill testa nollhypotesen $H_0 : \mu = \mu_0$ med hjälp av utfallen $x_1, x_2, \dots, x_n$ på signifikansnivå α . För att åstadkomma detta bildar vi testvariabeln

$$u = \frac{(\bar{x} - \mu_0)\sqrt{n}}{\sigma}.$$

Notera att vi kan också använda $\bar{x}$ som testvariabel, men u är enklare att använda eftersom den motsvarande stokastiska variabeln $U = (\bar{X} - \mu_0)\sqrt{n}/\sigma$ har fördelning $N(0, 1)$ när H_0 är sann. Val av kritiskt område C beror nu på mothypotesen H_1 :

- Om $H_1 : \mu \neq \mu_0$ förkastar vi H_0 om $|u| \geq \lambda_{\alpha/2}$ (dvs. $C = (-\infty, -\lambda_{\alpha/2}] \cup [\lambda_{\alpha/2}, +\infty)$).
- Om $H_1 : \mu < \mu_0$ förkastar vi H_0 om $u \leq -\lambda_{\alpha}$ (dvs. $C = (-\infty, -\lambda_{\alpha}]$).
- Om $H_1 : \mu > \mu_0$ förkastar vi H_0 om $u \geq \lambda_{\alpha}$ (dvs. $C = [\lambda_{\alpha}, +\infty)$).

Om σ inte är känd och måste skattas från $x_1, x_2, \dots, x_n$ genom s har vi testvariabeln

$$u = \frac{(\bar{x} - \mu_0)\sqrt{n}}{s},$$

som utfall av den stokastiska variabeln $U = (\bar{X} - \mu_0)\sqrt{n}/s$ fördelad enligt $t(n-1)$. Vi får då samma test som i fallet med känd σ ovan men byter ut $N(0, 1)$ -kvantilerna λ_α med $t(n-1)$ -kvantilerna $t_\alpha(n-1)$.

Exempel 4. Antag att en polis vid en nykterhetskontroll utför n oberoende mätningar $x_1, x_2, \dots, x_n$ av mängden alkohol i utandningsluften. Dessa mätningar har normalfördelade fel med standardavvikelse $\sigma = 0.20$. Vi kan då se dessa som utfall av oberoende stokastiska variabler $X_1, X_2, \dots, X_n$ fördelade enligt $N(\mu, \sigma)$. Gränsen för rattfylla går vid $\mu = 0.10$ milligram alkohol per liter (detta motsvarar ungefär 0.2 promille i blodet). Vi vill alltså testa nollhypotesen $H_0 : \mu = 0.10$ (oskyldig till rattfylleri) mot $H_1 : \mu > 0.10$ (skyldig) med signifikansnivån $\alpha = 0.001$. Med denna låga nivå riskerar vi alltså att felaktigt förkasta nollhypotesen (dvs. att vi finner någon skyldig till rattfylleri som inte är skyldig) i genomsnitt en gång per tusen.


Enligt metoden ovan har vi då testvariabeln

$$u = \frac{(\bar{x} - 0.10)\sqrt{n}}{0.2}$$

som vi använder för att förkasta nollhypotesen om $u \geq \lambda_{0.001} \approx 3.09$. Detta ger då styrkefunktionen

$$\begin{aligned} h(\mu) &= P(U \geq 3.09; \mu) = P\left(\frac{(\bar{X} - 0.1)\sqrt{n}}{0.2} \geq 3.09; \mu\right) \\ &= P\left(\frac{(\bar{X} - \mu)\sqrt{n}}{0.2} + \frac{(\mu - 0.1)\sqrt{n}}{0.2} \geq 3.09; \mu\right) \\ &= P\left(\frac{(\bar{X} - \mu)\sqrt{n}}{0.2} \geq 3.09 - \frac{(\mu - 0.1)\sqrt{n}}{0.2}; \mu\right) \\ &= 1 - \Phi\left(3.09 - \frac{(\mu - 0.1)\sqrt{n}}{0.2}\right) \end{aligned}$$

eftersom $(\bar{X} - \mu)\sqrt{n}/0.2 \sim N(0, 1)$ för parametervärdet μ .



Vi ser att styrkefunktionens utseende kan kontrolleras med hjälp av n . Om n är litet blir det en svagt växande funktion av μ . Med andra ord kommer vi inte alltid att

förkasta H_0 (dvs. vi kommer inte finna personen skyldig) även om vi borde (för att $\mu > 0.1$). Genom att ta ett större n (dvs. att göra fler mätningar) kan vi öka styrkan på testet genom att öka sannolikheten att fälla skyldiga personer.

Avslutningsvis noterar vi att vi kan bilda *approximativa* hypotesttest genom tillämpning av centrala gränsvärdessatsen. Antag att vi har en punktskattning θ_{obs}^* vars stickprovsvariabel θ^* kan visas vara approximativt normalfördelad. Om vi vidare antar att standardavvikelsen D är känd (dvs. beror på θ_0) kan vi bilda testvariabeln

$$u = \frac{\theta_{\text{obs}}^* - \theta_0}{D}$$

och använda samma förfarande som ovan. Om standardavvikelsen måste skattas ifrån data ersätter vi D i formeln ovan med denna skattning d . Låt oss tillämpa detta på opinionsundersökningsexemplet från tidigare föreläsningar.

Exempel 5. Vi har alltså $X \sim \text{Bin}(1000, p)$ med utfallet $x = 450$ och är intresserade av att skatta p . Nollhypotesen H_0 är att $p = 1/2$, dvs. det väger jämt i den röstberättigade populationen mellan ja och nej i frågan. Mothypotesen är $H_1 : p < 1/2$, dvs. att färre personer stödjer ja-sidan jämfört med nej-sidan.

Vi har vår punktskattning $p_{\text{obs}}^* = x/n$ med tillhörande stickprovsvariabel $p^* = X/n$. Eftersom n är stort har vi att X är approximativt normalfördelat och p^* likaså. Vi vet att $E[p^*] = p$ och $D[p^*] = \sqrt{p(1-p)/n}$, så vi har då att p^* är approximativt $N(p, \sqrt{p(1-p)/n})$ -fördelat.

Vi bildar då testvariabeln

$$u = \frac{p_{\text{obs}}^* - 1/2}{d},$$

där $d = \sqrt{p_{\text{obs}}^*(1-p_{\text{obs}}^*)/n}$ är standardfelet för skattningen. Under antagandena ovan för stora n är $U = (p^* - 1/2)/d$ approximativt $N(0, 1)$ -fördelat, så vi har testet

Förkasta $H_0 : p = 1/2$ till förmån för $H_1 : p < 1/2$ om $u < -\lambda_\alpha$, dvs. om $p_{\text{obs}}^* < 1/2 - \lambda_\alpha d$.

I vårt fall hade vi $p_{\text{obs}}^* = 0.45$ och $d \approx 0.016$, vilket ger att vi förkastar H_0 på signifikansnivån $\alpha = 0.01$ om $0.45 < 0.50 - 2.33 \cdot 0.016 = 0.463$. Vi förkastar alltså $H_0 : p = 1/2$ till förmån för $H_1 : p < 1/2$ och kan dra slutsatsen att det troligtvis inte finns tillräckligt många ja-väljare för att ge majoritet vid en folkomröstning.

Föreläsning tolv

Joakim Andén

Enkel linjär regression

Vi har hittills betraktat skattning av parametrar i olika statistiska modeller i form av punktskattning, intervallskattning och hypotestest. I dagens föreläsning ska vi tillämpa dessa begrepp på en specifik (och mycket användbar) modell: linjär regression. En regressionsmodell beskriver ett samband mellan två storheter, ofta betecknade x och y . Detta kan vara ett samband mellan tryck och smältpunkt för en viss kemisk förening, antal motionstimmar per vecka och livslängd eller något annat. En enkel linjär regressionsmodell har formen

$$y = \alpha + \beta x$$

dvs. vi ansätter ett linjärt samband mellan x och y . Denna ekvation, med de sanna värdena på α och β , kallas för den *teoretiska regressionslinjen*. Variabeln x kallas *regressionsvariabel*, *förklarande variabel* eller *oberoende variabel* medan y kallas *beroende variabel*. Notera att vi kan behandla en större klass av (icke-linjära) modeller genom transformation av variablerna. Om vi till exempel har sambandet

$$u = at^b$$

(dvs. ett rent potensförhållande) mellan den oberoende variabeln t och den beroende variabeln u kan vi logaritmera och då få


$$\log u = \log a + b \log t$$

vilket ger den linjära modellen $y = \alpha + \beta x$ genom att definiera $y = \log u$, $x = \log t$, $\alpha = \log a$, $\beta = b$.

Om vi har tillgång till exakta värden (dvs. utan fel) på x och y räcker det med två par (x_1, y_1) och (x_2, y_2) för att lösa ut α och β . Tyvärr är detta sällan fallet och vi måste skatta parametrarna utifrån datapunkter behäftade med mätfel. Ofta har vi då datapunkterna $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ som uppfyller

$$y_i = \alpha + \beta x_i + e_i$$

för $i = 1, 2, \dots, n$ där e_i är mätfelet för det i :te mätvärdet.



Exempel 1. Antag att vi har undersökt $n = 20$ nyfödda barn och mätt deras bilirubinhalt x samt koncentrationen hos ett visst protein y i ryggmärgsvätskan genom lumbarpunktion. Eftersom mätning bilirubinhalt är mindre invasiv (kan göras genom ett litet blodprov) än lumbarpunktion vill vi gärna kunna förutsäga proteinkoncentrationen utifrån bilirubinhalten. Antag att vi har erhållit datapunkterna

x	0.14	0.08	0.07	0.26	0.08	0.02	0.03	0.22	0.06	0.23
y	83	65	71	140	135	30	30	128	80	168
x	0.29	0.04	0.13	0.14	0.07	0.05	0.13	0.06	0.05	0.08
y	139	88	121	125	56	98	101	96	73	116

Vi söker alltså α och β så att modellen $y = \alpha + \beta x$ passar så bra som möjligt för datapunkterna ovan.

Ett sätt att angripa skattningen av α och β är att betrakta e_i som utfall av oberoende stokastiska variabler E_i med fördelning $N(0, \sigma)$ för någon (känd) σ . Vi får då att y_i är ett utfall av de oberoende stokastiska variablerna

$$Y_i = \alpha + \beta x_i + E_i$$

för $i = 1, 2, \dots, n$ och har då $Y_i \sim N(\mu_i, \sigma)$ för $\mu_i = \alpha + \beta x_i$. Vi har alltså n oberoende stokastiska variabler, men de är *inte* likafördelade.

För att skatta α och β kan vi bilda likelihoodfunktionen

$$\begin{aligned}
 L(\alpha, \beta) &= L(\alpha, \beta; y_1, y_2, \dots, y_n) \\
 &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \alpha - \beta x_i)^2}{2\sigma^2}} \\
 &= \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2}
 \end{aligned}$$

vilket ger log-likelihoodfunktionen

$$\log L(\alpha, \beta) = -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2 + C$$

där C är en konstant som inte beror på α , β eller σ^2 .

Om vi deriverar $\log L(\alpha, \beta)$ med avseende på α och β får vi

$$\begin{aligned} \frac{\partial}{\partial \alpha} \log L(\alpha, \beta) &= \frac{1}{\sigma^2} \sum_{i=1}^n y_i - \alpha - \beta x_i \\ \frac{\partial}{\partial \beta} \log L(\alpha, \beta) &= \frac{1}{\sigma^2} \sum_{i=1}^n x_i (y_i - \alpha - \beta x_i). \end{aligned}$$

Om vi sätter dessa till noll och multiplicerar med σ^2 får vi ekvationssystemet

$$\begin{cases} \sum_{i=1}^n (y_i - \alpha - \beta x_i) = 0 \\ \sum_{i=1}^n x_i (y_i - \alpha - \beta x_i) = 0. \end{cases}$$

Den första ekvationen ger då

$$\alpha = \frac{1}{n} \sum_{i=1}^n y_i - \beta \bar{x} = \bar{y} - \beta \bar{x}$$

och medan den andra ger

$$\beta \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i - \alpha \sum_{i=1}^n x_i = -n\alpha \bar{x} + \sum_{i=1}^n x_i y_i.$$

Om vi sätter in uttrycket för α får vi

$$\beta \sum_{i=1}^n x_i^2 = -n(\bar{y} - \beta \bar{x}) \bar{x} + \sum_{i=1}^n x_i y_i = -n\beta \bar{x}^2 + \sum_{i=1}^n x_i y_i - n\bar{x} \bar{y}.$$

Sedan löser vi ut β , vilket ger

$$\beta = \frac{\sum_{i=1}^n x_i y_i - n\bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{s_{xy}}{s_{xx}},$$

där vi har infört beteckningarna

$$s_{xy} = \sum_{i=1}^n x_i y_i - n\bar{x} \bar{y} \quad \text{och} \quad s_{xx} = \sum_{i=1}^n x_i^2 - n\bar{x}^2.$$

Notera att dessa kan skrivas om som

$$s_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad \text{och} \quad s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2,$$

men att de första uttrycken oftast är enklare att använda i beräkningar.

Vi kan visa att denna kritiska punkt för $\log L(\alpha, \beta)$ utgör ett globalt maximum. Notera först att för $z_1, z_2, \dots, z_n$ har vi

$$\sum_{i=1}^n (z_i - \alpha)^2 \leq \sum_{i=1}^n (z_i - \bar{z})^2$$

för alla $\alpha \in \mathbb{R}$, dvs. att $\bar{z}$ är ett minimum för $\alpha \mapsto \sum_{i=1}^n (z_i - \alpha)^2$. Om vi då tar $z_i = y_i - \beta x_i$ får vi

$$\sum_{i=1}^n (y_i - \beta x_i - \alpha)^2 \leq \sum_{i=1}^n (y_i - \beta x_i - \bar{y} + \beta \bar{x})^2$$

vilket efter multiplikation med $-1/2\sigma^2$ plus en konstant då ger

$$\log L(\alpha, \beta) \leq \log L(\bar{y} - \beta \bar{x}, \beta)$$

för alla $\alpha \in \mathbb{R}$. Det räcker alltså att maximera högerledet $\log L(\bar{y} - \beta \bar{x}, \beta)$ med avseende på β . Vi har redan sett att $\beta = s_{xy}/s_{xx}$ utgör en kritisk punkt, så vi måste visa att detta är ett globalt maximum. Vi har alltså

$$\begin{aligned} \frac{d}{d\beta} \log L(\bar{y} - \beta \bar{x}, \beta) &= \frac{d}{d\beta} \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta x_i - \bar{y} + \beta \bar{x})^2 \right) \\ &= \frac{d}{d\beta} \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \bar{y} - \beta(x_i - \bar{x}))^2 \right) \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \bar{y} - \beta(x_i - \bar{x}))(x_i - \bar{x}) \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x}) - \beta \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{\sigma^2} (s_{xy} - \beta s_{xx}). \end{aligned}$$

Detta ger alltså att $\beta = s_{xy}/s_{xx}$ är en kritisk punkt, som väntat. Andraderivatan är

$$\frac{d^2}{d\beta^2} \log L(\bar{y} - \beta \bar{x}, \beta) = -\frac{s_{xx}}{\sigma^2},$$

så om $s_{xx} \neq 0$ så är Andraderivatan strikt negativ, vilket ger att $\beta = s_{xy}/s_{xx}$ är ett globalt maximum. (Fallet $s_{xx} = 0$ motsvarar att $x_1 = x_2 = \dots = x_n$ och i detta fall kan vi inte passa en regressionslinje genom punkterna.)

Vi har då att ML-skattningen för (α, β) är

$$\alpha_{\text{obs}}^* = \bar{y} - \beta_{\text{obs}}^* \bar{x} \quad \text{och} \quad \beta_{\text{obs}}^* = \frac{s_{xy}}{s_{xx}}.$$


Om vi stoppar in dessa värden i ekvationen $y = \alpha + \beta x$ får vi

$$y = \alpha_{\text{obs}}^* + \beta_{\text{obs}}^* x,$$

vilket kallas den *skattade regressionlinjen*. Ofta är vi också intresserade i att förutsäga, dvs. göra en *prediktion*, av väntevärdet $\mu(x)$ för ett visst värde på x . Vi har då det *skattade väntevärdet*

$$\mu_{\text{obs}}^*(x) = \alpha_{\text{obs}}^* + \beta_{\text{obs}}^* x.$$

(I boken används notationen μ_0^* och x_0 istället för $\mu_{\text{obs}}^*(x)$ och x , men detta gör det svårare att skilja på skattning och stickprovsvariabel, så vi undviker detta här.)



Exempel 2. Vi återkommer nu till bilirubinmodellen ovan. Utifrån mätdata har vi

$$\sum_{i=1}^n x_i = 2.33 \quad \sum_{i=1}^n x_i^2 = 0.3701 \quad \sum_{i=1}^n y_i = 1943 \quad \sum_{i=1}^n x_i y_i = 259.79$$

vilket ger $\bar{x} = 0.1115$, $\bar{y} = 97.15$, $s_{xy} = 43.1455$ och $s_{xx} = 0.121455$. Enligt formelerna ovan ger detta punktskattningarna

$$\beta_{\text{obs}}^* \approx 355.2 \quad \text{och} \quad \alpha_{\text{obs}}^* \approx 57.5.$$

Låt oss säga att vi har en viss bilirubinhalt $x = 0.20$ och vill skatta proteinkoncentrationen. Vi får då

$$\mu_{\text{obs}}^*(0.20) = \alpha_{\text{obs}}^* + \beta_{\text{obs}}^* \cdot 0.20 \approx 57.5 + 355.2 \cdot 0.20 \approx 129.$$

En viktig egenskap är att skattningarna α_{obs}^* och β_{obs}^* är *linjära* i observationerna $y_1, y_2, \dots, y_n$, dvs. att de kan skrivas som linjärkombinationer av värdena $y_1, y_2, \dots, y_n$. Detta är en konsekvens av att regressionsmodellen för $y = \alpha + \beta x$ själv är linjär i x . Notera att vi *inte* har linjäritet för α_{obs}^* och β_{obs}^* med avseende på $x_1, x_2, \dots, x_n$, men detta skapar inga större problem eftersom x -värdena hålls fixa i modellen.

För att göra detta förhållande mer tydligt skriver vi om β_{obs}^* som

$$\begin{aligned}\beta_{\text{obs}}^* &= \frac{s_{xy}}{s_{xx}} = \frac{1}{s_{xx}} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ &= \frac{1}{s_{xx}} \left(\sum_{i=1}^n (x_i - \bar{x})y_i - \sum_{i=1}^n (x_i - \bar{x})\bar{y} \right) \\ &= \frac{1}{s_{xx}} \left(\sum_{i=1}^n (x_i - \bar{x})y_i - 0 \right) = \sum_{i=1}^n \frac{x_i - \bar{x}}{s_{xx}} y_i = \sum_{i=1}^n c_i y_i\end{aligned}$$

där $c_i = (x_i - \bar{x})/s_{xx}$. På samma sätt har vi

$$\alpha_{\text{obs}}^* = \bar{y} - \beta_{\text{obs}}^* \bar{x} = \frac{1}{n} \sum_{i=1}^n y_i - \sum_{i=1}^n c_i y_i \bar{x} = \sum_{i=1}^n \left(\frac{1}{n} - c_i \bar{x} \right) y_i = \sum_{i=1}^n d_i y_i,$$

där $d_i = 1/n - c_i \bar{x}$.

Vi kan nu använda linjäritetsrelationerna ovan för att undersöka väntevärdet och variansen hos våra skattningar. Vi har alltså stickprovsvariablerna

$$\beta^* = \sum_{i=1}^n c_i Y_i \quad \text{och} \quad \alpha^* = \sum_{i=1}^n d_i Y_i$$

för skattningarna β_{obs}^* respektive α_{obs}^* . För β^* har vi då väntevärdet

$$\begin{aligned}E[\beta^*] &= E\left[\sum_{i=1}^n c_i Y_i\right] = \sum_{i=1}^n c_i E[Y_i] = \sum_{i=1}^n c_i (\alpha + \beta x_i) \\ &= \frac{1}{s_{xx}} \sum_{i=1}^n (x_i - \bar{x})(\alpha + \beta x_i) \\ &= \frac{1}{s_{xx}} \left(\alpha \sum_{i=1}^n (x_i - \bar{x}) + \beta \sum_{i=1}^n x_i (x_i - \bar{x}) \right) \\ &= \frac{1}{s_{xx}} \left(\alpha \cdot 0 + \beta \sum_{i=1}^n x_i^2 - \beta \bar{x} \sum_{i=1}^n x_i \right) \\ &= \frac{1}{s_{xx}} \beta \left(\sum_{i=1}^n x_i^2 - n \bar{x}^2 \right) = \frac{1}{s_{xx}} \beta s_{xx} = \beta,\end{aligned}$$

där vi har använt att $\sum_{i=1}^n x_i - n\bar{x} = 0$. Skattningen β_{obs}^* är alltså väntevärdesriktig. Eftersom $Y_1, Y_2, \dots, Y_n$ antas vara oberoende med samma varians σ^2 får vi

$$V[\beta^*] = V\left[\sum_{i=1}^n c_i Y_i\right] = \sum_{i=1}^n c_i^2 V[Y_i] = \frac{\sigma^2}{s_{xx}^2} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{\sigma^2}{s_{xx}^2} s_{xx} = \frac{\sigma^2}{s_{xx}}.$$

Standardavvikelsen är då $D[\beta^*] = \sigma / \sqrt{s_{xx}}$ och kan skrivas om som

$$D[\beta^*] = \frac{\sigma}{\sqrt{n}} \cdot \frac{1}{\sqrt{s_{xx}/n}}.$$

Felet i skattningen blir alltså litet om mätfelet σ är litet, antalet mätvärden n är stort eller spridningen s_{xx}/n av x -värdena är stor. Eftersom felet går mot noll då $n \rightarrow +\infty$ så är skattningen konsistent.

Istället för att beräkna väntevärdet och variansen för α^* utför vi beräkningen för $\mu^*(x)$. Vi får då värdena för α^* genom att sätta in $x = 0$ eftersom $\alpha^* = \mu^*(0)$. Först har vi alltså väntevärdet

$$\begin{aligned} E[\mu^*(x)] &= E[\alpha^* + \beta^*x] = E\left[\sum_{i=1}^n (d_i + c_i x) Y_i\right] = \sum_{i=1}^n (d_i + c_i x) E[Y_i] \\ &= \sum_{i=1}^n \left(\frac{1}{n} - c_i \bar{x} + c_i x\right) (\alpha + \beta x_i) \\ &= \sum_{i=1}^n \left(\frac{1}{n} + c_i (x - \bar{x})\right) (\alpha + \beta x_i) \\ &= \sum_{i=1}^n \frac{\alpha}{n} + \alpha c_i (x - \bar{x}) + \frac{\beta x_i}{n} + \beta x_i c_i (x - \bar{x}) \\ &= \alpha + \beta \bar{x} + (x - \bar{x}) \sum_{i=1}^n c_i + \beta (x - \bar{x}) \sum_{i=1}^n x_i c_i \end{aligned}$$

Vi kan förenkla detta uttryck genom att beräkna

$$\sum_{i=1}^n c_i = \frac{1}{s_{xx}} \sum_{i=1}^n (x_i - \bar{x}) = \frac{1}{s_{xx}} \left(\sum_{i=1}^n x_i - n\bar{x} \right) = \frac{1}{s_{xx}} (n\bar{x} - n\bar{x}) = 0$$

och

$$\sum_{i=1}^n x_i c_i = \frac{1}{s_{xx}} \sum_{i=1}^n x_i (x_i - \bar{x}) = \frac{1}{s_{xx}} \left(\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i \right) = \frac{1}{s_{xx}} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) = \frac{1}{s_{xx}} \cdot s_{xx} = 1.$$

Om vi sätter in dessa identiteter får vi

$$E[\mu^*(x)] = \alpha + \beta \bar{x} + \beta (x - \bar{x}) = \alpha + \beta x.$$

Med andra ord är skattningen $\mu_{\text{obs}}^*(x)$ väntevärdesriktig (och likaså $\alpha_{\text{obs}}^* = \mu_{\text{obs}}^*(0)$).

Variansen fås på liknande sätt:


$$\begin{aligned}
 V[\mu^*(x)] &= V\left[\sum_{i=1}^n (d_i + c_i x) Y_i\right] = \sum_{i=1}^n (d_i + c_i x)^2 V[Y_i] = \sigma^2 \sum_{i=1}^n \left(\frac{1}{n} + c_i(x - \bar{x})\right)^2 \\
 &= \sigma^2 \sum_{i=1}^n \frac{1}{n^2} + 2 \frac{(x - \bar{x})}{n} \sum_{i=1}^n c_i + c_i^2 (x - \bar{x})^2 \\
 &= \sigma^2 \left(\frac{1}{n} + 2 \frac{(x - \bar{x})}{n} \sum_{i=1}^n c_i + (x - \bar{x})^2 \sum_{i=1}^n c_i^2 \right) \\
 &= \sigma^2 \left(\frac{1}{n} + 2 \frac{(x - \bar{x})}{n} \cdot 0 + (x - \bar{x})^2 \frac{1}{s_{xx}} \right) = \sigma^2 \left(\frac{1}{n} + \frac{(x - \bar{x})^2}{s_{xx}} \right),
 \end{aligned}$$

där vi har använt att $\sum_{i=1}^n c_i = 0$ och att

$$\sum_{i=1}^n c_i^2 = \frac{1}{s_{xx}^2} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{s_{xx}^2} \cdot s_{xx} = \frac{1}{s_{xx}}.$$

Om vi tar ut faktorn $1/n$ får vi då standardavvikelsen

$$D[\mu^*(x)] = \frac{\sigma}{\sqrt{n}} \cdot \sqrt{1 + \frac{(x - \bar{x})^2}{s_{xx}/n}}.$$



Låt oss analysera detta fel lite närmare. Först har vi den bekanta $\sigma/\sqrt{n}$ -faktorn – felet är proportionellt med det ursprungliga mätfelet σ och avtar som kvadratroten av stickprovsstorleken n . Den andra faktorn $\sqrt{1 + (x - \bar{x})^2/(s_{xx}/n)}$ är ny. Vi såg s_{xx}/n innan i samband med felet i skattningen β_{obs}^* – detta motsvarar spridningen i x -värdena. Om kvadratavståndet $(x - \bar{x})^2$ är litet med avseende på denna spridning får vi ett litet fel (så litet som grundfelet $\sigma/\sqrt{n}$ tillåter). Om å andra sidan x ligger

långt ifrån $\bar{x}$, längre bort än x -värdena $x_1, x_2, \dots, x_n$ (som använts för att skatta α och β) ligger, då får vi ett större fel. Anledningen till detta är att vi går från *interpolering* till *extrapolering*. Nära $\bar{x}$ har vi god kännedom av regressionslinjen, vi har många x - och y -värden som tvingar vår skattning $\mu_{\text{obs}}^*(x)$ in i ett snävt intervall. Längre bort finns många olika linjer som skulle passa de givna x - och y -värdena lika bra och vi har därför större osäkerhet.

Innan vi går vidare ska vi gå tillbaka till regressionsmodellen $Y_i = \alpha + \beta x_i + E_i$. Vi har skattat α och β men antagit att $V[E_i] = \sigma^2$ är känd (även om detta inte spelar någon roll såvida vi behöver standardavvikelserna $D[\beta^*]$ och $D[\mu^*(x)]$). Så behöver inte nödvändigtvis vara fallet. För att åstadkomma detta behöver vi skatta α , β och σ^2 samtidigt. Som innan sätter vi då upp likelihoodfunktionen

$$\begin{aligned} L(\alpha, \beta, \sigma^2) &= L(\alpha, \beta, \sigma^2; (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2}. \end{aligned}$$

Vi kan då beräkna partialderivatorna med avseende på α , β och σ^2 , sätta dessa till noll för att hitta en kritisk punkt. Vi visar sedan att denna punkt är ett globalt maximum och därför utgör vår ML-skattning för parametrarna. För α och β får vi samma α_{obs}^* och β_{obs}^* som innan och för σ^2 får vi skattningen

$$(\sigma^2)_{\text{obs}}^* = \frac{1}{n} \sum_{i=1}^n (y_i - \alpha_{\text{obs}}^* - \beta_{\text{obs}}^* x_i)^2.$$

Värdena $y_i - \alpha_{\text{obs}}^* - \beta_{\text{obs}}^* x_i$ brukar kallas regressionsmodellens *residualer* och betecknas ofta med r_i . Eftersom $\alpha_{\text{obs}}^* = \bar{y} - \beta_{\text{obs}}^* \bar{x}$ har vi att

$$\begin{aligned} \sum_{i=1}^n r_i^2 &= \sum_{i=1}^n ((y_i - \bar{y}) - \beta_{\text{obs}}^* (x_i - \bar{x}))^2 \\ &= \sum_{i=1}^n (y_i - \bar{y})^2 - 2\beta_{\text{obs}}^* \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) + (\beta_{\text{obs}}^*)^2 \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= s_{yy} - 2\beta_{\text{obs}}^* s_{xy} + (\beta_{\text{obs}}^*)^2 s_{xx} = s_{yy} - \frac{s_{xy}^2}{s_{xx}}, \end{aligned}$$

där vi infört notationen $s_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$. ML-skattningen ovan är då

$$(\sigma^2)_{\text{obs}}^* = \sum_{i=1}^n r_i^2 / n = (s_{yy} - s_{xy}^2 / s_{xx}) / n.$$

Denna är tyvärr inte väntevärdesriktig och måste korrigeras genom multiplikation med faktorn $n/(n-2)$, vilket ger den väntevärdesriktiga skattningen

$$s^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \alpha_{\text{obs}}^* - \beta_{\text{obs}}^* x_i)^2 = \frac{1}{n-2} \sum_{i=1}^n r_i^2 = \frac{s_{yy} - s_{xy}^2 / s_{xx}}{n-2}.$$

Kvadratroten s utgör då en punktskattning för σ . (Faktorn $n - 2$ i nämnaren fås eftersom summan av residualerna är utfall av en χ^2 -fördelning med $n - 2$ frihetsgrader. Anledningen till att vi har "förlorat" två frihetsgrader är att vi redan skattat två parametrar α och β och dessa då är "fixa" när vi bildar kvadratsumman.)

Exempel 3. I bilirubinexemplet är inte standaravvikelsen σ känd utan måste skattas. Utifrån datan har vi

$$\sum_{i=1}^n y_i^2 = 215061$$

vilket ger $s_{yy} = 26298.55$. Sedan innan hade vi $s_{xy} = 43.1455$ och $s_{xx} = 0.1211455$ så vi har då

$$s^2 = \frac{s_{yy} - s_{xy}^2/s_{xx}}{n - 2} \approx 609.5$$

och vi får då skattningen $s \approx 24.69$ av σ .

Om vi stoppar in detta istället för σ i formeln för standaravvikelsen $D[\beta^*]$ får vi medelfelet

$$d(\beta^*) = s/\sqrt{s_{xx}} \approx 70.84.$$

För $x = 0.20$ har vi

$$d(\mu^*(0.20)) = (s/\sqrt{n})\sqrt{1 + (0.20 - \bar{x})^2/(s_{xx}/n)} \approx 8.35.$$

Med tanke på att skattningarna själva är $\beta_{\text{obs}}^* \approx 355.2$ respektive $\mu_{\text{obs}}^*(0.20) \approx 129$ så är dessa fel varken mycket små eller mycket stora. Om vi istället skulle skatta $\mu(x)$ för ett x långt ifrån $\bar{x} = 0.1115$ skulle vi få ett större medelfel.

Intervallskattning och hypotestest

Som vi såg ovan är skattningarna α_{obs}^* , β_{obs}^* och $\mu_{\text{obs}}^*(x)$ linjärkombinationer av mätvärden $y_1, y_2, \dots, y_n$. Eftersom mätvärdena är utfall av de oberoende, normalfördelade stokastiska variablerna $Y_1, Y_2, \dots, Y_n$ så gäller att även stickprovsvariablerna α^* , β^* och μ^* är normalfördelade. Utifrån de beräknade väntevärdena och standaravvikelseerna ovan får vi då att

$$\beta^* \sim N\left(\beta, \frac{\sigma}{\sqrt{n}} \cdot \frac{1}{\sqrt{s_{xx}/n}}\right) \quad \text{och} \quad \mu^*(x) \sim N\left(\alpha + \beta x, \frac{\sigma}{\sqrt{n}} \cdot \sqrt{1 + \frac{(x - \bar{x})^2}{s_{xx}/n}}\right).$$

(Återigen får vi fördelningen för α^* genom förhållandet $\alpha^* = \mu^*(0)$.)

Om σ är känd har vi då konfidensintervallen

$$I_\beta = [\beta_{\text{obs}}^* - \lambda_{p/2} D, \beta_{\text{obs}}^* + \lambda_{p/2} D] \quad \text{där } D = \frac{\sigma}{\sqrt{n}} \cdot \frac{1}{\sqrt{s_{xx}/n}},$$

$$I_{\mu(x)} = [\mu_{\text{obs}}^*(x) - \lambda_{p/2} D, \mu_{\text{obs}}^*(x) + \lambda_{p/2} D] \quad \text{där } D = \frac{\sigma}{\sqrt{n}} \cdot \sqrt{1 + \frac{(x - \bar{x})^2}{s_{xx}/n}},$$

med konfidensgrad $1 - p$. (Vi använder beteckningen p här istället för α eftersom denna redan används för konstanttermen i regressionsmodellen.) Om σ är okänd måste denna skattas med $s = \sqrt{(s_{yy} - s_{xy}^2/s_{xx})/(n-2)}$ och man kan då visa att

$$\frac{\beta^* \sqrt{s_{xx}/n}}{s/\sqrt{n}} \sim t(n-2) \quad \text{och} \quad \frac{\mu^*(x) \left(1 + \frac{(x-\bar{x})^2}{s_{xx}/n}\right)^{-1/2}}{s/\sqrt{n}} \sim t(n-2).$$

Detta ger då konfidensintervallen

$$I_\beta = [\beta_{\text{obs}}^* - t_{p/2}(n-2)d, \beta_{\text{obs}}^* + t_{p/2}(n-2)d] \quad \text{där } d = \frac{s}{\sqrt{n}} \cdot \frac{1}{\sqrt{s_{xx}/n}},$$

$$I_{\mu(x)} = [\mu_{\text{obs}}^*(x) - t_{p/2}(n-2)d, \mu_{\text{obs}}^*(x) + t_{p/2}(n-2)d] \quad \text{där } d = \frac{s}{\sqrt{n}} \cdot \sqrt{1 + \frac{(x-\bar{x})^2}{s_{xx}/n}},$$

med konfidensgrad $1 - p$.

Dessa konfidensintervall kan också användas för att konstruera hypotestest genom konfidensmetoden. Till exempel kan vi pröva nollhypotesen att y inte beror på x , dvs. $H_0 : \beta = 0$ genom att H_0 förkastas med signifikansnivå p om $0 \notin I_\beta$, där I_β är ett konfidensintervall för β med konfidensgrad $1 - p$.

Exempel 4. I bilirubinexemplet fann vi att $\beta_{\text{obs}}^* \approx 355.2$ och $s \approx 24.69$, vilket gav medelfelet $d(\beta^*) \approx 70.84$. Eftersom $n = 20$ har vi då kvantilerna $t_{p/2}(n-2) = t_{0.025}(18) \approx 2.101$ för konfidensgraden $1 - p = 0.95$, vilket ger konfidensintervallet

$$\begin{aligned} I_\beta &= \beta_{\text{obs}}^* \pm t_{0.025}(18)d(\beta^*) \\ &\approx 355.2 \pm 2.101 \cdot 70.84 \\ &\approx 355.2 \pm 138.8 \approx [216.8, 494.5]. \end{aligned}$$

Vi kan alltså förkasta hypotesen $H_0 : \beta = 0$ med signifikansnivå $p = 0.05$ – det finns alltså troligen ett samband mellan bilirubinhalt och proteinkoncentration. Intervallet är däremot stort, vilket betyder att vi inte kan bestämma detta samband särskilt exakt med de data som vi har att tillgå. Samma kalkyl för $\mu(0.20)$ ger intervallet

$$I_{\mu(0.20)} \approx 129 \pm 16.4 \approx [112, 145],$$

vilket också är ganska brett.

Multipel linjär regression

Vi noterar till sist att den linjära regressionsmodellen kan generaliseras till fler än en regressionsvariabel. Vi har då modellen

$$y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k,$$

där vi behöver skatta parametrarna $\alpha, \beta_1, \beta_2, \dots, \beta_k$ utifrån mätdata

$$(x_{11}, x_{21}, \dots, x_{k1}, y_1), (x_{12}, x_{22}, \dots, x_{k2}, y_2), \dots, (x_{1n}, x_{2n}, \dots, x_{kn}, y_n).$$

Vi betraktar då y -värdena $y_1, y_2, \dots, y_n$ som utfall av oberoende stokastiska variabler $Y_1, Y_2, \dots, Y_n$ med fördelningar

$$Y_i \sim N(\mu_i, \sigma) \quad \text{där } \mu_i = \alpha + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki},$$

för $i = 1, 2, \dots, n$. Som innan kan vi då bilda likelihoodfunktionen $L(\alpha, \beta_1, \beta_2, \dots, \beta_k)$ och maximera denna för att få ML-skattningarna $\alpha_{\text{obs}}^*, (\beta_1)_{\text{obs}}^*, (\beta_2)_{\text{obs}}^*, \dots, (\beta_k)_{\text{obs}}^*$. Från dessa kan vi utveckla intervallskattningar och hypotestest precis som innan. Tyvärr blir beräkningarna här mer komplicerade och kräver verktyg som ligger utanför denna kurs. Mer information om regression (både enkel och multipel) kommer att behandlas i fortsättningskursen SF2930 Regressionanalys. Vi kommer också att utforska multipel regression i sista uppgiften av den andra datorlaborationen.

Föreläsning tretton

Joakim Andén

Apriorifördelning

Hittills har vi antagit att den sökta parametern har ett fixt värde och försöker skatta denna (eller dessa) utifrån ett slumpmässigt stickprov. Detta kan till exempel göras med en ML- eller MK-skattning. Tanken är att om vi repeterar denna skattning på olika stickprov så får vi en viss fördelning på skattningens stickprovsvariabel. Utifrån denna kan vi sedan beräkna väntevärde, standardavvikelse, konfidensintervall, testa hypoteser, och så vidare.

Alla dessa förfaranden utgår ifrån en (åtminstone teoretisk) repetition av experimentet, men en sådan är inte alltid möjlig. Till exempel kan vi vilja prata om sannolikheten att det regnar imorgon givet dagens väderförhållanden. Vi kan inte repetera detta experiment utan har bara ett stickprov. Grundproblemet är frekvenstolkningen av sannolikhetsbegreppet. Om vi istället tolkar sannolikheter subjektivt, dvs. som ett mått på hur mycket vi tror på ett visst påstående (som att det regnar imorgon), öppnas möjligheter att modellera andra fenomen.

En naturlig konsekvens av en subjektiv sannolikhetstolkning är att vi inte längre behöver betrakta parametern som ett fixt värde. I stället kan vi betrakta den som en stokastisk variabel med en viss fördelning. Denna fördelning motsvarar då vad för värden som vi tror att parametern antar. Med andra ord kvantifierar parametrarnas fördelning vår osäkerhet gällande dess värde.

Vi återgår nu till huvudproblemet inom statistisk inferens: skattning av parametrar från data. Med perspektivet ovan blir då uppgiften att bestämma parametrarnas fördelning utifrån mätdata. Detta görs enklast genom att betrakta mätdatan som utfall av en betingad fördelning där betingningen sker med avseende på den sökta parametern. Målet är sedan att vända på betingningen, dvs. att bestämma den betingade fördelningen av parametern med avseende på mätdatan. För att åstadkomma detta använder vi Bayes sats.

Låt oss anta att vår sökta parameter är ett utfall θ av den stokastiska variabeln Θ . Innan vi kan tillämpa Bayes sats behöver vi veta fördelningen på Θ innan vi ser datan. Detta kallas parametrarnas *apriorifördelning* (*a priori* betyder *på förhand* på latin) och betecknas med $f_{\Theta}(\theta)$ (detta är alltså täthetsfunktionen för Θ om det är en kontinuerlig stokastisk variabel och en sannolikhetsfunktion om den är diskret).

Apriorifördelningen $f_{\Theta}(\theta)$ motsvarar våra antaganden om Θ : utan att vi har sett några data, vilka värden tror vi att Θ antar? Vi kan på detta sätt baka in olika an-

taganden (hur stor eller liten borde parametern vara) eller information från tidigare experiment (vår modell kanske baseras på en annan modell där vi vet vad för värde Θ antar). Notera att detta inte är möjligt inom den klassiska inferensteorin: i till exempel ML-skattning så kan parametern θ anta vilket värde som helst (eller eventuellt begränsas till en delmängd, men inte mer än så).

Den andra ingrediensen beskriver hur parametern Θ påverkar fördelningen av våra mätdata. Detta är den betingade fördelningen av mätdata X givet $\Theta = \theta$ och skrivs $f_{X|\theta}(x|\theta)$. Vi kallar detta för *datafördelningen* eller *samplingfördelningen*. (Återigen använder vi samma beteckning för täthetsfunktion – om X är kontinuerlig – och sannolikhetsfunktion – om X är diskret.) Datafördelningen är redan bekant från tidigare föreläsningar, då kallade vi den för likelihoodfunktionen. Som vi kommer att se så skiljer de sig emellertid åt i hur de tillämpas och hur de tolkas.

Om vi multiplicerar datafördelningen med apriorifördelningen och integrerar över θ får vi *marginalfördelningen*


$$f_X(x) = \int_{\Sigma_\theta} f_{X|\theta}(x|\theta) f_\Theta(\theta) d\theta$$

enligt lagen om total sannolikhet där Σ_θ är mängden av möjliga parametrar. (Om Θ är diskret ersätter vi integralen med en summa $\sum_{\theta \in \Sigma_\theta} f_{X|\theta}(x|\theta) f_\Theta(\theta)$.) Detta är alltså den obetingade fördelningen för mätdata: fördelningen för X som vi förväntar oss om parametern Θ tillåts variera enligt apriorifördelningen $f_\Theta(\theta)$.

Ett sätt att förstå apriorifördelningar, datafördelningar och marginalfördelningar är att se det slumpmässiga försöket som en tvåstegsprocess: först dras en parameter θ_1 enligt $f_\Theta(\theta)$ och sedan dras x_1 enligt $f_{X|\theta}(x|\theta_1)$ – denna fördelning är alltså betingad med avseende på händelsen $\Theta = \theta_1$. Om detta försök repeteras (och vi får alltså en ny parameter θ_1 och datapunkt x_1 varje gång) så kommer de dragna värdena x_1 att följa fördelningen marginalfördelningen $f_X(x)$. Vi illustrerar detta med ett konkret exempel.

Exempel 1. Anta att vi har en påse med fyra stycken kronor. En har sannolikheten 0.2 att hamna på klave när vi singlar, två har sannolikheten 0.5 att hamna på klave och en har sannolikheten 0.8 att hamna på klave. Om vi låter θ beteckna sannolikheten att det dragna myntet hamnar på klave när vi singlar har denna sannolikhetsfunktionen

$$f_\Theta(\theta) = \begin{cases} 1/4, & \theta = 0.2 \\ 1/2, & \theta = 0.5 \\ 1/4, & \theta = 0.8 \\ 0, & \text{annars.} \end{cases}$$



Vi singlar nu det valda myntet n gånger. Antalet gånger den hamnar med på klave X har då fördelningen $\text{Bin}(n, \theta)$, vilket ger


$$f_{X|\theta}(x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}.$$

Vi har alltså en fördelning för X betingad med avseende på parametern θ .

Den marginella fördelningen är då

$$\begin{aligned} f_X(x) &= \sum_{\theta \in \{0.2, 0.5, 0.8\}} f_{X|\theta}(x|\theta) f_{\theta}(\theta) \\ &= \sum_{\theta \in \{0.2, 0.5, 0.8\}} \binom{n}{x} \theta^x (1 - \theta)^{n-x} f_{\theta}(\theta) \\ &= \binom{n}{x} \left(0.2^x 0.8^{n-x} \cdot \frac{1}{4} + 0.8^x 0.2^{n-x} \cdot \frac{1}{4} + 0.5^n \cdot \frac{1}{2} \right) \\ &= \binom{n}{x} \left(\frac{0.2^x 0.8^{n-x} + 0.8^x 0.2^{n-x}}{4} + \frac{0.5^n}{2} \right). \end{aligned}$$

Detta är alltså fördelningen som vi får om vi drar ett mynt, singlar det n gånger och räknar antalet klavar.



Aposteriorifördelning

Datafördelningen beskriver hur vår mätdata genereras utifrån parametrar dragna från apriorifördelningen – detta bildar en stokastisk modell för datan. För att lösa inferensproblemet vill vi gå åt andra hållet: från mätdata och datafördelningen vill vi bestämma en fördelning för parametern. Verktyget som låter oss göra detta är Bayes sats. Om vi låter $f_{\Theta|X}(\theta|x)$ beteckna den betingade fördelningen för Θ givet observationen $X = x$ får vi

$$f_{\Theta|X}(\theta|x) = \frac{f_{X|\Theta}(x|\theta)f_{\Theta}(\theta)}{f_X(x)}.$$

Fördelningen $f_{\Theta|X}(\theta|x)$ kallas *aposteriorifördelningen* (*a posteriori* betyder *i efterhand* på latin) och motsvarar alltså vår uppfattning av parametern θ givet att vi observerat datan x . Detta kan ses som en "uppdatering" av apriorifördelningen $f_{\Theta}(\theta)$. Innan vi observerat något överhuvudtaget antar vi att θ har fördelningen $f_{\Theta}(\theta)$. Vi korrigerar sedan denna efter att ha observerat x genom Bayes sats, vilket ger aposteriorifördelningen $f_{\Theta|X}(\theta|x)$. Denna fördelning kan nu användas för att dra olika slutsatser om parametern eller som apriorifördelning för ett annat experiment.

Exempel 2. I slantsinglingsexemplet ovan har vi

$$\begin{aligned} f_{\Theta|X}(\theta|x) &= \frac{\binom{n}{x} \theta^x (1-\theta)^{n-x} f_{\Theta}(\theta)}{\binom{n}{x} ((0.2^x 0.8^{n-x} + 0.8^x 0.2^{n-x})/4 + 0.5^n/2)} \\ &= \frac{\theta^x (1-\theta)^{n-x} f_{\Theta}(\theta)}{(0.2^x 0.8^{n-x} + 0.8^x 0.2^{n-x})/4 + 0.5^n/2}, \end{aligned}$$

för $\theta = 0.2, 0.5, 0.8$. Detta motsvarar alltså vår uppdaterade uppfattning om vilket mynt som valts ut givet att vi singlar myntet n gånger och fått x klavar.

Om $n = 20$ och $x = 14$ får vi

$$f_{\Theta|X}(\theta|14) \approx \begin{cases} 9.1 \cdot 10^{-6}, & \theta = 0.2, \\ 0.40, & \theta = 0.5, \\ 0.60, & \theta = 0.8, \\ 0, & \text{annars.} \end{cases}$$

Sannolikheten att vi drog myntet med $\theta = 0.2$ är alltså betydligt mindre än innan vi utförde experimentet. Samtidigt har inte sannolikheten att vi drog $\theta = 0.5$ ändrats mycket, medan det har blivit mycket mer sannolikt att $\theta = 0.8$.

Om vi istället hade fått $x = 16$ utav $n = 20$ singlar får vi aposteriorifördelningen


$$f_{\Theta|X}(\theta|16) \approx \begin{cases} 5.7 \cdot 10^{-8}, & \theta = 0.2, \\ 0.041, & \theta = 0.5, \\ 0.96, & \theta = 0.8, \\ 0, & \text{annars.} \end{cases}$$

Sannolikheten att vi drog $\theta = 0.8$ är nu mycket större än de andra möjligheterna.

Aposteriorifördelningen beror också på hur många singlar n vi utför. Om $n = 40$ och $x = 32$ får vi

$$f_{\Theta|X}(\theta|32) \approx \begin{cases} 3.5 \cdot 10^{-15}, & \theta = 0.2, \\ 9 \cdot 10^{-4}, & \theta = 0.5, \\ 0.999, & \theta = 0.8, \\ 0, & \text{annars.} \end{cases}$$

Notera att kvoten x/n är fortfarande densamma som ovan (0.8) men nu har vi en mycket större sannolikhet att $\theta = 0.8$. Datan har alltså en större uppdateringseffekt på aposteriorifördelningen eftersom vi har ett större stickprov ($n = 40$ istället för $n = 20$).



Parametern Θ behöver inte ha en diskret fördelning utan denna kan också vara kontinuerlig, som vi ser i följande exempel.

Exempel 3. Antag att $\Theta \sim U([0, 1])$, dvs. Θ är likformigt fördelad över intervallet $[0, 1]$. Detta motsvarar en så kallad icke-informativ apriorifördelning – den säger egentligen ingenting om parametern och vi gör alltså inga antaganden. Vi har då

$$f_{\Theta}(\theta) = \begin{cases} 1, & 0 \leq \theta \leq 1, \\ 0, & \text{annars.} \end{cases}$$

Som innan antar vi att datafördelningen för $X|\theta$ är $\text{Bin}(n, \theta)$. Marginalfördelningen för X blir då

$$f_X(x) = \int_0^1 \binom{n}{x} \theta^x (1-\theta)^{n-x} d\theta = \binom{n}{x} \int_0^1 \theta^x (1-\theta)^{n-x} d\theta.$$

Integralen kan skrivas med hjälp av betafunktionen $B(\alpha, \beta)$ som ges av

$$B(\alpha, \beta) = \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)},$$

där $\Gamma(\alpha)$ är gammafunktionen $\Gamma(\alpha) = \int_0^{\infty} e^{-u} u^{\alpha-1} du$. För heltal k, l har vi $\Gamma(k) = (k-1)!$ och $\Gamma(l) = (l-1)!$, vilket ger

$$B(k, l) = \frac{(k-1)!(l-1)!}{(k+l-1)!}.$$


Stoppar vi in detta i vår uttryck för $f_X(x)$ får vi

$$f_X(x) = \binom{n}{x} B(x+1, n-x+1) = \frac{n!}{(n-x)!x!} \cdot \frac{x!(n-x)!}{(n+1)!} = \frac{1}{n+1}.$$

Med andra ord är X likformigt fördelad över $x = 0, 1, \dots, n$.

Aposteriorifördelningen är nu

$$\begin{aligned} f_{\Theta|X}(\theta|x) &= \frac{f_{X|\Theta}(x|\theta)f_{\Theta}(\theta)}{f_X(x)} = \frac{\binom{n}{x}\theta^x(1-\theta)^{n-x}}{1/(n+1)} \\ &= \frac{(n+1)n!}{(n-x)!x!}\theta^x(1-\theta)^{n-x} \\ &= \frac{(n+1)!}{(n-x)!x!}\theta^x(1-\theta)^{n-x} \\ &= \frac{1}{B(x+1, n-x+1)}\theta^x(1-\theta)^{n-x} \end{aligned}$$



Låt oss anta att $n = 20$ och $x = 16$. Vi får då en fördelning som lutar starkt mot $\theta = 1$, vilket är rimligt givet det stora antalet klavar som erhöles.

Aposteriorifördelningen som beräknades ovan kallas för en *betafördelning*. Dessa har parametrarna α, β , betecknas $\text{Beta}(\alpha, \beta)$ och har täthetsfunktionen

$$f_{\Theta}(\theta) = \begin{cases} \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}, & 0 \leq \theta \leq 1, \\ 0, & \text{annars.} \end{cases}$$

Ovan har vi alltså att för $\Theta \sim U([0, 1])$ och $X|\Theta = \theta \sim \text{Bin}(n, \theta)$ har vi aposteriorifördelningen $\Theta|X = x \sim \text{Beta}(1+x, 1+n-x)$. Ett specialfall av betafördelningen är då $\alpha = \beta = 1$, vilket ger $U([0, 1])$.

Om $\Theta \sim \text{Beta}(\alpha, \beta)$ har vi

$$\begin{aligned} E[\Theta] &= \frac{1}{B(\alpha, \beta)} \int_0^1 \theta \cdot \theta^{\alpha-1} (1-\theta)^{\beta-1} d\theta \\ &= \frac{1}{B(\alpha, \beta)} \int_0^1 \theta^{(\alpha+1)-1} (1-\theta)^{\beta-1} d\theta \\ &= \frac{1}{B(\alpha, \beta)} \cdot B(\alpha+1, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+\beta+1)} \\ &= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)} \cdot \frac{\alpha\Gamma(\alpha)}{(\alpha+\beta)\Gamma(\alpha+\beta)} = \frac{\alpha}{\alpha+\beta}, \end{aligned}$$

där vi har utnyttjat definitionen av betafunktionen $B(\alpha, \beta)$ och att $\Gamma(x+1) = x\Gamma(x)$. På samma sätt får vi

$$E[\Theta^2] = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)},$$

vilket ger

$$V[\Theta] = E[\Theta^2] - E[\Theta]^2 = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}.$$

Parametrarna α och β bestämmer alltså hur sannolikheten är fördelad mellan noll och ett. Om $\alpha = \beta$ är den symmetrisk runt $1/2$, men om $\alpha \gg \beta$ lutar den mot ett och om $\beta \gg \alpha$ lutar den mot noll. Summan $\alpha + \beta$ kontrollerar osäkerheten: om summan är stor är fördelningen mer koncentrerad runt väntevärdet, annars är den diffus.

Det visar sig att betafördelningen inte bara uppstår som en aposteriorifördelning när vi har apriorifördelningen $U([0, 1])$ och datafördelningen $X|\Theta = \theta \sim \text{Bin}(n, \theta)$. Den är också en naturlig apriorifördelning i detta sammanhang.

Låt $\Theta \sim \text{Beta}(\alpha, \beta)$. Om $X|\Theta = \theta \sim \text{Bin}(n, \theta)$ har vi

$$\begin{aligned} f_{X|\Theta}(x|\theta)f_{\Theta}(\theta) &= \binom{n}{x} \theta^x (1-\theta)^{n-x} \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1} \\ &= \frac{\binom{n}{x}}{B(\alpha, \beta)} \theta^{\alpha+x-1} (1-\theta)^{\beta+n-x-1}. \end{aligned}$$

Om vi integrerar detta med avseende på θ över $[0, 1]$ får vi

$$\begin{aligned} f_X(x) &= \frac{\binom{n}{x}}{B(\alpha, \beta)} \int_0^1 \theta^{\alpha+x-1} (1-\theta)^{\beta+n-x-1} d\theta \\ &= \frac{\binom{n}{x}}{B(\alpha, \beta)} \cdot B(\alpha+x, \beta+n-x), \end{aligned}$$

där vi återigen utnyttjat definitionen av betafunktionen $B(\alpha, \beta)$. Aposteriorifördelningen blir då

$$\begin{aligned} f_{\Theta|X}(\theta|x) &= \frac{f_{X|\Theta}(x|\theta)f_{\Theta}(\theta)}{f_X(x)} \\ &= \frac{\theta^{\alpha+x-1}(1-\theta)^{\beta+n-x-1}}{B(\alpha+x, \beta+n-x)}. \end{aligned}$$

Med andra ord har vi $\Theta|X=x \sim \text{Beta}(\alpha+x, \beta+n-x)$. Uppdateringen av apriorifördelningen $\text{Beta}(\alpha, \beta)$ med utfallet x av $X|\Theta = \theta \sim \text{Bin}(n, \theta)$ är alltså aposteriorifördelningen $\text{Beta}(\alpha+x, \beta+n-x)$. Med andra ord räcker det att uppdatera parametrarna enligt

$$(\alpha, \beta) \mapsto (\alpha+x, \beta+n-x).$$

Dessa typer av relationer håller för många fördelningar. Man säger att betafördelningarna bildar en *konjugatfamilj* för binomialfördelningen $\text{Bin}(n, \theta)$ med avseende på parametern θ .

För normalfördelningen med känd standardavvikelse σ har vi att konjugatfamiljen är normalfördelningarna själva. Om $\Theta \sim N(\mu_0, \tau_0)$ och $X|\Theta = \theta \sim N(\theta, \sigma)$ har vi att $\Theta|X=x \sim N(\mu_1, \tau_1)$ där

$$\mu_1 = \tau_1^2 \left(\frac{\mu_0}{\tau_0^2} + \frac{x}{\sigma^2} \right) \quad \text{och} \quad \tau_1 = 1 / \sqrt{\frac{1}{\tau_0^2} + \frac{1}{\sigma^2}}.$$

Den nya datapunkten bakas alltså in i fördelningen för Θ genom att viktas med avseende på datafördelningens standardavvikelse σ och apriorifördelningens standardavvikelse. Vi skriver detta som följande uppdatering av parametrarna:

$$(\mu_0, \tau_0) \mapsto \left(\left(\frac{\mu_0}{\tau_0^2} + \frac{x}{\sigma^2} \right) / \left(\frac{1}{\tau_0^2} + \frac{1}{\sigma^2} \right), 1 / \sqrt{\frac{1}{\tau_0^2} + \frac{1}{\sigma^2}} \right).$$

För Poissonfördelningen $\text{Po}(\theta)$ som datafördelning består konjugatfamiljen av gammafördelningarna $\text{Gamma}(c, \lambda)$. Om $\Theta \sim \text{Gamma}(c, \lambda)$ och $X|\Theta = \theta \sim \text{Po}(\theta)$ har vi att utfallet x ger $\Theta|X=x \sim \text{Gamma}(c+x, \lambda+1)$. Vi skriver detta som uppdateringen

$$(c, \lambda) \mapsto (c+x, \lambda+1).$$

Till sist har vi exponentialfördelningen $\text{Exp}(\theta)$ som också har gammafördelningarna som konjugatfamilj. Om $\Theta \sim \text{Gamma}(c, \lambda)$ och $X|\Theta = \theta \sim \text{Exp}(\theta)$ har vi att utfallet x ger $\Theta|X=x \sim \text{Gamma}(c+1, \lambda+x)$. Vi skriver detta som

$$(c, \lambda) \mapsto (c+1, \lambda+x).$$

Konjugatfamiljer är naturliga på det sättet att de förenklar uppdateringsprocessen, men de behöver inte alltid vara passande apriorifördelningar för alla problem. Nu-förtiden finns det effektiva beräkningsmetoder som kan approximera aposteriorifördelningarna numeriskt i de fall då icke-konjugata apriorifördelningar används.

Aposteriorifördelning med flera värden

Uppdateringsformlerna som vi gav ovan går att generalisera till flera mätvärden. Vi börjar med binomialfördelningen. Antag att $\Theta \sim \text{Beta}(\alpha, \beta)$ och $X_1|\Theta = \theta \sim \text{Bin}(n_1, \theta)$, $X_2|\Theta = \theta \sim \text{Bin}(n_2, \theta)$ för X_1 och X_2 oberoende givet Θ . Om x_1 och x_2 är utfall av X_1 respektive X_2 så har vi först uppdateringen med avseende på $X_1 = x_1$:

$$(\alpha, \beta) \mapsto (\alpha + x_1, \beta + n_1 - x_1).$$

Med andra ord har vi aposteriorifördelningen $\Theta|X_1 = x_1 \sim \text{Beta}(\alpha + x_1, \beta + n_1 - x_1)$. Vi tar nu detta som vår apriorifördelning och uppdaterar den med utfallet $X_2 = x_2$, vilket ger

$$(\alpha + x_1, \beta + n_1 - x_1) \mapsto (\alpha + x_1 + x_2, \beta + n_1 + n_2 - x_1 - x_2).$$

Vi har då att $\Theta|X_1 = x_1, X_2 = x_2$ har fördelningen $\text{Beta}(\alpha + x_1 + x_2, \beta + n_1 + n_2 - x_1 - x_2)$.

Notera att vi kan också erhålla detta resultat genom att bilda $Y = X_1 + X_2$. Sedan innan vet vi då att $Y|\Theta = \theta \sim \text{Bin}(n_1 + n_2, \theta)$ eftersom sannolikheten att ett försök lyckas (θ) är densamma för både X_1 och X_2 . Om vi tillämpar den uppdateringsregeln för ett utfall med utfallet $Y = x_1 + x_2$ får vi

$$(\alpha, \beta) \mapsto (\alpha + x_1 + x_2, \beta + n_1 + n_2 - x_1 - x_2),$$

dvs. samma aposteriorifördelning som innan. Det spelar alltså ingen roll om vi gör två separata uppdateringar eller om vi uppdaterar med avseende på båda mätvärdena samtidigt.

Vi kan skriva detta som ett förhållande mellan aposteriorifördelningarna $f_{\Theta|X_1, X_2}(\theta|x_1, x_2)$ (fördelningen för Θ givet både $X_1 = x_1$ och $X_2 = x_2$) och $f_{\Theta|X_1}(\theta|x_1)$ (fördelningen för Θ givet bara $X_1 = x_1$). För $\Theta \sim \text{Beta}(\alpha, \beta)$ och oberoende $X_1|\Theta = \theta \sim \text{Bin}(n_1, \theta)$, $X_2|\Theta = \theta \sim \text{Bin}(n_2, \theta)$ har vi då visat

$$f_{\Theta|X_1, X_2}(\theta|x_1, x_2) = \frac{f_{X_2|\Theta}(x_2|\theta)f_{\Theta|X_1}(\theta|x_1)}{\int_{\Omega_\theta} f_{X_2|\Theta}(x_2|\theta)f_{\Theta|X_1}(\theta|x_1)d\theta}.$$

Det visar sig att formeln ovan gäller mer allmänt så länge X_1 och X_2 är oberoende givet Θ .

Sats 4. Antag att X_1 och X_2 är oberoende givet Θ . Då gäller att

$$f_{\Theta|X_1, X_2}(\theta|x_1, x_2) = \frac{f_{X_2|\Theta}(x_2|\theta)f_{\Theta|X_1}(\theta|x_1)}{\int_{\Omega_\theta} f_{X_2|\Theta}(x_2|\theta)f_{\Theta|X_1}(\theta|x_1)d\theta}.$$

Bevis. Vi skriver först om $f_{X_1, X_2|\Theta}(x_1, x_2|\theta)$ som $f_{X_2|X_1, \Theta}(x_2|x_1, \theta)f_{X_1|\Theta}(x_1|\theta)$, vilket fås ur definitionen för betingad sannolikhet. Eftersom X_1 och X_2 är oberoende givet θ har vi vidare att $f_{X_2|X_1, \Theta}(x_2|x_1, \theta) = f_{X_2|\Theta}(x_2|\theta)$. Vi stoppar nu in detta i Bayes sats,

vilket ger

$$\begin{aligned}
 & f_{\Theta|X_1, X_2}(\theta|x_1, x_2) \\
 &= \frac{f_{X_1, X_2|\Theta}(x_1, x_2|\theta)f_{\Theta}(\theta)}{\int_{\Omega_{\theta}} f_{X_1, X_2|\Theta}(x_1, x_2|\theta)f_{\Theta}(\theta)d\theta} \\
 &= \frac{f_{X_2|\Theta}(x_2|\theta)f_{X_1|\Theta}(x_1|\theta)f_{\Theta}(\theta)}{\int_{\Omega_{\theta}} f_{X_2|\Theta}(x_2|\theta)f_{X_1|\Theta}(x_1|\theta)f_{\Theta}(\theta)d\theta} \\
 &= f_{X_2|\Theta}(x_2|\theta) \cdot \frac{f_{X_1|\Theta}(x_1|\theta)f_{\Theta}(\theta)}{\int_{\Omega_{\theta}} f_{X_1|\Theta}(x_1|\theta)f_{\Theta}(\theta)d\theta} \cdot \frac{\int_{\Omega_{\theta}} f_{X_1|\Theta}(x_1|\theta)f_{\Theta}(\theta)d\theta}{\int_{\Omega_{\theta}} f_{X_2|\Theta}(x_2|\theta)f_{X_1|\Theta}(x_1|\theta)f_{\Theta}(\theta)d\theta}
 \end{aligned}$$

Eftersom

$$f_{\Theta|X_1}(\theta|x_1) = \frac{f_{X_1|\Theta}(x_1|\theta)f_{\Theta}(\theta)}{\int_{\Omega_{\theta}} f_{X_1|\Theta}(x_1|\theta)f_{\Theta}(\theta)d\theta}$$

har vi då

$$f_{\Theta|X_1, X_2}(\theta|x_1, x_2) = f_{X_2|\Theta}(x_2|\theta) \cdot f_{\Theta|X_1}(\theta|x_1) \cdot \frac{1}{\int_{\Omega_{\theta}} f_{X_2|\Theta}(x_2|\theta)f_{\Theta|X_1}(\theta|x_1)d\theta},$$

vilket skulle visas. □

Vi kan tillämpa satsen ovan flera gånger för att få aposteriorifördelningen för $\Theta \sim \text{Beta}(\alpha, \beta)$ givet flera utfall $x_1, x_2, \dots, x_k$ från de oberoende stokastiska variablerna $X_1|\Theta = \theta \sim \text{Bin}(n_1, \theta), X_2|\Theta = \theta \sim \text{Bin}(n_2, \theta), \dots, X_k|\Theta = \theta \sim \text{Bin}(n_k, \theta)$. Detta ger

$$(\alpha, \beta) \mapsto \text{Beta}\left(\alpha + \sum_{i=1}^k x_i, \beta + \sum_{i=1}^k n_i - x_i\right).$$

Vi kan också tillämpa satsen på de andra uppdateringsreglerna vi undersökte tidigare. För $\Theta \sim N(\mu_0, \tau_0)$ och oberoende $X_1|\Theta = \theta \sim N(\theta, \sigma), X_2|\Theta = \theta \sim N(\theta, \sigma), \dots, X_k|\Theta = \theta \sim N(\theta, \sigma)$ med utfallen $x_1, x_2, \dots, x_k$ har vi

$$(\mu_0, \tau_0) \mapsto \left(\left(\frac{\mu_0}{\tau_0^2} + \frac{\sum_{i=1}^k x_i}{\sigma^2} \right) / \left(\frac{1}{\tau_0^2} + \frac{k}{\sigma^2} \right), \frac{1}{\sqrt{\frac{1}{\tau_0^2} + \frac{k}{\sigma^2}}} \right).$$

För $\Theta \sim \text{Gamma}(c, \lambda)$ och oberoende $X_1|\Theta = \theta \sim \text{Po}(\theta), X_2|\Theta = \theta \sim \text{Po}(\theta), \dots, X_k|\Theta = \theta \sim \text{Po}(\theta)$ med utfallen $x_1, x_2, \dots, x_k$ har vi

$$(c, \lambda) \mapsto \left(c + \sum_{i=1}^k x_i, \lambda + k \right).$$

Slutligen för $\Theta \sim \text{Gamma}(c, \lambda)$ och oberoende $X_1|\Theta = \theta \sim \text{Exp}(\theta), X_2|\Theta = \theta \sim \text{Exp}(\theta), \dots, X_k|\Theta = \theta \sim \text{Exp}(\theta)$ med utfall $x_1, x_2, \dots, x_k$ har vi

$$(c, \lambda) \mapsto \left(c + k, \lambda + \sum_{i=1}^k x_i \right).$$

Punktskattningar

Aposteriorifördelningen är intressant i sig i och med att den specificerar vad vi tror att en parameter antar för ett värde. Man kan, till exempel, betrakta de olika kvantilerna för att bilda ett intervall där parametern ligger med stor sannolikhet.

Ofta kan det dock vara intressant att sammanfatta aposteriorifördelningen på något sätt och bilda en punktskattning. Ett vanligt sätt att åstadkomma detta är genom att bilda det betingade väntevärdet $E[\Theta|X = x]$. Detta motsvarar alltså det värde som parametern antar i genomsnitt under den skattade aposteriorifördelningen.

För fallet med $\Theta \sim \text{Beta}(\alpha, \beta)$ och $X|\Theta = \theta \sim \text{Bin}(n, \theta)$ hade vi att utfallet x gav uppdateringen

$$(\alpha, \beta) \mapsto (\alpha + x, \beta + n - x).$$

Om vi jämför väntevärdet för apriorifördelningen med väntevärdet för aposteriorifördelningen får vi

$$E[\Theta] = \frac{\alpha}{\alpha + \beta} \quad \text{och} \quad E[\Theta|X = x] = \frac{\alpha + x}{\alpha + \beta + n}.$$

Det senare värdet kan skrivas om som

$$E[\Theta|X = x] = \frac{n}{\alpha + \beta + n} \cdot \frac{x}{n} + \frac{\alpha + \beta}{\alpha + \beta + n} \cdot \frac{\alpha}{\alpha + \beta}.$$

Det betingade väntevärdet är alltså en slags kompromiss mellan aprioriväntevärdet och ML-skattningen x/n . När n är litet dominerar aprioriväntevärdet (vi har då inte tillräckligt många datapunkter n för att dominera apriorifördelningen), men när n är stort närmar vi oss x/n . Vi såg samma sak för normalfördelningen ovan – ju starkare vår datapunkt (större x , mindre σ), desto mer dominerar datan över apriorifördelningen.


Exempel 5. Låt oss ta $\Theta \sim \text{Beta}(2, 2)$. Denna fördelning är koncentrerad runt $E[\Theta] = 1/2$ men avtar när vi närmar oss noll eller ett. Om $X|\Theta = \theta \sim \text{Bin}(n, \theta)$ och $n = 20$ med utfallet $x = 18$ har vi

$$\Theta|X = x \sim \text{Beta}(2 + 18, 2 + 2) = \text{Beta}(20, 4).$$

Det betingade väntevärdet är då

$$E[\Theta|X = x] = \frac{20}{20 + 4} = \frac{5}{6} \approx 0.83,$$

vilket fortfarande ligger nära $1/2$ men närmar sig ett.



Vi kan också jämföra standardavvikelserna hos fördelningarna. Enligt formeln för variansen av betafördelningen ovan får vi

$$V[\Theta] = \frac{1}{20} \quad \text{och} \quad V[\Theta|X = x] = \frac{1}{180}.$$

Vi har alltså $D[\Theta] = 1/2\sqrt{5}$ och $D[\Theta|X = x] = 1/6\sqrt{5}$. Standardavvikelsen har reducerats med en faktor tre.

Fenomenet ovan är typiskt för aposteriorifördelningar – när vi uppdaterar apriorifördelningen så minskar standardavvikelsen i genomsnitt. Vi kan visa detta genom att använda formeln för den betingade variansen som vi tog fram tidigare i kursen:

$$V[\Theta] = E[V[\Theta|X]] + V[E[\Theta|X]].$$

Eftersom $V[E[\Theta|X]] \geq 0$ per definition får vi

$$E[V[\Theta|X]] \leq V[\Theta].$$

Med andra ord så är den genomsnittliga betingade variansen (där vi har medelvärdesbildat över alla möjliga mätdata X) mindre än apriorivariansen. Hur stor den här reduktionen är beror på variansen hos det betingade väntevärdet $E[\Theta|X]$. Om denna är stor, dvs. aposteriorifördelningen anpassar sig väl efter datan, så kommer vi ha en mindre betingad varians $V[\Theta|X]$, i genomsnitt.

En annan sammanfattning av aposteriorifördelningen fås om vi betraktar dess maximum, dvs. det θ som maximerar $f_{\Theta|X}(\theta|x)$. Denna punkt kallas *maximum a posteriori-skattning* (MAP-skattning). För betafördelningen $\text{Beta}(\alpha, \beta)$ har vi, till exempel att

$$\theta = \frac{\alpha - 1}{\alpha + \beta - 2}$$

maximerar $f_{\Theta}(\theta)$. Med uppdateringen från binomialfördelningen får vi då

$$\theta = \frac{\alpha + x - 1}{\alpha + \beta + n - 2}.$$

Återigen konvergerar denna mot x/n då $n \rightarrow +\infty$.

Föreläsning fjorton


Joakim Andén

Kredibilitetsintervall

Förutom punktskattningar finns det andra sätt att sammanfatta aposteriorifördelningen. Till exempel kan man använda *kredibilitetsintervall* (eller *aposterioriintervall*) för utfallen $x_1, x_2, \dots, x_k$ som är det intervall I_θ så att

$$P(\theta \in I_\theta | x_1, x_2, \dots, x_k) = 1 - \alpha,$$

dvs. sannolikheten att θ ligger i intervallet givet datapunkterna $x_1, x_2, \dots, x_k$ är $1 - \alpha$, vilket kallas *kredibilitetsgraden*. Ofta beräknas intervallet med hjälp av kvantilerna hos aposteriorifördelningen $f_{\theta|x_1, x_2, \dots, x_k}(\theta | x_1, x_2, \dots, x_k)$.



Exempel 1. Låt $\theta \sim N(0, 2)$ och $X|\theta \sim N(\theta, 4)$. Om vi har $k = 5$ utfall så att $\bar{x} = 2$, vad är då ett 95% kredibilitetsintervall?

Först har vi uppdateringen av parametrarna $(0, 2)$, vilket ger

$$(0, 2) \mapsto \left(\left(\frac{0}{2^2} + \frac{5 \cdot 2}{4^2} \right) / \left(\frac{1}{4} + \frac{5}{16} \right), \frac{1}{\sqrt{\frac{1}{4} + \frac{5}{16}}} \right) = \left(\frac{10}{16} / \frac{9}{16}, \sqrt{\frac{16}{9}} \right) = \left(\frac{10}{9}, \frac{4}{3} \right).$$

Med $\alpha = 0.05$ får vi då, eftersom $\lambda_{\alpha/2} = \lambda_{0.025} \approx 1.96$, kredibilitetsintervallet


$$I_\theta = \frac{10}{9} \pm \lambda_{0.025} \frac{4}{3} \approx 1.11 \pm 1.96 \cdot 1.33 \approx 1.11 \pm 2.61 \approx [-1.50, 3.72].$$

Det går att beräkna kredibilitetsintervall för andra aposteriorifördelningar, men detta kräver oftast numeriska beräkningar eftersom kvantilerna inte kan sammanfattas i tabell lika enkelt som för normalfördelningen.

Förlust och risk

Vi har studerat olika sätt att konstruera punktskattningar av en parameter: enkla stickprovsmedelvärden och stickprovsvarianser, ML-skattningar, MK-skattningar, betingade medelvärden och maximum aposteriori-skattningar. I vissa fall har vi kunnat härleda vissa egenskaper: väntevärdesriktighet, konsistens och effektivitet. Problemet är att dessa egenskaper inte nödvändigtvis säger något om vad vår skattning har för effekt när vi tillämpar den i olika sammanhang. Vi kanske vill använda skattningen för att dimensionera en konstruktion eller verkställa en köp- eller säljorder. Konsekvenserna av en felskattning kan vara stora i dessa fall och vi vill därför försöka minimera riskerna associerade med skattningen.

För att formalisera detta definierar vi en *förlustfunktion* $L(\theta, a)$ som motsvarar den förväntade förlusten givet att det sanna parametervärdet är θ , men vi skattar den som a . Om vi skattar korrekt, dvs. har $a = \theta$, får vi $L(\theta, a) = L(\theta, \theta) = 0$. Utöver detta kräver vi att $L(\theta, a) \geq 0$.



Några exempel på vanliga förlustfunktioner är

- Absolutfelet $L(\theta, a) = |\theta - a|$ – felet är i proportion till skillnaden mellan a och θ .
- Kvadratfelet $L(\theta, a) = |\theta - a|^2$ – felet är kvadratisk i skillnaden, dvs. större fel viktas större, relativt sett, än mindre fel.
- 0-1-felet

$$L(\theta, a) = \begin{cases} 0, & a = \theta \\ 1, & a \neq \theta. \end{cases}$$

(gäller bara om parametern θ är diskret) – alla fel är lika viktiga.

Man kan också definiera en förlustfunktion genom att modifiera någon av de ovanstående standardförlusterna:

$$L(\theta, a) = \begin{cases} 2|a - \theta|, & a > \theta \\ |a - \theta|, & a \leq \theta. \end{cases}$$

I detta fall viktar vi felen i proportion till skillnaden, men överskattningar vikts dubbelt så mycket som underskattningar. Oftast använder vi kvadratfelet $L(\theta, a) = |\theta - a|^2$ eftersom detta förenklar många beräkningar.

Antag att vi har en förlustfunktion $L(\theta, a)$ och en punktskattning $\theta_{\text{obs}}^* = g(x)$ givet utfallet x av stickprovsvariabeln X vars fördelning beror på θ . Vi definierar då punktskattningens *riskfunktion*

$$R(\theta, \theta^*) = \int_{X(\Omega)} L(\theta, g(x))f(x|\theta)dx,$$

där vi har antagit att X är kontinuerlig med täthetsfunktion $f(x|\theta)$. Notera att θ inte nödvändigtvis behöver vara en stokastisk variabel här, utan kan också bara vara en konstant, i vilket fall vi har $f(x|\theta) = f(x; \theta)$ enligt den tidigare beteckningen. Om X är diskret har vi, likt innan,

$$R(\theta, \theta^*) = \sum_{x \in X(\Omega)} L(\theta, g(x))p(x|\theta),$$

där $p(x|\theta)$ är X 's sannolikhetsfunktion. Vi kan sammanfatta båda fallen som

$$R(\theta, \theta^*) = E[L(\theta, g(X))|\theta].$$

Båda dessa definitioner kan generaliseras till fallet med flera utfall $x_1, x_2, \dots, x_n$ av oberoende stickprovsvariabler $X_1, X_2, \dots, X_n$, vilket ger

$$R(\theta, \theta^*) = E[L(\theta, g(X_1, X_2, \dots, X_n))|\theta].$$

För enkelhets skull kommer vi att presentera fallet med ett utfall x , men alla resultat kan generaliseras till flera utfall.

Med kvadratfelet $L(\theta, a) = |\theta - a|^2$ har vi att riskfunktionen $R(\theta, \theta^*)$ är lika med medelkvadratfelet MSE för θ^* . Vi kan då utnyttja uppdelningen i varians och systematiskt fel:

$$R(\theta, \theta^*) = V[\theta^*] + |E[\theta^*] - \theta|^2.$$

Exempel 2. Antag att $X \sim \text{Bin}(n, \theta)$. Vi har då ML-skattningen av θ

$$\theta^* = \frac{X}{n}.$$

Om vi antar att $\theta \sim \text{Beta}(\alpha, \beta)$ kan vi se fördelningen av X som betingad på θ , bilda aposteriorifördelningen $f_{\theta|X}(\theta|x)$ och beräkna dess väntevärde

$$\hat{\theta} = E[\theta|X] = \frac{\alpha + X}{\alpha + \beta + n}.$$

Hur ser riskfunktionerna ut för dessa punktskattningar under kvadratfelets förlustfunktion $L(\theta, a) = |\theta - a|^2$?

Vi använder uppdelningen i varians och systematiskt fel. Eftersom $E[X] = n\theta$ och $V[X] = n\theta(1 - \theta)$ har vi

$$E[\theta^*|\theta] = \theta \quad \text{och} \quad V[\theta^*|\theta] = \frac{\theta(1 - \theta)}{n},$$

vilket ger

$$R(\theta, \theta^*) = \frac{\theta(1 - \theta)}{n}.$$

Risken är alltså stor då $\theta = 1/2$ och avtar när θ närmar sig noll eller ett.

För $\hat{\theta}$ har vi

$$E[\hat{\theta}|\theta] = \frac{\alpha + n\theta}{\alpha + \beta + n}$$

och

$$V[\hat{\theta}|\theta] = \frac{n\theta(1 - \theta)}{(\alpha + \beta + n)^2}.$$

Detta ger riskfunktionen


$$R(\theta, \hat{\theta}) = \frac{n\theta(1 - \theta)}{(\alpha + \beta + n)^2} + \left(\frac{\alpha + n\theta}{\alpha + \beta + n} - \theta \right)^2 = \frac{n\theta(1 - \theta) + (\alpha(1 - \theta) - \beta\theta)^2}{(\alpha + \beta + n)^2}.$$

Risikfunktionens utseende beror alltså på valet av aprioriparametrar α, β , vilket ger oss en del flexibilitet. Till exempel kan det vara önskvärt att riskfunktionen är densamma oavsett θ eftersom vi inte vet vad för värde som θ kommer att anta. Man kan visa att riskfunktionen är konstant om $\alpha = \beta = \sqrt{n/4}$. Detta ger

$$\hat{\theta} = \frac{X + \sqrt{n/4}}{n + \sqrt{n}}$$

och

$$R(\theta, \hat{\theta}) = \frac{n}{4(n + \sqrt{n})^2} = \frac{1}{4(\sqrt{n} + 1)^2}.$$



Det betingade väntevärdet med apriorifördelningen $\text{Beta}(\sqrt{n/4}, \sqrt{n/4})$ ger då mindre risk för de flesta θ när n är stort, undantaget områdena precis vid noll och ett.

Bayesskattning

Risikfunktionen ger en bra uppfattning om hur stor vår förlust blir för en viss punktskattning givet ett visst värde på parametern θ . Problemet är att vi inte känner till θ i förväg, vilket gör det svårt att jämföra olika skattningar utifrån deras riskfunktioner. Vi behöver alltså ett sätt att sammanfatta risken.

Ett alternativ är att beräkna $\max_{\theta \in \Omega_\theta} R(\theta, \theta^*)$, den så kallade *maxrisken*. Detta motsvarar alltså det värsta tänkbara händelseförloppet. Vi kan då söka en skattning som minimerar denna maxrisk, vilket då kallas för en *minimaxskattning*.

Om vi har en apriorifördelning $f_\theta(\theta)$ för θ kan vi använda denna för att beräkna väntevärdet för risken över denna fördelning, dvs.

$$r(f_\theta, \theta^*) = \int_{\Omega_\theta} R(\theta, \theta^*) f_\theta(\theta) d\theta = E[R(\theta, \theta^*)].$$

Detta kallas för *Bayesrisken* av θ^* givet apriorifördelningen $f_\theta(\theta)$. Som innan så ersätter vi integralen med en summa när θ är en diskret parameter (och $f_\theta(\theta)$ då är en sannolikhetsfunktion). Den punktskattning som minimerar Bayesrisken kallas för en *Bayesskattning* (givet apriorifördelningen $f_\theta(\theta)$).

Det kan verka komplicerat att minimera $r(f_\theta, \theta^*)$ för att hitta Bayesskattningen, men det visar sig att vi kan vända på integrationsordningen, vilket förenklar minimeringen avsevärt. Vi utvecklar uttrycket för Bayesrisken genom att sätta in definitionen hos riskfunktionen och får då

$$\begin{aligned} r(f_\theta, \theta^*) &= \int_{\Omega_\theta} R(\theta, \theta^*) f_\theta(\theta) d\theta \\ &= \int_{\Omega_\theta} \int_{X(\Omega)} L(\theta, g(x)) f(x|\theta) dx f_\theta(\theta) d\theta \\ &= \int_{X(\Omega)} \int_{\Omega_\theta} L(\theta, g(x)) f(x|\theta) f_\theta(\theta) d\theta dx. \end{aligned}$$

Enligt Bayes sats har vi att $f(x|\theta) f_\theta(\theta) = f_{\theta|X}(\theta|x) f_X(x)$, vilket då ger

$$\begin{aligned} r(f_\theta, \theta^*) &= \int_{X(\Omega)} \int_{\Omega_\theta} L(\theta, g(x)) f_{\theta|X}(\theta|x) f_X(x) d\theta dx \\ &= \int_{X(\Omega)} \int_{\Omega_\theta} L(\theta, g(x)) f_{\theta|X}(\theta|x) d\theta f_X(x) dx \\ &= \int_{X(\Omega)} r(\theta^*|x) f_X(x) dx, \end{aligned}$$

där vi har infört beteckningen

$$r(\theta^*|x) = \int_{\Omega_\theta} L(\theta, g(x)) f_{\theta|X}(\theta|x) d\theta = E[L(\theta, g(x))|x]$$

för den så kallade *aposteriorrisken* för $\theta^* = g(X)$ givet utfallet x med apriorifördelningen $f_\Theta(\theta)$.

För att minimera Bayesrisken $r(f_\Theta, \theta^*)$ räcker det alltså att minimera aposteriorrisken $r(\theta^*|x)$ för varje x . Detta kan göras separat för varje x . Alternativt, om vi bara är intresserade av ett specifikt utfall x räcker det då att hitta det a som minimerar

$$E[L(\theta, a)|x].$$

Detta a är då Bayesskattningen av θ givet x för apriorifördelningen $f_\Theta(\theta)$.

Låt oss anta att $L(\theta, a) = |\theta - a|^2$. Eftersom $L(\theta, a) = (\theta - a)^2 = \theta^2 - 2\theta a + a^2$ har vi

$$E[L(\theta, a)|x] = \int_{\Sigma_\theta} \theta^2 f_{\Theta|X}(\theta|x) d\theta - 2a \int_{\Sigma_\theta} \theta f_{\Theta|X}(\theta|x) d\theta + a^2.$$

Den första termen beror inte på a , så vi kan ignorera den. Den andra termen är lika med $2aE[\theta|x]$, så vi vill alltså minimera

$$a^2 - 2aE[\theta|x]$$

med avseende på a , vilket fås när $a = E[\theta|x]$. Bayesskattningen för kvadratfelet är alltså lika med det betingade väntevärdet.

Vi antar nu att $L(\theta, a) = |\theta - a|$. Detta kan skrivas om som

$$L(\theta, a) = \begin{cases} -(\theta - a), & \theta \leq a \\ \theta - a, & \theta > a. \end{cases}$$

Vi antar att θ är kontinuerlig och att väntevärdet då kan skrivas som en integral över $\mathbb{R}$, vilket ger

$$\begin{aligned} E[L(\theta, a)|x] &= \int_{\mathbb{R}} L(\theta, a) f_{\Theta|X}(\theta|x) d\theta \\ &= - \int_{-\infty}^a (\theta - a) f_{\Theta|X}(\theta|x) d\theta + \int_a^{+\infty} (\theta - a) f_{\Theta|X}(\theta|x) d\theta \\ &= a \int_{-\infty}^a f_{\Theta|X}(\theta|x) d\theta - a \int_a^{+\infty} f_{\Theta|X}(\theta|x) d\theta - \int_{-\infty}^a \theta f_{\Theta|X}(\theta|x) d\theta + \int_a^{+\infty} \theta f_{\Theta|X}(\theta|x) d\theta. \end{aligned}$$

Vi vill nu derivera detta med avseende på a och använder då integralkalkylens fundamentalsats som lyder

$$\frac{d}{da} \int_{-\infty}^a g(x) dx = g(a) \quad \frac{d}{da} \int_a^{+\infty} g(x) dx = -g(a).$$

Detta ger då

$$\begin{aligned}\frac{d}{da}E[L(\theta, a)|x] &= \int_{-\infty}^a f_{\theta|x}(\theta|x)d\theta + af_{\theta|x}(a|x) - \int_a^{+\infty} f_{\theta|x}(\theta|x)d\theta + af_{\theta|x}(a|x) - af_{\theta|x}(a|x) - af_{\theta|x}(a|x) \\ &= \int_{-\infty}^a f_{\theta|x}(\theta|x)d\theta + \left(1 - \int_{-\infty}^a f_{\theta|x}(\theta|x)d\theta\right) \\ &= 2 \int_{-\infty}^a f_{\theta|x}(\theta|x)d\theta - 1.\end{aligned}$$

Med andra ord söker vi a så att

$$\int_{-\infty}^a f_{\theta|x}(\theta|x)d\theta = \frac{1}{2},$$

dvs. medianen av aposteriorifördelningen $f_{\theta|x}(\theta|x)$. Eftersom derivatan är växande i a så utgör medianen ett globalt minimum för aposterioririsken Bayesskattningen för absolutfelet är alltså medianen hos aposteriorifördelningen

Vi avslutar med 0–1-felet

$$L(\theta, a) = \begin{cases} 0, & a = \theta \\ 1, & a \neq \theta, \end{cases}$$

och antar då att θ är diskret. I detta fall har vi aposterioririsken

$$E[L(\theta, a)|x] = \sum_{\theta \in \Omega_\theta} L(\theta, a)f_{\theta|x}(\theta|x).$$

Eftersom $L(\theta, a) = 1$ för alla $a \neq \theta$ får vi då

$$E[L(\theta, a)|x] = 1 - f_{\theta|x}(a|x).$$

Aposterioririsken minimeras alltså för det a som maximerar $f_{\theta|x}(a|x)$, dvs. maximum aposteriori-skattningen. Bayesskattningen för 0–1-felet är alltså maximum aposteriori-skattningen.

Hypotesttest

Med detta ramverk kan vi också betrakta Bayesianska hypotesttest. Eftersom vi betraktar θ som ett utfall av den stokastiska variabeln Θ kan vi inte använda enkla hypoteser av typen $H_0 : \theta = \theta_0$ (som i det frekventistiska fallet) då dessa alltid har sannolikhet noll. Men om vi har $H_0 : \theta \leq \theta_0$ och $H_1 : \theta > \theta_0$ kan vi betrakta aposteriorisannolikheterna för dessa två hypoteser. Vi får då

$$P(H_0 | X = x) = P(\Theta \leq \theta_0 | X = x) \quad \text{och} \quad P(H_1 | X = x) = P(\Theta > \theta_0 | X = x)$$

och kan använda detta för att jämföra sannolikheterna för H_0 och H_1 och välja den största. Alternativt väljer vi att förkasta H_0 om dess sannolikhet är tillräckligt liten (som med ett p-värde), säg mindre än något värde α .

Detta förfarande är dock inte alltid optimalt. Låt oss använda teknikerna ovan från beslutsteori för att undersöka detta. Istället för en punktskattning låter vi handlingen a nu motsvara två val: att acceptera H_0 och att förkasta H_0 . Vi kallar dessa för a_1 respektive a_2 .

Vi kan nu definiera förlusten för dessa två handlingar beroende på det underliggande värdet θ . Om vi gör rätt val (dvs. väljer a_1 när $\theta \leq \theta_0$ eller väljer a_2 när $\theta > \theta_0$) så vill vi att förlusten ska vara noll, men annars har vi en viss kostnad. Vi får då en förlustfunktion på formen

$$L(\theta, a_1) = \begin{cases} 0, & \theta \leq \theta_0, \\ c_{II}, & \theta > \theta_0 \end{cases} \quad \text{och} \quad L(\theta, a_2) = \begin{cases} c_I, & \theta \leq \theta_0, \\ 0, & \theta > \theta_0 \end{cases}.$$

Med andra ord har vi kostnaden c_I för fel av första slaget (felaktigt förkastar H_0) och c_{II} för fel av andra slaget (felaktigt accepterar H_0).

Vi kan nu beräkna aposterioririsken för a_1 och a_2 givet någon observation $X = x$. För a_1 har vi

$$\begin{aligned} \int_{\Omega_\theta} L(\theta, a_1) f_{\theta|X}(\theta | x) d\theta &= c_{II} \int_{\theta > \theta_0} f_{\theta|X}(\theta | x) d\theta \\ &= c_{II} P(H_1 | X = x) = c_{II} (1 - P(H_0 | X = x)). \end{aligned}$$

Medan a_2 ger, på samma sätt,

$$\begin{aligned} \int_{\Omega_\theta} L(\theta, a_2) f_{\theta|X}(\theta | x) d\theta &= c_I \int_{\theta \leq \theta_0} f_{\theta|X}(\theta | x) d\theta \\ &= c_I P(H_0 | X = x). \end{aligned}$$

Vi väljer alltså a_2 , dvs. förkastar H_0 , om dess aposterioririsk $c_I P(H_0 | X = x)$ är mindre än aposterioririsken för a_1 , dvs. $c_{II} (1 - P(H_0 | X = x))$. Detta sker då

$$P(H_0 | X = x) < \frac{c_{II}}{c_I + c_{II}}.$$

Vi har alltså en slags "Bayessskattning" för vårt hypotesttest. Eftersom det inte handlar om en vanlig skattning (som punktskattning eller intervallskattning) brukar man kalla detta för en *bayesiansk beslutsregel*.

Gränsen för hur liten $P(H_0 | X = x)$ måste vara för att vi ska förkasta nollhypotesen beror alltså på kostnaderna c_I och c_{II} . Om c_I är liten och c_{II} är stor lägger vi mer vikt vid fel av andra slaget, vilket gör att $c_{II}/(c_I + c_{II})$ blir stor (nära ett), dvs. vi har lättare att förkasta H_0 . Å andra sidan, om vi har ett stort värde på c_I och ett litet värde på c_{II} blir kvoten liten (nära noll) och vi får svårare att förkasta H_0 . Notera att med detta system så behöver vi inte välja någon felrisk α – övergången mellan att acceptera och förkasta H_0 bestäms av kostnaderna c_I och c_{II} som i sin tur bestäms av tillämpningen.