

Projektuppgift

SF1930 Statistisk inläring och dataanalys

HT 2026

1. Projektet i korthet

Projektet består av en rapport i två delar och ett kort PM. I del A studerar ni enkätsvar från ett land i European Social Survey (ESS) där ni jämför andelen som ger ett visst svar mellan två grupper av landets respondenter. Detta görs först i det frekventistiska ramverket och sedan i det bayesianska för både isolerade grupper och med hjälp av hierarkiska modeller.

I del B tillämpar ni samma verktyg på en annan fråga för att undersöka eventuella kausala kopplingar. Där utnyttjar ni att en oväntad händelse inträffade medan ESS pågick i ett land, och ni jämför därför respondenter som intervjuades före händelsen med dem som intervjuades efter.

Avslutningsvis skriver ni ett PM (en promemoria, se avsnitt 4) där ni redogör för era resultat för en läsare utan statistisk bakgrund.

Projektet omfattar 2 hp, vilket motsvarar ungefär 50–60 timmars arbete och bedöms med godkänd eller underkänd. Projektet kan göras enskilt eller i par, men *vi rekommenderar att ni arbetar i par*, eftersom arbetsmängden är beräknad för två personer. Den som arbetar ensam gör samma projekt och bör räkna med samma 50–60 timmar. Den som vill arbeta i par men saknar partner kan mejla Joakim Andén (janden@kth.se), så hjälper vi till att hitta en.

Projektet har två deadlines. Förregistreringen (se A1) ska lämnas in senast *fredag 25 september*. Rapporten ska lämnas in senast *fredag 23 oktober*. Ni har alltså fem veckor på er att avklara projektet. Se till att utnyttja datorlaborationerna och räknestugan när ni fastnar. Information om inlämning och komplettering finns på uppgiftssidan i Canvas.

Material som tillhandahålls.

- *Händelsebeskrivningarna* (PDF): åtta kombinationer av land och händelse att välja mellan i del B.
- *Dataguiden* (PDF): registrering hos ESS, nedladdning, inläsning i Pandas, koder för saknade värden samt variabler för intervjudatum.
- *Exempelnotebook* (Jupyter): datarensningen i A1, veckoindelningen i B1 och en intervallplott, dvs. flera skattningar med intervall längs en gemensam axel.
- *Kodskelett för simulering* (notebooken från föreläsning 14): förkastelsemetoden och Metropolisalgoritmen med konvergenskontroller.

När ska ni börja med vad? Tabellen visar vilken föreläsning varje avsnitt kräver. Del B återanvänder verktygen från del A men inte dess resultat, så vänta inte med del B tills del A är klar. A1 och B1 kräver inga föreläsningar och bör påbörjas redan nu.

<i>Del A</i>	<i>Kräver</i>	<i>Del B</i>	<i>Kräver</i>
A1 Förhandskontroll och förregistrering	–	B1 Förberedelser och data	–
A2 Frekventistisk utgångspunkt	F9	B2 Skattning i referensfönstret	F11
A3 Konjugerade aposteriorifördelningar	F11	B3 Balans, triage och uppdelning	F13
A4 En annan apriorifördelning	F14	B4 Fönsterserien	F18
A5–A7 Den hierarkiska modellen och selektion	F15	B5 Slutsats	B4
A8 Intervall	F18	PM	A8, B5

Rapporten får omfatta högst 16 sidor (förslag på siduppdelning finns i avsnitt 5 nedan).

2. Del A. Ett land, två grupper

I del A väljer ni ett land i ESS omgång 11, som genomfördes 2023–2024. Ni får välja vilket land som helst *utom Sverige*. Ladda ned hela omgången för ert land (se dataguiden). Sedan väljer ni en svarsvariabel och ett sätt att dela in landets respondenter i grupper (se listorna nedan).

För att förenkla analysen behandlas värdena hos er svarsvariabel som binära. En del av variablerna är redan binära (där ja är 1 och nej är 2) men de allra flesta tar värden på en viss skala (oftast 0 till 10). För att skapa binära variabler väljer ni ett tröskelvärde och definierar svaren med värden över (eller lika med) tröskelvärdet som *positiva* svar och resten som *negativa*. Detta kallas för att *dikotomisera* variabeln. Varje grupp j har då x_j positiva svar av n_j respondenter. Vi modellerar detta som $X_j | \Theta_j = \theta_j \sim \text{Bin}(n_j, \theta_j)$.

Storheten vi skattar är densamma från A2 till A8 och ges av skillnaden i sannolikhet för ett positivt svar mellan två grupper j och k :

$$\delta = \theta_j - \theta_k.$$

Valet av grupper görs innan ni utför någon inferens (se A1 nedan). I de bayesianska avsnitten är Θ_j och Θ_k stokastiska variabler, och skillnaden mellan dem betecknas $\Delta = \Theta_j - \Theta_k$. Alltså är δ ett utfall av den stokastiska variabeln Δ .

Svarsvariabler

<i>Tema</i>	<i>Variabel</i>	<i>Fråga och skala</i>
Social tillit	ppltrst	0 = man kan inte vara nog försiktig, 10 = man kan lita på de flesta människor
	pplfair	de flesta: 0 = försöker utnyttja en, 10 = försöker vara rättvisa
	pplhlp	människor: 0 = ser mest till sig själva, 10 = försöker vara hjälpsamma
Tillit till institutioner	trstprl	tillit till landets parlament: 0 = ingen, 10 = fullständig
	trstlgl	... rättsväsendet
	trstplc	... polisen
	trstplt	... politiker
	trstprt	... politiska partier
	trstep	... Europaparlamentet
	trstun	... Förenta nationerna
Diskriminering	dscrgrp	tillhör en grupp som diskrimineras i landet (ja/nej)

<i>Tema</i>	<i>Variabel</i>	<i>Fråga och skala</i>
Attityder till invandring	imbgeco	invandring för ekonomin: 0 = dåligt, 10 = bra
	imueclt	kulturlivet av invandrare: 0 = undergrävs, 10 = berikas
	imwbcnt	landet som plats att leva på, genom invandrare: 0 = sämre, 10 = bättre
Politiskt deltagande, senaste 12 månaderna	contplt	kontaktat en politiker eller offentlig tjänsteman (ja/nej)
	badge	burit eller visat upp ett kampanjmärke eller en dekal (ja/nej)
	sgnptit	skrivit under en namninsamling (ja/nej)
	bctprd	bojkottat en produkt (ja/nej)
	pstplonl	lagt upp eller delat politiskt innehåll på nätet (ja/nej)
Välbefinnande	happy	0 = extremt olycklig, 10 = extremt lycklig
	stflife	nöjd med livet i stort: 0 = extremt missnöjd, 10 = extremt nöjd

Grupperingsvariabler

<i>Indelning</i>	<i>Variabel</i>	<i>Grupper</i>
Region	region	landets regioner så som de är kodade i filen (enligt NUTS). Antalet varierar mellan länder, från 1 till ungefär 30.
Hushållsinkomst	hinctnta	tio deciler av landets fördelning av hushållsinkomster
Ålder	från agea	sju fasta åldersklasser: 15–24, 25–34, 35–44, 45–54, 55–64, 65–74, 75 och äldre
Typ av bostadsort	domicil	fem kategorier, från storstad till landsbygd

A1. Förhandskontroll och förregistrering

Att redovisa: tabellen över gruppstorlekar före och efter rensning, förregistreringen och avvikelseredovisningen.

Med *rensning* menar vi att ni tar bort respondenter som saknar ett giltigt svar på svarsvariabeln eller grupperingsvariabeln. Hur saknade svar är kodade beskrivs i dataguiden. Med *landets delstickprov* menar vi alla respondenter från ert land i omgång 11.

Ert val av land, svarsvariabel, eventuellt tröskelvärde och indelning måste uppfylla kraven nedan.

	<i>Krav</i>
Landets delstickprov	Minst 1000 respondenter med giltigt svar på svarsvariabeln, efter rensning.
Grupper	Minst 5 icke-tomma grupper med den valda indelningen, före eventuell sammanslagning i (b) nedan.
De två grupper ni väljer	Minst 30 respondenter vardera, efter rensning.
Andel positiva svar	Andelen positiva svar i hela landets delstickprov ligger mellan 0.15 och 0.85. Den andelen gånger storleken på den minsta av era två valda grupper är minst 10.

Om er kombination inte uppfyller kraven bör ni byta indelning eller land.

- Välj land, svarsvariabel, tröskelvärde (om svarsvariabeln inte redan är binär) och indelning. Redovisa en tabell med en rad per grupp. Tabellen ska ange antalet respondenter före och efter rensning. Ange också vad ni tog bort och varför. (Exempelnotebooken utför precis dessa steg för Sverige.)
- Vissa grupper kommer att vara små, exempelvis en region med ett dussin respondenter. Bestäm hur ni ska hantera dem (behålla som de är, slå ihop, eller begränsa analysen till vissa grupper) och motivera beslutet.
- Välj de två grupper j och k vars skillnad ni ska skatta. Ni väljer enbart utifrån gruppstorlekarna, *innan* ni beräknar andelen positiva svar i någon grupp (ni kommer att se varför detta är viktigt senare).

Förregistrering. Att *förregistrera* innebär att man bestämmer och dokumenterar sina val innan man har sett resultaten. Om samma data tillåter många rimliga analyser kommer några av dem att visa en tydlig skillnad av ren slump. I efterhand är det lätt att övertyga sig själv om att just den analysen var naturlig. En studie av stora amerikanska kliniska prövningar av behandlingar mot hjärt-kärlsjukdom visade exempelvis att andelen positiva resultat sjönk kraftigt när förregistrering blev obligatorisk. En förregistrering är ett daterat dokument som visar vad man bestämde sig för innan man kunde se resultatet. Den hindrar ingen från att ändra sig, men den gör ändringen synlig.

Lämna in förregistreringsformuläret i Canvas enligt deadline ovan, ett formulär per par. Formuläret anger land, svarsvariabel, eventuellt tröskelvärde, grupperingsvariabel och de två grupperna j och k . Vid bedömningen jämförs det med rapporten.

Ni får avvika från förregistreringen, men avvikelserna måste redovisas i slutet av A1 i en *avvikelseredovisning*: vad som förregistrerades och vad som ändrades samt varför. En förregistrering kan inte lämnas in efter deadline. Om ni missar den skriver ni det i avvikelseredovisningen tillsammans med orsaken.

A2. Frekventistisk utgångspunkt

Att redovisa: $\hat{\theta}_j - \hat{\theta}_k$, motiverad som ML-skattning.

Innan vi inför några apriorifördelningar börjar vi med den frekventistiska skattningen.

- Beräkna den observerade andelen positiva svar $\hat{\theta}_j = x_j/n_j$ för varje grupp. Beräkna också $\hat{\theta}_j - \hat{\theta}_k$ för de två grupper ni valt. Visa att $\hat{\theta}_j - \hat{\theta}_k$ är ML-skattningen av δ i binomialmodellen, när de två grupperna behandlas som oberoende. Beskriv med en mening vad skattningen säger om de två grupperna.
- Visa att skattningen är väntevärdesriktig för δ och att dess varians når Cramér–Raos undre gräns.

A3. Konjugerade aposteriorfördelningar

Att redovisa: aposteriorfördelningen för Δ och $P(\Theta_j > \Theta_k \mid \mathbf{X} = \mathbf{x})$.

Nu går vi över till det bayesianska ramverket. Använd en likformig apriorifördelning, $\text{Beta}(1, 1)$, oberoende för var och en av de två grupperna.

- Härled aposteriorfördelningarna för Θ_j och Θ_k givet data.
- Ta fram aposteriorfördelningen för $\Delta = \Theta_j - \Theta_k$ genom simulering och plotta den. Båda aposteriorfördelningarna i (a) har slutna former. Förklara varför simulering ändå är det naturliga sättet att analysera fördelningen för Δ .

- (c) Formulera ett bayesianskt test av $H_0 : \theta_j \leq \theta_k$ mot $H_1 : \theta_j > \theta_k$ med 0–1-felet som förlustfunktion. Vilken hypotes väljer Bayesbeslutet, och varför?

A4. En annan apriorifördelning

Att redovisa: aposteriorifördelningen för Δ med en apriorifördelning ni själva väljer, med Monte Carlo-medelfel.

Den likformiga apriorifördelningen i A3 valdes av bekvämlighetsskäl. Här ersätter ni den med en apriorifördelning som uttrycker en annan uppfattning om de två andelarna. Den ska *inte* vara konjugerad till binomialfördelningen.

- (a) Ange er apriorifördelning och beskriv med ord vilken uppfattning den uttrycker. Kontrollera den genom att simulera från den. Är andelarna den ger rimliga för er svarsvariabel och ert land? Justera den annars, och redovisa vad ni till slut valde.
- (b) Simulera från den resulterande aposteriorifördelningen för Δ med förkastelsemetoden eller Metropolisalgoritmen. Notebooken från föreläsning 14 innehåller kodskelett för båda. Redovisa skattningen för aposterioriväntevärdet $E[\Delta \mid \mathbf{X} = \mathbf{x}]$ tillsammans med dess Monte Carlo-medelfel. Beskriv hur ni tog fram medelfelet.

Från och med kommer vi att skriva E och P även för värden som ni skattar med hjälp av Monte Carlo. Se alltid till att medelfelen är rimliga i dessa fall.

- (c) Jämför aposteriorifördelningen med den från A3. Hur mycket påverkade bytet av apriorifördelning svaret? Skulle detsamma gälla om varje grupp hade 10 respondenter? Motivera.

A5. Den hierarkiska modellen

Att redovisa: modellens graf, aposteriorifördelningen för hyperparametrarna som konturplott och som Metropoliskedjor, samt anpassningarna med empiriska Bayesmetoden och med den fullständiga bayesianska modellen.

I A2–A4 använde vi bara de två valda grupperna. Men alla andra grupper säger också något om hur andelarna $\theta_1, \theta_2, \dots, \theta_m$ varierar inom landet. Den hierarkiska modellen som tar alla dessa i beaktning är

$$X_j \mid \Theta_j = \theta_j \sim \text{Bin}(n_j, \theta_j), \quad \Theta_j \mid A = \alpha, B = \beta \sim \text{Beta}(\alpha, \beta), \quad j = 1, \dots, m,$$

där $\Theta_1, \dots, \Theta_m$ är betingat oberoende givet A, B . Använd apriorifördelningen för hyperparametrarna som ges av

$$f_{A,B}(\alpha, \beta) \propto (\alpha + \beta)^{-5/2}, \quad \alpha, \beta > 0.$$

Aposteriorifördelningen är egentlig om minst en grupp har $0 < x_j < n_j$. Notera att gruppindex bara kommer in i modellen via n_j och x_j . Apriorifördelningen behandlar alla grupper likadant, oavsett vad de heter (detta kallas *utbytbarhet* och spelar en central roll inom bayesiansk inferens).

- (a) Rita den motsvarande grafiska modellen och använd d-separation för att motivera att $\Theta_j \perp\!\!\!\perp \Theta_{j'} \mid A, B, \mathbf{X}$ för $j \neq j'$. Är Θ_j och $\Theta_{j'}$ d-separerade givet endast $\mathbf{X}$? (Ett foto eller en skannad bild av en handritad graf går bra.) Om ni vill använda LaTeX rekommenderar vi paketet TikZ.
- (b) Ställ upp den simultana aposterioritätheten för (Θ, A, B) givet $\mathbf{X} = \mathbf{x}$. Ta fram den marginella aposteriorifördelningen för (A, B) genom att integrera bort Θ . (Utnyttja ditt svar från (a) och var noga med vilka konstanter som får strykas.) Notera att den betingade aposteriorifördelningen för Θ givet (A, B) måste normaliseras innan den används.

Beräkna den marginella aposterioritätheten på ett grovt rutnät och plotta dess konturer. Kontrollera att huvuddelen av massan ligger långt bort från $(\alpha, \beta) = (0, 0)$. Simulera sedan från den med

Metropolisalgoritmen. Kör flera kedjor från spridda startpunkter och plotta dem i samma figur. Ta bort första halvan av varje kedja (uppvärmningsfasen) och visa löpande medelvärden i en annan figur. Dra slutligen $\Theta_1, \dots, \Theta_m$ från deras betingade aposteriorifördelning, för varje behållet utfall av (A, B) . Ni har nu ett stickprov från aposteriorifördelningen för (Θ, A, B) .

- (c) Anpassa modellen på två sätt. Använd första den empiriska Bayesmetoden, där (α, β) fixeras vid en skattning från data och Θ_j sedan behandlas som i A3. Använd sedan fullständiga bayesianska modellen, med stickprovet från (b). Jämför aposteriorifördelningarna för Θ_j under de två metoderna. Detta kan göras med en tabell över aposterioriväntevärde och aposterioristandardavvikelse per grupp eller med en intervallplott. Vilken metod ger bredast intervall och varför?

A6. Skillnaden i den hierarkiska modellen

Att redovisa: aposteriorifördelningen för Δ i den hierarkiska modellen (huvudresultatet), jämförelsen av fem skattningar av θ_j och den prediktiva jämförelsen.

Med stickprovet från A5 kan vi nu återvända till skillnaden mellan de två valda grupperna.

- (a) Redovisa aposteriorifördelningen för $\Delta = \Theta_j - \Theta_k$ för ert valda par under den fullständiga bayesianska modellen. Plotta den och ange dess väntevärde, ett mått på dess spridning och $P(\Theta_j > \Theta_k \mid \mathbf{X} = \mathbf{x})$. Detta är huvudresultatet i del A. Beskriv med några meningar vad det säger om skillnaden mellan de två grupperna.
- (b) Visa med ert stickprov att $\text{Var}[\Delta \mid \mathbf{X} = \mathbf{x}]$ är mindre än $\text{Var}[\Theta_j \mid \mathbf{X} = \mathbf{x}] + \text{Var}[\Theta_k \mid \mathbf{X} = \mathbf{x}]$. Förklara varför och koppla svaret till grafen i A5(a). Varför blir det fel om man bedömer skillnaden utifrån om de två gruppernas intervall överlappar?
- (c) Ställ för grupp j upp olika aposteriorifördelningar sida vid sida i en tabell. Ange aposterioriväntevärde och aposterioristandardavvikelse för var och en, tillsammans med $\hat{\theta}_j$. Aposteriorifördelningarna är
- (1) enbart denna grupp med likformig apriorifördelning (A3),
 - (2) enbart denna grupp med en apriorifördelning från A4,
 - (3) *fullständig sammanslagning*, där alla grupper antas ha ett gemensamt θ med samma apriorifördelning som i A3,
 - (4) empiriska Bayesmetoden, och
 - (5) den fullständiga bayesianska modellen.

En figur är välkommen men inget krav. Vad skiljer dem åt? Vilken information och vilka antaganden använder var och en som de andra inte använder?

- (d) Aposteriorifördelningen för Δ talar om hur väl vi kan bestämma δ , men den säger inte om skillnaden är stor eller liten för just detta land. En skillnad på 0.05 betyder en sak om grupper brukar skilja sig med 0.02 och en annan om de brukar skilja sig med 0.20. Hyperparametrarna ger oss en måttstock för att bedöma detta.

Simulera två *nya* grupper för varje behållet utfall av (A, B) , där $\tilde{\Theta}_1$ och $\tilde{\Theta}_2$ är betingat oberoende och $\text{Beta}(A, B)$ -fördelade givet A och B . Plotta $\tilde{\Delta} = \tilde{\Theta}_1 - \tilde{\Theta}_2$ längs samma axel som aposteriorifördelningen för Δ från (a). Anta att landets delstickprov vore tio gånger större, med alla n_j uppskalade. Vad skulle då hända med var och en av de två fördelningarna, och varför? Notera att med få grupper är (A, B) dåligt bestämda, och den prediktiva fördelningen blir därför bred.

A7. Selektion

Att redovisa: två sannolikheter för samma par av grupper, under två modeller.

I A1 valde ni j och k innan ni såg några andelar (eller hur?). Men vad händer om jämförelsen i stället väljs efter att man har tittat på data? Det kallas *selektion*, och det är ämnet för detta avsnitt.

- Låt t vara gruppen med högst $\hat{\theta}_i$ och b gruppen med lägst. En analytiker som inte bestämt sig i förväg kan välja just dessa två och redovisa $P(\Theta_t > \Theta_b \mid \mathbf{X} = \mathbf{x})$. Beräkna den på två sätt. Det första är med varje grupp för sig och likformig apriorifördelning, som i A3. Det andra är med den hierarkiska modellen. Vilken av dem är mindre, och varför?
- Paret (t, b) valdes för att dess observerade skillnad var störst. Beräkna därför sannolikheten att skillnaden verkligen är störst,

$$P(\Theta_t - \Theta_b \geq \Theta_p - \Theta_q \text{ för alla par } (p, q) \mid \mathbf{X} = \mathbf{x}).$$

Detta är aposteriorisannolikheten att t är gruppen med den största andelen och b gruppen med den minsta. Beräkna den med samma två modeller som i (a) och redovisa alla fyra sannolikheter i en tabell. För en given modell gäller sannolikheterna från (a) och (b) samma två grupper och kommer från samma aposteriorifördelning. Förklara varför de ändå skiljer sig så mycket. Förklara också varför ingen sådan skillnad uppstår för ert valda par (j, k) .

A8. Intervall

Att redovisa: fyra intervallskattningar av δ , ritade längs en gemensam axel.

Hittills har vi sammanfattat skillnaden med hela fördelningar och sannolikheter. I praktiken redovisas den ofta som ett intervall, och här jämför vi fyra sådana.

- Beräkna fyra intervall för δ : två 95% konfidensintervall och två 95% kredibilitetsintervall. Rita dem längs en gemensam axel.
 - Waldintervallet, som bygger på normalapproximation:

$$\hat{\theta}_j - \hat{\theta}_k \pm \lambda_{0.025} \sqrt{\frac{\hat{\theta}_j(1 - \hat{\theta}_j)}{n_j} + \frac{\hat{\theta}_k(1 - \hat{\theta}_k)}{n_k}}.$$

- Agresti-Caffo-intervallet, där varje grupp får ett extra positivt och ett extra negativt svar. I formeln ovan ersätts alltså $\hat{\theta}_j$ med $\theta_j^* = (x_j + 1)/(n_j + 2)$ och n_j med $n_j + 2$, och på motsvarande sätt för k .
 - Kredibilitetsintervallet från A3, med de två grupperna för sig och likformiga apriorifördelningar.
 - Kredibilitetsintervallet från A6(a), med den hierarkiska modellen.
- Några av de fyra intervallen blir nästan identiska. Vilka, och varför? Visa hur θ_j^* följer av er härledning i A3(a). Förklara sedan varför de olika intervallen ändå inte är samma slags påstående. Vad påstår vart och ett av dem, och om vad?
 - Anta att en av de två grupperna inte hade några positiva svar alls. Vad ger Waldintervallet då? Vad ger kredibilitetsintervallet i (3)? Svara utifrån formlerna. Ni behöver inte hitta ett sådant fall i era data.

3. Del B. En oväntad händelse under fältarbetet

Datainsamlingen i ett land kallas *fältarbete*, och tiden den pågår kallas *fältperiod*. En fältperiod i ESS pågår i flera månader. Vilket datum en respondent intervjuas styrs av logistik, exempelvis intervjuarnas arbetsbörda, resvägar och återbesök. Under ideella förhållanden styrs det inte av något hos respondenten.

Anta att en plötslig och oförutsägbar händelse inträffar mitt under fältperioden. Den delar då in respondenterna i två godtyckliga grupper: de som intervjuades före händelsen och de som intervjuades efter. Om indelningen är så gott som slumpmässig skattar en jämförelse mellan grupperna vad händelsen gjorde med svaren och kan på så sätt påvisa ett *kausalt* samband. Storheten vi skattar är återigen en skillnad mellan andelar,

$$\delta = \theta_j - \theta_k,$$

där j är gruppen efter händelsen och k gruppen före. Varje beräkning i del B är en jämförelse av två binomiala andelar, av samma slag som i del A. Men betyder jämförelsen verkligen det den verkar betyda? Detta är frågan vi kommer försöka besvara.

Två antaganden används i detta upplägg.

Ignorerbarhet innebär att vilken sida av händelsen en respondent hamnar på inte har något samband med vad hen skulle ha svarat. Antagandet brister om gruppernas *sammansättning* förändras under fältperioden. Med sammansättning menar vi fördelningen av respondenternas egenskaper, exempelvis andelen kvinnor eller andelen äldre. Lättnådda personer intervjuas kanske tidigt och motvilliga först efter flera återbesök. Intervjuarna kanske arbetar sig igenom regionerna i tur och ordning. Ignorerbarhet undersöks med balanskontroller i B3.

Exkluderbarhet innebär att indelningen isolerar händelsen, dvs. att inget annat som kan påverka svaren inträffade samtidigt. Händelsen förändrade inte heller själva undersökningen, exempelvis genom avbrutet fältarbete eller ändrad svarsvilja (exempelvis på grund av krig). En annan aspekt av detta är att respondenterna inte förutsåg händelsen. Notera att detta inte kan kontrolleras statistiskt utan måste motiveras utifrån vad som pågick i landet (och i världen) vid tidpunkten för händelsen.

På Canvas hittar ni händelsebeskrivningarna som omfattar åtta par av land och händelse. Varje par anger ESS-omgång, datum för händelsen, svarsvariabel, fönsterserie och referensfönster (vi kommer definiera dessa nedan). Välj en av paren och ladda ned hela omgången för dess land.

Svarsvariabeln är den som anges i händelsebeskrivningen. Den dikotomiserar så att värdet 6 *eller högre* på skalan 0–10 räknas som ett positivt svar. För alla uppgifter använder ni en likformig apriorifördelning, $\text{Beta}(1, 1)$, för varje Θ och varje Π (se nedan) i varje fönster.

Låt d vara antalet kalenderdagar mellan en respondents intervjudatum och händesdatumet (negativt för intervjuer före händelsen). Ett *fönster* på $\pm w$ dagar omfattar de respondenter som har $|d| \leq w$. Varje händelsebeskrivning anger tre fönster $w_1 < w_2 < w_3$, som tillsammans kallas *fönsterserien*. Intervjuer dateras med startdatum (eller med slutdatum om startdatum saknas). Eftersom det är svårt att bestämma när respondenterna tar del av händelsen så tas intervjuer på själva händesdagen, dvs. med $d = 0$, bort. Alla antal räknas efter att respondenter utan giltigt svar på svarsvariabeln har tagits bort (samma rensning som i A1). Variablerna för intervjudatum beskrivs i dataguiden.

Ett av de tre fönstren väljs ut som *referensfönstret* och används för att utföra diagnostiken i B3. Det är valt som det smalaste fönstret med ett användbart antal respondenter på båda sidor. Där är de två antagandena mest rimliga, och därför är det där mest informativt att undersöka gruppernas sammansättning. Slutsatsen i B5 dras dock från hela fönsterserien.

För att undersöka hur sammansättningen ser ut före och efter händelsen använder vi *balanskovariat*, tre dikotomiserade egenskaper som händelsen inte kan ha förändrat:

- andelen kvinnor (`gndr = 2`),
- andelen som är 45 år eller äldre (`agea`),
- andelen som bor i en storstad eller dess förorter (`domicil = 1` eller `2`).

Beteckningar. Som tidigare används θ och δ för andelar positiva svar och deras skillnader. För att beteckna sammansättning använder vi π_j som motsvarar sannolikheten att en respondent i gruppen efter händelsen har en viss egenskap, och π_k motsvarande för gruppen före. Dessa är egenskaper hos fältarbetet, och de observerade andelarna är skattningar av dem. Storheter som beräknas i ett visst fönster får fönstret som upphöjt index, exempelvis $\delta^{(w_1)}$ och $n_j^{(w_2)}$. För ett givet kovariat bildar respondenterna med egenskapen och de utan den två *delgrupper*. Skillnaderna mellan efter och före inom respektive delgrupp betecknas δ_1 och δ_0 . Som i del A betecknar versalerna Θ , Π och Δ motsvarande stokastiska variabler, exempelvis $\Delta = \Theta_j - \Theta_k$.

B1. Förberedelser och data

Att redovisa: antalet respondenter på varje sida av händelsen i varje fönster, och veckoserien för svarsvariabeln.

Innan vi kan jämföra något behöver vi veta hur många respondenter som finns nära händelsen och hur svaren utvecklades under fältperioden.

- Hämta omgång, land, händelsedatum och svarsvariabel från er händelsebeskrivning. Ladda ned data och beräkna varje respondents intervjudatum. Redovisa en tabell med $n_k^{(w)}$ (före) och $n_j^{(w)}$ (efter) för w_1 , w_2 och w_3 . Ange hur många intervjuer som togs bort för att de gjordes på händelsedagen.
- Plotta andelen positiva svar per vecka för hela fältperioden. Markera händelsen och ange antalet intervjuer per vecka, som etiketter eller i en andra panel. Exempelnotebooken visar hur man delar in intervjudatum i veckor. Beskriv vad figuren visar om hur fältarbetet var fördelat över tid och hur mycket av det som ligger nära händelsen. Beskriv också hur svaren utvecklades före och efter.

B2. Skattningen i referensfönstret

Att redovisa: aposteriorifördelningen för Δ i referensfönstret.

Vi börjar med den enklaste jämförelsen: före jämfört med efter i referensfönstret.

- Ange modellen och apriorifördelningen för grupperna före och efter händelsen. Beskriv vad som är beräkningsmässigt identiskt med A3 och vad som eventuellt skiljer sig.
- Redovisa aposteriorifördelningen för Δ i referensfönstret med en figur. Ange väntevärde, ett 95% kredibilitetsintervall och $P(\Theta_j > \Theta_k \mid \mathbf{X} = \mathbf{x})$. Beskriv med en mening vad resultatet säger om händelsens effekt, förutsatt att de två antagandena håller.

B3. Balans, triage och uppdelning

Att redovisa: en tabell över de tre balanskovariaten i referensfönstret, och en uppdelning av δ för ett av dem.

En *balanskontroll* ersätter svarsvariabeln med en egenskap som händelsen inte kan ha förändrat. Sedan ställs samma fråga som i B2 om två delgrupper. Ingens kön, ålder eller bostadsort ändrades av händelsen. Om gruppen efter händelsen har en annan andel kvinnor än gruppen före beror skillnaden alltså på ordningen i vilken människor intervjuades. En balanskontroll säger därför något om hur grupperna kom till, inte om vad händelsen gjorde. Den kan beräknas och tolkas innan ni har tittat på svarsvariabeln.

För ett givet kovariat är π_j och π_k binomiala andelar. Därför har $\Pi_j - \Pi_k$ en aposteriorifördelning, precis som Δ . Frågan är inte om kredibilitetsintervallet för $\Pi_j - \Pi_k$ innehåller noll. Frågan är om skillnaden är liten. Redovisa därför

$$P(|\Pi_j - \Pi_k| < \varepsilon \mid \mathbf{X} = \mathbf{x}), \quad \varepsilon = 0.05.$$

Ett *lågt* värde här betyder att antingen så skiljer sig grupperna i sammansättning, eller så är respondenterna för få för att avgöra saken, och i ett glest fönster är ”vi kan inte avgöra” den korrekta tolkningen. Ett *høgt* värde säger att grupperna liknar varandra i just denna egenskap, men ingenting om egenskaper som inte mättes.

Obalans betyder att grupperna skiljer sig i sammansättning, vilket i sig inte behöver betyda att vi får ett systematiskt fel i δ . Det som krävs är obalans i en egenskap som också har samband med svarsvariabeln som vi är intresserade av. Anta att 70% av gruppen efter händelsen bor i städer, mot 60% av gruppen före (dvs. en obalans på 0.10). Om stads- och landsbygdsbor båda svarar positivt med sannolikheten 0.30 blir andelen 0.30 i båda grupperna. Obalansen syns då inte i svaren. Anta i stället att stadsborna svarar positivt med sannolikheten 0.40 och landsbygdsborna med 0.20. Andelen efter händelsen blir då $0.7 \cdot 0.40 + 0.3 \cdot 0.20 = 0.34$, och andelen före blir $0.6 \cdot 0.40 + 0.4 \cdot 0.20 = 0.32$. Jämförelsen visar en skillnad på 0.02 även om händelsen inte har påverkat de underliggande andelarna i de respektive delgrupperna. Skillnaden 0.02 är $0.10 \cdot 0.20$, dvs. obalansen gånger skillnaden i svar mellan delgrupperna. Det är alltså produkten, och inte obalansen i sig, som avgör vilket kovariat som kan skapa en skenbar effekt. Att på detta sätt rangordna kovariaten efter hur mycket de kan påverka δ kallar vi här *triage*.

För att göra detta exakt delar vi varje grupp efter kovariatet. Låt θ_{j1} vara sannolikheten för ett positivt svar bland respondenter efter händelsen som har egenskapen (t.ex. stadsbor i exemplet ovan), och θ_{j0} bland dem som saknar den. Låt θ_{k1} och θ_{k0} vara motsvarande för gruppen före. Då gäller $\theta_j = \pi_j \theta_{j1} + (1 - \pi_j) \theta_{j0}$, och motsvarande för k . Subtraktion ger uppdelningen

$$\delta = \underbrace{\pi_j \delta_1 + (1 - \pi_j) \delta_0}_{\text{inomdelgruppsterm}} + \underbrace{(\pi_j - \pi_k)(\theta_{k1} - \theta_{k0})}_{\text{sammansättningsterm}},$$

där $\delta_1 = \theta_{j1} - \theta_{k1}$ och $\delta_0 = \theta_{j0} - \theta_{k0}$. Verifiera identiteten.

I sammansättningstermen mäts skillnaden i svar mellan delgrupperna i gruppen före händelsen, vars svar händelsen inte kan ha påverkat. Inomdelgruppstermen är vad jämförelsen ger när sammansättningen med avseende på kovariatet hålls fix. Varje storhet i identiteten är en binomial andel med likformig apriorifördelning. Båda termerna får därför aposteriorifördelningar från samma Monte Carlo-utfall. Notera att aposteriorifördelningen för Δ som de fyra cellerna ger skiljer sig något från den i B2, eftersom cellerna har egna apriorifördelningar.

(a) Redovisa en tabell för referensfönstret med en rad per kovariat. Tabellen ska innehålla

- aposterioriväntevärde och 95% kredibilitetsintervall för $\Pi_j - \Pi_k$,
- $P(|\Pi_j - \Pi_k| < \varepsilon \mid \mathbf{X} = \mathbf{x})$,
- aposterioriväntevärdet för skillnaden i svar före händelsen, $\Theta_{k1} - \Theta_{k0}$,
- aposterioriväntevärdet för produkten $(\Pi_j - \Pi_k)(\Theta_{k1} - \Theta_{k0})$.

Rangordna kovariaten efter produktens absolutbelopp. Notera det kovariat med störst absolutbelopp. För de två andra kovariaten, skriv en mening vardera om åt vilket håll deras obalans skulle kunna påverka δ .

(b) För det kovariat med störst produkt, redovisa antal respondenter och observerad andel positiva svar i var och en av de fyra cellerna. Redovisa också aposteriorifördelningarna för inomdelgruppstermen och sammansättningstermen. Om en cell innehåller mycket få respondenter blir kredibilitetsintervallet

för dess andel mycket brett. Det gäller exempelvis om cellen har färre än omkring 10 positiva eller 10 negativa svar. Om cellerna ser ut på detta sätt räcker det att redovisa antalen och konstatera att uppdelningen inte är informativ i detta fönster.

- (c) Under vilket antagande är inomdelgruppstermen en skattning av vad händelsen gjorde? Är det antagandet svagare eller starkare än det som krävs för δ , och varför?

B4. Fönsterserien

Att redovisa: aposteriorifördelningen för Δ i alla tre fönster i en figur, med det följda kovariatet i en andra panel.

Referensfönstret är ett val bland flera, och en skattning som beror på vilket fönster som valdes är ett annat slags resultat än en som inte gör det. Ett smalare fönster gör båda antagandena mer rimliga men ger snabbt färre respondenter, eftersom fältarbetet inte är jämnt fördelat. Ett bredare fönster ger högre precision, till priset att man jämför personer som intervjuades längre ifrån varandra.

- (a) Redovisa aposteriorifördelningen för Δ i w_1 , w_2 och w_3 i en figur. Visa aposterioriväntevärde och 95% kredibilitetsintervall för varje fönster. Låt den horisontella axeln ha de tre fönstren som jämnt fördelade kategorier, märkta med antal dagar. Lägg en liten tabell med $n_k^{(w)}$ och $n_j^{(w)}$ för varje fönster bredvid figuren. De tre intervallen kommer att överlappa kraftigt. Alla respondenter inom w_1 finns också inom w_2 , och alla inom w_2 finns inom w_3 . Förklara varför överlappningen betyder mindre än den skulle göra för tre oberoende stickprov. Koppla detta till A6(b).
- (b) Ta det kovariat som har lägst $P(|\Pi_j - \Pi_k| < \varepsilon \mid \mathbf{X} = \mathbf{x})$ i B3(a). Vi kallar det för *det följda kovariatet*. Beräkna aposteriorifördelningen för dess $\Pi_j - \Pi_k$ i alla tre fönster. Lägg till resultatet som en andra panel under figuren i (a), med gemensam horisontell axel. Visa väntevärde och intervall för varje fönster. Ange kovariatets skillnad i svar före händelsen från B3(a) i figurtexten. I det smalaste fönstret intervjuades de två grupperna under intilliggande veckor. I det bredaste kan det skilja flera månader. Varför kan sammansättningen skilja sig mer i det senare fallet?
- (c) Kurvan för δ i er figur har troligen en av fyra former.
- (1) Störst i det smalaste fönstret och avtagande utåt.
 - (2) Frånvarande i det smalaste fönstret och framträdande när fönstret vidgas.
 - (3) Ungefär densamma i alla fönster.
 - (4) Utan tydlig struktur och bred i det smalaste fönstret.

Beskriv vad var och en av formerna skulle tyda på om händelsen. Vilken form har er kurva? Läs sedan figuren tillsammans med veckoserien i B1(b) och det följda kovariatet i (b). Vad tillför kovariatets förändring över fönsterserien till tolkningen?

B5. Slutsats

Att redovisa: vad händelsen gjorde med svarsvariabeln, i ett stycke, argumenterat utifrån fönsterserien.

Beskriv i ett stycke vad er analys säger att händelsen gjorde med svarsvariabeln. Argumentera utifrån fönsterseriens form snarare än utifrån ett enskilt tal och ange skattningarnas spann över de tre fönstren snarare än ett enda värde. Slutsatsen "data skiljer inte en liten effekt från ingen effekt alls" är godtagbar för vissa av händelsebeskrivningarna, men den måste argumenteras utifrån intervallens bredd i varje fönster och antalet respondenter bakom dem.

4. PM:et

Rapporten berättar för någon som har läst den vad ni kom fram till. PM:et berättar för någon som inte har läst rapporten vad som med gott samvete kan sägas utifrån den.

Mottagaren av PM:et är en analytiker vid "Myndigheten för omvärldsanalys". Hen följer utvecklingen inom en rad samhällsfrågor och är förtrogen med ämnet men inte med statistiken. Hen har inte läst er rapport (och har ingen avsikt att göra det) men kommer att ta agera utifrån det ni skriver i PM:et.

PM:et ska omfatta 700–1000 ord. Det ska inte innehålla formler, beteckningar eller figurer. Siffror är välkomna och behövs, men varje siffra ska uttryckas så att läsaren kan använda den.

Ert PM måste ta upp de tre rubrikerna nedan. Frågorna under varje rubrik är exempel på vad ni kan diskutera och ni behöver inte besvara dem fråga för fråga. Välj ut det som ni bedömer är viktigast för läsaren utifrån era resultat och ge mindre utrymme åt det som betyder mindre.

- *Vilket antagande är svagast?* Jämförelsen i del B vilar på två antaganden, ignorerbarhet och exkluderbarhet. Vilket av dem är skörast för er händelse, och hur förklarar ni det för en läsare som inte känner till begreppen? Ändrades något i vilka som intervjuades under fältperioden, eller hände något annat samtidigt som händelsen? Hur mycket av slutsatsen står och faller med antagandet?
- *Vad handlar siffrorna om?* Två intervall kan se nästan likadana ut men motsvara olika påståenden. Vad säger era intervall något om de faktiska skillnaderna mellan grupperna, eller om hur ofta metoden träffar rätt? Spelar det någon roll att ni bestämde vilka grupper ni skulle jämföra innan ni såg resultaten, och hade svaret blivit detsamma i båda ramverken? Vilket slags påstående tillåter jämförelsen i del A och vilket slags påstående försöker jämförelsen i del B göra? Lyckas den senare?
- *Vad kan sägas offentligt?* Anta att ert resultat från del B plockas upp av en journalist eller används i en politisk diskussion. Vad skulle en ansvarsfull redogörelse säga, och vad skulle den avstå från att säga? Hur kan osäkerheten formuleras så att den inte suddas ut när den transformeras till en rubrik? Vad skulle ni själva vilja veta innan ni litade på resultatet?

Utgå från era egna resultat och skriv inte i allmänna termer. PM:et ska kunna läsas utan rapporten och ska därför inte hänvisa till dess avsnitt, figurer eller tabeller.

5. Rapporten

Inlämningen består av en PDF-fil som innehåller del A och B, PM:et och er kod, i den ordningen.

Format och omfattning. A4, 11 punkter, en spalt, normala marginaler och normalt radavstånd. Del A och B får tillsammans omfatta *högst* 16 *sidor*, inklusive figurer och tabeller. PM:et och koden räknas inte in.

Sidgränsen är snålt tilltagen med avsikt, eftersom rapporten delvis är en övning i att prioritera. Sidbudgeten nedan är vägledande och anger den tänkta omfattningen av varje avsnitt.

A1	A2	A3	A4	A5	A6	A7	A8	B1	B2	B3	B4	B5
$\frac{3}{4}$	$\frac{3}{4}$	$1\frac{1}{4}$	1	$2\frac{1}{2}$	2	$\frac{3}{4}$	1	$1\frac{1}{4}$	$\frac{3}{4}$	$1\frac{3}{4}$	$1\frac{1}{4}$	$\frac{1}{2}$

Skriv varje avsnitt kring det som ska redovisas, dvs. den tabell, figur eller det tal som avsnittet finns till för, och resonemanget som hör till. Deluppgifterna är delar av detta och inte en lista med frågor att besvara i tur och ordning.

Kod. Bifoga all kod som behövs för att återskapa varje tal och varje figur, efter PM:et och på onummerade sidor. Ni kan exportera er notebook som PDF och inkludera den i LaTeX med hjälp av `pdfpages`-paketet. Koden används bara för att kontrollera tal och räknas inte in i rapporten.