

Lösningar

1.1. Låt $X \sim \chi^2(p)$. Vi har att

$$\begin{aligned} f_X(x) &= \frac{1}{\Gamma(p/2)2^{p/2}} x^{p/2-1} e^{-x/2}, \\ &= \frac{(1/2)^{p/2}}{\Gamma(p/2)} x^{p/2-1} e^{-(1/2)x}. \end{aligned}$$

Därför har vi att $X \sim \Gamma(p/2, 1/2)$.

Låt nu $X \sim \text{Exp}(\lambda)$. Vi har då att

$$\begin{aligned} f_X(x) &= \lambda e^{-\lambda x}, \\ &= \frac{\lambda^1}{\Gamma(1)} x^{1-1} e^{-\lambda x}. \end{aligned}$$

Därför har vi att $X \sim \text{Gamma}(1, \lambda)$.

1.2. Generera ett stickprov av storlek 10 från en $\text{Beta}(3, 5)$ -population. Vad är stickprovsmedelvärdet och stickprovsvariansen? Jämför dem med $E[X]$ och $\text{Var}[X]$ där $X \sim \text{Beta}(3, 5)$.

1.3. (a) Vi använder inversionsmetoden: Om $X \sim \text{Pareto}(c, \alpha)$ har X fördelningsfunktion

$$\begin{aligned} F_X(x) &= \int_c^x \alpha c^\alpha t^{-(\alpha+1)} dt, \\ &= -c^\alpha t^{-\alpha} \Big|_c^x, \\ &= -c^\alpha x^{-\alpha} + c^\alpha c^{-\alpha}, \\ &= 1 - \left(\frac{c}{x}\right)^\alpha. \end{aligned}$$

Eftersom $F_X(x)$ är inverterbar för $0 < c \leq x < \infty$ med invers $F_X^{-1}(u) = \frac{c}{(1-u)^{1/\alpha}}$ kan vi använda inversionsmetoden genom att generera ett slumpmässigt utfall u från en $U(0, 1)$ -fördelning för att få ett utfall $x = \frac{c}{(1-u)^{1/\alpha}}$ från en $\text{Pareto}(c, \alpha)$ -fördelning.

(b) Se Jupyter notebook.

(c) Se Jupyter notebook.

(d)

$$\begin{aligned} E[X] &= \int_c^\infty x f_X(x) dx, \\ &= \int_c^\infty \alpha c^\alpha x^{-\alpha} dx, \\ &= \frac{\alpha c^\alpha}{1-\alpha} x^{-\alpha+1} \Big|_c^\infty, \\ &= 0 - \frac{\alpha c^\alpha}{1-\alpha} c^{-\alpha+1}, \\ &= \frac{\alpha c}{\alpha-1}. \quad (\text{när } \alpha > 1) \end{aligned}$$

För $c = 2.5$ och $\alpha = 4$ har vi $E[X] = 10/3 \approx 3.333$.

- 1.4.** Generera ett stickprov av storlek 100 från en $\chi^2(6)$ -fördelning. Plotta stickprovets histogram tillsammans med täthetsfunktionen.
- 1.5.** Generera ett stickprov av storlek 100 från en Gamma(7, 0.9)-population. Plotta stickprovets histogram tillsammans med täthetsfunktionen.
- 1.6.** (a) Vi beräknar täthetsfunktionen för $Y = -\log(U)$ där $U \sim U(0, 1)$ med hjälp av en transformation av stokastiska variabler (som vi kommer ihåg från SF1918). Vi har $Y = g(U)$ där $g(x) = -\log(x)$ vilken har invers $g^{-1}(x) = e^{-x}$. Därför har vi

$$\begin{aligned} f_Y(y) &= f_U(g^{-1}(u)) \left| \frac{d}{dy} g^{-1}(y) \right|, \\ &= f_U(e^{-y}) e^{-y}, \\ &= \begin{cases} e^{-y} & \text{om } 0 \leq e^{-y} \leq 1, \\ 0 & \text{annars,} \end{cases} \quad (U \text{ har domän } 0 \leq u \leq 1) \\ &= \begin{cases} e^{-y} & \text{om } y \geq 0, \\ 0 & \text{annars,} \end{cases} \end{aligned}$$

Därför $Y \sim \text{Exp}(1)$. Eftersom U och $1 - U$ är likafördelade har vi också att $-\log(1 - U) \sim \text{Exp}(1)$.

- (b) Notera att $X = g(U)$ där $g(u) = \log(u/(1-u))$. Om vi har $x = \log(u/(1-u))$ har vi att

$$\begin{aligned} x &= -\log\left(\frac{1-u}{u}\right), \\ e^{-x} &= \frac{1-u}{u}, \\ u &= \frac{1}{1+e^{-x}}. \end{aligned}$$

Därför har vi att $g^{-1}(x) = 1/(1 + e^{-x})$. Det följer att

$$\begin{aligned} f_X(x) &= f_U(g^{-1}(x)) \left| \frac{d}{dx} g^{-1}(x) \right|, \\ &= \frac{e^{-x}}{(1 + e^{-x})^2} \end{aligned}$$

Därför har vi att $X \sim \text{Logistic}(0, 1)$.

- (c) Eftersom familjen $\{f_X(x) : X \sim \text{Logistic}(\mu, \beta), \mu \in \mathbb{R}, \beta > 0\}$ är en läges-skalfamilj med standardfördelningen $\text{Logistic}(0, 1)$ har vi att $Y = \mu + \beta X$ för $X \sim \text{Logistic}(\mu, \beta)$ och $X \sim \text{Logistic}(0, 1)$. Enligt ovan vet vi att $\log(U/(1-U)) \sim \text{Logistic}(0, 1)$ för $U \sim U(0, 1)$. Därför kan vi genererar ett slumpmässigt utfall u från $U(0, 1)$ för att få utfallet

$$y = \mu + \beta \log(u/(1 - u))$$

från en $\text{Logistic}(\mu, \beta)$ -population.

- 1.7. Vi skulle vilja simulera hur lång tid vi väntar mellan ankomster av en viss buss vid en viss hållplats. I genomsnitt kommer bussen var 10:e minut. Simulera tre utfall från populationen av väntetider.
- 1.8. En viss fabrik tillverkar mynt. I genomsnitt förväntas mynt vara oviktade, men vissa mynt kan vara något viktade på grund av ojämnheter i materialet. Vi mäter ett mynts bias (systematiska fel) som sannolikheten att vi singlar myntet och får krona. Anta att myntens bias följer en $\text{Beta}(2, 2)$ -fördelning, simulera 10 mynt och rapportera deras bias. Vad är den observerade variansen biasen?
- 1.9. (a) Vi använder inversionsmetoden för att generera ett stickprov av storlek 10 från en $\text{NegBin}(2, 1/7)$ -fördelning. Vi kan generera sådana stickprov, exempelvis, 1000 gånger och räkna antalet stickprov som har stickprovsmedelvärdet mindre än $\bar{t} = 5.0$. Detta tal delas med 1000 skatta sannolikheten $P(\bar{T} \leq \bar{t})$ och vi ser att den skattade sannolikheten är ganska liten (Se Jupyter notebook). Detta föreslå att vårt stickprov kommer inte ifrån en $\text{NegBin}(2, 1/7)$ -population.
- (b) Om vi göra detsamma som i del (a) för en $\text{NegBin}(2, 2/7)$ -fördelningen får vi en större skattade sannolikheten. Så vi kan inte förkasta idén att vårt stickprov kommer ifrån denna population.
- 1.10. Vi skulle vilja simulera antalet ankomster på en timme för en viss buss på en viss hållplats där bussen kommer tre gånger varje 20 minuter i genomsnitt. Generera ett rimligt exempel för hur många gånger bussen kunna ankomma i en timme.

1.11. Använd inversionsmetoden som i Uppgift 1.9.

1.12. Använd Box–Muller-metoden för att generera ett stickprov från en $N(0, 1)$ -population och sedan använd faktumet att $Y \sim N(\mu, \sigma^2)$ uppfyller $Y = \mu + \sigma Z$ där $Z \sim N(0, 1)$ (dvs., använd normal-läges-skalfamiljens egenskaper).

1.13. Generera ett stickprov av storlek 500 från $(X_1, X_2)^T$ där

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= \frac{1}{2}X_1 + N_2 \end{aligned}$$

för $N_1 \sim N(0, 1)$, $N_2 \sim N(5, 4)$ och N_1 och N_2 är oberoende. Plotta stickprovet. Finns det någon observerbar korrelation mellan X_1 och X_2 ? Vad är stickprovsmedelvärdet?

1.14. Vi har två obereonde maskiner som var och en genererar ett tal, antingen 0 eller 1, när vi trycker på en viss knapp. Den första maskinen ger 1 med sannolikhet $3/5$ och den andra maskinen ger 1 med sannolikhet $3/8$. Simulera 100 utfall för den stokastiska variabeln X som betecknar summan av dem två talen produceras när vi trycker på knappen. Vad är stickprovsmedelvärdet och stickprovsvariansen?

1.15. Uppgiften ber oss att beräkna stickprovsmedelvärdet från en $\text{Multi}(4; 1/6, 1/6, 1/6, 1/6, 1/6)$ -population för ett stickprov av storlek 1000. För att generera ett sådant stickprov kan vi använda inversionsmetoden.

Vi börjar med att generera ett slumpmässigt utfall från en $\text{Multi}(1; 1/6)$ -population. Låt $X \sim \text{Multi}(1; 1/6, 1/6, 1/6, 1/6, 1/6, 1/6)$ I detta fall har vi

$$P(F_X(j-1) < u \leq F(j)) = P(X = j) = 1/6.$$

Givet u , ett utfall från en $U(0, 1)$ -population, vill vi därför hitta j^* så att

$$(j^* - 1)(1/6) = \sum_{j=1}^{j^*-1} P(X = j) < u \leq \sum_{j=1}^{j^*} P(X = j) = (j^*)(1/6);$$

dvs. för givet u vill vi hitta den minsta värdet j^* i $\{1, \dots, 6\}$ så att $u \leq (j^*)(1/6)$. Eftersom varje tärningskast är oberoende från de andra kan vi upprepa detta fyra gånger för att ta fram ett slumpmässigt utfall från $\text{Multi}(4; 1/6, 1/6, 1/6, 1/6, 1/6, 1/6)$ -populationen. Vi göra detta i den Jupyter notebook.

1.16. Generera ett stickprov av storlek 15 från en $\text{Bin}(10, 1/4)$ -population. Plotta stickprovets histogram. Jämför stickprovsmedelvärdet och stickprovsvariansen med $E[X]$ respektive $\text{Var}[X]$.

1.17. Låt $X \sim \text{NegBin}(r, p)$. Visa att

$$E[X] = \frac{r(1-p)}{p} \quad \text{och} \quad \text{Var}[X] = \frac{r(1-p)}{p^2}.$$

1.18. (a) (a) α känt:

$$c(\lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)}, \quad h(x) = x^{\alpha-1}, \quad w_1(\lambda) = \lambda, \quad t_1(x) = -x.$$

(b) λ känt:

$$c(\alpha) = \frac{\lambda^\alpha}{\Gamma(\alpha)}, \quad h(x) = e^{-\lambda x}, \quad w_1(\alpha) = \alpha-1, \quad t_1(x) = \log(x).$$

(c) α, λ båda okända:

$$c(\alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)}, \quad h(x) = 1,$$

$$w_1(\alpha, \lambda) = \alpha-1, \quad w_2(\alpha, \lambda) = \lambda, \quad t_1(x) = \log(x), \quad t_2(x) = -x.$$

(b) (a) α känt:

$$c(\beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)}, \quad h(x) = x^{\alpha-1}, \quad w_1(\beta) = \beta-1, \quad t_1(x) = \log(1-x).$$

(b) β känt:

$$c(\alpha) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)}, \quad h(x) = (1-x)^{\beta-1}, \quad w_1(\alpha) = \alpha-1, \quad t_1(x) = \log(x).$$

(c) α, β okända:

$$c(\alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)}, \quad h(x) = 1,$$

$$w_1(\alpha, \beta) = \alpha-1, \quad w_2(\alpha, \beta) = \beta-1, \quad t_1(x) = \log(x), \quad t_2(x) = \log(1-x),$$

(c)

$$c(p) = p^r, \quad h(x) = \binom{r+x-1}{x}, \quad w_1(p) = \log(1-p), \quad t_1(x) = x.$$

(d)

$$c(p_1, \dots, p_n) = 1, \quad h(\mathbf{x}) = \frac{m!}{x_1! \cdots x_n!}, \quad w_i(p_1, \dots, p_n) = \log(p_i), \quad t_i(\mathbf{x}) = x_i.$$

1.19. Generera ett stickprov av storlek 10 från en $\text{NegBin}(5, 2/3)$ -population. Vad är stickprovsmedelvärdet och stickprovsvariansen?

1.20. Vi säger X är $\text{Peak}(p, d)$ -fördelad om X har täthetsfunktion

$$f_X(x) = \begin{cases} 0 & \text{om } x < p - d, \\ \frac{1}{d^2}(x + d - p) & \text{om } p - d \leq x \leq p, \\ -\frac{1}{d^2}(x - d - p) & \text{om } p \leq x \leq p + d, \\ 0 & \text{om } x > p + d. \end{cases}$$

Visa att familjen $\mathcal{F} = \{f_X(x) : X \sim \text{Peak}(p, d), d > 0, p \in \mathbb{R}\}$ är en läge- och skalfamilj med standardtäthetsfunktion $f_Z(z)$ där $Z \sim \text{Peak}(0, 1)$. Vad är $E[X]$ och $\text{Var}[X]$ för $X \sim \text{Peak}(p, d)$?

1.21. Generera ett approximativt stickprov från en $\text{Peak}(1, 7)$ -population (se Uppgift 1.20). Vad är stickprovsmedelvärdet och stickprovsvariansen? Plotta stickprovhistogrammet tillsammans med fördelningens täthetsfunktion.

1.22. En konståkare tävlar i tävlingar där varje uppträdande ges fyra betyg mellan 0 och 12 och varje betyg ges av oberoende domare. Konståkarens totalbetyg X är genomsnittet av de fyra poängen. Vi kan *normalisera* ett givet betyg S från en individuell domare till ett *normaliserat betyg* $S/12 \in [0, 1]$.

- (a) Vi tror att konståkarens normaliserade betyg från varje domare modelleras av en $\text{Beta}(35, 40)$ -fördelning. Generera ett stickprov av storlek 500 från X . Vad är stickprovsmedelvärdet och stickprovsvariansen?
- (b) Antag istället att konståkarens normaliserade betyg modelleras av följande fördelningar: $\text{Beta}(35, 6)$, $\text{Beta}(37, 7)$, $\text{Beta}(29, 3)$ och $\text{Beta}(25, 5)$. Generera ett stickprov av storlek 500 från X . Vad är stickprovsmedelvärdet och stickprovsvariansen? Hur skiljer de sig från stickprovsmedelvärdet respektive stickprovsvariansen från (a)?

1.23. Anta att $f_X(x|\boldsymbol{\theta})$ är en täthetsfunktion för en fördelning som tillhör en exponentialfamilj. Då kan vi skriva

$$f_X(x|\boldsymbol{\theta}) = c(\boldsymbol{\theta})h(x) \exp \left(\sum_{j=1}^k w_j(\boldsymbol{\theta})t_j(x) \right).$$

Anta också att stödet till $f_X(x|\boldsymbol{\theta})$ beror på parameteren $\boldsymbol{\theta}$. Eftersom stödet för $f_X(x|\boldsymbol{\theta})$ beror på $\boldsymbol{\theta}$ existerar det $\boldsymbol{\theta}$ och $\boldsymbol{\theta}'$ och x så att $f_X(x|\boldsymbol{\theta}) > 0$ men $f_X(x|\boldsymbol{\theta}') = 0$. Eftersom

$$0 = f_X(x|\boldsymbol{\theta}') = c(\boldsymbol{\theta}')h(x) \exp \left(\sum_{j=1}^k w_j(\boldsymbol{\theta}')t_j(x) \right)$$

har vi att $c(\theta') = 0$ eller $h(x) = 0$.

Om $c(\theta') = 0$ följer det att $f_X(x|\theta') = 0$ för alla $x \in \mathbb{R}$ vilket är en motsägelse till antagandet att $f_X(x|\theta')$ är en täthetsfunktion. Det måste därför vara att $h(x) = 0$. Men detta är en motsägelse till antagandet att $f_X(x|\theta) > 0$. Vi har då visade att en familj fördelningar vars stöd beror på sina parametrar inte kan bilda en exponentialfamilj.

Notera att stödet $\{x \in \mathbb{R} : f_X(x|c, \alpha) \neq 0\}$ för $f_X(x|c, \alpha)$ där $X \sim \text{Pareto}(c, \alpha)$ beror på parametern c eftersom

$$f_X(x|c, \alpha) = \alpha c^\alpha x^{-(\alpha+1)}, \quad c \leq x < \infty.$$

Därför kan paretofördelningar inte bilda en exponentialfamilj.

1.24. (a)

$$c(\theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-\frac{\theta}{2}}, \quad h(x) = e^x, \quad w_1(\theta) = \frac{1}{2\theta}, \quad t_1(x) = -x^2.$$


Naturliga parameterrummet: $\{\eta \in \mathbb{R} : \eta > 0\}$.

(b)

$$c(\theta) = \frac{1}{\sqrt{2\pi a\theta^2}} e^{-\frac{1}{2a}}, \quad h(x) = 1, \quad w_1(\theta) = \frac{1}{2a\theta^2}, \quad w_2(\theta) = \frac{1}{2a\theta},$$

$$t_1(x) = -x^2, \quad t_2(x) = x.$$

Naturliga parameterrummet: en parabel utan punkt $[0, 0]^T$:



(c)

$$c(\alpha) = \frac{\alpha^\alpha}{\Gamma(\alpha)}, \quad h(x) = \frac{1}{x}, \quad w_1(\alpha) = \alpha, \quad t_1(x) = \log(x) - x.$$

Naturliga parameterrummet: $\{\eta \in \mathbb{R} : \eta > 0\}$

(d)

$$\begin{aligned}c(\theta) &= e^{-\theta^4}, & h(x) &= Ce^{-x^4}. \\w_1(\theta) &= \theta, & w_2(\theta) &= \theta^2, & w_3(\theta) &= \theta^3, \\t_1(x) &= 4x^3, & t_2(x) &= -6x^2, & t_3(x) &= 4x.\end{aligned}$$

Naturliga parameterutrymmet: $\{(\eta, \eta^2, \eta^3) \in \mathbb{R}^3 : \eta \in \mathbb{R}\}$ (en spiral i tre dimensioner som kallas den *rationella normalkurvan* i algebraisk geometri).

1.25. Visa att $\mathcal{F} = \{f_X(x|\alpha, \beta) : X \sim \text{Beta}(\alpha, \beta), \alpha > 0, \beta > 0\}$ är en exponentialfamilj.

1.26. Låt $X \sim \text{Beta}(\alpha, 2)$ och låt $Y = -\log(X)$.

- (a) Beräkna $E[Y]$ med hjälp av en transformation av stokastiska variabler.
- (b) Visa att $f_X(x | \alpha)$ tillhör en exponentialfamilj, och använd Sats 1.2 för att beräkna $E[Y]$.

1.27. Använd Sats 1.2 för att beräkna $\text{Var}[X]$ för $X \sim N(\mu, \sigma^2)$.

1.28. Använd Sats 1.2 för att ta fram en formel för $E[X^2]$ för $X \sim N(\mu, \sigma^2)$.

1.29. Visa att $\mathcal{F}_n = \{f_X(x | p) : X \sim \text{Bin}(n, p)\}$ för n fix är en exponentialfamilj. Använd Sats 1.2 för att ta fram en formel för $E[X]$ och $\text{Var}[X]$ för $X \sim \text{Bin}(n, p)$.

1.30. Visa att familjen $\mathcal{F}_n = \{f_X(x|n, p) : X \sim \text{NegBin}(n, p), p > 0\}$ är en exponentialfamilj när n är fix.

1.31.

$$c(\beta_1, \dots, \beta_m) = \frac{1}{Z}, \quad h(x) = 1, \quad w_i(\beta_1, \dots, \beta_m) = \log(\beta_i), \quad t_i(G) = \deg_G(i),$$

där $\deg_G(i)$ betecknar antalet noder i G som delar en kant med i .

1.32.

$$c(\theta) = (1-\theta)^{m^2}, \quad h(G) = 1, \quad w_1(\theta) = \log\left(\frac{\theta}{1-\theta}\right), \quad t_1(G) = 2|E(G)|,$$

där $E(G)$ betecknar kantmängden av G .

1.33. Använd Sats 1.2 för att ta fram en formel för $E[X]$ och $\text{Var}[X]$ där $X \sim \text{NegBin}(3, p)$.