

Lösningar

- 2.1.** Betrakta den stokastiska vektorn $\mathbf{X} = [X_1, X_2, X_3]^T$ där var och en av X_i har de möjliga utfallen 0 eller 1. Antag vidare att sannolikheten för utfallet $\mathbf{x} = [x_1, x_2, x_3]^T$ ges av följande tabell:

$\mathbf{x}$	$[0, 0, 0]^T$	$[0, 0, 1]^T$	$[0, 1, 0]^T$	$[0, 1, 1]^T$	$[1, 0, 0]^T$	$[1, 0, 1]^T$	$[1, 1, 0]^T$	$[1, 1, 1]^T$
$P(\mathbf{X} = \mathbf{x})$	1/24	1/8	2/15	1/5	1/36	5/36	1/7	4/21

- (a) Vad är marginalsannolikheten för $P(X_2 = x_2, X_3 = x_3)$?
 (b) Vad är marginalsannolikheten för $P(X_3 = x_3)$?
 (c) Är $X_1 \perp X_2$?
- 2.2.** En rättvis sexsidig tärning kastas tio gånger. Antalet gånger utfall i inträffa, betecknas x_i och registreras i vektorn $(x_1, x_2, x_3, x_4, x_5, x_6)$.
 (a) Vad är marginalsannolikheten $P(X_i = x_i)$ för varje $i = 1, 2, 3, 4, 5, 6$?
 (b) Vad är marginalsannolikheten för $P(X_i = x_i, X_j = x_j)$ för $i \neq j$?
- 2.3.** Låt $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5, X_6, X_7]^T \sim N(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = \begin{bmatrix} 0.517 \\ 0.839 \\ 0.817 \\ 0.660 \\ 0.674 \\ 0.385 \\ 0.259 \end{bmatrix} \quad \text{och} \quad \Sigma = \begin{bmatrix} 1 & 0.22 & 0.29 & 0.07 & 0.03 & 0.29 & 0.07 \\ 0.22 & 1 & 0.16 & 0.15 & 0.13 & 0.16 & 0.13 \\ 0.29 & 0.16 & 1 & 0.16 & 0.07 & 0.09 & 0.16 \\ 0.07 & 0.15 & 0.16 & 1 & 0.25 & 0.17 & 0.17 \\ 0.03 & 0.13 & 0.07 & 0.25 & 1 & 0.12 & 0.37 \\ 0.29 & 0.16 & 0.09 & 0.17 & 0.12 & 1 & 0.15 \\ 0.07 & 0.13 & 0.16 & 0.17 & 0.37 & 0.15 & 1 \end{bmatrix}.$$

Vad är marginalfördelningen för $\mathbf{Y} = [X_1, X_3, X_5, X_7]^T$?

- 2.4.** Låt N_1, N_2, N_3, N_4 vara oberoende och $N_1 \sim N(0, 3)$, $N_2 \sim N(0, 1)$, $N_3 \sim N(0, 1)$, $N_4 \sim N(0, 3)$. Låt vidare

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= 0.25X_1 + N_2, \\ X_3 &= -0.33X_2 + N_3, \\ X_4 &= 0.5X_2 + 0.75X_3 + N_4. \end{aligned}$$

Vad är marginalfördelningen för $[X_1, X_4]^T$?

- 2.5. (a) $X_1 = \cos(2\pi U_1)\sqrt{-2\log U_2}$ och $X_2 = \sin(2\pi U_1)\sqrt{-2\log U_2}$ där $U_1, U_2 \sim U(0, 1)$ är oberoende. Vi vill ta fram täthetsfunktionen $f_{X_1, X_2}(x_1, x_2)$ med hjälp av $f_{U_1, U_2}(u_1, u_2)$. Vi har variabelbyte

$$(x_1, x_2) = g(u_1, u_2) = \left(\cos(2\pi u_1)\sqrt{-2\log u_2}, \sin(2\pi u_1)\sqrt{-2\log u_2} \right)$$

med invers

$$g^{-1}(x_1, x_2) = \left(\frac{1}{2\pi} \operatorname{atan2}(x_2, x_1), e^{-(1/2)(x_1^2 + x_2^2)} \right),$$

där $\operatorname{atan2}(y, x)$ är funktionen som ges av

$$\operatorname{atan2}(y, x) = \begin{cases} \tan^{-1}(y/x), & \text{om } x > 0, \\ \tan^{-1}(y/x) + \pi, & \text{om } x < 0, y \geq 0, \\ \tan^{-1}(y/x) - \pi, & \text{om } x < 0, y < 0, \\ \pi/2, & \text{om } x = 0, y > 0, \\ -\pi/2 & \text{om } x = 0, y < 0. \end{cases}$$

Eftersom funktionen är lika med $\tan^{-1}(y/x)$ plus en konstant i nästan alla punkter har vi att

$$\begin{aligned} \frac{\partial}{\partial x} \operatorname{atan2}(y, x) &= \frac{\partial}{\partial x} \tan^{-1}(y/x) = -\frac{y}{x^2 + y^2} \\ \frac{\partial}{\partial y} \operatorname{atan2}(y, x) &= \frac{\partial}{\partial y} \tan^{-1}(y/x) = \frac{x}{x^2 + y^2} \end{aligned}$$

i dessa punkter. Man kan också visa att detta håller i alla andra punkter förutom $(x, y) = (0, 0)$ (där $\operatorname{atan2}$ är odefinierad). Vi har därför jacobideterminanten

$$J = \frac{\partial(u_1, u_2)}{\partial(x_1, x_2)} = \begin{vmatrix} \frac{\partial u_1}{\partial x_1} & \frac{\partial u_1}{\partial x_2} \\ \frac{\partial u_2}{\partial x_1} & \frac{\partial u_2}{\partial x_2} \end{vmatrix} = \begin{vmatrix} -\frac{x_2}{2\pi(x_1^2 + x_2^2)} & \frac{x_1}{2\pi(x_1^2 + x_2^2)} \\ -x_1 e^{-(1/2)(x_1^2 + x_2^2)} & -x_2 e^{-(1/2)(x_1^2 + x_2^2)} \end{vmatrix} = \frac{1}{2\pi} e^{-(1/2)(x_1^2 + x_2^2)}.$$

Så eftersom

$$f_{U_1, U_2}(u_1, u_2) = \begin{cases} 1 & (u_1, u_2) \in [0, 1]^2 \\ 0 & \text{annars} \end{cases}$$

har vi

$$f_{X_1, X_2}(x_1, x_2) = f_{U_1, U_2} \left(\frac{1}{2\pi} \operatorname{atan2}(x_2, x_1), e^{-(1/2)(x_1^2 + x_2^2)} \right) \frac{1}{2\pi} e^{-(1/2)(x_1^2 + x_2^2)}.$$

Eftersom $f_{U_1, U_2} \left(\frac{1}{2\pi} \operatorname{atan2}(x_2, x_1), e^{-(1/2)(x_1^2 + x_2^2)} \right)$ alltid är ett för alla (x_1, x_2) har vi

$$f_{X_1, X_2}(x_1, x_2) = \frac{1}{2\pi} e^{-(1/2)(x_1^2 + x_2^2)} = \frac{1}{\sqrt{2\pi}} e^{-(1/2)x_1^2} \cdot \frac{1}{\sqrt{2\pi}} e^{-(1/2)x_2^2}.$$

Det följer att $X_1 \perp X_2$ och $N_1, N_2 \sim N(0, 1)$.

```

(b) x1s = [ ]
    x2s = [ ]

    for i in range(10000):
        u1 = stats.uniform.rvs(0,1)
        u2 = stats.uniform.rvs(0,1)

        x1 = np.cos(2*np.pi*u1)*np.sqrt(-2*np.log(u\2))
        x2 = np.sin(2*np.pi*u1)*np.sqrt(-2*np.log(u\2))

        x1s.append(x1)
        x2s.append(x2)

    x1s = np.array(x1s)
    x2s = np.array(x2s)

    xs = np.concatenate((x1s,x2s))

    plt.hist(xs)
    plt.show()

    print(np.mean(xs))
    print(np.var(xs))

    print(np.cov(x1s,x2s))

```

- 2.6.** Beräkna täthetsfunktionen för $Y = 1/X$ där $X \sim \text{Gamma}(\alpha, \beta)$. Den stokastiska variabeln Y sägs vara *inversgammafördelad* vilket skrivs som $Y \sim \text{InvGamma}(\alpha, \beta)$.
- 2.7.** Beräkna täthetsfunktionen för $Y = 1/X$ där $X \sim \chi^2(\theta)$. Den stokastiska variabeln Y sägs vara *invers- χ^2 -fördelad* vilket skrivs som $Y \sim \text{inv-}\chi^2(\theta)$.
- 2.8.** (a) Vi har transformationen $g(x) = 1/x$ och därför $g^{-1}(y) = 1/y$.

$$\begin{aligned}
 f_Y(y) &= f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|, \\
 &= \frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{1}{y} \right)^{\alpha-1} e^{-\lambda(1/y)} \frac{1}{y^2}, \\
 &= \frac{\lambda^\alpha}{\Gamma(\alpha)} y^{-\alpha-1} e^{-\lambda/y}.
 \end{aligned}$$

(b) $g^{-1}(y) = 1/y$ igen.

$$\begin{aligned} f_Y(y) &= \frac{1}{\Gamma(\nu/2)2^{\nu/2}} (1/y)^{\nu/2-1} e^{-(1/y)/2} \frac{1}{y^2}, \\ &= \frac{1}{\Gamma(\nu/2)2^{\nu/2}} (1/y)^{\nu/2+1} e^{-1/(2y)}. \end{aligned}$$

Vi vet att $X \sim \text{Gamma}(\nu/2, 1/2)$. Därför har vi $Y \sim \text{InvGamma}(\nu/2, 1/2)$.

(c) $g^{-1}(y) = \nu\tau^2/y$ och $\frac{d}{dy}g^{-1}(y) = -\frac{\nu\tau^2}{y^2}$. Det följer att

$$\begin{aligned} f_Y(y) &= \frac{1}{\Gamma(\nu/2)2^{\nu/2}} (\nu\tau^2/y)^{\nu/2-1} e^{-\nu\tau^2/2y} \frac{\nu\tau^2}{y^2}, \\ &= \frac{\left(\frac{\nu\tau^2}{2}\right)^{\nu/2}}{\Gamma(\nu/2)} y^{-\nu/2-1} e^{-\nu\tau^2/2y}. \end{aligned}$$

$$Y/\nu\tau^2 \sim \text{Inv-}\chi^2(\nu).$$

(d) $Y \sim \text{InvGamma}(\nu/2, \nu\tau^2/2)$.

2.9. Beräkna täthetsfunktionen för $Y = 1/X$ där $X \sim \text{Beta}(\alpha, \beta)$. Den stokastiska variabeln Y sägs vara *betaprimfördelad* vilket skrivs som $Y \sim \text{Beta}'(\alpha, \beta)$.

2.10. Beräkna täthetsfunktionen för $Y = \log(X)$ där $X \sim N(\mu, \sigma^2)$. Den stokastiska fördelningen Y sägs vara *lognormalfördelad* vilket skrivs som $Y \sim \text{lognormal}(\mu, \sigma^2)$.

2.11. Låt $X_1, \dots, X_n$ vara oberoende och $\text{Exp}(\theta)$ -fördelade. Visa att $Y = X_1 + \dots + X_n \sim \text{Gamma}(n, \theta)$.

2.12. (a) Se Exempel 1.1.

(b) Se Exempel 1.2.

(c) Generera ett stickprov $x_1, \dots, x_n$ från en $\text{Gamma}(\alpha, \lambda)$ fördelning enligt algoritmen i del (b). Vi får då att $1/x_1, \dots, 1/x_n$ är ett stickprov från $\text{InvGamma}(\alpha, \beta)$ enligt Uppgift 2.8.

(d) Vi har att $\chi^2(\eta) = \text{Gamma}(\eta/2, 1/2)$ när η är jämnt. Så kan vi använda algoritmen i del (b).

2.13. Låt $X \sim \text{Po}(\lambda_1)$ och $Y \sim \text{Po}(\lambda_2)$ vara två oberoende stokastiska variabler. Visa att $Z = X + Y \sim \text{Po}(\lambda_1 + \lambda_2)$.

2.14. Visa att $Z = \frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta)$ där X och Y är oberoende stokastiska variabler så att $X \sim \text{Gamma}(\alpha, 1)$ samt $Y \sim \text{Gamma}(\beta, 1)$.

- 2.15.** (a) Om $g(x_1, \dots, x_n) = (x_{(1)}, \dots, x_{(n)})$ så är sekvensen nödvändigtvis sorterad; dvs.

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)} \Rightarrow (x_{(1)}, \dots, x_{(n)}) \in B.$$

Om å andra sidan $(x_{(1)}, \dots, x_{(n)}) \in B$ så kan vi ta $x_1 = x_{(1)}, \dots, x_n = x_{(n)}$ och då få att denna sekvens ingår i värdemängden eftersom

$$g(x_1, \dots, x_n) = (x_{(1)}, \dots, x_{(n)}).$$

Antag nu att vi har en punkt (sekvens) i B så att

$$x_{(1)} < x_{(2)} < \dots < x_{(n)};$$

dvs. alla olikheter är strikta - inga värde sammanfaller. I så fall kan vi ordna elementen på $n!$ olika distinkta sätt. Varje ordning ger en sekvens i $[0, 1]^n$ som avbildas på samma sekvens i B via g . Vi har alltså undermängderna

$$\{(x_1, \dots, x_n) \in [0, 1]^n : x_1 < x_2 < x_3 < \dots < x_n\},$$

$$\{(x_1, \dots, x_n) \in [0, 1]^n : x_2 < x_1 < x_3 < \dots < x_n\},$$

$$\{(x_1, \dots, x_n) \in [0, 1]^n : x_3 < x_1 < x_2 < \dots < x_n\},$$

$$\{(x_1, \dots, x_n) \in [0, 1]^n : x_3 < x_2 < x_1 < \dots < x_n\},$$

⋮

osv.

På varje undermängd agerar g genom permutation av elementen. (Första undermängd: identitet, Andra undermängd: $x_1 \leftrightarrow x_2$, osv...) Dessa permutationer är per definition bijektiva.

- (b) Som vi etablerade ovan är g en permutation då vi begränsar denna till en undermängd ovan. En permutation är en linjär avbildning (en permutationmatris) och dess jacobimatrix är därför densamma som avbildning själv. Till slut har vi att determinanten för en permutationmatris är antingen 1 eller -1 . Vi har därför att absolutvärdet är 1.

- (c) Låt

$$g^{-1}(x_{(1)}, \dots, x_{(n)}) = \{(x_1, \dots, x_n) \in [0, 1]^n : (x_{(1)}, \dots, x_{(n)}) = g(x_1, \dots, x_n)\}.$$

Antalet element i $g^{-1}(x_{(1)}, \dots, x_{(n)})$ är $n!$ enligt del (a). Vi får då

$$\begin{aligned} f_{X_{(1)}, \dots, X_{(n)}}(x_{(1)}, \dots, x_{(n)}) &= \left(\sum_{(x_1, \dots, x_n) \in g^{-1}(x_{(1)}, \dots, x_{(n)})} f_{X_1, \dots, X_n}(x_1, \dots, x_n) \right) \left| \frac{\partial(x_1, \dots, x_n)}{\partial(x_{(1)}, \dots, x_{(n)})} \right| \\ &= \left(\sum_{(x_1, \dots, x_n) \in g^{-1}(x_{(1)}, \dots, x_{(n)})} 1 \right) \cdot 1, \\ &= n! \end{aligned}$$

(d) Om $X_{(i)} = x_{(i)}$ har vi att

$$0 \leq X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(i-1)} \leq x_{(i)}$$

och

$$x_{(i)} \leq X_{(i+1)} \leq \dots \leq X_{(n)} \leq 1$$

eftersom

$$(X_{(1)}, \dots, X_{(i-1)}, x_{(i)}, X_{(i+1)}, \dots, X_{(n)}) \in B.$$

Marginalfördelningen för $X_{(i)}$ fås då av

$$f_{X_{(i)}}(x_{(i)}) = \int_0^{x_{(i)}} \int_0^{x_{(i-1)}} \dots \int_0^{x_{(2)}} dx_{(1)} \dots dx_{(i-2)} dx_{(i-1)} \cdot \int_{x_{(i)}}^1 \int_{x_{(i+1)}}^1 \dots \int_{x_{(n-1)}}^1 dx_{(n)} \dots dx_{(i)}$$

Den första integralsekvensen evalueras till $\frac{x_{(i)}^{i-1}}{(i-1)!}$ eftersom

$$\begin{aligned} \int_0^{x_{(2)}} dx_{(1)} &= x_{(2)}, \\ \int_0^{x_{(3)}} \int_0^{x_{(2)}} dx_{(1)} dx_{(2)} &= \int_0^{x_{(3)}} x_{(2)} dx_{(2)} = \frac{x_{(3)}^2}{2}, \end{aligned}$$

OSV..

På samma sätt fås den andra integralsekvensen till $(1 - x_{(i)})^{n-i}$ eftersom

$$\begin{aligned} \int_{x_{(n-2)}}^1 \int_{x_{(n-1)}}^1 dx_{(n)} dx_{(n-1)} &= \int_{x_{(n-2)}}^1 (1 - x_{(n-1)}) dx_{(n-1)} = \int_0^{(1-x_{(n-2)})} y dy = \frac{(1 - x_{(n-2)})^2}{2}, \end{aligned}$$

OSV...

Vi har alltså

$$\begin{aligned} f_{X_{(i)}}(x_{(i)}) &= \frac{n!}{(i-1)!(n-i)!} x_{(i)}^{i-1} (1 - x_{(i)})^{n-i}, \\ &= \frac{\Gamma(n+1)}{\Gamma(i)\Gamma(n-i+1)} x_{(i)}^{i-1} (1 - x_{(i)})^{(n-i+1)-1}. \end{aligned}$$

Därför $X_{(i)} \sim \text{Beta}(i, n-i+1)$.

(e)

2.16. Vad är den betingade fördelningen för $\mathbf{Y} \mid X_3 = 0$ där $\mathbf{Y} = [X_1, X_2]^T$ och

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= N_2, \\ X_3 &= 0.3X_1 + 0.4X_2 + N_3 \end{aligned}$$

om N_1, N_2, N_3 är oberoende och $N(0, 1)$ -fördelade?

2.17. (a) Låt $A = [a_{1,1} \cdots a_{1,n}]$ där

$$a_{i,j} = \begin{cases} 1 & i = j \\ 0 & \text{annars.} \end{cases}$$

Det följer att $A\boldsymbol{\mu} = \mu_i$ och $A\Sigma A^T = \Sigma_{ii}$. Vi har alltså att

$$X_i = A\mathbf{X} \sim N(A\boldsymbol{\mu}, A\Sigma A^T) = N(\mu_i, \Sigma_{ii}).$$

(b) Nu låter vi

$$A = \begin{bmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \end{bmatrix}$$

där

$$a_{1,k} = \begin{cases} 1 & k = i \\ 0 & \text{annars} \end{cases} \quad a_{2,k} = \begin{cases} 1 & k = j \\ 0 & \text{annars} \end{cases}.$$

Så har vi att

$$A\mathbf{X} = \begin{bmatrix} X_i \\ X_j \end{bmatrix}, \quad A\boldsymbol{\mu} = \begin{bmatrix} \mu_i \\ \mu_j \end{bmatrix}, \quad A\Sigma A^T = \begin{bmatrix} \sigma_{ii} & \sigma_{ij} \\ \sigma_{ij} & \sigma_{jj} \end{bmatrix}.$$

Därför har vi att

$$\begin{bmatrix} X_i \\ X_j \end{bmatrix} \sim N\left(\begin{bmatrix} \mu_i \\ \mu_j \end{bmatrix}, \begin{bmatrix} \sigma_{ii} & \sigma_{ij} \\ \sigma_{ij} & \sigma_{jj} \end{bmatrix}\right).$$

Nu låta

$$\sigma_i = \sqrt{\sigma_{ii}}, \quad \sigma_j = \sqrt{\sigma_{jj}}, \quad \rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \sigma_j}.$$

Vi har att

$$\begin{vmatrix} \sigma_{ii} & \sigma_{ij} \\ \sigma_{ij} & \sigma_{jj} \end{vmatrix} = \sigma_{ii}\sigma_{jj} - \sigma_{ij}^2 = \sigma_i^2 \sigma_j^2 (1 - \rho_{ij}^2)$$

och

$$\begin{aligned} \begin{bmatrix} \sigma_{ii} & \sigma_{ij} \\ \sigma_{ij} & \sigma_{jj} \end{bmatrix}^{-1} &= \frac{1}{\sigma_i^2 \sigma_j^2 (1 - \rho_{ij}^2)} \begin{bmatrix} \sigma_j^2 & -\rho_{ij} \sigma_i \sigma_j \\ -\rho_{ij} \sigma_i \sigma_j & \sigma_i^2 \end{bmatrix} \\ &= \frac{1}{1 - \rho_{ij}^2} \begin{bmatrix} 1/\sigma_i^2 & -\rho_{ij}/(\sigma_i \sigma_j) \\ -\rho_{ij}/(\sigma_i \sigma_j) & 1/\sigma_j^2 \end{bmatrix}. \end{aligned}$$

Så har vi att

$$f_{X_1, X_2}(x_1, x_2) = \frac{1}{2\pi\sigma_i\sigma_j\sqrt{1-\rho_{ij}^2}} \exp\left(-\frac{1}{2(1-\rho_{ij}^2)}\left(\left(\frac{x_i-\mu_i}{\sigma_i}\right)^2 - 2\rho_{ij}\left(\frac{x_i-\mu_i}{\sigma_i}\right)\left(\frac{x_j-\mu_j}{\sigma_j}\right) + \left(\frac{x_j-\mu_j}{\sigma_j}\right)^2\right)\right)$$

Nu kan vi beräkna $\text{Cov}[X_i, X_j] = \text{E}[(X_i - \mu_i)(X_j - \mu_j)]$:

$$\begin{aligned} \text{E}[(X_i - \mu_i)(X_j - \mu_j)] &= \frac{1}{2\pi\sigma_i\sigma_j\sqrt{1-\rho_{ij}^2}} \times \\ &\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x_i - \mu_i)(x_j - \mu_j) \exp\left(-\frac{1}{2(1-\rho_{ij}^2)}\left(\left(\frac{x_i-\mu_i}{\sigma_i}\right)^2 - 2\rho_{ij}\left(\frac{x_i-\mu_i}{\sigma_i}\right)\left(\frac{x_j-\mu_j}{\sigma_j}\right) + \left(\frac{x_j-\mu_j}{\sigma_j}\right)^2\right)\right) dx_i dx_j. \end{aligned}$$

Om vi sätter $u_1 = \left(\frac{x_i-\mu_i}{\sigma_i}\right)\left(\frac{x_j-\mu_j}{\sigma_j}\right)$ och $u_2 = \frac{x_i-\mu_i}{\sigma_i}$ får vi $x_i = \sigma_i u_2 + \mu_i$ och $x_j = \sigma_j u_1/u_2 + \mu_j$ vilket ger

$$\begin{vmatrix} 0 & \sigma_i \\ \sigma_j/u_2 & -\sigma_j u_1/u_2^2 \end{vmatrix} = \frac{\sigma_i \sigma_j}{u_2}.$$

Så integralen ovan blir

$$\begin{aligned} &= \frac{1}{2\pi\sigma_i\sigma_j\sqrt{1-\rho_{ij}^2}} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \sigma_i \sigma_j u_1 e^{-\frac{1}{2(1-\rho_{ij}^2)}\left(u_2^2 - 2\rho_{ij}u_1 + \left(\frac{u_1}{u_2}\right)^2\right)} \frac{\sigma_i \sigma_j}{|u_2|} du_1 du_2, \\ &= \frac{\sigma_i \sigma_j}{2\pi\sqrt{1-\rho_{ij}^2}} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} u_1 e^{-\frac{1}{2(1-\rho_{ij}^2)}\left(u_2^2 - 2\rho_{ij}u_1 + \left(\frac{u_1}{u_2}\right)^2\right)} \frac{du_1 du_2}{|u_2|}, \\ &= \sigma_i \sigma_j \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-u_2^2/2} \left(\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi} \cdot \sqrt{u_2^2(1-\rho_{ij}^2)}} e^{-\frac{1}{2(1-\rho_{ij}^2)}\left(u_1 - \rho_{ij}u_2\right)^2} du_1 \right) du_2. \end{aligned}$$

Integralen inom parenteserna är väntevärdet för en $N(\rho_{ij}u_2^2, u_2^2(1-\rho_{ij}^2))$ -fördelad variabel. Så har vi att

$$\text{Cov}[X_i, X_j] = \sigma_i \sigma_j \rho_{ij} \int_{-\infty}^{\infty} \frac{u_2^2}{\sqrt{2\pi}} e^{-u_2^2/2} du_2.$$

Integralen är nu $\text{E}[Z^2]$ där $Z \sim N(0, 1)$. Eftersom $\text{Var}[Z] = \text{E}[Z^2] - \text{E}[Z]^2$ har vi att $\text{E}[Z^2] = 1 + 0^2 = 1$. Så har vi att

$$\text{Cov}[X_i, X_j] = \sigma_i \sigma_j \rho_{ij} \cdot 1 = \sigma_{ij}.$$

(c) Vi låter $A = [a_{ij}]_{i=1, j=1}^{m, n}$ där

$$a_{ij} = \begin{cases} 1 & i = j \leq m \\ 0 & \text{annars} \end{cases}.$$

Så har vi att

$$A\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_m \end{bmatrix} \quad A\Sigma A^T = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1m} \\ \vdots & & \vdots \\ \sigma_{m1} & \cdots & \sigma_{mm} \end{bmatrix}.$$

Därför har vi att

$$\mathbf{Y} = A\mathbf{X} \sim N(A\boldsymbol{\mu}, A\Sigma A^T) = N\left(\begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_m \end{bmatrix}, \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1m} \\ \vdots & & \vdots \\ \sigma_{m1} & \cdots & \sigma_{mm} \end{bmatrix}\right).$$

- 2.18.** (a) Sylvesters kriterium säger att om determinanterna av de ledande kvadratiske undermatriserna är positiva så är matrisen positivt definit:

$$\begin{aligned} |2| &= 2 > 0, \\ \begin{vmatrix} 2 & 1 \\ 1 & 3 \end{vmatrix} &= 5 > 0, \\ \begin{vmatrix} 2 & 1 & 0 \\ 1 & 3 & 2 \\ 0 & 2 & 4 \end{vmatrix} &= 12 > 0. \end{aligned}$$

Så har vi att Σ är positivt definit.

(b)

$$\begin{bmatrix} Y \\ Z \end{bmatrix} = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

Så har vi att

$$\begin{bmatrix} Y \\ Z \end{bmatrix} \sim N\left(\begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \Sigma \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix}^T\right) = N\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix}\right).$$

Det följer att

$$\begin{aligned} E[Y] &= E[Z] = 0 \\ \text{Var}[Y] &= \text{Var}[Z] = 3 \\ \text{Cov}[Y, Z] &= 0. \end{aligned}$$

(c) Enligt formelsamlingen har vi att

$$\boldsymbol{\mu}_{X_1, X_3 | X_2=0} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 2 \end{bmatrix} \left(\frac{1}{3} \right) (0 - 0) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

och

$$\Sigma_{X_1, X_3 | X_2=0} = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} - \begin{bmatrix} 1 \\ 2 \end{bmatrix} \left(\frac{1}{3} \right) \begin{bmatrix} 1 & 2 \end{bmatrix} = \begin{bmatrix} 5/3 & -2/3 \\ -2/3 & 8/3 \end{bmatrix}.$$

(d) Vi ser från marginalfördelningen att X_1 och X_3 har noll kovarians. Eftersom de är normalfördelade betyder detta att $X_1 \perp\!\!\!\perp X_3$. Däremot visar svaret i del (c) att de inte är betingat oberoende givet X_2 . Detta kan ske på olika sätt. Det mesta naturliga sättet är att vi har $X_1 \sim N(0, 2)$, $X_3 \sim N(0, 4)$, och $Z \sim N(0, 1)$ alla oberoende och

$$X_2 = (1/2)X_1 + (1/2)X_3 + \sqrt{3/2}Z.$$

Detta återspeglar ett kausalt förhållande: att X_2 "genereras" av X_1 och X_3 tillsammans med några "fel" ges av Z . Mer om detta senare.

(e)

2.19. (a) Eftersom $x_1 + \dots + x_k = n$ har vi $n - x_1 = x_2 + \dots + x_k$. Vi marginalisera som i följande:

$$\begin{aligned} f_{X_1}(x_1) &= \sum_{[x_2, \dots, x_k]^T : x_2 + \dots + x_k = n - x_1} \frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k}, \\ &= \frac{n(n-1) \dots (n-x_1+1)}{x_1!} p_1^{x_1} \sum \frac{(n-x_1)!}{x_2! \dots x_k!} p_2^{x_2} \dots p_k^{x_k}, \\ &= \frac{n!}{x_1!(n-x_1)!} p_1^{x_1} (p_2 + \dots + p_k)^{n-x_1}, \quad (\text{multinomialsatsen}) \\ &= \binom{n}{x_1} p_1^{x_1} (1-p_1)^{n-x_1}. \quad (1-p_1 = p_2 + \dots + p_k) \end{aligned}$$

Det följer att $X_1 \sim \text{Bin}(n, p_1)$. Beviset fungerar detsamma för X_i för $i = 1, 2, \dots, k$.

(b)

$$\begin{aligned}
f_{X_1, \dots, X_{k-1} | X_k}(x_1, \dots, x_{k-1} | x_k) &= \frac{f_{X_1, \dots, X_k}(x_1, \dots, x_k)}{f_{X_k}(x_k)}, \\
&= \frac{\frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k}}{\binom{n}{x_k} p_k^{x_k} (1-p_k)^{n-x_k}}, \\
&= \frac{x_k! (n-x_k)!}{n!} p_k^{-x_k} (1-p_k)^{x_k-n} \frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k}, \\
&= \frac{(n-x_k)!}{x_1! \dots x_{k-1}!} p_1^{x_1} \dots p_{k-1}^{x_{k-1}} (1-p_k)^{x_k-n}, \\
&= \frac{(n-x_k)!}{x_1! \dots x_{k-1}!} \left(\frac{p_1}{1-p_k} \right)^{x_1} \dots \left(\frac{p_{k-1}}{1-p_k} \right)^{x_{k-1}}.
\end{aligned}$$

där det sista steget följer från $n - x_k = x_1 + \dots + x_{k-1}$. Det följer att $X_1, \dots, X_{k-1} | X_k \sim \text{Multi}(n - x_k; q_1, \dots, q_{k-1})$ där $q_i = p_i / (1 - p_k)$.

(c)

$$\text{Cov}[X_i, X_j] = E[X_i X_j] - E[X_i] E[X_j].$$

Vi kan skriva X_i som $X_i = \sum_{k=1}^n Y_{i,k}$ där

$$Y_{i,k} = \begin{cases} 1 & \text{om } X_k = i, \\ 0 & \text{annars} \end{cases}$$

Notera att $Y_{i,1}, \dots, Y_{i,n}$ är oberoende. Det följer att

$$\begin{aligned}
E[X_i X_j] &= E \left[\left(\sum_{k=1}^n Y_{i,k} \right) \left(\sum_{\ell=1}^n Y_{j,\ell} \right) \right], \\
&= \sum_{k=\ell} E[Y_{i,k} Y_{j,\ell}] + \sum_{k \neq \ell} E[Y_{i,k} Y_{j,\ell}], \\
&= 0 + \sum_{k \neq \ell} E[Y_{i,k} Y_{j,\ell}], \quad (\text{omöjligt att ha } X_k = i \text{ och } X_k = j) \\
&= \sum_{k \neq \ell} p_i p_j, \\
&= n(n-1) p_i p_j.
\end{aligned}$$

Det följer att

$$\text{Cov}[X_i, X_j] = n(n-1) p_i p_j - n^2 p_i p_j = -n p_i p_j.$$

Kovariansen är alltid negativ eftersom om vi öka värdet för X_k måste vi minska en annan variables värde (eftersom $x_1 + \dots + x_k = n$).

2.20. Låt $[X_1, \dots, X_m]^T \sim \text{Multi}(n; p_1, \dots, p_m)$ och låt $1 = b_0 < b_1 < \dots < b_{k-1} < b_k = m$ vara heltal. Vi definierar variablerna $Y_i = \sum_{j=b_{i-1}}^{b_i-1} X_j$ för alla $i = 1, \dots, k$ och betraktar deras simultana fördelning $\mathbf{Y} = [Y_1, \dots, Y_k]^T$. Visa att $\mathbf{Y} \sim \text{Multi}(n; q_1, \dots, q_k)$ där $q_i = p_{b_{i-1}} + \dots + p_{b_i}$ för alla $i = 1, \dots, k$.

2.21. $X \sim \text{Exp}(\lambda)$, $Y \sim \text{Exp}(\mu)$ med $X \perp\!\!\!\perp Y$. Vi har då

$$Z = \min(X, Y) \quad W = \begin{cases} 1 & X = Y \\ 0 & \text{annars.} \end{cases}$$

Notera att W kan formuleras utifrån X och Y också:

$$W = \begin{cases} 1 & X \leq Y \\ 0 & \text{annars.} \end{cases}$$

(Här har vi antagit att $W = 1$ om $X = Y$ vilket inte täcks av originaldefinitionen, men detta skiljer sig endast på en nollmängd.) Vi har nu

$$\begin{aligned} P(Z \leq z, W = 0) &= P(Z \leq z, Y < X), \\ &= P(Y \leq z, Y < X), \\ &= \int_0^z \int_y^\infty \mu e^{-\mu y} \lambda e^{-\lambda x} dx dy, \\ &= \int_0^z \mu e^{-\mu y} \left(\int_0^\infty \lambda e^{-\lambda x} dx \right) dy, \\ &= \int_0^z \mu e^{-\mu y} e^{-\lambda y} dy, \\ &= \int_0^z \mu e^{-(\mu+\lambda)y} dy, \\ &= \frac{\mu}{\mu + \lambda} (1 - e^{-(\mu+\lambda)z}). \end{aligned}$$

På samma sätt får vi

$$P(Z \leq z, W = 1) = \frac{\lambda}{\mu + \lambda} (1 - e^{-(\lambda+\mu)z}).$$

Det följer att

$$P(Z \leq z) = P(Z \leq z, W = 0) + P(Z \leq z, W = 1) = 1 - e^{-(\lambda+\mu)z}$$

och

$$\begin{aligned} P(W = 0) &= \lim_{z \rightarrow \infty} P(Z \leq z, W = 0) = \frac{\mu}{\lambda + \mu}, \\ P(W = 1) &= \lim_{z \rightarrow \infty} P(Z \leq z, W = 1) = \frac{\lambda}{\lambda + \mu}. \end{aligned}$$

Så har vi alltså

$$P(Z \leq z, W = w) = P(Z \leq z)P(W = w).$$

2.22. Betrakta modellen $[X_1, X_2]^T$ i Exempel 1.4. Visa att $X_1 \perp\!\!\!\perp X_2$ om och endast om $\lambda = 0$.

2.23. Låt $X_1 \sim \text{Po}(\lambda_1)$ och $X_2 \sim \text{Po}(\lambda_2)$ vara två oberoende stokastiska variabler. Sätt $Y = X_1 + X_2$

(a) Visa att $X_1 | Y = y \sim \text{Bin}(\theta)$ där $\theta = \frac{\lambda_1}{\lambda_1 + \lambda_2}$.

(b) Hur är $X_2 | Y = y$ fördelad?

2.24. (a) Vi vill ha att $f_{X,Y}(x, y) = 0$ om $[x, y]^T$ inte ligger i kvadraten och $f_{X,Y}(x, y)$ ha samma värde för alla $[x, y]^T$ i kvadraten. Därför måste täthetsfunktionen vara

$$f_{X,Y}(x, y) = \begin{cases} c & \text{om } -1 \leq x \leq 1 \text{ och } -1 \leq y \leq 1, \\ 0 & \text{annars,} \end{cases}$$

för en konstant c . Eftersom täthetsfunktionen måste integrera till 1 löser ut vi c från

$$\int_{-1}^1 \int_{-1}^1 f_{X,Y}(x, y) dx dy = 1$$

Vi ser att $c = 1/4$.

(b) integrera för att se: $f_X(x) = 1/2$ för $-1 \leq x \leq 1$ och $f_Y(y) = 1/2$ för $-1 \leq y \leq 1$.

(c) $P(X^2 + Y^2 < 1)$ är sannolikheten att $[x, y]^T$ ligger i cirkeln med radii 1 vilken har yta π . Därför $P(X^2 + Y^2 < 1) = \pi/4$.

(d) Hälften av kvadratens yta ligger under linjen $y = 2x$. Därför $P(Y - 2X < 0) = 1/2$.

2.25. (a) Vi använder transformationen av stokastiska variabler $U = X + Y$ och $V = X/(X + Y)$. Det följer att

$$X = UV, \quad \text{och} \quad Y = U - UV.$$

Jacobideterminanten är då

$$J = \det \begin{bmatrix} v & u \\ 1-v & -u \end{bmatrix} = -uv - u + uv = -u.$$

Det följer att

$$\begin{aligned}
f_V(v) &= \int_0^\infty \lambda e^{-\lambda uv} \mu e^{-\mu(u-uv)} u du, \\
&= \lambda \mu \int_0^\infty u e^{-u(\lambda v + \mu - \mu v)} du, \\
&= \lambda \mu \int_0^\infty \frac{w}{\lambda v + \mu - \mu v} e^{-w} \frac{dw}{\lambda v + \mu - \mu v}, \quad (w = u(\lambda v + \mu - \mu v)) \\
&= \frac{\lambda \mu}{(\lambda v + \mu - \mu v)^2} \int_0^\infty w e^{-w} dw, \\
&= \frac{\lambda \mu}{(\lambda v + \mu - \mu v)^2}
\end{aligned}$$

där det sista steget följer eftersom $w e^{-w}$ är täthetsfunktionen för $W \sim \text{Exp}(1)$.

När $\mu = \lambda$ har vi $f_V(v) = 1$; dvs. fördelningen är likaformig.

- (b) Notera först att λX och μY är $\text{Exp}(1)$ -fördelade (varför?). Därför kan vi beräkna fördelningen för $Z = U - V$ där U och V är oberoende och $\text{Exp}(1)$ -fördelade. Vi använder transformationen $W = U$ och $Z = U - V$. Vi har därmed

$$U = W \quad \text{och} \quad V = W - Z.$$

Jacobideterminanten är då

$$J = \det \begin{bmatrix} 1 & 0 \\ 1 & -1 \end{bmatrix} = -1.$$

Det följer att

$$\begin{aligned}
f_{W,Z}(w, z) &= f_{U,V}(g^{-1}(w, z)) | -1|, \\
&= e^{-w} e^{-(w-z)}, \\
&= e^{-2w+z}.
\end{aligned}$$

När vi marginaliserar har vi två fall att betrakta: Det är möjligt att $u > v$ (vilket motsvarar $z > 0$) men det är också möjligt att $u < v$ (vilket motsvarar $z < 0$). Om $z > 0$ har vi följande.

$$\begin{aligned}
f_Z(z) &= \int_z^\infty e^{-2w+z} dw, \quad (\text{eftersom } z = u - v < u = w) \\
&= e^z \int_z^\infty e^{-2w} dw, \\
&= \frac{1}{2} e^{-z}.
\end{aligned}$$

Om $z < 0$ har vi

$$\begin{aligned} f_Z(z) &= \int_0^\infty e^{-2w+z} dw, \\ &= e^z \int_0^\infty e^{-2w} dw, \\ &= e^z \left(\frac{1}{2} \right). \end{aligned}$$

Det följer att $f_Z(z) = \frac{1}{2}e^{-|z|}$.

- (c) Enligt diskussion i del (b) kan vi beräkna täthetsfunktionen för $Z = U/V$ där U och V är oberoende och $\text{Exp}(1)$ -fördelade. Vi använder transformationen $W = U$ och $Z = U/V$ vilken har invers ges av

$$U = W \quad \text{och} \quad V = W/Z.$$

Jacobideterminanten är

$$J = \det \begin{bmatrix} 1 & 0 \\ 1/z & -w/z^2 \end{bmatrix} = -\frac{w}{z^2}.$$

Det följer att

$$\begin{aligned} f_{W,Z}(w, z) &= e^{-w} e^{-w/z} \frac{w}{z^2}, \\ &= e^{-w(1+1/z)} \frac{w}{z^2}, \\ &= e^{-w((z+1)/z)} \frac{w}{z^2}. \end{aligned}$$

Marginalisera:

$$\begin{aligned} f_Z(z) &= \int_0^\infty \frac{w}{z^2} e^{-w((z+1)/z)} dw, \\ &= \int_0^\infty \frac{\alpha z^2}{(z+1)^2 z^2} e^{-\alpha} d\alpha, \quad (\alpha = w((z+1)/z)) \\ &= \frac{1}{(z+1)^2} \int_0^\infty \alpha e^{-\alpha} d\alpha, \\ &= \frac{1}{(z+1)^2}. \end{aligned}$$

2.26. (a) $N(\mathbf{b}, AA^T)$.

- (b) Låt $\mathbf{b} = \boldsymbol{\mu}$. Eftersom Σ är symmetrisk kan den diagonaliseras och skrivas som $\Sigma = VDV^T$ där V är en ortonormal matris och D är en diagonalmatris. Vi har då valen (i) $A = VD^{1/2}V^T$ och (ii) $A = VD^{1/2}$ som uppfyller $AA^T = \Sigma$.

- (c) Använd Exempel 2.14 och 2.15 tillsammans med resultatet från del (b) och Sats 2.2.
- (d) Ur en beräkningssynpunkt är Choleskyfaktoriseringen att föredra då den kräver färre multiplikationer $(n(n+1)/2)$ jämfört med diagonaliseringsmetoden (n^2) .

2.27. Betrakta den simultana fördelningen för $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ där

$$\begin{aligned} X_1 &= N_1, \\ X_2 &= 3X_1 + N_2, \\ X_3 &= -4X_2 + N_3, \\ X_4 &= 2X_1 + X_2 + N_4. \end{aligned}$$

och N_1, N_2, N_3, N_4 är oberoende och standardnormalfördelade.

- (a) Bestäm $\boldsymbol{\mu}$ och Σ så att $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$.
- (b) Vad är den betingade fördelningen för $[X_2, X_3]^T | X_4 = 0$? Generera ett stickprov av storlek 500 från denna fördelning och plotta resultatet. Finns det någon korrelation mellan X_2 och X_3 i denna fördelning?
- (c) Vad är marginalfördelningen för $[X_2, X_3]^T$? Generera ett stickprov från denna fördelning och plotta resultatet. Ser du någon korrelation här?

2.28. Låt X och Y vara oberoende stokastiska variabler.

- (a) Visa att $E[X^2] = \text{Var}[X] + E[X]^2$.
- (b) Visa att $\text{Var}[XY] = E[X^2] E[Y^2] - E[X]^2 E[Y]^2$.
- (c) Visa att $\text{Var}[XY] = \text{Var}[X] \text{Var}[Y] + \text{Var}[X] E[Y]^2 + \text{Var}[Y] E[X]^2$.

2.29. Vad är $E[\mathbf{X}]$ och $\text{Cov}[\mathbf{X}]$ där $\mathbf{X} = [X_1, X_2, X_3]^T$ är fördelad som i Uppgift 2.1?

2.30. Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim N(\boldsymbol{\mu}, \Sigma)$ där

$$\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \quad \text{och} \quad \Sigma = \begin{bmatrix} 5 & 1 & -0.5 & -0.3 \\ 1 & 4 & 0.25 & 0 \\ -0.5 & 0.25 & 5 & 2.4 \\ -0.3 & 0 & 2.4 & 4 \end{bmatrix}$$

- (a) Är $X_2 \perp X_4$?
- (b) Är $X_2 \perp X_3$?
- (c) Vad är $\text{Cov}[X_1, X_3]$?

- (d) Vad är $\text{Var}[X_2]$?
- (e) Vad är $E[X_2, X_3]$?
- (f) Vad är $\text{Cov}[\mathbf{Y}]$ där $\mathbf{Y} = [X_1, X_3, X_4]^T$?

2.31. Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T \sim N(\mathbf{0}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 1 & 0 & 2 & 2 \\ 0 & 1 & 0 & 0 \\ 2 & 0 & 5 & 4 \\ 2 & 0 & 4 & 5 \end{bmatrix}.$$

- (a) Vad är $E[(X_3 + X_4)X_2^2]$?
- (b) Vad är $E[(X_3 + X_4)^2 X_2^2]$?
- (c) Vad är $E[(X_3 + X_4)^2 + X_2^2]$?

2.32. Låt $\mathbf{X} = [X_1, X_2, X_3, X_4]^T$ vara fördelad som i Uppgift 2.31.

- (a) Vad är $\text{Var}[X_2 + X_3 + X_4]$?
- (b) Vad är $\text{Var}[(X_3 + X_4)X_2]$?
- (c) Vad är $\text{Var}[(X_3 + X_4)X_2^2]$?

2.33. Låt $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5]^T$ vara $N(\mathbf{0}, \Sigma)$ -fördelad där

$$\Sigma = \begin{bmatrix} 10 & 1 & -1 & -2 & 0 \\ 1 & 7 & 4 & -1 & 0 \\ -1 & 4 & 9 & 0 & 0 \\ -2 & -1 & 0 & 8 & 0 \\ 0 & 0 & 0 & 0 & 17 \end{bmatrix}.$$

Beräkna $E[(X_1 + X_2)^2((X_3 + X_4)^2 + X_5^2)^2]$.

2.34. Låt $\mathbf{X} = [X_1, X_2, X_3, X_4, X_5, X_6, X_7, X_8]^T \sim N(\mathbf{0}, \Sigma)$ där

$$\Sigma = \begin{bmatrix} 1 & 3 & 0 & 2 & 0 & 0 & 0 & 0 \\ 3 & 10 & 0 & 6 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 2 & 3 & 0 & 0 \\ 2 & 6 & 0 & 5 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 5 & 6 & 0 & 0 \\ 0 & 0 & 3 & 0 & 6 & 10 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 27 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 27 \end{bmatrix}.$$

Låt

$$Y = \frac{1}{(X_2 + X_4)^2 + (X_5 + X_6)^2 + X_7^2 + X_8^2}.$$

Vad är $E[Y]$?