

Lösningar

6.1. Vi har att

$$m_1 = \frac{1}{10} \sum_{i=1}^{10} x_i = 4.034 \quad \text{och} \quad m_2 = \frac{1}{10} \sum_{i=1}^{10} x_i^2 = 18.134.$$

Vi beräknar

$$E[X] = \int_c^\infty x \alpha c^\alpha x^{-\alpha-1} dx = \frac{\alpha c}{\alpha - 1} \quad (\text{för } \alpha > 1)$$

och

$$E[X^2] = \int_c^\infty x^2 \alpha c^\alpha x^{-\alpha-1} dx = \frac{\alpha c^2}{\alpha - 2}. \quad (\text{för } \alpha > 2)$$

Vi har då systemet ekvationer

$$\begin{aligned} m_1 &= \frac{\alpha c}{\alpha - 1}, \\ m_2 &= \frac{\alpha c^2}{\alpha - 2}. \end{aligned}$$

Vi löser ut c från den första ekvationen:

$$c = \frac{m_1(\alpha - 1)}{\alpha}.$$

Med hjälp av den andra ekvationen har vi då att

$$\begin{aligned} m_2 &= \frac{\alpha \left(\frac{m_1(\alpha-1)}{\alpha} \right)^2}{\alpha - 2}, \\ m_2 &= \frac{m_1^2(\alpha - 1)^2}{\alpha(\alpha - 2)}, \\ \frac{m_1^2}{m_2} &= \frac{\alpha(\alpha - 2)}{(\alpha - 1)^2}, \\ \frac{m_1^2}{m_2} &= 1 - \frac{1}{(\alpha - 1)^2}, \\ \alpha &= 1 + \sqrt{\frac{m_2}{m_2 - m_1^2}}. \end{aligned}$$

Därför har vi

$$c = \frac{m_1(\alpha - 1)}{\alpha} \quad \text{där} \quad \alpha = 1 + \sqrt{\frac{m_2}{m_2 - m_1^2}}.$$

För $m_1 = 4.034$ och $m_2 = 18.134$ får vi punktskattningen $[\tilde{\alpha}, \tilde{c}]^T = [4.122, 3.055]^T$.

6.2. Vi noterar först att

$$\begin{aligned} E[T] &= \int_{-\pi}^{\pi} t f_T(t | \alpha) dt, \\ &= \int_{-\pi}^{\pi} \frac{t}{2\pi} (1 + \alpha \cos(t)) dt, \\ &= \int_{-\pi}^{\pi} \frac{t}{2\pi} dt + \frac{\alpha}{2\pi} \int_{-\pi}^{\pi} t \cos(t) dt, \\ &= 0 + \frac{\alpha}{2\pi} (t \sin(t) + \cos(t)) \Big|_{-\pi}^{\pi}, \\ &= 0. \end{aligned}$$

Därför kan vi inte använda den första moment. Vi har dock att

$$\begin{aligned} E[T^2] &= \int_{-\pi}^{\pi} \frac{t^2}{2\pi} (1 + \alpha \cos(t)) dt, \\ &= \int_{-\pi}^{\pi} \frac{t^2}{2\pi} dt + \frac{\alpha}{2\pi} \int_{-\pi}^{\pi} t^2 \cos(t) dt, \\ &= \frac{\pi^2}{3} - 2\alpha. \end{aligned}$$

Om vi har ett stickprov $t_1, \dots, t_n$ har vi den andra momenten

$$m_2 = \frac{1}{n} \sum_{i=1}^n t_i^2.$$

Vi löser ut

$$m_2 = \frac{\pi^2}{3} - 2\alpha$$

för att få momentmetodens punktskattning

$$\tilde{\alpha} = \frac{\pi^2 - 3m_2}{6}.$$

6.3. Låt

$$\begin{aligned} X | \Lambda = \lambda &\sim \text{Po}(\lambda), \\ \Lambda &\sim \text{Gamma}(\alpha, \beta). \end{aligned}$$

Beräkna momentmetodens punktskattning för $[\alpha, \beta]^T$ med hjälp av följande stickprov från X .

3	4	3	5	5	3	4	1	2	2
4	6	10	6	3	10	11	15	3	3
3	6	7	11	1	6	4	4	2	6.

Rita datans histogram tillsammans med den skattade täthetsfunktionen och diskutera punktskattningens kvalitet.

6.4. Låt X vara en stokastisk variabel med täthetsfunktion

$$f_X(x \mid \lambda, \nu) = \frac{\lambda^2}{2\Gamma(2)} x e^{-\lambda x} + \frac{\nu^4}{2\Gamma(4)} x^3 e^{-\nu x}, \quad 0 \leq x < \infty.$$

Beräkna momentmetodens punktskattning för $[\lambda, \nu]^T$ med hjälp av följande stickprov från X .

4.708 5.454 4.564 6.406 4.053 3.577 2.493 4.368 0.532 9.518
1.985 2.395 1.614 0.573 1.624 4.004 2.107 2.044 2.032 1.716.

Rita datans histogram tillsammans med den skattade täthetsfunktionen och diskutera punktskattningens kvalitet.

6.5. Låt $X_1, \dots, X_n$ vara oberoende och $\text{Po}(\lambda)$ -fördelade. Log-likelihoodfunktionen är då

$$\begin{aligned} \ell &= \log f_{\mathbf{X}}(x_1, \dots, x_n), \\ &= \log \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!}, \\ &= \sum_{i=1}^n \log(e^{-\lambda} \lambda^{x_i}) - \log(x_i!), \\ &= -n\lambda + \sum_{i=1}^n x_i \log(\lambda) - \sum_{i=1}^n \log(x_i!), \\ &= -n\lambda + \log(\lambda) \sum_{i=1}^n x_i - \sum_{i=1}^n \log(x_i!) \end{aligned}$$

För att bestämma kritiska punkterna tar vi den första derivatan, sätter den lika med 0 och löser ut λ :

$$\begin{aligned} \frac{d\ell}{d\lambda} &= -n + \frac{\sum_{i=1}^n x_i}{\lambda}, \\ 0 &:= -n + \frac{\sum_{i=1}^n x_i}{\lambda}, \\ \lambda &= \frac{1}{n} \sum_{i=1}^n x_i, \\ \lambda &= \bar{x}. \end{aligned}$$

Kandidaten för ML-skattningen är då $\hat{\lambda} = \bar{x}$. Vi måste verifiera att denna punkt är det globala maximumet. För att se detta beräknar vi det andra derivatan och se att det är negativ på $\hat{\lambda}$:

$$\begin{aligned} \frac{d^2\ell}{d\lambda^2} &= \frac{d}{d\lambda} \left(-n + \frac{\sum_{i=1}^n x_i}{\lambda} \right), \\ &= -\frac{\sum_{i=1}^n x_i}{\lambda^2}. \end{aligned}$$

Eftersom $\sum_{i=1}^n x_i > 0$ för alla $x_1, \dots, x_n$ har vi att $\frac{d^2\ell}{d\lambda^2} < 0$. Det följer att ML-skattningen är $\hat{\lambda} = \bar{x}$. För givet data har vi ML-skattningen $\hat{\lambda} = 114.4$.

Vi använder ML-skattningen genom att anta $X \sim \text{Po}(114.4)$ Sannolikheten är då

$$P(X > 125) = 1 - \sum_{i=1}^{125} \frac{e^{-114.4}(114.4)^i}{i!} \approx 0.15.$$

6.6. Låt $X_1, \dots, X_n$ vara oberoende och $\text{Pareto}(c, \alpha)$ -fördelade. Log-likelihoodfunktionen är då

$$\begin{aligned} \ell &= \prod_{i=1}^n f_{\mathbf{X}}(x_1, \dots, x_n), \\ &= \log \prod_{i=1}^n \alpha c^\alpha x_i^{-\alpha-1}, \\ &= n \log(\alpha) + n\alpha \log(c) - (\alpha + 1) \sum_{i=1}^n x_i. \end{aligned}$$

Istället för att beräkna både partiella derivatorna noterar vi att större värdena för c ökar värdet för log-likelihoodfunktionen eftersom $n, \alpha > 0$ och $\log(c)$ är strikt växande. Eftersom $c < x_i$ för alla x_i tar vi då $\hat{c} = \min_i(x_i)$. För α tar vi den partiella derivatan, sätter den lika med 0 och löser ut α :

$$\begin{aligned} \frac{\partial \ell}{\partial \alpha} &= \frac{n}{\alpha} + n \log(c) - \sum_{i=1}^n \log(x_i), \\ 0 &:= \frac{n}{\alpha} + n \log(c) - \sum_{i=1}^n \log(x_i), \\ \alpha &= \frac{n}{\sum_{i=1}^n \log(x_i) - n \log(c)}. \end{aligned}$$

Vi ser också att för givet c

$$\frac{\partial^2 \ell}{\partial \alpha^2} = -\frac{n}{\alpha^2} < 0 \quad (\text{eftersom } n > 0).$$

Det följer att $\hat{\alpha}$ maximerar log-likelihoodfunktionen för givet c och därför ML-skattningen är

$$[\hat{c}, \hat{\alpha}]^T = \left[\frac{n}{\sum_{i=1}^n \log(x_i) - n \log(c)}, \min_i(x_i) \right]^T.$$

För givet data är då ML-skattning $[\hat{c}, \hat{\alpha}]^T = [2.51, 2.38]^T$. Momentmetodens punktskattning var $[4.12, 3.06]^T$. Det ser ut som ML-skattningen är lite mindre. Vi kunde undersöka om en (eller både) är

väntevärdesriktig. Vi skulle då föredra en den väntevärdesriktiga punktskattningen.

- 6.7. (a) Vi skriver den simultana täthetsfunktionen för $\mathbf{X} = [X_1, \dots, X_n]^T$ som

$$\begin{aligned} f_{\mathbf{X}}(x_1, \dots, x_n) &= \prod_{i=1}^n \frac{\alpha}{\beta^\alpha} x_i^{\alpha-1} \mathbf{1}_{[0, \beta]}(x_i), \\ &= \prod_{i=1}^n \frac{\alpha}{\beta^\alpha} x_i^{\alpha-1} \mathbf{1}_{(-\infty, \beta]}(x_i) \mathbf{1}_{[0, \infty)}(x_i), \\ &= g(T(\mathbf{x})|\alpha, \beta)h(\mathbf{x}), \end{aligned}$$

där

$$\begin{aligned} g(T(\mathbf{x})|\alpha, \beta) &= \frac{\alpha^n}{\beta^{n\alpha}} \left(\prod_{i=1}^n x_i \right)^{\alpha-1} \mathbf{1}_{(-\infty, \beta]}(\max_i(x_i)), \quad \text{och} \\ h(\mathbf{x}) &= \mathbf{1}_{[0, \infty)}(x_i). \end{aligned}$$

Det följer att

$$\left[\prod_{i=1}^n x_i, \max_i(x_i) \right]^T$$

är en tillräcklig statistika för $[\alpha, \beta]^T$.

- (b) För α fixt har vi $f_{\mathbf{X}}(x_1, \dots, x_n) = 0$ om $\beta < \max_i(x_i)$ och $f_{\mathbf{X}}(x_1, \dots, x_n)$ är en strikt minskning funktion av β om $\beta \geq \max_i(x_i)$. Därför har vi att $\hat{\beta} = \max_i(x_i)$.

För att skatta α tar vi den partiella derivatan

$$\begin{aligned} \frac{\partial}{\partial \alpha} \log f_{\mathbf{X}}(x_1, \dots, x_n) &= \frac{n}{\alpha} - n \log(\beta) + \log \left(\prod_{i=1}^n x_i \right), \\ &= \frac{n}{\alpha} - n \log(\beta) + \sum_{i=1}^n \log(x_i), \\ 0 &:= \frac{n}{\alpha} - n \log(\beta) + \sum_{i=1}^n \log(x_i), \\ \alpha &= \frac{n}{n \log(\beta) - \sum_{i=1}^n \lg(x_i)}. \end{aligned}$$

Vi verifiera att

$$\frac{\partial^2}{\partial \alpha^2} \log f_{\mathbf{X}}(x_1, \dots, x_n) = -\frac{n}{\alpha^2} < 0.$$

Det följer att

$$[\hat{\alpha}, \hat{\beta}]^T = \left[\frac{n}{n \log(\max_i(x_i)) - \sum_{i=1}^n \lg(x_i)}, \max_i(x_i) \right]^T$$

är ML-skattningen.

(c) För givet data får vi $[\hat{\alpha}, \hat{\beta}]^T = [12.59, 25]^T$.

6.8. Eftersom $X \perp\!\!\!\perp Y$ har vi

$$f_{X,Y}(x,y) = f_X(x)f_Y(y) = \frac{e^{-\lambda}\lambda^x}{x!} \frac{e^{-\beta\lambda}(\beta\lambda)^y}{y!} = \frac{e^{-(\lambda+\lambda\beta)}\lambda^{x+y}\beta^y}{x!y!}.$$

För ett stickprov $\mathbf{X}_1, \dots, \mathbf{X}_n$ har vi

$$\begin{aligned} \ell &= \log f_{\mathbf{X}}(\mathbf{x}_1, \dots, \mathbf{x}_n), \\ &= \log \prod_{i=1}^n \frac{e^{-(\lambda+\lambda\beta)}\lambda^{x_i+y_i}\beta^{y_i}}{x_i!y_i!}, \\ &= -n(\lambda + \lambda\beta) + \log(\lambda) \sum_{i=1}^n (x_i + y_i) + \log(\beta) \sum_{i=1}^n y_i - \sum_{i=1}^n \log(x_i!y_i!). \end{aligned}$$

De partiella derivatorna är

$$\begin{aligned} \frac{\partial \ell}{\partial \beta} &= -n\lambda + \frac{\sum_{i=1}^n y_i}{\beta}, \\ \frac{\partial \ell}{\partial \lambda} &= -n(\beta + 1) + \frac{\sum_{i=1}^n (x_i + y_i)}{\lambda}. \end{aligned}$$

Med hjälp av den första löser vi ut

$$\beta = \frac{\sum_{i=1}^n y_i}{n\lambda}.$$

Med hjälp av detta löser vi ut λ från den andra:

$$\begin{aligned} \lambda &= \frac{\sum_{i=1}^n (x_i + y_i)}{n(\beta + 1)}, \\ \lambda &= \frac{\sum_{i=1}^n (x_i + y_i)}{n \left(\left(\frac{\sum_{i=1}^n y_i}{n\lambda} \right) + 1 \right)}, \\ \lambda \left(\lambda - \frac{1}{n} \sum_{i=1}^n \right) &= 0, \end{aligned}$$

Vi har då att $\lambda = 0$ eller $\lambda = \bar{x}$. Maximumet kan inte vara $\lambda = 0$ eftersom detta ger oss $f_{\mathbf{X}}(\mathbf{x}_1, \dots, \mathbf{x}_n) = 0$. Vi har då $\hat{\lambda} = \bar{x}$. Detta ger oss $\hat{\beta} = \frac{\sum_{i=1}^n y_i}{\sum_{i=1}^n x_i} = \frac{\bar{y}}{\bar{x}}$. Med hjälp av andra derivator kan vi verifiera att denna punkt är det globala maximumet. För givet data får vi ML-skattningen $[\hat{\lambda}, \hat{\beta}]^T = [2.98, 2502.4]^T$.

6.9. Vi har att

$$\begin{aligned} S &= \frac{18}{17}(X - (1/4)Y), \\ N &= \frac{18}{17}(Y - (2/9)X) \end{aligned}$$

där $X \sim \text{Exp}(\lambda)$, $Y \sim \text{Exp}(\nu)$ är oberoende. Med hjälp av en transformation av stokastiska variabler får vi

$$f_{S,N}(s, n) = \frac{17}{18} \lambda \nu e^{-\lambda(s+(1/4)n) - \nu(n+(2/9)s)}.$$

För ett stickprov $\mathbf{z}_1, \dots, \mathbf{z}_m$ där $\mathbf{Z} = [S, N]^T$ har vi

$$\begin{aligned} \ell &= \log f_{\mathbf{Z}_1, \dots, \mathbf{Z}_m}(\mathbf{z}_1, \dots, \mathbf{z}_m), \\ &= m \log(17/18) + m \log(\lambda) + m \log(\nu) - \lambda \sum_{i=1}^m (s_i + (1/4)n_i) - \nu \sum_{i=1}^m (n_i + (2/9)s_i). \end{aligned}$$

De partiella derivatorna ger oss

$$\begin{aligned} \frac{\partial \ell}{\partial \lambda} &= \frac{m}{\lambda} - \sum_{i=1}^m (s_i + (1/4)n_i), \\ 0 &:= \frac{m}{\lambda} - \sum_{i=1}^m (s_i + (1/4)n_i), \\ \lambda &= \frac{m}{\sum_{i=1}^m (s_i + (1/4)n_i)}, \\ \frac{\partial \ell}{\partial \nu} &= \frac{m}{\nu} - \sum_{i=1}^m (n_i + (2/9)s_i), \\ 0 &:= \frac{m}{\nu} - \sum_{i=1}^m (n_i + (2/9)s_i), \\ \nu &= \frac{m}{\sum_{i=1}^m (n_i + (2/9)s_i)}. \end{aligned}$$

Vi kan verifiera med hjälp av andra derivator att denna punkt är det globala maximumet. Därför har vi ML-skattningen

$$[\hat{\lambda}, \hat{\nu}]^T = \left[\frac{m}{\sum_{i=1}^m (s_i + (1/4)n_i)}, \frac{m}{\sum_{i=1}^m (n_i + (2/9)s_i)} \right]^T.$$

För givet data har vi $[\hat{\lambda}, \hat{\nu}]^T = [0.88, 0.45]^T$.

6.10. Observera att $X_i \sim \text{U}(0, \theta)$. Därför har vi att momentmetodens punktskattning är $\hat{\theta} = 2\bar{x}$. Vi såg i föreläsningen att $\text{E}[\hat{\Theta}] = 2 \text{E}[\bar{X}] =$

θ . Vi kan också beräkna

$$\begin{aligned}\text{Var}[\hat{\Theta}] &= \text{Var}[2\bar{X}], \\ &= 4 \text{Var}[\bar{X}], \\ &= \frac{4}{n^2} \left(\sum_{i=1}^n \text{Var}[X_i] + \sum_{i \neq j} \text{Cov}[X_i, X_j] \right), \\ &= \frac{4n \text{Var}[X_1]}{n^2}, \quad (X_1, \dots, X_n) \text{ ober och likaförd} \\ &= \frac{\theta^2}{3n}, \quad (\text{Var}[X_1] = \theta^2/12).\end{aligned}$$

För ML-skattningen har vi likelihoodfunktionen

$$L(\theta) = f_{\mathbf{X}}(x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{(-\infty, \theta]}(x_i) \mathbf{1}_{[0, \infty)}(x_i) = \frac{1}{\theta^n} \mathbf{1}_{(-\infty, \theta]}(\max_i(x_i)) \mathbf{1}_{[0, \infty)}(\min_i(x_i)).$$

För $\theta \geq \max_i(x_i)$ är $L(\theta)$ strikt avtagande. För $\theta < \max_i(x_i)$ är $L(\theta) = 0$. Därför är det globala maximumet lika med $\hat{\theta} = \max_i(x_i)$. För att skatta väntevärdet och variansen för $\hat{\Theta}$ börjar vi med observationen att $F_X(x) = x/\theta$. Låt Y vara den stokastiska variabeln som räknar antalet X_i så att $X_i \leq x$ för $X_1, \dots, X_n$ oberoende. Det följer att $Y \sim \text{Bin}(n, F_X(x))$. Därför har vi att

$$F_{\hat{\Theta}}(x) = P(Y = n) = \binom{n}{n} F_X(x)^n = \left(\frac{x}{\theta}\right)^n.$$

Därför

$$f_{\hat{\Theta}}(x) = \frac{nx^{n-1}}{\theta^n}.$$

Det följer att

$$E[\hat{\Theta}] = \frac{n}{n+1}\theta \quad \text{och} \quad \text{Var}[\hat{\Theta}] = \frac{n}{n+2}\theta^2.$$

Variansen är därför

$$\text{Var}[\hat{\Theta}] = E[\hat{\Theta}^2] - E[\hat{\Theta}]^2 = \frac{n\theta^2}{(n+1)^2(n+2)}.$$

Vi ser att $\tilde{\theta}$ är väntevärdesriktig men inte $\hat{\theta}$. Om n är stor $\hat{\theta}$ har en liten bias. Men för n liten kan det vara stor. För stor n kan vi använda $\hat{\theta}$ men för liten n är $\tilde{\theta}$ ett bättre val.

- 6.11.** (a) Låt $\mathbf{x}_i = [x_{i1}, x_{i2}, x_{i3}]^T$ betecknar utfall $\mathbf{x}_i$ av ett stickprov $\mathbf{x}_1, \dots, \mathbf{x}_n$ från fördelningen $\mathbf{X} = [X_1, X_2, X_3]^T$. Log-likelihoodfunktionen

är då

$$\begin{aligned}
\ell(\mathbf{p} \mid \mathbf{x}) &= \log \prod_{i=1}^n f_{X_1}(x_{i1}) f_{X_2|X_1}(x_{i2} \mid x_{i1}) f_{X_3|X_2}(x_{i3} \mid x_{i2}), \\
&= \log \left(p_1^{n_{X_1=0}} (1-p_1)^{n-n_{X_1=0}} p_{2,X_1=0}^{n_{2,X_1=0}} (1-p_{2,X_1=0})^{n_{X_1=0}-n_{2,X_1=0}} \right. \\
&\quad \times p_{2,X_1=1}^{n_{2,X_1=1}} (1-p_{2,X_1=1})^{n_{X_1=1}-n_{2,X_1=1}} p_{3,X_2=0}^{n_{3,X_2=0}} (1-p_{3,X_2=0})^{n_{X_2=0}-n_{3,X_2=0}} \\
&\quad \times p_{3,X_2=1}^{n_{3,X_2=1}} (1-p_{3,X_2=1})^{n_{X_2=1}-n_{3,X_2=1}} \left. \right), \\
&= n_{X_1=0} \log(p_1) + (n - n_{X_1=0}) \log(1-p_1) \\
&\quad + n_{2,X_1=0} \log(p_{2,X_1=0}) + (n_{X_1=0} - n_{2,X_1=0}) \log(1-p_{2,X_1=0}) \\
&\quad + n_{2,X_1=1} \log(p_{2,X_1=1}) + (n_{X_1=1} - n_{2,X_1=1}) \log(1-p_{2,X_1=1}) \\
&\quad + n_{3,X_2=0} \log(p_{3,X_2=0}) + (n_{X_2=0} - n_{3,X_2=0}) \log(1-p_{3,X_2=0}) \\
&\quad + n_{3,X_2=1} \log(p_{3,X_2=1}) + (n_{X_2=1} - n_{3,X_2=1}) \log(1-p_{3,X_2=1})
\end{aligned}$$

där

$$\begin{aligned}
n_{X_1=j} &= |\{\mathbf{x}_i : x_{i1} = j\}|, \\
n_{2,X_1=j} &= |\{\mathbf{x}_i : x_{i1} = j \text{ och } x_{i2} = 0\}|, \\
n_{3,X_2=j} &= |\{\mathbf{x}_i : x_{i2} = j \text{ och } x_{i3} = 0\}|,
\end{aligned}$$

för $j \in \{0, 1\}$. Vi har den partiella derivatan

$$\frac{\partial}{\partial p_1} \ell(\mathbf{p} \mid \mathbf{x}) = \frac{n_{X_1=0}}{p_1} - \frac{n - n_{X_1=0}}{1 - p_1}.$$

När vi sätter derivatan lika med 0 och löser ut p_1 får vi

$$p_1 = \frac{n_{X_1=0}}{n}.$$

På samma sätt får vi

$$p_{2,X_1=0} = \frac{n_{2,X_1=0}}{n_{X_1=0}}, \quad p_{2,X_1=1} = \frac{n_{2,X_1=1}}{n_{X_1=1}}, \quad p_{3,X_2=0} = \frac{n_{3,X_2=0}}{n_{X_2=0}}, \quad p_{3,X_2=1} = \frac{n_{3,X_2=1}}{n_{X_2=1}}.$$

Det kan också visas att hessianmatrisen är en diagonalmatris med icke-negativa entré som visar att denna punkt är ML-skattningen.

För givna datan har vi

$$\begin{aligned}
n &= 4, \\
n_{X_1=0} &= 2, \\
n_{X_1=1} &= 2, \\
n_{X_2=0} &= 1, \\
n_{X_2=1} &= 3, \\
n_{2,X_1=0} &= 1, \\
n_{2,X_1=1} &= 0, \\
n_{3,X_2=0} &= 1, \\
n_{3,X_2=1} &= 2,
\end{aligned}$$

vilken betyder att ML-skattningen borde vara $[1/2, 1/2, 0, 1, 2/3]^T$. Men denna punkt är inte positivt och därför ligger det utifrån parameterrummet $(0, 1)^5$. Därmed har vi att ML-skattningen inte existerar för denna data.

(b) För datan $\mathbf{X}_1, \dots, \mathbf{X}_5$ har vi

$$\begin{aligned}
n &= 5, \\
n_{X_1=0} &= 2, \\
n_{X_1=1} &= 3, \\
n_{X_2=0} &= 2, \\
n_{X_2=1} &= 3, \\
n_{2,X_1=0} &= 1, \\
n_{2,X_1=1} &= 1, \\
n_{3,X_2=0} &= 1, \\
n_{3,X_2=1} &= 2.
\end{aligned}$$

Enligt formeln för ML-skattningen i del (a) har vi att ML-skattningen är $[2/5, 1/2, 1/3, 1/2, 2/3]^T \in (0, 1)^5$. Eftersom denna punkt ligger i parameterrummet har vi att ML-skattningen existerar.

6.12. Eftersom $X_i \sim \text{Exp}(\lambda)$ har X_i täthetsfunktion $f_{X_i}(x_i) = \lambda e^{-\lambda x_i}$, $0 \leq x_i < \infty$. Log-likelihoodfunktionen är

$$\begin{aligned}
\ell(\lambda \mid \mathbf{x}) &= \log \prod_{i=1}^n \lambda e^{-\lambda x_i}, \\
&= n \log(\lambda) - \lambda \sum_{i=1}^n x_i, \\
&= n \log(\lambda) - n\bar{x}\lambda.
\end{aligned}$$

Derivatan med avseende på λ är

$$\frac{d}{d\lambda}\ell = \frac{n}{\lambda} - n\bar{x}.$$

Så ML-skattningen ges av den kritiska punkten $\hat{\lambda} = \frac{1}{\bar{x}}$ – som kan verifieras att vara det globala maximat.

Eftersom $X \sim \text{Exp}(\lambda) = \text{Gamma}(1, \lambda)$ och $\sum_{i=1}^n X_i \sim \text{Gamma}(n, \lambda)$ har vi att $(\sum_{i=1}^n X_i)^{-1} \sim \text{InvGamma}(n, \lambda)$. Enligt formelsamlingen har vi att

$$\text{E}[(\sum_{i=1}^n X_i)^{-1}] = \frac{\lambda}{n-1}.$$

Det följer att

$$\text{E}[\hat{\lambda}] = \text{E}[n(\sum_{i=1}^n X_i)^{-1}] = n \text{E}[(\sum_{i=1}^n X_i)^{-1}] = \frac{n\lambda}{n-1}.$$

Vi har då

$$\text{Bias}[\hat{\lambda}] = \text{E}[\hat{\lambda}] - \lambda = \frac{n\lambda}{n-1} - \lambda = \frac{\lambda}{n-1}.$$

Eftersom $\text{Bias}[\hat{\lambda}] \rightarrow 0$ då $n \rightarrow \infty$ har vi att ML-skattningen är en bättre skattning för λ när stickprovet är stort.

- 6.13.** (a) Den givna skattningen är väntevärdesriktig om sin väntevärde är lika med β . Vi har att

$$\begin{aligned} \text{E} \left[\frac{\sum_i Y_i}{\sum_i x_i} \right] &= \frac{1}{\sum_i x_i} \sum_i \text{E}[Y_i], \\ &= \frac{1}{\sum_i x_i} \sum_i (\beta x_i + \text{E}[\varepsilon_i]), \\ &= \frac{1}{\sum_i x_i} \sum_i (\beta x_i + 0), \\ &= \beta \left(\frac{\sum_i x_i}{\sum_i x_i} \right), \\ &= \beta. \end{aligned}$$

Så har vi att skattningen är väntevärdesriktig.

(b) Eftersom $Y_i \perp Y_j$ för alla $i \neq j$ har vi att

$$\begin{aligned}\text{Var} \left[\frac{\sum_i Y_i}{\sum_i x_i} \right] &= \frac{1}{(\sum_i x_i)^2} \sum_i \text{Var}[Y_i], \\ &= \frac{\sum_i \sigma^2}{(\sum_i x_i)^2}, \\ &= \frac{n\sigma^2}{n^2 \bar{x}^2}, \\ &= \frac{\sigma^2}{n\bar{x}^2}.\end{aligned}$$

Notera att $\sum_i x_i^2 - n\bar{x}^2 = \sum_i (x_i - \bar{x})^2 \geq 0$. Därför har vi att $\sum_i x_i^2 \geq n\bar{x}^2$. Det följer att

$$\text{Var}[\hat{\beta}] = \frac{\sigma^2}{\sum_i x_i^2} \leq \frac{\sigma^2}{n\bar{x}^2} = \text{Var} \left[\frac{\sum_i Y_i}{\sum_i x_i} \right].$$

ML-skattningen har därmed varians som är mindre eller lika med variansen av den givna skattningen.

6.14. Cramér–Rao under gränsen ges av $1/I(p)$ där

$$I(p) = -n \mathbb{E} \left[\frac{\partial^2}{\partial p^2} \log f_X(X | p) \right].$$

Vi beräknar

$$\begin{aligned}I(p) &= -n \mathbb{E} \left[\frac{\partial^2}{\partial p^2} \log f_X(X | p) \right], \\ &= -n \mathbb{E} \left[\frac{\partial^2}{\partial p^2} \log (p^X (1-p)^{1-X}) \right], \\ &= -n \mathbb{E} \left[\frac{\partial^2}{\partial p^2} (X \log(p) + (1-X) \log(1-p)) \right], \\ &= -n \mathbb{E} \left[\frac{-X}{p^2} - \frac{1-X}{(1-p)^2} \right], \\ &= n \left(\frac{1}{p} + \frac{1}{(1-p)} \right), \\ &= \frac{n}{p(1-p)}.\end{aligned}$$

Eftersom $X_i \sim \text{Ber}(p)$ är $\sum_i X_i \sim \text{Bin}(n, p)$. Därför

$$\begin{aligned}\text{Var}[\bar{X}] &= \frac{1}{n^2} \text{Var} \left[\sum_i X_i \right], \\ &= \frac{np(1-p)}{n^2}, \\ &= \frac{p(1-p)}{n}.\end{aligned}$$

Det följer att $\bar{X}$ uppfyller Cramér–Rao undre gränsen.

- 6.15.** (a) Notera att $X_1, \dots, X_n$ är ett stickprov från en exponentialfamilj:

$$f_X(x \mid \theta) = \theta x^{\theta-1} = h(x)c(\theta)e^{t(x)w(\theta)}$$

där $h(x) = 1$, $c(\theta) = \theta$, $t(x) = \log(x)$ och $w(\theta) = \theta - 1$. Enligt Sats 6.5,

$$\begin{aligned} \frac{d}{d\theta} f(x \mid \theta) &= \frac{d}{d\theta} \log \prod_i \theta x_i^{\theta-1}, \\ &= \frac{d}{d\theta} \sum_i (\log(\theta) + (1 - \theta) \log(x_i)), \\ &= \sum_i ((1/\theta) + \log(x_i)), \\ &= -n \left(-\sum_i \frac{\log(x_i)}{n} - \frac{1}{\theta} \right) \end{aligned}$$

Om vi låter $a(\theta) = -n$ och $g(\theta) = 1/\theta$ får vi $\hat{\theta} := -\sum_i \frac{\log(x_i)}{n}$ som en kandidat. Vi behöver dock verifiera att $\hat{\theta}$ är väntevärdesriktig:

$$\begin{aligned} E[\hat{\theta}] &= -\frac{1}{n} \sum_i E[\log(X_i)], \\ &= -E[\log(X)], \quad (X_1, \dots, X_n \text{ likafördelade}) \\ &= -\int_0^1 \log(x) \theta x^{\theta-1} dx, \\ &= \frac{1}{\theta}. \end{aligned}$$

Så följer det från Sats 6.5 att $\hat{\theta} = -\sum_i \frac{\log(x_i)}{n}$ är en väntevärdesriktig skattning av $\frac{1}{\theta}$ som uppnår Cramér–Rao undre gränsen.

- 6.16.** (a) Antag att $\lambda > 0$ samt $c > 0$ och att vi har följande modell:

$$\begin{aligned} Y_i &\sim \text{Exp}(\lambda) \\ X_i &= \min(Y_i, c) \\ Z_i &= \begin{cases} 1, & Y_i \geq c \\ 0, & Y_i < c \end{cases}. \end{aligned}$$

Vi observerar bara X_i samt Z_i och vill skatta λ för ett givet c . Detta kallas en högercensurerad exponentialmodell och modellerar fenomen där vi bara kan observera data upp till ett visst värde c (detta är vanligt i studier där undersökningsfönstret ofta är begränsat i tiden).

Beräkna ML-skattningen för λ givet ett slumpmässigt stickprov $[X_1, Z_1]^T, \dots, [X_n, Z_n]^T$.

- (b) Antag att vi istället har en vänstercensurerad exponentialmodell:

$$\begin{aligned} Y_i &\sim \text{Exp}(\lambda) \\ X_i &= \max(Y_i, c) \\ Z_i &= \begin{cases} 1, Y_i \leq c \\ 0, Y_i > c \end{cases} \end{aligned}$$

På liknande sätt modellerar detta mätprocesser där vi inte har möjlighet att mäta utfall under en viss gräns (men vi vet att utfallet har inträffat under den gränsen).


Varför kan vi inte ta fram en enkel formel för ML-skattningen i detta fall?

- (c) Skriv ned gradientmetoden för skattning av λ och testa den på ett stickprov av storlek $n = 387$ med $\lambda = 0.7$ och $c = 1.2$.

- 6.17.** (a) Täthetsfunktionen ges av

$$f_X(x) = \frac{p}{\sqrt{2\pi}\sigma^2} e^{-(x-\mu_1)^2/2\sigma^2} + \frac{1-p}{\sqrt{2\pi}\sigma^2} e^{-(x-\mu_0)^2/2\sigma^2}.$$


Ett histogram med täthetsfunktionen plottad ovanpå kan se ut som



- (b) Gradienten ges av

$$\nabla \ell(p, \mu_0, \mu_1) = \begin{bmatrix} \frac{\partial \ell}{\partial p} \\ \frac{\partial \ell}{\partial \mu_0} \\ \frac{\partial \ell}{\partial \mu_1} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n \frac{r_i}{p} - \frac{1-r_i}{1-p} \\ \sum_{i=1}^n r_i \frac{x_i - \mu_1}{\sigma^2} \\ \sum_{i=1}^n (1-r_i) \frac{x_i - \mu_0}{\sigma^2} \end{bmatrix}$$

- (c) Gradientmetoden konvergerar efter ungefär 50 iterationer med steglängd 0.0003 (metoden divergerar för större steglängder). Konvergensen är relativt snabb i p men tar längre tid för μ_0 och μ_1 :




(d) Kedjeregeln (den vanliga) ger

$$\frac{\partial \ell}{\partial \alpha} = \frac{\partial \ell}{\partial p} \frac{dp}{d\alpha}.$$

Eftersom $p = e^\alpha / (1 + e^\alpha)$ har vi att $dp/d\alpha = e^\alpha / (1 + e^\alpha)^2$. Om vi sätter in $p = e^\alpha / (1 + e^\alpha)$ i uttrycket för $\partial \ell / \partial p$ och förenklar får vi

$$\frac{\partial \ell}{\partial \alpha} = \sum_{i=1}^n r_i - \frac{e^\alpha}{1 + e^\alpha} = \sum_{i=1}^n r_i - p.$$

Med denna omparametrisering kan vi använda steglängder upp till 0.002 utan att divergera, vilket ger en konvergens efter ungefär 10 iterationer:




(e) Sätter vi gradienten $\nabla \ell(p, \mu_0, \mu_1)$ till noll får vi

$$p = \frac{1}{n} \sum_{i=1}^n r_i$$

$$\mu_0 = \frac{\sum_{i=1}^n x_i (1 - r_i)}{\sum_{i=1}^n 1 - r_i}$$

$$\mu_1 = \frac{\sum_{i=1}^n x_i r_i}{\sum_{i=1}^n r_i}$$

Vi implementerar denna metod och får följande konvergensbeteende:



Metoden konvergerar alltså extremt snabbt, efter bara ett fåtal iterationer. Denna metod är en variant av den kraftfulla expectation-maximization-metoden eller EM-metoden som används för att skatta parametrar i många olika typer av statistiska modeller.