Lösningar

7.1. (a) Vi tar fram aposteriorifördelningen mha Bayes sats:

$$\begin{aligned} f_{\Theta|X}(\theta \mid x) &= \frac{f_{X|\Theta}(x \mid \theta) f_\Theta(\theta)}{f_X(x)} \\ &\propto f_{X|\Theta}(x \mid \theta) f_\Theta(\theta) \\ &= \theta e^{-\theta x} \frac{\lambda^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\lambda\theta} \\ &= \frac{\lambda^\alpha}{\Gamma(\alpha)} \theta^\alpha e^{-\theta(\lambda+x)} \\ &\propto \theta^\alpha e^{-\theta(\lambda+x)} \end{aligned}$$

$\Rightarrow \Theta \mid X \sim \text{Gamma}(\alpha+1, \lambda+x)$. Verifieras i formelsamlingen genom uppdateringsregeln för exponentialfördelad data med gammafördelad parameter där $n = 1$ och $\bar{x} = x$.

(c) Vi gör en ansats med Bayes sats och använder att observationerna är betingat oberoende givet Θ för att faktorisera den simultana täthetsfunktionen av $\boldsymbol{X} = [X_1, \ldots, X_n]^{\mathrm{T}}$:

$$\begin{aligned} f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) &\propto f_{\boldsymbol{X}|\Theta}(\boldsymbol{x} \mid \theta)_\Theta(\theta) \\ &= \left(\prod_{i=1}^n \theta e^{-\theta x_i} \right) \frac{\lambda^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\lambda\theta} \\ &= \theta^n e^{-\theta \sum_{i=1}^n x_i} \frac{\lambda^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\lambda\theta} \\ &\propto \theta^{\alpha+n-1} e^{-\theta(n\bar{x}+\lambda)} \end{aligned}$$

$$\Rightarrow \Theta \mid \boldsymbol{X} \sim \text{Gamma}(\alpha+n, \lambda+n\bar{x})$$

Vilket motsvarar uppdateringsregeln i formelsamlingen.

7.2. (a) Vi börjar med att ta fram aposteriorifördelningen. Att observera X och Y är samma sak som att observera den ena först och den andra sen. Antag först att vi observerar X. Då får vi:

$$\begin{aligned} f_{\Theta|X}(\theta \mid x) &= \frac{f_{X|\Theta}(x \mid \theta) f_\Theta(\theta)}{f_X(x)} \\ &\propto f_{X|\Theta}(x \mid \theta) f_\Theta(\theta) \\ &= (2\theta) e^{-2\theta x} \frac{\lambda^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\theta\lambda} \\ &\propto \theta^\alpha e^{-\theta(2x+\lambda)} \end{aligned}$$

$$\Rightarrow \Theta \mid X \sim \text{Gamma}(\alpha+1, 2x+\lambda)$$

Nu kan vi använda $\Theta \mid X$ som aposteriorifördelning i Bayes sats och utföra samma beräkningar (med $f_{Y|\Theta}(y \mid \theta)$ och $f_Y(y)$ som data- respektive aprioriprediktiv fördelning):

$$\begin{aligned} f_{\Theta|X,Y}(\theta \mid x, y) &= \frac{f_{Y|\Theta}(y \mid \theta) f_{\Theta|X}(\theta \mid x)}{f_Y(y)} \\ &\propto f_{Y|\Theta}(y \mid \theta) f_{\Theta|X}(\theta \mid x) \\ &= (3\theta) e^{-3\theta y} \frac{(\lambda + 2x)^{\alpha+1}}{\Gamma(\alpha+1)} \theta^{\alpha} e^{-\theta(\lambda+2x)} \\ &\propto \theta^{\alpha+1} e^{-\theta(\lambda+2x+3y)} \end{aligned}$$

$$\Rightarrow \Theta \mid X, Y \sim \text{Gamma}(\alpha + 2, \lambda + 2x + 3y)$$

Vi kan nu sätta in våra observationer, $X = 2.01$ och $Y = 3.82$ för att få att $\Theta \mid X, Y \sim \text{Gamma}(4, 17.48)$. Givet detta kan vi beräkna aposterioriväntevärdet genom:

$$E[\Theta \mid X, Y] = \frac{4}{17.48} \approx 0.229.$$

7.3. (a) Vi har alltså

$$X \mid \Theta = \theta \sim \text{Exp}(\theta) \qquad \text{och} \qquad \Theta \sim \text{Gamma}(\alpha, \lambda).$$

Eftersom vi inte har ett fixt värde på X kan vi inte använda definitionen av betingade täthetsfunktion och få ut aposteriorifördelningen som vanligt. Istället beräknar vi aposteriorifördelningens

fördelningsfunktion med hjälp av Bayes sats:

$$\begin{aligned}
F_{\Theta|X\geq 20}(\theta_0) &= P(\Theta \leq \theta_0 \mid X \geq 20), \\
&= \frac{P(\Theta \leq \theta_0, X \geq 20)}{P(X \geq 20)}, \\
&\propto P(\Theta \leq \theta_0, X \geq 20), \qquad \text{(eftersom } P(X \geq 20) \text{ ej beror paå } \Theta) \\
&= \int_0^{\theta_0} \int_{20}^{\infty} f_{X|\Theta}(x \mid \theta) f_{\Theta}(\theta) dx d\theta, \\
&= \int_0^{\theta_0} \int_{20}^{\infty} \theta e^{-\theta x} \frac{\lambda^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\lambda\theta} dx d\theta, \\
&\propto \int_0^{\theta_0} \theta^\alpha e^{-\lambda\theta} \left(\int_{20}^{\infty} e^{-\theta x} dx \right) d\theta, \\
&= \int_0^{\theta_0} \theta^\alpha e^{-\lambda\theta} \left[\frac{e^{-\theta x}}{-\theta} \right]_{20}^{\infty} d\theta, \\
&= \int_0^{\theta_0} \theta^\alpha e^{-\lambda\theta} \frac{e^{-20\theta}}{-\theta} d\theta, \\
&= \int_0^{\theta_0} \theta^\alpha e^{-(\lambda+20)\theta} d\theta.
\end{aligned}$$

Om vi differentierar med avseende på θ_0 får vi då

$$f_{\Theta|X\geq 20}(\theta) \propto \theta^{\alpha-1} e^{-(\lambda+20)\theta},$$

dvs. $\Theta \mid X \geq 20 \sim \text{Gamma}(\alpha, \lambda + 20)$. Enligt formelsamlingen har vi då

$$\begin{aligned}
\text{E}\left[\Theta \mid X \geq 20\right] &= \frac{\alpha}{\lambda + 20}, \\
\text{Var}\left[\Theta \mid X \geq 20\right] &= \frac{\alpha}{(\lambda + 20)^2}.
\end{aligned}$$

(b) Här använder vi bara standarduppdateringen för exponentiellt fördelad data med gamma-fördelad parameter:

$$\Theta \mid X = 20 \sim \text{Gamma}(\alpha + 1, \lambda + 20)$$

vilket ger:

$$\begin{aligned}
\text{E}\left[\Theta \mid X = 20\right] &= \frac{\alpha + 1}{\lambda + 20}, \\
\text{Var}\left[\Theta \mid X = 20\right] &= \frac{\alpha + 1}{(\lambda + 20)^2}.
\end{aligned}$$

Detta ger att både väntevärdet och variansen är större för $X = 20$ än $X \geq 20$.

(c) Eftersom små värden på Θ ger stora värden på X (t.ex. har vi att $\mathrm{E}[X \mid \Theta] = 1/\Theta$) så betyder stora värden på X i sin tur att Θ måste vara litet. Eftersom observationen (händelsen) $X \geq 20$ inkluderar möjligheten att X är väldigt stor, vilket leder till ett mindre värde på Θ. Alltså är det naturligt att aposterioriväntevärdet blir mindre.

Å andra sidan vet vi att $\Theta > 0$, så där de mest sannolika värdena blir mindre så koncentreras fördelningen för Θ i ett mindre intervall. Aposteriorivariansen blir således också mindre. Detta motsäger inte lagen om total varians som lyder

$$\mathrm{Var}[\Theta \mid X \geq 20] = \mathrm{E}[\mathrm{Var}[\Theta \mid X] \mid X \geq 20] + \mathrm{Var}[\mathrm{E}[\Theta \mid X]X \geq 20],$$

från vilket följer

$$\mathrm{E}[\mathrm{Var}[\Theta \mid X] \mid X \geq 20] \leq \mathrm{Var}[\Theta \mid X \geq 20].$$

Vänsterledet gäller väntevärde av $\mathrm{Var}[\Theta \mid X]$ för alla $X \geq 20$ och olikheten behöver alltså inte gälla för exakta värden på X, t.ex. $X = 20$.

7.4. (a) Vi har $X \mid \Theta = \theta \sim \mathrm{N}(\theta, \sigma^2)$ och $\Theta \sim \mathrm{N}(\mu, \tau^2)$. Genom att använda onormaliserade täthetsfunktioner och kvadratkomplettering får vi

$$\begin{aligned}
f_{\Theta|X}(\theta \mid x) &\propto f_{X|\Theta}(x \mid \theta) f_\Theta(\theta), \\
&\propto e^{-\frac{(x-\theta)^2}{2\sigma^2}} e^{-\frac{(\theta-\mu)^2}{2\tau^2}}, \\
&= e^{-\frac{x^2-2x\theta+\theta^2}{2\sigma^2}} e^{-\frac{\theta^2-2\theta\mu+\mu^2}{2\tau^2}}, \\
&\propto e^{-\frac{\theta^2-2x\theta}{2\sigma^2}} e^{-\frac{\theta^2-2\theta\mu}{2\tau^2}}, \qquad \text{(ta bort faktorer som inte beror på } \theta\text{)}, \\
&= e^{-\frac{1}{2(\sigma\tau)^2}\left(\tau^2\theta^2-2\tau^2\theta x+\sigma^2\theta^2-2\sigma^2\theta\mu\right)}, \\
&= e^{-\frac{\tau^2+\sigma^2}{2\sigma^2\tau^2}\left(\theta^2-2\left(\frac{\tau^2 x+\sigma^2\mu}{\sigma^2+\tau^2}\right)\theta\right)}, \\
&\propto e^{-\frac{\tau^2+\sigma^2}{2\sigma^2\tau^2}\left(\theta^2-2\left(\frac{\tau^2 x+\sigma^2\mu}{\sigma^2+\tau^2}\right)\theta+\left(\frac{\tau^2 x+\sigma^2\mu}{\sigma^2+\tau^2}\right)^2\right)}, \\
&= e^{-\frac{\tau^2+\sigma^2}{2\sigma^2\tau^2}\left(\theta-\frac{\tau^2 x+\sigma^2\mu}{\sigma^2+\tau^2}\right)^2}, \\
&= e^{\frac{-(\theta-\mu_1)^2}{2\tau_1^2}},
\end{aligned}$$

där vi har sätt

$$\mu_1 = \frac{\tau^2 x + \sigma^2\mu}{\sigma^2+\tau^2} = \frac{\frac{\mu}{\tau^2}+\frac{x}{\sigma^2}}{\frac{1}{\tau^2}+\frac{1}{\sigma^2}}, \qquad \tau_1^2 = \frac{\sigma^2\tau^2}{\tau^2+\sigma^2} = \frac{1}{\frac{1}{\tau^2}+\frac{1}{\sigma^2}}.$$

Så har vi $\Theta \mid X = x \sim \mathrm{N}(\mu_1, \tau_1^2)$.

(b) Eftersom $X_n \perp\!\!\!\perp X_1, \ldots, X_{n-1} \mid \Theta$ så har vi

$$f_{X_1,\ldots,X_{n-1},X_n|\Theta}(x_1,\ldots,x_n \mid \theta) = f_{X_1,\ldots,X_{n-1}|\Theta}(x_1,\ldots,x_{n-1} \mid \theta) f_{X_n|\Theta}(x_n \mid \theta).$$

Om vi stoppar in detta i formel för aposteriorifördelningen får vi

$$\begin{aligned} f_{\Theta|X_1,\ldots,X_n}(\theta \mid x_1,\ldots,x_n) &\propto f_{X_1,\ldots,X_n|\Theta}(x_1,\ldots,x_n \mid \theta) f_\Theta(\theta), \\ &= f_{X_1,\ldots,X_{n-1}|\Theta}(x_1,\ldots,x_{n-1} \mid \theta) f_{X_n|\Theta}(x_n \mid \theta) f_\Theta(\theta), \\ &\propto f_{\Theta|X_1,\ldots,X_{n-1}}(\theta \mid x_1,\ldots,x_{n-1}) f_{X_n|\Theta}(x_n \mid \theta). \end{aligned}$$

Med andra ord kan vi uppdatera fördelningen för θ steg för steg. Från del (a) har vi $\Theta \mid X_1 \sim \mathrm{N}(\mu_1, \tau_1^2)$. Om vi uppdaterar detta med $X_2 = x_2$ får vi $\Theta \mid X_1, X_2 = x_1, x_2 \sim \mathrm{N}(\mu_2, \tau_2^2)$ där

$$\mu_2 = \frac{\frac{\mu_1}{\tau_1^2} + \frac{x_2}{\sigma^2}}{\frac{1}{\tau_1^2} + \frac{1}{\sigma^2}} = \frac{\frac{\mu}{\tau^2} + \frac{x_1}{\sigma^2} + \frac{x_2}{\sigma^2}}{\frac{1}{\tau^2} + \frac{1}{\sigma^2} + \frac{1}{\sigma^2}} = \frac{\frac{\mu}{\tau^2} + \frac{x_1+x_2}{\sigma^2}}{\frac{1}{\tau^2} + \frac{2}{\sigma^2}}$$

eftersom

$$\frac{\mu_1}{\tau_1^2} = \left(\frac{\frac{\mu}{\tau^2} + \frac{x}{\sigma^2}}{\frac{1}{\tau^2} + \frac{1}{\sigma^2}}\right)\left(\frac{1}{\tau^2} + \frac{1}{\sigma^2}\right) = \frac{\mu}{\tau^2} + \frac{x}{\sigma^2}.$$

Vi får också att

$$\tau_2^2 = \frac{1}{\frac{1}{\tau^2} + \frac{2}{\sigma^2}}.$$

En rimlig ansats är därför att

$$\Theta \mid X_1, \ldots, X_n = x_1, \ldots, x_n \sim \mathrm{N}(\mu_n, \tau_n^2)$$

där

$$\mu_n = \frac{\frac{\mu}{\tau^2} + \frac{\sum_{i=1}^n x_i}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \qquad \tau_n^2 = \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}$$

Detta visas genom induktion på n där vi ser att

$$\begin{aligned} \mu_n &= \frac{\frac{\mu_{n-1}}{\tau_{n-1}^2} + \frac{x_n}{\sigma^2}}{\frac{1}{\tau_{n-1}^2} + \frac{1}{\sigma^2}} = \frac{\frac{\mu}{\tau^2} + \frac{\sum_{i=1}^{n-1} x_i}{\sigma^2} + \frac{x_n}{\sigma^2}}{\frac{1}{\tau^2} + \frac{(n-1)}{\sigma^2} + \frac{1}{\sigma^2}} = \frac{\frac{\mu}{\tau^2} + \frac{\sum_{i=1}^{n} x_i}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \\ \tau_n^2 &= \frac{1}{\frac{1}{\tau_{n-1}^2} + \frac{1}{\sigma^2}} = \frac{1}{\frac{1}{\tau^2} + \frac{n-1}{\sigma^2} + \frac{1}{\sigma^2}} = \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}. \end{aligned}$$

(c) Beräkningen av den aposterioriprediktiva fördelningen är densamma som för marginalfördelningen. I båda fallen har vi

$$Y \mid \Theta = \theta \sim \mathrm{N}(\theta, \sigma^2), \qquad \Theta \sim \mathrm{N}(\mu, \tau^2),$$

men i det aposterioriprediktiva fallet ersätter vi μ med μ_1 och τ^2 med τ_1^2. Vi vill alltså beräkna

$$f_Y(y) = \int_{-\infty}^{\infty} f_{Y|\Theta}(y \mid \theta) f_\Theta(\theta) d\theta.$$

Som innan kan vi arbeta med onormaliserade fördelningar men vi måste vara försiktiga då endast faktorer som inte beror på Θ kan tas utanför integralen. Vi har alltså

$$\begin{aligned}
f_Y(y) &= \int_{\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(y-\theta)^2} \frac{1}{\sqrt{2\pi\tau^2}} e^{-\frac{1}{2\tau^2}(\theta-\mu^2)^2} d\theta, \\
&= \frac{1}{\sqrt{4\pi\sigma^2\tau^2}} \int_{-\infty}^{\infty} e^{-\frac{y^2-2y\theta+\theta^2}{2\sigma^2}} e^{-\frac{\theta^2-2\theta\mu+\mu^2}{2\tau^2}} d\theta, \\
&= \frac{e^{-\frac{\mu^2}{2\tau^2}}}{\sqrt{4\pi\sigma^2\tau^2}} e^{-\frac{y^2}{2\sigma^2}} \int_{-\infty}^{\infty} e^{-\frac{\theta^2-2y\theta}{2\sigma^2}} e^{-\frac{\theta^2-2\theta\mu}{2\tau^2}} d\theta, \\
&\propto e^{-\frac{y^2}{2\sigma^2}} \int_{-\infty}^{\infty} e^{-\frac{1}{2\sigma^2\tau^2}(\tau^2\theta^2-2\tau^2\theta y+\sigma^2\theta^2-2\sigma^2\theta\mu)} d\theta, \\
&=\propto e^{-\frac{y^2}{2\sigma^2}} \int_{-\infty}^{\infty} e^{-\frac{\sigma^2+\tau^2}{2\sigma^2\tau^2}\left(\theta^2-2\frac{\tau^2 y+\sigma^2\mu}{\tau^2+\sigma^2}\theta\right)} d\theta, \\
&= e^{-\frac{y^2}{2\sigma^2}} \left(\int_{-\infty}^{\infty} e^{-\frac{\sigma^2+\tau^2}{2\sigma^2\tau^2}\left(\theta^2-2\left(\frac{\tau^2 y+\sigma^2\mu}{\tau^2+\sigma^2}\right)\theta+\left(\frac{\tau^2 y+\sigma^2\mu}{\tau^2+\sigma^2}\right)^2\right)} d\theta \right) e^{\frac{\sigma^2+\tau^2}{2\sigma^2\tau^2}\left(\frac{\tau^2 y+\sigma^2\mu}{\tau^2+\sigma^2}\right)^2}.
\end{aligned}$$

Integralen ovan är en onormaliserad täthetsfunktion för en normalfördelning, vilket ger

$$f_Y(y) \propto e^{-\frac{y^2}{2\sigma^2}} \left(\sqrt{\frac{2\sigma^2\tau^2}{\sigma^2+\tau^2}} \right) e^{\frac{\sigma^2+\tau^2}{2\sigma^2\tau^2}\left(\frac{\tau^2 y+\sigma^2\mu}{\tau^2+\sigma^2}\right)^2}$$

Integralens värde beror alltså inte på y och kan bakas in i normaliseringskonstanten. Vi förenklar detta vidare och får

$$\begin{aligned}
f_Y(y) &\propto e^{-\frac{y^2}{2\sigma^2}} e^{\frac{\sigma^2+\tau^2}{2\sigma^2\tau^2}\left(\frac{\tau^2 y+\sigma^2\mu}{\tau^2+\sigma^2}\right)^2}, \\
&= e^{-\frac{y^2}{2\sigma^2}} e^{\frac{\tau^4 y^2+2\tau^2\sigma^2 y\mu+\sigma^4\mu^2}{2\sigma^2\tau^2(\sigma^2+\tau^2)}}, \\
&= e^{\frac{-\sigma^2\tau^2 y^2+\tau^2\sigma^2 y\mu+\sigma^4\mu^2}{2\sigma^2\tau^2(\sigma^2+\tau^2)}}, \\
&\propto e^{\frac{-\sigma^2\tau^2 y^2+2\tau^2\sigma^2 y\mu}{2\sigma^2\tau^2(\sigma^2+\tau^2)}}
\end{aligned}$$

eftersom den sista termen inte beror på y. Med ytterligare förenkling och kvadratkomplettering får vi

$$\begin{aligned}
f_Y(y) &\propto e^{-\frac{y^2-2y\mu}{2(\sigma^2+\tau^2)}}, \\
&= e^{-\frac{y^2-2y\mu+\mu^2}{2(\sigma^2+\tau^2)}} e^{-\frac{\mu^2}{2(\sigma^2+\tau^2)}}, \\
&\propto e^{-\frac{(y-\mu)^2}{2\sigma^2+\tau^2}}.
\end{aligned}$$

Detta är en onormaliserad täthetsfunktion för $\mathrm{N}(\mu, \sigma^2 + \tau^2)$. För den aposterioriprediktiva fördelningen får vi då

$$Y \mid X = x \sim \mathrm{N}\left(\mu_1, \sigma^2 + \tau_1^2\right).$$

(d) Vi återvänder beräkningen för del (c) och kombinera denna med μ_n och τ_n^2 från del (b), vilket ger

$$Y \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{N}(\mu_n, \sigma^2 + \tau_n^2).$$

7.5. (a) Enligt formlerna vi tog fram i uppgift 7.4(b) har vi

$$\Theta \mid X = x \sim \mathrm{N}(\mu_n, \tau_n)$$

där

$$\mu_n = \frac{\frac{\mu}{\tau^2} + \frac{\sum_{i=1}^n x_i}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} = \frac{\frac{0}{4^2} + \frac{4.60}{1.6}}{\frac{1}{4^2} + \frac{5}{1.6}} \approx 0.9020,$$
$$\tau_n = \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} = \frac{1}{\frac{1}{4^2} + \frac{5}{1.6}} \approx 0.3137.$$

Vi har sedan att om $Y \perp\!\!\!\perp \boldsymbol{X} \mid \Theta$, $Y \mid \Theta = \theta \sim \mathrm{N}(\theta, \sigma^2)$ och $\Theta \sim \mathrm{N}(\mu, \tau^2)$ så har vi att

$$Y \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{N}(\mu_n, \sigma^2 + \tau_n^2) = \mathrm{N}(0.9020, 0.3137 + 1.6) = \mathrm{N}(0.9020, 1.9137).$$

Därför får vi

$$\begin{aligned} P(Y \geq 0 \mid \boldsymbol{X} = \boldsymbol{x}) &= 1 - P(Y \leq 0 \mid \boldsymbol{X} = \boldsymbol{x}), \\ &= 1 - \Phi\left(\frac{0 - 0.9020}{\sqrt{1.9137}}\right), \\ &= 1 - \Phi(-0.6520), \\ &= \Phi(0.6520), \\ &\approx 0.7422 \end{aligned}$$

enligt statstabellen.

(b) Generera data enligt beskrivningen, plotta histogrammet och skatta sedan stickprovsmedelvärde och stickprovsvarians från datan. Du kan sedan plotta täthetsfunktionen för en normalfördelningen med detta medelvärde och varians samt med histogrammet och täthetsfunktionen beräknad i del (a).

7.6. Från formelsamlingen har vi:

$$\mu = \frac{\alpha}{\alpha + \beta}, \quad \sigma^2 = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

Låt $c = \alpha + \beta$ beteckna summan av parametrarna

$$\Rightarrow \alpha = c\mu \quad , \quad \beta = c - \alpha = c(1-\mu)$$

Uttrycket for väntevärdet blir då

$$\mu = \frac{\alpha}{c}$$

M.h.a variansen kan vi hitta ett uttryck som skattar c:

$$\begin{aligned}
\sigma^2 &= \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)} \\
(\alpha+\beta+1) &= \frac{\alpha\beta}{\sigma^2(\alpha+\beta)^2} && (\alpha+\beta = c) \\
c+1 &= \frac{\alpha\beta}{\sigma^2 c^2} && (\alpha = c\mu) \\
c &= \frac{c\mu\cdot\beta}{\sigma^2\cdot c^2} - 1 \\
&= \frac{\mu\beta}{\sigma^2 c} - 1 && \left(\beta = c-\alpha, c = \frac{\alpha}{\mu}\right) \\
&= \frac{\mu\left(\frac{\alpha}{\mu} - \alpha\right)}{\sigma^2\left(\frac{\alpha}{\mu}\right)} - 1 \\
&= \frac{\mu\left(\frac{\alpha}{\mu} - \alpha\right)\cdot\frac{\mu}{\alpha}}{\sigma^2} - 1 \\
&= \frac{\mu(1-\mu)}{\sigma^2} - 1
\end{aligned}$$

Vi kan nu skatta parametrarna α och β m.h.a formlerna

$$\begin{aligned}
\alpha + \beta &= \frac{\mu(1-\mu)}{\sigma^2} - 1 \\
\alpha = (\alpha+\beta)\mu \quad , \quad \beta &= (\alpha+\beta)(1-\mu)
\end{aligned}$$

7.7. Låt $X_i = 1$ om frö ett överlever och $X_i = 0$ annars. Vi antar då att $X_i \mid \Theta = \theta \sim \text{Ber}(\theta)$ och $\Theta \sim \text{Beta}(\alpha, \beta)$ där $\text{E}[\Theta] = 0.7$ och $\text{Std}[\Theta] = 0.1$. Enligt resultatet i föregående uppgiften har vi att

$$\begin{aligned}
\alpha &= \left(\frac{(0.7)(1-0.7)}{0.1^2} - 1\right)(0.7) = 14, \\
\beta &= \left(\frac{(0.7)(1-0.7)}{0.1^2} - 1\right)(1-0.7) = 6,
\end{aligned}$$

så tar vi $\Theta \sim \text{Beta}(14, 6)$. Vi är givet datan $n\bar{x} = 4$ där $n = 10$. Enligt formelsamlingen har vi då att

$$\Theta \mid \boldsymbol{X} = \boldsymbol{x} \sim \text{Beta}(14+4, 6+10-4) = \text{Beta}(18, 12).$$

Vår uppdaterad förväntad sannolikhet är då aposterioriväntevärdet:

$$\mathrm{E}[\Theta \mid \boldsymbol{X} = \boldsymbol{x}] = \frac{18}{18+12} = 0.6.$$

7.8. (a) $\mathbf{X} \mid \Theta = \theta \sim \mathrm{Po}(\rho\theta)$ och $\Theta \sim \mathrm{Gamma}(\alpha, \lambda)$ ger

$$f_{\Theta|X}(\theta \mid x) \propto f_{X|\Theta}(x \mid \theta) f_{\Theta}(\theta) = \frac{(\rho\theta)^x}{x!} e^{-\rho\theta} \frac{\lambda^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\lambda\theta} \propto \theta^{\alpha+x-1} e^{-(\rho+\lambda)\theta}.$$

Så har vi $\Theta \mid X = x \sim \mathrm{Gamma}(\alpha + x, \rho + \lambda)$.

(b) Som i uppgift 4(b) kan vi använda faktumet att

$$f_{\Theta|X_1,\ldots,X_{n-1},X_n}(\theta \mid x_1, \ldots, x_{n-1}, x_n) \propto f_{X_n|\Theta}(x_n \mid \theta) f_{\Theta|X_1,\ldots,X_{n-1}}(\theta \mid x_1, \ldots, x_{n-1}).$$

Eftersom uppdateringsregeln som vi tog fram i del (a) för varje $X_i = x_i$ ser ut som

$$(\alpha, \lambda) \longmapsto (\alpha + x_i, \lambda + \rho_i)$$

är ett rimligt antagande att

$$\Theta \mid X_1, \ldots, X_n = x_1, \ldots, x_n \sim \mathrm{Gamma}\left(\alpha + \sum_{i=1}^n x_i, \lambda + \sum_{i=1}^n \rho_i\right).$$

Vi visar detta med hjälp av induktion. Vi såg redan i fallet $n = 1$ att resultatet håller. Anta nu att det håller för $n-1$, då har vi

$$\begin{aligned}
&f_{\Theta|X_1,\ldots,X_{n-1},X_n}(\theta \mid x_1, \ldots, x_{n-1}, x_n) \\
&\qquad \propto f_{X_n|\Theta}(x_n \mid \theta) f_{\Theta|X_1,\ldots,X_{n-1}}(\theta \mid x_1, \ldots, x_{n-1}), \\
&\qquad = \frac{(\rho_n\theta)^{x_n}}{x_n!} e^{-\rho_n\theta} \frac{\left(\lambda + \sum_{i=1}^{n-1} \rho_i\right)^{\alpha+\sum_{i=1}^n x_i}}{\Gamma\left(\alpha + \sum_{i=1}^n x_i\right)} \theta^{\left(\alpha+\sum_{i=1}^{n-1} x_i\right)-1} e^{-\left(\lambda+\sum_{i=1}^{n-1} \rho_i\right)\theta}, \\
&\qquad \propto \theta^{\alpha+\left(\sum_{i=1}^{n-1} x_i\right)+x_n-1} e^{-\left(\lambda+\left(\sum_{i=1}^{n-1} \rho_i\right)+\rho_n\right)\theta}, \\
&\qquad = \theta^{\left(\alpha+\sum_{i=1}^n x_i\right)-1} e^{-\left(\lambda+\sum_{i=1}^n \rho_i\right)\theta}.
\end{aligned}$$

Så har vi

$$\Theta \mid X_1, \ldots, X_n = x_1, \ldots, x_n \sim \mathrm{Gamma}\left(\alpha + \sum_{i=1}^n x_i, \lambda + \sum_{i=1}^n \rho_i\right),$$

vilket skulle visas.

(c) Vi har då

$$\begin{aligned}
\Theta \mid X_1, \ldots, X_n = x_1, \ldots, x_n &\sim \mathrm{Gamma}\left(\alpha + \sum_{i=1}^n x_i, \lambda + \sum_{i=1}^n \rho_i\right), \\
&= \mathrm{Gamma}(2 + 27, 3 + 23), \\
&= \mathrm{Gamma}(29, 26).
\end{aligned}$$

Enligt formelsamlingen har vi då

$$\mathrm{E}[\Theta \mid X_1, \ldots, X_n = x_1, \ldots, x_n] = 29/26 \approx 1.115.$$

(d) Här behöver vi den aposterioriprediktiva fördelningen för Y givet $\boldsymbol{X} = \boldsymbol{x}$. Allmänt kan vi se att om $Y \mid \Theta = \theta \sim \mathrm{Po}(\theta)$ och $\Theta \sim \mathrm{Gamma}(\alpha_1, \lambda_1)$ så får vi

$$\begin{aligned}
f_Y(y) &= \int_0^\infty f_{Y|\Theta}(y \mid \theta) f_\Theta(\theta) d\theta, \\
&= \int_0^\infty \frac{\theta^y}{y!} e^{-\theta} \frac{\lambda_1^{\alpha_1}}{\Gamma(\alpha_1)} \theta^{\alpha_1 - 1} e^{-\lambda_1 \theta} d\theta, \\
&= \frac{\lambda_1^{\alpha_1}}{y!\Gamma(\alpha_1)} \int_0^\infty \theta^{\alpha_1 + y - 1} e^{-(\lambda_1 + 1)\theta} d\theta, \\
&= \frac{\lambda_1^{\alpha_1}}{y!\Gamma(\alpha_1)} \frac{\Gamma(\alpha_1 + y)}{(\lambda_1 + 1)^{\alpha_1 + y}}, \\
&= \frac{(\alpha_1 + y - 1)!}{(\alpha_1 - 1)! y!} \lambda_1^{\alpha_1} \left(\frac{1}{\lambda_1 + 1} \right)^{\alpha_1 + y}, \\
&= \frac{(\alpha_1 + y - 1)!}{(\alpha_1 - 1)! y!} \left(\frac{1}{\lambda_1 + 1} \right)^{y} \left(\frac{\lambda_1}{\lambda_1 + 1} \right)^{\alpha_1}, \\
&= \frac{(\alpha_1 + y - 1)!}{(\alpha_1 - 1)! y!} \left(\frac{1}{\lambda_1 + 1} \right)^{y} \left(1 - \frac{1}{\lambda_1 + 1} \right)^{\alpha_1}.
\end{aligned}$$

Det följer från den sista formeln att $Y \sim \mathrm{NegBin}(\alpha_1, 1-(1/(\lambda_1+1))$. I vårt fall har vi att $\alpha_1 = 29$ och $\lambda_1 = 26$, vilket ger $Y \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{NegBin}(29, 1 - (1/26)) = \mathrm{NegBin}(29, 0.9630)$. Så har vi

$$P(Y = 0 \mid \boldsymbol{X} = \boldsymbol{x}) = \binom{29 + 0 - 1}{0} (0.037)^{29} (0.9630)^0 \approx 0.$$

7.9. (a) Av uppdateringsregeln för poissonfördelad data med gammafördelad parameter kan vi se att:

$$\begin{aligned}
\Theta \mid X &\sim \mathrm{Gamma}(2 + n\bar{x}, 3 + n) \\
&= \mathrm{Gamma}(2 + 27, 3 + 8) \\
&= \mathrm{Gamma}(29, 11)
\end{aligned}$$

$$\Rightarrow E[\Theta \mid X] = \frac{29}{11} \approx 2.636.$$

(b) Av exempel 7.8 i boken får vi att

$$Y \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{NegBin}\left(\alpha_n, \frac{\lambda_n}{\lambda_n + +1} \right)$$

där α_n och λ_n är parametrarna från aposteriorifördelningen. I vårt fall är $\alpha_n = 29$ och $\lambda_n = 11$. Sannolikheten för $Y = 0$ givet att Y är negativt binomialfördelad beräknas alltså:

$$\begin{aligned} P(Y=0) &= \binom{29+0-1}{0} \left(\frac{11}{12}\right)^{29} \left(1-\frac{11}{12}\right)^{0} \\ &= \left(\frac{11}{12}\right)^{29} \\ &\approx 0.0802 \end{aligned}$$

7.10. (a) Resultatet visas genom induktion: När $n = 1$ har vi

$$\sum_{i=1}^{n} X_i = X_1 \sim \text{Exp}(\theta) = \text{Gamma}(1, \theta).$$

Anta nu att resultatet håller för $n-1$. Vi har då $Y = \sum_{i=1}^{n-1} X_i \sim \text{Gamma}(n-1, \theta)$ och $X_n \sim \text{Exp}(\theta)$. Eftersom $X_1, \ldots, X_{n-1} \perp\!\!\!\perp X_n$ så har vi att $Y \perp\!\!\!\perp X_n$ och

$$f_{Y,X_n}(y, x_n) = f_Y(y) f_{X_n}(x_n) = \frac{\theta^{n-1}}{\Gamma(n-1)} y^{n-2} e^{-\theta y} \cdot \theta e^{-\theta x_n}.$$

Ta transformationen $g(y, x_n) = (y + x_n, x_n) = (u, v)$, vilken har invers:

$$g^{-1}(u, v) = (u - v, v).$$

Jacobideterminenten är då lika med 1. Så har vi att

$$\begin{aligned} f_{U,V}(u, v) &= f_Y(u - v) f_{X_n}(v) \cdot |J|, \\ &= \frac{\theta^{n-1}}{\Gamma(n-1)} (u-v)^{n-2} e^{-\theta(u-v)} \cdot \theta e^{-\theta v} \cdot 1, \\ &= \frac{\theta^{n}}{\Gamma(n-1)} (u-v)^{n-2} e^{-\theta u}. \end{aligned}$$

Vi beräknar då marginalfördelningen av $U = \sum_{i=1}^{n} X_i$:

$$\begin{aligned} f_U(u) &= \int_0^u f_{U,V}(u, v) dv, \\ &= \frac{\theta^n}{\Gamma(n-1)} e^{-\theta u} \int_0^u (u-v)^{n-2} dv, \\ &= \frac{\theta^n}{\Gamma(n-1)} e^{-\theta u} \int_0^u w^{n-2} dw, \qquad \text{(där vi tog } w = u - v\text{)} \\ &= \frac{\theta^n}{\Gamma(n-1)} e^{-\theta u} \cdot \frac{u^{n-1}}{n-1}, \\ &= \frac{\theta^n}{\Gamma(n)} u^{n-1} e^{-\theta u}, \end{aligned}$$

vilket skulle bevisas.

(b) Med hjälp av onormaliserade fördelningar ser vi att

$$\begin{aligned} f_{\Theta|Y}(\theta \mid y) &\propto f_{Y|\Theta}(y \mid \theta) f_{\Theta}(\theta), \\ &= \frac{\theta^{\beta}}{\Gamma(\beta)} y^{\beta-1} e^{-\theta y} \cdot \frac{\lambda^{\alpha}}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\lambda\theta}, \\ &\propto \theta^{\alpha+\beta-1} e^{-(\lambda+y)\theta}, \end{aligned}$$

vilket är den onormaliserade täthetsfunktionen för en Gamma($\alpha+\beta, \lambda+y$) fördelning. Dvs. $\Theta \mid Y = y \sim \text{Gamma}(\alpha+\beta, \lambda+y)$.

(c) Enligt formelsamlingen har vi att

$$\Theta \mid \boldsymbol{X} = \boldsymbol{x} \sim \text{Gamma}(\alpha+n, \lambda+n\bar{x}).$$

Enligt del (a) har vi att

$$Y = \sum_{i=1}^{n} X_i \sim \text{Gamma}(n, \theta).$$

Om vi tar $\beta = n$ i del (b) så har vi

$$\Theta \mid Y = y \sim \text{Gamma}(\alpha+\beta, \lambda+y) = \text{Gamma}(\alpha+n, \lambda+n\bar{x}),$$

dvs., de är densamma. Man kan tolka detta resultat som att aposteriorifördelningen bara beror på statistiken $\bar{X}$... mer om detta senare.

7.11. (a) Vi har att

$$\begin{aligned} I_x(\alpha, 1) &= \frac{\Gamma(\alpha+1)}{\Gamma(\alpha)\Gamma(1)} \int_0^x u^{\alpha-1}(1-u)^{1-1} du, \\ &= \frac{\alpha\Gamma(\alpha)}{\Gamma(\alpha)} \int_0^x u^{\alpha-1} du, \\ &= \alpha \frac{x^{\alpha}}{\alpha}, \\ &= x^{\alpha}. \end{aligned}$$

(b) Vi använder partialintegration och får

$$\begin{aligned}
I_x(\alpha,\beta) &= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\int_0^x u^{\alpha-1}(1-u)^{\beta-1}, \qquad \text{(differentiera } (1-u)^{\beta-1}\text{, integrera } u^{\alpha-1}\text{)},\\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\left(\left[\frac{u^\alpha}{\alpha}(1-u)^{\beta-1}\right]_0^x + \int_0^x \frac{u^\alpha}{\alpha}(\beta-1)(1-u)^{\beta-2}du\right),\\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\left(\frac{x^\alpha}{\alpha}(1-x)^{\beta-1} + \frac{\beta-1}{\alpha}\int_0^x u^\alpha(1-u)^{\beta-2}du\right),\\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\left(\frac{x^\alpha}{\alpha}(1-x)^{\beta-1} + \frac{\beta-1}{\alpha}\frac{\Gamma(\alpha+1)\Gamma(\beta-1)}{\Gamma(\alpha+\beta)}I_x(\alpha+1,\beta-1)\right),\\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\left(\frac{x^\alpha}{\alpha}(1-x)^{\beta-1} + \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}I_x(\alpha+1,\beta-1)\right),\\
&= I_x(\alpha+1,\beta-1) + \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\left(\frac{x^\alpha}{\alpha}(1-x)^{\beta-1}\right)
\end{aligned}$$

(c) Enligt del (b) så har vi

$$I_x(m,n) = I_x(m+1,n-1) + \frac{\Gamma(m+n)}{\Gamma(m)\Gamma(n)}\left(\frac{x^m}{m}(1-x)^{n-1}\right).$$

Vi kan fortsätta genom att applicera (b) på $I_x(m+1,n-1)$,
vilket ger

$$I_x(m,n) = \frac{\Gamma(m+n)}{\Gamma(m)\Gamma(n)}\left(\frac{x^m}{m}(1-x)^{n-1}\right) + \frac{\Gamma(m+n)}{\Gamma(m+1)\Gamma(n-1)}\left(\frac{x^{m+1}}{m+1}(1-x)^{n-2}\right) + I_x(m+2$$

osv. Vi kan alltså skriva

$$\begin{aligned}
I_x(m,n) &= \sum_{k=0}^{n-1}\frac{\Gamma(m+n)}{\Gamma(m+k)\Gamma(n-k)}\frac{x^{m+k}(1-x)^{n-k-1}}{m+k},\\
&= \sum_{k=0}^{n-1}\frac{\Gamma(m+n)}{\Gamma(m+k+1)\Gamma(n-k)}x^{m+k}(1-x)^{n-k-1},\\
&= \sum_{k=0}^{n-1}\binom{m+n-1}{m+k}x^{m+k}(1-x)^{n-k-1},
\end{aligned}$$

Med omskivningen $m+k \mapsto k$ får vi

$$I_x(m,n) = \sum_{k=m}^{m+n-1}\binom{m+n-1}{k}x^k(1-x)^{(m+n-1)-k}.$$

(d) Enligt binomialsatsen har vi

$$\sum_{k=0}^{m+n-1}\binom{m+n-1}{k}x^k(1-x)^{(m+n-1)-k} = (x+(1-x))^{m+n-1} = 1.$$

Med hjälp av del (c) så har vi

$$I_x(m,n) = 1 - \sum_{k=0}^{m-1} \binom{m+n-1}{k} x^k (1-x)^{(m+n-1)-k}.$$

7.12. (a) Enligt formelsamlingen har vi

$$\Theta \mid X_1, \ldots, X_n = x_1, \ldots, x_n \sim \text{Beta}(\alpha + n\bar{x}, \beta + n - n\bar{x})$$

för $X_1, \ldots, X_n \sim \text{Ber}(\theta) = \text{Bin}(1, \theta)$ betingat oberoende givet $\Theta \sim \text{Beta}(\alpha, \beta)$. För givna datan har vi då

$$\Theta \mid \boldsymbol{X} = \boldsymbol{x} \sim \beta(2, 4).$$

Med hjälp av formelsamlingen ser vi att

$$\text{E}[\Theta \mid \boldsymbol{X} = \boldsymbol{x}] = \frac{2}{2+4} = \frac{2}{6} = \frac{1}{3}.$$

(b) Eftersom $\Theta \mid \boldsymbol{X} = \boldsymbol{x} \sim \text{Beta}(\alpha_1, \beta_1)$ har

$$\begin{aligned} P(\Theta \leq \theta \mid \boldsymbol{X} = \boldsymbol{x}) &= \int_0^\theta \frac{\Gamma(\alpha_1 + \beta_1)}{\Gamma(\alpha_1)\Gamma(\beta_1)} \theta^{\alpha_1 - 1}(1-\theta)^{\beta_1 - 1} d\theta, \\ &= I_\theta(\alpha_1, \beta_1) \end{aligned}$$

så kan vi använda formler från föregående uppgift, dvs. vi vill beräkna $I_{0.25}(\alpha_1, \beta_1)$ där

$$\alpha_1 = 2, \beta_1 = 4$$

(enligt del (a)). Det lättaste valet är formeln i del (d) som ger

$$I_{0.25}(2,4) = 1 - \sum_{k=0}^{1} \binom{5}{k} (0.25)^k (1-0.25)^{5-k} = 1 - (0.25)^0(0.75)^5 - 5(0.25)^1(0.75)^4 \approx 0.367.$$

7.13. (a) Om antalet spårvagnar ät $N = n$ har vi att numrena är likformigt fördelade över den diskreta mängden $\{1, \ldots, n\}$. Dvs. vi har

$$f_{X|N}(x \mid n) = \begin{cases} 1/n & x = 1, \ldots, n \\ 0 & \text{annars} \end{cases}$$

där X är det observerade numret. Med $N \sim \text{Geom}(p)$ får vi därför

$$\begin{aligned} f_{N|X}(n \mid x) &\propto f_{X|N}(x \mid n) f_N(n), \\ &= \begin{cases} \frac{1}{n} p(1-p)^n & x = 1, \ldots, n \\ 0 & \text{annars} \end{cases} \\ &= \begin{cases} \frac{1}{n} p(1-p)^n & n = x, x+1, \ldots \\ 0 & \text{annars} \end{cases} \end{aligned}$$

För att bestämma sannolikhetsfunktionen söker vi alltså en konstant C så att

$$f_{N|X}(n \mid x) = \frac{C}{n} p(1-p)^n$$

för $n = x, x+1, \ldots$. Vi vet att summan över alla värden på n måste vara ett. Så får vi

$$\sum_{n=x}^{\infty} f_{N|X}(n \mid x) = \sum_{n=x}^{\infty} \frac{C}{n} p(1-p)^n = cp \sum_{n=x}^{\infty} \frac{(1-p)^n}{n} = 1.$$

För att utvärdera summan integrerar vi identiteten

$$\frac{1}{1-r} = \sum_{k=0}^{\infty} r^k$$

och får ut

$$\int_0^u \frac{1}{1-r} dr = \sum_{k=0}^{\infty} \int_0^u r^k dr,$$
$$-\log(1-u) = \sum_{k=1}^{\infty} \frac{u^k}{k}$$

Därför har vi att

$$\begin{aligned}
1 &= cp \sum_{n=x}^{\infty} \frac{(1-p)^n}{n}, \\
&= cp \left(\sum_{n=1}^{\infty} \frac{(1-p)^n}{n} - \sum_{n=1}^{x-1} \frac{(1-p)^n}{n} \right), \\
&= cp \left(-\log(1-(1-p)) - \sum_{n=1}^{x-1} \frac{(1-p)^n}{n} \right), \\
c &= p^{-1} \left(-\log(p) - \sum_{n=1}^{x-1} \frac{(1-p)^n}{n} \right)^{-1}
\end{aligned}$$

För $p = 0.01$ och $x = 56$ får vi $c \approx 201.9$ (m.h.a datorn). Det följer att

$$f_{N|X}(n \mid 56) = \frac{(201.9)}{n}(0.01)(0.99)^n = (2.019)\frac{(0.99)^n}{n}$$

för $n = 56, 57, \ldots$. Detta ger väntevärdet

$$\begin{aligned}
\mathrm{E}[N \mid X = 56] &= (2.019) \sum_{n=56}^{\infty} \frac{(0.99)^n}{n}, \\
&= (2.019) \left(\sum_{n=1}^{\infty} \frac{(0.99)^n}{n} - \sum_{n=1}^{55} \frac{(0.99)^n}{n} \right), \\
&= (2.019) \left(\frac{1}{1-0.99} - \frac{1-0.99^{55}}{1-0.99} \right), \\
&\approx 115.0.
\end{aligned}$$

(b) Observera att

$$\begin{aligned}
\mathrm{E}[N^2 \mid X = 56] &= (2.019) \sum_{n=56}^{\infty} n^2 \frac{(0.99)^n}{n}, \\
&= (2.019) \sum_{n=56}^{\infty} n(0.99)^n.
\end{aligned}$$

Denna summa kan beräkna genom att derivera identitetet

$$\frac{1}{1-r} = \sum_{k=0}^{\infty} r^k$$

med avseende på r. Detta ger oss

$$\sum_{k=0}^{\infty} k r^k = \frac{1}{(1-r)^2} - \frac{1}{1-r} = \frac{r}{(1-r)^2}.$$

I vårt fall har vi då

$$\begin{aligned}
\mathrm{E}[N^2 \mid X = 56] &= (2.019) \left(\sum_{k=0}^{\infty} n(0.99)^n - \sum_{k=0}^{55} n(0.99)^n \right), \\
&= (2.019) \left(\frac{0.99}{(1-0.99)^2} - \sum_{k=0}^{55} n(0.99)^n \right), \\
&\approx 17825.
\end{aligned}$$

Det följer att

$$\mathrm{Var}[N \mid X = 56] = \mathrm{E}[N^2 \mid X = 56] - \mathrm{E}[N \mid X = 56]^2 \approx 17825 - 115^2 = 4600$$

och

$$\mathrm{Std}[N \mid X = 56] \approx \sqrt{4600} \approx 67.8.$$

Vår skattning av N är alltså ganska osäker.

(c) En "likformig" aprioriförd elning för N ger en oegentlig fördelning för aposteriorifördelningen. En aprioriförd elning på formen $1/N$, däremot, ger en egentlig aposteriorifördelning men med oändligt väntevärde. Vi kan gå längre, med $1/N^k$ för större värden på k och får då ändligt aposteriorivä ntevärde (och ändlig aposteriorivarians för $k \geq 3$), men dessa aprioriförd elning kan inte längre anses som icke-informativa då vi starkt penaliserar större värden på N.

Det grundläggande problemet är att vi bara har en datapunkt och därför är det inte en bra idé att försöka använda en icke-informativ aprioriförd elning.

7.14. En icke-informativ aprioriförd elning ges av $f_\Theta(\theta) = 1$. Det följer att $\Theta \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{N}(\bar{x}, (2.1)/n)$. För den givna datan har vi $\bar{x} \approx 1.189$. Detta ger oss

$$\mathrm{E}[\Theta \mid \boldsymbol{x}] \approx 1.189.$$

7.15. Vi har att $X \mid \Theta = \theta \sim \mathrm{N}(0, \theta)$ där $\Theta \sim \mathrm{InvGamma}(2, 1)$. Eftersom InvGamma är den konjugerade aprioriförd elningen för variansen parametern i en normalförd elningen har vi att

$$\Theta \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{InvGamma}(2+(n/2), 1+(1/2)\sum_{i=1}^{n}(x_i-0)^2) \approx \mathrm{InvGamma}(4.5, 11.589)$$

(enligt formelsamlingen). Det följer att

$$\mathrm{E}[\Theta \mid \boldsymbol{X} = \boldsymbol{x}] \approx 8.564$$

och

$$\mathrm{Var}[\Theta \mid \boldsymbol{X} = \boldsymbol{x}] \approx 5.416$$

7.16. (a) $\Theta \sim \mathrm{Beta}(\alpha, \beta)$ och $\Theta \mid X = x \sim \mathrm{Beta}(\alpha + 1, \beta + x)$.

(b) $\Theta \sim \mathrm{Beta}(\alpha, \beta)$ och $\Theta \mid X = x \sim \mathrm{Beta}(\alpha + r, \beta + x)$.

(c) Paretoförd elningen

$$f_\Theta(\theta) = 1_{[a,+\infty)}(\theta)\frac{ka^k}{\theta^{k+1}}$$

och

$$f_{\Theta|X}(\theta \mid x) = 1_{[\max(a,x),+\infty)}(\theta)\frac{(k+1)\max(a,x)^{k+1}}{\theta^{k+2}}.$$

7.17. (a)

$$f_{Y|X}(y \mid x) = (\alpha+1)\frac{\Gamma(\beta+x+y)}{\Gamma(\beta+x)}\frac{\Gamma(\alpha+\beta+x+1)}{\Gamma(\alpha+\beta+x+y+2)}.$$

(b) Beta-negativa binomialfördelningen

$$f_{Y|X}(y \mid x) = \binom{r+y-1}{y} \frac{\Gamma(\alpha+\beta+r+x)}{\Gamma(\alpha+r)\Gamma(\beta+x)} \frac{\Gamma(\alpha+2r)\Gamma(\beta+x+y)}{\Gamma(\alpha+\beta+2r+x+y)}.$$

Observera att fördelningen i del (a) också är en beta-negativ binomialfördelning med $r = 1$.

(c)

$$f_{Y|X}(y \mid x) = \frac{k+1}{k+2} \begin{cases} \frac{1}{\max(a,x)}, & 0 \le y \le \max(a,x), \\ \frac{\max(a,x)^{k+1}}{y^{k+2}}, & y > \max(a,x). \end{cases}$$

(d) Läge–skala-t-fördelningen

$$\mathrm{t}\left(2\alpha+1, \mu, \frac{2}{2\alpha+1}\left(\beta + (x-\mu)^2/2\right)\right).$$