Lösningar

8.1. Generaliseringen av betafördelningen till k dimensioner kallas *Dirichletfördelningen*. För $k = 3$ har vi täthetsfunktionen

$$f_{X_1,X_2,X_3}(x_1, x_2, x_3) = \frac{\Gamma(\alpha_1 + \alpha_2 + \alpha_3)}{\Gamma(\alpha_1)\Gamma(\alpha_2)\Gamma(\alpha_3)} x_1^{\alpha_1 - 1} x_2^{\alpha_2 - 1} x_3^{\alpha_3 - 1},$$

för $0 < x_1, x_2, x_3 < 1, x_1 + x_2 + x_3 = 1$ och där $\alpha_1, \alpha_2, \alpha_3 > 0$ är konstanter.

(a) Visa att X_1, X_2 och X_3 är marginellt betafördelade samt bestäm deras parametrar α, β.

(b) Bestäm den betingade fördelningen $X_2 \mid X_1 = x_1$ och visa att för $W = X_2/(1 - X_1)$ har vi $W \mid X_1 = x_1 \sim \text{Beta}(\alpha_2, \alpha_3)$.

(c) Om $U = X_1/(X_1 + X_2)$, visa att $U \sim \text{Beta}(\alpha_1, \alpha_2)$.

(d) Visa att $\text{E}[X_1 X_2] = \frac{\alpha_1 \alpha_2}{(\alpha_1+\alpha_2+\alpha_3+1)(\alpha_1+\alpha_2+\alpha_3)}$ och beräkna $\text{Cov}[X, Y]$.

8.2. Det finns tre val i opinionsundersökningen: (1) Bush, (2) Dukakis och (3) Annan. Vi vill ta fram aposteriorifördelningen för andelen röstare som skulle rösta på varje alternativ om det var val samma dag. Eftersom datafördelningen är multinomialfördelningen är en naturlig aprioriförfördelningen Dirichletfördelningen.
Eftersom vi inte har någon vidare information om röstare tar vi två oberoende icke-informativa aprioriförfördelningar för andelarna innan debaten $\Theta^{(i)}$ och andelarna efter debaten $\Theta^{(e)}$. Vi väljer Laplacesaprioriförfördelning (den likformiga aprioriförfördelningen):

$$\Theta^{(i)} \sim \text{Dirichlet}(1, 1, 1) \qquad \Theta^{(e)} \sim \text{Dirichlet}(1, 1, 1).$$

Detta ger då aposteriorifördelningarna

$$\Theta^{(i)} \mid \boldsymbol{X}^{(i)} = \boldsymbol{x}^{(i)} \sim \text{Dirichlet}(1 + 294, 1 + 307, 1 + 38) = \text{Dirichlet}(295, 308, 39),$$
$$\Theta^{(e)} \mid \boldsymbol{X}^{(e)} = \boldsymbol{x}^{(e)} \sim \text{Dirichlet}(1 + 288, 1 + 332, 1 + 19) = \text{Dirichlet}(289, 33, 20).$$

Q_1 (resp. Q_2) är alltså andelen som föredrar Bush bland de som föredrar Bush eller Dukakis innan debaten (resp. efter debaten). Vi har alltså

$$Q_1 = \frac{\Theta_1^{(i)}}{\Theta_1^{(i)} + \Theta_2^{(i)}},$$
$$Q_2 = \frac{\Theta_1^{(e)}}{\Theta_1^{(e)} + \Theta_2^{(e)}}.$$

Från Uppgift 8.1 har vi

$$Q_1 \mid \boldsymbol{X}^{(i)} = \boldsymbol{x}^{(i)} \sim \text{Beta}(295, 308),$$
$$Q_2 \mid \boldsymbol{X}^{(e)} = \boldsymbol{x}^{(e)} \sim \text{Beta}(289, 333).$$

Eftersom betaparametrarna är positiva heltal kan vi använda simuleringsmetoderna från kapitel 1 för att generera utfall från $Q_2 - Q_1$ och beräknar approximativt

$$P(Q_2 - Q_1 \mid \boldsymbol{X}^{(i)} = \boldsymbol{x}^{(i)}, \boldsymbol{X}^{(e)} = \boldsymbol{x}^{(e)}) \approx 0.19.$$

8.3. (a) Den icke-informativa aprioriförde lningen för $X \mid \Theta_M = \theta_M, \Theta_V = \theta_v \sim \mathrm{N}(\theta_M, \theta_V)$ är

$$f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) \propto 1/\theta_V.$$

Enligt kursanteckningarna har vi att de marginella aposteriorifördelningarna är

$$\begin{aligned}
\Theta_{M,K} \mid \boldsymbol{X}_K = \boldsymbol{x}_K &\sim t(n_K - 1, \overline{k}, s_K^2/n_K), \\
\Theta_{S,K}^2 \mid \boldsymbol{X}_K = \boldsymbol{x}_K &\sim \mathrm{InvGamma}((n_K - 1)/2, (n_K - 1)s_K^2/2), \\
\Theta_{M,F} \mid \boldsymbol{X}_F = \boldsymbol{x}_F &\sim t(n_F - 1, \overline{f}, s_F^2/n_F), \\
\Theta_{S,F}^2 \mid \boldsymbol{X}_F = \boldsymbol{x}_F &\sim \mathrm{InvGamma}((n_F - 1)/2, (n_F - 1)s_F^2/2)
\end{aligned}$$

där $n_K = 32$, $n_F = 36$, $\overline{k} = 1.013$, $\overline{f} = 1.173$, $s_K = 0.24$ och $s_F = 0.20$. Det följer att

$$\begin{aligned}
\Theta_{M,K} \mid \boldsymbol{X}_K = \boldsymbol{x}_K &\sim t(31, 1.013, 0.0018), \\
\Theta_{S,K}^2 \mid \boldsymbol{X}_K = \boldsymbol{x}_K &\sim \mathrm{InvGamma}(15.5, 0.446), \\
\Theta_{M,F} \mid \boldsymbol{X}_F = \boldsymbol{x}_F &\sim t(35, 1.173, 0.0011), \\
\Theta_{S,F}^2 \mid \boldsymbol{X}_F = \boldsymbol{x}_F &\sim \mathrm{InvGamma}(17.5, 0.35)
\end{aligned}$$

(b) Detta fördelning och sannolikhet kan beskrivas med hjälp av simulering. Vi genererar oberoende utfall $[\theta_{M,K,i}, \theta_{M,F,i}]^T$ från $\Theta_{M,K} \mid \boldsymbol{X}_K = \boldsymbol{x}_K \sim t(31, 1.013, 0.0018)$ och $\Theta_{M,F} \mid \boldsymbol{X}_F = \boldsymbol{x}_F \sim t(35, 1.173, 0.0011)$ för $i = 1, \ldots, n$ för ett stort n. Sedan beräknar vi skillnaden $\theta_{M,F,i} - \theta_{M,K,i}$ för alla i. Vi kan plotta resultatens histogramm för att visualisera fördelningen. För att skatta sannolikheten vi låter r vara antalet i så att skillnaden är större än 0 och delas med n. Detta ger oss, exempelvis,

$$\mathrm{P}(\Theta_{\mathrm{M,F}} > \Theta_{\mathrm{M,K}} \mid \boldsymbol{X}_{\mathrm{K}} = \boldsymbol{x}_{\mathrm{K}}, \boldsymbol{X}_{\mathrm{F}} = \boldsymbol{x}_{\mathrm{F}}) \approx 0.998.$$

8.4. (a) Vi har att $\boldsymbol{X} \mid \boldsymbol{\Theta} = \boldsymbol{\theta} \sim \mathrm{Multi}(m, \boldsymbol{\theta})$ och $\boldsymbol{\Theta} \sim \mathrm{Dirichlet}(1, 1, 1, 1)$. Det följer enligt uppdateringsregeln att

$$\boldsymbol{\Theta} \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{Dirichlet}(1{+}2, 1{+}9, 1{+}11, 1{+}13) = \mathrm{Dirichlet}(3, 10, 12, 14).$$

Vi låter $\theta_0 = \theta_1 + \theta_2 + \theta_3 + \theta_4 = 39$. Enligt formelsamlingen har vi att

$$\mathrm{E}[\Theta_2 \mid \boldsymbol{X} = \boldsymbol{x}] = \frac{\theta_2}{\theta_0} = \frac{10}{39} \approx 0.256$$

och

$$\mathrm{Cov}[\Theta_2, \Theta_2 \mid \boldsymbol{X} = \boldsymbol{x}] = \frac{\theta_2(\theta_0 - \theta_2)}{\theta_0^2(\theta_0 + 1)} = \frac{(10)(39-10)}{39^2(39+1)} \approx 0.0048.$$

(b) Här letar vi efter en aposterioriprediktiva fördelning $\boldsymbol{Y} \mid \boldsymbol{X} = \boldsymbol{x}$ där $\boldsymbol{Y} \mid \Theta = \theta \sim \mathrm{Multi}(10, \boldsymbol{\theta})$ och $\boldsymbol{\Theta} \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{Dirichlet}(3, 10, 12, 14)$. Vi kan beräkna en analytiskt formel för den aposterioriprediktiva fördelningen:

$$\begin{aligned}
f_{\boldsymbol{Y}|\boldsymbol{X}}(\boldsymbol{y} \mid \boldsymbol{x}) &= \int f_{\boldsymbol{Y}|\boldsymbol{\Theta}}(\boldsymbol{y} \mid \boldsymbol{\theta}) f_{\boldsymbol{\Theta}|\boldsymbol{X}}(\boldsymbol{\theta} \mid \boldsymbol{x}) d\boldsymbol{\theta}, \\
&= \int \frac{10!}{y_1!y_2!y_3!y_4!} \theta_1^{y_1}\theta_2^{y_2}\theta_3^{y_3}\theta_4^{y_4} \cdot \frac{\Gamma(39)}{\Gamma(3)\Gamma(10)\Gamma(12)\Gamma(14)} \theta_1^2\theta_2^9\theta_3^{11}\theta_4^{13} d\boldsymbol{\theta}, \\
&= \frac{10!}{y_1!y_2!y_3!y_4!} \cdot \frac{\Gamma(39)}{\Gamma(3)\Gamma(10)\Gamma(12)\Gamma(14)} \int \theta_1^{y_1+2}\theta_2^{y_2+9}\theta_3^{y_3+11}\theta_4^{y_4+13} d\boldsymbol{\theta}, \\
&= \frac{10!}{y_1!y_2!y_3!y_4!} \cdot \frac{\Gamma(39)}{\Gamma(3)\Gamma(10)\Gamma(12)\Gamma(14)} \cdot \frac{\Gamma(y_1+3)\Gamma(y_2+10)\Gamma(y_3+12)\Gamma(y_4+14)}{\Gamma(39+y_1+y_2+y_3+y_4)}.
\end{aligned}$$

Väntevärdet $\mathrm{E}[\boldsymbol{Y} \mid \boldsymbol{X} = \boldsymbol{x}]$ ges då av

$$\sum_{[y_1,y_2,y_3,y_4]^T : \sum_i y_i = 10} \boldsymbol{y} \cdot \frac{10!}{y_1!y_2!y_3!y_4!} \cdot \frac{\Gamma(39)}{\Gamma(3)\Gamma(10)\Gamma(12)\Gamma(14)} \cdot \frac{\Gamma(y_1+3)\Gamma(y_2+10)\Gamma(y_3+12)\Gamma(y_4+}{\Gamma(39+y_1+y_2+y_3+y_4)}$$

men detta kan vara svårt att beräkna. Istället kan vi generera slumpmassiga utfall $\boldsymbol{\theta}_1, \ldots, \boldsymbol{\theta}_n$ från aposteriorifördelningen $\boldsymbol{\Theta} \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{Dirichlet}(3, 10, 12, 14)$ och då genererar vi ett utfall $\boldsymbol{y}_i$ från $\boldsymbol{Y} \mid \boldsymbol{\Theta} = \boldsymbol{\theta}_i$ för varje $\boldsymbol{\theta}_i$. Givet ett stort n kan vi använda dessa utfall för att få en bra skattning av $\mathrm{E}[\boldsymbol{Y} \mid \boldsymbol{X} = \boldsymbol{x}]$ samt $\mathrm{Var}[\boldsymbol{Y} \mid \boldsymbol{X} = \boldsymbol{x}]$.

8.5. (a) Vi kan anta att antalet cyklar (c) samt antalet andra fordon (a) är Poissonfördelade med parameter $\Theta_Y^{(c)}$ respektive $\Theta_Y^{(a)}$ för vägar med cykelbanor. Vi får då

$$\begin{aligned}
U_{Y,i}^{(c)} \mid \Theta_Y^{(c)} = \theta_Y^{(c)} &\sim \mathrm{Po}(\theta_Y^{(c)}), \\
U_{Y,i}^{(a)} \mid \Theta_Y^{(a)} = \theta_Y^{(a)} &\sim \mathrm{Po}(\theta_Y^{(a)})
\end{aligned}$$

för alla $i = 1, \ldots, 10$ där $U_{Y,i}^{(c)}$ och $U_{Y,i}^{(a)}$ är antalet cyklar respektive antalet andra fordon på den i:te vägen.
På samma sätt har vi för vägar utan cykelbanor parametrarna $\Theta_Z^{(c)}$ och $\Theta_Z^{(a)}$ med datafördelningar

$$\begin{aligned}
U_{Z,i}^{(c)} \mid \Theta_Z^{(c)} = \theta_Z^{(c)} &\sim \mathrm{Po}(\theta_Z^{(c)}), \\
U_{Z,i}^{(a)} \mid \Theta_Z^{(a)} = \theta_Z^{(a)} &\sim \mathrm{Po}(\theta_Z^{(a)})
\end{aligned}$$

för $i = 1, \ldots, 8$. De sökta andelarna är då

$$Y_i = \frac{U_{Y,i}^{(c)}}{U_{Y,i}^{(c)} + U_{Y,i}^{(a)}} \qquad \text{och} \qquad Z_i = \frac{U_{Z,i}^{(c)}}{U_{Z,i}^{(c)} + U_{Z,i}^{(a)}}.$$

(b) Från datan ser det ut som antalet cyklar ligger runt 10 medan antalet bilar ligger runt 100. Vi ta aprioriväntevärdena att vara 10 respective 100 och använder den naturliga konjugerade aprioriFördelningen för Poissonfördelningen:

$$\begin{aligned}
\Theta_Y^{(c)} &\sim \text{Gamma}(10, 1), \\
\Theta_Y^{(a)} &\sim \text{Gamma}(100, 1), \\
\Theta_Z^{(c)} &\sim \text{Gamma}(10, 1), \\
\Theta_Z^{(a)} &\sim \text{Gamma}(100, 1).
\end{aligned}$$

Vi antar vidare att alla dessa variabler är oberoende.

(c) Aposterioriförderlningarna blir då

$$\begin{aligned}
\Theta_Y^{(c)} \mid U_Y^{(c)} = u_Y^{(c)} &\sim \text{Gamma}(10 + 212, 1 + 10) = \text{Gamma}(222, 11), \\
\Theta_Y^{(a)} \mid U_Y^{(a)} = U_Y^{(a)} &\sim \text{Gamma}(100 + 948, 1 + 10) = \text{Gamma}(1048, 11), \\
\Theta_Z^{(c)} \mid U_Z^{(c)} = u_Z^{(c)} &\sim \text{Gamma}(10 + 52, 1 + 8) = \text{Gamma}(62, 9), \\
\Theta_Z^{(a)} \mid U_Z^{(a)} = u_Z^{(a)} &\sim \text{Gamma}(100 + 647, 1 + 8) = \text{Gamma}(747, 9).
\end{aligned}$$

(d) Här kan vi använda lagen om total förväntan:

$$\begin{aligned}
\mu_Y &= \text{E}[Y_i \mid \Theta_Y], \\
&= \text{E}\left[\frac{U_{Y,i}^{(c)}}{U_{Y,i}^{(c)} + U_{Y,i}^{(a)}} \mid \Theta_Y^{(c)}, \Theta_Y^{(a)} \right], \\
&= \text{E}\left[\text{E}\left[\frac{U_{Y,i}^{(c)}}{U_{Y,i}^{(c)} + U_{Y,i}^{(a)}} \mid U_{Y,i}^{(c)} + U_{Y,i}^{(a)}, \Theta_Y^{(c)}, \Theta_Y^{(a)} \right] \mid \Theta_Y^{(c)}, \Theta_Y^{(a)} \right], \\
&= \text{E}\left[\frac{1}{U_{Y,i}^{(c)} + U_{Y,i}^{(a)}} \text{E}\left[U_{Y,i}^{(c)} \mid U_{Y,i}^{(c)} + U_{Y,i}^{(a)}, \Theta_Y^{(c)}, \Theta_Y^{(a)} \right] \mid \Theta_Y^{(c)}, \Theta_Y^{(a)} \right], \\
&= \text{E}\left[\frac{1}{U_{Y,i}^{(c)} + U_{Y,i}^{(a)}} \cdot (U_{Y,i}^{(c)} + U_{Y,i}^{(a)}) \cdot \frac{\Theta_Y^{(c)}}{\Theta_Y^{(c)} + \Theta_Y^{(a)}} \mid \Theta_Y^{(c)}, \Theta_Y^{(a)} \right]
\end{aligned}$$

eftersom $U \sim \text{Po}(\lambda)$ och $V \sim \text{Po}(\mu)$ uppfyller $U \mid U + V = n \sim$

$\text{Bin}(n, \lambda/(\lambda+\mu))$ för $U \perp\!\!\!\perp V$ eftersom

$$\begin{aligned} f_{U|U+V}(u \mid n) &= \frac{f_{U,U+V}(u,n)}{f_{U+V}(n)}, \\ &= \frac{f_{U,V}(u, n-u) \cdot |1|}{f_{U+V}(n)}, \\ &= \frac{\frac{\lambda^u}{u!}e^{-\lambda}\frac{\mu^{n-u}}{(n-u)!}e^{-\mu}}{\frac{(\lambda+\mu)^n}{n!}e^{-\lambda-\mu}}, \\ &= \frac{n!}{u!(n-u)!}\left(\frac{\lambda}{\lambda+\mu}\right)^u\left(\frac{\mu}{\lambda+\mu}\right)^{n-u}. \end{aligned}$$

Vi har alltså att

$$\mu_Y = \frac{\Theta_Y^{(c)}}{\Theta_Y^{(c)} + \Theta_Y^{(a)}}$$

och på samma sätt

$$\mu_Z = \frac{\Theta_Z^{(c)}}{\Theta_Z^{(c)} + \Theta_Z^{(a)}}.$$

Genom att simulera 10000 utfall av μ_Y och μ_Z skattar vi att

$$P(\mu_Z \geq 2\mu_Y \mid \text{data}) \approx 0.668.$$

8.6. (a) Vi beräknar aposteriorifördelningen enligt formeln i kursanteckningarna. Detta ger oss

$$\Theta_M, \Theta_V \sim \text{NInvGamma}(-0.27, 9, 6, 14.2).$$

(b) Vi vill beräkna $P(\Theta_M < 0, \Theta_V > 1 \mid \boldsymbol{X} = \boldsymbol{x})$ vilket inte är möjligt att göra analytiskt. Vi simulerar därför 10000 utfall från aposteriorifördelningen i del (a) och beräkna andelen där $\theta_M < 0$ och $\theta_V > 1$. Vi får då

$$P(\Theta_M < 0, \Theta_V > 1 \mid \boldsymbol{X} = \boldsymbol{x}) \approx 0.73.$$

8.7. (a) Vi har alltså att

$$\boldsymbol{X} \mid \boldsymbol{\Theta} = \boldsymbol{\theta} \sim \text{N}(\boldsymbol{\theta}, \Sigma) \qquad \boldsymbol{\Theta} \sim \text{N}(\mu_0, \Lambda_0)$$

där Σ är en känd $m \times m$ matris (positivt definit). Detta ger

$$\begin{aligned} f_{\boldsymbol{X}|\boldsymbol{\Theta}}(\boldsymbol{x} \mid \boldsymbol{\theta}) &\propto e^{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\theta})^{\text{T}}\Sigma^{-1}(\boldsymbol{x}-\boldsymbol{\theta})}, \\ f_{\boldsymbol{\Theta}}(\boldsymbol{\theta}) &\propto e^{-\frac{1}{2}(\boldsymbol{\theta}-\mu_0)^{\text{T}}\Lambda_0^{-1}(\boldsymbol{\theta}-\mu_0)} \end{aligned}$$

så att

$$f_{\boldsymbol{\Theta}|\boldsymbol{X}}(\boldsymbol{\theta} \mid \boldsymbol{x}) \propto e^{-\frac{1}{2}((\boldsymbol{x}-\boldsymbol{\theta})^{\text{T}}\Sigma^{-1}(\boldsymbol{x}-\boldsymbol{\theta})+(\boldsymbol{\theta}-\mu_0)^{\text{T}}\Lambda_0^{-1}(\boldsymbol{\theta}-\mu_0))}$$

Uttrycket inom parentes kan nu skrivas som

$$(\boldsymbol{x}-\boldsymbol{\theta})^{\mathrm{T}}\Sigma^{-1}(\boldsymbol{x}-\boldsymbol{\theta})+(\boldsymbol{\theta}-\mu_0)^{\mathrm{T}}\Lambda_0^{-1}(\boldsymbol{\theta}-\mu_0)$$
$$=$$
$$\boldsymbol{\theta}^{\mathrm{T}}(\Lambda_0^{-1}+\Sigma^{-1})\boldsymbol{\theta}-\boldsymbol{\theta}^{\mathrm{T}}(\Lambda_0^{-1}\mu_0+\Sigma^{-1}\boldsymbol{x})-(\Lambda_0^{-1}\mu_0+\Sigma^{-1}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{\theta}+\boldsymbol{x}^{\mathrm{T}}\Sigma^{-1}\boldsymbol{x}+\mu_0^{\mathrm{T}}\Lambda_0^{-1}\mu_0.$$

Eftersom vi arbetar med den onormaliserade fördelningen kan vi tappa konstanterna i $\boldsymbol{\theta}$ som ger oss

$$\boldsymbol{\theta}^{\mathrm{T}}(\Lambda_0^{-1}+\Sigma^{-1})\boldsymbol{\theta}-\boldsymbol{\theta}^{\mathrm{T}}(\Lambda_0^{-1}\mu_0+\Sigma^{-1}\boldsymbol{x})-(\Lambda_0^{-1}\mu_0+\Sigma^{-1}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{\theta}.$$

Vi lägger till följande konstant i $\boldsymbol{\theta}$:

$$(\Lambda_0^{-1}\mu_0+\Sigma^{-1}\boldsymbol{x})^{\mathrm{T}}(\Lambda_0^{-1}+\Sigma^{-1})^{-\mathrm{T}}(\Lambda_0^{-1}+\Sigma^{-1})(\Lambda_0^{-1}+\Sigma^{-1})^{-1}(\Lambda_0^{-1}\mu_0+\Sigma^{-1}\boldsymbol{x}),$$

vilket kompletterar kvadraten och ger oss

$$(\boldsymbol{\theta}-(\Lambda_0^{-1}+\Sigma^{-1})^{-1}(\Lambda_0^{-1}\mu_0+\Sigma^{-1}\boldsymbol{x}))^{\mathrm{T}}(\Lambda_0^{-1}+\Sigma^{-1})(\boldsymbol{\theta}-(\Lambda_0^{-1}+\Sigma^{-1})^{-1}(\Lambda_0^{-1}\mu_0+\Sigma^{-1}\boldsymbol{x})).$$

Stoppar vi in detta i exponenten får vi det sökta resultatet.

(b) Nu har vi istället

$$f_{\boldsymbol{X}|\boldsymbol{\Theta}}(\boldsymbol{x}\mid\boldsymbol{\theta})\propto\frac{1}{\sqrt{\det(\boldsymbol{\theta})}}e^{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\theta}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})}$$
$$f_{\boldsymbol{\Theta}}(\boldsymbol{\theta})\propto\frac{1}{\det(\boldsymbol{\theta})^{(v_0+m+1)/2}}e^{-\frac{1}{2}\psi_0\boldsymbol{\theta}^{-1}}$$

Eftersom $(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\theta}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})$ är en skalär kan vi skriva

$$\begin{aligned}(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\theta}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})&=\mathrm{tr}((\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\theta}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})),\\&=\mathrm{tr}((\boldsymbol{x}-\boldsymbol{\mu})(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\theta}^{-1}).\end{aligned}$$

Detta ger då

$$f_{\boldsymbol{\Theta}|\boldsymbol{X}}(\boldsymbol{\theta}\mid\boldsymbol{x})\propto\frac{1}{\det(\boldsymbol{\theta})^{(v_0+1+m+1)/2}}e^{-\frac{1}{2}\mathrm{tr}((\psi_0+(\boldsymbol{x}-\boldsymbol{\mu})(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}})\boldsymbol{\theta}^{-1})}$$

vilket ger den sökta fördelningen.

(c) en massa beräkningar...liksom ovan.