Lösningar

10.1. Vi vill ha först täthetsfunktionen för $X = WY$:

$$\begin{aligned} F_X(x) &= P(X \leq x), \\ &= \begin{cases} P(W = -1, Y \geq -x) & x \leq 0 \\ P(W = -1, Y \leq +\infty) + P(W = 1, Y \leq x) & x > 0 \end{cases} \\ &= \begin{cases} P(W = -1, Y \geq -x) & x \leq 0 \\ P(W = -1) + P(W = 1, Y \leq x) & x > 0 \end{cases} \\ &= \begin{cases} \frac{1}{2}(1 - F_Y(-x)) & x \leq 0 \\ \frac{1}{2} + \frac{1}{2}F_Y(x) & x > 0. \end{cases} \end{aligned}$$

Eftersom $Y \sim \text{Exp}(\lambda)$ ser vi att

$$f_X(x) = \frac{\lambda}{2} e^{-\lambda|x|}$$

när vi differentierar båda komponenter av $F_X(x)$ ovan m.a.p. x.
Vi beräknar då

$$M(\lambda) = \sup_x \frac{\frac{1}{\sqrt{2\pi}} e^{-x^2/2}}{\frac{\lambda}{2} e^{-\lambda|x|}}$$

som en funktion av λ. För att göra detta vill vi maximisera

$$\begin{aligned} f(x) &= -x^2/2 + \lambda|x|, \\ &= \begin{cases} -x^2/2 + \lambda x & x \geq 0 \\ -x^2/2 - \lambda x & x < 0 \end{cases} \end{aligned}$$

I det första fallet har vi derivatan $-x + \lambda$, vilket betyder att funktionen har maximat på $\lambda = x$ när $x \geq 0$. På samma sätt har vi maximat på $\lambda = -x$ när $x < 0$.
Så har vi att

$$M(\lambda) = \frac{\frac{1}{\sqrt{2\pi}} e^{-\lambda^2/2}}{\frac{\lambda}{2} e^{-\lambda^2}} = \frac{2}{\lambda\sqrt{2\pi}} e^{\lambda^2/2}.$$

Det effektivaste valet för λ ges av värdet som minimiserar $M(\lambda)$ eftersom detta betyder att kandidatfunktionen är närmaste till målfunktionen. För att hitta det globala minimat tar vi derivatan av $\log(M(\lambda))$ med avseende på λ:

$$\begin{aligned} \frac{d}{d\lambda} \log(M(\lambda)) &= \frac{d}{d\lambda} \left(-\log(\lambda) + \frac{\lambda^2}{2} \right), \\ &= -\frac{1}{\lambda} + \lambda. \end{aligned}$$

Det följer att $\lambda = 1$ är minimat över alla möjliga λ (dvs. i intervallet $(0, \infty)$).

10.2. (a) Se jupyter notebook.

(b) Vi vill approximera två integraler:

$$\int_{\mathbb{R}} \frac{\theta}{1+\theta^2} e^{-(1-\theta)^2/2} d\theta = \int_{\mathbb{R}} \theta f_\Theta(\theta) f_{X|\Theta}(1 \mid \theta) d\theta = \int_{\mathbb{R}} h_1(\theta) f_\Theta(\theta) d\theta$$

och

$$\int_{\mathbb{R}} \frac{1}{1+\theta^2} e^{-(1-\theta)^2/2} d\theta = \int_{\mathbb{R}} f_\Theta(\theta) f_{X|\Theta}(1 \mid \theta) d\theta = \int_{\mathbb{R}} h_2(\theta) f_\Theta(\theta) d\theta$$

där vi låter

$$h_1(\theta) = \theta f_{X|\Theta}(1 \mid \theta) = \theta e^{-(1-\theta)^2/2}$$
$$h_2(\theta) = f_{X|\Theta}(1 \mid \theta) = e^{-(1-\theta)^2/2}.$$

Vi kan då genererar slumpmässiga utfall från $f_\Theta(\theta)$ m.h.a python eftersom $\Theta \sim t(1)$ och använder de simulerade utfallen för att approximera $\mathrm{E}[h_1(\Theta)]$ och $\mathrm{E}[h_2(\Theta)]$ genom att beräkna stickprovsmedelvärdet för $h_1(\Theta)$ och $h_2(\Theta)$ för utfallen. Då tar vi kvoten och få att aposterioriväntevärdet är ≈ 0.55.

(c) I detta fall tar vi kandidatfunktionen att vara täthetsfunktionen av ett $t(1)$ variabel. När vi plottar denna täthetsfunktion tillsamman med den onormaliserade täthetsfunktionen för aposterioritäthetsfunktion (målfunktionen) ser vi att ett bra val för skalparametern m är $m = 3.25$. När vi kör med förkastelsen metoden för $m = 3.25$ kommer vi att få slumpmässiga utfall från den onormaliserade fördelningen. I jupyter notebook skattar vi normaliseringkonstanten m.h.a. simulerade datan och kommer fram till ett aposterioriväntevärdet av ≈ 0.55.

10.3. (a) För att approximera $P(Z > 2)$ m.h.a. Monte-Carlo metoden genererar vi flera slumpmässiga utfall från en $\mathrm{N}(0, 1)$-fördelning med hjälp av Python och beräknar andelen som är större än 2. Detta ger oss $P(Z > 2) \approx 0.025$.

(b) I detta fall använder vi Python för att genererar flera slumpmässiga utfall från en $\mathrm{Gamma}(1, 1)$-fördelning och beräknar andelen som är större än 3.7. Detta ger oss en sannolikhet av ≈ 0.025.

För att beräkna värdet a så att $P(X > a) = 0.025$ noterar vi att $f_X(x) = e^{-x}$. Så har vi att

$$\begin{aligned} P(X > 1) &= \int_a^\infty e^{-x} dx, \\ &= e^{-a}. \end{aligned}$$

Vi söker a så att $0.025 = e^{-a}$ och därför ta $a = -\log(0.025) \approx 3.68$.

(c)

10.4. Vi har tidigare sett den icke-informativa fördelningen för lägesparametern Θ som ges av $f_\Theta(\theta) \propto 1$. Eftersom denna fördelning är oegentlig kan den skapa problem i vissa sammanhang och vi kan då välja att approximera denna med den egentliga fördelningen $\mathrm{U}(-A, A)$ för något $A > 0$.
Låt nu $X \mid \Theta = \theta \sim \mathrm{N}(\theta, 1)$ och $\Theta \sim \mathrm{U}(-10, 10)$. Använd förkastelsemetoden för att beräkna aposterioriväntevärdet för observationerna $x = 1$, $x = 3$, $x = 9$, $x = 11$ och $x = 13$. Tolka resultaten. Vad händer när $x \to +\infty$?

10.5. (a) Antag att vi kan simulera från $X \sim \mathrm{Gamma}(\alpha, 1)$. Eftersom

$$f_X(x) = \frac{1}{\Gamma(\alpha)} x^{\alpha-1} e^{-x}$$

har vi att för $Y = \frac{1}{\lambda} X$ så gäller

$$\begin{aligned} f_Y(y) &= f_X(\lambda y) \left| \frac{d}{dy} \lambda y \right|, \\ &= \frac{1}{\Gamma(\alpha)} \lambda^{\alpha-1} y^{\alpha-1} e^{-\lambda y} \cdot \lambda, \\ &= \frac{\lambda^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\lambda y}; \end{aligned}$$

dvs. $Y \sim \mathrm{Gamma}(\alpha, \lambda)$. Så vi kan använda $\mathrm{Gamma}(\alpha, 1)$ för att simulera från $\mathrm{Gamma}(\alpha, \lambda)$.

(b) Vi har alltså

$$f_X(x) = \frac{1}{\Gamma(\alpha)} x^{\alpha-1} e^{-x} \qquad \text{och} \qquad f_V(v) = \beta e^{-\beta v}$$

vilket ger

$$m = \sup_{x>0} \frac{f_X(x)}{f_V(x)} = \sup_{x>0} \frac{\frac{1}{\Gamma(\alpha)} x^{\alpha-1} e^{-x}}{\beta e^{-\beta x}} = \frac{1}{\beta \Gamma(\alpha)} \sup_{x>0} x^{\alpha-1} e^{(\beta-1)x}.$$

Vi vill därför maximera funktionen $g(x) = x^{\alpha-1} e^{(\beta-1)x}$ för $x > 0$. Om vi deriverar m.a.p. x får vi

$$\begin{aligned} \frac{d}{dx} \left(x^{\alpha-1} e^{(\beta-1)x} \right) &= (\alpha-1) x^{\alpha-2} e^{(\beta-1)x} + (\beta-1) x^{\alpha-1} e^{(\beta-1)x}, \\ &= x^{\alpha-2} e^{(\beta-1)x} (\alpha - 1 + (\beta-1)x). \end{aligned}$$

Sätter vi derivaten till noll får vi

$$x = -\frac{\alpha-1}{\beta-1}$$

eftersom $x \neq 0$.
Från lydelsen har vi att $\alpha > 1$, så $x > 0$ om och endast om $\beta < 1$. Om $\beta \geq 1$ ser vi att derivaten är strikt positiv och $x^{\alpha-1}e^{(\beta-1)x} \longrightarrow +\infty$ då $x \longrightarrow +\infty$.
Å andra sidan om $\beta \in (0,1)$ har vi att

$$x^{\alpha-1}e^{(\beta-1)x} \longrightarrow 0 \qquad \text{då} \qquad x \longrightarrow +\infty.$$

Så har vi ett maximum i $x = -\frac{\alpha-1}{\beta-1}$ med värde

$$\left(-\frac{\alpha-1}{\beta-1}\right)^{\alpha-1} e^{-(\alpha-1)}.$$

Detta ger då

$$m = \frac{1}{\Gamma(\alpha)} e^{-(\alpha-1)}(\alpha-1)^{\alpha-1} \frac{1}{\beta(1-\beta)^{\alpha-1}}.$$

För att minimera m vill vi nu ta β så att

$$\frac{1}{\beta(1-\beta)^{\alpha-1}}$$

blir så litet som möjligt. Detta är ekvivalent med att maximera $\beta(1-\beta)^{\alpha-1}$. Med hjälp av derivaten av denna funktion m.a.p. β hitta vi maximat i $\beta = 1/\alpha$.
Det följer att vi vill ha

$$m = \frac{1}{\Gamma(\alpha)} e^{-(\alpha-1)}(\alpha-1)^{\alpha-1} \frac{1}{\frac{1}{\alpha}\left(\frac{\alpha-1}{\alpha}\right)^{\alpha-1}} = \frac{\alpha^\alpha}{\Gamma(\alpha)} e^{-(\alpha-1)}.$$

(c) VI har fortfarande

$$f_X(x) = \frac{1}{\Gamma(\alpha)} x^{\alpha-1} e^{-x}$$

men kandidatfördelningen ges nu av

$$f_V(v) = \frac{\beta^{\lfloor\alpha\rfloor}}{\Gamma(\lfloor\alpha\rfloor)} x^{\lfloor\alpha\rfloor-1} e^{-\beta x}$$

Vi får då

$$\begin{aligned} m &= \sup_{x>0} \frac{f_X(x)}{f_V(x)}, \\ &= \sup_{x>0} \frac{\frac{1}{\Gamma(\alpha)} x^{\alpha-1} e^{-x}}{\frac{\beta^{\lfloor\alpha\rfloor}}{\Gamma(\lfloor\alpha\rfloor)} x^{\lfloor\alpha\rfloor-1} e^{-\beta x}}, \\ &= \frac{\Gamma(\lfloor\alpha\rfloor)}{\Gamma(\alpha)} \sup_{x>0} x^{\alpha-\lfloor\alpha\rfloor} e^{(\beta-1)x}. \end{aligned}$$

Uttrycket i supremum är detsamma som i del (b) men där α har ersatts med $\alpha - \lfloor\alpha\rfloor$. Det följer alltså att

$$\begin{aligned}\sup_{x>0} x^{\alpha-\lfloor\alpha\rfloor}e^{(\beta-1)x} &= \left(-\frac{\alpha-\lfloor\alpha\rfloor}{\beta-1}\right)^{\alpha-\lfloor\alpha\rfloor} e^{(\beta-1)\left(-\frac{\alpha-\lfloor\alpha\rfloor}{\beta-1}\right)},\\ &= (\alpha-\lfloor\alpha\rfloor)^{\alpha-\lfloor\alpha\rfloor}e^{-(\alpha-\lfloor\alpha\rfloor)}\frac{1}{(1-\beta)^{\alpha-\lfloor\alpha\rfloor}}\end{aligned}$$

förutsatt att $\beta < 1$. Vi får alltså

$$m = \frac{\Gamma(\lfloor\alpha\rfloor)}{\Gamma(\alpha)}(\alpha-\lfloor\alpha\rfloor)^{\alpha-\lfloor\alpha\rfloor}e^{-\alpha-\lfloor\alpha\rfloor}\frac{1}{\beta^{\lfloor\alpha\rfloor}(1-\beta)^{\alpha-\lfloor\alpha\rfloor}}$$

och vill därför maximera $\beta^{\lfloor\alpha\rfloor}(1-\beta)^{\alpha-\lfloor\alpha\rfloor}$ på $\beta \in (0,1)$ för att m ska bli så litet som möjligt. Vi får då $\beta = 1/\lfloor\alpha\rfloor$ som det globala maximat över $\beta \in (0,1)$. Vi har då

$$m = \frac{\Gamma(\lfloor\alpha\rfloor)}{\Gamma(\alpha)}e^{-(\alpha-\lfloor\alpha\rfloor)}\frac{\alpha^\alpha}{\lfloor\alpha\rfloor^{\lfloor\alpha\rfloor}}.$$

För $\alpha \in (1,2)$ har vi $\lfloor\alpha\rfloor = 1$, så har vi samma m men för $\alpha \geq 2$ ser vi att m är mindre än för en exponentiell kandidat.

(d)

10.6. Vi har alltså datafördelningen

$$f_{\boldsymbol{X}|\Theta}(\boldsymbol{x} \mid \theta) = \prod_{i=1}^{n} \theta e^{-\theta x_i} = \theta^n e^{-\theta\sum_{i=1}^n x_i},$$

så aposteriorifördelningen ges av

$$f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) \propto f_{\boldsymbol{X}|\theta}(\boldsymbol{x} \mid \theta) f_\Theta(\theta) = \theta^n e^{-\theta\sum_i x_i} f_\Theta(\theta).$$

där

$$f_\Theta(\theta) = \begin{cases} 2/3 & 0 \leq \theta < 1,\\ 2/3(2-\theta) & 1 \leq \theta < 2,\\ 0 & \text{annars.}\end{cases}$$

En rimlig kandidatfördelning är Gamma$(n+1, \sum_i x_i)$ eftersom dess täthetsfunktion överensstämmer till stor del med uttrycket för $f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x})$ ovan. Vi får då

$$\begin{aligned} m &= \sup_{\theta>0} \frac{\theta^n e^{-\theta\sum_i x_i} f_\Theta(\theta)}{\frac{\left(\sum_i x_i\right)^{n+1}}{\Gamma(n+1)}\theta^n e^{-\theta\sum_i x_i}},\\ &= \frac{\Gamma(n+1)}{\left(\sum_i x_i\right)^{n+1}} \sup_{x>0} f_\Theta(\theta),\\ &= \frac{\Gamma(n+1)}{\left(\sum_i x_i\right)^{n+1}} \cdot \frac{2}{3}.\end{aligned}$$

För att undvika numeriska problem (med underfyller eller overflow) förenklar vi accetanskvoten och accepterar kandidater v om u uppfyller

$$v < \frac{3}{2} f_\Theta(\theta).$$

Om vi har en ny kaffenmaskin har denna den betingade fördelningen

$$Y \mid \Theta = \theta \sim \text{Exp}(\theta).$$

Så vi kan använda genererade utfall från $\Theta \mid \boldsymbol{X} = \boldsymbol{x}$ för att simulera $Y \mid \boldsymbol{X} = \boldsymbol{x}$ genom att simulera ett urfall y_i från $\text{Exp}(\theta_i)$ för varje utfall θ_i av $\Theta \mid \boldsymbol{X} = \boldsymbol{x}$. Detta ger intervallet $[0.045, 8.40]$ och sannolikheter 0.983.

10.7. (a) Sannolikheten att lyckas är alltså

$$P(Z \geq a) = 1 - P(Z \leq a) = 1 - \Phi(a).$$

Så antalet försök innan vi lyckas är $\text{Geom}(1 - \Phi(a))$. Antalet försök inklusive det lyckade är då fördelat enligt $1 + \text{Geom}(1 - \Phi(a))$ med väntevärde

$$1 + \frac{\Phi(a)}{1 - \Phi(a)} = \frac{1}{1 - \Phi(a)}.$$

Så ju större a är desto mer ineffektiv är metoden.

(b) Vi vill beräkna

$$m = \sup_{x \geq a} \frac{\frac{1}{\sqrt{2\pi} e^{-x^2/2}}}{\lambda e^{-\lambda(x-a)}} = \frac{1}{\lambda\sqrt{2\pi}} \sup_{x \geq a} e^{-x^2/2 + \lambda(x-a)}.$$

För att maximera uttrycket i supremum deriverar vi med avseende på x och sätter till noll:

$$\frac{d}{dx}\left(e^{-x^2/2+\lambda(x-a)}\right) = (-x + \lambda)e^{-x^2/2+\lambda(x-a)} = 0$$

vilket ger $x = \lambda$. Vi har alltså två fall:
Om $\lambda < a$: inga kritiska punkter och strikt avtagande. Så har vi maximum i $x = a$ med värde $e^{-a^2/2}$.
Om $\lambda \geq a$: kritisk punkt i $x = \lambda$ med värde

$$e^{-\lambda^2/2+\lambda(\lambda-a)} = e^{\lambda^2/2-2a} \geq e^{-a^2/2}.$$

Vi har därmed ett globalt maximum och får

$$m = \frac{1}{\sqrt{2\pi}} e^{\lambda^2/2-\lambda a}.$$

Sammanfattningsvis har vi

$$m = \begin{cases} \frac{1}{\lambda\sqrt{2\pi}} e^{-a^2/2} & \lambda \in (0, a) \\ \frac{1}{\lambda\sqrt{2\pi}} e^{\lambda^2/2 - \lambda a} & \lambda \in [a, \infty). \end{cases}$$

På intervallet $(0, a)$ har vi inget minimum då intervallet är öppet. På intervallet $[a, \infty)$ är ändpunkten $\lambda = a$ en kandidat till minimum med värdet

$$\frac{1}{a\sqrt{2\pi}} e^{-a^2/2}.$$

Om vi deriverar med avseende på λ och sätter till noll får vi

$$\frac{d}{d\lambda}\left(\frac{1}{\lambda\sqrt{2\pi}} e^{\lambda^2/2 - \lambda a}\right) = \left(-\frac{1}{\lambda} + \lambda - a\right) \frac{1}{\lambda\sqrt{2\pi}} e^{\lambda^2/2 - \lambda a} = 0$$

vilket ger

$$\lambda = \frac{a}{2} \pm \frac{1}{2}\sqrt{a^2 + 4}.$$

Vi har redan att $\lambda \geq a$, så lösningen vi söker måste vara

$$\lambda = \frac{a}{2} + \frac{1}{2}\sqrt{a^2 + 4}.$$

I punkten $\lambda = a$ är derivaten negativ medan derivatan går mot $+\infty$ då $\lambda \longrightarrow +\infty$. Så det optimala värdet på λ måste vara

$$\frac{a}{2} + \frac{1}{2}\sqrt{a^2 + 4}.$$

(c)

10.8. Vi har

$$f_{\boldsymbol{X}|\Theta}(\boldsymbol{x} \mid \theta) \propto \theta^{\sum_i x_i} e^{-n\theta} \qquad \text{och} \qquad f_\Theta(\theta) \propto e^{-(\theta-\mu)^2/2}$$

vilket ger

$$f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) \propto \theta^{\sum_i x_i} e^{-n\theta} e^{-(\theta-\mu)^2/2}.$$

En vettig kandidatfördelning är då Gamma$(\sum_i x_1 + 1, n)$ vilket ger

$$m = \sup_{\theta > 0} \frac{\theta^{\sum_i x_i} e^{-n\theta} e^{-(\theta-\mu)^2/2}}{\frac{n^{\sum_i x_i + 1}}{\Gamma(\sum_i x_i + 1)}} = \frac{\Gamma(\sum_i x_i + 1)}{n^{\sum_i x_i + 1}}.$$

Vi vill undvika numeriska problem och söker därför att förenkla acceptanskvoten så mycket som möjligt. Vi accepterar alltså kandidaten v om

$$u < e^{-(v-\mu)^2/2}.$$

Vi använder nu förkastelsemetoden för att ta fram 10000 utfall av $\Theta \mid \boldsymbol{X} = \boldsymbol{x}$ med $\mu = 10$ och får

$$P(\Theta \leq 9 \mid \boldsymbol{X} = \boldsymbol{x}) \approx 0.385$$

och

$$P(\Theta > 9 \mid \boldsymbol{X} = \boldsymbol{x}) \approx 0.615.$$

aposterioriodds et är då

$$\frac{P(\Theta \leq 9 \mid \boldsymbol{X} = \boldsymbol{x})}{P(\Theta > 9 \mid \boldsymbol{X} = \boldsymbol{x})} \approx 0.63.$$

10.9. Låt $X \mid \Theta = \theta \sim \text{Bin}(n, \theta)$ där Θ har täthetsfunktionen

$$f_\Theta(\theta) = \frac{1}{2} \frac{\Gamma(20)}{\Gamma(16)\Gamma(4)} \left(\theta^{15}(1-\theta)^3 + (1-\theta)^{15}\theta^3\right)$$

Antag att vi har $n = 5$ och observerar $x = 3$.

(a) Plotta den onormaliserade täthetsfunktionen hos aposteriorifördelningen.

(b) Använd metropolisalgoritmen för att simulera från aposteriorifördelningen med normalfördelningen som hoppfördelning och plotta histogrammet. Hur påverkar valet av startpunkt och hoppfördelningens skala resultatet?

(c) Approximera aposterioriväntevärdet och aposteriorimedianen med hjälp av de simulerade utfallen. Är någon av dessa att föredra?

10.10. Enligt datan har vi aposteriorifördelningen

$$\Theta_M, \Theta_V \mid \boldsymbol{X} = \boldsymbol{x} \sim \text{NInvGamma}(4, 68, 7, 3, 14.94)$$

givet den icke-informativa aprioriförde lningen $f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) \propto 1/\theta_V$. Detta gav i sin tur den marginella aposteriorifördelningen

$$\Theta_M \mid \boldsymbol{X} = \boldsymbol{x} \sim t(6, 4.68, 0.71).$$

Genom att simulera 10000 utfall från denna fördelning fick vi då

$$\text{E}[\Theta_M^3 \mid \boldsymbol{X} = \boldsymbol{x}] \approx 117.$$

Detta ger i sin tur

$$\text{E}[L(\Theta_M, a_1) \mid \boldsymbol{X} = \boldsymbol{x}] \approx -8500,$$
$$\text{E}[L(\Theta_M, a_2) \mid \boldsymbol{X} = \boldsymbol{x}] \approx -2100.$$

Vi kan nu ersätta aprioriförde lningen med

$$f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) = \frac{1}{\sqrt{2\pi 2^2}} e^{-(\theta_M - 10)^2/8} \cdot \frac{1}{8} 1_{[1,9]}(\theta_V)$$

och tillämpa metropolisalgoritmen. Viktigt att tänka på här är att $\theta_V > 0$, så hoppfördelningen borde se till att denna parameter inte blir negativ. Detta görs enklast genom att ta en postiv stokastisk variabel och multiplicera med denna (istället för att addera). Från 4000 utfall får vi

$$\mathrm{E}[\Theta_M^2 \mid \boldsymbol{X} = \boldsymbol{x}] \approx 185$$

vilket i sin tur ger

$$\mathrm{E}[L(\Theta_M, a_1) \mid \boldsymbol{X} = \boldsymbol{x}] \approx -20200$$
$$\mathrm{E}[L(\Theta_M, a_2) \mid \boldsymbol{X} = \boldsymbol{x}] \approx -43400.$$

Med denna aprioriförfördelning är alltså a_2 (den större modellen) att föredra.

10.11. Vi vill simulera dirichletfördelningen Dirichlet$(\alpha_1, \ldots, \alpha_n)$ där vi antar att $\alpha_i > 1$ för alla $i = 1, 2, \ldots, n$.

(a) Visa att om $X_1, X_2, \ldots, X_n$ är oberoende och Exp(1)-fördelade så är

$$\boldsymbol{Y} = \frac{[X_1, X_2, \ldots, X_n]^{\mathrm{T}}}{\sum_{i=1}^n X_i}$$

likformigt fördelad över $\{\boldsymbol{x} \in [0,1]^n : \sum_{i=1}^n x_i = 1\}$.

(b) Implementera förkastelsemetoden för Dirichlet$(\alpha_1, \ldots, \alpha_n)$ med denna likformiga fördelning som kandidatfördelning. Verifiera att medelvärdet och variansen approximerar de sanna värdena för olika värden på $\alpha_1, \ldots, \alpha_n$.

10.12. (a) Vi simulera aposteriorifördelningen som ges av

$$f_{A,B|\boldsymbol{X}}(a, b \mid \boldsymbol{x}) \propto f_{\boldsymbol{X}|A,B}(\boldsymbol{x} \mid a, b) f_{A,B}(a, b),$$
$$= \frac{1}{\pi(1+a^2)} \cdot \frac{1}{\sqrt{2\pi \cdot 10^2}} e^{-(b-20)/200} \cdot \prod_{i=1}^n \frac{(a \max(t_i - 18.0) + b)^{y_i}}{y_i!} \cdot e^{-(a \max(t_i - 18.0) + b)}$$

där (t_i, y_i) är temperaturen respektive antalet sålda glassar för den i:te dagen. För att undvika numeriska problem arbetar vi med logaritmenav täthetsfunktionen och tar sedan exponenter i samband med beräkning av acceptanskvoten r. När vi gör denna simulation finner vi att $P(A > 0 \mid \boldsymbol{X} = \boldsymbol{x})$ är approximativt lika med ett.

(b) Med hjälp av 1000 utfall får vi

$$\mathrm{E}[A \mid \boldsymbol{X} = \boldsymbol{x}] \approx 3.2,$$
$$\mathrm{E}[B \mid \boldsymbol{X} = \boldsymbol{x}] \approx 24.6.$$

(c) Med ett 10×10-rutnät över lådan $[2, 4] \times [23, 26]$ hittar vi ett minimum i $\hat{a} = 3.11$ och $\hat{b} = 25.0$. Så A är lägre här och B är högre.

(d) Om vi flyttar in derivatan innanför väntevärdet får vi

$$\begin{bmatrix} \frac{\partial}{\partial a} \\ \frac{\partial}{\partial b} \end{bmatrix} \mathrm{E}\left[L((A,B),(a,b)) \mid \boldsymbol{X} = \boldsymbol{x}\right] = \mathrm{E}\left[\begin{bmatrix} \frac{\partial}{\partial a} \\ \frac{\partial}{\partial b} \end{bmatrix} L((A,B),(a,b)) \mid \boldsymbol{X} = \boldsymbol{x}\right],$$

$$= \mathrm{E}\left[\frac{1}{\sqrt{(A-a)^2+(B-b)^2}} \begin{bmatrix} a-A \\ b-B \end{bmatrix} \mid \boldsymbol{X} = \boldsymbol{x}\right].$$

Detta väntevärde kan approximeras med de simulerade utfallen. Om vi sätter $\lambda = 10^{-2}$ konvergerar vi efter $20-40$ iterationer till punkten $a = 3.23$ och $b = 24.6$ med en förlust på 0.58 jämfört med 0.68 för rutnätsapproximationen.