# Lösningar

**9.1**. Enligt exempel 9.2 ges bayesskattningen när vi vill minimera kvadratfelet av aposterioriväntevärdet $E[\Theta \mid X]$. Vi har aprioriförde lningarna: $\Theta \sim N(0, \tau^2)$ för $\tau^2 = 1, 10$. Av uppdateringsregeln för normalfördelad data med normalfördelad parameter får vi aposteriorifördelning:

$$(0, \tau^2) \longmapsto \left( \frac{\tau^2}{\tau^2+1} x, \frac{\tau^2}{\tau^2+1} \right) \Rightarrow \Theta \mid X \sim N\left( \frac{\tau^2}{\tau^2+1} x, \frac{\tau^2}{\tau^2+1} \right)$$

Alltså har vi bayesskattningen:

$$\hat{\theta} = E[\Theta \mid X] = \frac{\tau^2}{\tau^2+1} x.$$

Nu kan vi beräkna riskfunktionen $R(\theta, \hat{\theta})$ m.h.a sats 6.3:

$$\begin{aligned} R(\theta, \hat{\theta}) &= \mathrm{Var}[\hat{\theta}] + \Big( E[\hat{\theta}] - \theta \Big)^2 \\ &= \mathrm{Var}\left[ \frac{\tau^2}{\tau^2+1} x \right] + \left( E\left[ \frac{\tau^2}{\tau^2+1} x \right] - \theta \right)^2 \\ &= \left( \frac{\tau^2}{\tau^2+1} \right)^2 \underbrace{\mathrm{Var}[x]}_{=1} + \left( \frac{\tau^2}{\tau^2+1} \underbrace{E[x]}_{=\theta} - \theta \right)^2 \\ &= \left( \frac{\tau^2}{\tau^2+1} \right)^2 + \left( \frac{-\theta}{\tau^2+1} \right)^2 \\ &= \frac{\tau^{2^2} + \theta^2}{(\tau^2+1)^2}. \end{aligned}$$

Kom ihåg att variansen och väntevärdet tas med avseende på datafördelningen. Det är alltså $\mathrm{Var}_{X|\Theta}$ och $E_{X|\Theta}$ som används. Insättning av $\tau^2 = 1, 10$ ger riskfunktionerna:

$$\frac{1+\theta^2}{4} \quad , \quad \frac{100+\theta^2}{121}$$

som vi kan plotta och se att den andra riskfunktionen är betydligt flackare. Detta innebär att det andra valet av aprioriförde lning är mindre känsligt för fel när vi betraktar kvadratfelet.

**9.2**. (a)

(b) Vi vet att bayesskattningen minimerar aposterioririsken

$$\begin{aligned}
\mathrm{E}[L(\Theta, a) \mid \boldsymbol{X} = \boldsymbol{x}] &= \int_{\Omega} L(\theta, a) f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) d\theta, \\
&= \int_{-\infty}^{\infty} (e^{c(a-\theta)} - c(a-\theta) - 1) f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) d\theta, \\
&= e^{ca} \int_{-\infty}^{\infty} e^{-c\theta} d\theta - ca \int_{-\infty}^{\infty} f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) d\theta + c \int_{-\infty}^{\infty} \theta f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) d\theta - \int_{-\infty}^{\infty}. \\
&= e^{ca} \mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X} = \boldsymbol{x}] - ca + c \mathrm{E}[\Theta \mid \boldsymbol{X} = \boldsymbol{x}] - 1
\end{aligned}$$

Om vi differentierar med avseende på $a$ får vi

$$ce^{ca} \mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X} = \boldsymbol{x}] - c,$$

som ger oss en kritisk punkt enligt

$$\begin{aligned}
0 &= ce^{ca} \mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X} = \boldsymbol{x}] - c, \\
1 &= e^{ca} \mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X} = \boldsymbol{x}], \\
e^{-ca} &= \mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X} = \boldsymbol{x}], \\
a &= -\frac{1}{c} \log(\mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X} = \boldsymbol{x}]).
\end{aligned}$$

Andra derivatan ges av

$$c^2 e^{ca} \mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X} = \boldsymbol{x}]$$

vilken är positivt på den kritiska punkten ovan. Så är denna punkt det globala minimat (eftersom $L(\theta, a) \longrightarrow \infty$ då $a \longrightarrow \pm\infty$). Bayesskattningen är alltså

$$-\frac{1}{c} \log(\mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X}]).$$

(c) I detta fall har vi aposteriorifördelningen $\Theta \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{N}(\bar{x}, \sigma^2/n)$. Detta ger oss

$$\begin{aligned}
\mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X} = \boldsymbol{x}] &= \int_{-\infty}^{\infty} e^{-c\theta} \cdot \frac{1}{\sqrt{2\pi\sigma^2/n}} e^{-\frac{n}{2\sigma^2}(\theta-\bar{x})^2} d\theta, \\
&= \frac{n}{\sqrt{2\pi\sigma^2}} \int_{\infty}^{\infty} e^{-c\theta - \frac{n}{2\sigma^2}(\theta-\bar{x})^2} d\theta, \\
&= \frac{n}{\sqrt{2\pi\sigma^2}} \int_{\infty}^{\infty} e^{-\frac{n}{2\sigma^2}(\theta^2 - 2(\bar{x} - (c\sigma^2/n))\theta + \bar{x}^2)} d\theta, \\
&= \frac{n}{\sqrt{2\pi\sigma^2}} \int_{\infty}^{\infty} e^{-\frac{n}{2\sigma^2}(\theta^2 - 2(\bar{x} - (c\sigma^2/n))\theta + (\bar{x} - (c\sigma^2/n))^2)} e^{-\frac{n}{2\sigma^2}(\bar{x}^2 - (\bar{x} - c\sigma^2/n)^2)} d\theta, \\
&= e^{-\frac{n}{2\sigma^2}(\bar{x}^2 - (\bar{x} - c\sigma^2/n)^2)} \int_{-\infty}^{\infty} \frac{n}{\sqrt{2\pi\sigma^2}} e^{-\frac{n}{2\sigma^2}(\theta - (\bar{x} - c\sigma^2/n))^2)} d\theta, \\
&= e^{-\frac{n}{2\sigma^2}(\bar{x}^2 - (\bar{x} - c\sigma^2/n)^2)} \cdot 1, \\
&= e^{-c\bar{x} + \frac{c^2\sigma^2}{2n}}
\end{aligned}$$

Det följer att bayesskattningen ges av

$$\hat{\Theta} = -\frac{1}{c}\log(\mathrm{E}[e^{-c\Theta} \mid \boldsymbol{X}]) = -\frac{1}{c}\log(e^{-c\bar{X}+\frac{c^2\sigma^2}{2n}}) = \bar{X} - \frac{c\sigma^2}{2n}.$$

Om $c$ är stort blir skattningen mindre och underskattar då mer med avseende på medelvärdet $\bar{X}$ (dvs. ML-skattningen eller bayesskattningen m.a.p. kvadratfelet). Detta beror på att överskattningar penaliseras mer än underskattningar när $c$ är stort, så det är säkrare att underskatta.

**9.3**. Aprioriodds ges av

$$\frac{P(H_0)}{P(H_1)} = \frac{P(\Theta \in [4,100])}{P(\Theta \in [0,4])} = \frac{\Phi\left(\frac{100-2.8}{\sqrt{0.68}}\right) - \Phi\left(\frac{4-2.8}{\sqrt{0.68}}\right)}{\Phi\left(\frac{4-2.8}{\sqrt{0.68}}\right) - \Phi(\left(\frac{0-2.8}{\sqrt{0.68}}\right)} \approx \frac{1-\Phi\left(1.455\right)}{\Phi\left(1.455\right)-0} \approx 0.0793.$$

Aposteriorifördelningen är

$$\Theta \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathrm{N}\left(\frac{\frac{2.8}{0.68}+\frac{5.1}{0.26}}{\frac{1}{0.68}+\frac{1}{0.26}}, \frac{1}{\frac{1}{0.68}+\frac{1}{0.26}}\right) = \mathrm{N}(4.464, 0.188).$$

Så får vi aposterioriodds:

$$\frac{P(H_0 \mid \boldsymbol{X}=\boldsymbol{x})}{P(H_1 \mid \boldsymbol{X}=\boldsymbol{x})} = \frac{P(\Theta \in [4,100] \mid \boldsymbol{X}=\boldsymbol{x})}{P(\Theta \in [0,4] \mid \boldsymbol{X}=\boldsymbol{x})} \approx \frac{1-\Phi\left(\frac{4-4.464}{\sqrt{0.188}}\right)}{\Phi\left(\frac{4-4.464}{\sqrt{0.188}}\right)} \approx 6.027.$$

Så har vi bayesfaktorn

$$\frac{6.027}{0.0793} \approx 76.$$

**9.4**. (a) Vi har följande situationer

| val | investeringar (kr) | inkomst (kr) | vinst (kr) |
|---|---|---|---|
| $a_1$ | 1000000 | $30\theta$ | $-1000000+30\theta$ |
| $a_2$ | 300000 | $15\theta$ | $-300000+15\theta$ |
| $a_3$ | $-200000$ | $3\theta$ | $200000+3\theta$ |

Notera att förlust är negativ vinst så har vi förlustfunktionen

$$L(\theta, a) = -k\theta - b$$

där konstanterna $k$ och $b$ beror på handlingen $a$ enligt tabellen ovan.

Aprioriförde lningen är en blandad (dvs. både diskret och kontinuerlig) fördelning, eftersom vi har sannolikhet 0.9 att ha $\theta = 0$ och en täthetsfunktion

$$\frac{0.1}{300000}e^{-\theta/300000}$$

annars. Ett sätt att representera betta är att introducera en ny statistisk variabel $Z$ med värden i $\{0, 1\}$ och sannolikhetsfunktion

$$f_Z(z) = \begin{cases} 0.9 & z = 0 \\ 0.1 & z = 1. \end{cases}$$

Om $Z = 0$ tar vi $\Theta = 0$ och om $Z = 1$ har vi den betingade täthetsfunktionen

$$f_{\Theta|Z=1}(\theta) = \frac{\frac{0.1}{300000} e^{-\theta/300000}}{f_Z(1)} = \frac{1}{300000} e^{-\theta/300000}$$

Vi får då den simultana sannolikhets- och täthetsfunktionen

$$f_{Z,\Theta}(z, \theta) = \begin{cases} 0.9 & z = 0, \theta = 0 \\ \frac{0.1}{300000} e^{-\theta/300000} & z = 1, \theta > 0. \end{cases}$$

För att bestämma bayesbeslutet krävs att vi beräknar aposterioririsken för de olika alternativen i vilket i sin tur kräver aposteriorifördelningen för $Z, \Theta$ givet $X = x_1$.

Då det kan vara svårt att ta fram normaliseringskonstanten för aposteriorifördelningen (dvs. den tillhör inte en av våra standardfördelningar) väljer vi att arbeta med normaliserade fördelningar. Vi söker då första den aprioriprediktiva fördelningen $f_X(x)$. Vi har då

$$\begin{aligned} f_X(x_1) &= f_{X|Z,\Theta}(x_1 \mid 0, 0) f_{Z,\Theta}(0, 0) + \int_0^\infty f_{X|Z,\Theta}(x_1 \mid 1, 0) f_{Z,\Theta}(1, \theta) d\theta, \\ &= 0.8 e^{-0/100000} \cdot 0.9 + \int_0^\infty 0.8 e^{-\theta/100000} \cdot \frac{0.1}{300000} e^{-\theta/300000} d\theta, \\ &= 0.72 + \frac{0.8}{300000} \int_0^\infty e^{-4\theta/300000} d\theta, \\ &= 0.72 + 0.02, \\ &= 0.74. \end{aligned}$$

Aposteriorifördelningen blir då

$$\begin{aligned} f_{Z,\Theta|X}(z, \theta \mid x_1) &= \frac{f_{X|Z,\Theta}(x_1 \mid z, \theta) f_{Z,\Theta}(z, \theta)}{f_X(x_1)}, \\ &= \begin{cases} \frac{0.8 \cdot 0.9}{0.74} & z = 0, \theta = 0, \\ \frac{0.08}{0.74} \cdot \frac{1}{300000} e^{-4\theta/300000} & z = 1, \theta > 0. \end{cases} \end{aligned}$$

Vi får då aposterioririsken till

$$\begin{aligned}
\mathrm{E}[L(\Theta, a) \mid X = x_1] &= \int_0^\infty L(\theta, a) f_{Z,\Theta|X}(1, \theta \mid x_1) d\theta + L(0, a) f_{Z,\Theta|X}(0, 0 \mid x_1), \\
&= \frac{0.08}{0.74} \cdot \frac{1}{300000} \int_0^\infty (-k\theta - b) e^{-4\theta/300000} d\theta - \frac{0.08}{0.74} \cdot \frac{1}{300000} b \int_0^\infty e^{-4\theta/30} \\
&\qquad - \frac{0.72}{0.74} b, \\
&= -\frac{0.08}{0.74} \cdot \frac{1}{300000} k \cdot \frac{300000^2}{4^2} - \frac{0.08}{0.74} \cdot \frac{1}{300000} b \cdot \frac{300000}{4} - \frac{0.72}{0.74} b, \\
&\approx -2027k - b.
\end{aligned}$$

Från våra möjliga situationer har vi

| val | $k$ | $b$ | aposterioririsken |
|---|---|---|---|
| $a_1$ | 30 | $-1000000$ | $\approx 939100$ |
| $a_2$ | 15 | $-300000$ | $\approx 269595$ |
| $a_3$ | 3 | 200000 | $\approx -206100$ |

Så bayesbeslutet är $a_3$.

(b) Vi antar att vi alltså har två oberoende observationer

$$X = x_2 \qquad X' = x_3.$$

Däremot ser vi att observationen $X = x_2$ är oberoende av $Z, \Theta$ eftersom

$$f_{X|Z,\Theta}(x_2) = 0.2 = f_X(x_2).$$

På grund av detta påverkar inte $X = x_2$ fördelningen för $Z, \Theta$. Så vi har alltså

$$f_{Z,\Theta|X}(z, \theta \mid x_2) = f_{Z,\Theta}(z, \theta).$$

Nästa uppdatering är med avseende på $X' = x_3$. Där har vi

$$\begin{aligned}
f_X(x_3) &= f_{X|Z,\Theta}(x_3 \mid 0, 0) f_{Z,\Theta}(0, 0) + \int_0^\infty f_{X|Z,\Theta}(x_3 \mid 1, \theta) f_{Z,\Theta}(1, \theta) d\theta, \\
&= 0.8(1 - e^{-0/100000}) \cdot 0.9 + \int_0^\infty 0.8(1 - e^{-\theta/100000}) \cdot \frac{0.1}{300000} e^{-\theta/300000} d\theta, \\
&= 0.06.
\end{aligned}$$

Detta ger oss

$$f_{Z,\Theta|X}(z, \theta \mid x_3) = \begin{cases} 0 & z = 0, \theta = 0 \\ \frac{0.8}{0.06} e^{-\theta/300000}(1 - e^{-\theta/100000}) & z = 1, \theta > 0. \end{cases}$$

Som innan får vi aposterioririsken $\mathrm{E}[L(\Theta, a) \mid X = x_3] = -b - 375000k$, vilket ger risken $-10250000$ för $a_1$, $-5325000$ för $a_2$ och $-1325000$ för $a_3$. Bayesbeslutet är då $a_1$.

**9.5**. Vi låter $X = 1$ om en student har på sig overall och $X = 0$ annars. Vi modellerar denna variabel som bernoullifördelad med parametern $\theta$; dvs. $X \mid \Theta = \theta \sim \text{Ber}(\theta)$. Studenten använder en likformig aprioorifördelningen $\Theta \sim U(0,1)$ och han observerade två studenterna som ska till festen i overall. Vi antar att dessa två observationer är oberoende och beräknar aposterioorifördelningen

$$\begin{aligned} f_{\Theta|\boldsymbol{X}}(\theta \mid 1,1) &\propto f_{\boldsymbol{X}|\Theta}(1,1 \mid \theta) f_{\Theta}(\theta), \\ &= \theta^1(1-\theta)^{1-1}\theta^1(1-\theta)^{1-1} \cdot 1, \\ &= \theta^2, \\ &= \theta^{3-1}(1-\theta)^{1-1}. \end{aligned}$$

Så har vi att $\Theta \mid \boldsymbol{X} = [1,1]^{\text{T}} \sim \text{Beta}(3,1)$.
Han vill ha en förlustfunktion som är 0 om han tillhör majoriteten. Eftersom fest är stor kommer att majoriteten har på sig overall om och endast om $\theta > 1/2$. Därför tar vi nollhypotesen $\Omega_0 = [1/2, 1]$ och mothypotesen $\Omega_1 = [0, 1/2)$. Eftersom han tycker att det är fyra gånger så pinsamt att ha overall om majoriteten av studenterna inte har det jämfört med tvärtom använder vi då förlustfunktionen

$$L(\theta, a_1) = \begin{cases} 0 & \theta \in \Omega_0 \\ 4 & \theta \in \Omega_1 \end{cases} \qquad L(\theta, a_2) = \begin{cases} 1 & \theta \in \Omega_0 \\ 0 & \theta \in \Omega_1 \end{cases}$$

där $a_1$ är beslutet att ha på sig overall och $a_2$ är beslutet att inte ha på sig overall. Vi vill beräkna kvoten

$$\begin{aligned} \frac{\text{E}[L(\Theta, a_1) \mid \boldsymbol{X} = [1,1]^{\text{T}}]}{\text{E}[L(\Theta, a_2) \mid \boldsymbol{X} = [1,1]^{\text{T}}]} &= \frac{\int_0^{1/2} 4 f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) d\theta}{\int_{1/2}^1 1 f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) d\theta}, \\ &= \frac{4\int_0^{1/2} f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) d\theta}{\int_{1/2}^1 f_{\Theta|\boldsymbol{X}}(\theta \mid \boldsymbol{x}) d\theta}. \end{aligned}$$

Eftersom $\Theta \mid \boldsymbol{X} = [1,1]^{\text{T}} \sim \text{Beta}(3,1)$ har vi att

$$\begin{aligned} \int_0^{1/2} f_{\Theta|\boldsymbol{x}}(\theta \mid \boldsymbol{x}) d\theta &= \int_0^{1/2} \frac{\Gamma(4)}{\Gamma(3)\Gamma(1)} \theta^2 d\theta, \\ &= \int_0^{1/2} 3\theta^2 d\theta, \\ &= (1/2)^3, \\ &= 1/8 \end{aligned}$$

och

$$\int_{1/2}^1 f_{\Theta|\boldsymbol{x}}(\theta \mid \boldsymbol{x}) d\theta = 1 - \int_0^{1/2} f_{\Theta|\boldsymbol{x}}(\theta \mid \boldsymbol{x}) d\theta = 7/8.$$

Så har vi att

$$\frac{\mathrm{E}[L(\Theta, a_1) \mid \boldsymbol{X} = [1,1]^{\mathrm{T}}]}{\mathrm{E}[L(\Theta, a_2) \mid \boldsymbol{X} = [1,1]^{\mathrm{T}}]} = \frac{4(1/8)}{(7/8)} = 4/7.$$

Detta betyder att aposterioririsken av $a_2$ är större än aposterioririsken av $a_1$. Beslutet är då att har på sig overall.

**9.6**. Vi modellerar antalet godis som var ätit under dagen $A$ som $A \mid \Lambda = \lambda \sim \mathrm{Po}(\lambda)$. Vi har två möjliga aprioriförderlningar att bestämma mellan: $\Lambda = 8$ som motsvarar handling $a_1$ (yngre syskonen) och $\Lambda = 12$ som motsvarar $a_2$ (äldre syskonen). Eftersom den yngre syskonen är fyra gånger mer sannolik att stjäla godisar använder vi förlustfunktionen

$$L(\lambda, a_1) = \begin{cases} 0 & \lambda = 8 \\ 4 & \lambda = 12 \end{cases} \qquad L(\lambda, a_2) = \begin{cases} 1 & \lambda = 8 \\ 0 & \lambda = 12. \end{cases}$$

Vi använder en icke-informativ aprioriförderlningen $f_\Lambda(\lambda)$. Eftersom det finns bara två möjliga värde på $\lambda$ ($\lambda = 8$ och $\lambda = 12$) tar vi en likformig aprioriförderlningen över mängden $\{8, 12\}$; dvs. $P(\Lambda = 12) = P(\lambda = 8) = 1/2$. Aposterioriodden är då

$$\begin{aligned}
\frac{4P(\Lambda = 8 \mid A = 11)}{1P(\Lambda = 12 \mid A = 11)} &= \frac{4\frac{P(\Lambda=8, A=11)}{P(A=11)}}{1\frac{P(\Lambda=12, A=11)}{P(A=11)}}, \\
&= \frac{4P(\Lambda = 8, A = 11)}{1P(\Lambda = 12, A = 11)}, \\
&= \frac{4P(A = 11 \mid \Lambda = 8)P_\Lambda(8)}{1P(A = 11 \mid \Lambda = 12)P_\Lambda(12)}, \\
&= \frac{4P(A = 11 \mid \Lambda = 8)(1/2)}{1P(A = 11 \mid \Lambda = 12)(1/2)}, \\
&= \frac{4P(A = 11 \mid \Lambda = 8)}{1P(A = 11 \mid \Lambda = 12)}, \\
&= \frac{4\left(\frac{8^{11}e^{-8}}{11!}\right)}{\left(\frac{(12)^{11}e^{-12}}{11!}\right)}, \\
&\approx 2.524.
\end{aligned}$$

**9.7**. Datan $x$ dras från $X \mid \Theta_M = \theta_M, \Theta_V = \theta_V \sim \mathrm{N}(\theta_M, \theta_V)$ där $f_{\Theta_M, \Theta_V}(\theta_M, \theta_V) \propto 1/\theta_V$. Vi betraktar nollhypotesen $H_0 : \theta_M \leq 1$ och mothypotesen $H_1 : \theta > 1$. Enligt kursanteckningarna har vi att $\Theta_M \mid \boldsymbol{X} = \boldsymbol{x} \sim t(4, 1.38, 0.044)$ eftersom $n = 5$, $\bar{x} = 1.38$ och $s^2/n \approx 0.044$ för den givna datan. Denna fördelningen är en skalad

och skiftad t-fördelning med 4 frihetsgrader. Detta betyder att

$$\begin{aligned} P(\Theta_M \leq 1 \mid \boldsymbol{X} = \boldsymbol{x}) &= P((0.044)^{1/2}T + 1.38 \leq 1), \\ &= P(T \leq (-0.38)/(0.044)^{1/2}), \\ &\approx P(T \leq -1.812). \end{aligned}$$

där $T \sim t(4)$. Med hjälp av datorn beräkna vi att denna sannolikhet är $P(\Theta_M \leq 1 \mid \boldsymbol{X} = \boldsymbol{x}) \approx 0.072$; dvs.

$$P(H_0 \mid \boldsymbol{X} = \boldsymbol{x}) = 0.072$$

och

$$P(H_1 \mid \boldsymbol{X} = \boldsymbol{x}) = 1 - 0.072 = 0.928.$$

Det följer att aposterioriodden är $0.072/0.928 \approx 0.0776$ – vilket är ganska litet.
Eftersom den icke-informativa aprioriförd elningen är oegentlig är aprioriodden set odefinierat, så bayesfaktorn är också odefinierad.

**9.8**. Om slutpriset är $\Theta$ så har vi, a priori, $\Theta \sim \mathrm{N}(700, 300^2)$. Utropspriset $X$ har då den betingade fördelningnen

$$X \mid \Theta = \theta \sim \mathrm{N}(0.8\theta, 100^2).$$

Vi observerar alltså $X = x$ vilket ger aposteriorifördelningen

$$\Theta \mid X = x \sim \mathrm{N}\left( \frac{\frac{700}{300^2} + \frac{0.8x}{100^2}}{\frac{1}{300^2} + \frac{0.8^2}{100^2}}, \frac{1}{\frac{1}{300^2} + \frac{0.8^2}{100^2}} \right)$$

eftersom observationen $X = x$ är ekvivalent med att observera

$$Y = \frac{X}{0.8} = \frac{x}{0.8}$$

vilken har den betingade fördelningen $\mathrm{N}(\theta, 100^2/0.8^2)$ givet $\Theta = \theta$. Om vi stoppar in $y = x/0.8$ i uppdateringsformeln för $\Theta$ givet $Y = y$ så får vi formeln ovan.
Vi har då, med $x = 600$, att

$$\Theta \mid X = 600 \sim \mathrm{N}(742.6, 13313).$$

Förlustfunktionen är

$$L(\theta, a) = \begin{cases} 10(\theta - a) & a < \theta, \\ 1(a - \theta) & a \geq \theta \end{cases}$$

eftersom vi värdera underskattningar tio gånger mer än överskattningar. Detta är alltså en kvatilförlust, vilket ger att bayesskattningen utgavs av $1/(10 + 1) = 1/11$-kvantilen av $\Theta$.

Vi söker då $a$ så att

$$P(\Theta \geq a \mid X = 600) = 1/11.$$

Eftersom $\Theta \mid X = 600 \sim \mathrm{N}(742.6, 13313)$ är detta ekvivalent med

$$\begin{aligned} P(742.6 + \sqrt{13313}Z \geq a) &= 1/11, \\ P\left(Z \leq \frac{a - 742.6}{\sqrt{13313}}\right) &= 10/11, \\ \Phi\left(\frac{a - 742.6}{\sqrt{13313}}\right) &\approx 0.9091. \end{aligned}$$

Eftersom $\Phi(1.33) \approx 0.9091$ så får vi

$$a = 752.6 + 1.33\sqrt{13313} \approx 896kr.$$

**9.9**. (a) Bayesbeslutet är valet som minimerar aposterioririsken; dvs. vii väljer $a_0$ om och endast om

$$\mathrm{E}[L(\Theta, a_0) \mid X = 1] < \mathrm{E}[L(\Theta, a_1) \mid X = 1].$$

Med avseende på den givna förlustfunktionen har vi

$$\begin{aligned} \mathrm{E}[L(\Theta, a_0) \mid X = 1] &= P(\Theta \in \Omega_1 \mid X = 1), \\ \mathrm{E}[L(\Theta, a_1) \mid X = 1] &= P(\Theta \in \Omega_0 \mid X = 1). \end{aligned}$$

Vi har även (enlgit formelsamlingen) att aposterioriförde lningen är

$$\Theta \mid X = 1 \sim \mathrm{Beta}(1 + 1, , 9 + 5 - 1) = \mathrm{Beta}(2, 13)$$

eftersom $X \mid \Theta = \theta \sim \mathrm{Bin}(5, \theta)$ och $\Theta \sim \mathrm{Beta}(1, 9)$. Det följer att

$$\begin{aligned} P(\Theta \in \Omega_0 \mid X = 1) &= \int_0^{0.15} \frac{\Gamma(15)}{\Gamma(2)\Gamma(13)} \theta(1-\theta)^1 2 d\theta, \\ &= (13)(14) \int_{0.85}^{1} (1-u)u^{12} du, \qquad (u = 1 - \theta) \\ &\approx (13)(14)(0.0035), \\ &\approx 0.637. \end{aligned}$$

Vi har även att

$$P(\Theta \in \Omega_1 \mid X = 1) \approx 1 - 0.637 = 0.363.$$

Så är beslutet $a_0$.

(b) Med denna förlustfunktionen har vi att

$$\begin{aligned}
&\mathrm{E}[L(\Theta, a_0) \mid X = 1] = P(\Theta \in \Omega_1 \mid X = 1) = 0.363, \\
&\mathrm{E}[L(\Theta, a_1) \mid X = 1] = 2P(\Theta \in \Omega_0 \mid X = 1) = 2(0.637)
\end{aligned}$$

Eftersom aposterioririsken för $a_1$ är större tar vi beslutet $a_0$ igen.

(c) För denna förlustfunktion har vi att

$$\begin{aligned}
\mathrm{E}[L(\Theta, a_0) \mid X = 1] &= P(\Theta \in \Omega_1 \mid X = 1) = 0.363, \qquad \text{och} \\
\mathrm{E}[L(\Theta, a_1) \mid X = 1] &= \int_0^{0.15} (0.15 - \theta) \frac{\Gamma(15)}{\Gamma(2)\Gamma(13)} \theta (1-\theta)^{12} d\theta, \\
&= (0.15) \int_0^{0.15} \frac{\Gamma(15)}{\Gamma(2)\Gamma(13)} \theta (1-\theta)^{12} d\theta - (13)(14) \int_0^{0.15} \theta^2 (1-\theta)^{12} d\theta, \\
&\approx (0.15)(0.637) - (13)(14)(0.00029), \\
&\approx 0.148.
\end{aligned}$$

Eftersom risken är större för $a_0$ väljer vi $a_1$ i detta fall.

**9.10**. Vi beräknar först aposteriorifördelningen $\Theta \mid X = 4$:

$$\begin{aligned}
f_{\Theta|X}(\theta \mid 4) &\propto f_{X|\Theta}(4 \mid \theta) f_\Theta(\theta), \\
&\propto e^{-(4-\theta)} e^{-\theta} 1_{(\theta,\infty)}(4) 1_{(0,\infty)}(\theta), \\
&\propto e^{-4} 1_{(0,4]}(\theta) \qquad (1_{(\theta,\infty)}(4) 1_{(0,\infty)}(\theta) = 1 \text{ o.m.m. } \theta \leq 4 \text{ och } 0 < \theta) \\
&\propto 1_{(0,4]}(\theta).
\end{aligned}$$

Det följer att $\Theta \mid X = 4 \sim U(0, 4)$. Enligt den första raden i tabellen har vi att

$$L(\theta, AB) = \begin{cases} 0 & \text{om } 0 < \theta < 1 \\ 1 & \text{om } 1 < \theta < 2 \\ 1 & \text{om } 2 < \theta < 3 \\ 2 & \text{om } 3 < \theta. \end{cases}$$

Det följer att aposterioririsken för beslutet AB är

$$\begin{aligned}
\mathrm{E}[L(\Theta, AB) \mid X = 4] &= \int_0^4 L(\theta, AB) \cdot \frac{1}{4} d\theta, \\
&= \int_1^2 1 \cdot \frac{1}{4} d\theta + \int_2^1 1 \cdot \frac{1}{4} d\theta + \int_3^4 2 \cdot \frac{1}{4} d\theta, \\
&= \frac{1}{4}(1 + 1 + 2), \\
&= 1.
\end{aligned}$$

På samma sätt har vi

$$\begin{aligned}
\mathrm{E}[L(\Theta, A) \mid X = 4] &= \frac{1}{4}(1+2+2) = \frac{5}{4}, \\
\mathrm{E}[L(\Theta, B) \mid X = 4] &= \frac{1}{4}(1+2+2) = \frac{5}{4}, \\
\mathrm{E}[L(\Theta, 0) \mid X = 4] &= \frac{1}{4}(3+3+3) = \frac{9}{4}.
\end{aligned}$$

Bayesbeslutet är beslutet som minimerar aposteriorisken. Därför är beslutet AB.

**9.11**. Vi beräknar aposterioririsken

$$\begin{aligned}
\mathrm{E}[L(\boldsymbol{\Theta}, \boldsymbol{a}) \mid \boldsymbol{X} = \boldsymbol{x}] &= \int_\Omega L(\boldsymbol{\Theta}, \boldsymbol{a}) f_{\boldsymbol{\Theta}|\boldsymbol{X}}(\boldsymbol{\theta} \mid \boldsymbol{x}) d\boldsymbol{\theta}, \\
&= \int_\Omega (\boldsymbol{\theta} - \boldsymbol{a})^{\mathrm{T}} Q (\boldsymbol{\theta} - \boldsymbol{a}) f_{\boldsymbol{\Theta}|\boldsymbol{X}}(\boldsymbol{\theta} \mid \boldsymbol{x}) d\boldsymbol{\theta}, \\
&= \int_\Omega \left( \boldsymbol{\theta}^{\mathrm{T}} Q \boldsymbol{\theta} - \boldsymbol{\theta}^{\mathrm{T}} Q \boldsymbol{a} - \boldsymbol{a}^{\mathrm{T}} Q \boldsymbol{\theta} + \boldsymbol{a}^{\mathrm{T}} Q \boldsymbol{a} \right) f_{\boldsymbol{\Theta}|\boldsymbol{X}}(\boldsymbol{\theta} \mid \boldsymbol{x}) d\boldsymbol{\theta}, \\
&= \mathrm{E}[\boldsymbol{\Theta}^{\mathrm{T}} Q \boldsymbol{\Theta} \mid \boldsymbol{X} = \boldsymbol{x}] - 2\boldsymbol{a}^{\mathrm{T}} Q \,\mathrm{E}[\boldsymbol{\Theta} \mid \boldsymbol{X} = \boldsymbol{x}] + \boldsymbol{a}^{\mathrm{T}} Q \boldsymbol{a}.
\end{aligned}$$

Om vi differentierar detta uttryck med avseende på $a_k$ får vi

$$\begin{aligned}
&2a_k Q_{kk} + \sum_{j \neq k} Q_{kj} a_j + \sum_{i \neq k} a_i Q_{ik} - 2 \sum_j Q_{kj} \,\mathrm{E}[\Theta_j \mid \boldsymbol{X} = \boldsymbol{x}] \\
&= 2a_k Q_{kk} + \sum_{j \neq k} Q_{kj} a_j + \sum_{i \neq k} Q_{ki} a_i - 2 \sum_j Q_{kj} \,\mathrm{E}[\Theta_j \mid \boldsymbol{X} = \boldsymbol{x}] \\
&= 2 \sum_j Q_{kj} a_j - 2 \sum_j Q_{kj} \,\mathrm{E}[\Theta_j \mid \boldsymbol{X} = \boldsymbol{x}]
\end{aligned}$$

för all $k = 1, \ldots, d$ där vi har skrivit den första summan för att separera kvadrattermerna och använde att $Q$ är symmetriskt. Om vi sätter detta till noll får vi det linjära ekvationssystemet

$$2Q\boldsymbol{a} - 2Q \,\mathrm{E}[\boldsymbol{\Theta} \mid \boldsymbol{X} = \boldsymbol{x}] = 0.$$

Detta ger lösningen $\boldsymbol{a} = Q^{-1} Q \,\mathrm{E}[\boldsymbol{\Theta} \mid \boldsymbol{X} = \boldsymbol{x}] = \mathrm{E}[\boldsymbol{\Theta} \mid \boldsymbol{X} = \boldsymbol{x}]$. Hessianen är lika med $2Q$ och är alltså postivt definit. Vi har därför hittat bayesskattningen.

**9.12**. Efter en massa beräkningar borde man få

(a) $\Sigma + \sigma^2 \mathrm{I}$.

(c)

$$\Sigma(\Sigma + \sigma^2 \mathrm{I})^{-1} \sum_{i=1}^{n} \frac{\lambda_i^2}{\lambda_i^2 + \sigma^2 \mathrm{I}} v_i v_i^{\mathrm{T}}$$

De komponenter där $\lambda_i^2 \ll \sigma^2$ reduceras i amplitud medan komponenter där $\lambda_i^2 \gg \sigma^2$ behålls som de är.

(d) Medelkvadratfelet för observationen fås till 0.185 medan för skattningen får vi 0.0529. Vi har alltså en brusreduktion på ungefär $4\times$.