Lösningar

12.1. För att bedöma om antalet olyckor har minskat skulle vi kunna beräkna

$$P(X \leq 10 \mid \lambda = 15) = \sum_{i=0}^{10} \frac{e^{-15}15^i}{i!} \approx 0.11846.$$

Detta värde är ganska stort. Därför är det inte överväldigande bevis för att antalet olyckor har minskat. Det är därför inte motiverat att hävda att antalet olyckor har minskat.

12.2. Ett likelihood-kvottest ges av

Förkasta H_0 om $\lambda(\boldsymbol{x}) \leq c$ för något $c \in (0,1)$ där

$$\lambda(\boldsymbol{x}) = \frac{\sup_{\theta \in \Omega_0} L(\theta \mid \boldsymbol{x})}{\sup_{\theta \in \Omega} L(\theta \mid \boldsymbol{x})}.$$

I vårt fall är nollypotesen $H_0 : \beta = \beta_0$, så kvoten blir

$$\lambda(\boldsymbol{x}) = \frac{L(\beta_0 \mid \boldsymbol{x})}{L(\hat{\beta} \mid \boldsymbol{x})}$$

här $\hat{\beta}$ betecknar ML-skattningen av β enligt datan $\boldsymbol{x}$. Vi har att

$$\begin{aligned} L(\beta_0 \mid \boldsymbol{x}) &= \prod_{i=1}^{n} \frac{\Gamma(\beta_0 + 1)}{\Gamma(\beta_0)} (1 - x_i)^{\beta_0 - 1}, \\ &= \prod_{i=1}^{n} \beta_0 (1 - x_i)^{\beta_0 - 1}, \\ &= \beta_0^n \prod_{i=1}^{n} (1 - x_i)^{\beta_0 - 1}. \end{aligned}$$

For att beräkna ML-skattningen $\hat{\beta}$ använder vi log-likelihoodfunktionen

$$\begin{aligned} \ell(\beta \mid \boldsymbol{x}) &= \log L(\beta \mid \boldsymbol{x}), \\ &= \log \prod_{i=1}^{n} \frac{\Gamma(\beta + 1)}{\Gamma(\beta)} (1 - x_i)^{\beta - 1}, \\ &= n \log(\beta) + (\beta - 1) \sum_{i=1}^{n} \log(1 - x_i). \end{aligned}$$

Tar derivaten m.a.p. β och sätter lika med noll ger

$$\begin{aligned}\frac{d}{d\beta}\ell(\beta \mid \boldsymbol{x}) &= \frac{n}{\beta} + \sum_{i=1}^{n}\log(1-x_i),\\ &= \frac{n}{\beta} + n\overline{\log(1-x_i)},\\ 0 &= \frac{n}{\beta} + n\overline{\log(1-x_i)},\\ \hat{\beta} &= -\frac{1}{\overline{\log(1-x_i)}}.\end{aligned}$$

Eftersom den andra derivatan är alltid negativ vet vi att $\hat{\beta}$ är ML-skattningen.
Det följer att likelihoodkvoten är

$$\begin{aligned}\lambda(\boldsymbol{x}) &= \frac{\beta_0^n\prod_{i=1}^n(1-x_i)^{\beta_0-1}}{\hat{\beta}^n\prod_{i=1}^n(1-x_i)^{\hat{\beta}-1}},\\ &= \beta_0\left(\frac{-1}{\overline{\log(1-x)}}\right)^{-n}\prod_{i=1}^n(1-x_i)^{\beta_0+1/\overline{\log(1-x)}},\\ &= \beta_0^n\overline{\log(1/(1-x))}^n\prod_{i=1}^n(1-x_i)^{\beta_0+\overline{\log(1-x)}^{-1}}.\end{aligned}$$

Det följer att svaret är (c).

12.3. Ett likelihood-kvottest ges av

$$\text{Förkasta } H_0 \text{ om } \lambda(\boldsymbol{x}) \le c \text{ för något } c \in (0,1)$$

där

$$\lambda(\boldsymbol{x}) = \frac{\sup_{\lambda\in\Omega_0} L(\lambda \mid \boldsymbol{x})}{\sup_{\lambda\in\Omega} L(\lambda \mid \boldsymbol{x})}.$$

I detta fall har vi

$$\begin{aligned}\sup_{\lambda\in\Omega_0} L(\lambda \mid \boldsymbol{x}) &= L(\lambda_0 \mid \boldsymbol{x}),\\ &= \prod_{i=1}^n \frac{\lambda_0^\alpha}{\Gamma(\alpha)}x_i^{\alpha-1}e^{-\lambda_0 x_i},\\ &= \frac{\lambda_0^{n\alpha}}{\Gamma(\alpha)^n}\left(\prod_{i=1}^n x_i\right)^{\alpha-1}e^{-\lambda_0 n\bar{x}},\end{aligned}$$

och $\sup_{\lambda\in\Omega} L(\hat{\lambda} \mid \boldsymbol{x})$ där $\hat{\lambda}$ är ML-skattningen för λ givet datan $\boldsymbol{x}$.

För att beräkna $\hat{\lambda}$ betraktar vi log-likelihoodfunktionen:

$$\begin{aligned}
\ell(\lambda \mid \boldsymbol{x}) &= \log L(\lambda \mid \boldsymbol{x}), \\
&= \log \prod_{i=1}^{n} \frac{\lambda^{\alpha}}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\lambda x_i}, \\
&= \log\left(\frac{\lambda^{n\alpha}}{\Gamma(\alpha)^n}\right) + \log\left(\prod_{i=1}^{n} x_i\right)^{\alpha-1} - \lambda \sum_{i=1}^{n} x_i, \\
&= n\alpha \log(\lambda) - n\log(\Gamma(\alpha)) + (\alpha-1)\sum_{i=1}^{n} \log(x_i) - \lambda n\bar{x}.
\end{aligned}$$

Tar den första derivatan m.a.p. λ och sätter lika med noll ger

$$\begin{aligned}
0 &= \frac{n\alpha}{\lambda} - n\bar{x}, \\
\hat{\lambda} &= \frac{\alpha}{\bar{x}}.
\end{aligned}$$

Det kan helt enkelt verifieras att detta är ML-skattningen. Så har vi likelihoodkvoten

$$\begin{aligned}
\lambda(\boldsymbol{x}) &= \frac{\left(\frac{\lambda_0^{n\alpha}}{\Gamma(\alpha)^n}\right)\left(\prod_{i=1}^{n} x_i\right)^{\alpha-1} e^{-\lambda_0 n\bar{x}}}{\frac{\left(\frac{\alpha}{\bar{x}}\right)^{n\alpha}}{\Gamma(\alpha)^n}\left(\prod_{i=1}^{n} x_i\right)^{\alpha-1} e^{-(\alpha/\bar{x})n\bar{x}}}, \\
&= \left(\frac{\lambda_0\bar{x}}{\alpha}\right)^{n\alpha} e^{-\lambda_0 n\bar{x}+n\alpha}, \\
&= \left(\frac{e}{\alpha}\right)^{n\alpha} (\lambda_0\bar{x})^{n\alpha} e^{-\lambda_0 n\bar{x}}.
\end{aligned}$$

Det följer att $\lambda(\boldsymbol{x}) \leq c$ för något $c \in (0,1)$ om och endast om

$$(\lambda_0\bar{x})^{n\alpha} e^{-\lambda_0 n\bar{x}} \leq \frac{c}{(e/\alpha)^{n\alpha}} = c'$$

för något $c \in (0,1)$. Detta händer om och endast om

$$(\lambda_0\bar{x})^{n\alpha} e^{-\lambda_0 n\bar{x}} \leq c'$$

för något $c' \in (0,\infty)$. På samma sätt kan vi ta det n:te rot och få testet

Förkasta H_0 om $(\lambda_0\bar{x})^{\alpha} e^{-\lambda_0\bar{x}} \leq c$ för något $c \in (0,\infty)$.

Så har vi att svaret är (b).

12.4. Likelihoodkvoten är

$$\lambda(\boldsymbol{y}) = \frac{\sup_{\theta\in[0,\theta_0]} L(\theta \mid \boldsymbol{y})}{\sup_{\theta\in[0,1]} L(\theta \mid \boldsymbol{y})}.$$

Vi har att ML-skattningen för $\hat{\theta}$ över hela parameterrummet är $\hat{\theta} = \bar{y}$. Detta betyder att nämnaren är $L(\bar{y} \mid \boldsymbol{y})$. För att beräkna täljaren använder vi Exempel 5.1 där vi såg att $L(\theta \mid \boldsymbol{y})$ är strikt växande för $\theta < \bar{y}$ och strikt avtagande för $\theta > \bar{y}$. (Detta kan visas med hjälp av den första derivatan beräknas i Exempel 5.1 .) Därför, om $0 \leq \theta \leq \theta_0$ där $\bar{y} \leq \theta_0$ har vi att $\bar{y}$ är ML-skattningen i täljaren. Å andra sidan, om $\bar{y} > \theta_0$ har vi att $L(\theta \mid \boldsymbol{y})$ är strikt växande på intervallet $0 \leq \theta \leq \theta_0$. I detta fall är θ_0 ML-skattningen i täljaren. Därför har vi att

$$\lambda(\boldsymbol{y}) = \begin{cases} 1 & \bar{y} \leq \theta_0 \\ \frac{\theta_0^{n\bar{y}}(1-\theta_0)^{n-n\bar{y}}}{\bar{y}^{n\bar{y}}(1-\bar{y})^{n-n\bar{y}}} & \bar{y} > \theta_0. \end{cases}$$

Om vi låter $Z = \sum_{i=1}^{n} Y_i$ följer det att vi förkasta H_0 om

$$\frac{\theta_0^z(1-\theta_0)^{n-z}}{(z/n)^z(1-z/n)^{n-z}} \leq c.$$

För att visa att detta är ekvivalent med att förkasta H_0 om $z > b$ för något b kan vi visa $\lambda(\boldsymbol{y})$ är en avtagande funktion av z så att $\lambda(\boldsymbol{y}) < c$ sker för $z > b > n\theta_0$. För att göra detta beräknar vi derivatan m.a.p. z av $\log(\lambda(\boldsymbol{y}))$:

$$\log(\lambda(\boldsymbol{y})) = z\log(\theta_0) + (n-z)\log(1-\theta_0) - z\log(z/n) - (n-z)\log((n-z)/n),$$

$$\frac{d}{dz}\log(\lambda(\boldsymbol{y})) = \log\left(\frac{\theta_0}{z/n} \cdot \frac{(n-z)/n}{1-\theta_0}\right).$$

Uttrycket på högre sidan är negativt för $z/n > \theta_0$, vsv.

12.5. Låt X_1, X_2 vara diskreta stokastiska variabler med möjliga utfall $\{0, \ldots, d_1 - 1\}$ respektive $\{0, \ldots, d_2 - 1\}$ för heltal $d_1, d_2 > 1$.

(a) Den simultana fördelningen för $[X_1, X_2]^{\mathrm{T}}$ där $d_1 = d_2 = 2$ parametriseras av $p_{00}, p_{01}, p_{10}, p_{11}$ där

$$p_{ij} = P(X_1 = i, X_2 = j), \quad p_{00}+p_{01}+p_{10}+p_{11} = 1 \quad \text{och} \quad p_{ij} > 0.$$

Fördelningarna som uppfyller $X_1 \perp\!\!\!\perp X_2$ kan också parametriseras av $p_0^{(1)}, p_1^{(1)}, p_0^{(2)}, p_1^{(2)}$ där

$$p_j^{(i)} = P(X_i = j), \quad p_0^{(i)}+p_1^{(i)} = 1 \quad \text{och} \quad p_0^{(i)}, p_1^{(i)} > 0 \qquad \text{för } i = 1, 2.$$

Vi observerar ett stickprov $[x_{1,1}, x_{2,1}]^{\mathrm{T}}, \ldots, [x_{1,n}, x_{2,n}]^{\mathrm{T}}$ från $[X_1, X_2]^{\mathrm{T}}$ och vi vill testa

$$H_0 : X_1 \perp\!\!\!\perp X_2 \qquad \text{mot} \qquad H_1 : X_1 \not\perp\!\!\!\perp X_2.$$

Låt

$$G^2 = 2\sum_{a=1}^{d_1}\sum_{b=1}^{d_2} u_{1,2}^{(a,b)} \log\left(\frac{u_{1,2}^{(a,b)} n}{u_1^{(a)} u_2^{(b)}}\right),$$

där $u_{1,2}^{(a,b)}$ betecknar antalet gånger $[X_1, X_2]^{\mathrm{T}} = [a, b]^{\mathrm{T}}$ dyker upp i stickprovet och $u_i^{(a)}$ betecknar antalet gånger $X_i = a$ dyker upp. Visa att likelihood-kvottestet förkastar H_0 när $G^2 \geq c$ för givet $c \in [0, \infty)$.

(b) Statistiken G^2 i del (a) kallas för G^2-*statistiken* och den är asymptotiskt fördelad som $\chi^2(f)$ med $f = (d_1 - 1)(d_2 - 1)$ frihetsgrader. Likelihood-kvottestet ovan kallas för G-*testet*. G^2-statistiken och G-testet fungerar egentligen för godtyckliga val av $d_1, d_2 > 1$. Låt $d_1 = 3$, $d_2 = 2$ och $c = 5.99 = \chi^2_{0.05}(2)$. Använd G-testet för att acceptera eller förkasta $H_0 : X_1 \perp\!\!\!\perp X_2$ enligt följande data (ges på formen (x_1, x_2)):

$$(2,1),(0,1),(2,0),(2,0),(2,1),(1,0),(1,0),(1,1),(0,0),(0,0),$$
$$(0,1),(2,0),(1,0),(2,1),(0,0),(2,0),(0,1),(2,0),(2,0),(2,0)$$

12.6. (a) Log-likelihoodfunktionen ges av

$$\begin{aligned}\ell(\nu, \theta \mid \boldsymbol{x}) &= \log L(\nu, \theta \mid \boldsymbol{x}), \\ &= n \log(\theta) + n\theta \log(\nu) - (\theta + 1) \log\left(\prod_{i=1}^{n} x_i\right), \qquad \nu \leq \min_i(x_i).\end{aligned}$$

För givet θ är $\ell(\nu, \theta \mid \boldsymbol{x})$ en växande funktion i ν för $\nu \leq \min_i(x_i)$. Därför har vi att $\hat{\nu} = \min_i(x_i)$. För att bestämma ML-skattningen för θ tar vi derivatan m.a.p. θ och sätter den lika med noll:

$$\begin{aligned}0 &= \frac{\partial}{\partial \theta} \ell(\hat{\nu}, \theta \mid \boldsymbol{x}), \\ &= \frac{n}{\theta} + n \log(\min_i(x_i)) - \log\left(\prod_{i=1}^{n} x_i\right), \\ \hat{\theta} &= \frac{n}{t}\end{aligned}$$

där

$$T = \log\left(\frac{\prod_{i=1}^{n} X_i}{\min_i(X_i)}\right).$$

Det kan verifieras att $\hat{\theta}$ är ML-skattningen med hjälp av den andra derivatan.

(b) Vi behöver beräkna likelihoodkvoten

$$\lambda(\boldsymbol{x}) = \frac{\sup_{[\nu,\theta]:\theta=1} L(\nu, \theta \mid \boldsymbol{x})}{\sup_{[\nu,\theta]\in\Omega} L(\nu, \theta \mid \boldsymbol{x})}.$$

Vi såg i del (a) att täljaren ges av $L(\min_i(x_i), 1 \mid \boldsymbol{x})$ och nämnaren ges av $L(\min_i(x_i), n/t \mid \boldsymbol{x})$. Det följer att

$$\begin{aligned}\lambda(\boldsymbol{x}) &= \frac{\frac{\min_i(x_i)^n}{\left(\prod_{i=1}^n x_i\right)^2}}{\left(\frac{n}{t}\right)^n \min_i(x_i)^{n^2/t} / \left(\prod_{i=1}^n x_i\right)^{n/t+1}}, \\ &= \left(\frac{n}{t}\right)^n \frac{e^{-t}}{(e^{-t})^{n/t}}, \\ &= \left(\frac{n}{t}\right)^n e^{-t+n}.\end{aligned}$$

Eftersom $\frac{\partial}{\partial t}\log(\lambda(\boldsymbol{x})) = \frac{n}{t} - 1$ har vi att $\lambda(\boldsymbol{x})$ är växande om $t \leq n$ och avtagande om $t \geq n$. Det följer att $\lambda(\boldsymbol{x}) \leq c$ är ekvivalent till $T \leq c_1$ eller $T \geq c_2$ för lämpligt valda c_1, c_2.

12.7. (a) Under H_0 tar vi $\theta = \mu$, så har vi likelihoodkvoten

$$\begin{aligned}\lambda(\boldsymbol{x}, \boldsymbol{y}) &= \frac{\sup_\theta \prod_{i=1}^n \theta e^{-\theta x_i} \prod_{j=1}^m \theta e^{-\theta y_j}}{\sup_{\theta,\mu} \prod_{i=1}^n \theta e^{-\theta x_i} \prod_{j=1}^m \mu e^{-\mu y_j}}, \\ &= \frac{\sup_\theta \theta^{n+m} e^{-\theta\left(\sum_{i=1}^n x_i + \sum_{j=1}^m y_j\right)}}{\sup_{\theta,\mu} \theta^n e^{-\theta \sum_{i=1}^n x_i} \mu^m e^{-\mu \sum_{j=1}^m y_j}}.\end{aligned}$$

För att beräkna ML-skattningen i täljaren:

$$\begin{aligned}0 &= \frac{d}{d\theta}\ell(\theta \mid \boldsymbol{x}, \boldsymbol{y}), \\ &= \frac{d}{d\theta}\log\left(\theta^{n+m} e^{-\theta\left(\sum_{i=1}^n x_i + \sum_{j=1}^m y_j\right)}\right), \\ &= \frac{d}{d\theta}\left((n+m)\log(\theta) - \theta\left(\sum_{i=1}^n x_i + \sum_{j=1}^m y_j\right)\right), \\ &= \frac{n+m}{\theta} - \left(\sum_{i=1}^n x_i + \sum_{j=1}^m y_j\right), \\ \hat{\theta} &= \frac{n+m}{\sum_{i=1}^n x_i + \sum_{j=1}^m y_j},\end{aligned}$$

som kan verifieras att vara ML-skattningen. På samma sätt har vi ML-skattningen för nämnaren:

$$\hat{\theta} = \frac{n}{\sum_{i=1}^n x_i}, \qquad \hat{\mu} = \frac{m}{\sum_{j=1}^m y_j}.$$

Det följer att

$$\lambda(\boldsymbol{x}, \boldsymbol{y}) = \frac{(n+m)^{n+m}}{n^n m^m} \cdot \frac{\left(\sum_{i=1}^n x_i\right)^n \left(\sum_{j=1}^m y_j\right)^m}{\left(\sum_{i=1}^n x_i + \sum_{j=1}^m y_j\right)^{n+m}}.$$

Så förkastar vi H_0 om detta värde är mindre eller lika med c.

(b) Notera att

$$\begin{aligned}\lambda(\boldsymbol{x},\boldsymbol{y}) &= \frac{(n+m)^{n+m}}{n^n m^m}\cdot\frac{\left(\sum_{i=1}^n x_i\right)^n\left(\sum_{j=1}^m y_j\right)^m}{\left(\sum_{i=1}^n x_i+\sum_{j=1}^m y_j\right)^{n+m}},\\ &= \frac{(n+m)^{n+m}}{n^n m^m}\left(\frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n x_i+\sum_{j=1}^m y_j}\right)^n\left(\frac{\sum_{j=1}^m y_j}{\sum_{i=1}^n x_i+\sum_{j=1}^m y_j}\right)^m,\\ &= \frac{(n+m)^{n+m}}{n^n m^m}T^n(1-T)^m.\end{aligned}$$

Det följer att $\lambda(\boldsymbol{x},\boldsymbol{y})$ är en funktion i T. Utöver är denna funktion unimodal och maximeras i $T = n/(m+n)$. Det följer att regeln "Förkasta om $\lambda(\boldsymbol{x},\boldsymbol{y}) \le c$" är ekvivalent till att förkasta om $T \le a$ eller $T \ge b$ där a och b är konstanter som uppfyller $a^n(1-a)^m = b^n(1-b)^n$.

(c) När H_0 stämmer har vi $\sum_{i=1}^n X_i \sim \text{Gamma}(n,\theta)$ och $\sum_{j=1}^n Y_j \sim \text{Gamma}(m,\theta)$. Så har vi att $T \sim \text{Beta}(n,m)$.

12.8. (a) Under nollhypotesen H_0 har vi att X_i:s och Y_j:s bildar ett enda stickprov av storlek $n+m$ från en $\text{N}(\mu,\sigma_0^2)$-population där $\mu = \mu_X = \mu_Y$. ML-skattningen i detta fall är då

$$\begin{aligned}\hat{\mu} &= \frac{\sum_i x_i+\sum_j y_j}{n+m} = \frac{n\bar{x}+m\bar{y}}{n+m},\\ \hat{\sigma}_0^2 &= \frac{\sum_i(x_i-\hat{\mu})^2+\sum_j(y_j-\hat{\mu})^2}{n+m}.\end{aligned}$$

För att ta fram ML-skattningen som behövs i nämnaren till $\lambda(\boldsymbol{x},\boldsymbol{y})$ betrakta vi likelihoodfunktionen

$$L(\mu_X,\mu_Y,\sigma^2 \mid \boldsymbol{x},\boldsymbol{y}) = (2\pi\sigma^2)^{-(n+m)/2}\exp\left(-\frac{1}{2\sigma^2}\left(\sum_i(x_i-\mu_X)^2+\sum_j(y_j-\mu_Y)^2\right)\right).$$

Notera först att $\hat{\mu}_X = \bar{x}$ och $\hat{\mu}_Y = \bar{y}$ eftersom dessa variabler kan maximeras oberoende. För σ^2 tar vi derivatan

$$\frac{\partial}{\partial\sigma^2}\log L(\hat{\mu}_X,\hat{\mu}_Y,\sigma^2 \mid \boldsymbol{x},\boldsymbol{y}) = -\frac{n+m}{2}\cdot\frac{1}{\sigma^2}+\frac{1}{2}\left(\sum_i(x_i-\hat{\mu}_X)^2+\sum_j(y_j-\hat{\mu}_Y)^2\right)\frac{1}{\sigma^2}$$

Sätter detta lika med noll ger

$$\hat{\sigma}^2 = \frac{1}{n+m}\left(\sum_{i=1}^n(x_i-\bar{x})^2+\sum_{j=1}^m(y_j-\bar{y})^2\right).$$

Man kan ta den andra derivatan för att verifiera att denna punkt är engentligen det globala maximat. Så har vi likelihoodkvoten

$$\begin{aligned}\lambda(\boldsymbol{x},\boldsymbol{y}) &= \frac{(2\pi\hat{\sigma}_0^2)^{-(n+m)/2}\exp\left(-\frac{1}{2\hat{\sigma}_0^2}\left(\sum_i(x_i-\bar{x})^2+\sum_j(y_j-\bar{y})^2\right)\right)}{(2\pi\hat{\sigma}^2)^{-(n+m)/2}\exp\left(-\frac{1}{2\hat{\sigma}^2}\left(\sum_i(x_i-\bar{x})^2+\sum_j(y_j-\bar{y})^2\right)\right)},\\ &= \left(\frac{\hat{\sigma}_0^2}{\hat{\sigma}^2}\right)^{-(n+m)/2}\end{aligned}$$

Så följer det att testet förkastar nollhypotesen om $\frac{\hat{\sigma}_0^2}{\hat{\sigma}^2} > k$ för något konstant k.

För att visa att test kan använda statistiken T ersätta $\hat{\mu} = (n\bar{x}+m\bar{y})/(n+m)$ i täljaren och skriva

$$\begin{aligned}\sum_{i=1}^{n}\left(x_i-\frac{n\bar{x}+m\bar{y}}{n+m})^2\right) &= \sum_{i=1}^{n}\left((x_i-\bar{x})+\left(\bar{x}-\frac{n\bar{x}+m\bar{y}}{n+m}\right)\right)^2,\\ &= \sum_{i=1}^{n}(x_i-\bar{x})^2+\frac{nm^2}{(n+m)^2}(\bar{x}-\bar{y})^2.\end{aligned}$$

Om vi gör detsamma för Y-summan får vi

$$\begin{aligned}\frac{\hat{\sigma}_0^2}{\hat{\sigma}^2} &= \frac{\sum_i(x_i-\bar{x})^2+\sum_j(y_j-\bar{y})^2+\frac{nm}{n+m}(\bar{x}-\bar{y})^2}{\hat{\sigma}^2},\\ &= n+m+\frac{nm}{n+m}\cdot\frac{(\bar{x}-\bar{y})^2}{\hat{\sigma}^2},\\ &= n+m+\frac{nm}{n+m}\cdot\frac{(\bar{x}-\bar{y})^2}{\left(\frac{n+m-2}{nm}\right)S_p^2},\\ &= n+m+\frac{nm}{n+m-2}\cdot\left(\frac{\bar{x}-\bar{y}}{\sqrt{S_p^2(1/n+1/m)}}\right)^2\end{aligned}$$

(b) Under nollhypotesen H_0 har vi att

$$T = \frac{\bar{X}-\bar{Y}}{\sqrt{S_p(1/n+1/m)}} = \frac{(\bar{X}-\bar{Y})/\sqrt{\sigma^2(1/n+1/m)}}{\sqrt{((n+m-2)S_p^2/\sigma^2/(n+m-2)}}$$

där $(\bar{X}-\bar{Y}) \sim \mathrm{N}(0,\sigma^2(1/n+1/m))$. Vi har även att $(n-1)S_X^2/\sigma^2$ och $(m-1)S_Y^2/\sigma^2$ är oberoende χ^2-variabler med $(n-1)$ respektive $(m-1)$ frihetsgrader. Så har vi att

$$(n+m-2)S_p^2/\sigma^2 = (n-1)S_X^2/\sigma^2+(m-1)S_Y^2/\sigma^2 \sim \chi^2(n+m-2).$$

Eftersom $\bar{X}-\bar{Y} \perp\!\!\!\perp S_X^2, S_Y^2$ har vi att $\bar{X}-\bar{Y} \perp\!\!\!\perp S_p^2$, och därmed $T \sim t(n+m-2)$.

(c) För den givna datan har vi $n = 14$, $\bar{x} = 1249.86$, $s_X^2 = 591.36$, $m = 9$, $\bar{y} = 1261.33$, $s_Y^2 = 176.00$ och $s_p^2 = 433.13$. Så har vi att $T = -1.29$. Detta ger ett p-värde av 0.21 enligt en $t(21)$-fördelning. Så är det rimligt att acceptera nollhypotesen.

12.9. Vi har sett ovan att det är möjligt att testa $X_1 \perp\!\!\!\perp X_2$ för två diskreta stokastiska variabler X_1 och X_2 med hjälp av hypotestest.

(a) Visa att man kan generalisera G-testet till ett test för betingat obereonde.

(b) Lös Uppgift 4.29.

(c) Lös Uppgift 4.30.

(d) Anta att vi har ett stickprov från $\boldsymbol{X} = [X_1, \ldots, X_m]^{\mathrm{T}}$ där X_i har möjliga utfall $\{0, \ldots, d_i - 1\}$ för alla $i = 1, \ldots, m$ och heltal $d_1, \ldots, d_m > 1$. Anta att $\boldsymbol{X}$ har möjliga utfall $\prod_{i=1}^m \{0, \ldots, d_i - 1\}$. Beskriva en metod för att skatta en acykliska riktad graf $\mathcal{G}$ så att $\boldsymbol{X}$ är markovsk med avseende på $\mathcal{G}$.

12.10.

$$\lambda(\boldsymbol{x}) = \frac{L(3 \mid \boldsymbol{x})}{\sup_\lambda L(\lambda \mid \boldsymbol{x})},$$

så behöver vi ML-skattningen för λ. Detta beräknas m.h.a. log-likelihoodfunktionen:

$$\begin{aligned}
\ell(\lambda \mid \boldsymbol{x}) &= \log L(\lambda \mid \boldsymbol{x}), \\
&= \log \left(\prod_{i=1}^n \frac{1}{x_i!} \right) e^{-n\lambda} \lambda^{\sum_i x_i}, \\
&= \log \left(\prod_{i=1}^n \frac{1}{x_i!} \right) - n\lambda + \log(\lambda) \sum_{i=1}^n x_i, \\
0 &= \frac{d}{d\lambda} \ell(\lambda \mid \boldsymbol{x}), \\
&= -n + \frac{1}{\lambda} \sum_{i=1}^n x_i, \\
\hat{\lambda} &= \bar{x}.
\end{aligned}$$

Det kan verifieras m.h.a. andra derivatan att denna punkt är ML-

skattningen. Så har vi likelihoodkvoten

$$\begin{aligned}\lambda(\boldsymbol{x}) &= \frac{\prod_{i=1}^{n} \frac{3^{x_i} e^{-3}}{x_i!}}{\prod_{i=1}^{n} \frac{\bar{x}^{x_i} e^{-\bar{x}}}{x_i!}}, \\ &= \prod_{i=1}^{n} \left(\frac{3}{\bar{x}}\right)^{x_i} e^{\bar{x}-3}, \\ &= \left(\frac{3}{\bar{x}}\right)^{n\bar{x}} e^{n\bar{x}-3n}.\end{aligned}$$

För den givna datan har vi $\bar{x} = 2.8$ och därför har vi $\lambda(\boldsymbol{x}) \approx 0.934 \not\leq c = 0.5$. Vi accepterar då nollhypotesen $H_0 : \lambda = 3$.

12.11. (a) Observera att

$$\lambda(\boldsymbol{x}) = \frac{L(\theta_0|\boldsymbol{x})}{\max\left(L(\theta_0|\boldsymbol{x}), L(\theta_1|\boldsymbol{x})\right)} \leq c$$

där $0 < c < 1$. Eftersom $\lambda(\boldsymbol{x}) = 1 > c$ om och endast om

$$\max\left(L(\theta_0|\boldsymbol{x}), L(\theta_1|\boldsymbol{x})\right) = L(\theta_0|\boldsymbol{x})$$

behöver vi bara att visa resultatet när

$$\max\left(L(\theta_0|\boldsymbol{x}), L(\theta_1|\boldsymbol{x})\right) = L(\theta_1|\boldsymbol{x}).$$

I detta fall har vi att

$$\begin{aligned}c \geq \lambda(\boldsymbol{x}) &= \frac{L(\theta_0|\boldsymbol{x})}{\max\left(L(\theta_0|\boldsymbol{x}), L(\theta_1|\boldsymbol{x})\right)}, \\ &= \frac{L(\theta_0|\boldsymbol{x})}{L(\theta_1|\boldsymbol{x})}, \\ &= \lambda_r(\boldsymbol{x}).\end{aligned}$$

Därför har vi att resultatet stämmer med $d = c$.

(b) För alla $c \in (0, 1)$ har vi att $\lambda_r(\boldsymbol{x}) = \lambda(\boldsymbol{x})$ när $\lambda(\boldsymbol{x}) \leq c$ och $d = c$. Det följer att dessa två test är desamma.

12.12. Vi har att $X \sim \text{Ber}(\theta)$ och $\theta \in \Omega = \{\theta_0, \theta_1\}$ där $\theta_0 = 1/2$ och

$\theta_1 = 3/4$. Vi använder då testet från uppgift 1 med testvariabeln

$$\begin{aligned}
\lambda_r(\boldsymbol{x}) &= \frac{L(\theta_0|\boldsymbol{x})}{L(\theta_1|\boldsymbol{x})}, \\
&= \frac{\prod_{i=1}^n \theta_0^{x_i}(1-\theta_0)^{1-x_i}}{\prod_{i=1}^n \theta_1^{x_i}(1-\theta_1)^{1-x_i}}, \\
&= \left(\frac{\theta_0}{\theta_1}\right)^{\sum_{i=1}^n x_i} \left(\frac{1-\theta_0}{1-\theta_1}\right)^{n-\sum_{i=1}^n x_i}, \\
&= \left(\frac{1/2}{3/4}\right)^{\sum_{i=1}^n x_i} \left(\frac{1/2}{1/4}\right)^{n-\sum_{i=1}^n x_i}, \\
&= \left(\frac{1}{3}\right)^{\sum_{i=1}^n x_i} 2^n.
\end{aligned}$$

Vi får ut testet

$$\text{Förkasta } H_0 \text{ om } \lambda_r(\boldsymbol{x}) \leq c$$

för $c \in (0,1)$. Vi kan skriver om testet enligt

$$\begin{aligned}
\left(\frac{1}{3}\right)^{\sum_{i=1}^n x_i} 2^n &\leq c, \\
\left(\frac{1}{3}\right)^{\sum_{i=1}^n x_i} &\leq \frac{c}{2^n}, \\
\left(\sum_{i=1}^n x_i\right) \log(1/3) &\leq \log(c/2^n), \\
\sum_{i=1}^n x_i &\geq \frac{\log(c/2^n)}{-\log(3)}, \\
\sum_{i=1}^n x_i &\geq c'
\end{aligned}$$

där $c' = \frac{\log(c/2^n)}{-\log(3)} \in (0, \infty)$. För att få ett test av storlek α löser vi ut c' från

$$\alpha = \max_{\theta \in \Omega_0} \beta(\theta) = \beta(\theta_0) = P(\sum_{i=1}^n X_i \geq c' | \theta_0).$$

Vi har att $n = 10$. Eftersom $Y = \sum_{i=1}^n X_i \sim \text{Bin}(10, \theta_0)$ under nollhypotesen kan vi hitta värdet c' med hjälp av fördelningsfunktionen av $\text{Bin}(10, \theta_0)$. Detta ger oss $c' = 8$.

12.13. Vi använder testet från Uppgift 12.11. Vi har testvariabeln

$$\begin{aligned}\lambda_r(\boldsymbol{x}) &= \frac{\prod_{i=1}^n \frac{e^{-\lambda_0}\lambda_0^{x_i}}{x_i!}}{\prod_{i=1}^n \frac{e^{-\lambda_1}\lambda_1^{x_i}}{x_i!}}, \\ &= \frac{e^{-n\lambda_0}\lambda_0^{\sum_{i=1}^n x_i}}{e^{-n\lambda_1}\lambda_1^{\sum_{i=1}^n x_i}}, \\ &= \left(\frac{\lambda_0}{\lambda_1}\right)^{\sum_{i=1}^n x_i} e^{-n(\lambda_0-\lambda_1)}.\end{aligned}$$

Testet förkasta H_0 om

$$\left(\frac{\lambda_0}{\lambda_1}\right)^{\sum_{i=1}^n x_i} e^{-n(\lambda_0-\lambda_1)} \leq c$$

där $c \in (0,1)$. Vi kan skriver om detta enligt

$$\left(\sum_{i=1}^n x_i\right)\log(\lambda_0/\lambda_1) - n(\lambda_0-\lambda_1) \leq c' = \log(c)$$

Eftersom λ_0 och λ_1 och $\sum_{i=1}^n X_i \sim \text{Po}(n\lambda)$ har vi att testvariabeln

$$T(\boldsymbol{X}) = \left(\sum_{i=1}^n X_i\right)\log(\lambda_0/\lambda_1) - n(\lambda_0-\lambda_1)$$

tillhör läges-skalfamiljen med standardtäthetsfunktion $f_Z(z)$ där $Z \sim \text{Po}(n\lambda)$. För att hitta ett test av storlek α betraktar vi

$$\begin{aligned}\alpha &= P(\boldsymbol{X} \in R|\theta_0), \\ &= P(T(\boldsymbol{X}) \leq c'|\theta_0), \\ &= P\left(\sum_{i=1}^n X_i \leq \frac{c'+n(\lambda_0-\lambda_1)}{\log(\lambda_0/\lambda_1)}|\theta_0\right), \\ &= P\left(Z \leq \frac{c'+n(\lambda_0-\lambda_1)}{\log(\lambda_0/\lambda_1)}|\theta_0\right).\end{aligned}$$

Om vi låter z_α beteckna α-kvantilen för $Z \sim \text{Po}(n\lambda_0)$ har vi att

$$c' = z_\alpha \log(\lambda_0/\lambda_1) - n(\lambda_0-\lambda_1)$$

ger oss ett test med storlek α.

12.14. Enligt uppgift 3 på övning 12 vet vi att en likelihood-kvottest för $H_0 : \lambda = \lambda_0$ mot $H_1 : \lambda \neq \lambda_0$ ges av

Förkasta H_0 om $(\lambda_0\bar{x})^\alpha e^{-\lambda_0\bar{x}} \leq c$ för något $c \in (0,\infty)$.

Betrakta nu en funktion på formen $f(x) = x^c e^{-x}$ där c är en positiv konstant. Vi vill visa att denna funktion är unimodal på intervallet $(0, \infty)$ med maximat i $x = c$. För att bevisa detta tar vi derivatan

$$\begin{aligned}\frac{d}{dx} f(x) &= cx^{c-1}e^{-x} + (-1)e^{-x}x^c, \\ &= x^{c-1}e^{-x}(c - x).\end{aligned}$$

Så har vi kritiska punkten $x = c$ och $x = 0$. Eftersom $f(0) = 0$ och $f(c) = c^c e^{-c} > 0$ är punkten $x = c$ kandidaten för det globala maximat. När vi tar den andra derivatan får vi

$$\begin{aligned}\frac{d^2}{dx^2} f(x) &= c(c-1)x^{c-2}e^{-x} + c(-1)e^{-x}x^{c-1} + e^{-x}x^c + (-1)ce^{-x}x^{c-1}, \\ &= e^{-x}x^{c-2}(c^2 - c - 2cx + x^2), \\ &= e^{-x}x^{c-2}((x-c)^2 - c).\end{aligned}$$

När $x = c$ är denna derivatan negativ. Så är maximat i c. När $0 < x < c$ har vi

$$\frac{d}{dx} f(x) > 0$$

och när $x > c$ har vi $\frac{d}{dx} f(x) < 0$ — vilket betyder att $f(x)$ är unimodal med maximat i c. Det följer att testet ovan är ekvivalent till

$$\text{Förkasta } H_0 \text{ om } \lambda_0\hat{\lambda} \leq a \text{ eller } \lambda_0\hat{\lambda} \geq b \text{ för } a, b \in (0, \infty) \text{ med } f(a) = f(b) = c.$$

Under nollhypotesen har vi också att

$$\lambda_0\hat{\lambda} = \lambda_0\bar{X} = \frac{\lambda_0}{n}\sum_{i=1}^{n} X_i$$

där $Y = \sum_{i=1}^{n} X_i \sim \text{Gamma}(n\alpha, \lambda_0)$. Vi vill ha därför a så att

$$0.025 = P(\lambda_0\bar{X} \leq a) = P(Y \leq an/\lambda_0).$$

och b så att

$$0.095 = P(\lambda_0\bar{X} \geq b) = 1 - P(\lambda_0\bar{X} \leq b) = 1 - P(Y \leq bn.\lambda_0)$$

Dessa värden kan hittas med hjälp av kvantiler för Y; exempelvis när $n\alpha$ är ett jämt heltal kan man beräkna de direkt från statstabellen för en χ^2-fördelning.

12.15. Likelihood-kvottestet ges av

$$\text{Förkasta } H_0 \text{ om } \bar{x} \geq c\sigma/\sqrt{n}.$$

Styrkefunktionen ges av

$$\begin{aligned}\beta(\theta) &= P\left(\bar{X} \geq \frac{c\sigma}{\sqrt{n}}|\theta\right), \\ &= P\left(\frac{\bar{X}-\theta}{\sigma/\sqrt{n}} \geq \frac{c\sigma}{\sqrt{n}} - \frac{\theta}{\sigma/\sqrt{n}}|\theta\right), \\ &= P\left(Z \geq 1.645 - \frac{\theta\sqrt{n}}{\sigma}|\theta\right) \qquad (\alpha = 0.05,\ Z \sim \mathrm{N}(0,1))\end{aligned}$$

Man kan plotta detta (som en funktion av θ) med hjälp av python för olika värden av σ och givna värdena av n.

12.16. (a) Testet T_1 har storlek $\alpha = P(X_1 > 0.95|\theta = 0) = 0.05$. Testet T_2 har storlek

$$\alpha = P(X_1 + X_2 > C|\theta = 0).$$

När $1 \leq C \leq 2$ har vi att

$$P(X_1 + X_2 > C|\theta = 0) = \int_{1-C}^{1}\int_{C-x_1}^{1} 1 dx_2 dx_1 = \frac{(2-C)^2}{2}$$

Det följer att $C = 2 - \sqrt{2\alpha}$. För $\alpha = 0.05$ har vi att $C \approx 1.68$.

(b) Låt $\beta_1(\theta)$ och $\beta_2(\theta)$ beteckna styrkefunktionen för T_1 respektive T_2. Vi har att

$$\begin{aligned}\beta_1(\theta) &= P(X_1 > 0.95|\theta), \\ &= \begin{cases} 0 & \theta \leq -0.05, \\ \theta + 0.05 & -0.05 < \theta \leq 0.95, \\ 1 & \theta > 0.95. \end{cases}\end{aligned}$$

Med hjälp av en transformation av stokastiska variabler kan vi beräkna täthetsfunktionen för $Y = X_1 + X_2$. Detta ges av

$$f_Y(y|\theta) = \begin{cases} y - 2\theta & 2\theta \leq y < 2\theta + 1, \\ 2\theta + 2 - y & 2\theta + 1 \leq y < 2\theta + 2, \\ 0 & \text{annars.} \end{cases}$$

För att hitta denna formel för $f_Y(y|\theta)$ använder vi formelen

$$f_Y(y|\theta) = \int_{-\infty}^{\infty} f_{X_1}(x_1) f_{X_2}(y - x_1) dx_1.$$

För $y < 2\theta$ har vi att $f_Y(y|\theta) = 0$ och detsamma för $y > 2 + 2\theta$. När vi betrakta fallet $2\theta \leq y < 2\theta + 1$ vet vi att

$$f_{X_1}(x_1) f_{X_2}(y - x_1) = 1$$

om och endast om $y - x_1 > \theta$ och $x_1 \geq \theta$. Detta betyder att $y \geq x_1 \geq 2\theta$ Därför har vi att

$$f_Y(y|\theta) = \int_{2\theta}^{y} 1 dx_1 = y - 2\theta \qquad \text{när } 2\theta \leq y < 2\theta + 1.$$

I fallet $2\theta + 1 \leq y < 2\theta + 2$ har vi att

$$f_Y(y|\theta) = \int_{y-\theta-1}^{\theta+1} 1 dx_1 = 2\theta + 2 - y$$

eftersom vi har att $f_Y(y|\theta) = 1$ om och endast om $x_1 \leq \theta + 1$ och $y - x_1 \leq \theta + 1$. Det följer då att

$$\begin{aligned}\beta_2(\theta) &= P(Y > C|\theta), \\ &= \begin{cases} 0 & \theta \leq (C/2) - 1, \\ (2\theta + 2 - C)^2/2 & (C/2) - 1 < \theta \leq (C-1)/2, \\ 1 - (C - 2\theta)^2/2 & (C-1)/2 < \theta \leq C/2, \\ 1 & C/2 < \theta. \end{cases}\end{aligned}$$

(c) När vi plotta styrkefunktionarna ser vi att T_1 är starkare för θ nära 0 men T_2 är starkare för större θ.

12.17. (a) Styrkefunktionen ges av

$$\begin{aligned}\beta(\theta) &= P(\boldsymbol{X} \in R|\theta), \\ &= P(|\bar{X} - \theta_0|/(\sigma/\sqrt{n}) > c|\theta), \\ &= 1 - P\left(\frac{\bar{X} - \theta_0}{\sigma/\sqrt{n}} < c|\theta\right) + P\left(\frac{|\bar{X} - \theta_0}{\sigma/\sqrt{n}} < c\right), \\ &= 1 - F_Z\left(c + \frac{\theta_0 - \theta}{\sigma/\sqrt{n}}\right) + F_Z\left(-c + \frac{\theta_0 - \theta}{\sigma/\sqrt{n}}\right)\end{aligned}$$

där $Z \sim \mathrm{N}(0, 1)$.

(b) För att bestämma testet med storlek α löser vi ut c från

$$\begin{aligned}\alpha &= \beta(\theta_0), \\ &= 1 - F_Z\left(c + \frac{\theta_0 - \theta_0}{\sigma/\sqrt{n}}\right) + F_Z\left(-c + \frac{\theta_0 - \theta_0}{\sigma/\sqrt{n}}\right), \\ &= 1 - F_Z(c) + F_Z(-c), \\ &= 2(1 - F_Z(c)), \\ F_Z(c) &= 1 - \frac{\alpha}{2}.\end{aligned}$$

Det följer att $c = z_{\alpha/2}$ – $\alpha/2$-kvantilen av $Z \sim \mathrm{N}(0, 1)$. För $\alpha = 0.05$ har vi $c = 1.96$. Med hjälp av c värdet kan vi lösa ut stickprovets storlek som i exemplet i föreläsningen.

12.18. Låt S^2 vara stickprovsvariansen för $X_1, \ldots, X_n$ som är oberoende och $\mathrm{N}(\mu, \sigma^2)$-fördelade. Ta aprioriförde lningen $\sigma^2 \sim \mathrm{InvGamma}(\alpha, \beta)$. Vi betraktar testet

$$H_0 : \sigma \leq 1 \qquad \text{mot} \qquad H_1 : \sigma > 1.$$

(a) Bestäm området där $P(\sigma \leq 1|s^2) > P(\sigma > 1|s^2)$; dvs. området där bayestestet med $0-1$-felet kommer att acceptera H_0.

(b) Jämför området i del (b) med acceptansområdet för ett likelihood-kvottest. Finns det ett val parametrar α och β så att dessa områden sammanfaller?

12.19. (a) Styrkefunktionen av testet ges av

$$\begin{aligned}
\beta(\mu) &= P(\bar{X} \geq \mu_0 + (\sigma z_\alpha/\sqrt{n})|\mu), \\
&= P\left(\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \geq (\mu_0 + (\sigma z_\alpha/\sqrt{n}) - \mu)/(\sigma/\sqrt{n})|\mu\right), \\
&= P\left(\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \geq z_\alpha - \frac{\sqrt{n}}{\sigma}(\mu-\mu_0)|\mu\right), \\
&= \int_{z_\alpha - (\sqrt{n}/\sigma)(\mu-\mu_0)}^{\infty} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}z^2} dz.
\end{aligned}$$

Vi har att $\mu - \mu_0 \leq 0$ under H_0. Därför har vi att $z_\alpha - (\sqrt{n}/\sigma)(\mu-\mu_0) \longrightarrow \infty$ då $n \longrightarrow \infty$ eftersom $z_\alpha - (\sqrt{n}/\sigma)(\mu - \mu_0) > 0$ för $\mu \in \Omega_0$. Det följer att $\beta(\mu) \longrightarrow 0$ då $n \longrightarrow \infty$ för $\mu \in \Omega_0$.

(b) När $\mu \in \Omega_1$ har vi att $\mu - \mu_0 > 0$. Därför har vi att $z_\alpha - (\sqrt{n}/\sigma)(\mu-\mu_0) \longrightarrow -\infty$ då $n \longrightarrow \infty$. Det följer att $\beta(\mu) \longrightarrow 1$ då $n \longrightarrow \infty$. Eftersom sannolikheten att ha ett fel av andra slaget är lika med $1 - \beta(\mu)$ för $\mu \in \Omega_1$ har vi att denna sannolikhet går mot 0 då $n \longrightarrow \infty$.

(c) Låt $\mu \in \Omega_1$. Vi har då att $-(\sqrt{n}/\sigma)(\mu - \mu_0) < 0$ och detta värde är fixt när vi fixar μ och n. När vi minskar $\alpha \longrightarrow 0$ har vi att $z_\alpha \longrightarrow \infty$. Det följer att $z_\alpha - (\sqrt{n}/\sigma)(\mu - \mu_0) \longrightarrow \infty$. Därför har vi att $\beta(\mu) \longrightarrow 0$ för $\mu \in \Omega_1$. Detta betyder att om vi minskar sannolikheten för ett fel av första slaget så ökar vi sannolikheten av ett fel av andra slaget (om vi har n fixt).

Det bästa sätt att minska sannolikheten att vi ha ett fel är då att öka stickprovets storlek.

12.20. Likelihood-kvottestet med nivå α ges av

$$\text{Förkasta } H_0 : \theta \geq \theta_0 \text{ om } \tfrac{\bar{x}-\theta_0}{\sigma/\sqrt{n}} < -z_\alpha.$$

Som i förgående uppgifter kan vi beräkna strykefunktionen med hjälp av en standard-normalfördelning:

$$\beta(\theta) = \int_{-\infty}^{(\sqrt{n}/\sigma)(\theta_0-\theta)-z_\alpha} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2}\, dz.$$

Som vi såg i föreläsningen har vi riskfunktionen

$$R(\theta, W(\boldsymbol{X})) = \begin{cases} c_I\beta(\theta) & \theta \in \Omega_0, \\ c_{II}(1-\beta(\theta)) & \theta \in \Omega_1 \end{cases} = \begin{cases} 8\beta(\theta) & \theta \in \Omega_0, \\ 3(1-\beta(\theta)) & \theta \in \Omega_1. \end{cases}$$

När vi plottar detta funktion ser vi att den är diskontinuerlig i θ_0. Detta beror på att vi ha olika kostnader för ett fel av första slaget och ett fel av andra slaget. Om vi förkasta H_0 när H_0 stämmer får vi en högre straff än när vi förkasta H_1 när H_1 stämmer.

12.21. Låt $X_1, \ldots, X_n$ vara oberoende och Beta$(\mu, 1)$-fördelade och $Y_1, \ldots, Y_m$ oberoende och Beta$(\theta, 1)$-fördelade. Anta också att $X_1, \ldots, X_n, Y_1, \ldots, Y_m$ är oberoende.

(a) Bestäm ett likelihood-kvottest för $H_0 : \mu = \theta$ mot $H_1 : \mu \neq \theta$.

(b) Visa att testet i del (a) kan använda testvariabeln

$$T = \frac{\sum_{i=1}^n \log(X_i)}{\sum_{i=1}^n \log(X_i) + \sum_{j=1}^m \log(Y_j)}.$$

(c) Bestäm T:s fördelning när H_0 uppfylls och visa hur man kan konstruera ett test med storlek $\alpha = 0.10$.